武汉大学

学术型硕士学位论文

基于大语言模型的端到端论辩挖掘方法研究

End-to-End Argument Mining with Large Language Models

计算机科学与技术

0914-v3 修订工作稿

2026 年 9 月 14 日

版本说明

本稿在 0914-v2 基础上澄清两项贡献的输入、操作与输出，补齐局部增强的边集合、全文回填统计及异常到动作的对应规则，并加入可复算的构造示例和评分反例。相关工作补充至本次检索可核对的 2026 年公开成果。历史实验表格数值保持不变；新增示例仅用于解释机制，不是 AAEC/CDCP 实验。本轮未改变参考项目的训练或推理算法，也未运行真实数据实验。版本差异和建议取舍详见随稿《0914_v3 评估与修改说明》。

本稿使用三个证据层次：方法定义与代码检查说明算法如何执行；明确标注的构造例检验性质和反例；原稿结果记录保留已有实验信息。构造数值不得与真实实验成绩混同。原实验日志与划分材料仍缺失，Single-Pass 的 81.67 和 77.82 及两处 Full 的 83.71 尚未绑定 run ID。附录 A 集中列出 14 项历史证据待核验事项；正文保留影响结果解释的必要提示。当前稿为研究工作稿，正式送审还需补齐实验依据，并按学院适用模板完善封面、声明、授权页、致谢与成果页。

摘要

论辩挖掘旨在从非结构化文本中识别论辩组件及其关系，恢复符合语料标注规范的论辩图。生成式大语言模型能够统一表示组件跨度、类型和有向关系，但组件识别错误会限制后续关系预测的候选空间，单次生成也可能产生错误引用和缺乏语义依据的连接。针对上述问题，本文从训练阶段的结论组件增强和推理阶段的论辩图修正两个方面研究端到端论辩挖掘方法。

在训练阶段，本文设计面向结论类组件的局部论辩结构保持增强方法。从标注训练图中选取结论节点及其入邻居，以这些节点之间的已有关系约束组件改写；将变体回填原文并更新跨度，输出类型、编号与关系拓扑保持不变的增强文档，再通过分层检查筛选。该方法针对结论表达及其关系上下文的多样性，类型条件低秩适配、线索感知连续提示和句子级辅助目标提供配套表示能力。全文回填会同时复制未改写组件，因此样本增加不等同于类别比例改善。

在推理阶段，本文提出基于完整候选图评估与异常驱动局部修正的方法 MCR-BR。多个组件假设分别生成关系，形成可供整体比较的候选图；连接覆盖、边语义连贯性和输出合法性用于选择初始图，检测到的异常用于提出类型转换、组件替换、删边或限定源节点的关系重预测。修改通过合法性及代理评分检查后接受，否则回退。这里的完整候选指同时包含组件与关系，局部修正不具有任意遗漏节点恢复能力；覆盖评分与任务正确性的偏差通过构造反例明确说明。

现有实验记录中，完整框架在 AAEC 上的 Component-F1 和 Relation-F1 分别为 83.71 和 64.83，在 CDCP 上分别为 76.45 和 38.17。在采用粗粒度组件标签及有向无标签连接的 AAEC 到 CDCP 零样本迁移设置下，完整框架的 Link-F1 为 43.21，较同骨干 Single-Pass 记录提高 9.79 个 F1 点。上述记录呈现了训练增强与推理修正相结合的应用价值；两项方法的独立增益、等计算预算优势及更广泛的迁移能力，仍需在配置核验和相应消融基础上分别确定。

关键词：论辩挖掘；大语言模型；局部结构保持增强；结论组件；候选图评估；异常驱动修正

Abstract

Argument mining reconstructs components and relations from unstructured text under corpus-specific annotation guidelines. Generative large language models can represent component spans, types, and directed relations jointly. However, component errors restrict relation prediction, while a single generation may contain invalid references or unsupported links. This thesis studies complementary training-time conclusion enhancement and inference-time graph repair for end-to-end argument mining.

For training-time enhancement, this thesis designs local structure-preserving augmentation centered on conclusion components. A conclusion and its incoming neighbors define the editable nodes, and their annotated internal relations condition paraphrasing. Rewritten components are inserted into the original document with updated spans while preserving types, identifiers, and relation topology, followed by layered filtering. Type-conditioned low-rank adaptation, cue-aware continuous prompts, and a sentence-level auxiliary objective support representation learning. Whole-document reconstruction also duplicates unchanged components, so augmentation does not necessarily improve class balance.

For inference-time repair, this thesis proposes MCR-BR. Multiple component hypotheses receive relation predictions to form complete candidate graphs. Argument-link coverage, edge-level semantic coherence, and output validity guide initial selection; detected anomalies trigger type changes, component replacement, edge removal, or relation regeneration over specified source nodes. Edits are accepted only after validity and surrogate-score checks; otherwise, they are rolled back. Complete candidates contain both components and relations, but local repair cannot generally recover missing nodes. Constructed counterexamples clarify why higher surrogate scores need not indicate more accurate extraction.

The retained records report full-framework Component-F1/Relation-F1 scores of 83.71/64.83 on AAEC and 76.45/38.17 on CDCP. Under AAEC-to-CDCP zero-shot transfer with coarse component labels and directed unlabeled links, Link-F1 is 43.21, 9.79 points above the same-backbone Single-Pass baseline. These records indicate the potential value of combining enhancement and repair. Independent gains, matched-budget advantages, and broader transferability require configuration verification and corresponding ablations.

Keywords: Argument Mining; Large Language Models; Local Structure-Preserving Augmentation; Conclusion Components; Candidate-Graph Evaluation; Anomaly-Driven Repair

目录

第一章 绪论 1

第二章 任务表示与方法基础 8

第三章 面向结论类组件的局部论辩结构保持增强 12

第四章 基于候选图评估与异常驱动局部修正的论辩图生成 20

第五章 粗粒度标签协议下的跨语料迁移分析 35

第六章 总结与展望 39

参考文献 41

附录 A 复现与证据核验清单 44

附录 B 算法修订建议 45

附录 C 修订与辅助工具使用说明 47

附录 D 新参考实现与复现实验接口 48

第一章 绪论

1.1 研究背景与问题提出

论辩挖掘研究文本中的主张、理由及其连接方式，目标不只是判断作者赞成或反对什么，还包括定位论证内容并识别论证结构。其研究对象涵盖说服性作文、公共政策评论和其他带有论证行为的文本。论辩挖掘与立场检测、论证质量评价等任务相关，但组件和关系抽取的准确性不能直接替代对论证有效性或事实真实性的评价[1]。

本文关注从原始文本到组件跨度、组件类型及有向关系的联合预测。AAEC 以学生说服性作文为对象，区分 MajorClaim、Claim 和 Premise；CDCP 以电子规则制定评论为对象，采用 Fact、Testimony、Value、Policy 和 Reference 等组件类型[2][3]。两个语料的标签不能仅凭名称直接对齐，关系拓扑也不能统一假设为树。因此，本文将图约束限定为给定实验表示下的任务约束，不将所有自然语言论辩都定义为有向无环图。

生成式建模把多个子任务映射到同一输出序列，使组件和关系能够共享上下文，但没有消除输出内部的依赖关系。例如，一个 Claim 的跨度没有被召回时，以该节点为端点的金标准关系便不能在当前候选集合中得到精确匹配；一个存在的 Claim 被赋予错误编号时，则可能形成可被确定性检查发现的引用错误。前者是候选空间不足，后者是结构一致性错误，二者需要不同的处理机制。

这一差异构成本文的研究出发点。训练阶段尝试提高结论类组件的候选质量，推理阶段保留多个结构假设并利用图级反馈进行选择和局部修改。研究重点不是证明大语言模型能够生成结构化文本，而是分析结构约束如何参与候选选择、哪些局部错误可以被修正，以及这些操作在什么条件下值得额外的计算开销。

1.2 国内外研究现状

论辩挖掘的研究路线既包括组件和关系的联合预测，也包括给定组件后的分类与推理。比较相关方法时，需要区分输入是否包含金标准跨度、输出是否覆盖全部子任务，以及评价是否采用相同端点匹配规则。以下按生成建模、结构信号、数据增强、推理修正和跨语料评价组织相关工作，并据此界定本文的研究位置。

1.2.1 组件识别与联合结构预测

Stab 和 Gurevych 围绕说服性作文建立组件与关系分析方法，为 AAEC 上的结构预测提供了任务和标注基础[2]。Eger 等将组件识别与论证结构预测纳入神经端到端学习框架，说明联合建模并非大语言模型出现后才产生的路线[4]。Morio 等研究命题级双仿射解析与任务特定参数化，支持非树状论辩结构预测[5]。这些研究表明，共享表示、子任务依赖以及树与非树结构的区别，均是已有研究问题。

组件分割仍是实际端到端系统的重要环节。Caputo 等在 2026 年提出成对标签标注方案，微调小型开放大语言模型完成细粒度组件分割，并考察自动分割对下游组件分类的影响[6]。该工作聚焦分割及其下游分类，不应被表述为已完成与本文相同的整图关系抽取评价。它提示本文需要单独分析边界错误，而不能仅依据结论类型 F1 解释组件质量。

1.2.2 生成式论辩挖掘与结构化输出

Kawarada 等将论辩挖掘表述为文本到文本生成任务，比较微调模型和提示式模型在不同语料上的表现，是本文的直接生成式基线[7]。Cabessa 等进一步将组件分类、关系识别、关系分类及其联合形式组织为文本生成任务，在 PE、AbstRCT 和 CDCP 上研究多种微调大语言模型[8]。其方法节的输出以组件类型列表及已有组件编号间的关系为核心，不包含原始文本跨度分割这一同口径评价环节，因此不能直接将其 ACC 或关系分类分数填入本文的端到端结果表。

生成表示也从直接展开标签发展到更明确的结构预测。Das 等的 AASP 将论辩结构表示为受约束的预定义动作集合，由条件语言模型自回归地逐步构建结构[9]。本文依据其 2025 年公开的 arXiv 版本讨论该方法。AASP 说明“使用动作和约束构建论辩结构”已有直接相关路线；本文的区分点在于完整候选生成后的图级评估、异常触发和局部回退，而不是动作式建模本身。

2026 年的 ARGUS 系统集成组件分割、组件分类、关系识别与关系分类，并连接符号求解器进行论辩框架分析[10]。该成果发表于 AAAI 系统演示轨道，反映了端到端工具与形式推理的结合方向，但不能据此认定其提供了与本文相同的修正算法或同协议性能比较。结合 Li 等对 LLM 论辩挖掘任务和评估的综述[11]，本文将研究重点限定为可检验的训练增强和推理修正增量，而非“采用大语言模型”这一技术选择。

1.2.3 篇章结构、语义线索与关系推理

Sun 等提出 DENIM，以篇章结构感知前缀辅助生成式端到端论辩挖掘[12]。因此，利用结构信息影响生成过程并不是本文独有的思想。本文的线索感知提示与其相邻，但信号的表示粒度、进入模型的位置及生成后是否执行局部修改不同；这种设计差异需要由对照实验解释，不能仅凭模块名称证明优越性。

2025 年的研究进一步关注结构之外的关系语义。Das 等提取关联组件对之间的关键短语，并将其纳入增强自然语言格式的生成目标；这里的关键短语表达组件之间的概念联系，不等同于固定的结论提示词表[13]。Sun 等的 FOL-AM 把组件类型和关系预测统一为基于一阶逻辑规则的关系查询，研究多跳推理及其解释路径[14]。两项工作均以已分割的组件为前提，其分类或关系结果不能直接与本文从原始文本出发的精确匹配 F1 比较。

上述工作限制了本文可以主张的创新范围：线索利用、逻辑信息和结构建模均已有先例。本文以局部子图组织训练监督，以完整候选图组织推理评估，区别在于监督单位与修改流程。第四章的逐边语义评分仍是模型判断，并未实现 FOL-AM 式多跳规则推理，也不构成论证逻辑有效性的证明。

1.2.4 结构保持数据增强

大语言模型数据增强可以通过自然语言条件控制生成内容，但样本质量、标签一致性和分布偏差仍需检验[15]。CoDa 从训练实例提取约束并通过提示生成新样本，为条件增强提供了相关路线[16]。SegMix 在任务相关片段上进行结构感知的混合增强，并在命名实体识别和关系抽取等任务上验证；它不等同于对论辩组件进行自由文本替换[17]。

在本文中，增强对象不是孤立 Claim 句子，而是结论节点及其局部支撑或攻击邻域。组件类型、关系端点与方向共同构成需保持的监督条件，表达多样性则来自允许变化的文本内容。相对于通用约束生成，可主张的改进是面向论辩关系监督的局部增强单位及其筛选方式，而不是首次提出结构感知增强。

局部拓扑保持也不等同于语义标签必然正确或类别比例自动改善。新增一个 Claim 及多个 Premise 可能同时增加高频类别，语义筛选也可能继承验证模型偏差。第三章据此区分表达多样性、类别分布和真实测试集增益；只有在等样本量或等训练预算下比较无增强、普通改写与局部结构保持增强，才能分离该设计的独立作用。

2026 年，Sun 等针对 LLM 伪标注中的组件边界和关系噪声，分别引入边界细化与关系去噪[18]。其训练数据来源与本文从已标注局部结构生成变体的路径不同，但同样说明合成监督的可靠性需要专门处理。该文的 IoU 边界评价和关系分类指标不能直接替代本文的端到端精确匹配评价。

1.2.5 约束解码、多候选评估与局部修正

语法约束解码通过限制后继 token 控制结构化输出形式，其保证范围取决于实际编码的约束[19]。JSON 可解析不意味着跨度真实、引用完整或关系成立。前述 AASP 将结构动作约束融入生成，而本文在已有候选图上开展评估与修改，二者分别侧重生成过程约束与生成后选择、调整。

Self-Refine 通过反馈和迭代修订改进输出[20]；Huang 等指出，在其研究的推理设置中，缺乏外部反馈的内在自纠错可能无效甚至降低表现[21]。自一致性则通过采样多条推理路径并聚合答案改善所研究的推理任务[22]。这些方法分别提供修订与多采样思想，但不能直接证明本文验证器的可靠性或额外计算的收益。

论辩分析领域已有更直接的候选判断研究。Tran 等针对课堂讨论设计 LLM-refine：在不同 Claim、Evidence 和 Warrant 组合下形成分割候选，再由 LLM 选择合适结果[23]。该方法处理话轮组件分割与分类，并非对包含任意有向关系的完整论辩图实施局部修正。因此，“生成多个论辩候选再评判”不能作为本文独占的创新点；本文需要强调候选对象包含组件与关系，以及异常、动作、接受条件和回退如何共同定义修正过程。

Xiao 和 Li 在 2026 年提出另一项名为 ARGUS 的研究，将 LLM 自解释转为抽象论辩框架，并以形式语义规定最小代价修复目标[24]。它与前述 Caputo 等的 AAAI 论辩挖掘系统不是同一工作，任务也不同于原文跨度和关系抽取。本文未定义这类最小代价目标或形式语义保证，因此应将 MCR-BR 定位为面向抽取的有限预算启发式修正，不主张最小修改性质。

完整图选择还应与逐节点、逐边投票区分：独立投票可能拼接出候选池中从未出现过的结构，但选择完整候选也可能保留其遗漏节点。本文以图级评分选择初始状态，再尝试异常驱动修改；评分中的软合法性项不构成硬保证，有限接受动作也不等于严格限制全部模型调用。这些边界在第四章逐项分析。

1.2.6 中文资源、跨语料迁移与研究定位

跨语料训练已有直接研究。Morio 等提出 MT-AM，利用辅助论辩语料开展端到端多任务训练，并分析不同语料之间的可迁移性[25]。这与本文只在源域训练、在目标域测试的零样本设定不同：前者利用辅助语料扩展训练，后者检验给定源域模型的迁移表现，不能仅凭“跨语料”名称视为相同实验。

Savigny 和 Yun 于 2026 年发表 AMELIA，将 19 个论辩挖掘数据集转为统一格式，并比较单任务微调、多任务微调和分别微调后的模型合并[26]。它补充了统一任务表示与训练策略这一相邻方向；本文的局部增强和测试时图修正应分别说明相对增量，统一格式本身不构成本文创新。其多任务表现不能直接证明本文单一源域的零样本迁移结论。

Feger 等在 2025 年对 17 个英文句子级数据集进行泛化评估，发现所研究模型可能依赖数据集相关词汇线索，在未见数据集上表现下降[27]。该结果来自句子级论辩识别，而非完整论辩图抽取；本文将其作为检查词汇捷径和域内外差异的依据，不据此推断 MCR-BR 已克服这些问题。对于 Cue-aware 分支，尤其需要区分线索带来的域内收益与对目标域表达的适应能力。

中文资源同样需要按任务而非语言名称归类。ORCHID 面向中文辩论的目标无关立场检测和论辩对话摘要，不是 AAEC 式全文组件与关系图抽取数据集[28]。IAM 整合多项论辩挖掘任务，使用英文资源，不能作为中文论辩语料的例证[29]。本文实验使用英文 AAEC 和 CDCP，不主张已经验证中文或多语言能力。

综合以上研究，本文的研究位置是：训练阶段以结论中心局部子图保持关系监督，推理阶段以完整候选图评估和异常驱动局部修改处理生成错误；跨语料实验用于限定方法适用范围。现有文献已覆盖生成式联合预测、结构前缀、关键短语、一阶逻辑、多候选判断及跨语料训练，故本文不作“首次结合大语言模型与论辩结构”的宽泛主张，也不在缺乏同协议比较时宣称全面优于近期方法。

1.3 研究问题与主要研究工作

本文围绕端到端论辩挖掘中的组件识别错误及其向关系预测传播的问题展开研究，分别从训练阶段的结论组件增强和推理阶段的论辩图修正两个方面提出改进方法。前者以局部结构保持增强改善组件学习，后者利用完整候选图评估和异常驱动修正调整预测结果，共同服务于组件与关系的联合抽取。二者是训练与推理阶段的互补设计，不构成验证器向生成器回传梯度的联合训练过程。

1.3.1 研究问题

RQ1：以结论为中心的局部结构保持增强，能否在不明显损害 Premise 识别的条件下改善结论跨度与类型预测？需要通过分类别 Precision、Recall 和 F1，以及增强和表示模块的独立消融回答，不能将完整系统的全部增益归于训练增强。

RQ2：在相同骨干和候选池下，完整图评估与异常驱动局部修正能否改善端到端组件和关系抽取？需要区分候选数量、选择器和修正动作的作用，并进一步与确定性后处理、通用自修正在可比计算预算下比较。

RQ3：上述方法在明确标签归约的 AAEC 到 CDCP 迁移协议下，是否仍优于相应源域训练基线？该问题限定于单向、粗粒度迁移设置，不据此推导多语言或任意领域上的稳健性。

1.3.2 主要研究工作与贡献

（1）设计结论中心的局部结构保持增强方法。输入为已标注训练文档；选取结论及其入邻居，用局部诱导子图中的关系约束组件改写，再回填全文、重算跨度并筛选，输出可用于联合抽取训练的增强文档。具体贡献在于将结论表达变化与关系标注保持连接起来。是否优于普通改写，需要在相同源文档、接受样本量及训练预算下验证；条件适配、线索提示和辅助目标作为配套模块，不分别计为独立创新。

（2）提出完整候选图评估与异常驱动局部修正方法 MCR-BR。输入为同一文档的多组预测组件及其关系；先整体评分选择初始图，再按异常对象提出有明确字段边界的动作，经过合法性及代理评分检查后接受或回退，输出最终预测图与修正轨迹。具体贡献在于整图选择与任务特定修正流程的衔接。独立收益应由固定候选池的重排序与 BR 对照确认，成本价值应由等预算比较确认；该方法不承诺最终语义正确、最小修改或补回所有遗漏节点。

（3）开展域内评估与粗粒度协议下的跨语料迁移分析。围绕 AAEC 和 CDCP 整理组件、关系、消融、验证器替换及 Oracle 结果，并通过明确组件标签归约和有向无标签连接指标分析单向迁移表现。这部分属于验证与适用性分析，不构成第三项算法创新，也不将标签映射命名为新的领域自适应方法。

表 1-1 研究问题与证据对应关系

研究问题	主要方法	现有材料	尚缺的关键证据
RQ1 结论组件质量	局部结构保持增强	分类别表与配套模块消融记录	普通改写与结构条件对照、Premise 表现、全文类别统计
RQ2 图级结构恢复	完整候选图评估与异常驱动局部修正	域内比较、评分反例、代码动作定义	固定候选池、错误修改率、评分消融与等预算比较
RQ3 跨语料适用性	粗粒度映射下的源域迁移	AAEC 到 CDCP 单向记录	同协议评价与目标数据使用记录；双向迁移属扩展

两项方法贡献描述的是本文的设计内容，不意味着其独立优越性已经由完整系统总分充分证明。现有数值记录、消融和方法分析分别承担不同证据作用：总分支持完整配置的表现，控制变量消融用于归因，形式分析用于限定可达空间与算法性质；三者不能相互替代。

1.4 论文组织结构

第一章介绍研究问题、相关工作及两项方法贡献。第二章统一任务表示、序列化规范、评价口径和训练—推理接口。第三章给出面向结论类组件的局部论辩结构保持增强方法及配套表示模块。第四章介绍完整候选图评估与异常驱动局部修正方法 MCR-BR，分析其性质并整理域内结果。第五章在粗粒度标签和有向无标签连接协议下分析跨语料迁移。第六章总结研究工作及后续验证方向。附录保留实现核验清单与待实验的算法修订建议，不将建议视为已实现方法。

第二章 任务表示与方法基础

2.1 论辩组件与关系表示

设输入文档在固定评价分词器下表示为$D=(x_1,\ldots,x_n)$。一个组件定义为$c_i=(s_i,e_i,\tau_i)$，其中$1\le s_i\le e_i\le n$，跨度采用从 1 开始的闭区间，τ_i为数据集规定的类型。评价 token 与模型内部子词 token 不是同一概念；模型输出需映射回统一评价坐标后再比较。具体分词器和映射脚本属于实验配置，不能仅靠这一数学定义确定。

组件集合记为$C=\{c_1,\ldots,c_m\}$。关系定义为(i,j,r)，其中i和j引用组件编号，方向约定为论据或攻击来源指向被支持或被攻击的目标。预测图为$G=(V,E)$，节点对应组件，边对应关系。本文的“端到端”指评价从原始文本出发、不提供金标准组件；系统内部可以包含组件生成、关系构建与验证等阶段，并不特指一次模型调用。

表 2-1 域内任务的标签与评价边界

语料	组件类型	本文域内关系标签	需要区分的属性或结构
AAEC	MajorClaim、Claim、Premise	Support、Attack	Claim 对 MajorClaim 的 stance 不混入本文关系 F1
CDCP	Fact、Testimony、Value、Policy、Reference	Reason、Evidence	允许非树状连接；需核验多片段前提的预处理

表 2-1 依据相应语料与文本到文本基线的任务说明整理[2][3][7]。AAEC 中 Claim 与 MajorClaim 的立场属性不能在缺少说明的情况下转换为 Support 或 Attack 边；因此 MajorClaim 的重要性不能直接用本文关系集合中的高连接度来论证。CDCP 的功能类型也不与 Claim/Premise 天然等价，第五章的映射是额外评测选择。

2.2 合法图与序列化约定

对实验标注规范$\mathcal{A}$，记满足跨度、类型、引用和指定拓扑条件的图集合为$\mathcal{G}_{\mathcal{A}}$。本文的无环性属于所采用实验表示的约束，不是对所有论辩语料或抽象论辩理论的定义。若预处理删除环、合并组件或简化边，应报告受影响样本及其比例，以免通过预处理改变测试任务。

在“论据指向结论”的边方向下，局部根节点的出度为 0，叶节点的入度为 0。若需要定义深度，应沿实际边方向计算叶到根路径，或明确在反向图上计算根到叶距离，不能在原图中同时采用根出度为 0 和根沿出边到达叶的定义。一个文档可能包含多个不连通子图，因此不要求每篇文档恰好一个根。

序列化规范包括唯一组件 ID、整数跨度、合法类型及关系端点。以下为人工构造的格式示例，不是实验样本。评价 token 序列为“Libraries / should / stay / open / longer / . / Students / need / study / space / .”，其中 Claim 跨度为 1 至 5，Premise 跨度为 7 至 10，后者支持前者。

```
{
  "components": [
    {"id": 1, "type": "Claim", "span": [1, 5]},
    {"id": 2, "type": "Premise", "span": [7, 10]}
  ],
  "relations": [
    {"source": 2, "target": 1, "type": "Support"}
  ]
}
```

该例只说明坐标和引用约定。它不声称所有实现均采用相同字段顺序；第三章的门控依赖字段顺序，必须另行核对实际解码配置。去重、重叠跨度消解和编号重排均应同时更新关系端点，并保留原始输出与规范化输出，以便区分生成错误和解析器造成的变化。

2.3 生成建模与参数高效适配

对序列化输出$Y=(y_1,\dots,y_L)$，自回归模型定义为：

$$P_\theta(Y\mid D)=\prod_{t=1}^{L}P_\theta(y_t\mid D,y_{<t}). \quad (2\text{-}1)$$

Transformer 通过自注意力聚合上下文信息，为序列建模提供基础[30]。本文使用的骨干为原稿所述 Qwen2.5-7B-Instruct；Qwen2.5 技术报告可用于说明模型系列，但不能代替本文具体权重版本、训练配置和硬件记录[31]。序列概率受输出长度和字段顺序影响，用于候选排序时需明确是否长度归一化；高概率并不意味着候选图中的每条关系均正确。

LoRA 在冻结基础权重的条件下引入低秩增量[32]。对于一般线性投影，采用统一表示：

$$W=W_0+\frac{\alpha}{r}BA,\ A\in\mathbb{R}^{r\times d_{in}},\ B\in\mathbb{R}^{d_{out}\times r}. \quad (2\text{-}2)$$

其中r为秩，α为缩放系数。第三章的类型条件门控是附加于这一低秩分支的任务设计，不应把 LoRA 本身描述为新提出的结构。连续提示则使用可学习向量为冻结或部分微调的模型提供任务条件，其相关基础来自参数高效提示调优研究[33]。是否启用提示、提示插入位置及其与 LoRA 共同训练的方式，均属于具体实现而非方法名称自带的性质。

2.4 候选选择与代理评分

给定候选集合$\mathcal{S}=\{S_1,\ldots,S_K\}$，重排序选择代理评分最高的候选：

$$S^{*}=arg\,max_{S\in\mathcal{S}}E(S). \quad (2\text{-}3)$$

这一过程包含两个不同问题：候选池中是否存在较好的结构，以及评分器是否能选到该结构。增加候选数可能改善前者，却不保证后者；重复候选还会增加成本而不扩大结构覆盖。Candidate Oracle 可以在预先规定的金标准指标下估计当前候选池的可利用空间，但只能作为离线诊断，不能参与测试时的实际选择。

本研究采用语义与结构混合评分。确定性检查能判断跨度越界、引用缺失等形式条件，语义验证器则判断上下文是否支持某条论辩关系。二者性质不同：前者相对于明确定义的检查规则可重复计算，后者仍受模型误判、提示和采样影响。生成器与验证器分开调用并不等于模型或知识来源独立，相关误差也不能通过调用次数自然消除。

2.5 评价指标与可比性条件

对于组件或关系集合，以TP、FP、FN分别表示正确预测、错误预测和遗漏对象的数量。总体精确率、召回率和 F1 为：

$$P=\frac{TP}{TP+FP},R=\frac{TP}{TP+FN},F_1=\frac{2TP}{2TP+FP+FN}. \quad (2\text{-}4)$$

组件评价采用跨度和类型精确匹配；关系评价要求源组件、目标组件、方向及关系类型符合预先约定的匹配规则。为避免端点类型处理差异，复现实验必须明确端点匹配是否包含类型，并对所有方法使用同一脚本。总体 micro-F1 应先汇总对象计数再计算，不能用分类别 F1 的算术平均替代。每文档 macro-F1、跨类别 macro-F1 和多次运行的均值属于不同统计量，需分别命名。

本稿公式和新增分析使用集合级精确匹配解释；原稿表格尚缺评价脚本与重复运行记录，故不据此补填其 micro/macro 配置，也不把“±”擅自解释为标准差或置信区

间。F1 数值按百分制报告，两个值相减称为“F1 点”，不称相对提升百分比。相对增幅若使用，必须另列分母。

0914-v2 新评价脚本默认将端点跨度和类型共同纳入关系匹配，不依赖组件 ID 与金标准编号相同；重复预测按多重计数保留，多余项计入 FP。解析或验证失败的文档保留，其金标准对象进入 FN，不删除失败样本；漏交或重复文档 ID 则直接报错。分母为零时返回 0 并保留计数。跨种子汇总另报告均值和样本标准差，不把该新口径追认成原表“±”的含义。

跨域 Link-F1 主动忽略关系类型，不能与域内细粒度 Relation-F1 直接比较来估计领域性能下降。结构合法率也不能代替任务 F1：删除所有关系可能消除引用错误，却同时丢失真实边。完整评价应同时关注组件和关系质量、输出合法性、错误修改风险以及推理成本。

2.6 训练增强与推理修正的接口

第三章在训练集上构造结论中心增强样本，并将其与原始样本用于组件及结构化生成学习；第四章在测试输入上调用训练后的生成器，形成多个组件假设和对应候选图，再执行选择与局部修改。两个阶段共享第二章定义的组件坐标、类型和关系引用规范，但推理阶段的验证评分不回传为训练损失，本文未定义联合优化验证器和生成器的闭环训练算法。

因此，训练增强的作用应在推理策略固定时比较，图级选择与修正的作用应在生成器检查点及候选池固定时比较。完整框架可以报告组合后的表现，但不能用同一 Full 分数分别证明两个阶段的全部独立贡献。这一接口约定也是第三、四章同名配置核对的依据。

2.7 本章小结

本章统一了组件坐标、关系方向、数据集特定约束和评价口径，并区分语法合法性、图结构一致性与语义正确性。上述定义为第三章的结论组件增强和第四章的图级修正提供共同接口，也限定了实验结果能够支持的结论范围。

第三章 面向结论类组件的局部论辩结构保持增强

端到端论辩挖掘中的组件集合限定了后续关系搜索空间；在固定组件集的关系预测设定下，遗漏 Claim 会使其关联金标准边不可达。本章据此设计面向结论类组件的局部论辩结构保持增强方法，以结论及其支撑或攻击邻域组织生成条件，在表达变化中保留类型与关系监督。Claim-specific Adapter、Cue-aware Soft Prompting 和句子级辅助目标作为配套表示模块，与增强数据共同服务于结论组件学习，不分别列为独立创新。MajorClaim 与局部 Claim 在当前关系表示中的作用不同，下文分别说明其增强条件和证据范围。

3.1 组件不平衡与结构影响

3.1.1 统计口径

设训练集组件类型集合为$\mathcal{T}$，类型τ的组件实例数为N_τ，则实例级类别不平衡比定义为：

$$IR=\frac{max_{\tau\in\mathcal{T}}N_\tau}{min_{\tau\in\mathcal{T}}N_\tau}. \quad (3\text{-}1)$$

本文以完成数据划分之后的训练集组件实例作为类别统计单位。该口径不同于 token 级 BIO 标签数和句子级标签数，不能相互替代。实例数也不能直接决定生成损失的贡献，因为不同类型组件对应的输出长度和损失归一化方式可能不同。

待核验 R01：原稿没有提供实际训练划分下各类型的实例数、增强后的数量及 IR 值。本稿保留结论类增强的研究动机，但不把未经统计的“长尾程度”或“梯度覆盖”当作已证实事实。应分别报告 MajorClaim、Claim 和 Premise 的实例数、平均跨度长度及含该类型的文档数。

在本文 AAEC 关系评价中，Claim 到 MajorClaim 的 stance 不计为关系边。因此，局部 Claim 的遗漏可直接影响其关联边召回，MajorClaim 的优化主要对应文档级类型与语境表示；二者不能共享“高连接度节点”的统一论证。

3.1.2 错误传播路径

给定金标准组件集合C和预测组件集合$\hat{C}$，关系模块若不改变组件集合，只能在$\hat{C}\times\hat{C}$上预测。令V_{hit}为按既定端点匹配规则被召回的金标准节点集合，定义可达金标准边集合：

$$E_{reach}=\{(i,j,r)\in E: i\in V_{hit}, j\in V_{hit}\}. \quad (3\text{-}2)$$

当$|E|>0$且评价要求两端点精确匹配时，关系召回率满足：

$$R_{rel}\leq\frac{|E_{reach}|}{|E|}. \quad (3\text{-}3)$$

证明：任何计为正确的预测关系，其两个端点都必须存在于当前可匹配组件集合中，因此正确关系集合是E_{reach}的子集。该上界只描述候选空间，不保证这些边能被关系模块预测正确。对多个遗漏节点，应按关联边的并集计数，避免一条边因两个端点均遗漏而重复计入损失；对于在当前关系表示中没有关联边的 MajorClaim，不能由该式推出直接的关系召回损失。

该上界对所有关系端点成立，并不单独证明 Claim 比 Premise 更值得优先增强。选择结论中心，是希望同一次改写同时约束结论表达和其关联关系；其合理性需要由训练集类型计数、关联边分布和分类别错误验证。本文据此关注结论边界与类型，以及含有标注关联边的结论节点召回；在缺少度分布统计时，不将其统一描述为高连接度节点。

3.2 结论中心的局部结构保持增强

3.2.1 局部子图作为增强单位

若文本改写仅约束句子语义而未同步维护标注，组件边界和关系方向可能失配。本文以局部论辩子图而非孤立句子作为增强单位。对训练文档图$G=(V,E)$中的结论类节点v_c，提取其一跳支撑或攻击邻域：

$$V_c=\{v_c\}\cup\{v_i/(v_i,v_c,r)\in E\}, G_c=(V_c,E_c).$$

$$E_c=\{(i,j,r)\in E: i\in V_c, j\in V_c\}.$$

邻域节点按结论的入边选取，边集合则取这些节点上的诱导子图。因此，若两个入邻居之间已有标注边，该边也属于生成条件，不能只保留指向中心的星形边。全文中恰有一个端点位于该节点集合的边称为边界边：回填时保留其端点、方向与标签，并在全文语义筛选中一并检查。结构保持指不改变已有标注，不意味着模型证明了所有未标注关系均不存在。

在 AAEC 中，局部子图按已有关系标注构造，不将 Claim—MajorClaim 立场属性转为 Support/Attack 边。无关联入边的 MajorClaim 可能形成单节点单位，其增强仅增加结论表达变体。增强模型接收所选组件文本、类型及内部关系，输出各组件的替换

文本；组件 ID、类型和全部关系由原标注保留，跨度由回填后的统一分词重新计算。

3.2.2 条件生成约束

对局部子图G_c，以下条件生成式表示所选组件文本的联合改写；实际接口按组件 ID 返回替换文本，而不是让增强模型重新预测标注：

$$D_c' = LLM_{aug}\left(D_c \mid \mathcal{T}_c, E_c, \Pi\right), \quad (3\text{-}4)$$

其中D_c为所选组件的原始文本集合，$\mathcal{T}_c$为对应组件类型，E_c为内部关系，Π为改写约束。生成必须保留各组件的论辩角色和原有含义。程序仅接受与请求 ID 完全对应的替换项，将其回填全文并重新计算跨度，不接受新增组件、类型或关系字段。所有生成来源限定为训练文档；格式检查不承担证明训练文本与测试文本完全无语义重合的功能。

为降低模板化生成造成的分布偏差，增强提示同时允许词汇替换、句法重组和论据表述变化，但不允许改变原有立场。生成仅基于训练集进行；原始文档的全部增强版本与原文保持在同一数据划分中，防止同源样本跨集合泄漏。

3.2.3 三层质量筛选

对生成样本(D_c', G_c')依次执行三层筛选：

1. **格式合法性**：JSON 可解析、必需字段存在、组件编号唯一且跨度位于文本范围内；

2. **结构一致性**：组件数量、类型集合和关系方向满足给定模板，且不存在悬空引用和循环边；

3. **语义一致性**：单独调用验证器检查回填后的全文、组件角色和关系，包含因局部改写而可能受影响的边界边。该检查是模型判断，仍需人工抽检。

定义三个二值检查函数q_{fmt}、q_{str}和q_{sem}，样本接受条件为：

$$q\left(D_c', G_c'\right) = q_{fmt} \cdot q_{str} \cdot q_{sem} = 1. \quad (3\text{-}5)$$

三层筛选分别检查格式、标注结构与语义合理性。第三层的单独调用不等于独立模型、独立知识来源或人工验证。新参考实现由程序保留原关系表并检查全文语义；若局部改写损害边界边，应拒绝整个变体。验证器仍可能漏判，因此需报告边界边样本的人工抽检情况。

3.2.4 增强效果的可识别性与数据追踪

类别计数必须与训练实例的组织方式一致。仅当局部单位单独作为训练实例，且每个变体恰含一个 Claim 和k个 Premise 时，接受u个变体才对应N_C+u和N_P+ku；在$u>0$且计数分母为正时，Claim/Premise 比提高当且仅当$N_P>k\,N_C$。这一条件不能直接用于全文回填方案。

新参考实现每接受一个变体便增加一篇完整文档。设训练文档d含类型τ的组件数为$N_{d,\tau}$，该文档最终接受的变体数为a_d，则增强后计数应为：

$$N_\tau' = N_\tau + \sum_d a_d N_{d,\tau}.$$

若每篇源文档接受相同数量的变体，则各类实例数按相同比例增加，IR 不变；若接受数不同，类别比例变化来自源文档的重复权重及筛选结果。结论中心决定改写位置，不意味着只有结论进入新增训练样本。类别分布、表达多样性和测试效果因此需要分别统计。

MajorClaim 在不包含 stance 边的 AAEC 表示中可能形成单节点增强单位。这时只能声称增强了结论表达，不能声称保留了原本不存在的关系监督。局部子图文本若单独作为训练实例，需要说明输入上下文与测试时整篇输入的差异；若回填原文，则必须重新分词、更新所有受影响跨度及引用。两种路径不能在方法与实验之间混用。

待核验 R02：需补充增强模型名称与版本、完整提示、每个种子子图的尝试数、三层筛选各自通过数、去重规则、原始与增强样本混合比例，以及局部文本回填方式。不得使用测试集标签调节筛选阈值。建议为每个增强样本保留源文档 ID、源组件 ID、生成配置、拒绝原因和坐标映射，以支持训练集去重与错误追踪。

新参考实现将上述要求落实为训练集专用接口：按结论及入邻居构造局部单位，使用固定组件槽位改写并回填全文，随后重算所有受位移影响的跨度，保持类型、ID 和关系拓扑。默认每文档最多 4 个单位、每单位 2 次尝试、最多保留 1 个变体；通过格式、结构与模型语义筛选后再执行全局文本去重，实际混合比由输出统计。plain 对照只隐藏生成提示中的局部边，保持槽位及后续筛选相同，用于隔离结构条件的作用；它不等同于任一外部增强方法的复现。这些是新计划，尚无真实筛选计数和人工审计结果。

3.2.5 全文回填的构造示例

下面的文本和标注为人工构造，仅用于解释接口。原文为“Libraries should stay open longer. Students need study space. Campus services need investment.”。按 2.1 节坐

标，组件 1 是 Claim，跨度[1,5]；组件 2 是 Premise，跨度[7,10]；组件 3 是 Claim，跨度[12,15]。设标注包含 Support 边 2→1 和 2→3。

以组件 1 为中心时，选取组件 1 与 2，内部关系为 2→1；2→3 是边界边。将前两组件改写为“Libraries ought to remain open longer”和“Students require space for studying”，组件 3 文本保持不变。回填后的三个跨度分别为[1,6]、[8,12]和[14,17]，关系仍为 2→1 和 2→3。组件 3 虽然没有被改写，也因前文长度变化而更新坐标，并随完整文档再次进入训练。

该例说明需要同时做到文本回填、全体跨度更新和边界边复查。即使 ID 与边表完全相同，若把组件 2 改写为“不需要学习空间”，关系语义仍可能改变；确定性拓扑检查无法单独排除这类问题。

3.3 面向结论组件的配套表示增强

本节的适配器、连续提示和辅助目标用于利用前节的训练监督，属于结论组件增强方案的配套实现。与 DENIM 的篇章结构前缀[12]和关联关键短语方法[13]相比，本文关注结论类型条件和显式线索触发，而不将结构或线索的使用本身视为原创。三项模块的作用需分别通过受控消融解释。

3.3.1 Claim-specific Adapter

原稿提出在注意力投影层注入类型条件低秩分支。为明确 0914-v2 新参考实现，本节将全局分支与结论分支分别记为下标 g 和 c，对基础权重W_0和隐藏状态h_t写为：

$$h_t' = W_0 h_t + \frac{\alpha}{r} B_g A_g h_t + g_t \frac{\alpha}{r} B_c A_c h_t, \quad (3\text{-}6)$$

式中为说明方便写作等输入输出维度d；一般投影的矩阵维度按第二章定义。原稿给出的参数为$r=16$、$\alpha=32$，$g_t \in \{0,1\}$表示生成状态门控。原稿将门控描述为依赖 JSON 状态和已经生成的标签前缀，不读取测试金标准标签。

待核验 R03：这一描述尚不能确定可执行门控。如果类型值的首个 token 尚未生成，不能提前依据该类型是否为 Claim 决定门控；如果 span 字段先于 type 字段生成，后续类型分支也不能回溯改变已生成跨度。教师强制训练时也应避免把当前位置尚不可见的金标准类型作为推理时不可获得的门控信号。

新实现固定 id、type、span 的字段顺序。门控仅在已生成前缀包含完整闭合的结论类型后开启，在当前组件对象结束时关闭；类型首 token 与关系区域均不开启条件分支。AAEC 触发类型为 Claim/MajorClaim，CDCP 为 Policy/Value。教师强制同样只

使用当前位置可见前缀，不读取未来类型。基础全局 LoRA 与专项 LoRA 共同存在，并提供单一全局 rank32 对照以匹配两条 rank16 分支的 LoRA 参数量；参数相近不等于计算量相同。该定义通过因果前缀测试，但不能证明其改善边界或减少梯度覆盖，也不能将旧分数沿用为这一新实现的结果。

该因果门控更准确的含义是“已生成结论类型条件下的后续字段适配”。它在当前类型闭合后才开启，不能直接利用该类型去纠正同一组件已经输出的类型字段；后续 span 生成会受该分支影响。对类型 F1 的可能作用只能来自共享参数训练或后续上下文等间接路径，不能把分类别分数提高直接解释为门控当场纠正了类型。

3.3.2 Cue-aware Soft Prompting

显式篇章线索可作为结论识别的候选信号，但线索词与组件类型并非一一对应，其实际收益需由消融验证。本文首先在输入中检测预定义线索，
如“therefore”“thus”“in conclusion”等，再向输入表示附加$m=4$个可学习连续提示向量：

$$X'=[P_1,P_2,\ldots,P_m;X], \quad (3\text{-}7)$$

其中$P_i\in\mathbb{R}^d$为可训练提示向量。线索检测仅控制提示分支是否启用，最终组件边界与类型仍由上下文模型联合判断，从而避免把词典匹配直接等同于结论标签。对于未出现显式线索的隐式结论，模型仍可依赖正文语义和辅助目标进行预测。

新实现的完整词典为 therefore、thus、in conclusion、consequently、hence、to conclude，采用不区分大小写的词边界匹配；触发时在聊天模板输入嵌入之前插入 4 个可训练向量，无触发时不插入占位向量。该词典及插入位置为本次新增定义，原实验是否相同仍待核验。

3.3.3 多目标训练

以下公式明确新参考实现的归一化方式：生成项对单个任务样本的有效回答 token（含 EOS）求均值，提示 token 不参与生成损失。设有效输出长度为T_y，则：

$$\mathcal{L}_{gen}=-\frac{1}{T_y}\sum_{t=1}^{T_y}\log P(y_t\mid D,y_{<t}). \quad (3\text{-}8)$$

新实现按句末标点及文本结尾确定性切分输入，使用最后一层输入原文 token 的句内均值表示和线性二分类头，不池化输出标签。设输入句子数为N_s，与结论类金标准跨度有重叠的句子标签$z_i=1$，否则为 0；跨句组件可标记多个句子。AAEC 结论类为 MajorClaim/Claim，CDCP 为 Policy/Value。辅助项为：

$$\mathcal{L}_{sat}=-\frac{1}{N_s}\sum_{i=1}^{N_s}\left[z_i\log\hat{z}_i+(1-z_i)\log(1-\hat{z}_i)\right]. \quad (3\text{-}9)$$

联合目标为：

$$\mathcal{L}_{comp}=\mathcal{L}_{gen}+\lambda\mathcal{L}_{sat},\lambda=0.5. \quad (3\text{-}10)$$

辅助目标只参与训练，推理时不增加 JSON 字段。此处$\lambda=0.5$是两项样本内均值的权重，不是两个未归一化总和的固定比例。原稿公式为求和且没有代码佐证，本次改为均值是新实验协议选择，不构成原损失实现已经核实的结论。梯度累积按任务样本求均值，最后不足一个累积批次时按实际样本数归一化。

待核验 R04：上述新定义已写入参考代码并进行小模型测试，但原始实验采用的句子切分、池化、loss mask、归一化、词典和提示位置仍不可追溯；无显式线索样本的真实效果也尚未测量。重新训练后应报告这些选择及其消融，不能仅删除待核验标记。

3.4 实验设置与结果分析

3.4.1 设置与评价指标

实验采用 Qwen2.5-7B-Instruct 作为骨干模型，并使用 LoRA 进行参数高效微调。组件评价采用边界和类型同时精确匹配的 F1；除整体 Component-F1 外，分别报告 MajorClaim-F1 和 Claim-F1，以避免总体指标被高频类别主导。所有增强样本均由训练集产生，验证集用于模型选择和超参数确定，测试集仅用于最终评价。

表 3-1 暂作为原稿分类别结果记录保留，不能独立确认训练增强的净贡献：本表 Single-Pass 的 Comp-F1 为 81.67，而第四章同名记录为 77.82；本表 Full 的 83.71 又与第四章包含推理修正的 Full 相同。需根据 run ID 确认是否使用相同训练数据、检查点、推理预算和评价脚本，再决定拆表或更正名称。本稿不从两个冲突值中任选其一。

待核验 R05：本表配置对应关系以及外部基线分类别分数来源未确定。

3.4.2 主要结果

表 3-1 AAEC 组件分类别结果原稿记录

方法	MajorClaim-F1	Claim-F1	Comp-F1
FLAN-T5 (XXL)	71.23	76.45	80.15
LLM Single-Pass	73.45	78.21	81.67
Ours (Full)	**77.34**	**81.77**	**83.71**

按表内数值相减，Full 相对本表 Single-Pass 的 MajorClaim-F1、Claim-F1 和 Component-F1 差值分别为 3.89、3.56 和 2.04 个 F1 点；相对 FLAN-T5 (XXL)的整体差值为 3.56 个点。这些是算术差值，不是已完成配置控制的因果归因。当前没有 Premise 分类结果、组件 Precision 与 Recall 或错误混淆矩阵，不能据此排除对高频类别的损害，也不能把各类别 F1 与总体 F1 的差值直接解释为贡献比例。

3.4.3 模块作用与解释边界

第四章的完整消融结果显示，移除 Claim-specific Adapter 后 Component-F1 下降 1.75 个点，移除 Cue-aware Soft Prompting 后下降 1.37 个点，移除辅助目标后下降 0.82 个点。由于各模块共享训练数据和生成器参数，消融差值反映的是“在其他模块保留条件下”的边际影响，不应将多个差值简单相加解释为总增益。

结构感知数据增强的独立效果还应同时结合合成样本通过率、人工抽检一致性和真实测试集性能判断。本文不以生成样本数量本身作为有效性证据，而以未参与增强的测试集表现作为主要依据。

3.5 误差类型与讨论

结论组件学习需要重点检验以下三类潜在错误；当前缺少逐例输出，尚不将其视为已完成标注的错误分布。第一，隐式结论没有显式线索词，Cue-aware 分支难以提供额外信息；第二，一个长句同时包含论据和结论时，模型容易扩大组件边界；第三，MajorClaim 与 Claim 语义相近，模型可能在类型之间混淆。前两类错误需要更细粒度的边界建模，第三类错误则说明仅依赖局部语义不足，还需要结合文档级位置和段落结构。

本章方法以改善候选组件质量为目标；其净效果仍需消除表格配置冲突后验证。下一章进一步保留多个组件假设，并利用完整关系结构对候选进行重排序和局部修复，以分析仅改变训练阶段之外的恢复空间。

3.6 本章小结

本章以结论中心局部子图保持组件类型及关系监督，并以条件适配、线索提示和辅助目标配合学习。与孤立改写相比，差异在于显式保留局部关系；独立收益仍需等预算对照。新代码已明确门控规则，但原稿分类别结果的配置、Premise 表现与有效性证据仍待核验。

第四章 基于候选图评估与异常驱动局部修正的论辩图生成

本章提出基于完整候选图评估与异常驱动局部修正的 MCR-BR 方法。其评估对象包含组件和关系，先为多个组件假设构建完整图，再以结构检查和单独调用的语义验证信号选择初始状态；检测到的异常触发局部动作，并通过接受检查、回退、轮数和接受动作数限制控制修改。完整流程包括候选组件生成、候选图构建、一致性评分、初始解选择、异常检测和有界局部修正六个阶段。这里的“有界”特指所定义的修正步数约束，不代表已给出全部生成与验证调用的严格上界。

4.1 单次生成的错误传播与恢复目标

单次生成系统直接输出一个组件列表和关系列表。一旦组件被遗漏、边界偏移或编号错误，后续关系便可能出现悬空引用、孤立节点和错误连接。仅删除非法边的后处理不能补回缺失组件；自由生成式修订则可能同时改变正确结构。MCR-BR 据此限定修改对象和接受条件，但其当前动作集合同样不提供一般性的缺失节点插入能力。

原稿记录的 AAEC 修正触发率为 42.5%，修正前无效组件引用比例为 18.5%，JSON 格式错误比例为 6.2%，验证器判定的不连贯边比例为 22.4%。这些指标的分母可能分别是文档、引用或关系边，不能相加为总体错误率。触发率还依赖异常阈值，不等于经人工确认的错误文档比例。

可解析性由候选生成与解析阶段处理，图级 BR 只接收已经解析为组件和关系对象的候选。其恢复目标是调整引用、边界或类型错误，以及验证器指出的边语义和连接覆盖问题。覆盖不足只是预设软偏好，未带显式理由的合法 Claim 也可能触发它。

4.2 多候选组件生成与完整图构建

4.2.1 候选组件集合

给定文档D，模型不立即提交单一结果，而是通过温度采样和提示改写生成K个组件候选集：

$$\mathscr{C}=\{C^{(1)},C^{(2)},\ldots,C^{(K)}\}. \quad (4\text{-}1)$$

每个$C^{(k)}$包含组件跨度和类型。生成结果使用统一 JSON Schema 解析。原稿提出按模型置信度、跨度长度和文本位置消解重叠，但未给出排序优先级、置信度定义和并列处理规则，故目前尚不是可复现的确定性算法；待核验 R06 要求同时保存消解前

后结果及端点重映射。候选的目的不是重复采样相同输出，而是保留在组件边界、类型或遗漏节点上存在差异的竞争假设。

新实现不臆测置信度消解顺序：保留原始输出，严格解析后不自动改写重叠跨度或重排 ID，形式违规进入合法性检查；无法解析的候选明确记为失败。关系阶段要求原样复制固定组件，若模型改变组件则拒绝该候选。该处理不同于尚未明确的旧规范化算法，后续与外部方法比较必须使用相同协议。

4.2.2 候选论辩图构建

对每个组件候选集$C^{(k)}$，关系模块在有效组件编号之间预测关系集合$R^{(k)}$，得到完整候选结构：

$$S_k=\left(C^{(k)},R^{(k)},G^{(k)}\right),G^{(k)}=\left(V^{(k)},E^{(k)}\right). \quad (4\text{-}2)$$

关系预测的目标是只引用$C^{(k)}$中存在的组件。若这一限制通过每一步解码的硬约束实施，且后处理不破坏映射，则该阶段不应再产生悬空 ID；仅在提示中列出 ID 不构成同样的保证。原稿残余无效 ID 记录与约束阶段的关系须在日志中核对。AAEC 关系标签为 Support/Attack；CDCP 域内实验保留 Reason/Evidence；跨领域实验映射为有向 Link。

以下流程整理原稿的模块关系，不代表新增实验或新增修复动作。

图 4-1 MCR-BR 候选选择与局部修正流程

原始文档

↓ 组件生成与规范化

K 个组件候选

↓ 对每个候选预测关系

K 个完整候选图

↓ 合法性检查与语义验证

候选评分与初始图选择

↓ 检测异常并尝试局部动作

接受或回退 → 终止判断 → 输出图

新参考实现对 JSON 或必需字段解析失败的候选标记失败并跳过，不把它交给图级 BR，也不在该槽位内自动重试。后续槽位可以在总预算内继续生成；若没有可解析候选，返回明确失败，评价时保留该文档及其金标准对象。失败调用仍计入成本。

因而原表 JSON 错误从 6.2%到 0.0%的变化，在阶段和分母未明确前不能归因于四类图修改动作。

4.3 一致性引导的候选评分

综合评分函数定义为：

$$E(S_k)=\alpha E_{dens}(S_k)+\beta E_{coh}(S_k)+\gamma E_{val}(S_k), \quad (4\text{-}3)$$

其中$\alpha=0.4$、$\beta=0.4$、$\gamma=0.2$。三个分量均归一化到$[0,1]$，分别评价论证连接覆盖、边语义连贯性和输出合法性。其中覆盖分数只是对预测图的启发式偏好，不是相对于金标准的完整性度量。

4.3.1 论证连接覆盖

令$\mathcal{Q}(S_k)$为根据预设规则从预测组件中选出的覆盖评价节点集合，不使用测试金标准确定该集合。在 AAEC 中不要求文档级 MajorClaim 具有关系入边。集合成员的具体选择规则需与实现一起公开；若按已有入边选择，就可能漏掉本应诊断的孤立节点。验证器对边(i,j,r_{ij})返回$p_{ij}\in\{0,1\}$，结论节点v_j的通过验证的入边数为：

$$d_{coh}^{in}(v_j)=\sum_{(i,j,r_{ij})\in R^{(k)}} p_{ij}. \quad (4\text{-}4)$$

论证连接覆盖得分为：

$$E_{dens}(S_k)=\begin{cases}\dfrac{1}{|\mathcal{Q}(S_k)|}\sum_{v_j\in\mathcal{Q}(S_k)} min\left(\dfrac{d_{coh}^{in}(v_j)}{\tau(t_j)},1\right), & |\mathcal{Q}(S_k)|>0,\\ 0, & |\mathcal{Q}(S_k)|=0.\end{cases} \quad (4\text{-}5)$$

其中$\tau(t_j)$是原稿设置的期望连接数；此处t_j应理解为节点结构角色，而非只含组件类别的τ_j。原稿给出顶层关系结论节点取 2、其他评价节点取 1，但未给出角色识别和阈值选择记录，均需核验。此计数包含通过验证的 Attack 边，故称“论证连接”而非“支持证据数量”。它不测量前提的事实真实性，也不要求所有合法 Claim 必须至少有两条理由。

该分量是软偏好，不直接删除低入度节点。但它依赖预测的$\mathcal{Q}$，遗漏难以满足阈值的结论节点反而可能抬高平均分；因此高覆盖得分也可能与低组件召回并存。需用固定候选池比较移除该项后的 F1、预测边数和孤立节点分布，检查其是否诱导过连边或过删节点。

新参考实现将评价节点固定为 AAEC 的 Claim 及 CDCP 的 Policy/Value；节点在预测图中无出边时按顶层角色取阈值 2，否则取 1，空评价集合得分为 0。这一确定规则使新代码可执行，但是否对应原稿角色判定并无证据。新实现默认生成器与验证器共享同一检查点，仅使用不同提示；判断缓存绑定文本、关系上下文和模型身份，不把两次调用称为独立验证。

4.3.2 语义连贯性

对每条预测边，验证器结合源组件、目标组件、关系类型和上下文判断关系是否成立。语义连贯性得分为：

$$E_{coh}(S_k)=\begin{cases}\dfrac{1}{|R^{(k)}|}\sum_{(i,j,r_{ij})\in R^{(k)}} p_{ij}, & |R^{(k)}|>0,\\ 0, & |R^{(k)}|=0.\end{cases} \tag{4-6}$$

该得分与生成模型的序列概率不同：序列概率衡量输出在生成模型下是否常见，而E_{coh}专门判断边是否得到当前上下文支持。

覆盖分量和连贯性分量复用同一组边判断p_{ij}：前者按目标节点聚合，后者按预测边求平均。二者分别表达连接分布与边级通过比例，但不是两份独立语义证据。组合加权可能重复放大同一次验证错误，需要在固定候选池上分别移除覆盖项与连贯性项，观察最终 F1 及边数变化。

4.3.3 输出合法性

若候选通过全部确定性检查，则$E_{val}(S_k)=1$，否则为 0。检查项目包括 JSON 可解析性、必需字段完整性、token 跨度合法性、组件编号引用完整性、自环与结构环检测，以及数据集 Schema 允许的组件和关系类型。约束解码只能保证部分语法条件，无法替代跨度、引用和拓扑检查。

最终选择：

$$k^{*}=arg\,max_{1\le k\le K} E(S_k), S^{(0)}=S_{k^{*}}. \tag{4-7}$$

4.4 图约束下的有界局部修正

4.4.1 异常表示与优先级

对当前图S，错误检测器返回异常集合：

$$\mathcal{E}(S)=\{e=(v,\eta,\sigma)\},\quad (4\text{-}8)$$

其中$v\in\{VAL,COH,DENS\}$表示图合法性、边语义连贯性或连接覆盖不足异常，η表示受影响的节点或边，$\sigma\in[0,1]$表示严重度。严重度定义为：

$$\sigma(e)=\begin{cases}1, & v=VAL,\\ 1-p_{ij}, & v=COH,\eta=(i,j),\\ 1-\min\left(\dfrac{d_{coh}^{in}(v_j)}{\tau(t_j)},1\right), & v=DENS,\eta=j.\end{cases}\quad (4\text{-}9)$$

异常按严重度降序排列，同分时采用$VAL\succ COH\succ DENS$。有效性错误和被验证器拒绝的边直接触发修复。原稿“低于$\delta_{dens}=1.0$”应针对节点覆盖值$\min(d_{coh}^{in}/\tau,1)$解释，相应严重度为$1$减覆盖值，不能反过来把低严重度解释为需要修正。待核验 R07：阈值比较方向须与实际代码核对，本稿不据此认定旧实验已使用该解释。

4.4.2 修复动作

BR 定义四类局部动作：

1. **Promote/Demote**：在标注规范允许的结论类类型之间转换，例如 MajorClaim 与 Claim；

2. **Replace**：从其他候选集中选择与问题位置对应的替代跨度或组件类型；

3. **RemoveEdge**：删除验证器拒绝且删除后不产生新引用错误的边；

4. **LocalRerun**：固定当前组件集合，仅对受影响源节点的关系进行约束重预测，目标编号限定在有效组件集合内。

对候选动作a，记执行后的结构为$a(S)$。接受条件为：

$$Accept(a,S)=\mathbb{I}[a(S)\in\mathcal{G}_{\mathcal{A}}]\cdot\mathbb{I}[E(a(S))\geq E(S)].\quad (4\text{-}10)$$

因此，每次被接受的动作产生的图满足规定合法性检查，且在评分可重复的前提下不降低该代理评分；不满足条件的动作回退。这是对被接受后状态的性质，不保证初始图合法，也不保证最终一定合法。

Replace 在原稿中定义为替换已有位置的跨度或类型，并没有明确定义插入缺失节点。如果其实现不改变节点数量，不能据此声称找回所有遗漏 Claim；LocalRerun 固定组件集合，也不能补节点。Promote/Demote 改变类型后须同步重查允许的边类型和拓扑，尤其不能把 AAEC 的 stance 隐式转换为关系边。待核验 R08：四类动作需补充前置条件、受影响字段、坐标和 ID 更新规则及失败返回值。

表 4-1 新参考实现中的异常与动作对应

异常对象	候选动作与顺序	字段范围与执行限制
边级 VAL 或 COH	先 RemoveEdge，再 LocalRerun	删当前边；或重预测该边源节点的全部出边，源节点须存在
节点级 VAL	类型转换、Replace、LocalRerun	类型转换限 AAEC Claim/MajorClaim；Replace 保留当前 ID 与节点数
节点级 DENS	类型转换、Replace、LocalRerun	重预测源集合为当前图中除该目标外的全部节点，不插入组件
JSON 或字段无法解析	无图级动作	候选阶段记失败并跳过，不进入 BR

表 4-1 是参考代码的执行说明，不是已证明最优的动作顺序。Replace 按候选池中与当前跨度有交集的组件产生替代项，依跨度交并比降序、起止位置及类型排序；没有交集的遗漏组件不能因此被插入。ID 重复等问题也可能无法被现有保留 ID 的动作修好，此时保留失败原因而非宣称动作完备。

LocalRerun 固定全部组件，只替换指定源节点的出边，其余出边保留；目标可为当前任一有效组件，随后检查引用、自环和其他约束。对 DENS 异常，当前实现选择除问题目标以外的全部节点作为源集合，修改范围可能接近全图关系重预测。因此“局部”只说明字段和源集合受到限制，不保证修改只在目标的一跳邻域内；每异常最多 4 个动作候选还可能使排序靠后的 LocalRerun 未被尝试。

4.4.3 终止条件与计算预算

原稿设置最多执行$T=3$轮，每轮最多接受$M=2$个动作。以下为保留原语义的伪代码；GenerateActions 需返回有限序列，模型调用需有超时或解码上限，否则仅靠外层预算不足以保证整个程序终止。

算法 4-1 原稿有界修正流程及其接口要求

输入：候选图集合 {S1,...,SK}，最大轮数 T，每轮动作预算 M

输出：修正后的论辩图 S

```
S ← argmax E(Sk)
for t = 1,...,T:
    errors ← DetectErrors(S)
    if errors 中不存在触发项:
        break
    accepted ← 0
    for e in SortBySeverity(errors):
        for a in GenerateActions(e, candidate_pool):
            S' ← a(S)
            if Valid(S') and E(S') ≥ E(S):
                S ← S'
                accepted ← accepted + 1
                break
        if accepted = M:
            break
    if accepted = 0:
        break
return S
```

算法在三种情况下退出外层迭代：不存在触发异常、当前动作空间中没有可接受修改、轮数预算耗尽。在动作生成有限且每次调用终止的前提下，总接受动作数不超过$T\,M=6$。这一界限不约束被拒绝的尝试次数，不能据此声称最多发生 6 次额外模型调用。

新参考实现补充每文档最多 24 次动作尝试、每异常最多 4 个动作候选、全部生成及验证合计最多 128 次调用、累计最多 32768 个输出 token；普通单次生成上限 1024，边级判断上限 32。拒绝和失败调用均入账；复用候选池也保留候选生成的逻辑成本，实际新增调用另列。每次接受后更新异常并记录访问状态，避免等分往返。预算耗尽时保留最后已接受图或返回显式失败，不填入未验证输出。以上默认值是新工程配置，尚未由验证集成本曲线确定，也不提供硬墙钟超时保证。

4.4.4 代理目标与可恢复性分析

命题一：若验证器结果固定或缓存，评分函数固定，且每次仅接受$E(S')\geq E(S)$的动作，则被接受状态的评分序列单调不降。证明由接受条件逐次应用直接得到。若逐次重新随机调用验证器而不固定结果，同一图的分数也可能变化，因而这一命题的前提不再成立。由于评分范围有界，这一数值性质不意味着在有限时间达到全局最优，也不意味着 Relation-F1 单调提高；本文的停止依据仍是显式预算与有限动作空间。

命题二：软合法性加权不能保证初始选择合法。按原稿权重，一个非法图若覆盖与连贯性都为 1，可得 0.8；一个合法图若两项都为 0.5，则得 0.6。最大加权分可能选中非法图。这是由评分式构造的反例，不是实际测试样本。

命题三：全图合法后才接受的条件可能阻碍逐步修复。若初始图有两个独立无效引用，一次局部动作只修复其中一个，修改后的图仍不合法，因此被拒绝；即使两步组合能得到合法图，当前一步式接受规则也不一定能走到该状态。原稿同时报告残余无效 ID，因此不能宣称 BR 保证最终输出全部合法。

反例四：改变覆盖集合可以提高代理分数而损害组件预测。构造含两个 Claim 和两个 Premise 的合法图，Claim 1 孤立，两个 Premise 均以通过验证的 Support 边指向 Claim 2。两 Claim 均无出边，阈值为 2，因此覆盖分数为 0.5，连贯性与合法性均为 1，总分为 0.8。仅将孤立 Claim 1 改为 MajorClaim 后，它退出覆盖集合，覆盖分数升至 1，总分升至 1；边集没有变化。该动作满足当前合法性和非下降接受条件，且位于 DENS 动作序列前部。

若构造金标准中四个节点原本均正确，该修改使组件精确匹配 F1 由 100 降至 75，关系 F1 保持 100。数值来自同一构造图的确定性计数，不是测试集成绩。它证明当前接受规则不能排除这类错误修改，不能推断其在真实数据中的发生频率。修正方向及所需对照列于附录 B.5。

上述分析说明，现有方法的可陈述保证是“有限前提下的步数界”和“固定代理评分下的接受状态非下降”，不是语义正确性或全局最优保证。附录 B 提出可行候选优先、非法状态处置和总调用预算的修订建议；其中部分已在新项目提供独立选项或预算接口，仍未正式评测，不能回填为本章已有实验的生成过程。

4.5 实验设置

4.5.1 数据集与指标

域内实验使用 AAEC 和 CDCP。对任一预测对象集合，精确率、召回率和 F1 定义为：

$$P=\frac{TP}{TP+FP},R=\frac{TP}{TP+FN},F_1=\frac{2PR}{P+R}. \quad (4\text{-}11)$$

组件只有在起止边界和类型均与金标准一致时计为TP。关系只有在源组件、目标组件、方向和关系标签均正确时计为TP。AAEC 报告 Component-F1 以及 Support、Attack 和总体 Relation-F1；CDCP 保留 Reason 和 Evidence 两类关系并分别

报告 F1。关系评价基于模型预测组件而非金标准组件，因此同时反映组件识别与关系预测错误；Oracle 实验另行使用金标准组件估计关系模块上限。跨领域实验的粗粒度指标在第五章说明。

4.5.2 基线与实现

外部基线包括 FLAN T5-XXL、GPT-4-turbo 20-shot 和 RoBERTa-large 多任务模型。为比较同骨干配置，原稿内部比较采用 Qwen2.5-7B-Instruct 及相同 LoRA 训练设置，包括 Single-Pass、Constrained Decoding、DAG Post-process、Multi-Sample (LogProb)、Self-Refine、无修正的$K=1$版本和仅验证器重排序的$K=3$版本。原稿称优化器采用 AdamW 并使用早停，数据划分与评价脚本遵循文本到文本生成基线[7]，但当前未提供配置文件与脚本，尚不能认定所有协议已经对齐。

待核验 R09：需补齐数据版本及文档 ID 划分、输入按全文还是段落组织、分词及跨度转换、CDCP 多片段前提的处理、训练步数和有效 batch size、学习率、LoRA 目标层、dropout、温度、top-p、提示版本、检查点选择、随机种子、运行次数与硬件。原稿各表的“±”暂按原样保留，其代表标准差、标准误还是置信区间尚不确定，不进行显著性判断。

待核验 R10：下列外部 FLAN T5-XXL 的 AAEC 总体 80.15/61.19、CDCP 总体 72.68/33.96，以及 GPT-4-turbo 的 AAEC 总体 55.51/28.38 可在 Kawarada 等的结果表找到；本稿未核实这些外部基线的分类别数值来源。RoBERTa 及其他内部行也需绑定复现实验记录。相同骨干不等于相同预算，当前材料没有证实 Self-Refine、多采样和 MCR-BR 已做到总 token 数或调用次数匹配。

4.5.3 近期相关方法的比较边界

第一章补充的近期研究用于更新方法定位，并不自动成为已复现的实验基线。DENIM[12]和 AASP[9]是优先考虑的生成式或结构预测对照，但需先统一数据划分、输入粒度及精确匹配评价。Cabessa 等的分类生成方法[8]、关键短语方法和 FOL-AM 基于给定组件的任务设定，不能直接并入现有端到端分数表。若将其改造为端到端流程，应单列组件分割器和新增计算成本。

Tran 等的 LLM-refine[23]为多候选判断提供相邻对照思路，但其课堂话轮分割候选与本文整图不同。比较其思想时需要重新定义整图选择基线，不能沿用原论文任务分数。ARGUS 属于端到端系统演示，组件分割研究只覆盖部分子任务；本稿不为这些方法补造统一实验结果，也不据现有表格宣称超过全部近期方法。

4.5.4 配置核对与新实验命名

原稿明确列出的骨干、LoRA 秩与缩放、提示长度、辅助权重、三项评分权重及 K/T/M 可以登记为“稿件声称的配置”，但没有日志就不能升级为“已执行并验证”。学习率、划分 ID、目标层、dropout、种子、重复数及硬件等缺项不能用常见取值补作历史事实。附录 D 列出新项目的确定配置，供重新实验，不作为表 3-1 至表 5-2 的运行来源。

新项目将 Single-Pass 限定为一次联合整图生成，将 staged-K1 限定为一次组件生成加一次固定组件的关系生成；K3-LogProb、K3-Rerank、K3-Rerank-BR 则使用完整候选图，并可复用同一冻结候选池。训练模块及数据消融必须重新训练，推理消融则固定检查点。这一命名区分不能自行解释 81.67 与 77.82 的历史冲突，两个旧值仍保留待核验。

公平比较需核对实际预算。同样 3 个 epoch 在增强后通常对应更多更新；新代码提供更新步数上限，但仍需检查实际步数、样本/token 量和检查点选择是否匹配。移除软合法性评分不等于取消修正动作的硬合法性检查。新项目尚未实现所有旧表基线，未完成真实数据训练、多个种子重复或显著性检验。

4.6 域内主要结果

4.6.1 AAEC 结果

表 4-2 AAEC 域内结果原稿记录

方法	Comp-F1	Support-F1	Attack-F1	Relation-F1
FLAN T5-XXL	80.15	62.34	48.72	61.19
GPT-4-turbo 20-shot	55.51	29.86	18.45	28.38
RoBERTa-large MTL	76.43±0.55	54.21±0.52	41.83±0.67	52.15±0.54
LLM Single-Pass	77.82±0.51	58.43±0.45	44.21±0.62	56.87±0.48
LLM w/ Constrained Decoding	78.54±0.46	59.12±0.42	45.33±0.58	57.65±0.45
LLM w/ DAG Post-process	78.91±0.49	59.45±0.48	45.87±0.61	58.12±0.47
LLM Multi-Sample (LogProb)	79.45±0.38	60.12±0.41	46.58±0.55	58.94±0.42
LLM w/ Self-Refine	79.82±0.45	60.75±0.43	47.12±0.56	59.63±0.45
Ours ($K=1$, w/o correction)	81.24±0.44	61.87±0.39	48.34±0.58	60.73±0.41

方法	Comp-F1	Support-F1	Attack-F1	Relation-F1
Ours (Verifier-only Rerank, $K=3$)	82.18±0.40	63.15±0.36	49.82±0.52	62.21±0.38
Ours (Full, $K=3$)	**83.71±0.42**	**65.92±0.38**	**51.47±0.54**	**64.83±0.38**

按表 4-2 记录，Full 相对 FLAN T5-XXL 的 Component-F1 和 Relation-F1 差值分别为 3.56 和 3.64 个点，相对本表 Single-Pass 分别为 5.89 和 7.96 个点。约束解码、DAG 后处理及 Self-Refine 各行也呈现正向差值，但在提示、训练设置和推理预算未核验前，不能把差异全部归因于 BR，亦不能据此判断修复了哪一类节点或关系错误。

4.6.2 CDCP 结果

表 4-3 CDCP 域内结果原稿记录

方法	Comp-F1	Reason-F1	Evidence-F1	Relation-F1
FLAN T5-XXL	72.68	35.24	28.41	33.96
RoBERTa-large MTL	68.52±0.58	31.45±0.61	25.72±0.73	30.23±0.64
LLM Single-Pass	71.35±0.48	33.82±0.52	27.15±0.68	32.64±0.55
LLM w/ DAG Post-process	72.14±0.50	34.65±0.49	28.02±0.63	33.51±0.52
LLM w/ Self-Refine	72.95±0.47	35.58±0.48	28.94±0.60	34.42±0.50
Ours ($K=1$, w/o correction)	74.56±0.45	36.94±0.46	30.27±0.58	35.78±0.48
Ours (Verifier-only Rerank, $K=3$)	75.12±0.41	37.85±0.44	31.42±0.55	36.64±0.45
Ours (Full, $K=3$)	**76.45±0.43**	**39.12±0.45**	**32.86±0.57**	**38.17±0.46**

按表 4-3 记录，CDCP 上的 Full Relation-F1 比 FLAN T5-XXL 高 4.21 个点，为非 AAEC 语料上的适用性提供了待复核的结果。Evidence-F1 低于 Reason-F1，但该差异可能与样本数量、边界错误或标签判别等因素有关；没有类别计数及错误分解时，不能仅归因为证据型关系稀疏或语义隐含。

4.7 消融与机制分析

4.7.1 模块消融

表 4-4 模块消融原稿记录

配置	Comp-F1	Relation-F1	ΔComp	ΔRel
Full Method	83.71±0.42	64.83±0.38	—	—
$K=1$, w/o correction	81.24±0.44	60.73±0.41	-2.47	-4.10
w/o Claim-specific Adapter	81.96±0.48	63.08±0.44	-1.75	-1.75
w/o Cue-aware Prompting	82.34±0.45	62.87±0.40	-1.37	-1.96
w/o Multi-Objective	82.89±0.43	63.54±0.39	-0.82	-1.29
w/o Validity Signal E_{val}	81.56±0.46	61.92±0.43	-2.15	-2.91

由$K=1$无修正记录到$K=3$仅重排序记录，Relation-F1 差值为 1.48 个点，但同时改变候选数和选择过程，不能解释为重排序的单独贡献。由$K=3$仅重排序到 Full 的差值为 2.62 个点；只有在两者使用相同检查点、相同缓存候选池和相同评价脚本时，这才是对加入 BR 的有效对照。去除E_{val}的记录下降 2.91 个 Relation-F1 点，也需明确是仅移除评分项，还是同时移除了硬合法性检查。

训练模块消融反映其在其他模块保留时的条件差异，不能把各差值相加。本稿尚缺等样本量普通改写、无增强、无E_{dens}、无E_{coh}、逐动作移除和候选数—成本曲线等对照。因此当前表格没有完全分离增强、候选覆盖、选择器与修正操作的贡献。

4.7.2 验证器替换分析

表 4-5 验证器替换原稿记录

验证器	Comp-F1	Relation-F1	Top-1 一致率	修正触发率
Qwen2.5-7B（默认）	83.71	64.83	100.0%	42.5%
Llama-3-8B（独立）	83.71	64.55	94.2%	43.8%

按原稿记录，替换验证器后 Relation-F1 差值为-0.28 个点，Top-1 选择与默认验证器的一致率为 94.2%。默认行 100.0%是与自身比较的参照值，不是候选选择正确

率；高模型间一致率也可能来自共同偏差，不能视为人工标注一致率。待核验 R11：需说明一致率的分母、候选池是否固定、验证提示与解码配置，并以独立人工标注评估边判定的 Precision、Recall 及错误修改比例。

4.7.3 Oracle 上限

表 4-6 Oracle 条件结果原稿记录

条件	Comp-F1	Relation-F1	ΔRel
预测组件与当前选择器	83.71±0.42	64.83±0.38	—
Candidate Oracle（$K=3$中择优）	85.12±0.36	67.24±0.34	+2.41
Condition Oracle（金标准组件输入）	—	78.42±0.35	+13.59
Output Oracle（金标准替换）	100.00	83.35±0.32	+18.52

按表 4-6 记录，Candidate Oracle 相对当前选择器的 Relation-F1 差值为 2.41 个点，Condition Oracle 差值为 13.59 个点。前者只是给定候选池及 Oracle 选择准则下的经验诊断，不是整个任务的理论上限。后者同时改变关系模块的输入条件，可能引入分布变化，不能把 13.59 个点直接当作组件错误可被某一训练模块消除的量。

待核验 R12：Candidate Oracle 需说明逐文档优化哪个指标、如何处理并列以及先选择后汇总的口径。Output Oracle 必须明确金标准替换的是组件、关系还是全部图：若只替换组件且保留预测关系，Relation-F1 可以低于 100；若全部输出均替换为同一金标准，则表中 83.35 不符合该定义。定义澄清前不用于量化某类误差贡献。

4.7.4 修正行为统计

表 4-7 修正行为原稿记录

指标	结果
修正触发率	42.5%
触发文档平均迭代轮数	1.8
触发文档平均动作数	2.4
LocalRerun 占比	45.2%
RemoveEdge 占比	24.8%

指标	结果
Replace 占比	19.5%
Promote/Demote 占比	10.5%
无效 ID 比例	18.5% → 2.1%
JSON 格式错误比例	6.2% → 0.0%
不连贯边比例	22.4% → 5.8%
整体E_{val}通过率	75.3% → 97.9%

平均轮数和动作数只描述原稿记录下的运行行为，不足以证明多数真实错误已被修复。LocalRerun 的使用占比最高，也可能由动作生成顺序或触发策略决定，不能直接作为错误类别分布。RemoveEdge 的收益必须结合关系 Precision 与 Recall 判断，以避免通过过度删边取得表面合法性。

待核验 R13：需逐项声明分母及前后阶段，例如触发率按全部测试文档计算，动作占比按尝试还是接受动作计算，无效 ID 按引用还是文档计算。不连贯边比例来自验证器自身判断，与人工语义正确率不同；前后预测边数可能变化，应同时报告数量及比例。原稿 75.3%到 97.9%的合法率变化也需与 6.2%的 JSON 错误、18.5%的无效 ID 进行同阶段核对。

4.8 误差分析与局限

根据动作定义，删除错误边和在固定组件集上重预测关系属于可尝试的恢复情形；实际成功率需由逐例前后图与金标准证明。原稿没有提供可定位的真实案例，因此本稿不把概括性描述当作成功案例。尤其“从候选池找回遗漏 Claim”需要插入或联合替换机制，现有 Replace 定义不足以保证该能力。

潜在失败情形包括所有候选均遗漏隐式组件、局部判断无法发现多跳矛盾、验证器错误拒绝有效边或接受表面相关边。这些是需检验的失效假设，不是已完成标注的误差占比。真实案例应同时展示原文、金标准、初始图、触发异常、每步动作、代理评分以及最终任务匹配结果，并纳入错误修改案例。

下面给出可复算的成功路径作为机制示例，同样不代替真实错误分析。构造三个已正确识别的节点：一个无出边 Claim 和两个 Premise；初始图含两条入边，其中一条 Support 为构造金标准关系，另一条 Attack 不在金标准中。固定验证器分别返回 1

和 0，则覆盖、连贯性、合法性为 0.5、0.5、1，总分 0.6。COH 异常触发 RemoveEdge 后，三分量变为 0.5、1、1，总分 0.8，图仍合法，因而接受。

该例组件 F1 保持 100，关系 F1 由 66.67 升至 100，但 DENS 仍会因仅有一条通过验证的入边而触发。这说明一次正确删边不代表所有异常都应该继续消除；如果验证器随后误认第二条边，补边也可能提高代理分数而降低精确率。成功路径与反例四共同界定了该方法对验证器质量的依赖。

MCR-BR 还带来额外推理成本。$K=3$候选和逐边验证增加了并行计算量，局部修复则引入顺序解码。现有$T=3$和$M=2$仅限制轮数与接受动作数，尚未给出最坏调用成本上界。若有A_{try}次动作尝试，每次还可能涉及多个边验证调用，实际开销取决于候选边数、验证批处理和缓存策略。应测量生成与验证的调用次数、输入输出 token、端到端平均及 P95 时延、峰值显存，并在相同硬件上与 Single-Pass 比较。当前没有这些记录，不能定量宣称效率改善或成本已严格受控。

新项目现有预算接口只说明后续能够记录并限制哪些计算，不提供上述历史成本数据，也不证明在目标 GPU 上的效率优势。

4.9 本章小结

本章以完整候选图为评估对象，将多候选选择与异常驱动局部修正连接起来，明确了异常、动作、接受条件和回退的关系。这是相对于一般多采样和自由文本自修正的具体设计差异，而不是对两类已有思想的首次提出。现有域内、消融、验证器替换和 Oracle 记录为分析完整配置提供依据；BR 的净收益需在固定候选池下解释，额外计算的价值需经预算匹配比较。软合法性、非法初始图恢复和遗漏节点操作仍限定着当前方法的适用范围。

第五章 粗粒度标签协议下的跨语料迁移分析

本章在训练域与测试域不一致的条件下分析第三、四章方法的表现，作为两项方法贡献的适用性验证，而非第三项算法创新。与利用辅助语料联合训练的 MT-AM[25]不同，本章声明的零样本设定仅使用源域训练监督。鉴于近期句子级论辩识别研究揭示了词汇线索与跨数据集泛化之间的风险[27]，本章特别区分领域变化、标签归约和评价口径，避免将域内正向结果直接外推到目标域。

5.1 跨领域异构性

AAEC 与 CDCP 的差异至少包括三个层面。第一，AAEC 由学生说服性作文构成，CDCP 来自电子政务评论，文本长度、篇章组织和语言风格不同。第二，AAEC 使用 MajorClaim、Claim 和 Premise 三级组件体系，CDCP 使用 Fact、Testimony、Value、Policy 和 Reference 功能类型。第三，AAEC 关系为 Support/Attack 并额外包含 Claim stance，CDCP 关系为 Reason/Evidence 且允许多父节点。因此，直接比较细粒度类型 F1 或关系标签 F1 会同时混入领域变化和标注规范变化。

5.2 粗粒度标签与关系映射

组件映射函数$\varphi:\mathcal{T}_{src}\cup\mathcal{T}_{tgt}\to\{Claim,Premise\}$定义如下：

表 5-1 跨语料组件标签归约

数据集原标签	粗粒度标签	映射依据
AAEC MajorClaim	Claim	表达全文立场
AAEC Claim	Claim	表达局部结论
AAEC Premise	Premise	提供支撑或反驳理由
CDCP Policy	Claim	提出行动方案或规范性主张
CDCP Value	Claim	表达评价性或价值判断
CDCP Fact	Premise	提供可核验事实
CDCP Testimony	Premise	提供经验或证言
CDCP Reference	Premise	提供外部来源

关系映射函数ψ将 AAEC 的 Support/Attack 和 CDCP 的 Reason/Evidence 统一为有向 Link：

$$\psi(r)=Link, r\neq None. \quad (5\text{-}1)$$

该协议保留组件角色的粗粒度差异和关系方向，但主动舍弃支持/攻击、理由/证据等细粒度语义。因此，Unlabeled Link-F1 只能说明模型能否迁移“哪些组件应连接及连接方向”，不能证明细粒度关系分类已经实现跨域泛化。

5.3 零样本迁移协议

本章协议要求在 AAEC 训练集上拟合模型，并仅使用 AAEC 验证集选择检查点和超参数；迁移到 CDCP 时不使用目标域标注样本更新参数或选择阈值。原稿是否完全遵循该数据使用边界，仍需配置和日志核验。原稿对迁移时输出源标签还是目标标签没有提供可核验记录。新参考实现明确继续输出 AAEC 源标签，并只在评价阶段把预测与 CDCP 金标准分别映射为粗类型及有向 Link；不向生成器提供目标域标注示例，也不切换为目标细粒度输出 Schema。候选数、评分权重、连接覆盖阈值和修正预算均沿用源域配置。评价采用：

1. **Coarse Component-F1**：组件边界正确且映射后的 Claim/Premise 类型正确；

2. **Unlabeled Link-F1**：源节点、目标节点和方向均正确，不区分 Reason 与 Evidence。

新实现把标签对齐限制在评价阶段的确定性映射，Link 端点默认要求边界及粗类型一致；不使用目标测试结果调节阈值。源域 Schema 和图约束可能限制目标域输出，是需要评估的协议选择。所有指标基于预测组件计算；旧表是否遵循该新定义仍待 R14 核验。

5.4 跨领域迁移结果

表 5-2 AAEC 到 CDCP 迁移结果原稿记录

方法	Coarse Component-F1	Unlabeled Link-F1
FLAN T5-XXL（zero-shot）	52.34±0.65	31.25±0.72
LLM Single-Pass（zero-shot）	54.87±0.58	33.42±0.68

方法	Coarse Component-F1	Unlabeled Link-F1
Ours ($K=1$, w/o correction, zero-shot)	57.23±0.52	38.76±0.61
Ours (Full, zero-shot)	**60.78±0.48**	**43.21±0.55**

按表 5-2 记录，Full 相对 FLAN T5-XXL 的 Coarse Component-F1 和 Unlabeled Link-F1 差值分别为 8.44 和 11.96 个点，相对同骨干 Single-Pass 分别为 5.91 和 9.79 个点。两个指标的增幅不能直接用于错误归因；在未提供目标域错误分解时，不能断言收益主要来自连接碎片化或无效引用的减少。

43.21 的 Link-F1 与第四章 AAEC 域内 64.83 的 Relation-F1 使用不同标签口径，不能直接相减估计领域退化。要分离领域差异，应在源域与目标域都重新使用同一粗粒度组件映射、端点匹配和有向无标签连接脚本。本章目前只比较同一目标协议下各方法的记录。

待核验 R14：需确认模型在迁移时输出源标签、目标标签还是粗标签，映射发生在生成前还是评价前；同时说明 Link 端点匹配是否包含粗类型。提供 Schema 定义不等于使用标注示例，但若使用目标域示例、开发标签或按目标测试表现调阈值，就不再满足本章声明的零样本协议。

5.5 泛化来源与有效性威胁

框架可能从三个方面改善迁移。其一，多候选组件集合保留了目标域中不确定的边界和类型假设；其二，跨度、引用和无环性检查不依赖具体主题；其三，局部重预测比整图重新生成更少破坏已经正确的目标域结构。不过，当前证据仍受到以下限制：

1. 仅验证 AAEC 到 CDCP 单一迁移方向，尚不能覆盖医学、法律或多语言场景；

2. Policy/Value 到 Claim、Fact/Testimony/Reference 到 Premise 是基于功能角色的启发式归约，会损失部分语义；

3. Unlabeled Link-F1 不评价细粒度关系类型；

4. 目标域模型可能受公开数据预训练污染影响；

5. 验证器与生成器可能共享相似的预训练偏差。

因此，本章将跨领域结果定位为特定协议下的适用性证据，而不是通用领域泛化能力的证明。还需关注 Cue-aware 分支是否依赖源域常见结论词；可在目标域按有无

线索词分组报告性能，并比较关闭该分支时的变化。这是受近期泛化研究启发的待验证问题，不是已经完成的实验。增加 AbstRCT 等目标域、开展双向迁移和比较多种标签对齐策略，可进一步检验结论稳定性。

5.6 本章小结

本章明确了 AAEC 到 CDCP 零样本迁移的标签映射和无标签连接评价范围，并分析原稿保留记录。Full 的组件和连接分数高于表中基线，但这一比较仅限所声明的单向粗粒度协议，仍需核验实际数据使用与评价脚本。双向迁移可作为后续扩展，不是回答本章限定问题的必要条件。

第六章 总结与展望

6.1 工作总结

本文围绕生成式端到端论辩挖掘中的组件识别错误及其向关系预测传播的问题，形成训练阶段的结论组件增强与推理阶段的论辩图修正两项互补设计。研究主线是改善关系恢复所依赖的组件候选，并利用候选图中的结构与语义反馈调整预测结果，而不是将通用微调、提示或多次采样本身作为创新。

第一，设计面向结论类组件的局部论辩结构保持增强方法。以结论节点及其局部支撑或攻击邻域组织增强样本，在表达变化中保留组件类型和关系监督，并通过分层筛选控制样本质量；类型条件适配、线索感知提示及辅助目标构成配套的表示增强机制。该设计将结论表达的多样性与局部关系上下文相结合。本文同时分析了组件召回对可达关系集合的限制，以及保持局部拓扑不必然改善类别比例的条件。

第二，提出基于完整候选图评估与异常驱动局部修正的 MCR-BR 方法。多个组件假设分别生成候选论辩图，图级评分用于选择初始结构，异常检测用于触发局部动作，接受检查与回退用于控制修改过程。与仅增加采样次数或自由文本自修正相比，该方法明确了候选对象、反馈粒度和修改边界。其当前性质限于给定前提下的修正步数限制和固定代理评分下的接受状态非下降，不包括全局最优、最终必然合法或任意遗漏节点恢复的保证。

第三，在域内和规定的跨语料协议下分析方法表现。原稿记录中，Full 在 AAEC 上的 Component-F1 和 Relation-F1 为 83.71 和 64.83，在 CDCP 上为 76.45 和 38.17；在 AAEC 到 CDCP 的粗粒度组件与有向无标签连接协议下，两项指标分别为 60.78 和 43.21。上述结果保留为完整配置的实验记录，不将总增益分配给某一模块，也不将不同标签协议的分数直接相减解释领域退化。

相关工作比较表明，生成式联合抽取、篇章结构引导和论辩候选判断已有相邻研究。本文可主张的具体贡献应落在结论中心局部结构保持增强，以及完整候选图评估与异常驱动局部修正的设计和实证分析上。当前工作仍需完成配置对应、增强独立消融和预算匹配验证，才能进一步确认两项方法各自的增量价值；跨语料结果则仅支持所采用迁移方向与标签归约下的适用性判断。

对应 RQ1，现有记录尚不能分离结构增强的独立作用，需要同规模普通改写对照及 Premise 结果；对应 RQ2，现有表格给出组合配置的正向差值，固定候选池与等预算结果仍缺，评分反例说明接受规则不保证任务指标提高；对应 RQ3，结论限于原稿

单向粗粒度迁移记录，不能外推到未测试的语言或领域。三项问题的回答强度以各自证据为准。

6.2 当前不足与后续研究

首先，实验可追溯性尚不完整。应优先绑定每张结果表与实际运行配置，解决第三章和第四章同名方法的分数差异，补齐评价脚本、数据划分、重复次数及“±”含义。这些工作属于现有结论的验证前提，不应全部放入长期展望。

本轮已补充独立参考实现和配置说明，使重新实验具有代码起点；但软件测试不是方法有效性验证。在取得真实数据及模型、完成原始标注抽检并运行正式对照前，仍不能将新项目视为表格结果的复现证据。

其次，训练增强的独立贡献尚未分离。后续应在等训练预算下比较无增强、普通改写和结构感知增强，报告类别数量、筛选通过率、人工抽检及 Premise 表现；条件适配器需在训练与推理可用信息一致的实现下重新核验。

再次，图级修正需要同时控制错误修改与计算成本。除当前接受动作预算外，应定义被拒绝尝试的上限、验证缓存和失败返回策略。评价时应包含原本正确对象被破坏的比例，以及性能—时延—token 开销的对照，避免只以代理分数或合法率衡量修正收益。

最后，跨语料证据只覆盖一种归约和一个方向。双向迁移、更多目标语料、不同映射策略以及预训练污染审计可以检验结论的稳定性。在完成这些验证之前，中文、多语言及长篇专业文本仍属于待研究范围。

参考文献

[1] LAWRENCE J, REED C. Argument mining: A survey[J]. Computational Linguistics, 2019, 45(4): 765–818. DOI: 10.1162/coli_a_00364. 来源

[2] STAB C, GUREVYCH I. Parsing argumentation structures in persuasive essays[J]. Computational Linguistics, 2017, 43(3): 619–659. DOI: 10.1162/COLI_a_00295. 来源

[3] PARK J, CARDIE C. A corpus of eRulemaking user comments for measuring evaluability of arguments[C]//Proceedings of the Eleventh International Conference on Language Resources and Evaluation. Miyazaki: European Language Resources Association, 2018. 来源

[4] EGER S, DAXENBERGER J, GUREVYCH I. Neural end-to-end learning for computational argumentation mining[C]//Proceedings of the 55th Annual Meeting of the Association for Computational Linguistics, Volume 1. Vancouver: Association for Computational Linguistics, 2017: 11–22. DOI: 10.18653/v1/P17-1002. 来源

[5] MORIO G, OZAKI H, MORISHITA T, et al. Towards better non-tree argument mining: Proposition-level biaffine parsing with task-specific parameterization[C]//Proceedings of the 58th Annual Meeting of the Association for Computational Linguistics. Association for Computational Linguistics, 2020: 3259–3266. DOI: 10.18653/v1/2020.acl-main.298. 来源

[6] CAPUTO E, GRECO S, LA CAVA L. Argument component segmentation with fine-tuned large language models[C]//Findings of the Association for Computational Linguistics: EACL 2026. Rabat: Association for Computational Linguistics, 2026: 5154–5167. DOI: 10.18653/v1/2026.findings-eacl.272. 来源

[7] KAWARADA M, HIRAO T, UCHIDA W, et al. Argument mining as a text-to-text generation task[C]//Proceedings of the 18th Conference of the European Chapter of the Association for Computational Linguistics, Volume 1. St. Julian's: Association for Computational Linguistics, 2024: 2002–2014. DOI: 10.18653/v1/2024.eacl-long.121. 来源

[8] CABESSA J, HERNAULT H, MUSHTAQ U. Argument mining with fine-tuned large language models[C]//Proceedings of the 31st International Conference on Computational Linguistics. Abu Dhabi: Association for Computational Linguistics, 2025: 6624–6635. 来源

[9] DAS N, VAIBHAV V, CHOUDHARY Y S, et al. End-to-end argument mining through autoregressive argumentative structure prediction[EB/OL]. arXiv:2510.16363v1, 2025[2026-09-14]. DOI: 10.48550/arXiv.2510.16363. 来源

[10] CAPUTO E, GRECO S, LA CAVA L. ARGUS: Towards end-to-end argument mining with large language models[C]//Proceedings of the AAAI Conference on Artificial Intelligence, 2026, 40(48): 41547–41549. DOI: 10.1609/aaai.v40i48.42335. 来源

[11] LI H, SCHLEGEL V, SUN Y, et al. Large language models in argument mining: A survey[EB/OL]. arXiv:2506.16383v6, 2025[2026-09-13]. DOI: 10.48550/arXiv.2506.16383. 来源

[12] SUN Y, CHEN G, YANG C, et al. Discourse structure-aware prefix for generation-based end-to-end argumentation mining[C]//Findings of the Association for Computational Linguistics: ACL 2024. Bangkok: Association for Computational Linguistics, 2024: 11597–11613. DOI: 10.18653/v1/2024.findings-acl.689. 来源

[13] DAS N, SARADHI V V, ANAND A. On the role of key phrases in argument mining[C]//Findings of the Association for Computational Linguistics: NAACL 2025. Albuquerque: Association for Computational Linguistics, 2025: 5774–5787. DOI: 10.18653/v1/2025.findings-naacl.319. 来源

[14] SUN Y, CHEN G, ALINEJAD-ROKNY H, et al. Learning first-order logic rules for argumentation mining[C]//Proceedings of the 63rd Annual Meeting of the Association for Computational Linguistics, Volume 1. Vienna: Association for Computational Linguistics, 2025: 14133–14148. DOI: 10.18653/v1/2025.acl-long.691. 来源

[15] DING B, QIN C, ZHAO R, et al. Data augmentation using LLMs: Data perspectives, learning paradigms and challenges[C]//Findings of the Association for Computational Linguistics: ACL 2024. Bangkok: Association for Computational Linguistics, 2024: 1679–1705. DOI: 10.18653/v1/2024.findings-acl.97. 来源

[16] EVURU C K, GHOSH S, KUMAR S, et al. CoDa: Constrained generation based data augmentation for low-resource NLP[C]//Findings of the Association for Computational Linguistics: NAACL 2024. Mexico City: Association for Computational Linguistics, 2024: 3754–3769. DOI: 10.18653/v1/2024.findings-naacl.238. 来源

[17] PEI Y, BHUSE P, LIU Z, et al. SegMix: A simple structure-aware data augmentation method[EB/OL]. arXiv:2311.09505v1, 2023[2026-09-13]. DOI: 10.48550/arXiv.2311.09505. 来源

[18] SUN W, LI M, DAVIS J, et al. Weakly-supervised argument mining with boundary refinement and relation denoising[C]//Proceedings of the Ninth Fact Extraction and VERification Workshop (FEVER). Rabat: Association for Computational Linguistics, 2026: 1–12. DOI: 10.18653/v1/2026.fever-1.1. 来源

[19] GENG S, JOSIFOSKI M, PEYRARD M, et al. Grammar-constrained decoding for structured NLP tasks without finetuning[C]//Proceedings of the 2023 Conference on Empirical Methods in Natural Language Processing. Singapore: Association for Computational Linguistics, 2023: 10932–10952. DOI: 10.18653/v1/2023.emnlp-main.674. 来源

[20] MADAAN A, TANDON N, GUPTA P, et al. Self-Refine: Iterative refinement with self-feedback[EB/OL]. arXiv:2303.17651v2, 2023[2026-09-13]. DOI: 10.48550/arXiv.2303.17651. 来源

[21] HUANG J, CHEN X, MISHRA S, et al. Large language models cannot self-correct reasoning yet[EB/OL]. arXiv:2310.01798v2, 2024[2026-09-13]. DOI: 10.48550/arXiv.2310.01798. 来源

[22] WANG X, WEI J, SCHUURMANS D, et al. Self-consistency improves chain of thought reasoning in language models[EB/OL]. arXiv:2203.11171v4, 2023[2026-09-13]. DOI: 10.48550/arXiv.2203.11171. 来源

[23] TRAN N, LITMAN D, GODLEY A. Using large language models to analyze students' collaborative argumentation in classroom discussions[C]//Proceedings of the Artificial Intelligence in Measurement and Education Conference (AIME-Con): Full Papers. Pittsburgh: National Council on Measurement in Education, 2025: 111–125. 来源

[24] XIAO Y, LI S. ARGUS: Argumentation-based minimal-change repair for verifiable LLM self-explanations[C]//Proceedings of the 42nd Conference on Uncertainty in Artificial Intelligence. Proceedings of Machine Learning Research, 2026, 337: 7536–7551. 来源

[25] MORIO G, OZAKI H, MORISHITA T, et al. End-to-end argument mining with cross-corpora multi-task learning[J]. Transactions of the Association for Computational Linguistics, 2022, 10: 639–658. DOI: 10.1162/tacl_a_00481. 来源

[26] SAVIGNY H, YUN B. AMELIA: A family of multi-task end-to-end language models for argumentation[J]. Argument & Computation, 2026, 17(1). DOI: 10.1177/19462174251413169. 来源

[27] FEGER M, BOLAND K, DIETZE S. Limited generalizability in argument mining: State-of-the-art models learn datasets, not arguments[C]//Proceedings of the 63rd Annual Meeting of the Association for Computational Linguistics, Volume 1. Vienna: Association for Computational Linguistics, 2025: 23900–23915. DOI: 10.18653/v1/2025.acl-long.1164. 来源

[28] ZHAO X, WANG K, PENG W. ORCHID: A Chinese debate corpus for target-independent stance detection and argumentative dialogue summarization[C]//Proceedings of the 2023 Conference on Empirical Methods in Natural Language Processing. Singapore: Association for Computational Linguistics, 2023: 9358–9375. DOI: 10.18653/v1/2023.emnlp-main.582. 来源

[29] CHENG L, BING L, HE R, et al. IAM: A comprehensive and large-scale dataset for integrated argument mining tasks[C]//Proceedings of the 60th Annual Meeting of the Association for Computational Linguistics, Volume 1. Dublin: Association for Computational Linguistics, 2022: 2277–2287. DOI: 10.18653/v1/2022.acl-long.162. 来源

[30] VASWANI A, SHAZEER N, PARMAR N, et al. Attention is all you need[EB/OL]. arXiv:1706.03762, 2017[2026-09-13]. DOI: 10.48550/arXiv.1706.03762. 来源

[31] QWEN TEAM. Qwen2.5 technical report[EB/OL]. arXiv:2412.15115, 2024[2026-09-13]. DOI: 10.48550/arXiv.2412.15115. 来源

[32] HU E J, SHEN Y, WALLIS P, et al. LoRA: Low-rank adaptation of large language models[EB/OL]. arXiv:2106.09685, 2021[2026-09-13]. DOI: 10.48550/arXiv.2106.09685. 来源

[33] LESTER B, AL-RFOU R, CONSTANT N. The power of scale for parameter-efficient prompt tuning[C]//Proceedings of the 2021 Conference on Empirical Methods in Natural Language Processing. Association for Computational Linguistics, 2021: 3045–3059. DOI: 10.18653/v1/2021.emnlp-main.243. 来源

附录 A 复现与证据核验清单

本附录保留历史结果的 14 项未决事项。新项目已提供若干对应接口和测试，但不是原实验材料，因此下列事项不自动关闭。每项应以原始记录，或明确另列的新实验配置、日志、数据清单与结果解决，不能只删去标记。

表 A-1 待核验事项及最低交付证据

编号	位置与事项	所需证据
R01	3.1 类别分布	固定训练划分的类型计数、跨度长度及增强前后 IR
R02	3.2 增强流程	模型与提示版本、生成及筛选计数、数据混合和跨度回填实现
R03	3.3 门控因果性	字段顺序、首 token 处理、训练与推理门控轨迹、参数预算
R04	3.3 提示与辅助目标	词典、插入位置、句子池化、损失 mask 及归一化
R05	3.4 结果配置冲突	81.67 与 77.82、两处 83.71 各自对应的 run ID
R06	4.2 候选规范化	重叠消解规则、置信度与 ID 重映射、解析失败记录
R07	4.3 至 4.4 评分与触发	评价节点选择、结构角色判定、阈值与比较方向
R08	4.4 动作可执行性	前置条件、字段修改、组件插入是否存在、回退记录
R09	4.5 实验配置	划分 ID、评价脚本、超参数、种子、重复数、硬件及统计量定义
R10	4.5 基线与预算	外部分类型来源、内部复现日志、相同预算比较
R11	4.7 验证器	提示、模型版本、固定候选池和人工边级评价
R12	4.7 Oracle	选择指标、替换对象、端点匹配及汇总顺序
R13	4.7 行为统计	统计分母、生成阶段、前后数量和尝试或接受动作定义
R14	5.3 至 5.4 迁移协议	输出标签空间、目标数据使用记录和统一评价脚本

最小补实验顺序为：先复现同一 Single-Pass 和 Full 配置，再在固定候选池上比较序列概率、验证器评分和 BR；其后完成增强独立消融、合法性与语义评分消融、等计算预算对比。验证器人工评价和跨域扩展应在评价脚本稳定后开展，以免重复标注和重跑。

附录 B 算法修订建议

本附录给出针对第四章逻辑缺口的可实验建议。新项目已提供合法优先选择选项、尝试/调用/token 上限及逐次日志；没有实现非法中间状态的分阶段修复或 Insert。所有建议均未使用原稿分数验证。

B.1 合法候选优先与失败处理

可先对可解析候选执行确定性检查，在存在合法候选时仅对合法子集按语义与覆盖分数排序。若所有候选均不合法，应返回显式失败状态，或进入单独定义的合法化阶段，而不是继续宣称输出有硬合法性保证。保守删除和重新生成会改变召回与计算预算，必须作为独立配置评测。

B.2 非法状态下的阶段性修复

若允许从非法图逐步恢复，可定义有限的违规计数并使用词典序目标，先降低确定性违规，再在合法集合内优化代理分数。该策略改变了当前“修改后全图立即合法”的接受条件，因此需要新的终止与回退说明。也可以把能够一起消除相关错误的操作定义为原子事务，但不应把任意多次修改包装为一次动作从而规避预算统计。

B.3 节点补回与总调用预算

若希望补回遗漏 Claim，应显式定义 Insert 或联合替换动作，说明新跨度来自哪个候选、如何消解重叠、如何更新 ID 以及哪些边需要重预测。若不增加该动作，则应保留当前方法不能一般性补回缺失节点的限制。

总预算可分别设置为最大动作尝试数、最大生成调用数、最大验证调用数和最大输出 token 数，并将所有被拒绝操作计入预算。新项目采用的默认值见 4.4.3 节，属于待验证的新工程上限，而不是对原实验的补填；最终仍应依据验证集性能—成本曲线选择。新增预算策略后，需要重新报告与基线在等预算下的结果。

B.4 建议的可复现实验记录

本节日志亦应用于识别 4.4.4 节的评分反例：保留类型修改前后的覆盖集合、各节点阈值及任务匹配计数，避免只记录总分。

每个测试文档可记录文档 ID、检查点与提示哈希、候选原始输出、规范化结果、各分量评分、选中候选、触发异常、每次动作尝试与回退原因、调用及 token 消耗、最终预测。该

记录有助于核验评分是否因验证器随机性变化，以及代理目标改善是否真正对应任务 F1 改善。

B.5 覆盖评分投机的保守修订方向

优先评估将“关系修正”与“类型修正”分开：关系修正阶段固定初始图的覆盖节点 ID 和阈值，仅允许不改变组件类型的动作；类型修正另需基于文本的类型判断依据，并单列其错误修改率。当前仅关闭 Promote/Demote 仍不充分，因为 Replace 也能改变类型；仅固定覆盖分母也不充分，因为非下降接受允许等分的错误类型修改。

这一建议会改变现有动作空间与接受条件，本轮未将其写成已实现方法，也未替换旧表结果。应设置原规则、禁止类型变化、固定覆盖集合及阈值、两者结合的对照，先检查构造反例，再在冻结候选池上比较类型 F1、关系 F1、错误修改率和成本。跨候选重排序中不同候选的覆盖集合仍可能不同，固定 BR 初始集合不能自动解决选择阶段的偏差。

B.6 两项贡献的最小独立验证

训练增强首先比较无增强、普通改写、结构条件改写。后两者使用相同源文档、目标单位、全文筛选和尽可能匹配的接受样本量及优化步数；若两组筛选导致源文档分布不同，应报告这种差异。此处 plain 只隔离生成提示是否含局部边，不能代表完全不使用结构信息的增强基线。另加结论中心与随机组件中心的预算匹配对照，才能检验为何优先选择结论。

推理实验在每个固定检查点下缓存同一批候选，比较长度归一化序列概率选择、图级重排序、重排序加 BR；随后比较删边后处理和等调用或等 token 预算的通用修订。训练增强与 BR 可组成 2×2 对照：原始数据/结构增强分别配合重排序/重排序加 BR。候选池在同一检查点的两种推理策略间固定，不要求不同训练检查点产生相同候选。

报告分类别 Precision、Recall、F1、多个种子的结果和差值不确定性；若开展逐文档重采样，应在每次抽样后重新汇总 TP/FP/FN 再计算 micro-F1。真实成功与错误修改案例需附原文、金标准、候选、动作和成本。若结构增强没有稳定优于 plain，或 BR 没有在预算匹配下优于重排序，应相应收缩贡献表述，保留可复核的负结果与适用边界。

附录 C 修订与辅助工具使用说明

0914 版在 0913 版基础上，参照 academic-research-suite 的论文修订、文献检索和引用核查要求，依据作者认可的贡献定位进行修改。辅助工作包括研究主线整理、近期公开文献核查、任务与评价边界比较、局部措辞修订、引用编号检查和 Word 排版，并保存逐段差异及修改说明。未运行训练实验，未生成人工标注结果，未将论文全文上传外部研究服务，未代替作者确认研究事实。当前遗留稿件缺少完整逐块路线图与裁决链，本轮使用可追溯局部补丁记录，不声称通过 ARS 全套逐块授权或研究完整性认证。作者应审阅修改，核对引用、实现和数据，并按学校及学院适用要求确认辅助工具披露方式。

原稿列出的作者阶段性成果及其发表状态尚缺可核验材料，本稿不将其认定为虚假，也不继续作“已发表”陈述。后续可依据论文首页、录用通知或出版社记录补充成果页。

0914-v2 轮次在作者明确授权后新建实验代码，并完成构造数据与随机初始化小模型的前向、反向、短训练、保存和重载测试。上一段“未运行训练实验”对应 0914 文稿修订轮次；本轮运行的是软件测试，未进行真实语料上的正式模型训练、效能比较或人工标注。参考实现中新增的超参数与协议均有来源分级及代码记录；作者仍需审阅生成代码、核对理论定义并对最终研究事实负责。

0914-v3 依据作者“评估后可直接修改”的授权执行局部修订，沿用 academic-research-suite 的证据分级与贡献审查原则。新增内容包括方法定义澄清、2026 年相关文献的定向核查、构造示例及评分反例诊断；未将软件诊断作为正式实验。本轮保存逐项替换、完整差异与文件核对记录，不生成或追认缺失的历史实验日志，也不声称完成全套 ARS 授权链或独立校准的专家评审。

附录 D 新参考实现与复现实验接口

D.1 身份与配置来源

项目名为 argument_mining_0914，实现标识为 0914-reference-v1。其来源是本次依据论文进行的新开发，不是原实验仓库。项目含数据转换、精确匹配评价、训练与增强、五种推理策略、四类局部动作、19 份具名配置及运行说明；不存在与旧表分数绑定的真实运行记录。表 D-1 中“沿用原稿取值”仅指文字取值一致，不代表原实验已经验证。

表 D-1 新参考实现配置与证据来源

配置组	新实现取值或规则	来源及限制
骨干与核心参数	Qwen2.5-7B-Instruct；r=16，alpha=32；m=4；辅助权重 0.5	沿用原稿取值；本地未提供该模型权重
评分与修正	权重 0.4/0.4/0.2；K=3；T=3；M=2	沿用原稿取值；M 计接受动作，不计总调用
训练优化	AdamW；lr=0.0002；3 轮；微批 1、累积 8；dev 生成损失早停	学习率、轮数、累积数及选择细则为本次新设；未运行正式训练
目标层与随机性	q_proj/v_proj；dropout=0.05；默认 seed=17	新实现选择；不填作旧实验种子或目标层
生成与长度	temperature=0.7；top-p=0.9；单次最多 1024 新 token；上下文 8192	新实现选择；超长显式失败，不静默截断
设备与软件	具名训练配置为 CUDA/bfloat16；Torch 2.8.0、Transformers 4.57.6	目标 GPU 未验证；本机仅 CPU 小模型测试
总预算与缓存	每文档 24 次动作尝试；128 次调用；32768 输出 token	新预算接口；复用候选生成成本仍计逻辑预算
评价与划分	显式 train/dev/test ID；跨度与类型精确匹配 micro-F1	新评价协议；不能追认原表指标与划分

默认训练数据为原始训练集，结构增强并不因使用名为 Full 的配置自动发生；需显式将增强后的 train 文件传入并记录哈希。模块配置和数据版本共同决定实验身份。更多取值、提示、句子切分、数据格式及动作字段见项目实现说明。

D.2 输入输出与可追溯性

AAEC 入口接受 BRAT 标注；stance 属性不转换为 Claim 到 MajorClaim 的关系。CDCP 入口接受显式组件偏移与 Reason/Evidence 区间边，多前提默认拒绝，只有选定 expand 选项才展开为二元边。该选项改变表示，需单列协议。转换器使用明确的 Unicode 评价分词与字符到 token 映射；分词不同于骨干子词切分，边界不精确对齐时拒绝。真实发布数据尚未导入，首次使用必须抽样检查转换后的原文、跨度及边，不能认为构造样例测试已经验证全部语料兼容性。

每次运行输出配置、代码、数据和模型身份哈希，训练记录验证集检查点选择，推理记录候选原始输出、评分、选择与修正历史、失败原因及预算。已有输出目录不会自动覆盖。候选缓存绑定文档和生成配置，支持同池比较；失效缓存不能作为复现实验输入。配置可设更新步数上限，实际更新量仍由日志确认。新多种子汇总以不同 seed 且相同非种子配置为必要条件，报告样本标准差，不自动给出统计显著性。

D.3 当前验证范围与未完成工作

本轮 55 项自动测试全部通过、无跳过，覆盖坐标、标注转换构造样例、数据泄漏检查、重复预测与失败分母、因果门控、四类动作、缓存成本及预算等。随机初始化的小型 Qwen 结构验证了响应损失 mask、梯度流、冻结骨干、一个优化步骤、短训练和检查点重载；这不是 Qwen2.5-7B 或真实数据上的效果验证。完整验证报告保存在项目 validation 目录，运行时间与软件版本亦被记录。

仍未完成真实数据训练和评价、外部基线复现、语法约束解码、Self-Refine、Llama 验证器、金标准组件替换 Oracle、Insert、分阶段非法状态修复，以及目标 GPU 的显存和时延测试。代码中逐 token 无缓存生成路径便于核验门控但较慢，不作为高性能部署方案。上述边界决定了本次只能交付“可测试的新实验起点”，不能据此确认创新收益、论文全部分数或送审资格。