武汉大学

学术型硕士学位论文

面向关系感知学习与依赖闭合修正的端到端论辩挖掘方法研究

End-to-End Argument Mining via Relation-Aware Learning and Dependency-Closed Repair

Chen Tang

计算机科学与技术

0923-v1 预期数值占位稿 非实测 勿送审

2026 年 9 月 23 日

摘要

端到端论辩挖掘需要从原始文本中联合识别论辩组件的跨度、类型及组件间关系。组件不是相互独立的标签：训练时改变一个组件的表达，可能同时改变其与外部组件的支持、攻击或无关系状态；推理时修正一个组件的边界或类型，也可能使已有关系失效。现有生成式方法虽然能够统一输出论辩图，但仅增加文本变体或逐项修改预测，难以充分处理上述依赖。本文在作者前期结论组件专项优化、多候选重排序与有界修正研究的基础上，围绕关系监督的保持和预测依赖的恢复，形成两项相互补充的方法。

第一，设计面向结论组件的关系感知增强学习方法。以结论及其论辩邻域为改写单位，将改写区内部关系、跨边界关系和无关系状态共同纳入检查范围。生成器只改写指定组件文字，程序回填全文并输运标注，语义检查失败则拒绝整个变体。在继承结论专项适配、线索提示及句子辅助监督的基础上，以原文和增强文的对应组件及关系因素建立成对监督，约束共享生成表示对标签保持的表达变化维持一致。采用按源文档归一化的增强权重，控制同源变体数量造成的重复训练权重，类别分布另行统计。

第二，提出多候选驱动的依赖闭合论辩图修正方法 MCR-BR-J。在多候选重排序获得初始图后，固定由全文跨度提议和候选图组成的可修改对象空间，以组件集合替换统一表示插入、删除、边界或类型调整及分割合并。每个替换方案必须同时重建全部受影响关系，包括入边、出边和原无关系位置，再作为一个事务整体评估、提交或回退。完整对象评分器在交叉拟合预测上学习组件及关系的正确性，固定计数效用将接受决策解释为代价敏感风险代理的改进；预算和严格增分条件限定搜索过程。形式分析给出标注输运、局部差分计算和有限终止的条件，但不将这些性质等同于真实 F1 必然提高。

本文建立 AAEC 与 CDCP 上的验证协议，分别检验训练增强和推理修正的独立贡献，并将 CDCP 多前提关系作为原生超边处理。验证重点包括近邻增强方法、同数据不同损失、同候选同评分的顺序与联合修正、结构化全局解码，以及候选覆盖、错误修改和计算成本。现有成果与轻量诊断用于说明研究基础；第五章预期情景值仅为写作占位，新增方法的实证结论仍需与运行记录及严格评价绑定。

关键词：端到端论辩挖掘；关系感知增强；结论组件；依赖闭合；图修正；代价敏感评分

Abstract

End-to-end argument mining jointly identifies component spans, component types, and argumentative relations from raw text. Components are interdependent: paraphrasing a component during training may alter its relations to surrounding components, while changing its span or type during inference may invalidate existing relations. Increasing the number of textual variants or editing predictions independently does not explicitly address these dependencies. Building on the author's prior work on conclusion-specific modeling, multi-candidate reranking, and bounded repair, this thesis develops two complementary methods for preserving relational supervision and restoring prediction dependencies.

The first method is relation-aware augmentation learning for conclusion components. A conclusion-centered neighborhood defines the editable text, while internal relations, boundary-crossing relations, and annotated no-relation states define the affected supervision. Only designated component text may be rewritten. A deterministic reconstruction procedure transfers annotations to the augmented document, and detected semantic drift leads to rejection of the entire variant. In addition to the inherited adapter, cue-aware prompting, and sentence-level supervision, paired component and relation objectives encourage the shared generation representation to remain consistent across accepted variants. Source-document normalization controls the repeated contribution of unchanged content.

The second method, MCR-BR-J, performs dependency-closed argument-graph repair after multi-candidate reranking. A fixed candidate universe supports component-set replacements, including insertion, deletion, span or type changes, splitting, and merging. Every replacement is evaluated together with the reconstruction of all affected incoming and outgoing relations and previously absent links. The complete transaction is committed or rolled back atomically. An object-correctness scorer trained on out-of-fold predictions supplies a fixed count-based utility with a cost-sensitive risk interpretation. Strict acceptance and explicit budgets bound the search. Conditional analyses establish annotation transport, local utility differences, and finite termination, without claiming guaranteed improvement in true F1.

The evaluation protocol separates the contributions of training-time learning and inference-time repair on AAEC and CDCP, retaining CDCP multi-premise relations as native hyperedges. It includes related augmentation methods, matched-data loss ablations, sequential and joint repair under identical candidates and scores, global structured decoding, candidate recovery, harmful edits, and computational cost. Prior results and diagnostics establish the research basis. Numerical scenarios in Chapter 5 are writing placeholders, not measurements; new empirical claims require reproducible runs and strict evaluation.

Keywords: End-to-End Argument Mining; Relation-Aware Augmentation; Conclusion Components; Dependency Closure; Graph Repair; Cost-Sensitive Scoring

目录

第一章 绪论

第二章 任务表示与方法基础

第三章 面向结论组件的关系感知增强学习

第四章 多候选驱动的依赖闭合论辩图修正

第五章 综合实验设计与证据分析

第六章 总结与展望

参考文献

附录 A 复现与证据核验清单

附录 B 运行身份与事务记录规范

附录 C 前期成果归属与研究辅助说明

附录 D 参考实现与新增方法的对应状态

附录 E 前期数值与协议存档

第一章 绪论

1.1 研究背景与问题提出

论辩挖掘研究文本中的主张、理由及其连接方式，目标不只是判断作者赞成或反对什么，还包括定位论证内容并识别论证结构。其研究对象涵盖说服性作文、公共政策评论和其他带有论证行为的文本。论辩挖掘与立场检测、论证质量评价等任务相关，但组件和关系抽取的准确性不能直接替代对论证有效性或事实真实性的评价[1]。

本文关注从原始文本到组件跨度、组件类型及有向关系的联合预测。AAEC 以学生说服性作文为对象，区分 MajorClaim、Claim 和 Premise；CDCP 以电子规则制定评论为对象，采用 Fact、Testimony、Value、Policy 和 Reference 等组件类型[2][3]。两个语料的标签不能仅凭名称直接对齐，关系拓扑也不能统一假设为树。因此，本文将图约束限定为给定实验表示下的任务约束，不将所有自然语言论辩都定义为有向无环图。

生成式建模把多个子任务映射到同一输出序列，使组件和关系能够共享上下文，但没有消除输出内部的依赖关系。例如，一个 Claim 的跨度没有被召回时，以该节点为端点的金标准关系便不能在当前候选集合中得到精确匹配；一个存在的 Claim 被赋予错误编号时，则可能形成可被确定性检查发现的引用错误。前者是候选空间不足，后者是结构一致性错误，二者需要不同的处理机制。

这一差异构成本文的研究出发点。训练阶段尝试提高结论类组件的候选质量，推理阶段保留多个结构假设并利用图级反馈进行选择和局部修改。研究重点不是证明大语言模型能够生成结构化文本，而是分析结构约束如何参与候选选择、哪些局部错误可以被修正，以及这些操作在什么条件下值得额外的计算开销。

1.2 国内外研究现状

论辩挖掘的研究路线既包括组件和关系的联合预测，也包括给定组件后的分类与推理。比较相关方法时，需要区分输入是否包含金标准跨度、输出是否覆盖全部子任务，以及评价是否采用相同端点匹配规则。以下按生成建模、结构信号、数据增强、推理修正和跨语料评价组织相关工作，并据此界定本文的研究位置。

1.2.1 组件识别与联合结构预测

Stab 和 Gurevych 围绕说服性作文建立组件与关系分析方法，为 AAEC 上的结构预测提供了任务和标注基础[2]。Eger 等将组件识别与论证结构预测纳入神经端到端学习框架，说明联合建模并非大语言模型出现后才产生的路线[4]。Morio 等研究命题级双仿射解析与任务特定参数化，支持非树状论辩结构预测[5]。这些研究表明，共享表示、子任务依赖以及树与非树结构的区别，均是已有研究问题。

组件分割仍是实际端到端系统的重要环节。Caputo 等在 2026 年提出成对标签标注方案，微调小型开放大语言模型完成细粒度组件分割，并考察自动分割对下游组件分类的影响[6]。该工作聚焦分割及其下游分类，不应被表述为已完成与本文相同的整图关系抽取评价。它提示本文需要单独分析边界错误，而不能仅依据结论类型 F1 解释组件质量。

1.2.2 生成式论辩挖掘与结构化输出

Kawarada 等将论辩挖掘表述为文本到文本生成任务，比较微调模型和提示式模型在不同语料上的表现，是本文的直接生成式基线[7]。Cabessa 等进一步将组件分类、关系识别、关系分类及其联合形式组织为文本生成任务，在 PE、AbstRCT 和 CDCP 上研究多种微调大语言模型[8]。其方法节的输出以组件类型列表及已有组件编号间的关系为核心，不包含原始文本跨度分割这一同口径评价环节，因此不能直接将其 ACC 或关系分类分数填入本文的端到端结果表。

生成表示也从直接展开标签发展到更明确的结构预测。Das 等的 AASP 将论辩结构表示为受约束的预定义动作集合，由条件语言模型自回归地逐步构建结构[9]。本文依据其 2025 年公开的 arXiv 版本讨论该方法。AASP 说明“使用动作和约束构建论辩结构”已有直接相关路线；本文的区分点在于完整候选生成后的图级评估、异常触发和局部回退，而不是动作式建模本身。

2026 年的 ARGUS 系统集成组件分割、组件分类、关系识别与关系分类，并连接符号求解器进行论辩框架分析[10]。该成果发表于 AAAI 系统演示轨道，反映了端到端工具与形式推理的结合方向，但不能据此认定其提供了与本文相同的修正算法或同协议性能比较。结合 Li 等对 LLM 论辩挖掘任务和评估的综述[11]，本文将研究重点限定为可检验的训练增强和推理修正增量，而非“采用大语言模型”这一技术选择。

1.2.3 篇章结构、语义线索与关系推理

Sun 等提出 DENIM，以篇章结构感知前缀辅助生成式端到端论辩挖掘[12]。因此，利用结构信息影响生成过程并不是本文独有的思想。本文的线索感知提示与其相邻，但信号的表示粒度、进入模型的位置及生成后是否执行局部修改不同；这种设计差异需要由对照实验解释，不能仅凭模块名称证明优越性。

2025 年的研究进一步关注结构之外的关系语义。Das 等提取关联组件对之间的关键短语，并将其纳入增强自然语言格式的生成目标；这里的关键短语表达组件之间的概念联系，不等同于固定的结论提示词表[13]。Sun 等的 FOL-AM 把组件类型和关系预测统一为基于一阶逻辑规则的关系查询，研究多跳推理及其解释路径[14]。两项工作均以已分割的组件为前提，其分类或关系结果不能直接与本文从原始文本出发的精确匹配 F1 比较。

上述工作限制了本文可以主张的创新范围：线索利用、逻辑信息和结构建模均已有先例。本文以局部子图组织训练监督，以完整候选图组织推理评估，区别在于监督单位与修改流程。第四章的完整对象评分仍是模型判断，并未实现 FOL-AM 式多跳规则推理，也不构成论证逻辑有效性的证明。

1.2.4 结构保持数据增强

大语言模型数据增强可以通过自然语言条件控制生成内容，但样本质量、标签一致性和分布偏差仍需检验[15]。CoDa 通过从训练实例提取约束来指导生成[16]；SegMix 则在任务相关片段上实施结构感知的混合增强[17]。这些工作说明，利用标签或结构限制合成过程已有基础，不能仅以“结构保持”作为独立的新颖性依据。

论辩挖掘领域的直接近邻是 Bao 等提出的质量导向合成 QOS[35]。QOS 将上下文和组件分别组织为槽位化输入，在改写后恢复跨度并继承组件类型及关系标签。其方法节明确说明，论辩关系没有显式提供给生成模型，而依赖语义保持使原有关系继续成立。因此，本文不能主张首次开展保留论辩标注的改写；需要具体检验的区别是，显式描述并检查改写区域内部及穿越边界的关系，能否减少直接继承标签产生的监督噪声。

关系抽取领域也提供了重要近邻。ConsistRE 利用关系条件和上下文约束组织细粒度生成[38]；CovEReD 通过反事实实体替换研究文档级关系预测的一致性[37]；ODDA 进一步关注低资源关系抽取中增强样本的质量和多样性[39]。这些工作与论辩组件的角色、立场和支持／攻击关系并不相同，但共同限制了“利用关系控制增强”这

一宽泛主张。本文需同时报告标签可靠性、表达多样性、生成与筛选成本，而不能只以通过率解释增强质量。

Wang 等在 2026 年的联合实体关系抽取研究中，将 LLM 生成的增强样本用于半监督学习，并结合一致性正则化、伪标签及迭代反馈[36]。本文对该工作的比较依据出版方可获取的摘要和方法摘录，未取得完整全文，不据此断言其缺少某项细节。已有近邻表明，“数据增强加一致性学习”本身不足以构成本文的创新点；本文将比较范围收紧到论辩改写的影响域定义、跨边界监督检查，以及在相同增强样本上实施的组件—关系对齐学习。

增强还可能引入不可靠的表面线索。Rocha 等发现，补入话语标记对组件识别和分类的帮助因语料而异，并非在所有语料上均有效[40]。其文本标记补全不同于本文继承的连续提示模块，但提示本文需检查线索依赖，而不能把连接词出现视为关系成立的证据。Sun 等针对弱监督论辩挖掘提出组件边界细化与关系去噪[18]，也说明合成监督需要单独处理边界和关系噪声；其训练来源与评价口径不能直接等同于本文的精确跨度整图抽取。

据此，本文将训练侧研究问题限定为：以结论组件及其邻域作为改写区域，在明确的有限因素宇宙中覆盖按端点关联定义的影响对象，包括内部关系、跨边界关系及无关系标签，并将原文与增强文本的对应组件和关系纳入共享表示学习。这里的“保持”是生成约束与审核目标，不是语义标签必然正确的保证。方法贡献须通过普通改写、QOS 式改写、随机中心匹配对照，以及同一批增强数据上有无对齐学习的比较来区分，不能归因于额外样本量、训练预算或类别比例变化。

1.2.5 约束解码、多候选评估与局部修正

语法约束解码通过限制后继 token 控制结构化输出形式，其保证范围取决于实际编码的约束[19]。JSON 可解析不意味着跨度真实、引用完整或关系成立。前述 AASP 将结构动作约束融入生成，而本文在已有候选图上开展评估与修改，二者分别侧重生成过程约束与生成后选择、调整。

Self-Refine 通过反馈和迭代修订改进输出[20]；Huang 等指出，在其研究的推理设置中，缺乏外部反馈的内在自纠错可能无效甚至降低表现[21]。自一致性则通过采样多条推理路径并聚合答案改善所研究的推理任务[22]。这些方法分别提供修订与多采样思想，但不能直接证明本文验证器的可靠性或额外计算的收益。

论辩分析领域已有更直接的候选判断研究。Tran 等针对课堂讨论设计 LLM-refine：在不同 Claim、Evidence 和 Warrant 组合下形成分割候选，再由 LLM 选择合适

结果[23]。该方法处理话轮组件分割与分类，并非对包含任意有向关系的完整论辩图实施局部修正。因此，“生成多个论辩候选再评判”不能作为本文独占的创新点；本文需要强调候选对象包含组件与关系，以及异常、动作、接受条件和回退如何共同定义修正过程。

Xiao 和 Li 在 2026 年提出另一项名为 ARGUS 的研究，将 LLM 自解释转为抽象论辩框架，并以形式语义规定最小代价修复目标[24]。它与前述 Caputo 等的 AAAI 论辩挖掘系统不是同一工作，任务也不同于原文跨度和关系抽取。本文采用抽取对象上的代价敏感效用与预算约束，而不是抽象论辩语义下的最小变更目标；两者的目标、可修改对象和保证范围需要区分。

对组件与关系联合调整也已有相邻研究。Re-Cent 以关系标签引导跨度对抽取，并用关系与跨度对之间的相关性实施修正[43]，说明对象级评分和纠正并非独有机制。Pirozelli 等 2026 年的作者预印本在论辩重构流程中提供可选的组件合并、重写与关系检查步骤[44]。其重构允许改变组件表述，任务表示不同于本文的原文字面跨度抽取，但已足以排除“首次合并组件”或“首次同时处理组件与关系”的笼统表述。

评分目标与最终评价指标之间的关系同样需要明确。F1 是不可按单个预测对象简单相加的指标；Waegeman 等的分析表明，一般标签依赖条件下的 F1 最优决策不能仅由普通边际概率替代[41]。Lipton 等关于校准概率和最优 F1 阈值的结论也有明确条件，不支持将任意基线 F1 直接代入阈值并称为理论最优[42]。概率校准有助于检查预测置信度是否对应经验正确率[45]，但不能保证每次被选中的修改都正确。因此，本文区分代价敏感效用、预测概率校准和最终精确匹配 F1，不把三者视为等价指标。

本文的直接研究基础是作者参与完成的 ICIC 2026 成果：多候选完整图重排序与有界修正 MCR-BR[34]。原方法已经包含组件替换、类型调整和关系修改，本研究并非首次使二者可修改，而是进一步处理组件变化对关联关系的连带影响：将组件修改及受影响关系重建组织为原子事务，以包含完整端点信息的对象评分比较修改前后效用，并在约束和预算内搜索、接受或回退。该深化不再固定全部组件；它也不保证候选空间包含正确答案、不主张全局最优或单次修改必然提高 F1。与原方法、关系-only 修正及同评分的结构化解码进行匹配比较，才能确定事务闭合与搜索策略的独立作用。

1.2.6 中文资源、跨语料迁移与研究定位

跨语料训练已有直接研究。Morio 等提出 MT-AM，利用辅助论辩语料开展端到端多任务训练，并分析不同语料之间的可迁移性[25]。这与本文只在源域训练、在目标域测试的零样本设定不同：前者利用辅助语料扩展训练，后者检验给定源域模型的迁移表现，不能仅凭“跨语料”名称视为相同实验。

Savigny 和 Yun 于 2026 年发表 AMELIA，将 19 个论辩挖掘数据集转为统一格式，并比较单任务微调、多任务微调和分别微调后的模型合并[26]。它补充了统一任务表示与训练策略这一相邻方向；本文的局部增强和测试时图修正应分别说明相对增量，统一格式本身不构成本文创新。其多任务表现不能直接证明本文单一源域的零样本迁移结论。

Feger 等在 2025 年对 17 个英文句子级数据集进行泛化评估，发现所研究模型可能依赖数据集相关词汇线索，在未见数据集上表现下降[27]。该结果来自句子级论辩识别，而非完整论辩图抽取；本文将其作为检查词汇捷径和域内外差异的依据，不据此推断 MCR-BR 已克服这些问题。对于 Cue-aware 分支，尤其需要区分线索带来的域内收益与对目标域表达的适应能力。

中文资源同样需要按任务而非语言名称归类。ORCHID 面向中文辩论的目标无关立场检测和论辩对话摘要，不是 AAEC 式全文组件与关系图抽取数据集[28]。IAM 整合多项论辩挖掘任务，使用英文资源，不能作为中文论辩语料的例证[29]。本文实验使用英文 AAEC 和 CDCP，不主张已经验证中文或多语言能力。

综合以上研究，本文围绕“训练时提高组件—关系监督的可靠性”和“推理时联合恢复组件及其关系”组织两项研究工作。两项工作均以作者参与完成的 ICIC 2026 研究为基础[34]：训练侧继承结论专项适配、线索感知提示与辅助监督，进一步研究影响域约束增强和成对对齐学习；推理侧继承多候选完整图选择与有界修正，进一步研究依赖闭合的修改事务和完整抽取对象的代价敏感评分。学位论文的整体贡献由既有研究及上述深化共同构成，第三、四章分别说明继承内容、新增设计和验证边界。本文不将结构保持、联合预测、概率评分或有限预算各自列为首创，也不凭不同评价协议的已发表分数宣称优于近期方法；新增模块的效能由对应实验单独验证，跨语料实验用于限定其适用范围。

1.3 研究问题与主要研究工作

本文将组件—关系依赖置于训练和推理两个阶段考察。训练阶段改变文本表达而保持图监督，推理阶段保持原始文本而改变错误图预测。两项研究共享任务表示，但具有不同的输入、优化对象和验证条件；推理评分不向训练生成器回传梯度，不构成自训练或强化学习闭环。

1.3.1 研究问题

RQ1：在继承结论组件专项建模的基础上，覆盖内部、边界和 NONE 状态的关系约束，能否提高增强样本的监督可靠性；在同一批增强数据上，成对图因素学习能否进一步改善原始测试文本的严格抽取质量？前半部分检验数据构造，后半部分检验学习目标，不能以“增强后总分提高”同时回答。

RQ2：在固定初始图、候选对象和评分器的条件下，组件集合替换与关系依赖闭合能否恢复顺序局部修正难以处理的组件—关系错误，并取得可接受的误改风险与计算成本？候选是否包含正确对象、评分能否区分好坏修改、搜索是否找到高效用事务是三个不同问题，需要分别验证。

跨语料分析回答上述设计在任务协议变化下的适用边界，不另列第三项算法创新。AAEC 到 CDCP 的粗粒度映射仅为补充；原生域内结果是两项研究的主要证据。

1.3.2 两项方法贡献

（1）面向结论组件的关系感知增强学习。以作者前期结论专项适配、线索提示和句子辅助监督为基础，构造保持局部论辩功能的全文增强样本。新增设计将改写区内外关系及 NONE 状态纳入同一影响域，在标注输运和全文语义筛选之后，以对应组件和关系因素建立成对学习。该研究的贡献单位是“关系约束的数据构造与有效监督接口”，不是把适配器、提示、筛选、散度函数分别列成独立创新。相对既有增强与一致性学习，其价值需由近邻方法、同数据监督消融和匹配中心对照说明。

（2）多候选驱动的依赖闭合论辩图修正。在作者前期多候选重排序与有界修正基础上，以兼容组件集合替换统一组织多种组件操作，将所有受影响关系的删除、保留和重建纳入同一事务，再以固定对象评分及接受规则决定是否提交。新增设计解决“组件变更后哪些证据失效、如何完整比较修改前后状态”的问题。代价敏感效用提供一种可解释的决策实例，局部受限搜索提供预算内求解方式；二者不被表述为全新的通用概率理论或全局最优算法。

表 1-1 研究问题、机制与主要证据

研究问题	关键机制	必要对照	结论边界
RQ1 监督保持与学习	完整影响域、标注输运、成对因素学习	QOS 式增强；同数据去对齐；匹配随机中心	自动筛选不保证语义等价；一致性提高不等于 F1 提高
RQ2 依赖恢复与决策	集合替换、关系闭合、整体接受	同评分顺序修正；关系修正；同目标全局 ILP	有限终止不等于 F1 或全局最优保证
组合与适用边界	训练×推理的 2×2 设计	固定各自检查点内候选；域内与单向迁移分表	不要求超加性增益，不推出任意领域泛化

1.3.3 与本人 ICIC 2026 工作的递进关系

本文以前期论文 Improving End-to-End Argument Mining with LLMs via Multi-Candidate Reranking and Bounded Repair 为研究基础，作者为 Chen Tang、Min Peng 和 Gang Tian，官方公开记录归于 ICIC 2026 Posters Volume I[34]。学位论文的完整贡献可以包含本人前期成果及其深化；相对已公开论文的新增内容则必须单独界定。共同署名不自动确定每项研究的个人分工，最终成果说明须由作者与合作者据实核准。

表 1-2 前期成果与本论文深化内容

研究层次	ICIC 已公开机制	本论文新增内容	结果归属
训练与表示	结论专项适配、线索提示、句子辅助监督	关系影响域约束的增强及成对因素学习	ICIC 原表只支持前期配置
候选生成与选择	多候选组件、关系构建、整图重排序	保留为初始图接口，另建固定候选宇宙	候选增加与选择变化单独归因
组件及关系修正	类型调整、候选跨度替换、删边、局部重预测	兼容集合替换、完整依赖闭合、事务接受	不能说 ICIC 只改关系
评分与验证	覆盖、语义、合法性混合评分及非下降接受	完整对象正确性、固定计数效用、风险及搜索审计	新效用与新实验不沿用旧成绩

原 ICIC 方法已经可以改变组件类型和候选跨度。因此，本论文不把“首次同时修复组件和关系”作为创新点，而将深化集中在集合级恢复、依赖完整性及决策依据。此前固定组件的保守版 MCR-BR-C 提供受限关系对照，本论文主方案 MCR-BR-J 进一步开放组件修改，并以整体事务约束其影响。

1.4 论文组织结构

第一章提出组件—关系依赖问题，梳理相关研究并区分前期成果与新增内容。第二章统一组件、关系和超边表示，定义严格评价与训练—推理接口。第三章给出关系感知增强学习，包括影响域、标注输运、成对监督及其适用条件。第四章给出依赖闭合修正，包括候选空间、评分器、事务求解、接受与回退，并分析算法性质。第五章组织两项方法的独立验证、近邻与强对照、风险成本分析及跨语料协议，区分已有证据与新增实验。第六章总结方法及局限。附录提供材料核验、日志规范、前期成果说明、实现差距和历史数值存档。

第二章 任务表示与方法基础

2.1 论辩组件、二元关系与原生超边

设输入文档在固定评价分词器下表示为$D=(x_1,\ldots,x_n)$。组件定义为$c=(s,e,t)$，其中$1\le s\le e\le n$，跨度采用从 1 开始的闭区间，t为语料规定的类型。实现同时保存原文字符坐标与评价 token 坐标，并检查往返一致。评价 token 与模型子词不是同一对象；改变评价分词器时不能复用旧坐标。

二元关系记为$r=(c_i,c_j,\ell)$，包含完整源、目标组件和关系标签，方向由提供理由或攻击的一方指向目标。预测结构写为$G=(C,R)$。“端到端”指从原始文本评价组件和关系，不提供测试金标组件，并不要求整个系统仅调用一次模型。

CDCP 的多前提关系保留为$h=(S,c_j,\ell)$，其中S为非空源组件集合，c_j为目标。源集合的顺序规范化，但不拆成若干独立二元边。超边匹配要求源集合中全部组件、目标及标签同时正确；漏掉一个源成员不是同一完整关系。二元图是源集合大小为 1 的特例。本文用R统称关系对象，但实现必须保留其实际元数[3][46]。

表 2-1 域内任务与评价边界

语料	组件类型	关系对象	额外边界
AAEC	MajorClaim、Claim、Premise	Support、Attack 二元关系	Claim 对 MajorClaim 的 stance 单列，不转换为普通关系
CDCP	Fact、Testimony、Value、Policy、Reference	Reason、Evidence 原生超边	多前提不静默展开；类型不归并为 Claim/Premise

上述边界依据语料与联合预测研究定义[2][3][46]。CDCP 中的结论角色用于第三章选择增强中心，不改变原生组件标签；第五章跨语料标签归约是单独协议，不能反向改变域内金标。

2.2 合法结构与语义身份

相对于固定语料协议$\mathcal{A}$，以$\mathcal{G}_{\mathcal{A}}$表示合法结构集合。必要检查包括跨度位于原文、类型合法、关系端点存在、关系标签合法，以及语料确实要求的重叠、方向和拓

扑规则。不默认所有论辩图都必须为树或有向无环图，也不为满足解码约束删除不符合假设的测试金标。若语料包含嵌套或多前提结构，应在协议中显式处理。

组件的语义身份由文档、规范坐标和类型共同确定，关系身份由完整端点及标签确定，超边另包含规范排序后的完整源集合。JSON 编号仅用于序列化。编号重排不产生新组件，不计作编辑，也不触发重新打分；坐标或类型改变则是不同对象，不能复用旧端点的关系证据。

本版候选协议统一采用文档级输入。AAEC 枚举同文档不同组件的有向对，禁止自环，但不额外施加跨段或组件类型配对的硬掩码；没有标注边的候选状态为 NONE，不能由 stance 补造边。CDCP 的候选源为所选组件按位置排列后的连续非空区间，目标不能属于源集合；关系标签为 Reason 或 Evidence，其余状态为 NONE。主配置对同一端点槽位采用单一关系状态，若数据审计发现并存标签，则使用显式合法标签组合，不丢弃其中一项。组件重叠、嵌套及其他语料特定限制必须由数据审计固定为协议清单；发现反例时调整协议，而不是删除金标。无环性只作为经语料验证后的可选硬约束，不作为跨语料默认条件。

以下为人工构造示例，token 序列为“Libraries / should / stay / open / longer / . / Students / need / study / space / .”。它只说明坐标和引用，不作为效果证据。

```
{
  "components": [
    {"id": 1, "type": "Claim", "span": [1, 5]},
    {"id": 2, "type": "Premise", "span": [7, 10]}
  ],
  "relations": [
    {"sources": [2], "target": 1, "type": "Support"}
  ]
}
```

统一使用 sources 列表可容纳超边，但不能据此认为旧二元关系模型已经支持多前提。CDCP 的编码、候选构造、评分训练、优化器和评价器必须同时实现超边语义。字段顺序固定为 ID、type、span 等已声明顺序；第三章类型门控只能使用已经输出的前缀，不能读取尚未生成的标签。

2.3 生成建模与参数高效适配

对序列化输出$Y=(y_1,\dots,y_L)$，自回归生成定义为：

$$P_\theta(Y\mid D)=\prod_{t=1}^{L}P_\theta(y_t\mid D,y_{<t}). \quad (2\text{-}1)$$

Transformer 以注意力聚合上下文[30]。本文继承的参考骨干为 Qwen2.5-7B-Instruct，正式实验仍须绑定权重 revision、分词器、软件及硬件，模型系列报告不能替代实际运行记录[31]。生成概率受长度和字段顺序影响，高概率不意味着图中关系成立。

LoRA 在冻结权重上引入低秩更新[32]：

$$W = W_0 + \frac{\alpha}{r} B A, A \in \mathbb{R}^{r \times d_{in}}, B \in \mathbb{R}^{d_{out} \times r}. \quad (2\text{-}2)$$

其中r是秩，α是缩放系数。结论条件门控是前期研究施加于专项分支的任务机制，不是重新提出 LoRA。连续提示利用可学习向量表达任务条件，其基础来自提示调优研究[33]。本论文继承这些机制，并通过第三章的监督接口深化其学习目标，而不将通用参数高效方法计为本文创新。

2.4 候选空间、评分与搜索

多候选选择从已生成的完整图中确定初始状态：

$$G_{rank} = arg\,max_{G \in \mathcal{S}} E_{rank}(G), G_0 = L_{\mathcal{A}}(G_{rank}). \quad (2\text{-}3)$$

其中$L_{\mathcal{A}}$为各方法共用的确定性合法化过程，其规则与变更单独记录；无法得到合法状态时显式失败，不进入后续修正。因而原始重排序胜者与合法初始图不必相同。

候选池是否包含较好结构、评分器是否识别该结构、搜索能否找到更好的可达状态，分别对应覆盖、判断和求解能力。增加候选数只能可能扩大覆盖，不能自动提高后两者。Candidate Oracle 仅在离线分析中使用金标度量当前候选空间，不参与实际测试决策。

第四章在初始选择后另外固定跨度候选宇宙U、带类型组件宇宙$\mathcal{V}$和关系候选宇宙P，并在其上计算完整对象正确性分数。影响域“完整”均相对于显式声明的有限因素宇宙，不意味着枚举任意长度文本跨度或所有非空组件子集。未进入宇宙的正确对象对当前修正器不可达，需要报告覆盖上界。

确定性合法性、模型语义判断和统计校准不能互换。合法性检查只保证遵守编码规则；评分器的概率含义需要真实预测负例和独立校准材料；不同模型参数也不能保证生成器与评分器的误差统计独立。搜索反复选择高分对象还可能放大评分误差，因此须评价最终接受轨迹，而不只报告随机样本上的校准分数。

2.5 严格评价与可比性

对组件或完整关系对象，分别汇总TP、FP、FN，定义：

$$P=\frac{TP}{TP+FP},R=\frac{TP}{TP+FN},F_1=\frac{2TP}{2TP+FP+FN}. \quad (2\text{-}4)$$

新实验主指标采用精确组件 micro-F1 和严格关系 micro-F1。前者要求跨度与类型完全匹配；后者还要求全部端点跨度、类型、方向和关系标签正确。CDCP 超边以整个源集合计数，不把展开后的边数作为原生关系数。另报告边界 F1 及给定金标组件的关系分类诊断，但它们不替代主指标。域内细粒度 Relation-F1 与跨域无标签 Link-F1 分开命名和展示。

每个预测语义对象最多匹配一次金标；重复输出的多余项计 FP。图归一化若预先去重，则同时报告原始重复率，并对全部方法使用相同规则。解析、超长或图验证失败不能删除文档；该文档的金标对象仍进入 FN，失败率另报。数据 ID 缺失或重复须报错。集合分母为零时采用预先固定的零值约定，并保留原始计数。

micro-F1 先汇总对象再计算，不等于分类别 F1 均值或逐文档 F1 均值。F1 采用百分制，差值称“F1 点”。跨种子报告均值及样本标准差；文档级置信区间在每次重采样后重新汇总计数，重复文本按组重采样。旧表的“±”在缺少原始统计记录时保留原符号，不追认成某一种统计量。

2.6 两个阶段的闭环边界

训练阶段闭环为“指定改写槽位—全文回填—影响域检查—接受或拒绝—成对学习”；推理阶段闭环为“提出集合替换—重建全部依赖—整体评分—提交或回退”。这里的闭环指每个阶段内部具有明确验证和失败出口，不是将推理结果重新作为训练金标。

训练金标 → 关系感知增强与成对监督 → 训练后生成器

原始文本 → 多候选完整图 → MCR 初始图

全文跨度提议 → 固定候选宇宙 → 集合替换与依赖闭合

完整对象评分 → 整体接受或回退 → 最终图及修正记录

第三章辅助头在训练金标跨度上学习因素标签，第四章评分器在交叉拟合预测上判断完整对象是否正确。二者的目标和负例不同，不直接共用概率。训练改进在推理

策略固定时评价，推理改进在同一生成检查点及候选宇宙内评价；跨训练检查点不强迫使用完全相同的候选，因为候选质量本身属于训练效果。

2.7 本章小结

本章以完整语义对象统一组件、二元关系及多前提超边，明确候选覆盖、评分可靠性和搜索能力的区分。严格评价与语料特定约束为后续两项方法提供共同接口，也限定了形式性质和实验结果能够支持的结论范围。

第三章 面向结论组件的关系感知增强学习

3.1 研究问题与前期基础

论辩组件的文本表达、篇章角色及其关系不能彼此割裂。将一个结论改写为意思相近的句子，并不自动保证其与原有论据仍构成相同方向和类型的关系；只检查改写区域内部，也可能遗漏该区域与全文其他组件之间的变化。本章研究如下问题：在训练图的组件身份和标签固定时，如何改变局部表达，并把受影响的关系约束转化为生成器可利用的监督。

组件错误还会限制关系恢复。在组件集合固定的预测条件下，令 C_{hit} 为跨度和类型均正确匹配的金标组件集合，R_{reach} 为全部端点都属于 C_{hit} 的金标关系集合。当 $|R|>0$ 时，有 $Recall_{rel} \le |R_{reach}|/|R|$，因为任何正确关系必须首先具有正确端点。该结论同样适用于要求全部源成员正确的超边，但只给出可达上界，不保证可达关系被正确识别，也不证明结论比其他类型更值得优先增强。

本文以作者 ICIC 2026 工作中的结论专项适配、线索提示与句子辅助监督为基础[34]，进一步引入完整关系影响域约束和原文—增强文成对学习。前者明确检查哪些标签可能因改写失效，后者将两个视图间的组件对应和关系对应作用于共享生成表示。专项适配、提示及辅助头共同服务于这一训练侧贡献，不分别计作独立创新。

结构保持增强及一致性学习已有相关研究。QOS 通过论辩结构保持改写继承标注[35]；关系抽取中的 ConsistRE 将关系条件用于文本生成[38]，Wang 等研究关系保持增强与多视图一致性[36]。因此，本章不把“关系条件生成”或“一致性损失”本身作为新思想，研究重点是论辩图中内部、边界和无关系状态的联合约束，以及这些约束相对普通增强的独立作用。

结论中心取样也不以“结论在所有语料中均稀有”为前提。AAEC 保留 MajorClaim、Claim、Premise；CDCP 保留 Policy、Value、Fact、Testimony、Reference。Policy/Value 作为本章专项模块的触发类别，不等于它们与 AAEC 的 Claim 语义相同。类型频次、关系度和分类难度分别统计；AAEC 的 stance 属性不转为普通关系，缺少普通关系的 MajorClaim 仍可用于组件学习。

3.2 结论专项生成表示

3.2.1 类型条件低秩适配

模型以 Qwen2.5-7B-Instruct 为生成骨干，冻结基础权重，在注意力投影中配置全局与结论专项低秩分支。LoRA 的低秩参数化沿用已有方法[32]。对于 $W_0 \in \mathbb{R}^{d_{out} \times d_{in}}$，定义

$$h'_t = W_0 h_t + \frac{\alpha}{r} B_g A_g h_t + g_t \frac{\alpha}{r} B_c A_c h_t, A_\cdot \in \mathbb{R}^{r \times d_{in}}, B_\cdot \in \mathbb{R}^{d_{out} \times r}. \quad (3\text{-}1)$$

全局分支参与全部位置的计算，结论分支由 $g_t \in \{0,1\}$ 控制。组件字段按 id、type、span 序列化。只有已经可见的生成前缀包含完整闭合的结论类型值时，门控才在当前组件的后续字段开启，并在该组件对象结束后关闭。AAEC 的触发类型为 Claim/MajorClaim，CDCP 为 Policy/Value；输入位置、尚未闭合的类型字段和关系区域均令 $g_t = 0$。教师强制训练使用相同前缀规则，不读取当前位置之后的金标类型。

该门控表示“已选择结论类型之后的字段适配”，主要直接影响随后生成的跨度等内容，不能回溯纠正同一组件已经输出的类型。参考配置取 $r = 16$、$\alpha = 32$，并设置单一全局 rank-32 分支作为参数量匹配对照。两条 rank-16 分支与单条 rank-32 分支的参数规模可比，不意味着激活路径和运行成本相同。

3.2.2 线索提示与原有监督

连续提示采用可训练向量提供输入条件，其基础来自参数高效提示调优[33]。本章对 therefore、thus、in conclusion、consequently、hence、to conclude 进行不区分大小写的词边界匹配。命中任一短语时，在聊天模板的输入嵌入之前插入四个向量 $P_i \in \mathbb{R}^d$；未命中则不插入占位向量。提示位置不计入原文坐标。

词典只决定是否启用提示，不直接赋予结论标签。显式标记可能出现在非结论表达中，隐式结论也可能没有标记。有关话语标记增强的研究表明，其收益不能由标记数量直接推定[40]；因此，原始视图和增强视图各自依据输入文本触发提示，而不强制复制触发状态。

生成目标对有效回答 token（含 EOS）取平均，聊天输入和提示向量不参与该项损失：

$$L_{gen}(x, G) = -\frac{1}{T_y} \sum_{t=1}^{T_y} \log p_\theta(y_t \mid x, y_{<t}). \quad (3\text{-}2)$$

句子辅助任务沿用 ICIC 专项训练思路。根据句末标点和文档结尾确定句子边界，对输入原文对应的最后一层隐藏状态进行句内均值池化，经线性层和 sigmoid 得到 $\hat{z}_i$。句子与结论类金标跨度有交集时令 $z_i=1$，否则为零；跨句组件可以标记多个句子。定义

$$L_{sent}=-\frac{1}{N_s}\sum_{i=1}^{N_s}\left[z_i\log\hat{z}_i+(1-z_i)\log(1-\hat{z}_i)\right],\quad L_{ICIC}=L_{gen}+\lambda_{sent}L_{sent}. \tag{3-3}$$

参考配置取 $\lambda_{sent}=0.5$。句子头只读取输入表示，不池化金标回答；其监督用于共享表示学习，不在推理输出中增加字段。本节明确当前方法的技术接口，不将这些配置视为已经追溯确认的历史实验实现。

3.3 完整关系影响域约束的文本增强

3.3.1 改写区域与关系因素

对训练金标图 $G=(C,R)$，优先选择结论角色组件及其直接入邻居作为可改写集合 A；超边的入邻居包含完整源成员。其余原文保持只读。不存在合适结论中心时，按固定规则选择一般组件。中心规则在增强前确定，不利用验证集或测试集标签选择易改写样本。

记 $\Omega(C)$ 为协议允许的完整端点组合集合，因素 $\omega=(S,v)$ 由非空源组件集合 S 和目标 v 构成。AAEC 中 $|S|=1$，枚举全部合法有向组件对；内部正边、边界正边和其余合法对均纳入候选。因素标签 y_ω 为协议规定的关系状态，无标注关系时记作 NONE。若协议允许同一端点组合具有多个标签，则使用合法标签组合表示状态，不能通过任取一个标签丢失监督。

CDCP 保留 $(\{c_{i_1},\dots,c_{i_k}\},c_j,\ell)$ 的原生多前提超边，$\ell\in\{Reason,Evidence\}$，源成员按原文顺序规范化，不展开为若干独立二元关系。训练因素宇宙包括全部金标超边的端点组合，以及满足源范围规则、最多含三个源成员的候选组合；超过三个源成员的金标关系全部保留。NONE 仅在这一声明的有限宇宙中定义，并不声称枚举了组件集合的所有子集。连续性依据所选组件序列判定，不能以原文字符之间没有间隙替代。该预算使超过三个源成员的训练因素缺乏同元数 NONE 对照，形成长度相关的监督偏置，需分元数报告诊断，不能将此辅助头作为长超边正确性评分器。

设 $V(\omega)=S\cup\{v\}$，完整影响域定义为

$$\mathscr{D}_A=\{\omega\in\Omega(C):V(\omega)\cap A\neq\varnothing\}. \tag{3-4}$$

二元情形即 $\{(u,v):u\in A\vee v\in A,(u,v)\in\Omega(C)\}$。两端均在 A 中的因素属于内部因素，只有部分端点在 A 中的属于边界因素。NONE 表示当前标注协议中的无边状态，不是两段文字在任何解释下都不存在联系。本章的“完整”指预先声明宇宙内按端点关联定义的影响因素均被检查，不是全文语义影响完备性的保证。改写仍可能经指代或篇章语境影响两个只读端点，其域外漂移纳入人工审计。若因资源限制裁剪，则记录因素覆盖率，并将该设置标记为近似版本。

3.3.2 条件生成与坐标输运

增强模型接收全文、可改写组件的槽位和类型、只读端点目录及影响域标签。条件可采用“全部合法端点目录、显式正关系表、其余因素为 NONE”的无损编码，避免逐条重复大量无边因素；验证和训练时仍按展开后的因素执行。输出限定为组件 ID 到替换文本的映射，不允许新增组件、修改类型或自行重建关系表。

程序按原始字符区间执行槽位替换，随后对完整文档重新分词，建立组件对应

$$\varphi:C\longrightarrow C',(s_c,e_c,t_c)\longmapsto(s'_c,e'_c,t_c).\quad(3\text{-}5)$$

组件 ID 仅用于追踪身份，新的跨度由回填文本计算。只读组件也可能因前文长度变化而移动，因而必须更新全部组件坐标。φ 是组件之间的双射，不是新旧 token 之间的双射。关系和超边的全部端点按 φ 输运，得到 $\varphi(G)$。重叠槽位、坐标往返不一致或无法无损输运的尝试直接拒绝，原始训练样本仍保留，不通过删除异常金标来迁就增强操作。

例如，结论 c_1 与论据 c_2 属于改写区，c_2 同时支持只读结论 c_3。改写必须检查 $c_2\to c_1$ 和 $c_2\to c_3$，还要检查该区所涉及的原 NONE 因素。即使改写后的 c_2 仍支持 c_1，若它改变了对 c_3 的论证作用，该变体也不能继承原图。此例只解释检查范围，不作为实验案例。

3.3.3 接受规则与来源控制

筛选首先检查格式、槽位身份、坐标往返和全部端点引用；随后在全文上下文中检查论辩角色、指代、否定、模态和立场，并逐项核对影响域中的关系方向、标签及 NONE 状态；最后检查重复程度和机械添加结论词等退化改写。拓扑检查不额外施加数据协议未要求的无环性等限制。

语义验证器采用独立于增强模型参数的固定模型与提示。验证时向其提供待判定的文本、跨度及任务定义，不预先给出待判断因素的金标答案；验证器先分类，再由

程序与原标签比较。各阶段记录判定和拒绝原因。独立参数不等于误差独立，模型判断也不能充当语义保持证明，因而质量审计同时盲查接受样本、拒绝样本及普通改写样本。

任何一个受检标签发生漂移均拒绝整个变体，不删除失败关系后继续使用剩余部分。参考生成预算为每篇源文档最多四次尝试、最多接受两个变体；预算耗尽后保留已有通过样本，无通过样本则只保留原文，不无限重试。生成版本、提示、随机种子、源组件、φ、拒绝原因和 token 成本共同存档。原文及其全部变体始终属于同一数据划分。

全文回填并不自动重平衡类别。若源文档 d 含 $N_{d,\tau}$ 个类型 τ 的组件，接受 a_d 个变体，则存储样本中的该类总数为 $N'_{\tau}=N_{\tau}+\sum_{d} a_d N_{d,\tau}$。各源文档接受数相同会同比增加所有类型，而非只增加结论。因此，类别分布、表达多样性和标签保持分别报告，不能用增强数量替代有效性证据。多样化增强已有相应研究[39]，本章同时考察约束强度、接受率与表达变化的代价。

3.4 共享表示上的成对图因素学习

3.4.1 输入表示与训练头

单纯复制标注没有显式约束原文与改写文本的预测行为。本章在共享生成器上增加组件类型头和关系状态头，使用金标跨度定位训练因素。下游生成器输入只含任务指令及原文或增强文，不包含增强生成阶段的金标槽位、类型和关系条件；这些标注只用于定位监督及计算损失。令 h_i^x 为模型输入子词的隐藏状态，以原文字符跨度和分词器 offset mapping 确定组件对应子词集合 $B_x(c)$，排除聊天模板及连续提示位置，并显式补偿其索引位移；无法一致映射则报错。句子头使用同一映射规则。以 h_{end}^x 表示全文输入结束且回答尚未开始处的隐藏状态，定义

$$u_c^x=\mathrm{MeanPool}_{i\in B_x(c)} h_i^x,\quad p_C^x(c)=\mathrm{softmax}\, f_C([u_c^x;h_{end}^x]). \tag{3-6}$$

因果模型的早期 token 只能访问左侧上下文，因此跨度池化本身不是双向编码。拼接 h_{end}^x 提供一个可访问完整输入的上下文通道，但不等同于所有跨度 token 都具有双向注意力。该向量不能取自金标回答末尾，组件头也不输入待预测的金标类型。

关系头显式区分源和目标，写为

$$p_R^x(S,v)=\mathrm{softmax}\, f_R([\mathrm{Pool}(\{u_c^x:c\in S\});u_v^x;h_{end}^x;\eta(S,v)]), \tag{3-7}$$

其中 f_C、f_R 为两层感知机，$Pool$ 取源成员表示的算术均值。η 包括源成员数、源起点的最小值和均值、源终点的最大值和均值，以及目标起止位置；坐标均除以文档 token 数，不包含金标类型或关系标签。二元关系使用单一源表示；超边按规范顺序组织源成员，并以完整源集合和目标为监督对象。该头的输出包含 NONE，不能把“某个源成员与目标相关”替代为“整个超边正确”。两个头均只用于训练，金标跨度定位不向测试阶段提供任何组件或标签。

3.4.2 对齐与金标锚定

定义

$$A^{+}=A\cup\bigcup_{\substack{\omega\in\mathscr{D}_A\\ y_\omega\neq\mathrm{NONE}}}V(\omega). \qquad (3\text{-}8)$$

即改写组件以及通过正边或超边相连的只读端点。NONE 因素进入关系项，但不因此把全部远处组件都纳入组件对齐。对于一个通过筛选的视图 x'，组件对齐为

$$L_C^{align}(x,x')=\frac{1}{|A^{+}|}\sum_{c\in A^{+}}JS\left(p_C^{x}(c),p_C^{x'}(\varphi(c))\right), \qquad (3\text{-}9)$$

其中 $JS(p,q)=\frac{1}{2}KL(p\|\overline{p})+\frac{1}{2}KL(q\|\overline{p})$，$\overline{p}=(p+q)/2$。不对任一视图停止梯度。

将影响域划分为正关系组 D_{+} 和 NONE 组 D_0，令 $\mathscr{B}=\{b\in\{+,0\}:|D_b|>0\}$。关系对齐采用组间、组内两级平均：

$$L_R^{align}(x,x')=\frac{1}{|\mathscr{B}|}\sum_{b\in\mathscr{B}}\frac{1}{|D_b|}\sum_{\omega\in D_b}JS\left(p_R^{x}(\omega),p_R^{x'}(\varphi(\omega))\right). \qquad (3\text{-}10)$$

这样可避免数量较多的 NONE 因素仅凭数量淹没正关系。当 $\mathscr{D}_A=\varnothing$ 时，该项置零并跳过空域关系检查，不人为添加关系；全文其他关系的生成监督仍保留。A^{+} 为空时组件对齐也置零。

低 JS 可能来自两个视图一起预测错误，故每个视图同时接受金标监督。组件头交叉熵在该视图全部组件上取平均，关系头交叉熵在声明因素宇宙的正关系与 NONE 非空组之间分别归一化；二者相加记作 $S(x,G)$。空组件或空因素部分分别置零。金标锚定用于限制退化一致性，不构成排除全部退化解的数学保证。

3.4.3 按源文档归一化及梯度接口

设文档 d 接受 m_d 个变体，同源头监督定义为

$$L_{heads,d}^{sup}=\frac{S(x_d,G_d)+\sum_{j=1}^{m_d}S(x'_{dj},\varphi_j(G_d))}{1+m_d}. \quad (3\text{-}11)$$

成对项同样先在该文档的 m_d 个变体上取平均，记作 $\overline{L}_{C,d}^{align}$、$\overline{L}_{R,d}^{align}$。总目标为

$$L_d=L_{ICIC}(x_d,G_d)+\rho\frac{1}{m_d}\sum_{j=1}^{m_d}L_{ICIC}(x'_{dj},\varphi_j(G_d))$$
$$+\lambda_{sup}L_{heads,d}^{sup}+\lambda_C\overline{L}_{C,d}^{align}+\lambda_R\overline{L}_{R,d}^{align},L=\frac{1}{N}\sum_{d=1}^{N}L_d. \quad (3\text{-}12)$$

约定 $m_d=0$ 时整项增强损失和两个对齐项为零，原文生成、句子监督及原文头监督仍保留。ρ 控制同源增强的总权重，避免接受更多变体的文档仅因复制数量获得成倍权重。外层按源文档等权采样；梯度累积的最后一个不足批次按实际源文档数归一化。其余损失系数在验证集确定，测试集不参与选择。

对齐损失经输入隐藏状态回传共享全局 LoRA，并在相应视图触发时更新连续提示。输入阶段的结论门控为零，因此不能声称该损失直接更新结论专项分支；后者仍由原文及增强文的生成损失训练。实现检查单独反传对齐项，验证至少一个共享生成参数具有非零梯度，同时检查隐藏状态未被分离、上下文未包含金标回答，防止只有辅助头学习而生成器不变。

上述训练头预测给定金标跨度条件下的标签，不预测跨度是否正确，其概率也不是完整对象正确率。第四章在实际预测错误上训练的推理评分器与之分开；本章不将两个头直接用作图修正的接受依据。

3.5 算法过程与性质

算法 3-1 概括训练数据构造和参数学习，两阶段均只访问训练划分。

算法 3-1 关系感知增强学习

输入：训练文档及金标图、数据协议、固定增强与验证模型、每文档尝试和接受预算。输出：带结论专项表示的生成器。

1. 按源文档确定划分，检查坐标及标签协议，建立因素宇宙 $\Omega(C)$。

2. 选取改写集合 A，构造 $\mathscr{D}_A$，保留原文和完整金标图。

3. 在预算内生成槽位文本，回填全文并建立 φ；结构检查失败则记录并拒绝。

4. 检查角色、全部影响因素和表达退化；任一检查失败则拒绝整个变体，通过则保存视图及映射。

5. 对每篇源文档及其通过变体计算生成损失和句子损失，保留原有专项门控规则。

6. 从回答之前的输入表示计算两类头监督和非空域对齐，按同源变体及源文档两级归一化。

7. 优化共享可训练参数和辅助头；验证及测试时移除辅助头，仅以输入原文执行生成。

性质一：标注输运保持。 若可改写槽位互不冲突、φ 为组件双射，且类型和每个完整关系因素均按 φ 输运，则 G 与 $\varphi(G)$ 的组件数、组件类型及带方向和标签的关联结构保持。证明为：双射保证每个原组件恰对应一个新组件；端点逐一映射保证每条关系及超边既不新增也不丢失，逆映射可恢复原图。该性质针对标注对象成立，不能证明改写后的自然语言仍支持这些标签。

性质二：单因素预测稳定的充分条件。 对某一因素，设原视图正确类别为 y，分布 p 的间隔为 $\delta = p_y - max_{k \neq y} p_k > 0$。若增强视图分布 q 满足 $\| p - q \|_\infty < \delta / 2$，则 $arg\,max\, q = y$。因为对任意 $k \neq y$，$q_y - q_k > p_y - p_k - \delta \geq 0$。这只是逐因素条件，平均 JS 降低不意味着每个因素均满足该界，也不能使原先错误的预测自动正确。

两项性质解释了标签输运与预测约束的作用范围，不构成新的通用等变学习定理。本章约束的是辅助图因素分布，而非证明自回归生成的完整图分布严格等变。文本语义漂移、验证器偏差、金标噪声与候选宇宙外关系均可能破坏预期效果；最终判断仍以未参与增强的真实测试文本为依据。

3.6 独立实验协议

本章实验固定推理流程，不启用第四章的新修正机制，以隔离训练侧变化。核心比较包括：ICIC 风格原始训练；不提供显式关系的普通槽位改写；QOS 或明确标注差异的重实现；仅内部正边条件与事后边界检查的局部增强；完整影响域数据加普通监督；完全相同增强数据加成对图因素学习。后两组共享样本和更新预算，以区分数据质量与学习目标的作用。

进一步分别移除边界约束、NONE 约束、组件对齐和关系对齐；保留有金标头监督但没有 JS 的对照，避免将辅助监督收益全部归给一致性。结论中心与随机中心按组件数、改写长度和关系度匹配，并报告专项分支参数量匹配、有/无线索分组及线索扰动结果。共享参数和训练辅助头的参数量分别计入成本。文档数、训练更新数、解码设置和检查点选择规则保持一致；等接受样本量和等生成验证成本分别比较，不混称同预算。

主要指标为精确组件 micro-F1 和完整端点、类型、方向及标签均正确的严格关系 micro-F1，另报分类别精确率与召回率。CDCP 以完整超边评价，文献投影协议单列。随机种子数按第五章预先登记，最低三次、资源许可优先五次，以源文档为单位进行配对重采样；组件和关系不能当作彼此独立的重采样单位。

机制诊断包括接受率、各类标签漂移、意外新增关系、人工抽查一致性、表达变化和计算成本。CovEReD 的研究说明，增强一致性与原始任务表现需要分别检验 [37]，因此辅助头准确率或 JS 降低不替代最终抽取效果。本章给出新配置的评价协议；已有数值的归属、历史协议及可比性在第五章集中说明，不将旧结果作为新增机制已获验证的证据。

3.7 本章小结

本章在 ICIC 结论专项训练基础上，将增强约束从局部正关系扩展到声明因素宇宙内的完整影响域，并通过槽位映射建立原文与增强文的组件、关系对应。成对辅助头在保留生成和句子监督的同时约束共享表示，使标签输运与参数学习具有明确接口。其适用边界是：结构保持不等于语义保持，辅助一致性不等于生成正确率，结论中心也不自动带来类别重平衡。下一章保持输入文本不变，研究预测组件及其依赖关系的联合修正。

第四章 多候选驱动的依赖闭合论辩图修正

端到端论辩挖掘的预测错误不仅表现为关系标签错误，也包括组件遗漏、多检、边界偏移以及组件划分粒度不当。组件是关系的端点，修正一个组件可能同时改变多条关系的身份与合法性。因此，组件修正不能只比较节点自身的得分，关系修正也不能始终假设上游组件正确。本章在前期多候选重排序与有界修正方法 MCR-BR 的基础上，研究有限候选空间内的组件—关系协同修正。

本章方法记为 MCR-BR-J。其中，J 仅标识联合修正版，不构成独立于本章研究内容的第三项创新。方法保留完整候选图生成与初始重排序，将修正单位扩展为冲突闭合的组件集合替换，并同步重建所有依赖于变化端点的候选关系。通过固定文本证据评分、代价敏感效用和有限预算，使每次修改的对象、依据及停止条件保持一致。本章首先说明与前期工作的继承关系，再给出候选表示、联合事务、求解算法及其理论边界。

4.1 研究问题与前期方法的继承

作者前期 ICIC 工作提出了多候选重排序与有界修正框架，在不同组件假设上构建完整论辩图，并结合连接覆盖、语义连贯性和形式合法性选择候选。原版修正不仅处理关系，还包含组件类型转换与跨度替换，因而不能将“允许组件修改”本身作为本章新增贡献。为区分版本，以下将原版记为 BR-O，将固定组件的保守关系修正版记为 BR-C。[34]

BR-C 固定初始组件、覆盖评价节点及其阈值，只删除关系或重新预测限定源节点的出边。这一约束避免了组件被错误修改，同时明确了其能力上限：若正确跨度从未进入初始图，则仅调整关系不能恢复该组件。BR-O 的修改范围更宽，但按节点或有限出边组织动作时，不能完整表达“一组旧组件被一组新组件替换，同时重新判断全部相关关系”的决策。特别是在拆分、合并和类型改变中，沿用旧端点编号并不意味着原关系对象仍然有效。

已有联合结构预测使用因子或整数规划表达组件和关系之间的约束，组件与关系联合建模本身已有明确研究基础。[46]近期 Re-Cent 也结合跨度抽取与关系纠正，说明“抽取后再纠正”不是新的通用范式。[43]另有框架讨论组件合并、改写与关系重建；本章则保持原文不变，以可定位跨度为对象，不生成隐含前提。[44]本章的具体研究对象是：在 MCR 已保留的竞争假设以及有限补充候选中，如何以可变组件集合

为修改单位，闭合处理其入边、出边及原无边状态，并依据同一评分体系比较完整修改结果。

据此，本章将问题定义为有预算的结构选择。给定原文 x、初始图 G_0 和预先构建的候选宇宙，算法选择有限次结构事务，输出合法图 G。候选空间限定可恢复的对象，事务邻域限定一次允许跨越的结构变化，评分器提供修改依据，预算限定搜索代价。这四者分别影响性能，不能仅用最终 F1 的变化解释全部机制。

4.2 多候选完整图与初始选择

4.2.1 组件假设及完整图生成

给定文档 x，生成器通过预先固定的采样和提示配置产生 K 组组件假设：

$$\mathscr{C}=\{C^{(1)},\dots,C^{(K)}\}. \quad (4\text{-}1)$$

每个组件包含原文跨度与类型。随后，关系生成器在固定的 $C^{(k)}$ 上预测关系，形成 $G^{(k)}=(C^{(k)},R^{(k)})$。关系阶段不得悄悄重写组件；无法解析的输出记为失败，失败调用仍计入总成本。同一候选的原始输出、解析结果及坐标转换均保留，避免将后处理改变误认为生成模型的预测。

这一流程比较的是完整结构，而非先依据组件置信度选定一组组件，再只对该组预测关系。不同候选之间的边界、类型和连接差异，既为初始选择提供信息，也为后续集合替换保留竞争假设。全部候选来自预测，不使用评价集金标准补充遗漏对象。

4.2.2 原始覆盖评分的保留与边界

为保持与前期方法的可比性，初始选择沿用原 MCR 的加权形式：

$$E_{rank}(G)=0.4E_{dens}(G)+0.4E_{coh}(G)+0.2E_{val}(G). \quad (4\text{-}2)$$

设 $\mathcal{Q}(G)$ 为预测图中的覆盖评价节点，$p_r\in\{0,1\}$ 为关系语义验证结果，$d_{coh}^{\mathrm{in}}(j)$ 为指向节点 j 且通过验证的关系数，则

$$E_{dens}(G)=\frac{1}{|\mathcal{Q}(G)|}\sum_{j\in\mathcal{Q}(G)}min\left\{\frac{d_{coh}^{\mathrm{in}}(j)}{\tau_j},1\right\},E_{coh}(G)=\frac{1}{|R|}\sum_{r\in R}p_r. \quad (4\text{-}3)$$

空覆盖集合或空关系集合的对应分量取零。AAEC 的覆盖节点为预测 Claim，CDCP 为预测 Policy/Value；MajorClaim 不因缺少普通关系而被强制补边。本版确定性参考配置按节点是否存在出边设置结构角色阈值：无出边取 $\tau_j=2$，否则取 $\tau_j=1$。

这是本版明确采用的设计配置，不反推为全部历史实验已经核实的执行细节。CDCP 原生超边按完整关系计一次入边，不按源成员数重复增加覆盖。

E_{val} 在可解析性、跨度、类型及引用等全部协议检查通过时取 1，否则取 0；无环等结构条件仅在相应数据协议要求时启用。同分时按候选生成槽位选择。加权得分不等价于合法性硬约束，因此选出的候选还需通过所有对照共用的确定性合法化步骤，得到 G_0。本版基础步骤仅执行无歧义的坐标规范化、相同语义对象去重及 ID 重排，并同步更新引用；歧义 ID、越界、非法类型或剩余结构冲突直接报失败，不由此阶段额外猜测跨度、删除冲突组件或补边。规则、变更和成本单独记录；不能得到合法状态时不进入学习型修正。

覆盖与连贯性共用 p_r，不是相互独立的证据。覆盖集合与当前边数还会改变均分的分母，删除低分对象或改变组件类型可能提高平均分，却未必提高真实准确率。本章因此保留上述评分用于初始候选选择，但不将它直接延用为可变组件修正的接受目标。

4.3 固定候选宇宙与语义对象表示

4.3.1 跨度候选及冲突关系

修正开始前构建有限跨度集合 U，其来源包括：K 个候选图中的全部跨度；独立全文跨度头给出的补充候选；有限边界扰动、相邻候选的合并跨度以及长跨度的切分候选。独立跨度头采用文本编码器与边界或跨度预测头，使所有生成候选共同遗漏的区域仍有进入修正空间的机会。补充候选数量、最大长度及扰动范围均在开发阶段固定，搜索过程中不再扩展 U。

对跨度 $u \in U$，状态为 NULL 或一个合法组件类型。令 $\mathscr{V} = \{(u,t) : u \in U, t \in \mathcal{T}(u)\}$ 为带类型组件候选集合，预测组件满足 $C \subseteq \mathscr{V}$。同一跨度至多选择一个类型；不同跨度是否冲突遵循数据协议。若不允许重叠，则按两两交叠定义冲突；若允许特定嵌套，则保留合法组合。重叠的传递连通块中可能存在互不冲突的两个跨度，不能用“整个连通块至多选一个”替代两两冲突判断。

组件语义键由文档哈希、坐标版本、起止位置及类型组成，显示编号仅用于序列化。类型或边界变化均产生新语义对象，而不是对旧编号的无成本改名。原始字符坐标与模型 token 坐标保留映射，去重与精确评价使用同一规范化规则。

候选构建必须包含合法化后初始图的全部对象，不能只保留合法化前的原始候选。字符坐标、评价 token 及模型子词分别维护映射；跨度编码使用第二、三章的 offset mapping 规则，评价不直接使用模型子词编号。

4.3.2 关系候选与无边状态

在 $\mathscr{V}$ 上构建固定关系候选集合 P。二元关系对象包含完整源组件、目标组件、方向与关系标签；其语义键随任一端点的跨度或类型变化而变化。P 包含初始关系，并覆盖预算允许的合法端点与标签组合。不存在关系以 NONE 状态表示：它不是需要输出的边，而是某一候选关系槽位未选择任何正关系标签。

关系候选必须覆盖初始图中没有边的可行组合，否则算法只能删除或重标已有关系，无法补回遗漏关系。明显不相容的端点组合可提前排除，资源裁剪则需保存原因和候选来源。候选召回上限分别在组件、完整关系及所需集合替换层面衡量；“金标准对象在池中”和“当前事务邻域可以恢复它”并非同一个条件。

4.4 冲突闭合的集合替换与关系事务

4.4.1 集合替换动作

令当前组件集合为 C，一次提议指定新增集合 B 与主动删除集合 D_0。首先将 $B \cap C$ 中语义未变的对象视为保留项，从 B 及 D_0 中同时移除，再补齐所有与新增对象冲突的旧组件：

$$D = D_0 \cup \{c \in C : \exists b \in B, Conflict(c, b)\}, C' = (C \setminus D) \cup B. \quad (4\text{-}4)$$

B 内部必须兼容。即使某个冲突组件位于提议窗口之外，也必须进入 D；否则，新状态仍可能含有非法重叠。扩大删除集合超过预算时，提议被拒绝，不能通过忽略窗口外冲突获得虚假的局部可行性。

主邻域包含 $0 \to 1$、$1 \to 0$、$1 \to 1$、$1 \to 2$ 和 $2 \to 1$，对应遗漏补回、多检删除、类型或边界替换、拆分和合并。本版初始设计限制每事务 $|D| + |B| \le 3$。限制在冲突闭合后检查，而非只按最初指定的集合计数。更大邻域属于预算敏感性设置，不另列为方法创新。

4.4.2 依赖闭合与纯关系动作

令 $A = D \cup B$ 表示变化的完整组件对象，P_A 包含 P 中接触 A 任一对象的全部候选关系。该集合同时覆盖入边、出边、原有正关系和原 NONE 槽位。删除旧组件

后，所有引用旧语义键的关系必须删除；加入新组件后，其合法入出关系重新参与选择，不能按旧显示编号继承。

对于组件保持不变但关系存在错误的情形，保留纯关系提议 S_R，定义事务关系空间

$$P_{tx}=P_A\cup S_R. \quad (4\text{-}5)$$

RelationOnly 事务取 $D=B=\varnothing$，通过 S_R 表达增边、删边、换标签或反向。一个槽位进入 S_R 时，其全部合法标签候选一同进入；反向修改同时包含两个方向，避免仅在已有方向中重选标签。

对每个 C'，算法先求出受影响关系的最优可行补全，再比较完整的 $G'=(C',R')$，而非先依据组件分数提交 C'。事务外关系保持固定，但全局约束在整图上检查。如果新状态需要修改事务外关系才能合法，则显式扩大事务并重新计费，或拒绝提议。依赖闭合保证没有漏记端点变化造成的关系失效，并不意味着自然语言的语义影响只发生在一跳范围内。

4.5 完整对象评分及训练外候选学习

4.5.1 固定文本证据评分器

评分器分别估计组件与关系完整对象精确正确的概率：

$$q_C(c\mid x),q_R(r\mid x). \quad (4\text{-}6)$$

组件头根据跨度及全文表示预测 NULL/类型分布。关系头接收端点跨度表示、待核查端点类型、方向、关系标签及全文证据，以二元监督判断整个关系对象是否正确。其正例要求端点跨度、端点类型和关系标签同时满足精确匹配；仅在金标准端点上训练的关系分类准确率，不能替代这里的对象正确性概率。

本版采用固定文本编码、跨度 MLP 与有向端点组合 MLP 的基本实现。评分器与生成器使用不同参数，但不据此假定其错误彼此独立。评分器也不同于第三章用于辅助训练的预测头：前者学习真实候选中的正确与错误对象，后者服务于原文和增强文的配对监督。

同一文档的文本表示、模型版本、校准参数及候选得分在搜索开始前冻结。缓存同时绑定完整语义键，不以显示编号代替端点身份。不将当前图的度数、已选边数或

动态重编码加入 q，从而使同一个对象在不同搜索状态中具有相同分值。评分失败不默认为零概率，而是按预先声明的失败策略拒绝相关提议并记录。

4.5.2 OOF 候选与校准

评分器需要接触实际推理产生的错误，而不是只区分人工构造的容易负例。训练部分按源文档分组进行 out-of-fold（OOF）候选生成。对每一持出折，生成器和跨度头均不得训练于该折文档及其增强变体，再对持出文档产生完整候选、边界扰动和关系组合。候选与训练金标准进行精确匹配后，形成评分器监督数据。用于比较两种训练方法时，OOF 池共同包含两类生成器的候选并保留来源，避免评分器只适应某一生成器。

错误跨度和错误端点类型构成完整对象负例，原 NONE 槽位中的关系候选也必须进入训练池，但其正负标签由训练金标准决定，不能因生成器未输出该边便将其标负。若过采样困难负例或正例，应保存采样概率；用于校准的数据保持自然候选分布，不能以人工平衡比例替代部署先验。开发集按源文档分为校准部分与策略选择部分，分别用于概率校准及代价、阈值和预算选择。最终模型只在规定训练数据上重训，测试集不参与上述过程。

本版以训练内三折 OOF 作为初始配置。折数和开发划分须随复现实验一并报告，而非被视为历史实验的已核实设置。OOF 生成器的训练规模小于最终生成器，候选分布可能发生变化，因此校准部分还需检查最终生成器产生的候选。候选级校准并不直接保证被搜索选中的动作可靠；后续评价还需区分有益、中性和有害修改，观察选择后偏差与多轮误改。

4.6 代价敏感效用与保守接受门

4.6.1 固定计数效用

对对象类别 $X \in \{C, R\}$，设固定系数 $0 < \kappa_X < 2$，定义

$$\Phi_X(G) = 2\sum_{o \in X(G)} q_X(o \mid x) - \kappa_X |X(G)|, \Phi(G) = w_C \Phi_C(G) + w_R \Phi_R(G), \quad (4\text{-}7)$$

其中 $w_C, w_R > 0$。主配置以 $w_C = w_R = 1$ 为起点，κ_X 在开发阶段预先声明的范围内确定并冻结。基线 F1 可以用于初始化候选值，但不构成最优性依据。若为平衡两类对象数量而缩放，只使用固定训练集尺度，不除以当前图的组件数或关系数。

该效用具有明确的代价解释。令 Y_X 为真实对象集合，且暂假设 $q_X(o\mid x)=P(o\in Y_X\mid x)$。由 $FP_X=\lvert X(G)\rvert-TP_X$、$FN_X=\lvert Y_X\rvert-TP_X$，得到

$$\Phi_X(G)=(2-\kappa_X)\mathbb{E}[\lvert Y_X\rvert\mid x]-\mathbb{E}[\kappa_X FP_X+(2-\kappa_X)FN_X\mid x]. \quad (4\text{-}8)$$

第一项不随预测图变化，故最大化该效用等价于最小化固定误检与漏检代价的条件期望风险。该推导依赖期望的线性性，不要求对象正确性相互独立。候选池外真实对象造成的漏检同样属于不可改变的部分；池内错误与池外遗漏必须分别分析。

此处采用的是代价敏感代理，不是期望 F1。一般 F1 决策涉及真实标签数量与对象正确事件之间的依赖，仅有普通边际概率通常不足以计算最优决策。[41]特定条件下的 F1 最优阈值结论，也不能通过代入任意基线 F1 直接用于本章结构搜索。[42]上述风险恒等式为评分提供解释，不作为独立的基础理论创新。

4.6.2 接受规则与编辑成本

候选事务必须满足完整图合法、剩余预算允许以及

$$\Delta\Phi_C\geq 0,\Delta\Phi_R\geq 0,\Delta\Phi>\delta>0. \quad (4\text{-}9)$$

两个分项门限制以明显降低某类代理效用为代价换取另一类增益，总效用门排除等分修改。它们是保守代理条件，可能拒绝真实有益的结构替换，也不保证真实组件或关系 F1 不下降。数值容差与正间隔 δ 在评价前固定，不通过测试结果调整。

组件编辑成本为 $d_C=\lvert D\rvert+\lvert B\rvert$，关系成本为 $d_R=\lvert R\triangle R'\rvert$。类型或边界变化引起的旧关系删除与新关系加入分别计费。成本仅用于硬预算和同效用时少改优先，不加入效用作为“接近初始图”的奖励。累计编辑量与最终图相对 G_0 的净变化分别记录，避免反复修改同一对象却只报告最后一次差异。

4.7 局部整数规划与有界事务执行

4.7.1 每个组件提议的关系补全

主求解器采用“有界组件提议 + 局部 ILP 关系补全”。对一个已经通过冲突检查的 C'，令 $z_c=\mathbb{I}[c\in C']$ 为固定组件状态，$y_r\in\{0,1\}$ 表示关系候选 $r\in P$ 是否被选取。目标为

$$\max_y \; w_C\Phi_C(C')+w_R\sum_{r\in P}(2q_R(r\mid x)-\kappa_R)y_r. \quad (4\text{-}10)$$

组件项在单次求解中为常数，但在比较不同提议时不可省略。求解包含以下约束：

$$\begin{aligned}&\sum_{t\in\mathcal{T}(u)} z_{(u,t)}\le 1,\ z_c+z_d\le 1 \ \text{若}\ \ \mathit{Conflict}(c,d);\\ &y_r\le z_c\ \forall\, c\in \mathit{Ends}(r),\ \sum_{r\in\Gamma_s} y_r\le 1\ \forall\, s;\\ &y_r=\mathbb{I}[r\in R]\ \forall\, r\notin P_{tx},\ G'\in\mathcal{G}_{\mathcal{A}}.\end{aligned}\qquad (4\text{-}11)$$

Γ_s 表示同一关系槽位的互斥标签候选，全为零对应 NONE；$\mathcal{G}_{\mathcal{A}}$ 表示所采用协议的整图合法集合。前两项组件约束也作为提议合法性的显式检查。自环、非法类型组合及越界跨度在候选构建时排除，关系约束保证被选关系的全部端点存在，且不能绕过固定外部结构。若协议要求无环，引入 $0\le o_c\le M-1$、$M=|\mathcal{V}|$，对全部候选二元边加入

$$o_v\ge o_u+1-M\left(1-y_{(u,v,\ell)}\right).\qquad (4\text{-}12)$$

该式同时覆盖固定外部边；超边在协议要求时对各源成员到目标的方向分别加入相同约束。不要求无环时不额外施加该限制。对于 CDCP 的源范围规则，在固定的 C' 上计算候选超边是否合法，不合法者强制 $y_h=0$，包括因此失效的事务外超边；若这与外部固定约束冲突，当前事务不可行，必须扩大事务或拒绝。

分项效用门与编辑预算同样纳入 ILP。设 $y_r^0=\mathbb{I}[r\in R]$，关系编辑成本可线性写为

$$d_R=\sum_{r:\,y_r^0=1}\left(1-y_r\right)+\sum_{r:\,y_r^0=0} y_r.\qquad (4\text{-}13)$$

将 d_C,d_R 限制在各自剩余预算内，并约束 $\Delta\Phi_C,\Delta\Phi_R\ge 0$。严格总效用门在数值实现中采用固定正间隔及比较容差，提交前再次验证 $\Delta\Phi>\delta$。这些条件必须参与求解，不能先求无约束最高分结果、发现它违规后便断言不存在可接受结果。

4.7.2 提议队列、回退与终止

候选分歧、边界不确定性、跨度头补充区域和关系不确定性用于组织有限提议队列；优先级仅决定搜索顺序，不代替接受依据。本版设计起点为每轮最多 32 个提议、最多接受 3 次事务；求解时间上限在硬件小试后冻结。这些数值是待检验的工程配置，不是已经测量的最优参数。

算法 4-1 多候选驱动的依赖闭合修正

输入：文档 x，K 个候选图，候选与求解预算

1．以原 MCR 选择候选，执行共用合法化，得到 G0；G ← G0。

2．构建并冻结 U、P、对象评分、代价系数及接受阈值。

3．生成当前状态的有限提议队列，设置独立 no-op 回退项。

4．对预算内的每个 (D0, B, SR)：

a．抵消相同对象，完成冲突闭合，构造 C'。

b．构造包含入边、出边与 NONE 的关系事务空间。

c．固定外部关系，通过局部 ILP 求受约束的最佳补全。

d．对可行解重新验算合法性、效用门和完整编辑成本。

5．在已找到的合格事务中选总效用最高者，同分时少改优先，

再按规范化语义键排序消除并列。

6．若存在合格事务，原子提交并返回步骤 3；否则保留当前图。

7．达到预算即停止，输出当前图及全部尝试、拒绝和提交记录。

no-op 是求解器外的独立选择，不需要满足严格增分条件。对于已改变组件的提议，其局部关系 ILP 不一定包含原图，因此不能把“ILP 内存在空编辑”作为回退保障。所有修改先在副本中执行，通过复核后一次提交；拒绝或中断时保留最后一个完整合法状态。

求解超时但找到可行解时，可使用经复核的 incumbent，并记录求解间隙；未找到可行解则记录状态，不解释为数学不可行。只有完整检查本轮声明的队列，才可称该队列中未找到合格动作。候选构造、评分调用、全部求解尝试及失败处理均计入成本，不能只计最终接受的修改。

4.8 机制性质与适用边界

4.8.1 局部差值的精确计算

命题 4-1：固定候选宇宙及对象评分时，两个预测状态之间的效用差可由新增、删除对象精确计算。

证明：对 $X\in\{C,R\}$，记 $a_X(o)=2q_X(o\mid x)-\kappa_X$，则

$$\Delta\Phi_X=\sum_{o\in X(G')\setminus X(G)}a_X(o)-\sum_{o\in X(G)\setminus X(G')}a_X(o).\qquad(4\text{-}14)$$

两状态共有对象的得分相同，在求差时相消。依赖闭合将端点变化引起的旧关系失效、新关系加入纳入差集，因而不会漏算关系项。该性质来自固定可分解目标，不

意味着模型已经正确判断自然语言语义。若搜索中改变对象分数，则上述差值计算不再适用。

4.8.2 集合事务的可达性

命题 4-2：存在合法状态，使全部单对象改动均不能通过严格改进条件，而一个集合替换可以通过。

构造两个互不重叠的旧组件 a,b，新跨度 c 同时覆盖二者。取 $\kappa_C=0.4$，$q_C(a)=q_C(b)=0.3$，$q_C(c)=0.6$，对应效用为 $0.2,0.2,0.8$。这些边际与合法分布 $0.3\{a,b\}+0.6\{c\}+0.1\varnothing$ 相容。初始集合 $\{a,b\}$ 的效用为 0.4：单独删除任一组件降分，直接插入 c 或仅替换其中一个组件产生冲突；整体 $\{a,b\}\to\{c\}$ 则合法且增分 0.4。取 $w_C=1$、$0<\delta<0.4$ 并保持关系不变，即满足全部效用门。若一对一提议通过冲突闭合同时删除两个旧组件，它事实上已扩展为上述集合事务，不再属于受限的单对象动作。

该例说明成组事务可以跨越单对象严格改进的限制，而非证明真实样本上的 F1 必然提高。它也不意味着集合事务具有任意大小的搜索能力；本章默认邻域不能跨越所有可能的局部障碍。

4.8.3 有限终止与 F1 边界

命题 4-3：在有限候选状态空间内，严格提高同一固定 Φ 的接受序列不可能重复访问状态，因此必定有限终止。

证明：若回到某个已访问状态，该状态的固定效用应与先前相同；但每次接受均严格增分，形成矛盾。有限状态数进一步排除无限无重复序列。实际算法还受到尝试、时间和编辑预算约束，因预算停止不代表局部最优或全局最优。

对于单项语料 micro-F1，设真实正确数为 T、预测数为 P_0、金标准数为 Q，$F=2T/(P_0+Q)$。当修改前后分母均非零时，直接展开可得

$$F'-F=\frac{2\Delta T-F\,\Delta P_0}{P_0+Q+\Delta P_0}. \tag{4-15}$$

该恒等式说明真实增益同时取决于正确数和预测数的变化。推理时不知道真实 ΔT 与 F，估计概率及固定 κ 也不能替代它们。即使候选级校准良好，仍不能得到每次事务的误差上界。因此，本章只保证接受过程的代理效用单调，不宣称真实 F1 单调、期望 F1 最优或全局最优。

4.9 数据协议与方法比较

AAEC 保留 MajorClaim、Claim、Premise 及其规定关系接口。Claim stance 作为属性处理，不静默改为普通 Support/Attack。文档级或段落级输入、跨段关系范围和跨度规范均须固定；同一文档的切片不得跨训练与测试。缺少普通关系的 MajorClaim 仍参与组件评价，但不虚构其关系修正收益。

CDCP 主配置保留原生多前提关系：

$$h=\left(\{c_{i_1},\ldots,c_{i_k}\},c_j,\ell\right),\ell\in\{Reason,Evidence\}. \quad (4\text{-}16)$$

源成员按原文顺序规范化，整条超边作为一个精确对象。候选、评分、预算及评价均采用这一单位；一个成员正确不等于整条关系正确。与采用预处理或结构转换的既有研究比较时，必须明确相应协议。[46]

超边候选由初始图关系及预算内可共存的成员组合构成。初始设计对新增组合最多包含 3 个源成员，但保留初始图已有的更长超边，并单报裁剪覆盖损失。源范围连续性按所选组件序列检查，不以字符间没有空隙代替。任一源成员或目标变化均使旧超边整体失效；评分器使用有序成员聚合及成员数量、位置特征，ILP 要求全部成员和目标同时存在。组件变化还可能影响事务外超边的范围合法性，此时按整图约束扩大事务或拒绝，不能仅检查相交端点。原生超边结果与二元投影结果分别报告，不混用分数。

同目标全局 ILP 以可变组件指示量z_c共同求解。对每个超边h，若候选组件c按位置位于其最左与最右源成员之间、但不属于该源集合，则加入$y_h+z_c\le 1$，并结合全部端点存在和组件兼容约束，以保证被选源成员在最终组件序列中连续。局部 ILP 的固定C'预检是这一约束的特例。构建候选时不依据整个候选宇宙的固定邻接关系剪掉潜在合法源集合，因为中间候选可能最终不被选择。

方法比较共享生成器、候选池和合法初始图，分别考察 MCR-only、BR-O、BR-C、新评分器下的 RelationOnly、组件先改后重建关系、单对象动作及完整集合事务。其中 RelationOnly 虽固定组件，但评分目标不同于 BR-C，不能用前者代替后者。旧均分、固定计数效用与其他明确目标也需在同一候选条件下比较，区分候选改善、评分改善和搜索范围扩大。

全局 ILP 是必要的强对照。它在相同候选、对象评分和整图协议下同时选择全部组件与关系；局部方法不是新的通用整数规划技术。若全局模型的末态可行域包含局部算法输出，则充分求解的全局目标值不会低于局部结果。比较中应明确局部累计预

算与全局净编辑预算的差别，并同时报告同时间预算下的可行解、求解间隙及充分求解结果。局部事务的研究价值在于有限算力下的修正质量、可审计性与成本，而非声称理论上超越相同目标的全局最优解。

新配置的结论需要独立实验支持。前期 BR-O 或 BR-C 的记录不能直接归于本章联合修正版；第五章将区分历史结果、适用协议和新增验证项目。

4.10 本章小结

本章将 MCR 保留的多种结构假设转化为固定候选空间，以冲突闭合的组件集合替换及完整关系依赖重建作为修正单位。固定对象评分使修改差值可以精确核算，代价敏感效用明确了误检与漏检的取舍，分项门与预算约束使接受和停止条件可复现。相较于仅冻结组件或逐项修改，本章进一步表达了拆分、合并与关系重建之间的耦合；其有效性仍取决于候选覆盖、评分质量及预算内的可达性，不能由代理目标的单调性直接推出。

第五章 综合实验设计与证据分析

5.1 验证目标与证据分层

实验围绕两个问题展开：关系感知增强学习是否在相同监督资源下改善真实文本的组件与关系抽取；依赖闭合修正是否在相同候选与评分条件下取得更好的恢复、误改和成本折中。完整系统总分只回答组合表现，不能替代两个研究问题的独立验证。

本文区分四类证据：已公开 ICIC 论文中的原版结果用于说明前期基础；旧稿补充记录保留尚待配置和出处核准的信息；已有训练集上的 CPU 轻量诊断检查候选和评分路线的信号及失败模式；第三、四章新增方法的正式验证则应绑定新增实现、模型、预测和评价记录。前三类证据不自动升级为第四类，理论性质也不能替代效果比较。

表 5-1 证据状态与可支持的判断

证据类别	当前材料	可支持范围	不能支持的结论
ICIC 公开结果	官方公开论文的原版表格	前期 MCR-BR 及配套模块的报告结果	新增增强、闭合事务或原生超边实现的实证收益
旧稿补充记录	分类别表及历史配置文字	保留研究记录、定位材料差异	无 run ID 的组件分类消融归因
CPU 路线诊断	官方训练集内部分组划分、脚本和日志	候选覆盖及弱评分器的局部可行性	正式 LLM 方法复现或强基线上的收益
新增方法验证	本章定义的协议与对照	形成可复核的验证标准	在未接入结果时声称已达预期或显著优越

5.2 数据、划分与运行身份

5.2.1 域内协议

AAEC 采用其组件标签及 Support/Attack 关系，不将 stance 转换成普通边。CDCP 保留五种组件类型和 Reason/Evidence 多前提关系。正式实验首先冻结数据发布版本、原文哈希、文档 ID、坐标映射和异常样本清单，再定义训练、开发及测试划

分。历史文献协议可作为复现轨道另报，但不与新增严格端到端协议拼成一张排名表。

所有原文及其增强变体按源文档共同分组，不跨划分；同文本不同 ID 还需按全文哈希去重或分组。生成器只使用训练数据；增强中心选择、提示调整、早停和超参数筛选不使用测试标签。评分器的训练候选由训练集内部三折交叉拟合产生，确保每个文档的候选不是由在该文档标签上拟合的生成器直接产生。两种训练方案分别生成其交叉拟合候选，避免只在较弱或单一策略的错误分布上训练评分器。

开发集按源文档划为校准部分与策略选择部分，分别用于概率校准及阈值、预算选择；数据不足时使用预先固定的交叉验证安排，并报告每个阶段的用途。最终冻结所有选择后，测试集仅用于一次完整报告。独立模型和独立划分降低某些偏差，但不能证明评分误差与生成误差独立。

5.2.2 配置与成本

每次运行以数据、增强集合、模型 checkpoint、配置、代码与评价器的哈希组合定义身份。继承的骨干和原稿参数不是新增方法的最佳配置证明。第四章的候选上限、事务大小和尝试预算先作为工程起点，在开发集上形成性能—成本曲线后冻结。所有未通过筛选的增强尝试、被拒绝的修正事务、候选生成和评分开销都纳入统计。

训练报告有效更新步数、源文档访问量、增强 token 量、可训练参数量和设备时间；推理报告生成与验证调用、输入输出 token、CPU 求解时间、端到端时延及峰值显存。局部 ILP 和全局 ILP 使用同一求解器、线程设置和时间上限定义；超时保留可行解、上界或 gap，不把“运行到时限”写成“求得最优”。缓存可减少实际调用，但仍分别报告逻辑预算与实际成本。

5.3 第一项研究：增强与学习的可识别比较

5.3.1 数据构造对照

训练基础 T0 保留 ICIC 专项适配、线索提示及句子辅助目标，不含本论文新增增强与因素对齐。以相同源文档、中心分布、总生成预算和优化步数构造普通改写、结构条件改写、完整影响域改写及 QOS 式结构保持增强对照。QOS 是直接论辩增强近邻，不能仅用完全无结构的普通改写作为唯一基线[35]。

普通改写与结构条件改写之间只隔离生成条件时，可以共用后续全文筛选；但这种普通改写并非完全不使用结构信息，应明确称为“无显式关系条件生成 + 共同筛

选”。另设尽可能复现原方法的 QOS 轨道，记录其条件、筛选及资源差异，不能将显著改造后的版本仍称为无差别复现。

完整影响域的消融依次去掉跨边界正关系检查、NONE 检查，其他生成与筛选规则保持一致。由于检查强度改变接受率，同时报告两种资源视角：固定总尝试预算下的效果，及匹配接受样本量与训练步数下的效果。后者可能需要更多生成成本，不能隐去这部分代价。随机中心与结论中心按组件数、文本长度及关系度匹配，报告无法匹配的源文档和分布差异。

5.3.2 同数据学习对照

固定一份已接受的增强数据，比较“仅生成与原句子监督”“增加组件/关系头监督”“进一步增加成对因素对齐”。这样才能确定收益来自更多可用文本、辅助标签，还是成对约束本身。去掉对齐的对照仍保留相同辅助头和源文档权重，以免把参数或数据权重变化误归于对齐。

表 5-2 训练侧必要对照及其回答的问题

对照	固定条件	变化因素	验证问题
T0 与普通增强	骨干、推理、更新预算	是否增加接受的文本变体	一般数据增量是否已有收益
QOS 式与关系感知增强	源文档、预算、评价	约束范围及生成机制	是否超过直接近邻
局部正边与完整影响域	中心、生成器及资源口径	跨边界及 NONE 约束	新增检查是否减少标签漂移
同数据去对齐与完整学习	增强集合、头、权重、步数	成对因素损失	学习目标的净增量
结论与匹配随机中心	大小、长度、关系度	中心选择偏置	结论优先是否必要

辅助头性能与原文—变体一致性只作为中间指标。主结论仍以未改写真实测试文本上的组件与严格关系 P/R/F1 为依据，并分开报告结论类、非结论类、边界、类型及关系端点错误。对显式线索有无及线索扰动分组分析，检验提升是否主要依赖“therefore”等表面词。

5.3.3 标签可靠性审计

从接受和拒绝变体中按数据集、关系标签、内部/边界/NONE 因素分层抽样。人工判断者在不知道方法名称和自动判定的条件下，对角色、否定模态、指代、方向及标签保持进行判断；记录分歧和裁决，不在尚未开展时补填人数或一致性系数。公开审计样本 ID 及准则，并报告抽样误差。若自动筛选主要通过拒绝复杂关系提高表面保持率，应报告覆盖损失，不能只列接受样本的准确率。

5.4 第二项研究：候选、评分与闭合修正

5.4.1 三个相互分离的诊断

候选诊断计算严格组件覆盖、完整关系全部端点覆盖及满足兼容约束的可达 Oracle。组件逐项覆盖只是必要条件：两个各自正确的对象可能因错误冲突规则不能同时进入图；超边端点齐备也不意味着正确源集合已列入关系候选。因而同时报告对象覆盖、可行图上界、单次事务可达上界及有限多轮可达上界，不能把它们合并为一个“Oracle”。

评分诊断在固定提案上判断修改后真实任务变化。分别报告有益、无益及有害修改的排序质量，完整对象概率的可靠性图、Brier 分数、校准误差，以及严格接受后的净 TP/FP/FN 变化。构造扰动与模型自然错误分开；校准文档和最终策略评估文档分开。针对不同图大小、事务类型、超边元数及训练方案检查分布漂移。随机因素上的良好校准不足以保证搜索选出的高分事务可靠。

搜索诊断固定候选宇宙和全部评分，比较找到的效用、尝试次数、接受次数、编辑数及耗时。只有这样才能把收益归于闭合搜索而非更好的候选或更强评分器。若固定评分几乎不能区分好坏修改，则增加搜索可能更有效地放大错误，不能据形式性质继续宣称安全改进。

5.4.2 方法和强对照

MCR-only 为仅选择初始完整图；BR-O 为原 ICIC 式修正；BR-C 固定组件及初始覆盖目标；BR-J 为本论文主方案。由于 O、C 与 J 的候选和评分不同，这组系统比较只能回答完整方案差异，必须另加同候选、同评分的控制比较。

表 5-3 推理侧对照及归因

对照	对齐要求	主要问题	必须报告的代价
MCR-only、BR-O、BR-C、BR-J	同一生成检查点及初始候选	系统总体效果与原工作递进	新增候选、评分和求解全部成本
仅删边后处理	同一初始图及预算口径	是否只是删除错误关系获益	Recall 及真阳性损失
顺序组件修正再预测关系	同一宇宙、评分、动作预算	是否需要事务联合接受	组件单步拒绝导致的不可达情况
同动作不同评分	事务集合与搜索顺序	完整对象效用的作用	错误高分及接受后风险
同评分不同动作	固定评分和候选	集合替换及闭合的作用	编辑数量与事务大小
同目标全局 ILP	同一候选与效用、包含局部终态的可行域	局部修正的预算价值	可行解、gap、最优性状态及耗时
等预算通用重写或重生成	相同 token 或调用资源	专门修正是否值得额外机制	解析失败、幻觉跨度及全部成本

全局 ILP 采用局部终态的松弛可行域：固定相同候选宇宙、评分和合法性规则，组件与关系效用分别不低于初始图，最终净编辑量不超过局部累计编辑预算。局部方法的每一步分量非下降及累计预算，蕴含其最终状态满足上述约束；反向不成立，因此全局域包含局部可达终态，不称二者同域。全局 ILP 充分求解时，其效用不低于局部可行解，这是包含关系决定的数学上界，不应主张相反结果。局部方法可争取较低成本或更好的真实 F1；后者可能说明代理目标存在偏差，不代表其效用超过全局最优。不加分量门或采用其他净预算的全局版本单列。

5.4.3 风险、主动恢复与解释案例

按插入、删除、重定型、边界替换、拆分、合并及仅关系修改分组，报告尝试、合法、接受、真实有益和真实有害的事务数。主动恢复必须确实新增正确组件或完整关系；净收益为正但主要来自删去大量错误预测的结果不能直接表述为“恢复遗漏结构”。同时报告原本正确对象的保留率、误删、误加、端点修改后的关系重建准确率及无修改比例。

案例分析采用预先固定的误差类别和抽样规则，至少包含成功恢复、错误接受、错误拒绝、候选不可达和预算耗尽。逐例给出原文、金标、初始图、被替换组件、闭合域、效用差与实际 TP/FP/FN 差。不能仅挑选流畅的自然语言解释，而遗漏错误的跨度或关系。

5.5 组合设计、统计与决策标准

核心组合是训练 T0/T1 与推理 I0/I1 的 2×2 设计。T0 为继承 ICIC 训练基础，T1 在其上增加第三章方法；I0 为 MCR-only，I1 为 BR-J。对每个训练检查点缓存自己的候选，并在 I0/I1 之间固定。两个不同训练检查点产生不同候选是训练效果的一部分，不为了“控制变量”强迫它们使用同一池。

每个核心配置使用预先登记的多个随机种子，正式最低方案为 3 个，资源许可优先 5 个；这是一项实验要求，不是已完成的重复次数。主指标预先限定为组件和严格关系 micro-F1，其他指标用于机制分析。跨种子差值与文档级配对重采样共同报告，重复文本按组处理；不将多种子的每个文档当作独立重复扩大样本量。报告区间、效应量及失败配置，不依据结果临时挑选显著检验。

表 5-4 两项贡献的支持与收缩条件

研究判断	支持所需证据	不满足时的处理
完整影响域确有价值	比直接近邻或局部约束更少漂移，并在资源匹配下有可复核收益	将范围检查定位为质量控制，不宣称独立性能创新
成对学习有独立增量	相同增强数据和辅助头下稳定改善真实测试指标	删除或降级对齐模块，不用一致性指标替代任务收益
事务闭合有独立价值	同评分、同候选下优于顺序或单项修正的风险—收益折中	收缩为可解释的组合实现，保留负结果
局部修正值得使用	相对强全局解码或重生成有明确成本或风险优势	不以更多模块数量证明必要性
两项可构成完整研究	两条主线各有独立问题、机制、证据，且贡献归属明确	保留 ICIC 基础，调整新增主张而非虚构两个全新发明

组合不必呈现超加性增益。只要两个阶段在其固定条件下分别有稳定作用，便可讨论互补性；若某一阶段只在另一阶段存在时有效，应将依赖条件写明，不夸大普适

性。研究质量由证据、比较公平性和问题重要性共同决定，不由创新点数量自动保证学位评审或会议录用。

5.6 已有结果及轻量诊断的解释

5.6.1 ICIC 前期结果

ICIC 公开论文报告原版 Full 在 AAEC 的组件 F1 为 83.71、关系 F1 为 64.83，在 CDCP 分别为 76.45 和 38.17[34]。这些数值说明前期系统具有值得深化的实验基础，但不证明第三章新增强、第四章新效用或闭合事务已经有效。其指标口径、数据处理和统计量仍应与原始评价记录绑定；尤其 CDCP 旧结果不能自动解释为本论文严格原生超边结果。

原稿域内表、消融、验证器、Oracle、行为统计与跨域表在附录 E 按原数值保留，并注明前期归属。分类别组件表未在本轮核对的 ICIC 公开表中找到对应，且其 Single-Pass 组件 F1 为 81.67，与主结果表的 77.82 不同；在 run ID 明确前不据此估计训练增强的净贡献。原版行为表含组件替换及类型修改，也不能移作 BR-C 或 BR-J 的动作分布。

5.6.2 训练集内 CPU 诊断

已有轻量诊断仅使用官方训练集内容：AAEC 纳入 322 篇，按拟合、校准、审计划为 191、65、66 篇；CDCP 在记录排除文档 00411 后纳入 580 篇，对应 348、116、116 篇。划分按完整文本哈希分组，测试文件未用于解析、拟合、选择或评分。AAEC 使用固定版本镜像及官方划分文件，尚未证明镜像与原下载包逐字节一致；CDCP 数据异常及跨度映射问题保留在日志中。

诊断使用稀疏线性模型生成组件和候选，初始 typed component F1 为 AAEC 25.42、CDCP 4.89。这样弱的基线，尤其 CDCP 的过度分割，不能代表前期 LLM 系统的错误分布。除候选恢复和组件评分外，诊断还包含给定金标跨度与类型、仅单前提关系的条件分类；它不包含本论文端到端完整关系效用、原生多前提修正、闭合事务或 ILP。因此，本节不把其改善幅度写成正式方法的预期增量。已记录的收敛警告进一步限定其用途为预算受限路线检查。

该诊断的研究价值是把后续投入的条件具体化：必须在真实 LLM 自然错误上重新验证候选可达性和接受可靠性，并特别检查在弱基线中易见、在强基线中可能缩小的恢复空间。它不支持跳过强对照或直接推定新路线成功。

5.7 跨语料补充协议

AAEC 到 CDCP 迁移可沿用前期粗粒度协议，但须作为独立轨道：AAEC 的 MajorClaim 和 Claim 归为 Claim，Premise 保持；CDCP 的 Policy 和 Value 归为 Claim，Fact、Testimony 和 Reference 归为 Premise。该映射是工程上的功能归约，不主张不同语料类型天然等价。

关系标签可在补充轨道中归约为有向无标签连接。若将 CDCP 多前提超边投影为多个源到目标的连接，必须在协议名称中标记“二元投影”，固定去重和计数规则，并同时报告受影响的原生关系数量。投影结果不能用于宣称原生超边抽取能力，也不能与域内严格 Relation-F1 计算所谓性能下降。

真正的零样本迁移不使用目标训练或开发标签调整评分、阈值、映射和预算。若 CDCP 标签用于校准，则该轨道应命名为目标域校准迁移，不再称零样本。域内 CDCP 训练实验与迁移实验分别维护模型和数据用途清单。前期粗粒度结果见附录 E，新增方法只有在同协议输出接入后才能作递进比较。

5.8 预期情景占位及结果分析框架

本节为预期情景占位，不是实验结果。表 5-5 至表 5-10 中的数值由人工设定，用于检查比较关系、计算示例和论文叙述是否完整；它们不是模型运行输出、文献报告、统计估计或性能承诺。后缀 P 表示 placeholder，不是显著性检验的 p 值。所有情景数值须在正式报告前整体替换；不能只删除 P 或“非实测”说明。数据中的正向趋势代表待检验假设，不是接受实验结果的标准，真实的持平、下降及失败均应保留。

前期成绩只在 5.6 及附录 E 按其原协议报告，不进入本节的同协议排名。尤其 CDCP 的本节情景采用第二章的原生超边定义，不能将其与 ICIC 旧表的分数直接相减。标准差、置信区间、显著性、真实运行时间、人工判断者人数及一致性系数均不在本版虚构填入。

5.8.1 两个阶段的独立作用

T0 表示保留 ICIC 专项建模基础但不增加第三章新增强和成对因素学习；T1 表示完整关系感知增强学习。I0 为 MCR-only 初始图，不执行新增修正；I1 为第四章 BR-J。同一训练检查点的 I0 和 I1 使用同一初始图与候选缓存，T0 与 T1 各自产生自己的候选。四格比较在两个数据集上分别进行，采用组件与严格完整关系 micro-F1，分数以百分制表示。

表 5-5 两阶段组合的预期情景占位

配置	AAEC 组件 F1	AAEC 关系 F1	CDCP 组件 F1	CDCP 超边 F1
T0 + I0	83.0P	63.0P	76.0P	36.0P
T1 + I0	84.0P	65.0P	77.0P	38.0P
T0 + I1	83.8P	65.0P	77.0P	39.0P
T1 + I1	84.8P	67.0P	78.0P	41.0P

注：全部为人为设定的占位值，非实测。P 仅标记占位；各格不是多种子均值，不带显著性含义。表中基线行也不是已公开成绩。

在该假设情景中，不使用 BR-J 时，训练侧的关系 F1 增量在 AAEC 和 CDCP 上均为 2.0P 个百分点；固定 T1 检查点后，推理侧对应增量为 2.0P 和 3.0P 个百分点。两项同时启用相对 T0 + I0 的关系增量分别为 4.0P 和 5.0P 个百分点。四格关系 F1 的交互差“完整组合−仅训练−仅修正 + 均关闭”为 0.0P，刻意不预设超加性。若正式结果呈现类似模式，只能在报告区间和配对比较后讨论两个阶段各自有效，不能由组合总分直接证明某个内部模块必要。

正式主结果需同时给出 P/R/F1、各随机种子成绩和汇总定义。若 F1 提高主要由 Precision 上升而 Recall 下降产生，应继续核对误删；若只有 T1 + I1 改善，则将结论限定为两阶段依赖，不能沿用“独立有效”的分析。

5.8.2 关系约束与成对学习的归因

表 5-6 采用 I0 推理，完整方法行必须与表 5-5 的 T1 + I0 一致。生成与筛选对照采用匹配接受样本量、源文档访问量及训练更新预算的轨道，额外生成尝试另行计费；正式报告还应提供固定总尝试预算的另一条轨道。两种资源口径不得合并为同一结论。表中的 QOS 式方法是按本文共同接口组织的直接近邻对照，不冒充 QOS 原论文成绩。

表 5-6 训练侧消融的预期情景占位

训练配置	AAEC 组件 F1	AAEC 关系 F1	CDCP 组件 F1	CDCP 超边 F1
T0 无新增强	83.0P	63.0P	76.0P	36.0P

训练配置	AAEC 组件 F1	AAEC 关系 F1	CDCP 组件 F1	CDCP 超边 F1
普通改写 + 共同筛选	83.3P	63.5P	76.2P	36.5P
QOS 式结构增强	83.5P	64.1P	76.4P	37.0P
去跨边界正关系检查	83.6P	64.2P	76.5P	37.2P
去 NONE 检查	83.7P	64.3P	76.6P	37.3P
同数据仅基础训练损失	83.6P	64.0P	76.5P	37.0P
同数据同辅助头去对齐	83.8P	64.4P	76.7P	37.4P
匹配随机中心	83.9P	64.8P	76.9P	37.9P
T1 完整关系感知学习	84.0P	65.0P	77.0P	38.0P

注：全部为人为设定的占位值，非实测。“同数据”两行与 T1 复用完全相同的已接受增强集合；其中“同数据同辅助头去对齐”还保持相同辅助头、权重和步数，仅移除成对对齐损失。其他生成对照不声称拥有同一增强集合。去检查及随机中心行保留其余学习设置。

若实测接近该情景，完整学习相对同数据去对齐的关系增量均为 0.6P 个百分点，才是成对约束的候选证据；相对“仅基础训练损失”的差异同时包含辅助头监督，不能全部归于对齐。关系影响域的作用则由跨边界、NONE 及直接近邻对照分别解释，不能只用“普通改写较弱”支持整项创新。

本情景将结论中心与匹配随机中心的差距设得很小，避免预设所有设计都必然必要。若真实差距不稳定，应将结论优先降为任务启发式，而非核心创新成立的前提。增强标签可靠性仍需 5.3.3 的盲评：逐组报告抽样框、接受与拒绝样本、内部/边界/NONE 标签保持率及抽样误差；本版不捏造人工审计成绩。若改进只来自过滤掉困难文本，还需报告覆盖损失，不能仅据接受集保持率解释任务收益。

5.8.3 组件与关系联合修正的归因

表 5-7 固定 T1 生成检查点。上半部分是整系统比较，其中 BR-O、BR-C 可能使用不同评分或动作集合；下半部分在 BR-J 的固定候选宇宙和对象评分下比较顺序修正、闭合事务及全局 ILP。整系统胜负与闭合机制的净增量是两个问题，不合并解释。

表 5-7 推理侧比较的预期情景占位

推理方法	AAEC 组件 F1	AAEC 关系 F1	CDCP 组件 F1	CDCP 超边 F1
MCR-only I0	84.0P	65.0P	77.0P	38.0P
原版 BR-O 系统	84.3P	66.0P	77.3P	39.0P
固定组件 BR-C 系统	84.0P	66.2P	77.0P	39.3P
仅删边控制	84.0P	65.8P	77.0P	38.6P
同候选同评分 顺序修正	84.5P	66.3P	77.5P	39.6P
同候选同评分 BR-J	84.8P	67.0P	78.0P	41.0P
同目标全局 ILP	84.9P	66.8P	78.1P	40.8P

注：全部为人为设定的占位值，非实测。BR-C 和仅删边不改变组件，组件 F1 应与 I0 完全相同。全局 ILP 行是假定求得最优解时的情景，不表示已有求解日志；其目标效用不得低于同条件局部解，但真实 F1 不受该顺序约束。

如果真实比较保持表中关系，BR-J 相对顺序修正的关系差值为 AAEC 0.7P、CDCP 1.4P 个百分点。这仍需结合操作预算、候选缓存及评分器哈希，才能讨论事务接受的作用。BR-J 与原版系统的差值还包含候选和评分变化，不能单独命名为“依赖闭合收益”。

全局 ILP 在此情景下的组件分数略高、关系分数略低于 BR-J，用于提醒代理目标与评价目标可能不一致，不是局部算法优于全局最优的预设结论。正式实验必须报告最优性状态、时间限制、可行解和 gap；超时解不享有理论目标上界的保证。若全局 ILP 在同等成本下全面占优，应明确缩小局部修正的适用范围。

5.8.4 候选可达性与评分可靠性

表 5-8 只针对 T1 的冻结候选宇宙，候选覆盖以金标完整对象为分母，Oracle 以同一严格关系指标和合法性条件为准。单轮和多轮可达空间均包含 no-op；多轮允许的轨迹包含单轮轨迹，全局可行空间包含这些终态。组件覆盖、关系候选覆盖与关系 F1 分别报告，不能互相替代。

表 5-8 候选与可达性诊断的预期情景占位

诊断量	AAEC	CDCP
严格组件候选覆盖率 百分比	93.0P	88.0P
全部关系端点覆盖率 百分比	89.0P	76.0P
完整关系候选覆盖率 百分比	86.0P	72.0P
初始图严格关系 F1	65.0P	38.0P
单轮可达 Oracle 关系 F1	74.0P	51.0P
多轮可达 Oracle 关系 F1	75.0P	52.0P
全局可行图 Oracle 关系 F1	77.0P	54.0P
BR-J 严格关系 F1	67.0P	41.0P

注：全部为人为设定的占位值，非实测。完整关系候选覆盖不超过全部端点覆盖；单轮 Oracle 不超过多轮，多轮不超过全局。Oracle 使用金标，仅作诊断，不参与测试时选择或调参；这里的金标目标 Oracle 不是按预测效用求解的全局 ILP。

若真实候选覆盖较高而 BR-J 远低于可达 Oracle，应进一步定位评分或搜索问题，不能仅用 Oracle 存在就断言系统可实现对应收益。CDCP 必须要求完整源集合和目标同时出现；只覆盖若干单前提连接不算覆盖原生超边。反之，若关系对象根本未进入候选，改进评分器也无法将其恢复，应先处理候选来源和剪枝规则。

表 5-9 采用固定提案集合开展评分诊断，不让不同评分器通过各自搜索产生难度不同的提案。评分器在训练文档内部交叉拟合预测上学习，校准和策略选择按 5.2 划分；表中的接受可靠性还需在真实搜索选出的事务上单独报告，不能从固定提案诊断直接推出。

表 5-9 固定提案评分诊断的预期情景占位

评分方式	AAEC 有益排序 AUROC	CDCP 有益排序 AUROC	AAEC 关系 Brier	CDCP 超边 Brier
仅端点条件标签评分	0.65P	0.61P	不适用	不适用
完整对象评分 未校准	0.73P	0.69P	0.18P	0.22P
完整对象评分 经校准	0.73P	0.69P	0.15P	0.19P

注：全部为人为设定的占位值，非实测。AUROC 以严格关系 F1 是否提高定义有益提案，平局及下降合为非有益，其比例另报；事务分数采用固定总效用差，类别不足时指标记不适用。Brier 以完整关系是否严格正确为标签，预测对象包括跨度、类型及全部端点。端点条件标签概率不是完整对象概率，不计算同口径 Brier。

该情景允许校准降低 Brier 而不提高排序 AUROC，避免将校准等同于更强的排序能力。正式报告还需给出非有益中的平局和有害比例、完整组件 Brier、可靠性图及分组结果。即使固定提案排序改善，搜索仍可能集中选择错误高分事务；只有接受后净 TP/FP/FN 及误改率同时受控，才能支持使用该评分规则。

5.8.5 误改风险与计算代价

表 5-10 仅演示 T1 下的 AAEC 同候选同评分比较，防止单张表过宽。CDCP 按同样字段单列正式结果，并按超边元数分层。接受单元定义为算法一次完整提交；为避免顺序方法与事务方法的分组粒度不同造成误导，还必须报告固定文档级的净 TP/FP/FN 及编辑数，不能仅比较单元比例。

表 5-10 AAEC 风险与成本的预期情景占位

同评分方法	有益单元率百分比	有害单元率百分比	预测效用增量	推理时延比
顺序组件及关系修正	67.0P	18.0P	5.2P	1.30P
BR-J 闭合事务	75.0P	10.0P	6.0P	1.40P
全局 ILP 最优情景	不适用	不适用	6.4P	2.50P

注：全部为人为设定的占位值，非实测。单元率分母为所有已接受单元，按提交前后严格关系 F1 的正、负、零变化分为有益、有害和中性；中性比例为剩余部分。效用增量为相对相同初始图的每文档平均固定预测效用变化，全局行假定各文档证明最优。时延比以同检查点 MCR-only 总推理时延为 1，包括候选补充、评分、失败尝试及求解，不包含训练。

在此假设情景中，BR-J 相较顺序修正减少有害提交，但付出更高推理成本；它也没有达到全局最优的代理效用。若实测出现这种折中，可结合预算曲线讨论采用条件。相反，若误改率下降只来自极少提交，应同时展示总接受量和文档覆盖；若收益主要来自删除错误关系，则不能称为主动恢复。插入、拆分和合并的贡献须由新增正确组件或完整关系的净计数支持。

全部正式成本表还应列出实际硬件、token、调用、训练时间及峰值显存。本版不把时延比换算成尚未测得的秒数。没有正式样本数及预测文件时，不从上述比例反推事务计数，也不绘制看似来自多次运行的误差线。

5.8.6 由占位稿转为实证稿

替换以整张表及其相邻分析为单位：先绑定数据划分、代码与评价器、checkpoint、候选缓存、评分器及随机种子，再读取真实预测生成统计。跨表复用行必须来自同一配置，不可分别填入“接近预期”的值。若结果改变方向，应同步修改分析、摘要及结论，不根据本节趋势筛选种子或舍弃失败运行。

本节未给近年的外部方法伪造复现成绩，QOS 式占位行也不构成超越原论文的证据。正式结果需接入可比的直接近邻复现、等资源重生成、同动作不同评分及人工标签审计；不具可比条件的文献只作方法讨论。完成这些证据后，才能将 5.5 中的支持与收缩条件转为实证判断。

5.9 本章小结

本章将两项贡献分解为可检验的数据、学习、候选、评分和搜索机制，并以同数据、同候选、同评分和资源匹配的对照限定归因。5.8 补充了明确标记的预期情景及分析写法，使待报告的比较关系可检查，但不增加任何实证证据。现有成果保留其学术基础地位，新增机制的结论仍须由对应实验承担。正式报告应同时解释严格指标、原生超边、误改风险及成本，不能仅以 Full 总分或形式合法性替代方法价值。

第六章 总结与展望

6.1 研究总结

本版第五章的预期情景值只用于展示表格和条件式分析，不构成两项方法有效性的证据。本节保留方法设计层面的总结，不将占位差值写成实测提升；是否支持独立贡献及其适用条件，应依据新增方法的正式预测、运行记录和匹配对照判断。

本文围绕组件与关系之间的依赖，构建从训练监督保持到推理结构恢复的端到端论辩挖掘框架。两项研究分别改变文本表达与预测图状态，前者约束增强样本的学习过程，后者约束局部修改的决策过程，具有独立的问题、机制和评价接口。

第一项研究在作者 ICIC 结论专项建模基础上，引入关系感知增强与成对因素学习。增强检查不局限于改写区内部已有边，而覆盖跨边界依赖和 NONE 状态；程序负责确定性的标注输运，语义筛选负责发现可能的标签漂移，二者不相互替代。成对学习在共享输入表示上约束对应因素，并通过源文档归一化控制增强权重。其理论分析说明监督对应如何构造，不保证自然语言改写一定保持语义，也不将一致性提升等同于真实测试增益。

第二项研究在 ICIC 多候选重排序与有界修正基础上，引入兼容组件集合替换、关系依赖闭合和整体事务接受。该方法能够表示原版单项修改及固定组件保守版之外的若干恢复过程，同时将所有受影响关系纳入同一决策。固定完整对象评分和计数效用明确接受依据，给出条件性的风险解释、局部差分计算和有限终止性质。上述性质依赖固定候选、固定分数和预定约束，不能扩展为真实 F1、局部最优或全局最优保证。

本文同时建立与方法设计匹配的验证框架：在 AAEC 和 CDCP 原生任务上检验两个阶段的独立作用，保留多前提超边；以直接近邻、同数据损失、同评分动作、顺序修正与全局结构化解码作为关键对照；联合报告恢复收益、误改和计算成本。已公开前期结果与轻量诊断构成研究基础，新增方法的定量结论需按第五章协议接入对应材料，不能由历史分数代替。

6.2 局限性

训练侧的主要限制是语义检查与一致性目标可能共同偏向容易改写、关系显式的样本。有限候选影响域也不能保证覆盖所有潜在语义变化；NONE 仅表示当前标注无

关系，可能包含标注不完备性。过强对齐还可能压制有效表达差异。需要同时衡量标签可靠性、表达多样性、接受覆盖和真实任务性能。

推理侧的主要限制是候选宇宙和评分器。未被提议的正确跨度或超边不可恢复；固定分数在反复搜索后可能出现选择偏差；双分量非下降门也可能拒绝真实有益但代理分量下降的事务。预算化集合替换只能覆盖有限的分割合并规模，不能承诺修复任意组件错误。全局 ILP 强对照还将检验局部恢复是否具有独立的成本或风险价值。

数据侧的限制包括语料规模、标注差异及历史结果的协议可比性。训练集内 CPU 诊断不能代表完整 LLM 系统，粗粒度迁移不能代表原生超边迁移。前期论文中的共同成果需要明确引用和个人贡献说明，本论文不将既有模块改名后宣称为新增发明。

6.3 后续工作

下一阶段按证据风险递进开展：先完成原生数据与严格评价的一致性测试，再在真实 LLM 交叉拟合预测上验证候选可达空间及评分可靠性，随后实施同数据训练消融与同评分事务比较，最后完成组合和跨语料补充。每一步设定可收缩的主张边界，若成对学习或闭合搜索没有独立增量，则简化方法并保留负结果。

当前主线不加入强化学习、多代理辩论、隐含前提生成或新的跨语言任务。未来扩展应以本框架的候选、监督和决策瓶颈为依据，而不是增加模块数量。完成上述验证后，才能据实完善摘要中的结果结论及全文的实证论证。

参考文献

[1] LAWRENCE J, REED C. Argument mining: A survey[J]. Computational Linguistics, 2019, 45(4): 765–818. DOI: 10.1162/coli_a_00364. 来源

[2] STAB C, GUREVYCH I. Parsing argumentation structures in persuasive essays[J]. Computational Linguistics, 2017, 43(3): 619–659. DOI: 10.1162/COLI_a_00295. 来源

[3] PARK J, CARDIE C. A corpus of eRulemaking user comments for measuring evaluability of arguments[C]//Proceedings of the Eleventh International Conference on Language Resources and Evaluation. Miyazaki: European Language Resources Association, 2018. 来源

[4] EGER S, DAXENBERGER J, GUREVYCH I. Neural end-to-end learning for computational argumentation mining[C]//Proceedings of the 55th Annual Meeting of the Association for Computational Linguistics, Volume 1. Vancouver: Association for Computational Linguistics, 2017: 11–22. DOI: 10.18653/v1/P17-1002. 来源

[5] MORIO G, OZAKI H, MORISHITA T, et al. Towards better non-tree argument mining: Proposition-level biaffine parsing with task-specific parameterization[C]//Proceedings of the 58th Annual Meeting of the Association for Computational Linguistics. Association for Computational Linguistics, 2020: 3259–3266. DOI: 10.18653/v1/2020.acl-main.298. 来源

[6] CAPUTO E, GRECO S, LA CAVA L. Argument component segmentation with fine-tuned large language models[C]//Findings of the Association for Computational Linguistics: EACL 2026. Rabat: Association for Computational Linguistics, 2026: 5154–5167. DOI: 10.18653/v1/2026.findings-eacl.272. 来源

[7] KAWARADA M, HIRAO T, UCHIDA W, et al. Argument mining as a text-to-text generation task[C]//Proceedings of the 18th Conference of the European Chapter of the Association for Computational Linguistics, Volume 1. St. Julian’s: Association for Computational Linguistics, 2024: 2002–2014. DOI: 10.18653/v1/2024.eacl-long.121. 来源

[8] CABESSA J, HERNAULT H, MUSHTAQ U. Argument mining with fine-tuned large language models[C]//Proceedings of the 31st International Conference on Computational Linguistics. Abu Dhabi: Association for Computational Linguistics, 2025: 6624–6635. 来源

[9] DAS N, VAIBHAV V, CHOUDHARY Y S, et al. End-to-end argument mining through autoregressive argumentative structure prediction[EB/OL]. arXiv:2510.16363v1, 2025[2026-09-14]. DOI: 10.48550/arXiv.2510.16363. 来源

[10] CAPUTO E, GRECO S, LA CAVA L. ARGUS: Towards end-to-end argument mining with large language models[C]//Proceedings of the AAAI Conference on Artificial Intelligence, 2026, 40(48): 41547–41549. DOI: 10.1609/aaai.v40i48.42335. 来源

[11] LI H, SCHLEGEL V, SUN Y, et al. Large language models in argument mining: A survey[EB/OL]. arXiv:2506.16383v6, 2025[2026-09-13]. DOI: 10.48550/arXiv.2506.16383. 来源

[12] SUN Y, CHEN G, YANG C, et al. Discourse structure-aware prefix for generation-based end-to-end argumentation mining[C]//Findings of the Association for Computational Linguistics: ACL 2024. Bangkok: Association for Computational Linguistics, 2024: 11597–11613. DOI: 10.18653/v1/2024.findings-acl.689. 来源

[13] DAS N, SARADHI V V, ANAND A. On the role of key phrases in argument mining[C]//Findings of the Association for Computational Linguistics: NAACL 2025. Albuquerque: Association for Computational Linguistics, 2025: 5774–5787. DOI: 10.18653/v1/2025.findings-naacl.319. 来源

[14] SUN Y, CHEN G, ALINEJAD-ROKNY H, et al. Learning first-order logic rules for argumentation mining[C]//Proceedings of the 63rd Annual Meeting of the Association for Computational Linguistics, Volume 1. Vienna: Association for Computational Linguistics, 2025: 14133–14148. DOI: 10.18653/v1/2025.acl-long.691. 来源

[15] DING B, QIN C, ZHAO R, et al. Data augmentation using LLMs: Data perspectives, learning paradigms and challenges[C]//Findings of the Association for Computational Linguistics: ACL 2024. Bangkok: Association for Computational Linguistics, 2024: 1679–1705. DOI: 10.18653/v1/2024.findings-acl.97. 来源

[16] EVURU C K, GHOSH S, KUMAR S, et al. CoDa: Constrained generation based data augmentation for low-resource NLP[C]//Findings of the Association for Computational Linguistics: NAACL 2024. Mexico City: Association for Computational Linguistics, 2024: 3754–3769. DOI: 10.18653/v1/2024.findings-naacl.238. 来源

[17] PEI Y, BHUSE P, LIU Z, et al. SegMix: A simple structure-aware data augmentation method[EB/OL]. arXiv:2311.09505v1, 2023[2026-09-13]. DOI: 10.48550/arXiv.2311.09505. 来源

[18] SUN W, LI M, DAVIS J, et al. Weakly-supervised argument mining with boundary refinement and relation denoising[C]//Proceedings of the Ninth Fact Extraction and VERification Workshop (FEVER). Rabat: Association for Computational Linguistics, 2026: 1–12. DOI: 10.18653/v1/2026.fever-1.1. 来源

[19] GENG S, JOSIFOSKI M, PEYRARD M, et al. Grammar-constrained decoding for structured NLP tasks without finetuning[C]//Proceedings of the 2023 Conference on Empirical Methods in Natural Language Processing. Singapore: Association for Computational Linguistics, 2023: 10932–10952. DOI: 10.18653/v1/2023.emnlp-main.674. 来源

[20] MADAAN A, TANDON N, GUPTA P, et al. Self-Refine: Iterative refinement with self-feedback[EB/OL]. arXiv:2303.17651v2, 2023[2026-09-13]. DOI: 10.48550/arXiv.2303.17651. 来源

[21] HUANG J, CHEN X, MISHRA S, et al. Large language models cannot self-correct reasoning yet[EB/OL]. arXiv:2310.01798v2, 2024[2026-09-13]. DOI: 10.48550/arXiv.2310.01798. 来源

[22] WANG X, WEI J, SCHUURMANS D, et al. Self-consistency improves chain of thought reasoning in language models[EB/OL]. arXiv:2203.11171v4, 2023[2026-09-13]. DOI: 10.48550/arXiv.2203.11171. 来源

[23] TRAN N, LITMAN D, GODLEY A. Using large language models to analyze students' collaborative argumentation in classroom discussions[C]//Proceedings of the Artificial Intelligence in Measurement and Education Conference (AIME-Con): Full Papers. Pittsburgh: National Council on Measurement in Education, 2025: 111–125. 来源

[24] XIAO Y, LI S. ARGUS: Argumentation-based minimal-change repair for verifiable LLM self-explanations[C]//Proceedings of the 42nd Conference on Uncertainty in Artificial Intelligence. Proceedings of Machine Learning Research, 2026, 337: 7536–7551. 来源

[25] MORIO G, OZAKI H, MORISHITA T, et al. End-to-end argument mining with cross-corpora multi-task learning[J]. Transactions of the Association for Computational Linguistics, 2022, 10: 639–658. DOI: 10.1162/tacl_a_00481. 来源

[26] SAVIGNY H, YUN B. AMELIA: A family of multi-task end-to-end language models for argumentation[J]. Argument & Computation, 2026, 17(1). DOI: 10.1177/19462174251413169. 来源

[27] FEGER M, BOLAND K, DIETZE S. Limited generalizability in argument mining: State-of-the-art models learn datasets, not arguments[C]//Proceedings of the 63rd Annual Meeting of the Association for Computational Linguistics, Volume 1. Vienna: Association for Computational Linguistics, 2025: 23900–23915. DOI: 10.18653/v1/2025.acl-long.1164. 来源

[28] ZHAO X, WANG K, PENG W. ORCHID: A Chinese debate corpus for target-independent stance detection and argumentative dialogue summarization[C]//Proceedings of the 2023 Conference on Empirical Methods in Natural Language Processing. Singapore: Association for Computational Linguistics, 2023: 9358–9375. DOI: 10.18653/v1/2023.emnlp-main.582. 来源

[29] CHENG L, BING L, HE R, et al. IAM: A comprehensive and large-scale dataset for integrated argument mining tasks[C]//Proceedings of the 60th Annual Meeting of the Association for Computational Linguistics, Volume 1. Dublin: Association for Computational Linguistics, 2022: 2277–2287. DOI: 10.18653/v1/2022.acl-long.162. 来源

[30] VASWANI A, SHAZEER N, PARMAR N, et al. Attention is all you need[EB/OL]. arXiv:1706.03762, 2017[2026-09-13]. DOI: 10.48550/arXiv.1706.03762. 来源

[31] QWEN TEAM. Qwen2.5 technical report[EB/OL]. arXiv:2412.15115, 2024[2026-09-13]. DOI: 10.48550/arXiv.2412.15115. 来源

[32] HU E J, SHEN Y, WALLIS P, et al. LoRA: Low-rank adaptation of large language models[EB/OL]. arXiv:2106.09685, 2021[2026-09-13]. DOI: 10.48550/arXiv.2106.09685. 来源

[33] LESTER B, AL-RFOU R, CONSTANT N. The power of scale for parameter-efficient prompt tuning[C]//Proceedings of the 2021 Conference on Empirical Methods in Natural Language Processing. Association for Computational Linguistics, 2021: 3045–3059. DOI: 10.18653/v1/2021.emnlp-main.243. 来源

[34] TANG C, PENG M, TIAN G. Improving end-to-end argument mining with LLMs via multi-candidate reranking and bounded repair[C/OL]//ICIC2026 Posters: Poster Volume I. Toronto, 2026[2026-09-20]. DOI: 10.65286/icic.v22i1.76896. 来源

[35] BAO J, HUANG Y, SUN Y, et al. Exploring quality and diversity in synthetic data generation for argument mining[C]//Proceedings of the 2025 Conference on Empirical Methods in Natural Language Processing. Suzhou: Association for Computational Linguistics, 2025: 26581–26604. DOI: 10.18653/v1/2025.emnlp-main.1351. 来源

[36] WANG X, SHEN H, QI H, et al. Enhancing low-resource joint entity and relation extraction using large language models within semi-supervised learning[J]. ACM Transactions on Knowledge Discovery from Data, 2026, 20(3): 49:1–49:25. DOI: 10.1145/3799423. 来源

[37] MODARRESSI A, KÖKSAL A, SCHUETZE H. Consistent document-level relation extraction via counterfactuals[C]//Findings of the Association for Computational Linguistics: EMNLP 2024. Miami: Association for Computational Linguistics, 2024: 11501–11507. DOI: 10.18653/v1/2024.findings-emnlp.672. 来源

[38] ZHENG Y, KE W, LIU Q, et al. Making LLMs as fine-grained relation extraction data augmentor[C]//Proceedings of the Thirty-Third International Joint Conference on Artificial Intelligence. International Joint Conferences on Artificial Intelligence Organization, 2024: 6660–6668. DOI: 10.24963/ijcai.2024/736. 来源

[39] ZHONG Y, GAO Y, ZHANG X, et al. ODDA: An OODA-driven diverse data augmentation framework for low-resource relation extraction[C]//Findings of the Association for Computational Linguistics: ACL 2025. Vienna: Association for Computational Linguistics, 2025: 267–285. DOI: 10.18653/v1/2025.findings-acl.15. 来源

[40] ROCHA G, LOPES CARDOSO H, BELOUADI J, et al. Cross-genre argument mining: Can language models automatically fill in missing discourse markers?[J]. Argument & Computation, 2025, 16(1): 3–35. DOI: 10.3233/AAC-230008. 来源

[41] WAEGEMAN W, DEMBCZYŃSKI K, JACHNIK A, et al. On the Bayes-optimality of F-measure maximizers[J]. Journal of Machine Learning Research, 2014, 15(103): 3513–3568. 来源

[42] LIPTON Z C, ELKAN C, NARAYANASWAMY B. Thresholding classifiers to maximize F1 score[EB/OL]. arXiv:1402.1892v2, 2014[2026-09-20]. DOI: 10.48550/arXiv.1402.1892. 来源

[43] LI Z, ZHANG F, LYU K, et al. Re-Cent: A relation-centric framework for joint zero-shot relation triplet extraction[C]//Proceedings of the 31st International Conference on Computational Linguistics. Abu Dhabi: Association for Computational Linguistics, 2025: 7344–7354. 来源

[44] PIROZELLI P, ROCHA V H N, COZMAN F G, et al. An LLM-based system for argument reconstruction[EB/OL]. arXiv:2605.13793v1, 2026[2026-09-20]. DOI: 10.48550/arXiv.2605.13793. 来源

[45] GUO C, PLEISS G, SUN Y, et al. On calibration of modern neural networks[C]//Proceedings of the 34th International Conference on Machine Learning. Proceedings of Machine Learning Research, 2017, 70: 1321–1330. 来源

[46] NICULAE V, PARK J, CARDIE C. Argument mining with structured SVMs and RNNs[C]//Proceedings of the 55th Annual Meeting of the Association for Computational Linguistics, Volume 1. Vancouver: Association for Computational Linguistics, 2017: 985–995. DOI: 10.18653/v1/P17-1091. 来源

附录 A 复现与证据核验清单

本附录区分历史结果材料接入和新增设计验证。作者已说明既有实验完成，“待核验”仅表示现有材料尚未完成对应，不据此判断实验未发生，也不补造历史日志。事项编号沿用旧稿，位置更新到本版本；新增事项另列。

表 A-1 核验事项与最低证据

编号	对应事项	最低材料
R01	结论类别分布与增强权重	固定划分的类型数、跨度长度、关系度及原始/加权计数
R02	训练增强身份	生成模型、提示、源 ID、接受与拒绝记录、标注输运映射
R03	类型门控因果性	字段顺序、首 token 及边界处理、训练和推理门控轨迹
R04	提示及原有辅助目标	词典、位置、子词映射、句子标签和损失归一化
R05	附录 E 分类别结果冲突	81.67 与 77.82、两处 83.71 对应的 run ID 及配置
R06	候选规范化	重叠规则、语义身份、ID 重映射及失败样本
R07	旧评分与触发	ICIC 覆盖节点、阈值、分量定义与实现对应
R08	原版动作范围	每类动作前置条件、端点变化、回退及实际执行记录
R09	历史实验配置	划分、脚本、种子、重复数、硬件、“±”定义
R10	基线及资源	外部数值出处、内部复现身份和预算差异
R11	历史验证器	模型、提示、原候选池、逐关系判断材料
R12	历史 Oracle	选择指标、替换对象、端点匹配及计数方式
R13	历史行为统计	统计分母、尝试/接受定义、各阶段前后数量
R14	历史迁移协议	映射、输出标签、目标数据用途及二元投影说明
N01	原生 CDCP 支持	超边往返、完整源集合评价、长超边及源范围测试
N02	因素学习与无泄漏	输入模板、子词索引、金标锚定、空域及梯度测试
N03	评分器训练与校准	三折 OOF 候选、真实负例、校准/策略划分及长度分组
N04	闭合事务实现	冲突集合、完整依赖域、求解状态、no-op 及原子回退
N05	新增方法效果	近邻、同数据/同评分消融、2×2 及误改—成本材料

闭合事项须由原始材料或明确标识的新运行解决；新代码中存在某个接口，不等于历史表已经可复现，也不等于新方法已经通过实证验证。

附录 B 运行身份与事务记录规范

B.1 数据与模型身份

每次运行保存 run ID、源文档 ID 及完整文本哈希、数据版本与划分、原字符/评价 token 映射、模型权重 revision、提示和配置哈希、代码版本、环境、种子及运行时间。增强变体保存其唯一源文档及组件对应，不能以变体 ID 单独重新划分数据。派生结果同时指向其候选缓存、评分缓存和评价配置。

B.2 评分与接受轨迹

每个文档保存原始候选输出、统一合法化结果、MCR 分量、初始图、固定候选宇宙及其来源。每次尝试保存删除集合、加入集合、冲突扩张、关系闭合域、原状态和求解后状态、组件与关系效用差、语义编辑成本、求解状态与剩余预算。拒绝必须具有明确原因：非法、候选不可达、不可行、分量下降、总增益不足、预算超限或求解失败。

所有分数缓存以完整语义对象及评分器版本为键，不以可变 JSON 编号为键。提交后若改变因素宇宙、评分器、校准温度或效用系数，必须开始新的实验配置，不能沿用“固定目标”的证明。离线真实 TP/FP/FN 差只进入审计日志，不作为在线接受输入。

B.3 no-op、失败及预算

无修改状态是独立的可行回退项。候选构造失败、局部求解不可行、超时未得到可接受解或队列耗尽，均返回当前图并保留失败原因。事务计费按实际加入/删除的组件和完整关系对象，不按“打包一次”计为一个编辑。尝试、接受、求解及模型调用预算分别记录，被拒绝操作不能从成本中消失。

B.4 自动测试的最低覆盖

测试至少覆盖坐标往返、原生超边匹配、同坐标不同类型、纯 ID 重排、相互重叠但非传递的候选冲突、组件插入使超边源连续性变化、原 NONE 因素新增、纯关系修改、拆分与合并、双分量接受门、空增强、空因素域、预算耗尽和原子回退。对可枚举小图，用穷举比较 ILP 最优值与局部差分计算；构造测试用于证明实现遵循定义，不能替代真实数据收益。

附录 C 前期成果归属与研究辅助说明

C.1 前期共同成果

Chen Tang、Min Peng 和 Gang Tian 的 ICIC 2026 公开论文构成本研究的直接基础[34]。其已公开机制和本论文新增设计的对应关系见表 1-2。前期数值保留在附录 E；引用与结果归属不因其属于作者近期成果而省略。最终学位论文成果页中的本人分工、合作贡献及发表状态应由作者据正式材料核准，不仅依据署名顺序推断。

C.2 辅助工具与责任边界

研究辅助用于文献定位和核对、方法讨论、论证边界检查、参考代码、稿件修订及排版。作者应独立审阅方法、引用和代码，并对研究事实、贡献归属和结果解释负责。自动生成的文字、理论例子和软件测试不作为未开展的人工判断或正式模型实验记录。新增方法不将“假设结果符合预期”改写为已观察到的效果。

数据使用以原始发布条款为准，公开下载不自动意味着可任意再分发。论文公开材料应避免携带未获许可的语料副本、访问凭据或不必要的个人信息。作者声明、授权页、资助、伦理审批及致谢不由辅助系统代填，应按真实情况与学校要求补充。

附录 D 参考实现与新增方法的对应状态

D.1 既有工程身份

argument_mining_0914 是根据讨论后建的参考项目，不是找回的 ICIC 原始实验仓库。其 0915 工程记录覆盖数据转换、严格二元评价、专项训练、匹配增强、候选缓存、原版动作和保守关系修正。此前 75 项自动测试以及随机初始化小模型的前后向、短训练和重载测试属于软件验证，不代表 Qwen2.5-7B 在真实语料上的效果。

research_0920 另包含训练集内 CPU 诊断，已读取公开 AAEC/CDCP 训练数据并记录异常；它并未实现完整 BR-J 或成对因素学习。因而旧工程中“数据尚未导入”的历史状态不能泛指本版本全部材料，但也不能由诊断读取成功推断完整训练管线已支持原生超边。

表 D-1 正文机制与参考工程对应

机制	已有基础	本版仍需的实现与验证
结论门控、提示、句子损失	参考工程含因果门控和小模型测试	完整骨干运行、子词映射与正式训练绑定
槽位改写及匹配对照	已有普通/结构条件增强框架	完整影响域、边界/NONE 审计和原生超边
成对因素学习	正文新增定义	全文读出、头监督、源权重及梯度接口
多候选与 O/C 修正	已有缓存及两版动作	同池同预算绑定与历史结果复现
完整对象评分	CPU 诊断含组件候选与交叉拟合起点	真实 LLM 预测、完整关系/超边、校准及策略隔离
闭合事务与 ILP	正文新增定义	集合替换、冲突依赖、内层求解、双门及回退
严格 CDCP 超边评价	诊断保留原生关系审计信息	旧二元工程全链路升级，禁止默认 expand 替代

D.2 参数来源与复现范围

既有参考配置中 Qwen2.5-7B-Instruct、rank 16、alpha 32、四个提示向量、句子权重 0.5、K=3 和 MCR 权重 0.4/0.4/0.2 沿用原稿文字；这仅确认设计取值来源，不确认历史运行

身份。旧工程的学习率、epoch、batch、随机种子和调用上限中有后建选择，不能补填为 ICIC 原实验配置。新损失权重、候选数量、代价系数及事务预算按第三至五章协议另行确定。

本次正文修改不等于已将新增机制合入实验项目。复现时应先完成协议与单元测试，再交付运行配置、逐例输出及严格评价结果。软件可运行、形式性质成立、实验有效和满足送审要求是不同层次的判断，不相互替代。

附录 E 前期数值与协议存档

本附录逐表保留 0915-v1 稿件中的原始数字和方法行。除表 E-1 及协议映射表外，相应数值可在 ICIC 公开版本中找到；“可找到”不等于本次独立复现。所有结果均不属于 0920-v1 新增机制。旧表“±”的统计定义、划分及评价脚本仍按附录 A 核验，不由新协议追认。

E.1 AAEC 组件分类别旧稿记录

表 E-1 AAEC 组件分类别旧稿记录

方法	MajorClaim-F1	Claim-F1	Comp-F1
FLAN-T5 (XXL)	71.23	76.45	80.15
LLM Single-Pass	73.45	78.21	81.67
Ours (Full)	**77.34**	**81.77**	**83.71**

来源为旧稿补充记录；未在 ICIC 公开版中找到对应分类别表。Single-Pass 的 81.67 与表 E-2 的 77.82 尚需 run ID 解释，不用于新增强的独立归因。

E.2 ICIC 原版 AAEC 域内结果记录

表 E-2 ICIC 原版 AAEC 域内结果记录

方法	Comp-F1	Support-F1	Attack-F1	Relation-F1
FLAN T5-XXL	80.15	62.34	48.72	61.19
GPT-4-turbo 20-shot	55.51	29.86	18.45	28.38
RoBERTa-large MTL	76.43±0.55	54.21±0.52	41.83±0.67	52.15±0.54
LLM Single-Pass	77.82±0.51	58.43±0.45	44.21±0.62	56.87±0.48
LLM w/ Constrained Decoding	78.54±0.46	59.12±0.42	45.33±0.58	57.65±0.45
LLM w/ DAG Post-process	78.91±0.49	59.45±0.48	45.87±0.61	58.12±0.47
LLM Multi-Sample (LogProb)	79.45±0.38	60.12±0.41	46.58±0.55	58.94±0.42
LLM w/ Self-Refine	79.82±0.45	60.75±0.43	47.12±0.56	59.63±0.45
Ours ($K=1$, w/o correction)	81.24±0.44	61.87±0.39	48.34±0.58	60.73±0.41
Ours (Verifier-only Rerank, $K=3$)	82.18±0.40	63.15±0.36	49.82±0.52	62.21±0.38
Ours (Full, $K=3$)	**83.71±0.42**	**65.92±0.38**	**51.47±0.54**	**64.83±0.38**

对应 ICIC 公开版 Table 1 的 AAEC 部分[34]。所有方法名及数值按旧稿保留；外部结果的评价差异需按原文核验，不能视为统一严格协议下的复现。

E.3 ICIC 原版 CDCP 域内结果记录

表 E-3 ICIC 原版 CDCP 域内结果记录

方法	Comp-F1	Reason-F1	Evidence-F1	Relation-F1
FLAN T5-XXL	72.68	35.24	28.41	33.96
RoBERTa-large MTL	68.52±0.58	31.45±0.61	25.72±0.73	30.23±0.64
LLM Single-Pass	71.35±0.48	33.82±0.52	27.15±0.68	32.64±0.55
LLM w/ DAG Post-process	72.14±0.50	34.65±0.49	28.02±0.63	33.51±0.52
LLM w/ Self-Refine	72.95±0.47	35.58±0.48	28.94±0.60	34.42±0.50
Ours ($K=1$, w/o correction)	74.56±0.45	36.94±0.46	30.27±0.58	35.78±0.48
Ours (Verifier-only Rerank, $K=3$)	75.12±0.41	37.85±0.44	31.42±0.55	36.64±0.45
Ours (Full, $K=3$)	**76.45±0.43**	**39.12±0.45**	**32.86±0.57**	**38.17±0.46**

对应 ICIC 公开版 Table 1 的 CDCP 部分[34]。该表不证明本论文原生多前提超边的严格抽取性能。

E.4 ICIC 原版模块消融记录

表 E-4 ICIC 原版模块消融记录

配置	Comp-F1	Relation-F1	ΔComp	ΔRel
Full Method	83.71±0.42	64.83±0.38	—	—
$K=1$, w/o correction	81.24±0.44	60.73±0.41	-2.47	-4.10
w/o Claim-specific Adapter	81.96±0.48	63.08±0.44	-1.75	-1.75
w/o Cue-aware Prompting	82.34±0.45	62.87±0.40	-1.37	-1.96
w/o Multi-Objective	82.89±0.43	63.54±0.39	-0.82	-1.29
w/o Validity Signal E_{val}	81.56±0.46	61.92±0.43	-2.15	-2.91

对应 ICIC 公开版 Table 2[34]。专项适配、线索、多候选及有效性消融不等于完整影响域、成对学习和事务闭合消融。

E.5 ICIC 原版验证器替换记录

表 E-5 ICIC 原版验证器替换记录

验证器	Comp-F1	Relation-F1	Top-1 一致率	修正触发率
Qwen2.5-7B（默认）	83.71	64.83	100.0%	42.5%
Llama-3-8B（独立）	83.71	64.55	94.2%	43.8%

对应 ICIC 公开版 Table 3[34]。原二元验证器一致性不能替代新完整对象评分器的正确性校准；自比较的一致率不构成真实性证据。

E.6 ICIC 原版 Oracle 记录

表 E-6 ICIC 原版 Oracle 记录

条件	Comp-F1	Relation-F1	ΔRel
预测组件与当前选择器	83.71±0.42	64.83±0.38	—
Candidate Oracle（$K=3$中择优）	85.12±0.36	67.24±0.34	+2.41
Condition Oracle（金标准组件输入）	—	78.42±0.35	+13.59
Output Oracle（金标准替换）	100.00	83.35±0.32	+18.52

对应 ICIC 公开版 Table 5[34]。保留原名称，不改称新候选宇宙的可达率、原生超边上界或局部搜索最优值。

E.7 ICIC 原版修正行为记录

表 E-7 ICIC 原版修正行为记录

指标	结果
修正触发率	42.5%
触发文档平均迭代轮数	1.8
触发文档平均动作数	2.4

指标	结果
LocalRerun 占比	45.2%
RemoveEdge 占比	24.8%
Replace 占比	19.5%
Promote/Demote 占比	10.5%
无效 ID 比例	18.5% → 2.1%
JSON 格式错误比例	6.2% → 0.0%
不连贯边比例	22.4% → 5.8%
整体E_{val}通过率	75.3% → 97.9%

对应 ICIC 公开版 Table 6[34]。Replace 及 Promote/Demote 明确属于 BR-O，不能移作 BR-C 或 BR-J 的行为分布；动作占比不等于真实错误分布。

E.8 前期粗粒度组件映射

表 E-8 前期粗粒度组件映射

数据集原标签	粗粒度标签	映射依据
AAEC MajorClaim	Claim	表达全文立场
AAEC Claim	Claim	表达局部结论
AAEC Premise	Premise	提供支撑或反驳理由
CDCP Policy	Claim	提出行动方案或规范性主张
CDCP Value	Claim	表达评价性或价值判断
CDCP Fact	Premise	提供可核验事实
CDCP Testimony	Premise	提供经验或证言
CDCP Reference	Premise	提供外部来源

这是单独迁移协议的标签归约，不改变 AAEC/CDCP 的原生域内标签，也不证明标签在语义上天然等价。

E.9 ICIC 原版 AAEC 到 CDCP 迁移记录

表 E-9 ICIC 原版 AAEC 到 CDCP 迁移记录

方法	Coarse Component-F1	Unlabeled Link-F1
FLAN T5-XXL（zero-shot）	52.34±0.65	31.25±0.72
LLM Single-Pass（zero-shot）	54.87±0.58	33.42±0.68
Ours ($K=1$, w/o correction, zero-shot)	57.23±0.52	38.76±0.61
Ours (Full, zero-shot)	**60.78±0.48**	**43.21±0.55**

对应 ICIC 公开版 Table 4[34]。有向无标签 Link-F1 与严格原生关系 F1 分开；目标数据用途及多前提投影口径仍需历史材料核准。