# 武汉大学
## 学术型硕士学位论文

# 面向关系感知学习与依赖闭合修正的端到端论辩挖掘方法研究

Chen Tang

计算机科学与技术

**1011-v10 估算演示版**

2026 年 10 月

稿件说明：本稿为估算演示版。正文主结果由明确假设的目标值生成计数，并统一复算表图、差值与区间，不代表真实实验记录或经验证的效果预测。附录 D.2—D.3 保留既存 CPU 诊断；4.6.7 及 D.7—D.12 分别报告 148 篇 Luna 探索性扩样、64 篇新语料预测及另 32 篇 CDCP 评分对照。它们采用轻量实现，不替代训练方法与完整系统的受控实验。附录 E 保留前期存档。附录 H.6—H.8 保留独立旧情景；本版假设与压力条件见 H.5。正式稿须以同口径实测材料整体替换。

# Wuhan University

Academic Master's Thesis

# End-to-End Argument Mining via Relation-Aware Learning and Dependency-Closed Repair

Chen Tang

Computer Science and Technology

October 2026

# 摘要

端到端论辩挖掘从原始文本中识别论辩组件及其关系，为分析观点与理由之间的组织方式提供结构化表示。组件与关系之间的依赖贯穿训练和推理过程：训练文本的局部改写可能改变原有论证作用，使继承标注失真；预测组件的跨度或类型发生变化，也会使关联关系的端点失效。围绕这两类问题，本文在前期结论组件专项建模、多候选重排序与有界修正研究基础上，分别研究训练阶段的关系监督保持与推理阶段的结构恢复。

针对局部改写后的监督保持问题，提出关系影响域约束的增强与成对学习方法。该方法按组件端点依赖确定改写的关系影响域，同时检查集合内部与跨边界组合的已有关系及无关系状态。通过标注迁移建立原文与增强文的对应，在筛选合格的文本对上联合学习组件和关系因素，使增强数据构造与生成模型的学习目标相衔接。

针对组件修改后的结构恢复问题，提出多候选驱动的依赖闭合论辩图修正方法。该方法保持输入原文不变，将组件集合替换及全部受影响关系的重建组织为一个事务，依据完整对象评分、整图约束和编辑预算整体接受或回退。集合替换可表示遗漏补回、多检删除、边界与类型调整以及拆分合并；固定评分下的局部效用分析与有界执行明确了决策和停止条件。

主实验仍以明确假设计数演示训练和完整系统的比较口径。独立 Luna 轻量试验扩展至 AAEC 32 篇、CDCP 116 篇：AAEC 完整关系 F1 由 0 升至 1.44，出现生成候选中遗漏前提补入后的关系恢复；CDCP 由 1.54 降至 0，暴露候选覆盖不足和代理评分误改。新增 ArgUNSC 与 CasiMedicos-Arg 各 32 篇用于检查不同原生标注下的流程表现。另在 32 篇未用于此前诊断的 CDCP 文档上固定候选、初始图及预算，原评分与原生说明下显式评分的 BRJ-lite 关系 F1 分别为 0.00 与 1.60，均低于共同初始图的 3.33。这些实际输出使候选覆盖、评分与结构执行的限制可以逐项核查，但尚未验证训练侧监督保持、集合动作的独立增量、局部相对全局的采用价值或两阶段互补性。

关键词：端到端论辩挖掘；关系影响域；成对学习；依赖闭合；图修正；结构化预测

# Abstract

End-to-end argument mining identifies argumentative components and their relations directly from raw text. Dependencies between components and relations create two related problems. During training, a local paraphrase may alter the argumentative role of a component and invalidate inherited labels. During inference, changing a predicted span or type may invalidate the endpoints of associated relations. Building on prior work on conclusion-specific modeling, multi-candidate reranking, and bounded repair, this thesis studies supervision preservation during training and structural recovery during inference.

The first method combines relation-domain-constrained augmentation with paired factor learning. It defines an affected relation domain from component dependencies and checks both annotated relations and no-relation states within and across the editable set. Annotation transfer establishes correspondences between original and augmented documents. Paired component and relation learning then connects accepted text variations to the shared generation representation.

The second method is dependency-closed argument graph repair driven by multiple candidates. It leaves the input text unchanged and combines compatible component-set replacement with reconstruction of all affected relations. Each proposed transaction is accepted or rolled back as a whole under complete-object scores, global structural constraints, and explicit editing budgets. Set replacement represents insertion, deletion, span or type changes, splitting, and merging. Conditional analysis characterizes local utility differences and bounded execution without guaranteeing improvement in true extraction F1.

The main comparisons use explicitly assumed counts to illustrate the evaluation of training and the full system. A separate Luna pilot covers 32 AAEC and 116 CDCP documents. Strict complete-relation F1 increases from 0 to 1.44 on AAEC, with recorded recovery after a missing premise from the generated candidate pool is inserted, but decreases from 1.54 to 0 on CDCP. Candidate coverage and erroneous proxy scores limit repair. Two further pilots use 32 documents each from ArgUNSC and CasiMedicos-Arg under their native annotations. On another 32 CDCP documents, predictions, candidates, initial graphs, and budgets are held fixed: BRJ-lite obtains relation F1 scores of 0.00 with the original scoring protocol and 1.60 with native-label guidance and explicit object scores, both below the initial graph score of 3.33. These outputs support traceable analysis of candidate, scoring, and execution limitations. They do not yet validate supervision preservation, the independent value of set-level actions, local versus global solving, or complementarity between training and inference.

Keywords: End-to-End Argument Mining; Affected Relation Domain; Paired Learning; Dependency Closure; Graph Repair; Structured Prediction

# 目录

**摘要** ..... **I**

**Abstract** ..... **II**

**第一章 绪论** ..... **1**

1.1 研究背景与问题提出 ..... 1
1.2 国内外研究现状 ..... 2
1.2.1 端到端论辩挖掘与生成建模 ..... 2
1.2.2 关系保持数据增强 ..... 3
1.2.3 结构化预测与论辩图修正 ..... 4
1.2.4 综合评述与本文研究位置 ..... 5
1.3 研究问题与主要研究工作 ..... 6
1.3.1 研究问题 ..... 6
1.3.2 主要研究内容 ..... 7
1.3.3 前期成果与本论文的关系 ..... 7
1.4 论文组织结构 ..... 8

**第二章 任务表示与方法基础** ..... **9**

2.1 论辩组件与关系表示 ..... 9
2.1.1 组件及二元关系 ..... 9
2.1.2 多前提关系与任务边界 ..... 9
2.2 合法结构与对象身份 ..... 10
2.2.1 语料约束与候选范围 ..... 10
2.2.2 语义身份与序列化 ..... 11
2.3 生成建模与参数高效适配 ..... 11
2.4 候选空间与结构决策 ..... 11
2.5 严格评价与统计口径 ..... 12
2.6 公共实验协议 ..... 13
2.6.1 数据划分与使用范围 ..... 13
2.6.2 运行配置与可复现记录 ..... 13
2.6.3 统计分析与计算成本 ..... 15
2.7 训练与推理的接口 ..... 15
2.8 本章小结 ..... 16

**第三章 关系影响域约束的增强与成对学习** ..... **17**

3.1 引言 ..... 17
3.2 前期专项建模基础 ..... 17
3.2.1 类型条件低秩适配 ..... 17
3.2.2 线索提示与原有监督 ..... 18
3.3 关系影响域与标注迁移 ..... 18
3.3.1 改写区域与关系因素 ..... 18

3.3.2 条件生成与标注迁移.....21
3.3.3 接受规则与来源控制.....21
3.4 成对组件与关系学习.....22
3.4.1 输入表示与训练头.....23
3.4.2 对齐与金标锚定.....24
3.4.3 按源文档归一化及梯度接口.....25
3.5 算法及性质.....26
3.5.1 数据构造与参数学习.....26
3.5.2 性质与适用条件.....27
3.6 实验结果与分析.....28
3.6.1 实验设置与比较方法.....28
3.6.2 增强质量与标签可靠性.....29
3.6.3 抽取结果与学习目标消融.....31
3.6.4 中心选择与适用条件.....32
3.6.5 生成覆盖与计算成本.....33
3.6.6 变化 漂移与覆盖的联合解释.....33
3.7 本章小结.....34
**第四章 多候选驱动的依赖闭合论辩图修正.....35**
4.1 引言.....35
4.2 候选生成与初始图.....37
4.2.1 组件假设及完整图生成.....37
4.2.2 原始覆盖评分的保留与边界.....38
4.2.3 固定跨度候选与组件冲突.....39
4.2.4 完整关系候选与无边状态.....39
4.2.5 裁剪前规模与资源预检.....40
4.3 组件集合替换与受影响关系重建.....40
4.3.1 冲突闭合的集合替换.....40
4.3.2 全部受影响关系与纯关系事务.....41
4.4 对象评分与事务接受.....42
4.4.1 固定文本证据评分器.....42
4.4.2 训练外候选与概率校准.....43
4.4.3 固定计数效用.....43
4.4.4 分项接受门与编辑成本.....44
4.4.5 联合修正的教学算例.....44
4.5 求解算法及性质.....45
4.5.1 局部整数规划关系补全.....45
4.5.2 有界执行、原子提交与回退.....46
4.5.3 固定评分下的精确差值.....49
4.5.4 集合事务的可达性.....50
4.5.5 有限终止与真实指标边界.....50
4.6 实验与分析.....50

4.6.1 推理协议与方法对照 51
4.6.2 系统结果与策略对照 54
4.6.3 候选覆盖与恢复空间 56
4.6.4 完整对象评分与校准 57
4.6.5 恢复风险与资源取舍 58
4.6.6 预算条件的分析示例 60
4.6.7 案例分析 60
4.7 本章小结 62
**第五章 两阶段框架的综合分析 63**
5.1 两阶段的条件增量 63
5.2 对象作用与聚合成绩的解释边界 64
5.3 训练完成后的在线配置取舍 66
5.4 本章小结 66
**第六章 总结与展望 67**
6.1 研究总结 67
6.2 研究局限 67
6.3 后续研究方向 68
**参考文献 69**
**附录 A 数据处理与复现协议 73**
A.1 坐标与结构数据 73
A.2 配置与结果的关联 73
A.3 其他语料与语言的范围 74
A.4 本版参考规约与配置身份 74
A.5 结果登记与跨章复用 75
A.6 序列化、坐标与候选构造细则 76
**附录 B 评分与事务执行记录 77**
B.1 数据与模型身份 77
B.2 评分与接受轨迹 77
B.3 回退与预算 77
B.4 实现一致性测试 78
B.4.1 已执行的构造检查 78
B.4.2 训练与求解接口 78
B.4.3 外层预算与提交的边界判定 78
B.5 案例的统一记录格式 79
B.6 固定评分性质的证明与构造 80
**附录 C 成果归属与研究声明 81**
C.1 前期共同成果 81
C.2 数据与材料可得性 81
C.3 研究辅助与伦理说明 81

C.4 成果记录与署名责任 81

**附录 D 前期实验基础与轻量诊断 82**

D.1 前期结果的使用范围 82
D.2 训练集内诊断设置 82
D.3 诊断的启示与限制 82
D.4 本版构造验证及复算入口 86
D.5 micro 优化的计数反例 87
D.6 既有接口构造材料 87
D.7 初始 Luna 试验的条件与来源 88
D.8 初始批的完整计数与逐文档结果 89
D.9 初始批的执行与解释边界 90
D.10 探索性扩样与对象诊断 1
D.11 新增语料的来源与固定试验 1
D.12 CDCP 原生评分接口的配对检查 1

**附录 E 前期数值与协议存档 92**

E.1 AAEC 组件分类别旧稿记录 92
E.2 ICIC 原版 AAEC 域内结果记录 92
E.3 ICIC 原版 CDCP 域内结果记录 93
E.4 ICIC 原版模块消融记录 93
E.5 ICIC 原版验证器替换记录 94
E.6 ICIC 原版 Oracle 记录 94
E.7 ICIC 原版修正行为记录 94
E.8 前期粗粒度组件映射 95
E.9 ICIC 原版 AAEC 到 CDCP 迁移记录 96

**附录 F 符号与阅读索引 97**

F.1 核心术语与符号 97
F.2 实现接口补充 98
F.3 研究问题阅读索引 99

**附录 G 外部方法定位与比较协议 100**

G.1 检索范围与方法选择 100
G.2 代码入口与可复现性核查 101
G.3 QOS 式适配与本方法的差异 101
G.4 外部系统接入与结果登记 102

**附录 H 关键诊断与综合证据记录 103**

H.1 训练侧问题规模与初始错误的诊断设计 103
H.2 表达变化、源覆盖与资源轨道 103
H.3 候选规模、共同预算与求解状态 104
H.4 四格对象、恢复阻断与案例 105
H.5 模拟结果后的实证替换顺序 106

H.6 模板筛选的指标阅读示例.....107
H.7 预算条件的假设推演.....107
H.8 对象重叠的非唯一性示例.....110

# 图目录

图 1-1 原始文本中的组件与关系示意.....1
图 1-2 组件关系依赖下的两项研究内容.....6
图 2-1 训练监督保持与推理结构恢复的两阶段接口.....16
图 3-1 可改写组件及关系状态的检查范围示意.....19
图 3-2 关系影响域增强与成对学习的训练架构.....23
图 3-3 训练方案与学习目标的严格关系结果（估算情景）.....32
图 4-1 组件替换及受影响关系的事务式处理示意（人为构造）.....37
图 4-2 多候选驱动的依赖闭合修正执行流程.....49
图 4-3 联合修正中的关系恢复与原真阳性损失（估算情景）.....59
图 5-1 两个训练条件下的推理增量与交互关系（估算情景）.....64
图 H-1 给定成本与完成度假设下的预算结果.....110

# 表目录

表 1-1 近邻方法与本文研究位置.....5
表 1-2 前期成果与本论文深化内容.....8
表 2-1 域内任务与评价边界.....10
表 2-2 公共配置与评价规模（估算情景）.....14
表 3-1 关系保持改写的组件示意.....19
表 3-2 训练侧对照与归因条件.....28
表 3-3 接受样本的标签漂移率（%）（估算情景）.....29
表 3-4 接受与拒绝样本的因素漂移审计（估算情景）.....30
表 3-5 训练方案的严格抽取结果（匹配训练规模）（估算情景）.....31
表 3-6 相同增强集合上的学习目标比较（匹配训练规模）（估算情景）.....31
表 3-7 中心匹配的有效覆盖与自匹配（估算情景）.....32
表 3-8 结论中心与匹配随机中心的比较（匹配训练规模）（估算情景）.....33
表 3-9 固定尝试预算下的覆盖与构造成本（估算情景）.....33
表 4-1 推理方法的修改对象与决策接口.....52
表 4-2 推理侧对照及归因.....53
表 4-3 推理方法的严格抽取结果（估算情景）.....54
表 4-4 从完整组件到完整关系的候选覆盖（估算情景）.....56
表 4-5 三类恢复空间的关系计数诊断（估算情景）.....56
表 4-6 完整对象评分的区分与校准（估算情景）.....57
表 4-7 关系恢复与误改的累计计数（估算情景）.....58
表 4-8 推理成本与预算取舍（估算情景）.....59
表 4-9 Luna 探索性扩样的严格结果（真实运行）.....1
表 4-10 新增原生语料的固定样本结果（真实运行）.....1
表 4-11 CDCP 相同候选与初始图下的评分对照（真实运行）.....1
表 5-1 两阶段组合的四格结果（估算情景）.....63
表 5-2 条件增量与交互差（估算情景）.....63
表 5-3 四格比较的净错误计数变化（估算情景）.....64
表 5-4 CDCP 完整关系的源成员数分组（估算情景）.....65
表 5-5 相对共同起点的关系增量与在线额外时间（估算情景）.....66
表 A-1 复现材料的关联字段.....73
表 A-2 本版参考配置.....74
表 B-1 提议评估与提交的预算判定.....79
表 D-1 初始组件的错误配对分解（既存 CPU 诊断）.....83
表 D-2 补充跨度预算与候选覆盖（既存 CPU 诊断）.....83

表 D-3 已入池遗漏跨度的一步动作限制（既存 CPU 诊断） ..... 84
表 D-4 全部编辑提议的逐文档效果组成（既存 CPU 诊断） ..... 85
表 D-5 固定阈值策略的组件效果（既存 CPU 诊断） ..... 85
表 D-6 修改前后的严格组件对象变化（既存 CPU 诊断） ..... 86
表 D-7 Luna 试验的完整组件与关系计数（真实运行） ..... 89
表 D-8 全部 16 篇文档的初始至 BRJ-lite 结果及候选覆盖 ..... 89
表 D-9 探索性扩样的完整对象计数（真实运行） ..... 1
表 D-10 新语料转换与抽样范围 ..... 1
表 D-11 CDCP 候选评分的覆盖与金标事后诊断 ..... 1
表 D-12 新增试验的修正阶段实测成本 ..... 1
表 E-1 AAEC 组件分类别旧稿记录 ..... 92
表 E-2 ICIC 原版 AAEC 域内结果记录 ..... 92
表 E-3 ICIC 原版 CDCP 域内结果记录 ..... 93
表 E-4 ICIC 原版模块消融记录 ..... 93
表 E-5 ICIC 原版验证器替换记录 ..... 94
表 E-6 ICIC 原版 Oracle 记录 ..... 94
表 E-7 ICIC 原版修正行为记录 ..... 94
表 E-8 前期粗粒度组件映射 ..... 95
表 E-9 ICIC 原版 AAEC 到 CDCP 迁移记录 ..... 96
表 F-1 核心符号及其语义 ..... 97
表 F-2 方法与实验的阅读索引 ..... 99
表 G-1 外部研究候选与本稿比较用途 ..... 100
表 G-2 当前数据构造对照的适配范围 ..... 101
表 H-1 固定尝试轨训练成本存档（估算情景） ..... 104
表 H-2 共同池的变化与覆盖诊断（指标演示的估算情景） ..... 107
表 H-3 裁剪前规模与预检成本（成本函数示例） ..... 108
表 H-4 同端到端时限的质量与尾延迟（成本与完成度假设下的推演） ..... 109

# 第一章 绪论

## 1.1 研究背景与问题提出

论辩挖掘研究文本中的主张、理由及其连接方式。与仅判断作者赞成或反对某一议题相比，该任务还需要定位论证内容，并识别不同组件之间的支持或攻击关系，从而将自然语言论述转化为可分析的结构[1]。组件与关系抽取服务于论证结构分析，但抽取准确并不直接证明论证有效或事实真实。

图 1-1 以一个人为构造的图书馆片段说明任务输入与输出。原文中的“增加图书馆经费”和“延长开放时间”表达两个观点，“图书馆现有座位不足，而且开放时间偏短”提供相关理由。论辩挖掘需要共同确定这些文字的范围、论辩角色及连接关系。若只识别出观点而遗漏理由，或把完整理由截成一部分，关系预测所依赖的端点也会随之改变。

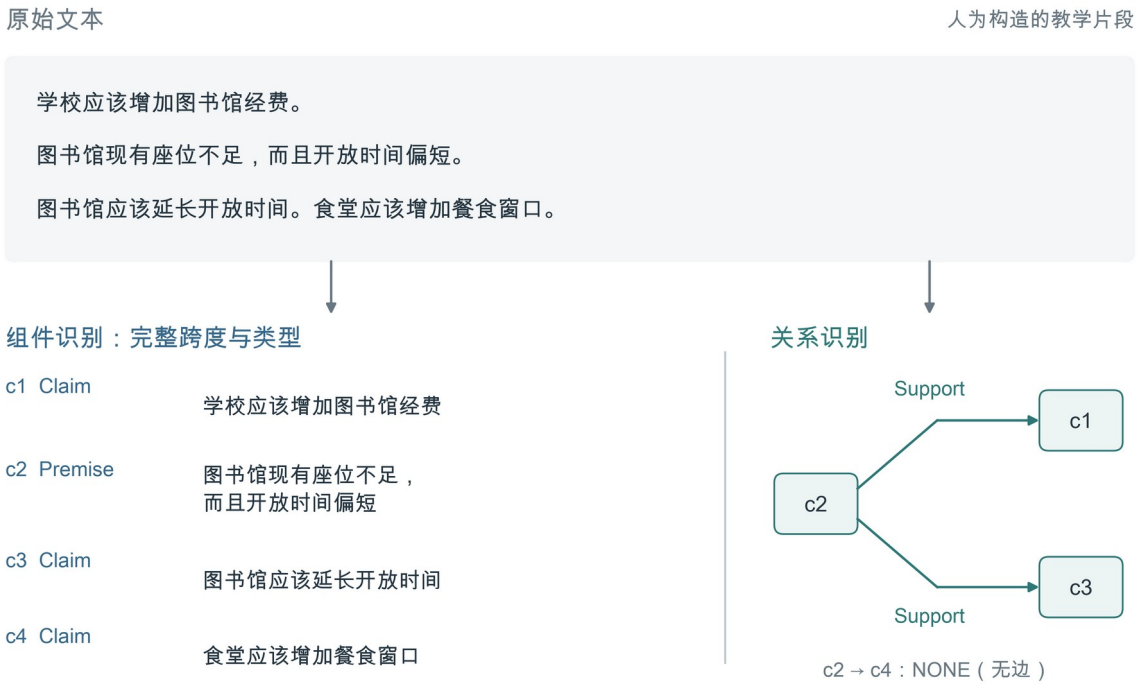



图 1-1 原始文本中的组件与关系示意

该例为便于说明而构造，不是 AAEC 或 CDCP 的标注样本，也不作为实验效果证据。本文后续沿用这一片段解释关系影响域和组件替换，使任务、训练与推理三个层面的讨论具有一致的直观参照。

生成式建模将组件和关系编码为同一输出序列，使多个子任务共享上下文[7]。共享表示并未消除输出对象之间的依赖。当组件跨度没有进入候选集合时，以该组件

为端点的关系就无法严格匹配；当组件存在而显示编号错误时，则可能通过确定性检查修复引用。候选遗漏、语义判断错误与编码不一致具有不同成因，需要分别处理。

训练数据增强也受到同一依赖关系的约束。将上述理由改写为“图书馆座位不够用”，可能仍然支持增加经费，却不再说明延长开放时间的必要性。如果直接继承原关系标注，增强样本就会引入监督噪声。仅检查改写集合内部的关系还不够，连接到集合外组件的关系以及原先无关系的端点组合也可能发生变化。

推理阶段的输入原文保持不变，但模型可能漏掉“延长开放时间”，或仅抽取理由的一部分。补回组件、扩展边界或调整类型之后，关联关系必须依据新的端点对象重新判断。本文据此开展分别作用于两个阶段的研究：训练阶段保持文本改写后的关系监督，推理阶段恢复预测修改后的依赖结构。两项研究以真实文本上的严格组件和关系评价为共同依据，并分别考察收益、失败情形与计算代价。

这两类依赖错误是否具有足够规模，是采用复杂机制的前提。关系影响域检查应与简单改写检查比较，集合修正应与固定组件的纯关系修正比较；若简单方法已覆盖主要问题，复杂设计就应收缩。既存 CPU 诊断、Luna 扩样及新增原生语料试验已记录端点恢复、标签混淆、候选缺失和评分误删（D.3 及 4.6.7）。这些观察支持检验所针对的问题，但其模型和候选配置与正式系统不同，不能替代目标系统的问题发生率；完整诊断方案见 H.1。

## 1.2 国内外研究现状

相关研究从组件识别逐步扩展到联合结构预测，并形成生成建模、数据增强和预测后修正等路线。本文按这些机制组织综述，重点关注输入是否包含金标组件、关系依赖如何进入模型，以及修改后如何判定结构质量。AAEC 和 CDCP 的任务表示及评价规则统一在第二章说明。

### 1.2.1 端到端论辩挖掘与生成建模

组件与关系的联合预测是端到端论辩挖掘的基础。Stab 和 Gurevych 围绕说服性作文建立组件与关系分析方法[2]；Eger 等将组件识别与论证结构预测纳入神经端到端学习框架[4]；Morio 等通过双仿射解析和任务特定参数化支持非树状结构预测[5]。这些工作使组件识别、关系判断和结构约束能够在统一任务中研究，同时提示不同语料不能一律按树结构处理。

生成式方法进一步统一了多个子任务的输出接口。Kawarada 等将论辩挖掘表述为文本到文本生成，为本文的直接生成式对照候选[7]。Cabessa 等把组件分类、关系识别和关系分类组织为生成任务，其方法基于已有组件列表展开，评价范围与从原始

文本定位跨度的设定不同[8]。AASP 则以受约束的预定义动作逐步构建论辩结构，将结构信息引入自回归生成过程[9]。本文依据该工作的 2025 年公开预印本讨论其机制。

GMAM 通过约束指针与重构位置编码生成组件和关系序列[47]，提供了处理输出依赖的一种紧凑方式。UniASA 则将多种论辩结构任务统一为序列生成，并引入子任务分解的多视图学习[48]。前者适合参照结构生成机制，后者适合考察统一表示与辅助任务的作用；本论文的成对学习另以同一原文及其经过检查的改写为对应单位。统一生成、辅助目标与对应约束解决的问题有所联系，其比较需要固定输入及完整对象评价，而不能仅按是否使用大模型分类。

结构与语义信号为生成提供了更具体的条件。DENIM 使用篇章结构感知前缀辅助端到端预测[12]；Das 等以关联组件间的关键短语表达概念联系[13]；FOL-AM 利用一阶逻辑规则组织关系查询和多跳推理[14]。后两项工作以已分割组件为前提，适合用于比较关系语义建模思想，不能直接把分类分数视为严格整图抽取成绩。

组件边界仍是生成系统中的重要误差来源。Caputo 等在 2026 年采用成对标签进行细粒度组件分割，并分析自动分割对后续分类的影响[6]。同年的 ARGUS 系统整合组件分割、组件分类、关系识别与分类，并连接符号求解器开展论辩框架分析[10]。结合 LLM 论辩挖掘综述所讨论的任务和评价差异[11]，本文将研究重点落在可独立检验的监督保持与结构恢复机制，而非模型规模或生成式接口本身。

### 1.2.2 关系保持数据增强

数据增强通过改变表达扩充监督，但生成内容与原标签之间的对应需要单独检查[15]。CoDa 从训练实例提取生成约束[16]，SegMix 在任务相关片段上进行结构感知混合[17]。这些方法表明，增强的作用不仅取决于样本数量，也取决于生成条件和标签可靠性。

论辩挖掘中的直接近邻是质量导向合成 QOS。该方法将上下文和组件组织为槽位化输入，在改写后恢复跨度并继承组件类型及关系标注；其方法节说明，论辩关系并未显式提供给生成模型，而依赖语义保持使原关系继续成立[35]。本文沿用槽位化改写与标注恢复这一研究基础，进一步关注改写的关系影响范围：同时考察集合内部、跨边界的合法端点组合，以及已有关系和无关系状态。

QOS 与同文提出的多样性导向合成 DOS 分别提供质量和多样性的参照[35]；本文的 QOS 式适配只继承其中的槽位化改写思想，不能代表两种方案或原论文完整系统的复现。2026 年 10 月公开的对抗强化学习合成研究交替优化生成器与判别器，生成新的文本—结构标注对[49]。结构质量与多样性的联合考虑已有直接近邻，不能作

为本文排他的研究空白。本文限定为保留原图监督的局部改写，其增量分别由关系影响域检查和对应因素学习的对照检验。两类数据构造目标不同，比较时先统一训练规模和下游抽取器，再解释结构新颖性与表达变化。

关系抽取研究为这种质量控制提供了相邻思路。ConsistRE 以关系条件和上下文约束组织细粒度生成[38]，CovEReD 通过反事实实体替换研究文档级关系预测的一致性[37]，ODDA 关注低资源条件下增强样本的质量与多样性[39]。Wang 等将 LLM 生成样本用于联合实体关系抽取，结合一致性正则化、伪标签与迭代反馈[36]。对后一工作的认识限于出版方摘要和方法摘录，未核实的细节不用于排除性比较。

增强还可能改变模型对表面线索的依赖。话语标记补全的效果因语料而异[40]，弱监督论辩挖掘也需要处理组件边界和关系噪声[18]。因此，本文同时评价标签漂移、表达多样性、接受覆盖和训练成本，并在同一批增强样本上比较不同学习目标，以区分数据构造与成对监督的作用。“保持”是生成和审核目标，其语义可靠性仍需真实审计与任务评价支持。

### 1.2.3 结构化预测与论辩图修正

结构化预测可以在生成时施加约束，也可以在生成后选择和修正候选。语法约束解码通过限制后继 token 控制输出形式[19]，AASP 则把结构动作约束纳入生成过程[9]。这类约束保证的是已编码的规则，跨度是否准确、关系是否成立还需要依据文本与标注评价。

生成后修订和多候选聚合提供了另一类接口。Self-Refine 利用反馈迭代修订输出[20]，自一致性通过采样多条路径聚合答案[22]。在缺乏外部反馈的推理设置中，自纠错也可能无效或降低表现[21]。论辩分析中的 LLM-refine 生成不同 Claim、Evidence 和 Warrant 组合，再选择分割结果[23]。上述研究支持对候选与判断过程分别分析，而不是默认更多修订必然带来收益。

对象与关系的联合处理也存在直接近邻。Re-Cent 以关系标签引导跨度对抽取，并通过关系与跨度对之间的相关性实施修正[43]。Pirozelli 等的论辩重构流程提供组件合并、重写和关系检查步骤，其允许改写组件表述，区别于原文字面跨度抽取[44]。Xiao 和 Li 的 ARGUS 研究则把 LLM 自解释转为抽象论辩框架，以形式语义定义最小代价修复目标[24]；它与前述同名论辩挖掘系统不是同一工作，修复目标也不同于本文的抽取对象效用。

本文的直接基础是作者参与完成的 ICIC 2026 多候选重排序与有界修正方法 MCR-BR[34]。原方法已包含候选跨度替换、类型调整和关系修改。本文进一步把兼

容组件集合替换及全部受影响关系的重建作为完整事务，显式规定评分、约束、预算和回退，重点研究修改之间的依赖如何进入决策。

评价目标为上述设计划定了边界。F1 的最优决策一般不能由单个对象的边际概率直接替代[41]，校准概率与最优 F1 阈值的关系也依赖特定条件[42]。概率校准用于检查置信度与经验正确率的对应[45]。本文据此区分对象概率、代价敏感效用和严格抽取 F1，以同候选、同评分的比较检验事务机制，并独立报告错误接受与计算成本。

### 1.2.4 综合评述与本文研究位置

不同语料的任务表示和训练来源会影响方法比较。MT-AM 利用辅助论辩语料开展多任务训练[25]；AMELIA 统一 19 个数据集的格式，并比较单任务、多任务及模型合并策略[26]。句子级泛化研究还观察到模型对数据集相关词汇线索的依赖[27]。本文以两种原生任务检验方法的适用范围，并将附录中的历史跨域结果单独保留。多任务训练、单源零样本迁移和目标域校准具有不同数据条件，不合并为一种“泛化”成绩。

表 1-1 从方法机制而非异口径分数比较最接近的研究。相关工作已经建立了结构保持增强、多候选选择及对象修正的基础；本文的研究位置在于两种依赖处理：改写前后监督对应的维护，以及组件变化后关联关系的完整重建。前者通过近邻增强、匹配中心和同数据学习消融评价，后者通过同候选同评分的动作比较及结构化全局解码评价。

表 1-1 近邻方法与本文研究位置

| 研究 | 任务或输入条件 | 相关机制 | 本文比较重点 |
| --- | --- | --- | --- |
| QOS[35] | 论辩标注文本的槽位化增强 | 改写后恢复跨度并继承类型及关系 | 内部与跨边界关系、NONE 检查及资源匹配 |
| ConsistRE 与 CovEReD[38][37] | 关系抽取及文档级关系预测 | 关系条件生成或反事实一致性 | 论辩角色依赖与组件关系成对学习 |
| AASP[9] | 自回归论辩结构生成 | 受约束动作构建结构 | 生成过程约束与生成后事务决策的区别 |
| Re-Cent[43] | 联合实体关系抽取 | 关系引导跨度对抽取与修正 | 组件集合修改的依赖域与整体接受条件 |
| 前期 MCR-BR[34] | 从原文生成多个完整论辩图 | 整图重排序及有界组件关系修改 | 集合替换、完整关系重建与风险成本归因 |

表中的机制依据已核对的原文归纳。外部对照选择进一步覆盖结构解析、文本生成、结构感知生成、动作生成与大模型系统，见附录 G。系统层面的主要复现候选为 Kawarada 等的文本生成方法与 UniASA；GMAM、DENIM 作为结构生成补充，QOS／DOS 作为数据构造近邻。选择依据是输入、表示及代码入口的可核对程度，而非仅选取较低的已发表分数。AAEC 的 stance 处理、CDCP 完整源集合和预测坐标仍须接入共同评价器后才确认可比性。其他语言和任务范围见附录 A.3。

## 1.3 研究问题与主要研究工作

组件与关系之间的依赖是两项研究的共同出发点。训练阶段改变文本表达而保持经过检查的图监督，推理阶段保持原文而修改预测图。图 1-2 概括二者的研究关系；它表示问题与方法的对应，不表示将测试预测重新当作训练金标。

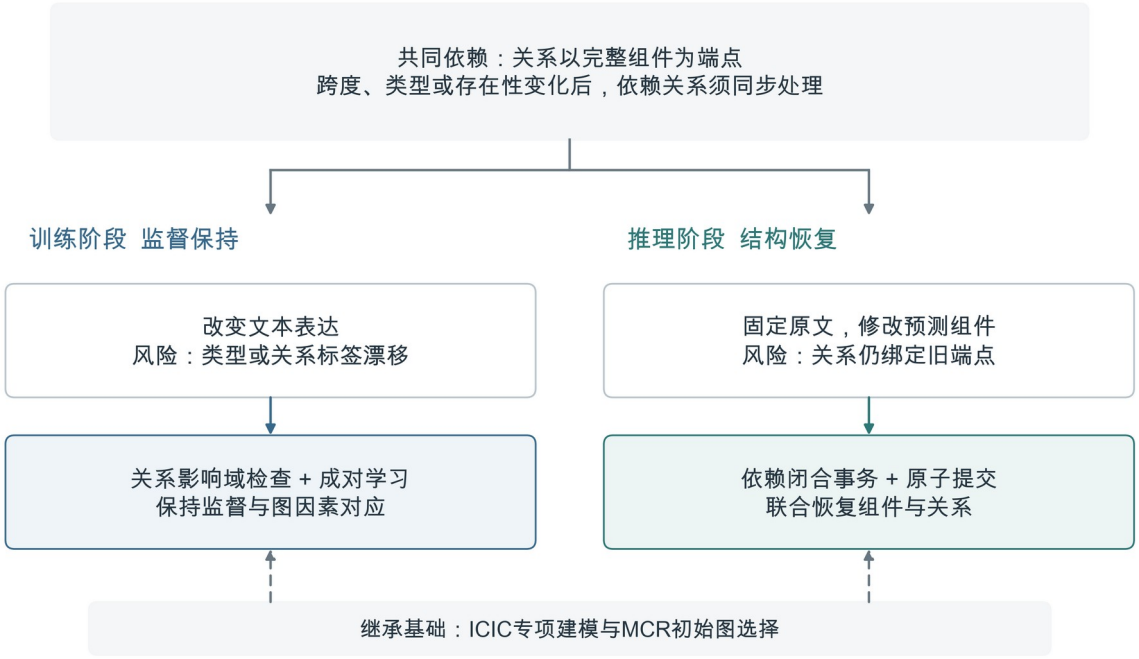



图 1-2 组件关系依赖下的两项研究内容

### 1.3.1 研究问题

RQ1：按关系影响域检查局部改写中的正关系与 NONE，并建立可靠的标注对应，能否在保留足够表达变化和源覆盖的条件下改善监督质量？在相同增强数据和训练预算上，成对因素学习能否进一步改善严格抽取结果？中心选择作为区域策略单独比较。

RQ2：在共同候选、评分与任务约束下，组件集合替换和关系闭合能够处理哪些逐项修改难以处理的错误？与同条件全局 ILP 相比，局部事务在什么求解预算、端到端时限或变更控制要求下值得采用？候选覆盖、真实误改及决策代价共同决定结论。

训练与推理的组合实验用于分析两项方法的互补性，两种原生任务的比较用于讨论适用边界，均不另列为第三项算法创新。

### 1.3.2 主要研究内容

（1）关系影响域约束的增强与成对学习。针对局部改写可能使继承标注失真的问题，按端点关联定义关系影响域，同时检查集合内部、跨边界组合的正关系与 NONE。通过标注迁移建立原文和增强文的对应，并在共享生成表示上学习对应组件与关系因素。该研究把增强数据构造与学习目标连接起来，在实验中分别识别约束范围、中心选择及成对监督的作用。

（2）多候选驱动的依赖闭合论辩图修正。针对组件变化会使关联关系失效、逐项修改难以完整评价影响的问题，以兼容组件集合替换统一表示补回、删除、边界与类型调整及拆分合并，同步重建全部受影响关系。候选事务在固定完整对象评分、整图约束和预算下整体接受或回退。代价敏感效用提供可核算的决策依据，局部整数规划用于求解预算内的关系补全。

两项方法共享任务表示，但优化对象不同。训练辅助头只用于学习阶段，推理评分器以完整预测对象的正确性为目标；推理评分不向生成器回传梯度。相应实验在各自固定条件下验证独立作用，再分析组合表现。

### 1.3.3 前期成果与本论文的关系

本文以前期论文 Improving End-to-End Argument Mining with LLMs via Multi-Candidate Reranking and Bounded Repair 为基础，作者为 Chen Tang、Min Peng 和 Gang Tian，官方公开记录归于 ICIC 2026 Posters Volume I[34]。表 1-2 区分已公开机制与本论文深化内容，已有模块作为研究基础保留，其结果仍归于原配置。

表 1-2 前期成果与本论文深化内容

| 研究层次 | ICIC 已公开机制 | 本论文深化内容 | 结果归属 |
| --- | --- | --- | --- |
| 训练与表示 | 结论专项适配、线索提示、句子辅助监督 | 关系影响域约束增强及成对因素学习 | 原表支持前期训练配置 |
| 候选生成与选择 | 多候选组件、关系构建、整图重排序 | 保留初始图接口，建立固定候选空间 | 候选质量与后续决策分别分析 |
| 组件及关系修正 | 类型调整、候选跨度替换、删边与局部重预测 | 兼容集合替换、完整依赖重建与事务接受 | 新增机制采用独立实验 |
| 评分与评价 | 覆盖、语义、合法性混合评分及非下降接受 | 完整对象正确性、计数效用与风险分析 | 新效用及原生超边评价单独报告 |

原方法已经能够修改组件类型和候选跨度，本文的增量集中在集合级修改、依赖完整性及决策依据。LoRA、提示、辅助头和散度函数分别是继承基础或实现手段，不单独计为原创贡献。前期共同成果的来源见附录 C.1。

## 1.4 论文组织结构

第一章从监督漂移与结构恢复两个问题出发，比较近邻方法并明确成果归属。第二章统一原生任务、完整对象评价与公共协议。第三章研究关系影响域和可靠对应，分别比较数据构造整体及固定数据上的学习目标。第四章说明集合依赖恢复的动作、目标与约束，按策略比较、覆盖、风险、成本及案例组织分析，局部与全局的采用优先级留待实际运行判断。第五章围绕组合增量、对象作用和训练完成后的在线配置选择展开。第六章总结两项设计及尚未完成的核心验证。

附录 A、B 集中保存坐标、序列化、队列调度、日志字段与性质证明，附录 C 说明成果归属，附录 D 分别保存前期基础、CPU 诊断、构造材料和 Luna 真实试验，附录 E 保留历史数值，附录 F 提供阅读索引。附录 G 保存外部方法接入协议；附录 H 区分真实诊断方案、指标演示、预算条件推演和对象非唯一性示例。各类模拟材料具有不同生成来源，不连接为已经完成的方法证据链。

# 第二章 任务表示与方法基础

两项方法需要在同一任务表示下讨论训练监督和预测修改。本章先定义组件、关系及其身份，再说明生成、候选与评价接口，最后给出第三至五章共用的实验协议。语料特有的结构要求与算法选择分别记录，避免把实现约束当作所有论辩文本的共同性质。

## 2.1 论辩组件与关系表示

### 2.1.1 组件及二元关系

本章用$D=(x_1,\ldots,x_n)$表示固定评价分词器下的输入文档，其中$x_i$为第$i$个评价 token；第三、四章用$x$表示同一整篇输入。下文在涉及第四章的删除操作时明确写“删除集合$D$”，不以裸字母代指输入文档。组件定义为$c=(s,e,t)$，其中$1\le s\le e\le n$，跨度采用从 1 开始的闭区间，$t$为语料规定的类型。实现同时保存原文字符坐标与评价 token 坐标，并检查往返一致。评价 token 与模型子词是不同对象，改变评价分词器时需重新建立坐标映射。

二元关系记为$r=(c_i,c_j,\ell)$，包含完整源组件、目标组件及关系标签，方向由提供理由或攻击的一方指向目标。预测结构写为$G=(C,R)$。“端到端”指从原始文本评价组件和关系，不提供测试金标组件，并不要求整个系统仅调用一次模型。

### 2.1.2 多前提关系与任务边界

CDCP 的多前提关系保留为$h=(S,c_j,\ell)$，其中$S$为非空源组件集合，$c_j$为目标。源集合的顺序规范化，但不拆成若干独立二元边。超边匹配要求源集合中全部组件、目标及标签同时正确；漏掉一个源成员就不再是同一完整关系。二元图是源集合大小为 1 的特例。本文用$R$统称关系对象，计算时保留其实际元数[3][46]。

表 2-1 域内任务与评价边界

| 语料 | 组件类型 | 关系对象 | 额外边界 |
| --- | --- | --- | --- |
| AAEC | MajorClaim、Claim、Premise | Support、Attack 二元关系 | Claim 对 MajorClaim 的 stance 单列，不转换为普通关系 |
| CDCP | Fact、Testimony、Value、Policy、Reference | Reason、Evidence 原生超边 | 多前提不静默展开；类型不归并为 Claim/Premise |

表 2-1 依据语料与联合预测研究区分两种任务[2][3][46]。CDCP 中的结论角色用于第三章的增强中心选择与专项模块触发，不改变原生组件标签。第五章分别评价两种语料的原生任务，不将域内比较解释为跨域迁移。粗粒度跨域映射仅属于附录 E 的历史协议，不反向改变本章的原生金标。

## 2.2 合法结构与对象身份

### 2.2.1 语料约束与候选范围

相对于固定语料协议$\mathscr{A}$，以$\mathcal{G}_{\mathscr{A}}$表示合法结构集合。检查内容包括跨度位于原文、类型合法、关系端点存在、关系标签合法，以及语料确实要求的重叠、方向和拓扑规则。树或有向无环图不是跨语料默认条件；嵌套、多前提及其他结构由具体协议处理，不通过删除测试金标来满足预设约束。

本文采用文档级候选协议。AAEC 枚举同文档不同组件的有向对，禁止自环，但不额外施加跨段或组件类型配对的硬掩码；未标注关系的候选状态为 NONE，不依据 stance 补造普通边。CDCP 的候选源为所选组件按位置排列后的连续非空区间，目标不能属于源集合；标签为 Reason 或 Evidence，其余状态为 NONE。主配置对同一端点槽位使用单一关系状态，若数据审计发现并存标签，则采用显式合法标签组合，保留全部标注。

组件重叠、嵌套及其他语料特定限制由数据审计固定为协议清单。若发现与设定不一致的样本，应修订并重新冻结协议。无环性仅作为经过语料验证的可选硬约束，其启用状态须在实验配置中报告。

### 2.2.2 语义身份与序列化

组件身份由文档、规范坐标和类型共同确定，可理解为“哪段文字承担哪种论辩角色”。关系身份由完整端点及标签确定，超边还包括规范排序后的完整源集合。JSON 编号只是序列化引用：纯编号重排不产生新组件，不计作编辑，也不触发重新打分；跨度或类型改变则产生不同对象，需要重新判断相关关系。

组件序列化与关系引用采用固定字段顺序；类型门控只读取已经生成的前缀。完整示例、坐标往返和异常处理见附录 A.6。统一 sources 字段只是表示入口，多前提任务还需候选、评分、优化与评价共同保留完整源集合。

## 2.3 生成建模与参数高效适配

对序列化输出$Y=(y_1,\ldots,y_L)$，自回归生成定义为：

$$P_\theta(Y\mid D)=\prod_{t=1}^{L}P_\theta(y_t\mid D,y_{<t}). \tag{2-1}$$

Transformer 通过注意力聚合上下文[30]。本文继承的参考骨干为 Qwen2.5-7B-Instruct[31]，正式运行前将按 2.6 节登记具体权重 revision、分词器及环境；当前骨干名称仅为参考设置。序列生成概率受长度和字段顺序影响，因此概率较高的输出仍需接受结构与语义评价。

LoRA 在冻结权重上引入低秩更新[32]：

$$W=W_0+\frac{\alpha}{r}BA,A\in\mathbb{R}^{r\times d_{in}},B\in\mathbb{R}^{d_{out}\times r}. \tag{2-2}$$

其中$r$是秩，$\alpha$是缩放系数。连续提示以可学习向量表达任务条件，其基础来自提示调优研究[33]。第三章继承上述参数高效机制及前期结论条件门控，进一步定义增强文本与因素学习接口；这些通用机制本身不作为本论文的新增理论。

## 2.4 候选空间与结构决策

多候选选择先从已生成的完整图中确定初始状态：

$$G_{rank}=arg\,max_{G\in\mathcal{S}}E_{rank}(G),G_0=L_{\mathcal{A}}(G_{rank}). \tag{2-3}$$

其中$L_{\mathcal{A}}$为各方法共用的确定性合法化过程，其规则与变更单独记录。若无法得到合法状态，则显式返回失败，不进入后续修正。原始重排序胜者与合法初始图因此可能不同。

结构恢复涉及三个环节：候选是否覆盖正确对象，评分是否能够识别较好的方案，搜索是否能在预算内找到该方案。增加候选数量可能扩大覆盖，但不能自动改善

判断或求解。Candidate Oracle 只在离线分析中使用金标度量候选空间，不进入测试时的决策。

第四章在初始选择后固定跨度集合$U$、带类型组件集合$\mathscr{V}$和关系候选集合$P$，下文将这组有限候选集合称为候选宇宙。“完整影响域”均相对于声明的候选范围定义，不意味着枚举任意文本跨度或所有非空组件子集。未进入候选宇宙的正确对象对当前修正器不可达，其影响由覆盖及可达上界分析说明。

合法性检查、语义评分与统计校准分别回答不同问题。合法性只涉及编码和结构规则；概率含义需在真实预测负例与独立校准材料上检验；使用不同模型参数也不保证生成器和评分器的错误统计独立。由于搜索可能反复选择错误高分对象，本文同时评价固定提案上的评分质量和最终接受轨迹上的误改。

## 2.5 严格评价与统计口径

对组件或完整关系对象，分别汇总$TP$、$FP$、$FN$。下式的$P$和$R$仅表示精确率与召回率，正文采用 Precision 和 Recall 指称这两个指标，以区别于第四章的关系候选池$P$及图中的关系集合$R$：

$$P=\frac{TP}{TP+FP},R=\frac{TP}{TP+FN},F_1=\frac{2TP}{2TP+FP+FN}. \tag{2-4}$$

主指标采用精确组件 micro-F1 和严格关系 micro-F1。前者要求跨度与类型完全匹配；后者还要求全部端点跨度、类型、方向和关系标签正确。CDCP 以完整源集合计数，不以展开后的边数替代原生关系数。边界 F1 和给定金标组件的关系分类作为辅助诊断，域内细粒度 Relation-F1 与跨域无标签 Link-F1 分别命名和展示。

每个预测语义对象最多匹配一次金标，多余重复项计 FP。若图归一化预先去重，则同时报告原始重复率，并对全部方法使用相同规则。解析、超长或图验证失败的文档仍进入评价，其金标对象计入 FN，失败率另报。数据 ID 缺失或重复需报错；分母为零时采用预先固定的零值约定，并保留原始计数。

micro-F1 先汇总对象再计算，不等于分类别或逐文档 F1 的均值。分数采用百分制，差值以百分点表示。跨种子报告均值与样本标准差，文档级置信区间在每次重采样后重新汇总计数，重复文本按组重采样。历史表中的“±”在原统计记录未绑定时保留原符号，不重新解释为某一种统计量。

## 2.6 公共实验协议

### 2.6.1 数据划分与使用范围

AAEC 和 CDCP 分别按表 2-1 的原生任务进行域内实验。数据发布版本、原文哈希、文档 ID、坐标映射和异常样本清单在划分前冻结。所有原文与其增强变体按源文档分组；相同文本但 ID 不同的文档按全文哈希去重或共同分组，防止变体和重复文本跨越训练、开发与测试边界。

表 2-2 的 320 篇与 580 篇均为训练侧源文档总数，包含开发用途；独立评价文档分别为 80 篇与 148 篇。生成超参数和固定训练轮数在 OOF 候选生成前冻结。三折交叉拟合在训练侧进行，每折生成器与跨度头均排除持出源文档及其全部变体；T0 和 T1 分别产生候选，覆盖各自错误分布。最终生成模型拟合全部训练侧源文档，独立评价标签不参与训练、提示调整或选择。

评分器使用训练侧 OOF 记录，并按固定源文档分组进一步划分拟合、校准和策略选择用途。AAEC 三部分为 256、32、32 篇，CDCP 为 464、58、58 篇，组间没有共享原文或变体。校准部分只拟合概率变换，策略部分只选择阈值与预算；这些角色属于同一训练侧总量，不另增加隐含开发集。评分器及规则冻结后，才在独立评价集汇总最终结果。上述隔离针对信息使用路径，不能据此认定生成器与评分器的误差独立。

### 2.6.2 运行配置与可复现记录

比较方案统一骨干、源文档分组与严格评价，方法间仅改变声明的增强条件、学习目标或修正策略。表 2-2 列出估算情景的参考设置与规模，不构成可执行配置；情景结果按语料、方法和种子关联，跨章复用同一记录。

表 2-2 公共配置与评价规模（估算情景）

| 项目 | 统一设置 | 使用说明 |
| --- | --- | --- |
| 骨干与适配 | Qwen2.5-7B-Instruct；LoRA rank 16、alpha 32、dropout 0.05 | 继承 ICIC 专项模块，基础权重冻结 |
| 学习配置 | AdamW；学习率 $2\times10^{-4}$；5 个 epoch；有效批量 32 源文档 | 每批 4 源文档，累计 8 步，末批按有效文档数归一化 |
| 长度与种子 | 输入 4096、输出 2048；总上下文 8192；种子 17、29、43 | 生成、训练及评价身份分别记录 |
| 材料规模 | AAEC 训练侧 320、独立评价 80；CDCP 训练侧 580、独立评价 148 | 训练侧含拟合、校准与策略用途；按源文档分组 |
| 匹配增强规模 | AAEC 500 变体／0.82M token；CDCP 900／1.35M | 同数据学习消融保持变体与更新条件一致 |
| 评分评价对象 | 每语料组件 2400、关系 4800 个完整对象 | 用于表 4-6 的固定提案评价，不是全部训练对象数 |
| 资源口径 | 单张 80GB 设备；CPU 4 线程；模型调用与求解分项计费 | 冷启动、缓存和一次性构造分开登记 |
| 局部与全局求解 | AAEC 每文档 3 秒，CDCP 5 秒；大预算 60／90 秒 | 单次上限不高于剩余总时限 |
| 外层与编辑预算 | 每轮 32 次尝试、3 次接受；最多 4 轮；组件 24、关系 96 | 尝试耗尽不禁止提交已评估的合格项 |

正式运行前须冻结数据与折清单、各模型及分词器版本、生成与审核提示、采样参数、损失系数、校准方式、求解器和资源上限。当前增强模型、语义验证器、文本编码器、跨度头及评分器尚未绑定具体检查点；$\rho$、$\lambda_{sup}$、$\lambda_C$、$\lambda_R$的取值及选择方案也未登记。配套配置单列未绑定字段，表中参考值不代替实测环境。运行后按附录 A 关联配置、候选与逐文档计数，分开保存生成、评分和求解成本。

### 2.6.3 统计分析与计算成本

核心比较固定 17、29、43 三个种子，均进入结果汇总。主指标为组件与严格关系 micro-F1，跨种子报告均值与样本标准差；文档级配对重采样重复 2000 次，每次先汇总对象计数再计算 micro-F1。重采样使用相同文档索引配对各方法和种子，得到固定三个种子条件下的文档不确定性，不将重复种子的同一文档视作新增独立文档。区间、效应量、持平、下降和失败配置采用同一报告口径。

成本统计覆盖全部尝试。训练阶段记录源文档访问量、增强 token 量、有效更新步数、可训练参数量、设备时间和显存；未通过筛选的生成也计入成本。推理阶段记录候选生成、评分、拒绝事务、求解及最终输出的全部开销，包括模型调用、输入输出 token、CPU 时间、端到端时延和峰值显存。缓存命中时分别报告逻辑预算与实际消耗。

正式运行前，训练侧将 T-B 的数据构造整体比较和 T-E 的同数据学习比较列为关键对照；推理侧以 RelationOnly 和单对象动作分别检验组件可变性与集合表达，以同目标全局 ILP 检验求解策略取舍。组件优先分步策略补充检验共同决策，其余消融和交互用于机制解释。各关键比较统一报告效应量、文档配对区间、错误代价和完整成本，不因现有人工材料只为部分比较提供区间而改变职责。

局部与全局 ILP 先比较相同逐文档总求解预算，另以相同端到端时限评价部署条件；软件、线程、缓存条件和共同准备开销保持一致，大预算结果不自动视为最优。95%区间为固定三种子条件下逐比较的文档配对区间，未作多重比较校正；区间跨零不能解释为等效，也不以多个未校正区间共同确认全部机制。求解状态、成本及失败记录见附录 H.3。

## 2.7 训练与推理的接口

训练阶段输入带标注文档，只改写指定组件文字，并检查组件角色与关系监督是否保持。推理阶段输入未提供金标的新文档，原文保持不变，允许修正模型预测的组件与关系。图 2-1 给出数据流和阶段接口，绪论图 1-2 则用于说明二者的研究分工。

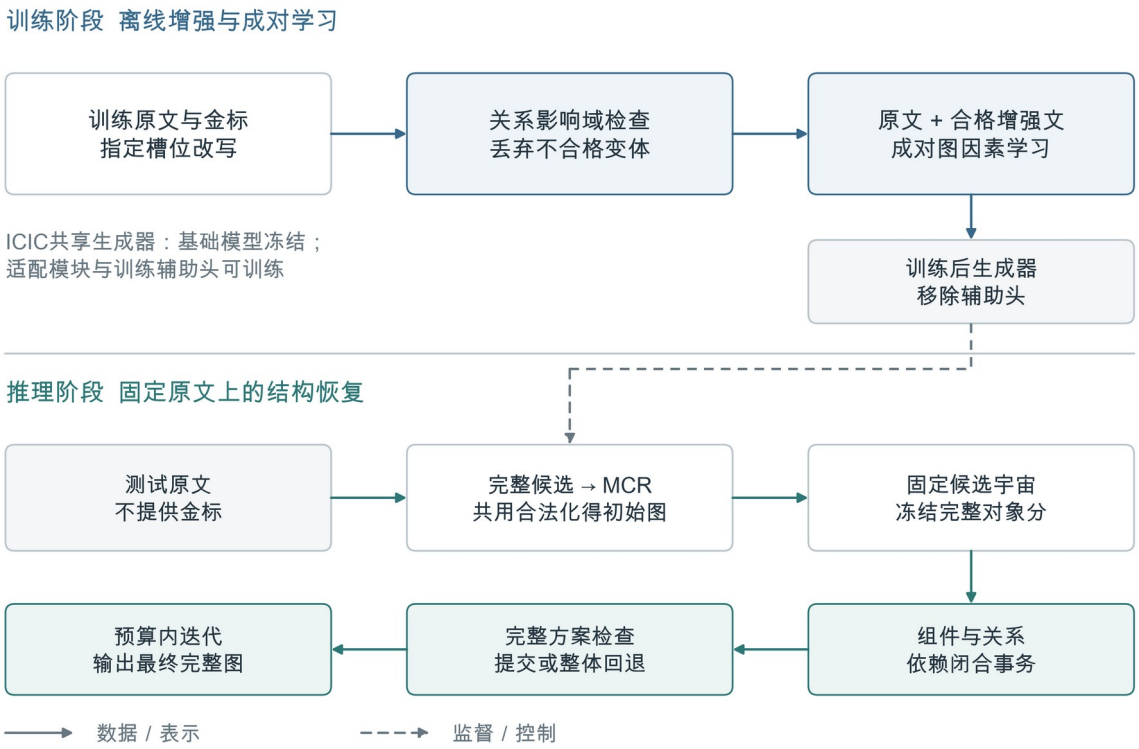



图 2-1 训练监督保持与推理结构恢复的两阶段接口

合格的原文与增强文用于更新生成器，测试文档仅交给训练后的模型。结论专项建模、多候选生成和初始重排序继承 ICIC 基础；关系影响域与成对因素学习、依赖闭合事务及接受决策为本论文的深化内容。训练辅助头不进入测试路径，推理评分不回传生成器，各阶段保留独立的拒绝和失败出口。

第三章辅助头在训练金标跨度上学习因素标签，第四章评分器在交叉拟合预测上判断完整对象是否正确，二者不直接共用概率。训练改进在推理策略固定时评价，推理改进在同一生成检查点和候选宇宙内评价；不同训练检查点可以产生不同候选，因为候选质量本身属于训练效果。

## 2.8 本章小结

本章以完整语义对象统一组件、二元关系和多前提超边，区分候选覆盖、评分判断与预算内搜索。严格评价、公共实验协议和阶段接口为后续方法提供共同基础。第三章在这一表示上研究改写后的监督保持，第四章研究组件预测变化后的结构恢复，第五章再评价两阶段组合。

# 第三章 关系影响域约束的增强与成对学习

## 3.1 引言

训练数据增强的关键问题，是文字发生变化后，组件角色与关系监督还能否被可靠继承。只看流畅度或组件含义，可能漏掉跨出改写区域的关系；只检查已有正关系，也可能遗漏原 NONE 组合被改写成支持关系的情况。关系影响域因此决定需要复核的对象，而原文与增强文的标注对应决定哪些监督可以共同学习。

影响域检查覆盖内部正关系、跨边界正关系及相应 NONE 组合。该范围由监督依赖确定，但它是否比简单改写检查更有必要，仍取决于真实漂移、有效表达变化与源文档覆盖；诊断设计见附录 H.1—H.2。

本章提出关系影响域约束的增强与成对学习：按完整端点依赖检查改写，迁移通过检查的标注，再将两视图的组件与关系因素对应用于共享表示学习。结论优先是默认区域选择策略，其价值由匹配随机中心对照检验；即使中心差异不稳定，监督对应和成对学习仍有各自可检验的问题。前期结论专项适配、提示与句子监督提供生成基础[34]，LoRA、辅助头与 JS 散度作为实现机制说明。

图书馆片段只解释可能的语义漂移。方法始终使用原生组件类型和完整关系：AAEC 的 stance 不转换为普通边，CDCP 的结论角色不改变原生类型。下文依次给出影响域、标注对应和学习目标，再分开分析数据构造与学习增量。

## 3.2 前期专项建模基础

### 3.2.1 类型条件低秩适配

本节说明前期专项建模与新增学习目标的接口。参考骨干为 Qwen2.5-7B-Instruct，冻结基础权重，在注意力投影中保留全局和结论专项低秩分支；LoRA 参数化沿用已有方法[32]。对于 $W_0 \in \mathbb{R}^{d_{out} \times d_{in}}$，定义

$$h'_t = W_0 h_t + \frac{\alpha}{r} B_g A_g h_t + g_t \frac{\alpha}{r} B_c A_c h_t, A_\cdot \in \mathbb{R}^{r \times d_{in}}, B_\cdot \in \mathbb{R}^{d_{out} \times r}. \tag{3-1}$$

全局分支参与所有位置的计算，结论分支由 $g_t \in \{0,1\}$ 控制。字段按 id、type、span 排列；可见前缀中的结论类型值完整闭合后，门控在该组件的后续字段开启，并在组件结束时关闭。AAEC 和 CDCP 的触发类型分别为 Claim/MajorClaim 和 Policy/Value；输入、未闭合类型字段及关系区域均令 $g_t = 0$。教师强制训练也仅使用可见前缀。

这一门控作用于类型确定后的跨度等字段，不回溯修改已输出类型。参考配置取 $r=16$、$\alpha=32$，以单一全局 rank-32 分支作为参数量匹配对照；实际计算成本另行测量。

### 3.2.2 线索提示与原有监督

连续提示沿用参数高效提示调优机制[33]。对 therefore、thus、in conclusion、consequently、hence、to conclude 作不区分大小写的词边界匹配；命中时在聊天模板输入嵌入之前插入四个向量 $P_i \in \mathbb{R}^d$，未命中则不插入。提示位置不计入原文坐标。

词典只控制提示启用，不赋予结论标签。话语标记的收益不能由标记数量直接推定[40]；原文与增强文分别按各自文本触发提示；该规则沿用前期配置，本章不将其单独计为新增机制。

生成目标对有效回答 token（含 EOS）取平均，聊天输入和提示向量不参与该项损失：

$$L_{gen}(x,G)=-\frac{1}{T_y}\sum_{t=1}^{T_y}\log p_\theta(y_t\mid x,y_{<t}). \tag{3-2}$$

句子辅助任务沿用 ICIC 专项监督思路：按句末标点和文档结尾分句，对输入最后一层隐藏状态作句内均值池化，经线性层和 sigmoid 得到 $\hat{z}_i$。句子与结论类金标跨度相交时令 $z_i=1$，否则为零；跨句组件可标记多个句子。定义

$$L_{sent}=-\frac{1}{N_s}\sum_{i=1}^{N_s}\left[z_i\log\hat{z}_i+(1-z_i)\log(1-\hat{z}_i)\right],\quad L_{ICIC}=L_{gen}+\lambda_{sent}L_{sent}. \tag{3-3}$$

参考配置取 $\lambda_{sent}=0.5$。句子头只读取输入表示，用于共享表示学习。上述生成目标与句子监督构成继承目标 $L_{ICIC}$；3.3 节构造增强视图，3.4 节在此基础上引入组件、关系头及成对监督。

## 3.3 关系影响域与标注迁移

### 3.3.1 改写区域与关系因素

本章的文本改写是训练数据增强：只替换已标注组件所对应的文字，不重写整篇文章，也不重新决定组件类型或关系答案。改写集合由组件组成，不必对应一个连续段落。“内部”与“跨边界”均相对于这个集合定义，与是否跨句、跨段没有直接等价关系。

表 3-1 用人为构造的中文片段说明二元关系，不作为 AAEC 或 CDCP 的实测样本。

表 3-1 关系保持改写的组件示意

| 组件 | 角色 | 原始文字 | 本轮处理 |
|---|---|---|---|
| $c_1$ | Claim | 学校应该增加图书馆经费。 | 可改写 |
| $c_2$ | Premise | 图书馆现有座位不足，而且开放时间偏短。 | 可改写 |
| $c_3$ | Claim | 图书馆应该延长开放时间。 | 文字只读 |
| $c_4$ | Claim | 食堂应该增加素食窗口。 | 文字只读 |

在此示意中，设定$c_2 \to c_1$和$c_2 \to c_3$为 Support，$c_2 \to c_4$为 NONE。可改写集合取$A=\{c_1, c_2\}$：前一条 Support 的两端均在集合内，后一条只有一端在集合内，分别属于内部和跨边界因素。$c_2 \to c_4$同样跨越边界，但标签为 NONE，表示该合法端点组合没有标注关系。NONE 不作为输出边，与组件不存在的状态不同。

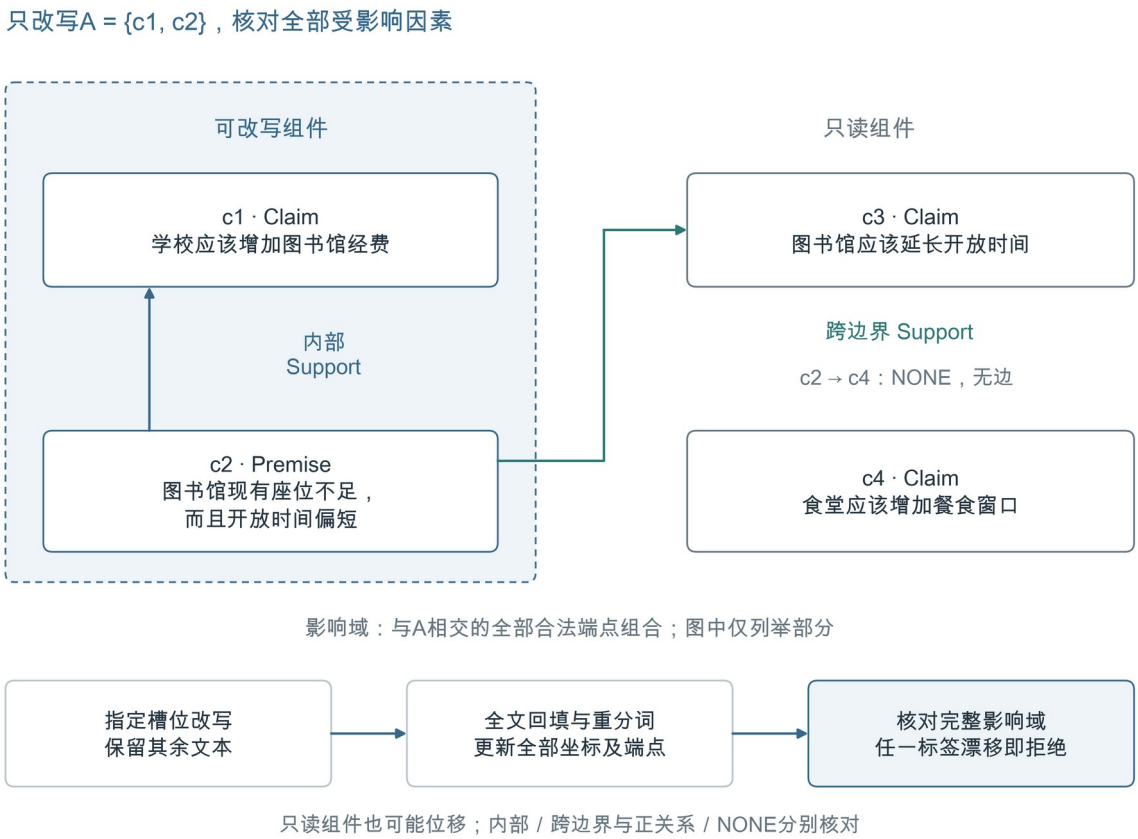



图 3-1 可改写组件及关系状态的检查范围示意

图 3-1 中的位置分类与标签状态相互独立。内部组合和跨边界组合都可能带有正关系标签，也都可能为 NONE。检查已有关系是为了防止支持、攻击或方向发生改

变；检查 NONE 则是为了防止改写引入原标注中不存在的新关系。图仅画出用于说明的组合，实际检查范围由下述定义确定。

对训练金标图 $G=(C,R)$，每篇文档固定一个中心。AAEC 优先集合为 Claim 与 MajorClaim，CDCP 为 Policy 与 Value；后者只定义本方法的触发角色，不改写原生类型。将种子、文档身份和规范化组件键按 UTF-8 规范 JSON 编码，计算 SHA-256，按哈希及组件键升序选取第一个对象。主参考种子为 17，同一文档全部尝试复用同一中心；不依据生成成功率换中心。

优先集合为空时，从全部合法金标组件按同一顺序回退，并记录 fallback；组件集合为空时保留原文、跳过增强。改写集合 $A$ 由中心及所有指向中心的金标关系的完整源成员组成，去重、不递归扩展。无入关系时仅改写中心；超过三源成员的金标超边仍完整纳入，新增 NONE 因素的元数预算不截断金标。其余组件文字只读。

若槽位重叠、完整输入超过冻结上下文上限，或影响域无法在单次审核资源内完整处理，则跳过该文档增强并记录具体原因，不删除源成员或改选其他中心。不同模型的上下文及调用上限由运行清单提供；未提供时不启动生成。每文档最多四次尝试、两个接受变体，原始样本始终保留。该选择控制定义和资源，不意味着结论中心已经优于其他中心。

记 $\Omega(C)$ 为协议允许的完整端点组合集合，因素 $\omega=(S,v)$ 由非空源组件集合 $S$ 和目标 $v$ 构成。AAEC 中 $|S|=1$，枚举全部合法有向组件对；内部正边、边界正边和其余合法对均纳入候选。因素标签 $y_\omega$ 为协议规定的关系状态，无标注关系时记作 NONE。若协议允许同一端点组合具有多个标签，则使用合法标签组合表示状态，不能通过任取一个标签丢失监督。

CDCP 保留 $(\{c_{i_1},\dots,c_{i_k}\},c_j,\ell)$ 的原生多前提超边，$\ell\in\{Reason,Evidence\}$。源成员按原文顺序规范化，整条超边作为一个关系对象，不展开为独立二元关系。

训练因素宇宙包含全部金标超边的端点组合，并补充满足源范围规则、最多含三个源成员的候选组合。超过三个源成员的金标关系仍全部保留。源范围的连续性依据所选组件序列判定，而非要求原文字符之间没有间隙。

NONE 仅在上述有限宇宙内定义，不涉及组件集合的全部子集。三源成员预算使更长的金标超边缺少同元数 NONE 对照，可能形成长度相关的监督偏置，需按元数诊断。这一辅助头不用于估计长超边的完整对象正确率。

设 $V(\omega)=S\cup\{v\}$，完整影响域定义为

$$\mathscr{D}_A=\{\omega\in\Omega(C):V(\omega)\cap A\neq\varnothing\}. \tag{3-4}$$

二元情形即 $\{(u,v):u\in A\vee v\in A,(u,v)\in\Omega(C)\}$。全部端点位于 $A$ 中的因素属于内部因素，仅部分端点位于 $A$ 中的属于边界因素。这里的“完整”限定于预先声明的因素宇宙；NONE 也是标注协议中的无边状态，不代表任意语义解释下均无联系。改写可能经指代或篇章语境影响两个只读端点，这类域外漂移纳入人工审计。资源裁剪版本另报因素覆盖率，并标记为近似设置。

### 3.3.2 条件生成与标注迁移

增强模型接收全文、可改写组件的槽位和类型、只读端点目录及影响域标签。条件可采用“全部合法端点目录、显式正关系表、其余因素为 NONE”的无损编码，避免逐条重复大量无边因素；验证和训练时仍按展开后的因素执行。输出限定为组件 ID 到替换文本的映射，不允许新增组件、修改类型或自行重建关系表。

程序按原始字符区间执行槽位替换，随后对完整文档重新分词，建立组件对应

$$\varphi:C\longrightarrow C',(s_c,e_c,t_c)\longmapsto(s'_c,e'_c,t_c). \tag{3-5}$$

组件 ID 仅用于追踪身份，新的跨度由回填文本计算。只读组件也可能因前文长度变化而移动，因而必须更新全部组件坐标。$\varphi$ 是组件之间的双射，不是新旧 token 之间的双射。关系和超边的全部端点按 $\varphi$ 输运，得到 $\varphi(G)$。重叠槽位、坐标往返不一致或无法无损输运的尝试直接拒绝，原始训练样本仍保留，不通过删除异常金标来迁就增强操作。

沿用表 3-1，$c_1$可改写为“学校应为图书馆投入更多经费”，$c_2$可改写为“当前图书馆的座位数量不够，开放时长也较短”。目标是改变表达，而保留组件角色及两条 Support。程序不沿用原字符位置，而根据回填后的长度重新确定$c_1$、$c_2$以及后续只读组件的坐标，再通过$\varphi$迁移关系端点。

若$c_2$只被改成“图书馆现有座位不足”，它仍可能支持$c_1$，却删除了支持$c_3$的开放时长信息。此时，仅检查内部正边会遗漏问题，跨边界检查应将该变体识别为候选拒绝项。同样，若改写加入支持$c_4$的新内容，即使两条原 Support 仍然存在，原 NONE 标签也不再适合直接继承。语义验证器可能漏判，因此上述条件仍需由 3.6.2 节的标签可靠性审计检验。

### 3.3.3 接受规则与来源控制

筛选首先检查格式、槽位身份、坐标往返和全部端点引用；随后在全文上下文中检查论辩角色、指代、否定、模态和立场，并逐项核对影响域中的关系方向、标签及 NONE 状态；最后检查重复程度和机械添加结论词等退化改写。拓扑检查不额外施加数据协议未要求的无环性等限制。

语义验证器采用独立于增强模型参数的固定模型与提示。验证时向其提供待判定的文本、跨度及任务定义，不预先给出待判断因素的金标答案；验证器先分类，再由程序与原标签比较。各阶段记录判定和拒绝原因。独立参数不等于误差独立，模型判断也不能充当语义保持证明，因而质量审计同时盲查接受样本、拒绝样本及普通改写样本。

任何一个受检标签发生漂移均拒绝整个变体，不删除失败关系后继续使用剩余部分。参考生成预算为每篇源文档最多四次尝试、最多接受两个变体；预算耗尽后保留已有通过样本，无通过样本则只保留原文，不无限重试。生成版本、提示、随机种子、源组件、$\varphi$、拒绝原因和 token 成本共同存档。原文及其全部变体始终属于同一数据划分。

全文回填并不自动重平衡类别。若源文档 $d$ 含 $N_{d,\tau}$ 个类型 $\tau$ 的组件，接受 $a_d$ 个变体，则存储样本中的该类总数为 $N'_{\tau}=N_{\tau}+\sum_d a_d N_{d,\tau}$。各源文档接受数相同会同比增加所有类型，而非只增加结论。因此，类别分布、表达多样性和标签保持分别报告，不能用增强数量替代有效性证据。多样化增强已有相应研究[39]，本章同时考察约束强度、接受率与表达变化的代价。

## 3.4 成对组件与关系学习

增强样本通过检查后，还需要让模型学会“不同表达对应相同论辩功能”。本节保留原文和增强文各自的金标训练，同时比较对应组件与关系的预测分布。例如，表 3-1 中的$c_2$换了说法后仍应被识别为论据，其对$c_1$、$c_3$的关系判断也应与原文一致。这一目标约束的是类型与关系判断，而不是要求新旧文本具有相同词序、长度或跨度坐标。仅使两个预测相同仍可能得到共同错误，因此成对约束必须与金标监督配合。

图 3-2 给出从增强样本到参数更新的训练架构。原文与增强文经过同一个生成器，组件对应 $\varphi$ 将两个视图的类型分布和关系状态分布连接起来；生成目标、句子监督与新增辅助目标共同作用于可训练表示。基础模型权重保持冻结，辅助头仅在训练阶段使用。

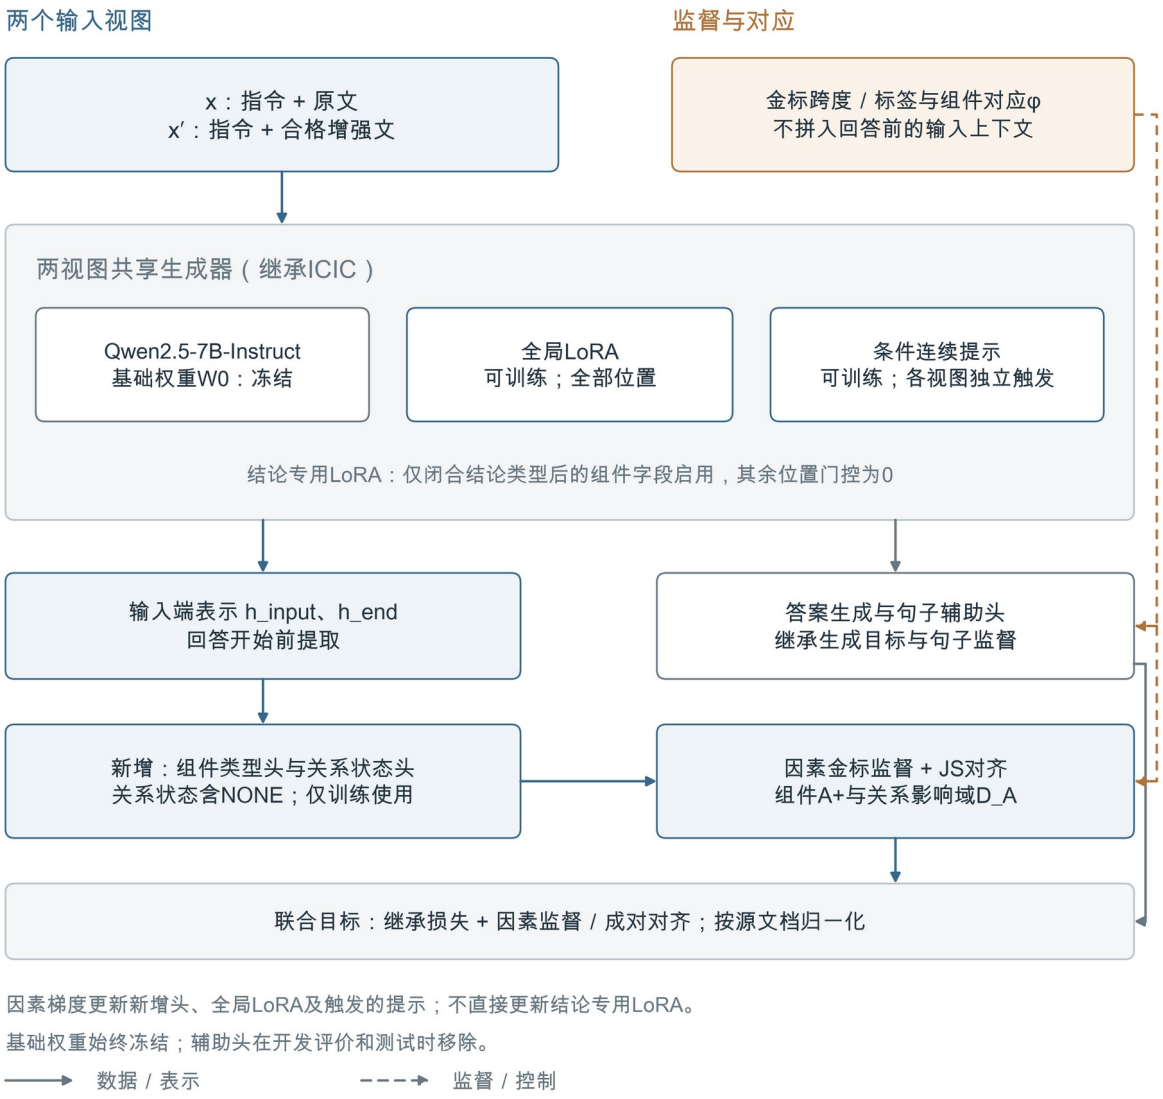



图 3-2 关系影响域增强与成对学习的训练架构

图 3-2 区分继承的专项适配、线索提示和句子监督，以及新增的组件头、关系头与成对损失。实线表示文本和隐藏状态的数据流，虚线表示监督或控制连接；冻结参数与可训练模块分别标示，各类参数的梯度来源在 3.4.3 节统一说明。

### 3.4.1 输入表示与训练头

组件类型头和关系状态头以共享生成器的输入表示为基础，使用金标跨度定位训练因素。下游生成器只接收任务指令及原文或增强文；增强构造阶段使用的金标槽位、类型与关系条件仅用于监督，不进入该模型的输入。

令 $h_i^x$ 为输入子词隐藏状态，$B_x(c)$ 为组件字符跨度对应的输入子词集合，$h_{end}^x$ 为全文输入结束且回答尚未开始处的隐藏状态。坐标映射和输入隔离的实现验收要求见附录 F.2。组件表示与类型分布定义为

$$u_c^x = MeanPool_{i \in B_x(c)} h_i^x,\ p_C^x(c) = softmax\, f_C([u_c^x; h_{end}^x]). \tag{3-6}$$

因果模型的早期 token 只能访问左侧上下文。拼接 $h_{end}^x$ 为跨度表示补充全文上下文通道，并不改变模型的因果注意力结构；组件头不输入待预测的金标类型。

关系头显式区分源和目标，写为

$$p_R^x(S, v) = softmax\, f_R([Pool(\{u_c^x : c \in S\}); u_v^x; h_{end}^x; \eta(S, v)]), \tag{3-7}$$

其中 $f_C$、$f_R$ 为两层感知机，$Pool$ 为源成员表示的算术均值。$\eta$ 包括源成员数、源起点的最小值和均值、源终点的最大值和均值，以及目标起止位置；坐标均除以文档 token 数，不包含金标类型或关系标签。二元关系采用单一源表示，超边按规范顺序组织源成员，以完整源集合和目标为监督对象，输出状态包含 NONE。两个辅助头在开发评价和测试时移除。

### 3.4.2 对齐与金标锚定

组件对齐应覆盖被改写的组件及其正关系所连接的只读端点，定义

$$A^+ = A \cup \bigcup_{\substack{\omega \in \mathscr{D}_A \\ y_\omega \neq \mathrm{NONE}}} V(\omega). \tag{3-8}$$

即改写组件以及通过正边或超边相连的只读端点。NONE 因素进入关系项，但不因此把全部远处组件都纳入组件对齐。对于一个通过筛选的视图 $x'$，组件对齐为

$$L_C^{align}(x, x') = \frac{1}{|A^+|} \sum_{c \in A^+} JS(p_C^x(c), p_C^{x'}(\varphi(c))), \tag{3-9}$$

其中 $JS(p, q) = \frac{1}{2} KL(p \| \overline{p}) + \frac{1}{2} KL(q \| \overline{p})$，$\overline{p} = (p + q)/2$。不对任一视图停止梯度。

将影响域划分为正关系组 $D_+$ 和 NONE 组 $D_0$，令 $\mathscr{B} = \{b \in \{+, 0\} : |D_b| > 0\}$。关系对齐采用组间、组内两级平均：

$$L_R^{align}(x, x') = \frac{1}{|\mathscr{B}|} \sum_{b \in \mathscr{B}} \frac{1}{|D_b|} \sum_{\omega \in D_b} JS(p_R^x(\omega), p_R^{x'}(\varphi(\omega))). \tag{3-10}$$

这样可避免数量较多的 NONE 因素仅凭数量淹没正关系。当 $\mathscr{D}_A = \varnothing$ 时，该项置零并跳过空域关系检查，不人为添加关系；全文其他关系的生成监督仍保留。$A^+$ 为空时组件对齐也置零。

低 JS 可能来自两个视图一起预测错误，故每个视图同时接受金标监督。组件头交叉熵在该视图全部组件上取平均，关系头交叉熵在声明因素宇宙的正关系与 NONE

非空组之间分别归一化；二者相加记作 $S(x,G)$。空组件或空因素部分分别置零。金标锚定用于限制退化一致性，不构成排除全部退化解的数学保证。

### 3.4.3 按源文档归一化及梯度接口

设文档 $d$ 接受 $m_d$ 个变体，同源头监督定义为

$$L_{heads,d}^{sup}=\frac{S(x_d,G_d)+\sum_{j=1}^{m_d}S(x'_{dj},\varphi_j(G_d))}{1+m_d}. \tag{3-11}$$

成对项同样先在该文档的 $m_d$ 个变体上取平均，记作 $\overline{L}_{C,d}^{align}$、$\overline{L}_{R,d}^{align}$。总目标为

$$\begin{aligned}L_d&=L_{ICIC}(x_d,G_d)+\rho\frac{1}{m_d}\sum_{j=1}^{m_d}L_{ICIC}(x'_{dj},\varphi_j(G_d))\\&+\lambda_{sup}L_{heads,d}^{sup}+\lambda_C\overline{L}_{C,d}^{align}+\lambda_R\overline{L}_{R,d}^{align},L=\frac{1}{N}\sum_{d=1}^{N}L_d.\end{aligned} \tag{3-12}$$

约定 $m_d=0$ 时，整项增强损失和两个对齐项为零，原文生成、句子监督及原文头监督仍保留。$\rho$ 控制每篇源文档的增强基础目标总权重：接受一个变体时，该变体的系数为 $\rho$；接受两个变体时，每个变体的系数为 $\rho/2$。因此，无变体文档的基础目标系数合计为 1，有变体文档为 $1+\rho$，不随已接受变体数继续倍增。这里的系数合计仅描述原文与增强文的 $L_{ICIC}$ 加权，不表示实际梯度幅度具有相同比例；头监督仍按 $1+m_d$ 个视图平均，对齐项按已接受文本对平均。

本文保留上述加权方式，使通过筛选的增强视图提供额外监督。外层按源文档等频采样控制访问频次，并不使有、无增强的文档具有相同的基础目标总权重。筛选会同时改变文本、被接受的源分布及哪些源获得额外权重，因此 T-B 估计整套数据构造的共同效应，不能单独归因于新表达。T-E 固定源、变体与权重，只改变损失项。若要区分表达变化与重复曝光，需另以同一接受清单将增强视图替换为对应原文，并保持源权重和更新数；本稿未做该对照，不据现有成绩作这一归因。梯度累积的最后一个不足批次按实际源文档数归一化。正式运行须在训练侧预先登记系数候选范围与选择规则，经开发选择后冻结；本版未绑定的系数见 2.6.2 节，测试集不参与选择。

对齐损失经输入隐藏状态回传共享全局 LoRA，并在相应视图触发时更新连续提示。输入阶段的结论门控为零，因此该损失不直接更新结论专项分支；后者仍由原文及增强文的生成损失训练。辅助目标必须作用于共享生成表示，而不只是训练两个附加分类器，梯度连接与更新范围的核验规则见附录 F.2。

上述训练头预测给定金标跨度条件下的标签，不预测跨度是否正确，其概率也不是完整对象正确率。第四章在实际预测错误上训练的推理评分器与之分开；本章不将两个头直接用作图修正的接受依据。

## 3.5 算法及性质

### 3.5.1 数据构造与参数学习

算法 3-1 将增强构造和参数学习分为两个阶段。前一阶段在固定预算内生成并筛选文本变体，后一阶段按源文档归一化训练。两阶段的数据构造及损失计算均只访问训练划分；开发集的参数选择与停止规则按第二章 2.6 节执行，测试标签不参与上述过程。

**算法 3-1 关系影响域增强与成对学习**

```
输入：训练文档及金标图 D_train，数据协议，固定增强与语义验证模型，
      每文档尝试上限 B_try、接受上限 B_accept，训练更新上限 U。
输出：训练后的端到端生成器 θ，以及增强样本、组件映射和来源记录。
检查训练划分、全文哈希分组、坐标和标签协议
for 每篇源文档 d ∈ D_train do
  保留原文 x_d 和完整金标图 G_d；令 Views_d = ∅
  按 3.3.1 固定中心及完整入源；不可处理则记原因并继续下一文档
  建立因素宇宙 Ω(C_d)，构造改写集合 A
  构造完整影响域 D_A；令 attempts = 0
  while attempts < B_try 且 |Views_d| < B_accept do
    attempts ← attempts + 1；生成组件槽位的替换文本
    回填全文、重新分词，建立全部组件的双射 φ
    if 格式、槽位、坐标或端点检查失败 then
      拒绝整个变体，记录原因及成本
      continue
    end if
    检查全文角色与表达退化
    if D_A ≠ ∅ then
      检查 D_A 中全部关系状态
    end if
```

算法 3-1（续）

```
      if 任一受检标签漂移或其他筛选条件失败 then
        拒绝整个变体，记录原因及成本
        continue
      end if
      将通过的全文视图、φ(G_d)、φ 和来源加入 Views_d
    end while
    保存 Views_d；集合为空时仍保留原文
  end for
  for step = 1, …, U do
    按源文档等频取训练批次；读取原文及其已接受视图
    依可见前缀门控，计算各视图的生成损失和句子辅助损失
    从回答开始前的输入表示计算组件头与关系状态头监督
    依 φ 计算非空域成对损失；无变体或空域的对齐项置零
    保留两个视图的梯度，按同源变体及源文档两级归一化
    按 3.4.3 节的梯度路径执行一次反向传播；基础模型权重冻结
    if 达到 2.6 节预先确定的停止条件 then
      break
    end if
  end for
  返回生成器及来源记录；开发评价和测试时移除训练辅助头
```

每篇文档的参考预算为最多四次尝试、最多接受两个变体，具体训练更新数由公共实验协议确定。参数学习在同一次反向传播中更新可训练参数：全局 LoRA、触发的连续提示及辅助头按各自损失路径更新，结论专项分支由生成损失更新。无增强样本时保留原文监督；梯度累积的最后一个不足批次按实际源文档数归一化。

### 3.5.2 性质与适用条件

**性质一：标注输运保持。** 若可改写槽位互不冲突、$\varphi$ 为组件双射，且类型和每个完整关系因素均按 $\varphi$ 输运，则 $G$ 与 $\varphi(G)$ 的组件数、组件类型及带方向和标签的关联结构保持。证明为：双射保证每个原组件恰对应一个新组件；端点逐一映射保证每条关系及超边既不新增也不丢失，逆映射可恢复原图。该性质针对标注对象成立，不能证明改写后的自然语言仍支持这些标签。

**性质二：单因素预测稳定的充分条件。** 对某一因素，设原视图正确类别为 $y$，分布 $p$ 的间隔为 $\delta = p_y - max_{k \neq y} p_k > 0$。若增强视图分布 $q$ 满足 $\| p - q \|_\infty < \delta / 2$，则 $arg\,max\, q = y$。因为对任意 $k \neq y$，$q_y - q_k > p_y - p_k - \delta \geq 0$。这只是逐因素条件，平均 JS 降低不意味着每个因素均满足该界，也不能使原先错误的预测自动正确。

两项性质解释了标签输运与预测约束的作用范围，不构成新的通用等变学习定理。本章约束的是辅助图因素分布，而非证明自回归生成的完整图分布严格等变。文

本语义漂移、验证器偏差、金标噪声与候选宇宙外关系均可能破坏预期效果；最终判断仍以未参与增强的真实测试文本为依据。

## 3.6 实验结果与分析

本节数值、审计判断和成本为估算情景，用于展示比较与分析；正式结果须由对应原始文本和运行记录整体替换。

本章以监督可靠性诊断为前提，按 2.6.3 预定的 T-B、T-E 分别评价数据构造整体及同数据学习增量；中心策略和过滤消融补充解释其条件。可靠性诊断关注改写后的标签，任务比较关注原始测试文本上的严格抽取结果。CovEReD 同样区分增强一致性与原始任务表现[37]。这种区分使格式合法、坐标正确和语义可靠承担不同证据作用，避免把自动筛选通过直接等同于任务收益。

### 3.6.1 实验设置与比较方法

训练侧统一使用 I0 推理。T0 保留前期 ICIC 的专项适配、线索提示与句子辅助目标；T1 加入关系感知增强、组件与关系头监督，以及成对因素对齐。AAEC 采用严格组件和二元关系评价，CDCP 采用完整原生超边。种子固定为 17、29 和 43，表中“±”表示三次结果的样本标准差，文档级配对区间另行报告。

表 3-2 训练侧对照与归因条件

| 编号与比较 | 固定条件 | 变化因素及解释 |
| --- | --- | --- |
| T-A T0 与普通增强 | 相同基础损失，不增加新头 | 普通增强的整体作用 |
| T-B QOS 式与完整增强 | 相同基础损失、匹配训练规模与更新条件 | 文本、源选择及重加权的整体效应 |
| T-C 去跨边界正关系 | 固定完整生成池和其他检查 | 跨边界正标签筛选的作用 |
| T-D 去 NONE 检查 | 固定生成池和正关系检查 | 无边状态筛选的作用 |
| T-E 基础、加头、加对齐 | 完全相同变体、源权重与更新数 | 辅助监督与成对项各自的增量 |
| T-F 结论与匹配随机中心 | 匹配区域大小、长度和关系度 | 中心策略的条件性差异 |
| T-G T0 与 T1 | 相同骨干和 I0 协议 | 完整训练方案，复用第五章主行 |

构造轨道固定每篇源文档最多 4 次尝试、接受 2 个变体，用于比较生成池、接受覆盖和构造成本。主成绩轨道匹配训练规模：AAEC 与 CDCP 分别使用 500 和 900 个变体、0.82M 和 1.35M 增强 token，并匹配源文档采样规则和有效更新条件。抽取成绩表 3-5、学习消融表 3-6 和中心比较表 3-8 属于后一轨道；表 3-9 只报告前一轨道的构造成本。两轨不拼接为同资源优势。

T-E 的三种设置直接复用同一增强集合及每篇文档的变体数，仅改变损失项。无增强加头对照用于区分头监督本身的作用。QOS 式方法使用共同任务接口和槽位表示，结果只解释这一适配条件。过滤消融使用同一完整关系条件生成池，四项检查依次为内部正关系、跨边界正关系、内部 NONE 和跨边界 NONE；完整配置为 1111，去跨边界正关系为 1011，去 NONE 为 1100。其差值不能单独归于生成提示中的对应条件。

### 3.6.2 增强质量与标签可靠性

语义判定按语料、接受或拒绝、内部或跨边界、正关系或 NONE 交叉分层。每个方法和语料的 8 个层各取 200 个因素，共 1600 个；接受与拒绝样本均保留。判定内容覆盖角色、方向、否定、模态、指代与标签保持，CDCP 同时检查完整源成员。两路判定的分歧单独登记，裁决后再汇总漂移率。

表 3-3 接受样本的标签漂移率（%）（估算情景）

| 语料与方法 | 内部正 | 跨边界正 | 内部 NONE | 跨边界 NONE | 分层均值 |
|---|---|---|---|---|---|
| AAEC 普通增强 | 7.50 | 15.50 | 11.50 | 24.50 | 14.75 |
| AAEC QOS 式 | 5.00 | 14.00 | 7.50 | 9.50 | 9.00 |
| AAEC 完整方案 | 2.00 | 5.00 | 2.50 | 5.00 | 3.62 |
| CDCP 普通增强 | 15.50 | 24.50 | 17.50 | 18.00 | 18.88 |
| CDCP QOS 式 | 8.00 | 13.00 | 8.50 | 16.50 | 11.50 |
| CDCP 完整方案 | 4.00 | 8.00 | 4.00 | 7.00 | 5.75 |

表 3-3 中，完整方案的接受层分层均值为 3.62%和 5.75%，低于普通增强与 QOS 式适配。各层的差异并非在所有方法和语料上同向；例如 CDCP 普通增强的内部 NONE 高于内部正关系，说明因素身份需要分别保留。表中跨边界风险为影响域检查提供情景化解释，真实设计必要性则需由训练侧诊断验证。完整方案还伴随覆盖下降，质量、变化幅度和源分布应联合解释。

表 3-4 接受与拒绝样本的因素漂移审计（估算情景）

| 语料与方法 | 接受漂移数／800 | 接受漂移% | 拒绝漂移数／800 | 拒绝漂移% |
|---|---|---|---|---|
| AAEC 普通增强 | 118 | 14.75 | 372 | 46.50 |
| AAEC QOS 式 | 72 | 9.00 | 309 | 38.62 |
| AAEC 完整方案 | 29 | 3.62 | 241 | 30.12 |
| CDCP 普通增强 | 151 | 18.88 | 378 | 47.25 |
| CDCP QOS 式 | 92 | 11.50 | 316 | 39.50 |
| CDCP 完整方案 | 46 | 5.75 | 264 | 33.00 |

两表以关系因素为单位，四类因素各占相同样本量，百分比是等层权重的均值，不是按整个生成池构成加权的总体漂移率。完整方案的拒绝层中，AAEC 有 559 / 800、CDCP 有 536 / 800 个因素保持标签。单个稳定因素不代表整个变体应被接受：其他因素、组件角色或质量条件仍可能不合格。因此这些数值不能直接解释为变体级误拒率；接受层漂移率也不能直接替代变体级筛选精确率。

完整审计还纳入两种过滤消融，共 5 种方法、2 种语料、每组 1600 个因素，合计 16000 个。两路因素判定的一致率为 96.31%，Cohen κ 为 0.902，描述的是一致性而非相对于独立金标准的准确率。接受层残余漂移与拒绝层稳定因素共同提示质量和覆盖的取舍；坐标、引用检查只提供结构前提，不能替代这一语义审计。

上述低漂移率只描述被接受因素，不能单独证明增强有用。字面变化、变体漂移和分层覆盖的联合阅读方法见 3.6.6 节；其模板示例移至附录 H.6，与本节因素审计及表 3-5、表 3-6 的成绩生成相互独立，不合并分母，也不形成从筛选到学习收益的因果链。

### 3.6.3 抽取结果与学习目标消融

表 3-5 训练方案的严格抽取结果（匹配训练规模）（估算情景）

| 方法 | AAEC 组件 | AAEC 关系 | CDCP 组件 | CDCP 关系 |
|---|---|---|---|---|
| T0 | 78.18±0.44 | 53.25±0.34 | 70.18±0.23 | 48.04±0.38 |
| 无增强 + 头监督 | 78.57±0.36 | 53.64±0.45 | 70.48±0.34 | 48.46±0.28 |
| 普通增强 | 78.77±0.37 | 53.86±0.55 | 70.67±0.21 | 48.67±0.17 |
| QOS 式适配 | 79.37±0.42 | 54.96±0.28 | 71.27±0.24 | 49.76±0.43 |
| 去跨边界正关系 | 79.88±0.46 | 56.27±0.21 | 71.98±0.28 | 50.96±0.50 |
| 去 NONE 检查 | 80.07±0.44 | 56.66±0.20 | 72.27±0.44 | 51.37±0.35 |
| T1 完整训练 | 80.48±0.26 | 57.77±0.32 | 72.77±0.52 | 52.45±0.33 |

T1 相对 T0 的严格关系 F1 分别增加 4.52 和 4.42 个百分点，这一总差值包含数据构造、头监督和成对学习。T-B 中 QOS 式适配与完整增强均采用基础损失：对照表 3-6 首行，AAEC 为 54.96 对 55.66，CDCP 为 49.76 对 50.47，差值为 0.70 和 0.71 个百分点。该差值同时包含文本、接受源分布与源重加权，故解释为数据构造整体效应。过滤消融固定生成池与学习配置，仍可能改变接受覆盖；其情景差值不单独证明某项检查通过表达变化产生收益。

表 3-6 相同增强集合上的学习目标比较（匹配训练规模）（估算情景）

| 方法 | AAEC 组件 | AAEC 关系 | CDCP 组件 | CDCP 关系 |
|---|---|---|---|---|
| 完整增强 + 基础损失 | 79.68±0.31 | 55.66±0.50 | 71.77±0.42 | 50.47±0.33 |
| 完整增强 + 头监督 | 79.98±0.00 | 56.56±0.63 | 72.27±0.64 | 51.24±0.47 |
| T1 完整训练 | 80.48±0.26 | 57.77±0.32 | 72.77±0.52 | 52.45±0.33 |

表 3-6 的三行使用完全相同的增强文本、来源权重和更新条件。增加头监督先建立组件与完整关系因素的输入表示；加入成对对齐后，AAEC 与 CDCP 的关系 F1 分别再增加 1.21 和 1.22 个百分点，情景文档配对 95%区间为[+0.40, +2.01]和[+0.22, +2.22]。完整结果同时包含数据构造、辅助监督和成对目标三部分，不能将总增量全部归给对齐项。区间只反映既定计数模型内的重采样变化，不是实际方法效应的置信区间。

无增强加头仅带来较小改善，进一步说明辅助头的存在不足以解释 T1 的全部变化。成对约束需要依靠可靠的对应因素；若增强本身改变论证角色，预测一致性也可能稳定错误监督。对齐强度应与标签可靠性和原始任务表现共同选择，而不能只最小化一致性损失。

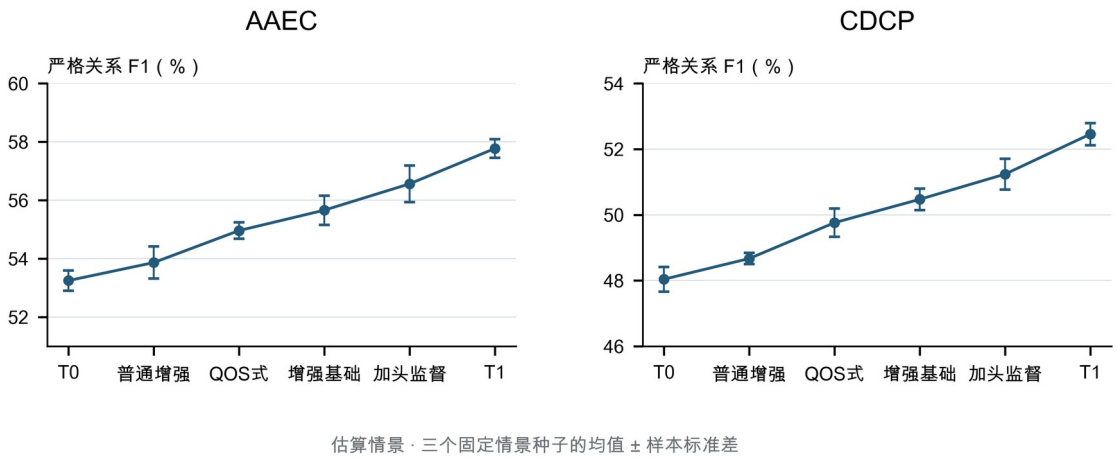



图 3-3 训练方案与学习目标的严格关系结果（估算情景）

### 3.6.4 中心选择与适用条件

随机中心从同一文档的全部合法组件中选择，允许结论角色和参考中心自身进入匹配池。两个中心的区域组件数、入关系数相同，区域字符总长之差除以参考长度不超过 20%。参考区域有效时自身必然满足匹配条件，因此不设置 unmatched；无组件、槽位重叠和资源超限按具体原因分别记录。

表 3-7 中心匹配的有效覆盖与自匹配（估算情景）

| 语料 | 文档数 | 有效参考 | 自匹配 | 异中心 | 构造失败 |
|---|---|---|---|---|---|
| AAEC | 320 | 310 | 112 | 198 | 10 |
| CDCP | 580 | 552 | 226 | 326 | 28 |

自匹配率以有效参考文档数为分母，AAEC 为 36.13%，CDCP 为 40.94%。全部有效文档比较解释中心选择策略的整体差异；异中心子集用于检查策略真正发生变化时的行为。两个集合的样本组成不同，不能把后者外推为全部文档的结论角色优势。回退文档与没有普通入关系的 MajorClaim 也不能单独支持这一优势。

表 3-8 结论中心与匹配随机中心的比较（匹配训练规模）（估算情景）

| 方法 | AAEC 组件 | AAEC 关系 | CDCP 组件 | CDCP 关系 |
|---|---|---|---|---|
| 结论中心 | 80.48±0.26 | 57.77±0.32 | 72.77±0.52 | 52.45±0.33 |
| 匹配随机中心 | 80.38±0.37 | 57.55±0.49 | 72.56±0.22 | 52.16±0.40 |

结论中心相对匹配随机中心的关系差值为 AAEC 0.22、CDCP 0.30 个百分点，情景配对 95%区间分别为[-0.35, +0.81]、[-0.61, +1.23]。区间均含 0；即使在这一设定中，也不能把完整方案增量归因于中心角色。

### 3.6.5 生成覆盖与计算成本

表 3-9 固定尝试预算下的覆盖与构造成本（估算情景）

| 语料与方法 | 接受率% | 源覆盖% | 生成 M token | 审核 M token |
|---|---|---|---|---|
| AAEC 普通增强 | 47.19 | 98.75 | 4.72 | 1.05 |
| AAEC QOS 式 | 42.81 | 93.75 | 4.95 | 1.62 |
| AAEC 完整方案 | 40.62 | 91.25 | 5.10 | 2.24 |
| CDCP 普通增强 | 46.12 | 96.90 | 6.80 | 1.60 |
| CDCP QOS 式 | 42.93 | 92.24 | 7.14 | 2.35 |
| CDCP 完整方案 | 40.52 | 90.00 | 7.42 | 3.61 |

固定尝试轨中，完整方案在 AAEC／CDCP 接受 520／940 个变体、覆盖 292／522 篇文档；匹配轨另取 500／900 个变体。全部尝试计费；两轨记录和旧轨训练成本见附录 H.2，旧成本不用于匹配主成绩。

增强的一次性投入与逐文档修正分开计费；严格筛选须兼顾覆盖与收益。

### 3.6.6 变化 漂移与覆盖的联合解释

增强诊断应同时报告生成池与接受池的字面变化、因素漂移及分层源覆盖。非复制和编辑距离回答文本是否变化，漂移审阅回答标注能否继承，覆盖说明哪些源仍被保留；三者各有分母，均不能单独代替任务收益。附录 H.6 用有限模板演示读表方法，不检验真实语义审核机制。

表 3-5、表 3-6 的人工成绩不是由该模板池训练得到。本稿据 T-B 界定数据构造整体比较，据 T-E 界定固定增强集合上的学习目标比较；正式验证须将接受清单、实际训练输入和评价输出绑定同一运行身份，才能连接数据质量与任务增量。

## 3.7 本章小结

本章针对局部改写后关系标注可能失效的问题，定义覆盖内部、跨边界及 NONE 状态的影响域，以标注迁移建立原文与增强文的可靠对应，并在对应因素上加入监督与成对目标。关键设计在于受影响监督的识别及其与学习的连接，结论中心只是默认选择。

受控比较分别回答数据构造整体及固定数据上的学习目标作用。现有人工成绩用于展示这些问题的比较方式；模板指标另作诊断示例，不承担学习效果解释。真实语义风险、源选择偏移和训练增量仍需同源记录验证，现阶段不由低漂移或字面变化推定方法有效。

# 第四章 多候选驱动的依赖闭合论辩图修正

## 4.1 引言

端到端论辩挖掘的预测错误不仅表现为关系标签错误，也包括组件遗漏、多检、边界偏移以及组件划分粒度不当。组件是关系的端点，修正一个组件可能同时改变多条关系的身份与合法性。因此，组件修正不能只比较节点自身的得分，关系修正也不能始终假设上游组件正确。本章在前期多候选重排序与有界修正方法 MCR-BR 的基础上，研究有限候选空间内的组件—关系协同修正。

集合修正的必要性取决于端点相关错误相对于纯关系错误的规模，以及候选中是否已有可恢复对象。组件类型、边界、遗漏与多检采用固定顺序诊断，候选缺失另作交叉维度；这些维度不能相加为互斥因果比例。附录 D.3 已补充既存 CPU 诊断的初始错误、端点条件及一步动作限制；该弱模型的过度分割不能代表目标 LLM。4.6.7 进一步给出生成候选中的组件补入、完整关系恢复及失败轨迹，并在固定候选和初始图上检验评分输入的调整。简化候选及未校准评分仍限制方法归因，正式目标模型诊断按 H.1 执行。

本章以 MCR-BR-J 表示依赖闭合的联合修正，保留候选图生成与初始重排序，将修改单位扩展为冲突闭合的组件集合及全部受影响关系。框架规定对象身份、目标、约束和接受条件；局部整数规划是本稿待检验的求解策略，同目标全局求解是主要对照。下文先说明动作与共同决策，再比较组件可变性、集合表达、误改及完整成本；不由“局部”或“有界”的名称预设采用价值。

作者前期 ICIC 工作提出了多候选重排序与有界修正框架，在不同组件假设上构建完整论辩图，并结合连接覆盖、语义连贯性和形式合法性选择候选。原版修正不仅处理关系，还包含组件类型转换与跨度替换，因而不能将“允许组件修改”本身作为本章新增贡献。为区分版本，以下将原版记为 BR-O，将固定组件的保守关系修正版记为 BR-C。[34]

BR-C 固定初始组件、覆盖评价节点及其阈值，只删除关系或重新预测限定源节点的出边。这一约束避免了组件被错误修改，同时明确了其能力上限：若正确跨度从未进入初始图，则仅调整关系不能恢复该组件。BR-O 的修改范围更宽，但按节点或有限出边组织动作时，不能完整表达“一组旧组件被一组新组件替换，同时重新判断全部相关关系”的决策。特别是在拆分、合并和类型改变中，沿用旧端点编号并不意味着原关系对象仍然有效。

已有联合结构预测使用因子或整数规划表达组件和关系之间的约束，组件与关系联合建模本身已有明确研究基础。[46]近期 Re-Cent 也结合跨度抽取与关系纠正，说明“抽取后再纠正”不是新的通用范式。[43]另有框架讨论组件合并、改写与关系重建；本章则保持原文不变，以可定位跨度为对象，不生成隐含前提。[44]本章的具体研究对象是：在 MCR 已保留的竞争假设以及有限补充候选中，如何以可变组件集合为修改单位，闭合处理其入边、出边及原无边状态，并依据同一评分体系比较完整修改结果。

据此，本章将问题定义为有预算的结构选择，并把同候选、同评分的全局 ILP 作为主要竞争方案。局部事务能明确一次变更及其依赖，但全局求解也可能提供更好的结构与保留率。研究重点是在共同准备成本、求解预算和变更要求下比较二者，而非将局部性、日志或有限终止直接视为优势。若真实比较不能形成有价值的质量、时延或变更控制取舍，则应简化局部机制或将其保留为可选修正策略。

图书馆论辩片段提供了一个人为构造的边界修正示意：假设初始组件$c_2$只包含“图书馆现有座位不足”，另一个候选还包含“而且开放时间偏短”。选择较长跨度会改变组件对象，原来连接短跨度的关系不能仅因显示编号相同就继续保留。算法须先构造“新组件及其关系”的完整候选状态，再判断整个修改是否值得提交。原文始终不变，修改的是对原文的结构解释；该片段不对应真实测试样本或运行结果。




图 4-1 组件替换及受影响关系的事务式处理示意（人为构造）

图 4-1 展示推理阶段的事务单位和接受顺序，不预设较长跨度一定正确。旧对象删除后，其入边和出边均失效；新对象的合法关系组合重新参与选择，包括此前没有输出关系的位置。图中对象与关系变化表示数据流，接受或回退表示控制流。只有完整方案满足整图约束、预算及效用门，才一起提交；否则保留修改前的完整状态。

## 4.2 候选生成与初始图

候选生成既为初始图选择提供竞争结构，也限定后续修正能够访问的对象。初始选择沿用前期 MCR 接口；修正开始前，来自多次生成和补充提议的对象被汇总为固定候选宇宙。两个步骤共享候选来源，但承担不同的决策任务。

### 4.2.1 组件假设及完整图生成

给定文档 $x$，生成器通过预先固定的采样和提示配置产生 $K$ 组组件假设：

$$\mathscr{C}=\{C^{(1)},\ldots,C^{(K)}\}. \tag{4-1}$$

每个组件包含原文跨度与类型。随后，关系生成器在固定的 $C^{(k)}$ 上预测关系，形成 $G^{(k)}=(C^{(k)},R^{(k)})$。关系阶段不得悄悄重写组件；无法解析的输出记为失败，失败调用仍计入总成本。同一候选的原始输出、解析结果及坐标转换均保留，避免将后处理改变误认为生成模型的预测。

这一流程比较的是完整结构，而非先依据组件置信度选定一组组件，再只对该组预测关系。不同候选之间的边界、类型和连接差异，既为初始选择提供信息，也为后续集合替换保留竞争假设。全部候选来自预测，不使用评价集金标准补充遗漏对象。

### 4.2.2 原始覆盖评分的保留与边界

为保持与前期方法的可比性，初始选择沿用原 MCR 的加权形式：

$$E_{rank}(G)=0.4\,E_{dens}(G)+0.4\,E_{coh}(G)+0.2\,E_{val}(G). \tag{4-2}$$

设 $\mathcal{Q}(G)$ 为预测图中的覆盖评价节点，$p_r\in\{0,1\}$ 为关系语义验证结果，$d_{coh}^{\mathrm{in}}(j)$ 为指向节点 $j$ 且通过验证的关系数，则

$$E_{dens}(G)=\frac{1}{|\mathcal{Q}(G)|}\sum_{j\in\mathcal{Q}(G)}\min\left\{\frac{d_{coh}^{\mathrm{in}}(j)}{\tau_j},1\right\},E_{coh}(G)=\frac{1}{|R|}\sum_{r\in R}p_r. \tag{4-3}$$

空覆盖集合或空关系集合的对应分量取零。AAEC 的覆盖节点为预测 Claim，CDCP 为预测 Policy/Value；MajorClaim 不因缺少普通关系而被强制补边。本文的确定性参考配置按节点是否存在出边设置结构角色阈值：无出边取 $\tau_j=2$，否则取 $\tau_j=1$。CDCP 原生超边按完整关系计一次入边，不按源成员数重复增加覆盖。上述规则是本文明确的设计配置，前期实验的实际执行细节仍以其独立运行记录为准。

$E_{val}$ 在可解析性、跨度、类型及引用等全部协议检查通过时取 1，否则取 0；无环等结构条件仅在相应数据协议要求时启用。同分时按候选生成槽位选择。加权得分不等价于合法性硬约束，因此选出的候选还需通过所有对照共用的确定性合法化步骤，得到 $G_0$。该步骤仅执行无歧义的坐标规范化、相同语义对象去重及 ID 重排，并同步更新引用；歧义 ID、越界、非法类型或剩余结构冲突直接报失败，不额外猜测跨度、删除冲突组件或补边。规则、变更和成本单独记录；不能得到合法状态时不进入学习型修正。

覆盖与连贯性共用 $p_r$，不是相互独立的证据。覆盖集合与当前边数还会改变均分的分母，删除低分对象或改变组件类型可能提高平均分，却未必提高真实准确率。本章因此保留上述评分用于初始候选选择，但不将它直接延用为可变组件修正的接受目标。

### 4.2.3 固定跨度候选与组件冲突

修正开始前构建固定跨度集合$U$。受保护部分包含合法化后初始图及全部成功解析候选图中的合法组件跨度；对象先去重，不以概率阈值裁掉初始图。独立跨度头和有限规则扩展提供补充部分。两部分分开计数，保护对象多于补充上限时不裁初始图；若总资源无法容纳保护部分，返回候选构造失败，而不是无声改变基线。

独立跨度头以训练金标监督起止边界，为候选召回提供补充，并在 OOF 中遵守与生成器相同的持出隔离。参考解码与一次性有限扩展覆盖邻近边界、相邻跨度合并和内部切分；扩展不递归，去重后才按边界分保留补充候选。坐标转换、排序和异常细则见附录 A.6，边界分仅用于召回排序。

受保护跨度不受补充长度和数量上限裁剪。候选的保护来源、补充来源及重叠数量分别登记；新增跨度不能通过改变去重或坐标规则隐式扩张候选空间。

对$u \in U$保留协议合法的全部类型，构成$\mathcal{V} = \{(u,t) : t \in \mathcal{T}(u)\}$。NULL 表示不选择，同一跨度至多一个类型。组件兼容按语料协议逐对判定；语义身份取决于规范跨度和类型，显示 ID 不进入评分。完整键与坐标映射见附录 A.6。

### 4.2.4 完整关系候选与无边状态

关系候选池$P$以完整端点槽位为单位构建。AAEC 枚举可共存组件的有向对；CDCP 枚举可共存、最多三个源成员的有序源集合与目标。除端点互斥等必然冲突外，不按整个候选宇宙中间是否存在其他跨度预删源组合，因为中间跨度可能最终不被选中。初始图与成功解析候选图的合法完整关系槽位受保护，已有长超边完整保留；补充槽位的元数上限仅约束新增组合。

一个槽位包含协议允许的全部关系标签，原生超边的完整源集合只算一个端点组合。槽位优先分为固定对象评分的标签最大值；按该分数降序及规范化槽位键升序保留前$N_{slot}$个补充槽位，全部标签一起保留，NONE 由不选正关系表示。用于排序的对象分在裁剪前按固定评分器求出，评分成本计入总成本；超出评分资源的预检上限则返回明确失败，不靠测试金标截断候选。

关系池枚举当前没有边的有向槽位，但独立裁剪不保证正逆两个方向共同保留。仅对二元关系，当正向与逆向完整槽位均在冻结池中、当前端点存在且两方向合法时，才枚举反向事务，并将两槽位全部合法标签共同纳入。缺少逆向槽位记为候选范围限制，不在搜索时补回池外关系；已有关系的纯删除仍可单独枚举。多源超边未定义多目标反向操作，不进入反向队列。初始保护、来源数量、去重、裁剪、未入队与评估后拒绝分开记录；候选池及分数在一次搜索前冻结。

不同语料的原生约束分别登记。ArgUNSC 与 CasiMedicos-Arg 只允许单源二元关系；CDCP 保留原生完整源集合及连续性要求。多个前提分别支持同一目标时，二元语料使用多条关系，不将其合并为超边；也不把 CDCP 的联合源范围拆成独立二元边。关系标签或组件类型同名不意味着标注准则相同，评分提示与严格评价均使用对应语料的定义（A.3 及 D.11）。

### 4.2.5 裁剪前规模与资源预检

保留 4096 个补充槽位，只约束最终进入搜索的数量。设候选宇宙含$m$个可区分跨度、每跨度至多$q$类，在忽略冲突和标签掩码的宽松计数下，AAEC 有至多$m(m-1)q^2$个带类型端点槽位；CDCP 新增源成员数不超过 3 时，枚举规模可达$\sum_{k=1}^{3} C(m,k)(m-k)q^{k+1}$。其中$C(m,k)$为组合数。实际合法性会减少数量，受保护长超边则另行加入。该计数说明候选补充的组合增长发生在裁剪之前，并不等于实测内存或运行时间。

资源限制须作用于裁剪前枚举和完整评分，阈值只由训练侧资源探测确定。超限作为构造失败保留，已耗时间及金标仍进入成本和评价；保护部分超限时不能靠删除初始正确对象满足限制。当前材料尚不能量化预检拒绝比例及恢复空间损失，计量字段见附录 H.3。

当前保持既定候选策略，以实际规模测量决定是否需要改变它。若裁剪前枚举不可承受，再比较预筛选或受限生成，并重新测量覆盖及完整关系遗漏；所有局部 / 全局对照都使用改变后同一候选快照。资源字段及失败分母见附录 H.3。

## 4.3 组件集合替换与受影响关系重建

组件修改与关系重建组成一次不可拆分的结构事务。算法先扩展删除集合以消除跨度冲突，再确定所有受端点变化影响的关系，最后对完整修改状态作出接受决定。纯关系修改也使用同一事务接口，因此可以在固定组件的条件下单独比较关系恢复能力。

### 4.3.1 冲突闭合的集合替换

令当前组件集合为 $C$，一次提议指定新增集合 $B$ 与主动删除集合 $D_0$。本章的$D_0$和$D$均为待删除组件的集合，输入文档始终记为$x$。首先将 $B \cap C$ 中语义未变的对象视为保留项，从 $B$ 及 $D_0$ 中同时移除，再补齐所有与新增对象冲突的旧组件：

$$D = D_0 \cup \{c \in C : \exists b \in B, Conflict(c,b)\}, C' = (C \setminus D) \cup B. \tag{4-4}$$

$B$ 内部必须兼容。即使某个冲突组件位于提议窗口之外，也必须进入 $D$；否则，新状态仍可能含有非法重叠。扩大删除集合超过预算时，提议被拒绝，不能通过忽略窗口外冲突获得虚假的局部可行性。

主邻域包含 $0\to1$、$1\to0$、$1\to1$、$1\to2$ 和 $2\to1$，对应遗漏补回、多检删除、类型或边界替换、拆分和合并。初始设计限制每事务 $|D|+|B|\le3$，在冲突闭合后检查，而非只按最初指定的集合计数。更大邻域作为预算敏感性设置单独评价。

### 4.3.2 全部受影响关系与纯关系事务

“依赖闭合”在本章以端点身份为边界：组件对象被删除或替换后，将所有引用它的关系以及新对象可能参与的关系一起纳入决策，避免只评估组件本身而遗漏关系损失。下文的“全部受影响关系”均指固定候选宇宙内的这一端点依赖域，不表示组件选择变化后所有新合法槽位都会自动进入事务。训练阶段的 NONE 来自既有标注，需要在改写后保持；本章的 NONE 是当前预测未选择正关系的状态，可能包含漏检，因此允许被改为一条经评分和约束接受的关系。

令变化对象集合 $A=D\cup B$ 包含删除的旧组件与加入的新组件，不同于第三章允许改写文字的组件集合。$P_A$ 包含候选池 $P$ 中接触变化对象集合 $A$ 任一对象的全部关系，同时覆盖入边、出边、原有正关系和原 NONE 槽位。删除旧组件后，所有引用旧语义键的关系必须删除；加入新组件后，其合法入出关系重新参与选择，不能按旧显示编号继承。

对于组件保持不变但关系存在错误的情形，保留纯关系提议 $S_R$，定义事务关系空间

$$P_{tx}=P_A\cup S_R. \tag{4-5}$$

RelationOnly 事务取 $D=B=\varnothing$，通过 $S_R$ 表达增边、删边、换标签或反向。一个槽位进入 $S_R$ 时，其全部合法标签候选一同进入；二元反向修改遵循 4.2.4 节的双槽位条件；任一方向缺失或当前非法时不进入反向队列，不能仅重选已有方向后称为反向。

对每个 $C'$，算法先求受影响关系的合格可行补全（取得最优性证书时才称为最优），再比较完整的 $G'=(C',R')$，而非先依据组件分数提交 $C'$。事务外关系保持固定，但全局约束在整图上检查。本版固定采用最小合法化扩域：将组件变化后失效的已选事务外关系所在完整槽位加入$S_R$，其全部合法标签参与重求解，旧边删除与新边加入全部计费；仍不可行或超预算时拒绝。该分支只处理已选旧关系的合法性，不自

动加入所有新合法而未选的非接触槽位。依赖闭合保证没有漏记端点变化造成的关系失效，并不意味着自然语言的语义影响只发生在一跳范围内。

CDCP 的源连续性还依赖哪些中间组件被选中，因此需要区分“旧关系失效”和“未选槽位变得合法”。例如，当前组件按位置排列为$a,b,c,t$，固定候选池已包含$h=(\{a,c\},t,Reason)$。由于$b$位于两个源成员之间，$h$当前非法且未被选中。若删除$b$的事务获准提交，$h$便满足源连续性，但其端点$a,c,t$均未变化，故$h$不属于该事务的$P_A$；若该事务的$S_R$也未包含它，$h$仍保持未选状态。为保留整图合法性而扩域，并不自动触发对这类新合法槽位的枚举。

在上述新状态中，若保持$h$的端点不变，后续提议仍需将$h$所在槽位纳入$S_R$，实际进入并执行于队列，且通过合法性、效用门与剩余预算检查，才可能恢复$h$。若删除$b$未被接受、候选池不含$h$、槽位被队列截断，或后续预算耗尽，则不能由这个例子推断恢复发生。本文保留端点依赖闭合，不为所有非接触的新合法槽位自动扩大事务域；这属于有限邻域与搜索预算的限制，不影响已接受状态的合法性、固定评分差分或有限终止性质。

沿用图 4-1，记短跨度旧对象为$c_2^{old}$，完整跨度候选为$c_2^{new}$。即使二者都显示为“组件 2”且都标为 Premise，它们的语义键仍不同。所有以$c_2^{old}$为端点的旧关系先从候选修改状态中全部移除；涉及$c_2^{new}$与$c_1$、$c_3$、$c_4$及其他合法端点的组合重新参与选择，不能按第三章示意图预置答案。若组件效用增加，但重建后的关系效用下降，则依照 4.4.4 的分项门拒绝整个方案。若两个分项均不下降、总增益达到严格门限且满足约束与预算，则整体接受。这个例子说明联合评价如何处理关系代价，不声称自动评分等于真实正确性。

## 4.4 对象评分与事务接受

联合事务需要可跨搜索状态比较的评分。为避免组件数、关系数或图结构变化引起评价口径漂移，本章在搜索前冻结完整对象的得分，并用固定计数效用比较新增与删除对象。分项接受门进一步约束组件和关系两个方向的代理代价交换。

### 4.4.1 固定文本证据评分器

评分器分别估计组件与关系完整对象精确正确的概率：

$$q_C(c\mid x),q_R(r\mid x). \tag{4-6}$$

组件头根据跨度及全文表示预测 NULL/类型分布。关系头接收端点跨度表示、待核查端点类型、方向、关系标签及全文证据，以二元监督判断整个关系对象是否正

确。其正例要求端点跨度、端点类型和关系标签同时满足精确匹配；仅在金标准端点上训练的关系分类准确率，不能替代这里的对象正确性概率。

评分器采用固定文本编码、跨度 MLP 与有向端点组合 MLP，参数不与生成器共享。它与第三章训练辅助头的区别在于监督对象：推理评分器学习真实候选中完整对象的正确性，训练辅助头学习原文与增强文的配对因素。参数分离的解释边界见 2.4 节。

同一文档的文本表示、模型版本、校准参数及候选得分在搜索开始前冻结。缓存同时绑定完整语义键，不以显示编号代替端点身份。不将当前图的度数、已选边数或动态重编码加入 $q$，从而使同一个对象在不同搜索状态中具有相同分值。评分接口还须区分低置信度与未取得评分。对缺失、非有限或显式未评估的值，保留缺失状态；只有拟删除或加入的组件，以及经最小合法化扩域后的事务关系空间均有有效分数，才评估该提议。事务外未变对象在差分中相消，不以任意默认值参与变化对象的接受判断。该约束补充输入完整性检查，不改变固定效用、依赖闭合及接受门；启发式模型给出数值也不等于其正确性已被校准。D.12 以既定候选开展有限对照。

### 4.4.2 训练外候选与概率校准

评分器需要接触实际推理产生的错误，而不是只区分人工构造的容易负例。训练部分按源文档分组进行 out-of-fold（OOF）候选生成。对每一持出折，生成器和跨度头均不得训练于该折文档及其增强变体，再对持出文档产生完整候选、边界扰动和关系组合。候选与训练金标准进行精确匹配后，形成评分器监督数据。用于比较两种训练方法时，OOF 池共同包含两类生成器的候选并保留来源，避免评分器只适应某一生成器。

错误跨度和错误端点类型构成完整对象负例，原 NONE 槽位中的关系候选也必须进入训练池，但其正负标签由训练金标准决定，不能因生成器未输出该边便将其标负。若过采样困难负例或正例，应保存采样概率；用于校准的数据保持自然候选分布，不能以人工平衡比例替代部署先验。开发集按源文档分为校准部分与策略选择部分，分别用于概率校准及代价、阈值和预算选择。最终生成器拟合训练侧源文档，评分模型则遵守 2.6.1 的拟合、校准和策略用途，不将校准或策略标签合并回评分器拟合池。

初始配置采用训练内三折 OOF，折划分与开发集用途按 2.6 节记录。OOF 生成器的训练规模小于最终生成器，候选分布可能发生变化。概率变换仅拟合 OOF 校准记录，不使用已被最终生成器拟合过的文档来冒充独立校准样本。冻结后在独立评价集

检查评分偏差，不据其标签重新调参。候选校准不直接保证搜索后动作可靠，4.6.4 和 4.6.5 节进一步分析评分及误改。

### 4.4.3 固定计数效用

对对象类别 $X\in\{C,R\}$，设固定系数 $0<\kappa_X<2$，定义

$$\Phi_X(G)=2\sum_{o\in X(G)}q_X(o\mid x)-\kappa_X|X(G)|,\Phi(G)=w_C\Phi_C(G)+w_R\Phi_R(G), \tag{4-7}$$

其中 $w_C,w_R>0$。主配置以 $w_C=w_R=1$ 为起点，$\kappa_X$ 在开发阶段预先声明的范围内确定并冻结。基线 F1 可以用于初始化候选值，但不构成最优性依据。若为平衡两类对象数量而缩放，只使用固定训练集尺度，不除以当前图的组件数或关系数。

该效用具有明确的代价解释。令 $Y_X$ 为真实对象集合，且暂假设 $q_X(o\mid x)=P(o\in Y_X\mid x)$。由 $FP_X=|X(G)|-TP_X$、$FN_X=|Y_X|-TP_X$，得到

$$\Phi_X(G)=(2-\kappa_X)\mathbb{E}[|Y_X|\mid x]-\mathbb{E}[\kappa_X FP_X+(2-\kappa_X)FN_X\mid x]. \tag{4-8}$$

第一项不随预测图变化，故最大化该效用等价于最小化固定误检与漏检代价的条件期望风险。该推导依赖期望的线性性，不要求对象正确性相互独立。候选池外真实对象造成的漏检同样属于不可改变的部分；池内错误与池外遗漏必须分别分析。

此处采用的是代价敏感代理，不是期望 F1。一般 F1 决策涉及真实标签数量与对象正确事件之间的依赖，仅有普通边际概率通常不足以计算最优决策。[41]特定条件下的 F1 最优阈值结论，也不能通过代入任意基线 F1 直接用于本章结构搜索。[42]上述风险恒等式为评分提供解释，不作为独立的基础理论创新。

### 4.4.4 分项接受门与编辑成本

候选事务必须满足完整图合法、剩余预算允许以及

$$\Delta\Phi_C\geq 0,\Delta\Phi_R\geq 0,\Delta\Phi>\delta>0. \tag{4-9}$$

两个分项门限制以明显降低某类代理效用为代价换取另一类增益，总效用门排除等分修改。它们是保守代理条件，可能拒绝真实有益的结构替换，也不保证真实组件或关系 F1 不下降。数值容差与正间隔 $\delta$ 在评价前固定，不通过测试结果调整。

组件编辑成本为 $d_C=|D|+|B|$，关系成本为 $d_R=|R\triangle R'|$。类型或边界变化引起的旧关系删除与新关系加入分别计费。成本仅用于硬预算和同效用时少改优先，不加入效用作为“接近初始图”的奖励。累计编辑量与最终图相对 $G_0$ 的净变化分别记录，避免反复修改同一对象却只报告最后一次差异。

### 4.4.5 联合修正的教学算例

以下用人工设定的二元图与分数说明一次完整决策，不对应 AAEC 或 CDCP 的观测样本，也不用于评价方法效果。设当前预测图含三个组件：$c_1$为 Claim，$c_2^o$和$c_3$为 Premise。当前图选中两条 Support 关系，分别为$r_1^o=(c_2^o,c_1,Support)$和$r_2^o=(c_3,c_2^o,Support)$。候选池另含$c_2^a$与$c_2^b$，二者均为$c_2^o$的不同边界版本，与$c_2^o$相冲突，但不与$c_1,c_3$重叠。三个版本两两不能同时选中；当前图没有其他关系接触$c_2^o$。

（1）固定评分与预算。设$\kappa_C=0.4$、$\kappa_R=0.2$、$w_C=w_R=1$、$\delta=0.02$，剩余组件和关系编辑预算分别至少为 2 和 4。三个边界版本的组件分数为$q_C(c_2^o)=0.20$、$q_C(c_2^a)=0.45$、$q_C(c_2^b)=0.35$；旧关系分数为$q_R(r_1^o)=0.18$、$q_R(r_2^o)=0.16$。因此，旧组件的效用贡献为$2\times0.20-0.4=0$，两条旧关系的合计贡献为$(2\times0.18-0.2)+(2\times0.16-0.2)=0.28$。未变化的组件和关系在求差时相消。

（2）构造替换与闭合域。先考虑$D=\{c_2^o\}$、$B=\{c_2^a\}$，则$C'=\{c_1,c_2^a,c_3\}$，$d_C=2\le3$。删除$c_2^o$后，$r_1^o$和$r_2^o$均失效，即使新的显示编号仍为“组件 2”，也不能继承任何一条旧边。闭合域纳入这两条旧关系，以及新端点参与的全部候选槽位和合法标签，包括原来为 NONE 的组合；事务外对象保持不变。

（3）补全并接受候选 a。设$r_1^a=(c_2^a,c_1,Support)$和$r_2^a=(c_3,c_2^a,Support)$的固定分数分别为 0.40 和 0.35，其余新端点候选的分数均小于 0.10。后者效用为负，取 NONE 优于加入这些关系。在本例无环且每个源至多一条出边的约束下，选择$r_1^a,r_2^a$合法，其关系贡献为$(2\times0.40-0.2)+(2\times0.35-0.2)=1.10$。由此得到$\Delta\Phi_C=0.50$、$\Delta\Phi_R=1.10-0.28=0.82$，总增益为 1.32，大于 0.02。删除两条旧边并加入两条新边使$d_R=4$。全部门限与预算通过后，才原子提交新组件及两条新关系。

（4）从同一旧图检查候选 b。令$D=\{c_2^o\}$、$B=\{c_2^b\}$，组件效用增加 0.30。对应的两条 Support 候选分数改为 0.11 和 0.05，其余新端点候选仍小于 0.10。暂不施加关系非下降门时，最高分补全只保留分数 0.11 的那条边，另一槽位取 NONE，关系贡献仅为$2\times0.11-0.2=0.02$。即使采用这一补全上界，仍有$\Delta\Phi_R=0.02-0.28=-0.26$。该状态的$d_C=2$、$d_R=3$，总增益 0.04 也超过 0.02，但关系分项下降。故实际包含分项门的 ILP 没有合格补全，整个提议被拒绝；当前图仍保留旧组件和两条旧边，不留下半完成状态。这里的无门限计算只用于解释不可接受的原因，不是算法先提交再回滚的执行顺序。

两次比较使用同一旧图、候选池、评分和预算，候选 b 不是在接受 a 之后继续评分。该算例展示了组件获益、失效关系及新关系重建如何共同决定提交；4.5.4 节的集合可达性反例则回答另一个问题，即成组替换何时能够越过单对象动作的限制。

## 4.5 求解算法及性质

局部求解固定一个组件提议，对其受影响关系寻找满足约束的补全，再由事务层比较所有已找到的合格方案。以下先给出整数规划与执行过程，再说明固定评分带来的精确差值、集合事务的可达性及有限终止条件。

### 4.5.1 局部整数规划关系补全

主求解器采用“有界组件提议 + 局部 ILP 关系补全”。对一个已经通过冲突检查的 $C'$，令 $z_c=\mathbb{I}[c\in C']$ 为固定组件状态，$y_r\in\{0,1\}$ 表示关系候选 $r\in P$ 是否被选取。目标为

$$\max_{y}\ w_C\Phi_C(C')+w_R\sum_{r\in P}(2q_R(r\mid x)-\kappa_R)\,y_r. \tag{4-10}$$

组件项在单次求解中为常数，但在比较不同提议时不可省略。求解包含以下约束：

$$\begin{gathered}\sum_{t\in\mathcal{T}(u)}z_{(u,t)}\le 1,\ z_c+z_d\le 1\ \text{若}\ \ \mathit{Conflict}(c,d);\\ y_r\le z_c\ \forall\, c\in \mathit{Ends}(r),\ \sum_{r\in\Gamma_s}y_r\le 1\ \forall\, s;\\ y_r=\mathbb{I}[r\in R]\ \forall\, r\notin P_{tx},G'\in\mathcal{G}_{\mathcal{A}}.\end{gathered} \tag{4-11}$$

$\Gamma_s$ 表示同一关系槽位的互斥标签候选，全为零对应 NONE；$\mathcal{G}_{\mathcal{A}}$ 表示所采用协议的整图合法集合。前两项组件约束也作为提议合法性的显式检查。自环、非法类型组合及越界跨度在候选构建时排除，关系约束保证被选关系的全部端点存在，且不能绕过固定外部结构。若协议要求无环，引入 $0\le o_c\le M-1$、$M=|\mathcal{V}|$，对全部候选二元边加入

$$o_v\ge o_u+1-M\,(1-y_{(u,v,\ell)}). \tag{4-12}$$

该式同时覆盖固定外部边；超边在协议要求时对各源成员到目标的方向分别加入相同约束。不要求无环时不额外施加该限制。对于 CDCP 的源范围规则，在固定的 $C'$ 上计算候选超边是否合法，不合法者强制 $y_h=0$，包括因此失效的事务外超边；若这与外部固定约束冲突，当前事务不可行，必须扩大事务或拒绝。

分项效用门与编辑预算同样纳入 ILP。设 $y_r^0=\mathbb{I}[r\in R]$，关系编辑成本可线性写为

$$d_R=\sum_{r:\,y_r^0=1}(1-y_r)+\sum_{r:\,y_r^0=0}y_r. \tag{4-13}$$

将 $d_C,d_R$ 限制在各自剩余预算内，并约束 $\Delta\Phi_C,\Delta\Phi_R\ge 0$。严格总效用门在数值实现中采用固定正间隔及比较容差，提交前再次验证 $\Delta\Phi>\delta$。这些条件必须参与求

解，不能先求无约束最高分结果、发现它违规后便断言不存在可接受结果。完整求解的破同分顺序为最大主效用、最少实际编辑、最小完整状态规范键，使用依次固定前级目标的求解方式，不以任意小权重扰动主目标。比较容差写入配置。超时 incumbent 重新核对全部约束，并记录前级最优与破同分是否完成；未经证明不称唯一最优。实际求解器的数值和线程确定性仍须验收。

### 4.5.2 有界执行、原子提交与回退

提议分为纯关系、插入、删除、替换、拆分和合并六类。纯关系枚举当前端点存在且合法的全部槽位，包含未选槽位；二元反向仅在冻结正逆槽位都存在且当前合法时共同进入$S_R$；未定义多源反向。插入枚举池中未选组件，删除枚举已选组件，替换枚举一个旧组件与一个新组件，允许类型与边界变化。拆分枚举一个旧组件与两个兼容新组件，两个新跨度均在旧跨度内且首尾包络等于旧跨度；合并为其逆操作。每项先完成冲突闭合，将与新增组件冲突的所有旧组件纳入删除集合，包括名义窗口之外的对象，再按实际$(|D|,|B|)$重新核对形态、跨度条件及三对象上限。不符合五种声明形态的提议不进入主邻域；名义插入若变成$2 \to 1$，单对象对照须拒绝。端点变化产生的旧入边、出边及完整超边全部删除，新增完整关系逐项重新计费。带坐标的正反例见附录 D.6。

共同调度单位为外层提议：评估一个组件或纯关系提议记一次尝试；该提议至少有一个阶段成功提交记一次接受。每轮最多尝试 32 项、接受 3 项，最多 4 轮；全程最多 128 项尝试、12 项接受，组件累计编辑 24、关系累计编辑 96。BR-J 一次接受对应一次原子提交；顺序方法最多对应两次阶段提交，阶段尝试、求解调用与提交另记，不能把外层额度称为相同计算量。顺序方法第一阶段已提交时，即使刚达外层接受上限，仍可在剩余实际资源内完成配套关系阶段。批长独立于上述额度。

每批从六类提议中轮转取项，在冻结对象分和剩余预算下评估，择优复核后原子提交。新评估消耗尝试额度，提交已有合格项只检查接受、编辑及实际资源；达到尝试上限不撤销已评估的合格项。首批全拒不立即停止，同一状态不因换轮重复评估；无法安全提交时返回最近完整合法图。排序、状态键、缓存游标和分项计费统一列于附录 B.3，预算边界见附录 B.4.3。

**算法 4-1 多候选驱动的依赖闭合修正**

输入：原文、生成候选、冻结配置和有限资源清单。
输出：最后完整合法图或明确初始化失败，以及轨迹。
初始化预算；执行 MCR 选择及共用合法化，计入全部成本
**if** 初始化失败 **then**
  **return** 明确失败状态
**end if**
冻结候选、对象分与效用系数；G ← G0
**for** 每一轮，在轮数及全程预算内 **do**
  重置本轮计数；首次进入状态才建队列，否则续用游标与缓存
  **while** 本轮与全程尚有尝试及接受名额，且评估资源允许 **do**
    按剩余尝试名额取至多批长个提议 Q；Gnoop ← G；H ← ∅
    **for** Q 中每个未评估提议，在评估资源内 **do**
      外层尝试加 1；调用算法 4-2，登记求解、失败及实际开销
      将通过复核的完整状态加入 H
    **end for**
    **if** H 非空 **then**
      按总效用、较少编辑、语义键择优
      复核接受名额、编辑及提交资源；不再要求剩余尝试名额
      提交条件不足则保留 Gnoop，记录原因并停止
      原子提交；失败则完整恢复 Gnoop 并停止
      更新实际编辑；外层接受加 1；未见状态建队列，已见则续用
    **else**
      保留 Gnoop；已遍历声明队列则停止，否则继续下一批
    **end if**
  **end while**
**end for**
**return** G 及实际停止原因；中断只返回最后完整合法状态

**算法 4-2 单提议的闭合评估**

输入：当前合法图 G、提议、冻结候选分和剩余预算。
输出：经复核的完整候选状态，或拒绝状态。
复制 G；抵消相同对象；完成冲突闭合
**if** 内部冲突、动作形态或组件成本不合规 **then**
  **return** 拒绝，原图不变
**end if**
构造端点依赖域；最小扩域处理失效的已选外部槽位
固定域外关系，将整图约束、效用门及剩余编辑预算加入 ILP
求解并登记状态；超时有 incumbent 时保留非最优身份
**if** 无可行解或评分失败 **then**
  **return** 区分原因的拒绝状态
**end if**
复核整图合法、完整删增成本、两个分项门及严格总增益
**return** 复核通过的完整状态；否则丢弃副本并返回拒绝

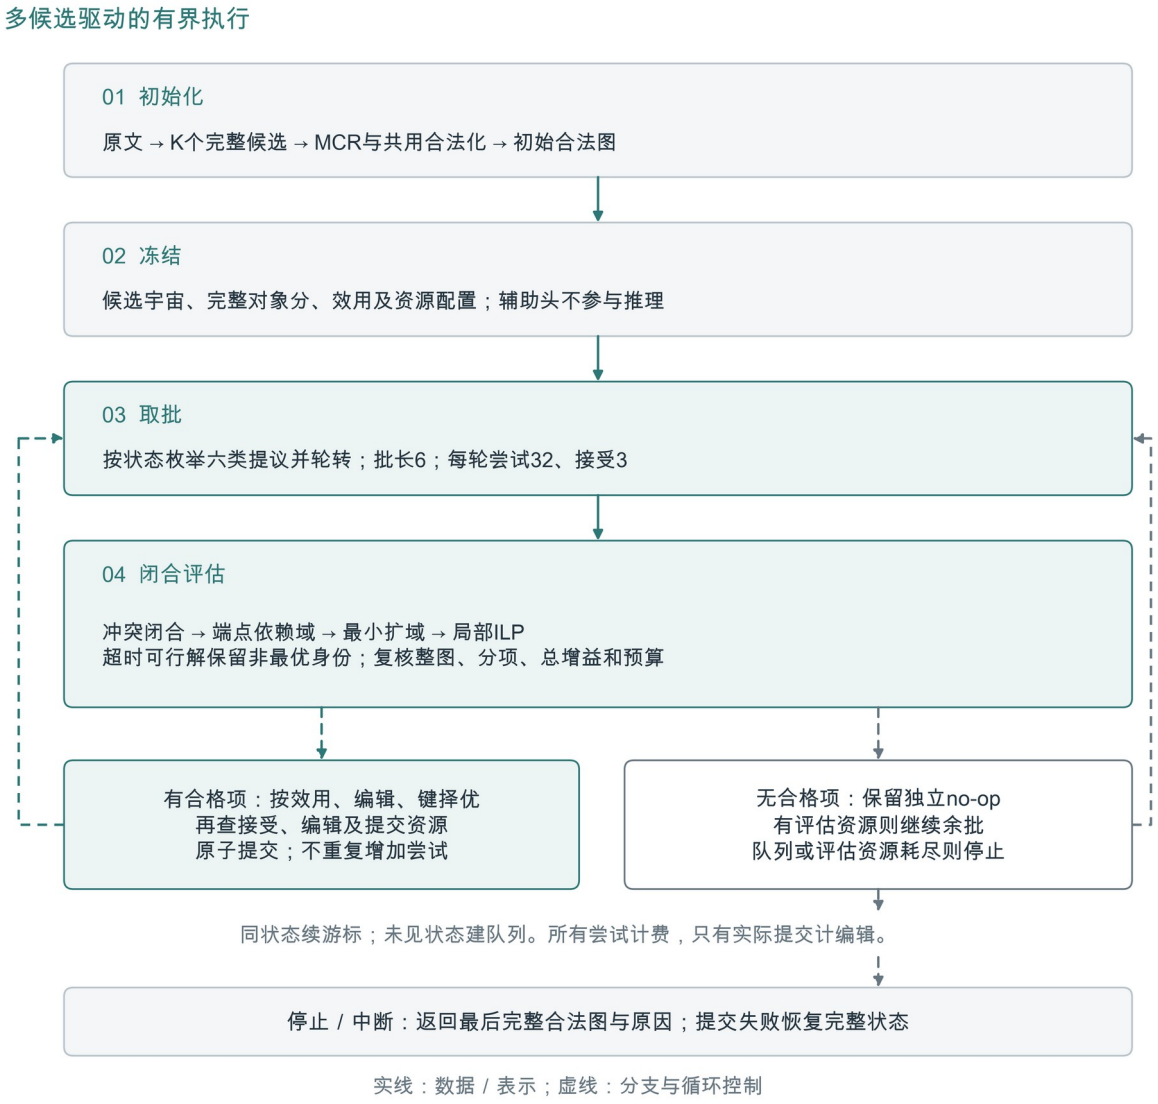



图 4-2 多候选驱动的依赖闭合修正执行流程

图 4-2 给出数据流，算法 4-1 和 4-2 确定批次与失败语义。no-op 独立于 ILP，不要求严格增分；改变组件后的局部问题不一定包含原图。候选构造、评分、全部拒绝及超时尝试均计实际资源，只有成功提交才增加语义编辑账本。提交失败恢复组件、关系、语义键和缓存引用，但已消耗时间与调用不退还。缺少可行 incumbent、数学不可行、评分失败和初始化失败分别记录。完整算法与日志接口在附录 B 中对应。

### 4.5.3 固定评分下的精确差值

命题 4-1：固定候选宇宙及对象评分时，两个预测状态之间的效用差可由新增、删除对象精确计算。

证明：对 $X\in\{C,R\}$，记 $a_X(o)=2q_X(o\mid x)-\kappa_X$，则

$$\Delta\Phi_X=\sum_{o\in X(G')\setminus X(G)}a_X(o)-\sum_{o\in X(G)\setminus X(G')}a_X(o). \tag{4-14}$$

固定评分使共同对象抵消，完整依赖重建使差集覆盖所有改变的关系。详细推导及评分变化时的适用边界见附录 B.6。

### 4.5.4 集合事务的可达性

命题 4-2：存在合法状态，使全部单对象改动均不能通过严格改进条件，而一个集合替换可以通过。

附录 B.6 给出两个旧组件合并为一个新组件的合法构造：单对象严格改进无法通过，整体替换可以通过。该反例刻画动作表达能力，不提供真实 F1 保证。

该例说明成组事务可以跨越单对象严格改进的限制，而非证明真实样本上的 F1 必然提高。它也不意味着集合事务具有任意大小的搜索能力；本章默认邻域不能跨越所有可能的局部障碍。

### 4.5.5 有限终止与真实指标边界

命题 4-3：在有限候选状态空间内，严格提高同一固定 $\Phi$ 的接受序列不可能重复访问状态，因此必定有限终止。

严格增加同一固定效用排除状态重复；有限候选空间使接受序列有限。证明及预算停止的区别见附录 B.6。

对于单项语料 micro-F1，设真实正确数为 $T$、预测数为 $P_0$、金标准数为 $Q$，$F=2T/(P_0+Q)$。当修改前后分母均非零时，直接展开可得

$$F'-F=\frac{2\Delta T-F\Delta P_0}{P_0+Q+\Delta P_0}. \tag{4-15}$$

该恒等式说明真实增益同时取决于正确数和预测数的变化。推理时不知道真实 $\Delta T$ 与 $F$，估计概率及固定 $\kappa$ 也不能替代它们。即使候选级校准良好，仍不能得到每次事务的误差上界。因此，本章只保证接受过程的代理效用单调，不宣称真实 F1 单调、期望 F1 最优或全局最优。

## 4.6 实验与分析

4.6.1—4.6.6 保留估算情景的主比较；4.6.7 单列实际 Luna 预测、轻量修正和评分对照。二者具有独立的运行身份、分母与成本口径。正式目标模型的完整比较仍按附录 H 完成。

本章主比较固定 T1 训练条件，以 I0 为共同起点，按 2.6.3 区分贡献检验与求解策略比较；4.6.7 的独立试验未进行 T1 训练。RelationOnly 和单对象动作直接检验组件可变性与集合表达，同目标全局 ILP 检验局部策略的采用价值，组件优先分步策略

补充检验共同决策。组件及完整关系计数评价最终输出，覆盖、Oracle、对象评分和恢复风险解释增量来源。数学构造保留在方法说明与附录 D，用于展示边界情形，不代替完整对照。

### 4.6.1 推理协议与方法对照

本章实验沿用 2.6 节规定的数据划分、严格评价与运行身份，生成器、候选及评分器的接口见 2.7 节。推理侧比较固定训练方案与生成检查点，并分别报告 AAEC 的完整关系及 CDCP 的原生超边结果。AAEC 的 Claim stance 保持属性身份；没有普通关系的 MajorClaim 参与组件评价，其缺边不被计为可恢复的关系错误。

CDCP 主配置保留原生多前提关系：

$$h=\left(\{c_{i_1},\ldots,c_{i_k}\},c_j,\ell\right),\ell\in\{Reason,Evidence\}. \tag{4-16}$$

源成员按原文顺序规范化，整条超边作为一个精确对象。候选、评分、预算及评价均采用这一单位；一个成员正确不等于整条关系正确。与采用预处理或结构转换的既有研究比较时，必须明确相应协议。[46]

超边候选由初始图关系及预算内可共存的成员组合构成。初始设计对新增组合最多包含 3 个源成员，但保留初始图已有的更长超边，并单报裁剪覆盖损失。源范围连续性按所选组件序列检查，不以字符间没有空隙代替。任一源成员或目标变化均使旧超边整体失效；评分器使用有序成员聚合及成员数量、位置特征，ILP 要求全部成员和目标同时存在。组件变化还可能影响事务外超边的范围合法性，此时执行 4.3.2 节的最小合法化扩域并重新计费，失败则拒绝，不能仅检查相交端点。原生超边结果与二元投影结果分别报告，不混用分数。

同目标全局 ILP 以可变组件指示量$z_c$共同求解。对每个超边$h$，若候选组件$c$按位置位于其最左与最右源成员之间、但不属于该源集合，则加入$y_h+z_c\le 1$，并结合全部端点存在和组件兼容约束，以保证被选源成员在最终组件序列中连续。局部 ILP 的固定$C'$预检是这一约束的特例。构建候选时不依据整个候选宇宙的固定邻接关系剪掉潜在合法源集合，因为中间候选可能最终不被选择。

推理侧设置整系统比较与机制受控比较两类对照。整系统比较共享生成检查点、初始完整候选和共用合法化规则，保留 MCR-only、BR-O、BR-C 及 BR-J 各自的候选补充、评分与修正机制，用于判断完整方案的效果及成本。受控比较则除被检验因素外，固定候选宇宙、对象评分、动作或搜索顺序及相应资源口径，分别检验评分、决策策略与事务范围的作用。表 4-1 定义各版本的操作接口，表 4-2 列出归因条件。

表 4-1 推理方法的修改对象与决策接口

| 方法 | 组件处理 | 关系处理与决策 |
| --- | --- | --- |
| MCR-only | 选定初始候选后不修正 | 不执行后续学习型修正 |
| BR-O | 原版类型及候选跨度等动作 | 保留前期修正流程与评分 |
| BR-C | 固定初始组件 | 保留固定覆盖目标的保守关系修正 |
| RelationOnly | 固定组件 | 采用 BR-J 的对象评分与效用，仅修改关系 |
| 顺序组件及关系修正 | 先决定组件变化 | 再重建关系，以检验分步决策 |
| 单对象动作 | 限制单次组件改动范围 | 在同一评分下检验受限动作的可达性 |
| BR-J | 兼容组件集合替换 | 重建受影响关系后整体接受或回退 |
| 同目标全局 ILP | 联合选择候选组件 | 在共同效用与整图约束下联合选边 |

BR-C 与 RelationOnly 均固定组件，但前者保留前期覆盖目标，后者采用新对象评分，因而分别承担原版系统对照与动作限制对照。

本版顺序对照命名为“组件优先的分步决策”。组件提议的第一阶段要求组件效用严格增加超过$\delta_C=\delta$，删除端点或源连续性变化导致失效的全部旧关系，并检查整图合法性及剩余编辑预算。第一阶段不设关系或总效用非下降门，实际关系删除全部收费。每批先在临时副本上评估所有获额度的外层提议：组件提议只用其第一阶段的$w_C\Delta\Phi_C$排序，纯关系提议用$w_R\Delta\Phi_R$排序；同分依次比较该阶段实际编辑数与规范键。只提交批内一个胜出提议，组件提议的未来关系补全不得影响这一选择。临时评估只消费实际计算资源，未提交的图编辑不计累计编辑。

组件提议胜出后立即提交第一阶段，外层接受加 1，再在合法中间图上以同一候选域及剩余资源求解配套关系阶段，要求关系效用严格增加超过$\delta_R=\delta$。第二阶段无解、无 incumbent 超时或实际资源耗尽均保留第一阶段状态，既有成本不退回；有 incumbent 时先按该阶段门限、合法性与预算复核。达到外层接受上限不会截断已接受提议的配套阶段，但真实资源和编辑上限始终有效。纯关系提议已在批内完成关系评估，胜出时直接提交，不重复求解；成功计一次外层接受。阶段尝试、求解、提交、时间、调用与 token 分别登记，两个阶段的关系删增均累计收费。

组件预筛后整体提交并在失败时撤销第一阶段，是另一种联合提交变体，不是本节顺序基线。单对象对照只允许冲突闭合后的$0\to1$、$1\to0$、$1\to1$，禁止$1\to2$、$2\to1$

，仍完整重建依赖关系。名义插入导致多对象删除时按实际形态限制。轨迹分叉后的队列不必相同，固定的是候选、对象分、规则和资源；另用同图同提议配对诊断区分信息使用方式。

该顺序对照比较组件优先分步策略与联合决策策略的整体差异，不单独识别纯执行顺序的因果作用。单对象动作检验集合替换的可达性，两者均不能代替完整 BR-J。附录 E 保留前期 BR-O 的历史协议，当前共同接口下的对照另行汇总。

表 4-2 推理侧对照及归因

| 对照 | 对齐要求 | 主要问题 | 必须报告的代价 |
| --- | --- | --- | --- |
| MCR-only、BR-O、BR-C、BR-J | 同一生成检查点、初始候选与共用合法化 | 完整系统效果及前期工作递进 | 候选补充、评分、失败尝试与求解成本 |
| 仅删边后处理 | 同一初始图及预算口径 | 收益是否主要来自删除错误关系 | Recall 及真阳性损失 |
| 组件优先分步与 BR-J | 同候选、评分、动作规则及明确资源口径 | 两种决策策略的整体差异，不单独归因于执行顺序 | 净恢复、误改与实际计算成本 |
| 同动作不同评分 | 同一候选、事务集合、搜索顺序与资源口径 | 旧均分、固定计数效用及其他明确目标的差异 | 错误高分及接受后风险 |
| RelationOnly、单对象动作与 BR-J | 固定候选、评分及资源口径，分别限制修改范围 | 组件可变性、集合替换与闭合范围的作用 | 编辑数量、事务大小及可达范围 |
| 同目标全局 ILP | 同一候选与效用，采用包含局部终态的可行域 | 有限预算下局部修正的价值 | 可行解、gap、最优性状态及耗时 |
| 等额度通用重写或重生成 | 明确对齐 token 额度或调用额度 | 给定额度代理下的修正收益 | 另报真实时间、解析失败、幻觉跨度及全部成本 |

全局 ILP 是同时选择全部组件与关系的强对照。其主配置固定相同候选、评分和合法性规则，要求组件与关系效用分别不低于初始图，并将两类对象的最终净编辑量

分别限制在局部累计编辑预算内。局部方法的分项非下降和累计预算保证其终态满足这些约束；反向关系不成立，因此该全局可行域包含局部可达终态，二者并非同域。已证明最优的全局效用构成相应局部解的上界；若求解未完成，最大化问题的有效求解上界也可用作界，但当前可行解的效用不是该保证。因此，即使候选、评分与求解时间相同，比较也同时包含局部累计编辑与全局净编辑约束的差异，不能全部归因于求解范围。可行解、求解间隙和最优性状态分别报告，大预算行不自动视为全局最优。上述包含关系只涵盖 BR-J 终态；顺序方法允许关系效用下降，其终态不一定满足初始分项下界。顺序方法若与全局方法比较，另设不加分项下界的版本。不加分项门或采用其他净预算的版本分别命名。

本节情景对应等求解预算比较，共同准备成本照常计入总时间。等端到端时限是另一比较条件，须从相同总额度扣除候选准备、评分和失败尝试，不能直接重命名现有成绩。预算点、规模分组、完整求解状态及失败分母集中于附录 H.3。

### 4.6.2 系统结果与策略对照

表 4-3 推理方法的严格抽取结果（估算情景）

| 方法 | AAEC 组件 | AAEC 关系 | CDCP 组件 | CDCP 关系 |
|---|---|---|---|---|
| I0（T1 初始图） | 80.48±0.26 | 57.77±0.32 | 72.77±0.52 | 52.45±0.33 |
| BR-O | 81.07±0.32 | 58.56±0.45 | 73.38±0.41 | 53.38±0.26 |
| BR-C | 80.48±0.26 | 58.96±0.34 | 72.77±0.52 | 53.96±0.34 |
| RelationOnly | 80.48±0.26 | 59.56±0.43 | 72.77±0.52 | 54.76±0.53 |
| 组件优先分步 | 81.27±0.30 | 59.55±0.34 | 73.57±0.57 | 54.56±0.26 |

表 4-3（续）

| 方法 | AAEC 组件 | AAEC 关系 | CDCP 组件 | CDCP 关系 |
|---|---|---|---|---|
| 单对象动作 | 81.77±0.33 | 60.67±0.34 | 74.07±0.32 | 55.83±0.29 |
| 未校准评分 | 82.28±0.48 | 60.07±0.41 | 74.76±0.30 | 55.17±0.38 |
| BR-J | 82.26±0.51 | 61.87±0.21 | 74.77±0.40 | 57.36±0.53 |
| 全局 ILP 等求解预算 | 82.58±0.23 | 62.27±0.29 | 75.18±0.27 | 57.86±0.28 |
| 全局 ILP 大预算 | 82.87±0.38 | 63.06±0.46 | 75.48±0.53 | 58.66±0.30 |
| 等 token 额度重生成 | 81.36±0.29 | 59.96±0.35 | 73.68±0.46 | 54.86±0.40 |

BR-J 相对 I0 在 AAEC 和 CDCP 上的关系 F1 分别增加 4.10 和 4.91 个百分点。相对固定组件 RelationOnly，高 2.31 和 2.60 个百分点，情景配对 95%区间为[+1.65, +2.97]、[+1.68, +3.51]；相对单对象动作，高 1.20 和 1.53 个百分点，区间为[+0.39, +1.98]、[+0.69, +2.45]。前一比较检验组件可变性，后一比较检验集合表达，均须结合编辑数量、误改及成本解释。这些区间由假设计数重采样得到，不确认真实端点错误上的收益，也不证明每项机制均有必要。

作为共同决策的补充比较，BR-J 相对于组件优先分步策略的关系增量为 2.33 和 2.80 个百分点，情景文档配对 95%区间分别为[+1.48, +3.10]和[+1.95, +3.67]。这些结果演示两种策略整体差异的报告方式。两者同时改变信息使用、接受条件和批内排序，不能单独识别纯执行顺序的因果作用。

另取一个独立的两阶段决策简例，取关系权重为 1、其余对象效用不变，并假设旧关系在修改组件前必须删除：旧、新组件效用分别为 0.20 和 0.80，旧、新关系效用分别为 0.90 和 0.20。若先提交组件，再成功生成新关系，总效用由 0.20 + 0.90 = 1.10 变为 0.80 + 0.20 = 1.00；联合门因关系分量下降而拒绝该提议。本例与 4.4.5 的教学算例采用不同赋值，仅说明代理目标下的决策差异；真实标签与代理评分不一致时，联合门也可能错误拒绝。

全局等求解预算结果略高于 BR-J，扩大求解预算后继续提高关系结果。这个次序符合更宽决策范围可能获得更好解的解释，但不能由任务 F1 反推预测效用的最优性。局部方法的价值还取决于求解时间、预算可控性与实际恢复轨迹，成本比较见 4.6.5 节。

### 4.6.3 候选覆盖与恢复空间

严格组件覆盖以完整金标组件数为分母；全部端点覆盖要求一条金标关系的所有完整端点均存在；完整关系覆盖进一步要求源集合、方向和标签被枚举。这三个层次均不表示对象能够共同进入合法图，也不表示已经进入实际队列。

表 4-4 从完整组件到完整关系的候选覆盖（估算情景）

| 覆盖层次 | AAEC %（计数） | CDCP %（计数） |
|---|---|---|
| 完整组件 | 95.18（1600/1681） | 91.79（1419/1546） |
| 全部完整端点 | 91.11（1137/1248） | 84.61（786/929） |
| 完整关系 | 87.42（1091/1248） | 79.22（736/929） |

AAEC 从组件覆盖到完整关系覆盖仍有差距，CDCP 的差距更大。原生超边需要同时满足多个源成员和目标的完整身份，因此单个跨度进入候选并不足以恢复关系。二元逆向槽位被裁掉时，该方向不进入反向队列；现有长超边保护与新长源集合枚举也分别记录，避免把候选范围限制统一归为评分失败。

令$\mathscr{H}_1$为初始图及一次允许事务的合法终态，$\mathscr{H}_L$为最多$L$次事务、每一步合法并满足累计编辑预算的终态，$\mathscr{H}_{net}$为相同候选与整图合法性下满足相同数值净编辑预算的图。三者解除预测效用门、队列截断和运行时限；前两者保留动作形态，$\mathscr{H}_L$保留中间状态与累计成本。包含 no-op 时，有$\mathscr{H}_1 \subseteq \mathscr{H}_L \subseteq \mathscr{H}_{net}$。主诊断的$L$对应 BR-J 外层接受上限，不是轮数或分步阶段数。

Oracle 按整个评价集合的严格关系 micro-F1 优化，即$2\sum_d TP_d / \left(\sum_d |R_d| + \sum_d |Y_d|\right)$。逐文档最优 F1 再平均不等于该目标。表 4-5 按共同计数展示三个恢复空间的诊断值，金标只参与离线诊断，不进入测试输出选择或预算调整。

表 4-5 三类恢复空间的关系计数诊断（估算情景）

| 空间 | AAEC F1 | TP/FP/FN | CDCP F1 | TP/FP/FN |
|---|---|---|---|---|
| 单事务松弛空间 | 76.77 | 940/261/308 | 70.26 | 639/251/290 |
| 多事务松弛空间 | 83.20 | 1020/184/228 | 77.67 | 708/186/221 |
| 全局净预算松弛空间 | 85.07 | 1043/161/205 | 80.37 | 733/162/196 |

多事务空间相对单事务空间保留了额外恢复余地，全局净预算空间又放宽了路径和累计开销限制。三者的数值差异说明“覆盖”“可达”和“实际接受”应分开分析；关系

候选存在仍可能需要后续事务才能被选择。附录 D.4 的四组件穷举给出最小例子：覆盖为 100%，一次事务最佳 F1 为 66.67，多步为 100.00，原因是删除非端点组件后，新合法关系还需单独的关系事务。

净编辑预算也不代表相同操作成本。先删除再加入同一对象的终态净变化为 0，实际累计编辑为 2。未完成全状态求解时，找到的可行值只提供最大化目标的下界，须与有效上界和最优性状态分开。金标 Oracle 和 4.6.1 的预测效用全局 ILP 使用不同目标，不能相互替代。

### 4.6.4 完整对象评分与校准

评分验证使用固定提案及完整对象精确标签，按文档分组，保留候选来源与自然错误类别。组件、关系分别统计 AUROC、Brier 和 10 个等宽分箱的 ECE；AUROC 反映排序，Brier 和 ECE 反映概率与标签的对应。概率校准的讨论遵循置信度与经验正确率的区分[45]。

表 4-6 完整对象评分的区分与校准（估算情景）

| 语料与对象 | AUROC | Brier 前→后 | ECE 前→后 | 对象数 |
|---|---|---|---|---|
| AAEC 组件 | 0.771 | 0.181→0.173 | 0.082→0.024 | 2400 |
| AAEC 关系 | 0.779 | 0.178→0.170 | 0.077→0.010 | 4800 |
| CDCP 组件 | 0.797 | 0.168→0.164 | 0.057→0.021 | 2400 |
| CDCP 关系 | 0.781 | 0.177→0.169 | 0.074→0.009 | 4800 |

校准后 Brier 和 ECE 下降，AUROC 保持不变，符合单调概率变换保持排序的特点。完整关系正例要求源成员、目标、端点类型、方向和标签同时匹配，不能把一个成员正确视为整条超边正确。未被生成器输出的关系也不自动记作负例，候选池需要保留完整标签槽位和明确定义的负例来源。

训练内 OOF 生成器与跨度头共同隔离持出文档及其变体，开发校准与策略选择使用不同子集。T0 和 T1 候选的分布变化纳入评分材料，最终模型的候选来源单独登记。表 4-3 中未校准评分低于完整 BR-J，但概率指标改善仍不构成接受后安全保证：搜索会选择高分对象，接受分布与固定提案分布不同，需进一步观察表 4-7 的恢复和误改。

### 4.6.5 恢复风险与资源取舍

表 4-7 关系恢复与误改的累计计数（估算情景）

| 语料与方法 | 恢复 TP | 损失 TP | 移除 FP | 新增 FP | 原 TP 保留% |
|---|---|---|---|---|---|
| AAEC 分步 | 181 | 115 | 255 | 193 | 94.54 |
| AAEC BR-J | 232 | 78 | 291 | 151 | 96.30 |
| AAEC 全局等求解预算 | 227 | 58 | 309 | 155 | 97.25 |
| CDCP 分步 | 141 | 82 | 286 | 234 | 94.23 |
| CDCP BR-J | 195 | 58 | 313 | 190 | 95.92 |
| CDCP 全局等求解预算 | 203 | 52 | 316 | 181 | 96.34 |

表 4-7 累加三个情景种子的关系对象变化，恢复为新增真阳性，损失为初始真阳性消失；FP 移除与新增分别计数。BR-J 在 AAEC 和 CDCP 保留了 96.30%和 95.92%的初始关系真阳性。尽管总体关系 F1 提高，仍有 42 和 86 个文档与种子配对的关系 F1 下降，分别占 17.50%和 19.37%。因此，分项代理门不保证每篇文档的真实指标非下降；此处比例同样只是情景生成结果。

分步方法最多进行两次阶段提交，BR-J 每个外层接受进行一次联合提交。本文以文档净 TP、FP、FN 比较风险，不直接把二者的“有益提交比例”放在同一分母下。组件与关系混合变化保留计数向量；以关系 F1 标记有益或有害时，也不掩盖组件端的变化。

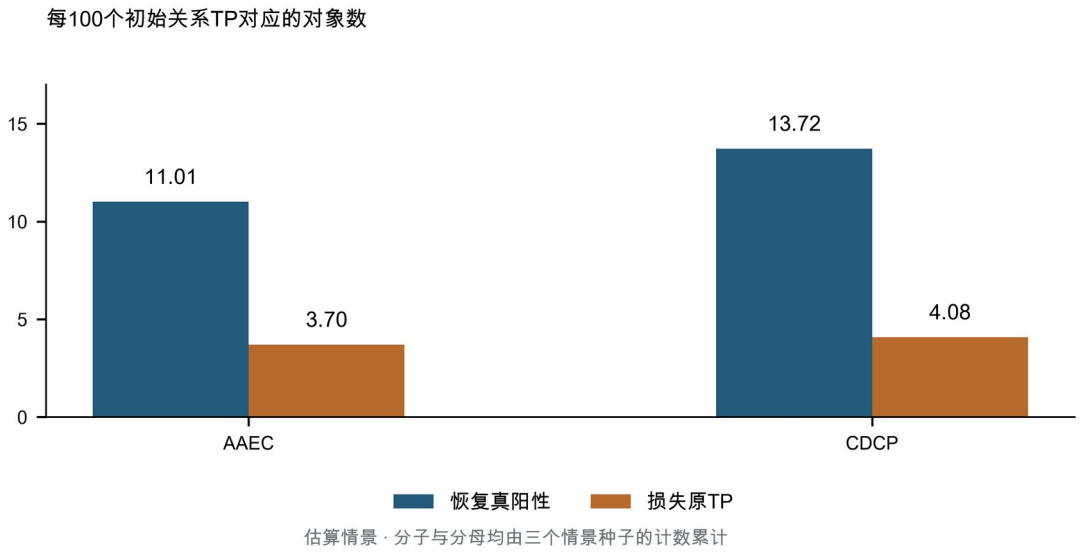



图 4-3 联合修正中的关系恢复与原真阳性损失（估算情景）

表 4-8 推理成本与预算取舍（估算情景）

| 语料与方法 | 平均秒 | P95 秒 | 求解秒 | 总 k token |
|---|---|---|---|---|
| AAEC I0 | 18.00 | 28.44 | 0.00 | 27.2 |
| AAEC 组件优先分步 | 31.45 | 49.69 | 1.05 | 45.2 |
| AAEC BR-J | 32.00 | 50.56 | 1.60 | 45.2 |
| AAEC 全局 ILP 等求解预算 | 33.40 | 52.77 | 3.00 | 45.2 |
| AAEC 全局 ILP 大预算 | 78.40 | 164.64 | 48.00 | 45.2 |
| AAEC 等 token 额度重生成 | 32.00 | 50.56 | 0.00 | 45.2 |
| CDCP I0 | 23.00 | 36.34 | 0.00 | 33.7 |
| CDCP 组件优先分步 | 44.28 | 69.96 | 1.68 | 51.7 |
| CDCP BR-J | 45.16 | 71.35 | 2.56 | 51.7 |
| CDCP 全局 ILP 等求解预算 | 47.40 | 74.89 | 4.80 | 51.7 |
| CDCP 全局 ILP 大预算 | 119.40 | 250.74 | 76.80 | 51.7 |
| CDCP 等 token 额度重生成 | 45.00 | 71.10 | 0.00 | 51.7 |

耗时包括候选生成、裁剪前对象评分、全部提议评估、失败处理和求解。保留 4096 个补充槽位不意味着只对 4096 个对象评分。表 4-8 的等求解预算比较采用相同逐文档总求解上限及线程设置，单次时限另记；大预算全局结果允许更长求解时间。

重生成与 BR-J 对齐总 token 额度，解析失败与额外调用进入成本，实际调用组织可以不同。这里的 token 合计包含各模型输入与输出，是额度代理；输入读取、评分和自回归解码的单位代价不同，等 token 不表示等 GPU 时间、等能耗或等端到端时延，成本结论须同时查看时间列。

BR-J 相对等求解预算全局 ILP 节省的平均总时间为 4.19%和 4.73%，关系 F1 按未舍入值低 0.40 和 0.49 个百分点。局部与全局的质量差异和 TP 保留须分别查看表 4-3 及表 4-7，不能预设局部更安全。BR-J 求解仅占总时间的 5.00%和 5.67%，主要成本仍在生成与评分。上述数值是设定成本下的算术关系，不支持突出的效率优势；采用判断须按附录 H.3 实测准备、求解、失败与尾延迟。

### 4.6.6 预算条件的分析示例

等求解预算与等端到端时限回答不同问题：后者须从总时限扣除共同准备、评分和失败处理。附录 H.7 以显式成本函数和完成度插值演示预算、回退及分母的联合分析；预检失败不删除，未枚举对象的潜在可恢复覆盖保持未知。

若准备成本和两类求解轨迹满足该附录的设定关系，可能出现某些规模与时限下的条件优势。其排序部分由相对速度及质量插值预先决定，不能由模拟区间确认算法采用条件。当前保留依赖闭合恢复这一研究核心，局部或全局的优先级等待共同候选、评分和资源条件下的实际运行；结果不支持时允许简化局部设计。

### 4.6.7 案例分析

实际试验分为三个独立部分：AAEC 32 篇与 CDCP 116 篇的探索性扩样；ArgUNSC 与 CasiMedicos-Arg 各 32 篇的固定规模试验；另 32 篇 CDCP 的配对评分对照。各部分均请求 gpt-5.6-luna / low，使用同一回答中的 g0、g1 构造有限候选，由新上下文任务评分，再运行 BRJ-lite 及 RelationOnly。BRJ-lite 保留依赖闭合、分项接受门和编辑预算，未训练本文的生成骨干或对象评分器，因此不替代表 4-3 的完整 BR-J。原始记录、失败分母及协议差异见 D.7—D.12。

表 4-9 Luna 探索性扩样的严格结果（真实运行）

| 语料 | 篇数 | 配置 | 组件 F1 | 完整关系 F1 |
|---|---|---|---|---|
| AAEC | 32 | MCR-only | 14.08 | 0.00 |
| AAEC | 32 | RelationOnly | 14.08 | 0.00 |
| AAEC | 32 | BRJ-lite | 27.58 | 1.44 |
| CDCP | 116 | MCR-only | 29.47 | 1.54 |

| 语料 | 篇数 | 配置 | 组件 F1 | 完整关系 F1 |
|---|---|---|---|---|
| CDCP | 116 | RelationOnly | 27.49 | 0.00 |
| CDCP | 116 | BRJ-lite | 18.53 | 0.00 |

表 4-9 包含原 16 篇及新增 132 篇，按全部文档 TP、FP、FN 汇总计算 F1。AAEC 有 4 篇完整关系 F1 提高，CDCP 无提高例；CDCP 另有 9 篇显式失败，全部计入修正结果分母。旧协议的 MCR 列保留其选中的原始图，即使结构非法，而失败修正计为空输出；两列的差异因而包含初始化失败的影响。扩样曾按是否找到正例决定 CDCP 后续波次，不据本表估计总体改善概率或作独立测试集推断。

AAEC essay051 提供了超出标点变体的恢复案例。初始图遗漏“多数图书馆设施可长期使用”这一前提；尝试 19 从模型生成候选中将其补入，并重建其对“投资图书馆有长期效果”的 supports 关系。两个端点均为生成候选，完整关系来自有限槽位补充，原 g0、g1 均未直接含有该正确关系。BRJ-lite 关系 F1 由 0 升至 8.00，RelationOnly 仍为 0；终态为 1 TP、8 FP、15 FN。该例说明组件补入可打开固定组件修正无法使用的关系端点，但缺少单对象和分步对照，尚不能证明集合事务或共同决策的独立优势。

AAEC essay001 则揭示初选与恢复之间的联系。MCR 选择 g1 后丢失了 g0 已有的正确对象；尝试 1 补入目标 Claim，尝试 7 补入前提并恢复 supports 关系，完整关系 F1 由 0 升至 12.50，而 RelationOnly 为 0。终态仍含 9 个关系 FP 和 5 个 FN。两例均来自全部四个严格正例，另两例 essay078、essay085 涉及句末标点边界。扩样恢复的 55 个正确组件中，28 个来自标点变体、27 个来自生成候选，不能把所有恢复解释成同一种机制。

CDCP 的负结果给出不同的限制。冻结池仅命中 22 / 200 条完整金标关系，19 条多源金标关系均未入池；已入池的 22 条中有 19 条按原评分规约取得 0.05。旧 116 篇的 485 个初始组件中，178 个完整命中、74 个跨度正确但类型错误，其中 value→fact 为 35 个、testimony→fact 为 14 个；其余 233 个没有精确金标跨度对应。该分解提示原生类型语义与候选覆盖值得优先检查，但不能把误差全部归因于提示。01057 中，正确 reason 关系因 0.05 分被删除，关系 F1 从 33.33 降至 0，RelationOnly 也发生同一损失；合法提交与代理增分不能替代真实正确性。

表 4-10 新增原生语料的固定样本结果（真实运行）

| 语料 | 配置 | 组件 F1 | 完整关系 F1 |
|---|---|---|---|
| ArgUNSC | MCR-only | 9.34 | 1.08 |
| ArgUNSC | RelationOnly | 9.34 | 0.00 |

| 语料 | 配置 | 组件 F1 | 完整关系 F1 |
|---|---|---|---|
| ArgUNSC | BRJ-lite | 8.62 | 0.00 |
| CasiMedicos-Arg | MCR-only | 10.86 | 0.83 |
| CasiMedicos-Arg | RelationOnly | 10.86 | 0.00 |
| CasiMedicos-Arg | BRJ-lite | 9.23 | 0.00 |

ArgUNSC 保留全部 32 篇，64 个候选图中 58 个通过解析、58 个满足实现的结构检查，1 篇初始化失败。金标共有 828 个组件和 505 条完整关系，冻结池分别命中 61 和 4 个；BRJ-lite 的关系 F1 为 0 篇提高、3 篇下降、29 篇不变。失败输出计为空预测，金标保持在分母；格式遵循、候选覆盖和修正变化分别解释，不能从成功子集外推整个语料。

CasiMedicos-Arg 保留全部 32 篇，64 个候选图中 29 个通过解析、26 个满足实现的结构检查，14 篇初始化失败。金标共有 389 个组件和 211 条完整关系，冻结池分别命中 34 和 3 个；BRJ-lite 的关系 F1 为 0 篇提高、1 篇下降、31 篇不变。失败输出计为空预测，金标保持在分母；格式遵循、候选覆盖和修正变化分别解释，不能从成功子集外推整个语料。

CDCP 配对试验采用 32 篇未进入前述审计集合的官方训练文档。两种评分方案固定相同生成结果、候选池、原评分 MCR 选择的初始图和全部预算，并分别运行 BRJ-lite 与 RelationOnly。“原生显式”方案同时加强 fact / testimony / value / policy / reference 及 reason / evidence 的原生说明，并要求每个候选显式给分或标记未知。它是两个输入因素的组合干预，不能单独归因于标签说明或输出格式。

表 4-11 CDCP 相同候选与初始图下的评分对照（真实运行）

| 评分方案 | 修正策略 | 组件 F1 | 完整关系 F1 |
|---|---|---|---|
| 共同初始 | MCR-only | 26.21 | 3.33 |
| 原评分 | RelationOnly | 26.21 | 0.00 |
| 原评分 | BRJ-lite | 18.23 | 0.00 |
| 原生显式 | RelationOnly | 26.21 | 1.65 |
| 原生显式 | BRJ-lite | 20.81 | 1.60 |

原评分 BRJ-lite 相对共同初始图恢复 0 条真关系、损失 2 条，新增 / 移除错误关系为 86 / 52；原生显式方案对应 1、2 及 47 / 41。两方案均保留 0 篇共同初始化失

败，未重新挑选更有利初始图。分数改变后修正路径也可能改变，因此需同时看真阳性保留、误报和 RelationOnly 结果，不能仅以接受次数或代理效用判断改进。

CDCP 00846 提供原生显式评分下的严格正例。原文以“消费者未必知道债权人及其联系方式”作为“通知应列明债权人的地址和电话”的 reason；两端点已在共同初始图中，该完整关系只在补充槽位中。其分数由原评分的 0.05 变为 0.75，首次关系提议即将其加入，关系 F1 由 0 升至 18.18，终态为 1 TP、3 FP、6 FN，组件未变化。RelationOnly 恢复了同一条关系并取得相同终态，因此该例支持评分与候选关系重建的作用，不能单独支持组件集合替换的增量。

本次原生显式评分的严格关系 F1 高于原评分，表明在这批固定输入上评分接口的组合调整有所改善；但它仍低于共同初始图的 3.33，且未保住原有两条真关系，尚不能作为总体修正有效的证据。它仍不能补回池外边界、原生类型或完整源组合。方法层面保留原生任务定义和评分缺失检查，研究结论限定于实际发生的对象变化；完整候选构造、训练评分器与局部 / 全局比较仍须另行验证。

## 4.7 本章小结

本章将组件集合替换、完整依赖重建与共同接受组织为结构恢复事务，处理逐个组件修改无法完整评价关系影响的问题。集合动作扩展可表达的修改范围；固定评分下的差值与终止性质说明规约边界，不保证真实 F1 或全局最优。

评价围绕 RelationOnly、单对象动作和同目标全局求解展开，分别检验组件可变性、集合表达及所付成本。人工计数保留比较口径，实际 Luna 轨迹补充了生成组件增补、关系恢复与评分误改的观察。固定候选下的评分对照进一步检查输入质量的作用；候选覆盖、未校准评分和未完成的全局比较仍限制完整方法的采用结论。预算函数留作附录中的条件分析，外部系统比较仍待按附录 G 接入；第五章继续讨论同批四格输出能回答和不能回答的问题。

# 第五章 两阶段框架的综合分析

本章复用同一批四格人工计数，依次讨论组合增量、对象作用的可识别性，以及训练完成后各配置的在线质量与时间取舍。统计口径的变化不另计为研究发现；对象补全仅作为附录 H.8 的非唯一性示例，不充当模型输出。

## 5.1 两阶段的条件增量

四格为 T0＋I0、T1＋I0、T0＋I1 和 T1＋I1，I1 采用 BR-J。同一训练条件下，I0 与 I1 共用检查点、初始图和候选；不同训练条件可以改变候选及评分适配，因而四格估计的是条件系统增量。第三章 T1 和第四章 BR-J 分别复用 T1＋I0、T1＋I1 的主行，全部三个种子均进入汇总。

表 5-1 两阶段组合的四格结果（估算情景）

| 方法 | AAEC 组件 | AAEC 关系 | CDCP 组件 | CDCP 关系 |
|---|---|---|---|---|
| T0＋I0 | 78.18±0.44 | 53.25±0.34 | 70.18±0.23 | 48.04±0.38 |
| T1＋I0 | 80.48±0.26 | 57.77±0.32 | 72.77±0.52 | 52.45±0.33 |
| T0＋I1 | 79.88±0.53 | 57.26±0.34 | 71.77±0.39 | 52.47±0.43 |
| T1＋I1 | 82.26±0.51 | 61.87±0.21 | 74.77±0.40 | 57.36±0.53 |

完整组合相对 T0＋I0 的关系增量为 8.62 和 9.33 个百分点。令$F_{ti}$表示同一指标的四格结果，交互差为$I = F_{11} - F_{10} - F_{01} + F_{00}$；下表按未舍入的种子均值计算，单位为百分点。

表 5-2 条件增量与交互差（估算情景）

| 语料与指标 | 训练在 I0 | 推理在 T0 | 推理在 T1 | 训练在 I1 | 交互差 |
|---|---|---|---|---|---|
| AAEC 组件 | +2.30 | +1.70 | +1.78 | +2.38 | +0.08 |
| AAEC 关系 | +4.52 | +4.01 | +4.10 | +4.61 | +0.09 |
| CDCP 组件 | +2.59 | +1.59 | +2.01 | +3.01 | +0.41 |
| CDCP 关系 | +4.42 | +4.43 | +4.91 | +4.89 | +0.48 |

AAEC 关系交互差为+0.09，情景配对 95%区间为[-1.05, +1.23]；CDCP 为+0.48，区间为[-0.87, +1.81]。两者均包含 0，因此组合增量与稳定超加性应分别判断。组件交互也仅描述条件总分的变化，不能据此确定两阶段改变的是哪些对象。

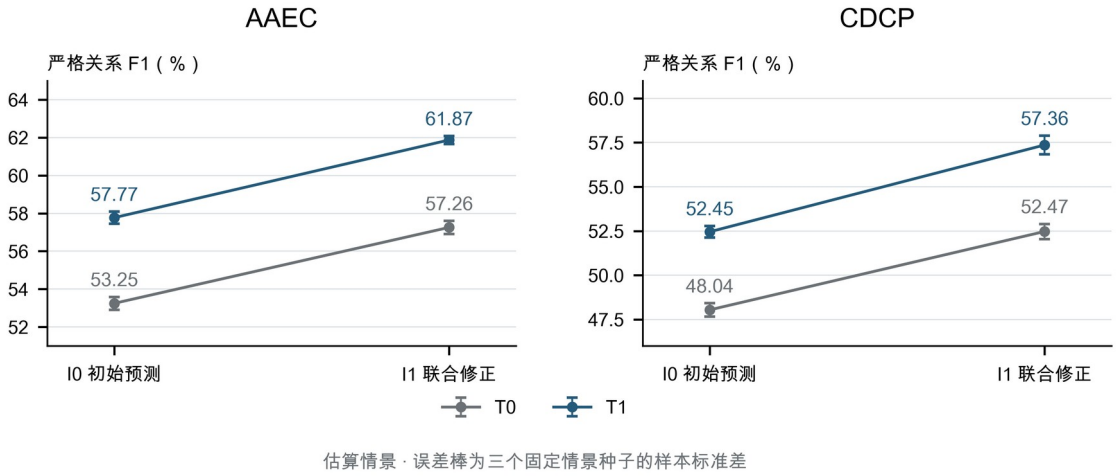



图 5-1 两个训练条件下的推理增量与交互关系（估算情景）

## 5.2 对象作用与聚合成绩的解释边界

净计数为对象分析提供总量约束。表 5-3 分别计算 T1 + I0 减 T0 + I0、T0 + I1 减 T0 + I0，以及 T1 + I1 减 T1 + I0，按同文档和种子累加；金标固定，所以每项 ΔFN 等于−ΔTP。

表 5-3 四格比较的净错误计数变化（估算情景）

| 语料与对象 | 训练增量 ΔTP／ΔFP | T0 修正 ΔTP／ΔFP | T1 修正 ΔTP／ΔFP |
|---|---|---|---|
| AAEC 组件 | +115 / -112 | +85 / -83 | +90 / -86 |
| AAEC 关系 | +169 / -154 | +150 / -136 | +154 / -140 |
| CDCP 组件 | +120 / -114 | +73 / -71 | +93 / -88 |
| CDCP 关系 | +123 / -109 | +124 / -108 | +137 / -123 |

AAEC 在 T1 下修正的关系净 TP 增加 154，T0 下为 150；CDCP 相应为 137 与 124。训练后剩余修正空间的变化须按语料分别解释。表 4-7 中 BR-J 的恢复减损失分别为 232−78、195−58，恰好对应上述净增量；图 4-3 并列保留两类数量。

上述净变化不确定共同修复、独有修复或损害的对象身份。同一组四格 TP、FP、FN 可对应不同的新增对象交集；附录 H.8 沿用旧情景的四格成绩及风险计数构

造不同重叠，说明这一不可识别性；其具体范围不移用于本版主表。正式分析需从同文档预测中对齐原文坐标、类型及完整关系键，才能报告具体改对或改错了什么。

既存 CPU 诊断的对象复算提供了一个有限观察：AAEC 禁删除对照净增 3 个正确组件、净减 3 个错误组件，但同时新增 30 个错误对象并移除 33 个错误对象（表 D-6）。净改善因此仍可能伴随错误对象之间的替换。该观察只属于弱模型的单阶段组件诊断。Luna 扩样中，AAEC 组件 FP 净增加 38 个，实际新增 73 个、移除 35 个；essay001 还表现为初选丢失已有正确对象、后续修正又将其恢复（4.6.7 及 D.10）。这说明恢复增量既受初始选择影响，也可能伴随错误对象更替。上述观察以及 D.12 的评分对照均只涉及推理阶段，不能代替同批训练四格的对象分析。

训练条件还可能同时改变初始错误、候选覆盖和评分适配，四格差值不分解各条路径；表 4-4 只有 T1 覆盖，不能当作 T0 到 T1 的覆盖变化。本章据此将结果解释为条件系统增量，真实对象作用按附录 H.4 核查，不预设互补或正交互。

源成员数分组补充说明哪些对象尚未被当前情景覆盖。以下计数仍为人工输入，不能识别同一对象在四格间的转移；逐对象阻断与同文档案例的采集见附录 H.4。

表 5-4 按固定人工金标集分组，三个种子共享该集合；各组 F1 分别计算，整体仍从全部对象计数重算。

表 5-4 CDCP 完整关系的源成员数分组（估算情景）

| 源成员数／金标数 | T0＋I0 | T1＋I0 | T0＋I1 | T1＋I1 |
|---|---|---|---|---|
| 1 个 / 556 | 53.15±1.15 | 57.91±0.54 | 57.55±0.80 | 62.11±0.73 |
| 2 个 / 252 | 41.95±2.30 | 46.62±1.27 | 47.09±0.09 | 51.93±0.81 |
| 3 个 / 121 | 34.15±5.61 | 36.11±4.29 | 36.92±3.62 | 43.80±3.14 |
| 超过 3 个 / 0 | — | — | — | — |

超过 3 成员组为 0，故不报告 F1，也不能据此判断长超边保护或恢复是否有效。保护以初始命中的长超边为分母，新建以初始遗漏的长超边为分母，分别记录其他候选图提供的保护槽位与新增枚举槽位。新增枚举上限为 3；更长关系只能从保护池选回，不能创造池外任意长源组合。本章限于原生域内任务，附录 E 的粗粒度跨域记录保持历史身份。

## 5.3 训练完成后的在线配置取舍

本节在训练投入已经发生的条件下，比较各配置的关系 F1 与在线平均时间。表 5-5 给出相对 T0 + I0 的情景增量，AAEC 和 CDCP 共同起点分别为 17.00 秒和 22.00 秒；一次性训练投入、服务量及摊销阈值不属于本表的分析范围。

表 5-5 相对共同起点的关系增量与在线额外时间（估算情景）

| 配置 | AAEC 增量 | AAEC 增秒 | CDCP 增量 | CDCP 增秒 |
|---|---|---|---|---|
| T0 + I0 | +0.00 | 0.00 | +0.00 | 0.00 |
| T1 + I0 | +4.52 | 1.00 | +4.42 | 1.00 |
| T0 + I1 | +4.01 | 14.00 | +4.43 | 22.16 |
| T1 + I1 | +8.62 | 15.00 | +9.33 | 23.16 |

在这一条件下，AAEC 的 T1 + I0 关系 F1 比 T0 + I1 高 0.51 个百分点，在线平均时间少 13.00 秒；CDCP 则低 0.02 个百分点，在线时间少 21.16 秒。后者在该情景中呈现近乎相同的质量与不同的时间，不能沿用旧版“两语料质量均更高”的结论。该比较以训练检查点已经可用为前提，不能直接回答重训或训练摊销条件下的总体选择。

在 T1 上增加 I1，关系 F1 的情景增量为 4.10 和 4.91 个百分点，在线时间增加 14.00 秒和 22.16 秒，并仍可能误改。是否采用组合应结合目标错误、质量收益与在线代价判断；实际部署还须检查尾延迟、失败及局部和全局求解取舍。

## 5.4 本章小结

四格比较把组合总增量分解为给定另一阶段时的条件变化，净计数和源成员分组进一步限定这些变化能解释的范围；它们尚未识别同一对象上的修复重叠或作用路径。本章配置比较仅回答训练完成后的在线取舍，不推算训练投入的摊销条件。这三个问题共同规定综合分析的职责，正式结果须来自同批可追溯输出，不由相容对象补全代替独立发现。

# 第六章 总结与展望

## 6.1 研究总结

本文围绕组件与关系依赖开展两项研究。训练阶段的局部文字改写可能破坏继承监督，推理阶段的组件修改可能使关联关系失效；两者共享严格对象表示，分别作用于监督保持和结构恢复，不另将组合命名为第三项算法创新。

第一项设计以关系影响域覆盖内部、跨边界及 NONE 因素，通过标注迁移建立可靠对应，再联合因素监督与成对学习。评价将数据构造整体与固定数据上的损失项分开：前者同时包含文本、源选择和重加权，后者控制同一增强集合。中心选择是实现策略，模板变化只是诊断示例；当前材料尚未验证真实漂移规模及学习收益。

第二项设计把兼容组件集合替换和全部受影响关系重建作为完整事务，以固定对象分、整图约束和预算共同决定提交。RelationOnly 和单对象动作是组件可变性与集合表达的关键对照，同目标全局求解检验资源取舍，分步策略补充分析共同决策。数学构造说明动作和决策边界，人工成绩展示比较口径，Luna 试验记录了生成端点补入、完整关系恢复、候选限制及评分误删，并对原生评分输入作了固定样本检查；局部与全局的真实优先级尚未确定，允许依据运行结果简化求解设计。

两阶段综合分析使用四格条件增量，并在训练投入已经发生的前提下讨论在线配置选择；聚合数值不能确定对象重叠，补全反例仅证明这种非唯一性。论文的核心验证仍是有限真实问题诊断、关键受控比较和同文档输出核查，而非增加模拟表格。外部系统须完成任务兼容核查与真实运行后，才可用于方法定位。

## 6.2 研究局限

正文主比较、增强审计判断和设定成本仍为估算情景。训练侧增强、成对学习、人工语义审核、同目标局部／全局与训练四格比较尚未完成。D.3 保留 CPU 诊断，D.7—D.10 报告 148 篇 Luna 探索性样本，D.11—D.12 另报告 64 篇新语料与 32 篇 CDCP 配对样本，均保留失败与严格计数。实际 MILP 已在轻量实现中执行，但其生成候选、同型号启发式评分、样本划分和本地运行成本不能代表正式系统。主成绩、模板筛选、预算函数和对象补全分别用于演示评价、指标阅读、条件分析及不可识别性，不与这些真实记录混为同一次实验。

方法边界直接影响待检验主张。影响域检查依赖语义判断与标注完备性，筛选同时改变文本和源权重；现有 T-B 不能分离新表达与重复曝光，成对项也不保证整图严格等变。推理受冻结候选、声明动作和评分误差限制，长超边新增能力有上限，分项

门可能拒绝真实有益提议。固定效用性质只约束决策过程，不保证真实 F1 或全局最优。

正式统计需遵守原生 AAEC 与 CDCP 任务和独立评价协议，区分原生关系、二元投影及历史跨域 Link-F1。平均时间不能代替尾延迟、批量吞吐或一次性投入；模拟重采样区间也不衡量成本函数设错的风险。上述核心验证按附录 H.5 完成后，应同时更新表图、对象案例及结论。

## 6.3 后续研究方向

当前核心比较和真实问题诊断尚未完成，属于本研究的验证缺口，集中列于附录 H.5。以下方向以这些核心证据取得并据此确定方法取舍为前提，不计入本文已完成工作。

一是研究标注不完备条件下的监督保持。本文把候选宇宙内未标注关系作为 NONE；当标注本身不完整时，严格保持可能固化漏标。进一步研究可区分已确认无关系与缺乏标注，检验这种区分如何影响标签保持和源覆盖，而不将更多改写一概视为有效增量。

二是研究更长多前提关系的候选组织。当前新增枚举限制源成员数，任意长组合既不能由保护池保证，也可能难以穷举。后续可在固定资源下比较候选覆盖与完整关系恢复，判断是否有必要扩展现有表示范围。上述方向服务于明确的失效条件，不预设增加机制必然更好。

# 参考文献

[1] LAWRENCE J, REED C. Argument mining: A survey[J]. Computational Linguistics, 2019, 45(4): 765–818. DOI: 10.1162/coli_a_00364. 来源

[2] STAB C, GUREVYCH I. Parsing argumentation structures in persuasive essays[J]. Computational Linguistics, 2017, 43(3): 619–659. DOI: 10.1162/COLI_a_00295. 来源

[3] PARK J, CARDIE C. A corpus of eRulemaking user comments for measuring evaluability of arguments[C]//Proceedings of the Eleventh International Conference on Language Resources and Evaluation. Miyazaki: European Language Resources Association, 2018. 来源

[4] EGER S, DAXENBERGER J, GUREVYCH I. Neural end-to-end learning for computational argumentation mining[C]//Proceedings of the 55th Annual Meeting of the Association for Computational Linguistics, Volume 1. Vancouver: Association for Computational Linguistics, 2017: 11–22. DOI: 10.18653/v1/P17-1002. 来源

[5] MORIO G, OZAKI H, MORISHITA T, et al. Towards better non-tree argument mining: Proposition-level biaffine parsing with task-specific parameterization[C]//Proceedings of the 58th Annual Meeting of the Association for Computational Linguistics. Association for Computational Linguistics, 2020: 3259–3266. DOI: 10.18653/v1/2020.acl-main.298. 来源

[6] CAPUTO E, GRECO S, LA CAVA L. Argument component segmentation with fine-tuned large language models[C]//Findings of the Association for Computational Linguistics: EACL 2026. Rabat: Association for Computational Linguistics, 2026: 5154–5167. DOI: 10.18653/v1/2026.findings-eacl.272. 来源

[7] KAWARADA M, HIRAO T, UCHIDA W, et al. Argument mining as a text-to-text generation task[C]//Proceedings of the 18th Conference of the European Chapter of the Association for Computational Linguistics, Volume 1. St. Julian’s: Association for Computational Linguistics, 2024: 2002–2014. DOI: 10.18653/v1/2024.eacl-long.121. 来源

[8] CABESSA J, HERNAULT H, MUSHTAQ U. Argument mining with fine-tuned large language models[C]//Proceedings of the 31st International Conference on Computational Linguistics. Abu Dhabi: Association for Computational Linguistics, 2025: 6624–6635. 来源

[9] DAS N, VAIBHAV V, CHOUDHARY Y S, et al. End-to-end argument mining through autoregressive argumentative structure prediction[EB/OL]. arXiv:2510.16363v1, 2025[2026-09-14]. DOI: 10.48550/arXiv.2510.16363. 来源

[10] CAPUTO E, GRECO S, LA CAVA L. ARGUS: Towards end-to-end argument mining with large language models[C]//Proceedings of the AAAI Conference on Artificial Intelligence, 2026, 40(48): 41547–41549. DOI: 10.1609/aaai.v40i48.42335. 来源

[11] LI H, SCHLEGEL V, SUN Y, et al. Large language models in argument mining: A survey[EB/OL]. arXiv:2506.16383v6, 2025[2026-09-13]. DOI: 10.48550/arXiv.2506.16383. 来源

[12] SUN Y, CHEN G, YANG C, et al. Discourse structure-aware prefix for generation-based end-to-end argumentation mining[C]//Findings of the Association for Computational Linguistics: ACL 2024. Bangkok: Association for Computational Linguistics, 2024: 11597–11613. DOI: 10.18653/v1/2024.findings-acl.689. 来源

[13] DAS N, SARADHI V V, ANAND A. On the role of key phrases in argument mining[C]//Findings of the Association for Computational Linguistics: NAACL 2025. Albuquerque: Association for Computational Linguistics, 2025: 5774–5787. DOI: 10.18653/v1/2025.findings-naacl.319. 来源

[14] SUN Y, CHEN G, ALINEJAD-ROKNY H, et al. Learning first-order logic rules for argumentation mining[C]//Proceedings of the 63rd Annual Meeting of the Association for Computational Linguistics, Volume 1. Vienna: Association for Computational Linguistics, 2025: 14133–14148. DOI: 10.18653/v1/2025.acl-long.691. 来源

[15] DING B, QIN C, ZHAO R, et al. Data augmentation using LLMs: Data perspectives, learning paradigms and challenges[C]//Findings of the Association for Computational Linguistics: ACL 2024. Bangkok: Association for Computational Linguistics, 2024: 1679–1705. DOI: 10.18653/v1/2024.findings-acl.97. 来源

[16] EVURU C K, GHOSH S, KUMAR S, et al. CoDa: Constrained generation based data augmentation for low-resource NLP[C]//Findings of the Association for Computational Linguistics: NAACL 2024. Mexico City: Association for Computational Linguistics, 2024: 3754–3769. DOI: 10.18653/v1/2024.findings-naacl.238. 来源

[17] PEI Y, BHUSE P, LIU Z, et al. SegMix: A simple structure-aware data augmentation method[EB/OL]. arXiv:2311.09505v1, 2023[2026-09-13]. DOI: 10.48550/arXiv.2311.09505. 来源

[18] SUN W, LI M, DAVIS J, et al. Weakly-supervised argument mining with boundary refinement and relation denoising[C]//Proceedings of the Ninth Fact Extraction and VERification Workshop (FEVER). Rabat: Association for Computational Linguistics, 2026: 1–12. DOI: 10.18653/v1/2026.fever-1.1. 来源

[19] GENG S, JOSIFOSKI M, PEYRARD M, et al. Grammar-constrained decoding for structured NLP tasks without finetuning[C]//Proceedings of the 2023 Conference on Empirical Methods in Natural Language Processing. Singapore: Association for Computational Linguistics, 2023: 10932–10952. DOI: 10.18653/v1/2023.emnlp-main.674. 来源

[20] MADAAN A, TANDON N, GUPTA P, et al. Self-Refine: Iterative refinement with self-feedback[EB/OL]. arXiv:2303.17651v2, 2023[2026-09-13]. DOI: 10.48550/arXiv.2303.17651. 来源

[21] HUANG J, CHEN X, MISHRA S, et al. Large language models cannot self-correct reasoning yet[EB/OL]. arXiv:2310.01798v2, 2024[2026-09-13]. DOI: 10.48550/arXiv.2310.01798. 来源

[22] WANG X, WEI J, SCHUURMANS D, et al. Self-consistency improves chain of thought reasoning in language models[EB/OL]. arXiv:2203.11171v4, 2023[2026-09-13]. DOI: 10.48550/arXiv.2203.11171. 来源

[23] TRAN N, LITMAN D, GODLEY A. Using large language models to analyze students' collaborative argumentation in classroom discussions[C]//Proceedings of the Artificial Intelligence in Measurement and Education Conference (AIME-Con): Full Papers. Pittsburgh: National Council on Measurement in Education, 2025: 111–125. 来源

[24] XIAO Y, LI S. ARGUS: Argumentation-based minimal-change repair for verifiable LLM self-explanations[C]//Proceedings of the 42nd Conference on Uncertainty in Artificial Intelligence. Proceedings of Machine Learning Research, 2026, 337: 7536–7551. 来源

[25] MORIO G, OZAKI H, MORISHITA T, et al. End-to-end argument mining with cross-corpora multi-task learning[J]. Transactions of the Association for Computational Linguistics, 2022, 10: 639–658. DOI: 10.1162/tacl_a_00481. 来源

[26] SAVIGNY H, YUN B. AMELIA: A family of multi-task end-to-end language models for argumentation[J]. Argument & Computation, 2026, 17(1). DOI: 10.1177/19462174251413169. 来源

[27] FEGER M, BOLAND K, DIETZE S. Limited generalizability in argument mining: State-of-the-art models learn datasets, not arguments[C]//Proceedings of the 63rd Annual Meeting of the Association for Computational Linguistics, Volume 1. Vienna: Association for Computational Linguistics, 2025: 23900–23915. DOI: 10.18653/v1/2025.acl-long.1164. 来源

[28] ZHAO X, WANG K, PENG W. ORCHID: A Chinese debate corpus for target-independent stance detection and argumentative dialogue summarization[C]//Proceedings of the 2023 Conference on Empirical Methods in Natural Language Processing. Singapore: Association for Computational Linguistics, 2023: 9358–9375. DOI: 10.18653/v1/2023.emnlp-main.582. 来源

[29] CHENG L, BING L, HE R, et al. IAM: A comprehensive and large-scale dataset for integrated argument mining tasks[C]//Proceedings of the 60th Annual Meeting of the Association for Computational Linguistics, Volume 1. Dublin: Association for Computational Linguistics, 2022: 2277–2287. DOI: 10.18653/v1/2022.acl-long.162. 来源

[30] VASWANI A, SHAZEER N, PARMAR N, et al. Attention is all you need[EB/OL]. arXiv:1706.03762, 2017[2026-09-13]. DOI: 10.48550/arXiv.1706.03762. 来源

[31] QWEN TEAM. Qwen2.5 technical report[EB/OL]. arXiv:2412.15115, 2024[2026-09-13]. DOI: 10.48550/arXiv.2412.15115. 来源

[32] HU E J, SHEN Y, WALLIS P, et al. LoRA: Low-rank adaptation of large language models[EB/OL]. arXiv:2106.09685, 2021[2026-09-13]. DOI: 10.48550/arXiv.2106.09685. 来源

[33] LESTER B, AL-RFOU R, CONSTANT N. The power of scale for parameter-efficient prompt tuning[C]//Proceedings of the 2021 Conference on Empirical Methods in Natural Language Processing. Association for Computational Linguistics, 2021: 3045–3059. DOI: 10.18653/v1/2021.emnlp-main.243. 来源

[34] TANG C, PENG M, TIAN G. Improving end-to-end argument mining with LLMs via multi-candidate reranking and bounded repair[C/OL]//ICIC2026 Posters: Poster Volume I. Toronto, 2026[2026-09-20]. DOI: 10.65286/icic.v22i1.76896. 来源

[35] BAO J, HUANG Y, SUN Y, et al. Exploring quality and diversity in synthetic data generation for argument mining[C]//Proceedings of the 2025 Conference on Empirical Methods in Natural Language Processing. Suzhou: Association for Computational Linguistics, 2025: 26581–26604. DOI: 10.18653/v1/2025.emnlp-main.1351. 来源

[36] WANG X, SHEN H, QI H, et al. Enhancing low-resource joint entity and relation extraction using large language models within semi-supervised learning[J]. ACM Transactions on Knowledge Discovery from Data, 2026, 20(3): 49:1–49:25. DOI: 10.1145/3799423. 来源

[37] MODARRESSI A, KÖKSAL A, SCHUETZE H. Consistent document-level relation extraction via counterfactuals[C]//Findings of the Association for Computational Linguistics: EMNLP 2024. Miami: Association for Computational Linguistics, 2024: 11501–11507. DOI: 10.18653/v1/2024.findings-emnlp.672. 来源

[38] ZHENG Y, KE W, LIU Q, et al. Making LLMs as fine-grained relation extraction data augmentor[C]//Proceedings of the Thirty-Third International Joint Conference on Artificial Intelligence. International Joint Conferences on Artificial Intelligence Organization, 2024: 6660–6668. DOI: 10.24963/ijcai.2024/736. 来源

[39] ZHONG Y, GAO Y, ZHANG X, et al. ODDA: An OODA-driven diverse data augmentation framework for low-resource relation extraction[C]//Findings of the Association for Computational Linguistics: ACL 2025. Vienna: Association for Computational Linguistics, 2025: 267–285. DOI: 10.18653/v1/2025.findings-acl.15. 来源

[40] ROCHA G, LOPES CARDOSO H, BELOUADI J, et al. Cross-genre argument mining: Can language models automatically fill in missing discourse markers?[J]. Argument & Computation, 2025, 16(1): 3–35. DOI: 10.3233/AAC-230008. 来源

[41] WAEGEMAN W, DEMBCZYŃSKI K, JACHNIK A, et al. On the Bayes-optimality of F-measure maximizers[J]. Journal of Machine Learning Research, 2014, 15(103): 3513–3568. 来源

[42] LIPTON Z C, ELKAN C, NARAYANASWAMY B. Thresholding classifiers to maximize F1 score[EB/OL]. arXiv:1402.1892v2, 2014[2026-09-20]. DOI: 10.48550/arXiv.1402.1892. 来源

[43] LI Z, ZHANG F, LYU K, et al. Re-Cent: A relation-centric framework for joint zero-shot relation triplet extraction[C]//Proceedings of the 31st International Conference on Computational Linguistics. Abu Dhabi: Association for Computational Linguistics, 2025: 7344–7354. 来源

[44] PIROZELLI P, ROCHA V H N, COZMAN F G, et al. An LLM-based system for argument reconstruction[EB/OL]. arXiv:2605.13793v1, 2026[2026-09-20]. DOI: 10.48550/arXiv.2605.13793. 来源

[45] GUO C, PLEISS G, SUN Y, et al. On calibration of modern neural networks[C]//Proceedings of the 34th International Conference on Machine Learning. Proceedings of Machine Learning Research, 2017, 70: 1321–1330. 来源

[46] NICULAE V, PARK J, CARDIE C. Argument mining with structured SVMs and RNNs[C]//Proceedings of the 55th Annual Meeting of the Association for Computational Linguistics, Volume 1. Vancouver: Association for Computational Linguistics, 2017: 985–995. DOI: 10.18653/v1/P17-1091. 来源

[47] BAO J, HE Y, SUN Y, et al. A generative model for end-to-end argument mining with reconstructed positional encoding and constrained pointer mechanism[C]//Proceedings of the 2022 Conference on Empirical Methods in Natural Language Processing. Abu Dhabi: Association for Computational Linguistics, 2022: 10437–10449. DOI: 10.18653/v1/2022.emnlp-main.713. 来源

[48] BAO J, JING M, DONG K, et al. UniASA: A unified generative framework for argument structure analysis[J]. Computational Linguistics, 2025, 51(3): 739–784. DOI: 10.1162/coli_a_00553. 来源

[49] ZHANG Z, WANG Q, DING K, et al. Improving synthetic data generation for argument mining via adversarial reinforcement learning[EB/OL]. arXiv:2610.07699v1, 2026[2026-10-10]. DOI: 10.48550/arXiv.2610.07699. 来源

[50] POIAGANOVA M, STEDE M. From debates to diplomacy: Argument mining across political registers[C]//Proceedings of the 12th Argument Mining Workshop. Vienna: Association for Computational Linguistics, 2025: 205–216. DOI: 10.18653/v1/2025.argmining-1.20.来源

[51] SVIRIDOVA E, YEGINBERGEN A, ESTARRONA A, et al. CasiMedicos-Arg: A medical question answering dataset annotated with explanatory argumentative structures[C]//Proceedings of the 2024 Conference on Empirical Methods in Natural Language Processing. Association for Computational Linguistics, 2024: 18463–18475. DOI: 10.18653/v1/2024.emnlp-main.1026.来源

# 附录 A 数据处理与复现协议

## A.1 坐标与结构数据

输入处理同时维护原文字符、评价 token 和模型子词三个坐标层。字符层用于槽位替换，评价 token 用于组件及完整关系匹配，模型子词用于表示读出。保存每层的版本和映射，对跨度往返、特殊 token 排除、空白与标点处理进行检查。改变分词器或规范化规则后重新构建映射，不复用不兼容的坐标缓存。

增强变体以源文档为分组单位，记录源 ID、完整文本哈希、改写槽位、组件对应、全部关系输运结果和拒绝原因。多前提关系同时保存完整源集合，往返序列化后按原生超边检验。重复文本共同分组，异常文档的处理在数据划分冻结前记录。

## A.2 配置与结果的关联

表 A-1 给出数据、配置、候选和结果的关联字段。历史存档与当前结果采用独立身份；跨章复用相同语料、方法和种子下的记录，避免重复汇总或另选较高分数。

表 A-1 复现材料的关联字段

| 材料 | 必需关联 | 用途 |
| --- | --- | --- |
| 数据与划分 | 版本、文档 ID、全文哈希、折 ID、异常清单 | 确认训练开发测试用途及重复分组 |
| 增强集合 | 源 ID、提示、生成器版本、接受拒绝记录、标注映射 | 区分增强条件及监督来源 |
| 模型与配置 | 权重 revision、代码版本、参数、随机种子、环境 | 确定配置身份及重复实验 |
| 候选与评分 | 初始图、候选来源、语义键、评分器及校准版本 | 检验候选覆盖与固定评分条件 |
| 事务与求解 | 尝试及提交轨迹、约束、预算、状态与 gap | 重放修改并核对停止条件 |
| 评价与统计 | 评价器版本、逐例预测、TP/FP/FN、种子聚合与重采样 | 复算严格指标、区间和成本 |

历史表的划分、评价脚本和“±”含义按其原始记录核准。附录 E 的分类别结果差异需由相应 run ID 解释，不能用另一配置的分数填补。新增验证使用 2.6 节公共协议，跨表复用结果行必须来自同一运行集合。

## A.3 其他语料与语言的范围

本文主比较范围仍为英文 AAEC 和 CDCP。补充试验纳入 ArgUNSC 的安理会发言[50]及 CasiMedicos-Arg 的英文病例解释[51]，分别保留原生跨度、类型与二元关系。前者的 Claim／Premise 按论证作用区分，后者将一般医学知识标为 Claim、病例特定观察标为 Premise；名称相同不意味着可合并标签或分母。ORCHID 面向中文辩论的目标无关立场检测和论辩对话摘要[28]，IAM 整合多项论辩挖掘任务并使用英文资源[29]。本稿只报告已经完成兼容转换与严格评价的范围，不由单语补充试验推断中文或多语言效果。

## A.4 本版参考规约与配置身份

方法配置采用单中心、受保护候选、分步提交和松弛 Oracle，并保留允许自匹配、条件反向与外层提议预算规则。正式方法参考配置身份沿用 1010-v1-global-review；文稿版本为 1011-v10。新增 Luna 固定规模试验另有运行身份和评分接口调整（D.11—D.12），不追溯改写参考配置或历史输出。生成参数、对象评分、外层预算及实际成本字段分别登记，计算条件见表 2-2，参考规则见表 A-2。

表 A-2 本版参考配置

| 模块 | 固定参考值或规则 | 解释范围 |
| --- | --- | --- |
| 中心与生成 | 种子 17；每文档 1 中心、4 次尝试、最多 2 变体 | 全文哈希与组件键参与排序 |
| 中心匹配 | 同组件数、入关系数；长度差／参考长度≤20% | 允许自匹配；有效参考文档无 unmatched |
| 补充跨度 | 头候选 64；长度≤64 评价 token；最终补充 64 | 保护对象不受该上限裁剪 |
| 规则扩展 | 边界各±1；基础相邻合并；内部边界切分 | 仅扩展一次，不递归 |
| 补充关系 | 源成员≤3；补充完整槽位 4096 | 双槽位保留且合法才反向；长超边受保护 |

表 A-2（续）

| 模块 | 固定参考值或规则 | 解释范围 |
| --- | --- | --- |
| 组件事务 | 冲突闭合后总编辑≤3 | 允许五种声明形态，纯关系另列 |
| 队列与额度 | 六类轮转；批长 6；每轮外层尝试 32、接受 3 | 最多 4 轮，总 128 / 12；同状态游标跨轮保留 |
| 累计编辑 | 组件 24；关系 96 | 分别累计，不使用最终净变化替代 |
| 参考接受门 | 分项非降；总差>0.01；数值容差 $10^{-9}$ | 容差仅处理数值误差，不放宽严格总门 |
| 固定效用配置 | κC=κR=1，wC=wR=1 | 分项接受门与成本口径共同固定 |
| 执行资源 | 上下文 8192；补充槽位 4096；局部总时限 3 / 5 秒 | 尝试、接受、编辑、复核与提交资源分别检查 |

组件与关系对象分应以至少双精度缓存进行确定排序；非有限分数返回评分失败，不按零分继续。规范键使用 UTF-8 规范 JSON，集合先排序；软件版本与序列化版本写入配置身份。预枚举上限用于阻止资源失控，超限返回候选构造失败而不是生成金标有利子集。上述资源失败保留该文档并按公共失败规则评价。顺序方法的批内排序只看首个实际决策阶段，外层一次接受最多两次阶段提交；配套阶段可越过已达的外层接受上限，但不得突破实际资源或编辑上限。求解器的多目标破同分与超时身份依 4.5.1 节保存。

## A.5 结果登记与跨章复用

结果键由语料、方法、种子和对象层次组成。第三章 T1、第四章 I0 和第五章 T1 + I0 引用同一键；第四章 BR-J 与第五章 T1 + I1 同样复用。document_counts.csv 保存逐文档 TP、FP、FN，scenario_results.json 汇总均值、标准差、配对区间和交互差，scenario_manifest.json 绑定生成程序与结果文件的 SHA-256。表格先读取原始精度计算差值，最后统一保留两位小数。

审计判定、对象概率及标签各自保存，漂移、一致性、Brier 和 ECE 均从对应记录汇总。成本字段按生成、评分、求解与重生成分项登记，不将 GPU 小时、CPU 秒和 token 混为同一单位。附录 E 采用其原有历史身份，不回填当前结果键。

附录 D.3 另以 research_0920/results 中的既存运行清单、候选预测与编辑记录为输入，由 _revision_1010_v8/analyze_saved_diagnostics.py 复算；diagnostic_supplement.json 保存输入哈

希、判定口径和汇总，六份 diagnostic_*.csv 保存文档错误、端点、覆盖、提议、策略及对象变化统计。该入口不生成第三至第五章的估算计数，也不进行模型训练或求解。

真实试验入口分别为 research_1010_v7_luna、research_1011_luna_expanded 及其 w02—w07 分波目录、research_1011_luna_expansion_analysis 与 research_1011_v10。历史原 16 篇按字节保留；合并文件逐篇连接源波次。新增目录保存发布文件哈希、转换审计、预先冻结样本、预测与评分提示、候选、输入 / 输出冻结及逐事务记录。评价与重放文件保存严格计数、原生源核对和差异清单。逐例原文、金标、前后对象及核验入口见配套实测分析记录，不将合并汇总当作新增模型调用。

## A.6 序列化、坐标与候选构造细则

以下人为构造的 token 序列为“Libraries / should / stay / open / longer / . / Students / need / study / space / .”。编码只说明坐标与端点引用，不作为效果证据。

```
{
  "components": [
    {"id": 1, "type": "Claim", "span": [1, 5]},
    {"id": 2, "type": "Premise", "span": [7, 10]}
  ],
  "relations": [
    {"sources": [2], "target": 1, "type": "Support"}
  ]
}
```

统一使用 sources 列表可以容纳超边，但多前提支持还要求候选构造、评分训练、优化器和评价器采用相同语义。字段顺序固定为已声明的 ID、type、span 等顺序；第三章类型门控仅使用已经生成的前缀，不读取未来标签。

独立跨度头使用全文编码器和两个线性层，分别预测评价 token 边界的起点与终点概率；监督来自训练集全部金标跨度。子词表示按 offset mapping 聚合到评价 token，空映射报错，训练采用起止两项二元交叉熵均值。内部解码采用零基半开区间，枚举$0 \le s < e \le n$且$e-s \le L_{span}$，以两端对数概率之和排序，同分按$(s,e)$升序；输出统一转换为 2.1 节从 1 开始的闭区间$[s+1,e]$后才构造评价语义键。此分数仅用于候选召回与裁剪，不是完整对象正确率。跨度头不输入金标答案，在 OOF 时与生成器使用相同持出隔离。

参考有限扩展对受保护跨度及跨度头前$N_{head}$个输出只执行一次：起止位置分别在$\{-1,0,1\}$内扰动；按位置排序，对相邻且不重叠的基础跨度加入合并区间；对基础跨度每个内部评价 token 边界加入左右切分区间。所有新跨度均通过坐标和最大长度检查，不递归使用新跨度继续扩展。去重后的补充跨度重新由同一边界头评分，按分数降序、坐标升序保留前$N_{supp}$个；多来源并存，不只保留获胜来源。受保护长跨度不受补充长度上限裁掉。

对$u \in U$保留协议合法的全部类型，构成$\mathcal{V}=\{(u,t): t \in \mathcal{T}(u)\}$。NULL 表示不选择该跨度。同一跨度至多一个类型，不允许重叠的语料按两两交叠判定冲突，不用传递连通块替代两两兼容。组件键由文档哈希、坐标版本、起止位置及类型组成；类型或边界变化生成新对象。原始字符、评价 token 与模型子词保持独立映射，显示 ID 不参与评分键。

# 附录 B 评分与事务执行记录

## B.1 数据与模型身份

运行级材料按表 A-1 关联至同一 run ID，本附录只补充文档级评分与事务轨迹。每条轨迹通过源文档 ID 连接原文、坐标映射、候选缓存、评分缓存和评价配置；增强变体仍归属于唯一源文档，不重新划分数据。

## B.2 评分与接受轨迹

每个文档保存原始候选输出、共同合法化结果、MCR 分量、初始图、固定候选宇宙及其来源。每次尝试记录删除集合、加入集合、冲突扩张、关系闭合域、原状态和求解后状态、组件与关系效用差、语义编辑成本、求解状态和剩余预算。拒绝原因分别标为非法、候选不可达、不可行、分量下降、总增益不足、预算超限或求解失败。

分数缓存以完整语义对象和评分器版本为键，不使用可变的显示编号。若执行中改变因素宇宙、评分器、校准温度或效用系数，则应作为新的实验配置，原有固定目标性质不再直接适用。离线真实 TP/FP/FN 差只进入审计记录，不作为在线接受输入。

## B.3 回退与预算

BR-J 执行语义遵循 4.5.2 节，顺序方法遵循 4.6.1 节。每条日志分别登记 outer_attempts、outer_accepts、component_stage_attempts、relation_stage_attempts、solver_calls 和各阶段 commits；外层一次尝试不随配套阶段重复增加，第一阶段成功即占一个接受名额。按阶段记录完整合法图及组件、关系累计编辑账本，保留计算资源的期初余额、本次消耗与期末余额。阶段二失败或启动前资源耗尽时不撤销阶段一；删边后再次加入分别计费。拒绝尝试不消费图编辑量，但其实际求解、模型调用及 token 不退还。状态游标与拒绝缓存跨轮延续，未见状态重新枚举，已有状态恢复其游标和缓存。

每类内部按固定组件效用差降序、对象编辑数升序和规范化提议键升序排序；纯关系类第一项改用该槽位在忽略整图耦合约束时的关系效用增量。此量只用于排序，不作为接受判断。六类按上述顺序轮转，每次从非空类取一个，参考批长为 6。提议键由状态哈希、排序后的$D,B$和完整槽位集合组成，重复提议只评估一次；拒绝缓存也包含状态身份。组件改变后可在新状态重新枚举旧状态非法的槽位，但不能扩张冻结候选宇宙。

继续评估新提议需要剩余尝试名额和评估资源；提交已评估候选需要剩余接受名额、组件与关系编辑预算以及复核和提交资源，提交本身不再增加尝试。达到外层尝试上限后不启动新评估，当前批次已经合格的候选仍可择优提交。无法完成复核或安全提交时保留最后完整合法图，分别登记停止原因，已消费计算成本不退回。

同一状态的队列游标、已尝试集合和拒绝缓存跨轮保留；每轮只重置本轮计数。首批全拒时继续余批，当前状态的声明队列耗尽且无合格项才停止。提交到未见状态后建立独立队列与游标，已有状态按状态键续用缓存；仅改变轮号不允许重评同一状态的同一提议。计算与调用成本对所有尝试计费，组件和关系编辑仅对实际提交的删增累计计费。秒数、调用和 token 限制必须由正式运行清单冻结。

## B.4 实现一致性测试

### B.4.1 已执行的构造检查

本版保留前版 v1 机制程序，以及中心匹配、条件反向、分阶段账本、带坐标拆合和状态队列接口程序的构造检查记录。输入、断言、结果及范围见附录 D.4 和 D.6。接口程序中的阶段成败与资源单位由 fixture 预设；破同分检查使用有限候选排序，均不是实际 ILP、模型或持久化事务测试。

### B.4.2 训练与求解接口

训练与求解接口包括十类：分词器三层坐标往返；回答前表示的输入隔离；共享 LoRA、冻结基础权重及专项分支的梯度连接；连续提示和门控；空域、变体数与末批归一化；候选保护、扩展与完整槽位裁剪；队列跨轮和状态变更；ILP 可行性、目标与预算；无解、两类超时、提交失败及中断恢复；严格组件和原生超边计数。每类保存输入、配置身份、输出和错误原因，使模块语义与方法定义对应。

求解器验收还须覆盖等效用解、非有限分数、比较容差和线程重复性。真实自动求导应采用产生非零损失的受控输入，同时检查计算图连接、参数允许更新状态和梯度范数；单个零梯度样例不足以判定断路。计算图连接、参数更新资格和数值梯度共同决定接口判定，求解可行性与最优性分别登记。

### B.4.3 外层预算与提交的边界判定

表 B-1 规定调度器的验收语义，与算法 4-1、4-2 及顺序方法的阶段账本保持一致。它是实现与测试应共同满足的判定表；独立参考函数通过不表示生产调度器已经完成这些分支的验收。

表 B-1 提议评估与提交的预算判定

| 边界情形 | 允许动作 | 账本与返回状态 |
| --- | --- | --- |
| 最后一次允许尝试得到合格候选 | 接受、编辑和安全提交资源足够时仍可提交 | 尝试已计费，不再要求新的尝试名额 |
| 尝试额度为 0，尚未启动新提议 | 不得评估新提议 | 保留当前图；已评估候选另按提交条件处理 |
| 接受额度为 0，拟启动新的外层接受 | 不得提交新的外层提议 | 已产生的计算消耗不退还 |
| 累计编辑或安全验证、提交资源不足 | 不得开始不能完成安全提交的动作 | 保留最近完整合法图，已耗计算不退还 |
| 顺序阶段一刚占满接受额度 | 允许同一外层提议的配套阶段二，仍检查编辑和实际资源 | 不增加外层接受数；阶段二失败保留阶段一 |

验证日志分别给出评估前余额、评估消耗、提交前余额和提交结果，使“不能继续评估”与“不能提交已评估结果”可独立核对。阶段二属于已有外层接受；该例外不能被用于启动另一个提议。

## B.5 案例的统一记录格式

成功恢复、错误接受、错误拒绝、候选不可达和预算耗尽使用相同字段，保留原文、完整对象、初始图、候选及决策轨迹。案例解释与总体计数相互补充，不以单个案例的可解释性估计错误频率。第四章按这一格式组织案例。

（1）原文与金标准。给出数据集、固定划分、真实文档 ID、相关原文及上下文，列出金标组件的跨度、类型和完整关系；CDCP 逐项列出超边源集合。金标准仅用于事后评价，不进入测试时的提议、评分和接受过程。

（2）初始状态与候选。展示同一合法初始图、每个候选的来源与完整语义键，并注明遗漏对象是否在固定宇宙中、所需对象能否兼容共存。无法构造所需完整关系时，应将候选缺失与局部邻域不可达分别标出。

（3）顺序与联合对照。固定原文、检查点、候选、评分和资源口径，分别列出顺序组件修正及关系重建的真实步骤，以及 BR-J 的完整事务。对照中的中间状态、拒绝和耗时必须来自各自运行日志；缺少一侧日志时标记待对照运行，不推演为已经发生的结果。

（4）删除与新增对象。分别列出主动删除集合、冲突补入的删除集合、新增组件，以及所有删除和新增的完整关系。对边界或类型变化明确旧、新端点身份，对入边、出边和原 NONE 槽位逐一标明处理结果，同时展示事务外保持关系及必要的扩域。

（5）代理判断与真实变化。记录修改前后的组件效用、关系效用、总效用及其差值，列出合法性、分项门、严格总效用门和预算检查结果；同时分别报告组件与关系的 TP、FP、FN 及 ΔTP、ΔFP、ΔFN，给出严格指标变化。事务计数与文档最终净变化并列，避免将重复修改或单元分组差异当作恢复收益。

（6）接受、拒绝与失败归因。成功恢复记录应指出实际新增的正确对象及保留的原正确对象；错误接受记录说明代理门通过后损失了哪些真实对象；错误拒绝记录保留被拒状态的真实评价及触发门限。候选不可达和预算耗尽分别记录缺失对象、已尝试队列、剩余额度和最终返回图。每例均保留回退状态、求解是否超时及其间隙，使运行过程可以重放。

## B.6 固定评分性质的证明与构造

本节对应 4.5.3 至 4.5.5 节，分别说明精确差值、集合动作的表达边界与有限终止。

两状态共有对象的得分相同，在求差时相消。依赖闭合将端点变化引起的旧关系失效、新关系加入纳入差集，因而不会漏算关系项。该性质来自固定可分解目标，不意味着模型已经正确判断自然语言语义。若搜索中改变对象分数，则上述差值计算不再适用。

构造两个互不重叠的旧组件 $a=[0,4)$、$b=[5,10)$，新跨度 $c=[0,10)$ 恰为二者包络，满足合并的坐标条件。取 $\kappa_C=0.4$，$q_C(a)=q_C(b)=0.3$，$q_C(c)=0.6$，对应效用为 $0.2,0.2,0.8$。这些边际与合法分布 $0.3\{a,b\}+0.6\{c\}+0.1\varnothing$ 相容。初始集合 $\{a,b\}$ 的效用为 $0.4$：单独删除任一组件降分，直接插入 $c$ 或仅替换其中一个组件产生冲突；整体 $\{a,b\}\to\{c\}$ 则合法且增分 $0.4$。取 $w_C=1$、$0<\delta<0.4$ 并保持关系不变，即满足全部效用门。若一对一提议通过冲突闭合同时删除两个旧组件，它事实上已扩展为上述集合事务，不再属于受限的单对象动作。

证明：若回到某个已访问状态，该状态的固定效用应与先前相同；但每次接受均严格增分，形成矛盾。有限状态数进一步排除无限无重复序列。实际算法还受到尝试、时间和编辑预算约束，因预算停止不代表局部最优或全局最优。

# 附录 C 成果归属与研究声明

## C.1 前期共同成果

Chen Tang、Min Peng 和 Gang Tian 的 ICIC 2026 公开论文构成本研究的直接基础[34]。已公开机制与本论文深化内容的对应关系见表 1-2，前期数值保留在附录 E。前期成果的引用及结果归属不因作者参与该工作而省略。

## C.2 数据与材料可得性

AAEC 和 CDCP 的数据使用遵循原始发布条款[2][3]。公开获取不等于允许任意再分发，公开复现材料需按许可提供下载指引或必要派生文件，避免附带访问凭据、不必要的个人信息及未获许可的语料副本。

ArgUNSC 所用作者仓库含 MIT 许可，CasiMedicos-Arg 数据卡标注 CC-BY 4.0；本地清单同时保存许可文本、发布版本和文件哈希[50][51]。许可记录用于追踪本次获取条件，正式公开材料仍须保留作者引用及适用归属说明。后者仅用于论辩结构抽取，不作为诊疗建议或医学正确性评价。

本地材料包含结果生成程序、统一配置、逐文档计数、审计判定、评分记录、图表数据与修订索引，入口见附录 A.5。数学构造材料保留在附录 D，用于复算性质和边界。材料的公开范围与存放入口由作者根据语料许可及成果归属确定。

## C.3 研究辅助与伦理说明

研究辅助用于文献定位与核对、方法讨论、论证边界检查、参考代码、文字修订及排版。作者负责独立审阅方法、引用和代码，并对研究事实、贡献归属及结果解释承担责任。自动生成的文字、理论例子和软件测试不作为人工标注或正式目标系统实验。本文另将明确请求模型、输入及输出均已冻结的 Luna 任务作为模型行为记录；其启发式评分未被称为人工审阅、独立专家判断或校准概率。

涉及人员参与、语料再使用及可能的敏感信息时，应按研究内容履行适用的机构程序。判定规则、分歧与裁决共同构成审计记录；一致性系数不能代替对语义标签的独立判断，本文不据此作机构审批或豁免声明。

## C.4 成果记录与署名责任

方法、程序、数据记录和论文文字采用版本关联，引用前期共同成果时保留原作者及成果身份。学位论文原创性声明、使用授权、署名与签字使用学校适用表单，由相应责任人确认；研究辅助不代替作者对事实、引用和结论的责任。

# 附录 D 前期实验基础与轻量诊断

## D.1 前期结果的使用范围

ICIC 公开论文报告原版 Full 在 AAEC 上的组件 F1 为 83.71、关系 F1 为 64.83，在 CDCP 上分别为 76.45 和 38.17[34]。这些成绩属于前期系统及原评价协议，用于说明研究基础，不支持第三章新增增强、第四章闭合事务或严格原生超边的效果结论。原表与补充记录逐项保留在附录 E。

附录 E.1 的分类别组件表来自旧稿补充记录，未在此前核对的 ICIC 公开表中找到对应，其 Single-Pass 组件 F1 为 81.67，与主表 77.82 不同。材料未绑定前，不据此估计增强增量。原版行为记录中的组件替换与类型修改归于 BR-O，不移作 BR-C 或 BR-J 的动作分布。

## D.2 训练集内诊断设置

前期 CPU 诊断纳入 AAEC 322 篇，拟合、校准、审计部分分别为 191、65、66 篇；CDCP 在记录排除文档 00411 后纳入 580 篇，对应 348、116、116 篇。划分按完整文本哈希分组，测试文件不参与解析、拟合、选择或评分。该诊断使用固定版本镜像和划分文件，数据异常与坐标映射问题保留在独立日志中。这些数量描述前期轻量诊断，和表 2-2 的比较配置分开，不用于两项新增方法的效果归因。

诊断采用稀疏线性模型生成组件与候选，初始 typed component F1 为 AAEC 25.42、CDCP 4.89。尤其 CDCP 存在较强过度分割，因此该错误分布不能代表前期 LLM 系统。诊断中的关系分类给定金标跨度与类型，且限于单前提，不包含端到端完整关系效用、原生多前提修正、闭合事务或 ILP。原记录中的收敛警告也限制了其解释范围。

## D.3 诊断的启示与限制

本节补充统计来自 2026 年 9 月 20 日已经完成的 CPU 轻量诊断。此次读取原始语料压缩包、固定划分、182 篇审计文档的候选预测及 38928 条编辑提议，核对文本哈希后复算；未重新拟合模型、调用目标大模型或执行 ILP。AAEC 的 66 篇文档对应 64 个全文哈希组，CDCP 的 116 篇对应 116 组。下列观察仅描述该次弱模型运行，不并入第三至第五章的估算主表，也不替代目标模型诊断。

初始组件先匹配跨度与类型均正确的对象，再匹配同跨度异类型对象；剩余对象按 token 交并比不低于 0.5、交并比降序及坐标类型键破同分进行一对一贪心配对。该事后描述规则沿用 H.1 的诊断口径，不改变严格评价。边界配对又按类型是否相同分开；未配对项只表示在本规则下未匹配，不能直接认定为独立的遗漏或多检成因。

表 D-1 初始组件的错误配对分解（既存 CPU 诊断）

| 计数项目 | AAEC | CDCP |
|---|---|---|
| 严格跨度与类型命中 | 340 | 86 |
| 同跨度异类型配对 | 79 | 28 |
| 边界差异且类型相同 | 238 | 178 |
| 边界与类型均有差异 | 128 | 137 |
| 未配对金标组件 | 201 | 294 |
| 未配对预测组件 | 904 | 2365 |
| 金标组件总数 | 986 | 723 |
| 初始预测组件总数 | 1689 | 2794 |

表 D-1 中，严格命中、三类错误配对及未配对金标之和等于金标总数；将末项换成未配对预测，则等于预测总数。每个错误配对同时贡献一个 FP 和一个 FN，不能把两者当作两次独立事件。由此还原的 AAEC 计数为 TP=340、FP=1349、FN=646，CDCP 为 86、2708、637。

按原生金标关系检查初始端点，AAEC 的 627 条关系中，全部端点跨度和类型正确的有 43 条（6.86%），跨度齐全但至少一个类型错误的有 116 条（18.50%），至少一个跨度缺失的有 468 条（74.64%）；CDCP 的 200 条对应 4 条（2.00%）、1 条（0.50%）、195 条（97.50%）。CDCP 其中 19 条为多前提关系。这一互斥分组仅检查端点条件，没有判断关系标签和方向是否预测正确；低正确率也反映弱模型的过度分割，不能外推为目标 LLM 的错误比例。

候选覆盖按保存的跨度排序依次截取 0、64、128、256、512 个补充位置，与初始跨度去重合并。精确跨度覆盖的分母为 986 / 723 个金标组件，全部端点跨度覆盖的分母为 627 / 200 条原生关系；两者均不要求候选类型或关系标签正确。候选均值和 P95 按文档计算，有向对均值逐文档按 n(n−1)计算后取均值，表示未施加类型及合法性约束的二元组合规模，不是实际评分对象数或实测耗时。

表 D-2 补充跨度预算与候选覆盖（既存 CPU 诊断）

| 语料 | 补充上限 | 跨度覆盖% | 端点覆盖% | 候选均值／P95 | 有向对均值 |
|---|---|---|---|---|---|
| AAEC | 0 | 42.49 | 25.36 | 25.59 / 35.75 | 660 |
| AAEC | 64 | 90.16 | 87.72 | 89.59 / 99.75 | 7968 |

| 语料 | 补充上限 | 跨度覆盖% | 端点覆盖% | 候选均值／P95 | 有向对均值 |
|---|---|---|---|---|---|
| AAEC | 128 | 95.84 | 95.22 | 153.59 / 163.75 | 23467 |
| AAEC | 256 | 97.57 | 97.45 | 281.59 / 291.75 | 79043 |
| AAEC | 512 | 98.68 | 99.04 | 537.59 / 547.75 | 288497 |
| CDCP | 0 | 15.77 | 2.50 | 24.09 / 57.50 | 894 |
| CDCP | 64 | 94.19 | 89.50 | 88.09 / 121.50 | 8009 |
| CDCP | 128 | 96.82 | 94.50 | 151.74 / 185.50 | 23240 |
| CDCP | 256 | 98.62 | 98.00 | 278.41 / 313.50 | 77887 |
| CDCP | 512 | 98.89 | 98.00 | 526.66 / 569.50 | 280216 |

从 128 增至 512 个补充跨度，AAEC 覆盖增加 28 个组件，CDCP 增加 15 个；对应二元有向组合均值约由 2.35 万 / 2.32 万升至 28.85 万 / 28.02 万。该统计展示覆盖与组合规模之间的取舍，但没有测量这些组合的实际枚举、完整超边评分或求解成本；第四章候选保护和裁剪前资源诊断仍须按目标实现执行。

候选入池与一步可达进一步分开。这里的“初始跨度缺失”不含同跨度异类型；在 128 补充池内，逐个遗漏金标跨度统计它与当前预测组件的重叠数，并在保存的编辑提议中查找该完整类型对象。原诊断仅允许插入，或替换至多一个冲突旧组件；与两个及以上旧组件重叠时不会枚举该加入动作。下表尚未检查接受阈值、关系重建及多步路径，不能视作最终恢复率。

表 D-3 已入池遗漏跨度的一步动作限制（既存 CPU 诊断）

| 语料 | 初始跨度缺失 | 进入 128 池 | 重叠至少 2 项 | 一步可加入 | 可加入／入池% |
|---|---|---|---|---|---|
| AAEC | 567 | 526 | 268 | 258 | 49.05 |
| CDCP | 609 | 586 | 530 | 56 | 9.56 |

AAEC 入池的 526 个遗漏跨度中，268 个（50.95%）受到上述一步动作限制；CDCP 为 530 / 586（90.44%）。这支持在该弱模型诊断中继续检查集合动作，但未证明目标 LLM 存在相同规模，也未证明 BR-J 能够合法恢复这些对象。仅扩大候选池不会自动解除当前动作的重叠限制。

全部 38928 条编辑提议均依据保存的修改前后对象与金标重新计算 TP、FP、FN 和逐文档 F1，复算值与原记录一致。表 D-4 的“升 / 平 / 降”按逐文档 F1 变化定义；“平”不等于对象完全不变，也不等于对汇总 micro-F1 没有影响。提议来自同一批文档且相互依赖，因此以下是组成统计，不能将提议条数当作独立样本量。

表 D-4 全部编辑提议的逐文档效果组成（既存 CPU 诊断）

| 语料与动作 | 提议数 | F1 升 | F1 平 | F1 降 | 升% |
|---|---|---|---|---|---|
| AAEC 插入 | 1224 | 28 | 9 | 1187 | 2.29 |
| AAEC 删除 | 1689 | 1328 | 21 | 340 | 78.63 |
| AAEC 换类型 | 3378 | 79 | 2619 | 680 | 2.34 |
| AAEC 换跨度 | 7857 | 230 | 4678 | 2949 | 2.93 |
| CDCP 插入 | 0 | 0 | 0 | 0 | — |
| CDCP 删除 | 2794 | 1389 | 1319 | 86 | 49.71 |
| CDCP 换类型 | 11176 | 28 | 10804 | 344 | 0.25 |
| CDCP 换跨度 | 10810 | 56 | 8674 | 2080 | 0.52 |

非删除提议中，AAEC 有益提议为 337 / 12459（2.70%），CDCP 为 84 / 21986（0.38%）；分别有 65 / 66 篇和 52 / 116 篇文档至少存在一个此类提议。较多文档存在可改善提议，并不意味着评分器能选中它。CDCP 没有插入提议，是该次初始分割与动作冲突规则共同形成的观察，不能据此判断真实文本不存在遗漏组件。

策略复算固定原校准阈值 4.0，不在审计文档上重新选阈值。主策略允许删除；禁用删除对照在其他保存提议中重新选择最高分且超过同一阈值的一项，每篇至多接受一次。置信区间是本次事后重分析：按全文哈希组配对重采样 2000 次，种子 10108，每次汇总计数后计算 micro-F1。AAEC 的重复文本共同抽取；区间仅反映这一次已保存模型的文档组不确定性，不包含重训种子变化，也不是多个比较校正后的确认性检验。

表 D-5 固定阈值策略的组件效果（既存 CPU 诊断）

| 语料与策略 | 接受数 | TP／FP／FN | 组件 F1 | ΔF1 | 95%区间 |
|---|---|---|---|---|---|
| AAEC 初始 | — | 340 / 1349 / 646 | 25.42 | — | — |
| AAEC 主策略 | 66 | 340 / 1283 / 646 | 26.06 | +0.64 | [+0.58, +0.71] |
| AAEC 禁删除 | 33 | 343 / 1346 / 643 | 25.64 | +0.22 | [+0.00, +0.51] |
| CDCP 初始 | — | 86 / 2708 / 637 | 4.89 | — | — |
| CDCP 主策略 | 115 | 86 / 2593 / 637 | 5.06 | +0.17 | [+0.12, +0.23] |
| CDCP 禁删除 | 0 | 86 / 2708 / 637 | 4.89 | +0.00 | [+0.00, +0.00] |

AAEC 主策略的组件 F1 由 25.42 升至 26.06，CDCP 由 4.89 升至 5.06；接受的 66 / 115 次操作均为删除。禁用删除后，AAEC 接受 32 次换跨度与 1 次换类型，新增 3 个严格正确对象，F1 提高 0.22 个百分点且区间包含 0；CDCP 没有提议超过同一阈值。该对照没有重新校准，回答的是在原评分和阈值下移除删除选项的结果，不是禁用删除方案经独立调优后的最佳性能。

表 D-6 修改前后的严格组件对象变化（既存 CPU 诊断）

| 语料与策略 | 新增正确 | 损失正确 | 新增错误 | 移除错误 |
|---|---|---|---|---|
| AAEC 主策略 | 0 | 0 | 0 | 66 |
| AAEC 禁删除 | 3 | 0 | 30 | 33 |
| CDCP 主策略 | 0 | 0 | 0 | 115 |
| CDCP 禁删除 | 0 | 0 | 0 | 0 |

表 D-6 按文档内的完整跨度与类型键比较前后集合，新增 / 损失正确对象之差等于 ΔTP，新增 / 移除错误对象之差等于 ΔFP。主策略没有新增正确对象，也未损失原有正确对象，收益来自移除 66 / 115 个错误预测；AAEC 禁删除对照虽然净增 3 个 TP、净减 3 个 FP，同时新增 30 个错误对象并移除 33 个错误对象。因而净成绩改善不能解释为每次修改都正确，单看净 FP 也会隐藏错误对象之间的替换。这里仅分析单次 CPU 诊断的组件，不承担第五章目标模型四格互补性的证据作用。

运行清单记载该次诊断使用 Python 3.9.6、NumPy 1.26.4、SciPy 1.13.1 和 scikit-learn 1.6.1，在 arm64 CPU 上单线程执行，完整诊断耗时 29.03 秒；此时间包含两语料的诊断流程，不能换算为本文系统的单文档推理延迟。此次校验了语料压缩包、分组划分、程序及协议哈希，并精确重放两语料的两项固定阈值策略。新增复算脚本和逐文档统计与原始运行分开保存，记录入口见 A.5。

上述补充提供了真实但有限的诊断依据：当前弱模型存在显著端点问题、入池后的动作限制，以及评分选择与潜在有益提议的差距。该模型与目标 LLM 的误差分布不同，关系评分又给定金标端点且限单前提；本节没有验证关系监督保持、完整关系重建、局部相对全局的采用价值或目标模型的四格对象作用。D.7—D.10 的 148 篇 Luna 样本仍来自本诊断划分，模型及运行身份分开，不能与 182 篇相加为独立文本总数。D.11—D.12 的另 96 篇使用单独冻结的语料或训练侧文档，亦按各自协议报告。软件可运行、形式性质成立与目标任务效果有效仍须分别验收。

## D.4 本版构造验证及复算入口

机制材料包含 19 项构造断言，接口材料包含 40 项有限断言，分别对应 validate_mechanisms.py 与 validate_interfaces.py 及其结果文件。这些数量是给定输入下的断言

记录数，不是覆盖率或研究贡献数量。材料使用组件、超边、字符区间、固定分数和阶段状态检查接口语义；输入、程序及配置哈希保存在_revision_1009_v2 中。

检查包括中心确定性、空集与回退、长金标超边、区域预算、字符输运、四类因素、逐源权重、候选保护、类别轮转、两两冲突、非接触新合法槽位、失效旧超边扩域、顺序与联合决策、第二阶段失败、Oracle 包含关系、精确最优值、累计与净成本、重复与空预测评价及 micro 目标反例。通过表示这些有限输入满足断言，不表示覆盖完整系统，也不等于单元测试覆盖率 100%。

参考程序使用半开字符区间；小图的三个关系对象和全部组件子集完整枚举得到 30 个合法图。编辑预算排除其中一个图，净预算集合为 29；最多三事务也达到 29，一事务仅 7。初始及一步的最佳关系计数为 TP=1、FP=0、FN=1；多步与全局为 TP=2、FP=0、FN=0。相应 66.67 及 100.00 由原始计数重算，金标和评分均为公开构造输入。该小图只含组件顺序及抽象删增形态，7／29／29 对应这一声明邻域。带坐标的拆合另用 D.6 的区间输入说明，二者不混合计算状态空间。

## D.5 micro 优化的计数反例

两个构造文档的金标关系数分别为 1000 和 10。文档 A 的可行计数为(1,0,999)或(0,0,1000)，文档 B 为(1,0,9)或(9,81,1)，括号依次为 TP、FP、FN。A 的逐文档最优选第一项，B 亦选第一项，因为 18.1818 高于 18.0000；两者汇总后 micro-F1 为 0.3953。若对整个计数集合优化，A 仍选第一项而 B 选第二项，汇总 micro-F1 为 1.8165。参考程序穷举四种组合核实该差别。

该反例证明逐文档最优不是语料 micro 最优的充分条件，不证明上述错误分布存在于目标语料，也不说明应在实际输出中使用金标。它仅用于确定 Oracle 实现必须优化共同计数目标。

## D.6 既有接口构造材料

中心匹配 fixture 覆盖全为结论角色、仅一个中心、存在合格非结论中心、区域超限与空组件；允许自匹配时有效参考区域均有匹配项。二十个固定文档键的构造记录用于检验自匹配统计分母，不估计真实语料比例。反向 fixture 分别记录双向保留、仅正向受保护、逆向裁剪、方向非法、端点类型替换和多源范围限制，不能把未入池或未入队归为评分拒绝。

顺序账本 fixture 将两阶段成功、阶段一拒绝、阶段二无解、无 incumbent 超时、阶段二前资源耗尽、关系编辑耗尽、纯关系操作与达到外层接受上限后的配套阶段分开。两阶段成功时外层尝试／接受各 1，组件／关系提交各 1，实际组件／关系编辑各 2；阶段二失败时保留新组件和空关系，关系删除成本 1 不退回。纯关系成功只有一次关系提交。人工资源单位仅验证余额约束，不换算成时延或 token。删后加回同一关系的累计编辑为 2、净编辑为 0。

跨度 fixture 采用半开字符坐标和完整类型键。旧组件[0,10)可拆为[0,4)与[5,10)，两段兼容且包络一致；越界、重叠或包络缩小分别拒绝，合法逆向合并通过形态检查。新增跨度若同时碰到窗口外旧组件，先补入删除集合再核查形态；名义插入覆盖两个旧组件时按 2→1 处理，单对象对照拒绝。预算不足不提交。入边、出边及超边的三个旧完整对象随旧端点删除，三个合法新关系重新计费，关系编辑总计 6。另检验插入不接触端点却使已选超边源连续性失效的最小扩域。

队列 fixture 证明其参考调度器首批全拒后可检查后批、同状态跨轮继续游标、未见状态重新枚举且去重，返回已有状态续用缓存。有限排序 fixture 验证效用、编辑数、规范键的顺序及非有限值拒绝。这些构造对应独立参考函数的输入输出，训练、求解和持久化接口按附录 B.4.2 分别组织。

## D.7 初始 Luna 试验的条件与来源

试验 AM-LUNA-20261010-001 实际执行于上海时间 2026 年 10 月 10 日至 11 日。每语料按文本长度四分位分层，每层按固定 SHA-256 顺序取 2 篇，共 16 篇；使用已有官方训练侧审计划分，不读取官方测试集。全部 16 篇与 D.3 的 182 篇按文档 ID 和全文哈希对应，为其子集。AAEC 原始训练文件在本地读取为 322 篇，CDCP 沿用排除 00411 后 580 篇的记录；该身份不改写表 2-2 的参考配置。模型可能在预训练时接触公开语料，未作污染排查。

请求模型为 gpt-5.6-luna，reasoning effort 为 low；实际快照、温度、采样种子和 token 数未由调度工具暴露，保持未记录。两项预测任务分别处理两语料，每篇在同一回答中给出 g0、g1，不视为独立抽样；另三项任务在新上下文中评分。五项任务不是五次底层 API 调用，生成与评分仍属同型号模型，未证明误差独立。提示仅提供盲输入，评分及输出冻结后本地评价才读取金标；这是输入与指令层面的隔离，共享文件系统没有操作系统级访问封锁。

候选合并两图的带类型跨度，并按预定规则补充去句末标点的边界变体。二元槽位在兼容候选之间枚举，多源槽位来自生成图及其端点变体，没有穷举论文主协议的全部多源组合。210 个组件均有显式评分；5404 个完整关系中 149 个被显式覆写，其余 5255 个使用事前固定默认值 0.05。这里的分数为启发式置信度，未训练、校准第四章的对象评分器。输入、评分、代码及预算均在金标评价前冻结，评价后不按结果改分或补候选。

两种修正策略使用同一合法初始图、候选池、评分及评价器。每个事务最多 3 个组件编辑，累计组件／关系编辑上限 24／96；每轮至多 32 次尝试、3 次接受，共 4 轮，批长 6。组件与关系的错误代价及权重均为 1，严格总效用门为 0.01；允许空图，不加无环约束。实际使用 SciPy 1.13.1 的 HiGHS MILP，单线程、每调用上限 0.25 秒，逐文档累计求解上限 AAEC 3 秒、CDCP 5 秒。RelationOnly 保持组件集合固定。

## D.8 初始批的完整计数与逐文档结果

表 D-7 Luna 试验的完整组件与关系计数（真实运行）

| 语料 | 配置 | 组件 TP／FP／FN | 关系 TP／FP／FN |
|---|---|---|---|
| AAEC | MCR-only | 2 / 38 / 124 | 0 / 32 / 82 |
| AAEC | RelationOnly | 2 / 38 / 124 | 0 / 0 / 82 |
| AAEC | BRJ-lite | 32 / 38 / 94 | 2 / 58 / 80 |
| CDCP | MCR-only | 17 / 17 / 32 | 1 / 17 / 16 |
| CDCP | RelationOnly | 17 / 17 / 32 | 0 / 4 / 17 |
| CDCP | BRJ-lite | 16 / 19 / 33 | 0 / 8 / 17 |

本试验以原文字符跨度、类型及完整关系键作精确集合匹配，未另行验证其与第二章正式 token 评价器的逐项等价性，故不与主表混算。金标组件共 AAEC 126 个、CDCP 49 个，金标完整关系分别 82 条、17 条。冻结池精确覆盖组件 33 / 126、19 / 49，完整关系 3 / 82、1 / 17；CDCP 两条多前提金标关系均未进入池。因此本次数据不能评价多前提恢复效果。RelationOnly 在 AAEC 移除 32 个初始关系 FP 且未恢复 TP，在 CDCP 损失 1 个 TP、移除 16 个 FP 并新增 3 个 FP；不能将较少输出直接解释为更好恢复。

BRJ-lite 的 AAEC 组件对象差集为新增正确 30、损失正确 0、新增错误 34、移除错误 34；关系为 2、0、58、32。CDCP 组件对应 0、1、6、4，关系对应 0、1、5、14。上述顺序按完整语义键比较初始与终态，不把累计编辑次数当作对象数。AAEC 的 28 个标点变体恢复及 CDCP 的真阳性损失均保留，不因总体分数或解释便利而删除。

表 D-8 全部 16 篇文档的初始至 BRJ-lite 结果及候选覆盖

| 文档 | 组件 F1 前→后 | 关系 F1 前→后 | 组件覆盖 | 关系覆盖 |
|---|---|---|---|---|
| AAEC 037 | 0.00→13.79 | 0.00→0.00 | 2 / 21 | 0 / 16 |
| AAEC 078 | 0.00→50.00 | 0.00→10.53 | 6 / 15 | 1 / 10 |
| AAEC 085 | 8.33→35.71 | 0.00→9.52 | 5 / 19 | 1 / 13 |
| AAEC 099 | 0.00→43.48 | 0.00→0.00 | 6 / 14 | 0 / 10 |
| AAEC 208 | 0.00→17.39 | 0.00→0.00 | 2 / 14 | 0 / 8 |
| AAEC 293 | 0.00→26.67 | 0.00→0.00 | 4 / 21 | 0 / 13 |

续表 D-8 全部 16 篇文档的初始至 BRJ-lite 结果及候选覆盖

| 文档 | 组件 **F1** 前→后 | 关系 **F1** 前→后 | 组件覆盖 | 关系覆盖 |
|---|---|---|---|---|
| AAEC 370 | 12.50→52.63 | 0.00→0.00 | 5 / 11 | 1 / 6 |
| AAEC 381 | 0.00→30.00 | 0.00→0.00 | 3 / 11 | 0 / 6 |
| CDCP 00396 | 40.00→40.00 | 0.00→0.00 | 1 / 3 | 0 / 0 |
| CDCP 00416 | 60.00→60.00 | 0.00→0.00 | 7 / 10 | 0 / 4 |
| CDCP 00428 | 50.00→40.00 | 0.00→0.00 | 1 / 2 | 0 / 1 |
| CDCP 00753 | 36.36→36.36 | 0.00→0.00 | 3 / 8 | 0 / 2 |
| CDCP 01024 | 0.00→0.00 | 0.00→0.00 | 0 / 4 | 0 / 0 |
| CDCP 01057 | 40.00→40.00 | 33.33→0.00 | 2 / 6 | 1 / 4 |
| CDCP 01282 | 54.55→36.36 | 0.00→0.00 | 3 / 7 | 0 / 2 |
| CDCP 01374 | 26.67→26.67 | 0.00→0.00 | 2 / 9 | 0 / 4 |

表 D-8 按原始文档 ID 列出全部样本，覆盖以完整跨度、类型及关系源集合 / 目标 / 标签严格匹配，分母为各文档金标数。CDCP 00396 的关系覆盖为 0 / 0，表示该文档无正关系，不计算覆盖百分比；其一个 FP 的标签更换见 4.6.7。零真阳性情形的 F1 统一为 0，配合 TP、FP、FN 解释。该表没有省略组件下降但关系不变的 00428、01282，也未把 16 篇结果扩展为语料基准。

## D.9 初始批的执行与解释边界

本次 32 个文档策略运行均返回合法图，共评估 1738 项提议，提交 139 项。1632 次 MILP 调用中 516 次返回最优、1116 次无可行解；后者包含 258 次最优解唯一性检查，不等于 1116 个运行失败。全部 139 项提交均完成最优值、最少关系编辑及唯一性核查。本次未发生超时或无 incumbent 回退，不能据这些成功轨迹声称相关失败分支已经历真实验收。金标评价前输出冻结，独立审核逐项检查原生标注、预算、事务外关系和效用门；本地重放 32 个运行得到相同终态及接受尝试序列。

轻量实现与正文仍有明确差异。候选生成没有采用本文训练骨干及完整两阶段抽取；多源枚举受生成图限制；评分没有使用训练及校准后的神经对象模型。六类队列虽保留轮转、冲突闭合与批内完整效用比较，类内却按规范对象键排序，而附录 B.3 按组件效用增益排序；有限尝试下这会改变访问路径。实现容差为 $10^{-8}$，并在严格总效用约束中加入 $10^{-6}$ 余

量，与正文统一规约需再核对。因此 BRJ-lite 始终单列命名，不把其轨迹视为算法 4-1 的完整等价实现。

AAEC 的 BRJ-lite 与 RelationOnly 修正阶段总耗时分别 0.434276、0.124535 秒，CDCP 为 0.120818、0.110312 秒；对应累计求解时间为 0.104983、0.060285、0.028174、0.038296 秒，均为各 8 篇总和。这些时间从冻结候选和评分输入后计量，不包含模型预测、评分、环境导入或完整准备成本，不能代入表 4-8 或作为端到端速度优势。当前没有同预算全局、单对象动作、分步策略、标点规范化专用对照，也没有训练四格，因而不能判定集合动作的增量、联合决策的必要性或局部策略的采用条件。

该初始批之后的探索性扩样与固定样本评分检查分别见 D.10 和 D.12；原 16 篇结果不重算、不回填。仅标点规范化、单对象及分步对照仍未完成。真实增强漂移与成对训练仍须独立完成。已有案例能够支撑“实际出现何种恢复或失败”的描述，不能替代“新增机制为何有效”的受控证据。

## D.10 探索性扩样与对象诊断

原 16 篇记录之后，先按相同长度分层和冻结哈希顺序扩为每语料 32 篇；随后仅对尚无严格关系 F1 正例的 CDCP，每层再取 4 篇、每波至多 16 篇，直至用尽 116 个唯一训练侧审计文本。最终 AAEC 32 篇、CDCP 116 篇；原 16 篇按字节复用，新增 37 项预测或评分模型任务，任务数不等同于底层 API 调用次数。这是已登记停止规则的探索性案例搜索，不能按独立固定样本试验解释。

表 D-9 探索性扩样的完整对象计数（真实运行）

| 语料 | 配置 | 组件 TP／FP／FN | 关系 TP／FP／FN |
|---|---|---|---|
| AAEC | MCR-only | 44 / 111 / 426 | 0 / 122 / 295 |
| AAEC | RelationOnly | 44 / 111 / 426 | 0 / 98 / 295 |
| AAEC | BRJ-lite | 99 / 149 / 371 | 4 / 255 / 291 |
| CDCP | MCR-only | 178 / 307 / 545 | 3 / 187 / 197 |
| CDCP | RelationOnly | 160 / 281 / 563 | 0 / 200 / 200 |
| CDCP | BRJ-lite | 111 / 364 / 612 | 0 / 267 / 200 |

严格键保留原生字符边界和组件类型；关系再要求完整源集合、目标、方向和标签同时匹配。AAEC 金标 470 个组件、295 条关系，池中命中 102 个组件、7 条完整关系；CDCP 对应 723、200 及 191、22。已入池正确关系中，AAEC 3 条、CDCP 19 条取原规约的缺省 0.05；这说明实际赋值，不证明未覆写对象从未被模型考虑。原评分本就要求检查全部候选，数值稀疏不能直接等同于心理意义上的未评估。

AAEC 的 4 个严格正例为 essay001、essay051、essay078、essay085，全部列入外部核验册。CDCP 的 9 个失败文档为 00404、00430、00728、00867、00881、01118、01150、01288、01292，原因涉及非法类型、重叠或非连续源范围。另 22 篇满足关系 FP 减少、TP 不减少且组件 F1 不下降的事后条件；这是误报抑制描述，不参与停止规则，也不称为关系 F1 提高。00312 中 FP 由 1 降至 0、组件 F1 保持 50.00，RelationOnly 得到相同结果，因此它不构成联合修正独有收益。

148 篇冻结输出已独立复算，296 个文档策略记录完成一次本地重放，终态对象或显式失败均一致，但 6 组接受尝试序列不同。差异保留在重放记录中，不覆盖原输出；可能涉及集合遍历的浮点累加及近似并列次序，尚未隔离确认单一原因。新增固定规模试验将效用求和顺序固定为规范 ID 顺序，公式和接受阈值不变；该实现调整不追溯改写旧结果。

## D.11 新增语料的来源与固定试验

新增检索截至 2026 年 10 月 11 日，优先选择同时提供原文、组件边界、原生类型及有向关系的作者发布语料。ArgUNSC 于 2025 年发布，覆盖 144 篇安理会发言，含 claim / premise 和 support / attack[50]；CasiMedicos-Arg 于 2024 年发布，以医生解释的病例问答为对象，含 Claim / Premise 和 Support / Attack[51]。前者的多个前提以分别指向主张的二元关系表达；后者允许 Claim 支持 Claim，一般医学知识仍标 Claim，病例特定观察才标 Premise。本试验仅使用后者的英文版本，未将同一病例的四种语言当作独立样本。

ArgUNSC 使用作者仓库的组件级 CSV 快照，按 Sentence_ID 拼接原句，组件必须完整逐字匹配并在来源句内开始；跨句组件允许延伸到后句。base.csv 的 Premises 字段与独立关系对文件校对：发布快照中有 3060 条正关系行，去重为 3009 条，与组件表的关系集合相同；论文的关系总数为 2973，二者没有强行对齐。两个文档存在重复组件 ID 或重叠，整篇排除；其余 142 篇中再排除 22 篇超过 8000 字符的文档，得到 120 篇合格源文档。

CasiMedicos-Arg 固定 Hugging Face revision 54a07ccf2993afc42a368e04682125b6f7b13be4，读取原始英文有序 token / BIO 与 relations 文件。各句内以单空格、句间以换行重建文本，Claim / Premise 由 BIO 还原，其他医学实体和 Marker 不改写成论辩组件。关系端点只允许对完整组件作唯一匹配，比较时统一 NFKC、空白和末尾 .,:;!?；不作编辑距离或语义补配，任何未映射端点使整篇不进入本次严格试验。

论文报告 558 个标注病例；所用快照的三划分共 622 行，其中 69 行缺少 token 标注，剩余 553 行，不能直接沿用论文分母。官方 test 的 125 行中 117 行有 token 标注，93 行可完整映射组件和全部关系；本次只从这 93 行抽样。排除记录先于预测冻结，故它限定了可转换子集的解释范围；不能把该子集成绩冒充官方完整测试集成绩。英文材料源于西班牙文病例，经翻译与人工修订，这也是其文本条件的一部分。

表 D-10 新语料转换与抽样范围

| 项目 | ArgUNSC | CasiMedicos-Arg 英文 |
|---|---|---|
| 所用发布文档 / 行 | 144 | test 125 |
| 完整可转换 | 142 | test 93 |
| 长度限制后合格 | 120 | 93 |
| 固定样本 | 32 | 32 |
| 原生发布划分 | 本次发布无官方划分 | 官方 test 子集 |
| 字符构造 | 原句单空格连接 | token 单空格与句间换行 |

两套语料分别按 token 长度四分位分层，在层内按 SHA256(V10-LUNA-FIXED32|语料|原文)排序各取 8 篇，预测前保存完整顺序、源文件哈希、盲输入和金标快照。各 8 篇一个预测任务，每篇生成两个图；关系为多源时不拆平来挽救二元语料的非法输出。全程不按效果追加文档或重试格式失败。ArgUNSC、CasiMedicos-Arg 和新 CDCP 预测共 12 项模型任务，盲评分共 31 项，合计 43 项；实际模型快照、温度、随机种子及 token 用量未由调度工具暴露。

新试验的构造器只在两张成功解析图给出的类型范围内保留跨度，补充去句末标点变体；二元槽位按不重叠端点枚举，CDCP 多源槽位仅来自生成图及其端点变体。4096 是构造预检的槽位上限，不是论文完整候选方案的等价实现。所有新文档采用逐文档累计 5 秒、每 MILP 调用最多 0.25 秒的求解额度，其余 128 次尝试、12 次接受及 24 / 96 编辑上限沿用旧试验；效用求和次序固定。

ArgUNSC 64 个图中 6 个因多源关系未通过二元解析；CasiMedicos-Arg 为 35 个，另有 3 个已解析图违反结构检查。错误记录和全部文档保持在评价分母。MCR 依原分数排名选图，未因为已知金标而换成其他候选；初始化失败时本次 MCR、BRJ-lite 及 RelationOnly 均按空预测计数。该规则与 D.10 保留原始 MCR 图的历史口径不同，两个试验不合并计算成绩。

ArgUNSC 的共同初始组件 / 关系 TP、FP、FN 为 43 / 50 / 785 与 3 / 50 / 502；BRJ-lite 为 42 / 105 / 786 与 0 / 69 / 505。关系恢复 / 损失 TP 为 0 / 3，新增 / 移除 FP 为 55 / 36。每篇严格计数、格式失败和候选覆盖保存于独立评价文件。

CasiMedicos-Arg 的共同初始组件 / 关系 TP、FP、FN 为 24 / 29 / 365 与 1 / 30 / 210；BRJ-lite 为 21 / 45 / 368 与 0 / 51 / 211。关系恢复 / 损失 TP 为 0 / 1，新增 / 移除 FP 为 34 / 13。每篇严格计数、格式失败和候选覆盖保存于独立评价文件。

## D.12 CDCP 原生评分接口的配对检查

CDCP 按可评价性区分类型：fact 是可依陈述当时的证据核验、且不依赖个人经历的命题，未来预测未必为 fact；testimony 表达个人状态或经历；value 为评价，policy 为具体行动

建议，reference 标记外部证据来源。reason 给出理由，evidence 提供判断目标真假的根据，其来源在原标注模型中与 testimony 或 reference 相关[3]。本次将这些区别写入评分说明，未把它们新增为硬类型掩码，也未将全部事实性语句自动当成 evidence。

新增 32 篇仅来自官方训练划分，排除前期整个 CDCP 审计文本集合，因此不与 D.10 的 116 篇重叠。抽样与预测同 D.11；候选、MCR 初始选择、求解器、队列和预算在两条件间完全相同。原评分仍使用低默认值 0.05 和显式覆写；原生显式方案对所有组件及关系 ID 输出 [0,1]数值或 null，不允许缺键。null 保持未知，涉及未知变化组件或闭合域关系的提议被拒绝；未变化对象的数值在差分中抵消。

本批金标包含 211 个组件、56 条完整关系，有限池覆盖 46 个组件、5 条完整关系；8 条多源金标关系中，池内命中 0 条。该上游范围在两条件间不变；调整评分不能生成缺失的类型、跨度或源集合。两条件的原生图解析相同，64 个图全部解析成功，63 个满足实现的结构检查。

表 D-11 CDCP 候选评分的覆盖与金标事后诊断

| 指标 | 原评分 | 原生显式 |
|---|---|---|
| 组件候选数 | 235 | 235 |
| 关系候选数 | 3670 | 3670 |
| 关系取默认 0.05 | 3101 | 无默认 |
| 显式未知组件 / 关系 | 无此字段 | 0 / 0 |
| 池内正确关系得分≥0.5 | 0 | 1 |
| 池内正确关系取默认分 | 5 | 无默认 |

表 D-11 的显式覆盖只证明字段齐备及数值有效，不能独立证明模型逐一完成了可靠语义判断；金标只用于冻结后的诊断。评分与预测为同型号模型的不同上下文，误差独立性未获证明。原生说明和输出覆盖同时变化，故该对照检验组合输入调整，不区分两个因素各自的效应。即使关系 F1 提高，也不等于分数已校准或完整 BR-J 有效。

本地接口检查覆盖两套新语料的二元元数、未知变化组件、未知关联关系、最小合法化扩域中的未知同槽标签，以及不相关未知对象不应阻断已评分提议。原始源文件、候选、分数和执行输入在读入评价标签前冻结；独立检查再从发布 CSV / BIO / 关系 JSONL 及 CDCP 原压缩包重建金标，复核事务外关系、接受门、累计预算与终态。构造检查只证明这些边界分支按规约执行，不替代语料上的收益。

表 D-12 新增试验的修正阶段实测成本

| 语料与评分 | 策略 | 完成／失败 | 墙钟秒 | MILP 秒 |
|---|---|---|---|---|
| ArgUNSC 原评分 | BRJ-lite | 31 / 1 | 0.4865 | 0.1922 |
| ArgUNSC 原评分 | RelationOnly | 31 / 1 | 0.1616 | 0.0928 |
| CasiMedicos-Arg 原评分 | BRJ-lite | 18 / 14 | 0.1172 | 0.0608 |
| CasiMedicos-Arg 原评分 | RelationOnly | 18 / 14 | 0.0488 | 0.0313 |
| CDCP 原评分 | BRJ-lite | 32 / 0 | 0.3991 | 0.1687 |
| CDCP 原评分 | RelationOnly | 32 / 0 | 0.3787 | 0.1943 |
| CDCP 原生显式 | BRJ-lite | 32 / 0 | 0.4831 | 0.1514 |
| CDCP 原生显式 | RelationOnly | 32 / 0 | 0.4477 | 0.1812 |

表 D-12 为每种语料、条件和策略的 32 篇合计，从固定候选和分数之后开始计时，不含 Luna 预测、评分、下载或环境准备。它不能解释为端到端延迟或局部相对全局的速度优势；完整逐调用状态保存在运行轨迹。

新增试验的 256 个文档条件策略记录另作一次冻结分数的本地重放，其中 256 个终态或显式失败一致，256 个接受尝试序列一致。重放不再调用 Luna，也不替换原轨迹；一致性只验证冻结输入后的执行，不代表模型多次抽样结果稳定。

# 附录 E 前期数值与协议存档

本附录逐表保留 0915-v1 稿件中的原始数字和方法行。除表 E-1 及协议映射表外，相应数值可在 ICIC 公开版本中找到；“可找到”不等于本次独立复现。所有结果均不属于 0920-v1 新增机制。旧表“±”的统计定义、划分及评价脚本仍按附录 A 核验，不由新协议追认。

## E.1 AAEC 组件分类别旧稿记录

表 E-1 AAEC 组件分类别旧稿记录

| 方法 | MajorClaim-F1 | Claim-F1 | Comp-F1 |
|---|---|---|---|
| FLAN-T5 (XXL) | 71.23 | 76.45 | 80.15 |
| LLM Single-Pass | 73.45 | 78.21 | 81.67 |
| **Ours (Full)** | **77.34** | **81.77** | **83.71** |

来源为旧稿补充记录；未在 ICIC 公开版中找到对应分类别表。Single-Pass 的 81.67 与表 E-2 的 77.82 尚需 run ID 解释，不用于新增强的独立归因。

## E.2 ICIC 原版 AAEC 域内结果记录

表 E-2 ICIC 原版 AAEC 域内结果记录

| 方法 | Comp-F1 | Support-F1 | Attack-F1 | Relation-F1 |
|---|---|---|---|---|
| FLAN T5-XXL | 80.15 | 62.34 | 48.72 | 61.19 |
| GPT-4-turbo 20-shot | 55.51 | 29.86 | 18.45 | 28.38 |
| RoBERTa-large MTL | 76.43±0.55 | 54.21±0.52 | 41.83±0.67 | 52.15±0.54 |
| LLM Single-Pass | 77.82±0.51 | 58.43±0.45 | 44.21±0.62 | 56.87±0.48 |
| LLM w/ Constrained Decoding | 78.54±0.46 | 59.12±0.42 | 45.33±0.58 | 57.65±0.45 |
| LLM w/ DAG Post-process | 78.91±0.49 | 59.45±0.48 | 45.87±0.61 | 58.12±0.47 |
| LLM Multi-Sample (LogProb) | 79.45±0.38 | 60.12±0.41 | 46.58±0.55 | 58.94±0.42 |
| LLM w/ Self-Refine | 79.82±0.45 | 60.75±0.43 | 47.12±0.56 | 59.63±0.45 |
| Ours ($K=1$, w/o correction) | 81.24±0.44 | 61.87±0.39 | 48.34±0.58 | 60.73±0.41 |
| Ours (Verifier-only Rerank, $K=3$) | 82.18±0.40 | 63.15±0.36 | 49.82±0.52 | 62.21±0.38 |
| **Ours (Full, $K=3$)** | **83.71±0.42** | **65.92±0.38** | **51.47±0.54** | **64.83±0.38** |

对应 ICIC 公开版 Table 1 的 AAEC 部分[34]。所有方法名及数值按旧稿保留；外部结果的评价差异需按原文核验，不能视为统一严格协议下的复现。

## E.3 ICIC 原版 CDCP 域内结果记录

表 E-3 ICIC 原版 CDCP 域内结果记录

| 方法 | Comp-F1 | Reason-F1 | Evidence-F1 | Relation-F1 |
|---|---|---|---|---|
| FLAN T5-XXL | 72.68 | 35.24 | 28.41 | 33.96 |
| RoBERTa-large MTL | 68.52±0.58 | 31.45±0.61 | 25.72±0.73 | 30.23±0.64 |
| LLM Single-Pass | 71.35±0.48 | 33.82±0.52 | 27.15±0.68 | 32.64±0.55 |
| LLM w/ DAG Post-process | 72.14±0.50 | 34.65±0.49 | 28.02±0.63 | 33.51±0.52 |
| LLM w/ Self-Refine | 72.95±0.47 | 35.58±0.48 | 28.94±0.60 | 34.42±0.50 |
| Ours ($K=1$, w/o correction) | 74.56±0.45 | 36.94±0.46 | 30.27±0.58 | 35.78±0.48 |
| Ours (Verifier-only Rerank, $K=3$) | 75.12±0.41 | 37.85±0.44 | 31.42±0.55 | 36.64±0.45 |
| **Ours (Full, $K=3$)** | **76.45±0.43** | **39.12±0.45** | **32.86±0.57** | **38.17±0.46** |

对应 ICIC 公开版 Table 1 的 CDCP 部分[34]。该表不证明本论文原生多前提超边的严格抽取性能。

## E.4 ICIC 原版模块消融记录

表 E-4 ICIC 原版模块消融记录

| 配置 | Comp-F1 | Relation-F1 | ΔComp | ΔRel |
|---|---|---|---|---|
| Full Method | 83.71±0.42 | 64.83±0.38 | — | — |
| $K=1$, w/o correction | 81.24±0.44 | 60.73±0.41 | -2.47 | -4.10 |
| w/o Claim-specific Adapter | 81.96±0.48 | 63.08±0.44 | -1.75 | -1.75 |
| w/o Cue-aware Prompting | 82.34±0.45 | 62.87±0.40 | -1.37 | -1.96 |
| w/o Multi-Objective | 82.89±0.43 | 63.54±0.39 | -0.82 | -1.29 |
| w/o Validity Signal $E_{val}$ | 81.56±0.46 | 61.92±0.43 | -2.15 | -2.91 |

对应 ICIC 公开版 Table 2[34]。专项适配、线索、多候选及有效性消融不等于完整影响域、成对学习和事务闭合消融。

## E.5 ICIC 原版验证器替换记录

表 E-5 ICIC 原版验证器替换记录

| 验证器 | Comp-F1 | Relation-F1 | Top-1 一致率 | 修正触发率 |
|---|---|---|---|---|
| Qwen2.5-7B（默认） | 83.71 | 64.83 | 100.0% | 42.5% |
| Llama-3-8B（独立） | 83.71 | 64.55 | 94.2% | 43.8% |

对应 ICIC 公开版 Table 3[34]。原二元验证器一致性不能替代新完整对象评分器的正确性校准；自比较的一致率不构成真实性证据。

## E.6 ICIC 原版 Oracle 记录

表 E-6 ICIC 原版 Oracle 记录

| 条件 | Comp-F1 | Relation-F1 | $\Delta$Rel |
|---|---|---|---|
| 预测组件与当前选择器 | 83.71±0.42 | 64.83±0.38 | — |
| Candidate Oracle（$K=3$中择优） | 85.12±0.36 | 67.24±0.34 | +2.41 |
| Condition Oracle（金标准组件输入） | — | 78.42±0.35 | +13.59 |
| Output Oracle（金标准替换） | 100.00 | 83.35±0.32 | +18.52 |

对应 ICIC 公开版 Table 5[34]。保留原名称，不改称新候选宇宙的可达率、原生超边上界或局部搜索最优值。

## E.7 ICIC 原版修正行为记录

表 E-7 ICIC 原版修正行为记录

| 指标 | 结果 |
|---|---|
| 修正触发率 | 42.5% |
| 触发文档平均迭代轮数 | 1.8 |
| 触发文档平均动作数 | 2.4 |
| LocalRerun 占比 | 45.2% |

表 E-7（续）

| 指标 | 结果 |
| --- | --- |
| RemoveEdge 占比 | 24.8% |
| Replace 占比 | 19.5% |
| Promote/Demote 占比 | 10.5% |
| 无效 ID 比例 | 18.5% → 2.1% |
| JSON 格式错误比例 | 6.2% → 0.0% |
| 不连贯边比例 | 22.4% → 5.8% |
| 整体$E_{val}$通过率 | 75.3% → 97.9% |

对应 ICIC 公开版 Table 6[34]。Replace 及 Promote/Demote 明确属于 BR-O，不能移作 BR-C 或 BR-J 的行为分布；动作占比不等于真实错误分布。

## E.8 前期粗粒度组件映射

表 E-8 前期粗粒度组件映射

| 数据集原标签 | 粗粒度标签 | 映射依据 |
| --- | --- | --- |
| AAEC MajorClaim | Claim | 表达全文立场 |
| AAEC Claim | Claim | 表达局部结论 |
| AAEC Premise | Premise | 提供支撑或反驳理由 |
| CDCP Policy | Claim | 提出行动方案或规范性主张 |
| CDCP Value | Claim | 表达评价性或价值判断 |
| CDCP Fact | Premise | 提供可核验事实 |
| CDCP Testimony | Premise | 提供经验或证言 |
| CDCP Reference | Premise | 提供外部来源 |

这是单独迁移协议的标签归约，不改变 AAEC/CDCP 的原生域内标签，也不证明标签在语义上天然等价。

## E.9 ICIC 原版 AAEC 到 CDCP 迁移记录

表 E-9 ICIC 原版 AAEC 到 CDCP 迁移记录

| 方法 | Coarse Component-F1 | Unlabeled Link-F1 |
|---|---|---|
| FLAN T5-XXL（zero-shot） | 52.34±0.65 | 31.25±0.72 |
| LLM Single-Pass（zero-shot） | 54.87±0.58 | 33.42±0.68 |
| Ours ($K=1$, w/o correction, zero-shot) | 57.23±0.52 | 38.76±0.61 |
| **Ours (Full, zero-shot)** | **60.78±0.48** | **43.21±0.55** |

对应 ICIC 公开版 Table 4[34]。有向无标签 Link-F1 与严格原生关系 F1 分开；目标数据用途及多前提投影口径仍需历史材料核准。

# 附录 F 符号与阅读索引

## F.1 核心术语与符号

表 F-1 汇总方法中的对象及其局部作用域。本文保留各章公式的既有符号，但在首次定义和跨章节叙述中使用“输入文档”“改写集合”“变化对象集合”和“关系候选池”等完整名称。评价量使用 Precision 和 Recall，与图对象集合分开命名。完整对象计数、概率评分、累计编辑与终态净变化分别使用对应符号，避免跨层混用。

表 F-1 核心符号及其语义

| 符号或术语 | 含义 | 使用边界 |
| --- | --- | --- |
| $x$或$D$ | 输入原始文档 | 推理修正不改写原文；第四章$D$另指删除集合 |
| $c=(s,e,t)$ | 跨度起止位置及类型组成的组件 | 显示 ID 不替代跨度和类型构成的身份 |
| $G=(C,R)$ | 组件集合及完整关系集合 | CDCP 关系保留完整源集合 |
| $A$ 第三章 | 允许替换文字的组件集合 | 不等于连续段落，不由测试标签选择 |
| $\Omega(C)$ | 协议声明的合法端点组合宇宙 | 有限范围，不枚举任意潜在语义联系 |
| $\mathscr{D}_A$ | 至少一个端点属于$A$的因素集合 | 同时包含内部与跨边界组合 |
| 内部与跨边界 | 端点相对于$A$的位置类别 | 与是否有关系标签是两个维度 |
| NONE | 合法端点组合无标注或未选正关系 | 训练保持金标状态；推理允许纠正漏检 |
| NULL | 候选跨度不被选为组件 | 不同于关系槽位的 NONE |
| $\varphi$ | 原文到增强文的组件对应 | 组件双射，不要求 token 一一对应 |
| $G_0$ | 经共同合法化得到的初始图 | 可能不同于原始重排序胜者 |
| $U,\mathscr{V},P$ | 跨度、带类型组件及关系候选宇宙 | 修正前固定；$P$在此不是精确率 |
| $P,R,F_1$ 评价指标 | 精确率、召回率和 F1 | 只在评价公式中作指标解释；正文优先使用 Precision 和 Recall |

表 F-1（续）

| 符号或术语 | 含义 | 使用边界 |
| --- | --- | --- |
| 构造验证 | 人工定义对象与分数上的真实程序执行 | 只验证规约，不是语料实验、模型预测或人工审计 |
| $D, B$ 第四章 | 删除旧组件和加入新组件的集合 | 冲突扩张后核对预算；$A = D \cup B$ |
| $q_C, q_R$ | 完整组件与关系对象的正确性估计 | 不同于给定金标跨度的训练标签概率 |
| $\Phi_C, \Phi_R, \Phi$ | 组件、关系及总代理效用 | 用于接受决策，不等于真实 F1 |
| no-op | 不提交修改而保留当前合法图 | 独立回退选择，不强制发生编辑 |

## F.2 实现接口补充

标注输运按原字符区间替换指定槽位，回填全文后重新分词并更新全部组件位置。字符坐标、评价 token 和模型子词分别保存映射。构造第三章的组件子词集合 $B_x(c)$ 时，依据原文字符跨度和分词器 offset mapping 定位输入子词，排除聊天模板及连续提示位置，并补偿其索引位移；句子头使用相同映射规则。训练表示映射不一致时报错，增强槽位重叠或坐标往返不一致时拒绝相应变体，不删除问题金标。

训练辅助头只读取回答开始前的输入表示，$h_{end}^{x}$ 取全文输入结束处的隐藏状态，不取金标回答末尾。金标跨度用于定位监督，待预测的组件类型与关系标签不作为辅助头输入。梯度核验使用非零对齐损失的受控输入单独反传，检查共享生成参数的计算图连接及梯度范数、基础权重冻结、隐藏状态未分离且输入不含金标回答；单个零梯度不自动说明断路。连接判定同时考虑计算图、参数更新资格和数值梯度。输入阶段结论专项门控关闭，对齐项不直接训练该分支；专项分支由生成损失更新。开发评价和测试时移除辅助头，推理评分器另按第四章定义。

推理侧的冲突闭合与关系依赖域遵循 4.3 节，队列采用状态键、六类轮转及独立批长，预算、提交及回退遵循 4.5.2 节；顺序对照按 4.6.1 定义两个提交阶段，并按附录 B.3 区分外层计数和阶段账本。Oracle 遵循 4.6.3 的松弛集合，不能调用预测效用 ILP 替代金标目标优化。模块接口分别为 SelectRegion、BuildCandidates、EnumerateQueue、ScoreObject、EvaluateTransaction、Commit 和 EvaluateCounts；输入输出及错误身份由附录 A、B 约束。

## F.3 研究问题阅读索引

表 F-2 将概念、方法和验证位置对应起来，便于连续阅读和交叉回查。索引同时关联方法入口、实验结果和接口说明。

表 F-2 方法与实验的阅读索引

| 阅读问题 | 方法入口 | 实验与记录入口 |
| --- | --- | --- |
| 训练改写与推理修正的区别 | 1.3、2.7 及图 1-2、图 2-1 | 第三、四章算法输入输出与第五章四格设计 |
| 内部跨边界与 NONE 的含义 | 3.3.1 及图 3-1 | 3.6.2 标签可靠性审计 |
| 改写后如何迁移标注 | 3.3.2 | 附录 A.1、B.1 与 F.2 |
| 成对学习是否独立有效 | 3.4 及图 3-2 | 3.6.1 同数据条件；3.6.3 学习目标消融 |
| 组件和关系为何整体决策 | 4.3、4.4.5 及图 4-1 | 4.6 同候选同评分比较；附录 B 案例记录 |
| 候选评分与搜索各限制什么 | 2.4、4.2 至 4.5 及图 4-2 | 4.6 覆盖评分风险诊断与附录 B |
| 两项研究如何组合 | 2.7 | 5.1 至 5.3 条件增量、对象边界与在线配置选择 |
| 与 ICIC 相比深化了什么 | 1.3.3 及表 1-2 | 附录 C 成果归属及附录 E 历史表 |
| 迁移结果如何解释 | 2.1 与 2.5 | 5.2 及附录 E.8 至 E.9 |

# 附录 G 外部方法定位与比较协议

## G.1 检索范围与方法选择

外部资料检索截至 2026 年 10 月 10 日，优先使用 ACL Anthology、论文原文、arXiv 作者版本与论文所指向的公开仓库。表 G-1 记录纳入考虑的方法类别，检索目的为建立可执行的比较范围，未据此作穷尽性新颖性或“首次”判断。原论文成绩不并入本版估算情景主表。

表 G-1 外部研究候选与本稿比较用途

| 研究 | 输入与机制 | 比较用途 | 接入时重点核对 |
| --- | --- | --- | --- |
| 结构 SVM / RNN[46] | 联合组件与关系的结构化预测 | 历史结构对照 | CDCP 预处理与完整源集合 |
| MT-AM[25] | 辅助语料与多任务训练 | 训练来源参照 | 额外监督不得混入单语料主轨 |
| GMAM[47] | 序列生成、约束指针与位置编码 | 结构生成补充 | 输出跨度、标签及候选表达 |
| Kawarada 等[7] | 标注文本的端到端生成 | 优先系统对照 | AAEC stance、CDCP 转换 |
| DENIM[12] | 篇章结构感知前缀 | 生成条件补充 | 篇章分析成本、AAEC 口径 |
| UniASA[48] | 统一生成与多视图学习 | 优先系统对照 | 标签映射、原生超边、辅助目标 |
| AASP[9] | 自回归结构动作 | 机制参照 | 动作表示与完整对象导出 |
| ARGUS[10] | 分割、分类与关系系统 | 系统接口参照 | 分割输入、求解目标与评价 |
| AMELIA[26] | 跨数据集分类及多任务接口 | 任务边界参照 | 不能替代原文跨度抽取成绩 |
| QOS / DOS[35] | 质量 / 多样性导向合成 | 数据构造近邻 | 生成目标、样本量与训练日程 |
| 对抗强化学习合成[49] | 文本与结构标注对联合生成 | 近期合成参照 | 生成器训练成本、数据目标 |

FOL-AM[14]与 Cabessa 等[8]还提供关系推理和生成分类的思路，但给定组件的输入条件与本稿端到端定位不同，放在相关机制比较中。纳入更多方法有助于定位，但不意味着所有方法都必须同等规模复跑。

## G.2 代码入口与可复现性核查

Kawarada 方法的公开入口为 am-as-text2text。当前说明使用 T5 / FLAN-T5 及 TANL 接口，支持 LoRA 等配置，并明确 CDCP 转换模块不在仓库中。它提供实现入口，但当前代码配置不能自动等同于 2024 论文原始设置；正式运行需固定提交、补全数据转换并核对差异。

UniASA 的公开仓库提供 AAEC、CDCP 等数据处理及训练脚本；AAEC 说明含标注修正，CDCP 依赖 graph_parser 预处理。这使其具备较明确的起点，也要求保留本稿原生金标并记录转换损失，不能直接采用处理后分数代替完整超边评价。GMAM 仓库提供另一结构生成入口。

DENIM 原文给出的代码地址为 syiswell/DENIM，近期合成论文给出 Synthetic-Data-for-Argument-Mining；前次资料核查未取得可检查的仓库内容，因此仅确认论文所载地址，不标记环境可运行。QOS / DOS 的作者仓库用于核对两类合成入口；AMELIA 仓库所列分类任务用于说明输入边界。AASP、ARGUS 的既有记录以原文方法为限，不将未检查的代码写成已复现。

Kawarada 和 UniASA 作为优先接入候选，当前共同任务结果尚未取得。至少一种方法通过原生任务兼容核查并实际运行后，才形成外部系统比较；结果登记按 G.4 执行，未运行项目保持待填，不使用人工分数代替。GMAM、DENIM 和动作模型仅作必要补充，QOS 式适配不替代端到端外部对照。

## G.3 QOS 式适配与本方法的差异

表 G-2 当前数据构造对照的适配范围

| 维度 | QOS 式适配 | 完整增强＋基础损失 |
| --- | --- | --- |
| 输入 | 共同标注文档与槽位接口 | 相同文档及关系影响域条件 |
| 改写范围 | 本稿固定槽位范围 | 相同范围，检查内部与跨界因素 |
| 标签检查 | 槽位恢复及共同基础检查 | 增加正关系 / NONE 影响域审核 |
| 训练规模 | AAEC 500、CDCP 900 变体 | 相同规模及增强 token 预算 |
| 学习目标 | 继承基础损失 | 相同基础损失；不含新增头 / 成对项 |
| 评价 | 原文严格组件与完整关系 | 相同原生评价器与独立文档 |

这一定义控制 T-B 的数据构造比较，不声称复现原论文全部 QOS、DOS 及联合日程。完整 T1 另包含头监督与成对项；表 3-6 的同数据比较承担其学习增量。若追加原始 QOS / DOS 复现，原方法和本稿适配版本分别命名，生成器调用、合成样本与下游训练全部计费。

## G.4 外部系统接入与结果登记

先冻结原始文档 ID、划分、评价分词器、类型和完整超边，再审计外部转换的每一步。AAEC 原方法若将 Claim stance 并入组件标签，需同时保留其原任务结果与本稿映射结果；CDCP 若拆分或收缩源集合，必须保留可逆来源，否则只进入兼容任务补充。不能借助测试金标为外部预测补回遗漏端点或合并出正确超边。

每个系统分别运行原配置核对轨与共同任务比较轨，记录代码提交、模型身份、额外数据、选择规则及全部失败文档。共同评价只比较可直接导出的原生完整对象；统一骨干可控时另做方法适配，不可控时解释为系统比较。若无法无损表达本稿任务，不把该方法放入严格主榜，也不以转换失败暗示其原任务能力较差。

# 附录 H 关键诊断与综合证据记录

## H.1 训练侧问题规模与初始错误的诊断设计

增强诊断按语料在训练侧持出组固定抽取 40 篇源文档，按文档长度与金标关系数的中位数交叉分层，层内随机抽取；不足的层取全量并记录实际文档数。先固定普通改写生成池，每篇最多 4 次尝试。内部正、跨界正、内部 NONE、跨界 NONE 分别抽至 200 个可审因素，若不足则全取，报告实际分母；同一变体允许多个因素，但保留源文档与变体 ID，按文档而非因素独立重采样。

原文与改写文并排审阅，审阅者不看方法名及接受标志；两人独立判断并保留分歧，经裁决形成因素标签。接受 / 拒绝分层用于筛选诊断，不能替代未筛生成池的问题发生率。方法选择使用训练侧材料，独立评价仅验证冻结结论。开发诊断完成后按 2.6 节重新生成正式 OOF 记录，保持拟合、校准及策略角色隔离。审计至少记录四层的文档数、变体数、因素数和漂移数，等层均值与按原池构成加权值分别报告。

初始预测诊断复用训练侧 OOF 记录。组件先按严格键命中，再配对同跨度异类型对象；剩余对象按 token 交并比降序、坐标顺序破同分进行一对一配对，交并比阈值在训练侧预定为 0.5，仅用于描述边界误差，完全不改主评价。未配对金标记遗漏，未配对预测记多检。关系同时记录“全部端点正确”“至少一个端点错误”及关系标签 / 方向状态；候选覆盖另作交叉维度，不能把各维度相加为因果比例。

## H.2 表达变化、源覆盖与资源轨道

非复制在仅作 Unicode NFC 及换行规范化后比较允许改写的组件文本，保留大小写、否定和标点。所有可解析变体为分母，只要一个允许槽位与原文不同即为非复制；生成池与接受池分别报告，解析失败数以全部尝试为分母另列。跨变体重复和完全复制另存标志，避免把反复生成同一个新句子视为高多样性。

规范化编辑距离采用固定评价分词器。对同一变体的各改写槽位，分别计算 Levenshtein 距离，再将距离之和除以各槽位原、新 token 长度较大值之和；不拼接跨槽边界，不纳入未允许改写的全文区域。分母为 0 时记 0 并单列空槽异常。报告中位数、四分位区间和零值比例，源文档为重采样单位。两项指标度量字面变化，不等于语义多样性或标签正确性。

接受覆盖按源文档统计，复用 H.1 的长度与关系复杂度分层，同时保留每个变体实际受检因素数。沿用文档、变体和因素三个分母，并列观察接受覆盖、字面变化与漂移，不另造综合评分。任何因素失败即拒绝的规则可能使受检因素多的文档更难通过；需要看同层内是否仍有这种趋势，不能从低漂移率直接排除，也不能从聚合相关性认定审核是唯一原因。显式 / 隐式关系只在标注依据可复核时作为附加描述，不为增加切片而填造标签。任务收益仍

由既有两组比较判断：同基础损失比较增强构造，同增强集合比较头监督与成对项；编辑距离本身不证明任务有用的多样性。

表 H-1 保留旧情景的固定尝试轨训练成本。它不进入匹配训练规模主结果的成本比较；正式训练需为两轨各自登记变体清单、增强 token、实际更新数、设备小时和峰值显存。

表 H-1 固定尝试轨训练成本存档（估算情景）

| 语料与方法 | 训练 GPU 小时 |
|---|---|
| AAEC 普通增强 | 1.46 |
| AAEC QOS 式 | 1.48 |
| AAEC 完整方案 | 1.79 |
| CDCP 普通增强 | 2.32 |
| CDCP QOS 式 | 2.38 |
| CDCP 完整方案 | 2.91 |

## H.3 候选规模、共同预算与求解状态

资源探测逐文档保存保护跨度数、补充跨度数、去重后跨度数、带类型组件数、裁剪前槽位数、正标签评分对象数、批次数、裁剪后槽位数，以及各阶段时间和峰值内存。槽位与标签对象分别计数，受保护与补充部分记录交集，不能重复相加。资源阈值依据训练侧探测及设备容量设定，连同探测文档 ID 冻结；预检失败、评分失败、无可行解和超时分别编码，所有独立评价文档保留在分母内。

等求解预算轨以表 2-2 的 3 秒 / 5 秒为基准，预定 0.5、1、2 倍三个逐文档总额度，大预算全局行另作补充。图规模按训练侧带类型组件数和裁剪前槽位数分别确定三分位切点，测试只应用固定切点。等端到端轨另按共同准备时间的训练侧 P95 加基准求解额度确定基准时限，并比较相同倍数；计时自读取文档后开始，包含生成、枚举、评分、提议构造、全部拒绝、求解和提交。输入无法在时限内完成准备也计失败，不把它从速度表排除。

共同候选与评分缓存可以复用，但单文档比较须向双方计入相同冷缓存准备成本；热缓存吞吐另报，不能只向一方计费。分别报告平均、P95、超时率、返回完整可行图的比例、无 incumbent 率、F1、初始 TP 损失与新 FP。局部和全局都提供从初始图出发的可行回退，求解器无 incumbent 与系统能返回回退图是不同事件。

每次最大化求解保存 status、incumbent 效用、有效上界、绝对 gap 和求解器定义的相对 gap，缺失值保持缺失并注明原因；最优性只采用求解器证书或已证明状态，不由时限长短推

断。局部子问题的界不拼成整图全局界。只有已验证包含关系的同目标全局上界，才能用于限制局部终态效用，仍不构成真实 F1 上界。

为区分资源失败与搜索效果，预检失败同时报告其文档比例及对应金标数量；若对象尚未完成枚举，潜在可恢复覆盖保持未知，不能填成 0 或从成功文档外推。局部累计预算与全局净预算的差别沿用 4.6.1 的可行域说明，共同候选、评分和时限不等于相同可达域。

旧情景的平均与 P95 耗时为设定输入；独立预算函数及完成度插值的示例集中于 H.7。两轨不拼接为同次运行曲线，模拟状态也不替代实测日志。本节规定的正式运行需单独记录求解证书、有效界及状态，缺失项保持缺失。

## H.4 四格对象、恢复阻断与案例

对象重叠以相同原文上的完整语义键对齐。记$P_{ti}$为四格中的预测对象集合，$\Omega$为金标，训练新命中集合为$R_T=(P_{10}\cap\Omega)\setminus P_{00}$，仅修正新命中为$R_I=(P_{01}\cap\Omega)\setminus P_{00}$。二者交集表示共同修复，差集分别表示独有修复；再检查完整组合新增命中中未被两种单阶段覆盖的对象，以及$\Omega\setminus P_{11}$中的剩余遗漏。原有正确对象被组合破坏、T1 正确对象被 I1 破坏也分别登记，新增错误关系与移除错误关系单列。

优先复用同一批四格输出完成一项对象级分析，不要求共同修复少、独有修复多或交互显著为正。训练影响初始错误、候选与评分的深层分解作为进一步分析：先在同一文档上连接初始错误、覆盖与最终对象，再在共同提案集合上检查评分。缺少受控比较时不作单路径归因，也不必为每条可能路径新增一个正文小节。

四格每个预测对象保存语料、文档 ID、种子、配置、原文规范坐标、组件类型及关系完整端点与标签。金标与预测都按共同语义键形成集合，先验证四格文档集合及评价身份完全一致，再生成共同修复、各自独有修复、组合新增、仍遗漏与新破坏的清单。关系新 FP、已移除 FP 独立记录，不把 TP 增加解释为所有错误减少。每个清单保留对象键及源运行身份，以供原文核查。

恢复失败按组件候选、完整槽位、动作、队列、执行资源、接受门的顺序取首个阻断；动作不可表达需要穷尽声明邻域或给出规则证据，未搜索到不能直接判定不可达。附加标志保留评分异常、超时等并发原因。保护长超边与新建长超边分别以初始命中 / 遗漏金标为分母，并报告其他候选图提供的长槽位来源；0 样本组不计算 F1 或成功率。

完整案例采用附录 B.5 的原文、金标、初始与最终对象和事务轨迹。选择规则在看结论前固定：覆盖成功恢复、错误接受、错误拒绝及最常见阻断类型，每类按预定文档排序取例，并与总体频数并列。教学例只解释机制，人工片段不能更名为实际运行案例。4.6.7 从已冻结的 Luna 输出给出生成端点补入、评分误删和新语料失败等观察，配套记录列出全部严格正例与按 ID 排序的代表例。它们没有训练四格、分步对照或经事后验证的错误拒绝病例，缺失类别不由推演填补。

## H.5 模拟结果后的实证替换顺序

本版主结果的估算原则是固定 v6 的 T0 情景起点、样本规模、随机扰动及成本口径，缩小假设训练和推理增量，再从整数 TP、FP、FN 重算全部主表。参数并未根据 CPU 诊断、历史论文或目标实验拟合；“增量较小”只表示相对旧演示的设定更克制，不意味着更接近实际结果。原始目标是生成器的平衡精确率／召回率中心，经过偏移和整数化后，与表中均值略有差别。

具体假设中，AAEC／CDCP 的关系 F1 中心依次为：T0 53.30／48.10，完整增强基础损失 55.70／50.50，加头监督 56.60／51.30，T1 57.80／52.50，RelationOnly 59.60／54.80，单对象 60.70／55.90，BR-J 61.90／57.40，等求解预算全局 62.30／57.90。固定组件对照严格复用 T1 组件计数；全局略高的排序是情景假设，不由可行域包含关系推出 F1 优越性。

零增益和负增益也属于需要保留的备选条件。用于读表的压力假设为：成对学习相对加头监督的关系增量分别取−0.50、0.00、+1.20 个百分点；允许组件变化相对 RelationOnly 取−0.50、0.00、+2.30；局部减全局取−1.50、−0.50、+0.50。它们逐项替换一个效应假设，尚未生成新的逐文档记录或计算置信区间，不能称为已完成的敏感性实验。零或负增益出现时，相应机制的采用结论须收缩，而不能保留正增益情景的文字。

成本同样依赖假设。若只将共同对象评分时间乘以 0.5、1、2，其他项保持表 4-8 设定，AAEC 局部相对等求解预算全局的总时间节省率依次为 5.15%、4.19%、3.06%，CDCP 为 5.96%、4.73%、3.34%。这只是总时间公式的重算，不包含评分误差、批量吞吐或求解轨迹变化；评分成本占比越大，单独加速求解的总收益越小。

核心验证仍未完成。第一阶段在固定的少量真实文档上复核监督漂移、端点相关错误、候选覆盖及裁剪前成本，保留来源、分层和全部失败记录；先确认复杂机制所针对的问题是否实际存在，再决定设计是否保留。模板和成本示例不提供该判断，结果不足时允许收缩主张或简化机制。

局部方案的优先级依据真实结果决定：在尾延迟、资源限制或明确逐步变更要求下稳定获益时可作为主方案；只对特定子集有用时作为条件选项；若全局更适合目标场景，则比较两种求解选择或简化局部设计。当前不在三者中预先定案，也不从成本函数选取有利阈值。日志可追溯并非局部独占优势，变更可控性须有具体约束和实际表现。

第二阶段按 2.6.3 完成关键比较：T-B 固定学习目标比较增强构造，T-E 固定增强集合比较学习项；推理侧用 RelationOnly、单对象动作和同目标全局 ILP 分别检验修改范围与求解取舍，分步策略作为补充。同时完成至少一个可解释的原生外部系统对照及共同条件下的四格运行。每项核心贡献有直接比较与机制解释后停止横向扩张，保留不利结果，不为追求显著性追加切片。

第三阶段复用正式同批四格输出，形成至少一项对象级综合认识及同文档前后案例。现有 Luna 扩样、新语料和评分对照已提供轻量推理层面的真实输出，但缺少训练因素及完整对

照，不能据此将四格对象分析标为完成。若第五章仍缺独立内容，压缩相应小节；不以更多集合定义代替发现。

正式替换同时更新表、图、区间、摘要、结论及模拟标识。文档排版、公式一致和人工计数复算仍作为质量检查保存；它们不计入真实训练或求解次数。历史附录 E 及本模拟版本继续存档。

## H.6 模板筛选的指标阅读示例

本节只演示怎样并列阅读变化、漂移与覆盖，不检验真实语义审核器。材料独立沿用 SIM-1010-V4 旧记录，与本版主表无训练绑定：每种语料规模构造 40 篇模板源文档，4 / 12 因素组各 20 篇，每源 4 个共同候选、最多接受 2 个，三种筛选共 960 条决定。检测率设为 0.18、0.55、0.90，误报率设为 0.005、0.012、0.023；漂移标签同样由程序赋予，较高检出能力已经进入假设。

表 H-2 共同池的变化与覆盖诊断（指标演示的估算情景）

| 语料与筛选 | 接受／尝试 | 非复制／接受 | 编辑距离中位数 | 漂移变体／接受 | 低／高组覆盖 |
|---|---|---|---|---|---|
| AAEC 普通筛选 | 80/160 | 69/80 | 0.75 | 23/80 | 20/20；20/20 |
| AAEC QOS 式筛选 | 75/160 | 64/75 | 0.75 | 14/75 | 20/20；19/20 |
| AAEC 完整筛选 | 67/160 | 59/67 | 0.75 | 2/67 | 20/20；18/20 |
| CDCP 普通筛选 | 80/160 | 70/80 | 0.75 | 23/80 | 20/20；20/20 |
| CDCP QOS 式筛选 | 75/160 | 65/75 | 0.75 | 14/75 | 20/20；20/20 |
| CDCP 完整筛选 | 65/160 | 54/65 | 0.75 | 0/65 | 20/20；16/20 |

同一表中的非复制、编辑距离、漂移和覆盖有不同分母。0.75 的编辑距离中位数来自有限模板，不是语义多样性证据；0/65 不证明审核安全。高复杂度组还同时改变因素数与漂移生成率，覆盖差不能只归因于检查数量。本节候选池未用于生成表 3-5、表 3-6 的训练成绩，因此不能将字面变化、低漂移与主任务增量串成因果链。真实诊断及同源绑定要求见 H.1—H.2。

## H.7 预算条件的假设推演

本节数值及图 H-1 独立保留 SIM-1010-V4 旧成本与质量轨迹，终点沿用 v6 的情景主成绩；它们未改为 v7 主表的预算实验。为保留可追溯的条件示例，本节不与新版表 4-3 或表 5-1 拼接，也不用于估计新版效果。

本节保留 SIM-1010-V4 的预算记录作为分析示例。它不执行 BR-J 或全局 ILP，而由成本函数指定完成时间，再在初始计数与旧终态计数之间线性插值 TP、FP 并取整；FN 由固定金标数补足。由此得到的排序是设定关系的后果，不能确认为算法实际采用条件。

228 篇模拟文档的候选跨度数设为金标组件数加 8，每跨度 2 种类型；合法槽位数取 4.2.5 组合上界的 60%，每槽位 2 个正标签评分对象。AAEC／CDCP 预检阈值为 9000／330000，端到端基准时限为 24／36 秒，比较 0.5、1、2 倍。以 CDCP 为例，令 S 为设定槽位数，局部与全局求解秒数分别为 3.0 + 0.000018×S 和 1.8 + 0.000070×S，再乘预设随机扰动。完成比例由扣除共同准备后的剩余时限与该时间之比决定，不包含实际搜索质量轨迹或可行图生成。

表 H-3 裁剪前规模与预检成本（成本函数示例）

| 语料与规模 | 文档数 | 槽位中位数 | 槽位最大值 | 完整准备估计 P95 秒 | 预检失败 |
|---|---|---|---|---|---|
| AAEC 小 | 27 | 1214 | 1560 | 12.59 | 0/27 |
| AAEC 中 | 27 | 1948 | 2380 | 13.88 | 0/27 |
| AAEC 大 | 26 | 2940 | 3196 | 15.64 | 0/26 |

表 H-3（续）

| 语料与规模 | 文档数 | 槽位中位数 | 槽位最大值 | 完整准备估计 P95 秒 | 预检失败 |
|---|---|---|---|---|---|
| CDCP 小 | 50 | 59472 | 101836 | 17.22 | 0/50 |
| CDCP 中 | 49 | 163612 | 203376 | 21.54 | 0/49 |
| CDCP 大 | 49 | 304180 | 366748 | 28.28 | 10/49 |

表 H-3 的 P95 按全部文档的完整准备估计计算；预检在枚举后进行，失败文档不再评分，实际到达的模拟耗时计入表 H-4。CDCP 失败 10 / 148 篇，全部保留金标和耗时分母；未枚举对象的可恢复覆盖保持未知。保留 4096 个补充槽位不等于只枚举或评分 4096 个对象。

表 H-4 同端到端时限的质量与尾延迟（成本与完成度假设下的推演）

| 语料与时限 | 局部关系 F1 | 全局关系 F1 | P95 秒 局部／全局 | 回退% 局部／全局 | 全局超时% |
|---|---|---|---|---|---|
| AAEC 12 秒 | 60.85±0.36 | 60.80±0.38 | 12.00 / 12.00 | 90.00 / 90.00 | 100.00 |
| AAEC 24 秒 | 66.56±0.22 | 66.96±0.33 | 18.47 / 19.63 | 0.00 / 0.00 | 0.00 |
| AAEC 48 秒 | 66.56±0.22 | 66.96±0.33 | 18.47 / 19.63 | 0.00 / 0.00 | 0.00 |
| CDCP 18 秒 | 56.76±0.63 | 56.24±0.46 | 18.00 / 18.00 | 71.62 / 71.62 | 90.54 |
| CDCP 36 秒 | 61.53±0.84 | 61.07±0.24 | 34.30 / 36.00 | 6.76 / 6.76 | 34.23 |
| CDCP 72 秒 | 61.53±0.84 | 61.85±0.32 | 34.30 / 49.14 | 6.76 / 6.76 | 0.00 |

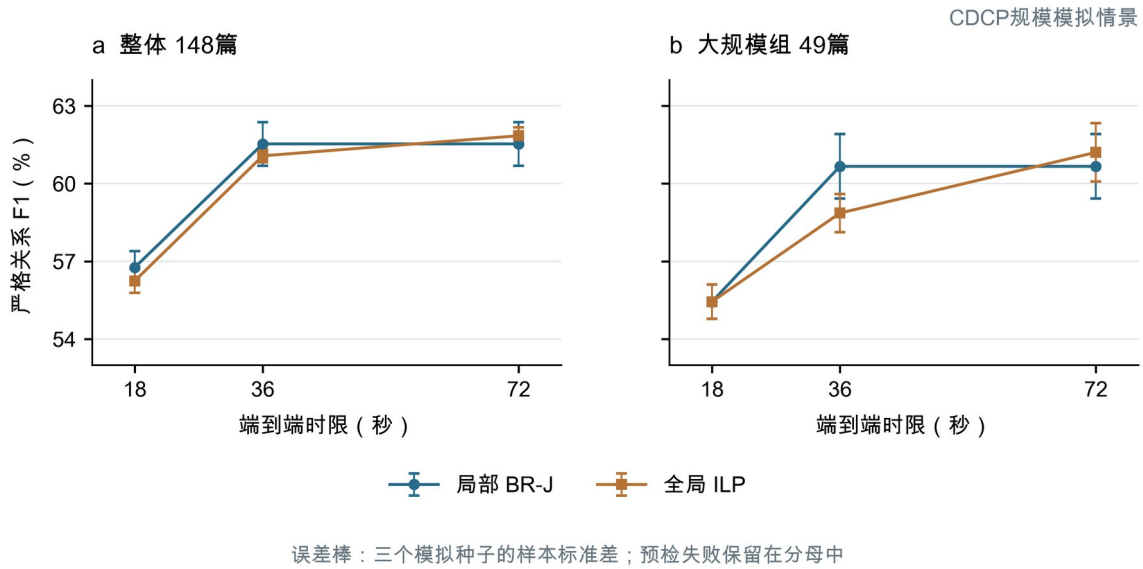



图 H-1 给定成本与完成度假设下的预算结果

在这一设定下，CDCP 大规模组 36 秒时局部关系 F1 较高；放宽至 72 秒后排序变化。其条件表达应为：若共同准备和两类求解轨迹具有所设关系，可能出现局部的条件优势。全局时间函数更陡本就使大规模紧时限下的完成比例偏低；改变相对速度或质量轨迹可能改变结论。此处不研究模拟模型本身，未据该情景选择实际阈值，也未把它用于摘要和方法定位。

图中误差棒为 17、29、43 三个模拟种子的样本标准差；原记录另保存按文档配对重采样 2000 次的全部区间及规模、预算组合。它们只表示给定生成假设后的变化，不反映函数或插值机制设错的风险。模拟状态与回退计数不能证明完整图合法或获得了 incumbent；实际优化器未执行，求解证书为 NOT_EXECUTED，gap 为空。旧表 4-8 的成本与本节来自不同轨道，不合并成运行曲线。

## H.8 对象重叠的非唯一性示例

既有旧情景对象记录为 684 个文档种子记录赋予抽象关系键，匹配 v6 四格未分组 TP、FP、FN 及 T1 到组合的风险总量，并不匹配 v7 主表。坐标、类型与端点均由程序构造，未重建完整组件预测图，也未约束源成员数分组；该文件只保留作非唯一性示例，不承担关于两阶段互补性的研究发现。

保持 T0I0、T1I0 和 T1I1 的集合不变，只重分配 T0I1 在初始遗漏金标中的新增对象。对每个文档种子，记两个单阶段新增命中数为 a、b，初始遗漏金标池大小为 M，则共同新增命中数可以在 $\max(0,a+b-M)$ 与 $\min(a,b)$ 之间变化。保留 T0I1 已命中的初始对象及全部 FP 不动，并从池中分别优先选择与另一阶段相交或不相交的对象，即可达到两个端点。此重分配保留四格所有严格关系成绩，也保留 T1 到组合的恢复、损失及 FP 变化。

逐文档累加后，AAEC 共同修复范围为 26—434，CDCP 为 158—550；旧补全选取的 353 / 505 只是其中一种构造。因此，计数足以约束成绩，却不足以确定共同修复和独有修复

的对象身份。此范围仅对声明的抽象关系集合成立，不证明完整图合法性、类型分组一致性或真实语料可行性。正文不再展示旧补全的重叠比例和合成坐标案例；原记录保留供复核。

旧版核验程序独立构造上述最小与最大交集，逐项检查旧计数及风险不变；它验证非唯一性这一构造结论，不新增模型运行。正式第五章应从同批四格实际输出对齐对象，保留原文、预测身份和具体改动，再判断重叠、损害或作用路径，不要求预先满足某种互补比例。