分类号 _____ 密 级 _____

U D C _____ 编 号 10486

武漢大學

硕 士 学 位 论 文

（学术学位）

基于结构增强语言模型的时序知识图谱推理方法研究

研 究 生 姓 名：蒋 梓 浩

学 号：2023202110051

校内导师姓名、职称：彭 敏 教 授

学科、专业名称：软 件 工 程

研 究 方 向：自 然 语 言 处 理

二〇二六年五月

Enhancing Temporal Knowledge Graph Reasoning with Structure-Augmented Language Models

Candidate: Zihao Jiang

Student number: 2023202110051

Supervisor: Prof. Min Peng

Major: Software Engineering

Speciality: Natural Language Processing



School of Computer Science

Wuhan University

May, 2026

论文原创性声明

本人郑重声明：所呈交的学位论文，是本人在导师指导下，独立进行研究工作所取得的研究成果。除文中已经标明引用的内容外，本论文不包含任何其他个人或集体已经发表或撰写过的研究成果。对本文的研究做出贡献的个人和集体，均已在文中以明确方式标明。本声明的法律结果由本人承担。

学位论文作者（签名）： 

2026 年 5 月 29 日

摘　　要

时序知识图谱（Temporal Knowledge Graph, TKG）是一类能够表示实体及其关系随时间动态变化的结构化知识表示形式，在智能问答、推荐系统以及金融分析等任务中具有重要的应用价值。相较于传统静态知识图谱，时序知识图谱不仅需要建模实体与关系之间的结构依赖，还需进一步捕捉其随时间变化的动态特征，为动态场景下的知识推理提供了重要支撑。然而，由于现实世界数据普遍存在稀疏性与不完整性，时序知识图谱中仍蕴含大量未观测的潜在事实及相关事件。因此，如何提出有效的时序知识图谱推理方法，以实现对潜在知识的准确预测，成为亟待解决的关键问题。

随着深度学习技术的发展，研究者开始探索融合时序知识图谱中的多源异质信息（如结构信息与文本语义），并结合时间因素进行建模，以提升模型的推理能力。近年来，语言模型在语义理解与表示方面展现出显著优势，能够在一定程度上弥补传统方法在语义建模与泛化能力方面的不足，从而为时序知识图谱推理提供了新的研究范式。然而，现有基于语言模型的时序知识图谱推理方法仍存在以下两方面不足。首先，语言模型基于序列建模范式，与时序知识图谱的结构化表示存在差异，难以建模复杂结构依赖与全局历史演化规律，进而影响推理结果的准确性。其次，现有方法在推理的可解释性方面仍存在不足，多数方法仍依赖嵌入表示学习框架，缺乏对推理过程的显式建模，导致推理过程不透明，从而限制其在实际应用中的可行性。

针对上述问题，本文围绕“基于结构增强语言模型的时序知识图谱推理”展开系统研究，旨在构建结构增强的语言模型推理框架，通过融合结构信息与语义信息实现统一建模，以提升语言模型对复杂结构依赖与时间演化规律的建模能力，从而提升推理的准确性和可解释性。具体工作如下：

（1）**针对预训练语言模型难以建模复杂结构依赖与全局历史演化规律的问题，本文提出一种基于预训练语言模型的结构增强时序知识图谱推理方法**。该方法以预训练语言模型为基础，通过融合图结构表示与时间相关历史上下文，并显式建模关系重现模式，实现结构信息、语义信息与时间演化规律的协同建模。一方面，将图空间中的实体与关系表示引入预训练语言模型，构建时间感知的软提示机制以实现结构嵌入向语言模型表示空间的映射，从而促进图结构与文本语义的对齐，提升模型对高阶结构依赖的建模能力；另一方面，针对时序知识图谱中的事实重现现象，引入全局历史重现模式建模机制，通过统计历史事实的频率分布，并结合时间窗口与权重机制强化近期信息，从而刻画时间演化规律，提升模型对动态变化的建模能力；在推理阶段，通过融合结构语义建模结果与历史重现模式建模结果，实现多源信息的有效整合，从而提升模型的预测性能与泛化能力。实验结果表明，所提方法在多个数据集上均显著优于现有方法，有效弥补了预训练语言模型在结构建模方面的不足。

（2）**针对现有方法在推理可解释性方面的不足，本文提出一种基于大语言模型的结构感知生成式时序知识图谱推理框架**。在数据层面，基于真实场景的时序知识图谱数据，提取与查询相关的子图推理链，并将其转化为自然语言形式，构建面向可解释过程的时序知识图谱推理基准，以系统评估现有方法的可解释推理能力。在方法设计层面，进一步提出结构感知的生成式推理模型。首先，引入时序结构感知编码器对历史知识进行建模，学习实体与关系的结构表示，以捕捉图结构中的依赖关系及其时间演化特征；其次，构建结构-文本对齐适配器，将结构表示映射至语言模型的语义空间，从而构建结构感知的输入表示，使结构信息能够被语言模型有效利用；最后，通过指令微调策略，将时序知识图谱推理任务统一建模为生成式任务，使模型能够同时输出预测结果及其对应的推理解释，从而实现推理过程的显式建模。实验结果表明，提出的方法在所构建的基准上优于现有方法，在预测准确性、解释生成质量与推理一致性方面均取得提升，进一步验证了结构增强语言模型在可解释推理任务中的有效性。

综上所述，本文系统研究了基于结构增强语言模型的时序知识图谱推理方法，从预训练语言模型的结构建模出发，逐步扩展至大语言模型的生成式推理，在推理准确性与可解释性方面均取得提升，进一步展现了语言模型在时序知识图谱推理中的应用潜力，并为复杂结构依赖建模与可解释推理问题提供了新的技术路径。

关键词：时序知识图谱推理; 语言模型; 时序知识图谱；结构信息

ABSTRACT

Temporal Knowledge Graphs (TKGs) are a class of structured knowledge representations that capture the temporal evolution of relationships among entities, and have demonstrated significant value in applications such as question answering, recommendation systems, and financial analysis. Compared with traditional static knowledge graphs, TKGs not only require modeling structural dependencies among entities and relations, but also capturing their dynamic temporal characteristics, thereby providing essential support for reasoning in dynamic environments. However, due to the inherent sparsity and incompleteness of real-world data, TKGs still contain a large number of unobserved facts and events. Therefore, designing effective temporal knowledge graph reasoning (TKGR) methods for accurate prediction of latent knowledge remains a critical research challenge.

With the advancement of deep learning, recent studies have explored integrating multi-source heterogeneous information in TKGs (e.g., structural information and textual semantics) with temporal modeling to enhance reasoning capabilities. In particular, language models have shown strong advantages in semantic understanding and representation, offering a new paradigm for TKGR. Nevertheless, existing language model-based approaches still face two key challenges. First, language models rely on sequence modeling, which differs fundamentally from the structured representation of TKGs, making it difficult to effectively capture complex structural dependencies and global temporal evolution patterns. Second, most existing methods lack interpretability, as they rely on implicit representation learning without explicitly modeling the reasoning process, resulting in limited transparency and reliability in practical applications.

To address these challenges, this thesis conducts a systematic study on temporal knowledge graph reasoning based on structure-enhanced language models. The objective is to develop a unified framework that integrates structural and semantic information through joint modeling, thereby enhancing the capability of language models to capture complex structural dependencies and temporal evolution patterns, while improving prediction accuracy and interpretability. The main contributions are summarized as follows:

(1) To address the limitations of pre-trained language models in modeling complex structural dependencies and global temporal evolution patterns, this work proposes a structure-enhanced TKGR method based on pre-trained language models. Specifically, the proposed method integrates graph structural representations with temporal historical information and explicitly models relational recurrence patterns, enabling the joint modeling of structural in-

formation, semantic information, and temporal dynamics. On the one hand, a time-aware soft prompt mechanism is introduced to incorporate entity and relation representations from the graph space into the language model input, aligning structural embeddings with textual semantics and improving the modeling of high-order structural dependencies. On the other hand, a global historical recurrence modeling module is designed to capture recurrence phenomena in TKGs by modeling the frequency distribution of historical facts. Furthermore, time window and time weighting mechanisms are employed to emphasize recent historical information, thereby enhancing the modeling of temporal evolution. During inference, structural-semantic modeling and historical recurrence modeling are jointly integrated to achieve effective multi-source information fusion. Experimental results demonstrate that the proposed method consistently outperforms existing approaches on multiple benchmark datasets, significantly improving prediction performance and generalization ability.

(2) To address the limitations of existing methods in interpretability, this work further proposes a structure-aware generative TKGR framework based on large language models. At the data level, an explainable TKGR benchmark is constructed by extracting query-related subgraph reasoning chains from real-world TKGs and transforming them into natural language explanations, enabling unified evaluation of prediction performance and explanation quality. At the model level, a structure-aware generative reasoning model is developed. Specifically, a temporal structure-aware encoder is introduced to model historical structural information and learn representations of entities and relations, capturing structural dependencies and temporal evolution patterns. A structure-text alignment adapter is further designed to map structural representations into the semantic space of the language model, enabling effective utilization of structural information. Finally, through instruction tuning, the TKGR task is reformulated as a generative process, allowing the model to simultaneously produce prediction results and corresponding reasoning explanations, thereby achieving explicit modeling of the reasoning process. Experimental results show that the proposed framework outperforms existing methods across multiple datasets, achieving improvements in prediction accuracy, explanation quality, and reasoning consistency, while demonstrating strong robustness and generalization capability.

In summary, this thesis systematically investigates temporal knowledge graph reasoning based on structure-enhanced language models. Starting from structural modeling with pre-trained language models, the study is further extended to generative reasoning with large language models. The proposed approaches achieve significant improvements in both prediction accuracy and interpretability, demonstrating the effectiveness of integrating structural

and semantic information. This work provides new insights into structure-enhanced language modeling and establishes a solid foundation for explainable temporal reasoning in real-world complex scenarios.

Keywords: Temporal Knowledge Graph Reasoning; Language Model; Temporal Knowledge Graph; Structural Information

目　录

摘　要 . . . . . **I**

ABSTRACT . . . . . **III**

第 1 章　绪论 **1**

1.1　研究背景与意义 1

1.2　国内外研究现状 3

1.2.1　基于图结构模型的时序知识图谱推理方法 4

1.2.2　基于语言模型的时序知识图谱推理方法 5

1.2.3　基于时序知识图谱的推理应用 6

1.3　主要研究内容 7

1.4　论文的组织架构 9

第 2 章　相关理论与技术 **12**

2.1　时序知识图谱推理定义 12

2.2　时序知识图谱推理方法 13

2.2.1　基于图结构模型的方法 13

2.2.2　基于语言模型的方法 15

2.3　参数高效微调 16

2.3.1　基于输入空间的方法 16

2.3.2　基于模型参数的方法 17

2.4　本章小结 18

第 3 章　基于预训练语言模型的结构增强时序知识图谱推理方法 . . . **20**

3.1　引言 20

3.2　问题定义 23

3.3　联合结构与历史重现模式增强的预训练语言模型 23

3.3.1　结构与语义协同建模模块 23

3.3.2　全局历史重现模式建模模块 25

3.3.3　模型训练与推理 26

3.4　实验与分析 27

3.4.1　实验数据集与评测指标 27

3.4.2　基线方法 28

3.4.3 实验设置 28
3.4.4 主要实验结果 30
3.4.5 消融实验 31
3.4.6 四元组频次分布分析 32
3.4.7 训练策略有效性分析 33
3.4.8 模型泛化性能分析 35
3.4.9 超参数敏感性分析 36
3.5 本章小结 37

第 4 章 基于大语言模型的结构感知生成式时序知识图谱推理框架 . . 38
4.1 引言 38
4.2 问题定义 41
4.3 面向可解释过程的时序知识图谱推理基准 41
4.3.1 样本构建与划分策略 43
4.3.2 推理链文本构建 44
4.3.3 可解释文本生成 45
4.3.4 数据质量控制 46
4.4 结构感知的生成式推理模型 46
4.4.1 时序结构感知编码器 47
4.4.2 结构-文本对齐适配器 47
4.4.3 基于指令微调的可解释推理优化 48
4.5 实验与分析 49
4.5.1 实验数据集与评测指标 49
4.5.2 基线方法 49
4.5.3 实验设置 50
4.5.4 主要实验结果 51
4.5.5 消融实验 56
4.5.6 模型泛化性与鲁棒性分析 56
4.5.7 训练策略有效性分析 58
4.5.8 案例分析 59
4.6 本章小结 60

第 5 章 总结与展望 61
5.1 全文工作总结 61

5.2 未来工作展望 62

参考文献 64

攻硕期间发表的与学位论文相关的科研成果目录 74

致谢 76

图目录

1.1 时序知识图谱的四元组形式示意图 1
1.2 论文整体研究内容框架图 8
1.3 论文组织结构图 10

2.1 ECOLA 模型结构图 15

3.1 现有 PLM-based 的方法面临的两个挑战 21
3.2 PSG 的总体框架示意图 24
3.3 ICEWS 系列数据集上四元组频次分布分析结果 33
3.4 不同图模型下 PSG 在 ICEWS14 数据集上的性能对比（单位：%） . . . 35
3.5 不同预训练语言模型下 PSG 在 ICEWS14 数据集上的性能对比（单位：%） 35
3.6 时间权重系数 k 的敏感性分析，横轴是 k，纵轴是 MRR（单位：%） . 36
3.7 时间窗口大小 w 的敏感性分析，横轴是 w，纵轴是 MRR（单位：%） . 36

4.1 现有时序知识图谱推理方法与本文方法的对比示意图 39
4.2 ETR 基准构建流程 42
4.3 可解释文本生成工作流提示 45
4.4 GETER 模型总框架图 47
4.5 不同编码器下 GETER 在 ICEWS14 与 GDELT 数据集上的性能对比（单位：%） 57
4.6 不同 MLP 层数设置下 GETER 在 ICEWS14 与 GDELT 数据集上的性能对比（单位：%） 58
4.7 GETER 与 LoRA 微调方法在五个数据集上的训练时间对比（单位：小时） 58

表格目录

3.1 模型 PSG 评测数据集统计信息 27
3.2 PSG 实验环境配置 29
3.3 PSG 模型主要超参数设置 29
3.4 各模型在 ICEWS14、ICEWS18 和 ICEWS05-15 数据集上的实验结果统计（单位：%） 30
3.5 不同模块对 PSG 性能的影响（单位：%） 31
3.6 不同冻结参数策略下,PSG 在 ICEWS14 上的性能（单位：%） 33
3.7 各模型在 ICEWS14 数据集上的模型规模与单轮训练时间 34
3.8 不同历史采样策略在 ICEWS14 数据集上的性能对比（单位：%） 34

4.1 ETR 基准的数据统计信息 42
4.2 ETR 基准质量人工评估结果 46
4.3 GETER 实验环境配置 50
4.4 模型训练与推理阶段的主要超参数设置 50
4.5 GETER 在 ICEWS14 数据上预测任务的性能结果（单位：%） 51
4.6 GETER 在 ICEWS18 数据上预测任务的性能结果（单位：%） 52
4.7 GETER 在 ICEWS05-15 数据上预测任务的性能结果（单位：%） 52
4.8 GETER 在 GDELT 数据上预测任务的性能结果（单位：%） 53
4.9 GETER 在 WIKI 数据上预测任务的性能结果（单位：%） 53
4.10 GETER 在 ICEWS14, GDELT 以及 ICEWS05-15 数据上解释生成任务的性能结果（单位：%） 55
4.11 GETER 在 ICEWS18 和 WIKI 数据上解释生成任务的性能结果（单位：%） 55
4.12 GETER 在不同模块配置下的消融实验结果（单位：%） 56
4.13 不同的推理链输入方式下 GETER 在 ICEWS14 数据集上的性能对比 . . 57
4.14 GETER 与基线方法的案例对比 59

第 1 章　绪论

1.1　研究背景与意义

在信息技术快速发展的背景下，人工智能技术正以前所未有的速度演进，人类社会由此进入数据规模持续爆发增长的时代。无论是日常社交活动、电子商务行为，还是金融、医疗等关键领域，均在持续产生海量数据。这类数据不仅规模庞大、信息丰富，同时也呈现出多源异构、强关联性与高复杂性等特点，对数据的有效组织、语义理解与深层利用提出了更高要求[1]。在此背景下，如何从海量数据中构建结构化知识，并基于知识开展有效推理，成为当前人工智能领域的重要研究问题。

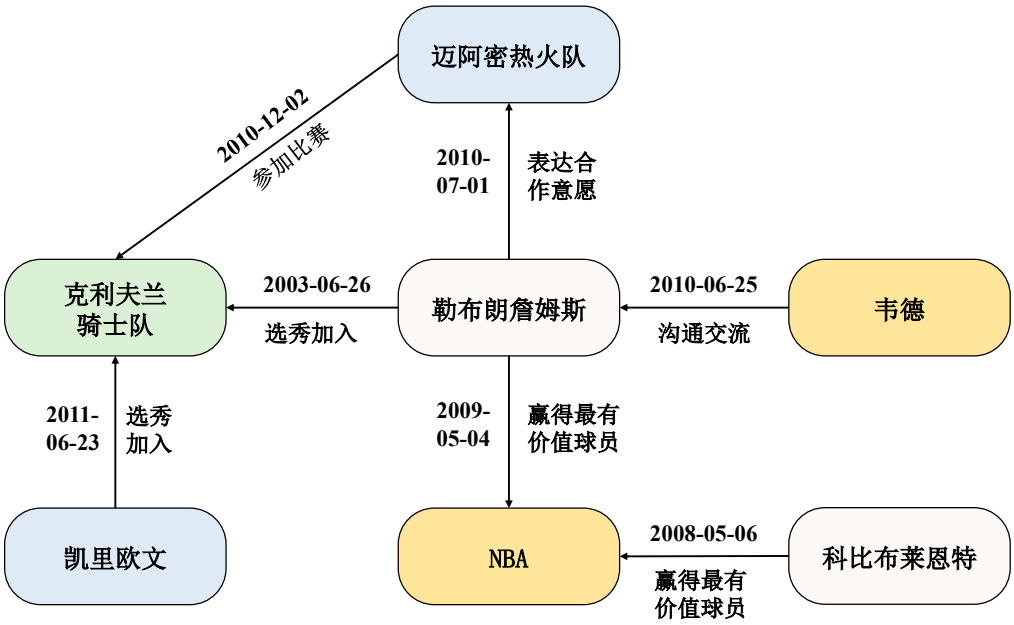


图 1.1 时序知识图谱的四元组形式示意图

知识图谱（Knowledge Graph, KG）作为一种结构化表示现实世界知识的技术，通过将分散且异构的数据组织为统一的语义网络，为知识的存储、管理与推理提供了重要支撑。相比传统的非结构化数据表示方式，知识图谱通过三元组形式（头实体，关系，尾实体）对知识进行显式建模，使得实体之间的语义关系能够被有效刻画，从而在智能问答[1–3]、推荐系统[4]、医疗诊断[5]以及金融分析[6]等多个领域得到了广泛应用。然而，传统知识图谱基于静态三元组的表示方式，难以刻画知识随时间变化的演化过程。现实世界中的知识往往呈现出持续演化的动态特性，实体之间的关系会随着事件的发生与发展不断更新，如国家间关系的变化、企业合作关系的调整等，这些都体现出显著的时间依赖性。为应对上述挑战，时序知识图谱（Temporal Knowledge Graph, TKG）被提出，通过在三元组基础上引入时间维度，将知识表示扩展为四元组（头实体、关系、尾实体、时间戳），从而实现对实体关系随时间变化的建模。如图 1.1所示，

四元组（勒布朗詹姆斯，选秀加入，克利夫兰骑士队，2003-06-26）表示在 2003 年 6 月 26 日，勒布朗詹姆斯通过选秀加入克利夫兰骑士队的事实。其中，时间戳刻画了该事实发生的具体时间，使知识表示不仅包含实体及其关系，还能够反映实体关系的时间依赖性，从而更准确地刻画现实世界中知识的动态演化过程。

尽管如此，在实际应用中构建的时序知识图谱通常规模庞大且存在不完整性。一方面，受数据采集过程中的噪声、信息缺失以及观测偏差等因素影响，现有数据难以全面覆盖真实世界中的全部事实；同时，知识抽取与构建方法的精度限制也会引入错误或遗漏，从而加剧时序知识图谱的不完整性。另一方面，随着时间的演化，新的事实不断产生，已有知识也可能发生变化，使得时序知识图谱需要持续更新与扩展。这种不完整性与动态性进一步制约了知识表示的完备性与一致性。因此，有必要在已有时序知识的基础上建模实体关系的演化规律，以推断潜在事实并补全缺失信息。在此背景下，时序知识图谱推理（Temporal Knowledge Graph Reasoning, TKGR）逐渐成为该领域的重要研究方向。其核心目标是在已有的时序知识基础上，挖掘潜在关联与演化模式，从而实现对未观测事实及未来事件的预测（即知识补全），并提升对复杂现实世界的刻画能力。现有的时序知识图谱推理任务通常可以划分为两种设定：插值推理和外推推理[7–8]。其中，插值推理任务主要关注在已观测时间范围内对缺失事实进行预测，即在已知时间戳区间内补全未观测到的实体关系；而外推推理任务则基于历史时序知识，推断未来时间点上尚未发生或尚未观测到的事实，从而刻画知识的演化趋势。

随着深度学习技术的快速发展，研究者逐渐关注如何充分利用时序知识图谱中蕴含的多源异质信息，包括图结构、实体类型以及文本描述等，并结合时间因素对实体和关系进行有效建模，以提升时序知识图谱推理性能。围绕这一问题，现有研究从多个角度展开了广泛探索。早期研究主要集中于基于表示学习和基于图神经网络（Graph Neural Networks, GNN）的建模范式。基于表示学习的方法通常依赖距离度量[9]或语义匹配[10]假设，对单个时序四元组进行打分，通过学习实体与关系的低维嵌入表示来刻画其关联信息，从而具备对局部事实的建模能力。相比之下，基于图神经网络的方法通过对时序知识图谱的结构信息进行建模，利用消息传递机制融合实体的邻域信息[11]，并结合时间因素刻画实体关系的动态依赖[12]，在一定程度上提升了对复杂结构模式的表达能力。然而，上述两类方法在语义理解能力与复杂模式建模方面仍存在显著局限。一方面，基于表示学习的方法通常侧重于对局部结构或独立事实进行建模，难以有效捕捉实体关系在时间维度上的长期依赖与复杂演化规律，例如周期性模式与长期趋势，从而限制了其对动态知识的刻画能力；另一方面，基于图神经网络的方法主要依赖结构信息进行建模，对实体名称及文本描述等语义信息的利用不足，从而在复杂语义关系建模方面存在一定局限性。

近年来，随着以 BERT[13] 为代表的预训练语言模型（Pre-trained Language Models, PLMs）的发展，语言模型在语义理解与表示方面取得了显著进展。在此基础上，伴随训练语料规模的持续扩展与模型架构的不断演进，以 ChatGPT[14] 和 DeepSeek[15] 为代表的大语言模型（Large Language Models, LLMs）逐渐兴起，并展现出更强的建模能力与泛化性能，为时序知识图谱推理提供了新的研究范式与技术路径。一方面，语言模型能够充分挖掘文本中的上下文语义信息，提升对实体关系的语义建模能力；同时，得益于大规模预训练，其在数据稀疏或未见关系模式下仍具备较强的泛化能力从而增强模型在复杂动态环境中的适应性与鲁棒性。另一方面，语言模型具备较强的自然语言生成能力，能够以可读文本形式呈现推理过程，构建连贯的推理逻辑链，从而提升推理过程的透明性，并为复杂推理任务中的结果验证与分析提供支持，更好地满足实际应用需求。

然而，现有研究表明[16–18], 利用语言模型解决时序知识图谱推理问题仍然面临诸多挑战。**首先，语言模型与时序知识图谱在表示模态上存在显著差异，使其难以直接适用于该任务**。语言模型主要基于自然语言序列进行建模，擅长捕捉上下文语义信息，但缺乏对图结构的显式建模能力以及对时序依赖关系的先验刻画；而时序知识图谱以结构化形式组织知识，蕴含丰富的结构与时间特性，例如多跳关联、重现模式以及长期依赖等。这类复杂的结构依赖和动态演化模式难以直接通过序列建模方式进行有效刻画，从而对语言模型构成了本质挑战。**其次，现有方法在推理可解释性方面仍存在明显不足**。现有时序知识图谱推理方法多基于嵌入表示学习框架，通过学习实体与关系的低维表示并构建评分函数进行排序预测。其推理过程隐含于模型参数之中，缺乏显式建模，难以提供可验证的推理依据，从而限制其在实际应用中的可解释性与可靠性。尤其在复杂时序逻辑与高风险决策场景中，如政策分析、医疗诊断等典型应用场景，模型除需具备预测能力外，还需提供可解释且可追溯的推理过程，以支撑可靠决策。随着大语言模型的快速发展，其在语义理解与生成能力上的优势使可解释生成式推理成为可能。然而，大语言模型在推理过程中容易产生幻觉问题[18]，即生成看似合理但与真实世界不一致的结果，从而削弱推理结果的可靠性[19]。在复杂推理场景中，该问题可能引发错误信息的累积与传播，进而影响模型的稳定性与实际应用价值。综上所述，如何使语言模型感知并有效利用时序知识图谱中的结构信息，实现结构与语义的协同推理，从而提升推理的准确性与可解释性，已成为亟待解决的关键研究问题。

1.2 国内外研究现状

时序知识图谱是在传统知识图谱基础上引入时间信息而形成的一种动态知识表示形式，其核心组成单位由（头实体，关系，尾实体，时间戳）构成的时序四元组以及相关属性信息。通过在关系中显式建模时间维度，时序知识图谱能够刻画实体关系随时

间的演化过程，从而构建出具有动态特性的知识网络结构。相较于文档文本等非结构化数据，时序知识图谱不仅包含丰富的结构信息与语义信息，还蕴含关键的时间依赖与演化规律。在上述背景下，围绕时序知识图谱推理问题，研究者从不同角度展开了广泛探索。总体而言，现有时序知识图谱推理方法可以从建模范式上划分为两类：基于图结构模型的方法与基于语言模型的方法。前者依赖结构特性与历史演化规律进行建模，后者借助语义建模与生成能力实现推理。与此同时，相关技术已在问答等实际场景中得到广泛应用，进一步推动了该领域的发展。基于此，本小节将从上述两类方法及典型应用场景三个方面，对国内外研究现状进行系统综述。

1.2.1 基于图结构模型的时序知识图谱推理方法

基于图结构模型的时序知识图谱推理方法从结构与时间两个维度建模知识图谱的演化过程，通过刻画实体、关系与时间之间的交互关系以及局部结构与路径依赖，实现对实体关系动态变化的建模，从而支持未来事实预测与缺失事实补全。根据建模方式的不同，现有方法大致可分为：基于空间距离的方法、基于张量分解的方法、基于图神经网络的方法以及基于历史模式建模的方法。

基于空间距离方法通过将时序知识图谱中的事实表示映射到低维嵌入空间，并通过对实体、关系及时间戳向量施加平移约束，使其满足特定的几何关系，从而实现对缺失事实的建模。代表方法如 TTransE[9]，通过在 TransE[20]模型基础上引入时间维度，将时间信息融入平移操作中，从而能够对简单的时序演化过程进行建模。HyTE[21]通过将时序知识图谱按照时间顺序划分为多个静态知识子图，并将每个时间戳对应的三元组投影到相应的超平面中，从而实现对时间演化过程的建模。进一步地，基于张量分解的方法通常基于张量分解思想，将时序知识图谱表示为高阶张量，并通过分解学习实体、关系及时间的潜在表示。典型方法如 TA-DistMult[22]，通过引入时间编码机制，将实体、关系与时间信息进行融合，从而实现对时序关系的建模；TComplEx[23]在复数空间中对包含时间维度的事实张量进行分解，引入时间嵌入向量以刻画动态变化过程，从而能够有效建模不对称关系。总体而言，上述两类方法具备结构简单、计算效率高等优势，但受限于局部四元组建模，其在刻画复杂时序依赖关系时往往面临性能瓶颈。

图神经网络通过其对图结构的全局建模能力，为时序知识图谱推理提供了新的建模范式，使得对多跳关联的刻画成为可能，从而推动了该领域的发展。这类方法通过在图结构上进行多轮消息传递，聚合实体的邻域信息，并结合时间编码或循环神经网络对历史图结构进行建模，从而能够更好地刻画实体关系的动态演化过程，并提升对复杂结构依赖的建模能力。该类方法通常以关系图卷积网络（Relational Graph Convolutional Networks, R-GCN）[24] 为基础，通过关系感知的邻域聚合机制学习实体的结构表示，从

而捕捉知识图谱中的多关系结构依赖。在此基础上，RE-GCN[12] 将关系感知的图卷积网络与循环神经网络相结合，将时序知识图谱建模为一系列随时间演化的图结构，并通过递归方式学习实体与关系在不同时间步的动态表示，从而同时刻画结构依赖与时间序列模式；RE-NET[7] 从时间序列建模的角度出发，将时序知识图谱推理建模为自回归过程，通过循环神经网络对历史事件序列进行编码，并结合邻域聚合机制刻画同一时间步内的结构信息，从而实现对未来事件的预测。进一步地，针对时序依赖建模不足的问题，HGLS[25]通过将时序知识图谱序列转化为全局图，引入层次化关系型图神经网络以同时建模长短期时间依赖，并通过门控融合机制自适应地整合实体与关系的多尺度时序表示，从而提升模型对复杂时间演化模式的刻画能力。此外，L^2TKG[26]则关注时序知识图谱中未显式建模的潜在关系，通过设计潜在关系学习模块，同时挖掘同一时间及跨时间的隐含关联，从而弥补传统方法仅依赖显式结构信息的不足。然而，这类基于图神经网络的方法仍主要依赖局部邻域信息进行建模，在捕捉跨时间的长距离依赖及全局结构模式方面存在局限。

针对基于图神经网络的方法在建模长期时间依赖方面的不足，研究者从历史演化规律的角度出发，提出了基于历史模式建模的方法。这类方法通过显式挖掘历史事件序列中的潜在时间依赖，从而提升模型预测的泛化能力。具体地，一些方法侧重于建模历史事件中的重复模式与统计规律，通过对历史事实的出现频率或重复性进行建模，刻画实体关系的周期性与演化趋势，代表性方法如 CyGNet[27] 和 SiMFy[28]。另一些方法通过学习历史依赖关系来刻画时间演化过程。例如，CENET[29] 通过对历史事件序列进行自监督建模，并引入对比学习机制区分历史依赖与非历史依赖，从而有效刻画实体关系的动态演化模式；xERTE[30] 基于强化学习框架，在查询相关子图上进行推理，通过时间感知的注意力机制与迭代邻域扩展策略，联合建模结构特征与时间动态，从而更好地捕捉复杂的因果依赖关系。此外，一些研究从尝试从可解释性的角度出发，通过挖掘时序逻辑规则进行推理。例如，TLogic[31] 基于时间随机游走提取时序逻辑规则，用于建模实体之间的时间一致性关系，不仅提升了模型性能，同时在归纳场景中表现出良好的泛化能力。尽管上述方法在结构建模与时间依赖刻画方面取得进展，但其建模范式仍局限于单一结构信息，难以实现多源信息的有效融合，从而在通用性与推理效率方面受到制约。

1.2.2 基于语言模型的时序知识图谱推理方法

随着预训练语言模型的发展，语言模型方法逐渐被引入时序知识图谱推理；伴随训练语料规模的扩展与模型架构的演进，大语言模型的兴起进一步推动了该方向的演化。这类方法通过将结构化四元组转化为文本序列，实现对实体、关系与时间信息的统一语义建模，从而利用其语义理解与生成能力提升推理性能。相较于基于图结构的

建模范式，该类方法更侧重语义层面的推理能力。

早期研究主要通过将预训练语言模型适配于时序知识图谱任务，实现对结构化信息的语义编码。例如，PPT[32] 通过构造提示模板，将实体、关系及时间信息转化为“[CLS] 头实体 [SEP] 关系 [SEP] 尾实体 [SEP] 时间戳 [SEP]”的文本序列输入，同时引入历史时间间隔模板，并将时序知识图谱推理任务重构为掩码语言建模任务，从而利用预训练语言模型进行预测；ChapTER[33] 提出统一的伪孪生框架，通过共享参数对实体、关系和时间进行编码，并结合前缀微调策略提升时间建模能力；CoPET[34] 进一步引入对比学习机制，通过融合时间不变信息增强时序表示学习能力。上述方法通过文本化结构化时序知识以发挥语言模型的语义建模能力，但其建模范式仍依赖隐式表示学习与候选排序，缺乏对推理过程的显式刻画。

随着大语言模型能力的持续增强，相关研究逐步探索其在时序推理任务中的直接建模能力。例如，Lee 等人[35]利用大语言模型的上下文学习能力，通过设计示例与提示模板，在无需参数更新的情况下实现时序推理；CoH[36]提出基于历史链的推理框架，通过逐步探索高阶历史事实，实现对长距离时间依赖的建模，从而提升预测性能；TimeLlaMA[37] 通过构造结构化输入序列并结合语言模型的生成能力，实现一定程度的可解释推理。在此基础上，近期研究进一步探索将大语言模型与符号推理相结合，以提升时序知识图谱推理的可解释性。GenTKG[38] 通过引入逻辑规则挖掘与检索策略，并结合指令微调（Instruction Tuning），使大语言模型能够直接生成预测结果；LLM-DA[39]则提出一种由大语言模型引导的动态适应方法，通过从历史数据中抽取时序逻辑规则，显式刻画实体关系的时间演化模式。这些规则不仅能够揭示潜在的时间依赖关系，还为推理过程提供了可解释的依据。总体而言，语言模型方法为时序知识图谱推理提供了新的建模范式，通过语义建模与生成能力提升推理性能，并在一定程度上增强模型的可解释性。然而，现有方法仍主要停留于判别式框架，缺乏对推理过程的显式建模与可追溯性。此外，结构化时序依赖与历史信息的有效融合以及模型幻觉的抑制，仍是亟待突破的关键问题。

1.2.3 基于时序知识图谱的推理应用

随着时序知识图谱推理方法的不断发展，相关研究逐渐由结构建模与事实预测范式，拓展至面向复杂应用场景的推理问题。其中，时序知识图谱问答（Temporal Knowledge Graph Question Answering, TKGQA）作为典型应用，受到了广泛关注。与传统的时序知识图谱推理任务不同，时序知识图谱问答需要基于查询问题，从时序知识图谱中检索相关证据，并进行多步推理以获得最终答案。这类任务通常涉及复杂的时间约束（如“之前/之后”“首次/末次”）以及跨时间的多跳推理过程，对模型的时序建模能力与推理能力提出了更高要求。因此，时序知识图谱问答可以被视为对时序知识图

谱推理能力的进一步扩展与综合检验，不仅需要模型具备对结构与时间依赖的建模能力，还需要具备面向问题的动态推理与证据整合能力。

现有时序知识图谱问答方法主要可以分为两类：基于表示学习的方法以及基于语言模型的方法。基于表示学习的方法通常将时序知识图谱问答建模为补全范式，通过学习实体、关系与时间的嵌入表示实现推理。例如，MultiQA[40]、TempoQR[41]等方法，均基于表示学习框架，通过构建评分函数评估候选答案的合理性。尽管上述方法在性能上有所提升，但其建模范式本质上仍依赖候选事实评分，难以刻画多步推理过程及复杂时间依赖关系。近年来，随着语言模型的发展，研究者开始探索基于语言模型的时序知识图谱问答方法。这类方法通常将问题视为对时序知识图谱的查询，通过检索相关历史事实并结合语言模型进行推理。例如，ARI[42]通过引入时间感知的训练信号增强模型对时序信息的建模能力；TempAgent[43]将语言模型建模为交互式智能体，通过多步交互完成推理过程；TimeR^4[44]通过优化提升检索模块，提高模型对关键历史证据的获取能力；而 RTQA[45]则通过问题分解策略，将复杂问题拆解为多个子问题，并结合语言模型逐步求解。

尽管现有方法取得一定进展，但其建模范式仍停留于基于评分的框架，缺乏对推理过程的显式刻画。在实际应用中，决策主体除关注预测准确性外，更强调推理的可靠性与可解释性，以获得可验证且可追溯的决策依据。因此，构建兼具准确性、可靠性与可解释性的时序知识图谱推理框架，已成为该领域亟待突破的关键问题。

1.3 主要研究内容

尽管基于语言模型的时序知识图谱推理方法已取得一定进展，但仍面临以下两方面的关键挑战。首先，该类方法主要依赖文本语义建模，通常将结构化四元组转化为序列文本输入，这种建模方式忽略了时序知识图谱中两类关键结构特征：高阶结构依赖关系与全局重现模式。其中，高阶结构依赖关系指实体间通过多跳路径形成的间接关联，例如国家 A 可能通过国家 B 与国家 C 建立合作关系，该类关系难以通过单一邻域信息进行有效刻画；全局重现模式则指事件在时间维度上的重复出现或周期性变化，例如同一实体之间的合作关系在不同时间多次发生，反映了潜在的时间演化规律。其次，现有方法多基于嵌入表示学习范式，其推理过程隐含于模型参数之中，缺乏显式刻画，难以提供可解释的推理过程与可验证的决策依据。随着训练语料规模的不断扩大，预训练语言模型持续向大语言模型演进。随着预训练语言模型向大语言模型演进，模型规模与架构持续扩展，逐步形成以生成范式为核心的建模方式，为解决上述问题提供了新的研究路径。具体地，大语言模型通过其语义建模与文本生成能力，在支持复杂推理的同时，能够以自然语言形式输出结果（即生成式推理），从而提升推理过程的可解释性与实用性。然而，利用大语言模型实现可解释的时序知识图谱推理仍

存在诸多挑战。一方面，大语言模型难以显示感知并有效利用时序知识图谱中的结构依赖关系及历史演化信息，导致推理过程缺乏结构约束，易产生与事实不一致的“幻觉”问题，从而影响推理结果的可靠性；另一方面，随着模型规模的不断扩大，相关方法仍需在计算与存储开销之间取得平衡，以满足实际应用中的效率需求。

为应对上述挑战，本文围绕“基于结构增强语言模型的时序知识图谱推理”展开系统性研究，旨在构建结构增强的语言模型推理框架，通过融合结构信息与语义信息实现统一建模，以提升语言模型对复杂结构依赖关系与时间演化规律的建模能力，从而提升推理的准确性和可解释性。如图 1.2所示，本文的研究内容可以划分为两部分：

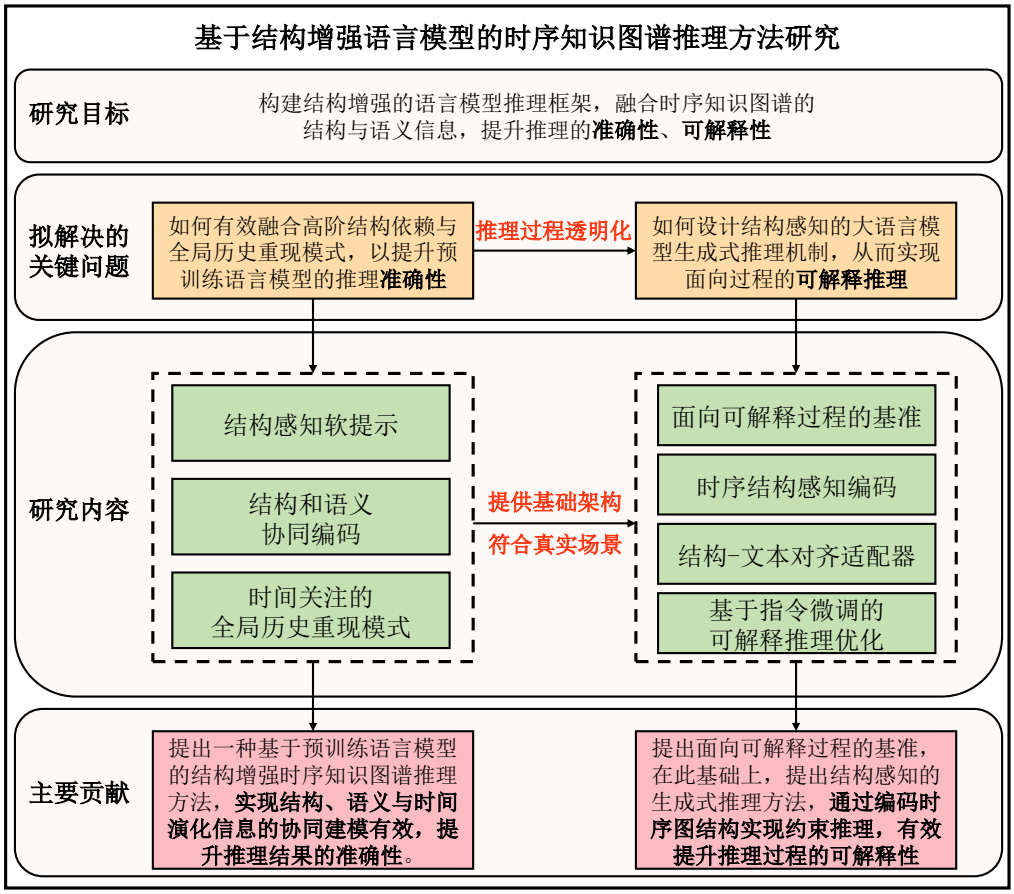


图 1.2 论文整体研究内容框架图

（1）基于预训练语言模型的结构增强时序知识图谱推理方法

为了解决预训练语言模型难以直接建模时序知识图谱中复杂结构依赖关系与全局历史演化模式的问题，本文提出一种基于预训练语言模型的结构增强时序知识图谱推理方法。该方法以预训练语言模型为基础，通过融合图结构表示与时间相关历史上下文，并显式建模关系重现模式，实现结构信息、语义信息与时间演化规律的协同建模。一方面，将图空间中的实体与关系表示引入预训练语言模型，通过设计时间感知的软提示，将结构嵌入映射到语言模型的表示空间，实现图结构与文本语义的有效对齐，

以增强模型对高阶结构依赖关系的建模能力；另一方面，针对时序知识图谱中广泛存在的关系重现现象，本文进一步引入全局历史重现模式建模机制，通过统计历史事实中的频率分布信息，捕捉具有时间相关性的全局演化规律，并通过时间窗口与时间权重机制强化近期历史信息对预测结果的影响，从而提升模型对时间动态变化的刻画能力；在推理阶段，通过融合结构语义协同建模模块与历史重现模式建模模块的预测结果，实现多源信息的联合建模，从而提升模型在复杂时序推理任务中的预测准确性与泛化能力。实验结果表明，所提出的方法在多个数据集上均显著优于现有方法，有效弥补预训练语言模型在结构建模方面的不足，显著提升模型在时序知识图谱推理任务中的性能，并具备良好的泛化性能与计算效率。

（2）基于大语言模型的结构感知生成式时序知识图谱推理框架

现有大多数时序知识图谱推理方法仍属于隐式嵌入表示学习框架，侧重预测性能而缺乏对推理过程的显式建模，导致推理过程不透明、可解释性不足，进而限制了模型在实际应用中的可行性。尽管语言模型的发展，尤其是大语言模型的兴起，为实现面向可解释过程的时序推理提供了新的可能，但其主要依赖文本语义建模，容易产生“幻觉”问题。具体而言，该类方法难以充分刻画时序知识图谱中的结构化特征，进而导致生成结果难以满足结构约束，从而影响推理的可靠性与一致性。针对上述问题，提出一种基于大语言模型的结构感知生成式时序知识图谱推理框架。在数据层面，本文基于新闻事件、国际关系以及结构化知识真实场景的时序知识图谱数据，提取与查询相关的子图推理链，并将其转化为对应的自然语言描述，从而构建面向可解释过程的时序知识图谱推理基准，以系统评估模型的可解释推理能力。在方法设计层面，首先引入时序结构感知编码器对历史知识进行建模，学习实体与关系的结构表示，以有效捕捉图结构中的依赖关系及其时间演化特征；其次，进一步设计结构-文本对齐适配器，将结构表示映射至语言模型的语义空间，从而构建结构感知的输入表示，使结构信息能够被大语言模型充分感知与利用；最后，通过指令微调策略，将时序知识图谱推理任务统一建模为生成式任务，使模型能够同时输出预测结果及其对应的推理解释文本，实现对推理过程的显式建模。实验结果表明，提出的方法在所构建的基准上优于现有方法，不仅在预测准确性方面实现了提升，同时在解释生成质量与推理一致性方面表现出明显优势，验证了结构增强语言模型在可解释时序推理任务中的有效性。

1.4 论文的组织架构

本文共分为五个章节，整体组织结构如图 1.3所示。

第 1 章阐述绪论。主要围绕时序知识图谱推理的研究背景与意义展开论述。首先，分析了开展知识表示与推理研究的必要性，引出时序知识图谱及其推理问题的重要研究价值；其次，系统梳理国内外在时序知识图谱推理领域的研究现状，进一步明确本

文所关注的关键问题与研究挑战；最后，给出本文的主要研究内容与技术路线，并对论文整体结构进行说明。

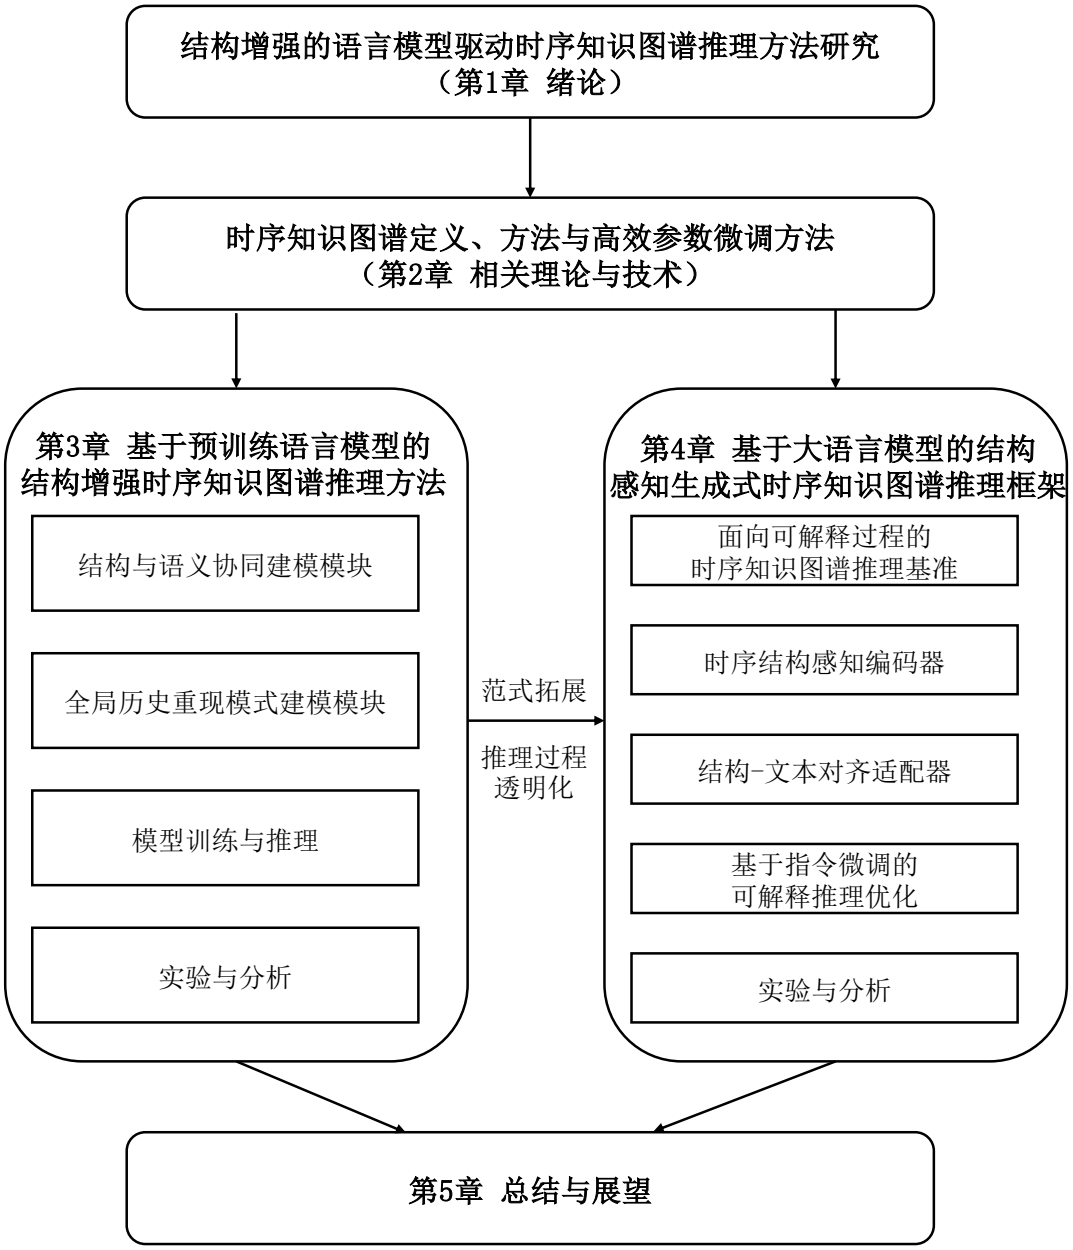


图 1.3 论文组织结构图

第 2 章介绍相关理论与技术。首先对时序知识图谱及其推理任务进行形式化定义，随后系统综述现有时序知识图谱推理方法，包括基于图结构模型的方法与基于语言模型的方法，并进一步介绍参数高效微调技术，为后续方法设计提供理论基础支撑。

第 3 章介绍提出的基于预训练语言模型的结构增强时序知识图谱推理方法。该方法通过构建结构与语义协同建模模块，将图结构信息与文本语义表示进行融合，同时设计全局历史重现模式建模模块以捕捉长期时间依赖关系，并结合相应的训练与推理

策略，实现对时序知识的有效建模与推理。最后，通过在多个数据集上的系统实验，从预测性能与泛化能力等方面全面验证所提出方法的有效性。

第 4 章介绍提出的基于大语言模型的结构感知生成式时序知识图谱推理框架。在第 3 章所提出的结构增强语言模型建模框架基础上，进一步引入生成式推理范式，以实现推理过程的显式建模并提升可解释性。本章从数据与方法两个层面展开：一方面构建面向可解释过程的推理评测基准，系统评估模型的可解释推理能力；另一方面提出结构感知生成式推理模型，以实现准确且可解释的推理过程；最后通过系统实验验证所提方法的有效性与优越性。

第 5 章为总结与展望。本章系统回顾了全文的研究动机、模型设计与方法及实验结果；在此基础上，围绕时序知识图谱推理中的关键挑战，分析了可能的改进方向，并对未来具有潜在研究价值的方向进行了展望。

第 2 章　相关理论与技术

时序知识图谱蕴含了大量随时间演化的结构化知识，能够刻画现实世界中实体关系的动态变化过程，为知识问答、事件预测以及决策分析等下游任务提供重要的理论与技术支撑。实现有效的时序知识图谱推理，对于充分挖掘时序知识图谱中蕴含的动态信息具有重要意义。本章围绕时序知识图谱推理任务所涉及的基础理论与关键技术展开介绍，为后续章节中提出的方法奠定理论基础。首先，从知识表示与推理的角度出发，对时序知识图谱推理任务进行形式化定义，明确其研究目标与核心挑战；在此基础上，对现有时序知识图谱推理方法进行系统梳理，重点分析基于结构建模的方法与基于语言模型的方法之间的差异与局限性；进一步地，考虑到语言模型在本研究中的核心作用，对参数高效微调技术进行介绍，重点分析基于输入空间的方法与基于模型参数的方法，为后续构建结构增强的语言模型推理框架提供理论支撑。

2.1　时序知识图谱推理定义

设 $\mathcal{E}$、$\mathcal{R}$ 和 $\mathcal{F}$ 分别表示实体集合、关系集合和事实集合。时序知识图谱（TKG）可以表示为按照时间排序的一系列知识图谱快照序列，即 $\mathcal{G} = \{\mathcal{G}_0, \mathcal{G}_1, \ldots, \mathcal{G}_n\}$。其中，每一个快照 $\mathcal{G}_t = \{\mathcal{E}_t, \mathcal{R}_t, \mathcal{F}_t\}$ 表示在时间戳 t 时观测到的知识，$\mathcal{E}_t \subseteq \mathcal{E}$ 和 $\mathcal{R}_t \subseteq \mathcal{R}$ 分别表示在时间 t 出现的实体与关系集合，$\mathcal{F}_t$ 表示在该时间戳成立的事实集合。具体地，每一个事实以四元组 (s, r, o, t) 的形式表示，其中 $s \in \mathcal{E}_t$ 和 $o \in \mathcal{E}_t$ 分别表示头实体与尾实体，$r \in \mathcal{R}_t$ 表示实体之间的关系，t 表示该事实发生的时间。因此，时序知识图谱能够刻画实体关系随时间变化的动态演化过程。在此基础上，时序知识图谱推理（TKGR）旨在基于历史知识对未来或缺失事实进行预测。根据查询时间是否位于已观测时间范围内，该任务通常可以划分为插值推理（Interpolation Reasoning）和外推推理（Extrapolation Reasoning）两类。插值推理指在已观测时间范围内对缺失事实进行补全。插值推理是指在已观测时间范围内对缺失事实进行补全。例如，在已知某人物于 2009 年至 2017 年期间担任某职位的部分时间片段信息时，模型需要推断其在中间某一具体时间点（如 2012 年）是否仍然担任该职位。该类任务主要依赖于对已有时间范围内结构信息及局部时间上下文的建模能力。外推推理是指基于历史时间序列对未来未观测事实进行预测。例如，给定某公司在过去若干年份中的合作关系变化，模型需要预测其在未来某一时间点（如下一年度）可能建立的合作关系。该类任务要求模型能够从历史数据中学习关系的演化趋势，从而实现跨时间的泛化预测能力。

本文关注的是外推推理任务。在外推设定下，训练集、验证集和测试集分别对应时间区间 $[T_0, T_1)$、$[T_1, T_2)$ 和 $[T_2, T_3)$，其中 $T_0 < T_1 < T_2 < T_3$。在该设定中，模型仅能利用历史时间范围内的知识进行训练，并在未来时间段上进行预测。给定查询

$q=(s_q,r_q,?,t_q)$，外推式时序知识图谱推理任务的目标是基于时间 t_q 之前的历史知识图谱序列 $\mathcal{G}_{t<t_q}=\{\mathcal{G}_0,\mathcal{G}_1,\ldots,\mathcal{G}_{t_q-1}\}$，推断缺失的尾实体。模型通常通过对候选实体进行打分并排序，从而预测最有可能成立的实体。

2.2 时序知识图谱推理方法

2.2.1 基于图结构模型的方法

基于图结构模型的时序知识图谱推理方法通常可以分为三类：基于距离空间的方法、基于张量分解的方法以及基于图神经网络的方法。早期研究主要集中于前两类方法，通常通过将实体、关系及时间信息嵌入到连续向量空间中，并基于结构约束设计评分函数，对候选四元组的合理性进行建模。其基本假设是：真实事实在嵌入空间中应满足特定的几何或代数关系，而错误事实则应与之显著区分。基于这一假设，模型通过拉开正负样本之间的得分差距，实现对时序知识的有效建模与推理。给定四元组 (s,r,o,t)，结构化方法通常定义评分函数 $g(s,r,o,t)$ 用于衡量该事实的置信度，并通过如下目标函数进行优化，如公式 2.1所示：

$$\mathcal{L}=\sum_{(s,r,o,t)\in\mathcal{F}}\ell\big(g(s,r,o,t),g(s',r,o',t')\big), \tag{2.1}$$

其中，(s',r,o',t') 表示通过负采样构造的错误事实，$\ell(\cdot)$ 表示相应的损失函数。基于距离的方法将实体、关系及时间嵌入到统一的向量空间中，并通过距离函数刻画事实的合理性，其核心在于约束真实四元组在嵌入空间中满足特定的平移或变换关系。例如，TTransE[9]基于平移机制建模时序信息，其评分函数如公式 2.2所示：

$$g(s,r,o,t)=\|\mathbf{e}_s+\mathbf{e}_r+\mathbf{e}_t-\mathbf{e}_o\|, \tag{2.2}$$

其中，$\mathbf{e}_s,\mathbf{e}_r,\mathbf{e}_o,\mathbf{e}_t$ 分别表示头实体、关系、尾实体及时间的向量表示。然而，这类方法在刻画复杂关系模式（如对称关系、多跳依赖及高阶交互）方面存在一定局限。

基于张量分解的方法从多线性代数视角对时序知识图谱进行建模，将其表示为高阶张量，并通过张量分解捕捉实体、关系与时间之间的高阶交互关系。典型的张量分解方法包括 CP 分解（Canonical Polyadic Decomposition）[46]和 Tucker 分解[47]等。例如，ConT[48]在 RESCAL[49]的基础上引入时间嵌入，并结合 Tucker 分解建模关系的动态演化；TComplEx[23]则在复数空间中对实体、关系及时间进行统一建模，从而增强模型的表达能力。一般而言，该类方法采用双线性或多线性形式定义评分函数，如公式 2.3所示：

$$g(s,r,o,t)=\langle\mathbf{e}_s,\mathbf{W}_r^{(t)},\mathbf{e}_o\rangle, \tag{2.3}$$

其中，$\mathbf{W}_r^{(t)}$ 表示关系 r 在时间 t 下的参数表示，$\langle\cdot\rangle$ 表示多线性乘积操作。相比于基于

距离的方法，基于张量分解方法在刻画复杂关系模式方面具有更强的建模能力，但通常伴随着更高的计算开销与参数复杂度。

随着图神经网络（GNN）[50]的发展，越来越多的研究[11–12]尝试通过建模图结构中的邻域依赖关系来实现时序知识推理。相较于基于距离或张量分解的方法，基于图神经网络的方法在结构建模方面具有更强的表达能力。其核心思想在于通过多层消息传递机制，对邻域节点信息进行逐层聚合，从而学习节点的高阶表示。对于第 l 层图神经网络，在时间戳 t 下，具体的传播过程如公式 2.4所示：

$$H_t^{(l+1)} = f(H_t^{(l)}, A_t), \tag{2.4}$$

其中，$H_t^{(l)} \in \mathbb{R}^{N\times d}$ 表示时间 t 下第 l 层的节点表示，A_t 为对应时间的邻接矩阵，$f(\cdot)$ 表示非线性变换函数。在典型的图卷积网络（GCN）中，该传播规则可表示为公式 2.5：

$$H_t^{(l+1)} = \sigma\left(\tilde{D}_t^{-\frac{1}{2}}\tilde{A}_t\tilde{D}_t^{-\frac{1}{2}}H_t^{(l)}W^{(l)}\right), \tag{2.5}$$

其中，$\tilde{A}_t = A_t + I$ 表示时间 t 下加入自环后的邻接矩阵，$\tilde{D}_t$ 为对应的度矩阵，$W^{(l)}$ 为第 l 层的可学习参数，$\sigma(\cdot)$ 为非线性激活函数。从 Weisfeiler-Lehman（WL）测试[51]的角度来看，图神经网络可以理解为对节点邻域特征的迭代聚合与更新，如公式 2.6所示：

$$h_{s,t}^{(l+1)} = \sigma\left(\sum_{o\in\mathcal{N}_t(s)}\frac{1}{c_s}W^{(l)}h_{o,t}^{(l)} + W_0^{(l)}h_{s,t}^{(l)}\right), \tag{2.6}$$

其中，$\mathcal{N}_t(s)$ 表示在时间 t 下与实体 s 相连的邻居实体集合，c_s 为归一化系数，$W^{(l)}$ 为第 l 层的共享权重矩阵，$W_0^{(l)}$ 表示自环权重矩阵。由于时序知识图谱中存在多种关系类型，关系图卷积网络（R-GCN）[24]对上述范式进行了进一步扩展，节点表示的更新过程可表示为公式 2.7：

$$h_{s,t}^{(l+1)} = \sigma\left(\sum_{r\in\mathcal{R}}\sum_{o\in\mathcal{N}_t(s,r)}\frac{1}{c_{s,r}}W_r^{(l)}h_{o,t}^{(l)} + W_0^{(l)}h_{s,t}^{(l)}\right), \tag{2.7}$$

其中，$\mathcal{N}_t(s,r)$ 表示在时间 t 下通过关系 r 与实体 s 相连的邻居实体集合，$c_{s,r}$ 为归一化系数，$W_r^{(l)}$ 为关系特定的权重矩阵，$W_0^{(l)}$ 表示自环权重矩阵。

为了更有效地融合图结构信息与时间动态特征，部分方法[7]将图神经网络与循环神经网络等序列建模机制相结合，对历史时间序列中的结构信息进行建模，从而增强模型对复杂时序依赖关系及动态演化过程的刻画能力。尽管取得了一定进展，基于图神经网络的方法主要依赖结构信息进行建模，难以有效融合文本语义信息，从而在复杂时序推理任务中仍存在局限。

2.2.2 基于语言模型的方法

随着语言模型的快速发展，基于语言模型的时序知识图谱推理方法逐渐成为重要研究方向。该类方法通常将时序知识图谱中的结构化四元组转化为文本序列输入，通过语言模型对实体、关系及时间进行统一建模，从而利用其强大的语义理解与生成能力提升推理性能。相较于基于图结构模型的推理方法，此类方法更加侧重语义建模。

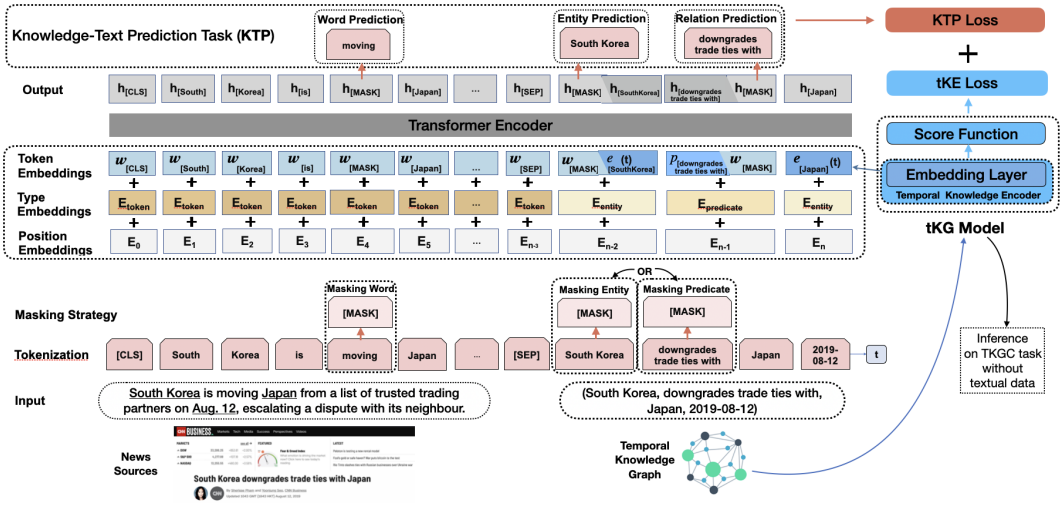


图 2.1 ECOLA 模型结构图

早期研究主要基于以 BERT[52] 为代表的预训练语言模型(PLMs),通常采用 Encoder-only 结构，并将任务建模为掩码语言建模任务。具体地，通常通过构造提示模板，将四元组 (s, r, o, t) 转化为文本序列输入，例如“[CLS]s[SEP]r[SEP]o[SEP]t[SEP]”，并通过掩码预测或分类任务实现对缺失实体的预测。如图 2.1所示，ECOLA[53] 通过构造“知识—文本”对齐机制，将时序知识图谱中的四元组与对应文本描述进行联合建模，并设计双重优化目标实现推理。此外，还有一些方法[32–34] 通过引入提示学习、前缀微调及对比学习机制，进一步增强模型对时间信息的建模能力。这类方法通过将结构化知识转化为文本输入，有效利用了预训练语言模型的语义表示能力。然而，由于其本质仍属于判别式建模范式，通常依赖候选实体排序或得分函数进行预测，其推理过程缺乏显式建模。

随着训练语料规模的不断扩大以及模型参数规模的持续增长，预训练语言模型逐步演进为大语言模型，其主流架构也由 Encoder-only 范式向 Decoder-only 的自回归生成范式转变。在此背景下，越来越多研究开始探索基于大语言模型的时序推理方法。该类方法通常基于自回归语言建模机制，将推理任务建模为条件序列生成问题。给定输入序列 $\mathbf{X} = (x_1, x_2, \ldots, x_T)$，语言模型通过建模如公式 2.8所示的联合概率分布：

$$P(x_1, x_2, \ldots, x_T) = \prod_{t=1}^{T} P(x_t \mid x_{<t}), \tag{2.8}$$

其中，$x_{<t} = (x_1, x_2, \ldots, x_{t-1})$ 表示当前位置之前的上下文信息。在该生成范式下，部分方法[35–36]以历史事实或结构化提示作为条件输入，并结合上下文学习，通过自回归方式生成目标实体或完整事实。此外，一些研究开始探索将大语言模型与符号推理相结合。例如，GenTKG[38]通过引入逻辑规则挖掘与检索机制，并结合指令微调，实现对目标事实的直接生成；LLM-DA[39]则从历史数据中抽取时序逻辑规则，并利用大语言模型对其进行引导与优化，从而提升推理性能。

尽管上述方法取得了一定进展，但仍存在明显局限：一方面，现有方法多依赖单一结构信息或语义信息，尚未实现二者的有效协同；另一方面，相关方法通常依赖隐式表示或外部规则，缺乏对推理过程的统一建模，导致模型泛化能力受限，同时在生成过程中仍难以有效抑制模型幻觉问题，从而影响推理的可靠性。

2.3 参数高效微调

随着语言模型参数规模的不断扩大，传统全参数微调需要更新全部模型参数，带来了较高的计算与存储开销，且在多任务场景下扩展性较差。相比之下，参数高效微调（Parameter-Efficient Fine-Tuning, PEFT）通过冻结大部分预训练参数，仅优化少量新增参数或结构，实现对下游任务的高效适配，在保证性能的同时显著降低资源消耗。从优化形式上看，参数高效微调可以表示为如公式 2.9所示的受限优化问题：

$$\min_{\Delta\theta} \mathcal{L}(f_{\theta+\Delta\theta}(x), y), \quad \text{s.t. } \|\Delta\theta\| \ll \|\theta\|, \tag{2.9}$$

其中，$f_\theta(\cdot)$ 表示参数为 θ 的预训练模型，输入为样本 x，输出为模型预测结果；$\Delta\theta$ 表示对模型参数的增量更新；$\mathcal{L}(\cdot)$ 为任务相关的损失函数，用于度量模型预测 $f_{\theta+\Delta\theta}(x)$ 与真实标签 y 之间的差异。约束条件 $\|\Delta\theta\| \ll \|\theta\|$ 表示仅对少量参数进行更新。

2.3.1 基于输入空间的方法

基于输入空间的参数高效微调方法旨在通过在原始输入序列中引入可学习的提示（prompt）或前缀（prefix），引导预训练语言模型完成下游任务，而无需更新模型主体参数。这类方法的核心思想是：将任务知识编码为连续向量形式，并通过改变模型的输入表示或注意力上下文，从而实现对模型行为的调控。由于仅需优化少量附加参数，该类方法具有参数开销小、训练高效、易于迁移等优点。基于输入空间的典型代表方法包括：Prompt Tuning[54]、P-Tuning[55]和 Prefix Tuning[56]。

Prompt Tuning 在输入序列前拼接一组可学习的连续提示向量。对于输入向量 $\mathbf{x} = (x_1, \ldots, x_n)$，引入提示 $\mathbf{p} = (p_1, \ldots, p_m)$，模型输入如公式 2.10所示：

$$\tilde{\mathbf{x}} = [\mathbf{p}; \mathbf{x}], \quad y = f_\theta(\tilde{\mathbf{x}}), \tag{2.10}$$

其中，该方法仅通过调整输入表示 $\mathbf{p}$ 实现任务适配。为进一步提升 Prompt Tuning 的表达能力，P-Tuning 将可学习提示从输入层扩展至 Transformer[57]的各层，从而实现更深层次的模型调控，通过在每一层引入连续提示表示，使模型能够在多层表示空间中注入任务相关信息。不同于 Prompt Tuning 和 P-Tuning 主要通过在输入层引入提示进行调控，Prefix Tuning 进一步将提示扩展至注意力机制层面，通过在注意力机制中对键（Key）和值（Value）进行前缀扩展，从而直接调控注意力分布，实现对模型行为的更细粒度控制。相比仅作用于输入表示的方法，该方法能够在更深层次影响模型表示，因而具有更强的表达能力。具体地，在第 l 层注意力计算中，通过在键和值维度拼接可学习的前缀参数，其计算如公式 2.11所示：

$$K_l' = [P_l^K; K_l], \quad V_l' = [P_l^V; V_l], \tag{2.11}$$

其中，$P_l^K, P_l^V \in \mathbb{R}^{m\times d}$ 表示长度为 m 的前缀表示，$K_l, V_l \in \mathbb{R}^{n\times d}$ 分别为原始键和值矩阵。在此基础上，注意力计算形式如公式 2.12所示：

$$\text{Attention}(Q_l, K_l', V_l') = \text{softmax}\left(\frac{Q_l {K_l'}^{\top}}{\sqrt{d}}\right) V_l', \tag{2.12}$$

其中，$Q_l \in \mathbb{R}^{n\times d}$ 表示查询（Query）矩阵，$K_l', V_l' \in \mathbb{R}^{(n+m)\times d}$ 分别表示在原始 Key 和 Value 矩阵基础上拼接前缀表示后的扩展矩阵。在此基础上，注意力机制通过计算 Query 与 Key 之间的相似度获得权重分布，并对 Value 进行加权求和，从而建模序列中的上下文依赖关系。通过在 Key 和 Value 空间引入前缀表示，Prefix Tuning 为每一层注意力机制提供了额外的上下文信息，使模型能够在不更新原始参数的情况下，有效引导注意力分布关注与特定任务相关的表示，从而提升模型任务的表达能力。

2.3.2 基于模型参数的方法

相较于基于输入空间的方法，基于模型参数的方法通过在模型内部参数空间中引入少量可训练参数，在保持大部分预训练参数冻结的前提下，实现对模型能力的高效迁移。该类方法的典型代表包括适配器方法[58]（Adapter Tuning）和低秩适配[59]（Low-Rank Adaptation，LoRA）。其中，LoRA 由于结构简单、参数高效且易于部署，已成为当前最具代表性的参数高效微调方法之一。具体地，该方法认为在下游任务适配过程中，模型参数的有效更新通常具有较低的内在秩，因此无需对完整参数矩阵进行自由更新，可以通过低秩分解对参数增量进行近似建模。设预训练模型中某线性变换层的权重矩阵为 $\mathbf{W}_0 \in \mathbb{R}^{d\times k}$，传统全参数微调需要直接学习更新矩阵 $\Delta\mathbf{W} \in \mathbb{R}^{d\times k}$，模型参数的更新过程可表示为公式 2.13：

$$\mathbf{W} = \mathbf{W}_0 + \Delta\mathbf{W}. \tag{2.13}$$

为降低参数开销并约束更新空间，LoRA 将参数增量表示为两个低秩矩阵的乘积, 如公式 2.14所示：

$$\Delta \mathbf{W} = \mathbf{BA}, \tag{2.14}$$

其中，$\mathbf{A} \in \mathbb{R}^{r \times k}$，$\mathbf{B} \in \mathbb{R}^{d \times r}$，且 $r \ll \min(d, k)$ 为低秩维度。在此基础上，引入 LoRA 后，线性层输出的表达如公式 2.15所示：

$$\mathbf{h} = \mathbf{W}_0 \mathbf{x} + \mathbf{BAx}, \tag{2.15}$$

其中，$\mathbf{x}$ 表示输入向量。在训练过程中，LoRA 冻结原始权重 $\mathbf{W}_0$，仅优化低秩矩阵 $\mathbf{A}$ 和 $\mathbf{B}$。由于低秩维度 r 通常远小于原矩阵维度，因此其可训练参数量显著低于全参数微调，从而在保证模型性能的同时有效降低训练开销。为稳定训练过程，LoRA 通常还会引入缩放系数 α，参数更新如公式 2.16所示：

$$\mathbf{W} = \mathbf{W}_0 + \frac{\alpha}{r}\mathbf{BA}, \tag{2.16}$$

其中，α 为缩放超参数，用于控制低秩更新项对原始权重的影响程度。这种设计能够在不同秩设置下保持更新幅度相对稳定，从而提升训练的鲁棒性。从参数量角度来看，若原始权重矩阵的参数量为 $d \times k$，则 LoRA 仅需引入 $r \times k + d \times r = r(d + k)$ 个额外参数。当 $r \ll \min(d, k)$ 时，其参数开销远小于直接学习完整的 $\Delta \mathbf{W}$，这使得 LoRA 在大模型微调场景中具有明显优势。

在 LoRA 的基础上，研究者提出了一系列改进方法，以进一步提升其在资源效率和训练性能方面的表现。其中，QLoRA[60]通过引入低比特量化以及分段优化策略，在保持模型性能的同时显著降低显存开销，使得在有限硬件资源下微调大规模语言模型成为可能；LoRA+[61]通过对低秩分解中的不同参数采用差异化学习率，加速模型收敛过程并提升训练效率；AdaLoRA[62]从参数分配角度出发，根据不同层的重要性动态调整低秩维度，从而在固定参数预算下实现更优的性能表现。总体而言，这些 LoRA 变体分别从显存优化、训练策略和参数分配等方面对原始方法进行了扩展，进一步提升了参数高效微调方法在大规模模型中的实用性与灵活性。

2.4 本章小结

本章围绕时序知识图谱推理任务所涉及的基础理论与关键技术进行了系统梳理与分析。首先，对时序知识图谱及其推理任务进行了形式化定义，明确了外推推理作为本文关注的核心问题。其次，从结构建模与语义建模两个角度，对现有时序知识图谱推理方法进行了分类与总结。基于图结构模型的方法通过嵌入学习或图神经网络对实体关系及其时间演化进行建模，在结构表示方面具有较强能力，但难以充分利用文本语义信息；而基于语言模型的方法则通过将结构化知识转化为文本输入，利用预训练语言

模型的语义建模能力或大语言模型的生成能力提升推理性能，但在推理过程建模、结构信息融合及泛化能力等方面仍存在不足。最后，针对语言模型在本文的关键作用，进一步介绍了参数高效微调技术，包括基于输入空间的方法和基于模型参数的方法，为后续章节的模型构建与实验验证提供了重要的理论支撑。

第 3 章　基于预训练语言模型的结构增强时序知识图谱推理方法

近年来，越来越多的研究尝试将预训练语言模型应用于时序知识图谱推理任务，以增强对复杂语义信息的建模能力。然而，现有方法难以实现文本语义、图结构与时间演化信息的统一建模与协同融合，从而制约模型性能的进一步提升。针对上述问题，本章聚焦外推推理场景中预训练语言模型对结构依赖与历史演化信息利用不足的挑战，提出一种基于预训练语言模型的结构增强时序知识图谱推理方法。具体地，从结构依赖与全局历史模式两个关键视角出发，系统分析现有方法的局限性，并在此基础上构建相应的结构增强机制，使模型能够在充分利用语义信息的同时，有效捕捉跨时间的结构依赖关系与历史重现规律，以实现更加准确的推理。

3.1　引言

时序知识图谱通过在传统知识图谱三元组的基础上引入时间维度，以四元组的形式刻画动态演化的事实，在金融分析[63]、问答[64]等实际应用中具有重要价值。然而，由于现实世界知识的不断变化以及数据采集的局限性，现有时序知识图谱往往存在不完整性问题。因此，时序知识图谱推理（TKGR）旨在基于历史事实预测缺失或未来发生的事件，已成为当前研究的热点方向。根据预测时间是否已知，TKGR 任务通常可分为插值推理与外推推理两类。本章关注的是外推推里任务，旨在基于历史观测事实，对未来时间戳上的事实进行预测。

近年来，研究者提出了多种方法以建模时序知识图谱中的结构依赖与时间演化特性，从而提升模型外推能力。已有研究[7,12,29]主要依赖图神经网络（GNNs）对图结构及其随时间变化的模式进行建模，能够在一定程度上捕捉实体之间的结构关系。然而，这类方法在语义建模方面存在不足，难以充分利用文本信息中的丰富语义知识。随着预训练语言模型（PLMs）在自然语言处理领域取得突破性进展，其较强的语义建模能力为 TKGR 任务提供了新的解决思路。相关研究尝试将历史事实转化为文本形式输入 PLMs，从而增强模型对实体与关系语义的理解能力。例如，PPT[32]将实体、关系以及时间区间转化为文本提示，并将时序知识图谱推理任务重构为掩码标记预测任务，使模型能够通过基于提示的输入形式有效挖掘时序语义信息；ECOLA[53]通过联合优化语言模型的语言建模目标与知识图谱的损失，并进一步引入新闻文本作为辅助信息，以增强模型对事件语义、时间表达及演化背景的理解能力；ChapTER[33]提出统一的孪生框架，在共享参数的条件下对实体、关系与时间进行编码，同时结合前缀微调以提升时序建模能力；CoPET[34] 通过对比学习框架引入时间不变信息，进一步提升了时序表示学习的效果。尽管基于预训练语言模型（PLM-based）的方法在时序语义建模方

面取得了一定进展，但仍然存在两个关键问题亟待解决。

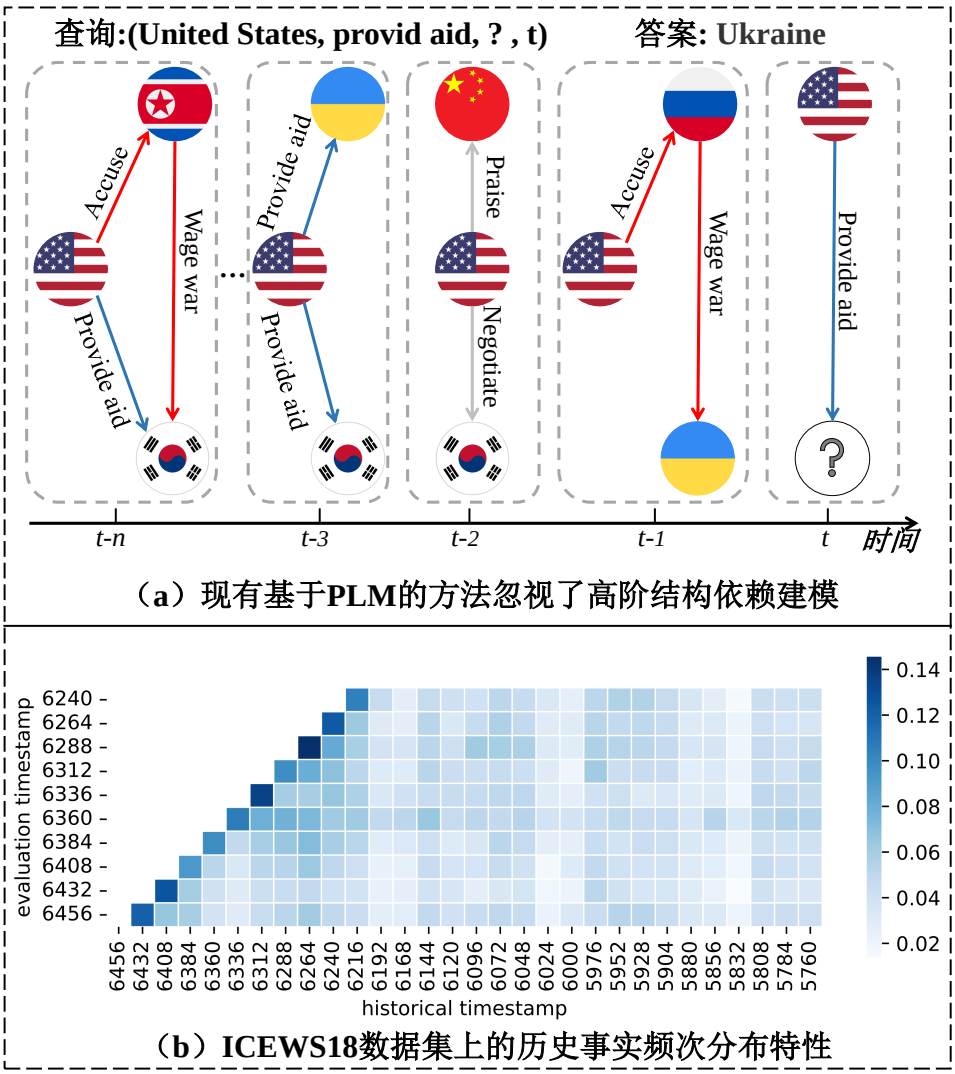


图 3.1 现有 PLM-based 的方法面临的两个挑战

首先，现有 PLM-based 的方法难以有效捕捉时序知识图谱中的复杂结构依赖关系。当模型仅基于孤立或浅层的历史上下文进行建模时，在外推场景下容易导致预测结果不稳定。如图 3.1（a）所示，对于查询（United States, provide aid, ?, t），仅依赖与United States直接相关的一阶历史信息不足以确定正确答案。相反，正确结果可能依赖于早期时刻中所蕴含的高阶关系结构。例如，在时间 $t-n$ 的历史快照中，United States曾指责（Accuse）North Korea对South Korea发动战争（Wage War），并向South Korea提供援助。这一历史结构反映出一种潜在模式，即United States通常在指责某一方发起冲突后，倾向于向冲突中受到攻击的一方提供援助。当类似情形在后续时间步再次出现时，例如在 $t-1$ 时刻，United States指责Russia对Ukraine发动战争；则在 t 时刻，模型应能够基于该结构依赖模式进行迁移推理，从而推断United States很可

能会向Ukraine提供援助。

其次，现有 PLM-based 方法未能充分利用历史重复事实所蕴含的全局统计信息。在实际场景中，大量重复出现的历史交互模式往往蕴含重要的全局趋势信息。例如，与United States相关的“曾接受援助”的实体所对应的历史交互，可以为查询（United States, provide aid, ?, *t*）提供有价值的全局先验，从而辅助模型进行更加合理的推断。为了验证上述现象，如图 3.1（b）所示，对 ICEWS18 数据集中的历史事实频次分布进行了统计分析，以刻画不同时间戳之间的事实重现程度。其中，纵轴表示评估时间戳，横轴表示历史时间戳，并按照从近到远的顺序进行排列。统计结果表明，历史事实中普遍存在显著的重现模式（Recurring Patterns），且该类模式在时间上呈现出明显的“近期效应”，即距离评估时间越近的历史事实，其重现程度越高，对未来预测也更具相关性。因此，在时序知识图谱推理过程中，有效融合历史事实中的全局统计信息，并强化对近期历史信息的建模，对于提升模型的推理性能具有重要意义。

针对上述问题，提出一种联合结构与历史重现模式增强的预训练语言模型（a **P**LM-based framework that takes into account **S**tructure and **G**lobal information for TKGR, **PSG**）。该方法面向外推推理场景，旨在在充分发挥预训练语言模型语义建模能力的同时，引入结构信息与全局历史统计规律，实现结构与语义的协同建模，从而提升模型在复杂时序推理任务中的表现。一方面，通过引入时间感知的软提示（Time-aware Soft Prompts），将图空间中的实体与关系结构信息映射至语言模型输入空间，并与描述性文本及历史事实共同输入冻结的预训练语言模型，从而构建结构与语义协同建模模块；另一方面，构建了全局历史重现模式模块，从时间维度对历史事实的出现频次进行统计与聚合，刻画不同时间点之间的事实重现程度；在此基础上，引入时间窗口与时间衰减因子，对历史信息进行加权建模，从而突出近期历史事实在推理过程中的重要作用；在推理阶段，对结构与语义协同建模模块与全局历史重现模式建模模块的输出进行融合，使模型能够同时利用结构依赖与全局历史规律进行联合推理，从而在外推场景下获得更加准确且鲁棒的预测结果。本章的主要贡献如下：

（1）提出了一种联合结构与历史重现模式增强的预训练语言模型 PSG。通过引入时间上下文感知的软提示，实现语义信息与结构信息的有效融合与平衡建模，并进一步融合历史事实中的全局统计信息，从而提升模型对复杂时序依赖的建模能力。

（2）针对全局历史重现模式建模模块，通过对四元组频次分布的统计分析，用于刻画历史事实中的重现模式及其时间相关性；在此基础上，引入时间窗口与时间加权机制，以强化近期历史信息在推理中的作用。

（3）在三个公开的时序知识图谱数据集上开展系统实验评估。结果表明，PSG 在多个评价指标上显著优于现有基线方法，并展现出良好的泛化能力，充分验证了其在时序结构化知识建模中的有效性。

3.2 问题定义

设 $\mathcal{E}$、$\mathcal{R}$ 和 $\mathcal{F}$ 分别表示实体集合、关系集合与事实集合。时序知识图谱可以表示为随时间演化的知识图谱快照序列，即 $\mathcal{G}=\{\mathcal{G}_0,\mathcal{G}_1,\ldots,\mathcal{G}_n\}$。其中，每个时间戳 t 对应一个知识图谱快照 $\mathcal{G}_t=\{\mathcal{E}_t,\mathcal{R}_t,\mathcal{F}_t\}$，表示在时刻 t 所观测到的知识。$\mathcal{E}_t\subseteq\mathcal{E}$ 和 $\mathcal{R}_t\subseteq\mathcal{R}$ 分别表示在时间戳 t 出现的实体集合与关系集合，$\mathcal{F}_t$ 表示该时刻发生的时序事实集合。具体地，每个事实表示为四元组 (s,r,o,t)，其中 $s\in\mathcal{E}_t$ 和 $o\in\mathcal{E}_t$ 分别表示头实体与尾实体，$r\in\mathcal{R}_t$ 表示实体之间的关系，t 表示该事实发生的时间戳。遵循外推推理设定，训练集、验证集和测试集分别对应时间区间 $[T_0,T_1)$、$[T_1,T_2)$ 和 $[T_2,T_3)$，其中 $T_0<T_1<T_2<T_3$。在该设定下，模型仅能利用历史观测事实进行学习，并需要对未来时间戳上的事实进行预测。给定查询 $q=(s_q,r_q,?,t_q)$，外推时序知识图谱推理任务旨在基于时间戳 t_q 之前的历史知识图谱序列 $\mathcal{G}_{t<t_q}=\{\mathcal{G}_0,\mathcal{G}_1,\ldots,\mathcal{G}_{t_q-1}\}$ 推断缺失的尾实体。为实现更加全面的性能评估，遵循先前工作[65–66]，进一步引入逆事实（inverse facts）对数据进行增强。具体地，对于每一个关系 $r\in\mathcal{R}$，定义其对应的逆关系 r^{-1}，并将每一个事实 (s,r,o,t) 转换为对应的逆事实 (o,r^{-1},s,t)。通过该变换，可以将头实体预测与尾实体预测统一为尾实体预测任务。具体来说，对于形式为 $(s_q,r_q,?,t_q)$ 的查询保持不变，而对于形式为 $(?,r_q,o_q,t_q)$ 的查询，则将其转换为 $(o_q,r_q^{-1},?,t_q)$。通过上述处理，模型能够在统一的预测框架下进行评估，从而更全面地反映其推理能力。

3.3 联合结构与历史重现模式增强的预训练语言模型

如图 3.2 所示，提出的 PSG 模型由两个核心模块构成：结构与语义协同建模模块和全局历史重现模式建模模块。一方面，在结构与语义协同建模模块，通过引入包含图结构信息的时间感知软提示，并结合实体描述文本、关系文本及相关历史事实构建输入序列，将其输入至预训练语言模型中，从而增强模型对结构依赖关系的表达能力；另一方面，在全局历史重现模式建模模块中，对历史事实的频次分布进行统计与建模，以刻画不同时间点之间的事实重现规律，并引入时间窗口与时间权重机制，对历史信息进行加权建模，从而强化近期历史事实在推理过程中的作用；在推理阶段，对两个模块的输出结果进行融合，以获得更加准确且鲁棒的预测结果。

3.3.1 结构与语义协同建模模块

（1）输入构建

给定查询 $q=(s_q,r_q,?,t_q)$，预训练语言模型的输入主要包括两部分：头实体（关系）的嵌入表示以及文本信息。具体地，本节从图模型中引入头实体嵌入 $\boldsymbol{E}_{s_q}\in\mathbb{R}^d$ 和关系嵌入 $\boldsymbol{E}_{r_q}\in\mathbb{R}^d$，其中 d 表示嵌入维度。随后，将这些依赖图结构的嵌入表示与文本信息进行结合，使二者能够通过预训练语言模型进行交互。为了赋予 $\boldsymbol{E}_{s_q}$ 和 $\boldsymbol{E}_{r_q}$ 时

间上下文感知的表示能力，进一步引入两类文本信息：事实描述（Factual Descriptions）和历史上下文（Historical Context）。

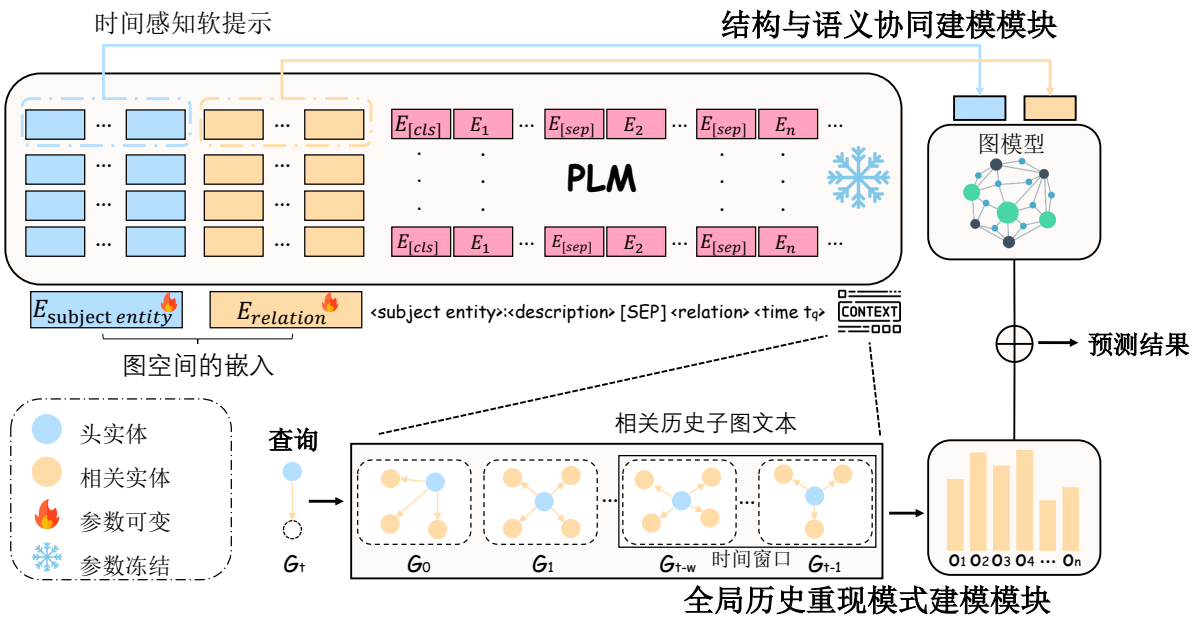


图 3.2 PSG 的总体框架示意图

事实描述。现有时序知识图谱数据集中的实体通常仅以名称形式表示，语义信息有限；相比之下，关系文本往往蕴含更丰富的语义信息。为此，引入实体描述信息以增强语义表达能力。例如，对于实体“China”，其描述可表示为“East Asian, world's most populous, rich history”（位于东亚，人口规模居世界首位，历史悠久）。随后，将实体原始名称与其描述拼接，形成头实体文本 $\mathcal{Q}_{s_q}$。对于关系文本 $\mathcal{Q}_{r_q}$，直接采用关系名称；对于时间文本 $\mathcal{Q}_{t_q}$，则采用“yyyy-mm-dd”的格式进行表示。

历史上下文。为了引入历史上下文信息，针对查询 $q = (s_q, r_q, ?, t_q)$ 采样相关的历史四元组，并将其转换为文本形式。具体地，定义历史四元组集合 $\mathcal{H}(s_q, r_q, t_q)$ 如公式 3.1所示：

$$\mathcal{H}(s_q, r_q, t_q) = \{(s, r, o, t) \mid (s, r, o, t) \in \mathcal{F},\ t < t_q\}. \tag{3.1}$$

随后，将所有历史上下文按照时间升序进行重排，并构造输入到预训练语言模型中的文本提示 $\mathcal{P}(q)$，具体如公式 3.2所示：

$$\mathcal{P}(q) = \langle \text{cls} \rangle\ \mathcal{Q}_{s_q} \,||\, \mathcal{Q}_{r_q} \,||\, \mathcal{Q}_{t_q}\ \langle \text{sep} \rangle\ \mathcal{H}(s_q, r_q, t_q)\ \langle \text{sep} \rangle, \tag{3.2}$$

其中，$\mathcal{P}(q)$ 表示构造的模型输入序列；$\langle \text{cls} \rangle$ 与 $\langle \text{sep} \rangle$ 分别为分类标记与分隔标记；$||$ 表示不同字段之间的拼接操作。

（2）文本表示与图空间对齐

已有研究表明[56,67]，软提示微调方法通过调整少量参数即可实现与全参数微调相当的性能。在此基础上，提出一种时间感知的软提示微调方法，以增强模型对时序信息的建模能力。具体地，将时间感知软提示（表示为 $\boldsymbol{TS}$）以及上述构造的文本提示 $\mathcal{P}(q)$ 一同输入冻结的预训练语言模型，以显式建模时间依赖关系。为了得到 $\boldsymbol{TS}$，对 $\boldsymbol{E}_{s_q}$ 和 $\boldsymbol{E}_{r_q}$ 进行线性变换，具体定义如公式 3.3和公式 3.4所示：

$$\boldsymbol{TS} = \left[F\left(\boldsymbol{E}_{s_q}\right); F\left(\boldsymbol{E}_{r_q}\right) \right], \tag{3.3}$$

$$F(x) = \mathbf{W}_{x_2} \cdot \mathrm{ReLU}\left(\mathbf{W}_{x_1} \cdot (x \parallel \psi(\boldsymbol{t}_q)) \right), \tag{3.4}$$

其中，$\boldsymbol{W}_{x_1} \in \mathbb{R}^{d_h \times 2d}$、$\boldsymbol{W}_{x_2} \in \mathbb{R}^{(l*H*m)\times d_h}$ 为可训练的权重矩阵，d_h 表示映射层中的中间隐藏维度，l 表示序列长度，H 表示 Transformer 层的隐藏维度，$\parallel$ 表示拼接操作，$\psi(\cdot)$ 表示通用时间编码函数。

设 $\boldsymbol{h}^{(j)} \in \mathbb{R}^{n\times d}$ 表示输入文本提示 $\mathcal{P}(q)$ 在第 j 个 Transformer 层后的所有词元（token）输出嵌入，则在每一层中，将长度为 m 的时间感知软提示词元嵌入与文本词元嵌入进行拼接，具体形式如公式 3.5所示：

$$\tilde{\boldsymbol{h}}^{(j)} = \boldsymbol{p}^{(j)} \parallel \boldsymbol{h}^{(j)},\ 0 \le j \le L, \tag{3.5}$$

其中，$\boldsymbol{p}^{(j)}$ 表示第 j 层的 $\boldsymbol{TS}$ 词元嵌入，$\tilde{\boldsymbol{h}}^{(j)}$ 表示拼接后的输入词元嵌入。进一步地，第 j 层中第 i 个输入词元 $\tilde{\boldsymbol{h}}_i^{(j)} \in \mathbb{R}^H$ 定义如公式 3.6所示：

$$\tilde{\boldsymbol{h}}_i^{(j)} = \begin{cases} \boldsymbol{p}_i^{(j)}, & 0 \le i < m \\ \boldsymbol{e}_i^{(j)}, & (i \ge m) \wedge (j = 0) \\ \mathrm{FFN}(\tilde{\boldsymbol{h}}^{(j-1)})_i, & \text{Otherwise} \end{cases} \tag{3.6}$$

最终，将冻结的预训练语言模型输出的 $\boldsymbol{TS}$ 表示输入图模型，并通过 softmax 函数得到结构与语义协同建模模块的预测结果，如公式 3.7所示：

$$S_{syn}^{(s_q,r_q)} = \mathrm{softmax}\left(f\left(\boldsymbol{E}_{s_q}, \boldsymbol{E}_{r_q}\right)\right), \tag{3.7}$$

其中，$S_{syn}^{(s_q,r_q)} \in \mathbb{R}^{|\mathcal{E}|}$ 表示候选实体的预测分数，$f(\cdot)$ 表示图模型的评分函数。

3.3.2 全局历史重现模式建模模块

全局历史重现模式建模模块基于历史知识图谱序列 $\mathcal{G}_{t<t_q}$，对历史事实的全局统计规律进行建模，从而刻画时序知识图谱中的事实重现模式及其时间演化特性。给定查询 $q = (s_q, r_q, ?, t_q)$，该模块通过统计历史时间戳上的交互频次，获得候选实体的全局

频次得分。对于每一个历史时间戳 $t' < t_q$，计算对应的频次向量 $\mathbf{Z}_{t'}^{(s_q,r_q)} \in \mathbb{R}^{|\mathcal{E}|}$，该向量统计在时间戳 t' 下，以 s_q 为头实体、r_q 为关系的所有事实中各候选实体作为尾实体的出现次数，定义如公式 3.8所示：

$$\mathbf{Z}_{t'}^{(s_q,r_q)}(o) = \sum_{x \in \mathcal{G}_{t'}} \mathbb{I}[x = (s_q, r_q, o, t')], \tag{3.8}$$

其中，$\mathbb{I}[\cdot]$ 为指示函数，当条件成立时取值为 1，否则为 0。进一步地，基于对四元组频次分布的统计分析可以发现，不同时间戳之间的事实重现程度存在显著差异，其中距离评估时间越近的历史事实，其重现概率通常更高，对当前预测具有更强的参考价值。换言之，历史事实在时间维度上呈现出明显的时间相关性与“近期效应”，即近期发生的交互更可能在未来再次出现。基于这一观察，引入时间窗口与时间权重机制，对不同时间段的历史信息进行分段建模与加权聚合，从而突出近期历史事实在推理过程中的作用，提升模型对时序演化规律的刻画能力（详细分析见第 3.4.6节）。在此基础上，对所有历史时间戳 $t' < t_q$ 的频次信息进行如公式 3.9所示的聚合：

$$\mathbf{Z}_{t_q}^{(s_q,r_q)} = \mathbf{Z}_{t' < t_q - w}^{(s_q,r_q)} + k \cdot \mathbf{Z}_{t_q - w \le t' < t_q}^{(s_q,r_q)}, \tag{3.9}$$

其中，$\mathbf{Z}_{t_q}^{(s_q,r_q)} \in \mathbb{R}^{|\mathcal{E}|}$ 表示聚合后的频次向量，w 表示时间窗口大小，$k \geq 1$ 为时间权重系数，用于对时间窗口内的近期历史交互赋予更高权重。最后，通过 softmax 函数对频次向量进行归一化，得到基于全局历史信息的候选实体预测分布，如公式 3.10所示：

$$\mathcal{S}_{freq}^{(s_q,r_q)} = \mathrm{softmax}\left(\mathbf{Z}_{t_q}^{(s_q,r_q)}\right). \tag{3.10}$$

通过上述建模，该模块能够有效捕捉历史事实中的重现模式及其时间相关性，为时序知识图谱推理提供重要的全局统计信息。

3.3.3 模型训练与推理

给定查询 $q = (s_q, r_q, ?, t_q)$，缺失尾实体的预测可被建模为一个多分类问题。在训练阶段，基于图模型输出的评分函数，采用标准的交叉熵损失函数对模型进行优化，具体定义如公式 3.11所示：

$$\mathcal{L} = -\sum_{t \in \mathcal{T}} \sum_{(s,r,o,t) \in \mathcal{G}_t} \log f(\boldsymbol{E}_s, \boldsymbol{E}_r), \tag{3.11}$$

其中，$\mathcal{T}$ 表示所有时间戳的集合，$\mathcal{G}_t$ 表示时间戳 t 下的事实集合，$f(\cdot)$ 为图模型的评分函数。在推理阶段，引入权重系数 $\alpha \in [0, 1]$ 对上述两个模块的输出进行加权融合，从而得到最终的候选实体预测概率分布，具体形式如公式 3.12所示：

$$\mathbf{P}(o \mid s_q, r_q, t_q) = \alpha \cdot \mathcal{S}_{syn}^{(s_q,r_q)}(o) + (1 - \alpha) \cdot \mathcal{S}_{freq}^{(s_q,r_q)}(o), \tag{3.12}$$

其中，$\mathbf{P}(o \mid s_q, r_q, t_q) \in \mathbb{R}^{|\mathcal{E}|}$ 表示候选实体的最终预测概率分布，$S_{syn}^{(s_q,r_q)}$ 与 $S_{freq}^{(s_q,r_q)}$ 分别表示结构与语义协同建模模块和全局历史重现模式建模模块输出的预测分数。最终预测结果 o_{t_q} 为具有最大预测概率的实体，定义如公式 3.13所示：

$$o_{t_q} = \arg\max_{o \in \mathcal{E}} \mathbf{P}(o \mid s_q, r_q, t_q). \tag{3.13}$$

通过上述融合机制，模型能够在不同信息来源之间实现有效协同，从而获得更加稳定的预测结果。

3.4 实验与分析

本节通过多数据集对比实验验证所提方法 PSG 的有效性，并结合消融实验与多维度分析（包括训练策略、泛化能力及超参数），以全面评估模型的性能与稳定性。

3.4.1 实验数据集与评测指标

在三个具有代表性的时序知识图谱基准数据集上开展实验，包括 ICEWS14[68]、ICEWS18[69] 以及 ICEWS05-15[68]。上述数据集均来源于 Integrated Crisis Early Warning System（ICEWS），该系统是一个大规模政治事件交互数据库，广泛应用于时序推理与事件预测任务的评估。其中，ICEWS14 和 ICEWS18 分别涵盖单一年份内的事件数据，而 ICEWS05-15 则覆盖了 2005 年至 2015 年的长期时间跨度，具有更加丰富且复杂的时间演化特性。总体而言，这三个数据集能够为模型在不同时序场景下的性能评估提供全面的基准。表 3.1详细列出了这些数据集的详细统计信息。

表 3.1 模型 PSG 评测数据集统计信息

数据集	实体数量	关系数量	训练集大小	验证集大小	测试集大小	时间间隔
ICEWS14	7128	230	74,845	8514	7371	24 小时
ICEWS18	23,033	256	373,018	45,995	49,545	24 小时
ICEWS05-15	10,488	251	368,868	46,302	46,159	1 天

对于评估指标，采用时序知识图谱推理任务中常用的平均倒数排名（Mean Reciprocal Rank, MRR）以及 Hits@N（$N \in \{1, 3\}$）指标对模型性能进行评估。遵循已有工作[70]，在原始评估设置下报告结果，这是由于过滤设置在外推时序知识图谱推理任务中已被证明不适用。对于每一个查询样本，模型会对所有候选实体进行排序，并根据真实实体在排序列表中的位置进行评估。设真实实体的排名为 rank_i，MRR 定义如公式 3.14所示：

$$\text{MRR} = \frac{1}{|\mathcal{Q}|} \sum_{i=1}^{|\mathcal{Q}|} \frac{1}{\text{rank}_i}, \tag{3.14}$$

其中，$\mathcal{Q}$ 表示测试查询集合。MRR 能够综合反映模型在所有查询上的排序质量，其值越高表示模型性能越好。此外，Hits@N 用于衡量真实实体是否出现在前 N 个预测结果中，其定义如公式 3.15所示：

$$\text{Hits@}N = \frac{1}{|\mathcal{Q}|}\sum_{i=1}^{|\mathcal{Q}|}\mathbb{I}(\text{rank}_i \leq N), \tag{3.15}$$

其中 $\mathbb{I}(\cdot)$ 为指示函数，当条件成立时取值为 1，否则为 0。Hits@N 主要反映模型在前 N 个候选结果中的命中能力，是衡量模型预测准确性的重要指标。

3.4.2 基线方法

为全面评估 PSG 的有效性，选取多种具有代表性的基线方法进行对比，主要包括三类：基于静态图的方法（Static Graph-based methods）、基于时序图的方法（Temporal Graph-based methods）以及基于预训练语言模型的方法（PLM-based methods）。

（1）**基于静态图的方法**。这类方法忽略时间信息，仅基于时序知识图谱的结构进行建模。选取 DistMult[71]、RotatE[72]、R-GCN[24]和 ConvTransE[73]作为该类别的代表方法。

（2）**基于时序图的方法**。该类方法在静态图建模范式基础上引入时间维度，通过刻画结构依赖关系及其演化过程，实现对实体与关系动态变化的建模。具体地，通常基于图神经网络，并结合历史演化信息与时间编码机制，以增强对复杂时序依赖的刻画能力。选取 RE-NET[7]、RE-GCN[12]、CyGNet[27]、SiMFy[28] 以及 CENET[29] 作为代表方法。需要说明的是，SiMFy 和 CENET 的实验结果均基于其开源实现，在统一实验设置下复现得到，以确保实验对比的公平性与一致性。

（3）**基于预训练语言模型的方法**。这类方法通过将时序知识图谱中的结构化事实转化为文本形式，并利用语言模型的语义建模能力进行推理。选取 SimKGC[74]、KGT5[75]、PPT[32]、CoPET[34] 以及 ChapTER[33]作为该类别的代表方法。需要说明的是，SimKGC [1] 和 KGT5 [2] 均基于其开源代码进行了复现，并对其输入形式进行了适配，以支持时序知识图谱数据集上的实验设置；此外，由于 CoPET 和 ChapTER 方法在原始论文中未报告原始评估设置下的实验结果，基于其公开代码与原始参数设置，在统一的原始评估协议下对上述方法进行了重新实现与评测。

3.4.3 实验设置

在统一的实验环境与参数设置下对模型进行训练与评估。具体的硬件与软件环境配置如表 3.2 所示，主要超参数设置如表 3.3 所示。在模型参数方面，实体与关系嵌

1 https://github.com/intfloat/SimKGC

2 https://github.com/apoorvumang/kgt5/

入的维度 d 设置为 200；融合权重系数 α 设置为 0.001，用于平衡结构与语义协同建模模块与全局历史重现模式建模模块的贡献；时序感知软提示长度 m 设置为 5。针对不同数据集，时间权重系数 k 分别设置为 14、8 和 26，对应 ICEWS14、ICEWS18 和 ICEWS05-15 数据集；时间窗口大小 w 分别设置为 3、5 和 15。在训练配置方面，模型采用 AdamW[76] 优化器，学习率设置为 1×10^{-4}，权重衰减系数为 1×10^{-5}，批次大小（batch size）设置为 512，最大训练轮数为 10。

表 3.2 PSG 实验环境配置

配置项	具体信息
操作系统	Ubuntu 20.04.1 LTS
CPU	Intel Ice Lake Silver 4314
内存	256 GB
GPU	NVIDIA A800 (80GB)
CUDA	11.8
框架	PyTorch

表 3.3 PSG 模型主要超参数设置

参数	取值
嵌入维度 d	200
融合权重 α	0.001
软提示长度 m	5
时间权重系数 k	{14, 8, 26}
时间窗口大小 w	{3, 5, 15}
学习率	1×10^{-4}
权重衰减	1×10^{-5}
批次大小	512
训练轮数	10
最大文本长度	144
实体描述长度	50
历史上下文数量	3
优化器	AdamW
预训练模型	bert-base-cased
图模型	ConvTransE

在输入构建方面，文本序列的最大长度设置为 144，实体描述的最大长度设置为

50，同时，基于实体-关系对相关采样策略，选取最近 3 条历史事实作为上下文信息，以增强模型对时序依赖的建模能力。在模型结构上，采用 bert-base-cased [1] 作为预训练语言模型进行参数初始化，用于建模文本语义信息；同时选用 ConvTransE[73]作为图模型，以刻画结构依赖关系。

3.4.4 主要实验结果

表 3.4 各模型在 ICEWS14、ICEWS18 和 ICEWS05-15 数据集上的实验结果统计（单位：%）

模型	ICEWS14			ICEWS18			ICEWS05-15		
	MRR	Hits@1	Hits@3	MRR	Hits@1	Hits@3	MRR	Hits@1	Hits@3
DistMult[71]	20.32	6.13	27.59	13.86	5.61	15.22	19.91	5.63	27.22
RotatE[72]	25.71	16.41	29.01	14.53	6.47	15.78	19.01	10.42	21.35
R-GCN[24]	28.03	19.42	31.95	15.05	8.13	16.49	27.13	18.83	30.41
ConvTransE[73]	31.50	22.46	34.98	23.22	14.26	26.13	30.28	20.79	33.80
RE-NET[7]	35.77	25.99	40.10	26.17	16.43	29.89	36.86	26.24	41.85
RE-GCN[12]	37.78	27.17	42.50	27.51	17.82	31.17	38.27	27.43	43.06
CyGNet[27]	35.45	26.05	39.91	26.46	16.62	30.57	35.46	25.44	40.20
SiMFy[28]	39.48	29.26	44.61	28.61	18.74	32.50	41.92	31.18	47.33
CENET[29]	37.96	28.46	42.23	27.39	17.46	31.45	40.37	30.01	45.61
SimKGC[74]	27.39	19.90	29.72	19.87	12.77	21.85	29.52	21.20	32.15
KGT5[75]	33.36	24.36	37.48	23.77	15.02	26.86	32.81	23.75	36.85
PPT[32]	38.42	28.94	42.50	26.63	16.94	30.64	38.85	28.57	43.35
CoPET[34]	31.04	21.53	35.29	22.36	13.83	24.76	31.34	22.05	34.78
ChapTER[33]	32.81	23.27	36.67	22.82	14.23	25.72	31.77	22.00	35.63
PSG	**43.13**	**33.79**	**48.03**	**30.69**	**21.31**	**34.63**	**45.00**	**35.13**	**50.33**

表 3.4展示了 PSG 与各类基线方法在 ICEWS14、ICEWS18 和 ICEWS05-15 三个数据集上的实验结果。所有指标均以百分比（%）表示, **粗体**表示最优结果，下划线 表示次优结果。实验结果表明，PSG 在所有数据集及评价指标上均取得最优性能，充分体现了其在时序知识图谱推理任务中的优势。进一步分析可见，PSG 在 ICEWS05-15 数据集上的性能提升最为显著。该数据集具有更长的时间跨度与更复杂的历史依赖关系，对模型的长期依赖建模能力提出了更高要求；而 PSG 通过联合建模结构信息与全局历史模式，能够更有效地应对该类复杂场景。下面从不同模型类别对比角度展开分析：

1 https://huggingface.co/google-bert/bert-base-cased

（1）**基于静态图方法的对比分析**。在静态图模型中，ConvTransE 表现最优。相较于 ConvTransE，PSG 在 ICEWS14、ICEWS18 和 ICEWS05-15 数据集上的 MRR 分别提升 11.63%、7.47% 和 14.72%，Hits@1 分别提升 11.33%、7.05% 和 14.34%。该结果表明，未引入时间信息的静态图模型难以充分刻画时序依赖关系。

（2）**基于时序图方法的对比分析**。在时序图模型中，性能最优的方法为 SiMFy。相较于 SiMFy，PSG 在 ICEWS14、ICEWS18 和 ICEWS05-15 数据集上的 MRR 分别提升 3.65%、2.08% 和 3.08%，在 Hits@1 指标上分别提升 4.53%、2.57% 和 3.95%。尽管时序图方法能够通过消息传递机制建模历史演化信息，但其主要依赖结构信息，缺乏对语义信息的有效利用；相比之下，PSG 通过融合结构与语义信息，并结合全局历史重现模式，能够更全面地刻画实体之间的时序依赖关系。

（3）**基于预训练语言模型方法的对比分析**。在 PLM-based 方法中，PPT 表现最优。相较于 PPT，PSG 在 ICEWS14、ICEWS18 和 ICEWS05-15 数据集上的 MRR 分别提升了 4.71%、4.06% 和 6.15%，在 Hits@1 指标上分别提升 4.85%、4.37% 和 6.56%。该结果表明，仅依赖文本语义信息难以有效建模时序知识图谱中的复杂结构依赖关系；而 PSG 通过引入结构增强机制，实现语义信息与结构信息的协同建模，使模型在充分利用语义信息的同时，能够有效捕捉跨时间的结构依赖关系与历史重现规律，从而实现更加准确且稳定的时序推理。

3.4.5 消融实验

表 3.5 不同模块对 PSG 性能的影响（单位：%）

编号	模型变体	ICEWS14		ICEWS18		ICEWS05-15	
		MRR	Hits@1	MRR	Hits@1	MRR	Hits@1
1	**PSG**	**43.13**	**33.79**	**30.69**	**21.31**	**45.00**	**35.13**
2	移除事实描述信息	41.88	32.23	29.16	20.27	43.96	34.95
3	移除历史上下文信息	42.02	33.19	29.50	20.63	44.41	35.05
4	移除图结构模型	39.91	31.39	27.88	19.54	40.97	30.76
5	移除全局历史重现模式建模模块	39.65	29.64	27.51	17.91	41.11	30.06
6	移除时间权重因子 k	40.75	30.76	28.86	19.16	42.33	31.24

为深入分析模型各组成部分对整体性能的影响，本节开展了消融实验。实验结果如表 3.5所示，展示了 PSG 在三个数据集上五种变体在 MRR 和 Hits@1 指标下的性能表现。其中，“移除事实描述信息”表示在输入构建中不引入结构化事实的文本描述，仅保留基础语义信息；“移除历史上下文信息”表示不使用历史事实作为上下文输

入；“移除图结构模型”表示仅依赖预训练语言模型进行推理；“移除全局历史重现模式模块”表示不利用历史事实中的全局统计规律；“移除时间权重因子 k”表示对所有历史事实赋予相同权重，即不区分不同时间段历史信息的重要性。实验结果表明，移除任一模块均会导致模型性能下降，表明各组成部分在模型中均发挥关键作用。

具体地，在输入层面，当移除事实描述信息（编号 2）或历史上下文信息（编号 3）时，模型性能均出现不同程度的下降。其中，移除事实描述信息在三个数据集上的 MRR 分别下降 1.25%、1.53% 和 1.04%，表明事实描述信息对于增强语义表示具有重要作用；同时，历史上下文信息的缺失也会削弱模型对时序依赖关系的建模能力。从结构建模角度来看，移除图结构模型（编号 4）会导致性能显著下降，表明仅依赖语言模型的语义表示难以充分刻画时序知识图谱中的结构依赖关系，进一步验证了结构信息在时序推理任务中的关键作用。移除全局历史重现模式建模模块（编号 5）同样带来明显性能下降，表明该模块在捕捉历史事实中的全局统计规律方面具有重要作用，有助于模型利用历史重现信息进行有效推理。当移除时间权重因子 k（编号 6），即对所有历史事实赋予相同权重，模型性能出现明显下降，进一步验证了近期历史事实在时序推理中的重要性。

3.4.6 四元组频次分布分析

算法 1: 评估时间戳与历史时间戳之间的事实重现比例计算

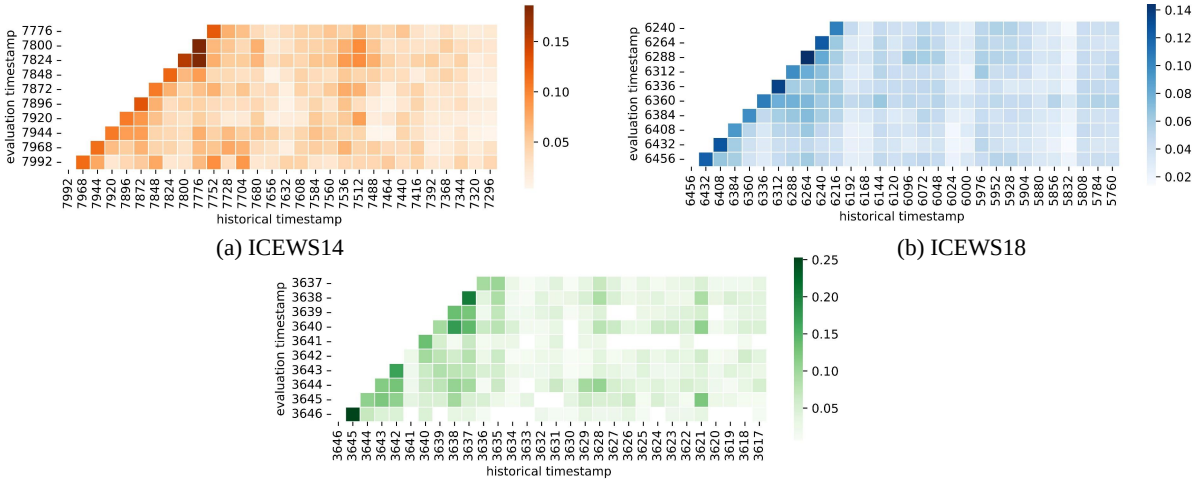
Input: 时序知识图谱验证集数据 $\mathcal{D} = \{(s, r, o, t)\}$，评估时间戳集合 $\mathcal{Y} = \{t_y \mid \forall t_y \in \mathcal{D}\}$，历史时间戳集合 $\mathcal{X} = \{t_x \mid t_x < t_y, \forall t_y \in \mathcal{Y}, \forall t_x \in \mathcal{D}\}$。

Output: 频次比例矩阵 $\mathbf{A} \in \mathbb{R}^{|\mathcal{Y}|\times|\mathcal{X}|}$。

foreach $t_y \in \mathcal{Y}$ **do**
  foreach $t_x \in \mathcal{X}$ **do**
    计算 OverlapRatio $= \frac{|\{(s,r,o)\in\mathcal{D}_{t_x}\cap\mathcal{D}_{t_y}\}|}{|\mathcal{D}_{t_y}|}$;
    令 $\mathbf{A}[t_y, t_x] \leftarrow$ OverlapRatio;
  end
end
return A;

本节对四元组频次分布进行分析，以验证所提出的全局历史重现模式建模模块（对应第 3.3.1节）的合理性。整体计算流程如算法 1 所示。对于每一个评估时间戳 t_y，计算其与各历史时间戳 t_x 之间的覆盖权重（OverlapRatio），用于刻画历史时间戳 t_x 与目标时间戳 t_y 之间的时间相关程度。其中，覆盖权重定义为在两个时间戳 t_x 和 t_y 中共同出现的三元组 (s, r, o) 的比例。该比例越高，说明目标时间戳 t_y 中出现的事实有更大一部分已在历史时间戳 t_x 中出现，从而反映出二者之间更强的时间相关性。在三个数据集上的分析结果如图 3.3 所示。图中颜色越深，表示历史时间戳与评估时间戳之间

的事实重现程度越高，从而反映出更强的时间相关性。可以观察到，目标时间戳对应的事实在时间分布上明显偏向近期历史区间。这说明在未来事件预测中，近期历史事实往往具有更高的相关性与参考价值。因此，有必要从历史事实中挖掘重现模式，并强化对近期历史信息的建模，以提升模型的预测能力。



(a) ICEWS14　(b) ICEWS18

(c) ICEWS05-15

图 3.3 ICEWS 系列数据集上四元组频次分布分析结果

3.4.7 训练策略有效性分析

为系统评估所提出的 PSG 模型训练策略的有效性，本节从冻结参数策略、训练效率以及历史上下文采样策略三个方面对模型进行系统性实验分析。

表 3.6 不同冻结参数策略下,PSG 在 ICEWS14 上的性能（单位：%）

编号	模型	MRR	Hits@1
1	**PSG**	**43.13**	**33.79**
2	仅微调底层第 1 层参数	41.95	33.19
3	仅微调高层第 1 层参数	41.56	32.90
4	仅微调底层前 6 层参数	38.61	31.22
5	仅微调高层后 6 层参数	36.81	30.72
6	全参数微调	36.18	30.24

冻结参数策略对模型性能的影响。表 3.6 展示了不同冻结参数策略下 PSG 的性能表现。随着预训练语言模型中可训练参数数量的增加，PSG 的性能整体呈下降趋势。其中，在全参数微调设置下性能下降最为显著，MRR 相较完整模型下降了 6.95%，同时 Hits@1 指标也下降了 3.55%。该结果表明，冻结预训练语言模型参数有助于保留其原有的语义表示能力，从而更好地与结构信息进行协同建模。进一步分析表中编号 2-5

的实验结果可以发现，对底层参数进行微调的性能整体优于对高层参数进行微调。这主要是由于预训练语言模型的底层通常编码更加基础且通用的语义特征，而高层更偏向任务相关表示，过度微调容易破坏原有语义结构，从而对模型性能产生负面影响。

表 3.7 各模型在 ICEWS14 数据集上的模型规模与单轮训练时间

模型	预训练模型基座	模型总参数量	训练参数量	训练时间/轮
SimKGC	bert-base-cased	216.6M	216.6M	3.2 分钟
KGT5	T5-base	223M	223M	42.6 分钟
ChapTER	bert-base-cased	217.0M	0.37M	3.3 分钟
PSG	bert-base-cased	124.3M	14.8M	4.2 分钟

模型效率层面的变化。表 3.7 展示了不同方法在参数规模与训练效率方面的对比结果。具体地，SimKGC 和 KGT5 通常需要对全部参数进行微调，训练开销较大；而 ChapTER 仅需调整极少量参数，在参数效率方面表现突出。相比之下，PSG 在引入结构建模与全局历史重现模式的同时，仅需对部分参数进行训练（14.8M），在保证模型表达能力的同时有效控制了训练开销。尽管 PSG 相较于 ChapTER 在可训练参数规模和训练成本上有所增加，但其在各项评价指标上均取得更优的性能，体现出更强的建模能力。这表明 PSG 在训练效率与模型性能之间实现了良好的权衡，在适度增加计算成本的前提下，能够显著提升时序推理效果。

表 3.8 不同历史采样策略在 ICEWS14 数据集上的性能对比（单位：%）

采样策略	MRR	Hits@1	Hits@3
pair-related	**43.13**	**33.79**	**48.03**
entity-related	42.53	33.55	47.32
relation-related	42.23	33.11	46.65

历史上下文采样策略对模型性能的影响。表 3.8 展示了不同采样策略对 PSG 模型性能的影响。针对查询 $(s_q, r_q, ?, t_q)$，分别从实体相关（*entity-related*）、关系相关（*relation-related*）以及实体-关系对相关（*pair-related*）三个角度选取历史四元组。其中，*entity-related* 表示选取所有以查询头实体 s_q 为中心的事实；*relation-related* 表示选取与关系 r_q 相关的历史事实；而 *pair-related* 则同时约束头实体与关系的历史四元组。实验结果表明，同时考虑实体与关系的联合历史信息，能够提供更加丰富且具有上下文一致性的背景知识，从而有助于模型更准确地捕捉时序依赖关系。

3.4.8 模型泛化性能分析

为系统评估所提出方法的鲁棒性与泛化能力，本节从 PSG 对不同图模型与预训练语言模型的适配性出发进行分析。具体地，通过替换不同骨干网络，评估其在多种配置下的性能表现，从而验证方法对底层模型的低依赖性及良好的通用性。

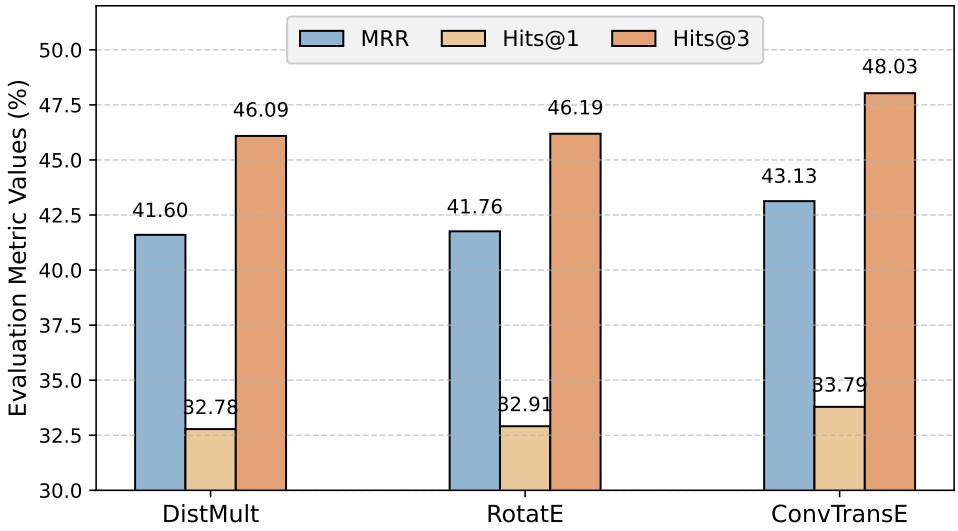


图 3.4 不同图模型下 PSG 在 ICEWS14 数据集上的性能对比（单位：%）

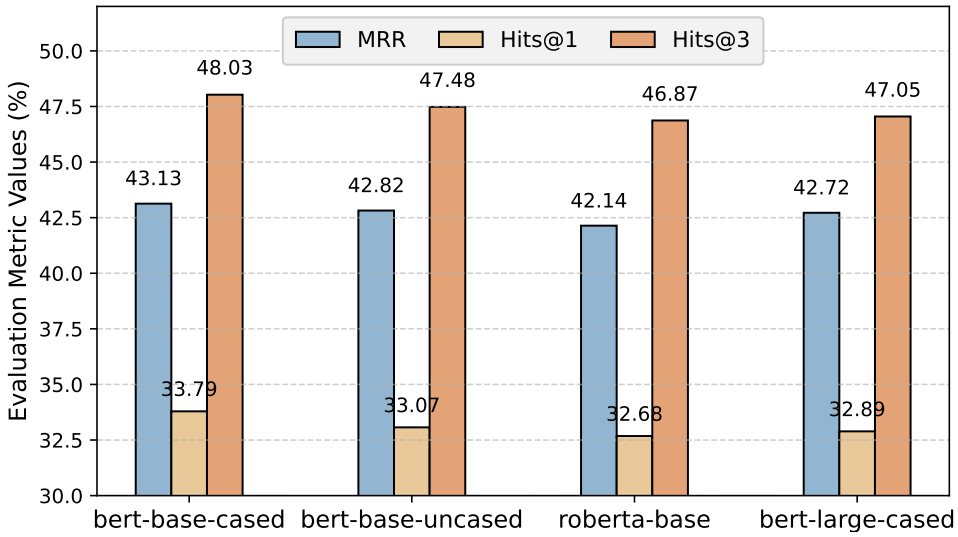


图 3.5 不同预训练语言模型下 PSG 在 ICEWS14 数据集上的性能对比（单位：%）

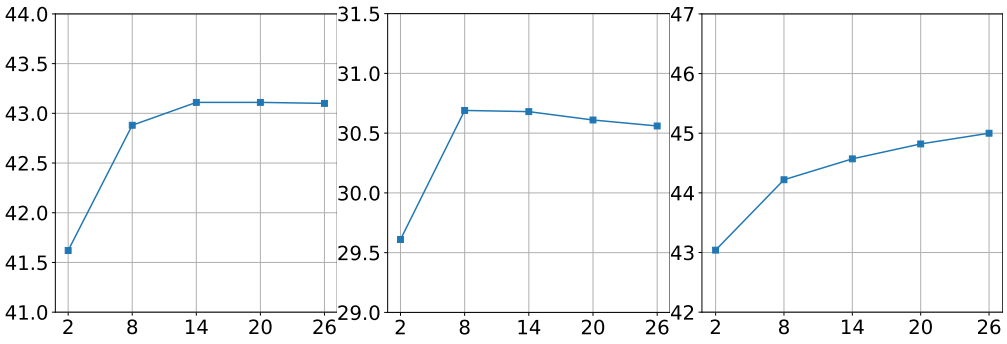
在图模型方面，选取三种具有代表性的图模型，包括 ConvTransE[73]、DistMult[71]以及 RotatE[72]，实验结果如图 3.4所示。结果表明，PSG 在不同图模型上均取得稳定的性能表现，说明该方法对特定图模型结构依赖较低，具有良好的适配性。无论是在结构较为简单的 DistMult 模型，还是在建模能力更强的 RotatE 和 ConvTransE 模型上，PSG 均能够保持较优性能，验证了其在不同图模型下的通用性。

在预训练语言模型方面，选取多种主流 PLM 进行实验，包括：bert-base-cased、bert-base-uncased、bert-large-cased 以及 roberta-base [1]，实验结果如图 3.5所示。结果表明，不同 PLM 作为主干网络的性能差异较小，整体表现均维持在较高水平。例如，基于 roberta-base 的 PSG 在 MRR、Hits@1 和 Hits@3 指标上分别达到 42.14%、32.68% 和 46.87%。

综上所述，PSG 在不同图模型与预训练语言模型上均表现出良好的适配性与稳定性。

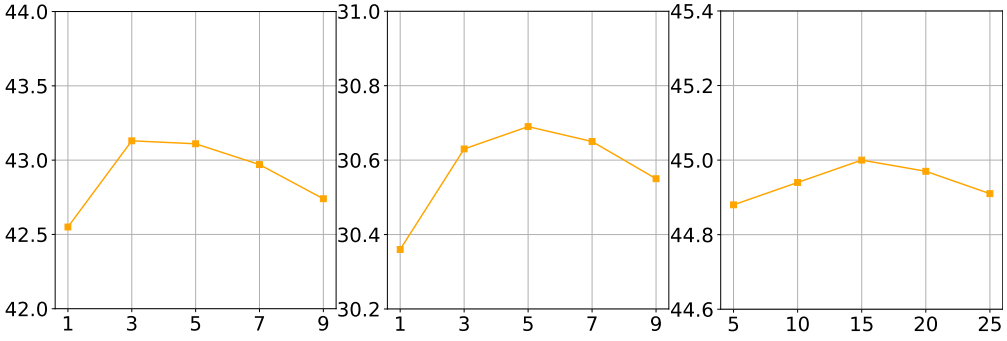
3.4.9 超参数敏感性分析

为了进一步分析关键超参数对模型性能的影响，本节对时间权重系数 k 和时间窗口大小 w 进行了敏感性实验，结果如图 3.6 和图 3.7 所示，评估指标为 MRR。



(a) ICEWS14　　(b) ICEWS18　　(c) ICEWS05-15

图 3.6 时间权重系数 k 的敏感性分析，横轴是 k，纵轴是 MRR（单位：%）



(a) ICEWS14　　(b) ICEWS18　　(c) ICEWS05-15

图 3.7 时间窗口大小 w 的敏感性分析，横轴是 w，纵轴是 MRR（单位：%）

从图 3.6可以观察到，随着时间权重系数 k 的增大，模型在 MRR 指标上的性能整体呈上升趋势，说明引入更多历史时间信息有助于提升模型的推理能力。但当 k 进一

1 https://huggingface.co/FacebookAI/roberta-base

步增大时，性能提升逐渐趋于平缓，表明历史信息的边际贡献逐步减弱，过多历史信息难以带来显著增益。

从图 3.7可以观察到，时间窗口大小 w 对模型性能具有明显影响。在较小的 w 取值范围内，模型能够有效利用近期历史信息，从而取得较好的性能表现；而当 w 过大时，模型性能出现一定程度的下降，说明过长时间范围内的历史信息可能引入噪声，削弱模型对关键时序依赖的判别能力。此外，不同数据集上的最优参数设置存在一定差异：在 ICEWS14、ICEWS18 和 ICEWS05-15 数据集上，模型分别在 $w = 3$、$w = 5$ 和 $w = 15$ 时取得最佳性能。这一现象表明，时间窗口的选择需与数据集的时间跨度及其动态特性相匹配。

综上所述，时间权重系数 k 和时间窗口大小 w 均对模型性能具有关键影响，合理设置二者能够在信息利用与噪声抑制之间实现有效权衡，从而提升模型整体性能。

3.5 本章小结

针对时序知识图谱外推推理任务中预训练语言模型难以有效建模结构依赖与历史演化信息的问题，提出了一种联合结构信息与全局历史重现模式的预训练语言模型方法 PSG。该方法通过引入时间感知软提示，将图结构信息映射至语言模型输入空间，实现结构信息与语义信息的协同建模；同时，基于历史事实的频次分布构建全局历史重现模式建模模块，并结合时间窗口与时间权重机制，对不同时间段的历史信息进行加权建模，从而强化近期历史信息在推理过程中的作用。在三个典型的时序知识图谱数据集上的实验结果表明，PSG 均显著优于现有基线方法，验证了所提出方法的有效性。通过消融实验分析了各组成模块对模型性能的贡献，结果表明结构信息建模与全局历史重现模式均对提升模型性能具有重要作用。此外，通过对四元组频次分布的统计分析，验证了历史事实中存在显著的重现模式及其“近期效应”，为模型构建提供了理论依据。在进一步分析中，从训练策略、模型效率及历史上下文采样策略等多个角度对 PSG 进行了深入探讨，结果表明所提出方法在性能与效率之间取得了良好的平衡。同时，通过模型泛化性能分析与超参数敏感性分析，验证了 PSG 在不同图模型与预训练语言模型下均具有良好的适配性与稳定性，并能够在不同参数设置下保持较优性能。

第 4 章　基于大语言模型的结构感知生成式时序知识图谱推理框架

基于第三章中预训练语言模型在提升时序知识图谱推理准确性方面的研究成果，本章进一步围绕推理过程的可解释性展开研究。尽管基于预训练语言模型的方法表现出较强的性能，但其整体仍以嵌入表示学习为主，缺乏对推理过程的显式建模能力，致使推理流程与证据链难以透明化，因此限制了其在实际场景中的应用。尤其在复杂时序逻辑与高风险决策场景中，模型不仅需要提供准确的预测结果，还需具备可解释、可追溯的推理能力，以满足实际决策需求。随着训练语料与模型规模的不断扩大，预训练语言模型逐步演进为以生成范式为核心的大语言模型（LLMs）。在此基础上，大语言模型驱动的生成式推理能够在生成结果的同时显式刻画推理过程，从而提升模型的可解释性。然而，LLMs 庞大的参数规模带来了较高的微调成本，同时在生成过程中存在“幻觉”问题，难以保证推理结果满足结构约束，从而对推理过程的可靠性提出了新的挑战。针对上述问题，本章聚焦于可解释时序知识图谱推理，提出一种基于大语言模型的结构感知生成式推理框架。具体包括：在数据层面，构建面向可解释过程的时序知识图谱推理评测基准，以系统评估现有方法的可解释推理能力；在方法设计层面，进一步提出结构感知的生成式推理模型，以实现有效的可解释推理。

4.1　引言

时序知识图谱通过整合多源异构数据并构建结构化的时序演化网络，逐渐应用于时序问答[77]、推荐系统[78–79]以及电力监测[80]等复杂场景。在此背景下，时序知识图谱推理作为挖掘潜在时序规律与预测未来事件的重要手段，逐渐成为研究热点。近年来，研究者围绕时序知识图谱推理提出了多种方法，主要包括基于图神经网络的方法和基于预训练语言模型的方法。其中，基于图神经网络的方法通过捕捉图结构信息建模时序演化，而基于预训练语言模型的方法则通过将结构化事实转化为文本输入实现语义信息的建模。然而，如图 4.1(a) 所示，这些方法在建模范式上仍以嵌入表示学习为核心，输出结果通常不透明，缺乏对推理过程的显式刻画，难以提供清晰且可验证的推理依据。具体地，这类方法通过对候选事实进行评分或排序完成预测，尽管能够在一定程度上提升预测精度，但其推理过程隐含于模型参数之中，缺乏中间推理路径，因而难以实现有效的可解释推理。在实际应用中，这一问题在复杂时序逻辑与高风险决策场景中尤为突出（如政策分析、医疗诊断等），仅依赖预测结果已难以满足需求，还需提供可解释、可追溯的推理过程，以支撑可靠决策。

为缓解上述问题，研究者开始从可解释性角度对时序知识图谱推理进行探索，但整体仍处于初步阶段，主要包括基于逻辑规则的方法[81–82]和基于强化学习的方法[30,83]。

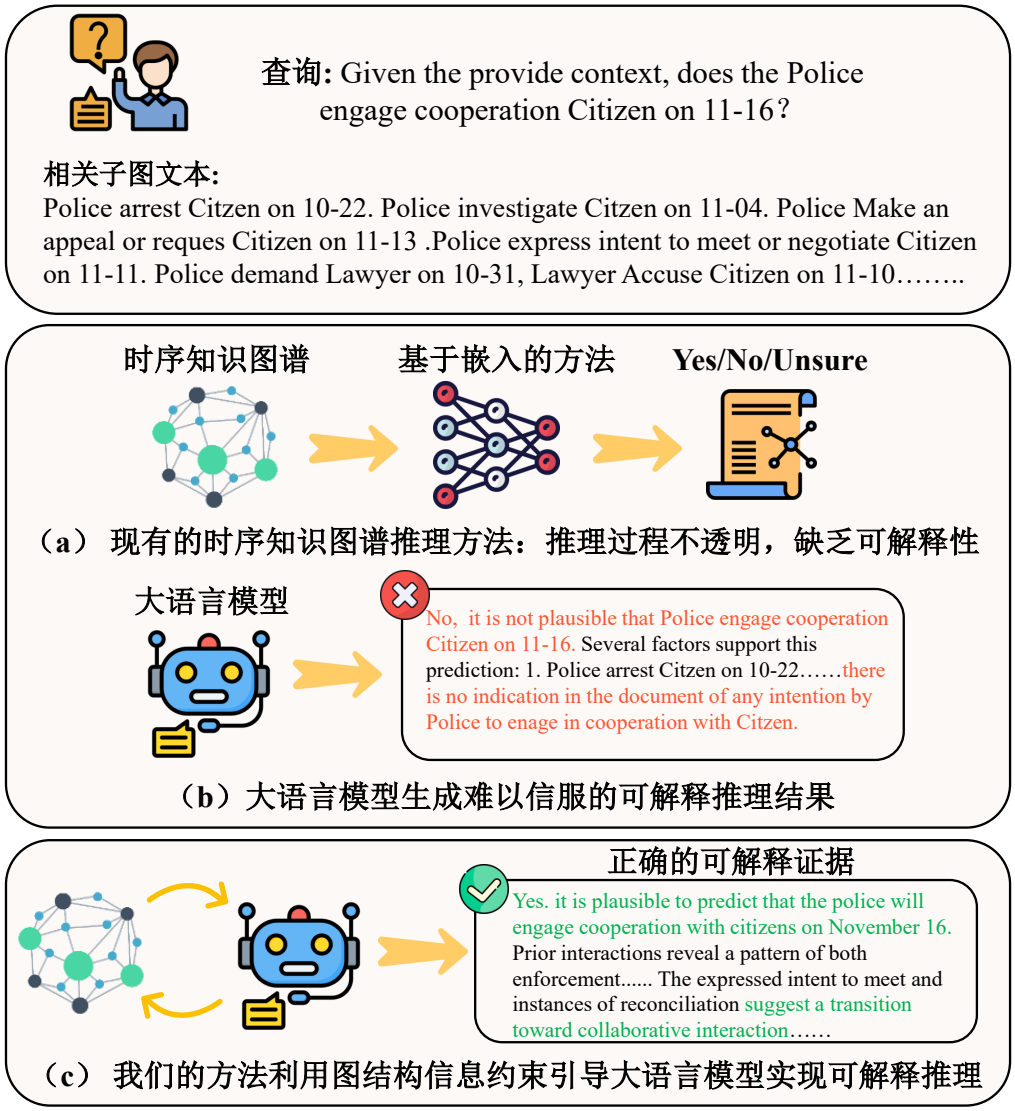


图 4.1 现有时序知识图谱推理方法与本文方法的对比示意图

基于逻辑规则的方法通过挖掘时序知识图谱中的规则模板，以实现推理过程的可解释性。例如,TLogic[31]通过在时序知识图谱上进行随机游走以挖掘潜在的时序逻辑规则，从而实现对历史依赖关系的显式建模。然而，这类基于逻辑规则的方法在复杂时序场景下难以兼顾表达能力与泛化能力。其规则通常依赖有限的模式空间，难以覆盖复杂多变的时序依赖关系；同时，其组合与扩展能力有限，在多跳推理及长时间跨度依赖场景下建模能力受限。基于强化学习的方法通过在时序知识图谱上学习推理路径来构建解释过程。例如，xERTE[30]通过构建与查询相关的子图以缩小搜索空间，并在此基础上学习潜在的推理路径；TITer[83]则通过逐步遍历图结构，构建序列化的推理链，从而完成目标事实的预测。然而，这类基于强化学习的方法通常依赖于隐式策略表示进行决策，缺乏清晰的语义表达，使得生成的推理路径难以直接被人类理解；同时，该类方法对奖励函数设计较为敏感、易出现训练不稳定等问题，因而难以应用于复杂时

序知识图谱推理任务。

相较于上述方法，大语言模型凭借强大的语义理解与文本生成能力，为面向可解释过程的时序知识图谱推理提供了新的技术路径。不同于传统方法仅输出预测结果，LLMs 能够以自然语言形式生成推理过程，从而显式刻画中间推理路径，提升模型的可解释性与可读性。然而，直接将大语言模型应用于该任务仍面临挑战。如图 4.1(b) 所示，模型在推理过程中易产生与事实不一致的内容，即“幻觉”问题，导致推理过程缺乏可靠性与可信性。其根本原因在于，LLMs 依赖对结构化事实的线性化表示，难以充分利用时序知识图谱中的结构依赖关系，从而限制了其在复杂推理场景下的表现。基于此，本章进一步探讨如下核心问题：如何使 LLMs 在复杂时序知识图谱推理场景中，在保证预测准确性的同时，生成结构清晰且逻辑一致的可解释推理过程？

针对上述问题，本章提出一种基于大语言模型的结构感知生成式时序知识图谱推理框架，以提升推理过程的可解释性。具体地，在数据层面，构建了面向可解释过程的时序知识图谱推理评测基准 ETR，用于系统评估模型在不同时间尺度下的预测与解释生成能力。该基准覆盖新闻事件、国际关系和结构化知识三类典型场景的时序知识图谱数据，并涵盖分钟级、天级和年级等多种时间粒度。每个样本由查询文本、推理链文本以及解释文本三部分组成，其中解释文本在约束生成策略下自动构建，融合预测结果及其对应的推理过程，从而为模型提供统一的可解释性评估标准。进一步地，在方法设计层面，为引导大语言模型生成逻辑一致的推理解释，提出一种结构感知的生成式推理模型（a structure-aware generative framework that integrates **G**raph structures with text for **E**xplainable **TE**mporal **R**easoning, **GETER**）。具体地，首先引入时序结构感知编码器对历史结构信息进行建模，将查询与推理链对应的结构信息编码为软图表示；随后，利用轻量级结构-文本适配机制，将结构表示映射至大语言模型的语义空间，实现图结构信息与文本语义的有效对齐；最后，结合指令微调策略，使模型在融合结构信息与上下文语义的基础上，实现对预测结果及其推理过程的联合生成，从而提升推理的可解释性。在 ETR 基准上的实验结果表明，所提方法在保持预测性能的同时，能够生成逻辑一致的推理解释，从而在不同应用场景中展现出良好的可解释性与适用性。综上所述，本章的主要贡献如下：

（1）构建了面向可解释过程的时序知识图谱推理评测基准 ETR，覆盖多种应用场景与时间粒度，为系统评估模型的可解释时序推理能力提供了统一标准。

（2）提出了结构感知的生成式推理模型 GETER，通过引入结构编码与结构-文本对齐机制，有效融合时序知识图谱中的结构信息与大语言模型的语义表示能力，从而提升模型的可解释推理能力。

（3）在 ETR 基准上的实验结果表明，GETER 在保证预测性能的同时，实现了逻辑一致且可读性良好的推理解释，并在不同场景下展现出良好的泛化能力。

4.2 问题定义

时序知识图谱 $\mathcal{G}$ 表示为按时间戳排列的静态知识图谱序列 $(\mathcal{G}_0, \mathcal{G}_1, \ldots, \mathcal{G}_t)$。具体地，$\mathcal{G} = (\mathcal{E}, \mathcal{R}, \mathcal{F})$，其中 $\mathcal{E}$、$\mathcal{R}$ 和 $\mathcal{F}$ 分别表示实体集合、关系集合以及事实集合。每个事实表示为四元组 $(e_s, r, e_o, t) \in \mathcal{F}$。在此基础上，可解释时序知识图谱推理任务定义为：在给定历史推理链的条件下，对未来查询进行预测，并生成对应的推理解释。任务数据集定义如公式 4.1所示：

$$\mathcal{D} = \{(q_i, \mathcal{C}_i, y_i, \mathcal{A}_i)\}_{i=1}^{N}, \tag{4.1}$$

其中，q_i 表示查询，$\mathcal{C}_i$ 表示由历史事实构成的推理链，$y_i \in \{\text{Yes}, \text{No}, \text{Unsure}\}$ 表示预测标签，$\mathcal{A}_i$ 表示对应的推理解释。推理链 $\mathcal{C}_i$ 由时间区间 $[t_q - w, t_q)$ 内的历史事实集合 $\mathcal{F}_{[t_q-w,t_q)}$ 构成，w 表示时间窗口大小。进一步地，该任务的目标在于学习一个映射函数，定义如公式 4.2所示：

$$f : (q, \mathcal{C}, \mathcal{G}) \rightarrow (y, \mathcal{A}), \tag{4.2}$$

其中，y 表示预测结果，$\mathcal{A}$ 表示自然语言推理解释。此外，为保证模型的时序外推能力，训练集 $\mathcal{T}_{train}$ 与测试集 $\mathcal{T}_{test}$ 满足外推设定[7]，即训练时间 t_{train} 严格早于测试时间 t_{test}，形式化表示为 $t_{train} < t_{test}$。与传统时序知识图谱推理任务仅关注预测结果不同，该任务要求模型在完成预测的同时生成对应的推理解释文本，从而提升推理过程的可解释性与可靠性。对于传统基于嵌入的模型，由于缺乏文本生成能力，通常仅能输出预测结果；而对于大语言模型，其能够在给出预测结果的同时生成对应的推理解释。

4.3 面向可解释过程的时序知识图谱推理基准

现有研究多侧重于预测性能的提升，缺乏对推理过程的显式刻画，从而导致推理过程的透明性与可解释性不足；同时，缺乏面向可解释过程的时序知识图谱推理统一评测基准，难以系统性评估模型的可解释推理能力。

为解决上述问题，如图 4.2所示，本节构建了面向可解释过程的时序知识图谱推理评测基准 **ETR**，从多应用场景与时间粒度出发，结合多维评价指标，对模型的可解释推理能力进行系统评估。具体地，首先基于时序知识图谱构建多类型样本（见第 4.3.1节），包括正样本、负样本和中立样本，以刻画不同推理场景下的预测需求；其次，针对每个查询，从历史时间窗口内抽取相关事实，构建对应的推理链（见第 4.3.2节），以表征事件之间的时序依赖关系；随后，结合查询与推理链，利用 GPT-4o 在约束模板下生成解释文本（见第 4.3.3节），实现预测结果与推理过程的联合建模；最后，对生成结果进行质量控制（见第 4.3.4节），包括过滤无效答案与人工审查；其中，人工审查从解释文本质量与整体一致性两个维度进行系统评估，以确保基准数据的可靠性与有效性。

如表 4.1所示，构建的 ETR 基准覆盖多种应用场景与时间粒度。具体地，选取五个

广泛使用的时序知识图谱数据集[35,38]，包括 ICEWS14[68]、ICEWS18[30]、ICEWS05-15[68]、GDELT[38] 以及 WIKI[84]。

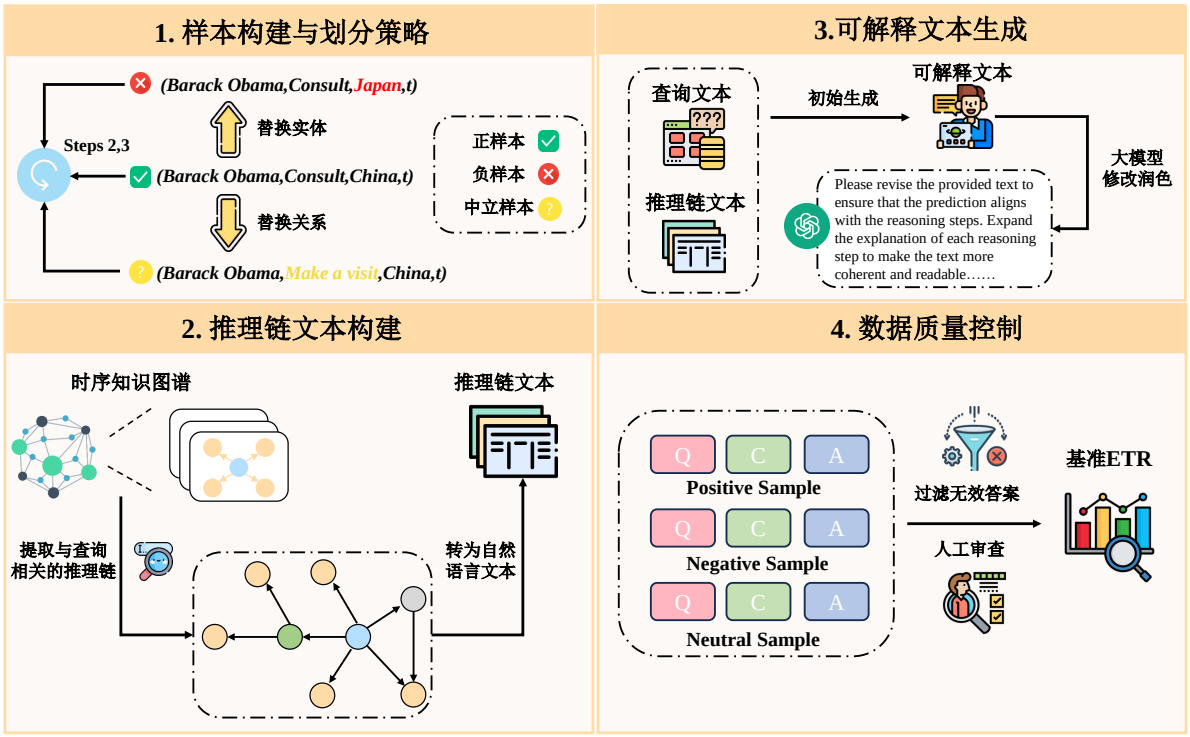


图 4.2 ETR 基准构建流程

表 4.1 ETR 基准的数据统计信息

数据集	时间粒度	实体数	关系数	类型	正样本	负样本	中立样本	总数
ICEWS14	1 天	7128	230	训练集	5000	4800	4500	14300
				测试集	800	700	600	2100
ICEWS05-15	1 天	10094	251	训练集	4500	4400	4200	13100
				测试集	720	680	660	2060
ICEWS18	1 天	23033	256	训练集	4400	4200	4000	12600
				测试集	750	700	650	2100
GDELT	15 分钟	5850	238	训练集	4800	4600	4400	13800
				测试集	800	700	650	2150
WIKI	1 年	12554	24	训练集	2482	2504	2342	7328
				测试集	347	286	316	949

从应用场景的角度来看，ETR 基准所选数据集可归纳为以下三类：

新闻事件与国际关系场景（ICEWS）。包括 ICEWS14、ICEWS18 和 ICEWS05-15，均来源于 *Integrated Crisis Early Warning System*（ICEWS）。该类数据集主要记录国际新闻事件，侧重刻画国家之间的交互关系。其中，ICEWS14 和 ICEWS18 分别包含 2014 年和 2018 年的事件数据，ICEWS05-15 覆盖 2005 至 2015 年的长期时间跨度。

动态事件流场景（GDELT）。来源于 *Global Database of Events, Language, and Tone*（GDELT），记录高频新闻事件，具有 15 分钟级时间粒度，能够刻画细粒度的动态事件演化过程。

结构化知识场景（WIKI）。来源于维基数据（Wikidata）知识库，主要描述结构化事实，时间粒度为年级，适用于建模长期稳定的知识关系。

综述所述，这些数据覆盖了从分钟级到年级的多尺度时间信息，并在实体规模与关系复杂度上呈现显著差异，从而为系统评估模型在不同时间尺度与多应用场景下的可解释时序推理能力提供了多样化的数据支撑。

4.3.1 样本构建与划分策略

为全面评估模型可解释推理任务中的能力，特别是 LLMs 对查询与历史事实之间推理关系的建模能力，构建了正样本、负样本以及中立样本三类数据。正样本刻画真实事实，用于衡量模型的事实判别能力；负样本引入错误结论，用于检验模型的错误识别能力；中立样本刻画证据不足场景，用于评估模型的不确定性推理能力。

（1）正样本

正样本取自时序知识图谱中的真实事实，用于评估模型的事实判别能力。对于任意查询 $q_i = (e_s, r, e_o, t_q) \in \mathcal{F}$，从历史时间窗口 $[t_q - w, t_q)$ 内抽取相关事实，构建对应的推理链 $C_i = C(e_s, e_o)$，并将其标注为正样本。形式化地，正样本集合的定义如公式 4.3所示：

$$\mathcal{D}_{\text{pos}} = \{(q_i, C_i, y_i, \mathcal{A}_i) \mid q_i \in \mathcal{F},\ y_i = \text{Yes}\}, \tag{4.3}$$

其中，$\mathcal{A}_i$ 表示基于 q_i 与 C_i 生成的推理解释。

（2）负样本

负样本用于评估模型识别错误事实的能力。具体地，给定正样本查询 $q_i = (e_s, r, e_o, t_q)$，通过替换尾实体构造反事实查询，并基于其构建对应的推理链。形式化地，负样本集合的定义如公式 4.4所示：

$$\mathcal{D}_{\text{neg}} = \left\{ (q_i, C_i, y_i, \mathcal{A}_i) \;\middle|\; \begin{array}{ll} q_i = (e_s, r, e'_o, t_q), & e'_o \in \mathcal{E},\ e'_o \neq e_o, \\ (e_s, r, e'_o, t_q) \notin \mathcal{F}, & y_i = \text{No} \end{array} \right\}, \tag{4.4}$$

其中，$C_i = C(e_s, e'_o)$ 表示基于替换后的实体对构建的推理链。该构造引入与真实事实语义相关但不成立的样本，用于评估模型的判别能力与鲁棒性。

（3）中立样本

中立样本用于评估模型在证据不足情况下的推理能力。当历史信息不足以支持或否定查询时，模型应能够输出不确定判断。给定正样本查询 $q_i = (e_s, r, e_o, t_q)$，通过替换关系构造语义中立的查询，并基于相同历史推理链进行推理。形式化地，中立样本集合的定义如公式 4.5所示：

$$\mathcal{D}_{\text{neu}} = \left\{ (q_i, \mathcal{C}_i, y_i, \mathcal{A}_i) \;\middle|\; \begin{array}{l} q_i = (e_s, r', e_o, t_q), \quad r' \neq r, \\ (e_s, r', e_o, t_q) \notin \mathcal{F}, \quad P_{\text{NLI}}(\text{neutral} \mid r, r') > \tau, \\ \mathcal{C}_i = \mathcal{C}(e_s, e_o), \quad y_i = \text{Unsure} \end{array} \right\}, \tag{4.5}$$

其中，r' 表示通过自然语言推理（Natural Language Inference, NLI）模型[85]筛选得到的语义中立关系。具体地，将关系 r 与候选关系 r' 转化为文本对，并输入 NLI 模型进行判别，模型将文本对的语义关系划分为蕴含、矛盾或中立三类；为筛选中立关系，仅当满足 $P_{\text{NLI}}(\text{neutral} \mid r, r') > \tau$ 时，才将 r' 选作中立关系，其中 τ 为预设阈值。该构造在保持历史上下文一致的前提下引入关系扰动，用于评估模型的不确定性建模能力。

结合上述三类数据，，最终数据集可表示为：$\mathcal{D} = \{\mathcal{D}_{\text{pos}} \cup \mathcal{D}_{\text{neg}} \cup \mathcal{D}_{\text{neu}}\}$。以 ICEWS14 数据集为例，给定正样本查询 (Barack Obama, Consult, China, t)，其推理链由历史时间窗口内与 Barack Obama 和 China 相关的四元组事实构成，用于支持该查询成立。负样本通过替换尾实体构造查询，例如将 China 替换为 Japan 得到 (Barack Obama, Consult, Japan, t)，并基于 Barack Obama 和 Japan 抽取对应推理链。中立样本通过 NLI 模型筛选与原关系语义中立的关系，并据此替换构造查询。例如将 Consult 替换为 Make a visit，得到 (Barack Obama, Make a visit, China, t)，该查询与正样本共享相同的推理链。

4.3.2 推理链文本构建

基于给定查询，本节聚焦构建相关推理链文本。具体地，给定查询 $q = (e_s, r, e_o, t_q)$，采用广度优先搜索方法[86]从时序知识图谱中抽取与实体 e_s 和 e_o 相关的图结构推理链 $\mathcal{C}(e_s, e_o)$。推理链的抽取限定在历史时间窗口 $[t_q - w, t_q)$ 内，定义如公式 4.6所示：

$$\mathcal{C}(e_s, e_o) \leftarrow \bigwedge_{i=1}^{l} (E_i, R_i, E_{i+1}, T_i), \tag{4.6}$$

其中，$E_1 = e_s$，$E_{l+1} = e_o$，$l \in \{1, 2\}$ 表示推理路径的长度。E_i、R_i 和 T_i 分别表示路径中第 i 步对应的实体、关系和时间戳。在获得推理链 $\mathcal{C}(e_s, e_o)$ 后，进一步将其转换为自然语言形式，得到对应的推理链文本 C_i，作为模型的输入从而实现结构化图信息与文本语义表示之间的映射。

可解释文本生成提示模板

初始化模板：
We predict that [e_s] [r] [e_o] will happen on [t_q]. Here are the reasoning steps: $\mathcal{C}(e_s,e_o)$.
正样本润色模板：
You are an expert in temporal knowledge graph reasoning and natural language explanation generation.
Given the following text:
"We predict that [e_s] [r] [e_o] will happen on [t_q]. Here are the reasoning steps: $\mathcal{C}(e_s,e_o)$.“ Revise the explanation to improve its quality.
Requirements:
- The prediction must be fully supported by the reasoning steps;
- Each reasoning step should be clearly explained and logically connected;
- You may add intermediate reasoning steps if necessary;
- The explanation should be fluent, coherent, and easy to understand.
Output a single concise paragraph with strong logical consistency and no bullet points.
负样本润色模板：
You are an expert in temporal knowledge graph reasoning and natural language explanation generation.
Given the following text:
"It is unlikely that [e_s] [r] [e_o'] will happen on [t_q]. Here are the reasoning steps: $\mathcal{C}(e_s,e_o')$."
Revise the explanation to justify why the event is unlikely.
Requirements:
- The conclusion must be consistent with the reasoning steps;
- Explicitly explain why the reasoning steps do not support the event;
- Highlight contradictions or missing evidence when applicable;
- Ensure the explanation is coherent and logically sound.
Output a single concise paragraph with strong logical consistency and no bullet points.
中立样本润色模板：
You are an expert in temporal reasoning and uncertainty-aware explanation generation.
Given the following text:
"It is uncertain whether [e_s] [r'] [e_o] will happen on [t_q]. Here are the reasoning steps: $\mathcal{C}(e_s,e_o)$."
Revise the explanation to reflect uncertainty.
Requirements:
- The explanation must show that the reasoning steps are insufficient to support or refute the event;
- Clearly indicate missing or inconclusive evidence;
- Avoid making definitive conclusions;
- Ensure the explanation is coherent and logically consistent.
Output a single concise paragraph with strong logical consistency and no bullet points.
评估与优化模板：
You are an expert in evaluating explanation quality for temporal reasoning.Given the generated explanation, assess and refine it according to the following criteria:- Logical consistency: Is the conclusion supported by the reasoning steps?- Completeness: Are all reasoning steps adequately explained?- Clarity: Is the explanation fluent and easy to understand?- Faithfulness: Does the explanation accurately reflect the reasoning chains?If any issues are identified, revise the explanation to improve its overall quality. Output a single refined paragraph with clear logic and strong readability.

图 4.3 可解释文本生成工作流提示

4.3.3 可解释文本生成

基于查询及其推理链文本，进一步生成可解释文本。对于正样本，给定查询 $q=(e_s,r,e_o,t_q)$ 及其对应的推理链 $\mathcal{C}(e_s,e_o)$，生成与推理过程一致的自然语言解释。本节提出了一种分阶段的生成方法，包括初始生成、结果优化与质量评估三个阶段，以提升解释文本的逻辑一致性与表达质量，其整体流程如图 4.3 所示。

在初始化阶段，基于预定义模板生成初始解释文本 $\mathcal{A}_i'$，将结构化推理链转化为基础的自然语言描述。然而，受限于模板表达能力及部分推理链支撑不足，初始文本通常存在表达不连贯、语言不自然和逻辑一致性不足等问题。进一步地，在润色阶段，引入 GPT-4o 对初始解释文本进行优化，生成中间解释文本 $\mathcal{A}_i''$，通过构建约束生成提示，引导模型逐步展开推理链与语义重构，从而提升文本的连贯性与可读性。在评估与优化阶段，构建基于 GPT-4o 的自动评估机制，从逻辑一致性、完整性与表达清晰性等维

度对中间文本进行质量评估，并在必要时进行修正，最终得到可解释文本 $\mathcal{A}_i$。

对于负样本与中立样本，采用与正样本一致的三阶段生成流程，通过差异化提示分别生成反证性解释与不确定性解释，实现对不同推理情形的统一建模。

4.3.4 数据质量控制

为保证 ETR 基准质量，首先，对公式 4.1所定义数据集的推理解释结果进行有效性筛选，剔除不满足基本逻辑约束或语义不完整的样本。

在此基础上，进一步引入人工评估验证数据质量，邀请三名专家对基准数据进行评估。每位专家随机抽取 200 个样本，并从解释文本质量与整体一致性两个维度进行评分，评分范围为 1 至 3 分。其中，解释文本质量用于衡量生成解释的清晰性、连贯性与合理性；整体一致性用于评估查询文本、推理链与解释文本之间的逻辑一致程度。人工评估结果如表 4.2所示。结果表明，该基准在解释质量与一致性方面表现良好，验证了 ETR 构建流程的有效性与可靠性。

表 4.2 ETR 基准质量人工评估结果

评估人员	解释文本质量	整体一致性
专家 1	2.80	2.78
专家 2	2.74	2.79
专家 3	2.86	2.89

4.4 结构感知的生成式推理模型

在构建面向可解释过程的时序知识图谱推理基准的基础上，本节进一步提出一种结构感知的生成式推理模型 GETER，通过引入结构约束缓解大语言模型生成过程中的“幻觉”问题。如图 4.4 所示，该模型在生成式推理框架中显式引入时序图结构信息，通过结构与语义的协同建模，提升模型的推理能力与可解释性。首先，引入时序结构感知编码器（见第 4.4.1节），对历史时序图结构进行建模，学习实体与关系的结构表示，从而刻画其时间依赖与结构依赖特征；其次，构建结构-文本对齐适配器（见第 4.4.2节），将图结构表示映射至语言模型的语义空间，实现结构信息与文本语义的有效对齐，使模型能够在生成过程中充分利用隐含的结构信息；最后，采用指令微调策略（见第 4.4.3节），引导模型在融合结构信息与上下文语义的基础上，同时生成预测结果及其对应的推理过程，从而提升模型的推理性能与可解释性。

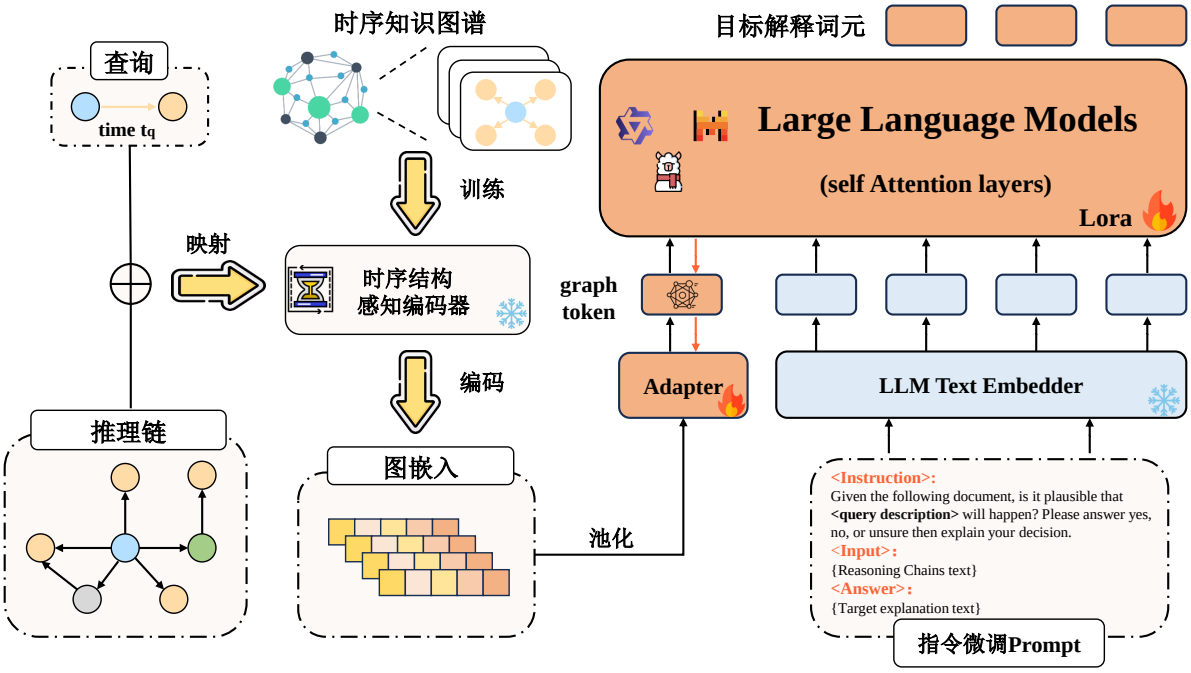


图 4.4 GETER 模型总框架图

4.4.1 时序结构感知编码器

为充分利用大语言模型在语义理解与生成方面的优势，同时弥补其对时序知识图谱结构信息建模能力的不足，首先引入时序结构感知编码器，对图结构信息进行建模。给定时序知识图谱 $\mathcal{G}$，采用时序图编码模型（如 RE-GCN[12]），通过图神经网络的消息传递机制捕捉实体与关系的结构依赖及其时间演化模式，获得如公式 4.7的结构表示：

$$\mathbf{s_n} = TGE(x_n \mid \mathcal{G}) \in \mathbb{R}^{d_s}, \tag{4.7}$$

其中，x_n 表示实体或关系 n 的初始表示，d_s 为结构嵌入的维度，TGE(·) 表示时序图编码器（Temporal Graph Encoder）。在此基础上，可分别得到实体嵌入矩阵 $\mathbf{E} \in \mathbb{R}^{|\mathcal{E}| \times d_s}$ 与关系嵌入矩阵 $\mathbf{R} \in \mathbb{R}^{|\mathcal{R}| \times d_s}$。得到的 $\mathbf{s_n}$ 融合了时序图结构信息，为后续结构表示与大语言模型语义空间的对齐提供了桥梁。

4.4.2 结构-文本对齐适配器

为实现图结构表示与语言模型语义空间的有效融合，构建结构-文本对齐适配器（Adapter），将结构信息以软提示的形式注入大语言模型。具体地，给定查询 $q = (e_s, r, e_o, t)$ 及其对应的推理路径 $\mathcal{C}(e_s, e_o)$，基于结构嵌入通过无参数的消息传递方式对查询及推理路径进行聚合，得到图结构表示；随后，通过可训练的投影矩阵 $\mathbf{W}_p \in \mathbb{R}^{3d_s \times d_x}$ 将其

映射至语言模型的嵌入空间，具体操作见公式 4.8和公式 4.9：

$$\mathbf{S}_{C(e_s,e_o)} = \sum_{(e'_s,r',e'_o)\in C(e_s,e_o)} (\mathbf{e}'_\mathbf{s} \| \mathbf{r}' \| \mathbf{e}'_\mathbf{o}), \tag{4.8}$$

$$\mathbf{S}_{graph} = \mathbf{W}_p \cdot \frac{\mathbf{S}_{C(e_s,e_o)} + \mathbf{S}_q}{|C(e_s,e_o)| + 1}, \tag{4.9}$$

其中，$\|$ 表示向量拼接操作，$\mathbf{S}_q = (\mathbf{e_s} \| \mathbf{r} \| \mathbf{e_o})$，$\mathbf{S}_{graph}$ 表示映射后的图结构表示，d_x 为语言模型嵌入空间的维度。该线性映射方式能够有效实现结构信息与文本语义的对齐，已在相关研究中得到验证[87–89]。该跨模态对齐机制有效弥合了图结构表示与语言模型语义空间之间的差异，以提升模型对结构信息的感知能力。

4.4.3 基于指令微调的可解释推理优化

在实现融合结构信息与文本语义后，通过指令微调策略对模型进行优化，使其适应可解释时序推理任务。具体地，将查询文本 Q 与推理路径文本 $C(e_s,e_o)$ 作为输入，得到对应的文本表示 $X = X_Q + X_C$。设 $\boldsymbol{X} \in \mathbb{R}^{|X|\times d_x}$ 为输入文本的嵌入表示，其中 $|X|$ 为序列长度。在此基础上，将结构表示 $\mathbf{S}_{graph}$ 作为软提示与文本表示进行拼接，构造最终输入，如公式 4.10所示：

$$\boldsymbol{X}' = \mathbf{S}_{graph} \| \boldsymbol{X}, \tag{4.10}$$

其中，$\|$ 表示向量拼接操作。进一步地，模型的训练目标为最大化目标解释文本 $Y_{\mathcal{A}}$ 的生成概率，如公式 4.11所示：

$$P(\boldsymbol{Y}_{\mathcal{A}} \mid \boldsymbol{X}', \boldsymbol{X}_{\mathcal{I}}) = \prod_{j=1}^{L} P_\theta\left(y_j \mid \boldsymbol{X}', \boldsymbol{X}_{\mathcal{I}}, \boldsymbol{Y}_{<j}\right), \tag{4.11}$$

其中，$\boldsymbol{X}_{\mathcal{I}}$ 表示指令部分的嵌入表示，L 为目标文本长度，$\boldsymbol{Y}_{<j}$ 表示已生成的前缀序列。基于上述生成建模方式，模型训练采用标准的负对数似然作为优化目标，对模型进行监督微调，其损失函数定义如公式 4.12所示：

$$\mathcal{L}_{\text{SFT}} = -\sum_{j=1}^{L} \log P_\theta\left(y_j \mid \boldsymbol{X}', \boldsymbol{X}_{\mathcal{I}}, \boldsymbol{Y}_{<j}\right). \tag{4.12}$$

考虑到对大语言模型进行全参数微调的计算开销较高，采用低秩适配（LoRA）方法[59]进行参数高效微调，在保持模型性能的同时显著降低训练成本。基于上述构建，模型能够在参数高效的条件下，有效融合结构信息与文本语义，实现对预测结果及其推理过程的统一建模与生成。

4.5 实验与分析

本节通过多数据集对比实验及评价指标验证所提方法 GETER 的有效性，并结合消融实验与多维度分析（包括模型泛化性、鲁棒性及训练策略），全面评估模型的性能与稳定性，同时通过案例分析进一步展示其推理过程的可解释性。

4.5.1 实验数据集与评测指标

为全面评估所提出模型 GETER 的性能，选取了 ETR 基准中包含的 ICEWS14、ICEWS18、ICEWS05-15、GDELT 以及 WIKI 五个时序知识图谱数据集。如表 4.1所示，这些数据集覆盖了新闻事件、国际关系及结构化知识三种应用场景，能够从不同时间跨度与数据分布角度，系统评估模型可解释推理能力。在评测指标方面，从**预测性能**与**解释质量**两个维度对模型进行综合评估，即分别对应预测任务与解释生成任务。预测任务评估给定四元组的成立性，采用精确率（Precision）、召回率（Recall）及 F1 值作为评价指标，衡量模型对目标事实的判别能力。具体地，考虑到预测任务为三分类问题，分别计算各类别的精确率与召回率，并据此得到对应的 F1 值，最终对各类别的 F1 值进行加权平均以获得整体性能指标。解释生成任务采用 BLEU[90]（4-gram）、ROUGE[91]（ROUGE-L）、METEOR[92] 以及 BertScore[93]四项指标，衡量模型生成解释与真实解释之间的语义一致性与文本相似度，从而综合评估模型的可解释推理能力。

4.5.2 基线方法

（1）基于嵌入的方法

选取当前主流的基于图表示学习的时序知识图谱嵌入方法，包括 RE-GCN[12] 、CEN[94]、CENET[29] 以及 SiMFy[28]。针对可解释时序推理任务，对于给定查询四元组 (e_s, r, e_o, t_q)，采用多层感知机（MLP）对实体与关系的嵌入表示进行适配，其形式如公式 4.13所示：

$$P = \mathbf{W}_{\text{query}}(e_s \parallel r \parallel e_o), \tag{4.13}$$

其中，$\parallel$ 表示向量拼接操作，$P \in \mathbb{R}^3$ 表示预测结果，$e_s, r, e_o \in \mathbb{R}^{1\times d_s}$ 分别为头实体、关系与尾实体的嵌入表示，$\mathbf{W}_{\text{query}} \in \mathbb{R}^{3\times 3d_s}$ 为可学习的参数矩阵，d_s 为嵌入维度。需要指出的是，该类方法仅能够完成预测任务，无法完成解释生成任务。

（2）闭源大语言模型

选取闭源大语言模型 GPT-4o[95] 作为对比方法。该模型具备较强的自然语言理解与生成能力，在零样本（zero-shot）设置下，能够直接基于文本进行推理并生成解释。

（3）开源大语言模型

选取三种具有代表性的开源大语言模型，包括 Llama3-8B-Instruct[96]、Qwen2.5-7B-Instruct[97] 以及 Mistral-7B-Instruct-v0.3[98]。在评估过程中，分别采用零样本与基于 LoRA 的参数高效微调两种设置，分析不同推理范式下模型的性能表现。

4.5.3 实验设置

表 4.3 GETER 实验环境配置

配置项	具体信息
操作系统	Ubuntu 20.04.1 LTS
CPU	Intel Ice Lake Silver 4314
内存	256 GB
GPU	NVIDIA A800 (80GB) × 2
CUDA	11.8
框架	PyTorch

表 4.4 模型训练与推理阶段的主要超参数设置

参数名称	**取值**
LoRA r	16
LoRA α	32
LoRA dropout	0.05
LoRA 作用模块	(q, k, v, o, down, up, gate) projection
最大序列长度	2048
训练轮数（epochs）	3
单卡 batch size	6
梯度累积步数	1
学习率	3×10^{-4}
权重衰减	1×10^{-5}
warmup 比例	0.01
学习率调度策略	cosine
生成序列数量	10
投影层数	1

在模型架构方面，本实验采用开源大语言模型作为基础骨干模型（backbone），包括 Llama3-8B-Instruct、Qwen2.5-7B-Instruct 以及 Mistral-7B-Instruct-v0.3，并选用 RE-GCN 作为时序结构编码器。在数据构建与参数设置方面，时间窗口大小 w 设置为 30，阈值 τ 设置为 0.7，用于构建面向可解释过程的时序知识图谱推理基准 ETR。在模型训练过程中，时序结构编码器 RE-GCN 保持参数冻结，仅对大语言模型部分进行微调。同时，引入低秩适配方法对模型进行参数高效微调。结构嵌入维度 d_s 设置为 512，文本嵌入维度 d_x 保持与所选大语言模型的隐藏层维度一致。为确保实验对比的公平性，所有基于嵌入的基线方法均采用一致的结构嵌入维度，即 $d_s = 512$。在训练与优化方面，采用 DeepSpeed ZeRO Stage 3 [1] 进行分布式训练，以提升模型训练效率。模型训练与评

1 https://github.com/microsoft/Megatron-DeepSpeed

测均在 2 张 NVIDIA A800（80GB）GPU 上进行，具体实验环境如表 4.3。其余训练与推理阶段的具体超参数设置如表 4.4 所示。

4.5.4 主要实验结果

（1）预测任务表现

表 4.5、表4.6、表4.7、表4.8和表4.9分别展示了 GETER 在 ICEWS14、ICEWS18、ICEWS05-15、GDELT 和 WIKI 数据集上的预测任务性能。所有指标均以百分比（%）表示, **粗体**表示最优结果，下划线 表示次优结果，表中“*w/o chains text*”表示未将推理链文本作为 LLMs 的输入。结果表明，GETER 在五个数据集上均取得显著优于现有方法的性能，验证了该方法的有效性与优越性。

表 4.5 GETER 在 ICEWS14 数据上预测任务的性能结果（单位：%）

模型	类别	Positive			Negative			Neutral			整体		
		Precision	Recall	F1	Precision	Recall	F1	Precision	Recall	F1	Precision	Recall	F1
基于嵌入的方法	REGCN	58.02	48.38	52.76	48.89	62.86	55.00	80.11	71.17	75.38	61.29	59.71	59.97
	CENET	70.51	45.12	55.03	53.03	71.29	60.82	75.43	81.33	78.27	66.09	64.19	63.60
	CEN	60.29	62.25	61.25	56.05	50.29	53.01	73.53	79.17	76.24	62.66	63.10	62.79
	SiMFy	68.84	43.63	53.40	53.43	76.86	63.03	79.86	78.00	78.92	66.85	64.52	63.90
GPT-4o	zero-shot *w/o chains text*	41.89	72.62	53.13	24.63	16.86	20.02	23.08	9.00	12.95	30.76	35.86	30.61
	zero-shot	58.53	61.75	60.10	33.05	5.57	9.54	37.08	70.33	48.56	43.91	45.48	39.95
Llama3-8B-Instruct	zero-shot *w/o chains text*	41.94	14.62	21.69	30.23	24.57	27.11	26.20	54.67	35.42	33.54	29.38	27.42
	zero-shot	40.59	93.00	56.51	21.17	6.71	10.20	44.44	3.33	6.20	38.62	35.22	26.70
	LoRA *w/o chains text*	54.16	73.25	62.27	35.28	38.86	36.98	82.59	34.00	48.17	55.99	50.57	49.81
	LoRA	66.08	75.25	70.37	56.75	59.43	58.06	78.73	59.83	67.99	66.59	65.57	65.59
	GETER	71.62	78.87	75.07	66.90	67.86	67.38	88.41	75.00	81.15	74.85	74.10	74.25
Qwen2.5-7B-Instruct	zero-shot *w/o chains text*	41.51	16.50	23.61	32.18	62.71	42.54	17.94	12.50	14.73	31.67	30.76	27.39
	zero-shot	55.79	50.62	53.08	34.79	65.00	45.32	57.58	6.33	11.41	49.30	42.76	38.59
	LoRA *w/o chains text*	66.85	59.25	62.82	51.23	68.43	58.59	83.33	63.33	71.97	66.35	63.48	64.03
	LoRA	74.32	74.88	74.60	61.58	70.29	65.64	83.64	69.00	75.62	72.73	71.67	71.90
	GETER	81.56	71.88	76.41	68.84	81.43	74.61	86.95	82.17	84.49	78.86	78.00	78.12
Mistral-7B-Instruct	zero-shot *w/o chains text*	68.18	1.87	3.65	38.38	40.57	39.44	33.63	75.00	46.44	48.38	35.67	27.81
	zero-shot	55.56	13.75	22.04	27.43	27.86	27.64	30.65	60.83	40.76	39.06	31.90	29.26
	LoRA *w/o chains text*	77.89	46.25	58.04	56.13	78.43	65.44	77.13	83.17	80.03	70.42	67.52	66.79
	LoRA	72.56	73.38	72.96	60.66	73.57	66.49	87.56	64.50	74.28	72.88	70.90	71.18
	GETER	83.62	72.12	**77.45**	69.23	83.57	**75.73**	87.79	82.67	**85.15**	80.02	78.95	**79.08**

具体地，GETER 在不同时间跨度的数据集上均表现出良好的泛化能力。在时间跨度较长的 ICEWS05-15 数据集上，模型仍能保持较优性能，表明其能够有效建模长期时序依赖关系；在高频事件数据集 GDELT 上，尽管任务更加复杂且数据噪声较高，模型依然保持领先，体现出较强的鲁棒性；在结构化程度较高的 WIKI 数据集上，GETER 取得了最优结果，进一步表明其在不同数据分布和任务场景下均具备良好的适应能力。下面从不同模型类别对比角度展开分析：

首先，相较于基于嵌入的方法，GETER 在五个数据集上均取得了显著性能提升。在以 Mistral 作为模型骨干的设置下，相较于各数据集上表现最优的嵌入模型，在 ICEWS14

表 4.6 GETER 在 ICEWS18 数据上预测任务的性能结果（单位：%）

模型	类别	Positive			Negative			Neutral			整体		
		Precision	Recall	F1	Precision	Recall	F1	Precision	Recall	F1	Precision	Recall	F1
基于嵌入的方法	REGCN	59.34	65.20	62.13	62.82	55.29	58.81	80.91	82.15	81.53	67.18	67.14	67.03
	CENET	65.38	58.93	61.99	62.58	66.43	64.45	82.97	86.92	84.90	69.89	70.10	69.90
	CEN	60.60	59.07	59.82	59.38	62.43	60.86	80.25	78.15	79.19	66.28	66.10	66.16
	SiMFy	64.71	57.47	60.88	61.29	64.00	62.61	79.23	85.69	82.34	68.07	68.38	68.10
GPT-4o	zero-shot *w/o chains text*	47.43	56.67	51.64	38.20	35.14	36.61	26.79	23.08	24.79	37.96	39.10	38.32
	zero-shot	53.09	69.87	60.33	34.51	18.14	23.78	38.12	43.69	40.72	42.26	44.52	42.08
Llama3-8B-Instruct	zero-shot *w/o chains text*	25.19	4.53	7.68	31.25	20.00	24.39	27.82	64.92	38.95	28.02	28.38	22.93
	zero-shot	39.37	91.87	55.12	33.09	13.14	18.81	45.83	5.08	9.14	39.28	38.76	28.79
	LoRA *w/o chains text*	57.20	57.73	57.47	39.31	58.86	47.14	90.17	40.92	56.30	61.44	52.90	53.66
	LoRA	75.14	53.20	62.30	49.43	43.43	46.24	55.87	82.00	66.46	60.61	58.86	58.23
	GETER	72.42	79.47	**75.78**	78.87	69.86	74.09	87.06	88.00	**87.53**	79.10	78.90	78.85
Qwen2.5-7B-Instruct	zero-shot *w/o chains text*	43.98	23.87	30.94	34.15	49.86	40.53	24.74	25.54	25.13	34.75	33.05	32.34
	zero-shot	58.01	35.73	44.22	35.55	77.14	48.67	35.29	6.46	10.92	43.49	40.48	35.40
	LoRA *w/o chains text*	72.00	33.60	45.82	45.02	89.14	59.83	92.31	51.69	66.27	69.29	57.71	56.82
	LoRA	69.50	69.87	69.68	52.46	71.57	60.54	84.14	50.62	63.21	64.63	68.35	64.48
	GETER	74.87	74.67	74.77	72.88	76.00	74.41	88.75	84.92	86.79	78.50	78.29	78.37
Mistral-7B-Instruct	zero-shot *w/o chains text*	57.14	0.53	1.06	35.71	32.86	34.23	34.51	76.92	47.64	42.99	34.95	26.53
	zero-shot	69.57	2.13	4.14	35.04	31.29	33.06	30.10	67.23	41.58	45.84	32.00	25.37
	LoRA *w/o chains text*	69.52	49.87	58.07	62.68	49.43	55.27	61.19	95.08	74.46	64.66	63.71	62.21
	LoRA	73.41	57.07	64.22	62.80	66.57	64.63	70.45	84.00	76.63	68.96	68.57	68.20
	GETER	75.36	75.87	75.61	73.98	78.00	**75.94**	90.61	84.62	87.51	79.62	79.29	**79.40**

表 4.7 GETER 在 ICEWS05-15 数据上预测任务的性能结果（单位：%）

模型	类别	Positive			Negative			Neutral			整体		
		Precision	Recall	F1	Precision	Recall	F1	Precision	Recall	F1	Precision	Recall	F1
基于嵌入的方法	REGCN	66.96	63.33	65.10	65.57	61.62	63.53	79.05	88.64	83.57	70.38	70.87	70.50
	CENET	65.27	69.44	67.29	65.30	63.09	64.17	91.05	87.88	89.44	73.54	73.25	73.36
	CEN	67.45	59.58	63.27	61.33	70.44	65.57	88.02	85.76	86.88	72.02	71.55	71.59
	SiMFy	69.03	66.25	67.61	65.45	68.53	66.95	89.35	88.94	89.14	74.36	74.27	74.29
GPT-4o	zero-shot *w/o chains text*	46.72	68.19	55.45	25.52	27.21	26.33	25.70	11.06	15.47	32.99	36.36	33.03
	zero-shot	65.32	58.33	61.63	22.45	8.09	11.89	36.86	65.45	47.16	42.05	44.03	40.58
Llama3-8B-Instruct	zero-shot *w/o chains text*	42.98	6.81	11.75	31.60	26.76	28.98	29.20	60.61	39.41	34.81	30.63	26.30
	zero-shot	41.62	91.11	57.14	25.28	13.38	17.50	44.35	8.33	14.03	37.10	38.93	30.24
	LoRA *w/o chains text*	51.29	91.25	65.67	51.73	30.74	38.56	93.87	53.33	68.02	65.08	59.13	57.47
	LoRA	74.92	68.06	71.32	70.56	40.88	51.77	61.46	94.24	74.40	69.17	67.48	65.86
	GETER	73.37	84.58	78.58	83.84	69.41	75.95	91.00	91.97	**91.48**	82.48	81.94	**81.84**
Qwen2.5-7B-Instruct	zero-shot *w/o chains text*	46.63	24.03	31.71	30.80	54.85	39.45	18.83	13.64	15.82	32.50	30.87	29.17
	zero-shot	60.88	30.69	40.81	33.99	83.53	48.32	23.08	0.91	1.75	39.89	38.59	30.78
	LoRA *w/o chains text*	79.27	42.50	55.33	56.24	88.09	68.65	89.49	82.58	85.89	74.95	70.39	69.52
	LoRA	84.18	55.42	66.83	62.07	82.79	70.95	82.92	85.30	84.09	76.48	74.03	73.72
	GETER	71.68	86.11	78.23	84.36	64.26	72.95	88.77	91.06	89.90	81.34	80.49	80.23
Mistral-7B-Instruct	zero-shot *w/o chains text*	61.70	4.03	7.56	34.78	31.76	33.21	33.98	71.67	46.10	43.93	34.85	28.37
	zero-shot	59.52	10.42	17.73	35.97	25.44	29.80	36.13	79.55	49.69	44.25	37.52	31.96
	LoRA *w/o chains text*	66.30	75.97	70.81	77.39	26.18	39.12	62.79	95.61	75.80	68.84	65.83	61.95
	LoRA	77.44	68.19	72.53	68.77	75.44	71.95	82.94	85.45	84.18	76.34	76.12	76.07
	GETER	75.67	82.50	**78.94**	82.85	71.03	**76.48**	88.29	92.58	90.38	82.08	81.94	81.80

表 4.8 GETER 在 GDELT 数据上预测任务的性能结果（单位：%）

模型	类别	Positive			Negative			Neutral			整体		
		Precision	Recall	F1	Precision	Recall	F1	Precision	Recall	F1	Precision	Recall	F1
基于嵌入的方法	REGCN	61.93	53.87	57.62	55.61	63.71	59.39	84.05	84.31	84.18	66.56	66.28	66.22
	CENET	65.58	57.63	61.34	59.39	66.43	62.71	87.05	88.92	87.98	70.05	69.95	69.84
	CEN	64.80	56.37	60.29	57.21	66.29	61.42	87.40	86.46	86.93	69.16	68.70	68.71
	SiMFy	63.11	63.50	63.30	60.39	61.43	60.91	89.42	87.08	88.23	70.18	69.95	70.06
GPT-4o	zero-shot *w/o chains text*	44.70	12.12	19.08	32.97	65.14	43.78	27.82	23.54	25.50	35.78	32.84	29.06
	zero-shot	49.67	37.50	42.74	32.48	43.43	37.16	30.16	28.31	29.21	38.18	36.65	36.83
Llama3-8B-Instruct	zero-shot *w/o chains text*	38.10	1.00	1.95	31.80	34.57	33.13	29.09	61.23	39.44	33.32	30.14	23.44
	zero-shot	41.04	76.75	53.48	26.92	11.00	15.62	40.76	23.08	29.47	36.36	39.12	33.90
	LoRA *w/o chains text*	97.75	45.33	61.94	3.86	52.94	7.19	54.46	94.65	69.14	54.09	62.72	46.29
	LoRA	81.87	51.01	62.86	19.14	56.30	28.57	77.23	79.94	78.56	60.05	61.48	56.44
	GETER	75.49	53.50	62.62	59.10	82.14	68.74	91.64	86.00	**88.73**	75.03	72.65	72.51
Qwen2.5-7B-Instruct	zero-shot *w/o chains text*	34.18	6.75	11.27	32.27	73.86	44.92	26.41	15.85	19.81	31.21	31.35	24.81
	zero-shot	57.89	13.75	22.22	32.77	91.29	48.23	40.00	0.62	1.21	44.30	35.02	24.34
	LoRA *w/o chains text*	22.88	49.46	31.28	90.71	36.56	52.11	6.62	100.00	12.41	40.05	60.54	32.36
	LoRA	13.13	76.09	22.39	92.71	40.74	56.61	54.92	85.20	66.79	51.67	67.33	46.95
	GETER	75.64	55.13	**63.77**	61.40	81.57	**70.06**	89.32	87.54	88.42	75.14	73.53	**73.27**
Mistral-7B-Instruct	zero-shot *w/o chains text*	34.29	3.00	5.52	30.40	61.29	40.64	23.17	23.85	23.50	29.66	28.28	22.39
	zero-shot	44.44	0.50	0.99	34.34	19.57	24.93	29.68	79.54	43.23	36.69	30.60	21.55
	LoRA *w/o chains text*	11.00	83.81	19.45	97.71	41.40	58.16	57.38	94.91	71.52	53.26	73.36	47.80
	LoRA	64.88	56.78	60.56	55.29	54.89	55.09	73.85	90.40	81.29	64.47	66.33	65.05
	GETER	76.21	51.25	61.29	58.15	84.57	68.92	92.76	84.77	88.59	75.33	72.23	72.02

表 4.9 GETER 在 WIKI 数据上预测任务的性能结果（单位：%）

模型	类别	Positive			Negative			Neutral			整体		
		Precision	Recall	F1	Precision	Recall	F1	Precision	Recall	F1	Precision	Recall	F1
基于嵌入的方法	REGCN	81.76	69.74	75.27	72.32	68.53	70.38	70.94	85.76	77.65	75.31	74.71	74.59
	CENET	77.95	74.35	76.11	77.19	76.92	77.06	81.38	85.76	83.51	78.86	78.93	78.86
	CEN	77.50	71.47	74.36	78.44	73.78	76.04	77.22	87.97	82.25	77.69	77.66	77.49
	SiMFy	78.25	79.83	79.03	82.03	73.43	77.39	78.76	84.49	81.53	79.56	79.45	79.40
GPT-4o	zero-shot *w/o chains text*	66.93	72.33	69.53	40.85	77.27	53.45	93.94	9.81	17.77	68.07	53.00	47.45
	zero-shot	52.51	75.50	61.94	33.80	41.96	37.44	88.42	26.58	40.88	58.83	49.10	47.54
Llama3-8B-Instruct	zero-shot *w/o chains text*	68.98	37.18	48.31	51.74	57.34	54.39	47.19	66.46	66.46	56.53	53.00	52.44
	zero-shot	39.23	76.08	51.76	27.01	25.87	26.43	100.00	0.63	1.26	55.78	35.83	27.31
	LoRA *w/o chains text*	91.35	77.89	84.08	67.83	73.76	70.67	78.48	88.89	83.36	79.98	80.31	79.80
	LoRA	96.25	82.06	88.59	70.98	75.75	73.29	75.95	87.59	81.36	81.88	82.00	81.57
	GETER	99.13	98.85	98.99	85.89	95.80	90.58	96.13	86.39	91.00	94.14	93.78	93.79
Qwen2.5-7B-Instruct	zero-shot *w/o chains text*	52.44	37.18	43.51	37.83	90.21	53.31	61.90	4.11	7.72	51.19	42.15	34.54
	zero-shot	73.29	34.01	46.46	32.69	89.16	47.84	50.00	1.27	2.47	53.30	39.73	32.23
	LoRA *w/o chains text*	91.93	82.86	87.16	76.22	84.82	80.29	85.76	88.27	87.00	85.14	85.25	85.04
	LoRA	83.29	94.75	88.65	85.31	72.84	78.58	86.39	88.35	87.36	84.93	86.02	85.19
	GETER	95.30	99.42	97.32	96.28	90.56	93.33	93.71	94.30	94.01	95.07	95.05	95.02
Mistral-7B-Instruct	zero-shot *w/o chains text*	73.87	23.63	35.81	54.85	45.45	49.71	42.26	80.38	55.40	57.62	49.10	46.52
	zero-shot	75.20	54.18	62.98	38.95	51.75	44.44	41.69	42.09	41.89	53.12	49.42	50.37
	LoRA *w/o chains text*	86.17	83.75	84.94	72.38	84.15	77.82	87.03	79.48	83.08	82.30	82.45	82.18
	LoRA	93.66	85.30	89.29	82.52	91.12	86.61	86.08	88.03	87.04	87.78	87.96	87.73
	GETER	98.86	99.71	**99.28**	99.61	89.86	**94.49**	92.67	100.00	**96.19**	97.02	96.84	**96.81**

数据集上提升了 15.18%，在 ICEWS05-15 数据集上提升了 7.51%，在 ICEWS18 数据集上提升了 9.50%，在 GDELT 数据集上提升了 1.96%，在 WIKI 数据集上提升了 17.41%。这一结果表明，传统基于嵌入的方法缺乏对语义信息的显式建模能力，在复杂时序依赖关系建模方面存在一定局限。相比之下，GETER 基于大语言模型的生成式框架，融合结构信息与语义信息，在预测任务中实现更准确且鲁棒的预测性能。

其次，相较于闭源大语言模型 GPT-4o，GETER 同样在五个数据集上均取得了显著性能提升。在 ICEWS14、ICEWS05-15、ICEWS18、GDELT 和 WIKI 数据集上，GETER 分别提升了 39.13%、35.73%、37.32%、29.94% 和 54.73%。上述结果表明，仅依赖大语言模型的语义理解与生成能力，难以有效捕捉时序知识图谱中的结构信息与复杂演化模式；相比之下，GETER 通过引入结构约束建模与结构—语义对齐机制，在保留语言理解能力的同时增强结构感知与推理能力，从而在复杂时序推理任务中取得显著性能提升。

最后，相较于开源大语言模型，GETER 同样展现出稳定且显著的性能优势。在 zero-shot 设置下，各模型整体性能较低，而通过 LoRA 微调后虽有所提升，但仍明显落后于 GETER。在 ICEWS14 数据集上，相较于对应 backbone 的 LoRA 微调方法，GETER 分别在 Llama3-8B-Instruct、Qwen2.5-7B-Instruct 和 Mistral-7B-Instruct 上提升了 8.66%、7.18% 和 7.90%。上述结果表明，参数高效微调能够在一定程度上提升大语言模型的任务适应能力，但由于缺乏对时序结构信息的显式建模，性能增益有限；相比之下，GETER 通过引入结构与语义的协同建模，能够更有效地刻画复杂时序依赖关系，从而实现更优的推理性能。

综上所述，GETER 在不同模型类别设置下均表现出稳定的性能优势，并在多样化数据场景中取得显著提升。实验结果表明，该方法在复杂时序依赖建模与结构信息利用方面具有明显优势，进一步验证了结构感知生成式建模在提升时序知识图谱推理准确性与可解释性方面的有效性。

（2）解释生成任务表现

表 4.10和表 4.11展示了 GETER 在解释生成任务上的性能表现。实验结果表明，GETER 在五个数据集上均优于现有方法，且在保证预测性能的同时能够生成更加准确且语义一致的推理解释文本。

相较于闭源大语言模型 GPT-4o，GETER 在解释生成质量上展现出显著优势。GPT-4o 在 zero-shot 设置下整体表现较弱，尤其在 BLEU-4 与 ROUGE-L 指标上，难以准确捕捉真实解释中的词汇与结构信息；相比之下，GETER 在各项评价指标上均取得明显提升。该结果表明，在结构信息约束的基础上引入指令微调，能够使模型更好地适应任务，显式学习查询与推理链之间的关联模式，从而有效提升解释生成的表达能力与语义一致性。

表 4.10 GETER 在 ICEWS14, GDELT 以及 ICEWS05-15 数据上解释生成任务的性能结果（单位：%）

模型	数据集 / Types	ICEWS14				GDELT				ICEWS05-15			
		BLEU-4	rougeL	METEOR	BertScore (F1)	BLEU-4	rougeL	METEOR	BertScore (F1)	BLEU-4	rougeL	METEOR	BertScore (F1)
GPT-4o	zero-shot *w/o chains text*	10.78	23.82	31.14	68.16	5.95	21.30	26.84	64.73	10.74	23.63	30.94	68.00
	zero-shot	22.94	41.04	37.24	79.25	9.16	27.61	32.32	70.91	22.64	40.83	36.27	79.16
Llama3-8B-Instruct	zero-shot *w/o chains text*	4.35	16.32	16.71	61.35	2.38	13.41	17.03	56.98	2.27	12.88	10.53	58.28
	zero-shot	9.70	30.19	26.60	70.25	5.61	27.10	25.73	67.42	10.08	31.13	27.44	70.02
	LoRA *w/o chains text*	27.73	39.71	45.94	80.16	18.12	37.05	35.92	77.51	27.59	39.63	45.80	80.17
	LoRA	39.21	50.96	**54.03**	84.28	34.32	54.84	51.49	**83.75**	42.98	54.50	56.65	85.45
	GETER	**40.54**	**52.54**	53.87	**84.75**	**34.46**	**55.42**	**51.75**	83.62	**45.98**	**57.27**	**58.16**	**86.39**
Qwen2.5-7B-Instruct	zero-shot *w/o chains text*	7.43	19.73	30.82	66.03	3.76	17.90	28.25	63.15	7.81	19.87	30.27	65.94
	zero-shot	11.18	28.49	27.98	72.28	7.55	26.90	25.97	70.00	10.53	28.53	26.32	72.04
	LoRA *w/o chains text*	28.17	40.22	45.20	80.12	17.15	36.89	34.52	75.71	28.60	40.52	45.76	80.39
	LoRA	39.59	**51.48**	53.30	84.35	26.10	47.30	43.85	79.93	43.55	55.01	56.22	85.62
	GETER	**39.78**	51.46	**55.03**	**84.53**	**33.81**	**54.76**	**50.18**	**83.59**	**44.72**	**56.17**	**57.22**	**86.01**
Mistral-7B-Instruct	zero-shot *w/o chains text*	7.17	19.40	24.27	65.46	4.89	18.20	25.78	63.60	7.24	19.29	23.26	65.10
	zero-shot	9.19	28.36	25.70	71.63	7.46	27.96	25.99	70.43	7.95	27.40	23.60	70.73
	LoRA *w/o chains text*	28.01	39.84	45.70	80.34	18.22	38.08	35.74	76.76	28.26	40.13	45.96	80.45
	LoRA	38.81	50.81	52.62	84.02	30.93	52.24	47.28	82.28	43.03	54.56	55.94	85.47
	GETER	**40.21**	**51.84**	**54.90**	**84.65**	**32.18**	**53.27**	**49.06**	**82.83**	**45.07**	**56.48**	**57.70**	**86.13**

表 4.11 GETER 在 ICEWS18 和 WIKI 数据上解释生成任务的性能结果（单位：%）

模型	数据集 / Types	ICEWS18				WIKI			
		BLEU-4	rougeL	METEOR	BertScore (F1)	BLEU-4	rougeL	METEOR	BertScore (F1)
GPT-4o	zero-shot *w/o chains text*	9.33	22.67	29.87	67.48	13.25	28.18	36.65	69.10
	zero-shot	14.84	31.16	37.47	72.98	25.98	41.77	45.52	78.69
Llama3-8B-Instruct	zero-shot *w/o chains text*	4.10	15.85	16.20	61.14	9.39	25.41	27.95	66.88
	zero-shot	10.01	29.52	27.19	70.01	14.67	36.67	33.43	75.85
	LoRA *w/o chains text*	23.55	35.95	42.54	78.02	48.99	63.53	63.08	87.13
	LoRA	37.33	49.18	53.05	83.58	52.09	65.27	66.67	87.99
	GETER	**40.39**	**52.12**	**54.85**	**84.60**	**55.52**	**68.06**	**69.16**	**88.77**
Qwen2.5-7B-Instruct	zero-shot *w/o chains text*	7.02	19.52	30.09	65.92	7.33	21.46	34.56	66.38
	zero-shot	10.46	27.97	26.80	71.77	20.21	36.19	41.52	77.61
	LoRA *w/o chains text*	25.50	37.61	42.91	78.56	51.84	65.09	65.59	87.79
	LoRA	37.49	49.61	52.07	83.60	53.57	67.19	67.23	88.59
	GETER	**38.99**	**50.70**	**53.79**	**84.17**	**55.00**	**67.49**	**70.00**	**88.99**
Mistral-7B-Instruct	zero-shot *w/o chains text*	7.60	19.43	23.98	65.87	11.41	26.23	31.64	67.79
	zero-shot	9.74	29.00	26.00	71.95	21.25	40.05	41.43	77.27
	LoRA *w/o chains text*	25.46	37.62	42.91	78.67	51.58	66.32	65.29	87.96
	LoRA	36.96	49.12	51.70	83.38	52.61	65.40	66.80	87.97
	GETER	**39.64**	**51.62**	**54.04**	**84.37**	**54.96**	**67.74**	**69.17**	**88.92**

相较于开源大语言模型，GETER 同样展现出稳定且显著的性能优势。实验结果表明，在 zero-shot 设置下，各模型的解释生成质量普遍较低；通过 LoRA 微调后虽有所提升，但整体仍明显落后于 GETER。例如，在 ICEWS14、ICEWS18 及 WIKI 数据集上，LoRA 方法在部分语义相关指标（如 METEOR、BertScore）上取得一定改进，但在 BLEU-4 与 ROUGE-L 等指标上仍存在明显差距。相比之下，GETER 通过在结构约束引导下进行指令微调，能够有效利用图结构信息完成可解释推理。在 BLEU-4 和 ROUGE-L 指标上的提升表明 GETER 生成结果在词汇匹配与句法结构上更贴近真

实解释；METEOR 和 BertScore 的优势则体现其在语义一致性与表达能力方面的提升。尽管个别指标提升幅度相对有限，整体结果仍表明 GETER 在解释生成质量上具备更稳定且全面的优势。综上所述，GETER 通过融合时序结构信息与语义表示，在提升预测性能的同时显著增强解释生成的准确性与一致性，验证了结构感知生成式建模在可解释时序知识图谱推理任务中的有效性与优越性。

4.5.5 消融实验

为分析各组成模块对模型整体性能的影响，在 ICEWS14、GDELT 和 ICEWS05-15 三个数据集上开展了消融实验，实验结果如表 4.12 所示，采用整体 F1 作为评价指标。表中，“移除结构-文本适配器”表示模型仅依赖文本输入进行推理；“移除推理链文本”表示不引入显式的推理链作为上下文信息；“移除结构适配器与推理链”表示模型仅基于基础指令微调进行推理，不利用结构信息与推理链文本。实验结果表明，移除任一模块均会导致模型性能不同程度下降，说明各组成部分均对模型具有重要作用。

表 4.12 GETER 在不同模块配置下的消融实验结果（单位：%）

编号	模型变体	ICEWS14	GDELT	ICEWS05-15
1	**GETER**	**79.08**	**72.02**	**81.80**
2	移除结构-文本适配器	$71.18_{(\downarrow 7.90)}$	$65.05_{(\downarrow 6.97)}$	$76.07_{(\downarrow 5.73)}$
3	移除推理链文本	$72.05_{(\downarrow 7.03)}$	$68.89_{(\downarrow 3.13)}$	$77.82_{(\downarrow 3.98)}$
4	移除结构适配器与推理链	$66.79_{(\downarrow 12.29)}$	$47.80_{(\downarrow 24.22)}$	$61.95_{(\downarrow 19.85)}$

具体地，当移除结构-文本适配器时（第 2 行），模型在三个数据集上的整体 F1 分别下降了 7.90%、6.97% 和 5.73%，说明结构信息对于建模时序依赖关系具有关键作用；当移除推理链文本时（第 3 行），性能同样出现明显下降，表明显式的推理路径能够为模型提供重要的上下文信息，从而提升推理的准确性。此外，同时移除结构-文本适配器与推理链文本时（第 4 行），模型性能下降最为明显，在 ICEWS14、GDELT 和 ICEWS05-15 数据集上分别下降了 12.29%、24.22% 和 19.85%。该结果表明，结构信息与推理链文本在模型推理过程中具有互补作用，协同建模对于提升时序知识图谱推理性能至关重要。综上所述，消融实验验证了 GETER 中各模块的有效性，说明通过融合结构信息与推理链文本，能够显著提升模型的性能表现。

4.5.6 模型泛化性与鲁棒性分析

（1）不同时序结构编码器的影响分析

为评估不同时序结构感知编码器对模型性能的影响，本节将 RE-GCN、CEN、CENET 以及 SiMFy 分别集成到 GETER 模型中，并在 ICEWS14 和 GDELT 数据集上基于整体

F1 指标进行对比实验。结果如图 4.5 所示。实验结果表明，GETER 在各种编码器上均能够保持稳定且较高的性能表现，并显著优于仅依赖 LoRA 微调的方法。这一结果表明，GETER 的性能提升并不依赖于特定编码器，从而体现出良好的泛化能力。

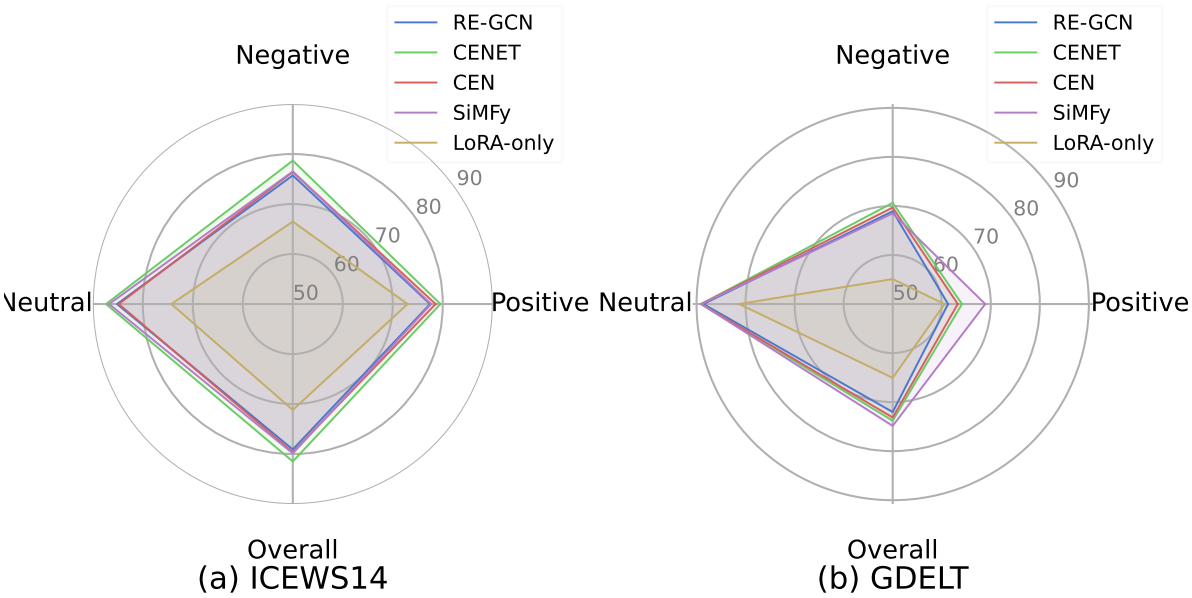


图 4.5 不同编码器下 GETER 在 ICEWS14 与 GDELT 数据集上的性能对比（单位：%）

（2）推理链输入方式的影响分析

本节进一步探讨推理链输入方式对模型性能的影响。具体地，输入方式包括路径排序及基于时间戳的多种排序策略（时间升序、时间降序与随机顺序）。其中，“路径排序”表示按照数据集中的原始构建顺序组织推理链，不进行额外的时间或结构重排。实验结果如表 4.13 所示。结果表明，时间降序排列时模型性能最优，说明近期历史信息对当前决策具有更强的指导作用；在随机顺序设置下，模型仍保持较为稳定的性能表现，说明 GETER 并不过度依赖推理链的显式顺序，而是能够通过结构-文本适配机制有效建模结构信息与语义信息之间的内在关联，从而具备较强的鲁棒性与泛化能力。该结果进一步验证了方法在不同输入组织方式下的稳定性。

表 4.13 不同的推理链输入方式下 GETER 在 ICEWS14 数据集上的性能对比

模型	正样本	负样本	中立样本	整体
路径排序	77.45	75.73	85.15	79.08
时间降序	**80.53**	76.00	**86.34**	**80.68**
时间升序	77.72	**77.52**	86.04	80.03
随机顺序	75.02	76.31	82.45	77.57

4.5.7 训练策略有效性分析

（1）MLP 层数的影响分析

在原始设置中，GETER 采用单层 MLP 将图结构特征映射至大语言模型的语义空间。为分析网络深度的影响，本节将其替换为多层 MLP，并在 ICEWS14 与 GDELT 数据集上开展对比实验。实验结果如图 4.6 所示，随着 MLP 层数的增加，模型性能提升有限，甚至在部分情况下略有下降，表明单层 MLP 已能够有效完成结构表示向语义空间的映射，增加网络深度未带来显著收益。该结果进一步说明，GETER 的性能提升主要来源于结构信息与语义信息的协同建模，而非依赖更复杂的映射结构。

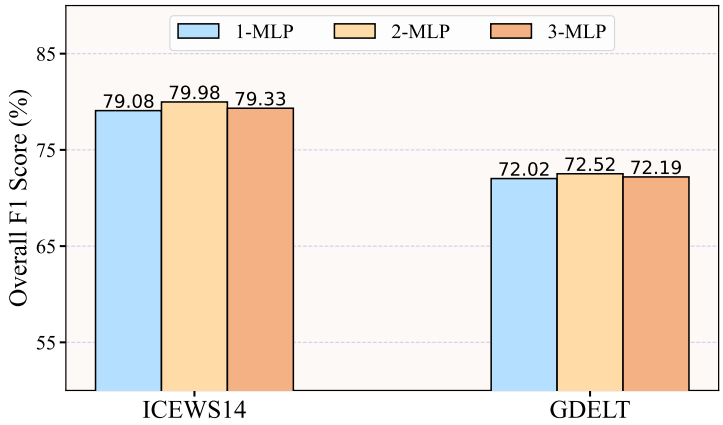


图 4.6 不同 MLP 层数设置下 GETER 在 ICEWS14 与 GDELT 数据集上的性能对比（单位：%）

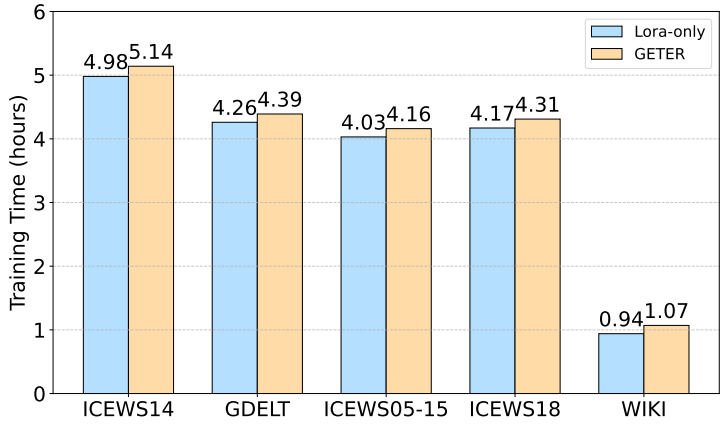


图 4.7 GETER 与 LoRA 微调方法在五个数据集上的训练时间对比（单位：小时）

（2）复杂度与效率分析

大语言模型通常面临较高的计算开销问题。GETER 方法在训练与推理阶段的复杂度为 $O(|L_1|^2 \cdot |L_2|)$，其中 $|L_1|$ 表示输入文本长度，$|L_2|$ 表示输出文本长度。为降低计算成本，采用 LoRA 与 DeepSpeed 对模型进行加速。进一步地，如图 4.7 所示，GETER

相较于标准 LoRA 微调方法仅引入了较小的额外时间开销。结合其在预测性能与解释生成质量上的显著提升，该额外计算成本在实践中是可接受的。

4.5.8 案例分析

本节通过一个具体的案例对比分析，进一步体现 GETER 在可解释时序推理任务中的优势。具体地，基于 Mistral 模型，对比基于 *LoRA* 微调的方法与 GETER 在预测结果与推理过程上的差异。选取如下正样本查询：（澳大利亚警方，开展实质性合作，澳大利亚公民，*2014-11-16*），其真实标签为“Yes”。相关结果如表 4.14 所示。

表 4.14 GETER 与基线方法的案例对比

查询: *Police (Australia) will Engage in material cooperation Citizen (Australia) on 2014-11-16*		
方法	**预测任务输出**	**解释生成任务输出**
LoRA 微调	✗	No. Based on the information provided, it is predicted that Police (Australia) will not engage in material cooperation with Citizen (Australia) on 2014-11-16. This prediction is supported by a series of events leading up to this date, which indicate a pattern of conflict and adversarial interactions between the police and citizens.In the days preceding 2014-11-16, the police have been involved in multiple actions against citizens, including arrests, detentions, and charges on 2014-11-12, 13, and 14..... Despite some expressions of intent to negotiate or meet, the overall pattern of behavior suggests a lack of cooperative engagement. Given this context of ongoing conflict and legal actions, it is reasonable to conclude that material cooperation between the police and citizens is unlikely to occur on 2014-11-16.
GETER	✓	Yes. Based on the sequence of events outlined in the document, it is plausible to predict that the Police in Australia will engage in material cooperation with Australian citizens on November 16, 2014. This prediction is supported by a series of interactions ..... **However, alongside these actions, the police also made several appeals and requests to citizens on the same dates, suggesting a willingness to engage in dialogue or seek assistance. Additionally, the police expressed an intent to meet or negotiate with citizens on multiple occasions, including November 11 and November 14, which implies a shift towards more collaborative engagement.** Despite the confrontational actions, such as the use of force and accusations, the police also demonstrated a capacity for reconciliation by returning or releasing individuals on November 14. This dual approach of enforcement and negotiation, combined with the police's expressed intent to meet and cooperate, supports the likelihood of material cooperation occurring on November 16, 2014.

具体地，基于 *LoRA* 微调的方法虽然能够在一定程度上识别潜在合作信息并建模事件的时间演化关系，但仍难以有效刻画合作行为与对抗行为之间的复杂交互关系（红色标注）。其推理过程主要聚焦于逮捕、指控等对抗行为，从而导致错误的负向预测结果。相比之下，GETER 能够更准确地捕捉事件关系的动态演化过程及其中蕴含的合作信号（绿色标注）。通过识别请求与合作意图等关键结构性线索，GETER 不仅能够给出正确的预测结果，还能够生成与之对应的合理解释，体现了其在可解释时序推理中的优势。

4.6 本章小结

本章针对现有方法在可解释性与推理过程显式刻画方面的不足，提出了一种基于大语言模型的结构感知生成式时序知识图谱推理框架，并从数据构建与方法设计两个层面展开系统研究。在数据层面，构建了面向可解释过程的时序知识图谱推理评测基准 ETR。该基准覆盖新闻事件、国际关系及结构化知识三种典型应用场景，并包含多种时间粒度设置，能够系统评估模型可解释时序推理能力。在方法设计层面，提出结构感知的生成式推理模型 GETER，以缓解大语言模型生成过程中的“幻觉”问题，提升可解释推理结果的可靠性。该模型通过时序结构编码与结构—文本对齐机制实现结构信息与语义信息的有效融合，并结合指令微调策略，在统一生成框架下同时输出预测结果及其推理解释，从而增强推理过程的逻辑一致性与结果的可信性。大量实验结果表明，GETER 在 ETR 基准上取得了优于现有方法的性能，在预测准确性与解释质量两个方面均表现出显著优势。进一步地，消融实验与鲁棒性分析验证了结构信息建模在提升模型可解释推理能力中的关键作用。综上所述，该方法拓展了时序知识图谱推理的研究范式，通过融合时序结构信息增强了大语言模型对复杂时序依赖关系的建模能力，为可解释时序推理提供了新的技术路径。

第 5 章　总结与展望

5.1　全文工作总结

时序知识图谱（Temporal Knowledge Graph, TKG）作为刻画现实世界动态关系的重要工具，通过引入时间维度对实体关系的演化过程进行建模，在事件预测、决策支持等场景中具有重要应用价值。相较于传统静态知识图谱，时序知识图谱不仅需要建模实体与关系之间的结构依赖，还需进一步刻画其随时间变化的动态特征。然而，围绕时序知识图谱推理任务，现有方法多依赖嵌入表示学习框架，通过学习实体与关系的低维表示并设计评分函数完成推理。这类方法通常侧重结构建模，缺乏对语义信息的有效利用，且难以提供可解释的推理过程。随着预训练语言模型与大语言模型的发展，将语言模型引入时序知识图谱推理逐渐成为重要研究方向。语言模型在语义理解与表示方面具有显著优势，为提升模型的泛化能力提供了新的技术路径。然而，现有基于语言模型的方法仍面临关键挑战：语言模型基于序列建模范式，与时序知识图谱的结构化表示存在差异，难以有效建模复杂结构依赖与历史演化规律；进一步地，现有方法在推理可解释性方面仍存在不足，缺乏对推理过程的显式建模，限制了其在实际应用中的可行性。针对上述问题，本文围绕“基于结构增强语言模型的时序知识图谱推理方法”开展系统研究，旨在构建结构增强的语言模型推理框架，通过融合结构信息与语义信息实现统一建模，以提升模型对复杂结构依赖与时间演化规律的建模能力，从而提升推理的准确性与可解释性。具体工作如下：

（1）基于预训练语言模型的结构增强时序知识图谱推理方法

针对预训练语言模型难以有效建模时序知识图谱中复杂结构依赖与历史演化规律的问题，本文提出了一种融合结构信息与历史重现模式的预训练语言模型增强方法。该方法以预训练语言模型为基础，通过融合图结构表示与时间相关历史信息，并显式建模关系重现模式，实现结构信息、语义信息与时间演化规律的协同建模。一方面，通过引入时间感知软提示机制，将图空间中的实体与关系表示映射至语言模型输入空间，从而实现结构嵌入与文本语义的对齐，增强模型对高阶结构依赖的建模能力；另一方面，针对时序知识图谱中的事实重现现象，构建全局历史重现模式建模模块，通过统计历史事实的频次分布刻画时间演化规律，并结合时间窗口与时间加权机制强化近期历史信息，从而提升模型对动态变化的建模能力。在推理阶段，通过融合结构-语义建模结果与历史重现模式建模结果，实现多源信息的协同建模。实验结果表明，所提出方法在多个数据集上均显著优于现有方法，有效提升了推理性能与泛化能力，并验证了结构信息与历史模式建模的有效性。

（2）基于大语言模型的结构感知生成式时序知识图谱推理框架

针对现有方法在推理可解释性方面的不足，本文进一步提出基于大语言模型的结

构感知生成式时序知识图谱推理框架。在数据层面，构建面向可解释过程的时序知识图谱推理评测基准，通过提取与查询相关的历史子图并转化为自然语言形式，实现对预测性能与解释生成能力的统一评估。在方法设计层面，提出结构感知的生成式推理模型。首先，引入时序结构感知编码器对历史结构信息进行建模，学习实体与关系的结构表示，以捕捉图结构中的依赖关系及其时间演化特征；其次，构建结构-文本对齐机制，将结构表示映射至语言模型语义空间，从而构建结构感知输入；最后，通过指令微调策略，将推理任务统一建模为生成式过程，使模型能够同时输出预测结果及其对应的推理解释，从而实现推理过程的显式建模。实验结果表明，所提出方法在构建的评测基准上均优于现有方法，在预测准确性、解释生成质量与推理一致性方面均取得显著提升，并表现出良好的稳定性与泛化能力。

综上所述，本文系统研究了基于结构增强语言模型的时序知识图谱推理方法，从预训练语言模型的结构建模出发，进一步拓展至大语言模型的生成式推理，在推理准确性与可解释性方面均取得显著提升。相关实验结果表明，结构增强语言模型在时序知识图谱推理任务中具有良好的应用潜力，并为复杂结构依赖建模与可解释推理问题提供了新的技术路径。

5.2 未来工作展望

本文围绕基于结构增强语言模型的时序知识图谱推理方法，系统探讨了结构信息与语义信息的融合建模方式，并进行了深入研究与实验验证。尽管本文方法在预测性能与可解释性方面取得了显著提升，但在复杂结构建模、生成式推理可靠性以及实际应用等方面仍存在进一步探索空间。基于此，未来可从以下几个方面开展研究：

（1）探索更高阶的时序结构建模方法：当前方法主要依赖于现有时序图编码器对结构信息进行建模，在多跳推理与长时间跨度依赖关系建模方面仍存在一定局限。未来可进一步探索基于路径级建模、多尺度时间建模以及动态图表示学习等方法，从而更加细粒度地刻画实体关系的动态演化过程，提升模型对复杂时序依赖关系的表达能力。

（2）提升生成式推理的可靠性与可控性：尽管本文通过引入结构信息在一定程度上缓解了大语言模型的幻觉问题，但在复杂推理场景中（如多跳问答），生成结果的真实性与一致性仍难以得到充分保障。未来可结合检索增强生成、外部知识验证机制以及约束解码策略，在生成过程中引入结构约束与事实校验，从而进一步提升推理结果的可靠性与可控性。此外，本文主要以自然语言形式生成推理解释，但在复杂应用场景下，仅依赖文本解释难以全面呈现推理过程。未来可结合推理路径可视化、子图结构展示以及符号规则抽取等方法，构建多模态解释框架，从多个维度增强推理结果的可理解性与可验证性。

（3）拓展实际应用场景与跨领域任务：时序知识图谱推理在生物医学、金融分析及复杂系统建模等领域具有广泛应用潜力。此外，针对真实应用中普遍存在的数据规模大、结构复杂、噪声干扰强及标注稀缺等问题，仍需探索更加鲁棒且具备良好泛化能力的建模方法。通过将语言模型的语义理解能力与时序知识图谱的结构表达能力相结合，有望在复杂实际任务中实现更高效、可靠的时序推理，从而推动相关技术在多领域场景中的落地与应用。

参考文献

[1] 马昂. 知识图谱可解释推理与推荐研究[D]. 北京邮电大学, 2025.

[2] JI S, PAN S, CAMBRIA E, et al. A survey on knowledge graphs: Representation, acquisition, and applications[J]. IEEE transactions on neural networks and learning systems, 2021, 33(2): 494-514.

[3] LAN Y, HE G, JIANG J, et al. Complex knowledge base question answering: A survey [J]. IEEE Transactions on Knowledge and Data Engineering, 2022, 35(11): 11196-11215.

[4] CUI Z, WENG Y, TANG X, et al. Comprehending knowledge graphs with large language models for recommender systems[C]//Proceedings of the 48th international ACM SIGIR conference on research and development in information retrieval. 2025: 1229-1239.

[5] ZHAO X, LIU S, YANG S Y, et al. Medrag: Enhancing retrieval-augmented generation with knowledge graph-elicited reasoning for healthcare copilot[C]//Proceedings of the ACM on Web Conference 2025. 2025: 4442-4457.

[6] CHEN Y, WU F, WANG J, et al. Knowledge-augmented financial market analysis and report generation[C]//Proceedings of the 2024 Conference on Empirical Methods in Natural Language Processing: Industry Track. 2024: 1207-1217.

[7] JIN W, QU M, JIN X, et al. Recurrent event network: Autoregressive structure inferenceover temporal knowledge graphs[C]//Proceedings of the 2020 conference on empirical methods in natural language processing (EMNLP). 2020: 6669-6683.

[8] 肖蕾, 李琪. 时序知识图谱补全方法研究综述[J]. 计算机工程与应用, 2024, 60(06): 43-54.

[9] GARCÍA-DURÁN A, DUMANČIĆ S, NIEPERT M. Learning sequence encoders for temporal knowledge graph completion[C]//Proceedings of the 2018 conference on empirical methods in natural language processing. 2018: 4816-4821.

[10] 王俞涵, 陈子阳, 赵翔, 等. 时序知识图谱表示与推理的研究进展与趋势[J]. 软件学报, 2024, 35(08): 3923-3951.

[11] LI Z, GUAN S, JIN X, et al. Complex evolutional pattern learning for temporal knowl-

edge graph reasoning[C]//Proceedings of the 60th annual meeting of the association for computational linguistics (volume 2: short papers). 2022: 290-296.

[12] LI Z, JIN X, LI W, et al. Temporal knowledge graph reasoning based on evolutional representation learning[C]//Proceedings of the 44th international ACM SIGIR conference on research and development in information retrieval. 2021: 408-417.

[13] DEVLIN J, CHANG M W, LEE K, et al. Bert: Pre-training of deep bidirectional transformers for language understanding[C]//Proceedings of the 2019 conference of the North American chapter of the association for computational linguistics: human language technologies, volume 1 (long and short papers). 2019: 4171-4186.

[14] ACHIAM J, ADLER S, AGARWAL S, et al. Gpt-4 technical report[J]. CoRR, 2023, abs/2303.08774.

[15] DEEPSEEK-AI. Deepseek-v3 technical report[J]. CoRR, 2024, abs/2412.19437.

[16] PAN S, LUO L, WANG Y, et al. Unifying large language models and knowledge graphs: A roadmap[J]. IEEE Transactions on Knowledge and Data Engineering, 2024, 36(7): 3580-3599.

[17] LIANG K, MENG L, LIU M, et al. A survey of knowledge graph reasoning on graph types: Static, dynamic, and multi-modal[J]. IEEE Transactions on Pattern Analysis and Machine Intelligence, 2024: 1-20.

[18] HUANG L, YU W, MA W, et al. A survey on hallucination in large language models: Principles, taxonomy, challenges, and open questions[J]. ACM Transactions on Information Systems, 2025, 43(2): 1-55.

[19] SAHOO P, MEHARIA P, GHOSH A, et al. A comprehensive survey of hallucination in large language, image, video and audio foundation models[J]. Findings of the Association for Computational Linguistics: EMNLP 2024, 2024: 11709-11724.

[20] BORDES A, USUNIER N, GARCIA-DURAN A, et al. Translating embeddings for modeling multi-relational data[J]. Advances in neural information processing systems, 2013, 26.

[21] DASGUPTA S S, RAY S N, TALUKDAR P. Hyte: Hyperplane-based temporally aware knowledge graph embedding[C]//Proceedings of the 2018 conference on empiri-

cal methods in natural language processing. 2018: 2001-2011.

[22] GARCÍA-DURÁN A, DUMANČIĆ S, NIEPERT M. Learning sequence encoders for temporal knowledge graph completion[C]//Proceedings of the 2018 conference on empirical methods in natural language processing. 2018: 4816-4821.

[23] LACROIX T, OBOZINSKI G, USUNIER N. Tensor decompositions for temporal knowledge base completion[C]//ICLR. OpenReview.net, 2020.

[24] SCHLICHTKRULL M S, KIPF T N, BLOEM P, et al. Modeling relational data with graph convolutional networks[C]//ESWC. 2018: 593-607.

[25] ZHANG M, XIA Y, LIU Q, et al. Learning long-and short-term representations for temporal knowledge graph reasoning[C]//Proceedings of the ACM Web Conference 2023. 2023: 2412-2422.

[26] ZHANG M, XIA Y, LIU Q, et al. Learning latent relations for temporal knowledge graph reasoning[C]//Proceedings of the 61st Annual Meeting of the Association for Computational Linguistics (Volume 1: Long Papers). 2023: 12617-12631.

[27] ZHU C, CHEN M, FAN C, et al. Learning from history: Modeling temporal knowledge graphs with sequential copy-generation networks[C]//Proc. of AAAI. 2021: 4732-4740.

[28] LIU Z, TAN L, LI M, et al. Simfy: A simple yet effective approach for temporal knowledge graph reasoning[C]//Findings of the Association for Computational Linguistics: EMNLP 2023. 2023: 3825-3836.

[29] XU Y, OU J, XU H, et al. Temporal knowledge graph reasoning with historical contrastive learning[C]//Proceedings of the AAAI conference on artificial intelligence: Vol. 37. 2023: 4765-4773.

[30] HAN Z, CHEN P, MA Y, et al. Explainable subgraph reasoning for forecasting on temporal knowledge graphs[C]//International conference on learning representations. 2020.

[31] LIU Y, MA Y, HILDEBRANDT M, et al. Tlogic: Temporal logical rules for explainable link forecasting on temporal knowledge graphs[C]//Proc. of AAAI. 2022: 4120-4127.

[32] XU W, LIU B, PENG M, et al. Pre-trained language model with prompts for temporal knowledge graph completion[C]//Findings of the association for computational linguistics: ACL 2023. 2023: 7790-7803.

[33] PENG M, LIU B, XU W, et al. Deja vu: Contrastive historical modeling with prefix-tuning for temporal knowledge graph reasoning[C]//Findings of the Association for Computational Linguistics: NAACL 2024. 2024: 1178-1191.

[34] ZHANG Y, QIAN X, ZHAO Y, et al. Bring invariant to variant: A contrastive prompt-based framework for temporal knowledge graph forecasting[C]//Proceedings of the 2024 Joint International Conference on Computational Linguistics, Language Resources and Evaluation (LREC-COLING 2024). 2024: 2526-2536.

[35] LEE D H, AHRABIAN K, JIN W, et al. Temporal knowledge graph forecasting without knowledge using in-context learning[C]//Proceedings of the 2023 conference on empirical methods in natural language processing. 2023: 544-557.

[36] XIA Y, WANG D, LIU Q, et al. Chain-of-history reasoning for temporal knowledge graph forecasting[C]//Findings of the Association for Computational Linguistics: ACL 2024. Bangkok, Thailand: Association for Computational Linguistics, 2024: 16144-16159.

[37] YUAN C, XIE Q, HUANG J, et al. Back to the future: Towards explainable temporal reasoning with large language models[C]//Proceedings of the ACM on Web Conference 2024. 2024: 1963-1974.

[38] LIAO R, JIA X, LI Y, et al. Gentkg: Generative forecasting on temporal knowledge graph with large language models[C]//Findings of the association for computational linguistics: NAACL 2024. 2024: 4303-4317.

[39] WANG J, SUN K, LUO L, et al. Large language models-guided dynamic adaptation for temporal knowledge graph reasoning[J]. Advances in Neural Information Processing Systems, 2024, 37: 8384-8410.

[40] CHEN Z, LIAO J, ZHAO X. Multi-granularity temporal question answering over knowledge graphs[C]//Proceedings of the 61st Annual Meeting of the Association for Computational Linguistics (Volume 1: Long Papers). 2023: 11378-11392.

[41] MAVROMATIS C, SUBRAMANYAM P L, IOANNIDIS V N, et al. Tempoqr: temporal question reasoning over knowledge graphs[C]//Proceedings of the AAAI conference on artificial intelligence: Vol. 36. 2022: 5825-5833.

[42] CHEN Z, LI D, ZHAO X, et al. Temporal knowledge question answering via abstract reasoning induction[C]//Proceedings of the 62nd Annual Meeting of the Association for Computational Linguistics (Volume 1: Long Papers). 2024: 4872-4889.

[43] QIANYIHU Q, TU X, CONG G, et al. Time-aware react agent for temporal knowledge graph question answering[C]//Findings of the Association for Computational Linguistics: NAACL 2025. 2025: 6013-6024.

[44] QIAN X, ZHANG Y, ZHAO Y, et al. Timer4: Time-aware retrieval-augmented large language models for temporal knowledge graph question answering[C]//Proceedings of the 2024 conference on empirical methods in natural language processing. 2024: 6942-6952.

[45] GONG Z, LI J, LIU Z, et al. RTQA : Recursive thinking for complex temporal knowledge graph question answering with large language models[C]//Proceedings of the 2025 Conference on Empirical Methods in Natural Language Processing. Suzhou, China: Association for Computational Linguistics, 2025: 9853-9870.

[46] LACROIX T, USUNIER N, OBOZINSKI G. Canonical tensor decomposition for knowledge base completion[C]//International conference on machine learning. PMLR, 2018: 2863-2872.

[47] BALAŽEVIĆ I, ALLEN C, HOSPEDALES T. Tucker: Tensor factorization for knowledge graph completion[C]//Proceedings of the 2019 conference on empirical methods in natural language processing and the 9th international joint conference on natural language processing (EMNLP-IJCNLP). 2019: 5185-5194.

[48] MA Y, TRESP V, DAXBERGER E A. Embedding models for episodic knowledge graphs[J]. Journal of Web Semantics, 2019, 59: 100490.

[49] NICKEL M, TRESP V, KRIEGEL H P, et al. A three-way model for collective learning on multi-relational data.[C]//Icml: Vol. 11. 2011: 3104482-3104584.

[50] KIPF T N, WELLING M. Semi-supervised classification with graph convolutional networks[C]//ICLR (Poster). OpenReview.net, 2017.

[51] XU K, HU W, LESKOVEC J, et al. How powerful are graph neural networks?[C]// ICLR. OpenReview.net, 2019.

[52] DEVLIN J, CHANG M W, LEE K, et al. Bert: Pre-training of deep bidirectional transformers for language understanding[C]//Proceedings of the 2019 conference of the North American chapter of the association for computational linguistics: human language technologies, volume 1 (long and short papers). 2019: 4171-4186.

[53] HAN Z, LIAO R, GU J, et al. Ecola: enhancing temporal knowledge embeddings with contextualized language representations[C]//Findings of the Association for Computational Linguistics: ACL 2023. 2023: 5433-5447.

[54] LESTER B, AL-RFOU R, CONSTANT N. The power of scale for parameter-efficient prompt tuning[C]//Proceedings of the 2021 conference on empirical methods in natural language processing. 2021: 3045-3059.

[55] LIU X, JI K, FU Y, et al. P-tuning: Prompt tuning can be comparable to fine-tuning across scales and tasks[C]//Proceedings of the 60th Annual Meeting of the Association for Computational Linguistics (Volume 2: Short Papers). 2022: 61-68.

[56] LI X L, LIANG P. Prefix-tuning: Optimizing continuous prompts for generation[C]// Proceedings of the 59th Annual Meeting of the Association for Computational Linguistics and the 11th International Joint Conference on Natural Language Processing (Volume 1: Long Papers). 2021: 4582-4597.

[57] VASWANI A, SHAZEER N, PARMAR N, et al. Attention is all you need[J]. Advances in neural information processing systems, 2017, 30.

[58] HOULSBY N, GIURGIU A, JASTRZEBSKI S, et al. Parameter-efficient transfer learning for nlp[C]//International conference on machine learning. PMLR, 2019: 2790-2799.

[59] HU E J, SHEN Y, WALLIS P, et al. Lora: Low-rank adaptation of large language models. [J]. Iclr, 2022, 1(2): 3.

[60] DETTMERS T, PAGNONI A, HOLTZMAN A, et al. Qlora: Efficient finetuning of quantized llms[J]. Advances in neural information processing systems, 2023, 36: 10088-10115.

[61] HAYOU S, GHOSH N, YU B. Lora+: Efficient low rank adaptation of large models[C]// Proceedings of Machine Learning Research: ICML. PMLR / OpenReview.net, 2024: 17783-17806.

[62] ZHANG Q, CHEN M, BUKHARIN A, et al. Adalora: Adaptive budget allocation for parameter-efficient fine-tuning[J]. CoRR, 2023, abs/2303.10512.

[63] XIANG S, CHENG D, SHANG C, et al. Temporal and heterogeneous graph neural network for financial time series prediction[C]//Proceedings of the 31st ACM international conference on information & knowledge management. 2022: 3584-3593.

[64] GAO Y, QIAO L, KAN Z, et al. Two-stage generative question answering on temporal knowledge graph using large language models[C]//Findings of the Association for Computational Linguistics: ACL 2024. 2024: 6719-6734.

[65] WANG X, GAO T, ZHU Z, et al. Kepler: A unified model for knowledge embedding and pre-trained language representation[J]. Transactions of the Association for Computational Linguistics, 2021, 9: 176-194.

[66] PENG M, LIU B, XIE Q, et al. Smile: Schema-augmented multi-level contrastive learning for knowledge graph link prediction[C]//Findings of the Association for Computational Linguistics: EMNLP 2022. 2022: 4165-4177.

[67] CHEN C, WANG Y, SUN A, et al. Dipping plms sauce: Bridging structure and text for effective knowledge graph completion via conditional soft prompting[C]//Findings of the association for computational linguistics: ACL 2023. 2023: 11489-11503.

[68] GARCÍA-DURÁN A, DUMANČIĆ S, NIEPERT M. Learning sequence encoders for temporal knowledge graph completion[C]//Proceedings of the 2018 conference on empirical methods in natural language processing. 2018: 4816-4821.

[69] HAN Z, CHEN P, MA Y, et al. Explainable subgraph reasoning for forecasting on temporal knowledge graphs[C]//International conference on learning representations. 2020.

[70] HE Y, ZHANG P, LIU L, et al. HIP network: Historical information passing network for extrapolation reasoning on temporal knowledge graph[C]//IJCAI. ijcai.org, 2021: 1915-1921.

[71] YANG B, YIH W, HE X, et al. Embedding entities and relations for learning and inference in knowledge bases[C]//ICLR (Poster). 2015.

[72] SUN Z, DENG Z, NIE J, et al. Rotate: Knowledge graph embedding by relational rotation in complex space[C]//ICLR (Poster). OpenReview.net, 2019.

[73] SHANG C, TANG Y, HUANG J, et al. End-to-end structure-aware convolutional networks for knowledge base completion[C]//Proceedings of the AAAI conference on artificial intelligence: Vol. 33. 2019: 3060-3067.

[74] WANG L, ZHAO W, WEI Z, et al. Simkgc: Simple contrastive knowledge graph completion with pre-trained language models[C]//Proceedings of the 60th annual meeting of the association for computational linguistics (volume 1: long papers). 2022: 4281-4294.

[75] SAXENA A, KOCHSIEK A, GEMULLA R. Sequence-to-sequence knowledge graph completion and question answering[C]//Proceedings of the 60th annual meeting of the association for computational linguistics (volume 1: long papers). 2022: 2814-2828.

[76] LOSHCHILOV I, HUTTER F. Decoupled weight decay regularization[C]//ICLR (Poster). OpenReview.net, 2019.

[77] SHANG C, WANG G, QI P, et al. Improving time sensitivity for question answering over temporal knowledge graphs[C]//Proceedings of the 60th Annual Meeting of the Association for Computational Linguistics (Volume 1: Long Papers). 2022: 8017-8026.

[78] ZHAO Y, WANG X, CHEN J, et al. Time-aware path reasoning on knowledge graph for recommendation[J]. ACM Transactions on Information Systems, 2022, 41(2): 1-26.

[79] BOGINA V, KUFLIK T, JANNACH D, et al. Considering temporal aspects in recommender systems: a survey[J]. User Model. User Adapt. Interact., 2023, 33(1): 81-119.

[80] 纪鑫, 武同心, 杨智伟, 等. 基于时序知识图谱的电力设备缺陷预测[J]. 北京航空航天大学学报, 2024, 50(10): 3131-3138.

[81] LIN Q, LIU J, MAO R, et al. Techs: Temporal logical graph networks for explainable extrapolation reasoning[C]//Proceedings of the 61st annual meeting of the association for computational linguistics (volume 1: long papers). 2023: 1281-1293.

[82] MEI X, YANG L, CAI X, et al. An adaptive logical rule embedding model for inductive reasoning over temporal knowledge graphs[C]//Proceedings of the 2022 conference on empirical methods in natural language processing. 2022: 7304-7316.

[83] SUN H, ZHONG J, MA Y, et al. Timetraveler: Reinforcement learning for temporal knowledge graph forecasting[C]//Proceedings of the 2021 conference on empirical methods in natural language processing. 2021: 8306-8319.

[84] LEBLAY J, CHEKOL M W. Deriving validity time in knowledge graph[C]//Companion proceedings of the the web conference 2018. 2018: 1771-1776.

[85] HE P, GAO J, CHEN W. Debertav3: Improving deberta using electra-style pre-training with gradient-disentangled embedding sharing[C]//ICLR. OpenReview.net, 2023.

[86] JIANG J, ZHOU K, ZHAO W X, et al. Reasoninglm: Enabling structural subgraph reasoning in pre-trained language models for question answering over knowledge graph [C]//Proceedings of the 2023 Conference on Empirical Methods in Natural Language Processing. 2023: 3721-3735.

[87] HE X, TIAN Y, SUN Y, et al. G-retriever: Retrieval-augmented generation for textual graph understanding and question answering[J]. Advances in Neural Information Processing Systems, 2024, 37: 132876-132907.

[88] LIU B, ZHANG J, LIN F, et al. Filter-then-generate: Large language models with structure-text adapter for knowledge graph completion[C]//Proceedings of the 31st International Conference on Computational Linguistics, COLING 2025, Abu Dhabi, UAE, January 19-24, 2025. Association for Computational Linguistics, 2025: 11181-11195.

[89] XU W, LIU B, PENG M, et al. Historical facts learning from long-short terms with language model for temporal knowledge graph reasoning[J]. Information Processing & Management, 2025, 62(3): 104047.

[90] PAPINENI K, ROUKOS S, WARD T, et al. Bleu: a method for automatic evaluation of machine translation[C]//Proceedings of the 40th annual meeting of the Association for Computational Linguistics. 2002: 311-318.

[91] LIN C Y. Rouge: A package for automatic evaluation of summaries[C]//Text summarization branches out. 2004: 74-81.

[92] BANERJEE S, LAVIE A. Meteor: An automatic metric for mt evaluation with improved correlation with human judgments[C]//Proceedings of the acl workshop on intrinsic and extrinsic evaluation measures for machine translation and/or summarization. 2005: 65-72.

[93] ZHANG T, KISHORE V, WU F, et al. Bertscore: Evaluating text generation with BERT [C]//ICLR. OpenReview.net, 2020.

[94] LI Z, GUAN S, JIN X, et al. Complex evolutional pattern learning for temporal knowledge graph reasoning[C]//Proceedings of the 60th annual meeting of the association for computational linguistics (volume 2: short papers). 2022: 290-296.

[95] OPENAI. GPT-4 technical report[J]. CoRR, 2023, abs/2303.08774.

[96] DUBEY A, JAUHRI A, PANDEY A, et al. The llama 3 herd of models[J]. CoRR, 2024, abs/2407.21783.

[97] YANG A, YANG B, ZHANG B, et al. Qwen2.5 technical report[J]. CoRR, 2024, abs/2412.15115.

[98] JIANG A Q, SABLAYROLLES A, ROUX A, et al. Mixtral of experts[J]. CoRR, 2024, abs/2401.04088.

攻硕期间发表的与学位论文相关的科研成果目录

发表的学术论文：

[1] **Jiang Z**, Peng M, Xu W, Liu B, Xiao Y, Liu K, Peng M. Boosting Pre-trained Language Models for Temporal Knowledge Graph Reasoning via Joint Structure and Recurring Patterns[C]. //Proceedings of the 26th International Conference on Web Information Systems Engineering: WISE, 2025.（第一作者，CCF C 类会议, 支撑本研究第三章）

[2] **Jiang Z**, Liu B, Peng M, Xu W, Xiao Y, Shan Z, Peng M. Towards Explainable Temporal Reasoning in Large Language Models: A Structure-Aware Generative Framework[C].//In Findings of the Association for Computational Linguistics: ACL, 2025.（第一作者，CCF A 类会议 Findings, 支撑本研究第四章）

[3] Xiao Y, **Jiang Z**, Wang E, Liu J. Modeling Relational Correlations with Dual-View Transformation for Temporal Knowledge Graph Forecasting[C]. // Proceedings of the International Joint Conference on Neural Networks: IJCNN, 2025.（第二作者，CCF C 类会议）

[4] Xu W, Liu K, **Jiang Z**, Song M, Zhang B, Peng M. Learning from Reconstruction: A Two-Stage Global-to-Local Framework for Temporal Knowledge Graph Completion[C].// Proceedings of the IEEE International Conference on Acoustics, Speech and Signal Processing: ICASSP, 2025.（第三作者, CCF B 类会议）

[5] Xu W, Liu B, Peng M, **Jiang Z**, Jia X, Liu K, Liu L, Peng M. Historical Facts Learning from Long-Short Terms with Language Model for Temporal Knowledge Graph Reasoning[J]. Information Processing and Management, 62(3):104047, 2025.（第四作者，CCF B 类期刊）

[6] Peng M, Liu B, Xu W, **Jiang Z**, Zhu J, Peng M. Deja vu: Contrastive Historical Modeling with Prefix-tuning for Temporal Knowledge Graph Reasoning[C]. // In Findings of the Association for Computational Linguistics: NAACL, 2024.（第四作者，CCF B 类会议 Findings）

在投的学术论文：

[1] **Jiang Z**, Xu W, Peng M, Liu B, Xiao Y, Shan Z, Jia X, Peng M. Structure-Aware Generative Framework for Temporal Knowledge Graph Reasoning with Historical Evidence[J]. World Wide Web Journal, 2025.（第一作者，CCF B 类期刊，在审）

[2] **Jiang Z**, Peng M, Shan Z, Xu W, Liu B, Chen G, Gao Z, Peng M. TKG-Thinker: Towards Dynamic Reasoning over Temporal Knowledge Graphs via Agentic Reinforcement

Learning[C]// Proceedings of the 2026 Conference on Empirical Methods in Natural Language Processing: EMNLP, 2026.（第一作者，CCF B 类会议，在审）

参与的科研项目：

[1] 科技创新 2030—“新一代人工智能”重大项目“人机融合医疗会诊关键技术与应用”（项目编号：2021ZD0113304，2022/01–2024/12），结项，主要参与者

[2] 国家自然科学基金区域联合项目“基于开放知识网络和产业知识图谱的区域产业趋势分析与风险预警”（项目编号：U23A20316，2024/01-2027/12）, 在研, 主要参与者

致　　谢

时光飞逝，转眼间，我要和珞珈山说再见了。老实说，我的内心是十分不舍的，自己非常喜欢在武大的时光，这里留下了太多美好瞬间。我喜欢在实验室和实验室的小伙伴们一起探讨学术、展望未来；喜欢和球友们约上一场篮球，然后一起撸串的时光；也喜欢樱花盛开的时候，能与家人朋友一起享受美丽的风景。回顾整个硕士期间的生活，自己经历过科研入门的迷茫、论文被拒的焦虑、自我怀疑，也曾因压力大而难以入睡。幸运的是，我都克服了这些困难，这也成为了我人生路上的宝贵财富。当然，这也离不开家人和朋友们的支持。正是有你们的陪伴，我才能走过迷茫与焦虑，才能顺利的完成自己的学业，因此，在这里，我需要向你们每一个帮助和支持我的人表示感谢，是你们让我的生活总是充满开心！

首先，我想衷心的感谢我的导师彭敏教授。正是因为彭老师，我才有机会来到 B504 实验室，感受到这个温暖大家庭的关怀与陪伴。正是在彭老师的悉心指导下，我逐渐适应了科研的节奏，提升了自己的综合能力。无论在科研还是生活上，彭老师都尽心尽力，给予我无微不至的关怀和指导，这让我在武大的日子充满力量与温暖。在科研上，彭老师在本科保研时就帮我确定了研究方向，让我少走了许多弯路。感谢老师给予我参加国际会议的机会，让我走出校园、见识更广阔的学术世界，并与顶尖人工智能学者交流，拓展了视野与思考。这些经历成为我人生中难忘且宝贵的财富。在生活上，彭老师也关心我的身体状况，会提醒我劳逸结合，让我能够调养好身体、保持精力。因此，我很庆幸自己能够遇到一个这么好的导师，在这里再次向老师表达感谢，希望您在未来工作顺利，身体健康！

其次，我想感谢 B504 实验室的全体同学。正是有了你们，我感受到了实验室的温暖，也让我的生活不再枯燥。每一次的约饭、桌游、健身和篮球，都让我的日子充实而快乐。感谢徐文杰师兄的悉心指导，帮助我入门硕士的研究方向，让我掌握基本的科研技能；感谢彭淼师兄，我很庆幸实验室里有这样一位本科同校的学长，不仅在科研上给予我细致指导，也在生活上关心照顾；感谢刘奔师兄，在你的指导与合作下，我完成了人生中的第一篇顶会论文，你也会给我分享许多前沿的技术，让我了解企业视角下的实际需求。同时，我也要特别感谢单臻衍、陈政宇、马文博、肖梦溪、刘磊、夏星雨等师兄师姐、师弟师妹们。正是有了你们的陪伴和支持，我的生活才如此充实，科研的日子也因此充满了乐趣和温暖。

再者，我还想感谢在我求学路上的朋友们。感谢“篮球群”的博士和硕士们，你们的陪伴和欢笑让科研的紧张得以缓解；感谢“附中三人组”群里的小伙伴们，自高中毕业以来一直保持联系，互相鼓励，共同成长；感谢舍友们，与你们一起生活的日子让我感受到家的温暖，无论是夜晚的闲聊、学习中的互助，还是生活琐事中的关心，

你们都让我的硕士生活更加充实。特别感谢小乐同学的陪伴。在我迷茫或失落时，你的鼓励和关心让我不再孤单；在慌乱时，你让我保持镇定。未来的路上，希望我们始终相伴，共同前行。

最后，我想感谢我的家人，正是有你们，我才能无惧挑战，勇敢追梦。从小到大，父母一直给予我鼓励式的教育，让我学会独立思考，也学会面对挑战。感谢父母的包容与理解，这份支持成为我不断前行的动力。花有重开日，人无再少年。喜欢在珞珈山的日子，伴着”落英缤纷，我的灵魂“的旋律，在武大的校园里漫步，感受每一刻的宁静与美好。珞珈山的故事即将结束，但在这里的美好记忆将永远留在我的内心深处。我深知自己并不是天赋异禀的少年，但我相信通过自己的努力，能够一步一步的实现自己的理想与目标，希望自己在接下来的博士阶段能够更加顺利，克服一个又一个困难。再次向所有在我身边的家人和朋友们表示感谢，愿你们平安喜乐，一切顺利！

武汉大学学位论文使用授权协议书

（一式两份，一份论文作者保存，一份留学校存档）

本学位论文作者愿意遵守武汉大学关于保存、使用学位论文的管理办法及规定，即：学校有权保存学位论文的电子版和印刷本，并提供文献检索与阅览服务；学校可以采用影印、缩印、数字化或其它复制手段保存论文；在以教学与科研服务为目的前提下，学校可以向本校认证用户公布部分及全部内容。

1、 在本论文提交当年，同意向本校认证用户提供查询及前十六页浏览服务。

2、 在本论文提交□当年/□一年/□两年/☑三年以后，允许本校认证用户在线浏览全文，学校可以为存在馆际合作关系的图书馆提供全文文献传递服务。

论文作者（签名）：蒋梓浩

学　　号：2023202110051

学　　院：计算机学院

日期：2026年5月29日