分类号 密 级

U D C 编 号 10486

武漢大學

硕 士 学 位 论 文

现代汉语与文言文风格的迁移方法研究

研 究 生 姓 名 ：许敏章

学 号 ：2021202110098

指导教师姓名、职称 ：彭敏 教授

专 业 名 称 ：人工智能

研 究 方 向 ：自然语言处理

二〇二四年五月

Text Style Transfer between Modern Chinese and Classical Chinese

By

Minzhang Xu

Supervised By

Prof. Min Peng

Wuhan University

May, 2024

论文原创性声明

本人郑重声明：所呈交的学位论文，是本人在导师指导下，独立进行研究工作所取得的研究成果。除文中已经标明引用的内容外，本论文不包含任何其他个人或集体已发表或撰写的研究成果。对本文的研究做出贡献的个人和集体，均已在文中以明确方式标明。本声明的法律结果由本人承担。

学位论文作者（签名）：_____

日期：　　年　　月　　日

武汉大学学位论文使用授权协议书

本学位论文作者愿意遵守武汉大学关于保存、使用学位论文的管理办法及规定，即：学校有权保存学位论文的印刷本和电子版，并提供文献检索与阅览服务；学校可以采用影印、缩印、数字化或其它复制手段保存论文；在以教学与科研服务为目的前提下，学校可以在校园网内公布部分或全部内容。

一、在本论文提交当年，同意在校园网内以及中国高等教育文献保障系统（CALIS）、高校学位论文系统提供查询及前十六页浏览服务。

二、在本论文提交□当年/□一年/□两年/□三年以后，同意在校园网内允许读者在线浏览并下载全文，学校可以为存在馆际合作关系的兄弟高校用户提供文献传递服务和交换服务。（保密论文解密后遵守此规定）

论文作者（签名）：_____

学　　号：_____

学　　院：_____

日期：　　年　　月　　日

摘要

随着机器写作技术的发展，个性化文本生成已经成为一种趋势。文本风格迁移任务由此应运而生，其目标是在保留输入文本内容的同时，将文本从原始风格准确迁移到目标风格。在过去的文本风格迁移研究中，研究者往往只关注情感迁移等简单的英文风格迁移任务。然而，用户的风格迁移需求日渐复杂，使得现有方法难以满足实际需求。此外，随着汉语的全球影响力增强和文化传承意识提升，文言文愈发受到人们的关注，然而现阶段能够对现代汉语与文言文进行理解与生成的模型寥寥无几。因此，论文聚焦于现代汉语与文言文的文本风格迁移任务，并在此基础上展开探索。

目前，现代汉语与文言文的文本风格迁移研究面临如下两个挑战：（1）文本风格与内容耦合度极高，风格属性复杂，在计算资源有限和缺少标注数据的情况下，现有小模型的风格抽取与生成能力无法满足任务需要；（2）在拥有足够计算资源的情况下，虽然大语言模型具有更强的理解与生成能力，但其在文本风格迁移领域，还未与人类偏好进行较好的对齐，同时大模型的幻觉也会对内容信息造成干扰。

针对上述挑战，论文展开以下探索：（1）针对计算资源有限的小模型，论文提出基于提示强化学习的文本风格迁移算法。一方面使用同义词表映射方法构建伪平行语料，为模型训练提供热启动；另一方面设计基于多维信号反馈的强化学习算法，在不牺牲内容信息完整性和生成语言流畅性的前提下，完成现代汉语与文言文风格的迁移。实验结果表明，该方法能对复杂的现代汉语与文言文风格进行有效的理解和迁移，相比基准模型，内容保留完整度在《史记》风格数据集上得到至少 9.63%的提升，同时该方法结果在风格迁移准确性、内容保留完整性、语言流畅性三个维度达到良好的平衡。（2）针对拥有足够计算资源的大模型，提出基于指令增强的大模型风格迁移框架。针对开源大模型，设计基于要求引导的指令微调方法，将模型的风格迁移偏好与人类偏好对齐，在训练阶段有效增强大模型对复杂文本风格的理解与生成能力，减小模型幻觉的干扰。针对参数权重闭源的大模型，设计基于提示分析的上下文学习方法，在推断阶段提升模型的零样本与少样本风格迁移能力。同时，论文探究提出的大模型风格迁移框架在风格迁移准确性、内容保留完整性和文本流畅性三个维度对不同规模大模型的影响。

关键词：文本风格迁移；强化学习；指令微调；上下文学习

Abstract

With the advancement of text generation technology, automated machine writing has deeply integrated into people's lives, and the generation of texts with personalized styles according to user requirements has become an urgent need. Against this backdrop, the task of text style transfer has emerged, aiming to accurately transfer the text from the original style to the target style while retaining the content of the input text and ensuring language fluency. In past research on text style transfer, researchers often focused only on simple English text style transfer tasks such as emotional transfer, characterized by a low coupling degree between text style and content. However, users' style transfer needs are becoming increasingly complex, and complex text styles are often highly coupled with content, making existing methods unable to meet practical needs. Moreover, with the growing global influence of Chinese users and the emphasis on inheriting Chinese culture, Classical Chinese has received increasing attention. However, there are few models capable of understanding and generating both Modern and Classical Chinese at this stage. Therefore, this thesis focuses on the text style transfer task between Modern and Classical Chinese and explores this area further.

Currently, the research on text style transfer between Modern and Classical Chinese faces the following two challenges: (1) The text style is highly coupled with content, and the style attributes are complex. With limited computational resources and a lack of annotated data, the style extraction and generation capabilities of existing small models cannot meet the task requirements; (2) With sufficient computational resources, although large language models have stronger understanding and generation capabilities, they have not yet aligned well with human preferences in the field of text style transfer, and the illusions of large models can also interfere with content information.

In response to these challenges, this dissertation explores the following: (1) For small models with limited computational resources, a text style transfer algorithm based on prompt-enhanced reinforcement learning is proposed, which completes the style transfer between Modern and Classical Chinese without sacrificing the integrity of content information and the fluency of generated language. Experimental results show that this method can effectively understand and transfer the complex styles of Modern and Classical Chinese. Compared to the baseline model, the content retention completeness on the "Records of the Grand Historian" style dataset has improved by at least 9.63%, and this method achieves a good balance in style transfer accuracy, content retention completeness, and language fluency. (2) For large models

with sufficient computational resources, a large model style transfer method based on instruction enhancement is proposed, using “demand guidance” and “prompt analysis” instructions to effectively enhance the large model’s understanding and generation capabilities for complex text styles during the training and inference phases, reducing the interference of model illusions. At the same time, the dissertation explores the impact of the proposed enhanced instructions on different scales of large models in terms of style transfer accuracy, content retention completeness, and fluency.

Keywords: Text Style Transfer, Reinforcement Learning, Instruction Tuning, In-context Learning

目录

摘要 I

Abstract II

目录 IV

第 1 章 绪论 1

1.1 研究背景与意义 1

1.1.1 研究背景 1

1.1.2 研究意义 2

1.2 国内外研究现状 3

1.2.1 基于小模型的文本风格迁移研究进展 3

1.2.2 基于大模型的文本风格迁移研究进展 6

1.3 主要研究内容 9

1.4 主要贡献与创新 11

1.5 论文的组织结构 12

第 2 章 相关理论与技术 13

2.1 文本风格迁移 13

2.2 预训练语言模型 14

2.3 强化学习方法 16

2.4 提示学习与指令微调方法 18

2.5 本章小结 20

第 3 章 基于提示强化学习的文本风格迁移 21

3.1 引言 21

3.2 基于提示的模型热启动算法 23

3.2.1 伪平行语料构建方法.....23
3.2.2 基于提示的风格迁移微调.....24
3.3 基于多维信号反馈的强化学习算法.....25
3.3.1 奖励工程设计.....26
3.3.2 策略梯度优化算法.....28
3.4 实验对比与分析.....28
3.4.1 实验数据.....29
3.4.2 基准模型概述.....29
3.4.3 模型训练详情.....30
3.4.4 评价指标.....30
3.4.5 实验结果与分析.....31
3.5 本章小结.....37
第 4 章 基于指令增强的大模型风格迁移框架 38
4.1 引言.....38
4.2 基于要求引导的指令微调.....40
4.2.1 风格迁移指令设计.....41
4.2.2 迁移偏好指令设计.....42
4.2.3 错误学习指令设计.....44
4.3 基于提示分析的上下文学习.....45
4.4 实验对比与分析.....46
4.4.1 实验数据.....47
4.4.2 基准模型概述.....48
4.4.3 模型训练详情.....48
4.4.4 评价指标.....49

4.4.5 实验结果与分析.....50
4.5 本章小结.....56
第 5 章 总结与展望 57
5.1 全文工作总结.....57
5.2 未来工作展望.....58
参考文献 60
致 谢 69
附录 A：个人简历 70
附录 B：在学期间参与的科研项目 71
附录 C：在学期间取得的学术成果 72

第1章 绪论

1.1 研究背景与意义

1.1.1 研究背景

文本具有情境性，每个表达都与特定的时间、地点和场合相适应。文本的风格属性反映了说话者的独特特点，并通常具有明确的目的。风格的直观概念是表达语义的方式[1]。例如，缺乏自信的人可能更倾向于使用疑问句（如，“这是真的，对吗？”），而不是陈述句（如，“这绝对是真的。”）；同样，正式社交场合下，敬语书面语（如，“请入座。”）往往比非正式用语（如，“来坐!”）更为常见。正如每个人都有自己的签名一样，风格来源于每个人言语中的固有特征，可以使用某些文体修辞手段（例如隐喻）以及词语选择、句法结构等进行表达。

随着机器自动写作技术的发展，人们不再满足于风格千篇一律的机器写作，对机器生成文本的风格要求愈发复杂化和多样化。文本风格迁移（Text Style Transfer，TST）任务应运而生，其目的是在完整保留文本内容、保证生成文本流畅性的前提下，改变文本的风格。在该领域的实际研究中，语言风格的概念被拓展为文本的一般属性[2]。

目前，大多数研究主要着眼于正式性用语[3]、幽默与浪漫风格[4]和情感极性迁移[5]等应用场景。而这些场景中的风格往往与文本传达的内容高度解耦，文本中能抽取出鲜明的风格标志词，例如，将消极的评论文本“*这里的服务很糟糕*”迁移为积极评论“*这里的服务非常好*”，只需要改变与文本情绪极性相关的词段，其它的文本则几乎保持不变。这类风格迁移任务与现实生活中的风格迁移需求相比过于简单和理想化，无法满足用户复杂多样的迁移需求。为此，Xu 等人提出了“复杂文本风格迁移”任务[6]，其中，复杂风格表示较为抽象、甚至需要由相关领域专家才能够辨别的风格。复杂文本风格迁移任务仍是有待探索与研究的新兴领域。

论文重点关注现代汉语与文言文的复杂文本风格迁移任务，面对不同的计算资源背景，从缺少足量计算资源的小模型和拥有较多计算资源的大模型两个场景，研究全面的解决方案。

面向小模型的文本风格迁移是目前研究较多的任务场景，其特点是模型泛化能力较弱、依赖训练数据。而相较于其它文本风格迁移任务，现代汉语与文言文的风格迁移任务尤为缺少平行语料[7]，且风格与内容高度耦合，对小模型的无监督风格理解与生成能力、文言文的理解能力均提出了较高的要求。因此，如何使用无监督学习方法进行现代汉语与文言文的风格迁移，使得模型既能按要求生成指定风格的文本，同时保证文本原意不变、语句流畅，是一个仍有待探索的难题。

随着大模型的兴起，文本风格迁移任务取得了新的进展和展望。大模型可以使用指定的风格对用户指令进行回复，例如使用莎士比亚的风格来解答数学题[8]。此外，Zhang 等人发现中文大模型 ChatGLM[9]可以很好地理解文言文[10]。与小模型相比，大模型由于其卓越的理解和生成能力，在处理现代汉语与文言文之间的文本风格转换任务时展现出更加巨大的潜力。尽管如此，目前大模型在文言文的风格理解与生成能力上仍有待提高，同时对于大模型在文本风格迁移方面的研究仍然不足。

综上所述，论文针对指定风格的现代汉语与文言文的文本风格迁移任务，从基于小模型的迁移算法、基于指令增强的大模型风格迁移方法两个层面切入，旨在从训练算法、训练数据和偏好对齐等多个层面展开研究，提升模型生成结果的风格准确性、内容完整性和文本流畅性，为该任务的不同应用场景提出全面的解决方案。

1.1.2 研究意义

文本风格迁移是人工智能领域对文本进行深化理解和生成的关键环节。为了使人工智能系统能够准确地理解和生成语言，需要对文本进行风格或属性建模，而不仅仅是对语义进行非风格化的语言表达。在现实场景中，文本风格迁移被应用于诸多领域，如文本润色[3]、诗歌创作[11]、人机对话[12]、特定风格标题生成[13]和社区评论环境改善[14]等。

于理论层面，研究现代汉语与文言文风格迁移具有较强的理论意义。在现代汉语与文言文之间进行高质量风格迁移的过程中，至关重要的是对文本的复杂风格进行精确建模，并在风格、内容、流畅性三者间达到良好平衡。该研究涉及到文本生成、数据增强和偏好对齐等领域，可提升模型对文本的抽象风格和语义的理解与生成能力，从而提高模型在理解和生成文本方面的准确性。此外，该研究

也可与其它文本生成任务结合，丰富模型生成文本的风格多样性，使得机器自动写作能够满足个性化需求的应用场景。

于应用层面，现代汉语与文言文风格迁移也具有丰富的应用意义。一方面，它有助于深入理解现代汉语和文言文之间的转换规则和结构，推动语言学研究的发展；另一方面，它也有助于传承和弘扬文言文所承载的中华文化。深入理解和掌握文言文，将显著提升人们对古代汉语的理解力和表达力，对于语文教育尤其是文言文教育具有重要意义。此外，对于编辑和翻译工作中需要使用文言文的场景，针对现代汉语与文言文风格的建模、迁移与生成研究也会发挥重要作用。

1.2 国内外研究现状

本章以小模型和大模型两个层面作为切入点，对文本风格迁移领域的国内外现状进行归纳和总结。

1.2.1 基于小模型的文本风格迁移研究进展

基于小模型的文本风格迁移方法的核心在于数据，其可按照标注平行数据的可获得性划分为监督学习方法与无监督学习方法。其中，监督学习方法适用于拥有多种不同风格、文本内容一一对齐的平行数据场景，而无监督学习方法则适用于存在多个不同单一风格、文本内容没有经过平行对齐的数据场景。

（1）监督学习方法

同其它自然语言生成任务（如神经机器翻译）类似，TST 任务的监督学习方法大多采用序列到序列（Sequence to Sequence，Seq2seq）的编码器-解码器结构。正如神经机器翻译领域通常遇到的过度翻译和遗漏翻译等幻觉问题[15]，TST 任务也面临内容信息遗漏、内容错误、风格迁移不完全或者错误等幻觉问题。现有研究采取多任务学习、原文改写策略和数据增强等方式针对性地解决这些问题。

多任务学习方法在模型进行文本对风格属性学习的基础上，引入其他的任务进行协同学习，多个任务损失进行相互促进，从而提升模型效果。Xu 等人在最大似然损失的基础上提出了额外三个任务损失：分类器引导损失、自我重建损失、循环损失[16]。分类器引导损失通过额外训练的风格属性分类器计算，引导模型生成风格更接近目标风格的文本；自我重建损失使模型按原始风格重新生成输入文

本；循环损失令模型先从原始风格迁移至目标风格，再迁移回原始输出。这些多任务损失也被后续的很多研究方法广泛采用，成为 TST 领域最常用的损失。此外，也有研究将机器翻译与风格迁移[17]、语法错误检测与风格迁移[18]结合进行多任务学习。

原文改写策略主要针对原始风格与目标风格词表相同、语法结构相似的简单文本风格迁移任务，通过对原始输入文本的部分保留与改写，在保证风格完整迁移的前提下减少对输入地修改，以此保证迁移过程中内容的完整度。Jhamtani 等人引入“复制机制”和指针网络来有选择地从输入中复制词语到输出中[19]，有效提升了稀有词汇与专有名词信息的完整度。Kajiwara 等人为了避免模型保留过多输入文本，使用“负词法约束解码”来防止模型对输入进行直接复制[20]。

由于 TST 领域中的标注数据较为稀少，也有一些研究通过数据增强的方法扩充训练数据，达到提升模型效果的作用。Rao 等人用训练数据额外训练了一个短语级的机器翻译模型，将文本中的短语替换成同义词，从而构建伪平行语料用作额外训练数据[3]。Zhang 等人通过回译、性质判别方法，利用机器翻译模型生成更多样的输入输出文本，增加数据的多样性[18]。

现阶段，由于大多数应用场景缺少有标注数据，更多的研究转向无监督学习。

（2）无监督学习方法

由于文本风格迁移任务中平行语料的获取相对困难，目前主要的研究工作集中于无监督学习方法，其目标是通过大量非平行的风格文本语料，显式或隐式地改变文本的风格属性，同时保留文本内容，完成迁移工作。目前，无监督学习方法采用的策略可大致分为解耦与非解耦两大类。

解耦策略是 TST 领域中应用最广泛的策略之一，其核心思想是将文本的风格属性与内容信息显式或隐式地解耦，将内容表征与目标风格表征融合，生成目标序列。若风格表征能与内容表征完全解耦，那么模型就能在保留完整内容信息的同时，实现对文本风格的准确迁移。解耦方法可根据是否直接对文本本身进行解耦分为显式解耦与隐式解耦。

显式解耦通常只适用于简单风格迁移任务，要求能从词法或句法上直接将风格标志词抽取出来，从自然语言文本的层面进行显式的解耦与迁移。具有代表性的研究是 Li 等人设计的“删除、检索与生成”模型[21]。以情感风格迁移为例，该模型第一步通过词频统计将输入文本中检测到的情感标志词删除；第二步从目

标风格的语料中检索与输入文本最接近的语句，抽取其中的风格标志词作为备选风格词；第三步，将风格备选词与删除后的输入一同输入生成器中，生成最终的输出结果。Wang 等人则采用生成对抗网络（Generative Adversarial Network，GAN）训练遮罩预测器，以此对文本中蕴含的风格词语进行遮罩，随后使用辨别器引导的风格填充损失、多样性损失、一致性损失对风格填充模型进行训练[22]。类似地，Zhu 等人使用 Bert[23]嵌入，与句法依存分析相结合，同时使用排序算法来对输入文本中的词语进行遮罩，随后通过构建伪平行语料的方式训练风格填充模型，以此减少风格注入过程中同时注入无关内容信息的情况[24]。

隐式解耦则在文本表示的层面对文本的风格与内容进行解耦，其具体的解耦以及风格注入过程都是不可见的。隐式解耦的主要方法是通过编码器将文本映射到隐空间，从而获取潜在表示，并进一步分离内容和风格属性表示向量，将内容表示与目标风格表示进行融合，完成风格迁移。Hu 等人首次提出将变分自编码器和属性判别器结合，属性编码控制目标句子的风格，编码器则用于获取与属性无关的文本内容编码，由属性判别器提供反馈信号来优化生成器[25]。后续研究[26–32]在此基础上进行改进，增加对内容编码进行编辑的步骤，丰富属性编码的表征能力，优化模型的生成能力。Mai 等人在此基础上引入前缀微调，这些前缀相较于风格属性编码具有更强的表征能力，前缀微调也令模型训练的参数减少至 2%[33]。然而，这类方法面对复杂文本风格迁移任务，则往往存在风格和内容难以彻底解耦、缺乏直接评估解耦质量的方法等问题。

非解耦策略的研究则认为将文本风格与内容进行解耦是没有必要的[34]。此外，文本风格与内容解耦的方法也面临难以保证质量、难以对解耦方法的优劣进行评估的问题[35]。因此，非解耦方法直接对文本或文本的潜在表示进行修改，端到端地达成风格迁移的目的，常用方法包括强化学习、回译、非自回归模型、非解耦的属性控制生成等。

强化学习策略可以显式地使用奖励函数来建模迁移准确率、文本内容完整度和句子流畅性。Luo 等人把源句和目标句的映射，以及目标句和源句的映射视为一个双重学习任务，采用强化学习的训练方式，通过人工设计的奖励函数获取反馈以解决平行语料缺乏的问题[36]。Gong 等人提出基于强化学习的生成器和评估器架构，用以提高风格迁移的句子的语法准确性[37]。而如何设计优化策略从而在不解耦的情况下同时达成风格迁移、内容保留完整、语言流畅三个要求，仍是强

化学习策略的一个难点，同时，强化学习方法也存在训练不稳定的问题。

回译策略[38]的主要思路是假定有一个目标语言句 y，通过训练好的目标语言到源语言的翻译模型，得到伪平行句对(x, y)，然后将其加入平行语料库中进行训练。这种方法可以更好地借助单语料来辅助翻译模型的训练。Prabhumoye 等人首次将回译思想引入到文本风格迁移问题中，来辅助进行内容表示的抽取[39]。与此类似，Zhang 等人使用回译策略迭代构建伪平行语料库并优化模型，逐步提升模型的性能[40]。这种方法非常依赖翻译模型的质量，而回译文本能够提供的增强空间也十分有限。

此外，Huang 等人利用非自回归模型可以对文本进行词级别对齐的特性，将 TST 任务转化成非自回归文本对齐与遮罩预测的任务，从而降低引入内容无关信息的概率，提高内容保留完整度[41]。这种方法虽然效率高，但是由于目前非自回归模型的研究有限，其生成质量仍相对较低，同时，对生成文本的长度预测本身也增加了生成的误差。Xu 等人则引入 Barlow Twins 损失，从句子层面和段落层面提升属性编码器的表示丰富度，从而完成复杂风格的文本迁移[6]。这个方法需要额外的上下文数据作为参考，应用场景有限。

本节对基于小模型的文本风格迁移国内外现状进行了详细介绍。其中，监督学习方法由于 TST 领域缺少平行语料而难以被广泛应用。无监督学习方法中，解耦方法存在的问题包括复杂文本风格难以与内容进行彻底的解耦、解耦的质量无法进行直接评估和监测等。而非解耦方法则面临间接的迁移优化策略难以在风格迁移度、内容完整度、语言流畅度三者间达到较好的平衡，依赖于额外的辅助模型的生成质量、可能需要额外的上下文语料等难题。论文根据现代汉语与文言文风格迁移的任务特性，针对非解耦的强化学习方法，通过对内容保留完整度、风格迁移准确度、语言流畅度三者进行显式建模，达到三者的平衡统一；同时引入基于提示的热启动算法来解决强化学习训练不稳定的问题，完成现代汉语与文言文的复杂文本风格迁移任务。

1.2.2 基于大模型的文本风格迁移研究进展

大语言模型的兴起为自然语言处理领域带来了新的火花。进行人类偏好对齐后的大模型可以较为精准地理解人类设计的指令的含义，从而完成指令下达的任务。Bubeck 等人在对 GPT-4[42]评测实验中发现，GPT-4 拥有理解复杂概念的能

力，能够在不同的语气、风格、专业领域等方面进行文本的迁移和生成，例如，用柏拉图对话的风格来阐述自回归模型的使用弊端[8]。

目前，大语言模型在下游任务上的学习范式主要可分为三种：不进行参数化微调的上下文学习（In-context Learning，ICL）、基于自然语言硬提示的指令微调以及基于隐向量软提示的提示学习。

不进行参数化微调的上下文学习方法的核心是通过提示工程找到对于当前模型最优的硬提示，构建最合适的、无偏的上下文学习样例，从而在完全冻结模型参数的基础上，实现无训练前提下的模型效果提升。Brown 等人发现，对于具有一定规模的大语言模型而言，仅仅通过人工精心设计的提示，而不对模型参数进行任何下游任务微调的零样本学习就能引导大模型较好地完成很多自然语言处理领域的任务[43]。Sanh 等人通过实验验证了大模型零样本泛化能力的主要来源是模型预训练过程中显式或隐式的多任务学习[44]。Zhao 等人则发现，上下文学习与少样本学习的过程中，选取的学习样本会对模型造成偏置[45]。针对这种情况，他们提出在上下文学习前需要对设计的提示上下文进行校准，以及需要谨慎地选取少样本的样例。在文本风格迁移任务中，Reif 等人首次提出“增强的零样本学习方法”，通过人工构建提示模板，同时使用与目标风格相近的其它风格样本对数据进行领域迁移增强，实现大语言模型对任意风格的文本迁移任务[46]。

上下文学习的另一种思路是额外训练小模型辅助大模型生成，用小模型对大模型的输入提示文本进行生成或者排序，或是对大模型随机采样生成的结果进行评估和排序，从而得到最好的生成结果。Liu 等人训练一个排序模型，对人工设计的种子提示以及用 ChatGPT 生成的增强提示进行排序筛选，选出最适合当前任务的提示模板，来得到最优的模型生成结果[47]。Deng 等人则使用强化学习策略来生成最优的提示输入[48]，避免直接从人工设计的提示模板进行选择，相比前一种方法，具有更高的提示文本多样性。Suzgun 等人则着眼于模型生成的结果，通过对模型随机采样后的结果从风格强度、内容一致性、文本流畅性三个角度进行排序，选出模型生成的最优结果[49]。Huang 等人引入额外的重难点词汇解析，用外部知识辅助大模型生成，较少模型在重难点词翻译上产生的幻觉，提升模型效果[50]。上下文学习的方法优点是几乎不需要对模型参数进行训练，消耗资源少，但缺点是生成的结果几乎完全取决于大模型本身在下游任务上的能力，大模型能力的上限决定了最终生成结果的优劣。

基于自然语言的硬提示指令微调方法首先由 Ouyang 等人提出，它的目的是通过人类反馈的微调方法，将经过预训练的语言模型与人类偏好进行对齐，从而提升模型在下游任务的表现，以及模型听从人类指令的能力[51]。如今，这种方法已经成为大模型训练的一种重要范式。Jiao 等人构建基于提示的多语言翻译指令、错误引导指令、对比指令，对 Llama 进行指令微调，提升模型在多语言机器翻译上的效果[52]。Zhang 等人使用人工和 ChatGPT 设计安全与目标优先级指令，微调后显著提升了大模型的安全性与越狱攻击下的鲁棒性[53]。在文本风格迁移领域，目前指令微调方法的研究仍然非常稀少。由于高质量数据往往难以获得，很多研究提出指令增强的方法来应对指令数据太少的情况。Li 等人通过指令自我重生成、回译与重筛选来生成新的指令，实现指令增强[54]。Xu 等人设计一套生成复杂指令的提示模板，引导 ChatGPT 生成高质量的指令，来辅助开源大模型的指令微调过程[55]。

基于隐向量软提示微调方法是介于硬提示指令微调方法和全量微调方法之间的折中选择。虽然自然语言硬提示具有很好的可读性，但是由人类构建的硬提示可能无法与模型对齐，无法充分发挥模型的潜力；而全量微调不仅代价太大，而且可能出现过拟合的情况。提示微调方法在模型的嵌入层或者每一层前加入额外的隐向量前缀，在训练过程中冷冻模型本身的参数，只对前缀隐向量进行微调，大大降低了训练的资源消耗，同时完成了模型与下游任务的对齐[56–58]。Mai 等人将提示微调与生成对抗网络结合，训练风格迁移生成器，大大降低了计算资源的开销[33]。Ju 等人训练多个任务前缀、风格前缀，使模型能够完成复杂多风格迁移任务[59]。这种方法虽然可以极大地降低训练时的开销，但是前缀软提示往往难以训练，非常依赖超参数的调整。

本节对基于大模型的文本风格迁移国内外现状进行了详细介绍。其中，不进行参数化微调的上下文学习方法在文本风格迁移领域的研究最为丰富，通过对输入提示的调整，避免直接对大模型参数进行微调，效率高且资源占用极低，但是模型结果的优劣直接由模型本身的能力上限决定。基于自然语言的硬提示指令微调方法，具有良好的可解释性，也能够通过微调使模型与文本风格迁移的下游任务需求进行对齐，但缺点是该领域的数据往往非常稀少，难以满足指令微调的需求。尽管一些现有研究采用了指令增强的手段，但它们在文本风格迁移领域的应用仍有待探索。基于隐向量软提示微调方法在零样本学习与全量微调间做出较好

的平衡，但也对训练数据量提出了要求，同时也存在难以训练、依赖超参数调整的问题。论文着眼于文本风格迁移的指令增强方法，探索特定指令结构的设计，提出基于要求引导的指令微调方法和基于提示分析的上下文学习方法，一方面促进模型对文本风格的理解，一方面减少模型在内容信息上产生的幻觉。

1.3 主要研究内容

论文的主要目标是探究现代汉语与文言文的风格迁移方法，针对现代汉语与文言文风格迁移任务面临的两类挑战，从多个不同的角度进行研究，包括训练算法、训练数据与偏好对齐等。论文的研究内容框架如图 1.1 所示。以下是研究的具体内容：

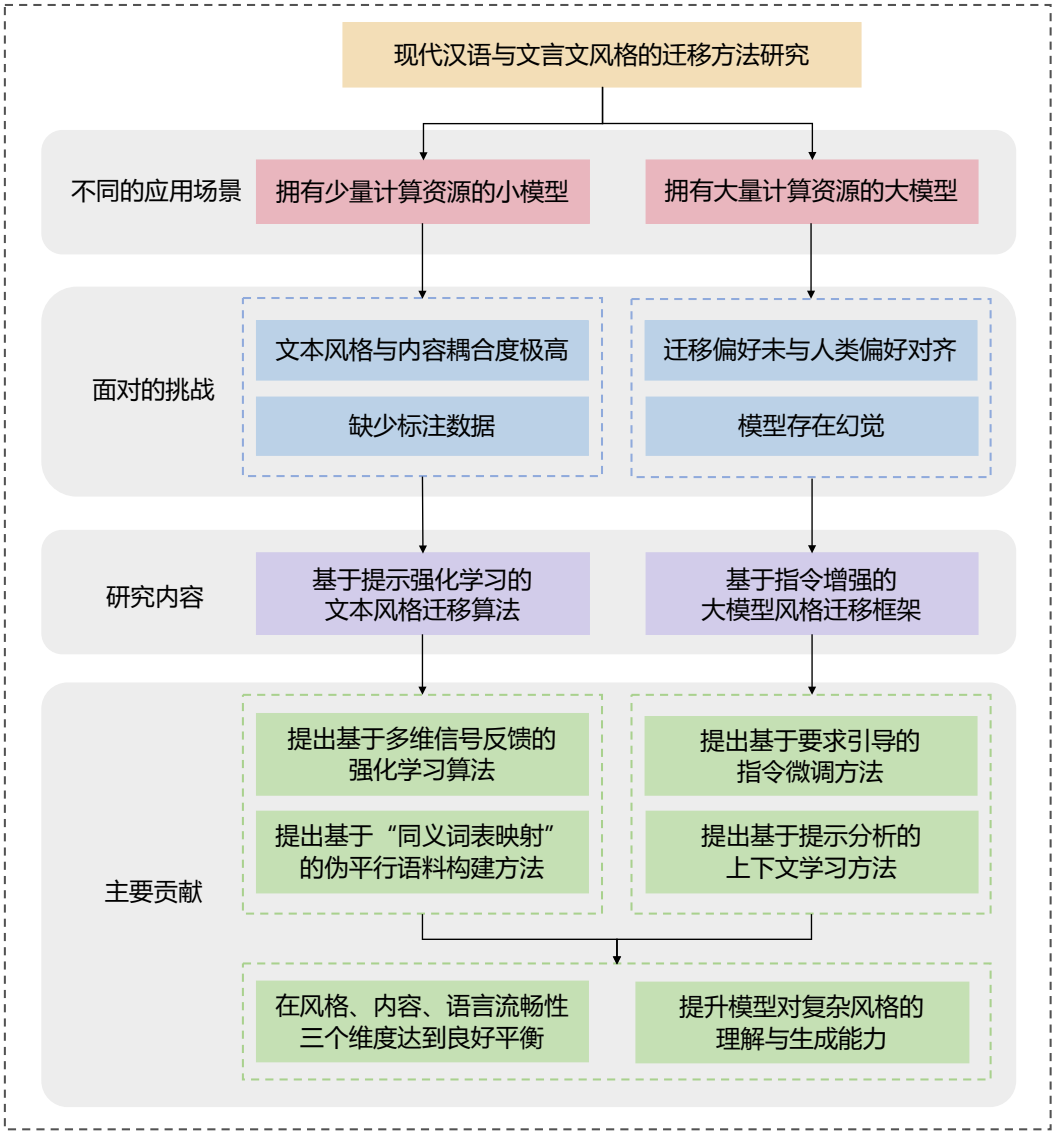


图 1.1 研究内容框架图

（1）从训练算法和训练数据的角度，研究面向小模型的提示强化学习风格迁移算法。作为一种复杂文本风格迁移任务，现代汉语与文言文的风格与文本内容高度耦合，难以找到标志性的风格关键词，而基于解耦策略的模型无法准确将文本的风格隐向量与内容隐向量分离。目前已有的非解耦方法在缺少平行语料的情况下，难以平衡风格准确度、内容保留完整度、语言流畅度三者的关系。针对以上难题，论文提出基于强化学习的复杂文本风格迁移算法，避免了内容与风格的解耦，通过显式定义的奖励函数，对风格、内容、流畅性进行平衡，同时提升算法的可解释性。该算法包括以下三个部分：①伪平行数据构建，通过同义词表映射，使用词移距离（Word Mover's Distance，WMD）匹配在原始风格与目标风格语料间构建伪平行数据，将无监督问题转化为伪监督问题；②利用伪平行数据进行模型的粗精度微调，为后续的强化学习算法提供初步的热启动；③通过梯度策略算法，利用论文设计的三个奖励函数显式地对模型进行优化，得到最终的风格迁移模型。

（2）从偏好对齐的角度出发，针对现代汉语与文言文的文本风格迁移任务，研究基于指令增强的大模型风格迁移框架：面向开源大模型，论文提出基于要求引导的指令微调方法；面向不开源模型权重参数的大模型，提出基于提示分析的上下文学习方法。现有的大语言模型的预训练数据主要为英语或现代汉语，文言文的数据相对较少，因此，大模型对文言文风格的理解与生成存在一定困难。此外，大模型也面临着“幻觉”的困扰，容易生成不符合原始输入内容的信息。针对上述问题，论文分别搭建服务于文本风格迁移的开源大模型（0.5B-14B）训练框架和不进行参数训练的上下文学习框架。一方面，针对开源模型设计适合该任务的新颖指令微调方法，通过三种指令增强策略，使其与文本风格迁移领域的人类偏好进行对齐，满足风格、内容等多个维度的要求。这将有效弥补现有研究在开源大模型训练方面的缺失。具体的三种指令增强策略包括：①构建风格迁移指令，使模型学习进行风格迁移任务的基本范式；②构建迁移偏好指令，通过数据偏好的学习与人类偏好进行对齐，从高质量与低质量数据的对比中学习复杂风格属性；③构建错误学习指令，从不同类型的错误生成结果中对风格迁移的各个维度进行强化，减小幻觉，满足风格准确率、内容完整度、文本流畅性三个核心要求。另一方面，针对闭源模型，在不改变模型参数权重的基础上，设计上下文学习指令，通过提示指令和分析指令，使模型从指令上下文中学习风格迁移的范式，

增强模型对现代文和文言文的复杂风格的理解，同时减少幻觉的产生。

1.4 主要贡献与创新

论文研究现代汉语与文言文的文本风格迁移方法，为该领域的不同应用场景提出全面的解决方案。主要贡献如下：

（1）针对缺少计算资源的小模型场景，论文提出基于提示强化学习的文本风格迁移算法，通过奖励设计，为模型提供显式反馈，非解耦地完成文本风格迁移，同时尽可能保证内容的完整保留以及生成语言的流畅性。相比于现有强化学习算法，论文设计具有鲁棒性的三种奖励函数：风格迁移准确率奖励、内容保留完整度奖励、语言流畅度奖励，并在这三者间达到良好的平衡，同时有效缓解对抗性样本造成的错误奖励方向的指引问题。此外，针对缺少平行语料的场景，论文依据现代汉语与文言文风格迁移的应用场景，提出基于“同义词表映射”的伪平行语料构建方法。构建外部同义词表并对现代汉语与文言文的语料文本进行映射替换，再使用词移距离计算不同风格语料间的语义相似度，从而构建伪平行的自动标注文本，将无监督任务转化为监督任务。生成的伪平行标注语料可对风格迁移的序列到序列模型进行粗精度的微调，为基于提示强化学习的算法提供热启动，大大增加强化学习训练的稳定性。此外伪平行语料通过后续的强化学习训练、清洗与优化后可用于构建大模型的指令数据集，丰富指令数据的多样性。

（2）针对拥有足够计算资源的大模型场景，论文提出基于指令增强的大模型风格迁移框架。首先，针对开源大模型场景，论文提出基于要求引导的指令微调方法，增强大模型对复杂文本风格的深层次理解，同时减小模型的幻觉。训练指令由三个部分组成：风格迁移指令、迁移偏好指令、错误学习指令。风格迁移指令用于定义风格迁移任务的基本范式，训练模型遵循风格迁移任务的指令并正确生成满足任务要求的输出；迁移偏好指令旨在令模型从高质量与低质量数据的对比中学习不同输出之间的质量偏好，强化模型对于复杂风格属性的认知与理解；错误学习指令则从风格迁移错误、内容存在遗漏等不同类型的错误生成结果出发，让模型从错误中学习，从风格迁移的各个维度进行强化，减小模型幻觉，满足风格准确率、内容完整度、文本流畅性三个核心要求。其次，针对参数权重不开源的大模型场景，论文提出基于提示分析的上下文学习方法，在完全不对模型参数进行训练的前提下，提升模型的零样本与少样本学习能力。该上下文提示模板中

的核心部分是提示和分析模块。提示模块用于引导当前迁移输出的方向；而分析模块则依据当前的提示、输入和输出，从风格、内容、流畅性三个角度进行具体分析和评价，使得模型能够从指令上下文中学习风格迁移的模式，从而深化其对复杂文本风格的理解、减少迁移过程中产生的幻觉。

（3）论文在《白话史记》和《史记》数据集上对提出的模型和算法进行实验验证。基于小模型的提示强化学习算法相较于现有的优秀基准模型，其生成的迁移文本在复杂风格理解与生成、内容保留完整性、语言流畅性的平衡方面更具优势。论文也分别设计消融实验对模型的各个模块进行有效性验证。对于基于指令增强的大模型训练框架，论文分析各类增强指令在不同规模大模型上，对风格理解与生成能力、内容保留能力等多个维度的影响。实验充分说明论文提出的训练框架在现代汉语与文言文风格迁移的不同应用场景下，在风格、内容、语言流畅性三个维度能达到良好的平衡，生成结果具有有效性和优越性。此外，论文也使用文本风格迁移领域常见的情感迁移数据集 Yelp[5]进行实验，证明所提出的算法的通用性和有效性。

1.5 论文的组织结构

本论文将由五个章节组成，各章节的主要内容如下：

第一章：绪论，介绍论文的研究背景、意义、国内外现状、论文的主要内容与贡献。

第二章：相关理论与技术，介绍文本风格迁移任务的形式化定义和论文涉及的理论与技术。

第三章：基于提示强化学习的文本风格迁移方法研究，详细介绍论文提出的提示强化学习方法、其在文本风格迁移任务中的应用，以及实验设计与结果分析。

第四章：基于指令增强的大模型风格迁移训练框架，介绍论文设计的基于要求引导的开源大模型训练方法、基于提示分析的上下文学习方法，及其在文本风格迁移任务中的优势，并给出实验验证结果与分析。

第五章：总结与展望。对本文的研究成果进行总结，并对未来研究方向和可能的改进方法进行展望。

第2章 相关理论与技术

文本风格迁移作为一类文本生成任务，体现模型对文本固有属性风格的理解与生成能力，在大模型的评估中也是一项十分重要的评估任务。本章首先对文本风格迁移任务作形式化定义，随后对论文所使用的各项理论技术，包括预训练语言模型、强化学习方法、提示学习与指令微调方法等进行介绍。

2.1 文本风格迁移

文本风格迁移任务的目标是在给定原始风格与目标风格的前提下，将用户提供的原始输入文本在保留其内容信息的同时，迁移至目标风格。针对现代汉语与文言文的复杂文本风格迁移任务，论文进行如下定义：

给定多个不同风格的非平行文言文与现代文的语料库（论文以文言文与现代文各一种风格为例）：文言文风格的语料库$D_c = \{x_i\}_{i=1}^{C}$，和现代汉语风格的语料库$D_m = \{x_i\}_{i=1}^{M}$，任务的目标是使用无监督的方法学习一个参数化函数f_θ，将具有原始风格s_{src}的句子x映射到具有目标风格s_{tgt}的流畅句子y，同时尽可能保留原始文本的内容，避免信息的错误和遗漏。风格迁移的方向可以是单向的，也可以是双向甚至多向的。

文本风格迁移任务的样例如图 2.1 所示。样例中，用户给定一句文本，要求机器分别把它迁移到金庸与琼瑶的写作风格，同时给出了相关风格的信息，而机器则根据用户的要求生成满足风格条件、同时不改变内容原意的文本。

文本风格迁移通常以预训练语言模型为训练骨架，采用的技术路线可分为风格与内容解耦、不对风格与内容进行解耦两类。考虑到论文 1.1.1 节中描述的现代汉语与文言文风格迁移任务的特性，论文使用非解耦的强化学习算法对语言模型进行训练。

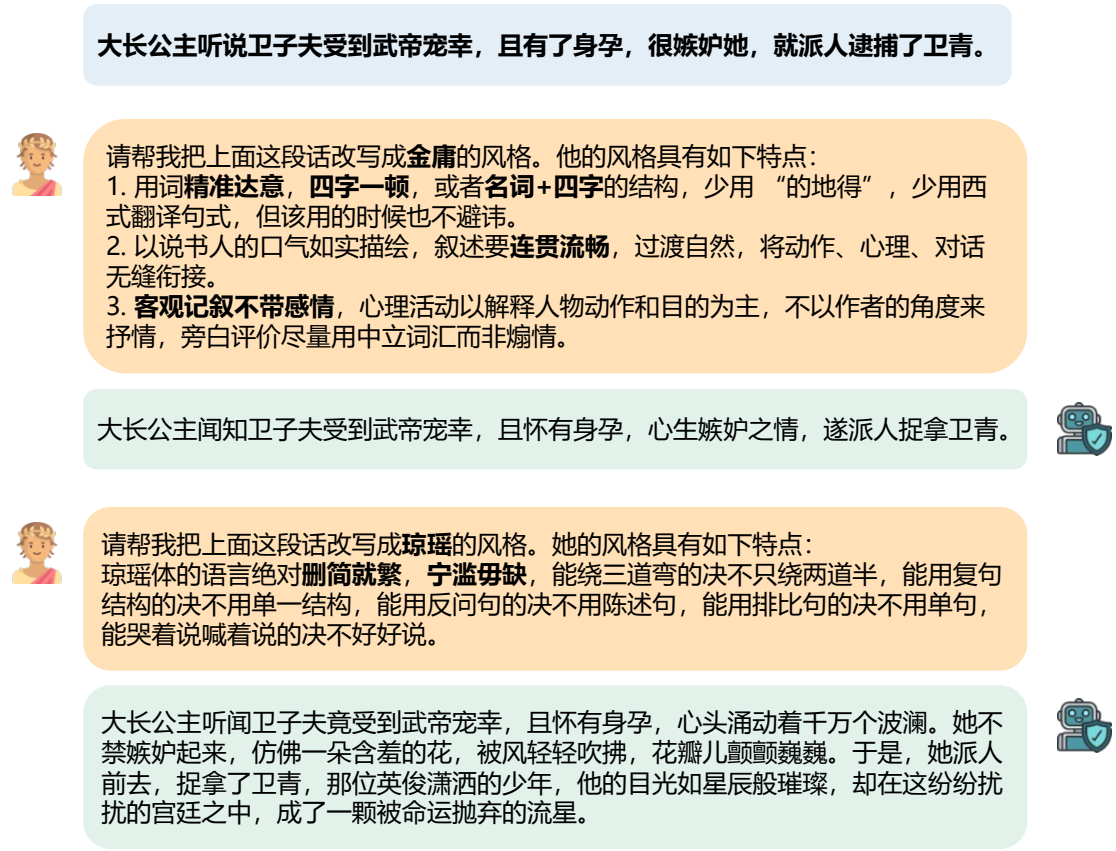


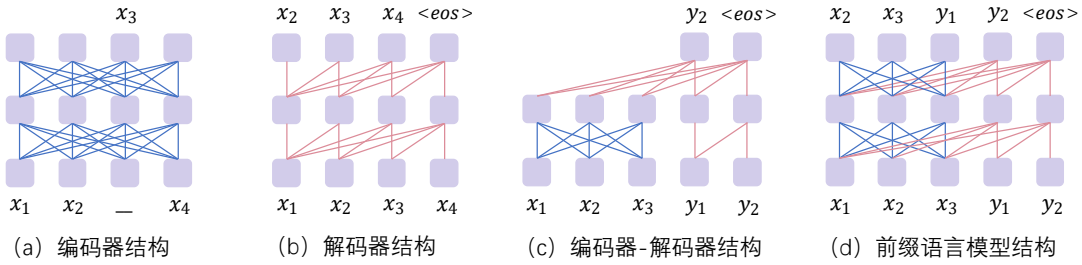
图 2.1 文本风格迁移任务的样例

2.2 预训练语言模型

对于自然语言处理中的文本风格表示与生成任务，早期研究主要采用循环神经网络（Recurrent Neural Network，RNN）的架构[19,61]。而随着 GPT[62]与 BERT[23]模型的陆续提出，自然语言处理领域从此进入预训练与微调的时代[63]，这些预训练语言模型所使用的 Transformer[64]架构也顺势成为最炙手可热的模型架构。Transformer 的核心构建模块是自注意力。自注意力机制是注意力的一种变体，通过将每个元素替换为其余序列的加权平均值来处理序列。最初的 Transformer 由编码器-解码器（Encoder-Decoder）架构组成，其目的是完成序列到序列（Sequence to Sequence，Seq2seq）任务。而近年来，越来越普遍的做法是使用由单个 Transformer 层堆叠而成的模型，依据不同下游任务的场景和需求采用不同形式的自注意力来生成适用于语言建模或分类和跨度预测任务的架构。Transformer 最初被证明在机器翻译方面非常有效，并在随后被广泛应用于各种 NLP 场景[65]。

现有的预训练语言模型均拥有类似的 Transformer 架构，它们依据模型的掩

码（Mask）结构可分为以下 4 种变体结构：编码器结构、解码器结构、编码器-解码器结构、前缀语言模型结构。前文提到，在 Transformer 中，自注意力操作接受一个序列作为输入，并输出相同长度的新序列，而输出序列的每个元素都是通过计算输入序列各个元素的加权平均值得到的。具体而言，设y_i表示输出序列的第i个元素，x_j表示输入序列的第j个元素，则y_i的计算公式为$\sum_j w_{i,j}x_j$。其中$w_{i,j}$是由自注意力机制产生的标量权重，是关于x_i和x_j的函数。而注意力掩码则用于将输入序列种的某些权重置零，从而限制在给定输出时间步中，当前位置的元素可以关注其它哪些输入元素。不同变体的结构图如图 2.2 所示。



（a）编码器结构　（b）解码器结构　（c）编码器-解码器结构　（d）前缀语言模型结构

图 2.2 Transformer 不同变体结构图

（1）编码器（Encoder）结构。编码器使用了“完全可见”的注意力掩码。完全可见的掩码允许自注意力机制在生成每个输出元素时关注输入的任何元素。编码器的结构如图 2.2（a）所示。这种掩码形式可以对整个输入序列进行关注，使模型学习更深层的双向上下文信息，因此，编码器结构的模型常应用于文本分类、文本表示等不需要因果时序关系，需要对文本抽取丰富表征的下游任务种。Bert[23]便使用了这种完全可见的掩码模式，并在输入中添加了一个特殊的“分类”标记。与该分类标记对应位置的输出用于对整个输入序列进行分类预测。

（2）解码器（Decoder）结构。解码器用于自回归地生成输出序列。在每个输出时间步，模型从预测分布中采样一个标记，并将该样本反馈到模型中，以生成下一个输出时间步的预测。因此，解码器可以作为一类用于下一步预测的语言模型（LM）使用。这种在自注意力操作中，限制模型在当前时间步只能获取其前序序列信息的掩码方式叫做因果掩码。在生成输出序列的第i个元素时，因果掩码会阻止模型关注输入序列的第$j(j > i)$个元素，以确保模型在生成输出时无法“预知未来”。架构的示意图如图 2.2（b）所示。

语言模型通常用于压缩或序列生成，它也可以在文本到文本框架中简单地通

过连接输入和目标来使用。例如，对于将汉语翻译为英语的任务中：如果有一个训练数据，输入句子为“*那很好。*”，目标为“*That is good.*”，那么只需在进行前缀连接的输入序列“*translate Chinese to English: 那很好。target: That is god.*”上进行下一步预测的模型训练。而如果想获得该示例的模型预测结果，则可以提供前缀“*translate Chinese to English: 那很好。target:*”，语言模型便能够自回归地生成后续序列。通过这种方式，模型可以根据输入预测输出序列，满足文本到文本任务的需求。

（3）编码器-解码器（Encoder-Decoder）结构。编码器-解码器结构的Transformer即是原始版本的Transformer结构，它由编码器和解码器两个不同的模块堆叠组成：编码器接收输入序列，而解码器生成新的输出序列。编码器-解码器结构的模型同时具有编码器与解码器的优点，一方面在生成输出序列时能够遵循因果时序的原则，另一方面，又可以对完整的前缀序列上下文进行编码。这种架构变体的示意图在图2.2（c）中展示。论文第3章中所使用的MT5模型采用的就是编码器-解码器结构。

（4）前缀语言模型（Prefix LM）结构。解码器结构会对前缀序列进行因果预测的缺点，可以通过改变模型的掩码模式来避免：模型不再对序列的所有位置使用因果掩码，而是在序列的前缀部分使用完全可见的掩码。这种掩码模式以及由此产生的“前缀LM”的示意图在图2.2（d）中进行说明。在论文2.2.2提到的示例中，完全可见的掩码将应用于前缀“*translate Chinese to English: 那很好。target:*”，而因果掩码将在训练过程中用于预测目标“*That is good.*”。前缀LM与BERT架构之间的主要区别在于分类器仅集成到前缀LM的Transformer解码器的输出层中[65]。

2.3 强化学习方法

强化学习是智能体（Agent）通过与环境进行交互，在不断的试错中优化策略算法的训练方法。强化学习的核心思想是通过学习策略来实现回报的最大化或达成特定目标，其本质是由五元组$(\mathcal{S},\mathcal{A},\mathcal{P},\mathcal{R},\mathrm{P}(s'|s,a))$构成的马尔可夫决策过程：

（1）状态（State）：表示智能体在某一时刻所处的环境状态。状态空间通常用符号集合$\mathcal{S}$表示。

（2）动作（Action）：智能体在某一状态下可以执行的操作。动作空间用符号集合$\mathcal{A}$表示。

（3）策略（Policy）：策略函数$\pi(s)$描述了在状态s下应该选择的动作a。强化学习的最终目的是最优化策略函数，以最大化价值函数。

（4）奖励（Reward）：奖励函数$R(s,a)$表示在状态s下采取动作a后获得的即时奖励。奖励可以是正数、负数或零。

（5）状态转移概率（Transition Probability）：状态转移函数$P(s'|s,a)$描述了在状态s下采取动作a后，系统转移到状态s'的概率。

贝尔曼方程是强化学习的基础和核心。它描述了最优策略的行为价值函数和状态价值函数之间的关系：

状态价值函数（State Value Function）$V_\pi(s)$表示从当前状态s开始，按照策略π执行动作，系统所获得的累积回报的期望。具体形式如公式（2-1）所示：

$$V_\pi(s) = \mathbb{E}_\pi\left[\sum_{k=0}^{\infty} G_t \mid s_t = s\right] \tag{2-1}$$

其中，t是时间步，G_t是智能体采取当前动作后未来可能获得的长期回报：

$$G_t = \gamma^k R_{t+k+1} \tag{2-2}$$

其中，R_{t+1}表示从状态s_t转移到状态s_{t+1}时获得的回报，$\gamma \in [0,1]$是折扣因子。

动作价值函数（State-Action Value Function，又称 Q-Function）$Q_\pi(s,a)$表示在状态s下采取动作a后，按照策略π执行动作，系统所获得的累积回报的期望。具体形式如公式（2-3）所示：

$$Q_\pi(s,a) = \mathbb{E}_\pi[\, G_t \mid s_t = s, a_t = a\,] \tag{2-3}$$

动作价值函数与状态价值函数之间的关系为：

$$V_\pi(s) = \sum_{a\in\mathcal{A}} \pi(s,a) Q_\pi(s,a) \tag{2-4}$$

依据贝尔曼方程，可以通过最大化价值函数学习最优策略。

强化学习方法可以分为两大类：基于模型和无模型的强化学习方法。无模型的强化学习算法不会对环境进行建模。它们直接根据与环境交互产生的数据（状态、动作、奖励等）来寻找最佳策略。常见的无模型算法包括：值函数方法（Value-Based），它通过估计状态值函数或状态-动作值函数来优化策略；策略梯度方法（Policy-Based），它直接优化策略，通常使用梯度上升法；Actor-Critic 方法，该

方法结合值函数和策略梯度，同时更新策略和值函数。而基于模型的强化学习算法通过对环境建立模型来理解环境。智能体可以在模型中预测下一步的状态和奖励，然后找出最佳策略。常见的基于模型的算法包括：计划方法（Planning），它使用环境模型进行规划，例如动态规划和蒙特卡洛树搜索；模型预测控制（Model-Predictive Control），它在每个时间步骤中，使用环境模型来优化策略。论文所使用的强化学习算法是蒙特卡洛采样的策略梯度算法。

策略梯度算法是强化学习算法中备受关注的方法，为解决复杂问题提供了新的思路。与基于价值的强化学习方法不同，策略梯度算法直接关注策略的优化，通过调整策略参数以最大化累积奖励。这种方法的优点在于能够处理连续动作空间，尤其在动作维度高、离散动作难以表示、或不存在明确的动作选择依据时具有显著优势。

策略梯度类的算法通过梯度计算来更新策略网络的参数。因此，目标函数直接设计成期望累积奖励。这个期望值可以有多种表达方式，对应着不同的具体算法对损失函数的不同计算方法。累积奖励的期望值无法直接计算，需要采用蒙特卡洛方法，多次采样取近似的平均值。每次采样都会生成一个轨迹（Trajectory）。在不断迭代运行中，获取了大量的轨迹后，使用一定的变换和近似去计算累积奖励，作为用于梯度更新的损失函数。

2.4 提示学习与指令微调方法

提示学习与指令微调方法在自然语言处理（Natural Language Processing，NLP）领域中具有重要意义，有助于提高大型语言模型的泛化能力，极大增强了大模型的零样本与少样本学习能力。

（1）提示学习（Prompt Learning）

提示学习是一种利用预训练模型的知识来指导下游任务的方法。它通过为模型添加额外的文本或代码提示，使其更好地理解特定任务或领域。这些提示通常包括问题、任务描述或预定义的文本片段，用于引导模型生成合适的文本结果。提示学习依据提示的类型可分为两类：硬提示与软提示。其中，硬提示指人能看懂的自然语言提示，这类提示通常需要进行人工撰写，或是使用模型生成自然语言文本，与模型的输入拼接在一起，作为最终的输入文本；软提示则是需要进行额外训练的向量序列，拼接在模型的词嵌入层以及每个 Transformer 块的输入层

前端，通过 P-tuning[58]、Prefix-tuning[56]等方式对软提示序列进行训练，整个提示序列对人来说是不可读的。论文主要研究硬提示学习。硬提示的构造过程称为提示工程，提示工程可分为提示构造、答案构造、答案与标签映射三部分。

①提示构造（Prompt Construction）。在提示学习中，第一步是进行模板的设计，模板中通常包含输入槽和答案槽。输入槽用于接收原始输入，而答案槽用于生成答案。例如，对于情感分类任务，可以设计以下模板：

“[X]总体来说，这是一部[Z]的电影。”

在这个模板中，[X]是输入槽，答案槽[Z]用于生成情感极性的答案。具体实验中，可以将原始句子代入输入槽[X]中，然后根据提示生成答案[Z]。

②答案构造（Verbalizer Construction）。答案构造阶段将提示与预训练模型结合，生成对应的答案。这个过程可能包括补全句子、填空或其他形式的文本生成。

③答案与标签映射（Verbalizer-Label Mapping）。最后，生成的答案需要映射到输出的标签或文本。例如，对于情感分类任务，可以将生成的情感极性映射到“正面”或“负面”。

构建完合适的提示模板后，可以进行答案预测。在实际应用中，通常需要对模型进行微调，以适应特定下游任务的要求。

（2）指令微调（Instruction Tuning）

指令微调是一种针对大型语言模型进行优化的技术。它的目的是将通用预训练模型转变为专用模型，以弥合通用模型与特定应用需求之间的差距，确保语言模型更贴近人类的期望。

大型语言模型的预训练是通过预测当前序列的下一个词来进行的。虽然这样的预训练可以保存很多知识，但是在实际应用中，由于未能与人类的意图与指令对齐，模型可能无法充分利用这些知识来回答特定问题。例如，训练语料中的知识大多是陈述句，而实际问题可能是疑问句或需要推理的复杂问题。因此，需要指令微调来挖掘大型语言模型的潜力。

在指令微调中，首先需要构建符合指令格式的实例，然后以有监督的方式对大模型进行微调。指令格式通常包含任务描述、输入、输出、示例等部分：任务描述负责描述模型需要完成的任务，例如“*请回答以下问题：*”；输入则提供给定的问题或文本，例如“*中国的首都是哪个城市？*”；输出为期望的答案，例如“*中国的首都是北京*”；而示例指令可以帮助模型理解任务，例如：“*请将英文翻译为*

中文，输入示例：The capital city of China is Beijing，输出示例：中国的首都是北京。请翻译：Which city is the capital of US?”，回答：“*美国的首都是哪个城市？*”。现有研究表明，提供示例的上下文学习能够增强模型的泛化能力，使模型更好地完成指令要求[66]。

指令微调可以帮助大模型拥有更好的推理能力，从而展现出卓越的泛化能力，能够完成未见过的任务。即使微调的指令中没有设计相关的任务，大型模型在新任务上的表现也会优于微调之前[67]。

2.5 本章小结

本章首先对文本风格迁移任务进行形式化定义，使用符号、文字与图像语言对现代文与文言文的文本风格迁移任务进行进一步的解释说明。随后对论文用到的各类理论与技术进行详细阐述与说明。首先，对领域内的四类常见的预训练语言模型结构进行介绍，分析各类模型结构的优缺点。其次，对论文第 3 章涉及的强化学习技术进行概述，并对其中的各类算法进行简要说明。最后，对论文第 3 章、第 4 章使用的提示学习与指令微调技术进行介绍。

第3章 基于提示强化学习的文本风格迁移

文本风格迁移任务旨在针对给定的目标风格，保留内容的同时自动调整文本的风格属性。在缺少足够计算资源的情况下，利用小模型在无监督场景下进行文本风格迁移任务，尽可能弥补其与大模型之间的差距是一项挑战。因此，本章以小模型为基础展开研究。作为一种复杂文本风格迁移任务，现代汉语与文言文的风格与文本内容高度耦合，难以找到标志性的风格关键词，而基于解耦策略的模型无法准确将文本的风格隐向量与内容隐向量分离。目前已有的非解耦方法在缺少平行语料的情况下，难以平衡风格迁移准确度、内容保留完整度、语言流畅度三者的关系。针对以上难题，论文提出基于提示强化学习的文本风格迁移算法，避免内容与风格的解耦，通过奖励工程设计奖励函数，从风格、内容、流畅性三个维度进行平衡，提升算法的可解释性。

3.1 引言

传统的文本风格迁移任务重点着眼于情感迁移、礼貌性用语迁移等简单风格迁移场景。在这些简单场景下，风格特征与传递内容信息的文本泾渭分明，只需要找出代表风格的标志词，再找到契合的目标风格标志词进行替换，即可完成简单文本风格迁移操作，而在此过程中，源文本的绝大多数词语不需要做出任何改变。然而，由于用户对自动化文本风格迁移的需求愈发多样化与复杂化，现有研究对应用场景的过度理想化、简单化与用户实际的复杂需要构成了该领域的重要矛盾，阻碍了文本风格迁移领域的发展与现实运用。简单文本风格迁移任务与复杂文本风格迁移任务的对比样例如表 3.1 所示。论文面向复杂文本风格迁移任务，以现代汉语与文言文的风格迁移为例进行探索。

现有的文本风格迁移研究主要采用风格与内容解耦的方法，分别学习风格嵌入与内容嵌入，再将目标风格嵌入与输入文本的内容嵌入融合，生成最终的风格迁移文本[6,32,33,68]。在风格清晰且易于与文本内容分离的简单文本风格迁移场景中，这类研究只需要探索更丰富、更充分的风格表示方法，与输入文本内容进行融合即可得到非常优秀的结果。然而，面对复杂的文本风格迁移场景，风格与内容进行彻底解耦的难度非常高，能否将风格属性与文本内容彻底分开仍然尚无明

确的答案[34]。针对更契合现实应用需求和现实应用场景的复杂文本风格迁移任务，目前仍没有很好的办法将复杂风格与文本内容彻底解耦。

表 3.1 简单与复杂文本风格迁移任务的对比

情感迁移（简单文本风格迁移任务）	
Positive（积极情感）	The service is **very poor**.（这里的服务**很差劲**。）
Negative（消极情感）	The service is **pretty good**.（这里的服务**非常好**）
修辞与幽默性迁移（复杂文本风格迁移任务）	
Metaphor（隐喻）	I entered the theater **in the bloom of youth and emerged with a family of field mice living in my long, white mustache**.（我在**青春年少的时候**走进剧院，**出来的时候，有一群田鼠住在我又长又白的胡子里**。）
Straight forward（直白）	The movie was **very long**.（这部电影**非常长**）

而目前的非解耦方法则面临如下挑战：间接的迁移优化策略难以在风格迁移度、内容完整度、语言流畅度三者间达到较好的平衡；设计的优化策略容易受到对抗样本攻击的影响导致优化方向错误，造成训练缺乏鲁棒性；模型的训练效果显著受到外部辅助模型质量的制约、可能需要额外的上下文语料或平行语料等。

为了解决上述问题，论文提出基于提示强化学习的复杂文本风格迁移算法（Prompt Based Reinforcement Learning for Text Style Transfer，PBRL），算法包括两个模块：基于提示的模型热启动算法与基于多维信号反馈的强化学习算法。算法的整体框架如图 3.1 所示。基于提示的模型热启动算法可以缓解强化学习训练过程中广泛存在的训练过程不稳定、非常依赖模型参数初始化和超参数调整的问题。面对缺少平行语料的无监督学习场景，首先通过“同义词表映射”建立粗精度的伪平行标注文本。随后使用伪平行标注文本对初始的 Seq2seq 模型进行粗精度的微调，为下一阶段的强化学习策略模型提供热启动，避免因为初始状态太差导致奖励函数模型处理分布外数据，导致错误的奖励评分，进而影响优化方向。基于多维信号反馈的强化学习算法则针对目前研究中常见的错误生成结果，指向性地构建三类奖励函数，从风格迁移准确性、内容保留完整性、文本语言流畅性三个维度引导模型训练，提升模型的迁移性能。

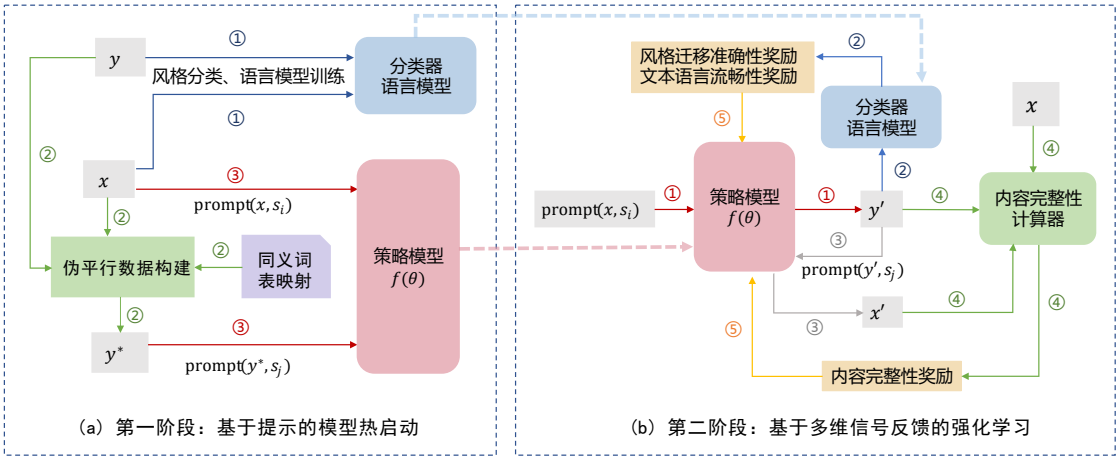


图 3.1 基于提示强化学习算法的整体框架图

3.2 基于提示的模型热启动算法

模型的热启动是整个 PBRL 模型的第一步，其目标是在缺少高质量平行语料的无监督学习情境下，构建相对粗精度的伪平行标注文本，进行初步的风格迁移微调，使得强化学习的训练过程更稳定。模型的热启动总共包括两个部分：伪平行语料的构建，以及基于提示的风格迁移微调。

3.2.1 伪平行语料构建方法

对于强化学习算法而言，策略模型的初始化状态直接影响到训练的优化进程和鲁棒性，因此，确保模型在强化学习之前经过有效且充分的微调至关重要。然而，如何构建具有高质量的伪平行语料库仍然是一个挑战。虽然现代汉语与文言文的风格文本存在语义的相关性，但论文在前期实验中发现，一方面由于预训练数据的限制，另一方面由于古代汉语和现代汉语的措辞和语法结构存在差异，现有的汉语预训练模型都未能够实现在现代汉语与文言文之间较好的语义对齐。

虽然缺乏平行语料数据，但考虑到领域内存在大量的古汉语字典，论文使用词典网[1]中收录的文言文同义字字典，使用 TF-IDF 算法筛选出约 3800 个同义词构建文言文与现代汉语的同义词表作为外部知识库，通过“同义词表映射”方法，对文言文文本进行映射替换。随后使用 ChatGPT 改写文本，使映射后的文本更流畅、更符合现代汉语的语序，通过这种方式，促进文言文与现代汉语文本之间

[1] https://www.cidianwang.com/guhanyu/

的语义对齐。得到改写文本后，论文使用词移距离（Word Mover's Distance，WMD）[69]对映射改写后的文本进行语义相似度匹配，得到粗精度的伪平行文本对。

WMD 是一种衡量文本之间相似性的距离函数，可以使词嵌入从句子的局部共现中学习到语义上有意义的单词表示。具体而言，WMD 衡量了两个文本之间的不相似性，即一个文档中嵌入的单词达到另一个文档中嵌入的单词所需要“移动”的最小距离。

给定一句文言文风格文本s_m和现代汉语风格文本s_n，对于s_m中的任意词向量w_i $(0 < i < \text{len}(s_m))$和$s_n$中的任意词向量$w_j$ $(0 < j < \text{len}(s_n))$，它们之间的词移距离是$w_i$和$w_j$之间的欧氏距离：

$$c(i,j) = \left\| w_i - w_j \right\|_2 \tag{3-1}$$

设n是词表大小，$T \in \mathbb{R}^{n \times n}$是两个文本的稀疏词流矩阵，$T_{ij}$表示$s_m$中的词向量$w_i$转换到$s_n$中的$w_j$所需的操作数。当将词$w_i$转移到$w_j$时，$w_i$的流出总和恒等于它在句子$s_m$中的词频权重$d_m$，即$\sum_j T_{ij} = d_m$；而$w_j$的流入总和恒等于它在$s_n$中的词频权重$d_n$，即$\sum_i T_{ij} = d_n$。由此，可得两个句子之间的词移距离：

$$\text{WMD}(s_m, s_n) = \min_{T \geq 0} \sum_{i,j=1}^{n} T_{ij} \cdot c(i,j) \tag{3-2}$$

将词移距离求倒并归一至[0,1]区间内，即可得到两个句子之间的词移相似度。若两个句子s_i, s_j的词移相似度满足公式（3-3）的条件，则可认为s_i, s_j是伪平行文本对：

$$\begin{cases} \text{WMD}(s_i, s_j) = \max\limits_{s_j \in C^T} \text{WMD}(s_i, s_j) \\ \text{WMD}(s_i, s_j) > \varepsilon \end{cases} \tag{3-3}$$

其中，C^T表示目标风格语料库，ε表示人为设定的词移相似度阈值。

3.2.2 基于提示的风格迁移微调

得到伪平行标注数据后，论文使用基于提示的风格迁移微调对模型进行热启动。考虑到输入文本和目标文本具有相同的内容和相似的词汇，原始输入文本相对于输出文本，可看作是打乱词语顺序和词语替换之后的噪声输入。在这种视角下，文本风格迁移的过程可以视为经过去噪处理，最后生成目标风格文本的过程。

而提示学习（Prompt Learning）的核心在于引导模型使用预先构建的模板生

成指定类别或任务的文本，将所有 NLP 中的任务统一为生成任务，减少对训练过程中数据的依赖。因此，论文由提示模板来锚定原始输入文本和目标输出文本的风格要求，避免构建多个不同迁移方向、结构完全相同的对偶模型，一方面减少模型的结构冗余，另一方面避免因为对偶模型性能上的差距造成的迁移奖励存在偏差的情况。论文设计的两种类型的提示函数如公式（3-4）所示，其中，[X]表示需要注入的原始输入文本x。不同的提示前缀使得模型可以在两个方向上完成风格迁移。

$$\text{prompt}(x, c_i) = \begin{cases} \text{将下面这段话改写成白话文风格：\n[X],} & i = 0 \\ \text{将下面这段话改写成史记风格：\n[X],} & i = 1 \end{cases} \tag{3-4}$$

模型的最大似然损失定义为：

$$L_{MLL} = -\log \mathrm{P}(\mathrm{F}(y_{1:n}|x_{1:m})) = -\sum_{\mathrm{t}=1}^{\mathrm{n}} \log \mathrm{P}(\mathrm{F}(y_t|y_{1:t-1}, x_{1:m}, c_i)) \tag{3-5}$$

其中，c_i表示两种迁移的风格方向，$\mathrm{F}(\cdot)$表示提示注入函数。

3.3 基于多维信号反馈的强化学习算法

尽管上述提到的微调算法在训练过程中能够使生成的句子逐渐趋近伪平行目标句子，但由于两句伪平行文本对的表述内容通常难以完全一致，缺失或多余的文本内容会为迁移学习引入噪声，增加学习的难度，进而导致其内容一致性的不足。另一方面，仅仅通过最大似然损失对模型进行优化，从而间接地学习文本的风格特征、进而完成迁移任务，容易导致模型生成结果的风格迁移不充分，无法达到风格迁移的目的。

为了解决这些难题，论文将离散文本的风格迁移优化问题形式化为一个多维信号反馈的强化学习问题。在这个模式中，生成模型根据策略$\pi(y_t|y_{<t}, x, c)$逐一选择当前时间步的词语$[y, \dots, y_T]$，来最大化奖励$R(y, x, c) = R(\mathrm{P}(x, c), x, c) = \pi(y_t|y_{<t}, x, c)$。在时间步$t$，生成模型接收先前的生成文本$y_{<t}$，并根据策略生成下一个词语$y_t$。当生成模型完成整个生成过程后，它会获得任务奖励$R(y, x, c)$。将策略生成模型参数定义为$\theta$，则上述风格迁移任务可重新表述为：

$$\max_{\theta} R(\hat{y}, x, c), \hat{y} \sim \prod_{t=1}^{T} \pi_\theta (y_t|y_{<t}, x, c) \tag{3-6}$$

与解耦算法和其他非解耦算法相比，基于强化学习的非解耦方法具有的一个关键优势是，不需要在模型内部隐式地对风格表示、内容表示进行建模，而是将其视作一个黑盒，利用预先训练好的外部打分模型，依据评分对文本的风格、内容与流畅度进行直接优化。一方面，强化学习方法能够通过奖励信号对文本空间实施更有效的指向性探索；另一方面，从策略网络中随机采样来探索文本空间也带来了更大的灵活性。

由于在一个句子生成完之前，很难去界定它的风格特征以及内容是否表述完整、语言表达是否流畅，论文采取在线策略梯度的方式，在每一个句子生成结束后累积当前所有时间步的奖励信号和梯度，同步更新所有的时间步参数。

3.3.1 奖励工程设计

奖励工程指在设计强化学习算法的时候，对其中的奖励函数进行设计，力求找到最合适于当前训练需求的奖励函数，而奖励函数直接决定了训练过程的方向。进行合适的奖励工程设计对于算法训练的效率以及算法的成功优化都起着至关重要的作用。而复杂文本风格迁移任务需要从风格、内容、流畅度三个维度优化模型，对奖励工程提出了更高、更复杂的要求。而复杂的奖励函数也会导致奖励信号的不稳定与脆弱性，例如容易被对抗样本攻击导致错误的奖励反馈，进而整个训练过程与训练方向的不稳定，导致最后的优化失败。

为了解决这些问题，论文设计三个奖励函数，分别对标风格迁移准确性、内容保留完整性、文本流畅性三个维度的要求，同时采取 z-score 标准化以及差值奖励等措施来增强算法的鲁棒性和训练效率。

（1）风格迁移准确性奖励

为了提升训练的稳定性，同时减少训练的资源消耗，论文使用预先训练的风格分类器作为风格迁移准确性的打分模型。使用无标签的两个不同风格语料库，对风格标注后训练一个分类器CLS_{φ}。训练完成后，分类器的参数将被冻结，用于为强化学习过程中采样生成的文本进行风格打分。

不同于现有研究采用生成文本的累计风格准确率或是正确风格的对数概率作为文本的风格迁移准确性评分，论文采用概率差值作为基础奖励，鼓励策略模型生成不仅风格正确、而且风格正确概率大的文本序列。这样能够尽可能避免论文 3.1 节中提到的对抗样本对风格准确性打分造成的错误影响，同时也可以减小

由于随机采样造成的文本序列是分类器的分布外样本，导致的分类错误的影响。具体的风格迁移准确性奖励函数如公式（3-7）所示：

$$R_{cls} = \mathrm{P}_{\varphi}(c) - \max_{c' \neq c} \mathrm{P}_{\varphi}(c') \tag{3-7}$$

其中，c表示目标迁移风格，c'表示原始输入风格，$\mathrm{P}_{\varphi}(c) = \mathrm{P}_{\varphi}(c|\hat{y}) = \mathrm{P}_{\varphi}(c|\mathrm{P}_{\theta}(x, c'))$表示策略模型生成的由输入文本迁移到目标风格的句子$\hat{y}$是目标风格$c$的概率。

（2）内容保留完整性奖励

虽然在上文 3.2.1 节中已经构建了伪平行标注文本，但是伪平行文本的标注准确度相对较低，已经无法满足强化学习过程中对应的高精度需求，因此，论文借鉴了回译的思想，采用对偶循环生成的架构，来评判生成文本的内容保留完整性：

令原始风格为c，目标风格为c'，从c风格迁移到c'风格，采用随机采样策略生成的文本为$\hat{y}$，再将$\hat{y}$使用贪婪策略反向迁移回原始风格c，得到文本$\hat{x}$。若$\hat{y}$在迁移的过程中保留了完整无偏差的内容信息，那么它再对偶地反向迁移回原始风格得到的$\hat{x}$应与原始文本x相似。基于这种思想，可以得到内容保留完整性奖励：

$$R_{con} = \mathrm{P}_{\theta}(x|\hat{y}, c), \hat{y} \leftarrow \mathrm{P}_{\theta}(\hat{y}|x, c') \tag{3-8}$$

（3）文本语言流畅性奖励

在监督学习中，文本的语言流畅性通常只需要在标注数据上优化最大似然损失即可获得流畅自然的文本。然而，大部分的文本风格迁移场景是缺少高质量的标注文本的。因此，与风格迁移准确性奖励相似，论文额外训练现代汉语与文言文的语言模型$LM_{\delta 0}$、$LM_{\delta 1}$，通过计算生成文本$\hat{y}$在语言模型上的困惑度（Perplexity，PPL），作为语言流畅性的信号。具体的文本语言流畅性奖励定义为：

$$\mathrm{PPL}(\hat{y}) = \begin{cases} \mathrm{PPL}_{\delta 0}(\hat{y}), & c = 0 \\ \mathrm{PPL}_{\delta 1}(\hat{y}), & c = 1 \end{cases},$$

$$R_{ppl} = L_2 Norm(\frac{1}{\mathrm{PPL}(\hat{y})}) \tag{3-9}$$

其中，$L_2 Norm$表示 L2 范式归一化。而 PPL 的计算方式为：

$$\mathrm{PPL}_{\delta}(\hat{y}) = 2^{J},$$

$$J_{\delta} = -\sum_{j=1}^{|V|} \hat{y}_j \times \log(\hat{y}_j) \tag{3-10}$$

将三种奖励函数进行 z-score 标准化，可以增强训练的稳定，减小奖励信号偏差，使得不同的奖励函数落入同一个区间范围内，即：

$$z-score\big(R(x,c)\big) = \frac{R(x,c) - mean\big(R(x,c)\big)}{\mathrm{std}\big(R(x,c)\big)} \tag{3-11}$$

最后，得到整体的奖励函数：

$$R = \alpha \cdot R_{cls} + \beta \cdot R_{con} + \gamma \cdot R_{ppl} \tag{3-12}$$

其中，α、β和γ分别是三种奖励函数的权重。

3.3.2 策略梯度优化算法

由于在一个句子生成完之前，很难去界定它的风格特征是否准确、内容是否表述完整、以及语言表达是否流畅，论文采取在线策略梯度的方式，在每一个句子生成结束后累积当前所有时间步的奖励信号和梯度，同步更新所有的时间步参数。虽然这种方式可能导致参数无法及时在每个时间步更新，但是在缺少足够数据的情况下能够有效减少错误的累积，使训练过程更加稳定。

论文使用蒙特卡洛采样法来近似生成文本的奖励期望，使用在线策略梯度的方式，优化模型参数：

$$\begin{aligned}\nabla \mathbb{E}_{\theta}(R) &= \sum_{k} R_k \cdot \nabla \mathrm{P}_{\theta}(y_k|x,c) \\ &= \sum_{k} R_k \cdot \mathrm{P}_{\theta}(y_k|x,c) \cdot \nabla \log \mathrm{P}_{\theta}(y_k|x,c) \\ &\cong \frac{1}{K}\sum_{k=1}^{K} R_k \cdot \nabla \log \mathrm{P}_{\theta}(y_k|x,c)\end{aligned} \tag{3-13}$$

3.4 实验对比与分析

本节从实验数据集、对比的基准模型、论文设计的算法所使用模型的训练环境与参数设计、评价指标、实验结果与分析等 5 个方面介绍实验的设计细节和结果分析。

3.4.1 实验数据

复杂文本风格迁移是一个新兴的研究任务，目前缺少公开的数据集，现代汉语与文言文的文本风格迁移任务也面临同样的困境。因此，论文选择在文言文语料中被誉为“无韵之离骚”的风格特征鲜明的《史记》，同时在各大古诗文网站上爬取不同的《白话史记》版本，通过数据的清洗，最终收集成《白话史记》与《史记》的无监督风格迁移数据集。其中，测试集和验证集进行了人工标注对齐，训练集则是无标注的非平行语料。数据集的具体统计信息如表 3.2 所示。

此外，为了进一步验证论文提出算法的有效性和泛化性，论文也在文本风格迁移领域知名的情感迁移数据集 Yelp[5]上进行实验。

表 3.2 《白话史记》与《史记》无监督数据集统计信息

风格类别	数据子集	样本数量	数据样例
史记	训练集	18380	孔子曰：“丘未得其志也。”
	验证集	6127	取人之有，以自为宝，是不彊乎？
	测试集	6127	太后不食，日夜泣不止。
白话史记	训练集	18391	六年的春天，秦缪公率领军队讨伐晋国。
	验证集	6127	高祖心里非常高兴。
	测试集	6127	太尉周勃进见说：“希望单独跟你说话。”

3.4.2 基准模型概述

由于论文研究的是一个相对较新的领域，缺乏公开数据集和相应的榜单，因此论文以近年拥有公开源码的先进研究工作作为基准模型，与论文提出的算法进行比较。

（1）DualRL[36]：DualRL 是包含两个对偶生成模型的强化学习训练框架。其中生成模型是 6 层的 Seq2seq Transformer，奖励函数是由额外训练的分类器 TextCNN 进行风格准确率奖励和对偶内容重建奖励。

（2）NAST[41]：NAST 使用非自回归模型，先对输入文本进行原始文本与目标的单词级对齐，随后使用非自回归模型根据对齐后的文本生成迁移结果。

（3）TAG[70]：TAG 分为标注器和生成器。标注器负责将需要修改的字词标

注出来，而生成器负责对标注器标注出的需要修改的字词进行修改。

（4）RACoLN[71]：RACoLN 使用重建损失隐式地移除文本中的风格从而得到文本的内容表示，同时使用条件层归一化构建与内容相关的风格表示，二者融合得到目标文本。模型的编码器与解码器均采用带有注意力的单层 GRU 结构。

（5）GPT-3.5-turbo（ChatGPT）[2]：它是 OpenAI 开发的一个闭源的大语言模型，具有行业领先的性能。

3.4.3 模型训练详情

论文使用 PyTorch[3]与 Transformers[4]框架，生成模型使用修改后的 MT5-Base，并在此基础上修改了词表与词嵌入大小以及最顶端的 LM-head，只保留了汉语的和 48 个特殊哨兵词嵌入。蒙特卡洛采样过程选择基于 Top-P 与 Top-K 采样法对生成的词语进行随机采样。风格分类器在 Bert-Chinese-base[5]的基础上进行微调，用于计算困惑度的语言模型则采用 GPT2-Chinese-Cluecorpussmall[6]和 GPT2-Chinese-Ancient[7]进行微调。具体的超参数如表 3.3 所示。

表 3.3 基于提示强化学习算法的超参数

超参数	取值
风格迁移准确性奖励权重α	0.35
内容保留完整性奖励权重β	0.35
文本语言流畅性奖励权重γ	0.3
学习率	1e-5
Batch 大小	48
词移相似度阈值ε	0.6

3.4.4 评价指标

论文主要从三个维度评价模型的有效性：风格迁移准确率、内容保留完整性、文本语言流畅性。其中，风格迁移准确率采取与风格迁移奖励函数类似的方式，

[2] https://openai.com/chatgpt
[3] https://pytorch.org/
[4] https://github.com/huggingface/transformers
[5] https://huggingface.co/google-bert/bert-base-chinese
[6] https://huggingface.co/uer/gpt2-chinese-cluecorpussmall
[7] https://huggingface.co/uer/gpt2-chinese-ancient

通过外部训练的风格分类器进行评判；内容保留完整性则通过 BLEU-4 进行计算；文本语言流畅性通过外部训练的语言模型计算文本的困惑度。评价指标后方的箭头（↑和↓）指向了该指标更理想的方向。

（1）风格分类器准确率（Accuracy，ACC）↑：准确率评判的是所有预测正确的正负类样本所占的比重。由于测试集中不同风格的样本数比重均衡，采用准确率对风格迁移的程度进行评判是合理的。

（2）内容保留完整性 BLEU-4↑：BLEU-4 是文本风格迁移领域最广泛使用的指标之一，通过测试集中给定的参考文本，计算 1-Gram 到 4-Gram 的累积评分，来评判生成文本与参考文本的一致程度。

（3）文本困惑度（Perplexity，PPL）↓：困惑度是评价文本生成任务中语言流畅度的常用指标之一，用于计算生成的文本在语言模型上的概率，语言模型对生成文本的困惑度越低，代表该文本在语言模型上生成得更流畅。

3.4.5 实验结果与分析

本节对第 3 章中设计的算法的实验结果进行介绍与分析，实验分为四部分：伪平行语料构建结果分析、基于多维信号反馈的强化学习算法结果分析、消融实验结果分析和模型在简单文本风格迁移任务上的测试结果分析。

（1）伪平行语料构建结果分析

通过同义词表映射后的文本匹配结果样例如表 3.4 所示。由结果分析可知，将文言文中的关键词替换为现代汉语的同义词后，文言文与现代汉语句对之间的同义文本匹配度平均提升了 0.138，增强了伪平行标注语料的准确性。

从样例文本中可见，若两句话本身是语义对齐的，那么经过映射替换、以及 ChatGPT 的流畅度改写后，文本的相似度均有提升，原先低于阈值 0.6 的正确匹配文本基本能够达到阈值以上；而若是两句话本身是错误匹配的，那么经过映射替换和改写后，文本的相似度更倾向于下降。

该方法从直观上分析，也与人类学习的模式相似：在学习文言文的过程中，需要查阅古汉语字典，学习重难点词汇和生僻字的对应意思，然后才能更好地理解文言文的涵义。论文提出的算法也是基于这个思路，通过外部词表知识的映射与替换关系，有效改善了匹配过程中模型对文言文重难点词汇的理解能力，从而提升匹配的准确度。

表 3.4 同义词表映射结果样例

目标匹配文本：秦始皇七年，庄襄王的**母亲**夏太后**去世。**		
文本类型	文本内容	目标相似度
原始文本	始皇七年，庄襄王**母**夏太后**薨**。	0.727
映射后文本	始皇七年，庄襄王**母亲**夏太后**去世**。	0.871 (+0.144)
目标匹配文本：吕不韦很**生气**，但一想到已经为子楚**破费了很多家财**，**想要**用这种手段钓到奇货，**于是就**献出了他的姬妾。		
文本类型	文本内容	目标相似度
原始文本	吕不韦**怒**，念业已**破家**为子楚，**欲**以钓奇，**乃遂**献其姬。	0.549
映射后文本	吕不韦**生气**了，念业已为子楚**破费家财**，**想要**以钓奇，**于是就**献其姬。	0.689 (+0.15)
目标匹配文本：他没有儿子，断绝了后代，封国被废除。		
文本类型	文本内容	目标相似度
原始文本	自**归**而**斩**之，**是示**後无**反意**也。	0.476
映射后文本	自**归来**而**斩杀**之，**这是告诉**後无**反叛的意思**也。	0.473 (−0.03)
映射后文本相似度提升平均值	-	+0.138

（2）基于多维信号反馈的强化学习算法结果分析

如果缺少了模型的热启动，强化学习算法在实际实验中难以收敛得到输出结果，由此可见热启动算法是算法整体框架中必不可少的重要部分。因此，论文重点分析基于多维信号反馈的强化学习算法的实验结果。表 3.5 展示论文提出的算法和不同基准模型在各类指标上的结果对比，表 3.6 展示在不同迁移方向上不同算法模型的结果对比。

分析表 3.5 和表 3.6 的结果，可以得出如下结论：

①论文提出的方法（PBRL）在以文言文与现代汉语为例的复杂文本风格迁移任务中，在风格迁移准确性、内容保留完整性、文本语言流畅性三个维度取得了最均衡的迁移结果，在内容保留完整性上达到最优，在风格迁移准确率和文本流畅性上均排名第二，风格与内容的几何平均数上得到最优的结果。PBRL 的生成结果不仅保证了风格迁移的准确性（迁移后的风格准确率高达 98.69%，仅比最高的 DualRL 低了 0.4%），同时也达到了最高的内容完整性，文本也相对流畅。在查看和比对各个模型的生成结果后，论文发现，不对文本风格与内容进行解耦

的 DualRL 虽然生成的风格准确率和文本流畅性很高，但是存在普遍的内容丢失甚至彻底丢失的情况，因此，即便它在两个指标上达到了最高的性能，但是仍然完全无法胜任复杂文本风格迁移的工作。而其它的解耦模型也均存在风格无法正确迁移、内容无法进行保留的情况。此外，可能是因为 ChatGPT 的训练语料中，文言文的数据相对较少，导致其对文言文风格的理解能力偏弱，ChatGPT 在零样本和提供上下文样例的少样本情况下虽然效果优于其它适用于简单文本风格迁移任务的小模型，但是效果仍略逊于论文提出的强化学习算法。

表 3.5 《白话史记》与《史记》数据集上的整体性能对比

模型	总 ACC ↑	总 BLEU ↑	总 PPL ↓	G-Score ↑
DualRL	**99.09**	4.03	**18.96**	19.98
NAST	61.86	8.31	763.13	22.67
TAG	2.09	5.11	484.72	3.27
RACoLN	68.99	4.30	257.51	17.22
ChatGPT（无上下文样例）	85.28	18.13	42.37	39.32
ChatGPT（有上下文样例）	94.28	23.87	38.14	47.43
伪平行 Seq2seq	98.18	23.53	69.20	48.06
PBRL	98.69	**33.50**	66.17	**57.50**

注：G-Score 代表总 ACC 和总 BLEU 的几何平均数，伪平行 seq2seq 表示只经过论文构造的伪平行数据的监督学习而未经过后续强化学习训练的模型

表 3.6 《白话史记》与《史记》数据集上各迁移方向的迁移性能对比

模型	ACC-a ↑	BLEU-a ↑	PPL-a ↓	ACC-b ↑	BLEU-b ↑	PPL-b ↓
DualRL	**98.69**	5.22	**16.83**	**99.49**	3.10	**21.35**
NAST	46.24	6.02	890.34	82.76	11.48	654.10
TAG	0.78	4.92	596.13	5.57	5.31	394.13
RACoLN	49.26	4.19	248.25	96.62	4.42	267.13
PBRL	97.98	**27.70**	38.71	99.41	**40.52**	113.11

注：(.)-a 表示从《史记》迁移到《白话史记》方向，(.)-b 代表从《白话史记》迁移到《史记》方向

②面对现代汉语与文言文的复杂文本风格迁移任务，从现代汉语到文言文的迁移子任务模型总体上完成得更好，而对于文言文到现代汉语的风格迁移子任务，其生成结果风格的准确性和内容完整度均更低。除了 DualRL 外，所有模型在《白

话史记》迁移至《史记》的风格迁移与内容保留上均做得更好。根据生成的结果分析，现代汉语中的语义省略更少，也减少了歧义和多义现象，使得模型进行语义对齐的难度降低；而《史记》文言文的语言简洁，存在非常多的语义省略和一词多义现象，这对模型的迁移和语义理解造成了困难。此外，论文发现，PBRL 生成的文言文 PPL 相对较高的原因可能是，模型在生成过程中选用了与目标文本意义相近，但是相对不常用的词语，而该词语可能在现代汉语中更常见，因此造成了困惑度的增加，例如：目标文本是“*禄、产等惧诛,谋作乱。*”，模型生成的结果为“*吕禄、吕产等恐诛,乃阴谋作乱。*”其中，“恐”与“惧”意思相近，但是少有作为单字出现在《史记》文言文中表示“害怕”的意思，“阴谋”与“谋”相比，则更接近现代汉语的表述。

③相比于只经过伪平行标注数据微调的热启动模型，基于多维度信号反馈的强化学习算法能够提供从风格、内容、文本流畅度等多个方面的更高精度的反馈信号，使得模型在各个维度的效果进一步提升。这是因为论文构造的伪平行数据精度相对较低，存在语义相近但并非完全相同的非平行文本对，而这些低质量数据会在训练中引入额外噪声，从而影响模型的语义理解能力、风格理解与迁移能力、语言流畅性等多方面的能力。由表 3.5 可知，噪声数据对内容一致性的负面影响最大，这是因为伪平行数据对文本的内容造成直接影响；语言流畅性受到的负面影响次之，而影响最小的是风格迁移准确率，这是因为错误的平行文本对所对应的文本风格依然是平行的。

（3）消融实验

为了验证论文提出的基于多维度信号反馈的强化学习算法中各个子模块的有效性，论文分别去除风格、内容、流畅性等各个维度的信号模块，验证各个模块的作用。此外，也通过调整各个维度信号的权重超参数，探究不同维度的信号对风格迁移结果的影响。

① 各个维度信号模块对风格迁移结果的影响

消融实验的结果如表 3.7 所示。为了保证去掉相关信号后损失的整体大小不受到影响，剩余信号的权重均等比例放大，使其权重和仍为 1，例如删除语言流畅性信号（原权重占比为 0.3）后，剩余两个信号的权重均从 0.35 变为 0.5。

表 3.7 《白话史记》与《史记》数据集上的 PBRL 消融实验结果

模型	总 ACC ↑	总 BLEU ↑	总 PPL ↓	G-Score ↑
PBRL	**98.69**	33.50	66.17	**57.50**
w/o con	97.56	29.45	**59.52**	53.60
w/o cls	97.19	**33.67**	64.91	57.20
w/o ppl	97.89	3.77	916.05	19.21

注：w/o 表示去掉某个模块，con 表示内容信号奖励，cls 表示风格信号奖励，ppl 表示流畅性信号奖励

从表 3.7 的结果中可知，不论去掉三个信号中的任何一个，模型的生成结果都会受到或多或少的负面影响，其中，起到最大负面影响的是去掉语言流畅度信号的消融模型。若去掉内容保留完整性奖励信号，受到最大影响的是 BLEU 指标。由于缺少了对内容信息的反馈，生成的文本虽然拥有较高的风格迁移准确性和语言流畅度（其 PPL 甚至低于完整模型 PBRL），但存在较多的内容丢失或者错误，因此整体结果有较多下降。若去掉风格迁移准确性奖励信号，生成文本的风格准确率会受到最大的影响，其风格准确率是所有消融对比模型中的最低值，但是由于此时内容和流畅性的信号占比增加，因此在内容保留指标 BLEU 和语言流畅度指标 PPL 上的效果均有所提升。而去掉语言流畅度信号后，模型由于无法生成流畅的文本，使得三个指标均有所下降，尤其是最依赖于语言句法结构的困惑度 PPL，此外，由于 BLEU 是通过计算 1-4Gram 得到的，因此也受到了不小的影响。

②各个维度信号的权重对风格迁移结果的影响

依据表 3.7，可知文本流畅性信号对稳定整个强化学习的训练过程，保证生成语言的自然流畅性起到十分重要的作用，若模型无法生成流畅的自然语言，其它指标也会受到影响。在保证文本生成自然、流畅结果的前提下，论文也探究风格迁移准确性信号与内容保留完整性信号占比对迁移结果的影响。令$\mu = \frac{\alpha}{\beta}$，即风格信号与内容信号的权重比值，它们占比对风格迁移结果的影响如图 3.2 所示。

由图 3.2 可知，当$\mu \in \{0.1, 0.2, 1, 5, 10\}$时，在风格信号与内容信号权重相等（$\mu = 1$）时，模型的迁移结果在风格迁移准确率和内容一致性上均达到峰值；当风格信号权重占比更高（$\mu > 1$）时，风格准确率虽然下降，但是降幅小于内容一致性；当内容信号权重占比更高（$\mu < 1$）时，内容一致性的降幅略小于风格准确率。此外，当风格信号占比更大时，模型迁移结果受到的风格和内容维度

的负面影响均更小。

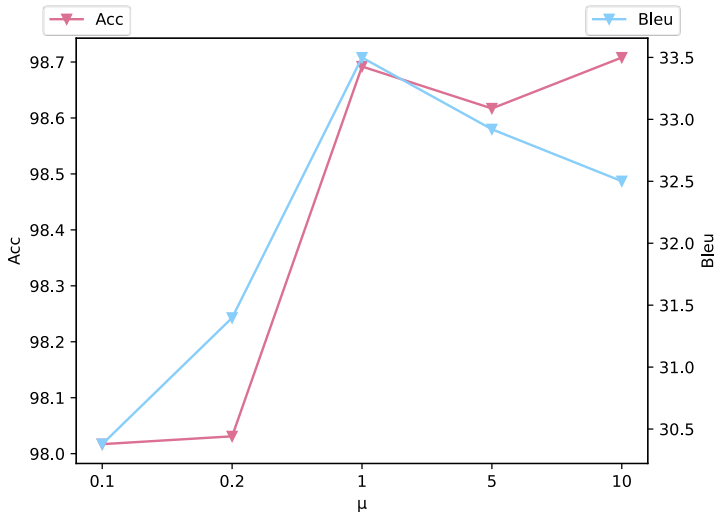


图 3.2 风格信号与内容信号权重比对迁移结果的影响

（4）简单文本风格迁移任务上的测试结果分析

为了进一步验证论文提出算法的有效性和可泛化性，论文也在文本风格迁移领域常用的公开情感迁移数据集 Yelp[5]上进行实验验证。Yelp 数据集是一个典型的简单情感数据集，其中大多数文本都有明显清晰的风格标志词。模型的对比结果如表 3.8 所示。

表 3.8 Yelp 数据集上的整体性能对比

模型	总 ACC ↑	总 BLEU ↑	总 PPL ↓	G-Score ↑
DualRL	85.6	55.2	-	68.7
NAST	79.6	58.0	70	67.7
TAG	86.6	19.8	-	41.4
RACoLN	**91.3**	20.0	**60.1**	**73.6**
PBRL	87.2	**58.6**	64.2	71.5

注：G-Score 代表总 ACC 和总 BLEU 的几何平均数，表格中“-”部分代表对应研究中未给出结果

由表 3.8 结果分析可知，PBRL 在简单的情感风格迁移任务上也取得了优秀的结果。虽然 PBRL 模型的风格 ACC 与 PPL 均低于 RACoLN 模型，但 RACoLN 模型在风格重建的过程中存在过度重建的现象，例如将“*Bad service.*”迁移为“*Good food.*”，虽然风格迁移准确率较高，但文本内容却被完全改变，导致其迁移结果中内容保留完整性太低、失真较多。尽管 RACoLN 在风格 ACC 上取得最优的结果，但综合来看，它生成的文本不足以达成风格迁移任务的要求。因此，

从整体结果上看，PBRL 在简单风格迁移任务上依然具有在风格、内容、文本流畅性三者上达到良好平衡的优点，整体迁移结果更佳。

3.5 本章小结

本章对基于提示强化学习的复杂文本风格迁移算法进行了介绍。该算法首先通过同义词表映射与改写方法构建伪平行标注文本，并在此基础上进行基于提示的风格迁移微调，从而为后续的强化学习算法提供良好的模型热启动，稳定模型训练的方向与进程。然而，伪平行标注数据的精度相对较低，为此论文进一步设计了基于多维信号反馈的强化学习算法，从风格迁移准确性、内容保留完整性、文本语义流畅性三个维度，为模型提供更高精度的优化信号，从而生成更高质量的结果。实验结果表明，论文提出的方法在现代汉语与文言文的复杂文本风格迁移任务上取得了优异的结果。消融实验也验证了算法各个子模块的有效性。此外，论文也在公开的简单风格迁移数据集 Yelp 上验证了算法的通用性与可泛化性。

第4章 基于指令增强的大模型风格迁移框架

在第 3 章中，论文介绍了在缺少大量计算资源的场景下，使用小模型完成面向现代汉语与文言文的基于提示强化学习的复杂文本风格迁移算法。而在拥有足量计算资源的情况下，近年来新兴的大语言模型技术则拥有更广阔的发挥空间。本章将针对该场景，研究如何使用大模型完成复杂文本风格迁移任务，通过指令增强、上下文学习等技术，增强大模型对复杂文本风格的理解与生成能力，同时减少大模型幻觉以尽可能完整无误地保存原始输入文本的内容信息。

4.1 引言

大语言模型（Large Language Models，LLM）已经凭借其强大的语言理解与生成能力和良好的泛化性在 NLP 的各个领域（包括神经机器学习、文本摘要、自动问答等）大放异彩。LLM 技术为整个 NLP 领域开启新的纪元，也令人们看见人工智能生成内容（AI-Generated Content，AIGC）与通用人工智能（Artificial General Intelligence，AGI）的曙光。

现有研究已经证明，ChatGPT 和 GPT-4 作为 LLM 的代表模型，具有一定理解复杂文本风格、语气的能力和进行角色扮演的能力[8]。然而，以 ChatGPT 为代表的闭源 LLM 以及以 Qwen1.5 系列模型和 ChatGLM3-6B 为代表的开源中文模型，面对文言文和现代汉语的复杂风格，在理解上依然存在一定的困难，模型的风格迁移偏好并没有与人类偏好进行对齐，因此无法进行比较准确的理解和迁移。

此外，LLM 存在一直广为人诟病的“幻觉”现象。与心理学上的幻觉现象类似，LLM 的幻觉指难以与其它“真实”文本区分开的带有错误的、不真实信息的文本。这种幻觉文本中携带有不忠诚于原始输入指令或者现实世界知识，或是携带有无意义的信息，即便它往往给人流畅自然的印象。这种特性使得某些特定领域的幻觉文本需要领域专家才能进行甄别，也降低了 LLM 在实际场景中的可用性。而幻觉现象也会直接导致在文本风格迁移领域，LLM 生成与原始输入文本的表意不相符合的文本。

虽然目前文本风格迁移领域关于提升大模型风格理解能力与减弱幻觉造成的内容不一致的研究比较缺乏，但是与文本风格迁移领域相近的机器翻译领域，

已经有研究提出指令增强的方法来保证语言类型的翻译，同时避免过度翻译和遗漏翻译的问题。Jiao 等人针对开源模型，提出基于提示的翻译指令，通过“Hint”槽，引导模型同时生成高偏好与低偏好的翻译结果，以及带有翻译错误的生成结果，促进模型对内容信息的完整翻译[52]。Huang 等人则针对闭源模型，通过对齐文本中的重难点词汇的方式，分两阶段进行生成，促进大模型对文本翻译的准确性：第一阶段，引导模型找出文本中的重难点词汇，并对其进行理解和解释；第二阶段，结合第一阶段的重难点词汇，对整个句子进行完整的翻译[50]。

而对于文本风格迁移任务，大模型目前存在以下两个问题：首先，如何在进行微调的情况下设计合理的指令数据，使得模型的风格迁移偏好同人类偏好进行对齐，进而增强模型对复杂文本风格的理解和建模能力，同时保证完整的内容输出。其次，如何在不进行训练的情况下，通过上下文学习（In-context Learning，ICL）等方式提升大模型的复杂文本风格理解能力和减少模型的幻觉输出。

针对以上两个问题，论文提出基于指令增强的大模型风格迁移框架，分别针对训练和只进行提示工程的不训练场景，提出基于要求引导的指令微调方法和基于提示分析的上下文学习方法，通过构建增强指令，在训练和推断两个阶段分别提升模型的复杂文本风格理解与生成能力，同时减少幻觉带来的内容错误或遗漏的情况。整体的算法框架如图 4.1 所示。

基于要求引导的指令微调方法能够有效增强大模型对复杂文本风格的理解，训练指令包括三个部分：首先，风格迁移指令定义风格迁移任务的基本范式，让模型遵循指令并生成满足任务要求的输出；其次，迁移偏好指令通过高质量与低质量数据的对比，让模型学习不同输出之间的质量偏好，增强对复杂风格属性的认知；最后，错误学习指令从风格迁移错误、内容遗漏等不同类型的错误结果出发，让模型从错误中学习，减小幻觉，满足核心要求。而基于提示分析的上下文学习方法在不对模型参数进行训练的前提下，提升模型的零样本与少样本学习能力，提示模板包括角色定义、输入、提示、输出和分析模块。其中，提示和分析模块对模型的理解和幻觉起到关键作用。

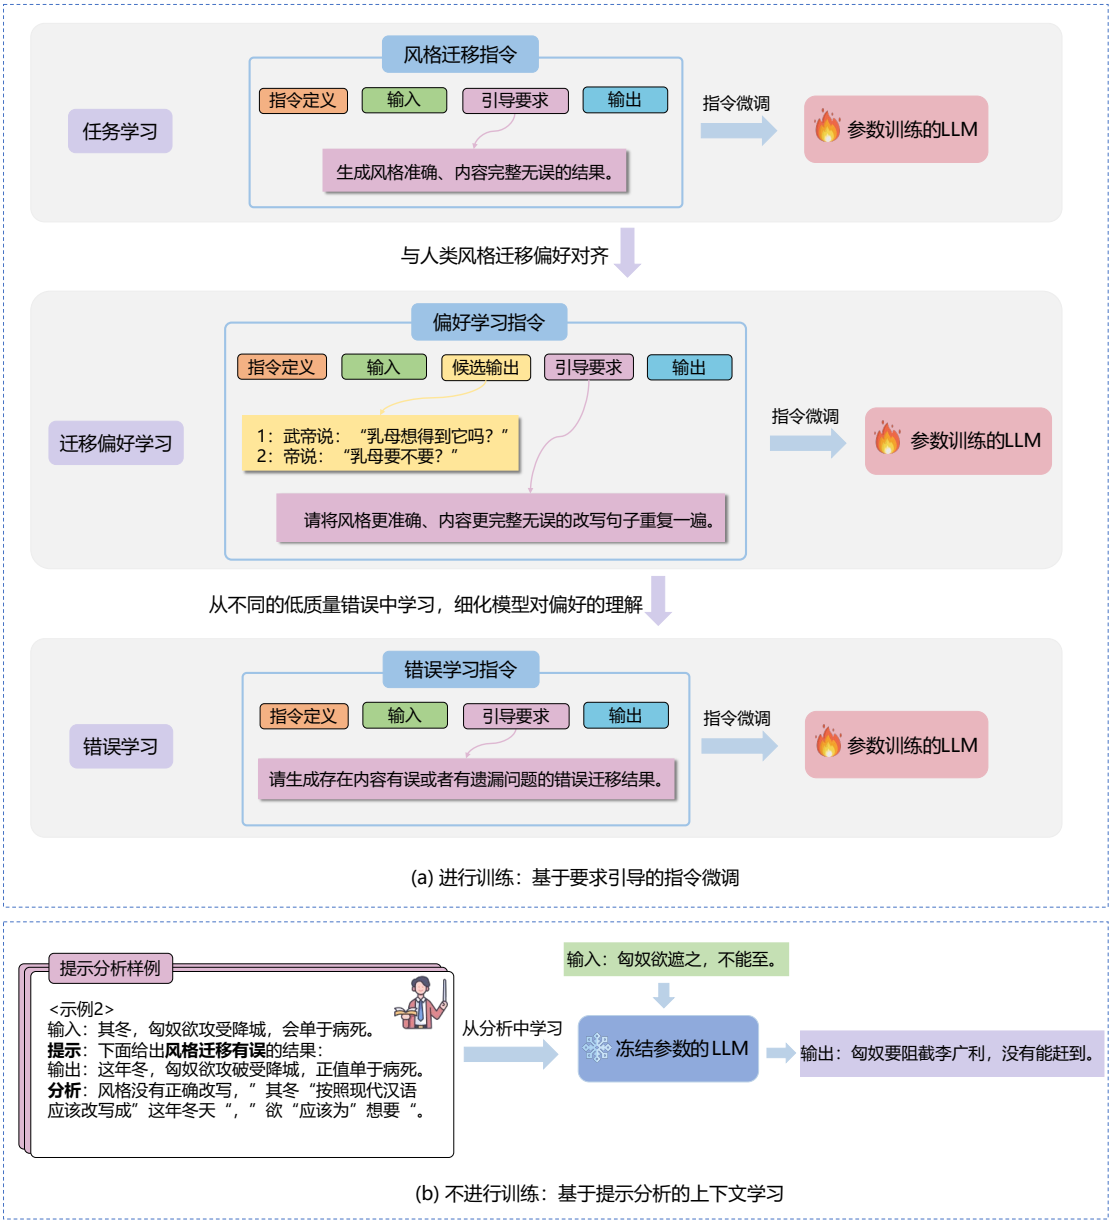


图 4.1 基于指令增强的大模型风格迁移框架

4.2 基于要求引导的指令微调

为了让模型在指令中更深入地理解文本风格，同时加强对内容保留完整性要求的实施程度，论文提出基于要求引导的指令微调方法。这种指令微调方法包括三个组成部分：风格迁移指令、迁移偏好指令、以及错误学习指令。其中，风格迁移指令可以使模型完成通用的风格迁移任务，与风格迁移的任务要求进行对齐，是指令池中的基础指令模块。而迁移偏好指令和错误学习指令则是属于增强指令，通过构建带偏好的指令以及带有错误信息的指令，引导模型更深入地学习和理解

人类风格迁移偏好，强化复杂文本风格的理解以及内容保留完整的要求。不同类型的指令则通过要求加以区分，从而引导模型完成不同的任务要求。

4.2.1 风格迁移指令设计

风格迁移指令是拥有要求引导的任务指令，它是直接引导模型完成风格迁移任务的基础指令，也是整个指令微调过程中最重要的指令。论文参考 Alpaca[8]的指令设计方式，将指令模板分为“指令”（Instruction）、“输入”（Input）、“要求”（Requirement）和“输出”（Output）四部分。具体的指令模板如图 4.2 所示。

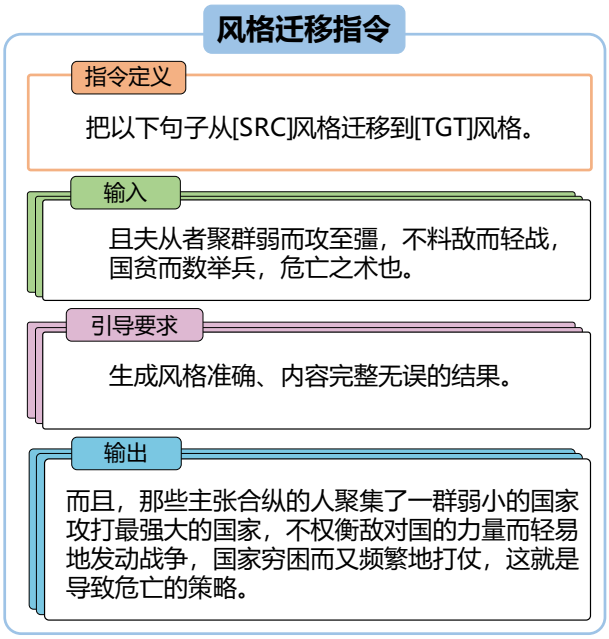


图 4.2 风格迁移指令样例

在风格迁移指令中，指令定义部分的[SRC]和[TGT]代表原始风格和目标风格的注入槽位，它直接决定了风格迁移的具体任务、涉及到的风格属性。论文一共设计了 32 条同义的风格迁移指令，图中展示的是其中一条指令的样式。论文设计的所有指令定义样式见表 4.1。输入部分则是等待模型进行风格迁移的原始输入文本，其风格与[SRC]的填充风格词一致。引导要求部分用于引导模型完成当前指令的核心要求，即“生成风格准确、内容完整无误的结果”，它是指令中的关键引导部分，引导模型生成文本的方向，决定模型目标输出的最终形态结构。输出部分则是模型的生成目标，它也与[TGT]槽的填充风格一致。

[8] https:// github.com/tatsu-lab/stanford_alpaca

表 4.1 风格迁移指令的样式

样式序号	风格迁移指令
1	把以下句子从[SRC]风格迁移到[TGT]风格。
2	下面的句子用[TGT]风格改写是什么样的？
3	请给出以下句子用[TGT]风格改写的结果。
4	将以下句子从[SRC]风格转换到[TGT]风格。
5	将以下句子从原始的[SRC]形式翻译成[TGT]形式。
6	将接下来的句子从[SRC]风格转换为[TGT]风格。
7	将给定的句子从[SRC]格式改为[TGT]格式。
8	将以下句子从它们的[SRC]版本转换成[TGT]版本。
9	将输入的来自[SRC]风格的句子改编成[TGT]风格。
10	将下一句话从[SRC]格式转换为[TGT]格式。
11	将指定的输入从它们的[SRC]形式转换为[TGT]形式。
12	将以下句子从[SRC]风格重新转换为[TGT]风格。
13	对接下来的句子进行修改，将它们从[SRC]风格转换为[TGT]风格。
14	以下句子在[TGT]风格中如何表述？
15	这些句子翻译成[TGT]风格是什么意思？
16	在[TGT]风格的情境中，接下来的句子如何表示？
17	你会如何用[TGT]风格表达以下句子的意思？
18	以下句子在[TGT]风格中的表述是什么?
19	在[TGT]风格中，给定的输入该如何表达?
20	当迁移到[TGT]风格时，这些句子传达了什么信息？
21	请问在[TGT]的风格中以下句子的预期改编结果是什么？
22	以下句子应该如何改写才能体现[TGT]风格？
23	就[TGT]风格而言，接下来的句子该如何表述?
24	请提供以下句子的[TGT]风格迁移结果。
25	你能为接下来的句子提供[TGT]风格的翻译吗？
26	请提供以下语句的[TGT]风格版本。
27	如果您能为这些输入提供[TGT]风格的改写结果，我将不胜感激。
28	你能提供所提到句子的[TGT]风格的版本吗？
29	请分享所给句子的[TGT]版本。
30	请给出后面[SRC]风格的句子迁移到[TGT]风格的结果。
31	请提交以下句子的[TGT]风格转换结果。
32	请提供所列句子的[TGT]风格改写结果。

4.2.2 迁移偏好指令设计

考虑到较为复杂的文本风格属性，尤其是在大模型的训练语料中，现代汉语与文言文的指定风格占比相对稀少。因此，大模型可能无法简单地通过指令中注入的“[SRC]”槽和“[TGT]”槽来理解对应的风格具体是什么。因此，论文设计

迁移偏好指令，通过在输入中给出的多个输出样例，并对它们进行偏好的对比，引导模型学习不同文本之间包含的风格准确性以及内容保留的完整性，从而与人类风格迁移偏好对齐。迁移偏好指令的模板样例如图 4.3 所示。

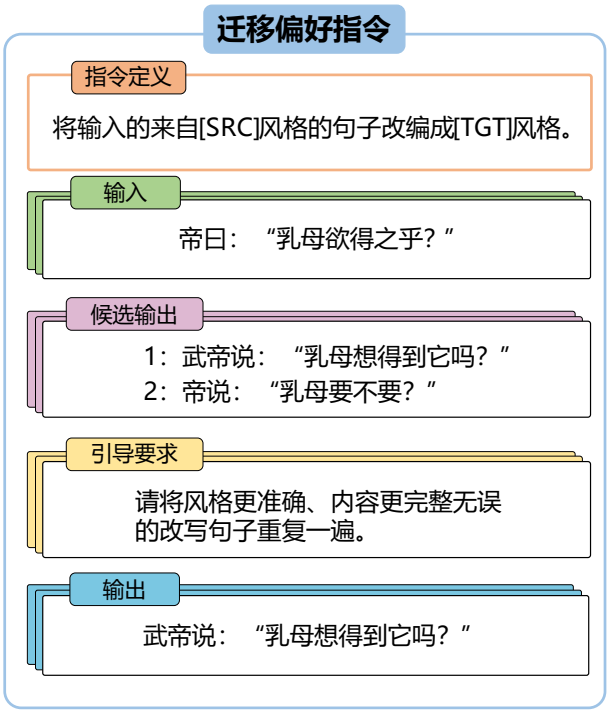


图 4.3 迁移偏好指令样例

在迁移偏好指令共包含指令定义、输入、候选输出、引导要求、输出四个模块。其中，指令定义部分与风格迁移指令相同，其目的是定义迁移过程所涉及的两种风格属性。输入部分也与风格迁移指令相同，代表需要进行风格迁移的原始输入文本。而候选输出部分则包含需要模型进行偏好筛选的多个候选输出，这些输出是通过 ChatGPT 进行噪声修改、以及使用第三章提出的模型框架通过针对性调整不同信号的奖励函数权重，生成的内容存在错误或者遗漏、或者风格迁移不完全的噪声输出文本。引导要求部分具有引导模型完成偏好对齐这项子任务的功能，它要求模型从多个给定的候选输出中找出更符合人类偏好的迁移结果，将其复述出来。论文共设计了 7 种不同的引导指令，详见表 4.2。输出部分是期望模型输出的最符合人类迁移偏好的候选输出结果。

设计迁移偏好指令的直接灵感来源于人类进行写作训练过程的范式：一方面，需要亲自尝试写作，另一方面，也需要不断地阅读各类文章，并在阅读过程中学习如何鉴赏文学作品；只有拥有一定的鉴赏能力，能够分辨文章的优劣，才能写出更好的作品。而通过迁移偏好指令让模型与人类对风格迁移文本的偏好进行对

齐，使得模型在偏好对齐的训练过程中，深化对文本风格的理解，同时强化对内容保留的认识。

表 4.2 迁移偏好指令的样式

样式序号	迁移偏好指令
1	复述上述输出样例中更好的输出结果。
2	请将风格更准确、内容更完整无误的改写句子重复一遍。
3	你认为内容没有遗漏和错误、风格迁移正确的输出结果是哪个？
4	上面哪个迁移结果是更好的？请把它复述出来。
5	我们会选择作为转换结果的候选输出是哪个句子？
6	重复上面的迁移结果中内容保留更好、风格迁移更准确的句子。
7	上面哪个改写结果更适合作为任务的输出？

4.2.3 错误学习指令设计

现有研究表明，大模型能够在错误数据中学习到知识[52]。因此，论文将获得的噪声数据分为只存在风格迁移不准确问题、只存在内容保留不完整或有误问题、同时存在两种问题的三类，并使用引导要求模块来对这三类错误的低质量文本生成结果作区分，引导模型学习低质量的错误样本数据。

具体的指令样例见图 4.4。

错误学习指令分为三个部分：指令定义、输入、引导要求和输出。其中，指令定义与输入与前两种指令相同。引导要求部分则希望模型能够生成内容错误、风格迁移错误或者两种问题兼有的错误迁移结果。针对引导要求部分，论文设计了 5 种不同的指令样式，详见表 4.3。输出部分是满足引导要求的错误目标文本。

错误学习指令的学习是在迁移偏好学习的基础上，细化模型对偏好理解的训练过程。相比迁移偏好学习，错误学习指令对不同的低质量错误进行更细化的分类，从内容遗漏和错误、风格迁移不准确、以及内容和风格均存在问题三个角度，促进模型对风格迁移任务本身的理解，进而提升模型的效果。

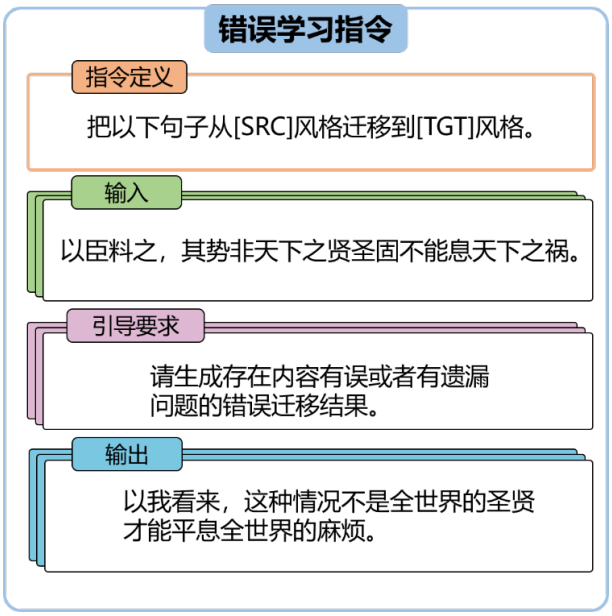


图 4.4 错误学习指令样例

表 4.3 错误学习指令样式

样式序号	错误学习指令
1	生成[ERR]的结果。
2	请给出具有[ERR]特点的改写结果。
3	出现[ERR]问题的结果可能是什么样的？
4	请生成存在[ERR]问题的错误迁移结果。
5	请输出有[ERR]错误的转换结果。

4.3 基于提示分析的上下文学习

针对开源大模型，可以通过指令微调的方法在训练中对齐人类偏好和意图，促进模型对复杂风格的理解和迁移过程中对内容完整保留要求的落实。而对于闭源模型而言，只能依赖其本身的强大语言理解和生成能力，使用零样本或少样本的方法完成迁移任务。而 Min 等人研究发现，相比输入与输出的模式，大模型更容易从指令的模式中进行学习[66]。因此，论文以 ChatGPT 为例，采用上下文学习方法（In-context Learning，ICL），设计基于提示分析的上下文学习指令，促进 ChatGPT 的现代汉语与文言文的复杂文本风格迁移能力。

论文设计的指令如图 4.5 所示。其中，角色定义部分是整个提示模板的激活指令，赋予 ChatGPT “风格改写专家”的角色，并令其按照风格要求进行风格迁移工作。随后的不同样例包含输入、提示、输出、分析四个子模块。输入表示样例中的原始输入。提示用于指引模型该样例生成结果的方向。论文一共设计了“内

容保留有误”、“风格迁移有误”、“正确/迁移无误”三种提示。输出表示依据上述输入中的原始输入文本和提示子模块的引导要求，期待模型生成的结果。分析子模块则针对样例中提供的输入和输出文本，进行指向性的分析，意在令模型学习有误的输出中具体的错误在何处，例如针对提示为“风格有误”的样例，其分析为：“风格没有正确改写，‘其冬’按照现代汉语应该改写成‘这年冬天’，‘欲’应该为‘想要’。”通过细致而准确的分析描述，模型便可以学习到比概括性的“风格有误”更为详细的具体错误，同时学习应该如何对其进行修改。位于整个提示模板最末端的输入部分则是最终需要模型生成的风格迁移文本。

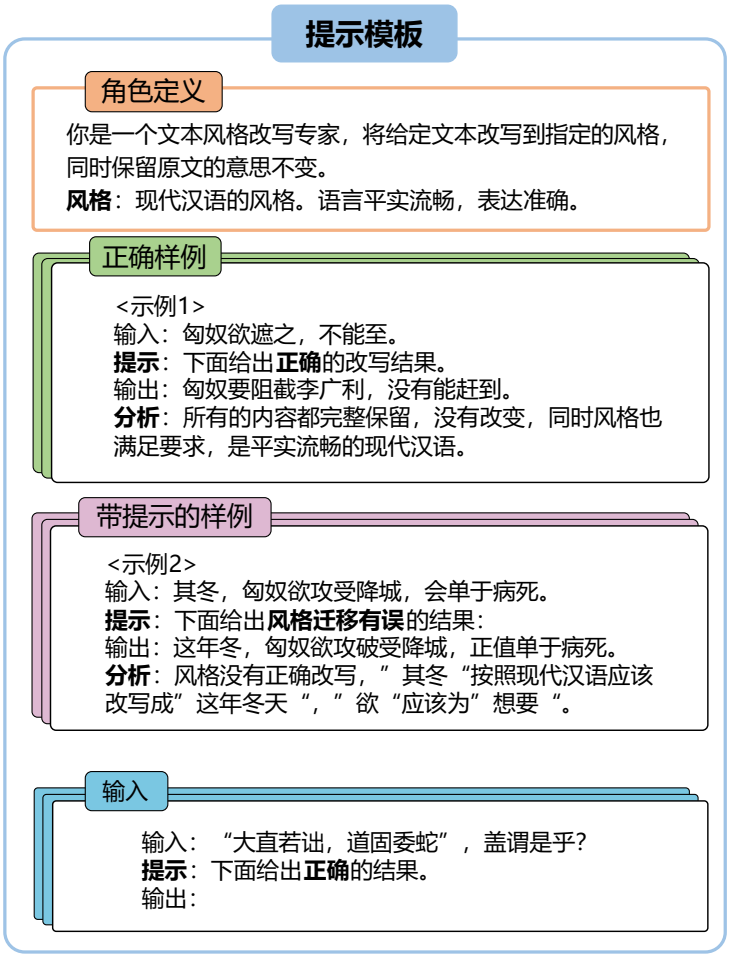


图 4.5 基于提示分析的上下文提示模板样例

4.4 实验对比与分析

本节从实验数据、对比的基准模型、论文设计的训练与上下文学习框架所使用模型的训练环境与参数设计、评价指标、实验结果与分析等 5 个方面介绍实验的设计细节和结果分析。

4.4.1 实验数据

与论文第 3 章类似，本章的实验数据依然在《白话史记》与《史记》的风格迁移数据的基础上进行构建。对基于要求引导的指令微调方法，论文针对三种不同的任务指令和增强指令，构造不同样式的数据子集。其中，风格迁移指令子集包含训练、验证、测试三个子集；而迁移偏好指令子集与错误学习指令子集两种增强指令集分别包含训练、验证两个子集。数据集的统计信息如表 4.4 所示。

针对风格迁移的任务指令，论文使用与第 3 章相同的训练、验证和测试集数据，将其按 4.2 节中的要求注入对应的槽位中，得到任务指令数据子集。针对迁移偏好指令与错误学习指令，论文使用 ChatGPT 与第 3 章中的强化学习模型构造风格迁移错误的数据与内容保留有误的数据。

表 4.4 指令微调数据集统计信息

指令数据类别	数据子集	样本占比	数据量
风格迁移	训练集	训练集 0.8 验证集 0.2	18.5MB
	测试集	-	4.6MB
迁移偏好	训练集	训练集 0.8 验证集 0.2	52.1MB
错误学习	训练集	训练集 0.8 验证集 0.2	31.6MB

为了构造内容保留有误的数据，论文使用 ChatGPT，通过指向内容有误要求的文本生成提示模板，生成内容有缺失、或是内容有信息错误的噪声目标文本。得到内容噪声文本后，论文使用 BLEU 分数对其进行筛选，保留与目标文本的 BLEU 分数在[28, 80]范围内文本。

经过前期实验发现，由于 ChatGPT 无法较好地区分文言文与现代汉语，有时候甚至简单地将有无繁体字作为区分两者的方式，因此，ChatGPT 无法构造指向风格迁移有误要求的数据。于是，论文使用第 3 章中介绍的基于提示强化学习的风格迁移算法，通过调整其中的风格迁移准确率信号的权重至 0，训练出内容基本保留、风格迁移不完全、甚至几乎没有进行风格迁移的风格噪声模型。随后使用该风格噪声模型生成风格迁移有误的数据。与内容噪声文本类似，论文使用

风格分类器对风格噪声文本进行分类，保留风格分类错误的文本。

4.4.2 基准模型概述

论文使用近两年知名的中文开源大模型 Qwen1.5 系列模型与 ChatGLM3 模型、闭源的 ChatGPT、以及文本风格迁移领域提供开源代码的基于大模型的研究工作进行实验对比。

（1）Qwen1.5-Chat 系列（0.5B-14B）[9]：Qwen1.5 系列是阿里巴巴云构建的大型语言模型“通义千问”家族中的改进版本。该系列模型提升了 Chat 模型与人类偏好的对齐程度，并且显著增强了模型的多语言处理能力。尽管仍然明显落后于 GPT-4-Turbo，但其最大的开源 Qwen1.5 模型 Qwen1.5-72B-Chat 相较于其它知名大模型，表现出卓越的性能。同时，相比知名的 LLaMA 系列等模型，其在中文语料上拥有更好的支持。

（2）ChatGLM3-6B[10]：ChatGLM3 是 ChatGLM 系列中的第三代开源版本，目前只公布了 6B 参数的模型。在各类公开数据集上的测评显示，ChatGLM3-6B-Base 在 10B 以下的预训练模型中，具有最强的性能。此外，Zhang 等人发现中文大模型 ChatGLM 可以很好地理解文言文[10]。

（3）GPT-3.5-turbo（ChatGPT）[11]：它是 OpenAI 开发的一个闭源的大语言模型，同时具有行业领先的性能。

4.4.3 模型训练详情

论文提出的模型使用 pytorch[12]、transformers[13]框架和 LLaMA-Factory[14]仓库实现。其中，基于要求引导的指令微调方法在 Qwen1.5-0.5B、Qwen1.5-7B、Qwen1.5-14B 和 ChatGLM3-6B 上进行实验验证。基于提示分析的上下文学习方法则主要在 ChatGPT 上进行实验验证。指令微调方法中涉及到的具体超参数如表 4.5 所示。

[9] https://huggingface.co/collections/Qwen/qwen15-65c0a2f577b1ecb76d786524
[10] https://huggingface.co/THUDM/chatglm3-6b
[11] https://openai.com/chatgpt
[12] https://pytorch.org/
[13] https://github.com/huggingface/transformers
[14] https://github.com/hiyouga/LLaMA-Factory

表 4.5 基于要求引导的指令微调方法的超参数

超参数	取值
Qwen1.5-0.5B-Chat	
Batch 大小	48
学习率	5e-5
混合精度	bf16
ZeRO stage	3
微调方式	Lora
超参数	取值
Qwen1.5-0.5B-Chat	
Batch 大小	48
学习率	5e-5
混合精度	bf16
ZeRO stage	3
微调方式	Lora
Qwen1.5-7B（与 0.5B 模型相同的参数不再赘述）	
Batch 大小	32
ZeRO stage	3
Qwen1.5-14B（与 0.5B 模型相同的参数不再赘述）	
Batch 大小	32
ZeRO stage	2
微调方式	QLora
ChatGLM3-6B（与 Qwen1.5-0.5B 模型相同的参数不再赘述）	
Batch 大小	10
ZeRO stage	2
微调方式	QLora

4.4.4 评价指标

论文主要从三个维度评价模型的有效性：风格迁移准确率、内容保留完整性、文本语言流畅性。其中，风格迁移准确率使用外部训练的风格分类器进行评判；

内容保留完整性则通过 BLEU-4 分数进行计算；文本语言流畅性通过外部训练的语言模型计算文本的困惑度。这三个维度评价指标的详细介绍见论文的第 3.4.4 节，此处不再赘述。

4.4.5 实验结果与分析

本节对第 4 章提出方法的实验结果进行分析，实验结果共分为三部分：基于要求引导的指令微调结果、基于提示分析的上下文学习结果和案例分析。

（1）基于要求引导的指令微调结果分析

①对比实验

基于要求引导的指令微调方法的对比实验结果如表 4.6 所示。其中，All 表示使用论文提出了三种指令数据进行微调，Only_transfer 表示仅使用风格迁移指令的模型，w/o Prefer 表示去除迁移偏好指令的模型，w/o Error 表示去除错误学习指令的模型。文言文迁移到现代汉语、现代汉语迁移到文言文的实验结果如表 4.7 所示。

分析表 4.6 和 4.7 中的对比实验结果，可以得出如下结论：

1）论文提出的基于要求引导的指令微调方法在较大规模的模型（模型参数≥6B）上得到最优的迁移结果。经过三种增强指令微调的模型在较大规模的模型上风格迁移准确率和内容保留完整性上均达到最优，在文本语言流畅性上略低于除了原始模型以外的结果。由此可知，当模型具有较高的理解与生成能力时，通过对模型进行迁移偏好的对齐以及从低质量错误数据及其分析中进行学习，能够促进模型对现代汉语与文言文的复杂风格的理解，从而提升模型的迁移效果。而 Qwen1.5-0.5B-Chat 模型在只进行风格迁移指令训练、在风格迁移指令与错误学习指令上训练的结果达到最优，可能是因为小规模模型理解和遵守指令的能力较弱，迁移偏好指令中，对更优的输出样例进行筛选的指令会干扰风格迁移任务本身的指令学习，使得模型更倾向于重复指令中的输入文本。

此外，通过对生成样本的分析，论文发现虽然于要求引导的指令微调方法的 PPL 指标略高于其它模型，但是抽样 100 条的人工流畅性评估发现，其生成文本仍然是相对流畅的，这可能与文本流畅度的评价指标 PPL 与人类评估一致性并不高有关，另一方面可能是因为目前缺少强大的文言文语言模型来对文言文的语言流畅性作公正的评价。这可能意味着本风格迁移任务仍需要探索与人类评估更

一致的自动评价方法。

表 4.6 基于要求引导的指令微调方法主体实验结果

模型	总 ACC ↑	总 BLEU ↑	总 PPL ↓	G-Score ↑
Qwen1.5-0.5B-Chat				
原始模型	17.00	8.47	59.67	12.00
All	96.92	25.16	34.92	49.38
Only_transfer	**96.99**	24.71	**34.10**	48.95
w/o Prefer	96.88	**25.35**	34.12	**49.56**
w/o Error	96.67	25.07	34.48	49.23
Qwen1.5-7B-Chat				
原始模型	85.76	10.73	45.01	30.33
All	**98.40**	**34.03**	20.73	**57.87**
Only_transfer	98.13	33.21	20.14	57.09
w/o Prefer	98.27	33.46	20.41	57.34
w/o Error	98.14	33.49	**19.94**	57.33
Qwen1.5-14B-Chat				
原始模型	93.48	13.05	35.87	34.93
All	**98.78**	**36.39**	19.58	**59.96**
w/o Prefer	98.13	36.06	19.32	59.49
w/o Error	98.09	35.51	**19.08**	59.02
ChatGLM-6B				
原始模型	51.24	9.29	61.43	21.82
All	**97.45**	**28.12**	**30.02**	**52.35**
w/o Prefer	96.15	26.75	32.39	50.72
w/o Error	97.10	27.66	30.32	51.82
ChatGPT（无上下文样例）	85.28	18.13	42.37	39.32
ChatGPT（有上下文样例）	94.28	23.87	38.14	47.43
PBRL	98.69	33.50	66.17	57.50

2）参数规模越大的模型经过指令微调后取得的迁移效果提升越显著。由 Qwen1.5 系列模型（0.5B-14B）结果可知，模型参数规模越大，经过三种指令微

调后模型结果在风格迁移准确率、内容保留完整性上的提升越大。这可能是因为模型越大，其对指令的理解能力更强，更能够从迁移偏好指令和错误学习指令中学习到正确的文本风格迁移方法。与此一致的结果是，对于未经过微调的原始模型而言，模型越大，在零样本条件下进行文本风格迁移的能力越强。

表 4.7 基于要求引导的指令微调方法在各迁移方向上的结果

模型	ACC-a ↑	BLEU-a ↑	PPL-a ↓	ACC-b ↑	BLEU-b ↑	PPL-b ↓
Qwen1.5-0.5B-Chat						
原始模型	55.67	13.06	39.27	5.19	5.50	90.66
All	**95.64**	21.66	22.24	98.22	29.22	54.84
Only_transfer	95.59	21.01	**21.53**	**98.42**	29.06	54.00
w/o Prefer	95.57	**21.68**	22.55	98.20	**29.64**	**51.62**
w/o Error	95.33	21.34	22.98	98.03	29.45	51.73
Qwen1.5-7B-Chat						
原始模型	**98.16**	17.69	21.20	74.93	6.51	95.58
All	97.61	**30.69**	**18.13**	**99.20**	**37.73**	23.69
Only_transfer	97.29	30.26	18.32	98.97	36.45	**22.14**
w/o Prefer	97.42	30.54	17.87	99.13	37.55	23.32
w/o Error	97.19	30.60	17.91	99.10	36.65	22.20
Qwen1.5-14B-Chat						
原始模型	**99.80**	19.21	**17.22**	87.56	8.87	74.71
All	98.03	**32.41**	17.52	**99.54**	**40.85**	21.89
w/o Prefer	97.23	32.32	17.75	99.04	40.24	**21.02**
w/o Error	97.24	32.18	17.60	98.94	39.19	20.68
ChatGLM-6B						
原始模型	92.62	13.68	28.26	28.35	6.31	133.52
All	**95.90**	**24.16**	22.22	**99.02**	**32.74**	**40.56**
w/o Prefer	94.37	22.94	23.54	97.98	31.19	44.55
w/o Error	95.63	23.66	**22.11**	98.60	32.33	41.57

注：(.)-a 表示从《史记》迁移到《白话史记》方向，(.)-b 代表从《白话史记》迁移到《史记》方向

3）经过指令微调的模型在《白话史记》迁移至《史记》的任务上更出色，

而未经过指令微调的原始模型在《史记》迁移至《白话史记》的任务上更出色。这种现象的原因可能是原始模型对现代汉语的理解和生成能力较强，缺乏文言文的生成能力，但具有一定的文言文理解能力。经过指令微调后，模型在文言文上的理解与生成能力均大幅提升，而由于与第 3.4.5（2）节中类似的原因，最终在《白话史记》迁移至《史记》的任务上的迁移能力反超在《史记》迁移至《白话史记》任务上的迁移能力。

②消融实验

由表 4.6 和 4.7 中的消融实验结果，可以得出如下结论：

1）当模型规模较大时，三种增强指令均能提升模型的迁移能力，且错误学习指令带来的提升比迁移偏好指令普遍更大。除了 Qwen1.5-0.5B-Chat 模型，其它更大规模的模型经过三种指令微调后的结果均明显优于消融模型的结果。错误学习指令中的低质量样本及其分析可以更大程度上加深模型对文本风格、内容完整与无误性的理解，因此对模型的提升更大。对生成的结果的分析可知，经过错误学习指令的训练后，模型的幻觉显著减小，尤其是内容信息的遗漏明显减少。

2）当模型本身的指令遵循能力和语言理解与生成能力较弱时，增强指令反而会成为干扰模型训练的噪声数据，从而带来负面影响。由于三种指令的具体任务要求各不相同，且迁移偏好指令的任务要求与风格迁移指令和错误学习指令的任务要求存在较大偏差，当模型的指令理解遵循能力较弱时，不同指令的数据便会成为相互之间的噪声数据，引起模型幻觉现象增多，从而导致模型的风格、内容和语言流畅度均受到负面影响。

（2）基于提示分析的上下文学习结果分析

基于要求提示分析的上下文学习方法的实验结果如表 4.8 所示。分析实验结果可以得出如下结论：

表 4.8 基于要求引导的指令微调方法主体实验结果

模型	总 ACC ↑	总 BLEU ↑	总 PPL ↓	G-Score ↑
ChatGPT（无上下文样例）	85.28	18.13	42.37	39.32
ChatGPT（有上下文样例）	94.28	**23.87**	38.14	47.43
ChatGPT（提示分析指令）	**96.59**	23.36	**36.55**	**47.50**

①对于大模型相对不擅长的现代汉语与文言文的复杂文本风格迁移任务，上

下文学习提供的样例范式能够显著提升模型各个维度的效果。这表明具有很强文本理解与生成的大模型能够从极少量的样本（实验中提供的上下文样例为 5 个）中学习复杂的文本风格，同时减小模型幻觉。

②基于提示分析的上下文学习方法能够极大地促进模型对复杂文本风格的理解与生成能力，提升语言流畅性。然而，可能是提示分析中的错误样本也会造成一定的偏置，该方法生成结果在内容评价指标 BLEU 上略低于（-0.51）只提供正确上下文样例的模型结果。

（3）案例研究

为了更直观地验证论文第 4 章提出方法的有效性，表 4.9 列举 ChatGLM3-6B 模型和 ChatGPT 分别由《史记》迁移至《白话史记》的生成结果案例。表格中生成结果加下划线部分表示内容出错的文本，加粗部分为风格出错的文本。

表 4.9 模型在《史记》迁移至《白话史记》任务上的生成结果案例

模型	总 ACC ↑	总 BLEU ↑	《史记》迁移至《白话史记》结果
输入	-	-	因稍以法诛秦所置长吏，以其党为假守。
参考输出	-	-	借此机会，逐渐用法律杀了秦朝安置的官吏，而用他的亲信做代理长官。
ChatGLM-6B			
原始模型	92.62	13.68	由于稍微采用了法家的策略来诛杀秦朝所设置的官吏,导致他们的同党成为了假守。
All	**95.90**	**24.16**	于是，逐渐用法律诛杀秦朝派来的官吏，用他们的同党作代理知事。
w/o Prefer	94.37	22.94	于是趁机**以法**诛灭了韩所设置的官吏，用他们的党羽作为代理**守**。
w/o Error	95.63	23.66	于是趁机**以法**诛灭了秦朝所派的官吏，用他们的同党人做官。
ChatGPT			
原始指令	85.28	18.13	因为稍微用法律处置秦朝所安排的官员，以及他们的同党被假冒**为守**。
有上下文样例	94.28	**23.87**	因为稍微用法律处置秦朝所安排的官员，以及他们的同党被认为是假冒守卫。
提示分析指令	**96.59**	23.36	因为稍微使用法律来惩治秦朝任命的官员，将他们的同党安排为假的守卫。

表 4.10 列举 ChatGLM3-6B 模型和 ChatGPT 分别由《白话史记》迁移至《史记》的生成结果案例。表格中生成结果加下划线部分表示内容出错的文本，加粗部分为风格出错的文本。

表 4.10 模型在《白话史记》迁移至《史记》任务上的生成结果案例

模型	总 ACC ↑	总 BLEU ↑	《白话史记》迁移至《史记》结果
输入	-	-	河南太守考核并推荐他有才能而升为御史，派到关东去督捕盗贼。
参考输出	-	-	河南守案举以为能，迁为御史，使督盗贼关东。
ChatGLM-6B			
原始模型	92.62	13.68	**河南太守考核并推荐他有才能而升为御史，派到关东去督捕盗贼。**
All	**99.02**	**32.74**	河南守举其才，使为御史，使东督盗贼。
w/o Prefer	97.98	31.19	河南守察其能而举为御史，使东守盗。
w/o Error	98.60	32.33	河南守察其能，举为御史，使领关东盗贼。
ChatGPT			
原始指令	85.28	18.13	河南太守**核实**其**才能**，遂**升**为御史，**遣至关东督捕盗贼**。
有上下文样例	94.28	**23.87**	河南太守**考核推荐**其**有才**，**升**为御史，**往关东督捕盗贼**。
提示分析指令	**96.59**	23.36	河南太守核其才，**升**为御史，驰驱关东，**督捕盗贼**。

从表 4.9 和表 4.10 中分析可知，ChatGLM3-6B 模型在进行基于要求引导的指令微调后，虽然也存在少数内容不准确的情况，但是在风格迁移准确性、内容保留完整性上都得到了一定提升，且在内容方面的提升最为明显。ChatGPT 整体的结果都逊色于经过指令微调后的 ChatGLM3-6B，而经过基于提示分析的上下文学习后，模型在文本风格迁移准确性上提升更大，内容保留程度上提升相对较小。整体而言，上述案例表明论文提出的基于指令增强的大模型风格迁移框架能够提升模型对复杂文本风格的理解与生成能力，同时在风格、内容、语言流畅性上达成良好的平衡。

4.5 本章小结

本章对基于指令增强的大模型风格迁移框架进行了介绍。该框架依据是否对模型参数进行训练分为基于要求引导的指令微调和基于提示分析的上下文学习。在基于要求引导的指令微调方法中，论文介绍了指令池中三种增强指令的结构及其构建方式，它们分别从任务目标定义与训练、与人类偏好的对齐、从错误中学习的角度，逐步细化模型对任务要求与风格的理解能力，提升模型的效果。在基于提示分析的上下文学习中，论文设计了角色定义、提示与分析槽，在上下文中丰富对文本风格迁移任务的信息，使用提示和样例分析增强模型对风格的理解能力，使模型在上下文范式中学习，从而增强模型风格迁移的能力。在《白话史记》与《史记》迁移数据集上的实验结果表明，论文提出的方法在现代汉语与文言文的文本风格迁移任务上取得了优异的结果。消融实验也验证了算法各个子模块的有效性。

第5章 总结与展望

本章对论文的所有工作进行简要概括和展望。首先，以当前复杂文本风格迁移任务面临的两大挑战为切入点，分别对论文提出的两大算法框架进行简略的总结。随后，对该领域有待探索的问题进行展望。

5.1 全文工作总结

相对于简单风格迁移任务，复杂文本风格迁移任务更接近现实中用户的实际需求，而该领域的相关研究目前相对较少。论文针对复杂文本风格迁移任务中，在不同的计算资源场景下，小模型与大模型分别面临的挑战，重点解决两个关键问题：（1）在基于小模型的无监督场景下，对复杂文本风格迁移准确性、内容保留完整程性、生成文本的语言流畅性的“不可能三角”进行平衡的问题。（2）在基于大模型的场景下，增强模型对复杂文本风格理解能力、减少模型幻觉的问题。为此，论文分别提出了基于提示强化学习的复杂文本风格迁移算法与基于指令增强的大模型风格迁移框架，为不同应用场景提出了全面的解决方案，其主要内容与贡献如下：

（1）针对缺少计算资源的小模型，论文提出了基于提示强化学习的复杂文本风格迁移算法。通过奖励工程设计，使模型获得显式反馈，非解耦地完成复杂文本风格的迁移。论文平衡了风格迁移准确性、内容保留完整性和语言流畅性，有效缓解对抗性样本造成的错误方向指引问题。

（2）针对缺少平行语料的场景，论文为现代汉语与文言文的风格迁移构建伪平行语料。使用古汉语常用字字典，通过“同义词表映射”方法，将现代汉语与文言文的语料文本映射替换，计算不同风格语料的语义相似度。伪平行标注语料可对序列到序列模型进行粗精度的微调，为基于提示强化学习的算法提供热启动，增强训练稳定性。

（3）针对拥有足够计算资源的开源大模型，论文提出了基于要求引导的指令微调方法。训练指令包括风格迁移、迁移偏好和错误学习。使用增强指令对大模型进行微调训练，论文增强了大模型对复杂文本风格的理解，减小了模型幻觉，进一步满足文本风格迁移任务中对风格准确率、内容完整度和文本流畅性的要求。

（4）针对参数权重不开源的大模型场景，论文提出了基于提示分析的上下文学习方法，提升模型的零样本与少样本学习能力。上下文提示模板包括角色定义、输入、提示、输出和分析模块，其中提示和分析模块对模型对于复杂文本风格的理解和减小幻觉起到关键作用。

（5）在《白话史记》与《史记》的现代汉语与文言文数据集上验证了所提出的模型和算法。实验结果表明，论文提出的算法在不同应用场景下都具有有效性和优越性。此外，论文还使用了文本风格迁移领域常见的情感迁移数据集 Yelp 进行实验验证，证明了算法的通用性和有效性。

5.2 未来工作展望

论文对现代汉语与文言文的复杂文本风格迁移任务进行研究，从小模型、大模型等多个角度，提供了全面的解决方案，提升了模型的文本风格迁移效果。然而，针对该任务，仍有许多问题有待更深入的研究和探索：

（1）更细粒度的强化学习奖励信号。论文设计的面向小模型的强化学习算法中，由于在文本序列生成完成之前，风格分类器和语言模型无法对单个语句进行风格和流畅度的评估，因此，论文采取了使用累积奖励对生成的整个动作序列进行统一优化的策略，然而这种方式会导致奖励的延迟性反馈。未来，可以借鉴基于人类反馈的强化学习算法（Reinforcement Learning from Human Feead Back，RLHF）进一步探索及时性奖励模型的训练方法，以解决延迟性反馈带来的训练误差。

（2）缺少外部知识的无监督的复杂文本风格迁移算法。面对缺少标注语料的场景，论文利用外部的同义词词典知识，构建伪平行数据，从而将无监督问题转化为监督问题，对模型进行前期的热启动，保证强化学习算法的训练稳定性。然而，面对缺少外部知识、无法构建伪平行数据的场景，目前依然没有特别好的解决方法。一种技术思路是增强模型的风格表示能力，通过更丰富的风格表示对复杂文本风格进行建模，从而使解耦模型能够对复杂文本风格与内容进行解耦，进而完成迁移任务；另一种思路则是利用大模型的强大的生成能力进行数据增广，通过极少量人工构建的平行文本，探索使用大模型构建较高质量的伪平行数据的方法。

（3）文本风格的迁移学习。目前，绝大多数研究只针对特定的几种风格，

如情感、正式性用语、莎士比亚风格等进行风格迁移任务。然而，在现实场景下，用户的风格迁移需求多种多样，现有模型，尤其是经过针对性微调的小模型与指令微调后的大模型，难以应对用户复杂多样的风格迁移需求。因此，探究多风格、甚至任意文本风格的迁移方法，对未曾出现在训练集中的新风格进行迁移学习、提升模型的泛化能力，是文本风格迁移模型得以在现实场景下运用的关键。一种可能的技术方案是利用大模型的强大泛化能力，探索使用上下文学习、思维链等方法实现迁移学习的方法。

（4）与人类偏好更一致的自动评估方法。目前通用的文本风格迁移的自动评估方法主要包括风格分类器准确率、BLEU-4 分数、语言模型的困惑度等。然而，不论是从论文的实验样例分析、还是其它学者的研究均发现，这些自动评估方法与人类评估一致性存在偏差，无法准确地衡量风格迁移、内容保留的完整程度和文本的流畅性。因此，探索与人类偏好更一致的自动评估方法，也是未来有待研究的重要方向。

参考文献

[1] McDonald D D, Pustejovsky J D. A Computational Theory of Prose Style for Natural Language Generation[C]//Second Conference of the European Chapter of the Association for Computational Linguistics. Geneva, Switzerland: Association for Computational Linguistics, 1985: 187-193.

[2] Mou L, Vechtomova O. Stylized Text Generation: Approaches and Applications[C]//Proceedings of the 58th Annual Meeting of the Association for Computational Linguistics: Tutorial Abstracts. Online: Association for Computational Linguistics, 2020: 19-22.

[3] Rao S, Tetreault J. Dear Sir or Madam, May I Introduce the GYAFC Dataset: Corpus, Benchmarks and Metrics for Formality Style Transfer[C]//Proceedings of the 2018 Conference of the North American Chapter of the Association for Computational Linguistics: Human Language Technologies, Volume 1 (Long Papers). New Orleans, Louisiana: Association for Computational Linguistics, 2018: 129-140.

[4] Gan C, Gan Z, He X, et al. StyleNet: Generating Attractive Visual Captions With Styles[C]//Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition. 2017: 3137-3146.

[5] Shen T, Lei T, Barzilay R, et al. Style Transfer from Non-Parallel Text by Cross-Alignment[C]//Advances in Neural Information Processing Systems: Vol. 30. Curran Associates, Inc., 2017: 6830-6841.

[6] Xu R, Huang Y, Chen X, et al. Specializing Small Language Models towards Complex Style Transfer via Latent Attribute Pre-Training[M]. ECAI 2023: 2802-2809.

[7] 陈可佳, 费子阳, 陈景强, 等. 文本风格迁移研究综述[J]. 软件学报, 2022, 33(12): 4668-4687.

[8] Bubeck S, Chandrasekaran V, Eldan R, et al. Sparks of Artificial General Intelligence: Early experiments with GPT-4[J]. arXiv preprint arXiv:2303.12712, 2023.

[9] Du Z, Qian Y, Liu X, et al. GLM: General Language Model Pretraining with Autoregressive Blank Infilling[C]//Proceedings of the 60th Annual Meeting of the Association for Computational Linguistics (Volume 1: Long Papers). Dublin, Ireland: Association for Computational Linguistics, 2022: 320-335.

[10] Zhang Y, Li H. Can Large Language Model Comprehend Ancient Chinese? A Preliminary Test on ACLUE[C]//Ancient Language Processing Workshop. 2023: 80-87.

[11] Yi X, Sun M, Li R, et al. Automatic Poetry Generation with Mutual Reinforcement Learning[C]//Proceedings of the 2018 Conference on Empirical Methods in Natural Language Processing. Brussels, Belgium: Association for Computational Linguistics, 2018: 3143-3153.

[12] Zhou H, Huang M, Zhang T, et al. Emotional Chatting Machine: Emotional Conversation Generation with Internal and External Memory[J]. Proceedings of the AAAI Conference on Artificial Intelligence, 2018, 32(1): 730-738.

[13] Jin D, Jin Z, Zhou J T, et al. Hooks in the Headline: Learning to Generate Headlines with Controlled Styles[C]//Proceedings of the 58th Annual Meeting of the Association for Computational Linguistics. Online: Association for Computational Linguistics, 2020: 5082-5093.

[14] Nogueira dos Santos C, Melnyk I, Padhi I. Fighting Offensive Language on Social Media with Unsupervised Text Style Transfer[C]//Proceedings of the 56th Annual Meeting of the Association for Computational Linguistics (Volume 2: Short Papers). Melbourne, Australia: Association for Computational Linguistics, 2018: 189-194.

[15] Tu Z, Lu Z, Liu Y, et al. Modeling Coverage for Neural Machine Translation[C]//Proceedings of the 54th Annual Meeting of the Association for Computational Linguistics (Volume 1: Long Papers). Berlin, Germany: Association for Computational Linguistics, 2016: 76-85.

[16] Xu R, Ge T, Wei F. Formality Style Transfer with Hybrid Textual Annotations[J]. CoRR, 2019, abs/1903.06353.

[17] Niu X, Rao S, Carpuat M. Multi-Task Neural Models for Translating Between

Styles Within and Across Languages[C]//Proceedings of the 27th International Conference on Computational Linguistics. Santa Fe, New Mexico, USA: Association for Computational Linguistics, 2018: 1008-1021.

[18] Zhang Y, Ge T, Sun X. Parallel Data Augmentation for Formality Style Transfer[C]//Proceedings of the 58th Annual Meeting of the Association for Computational Linguistics. Online: Association for Computational Linguistics, 2020: 3221-3228.

[19] Jhamtani H, Gangal V, Hovy E, et al. Shakespearizing Modern Language Using Copy-Enriched Sequence to Sequence Models[C]//Proceedings of the Workshop on Stylistic Variation. Copenhagen, Denmark: Association for Computational Linguistics, 2017: 10-19.

[20] Kajiwara T. Negative Lexically Constrained Decoding for Paraphrase Generation[C]//Proceedings of the 57th Annual Meeting of the Association for Computational Linguistics. Florence, Italy: Association for Computational Linguistics, 2019: 6047-6052.

[21] Li J, Jia R, He H, et al. Delete, Retrieve, Generate: a Simple Approach to Sentiment and Style Transfer[C]//Proceedings of the 2018 Conference of the North American Chapter of the Association for Computational Linguistics: Human Language Technologies, Volume 1 (Long Papers). New Orleans, Louisiana: Association for Computational Linguistics, 2018: 1865-1874.

[22] Wang J, Zhang R, Chen J, et al. Text Style Transferring via Adversarial Masking and Styled Filling[C]//Proceedings of the 2022 Conference on Empirical Methods in Natural Language Processing. Abu Dhabi, United Arab Emirates: Association for Computational Linguistics, 2022: 7654-7663.

[23] Devlin J, Chang M W, Lee K, et al. BERT: Pre-training of Deep Bidirectional Transformers for Language Understanding[C]//Proceedings of NAACL-HLT. 2019: 4171-4186.

[24] Zhu W, Bhat S. “Slow Service” ↛ “Great Food”: Enhancing Content Preservation in Unsupervised Text Style Transfer[C]//Proceedings of the 15th International Conference on Natural Language Generation. Waterville, Maine, USA and virtual

meeting: Association for Computational Linguistics, 2022: 29-39.

[25] Hu Z, Yang Z, Liang X, et al. Toward Controlled Generation of Text[C]//Proceedings of the 34th International Conference on Machine Learning. PMLR, 2017: 1587-1596.

[26] Yang Z, Hu Z, Dyer C, et al. Unsupervised Text Style Transfer using Language Models as Discriminators[C]//Advances in Neural Information Processing Systems: Volume 31. Curran Associates, Inc., 2018: 7287-7298.

[27] Zhao J, Kim Y, Zhang K, et al. Adversarially Regularized Autoencoders[C]//Proceedings of the 35th International Conference on Machine Learning. PMLR, 2018: 5902-5911.

[28] Fu Z, Tan X, Peng N, et al. Style Transfer in Text: Exploration and Evaluation[C]//Proceedings of the AAAI Conference on Artificial Intelligence, 2018, 32(1): 663-670.

[29] Wang K, Hua H, Wan X. Controllable Unsupervised Text Attribute Transfer via Editing Entangled Latent Representation[C]//Advances in Neural Information Processing Systems: Volume 32. Curran Associates, Inc., 2019: 11036-11046.

[30] Liu D, Fu J, Zhang Y, et al. Revision in Continuous Space: Unsupervised Text Style Transfer without Adversarial Learning[C]//Proceedings of the AAAI Conference on Artificial Intelligence, 2020, 34(05): 8376-8383.

[31] John V, Mou L, Bahuleyan H, et al. Disentangled Representation Learning for Non-Parallel Text Style Transfer[C]//Proceedings of the 57th Annual Meeting of the Association for Computational Linguistics. Florence, Italy: Association for Computational Linguistics, 2019: 424-434.

[32] Han J, Wang Q, Zhang L, et al. Text Style Transfer with Contrastive Transfer Pattern Mining[C]//Proceedings of the 61st Annual Meeting of the Association for Computational Linguistics (Volume 1: Long Papers). Toronto, Canada: Association for Computational Linguistics, 2023: 7914-7927.

[33] Mai H, Jiang W, Deng Z. GAN Prefix-Tuning Based Unsupervised Text Style Transfer [C]//Findings of the Association for Computational Linguistics: EMNLP 2023. 2023: 14847-14856.

[34] Hu Z, Lee R K W, Aggarwal C C, et al. Text Style Transfer: A Review and Experimental Evaluation[J]. ACM SIGKDD Explorations Newsletter, 2022, 24(1): 14-45.

[35] Lample G, Subramanian S, Smith E M, et al. Multiple-Attribute Text Rewriting[C]//7th International Conference on Learning Representations, ICLR 2019. https://openreview.net/forum?id=H1g2NhC5KQ.

[36] Luo F, Li P, Zhou J, et al. A Dual Reinforcement Learning Framework for Unsupervised Text Style Transfer[C]//Proceedings of the Twenty-Eighth International Joint Conference on Artificial Intelligence. Macao, China: International Joint Conferences on Artificial Intelligence Organization, 2019: 5116-5122.

[37] Gong H, Bhat S, Wu L, et al. Reinforcement Learning Based Text Style Transfer without Parallel Training Corpus[C]//Proceedings of the 2019 Conference of the North American Chapter of the Association for Computational Linguistics: Human Language Technologies, Volume 1 (Long and Short Papers). Minneapolis, Minnesota: Association for Computational Linguistics, 2019: 3168-3180.

[38] Ganitkevitch J, Callison-Burch C. The Multilingual Paraphrase Database[C]//Proceedings of the Ninth International Conference on Language Resources and Evaluation (LREC'14). Reykjavik, Iceland: European Language Resources Association (ELRA), 2014: 4276-4283.

[39] Prabhumoye S, Tsvetkov Y, Salakhutdinov R, et al. Style Transfer Through Back-Translation[C]//Proceedings of the 56th Annual Meeting of the Association for Computational Linguistics (Volume 1: Long Papers). Melbourne, Australia: Association for Computational Linguistics, 2018: 866-876.

[40] Zhang Z, Ren S, Liu S, et al. Style Transfer as Unsupervised Machine Translation[J]. CoRR, 2018, abs/1808.07894.

[41] Huang F, Chen Z, Wu C H, et al. NAST: A Non-Autoregressive Generator with Word Alignment for Unsupervised Text Style Transfer[C]//Findings of the Association for Computational Linguistics: ACL-IJCNLP 2021. 2021: 1577-1590.

[42] Achiam J, Adler S, Agarwal S, et al. GPT-4 Technical Report [J]. arXiv preprint

arXiv:2303.08774, 2023.

[43] Brown T, Mann B, Ryder N, et al. Language Models are Few-Shot Learners[C]//Advances in Neural Information Processing Systems: Volume 33. Curran Associates, Inc., 2020: 1877-1901.

[44] Sanh V, Webson A, Raffel C, et al. Multitask Prompted Training Enables Zero-Shot Task Generalization[C]//International Conference on Learning Representations. 2021. https://openreview.net/forum?id=9Vrb9D0WI4.

[45] Zhao Z, Wallace E, Feng S, et al. Calibrate Before Use: Improving Few-shot Performance of Language Models[C]//Proceedings of the 38th International Conference on Machine Learning. PMLR, 2021: 12697-12706.

[46] Reif E, Ippolito D, Yuan A, et al. A Recipe for Arbitrary Text Style Transfer with Large Language Models[C]//Proceedings of the 60th Annual Meeting of the Association for Computational Linguistics (Volume 2: Short Papers). Dublin, Ireland: Association for Computational Linguistics, 2022: 837-848.

[47] Liu Q, Qin J, Ye W, et al. Adaptive Prompt Routing for Arbitrary Text Style Transfer with Pre-trained Language Models[C]//Proceedings of the AAAI Conference on Artificial Intelligence, 2024, 38(17): 18689-18697.

[48] Deng M, Wang J, Hsieh C P, et al. RLPrompt: Optimizing Discrete Text Prompts with Reinforcement Learning[C]//Proceedings of the 2022 Conference on Empirical Methods in Natural Language Processing. Abu Dhabi, United Arab Emirates: Association for Computational Linguistics, 2022: 3369-3391.

[49] Suzgun M, Melas-Kyriazi L, Jurafsky D. Prompt-and-Rerank: A Method for Zero-Shot and Few-Shot Arbitrary Textual Style Transfer with Small Language Models[C]//Proceedings of the 2022 Conference on Empirical Methods in Natural Language Processing. Abu Dhabi, United Arab Emirates: Association for Computational Linguistics, 2022: 2195-2222.

[50] Huang Y, Feng X, Li B, et al. Aligning Translation-Specific Understanding to General Understanding in Large Language Models[J]. arXiv preprint arXiv:2401.05072, 2024.

[51] Ouyang L, Wu J, Jiang X, et al. Training language models to follow instructions

with human feedback[J]. Advances in neural information processing systems, 2022, 35: 27730-27744.

[52] Jiao W, Huang J tse, Wang W, et al. ParroT: Translating during Chat using Large Language Models tuned with Human Translation and Feedback[C]//Findings of the Association for Computational Linguistics: EMNLP 2023. 2023: 15009-15020.

[53] Zhang Z, Yang J, Ke P, et al. Defending Large Language Models Against Jailbreaking Attacks Through Goal Prioritization[J]. arXiv preprint arXiv:2311.09096, 2023.

[54] Li X, Yu P, Zhou C, et al. Self-Alignment with Instruction Backtranslation[C]//The Twelfth International Conference on Learning Representations. 2023.

[55] Xu C, Sun Q, Zheng K, et al. WizardLM: Empowering Large Language Models to Follow Complex Instructions[J]. arXiv preprint arXiv:2304.12244, 2023.

[56] Li X L, Liang P. 20220309-Prefix-Tuning: Optimizing Continuous Prompts for Generation[C]//Proceedings of the 59th Annual Meeting of the Association for Computational Linguistics and the 11th International Joint Conference on Natural Language Processing (Volume 1: Long Papers). Online: Association for Computational Linguistics, 2021: 4582-4597.

[57] Gu Y, Han X, Liu Z, et al. PPT: Pre-trained Prompt Tuning for Few-shot Learning[C]//Proceedings of the 60th Annual Meeting of the Association for Computational Linguistics (Volume 1: Long Papers). 2022: 8410-8423.

[58] Liu X, Ji K, Fu Y, et al. P-Tuning: Prompt Tuning Can Be Comparable to Fine-tuning Across Scales and Tasks[C]//Proceedings of the 60th Annual Meeting of the Association for Computational Linguistics (Volume 2: Short Papers). Dublin, Ireland: Association for Computational Linguistics, 2022: 61-68.

[59] Ju S, Wang C. Beyond Simple Text Style Transfer: Unveiling Compound Text Style Transfer with Prompt-Based Pre-Trained Language Models[C]//ICASSP 2024 - 2024 IEEE International Conference on Acoustics, Speech and Signal Processing (ICASSP). 2024: 6850-6854.

[60] Ji Z, Lee N, Frieske R, et al. Survey of Hallucination in Natural Language Generation[J]. ACM Computing Surveys, 2023, 55(12): 1-38.

[61] Ilić S, Marrese-Taylor E, Balazs J, et al. Deep contextualized word representations for detecting sarcasm and irony[C]//Proceedings of the 9th Workshop on Computational Approaches to Subjectivity, Sentiment and Social Media Analysis. Brussels, Belgium: Association for Computational Linguistics, 2018: 2-7.

[62] Radford A, Narasimhan K, Salimans T, et al. Improving Language Understanding by Generative Pre-Training[EB/OL]. (2018). https:// s3-us-west-2. amazonaws. com/openai-assets/research-covers/ language-unsupervised/language_understanding_paper.pdf.

[63] 车万翔, 刘挺. 自然语言处理新范式：基于预训练模型的方法[J]. 中兴通讯技术, 2022, 28(2): 3-9.

[64] Vaswani A, Shazeer N, Parmar N, et al. Attention is All you Need[C]//Advances in Neural Information Processing Systems: Volume 30. Curran Associates, Inc., 2017: 5998-6008.

[65] Raffel C, Shazeer N, Roberts A, et al. Exploring the Limits of Transfer Learning with a Unified Text-to-Text Transformer[J]. Journal of Machine Learning Research, 2020, 21(140): 1-67.

[66] Min S, Lyu X, Holtzman A, et al. Rethinking the Role of Demonstrations: What Makes In-Context Learning Work?[C]//Proceedings of the 2022 Conference on Empirical Methods in Natural Language Processing. Abu Dhabi, United Arab Emirates: Association for Computational Linguistics, 2022: 11048-11064.

[67] Zhang S, Dong L, Li X, et al. Instruction Tuning for Large Language Models: A Survey[J]. arXiv preprint arXiv:2308.10792, 2023.

[68] Jin D. Deep Learning for Text Style Transfer: A Survey [J]. Computational Linguistics, 2022, 48(1): 155-205.

[69] Kusner M, Sun Y, Kolkin N, et al. From Word Embeddings To Document Distances[C]//Proceedings of the 32nd International Conference on Machine Learning. PMLR, 2015: 957-966.

[70] Madaan A, Setlur A, Parekh T, et al. Politeness Transfer: A Tag and Generate Approach[C]//Proceedings of the 58th Annual Meeting of the Association for Computational Linguistics. 2020: 1869-1881.

[71] Lee D, Tian Z, Xue L, et al. Enhancing Content Preservation in Text Style Transfer Using Reverse Attention and Conditional Layer Normalization[C]//Proceedings of the 59th Annual Meeting of the Association for Computational Linguistics and the 11th International Joint Conference on Natural Language Processing (Volume 1: Long Papers). Online: Association for Computational Linguistics, 2021: 93-102.

致　谢

荏苒冬春谢，在武大求学近八年，现在，我的求学生涯也到达尾声。回首过去三年的硕士生活，过往历历在目，有初入实验室的迷茫、课题陷入僵局的苦闷，也有老师的悉心指导和同学们热心的帮助，有论文录用时的欢欣……过往种种，历历在目，抚之怅然，又无处可寻。在此，我向曾经帮助过我的老师、同学和亲友献上我最诚挚的感谢。

首先感谢我的恩师彭敏教授。彭老师是我科研学习路上的引路人，为我的硕士生涯提供了许多指导和帮助。感谢您将我带入实验室温暖的大家庭中，也为我们提供了良好的学习环境和许多学术交流机会。在学术上，您认真不苟地指导我开展课题工作，使我硕士生涯中没有经历拒稿的挫折，论文均被顺利接收；在生活中，您关怀备至，在我生病期间给予了我很多鼓励和日常生活中的支持。在此，我向彭老师表示衷心的感谢和真挚的敬意，祝您阖家欢乐、工作顺利。

其次，我要感谢贾旭、刘奔和其他实验室的同学们，带我融入这个其乐融融的大家庭，在我的学习和生活中提供了许多热心的帮助。初入实验室的懵懂时期，贾博士和韩博士为我耐心解惑；和刘奔师兄的讨论总能激发新的思维火花；和实验室同学们每周一聚的推杯换盏、一同参加 CCL 会议，也是我硕士期间难忘的学术交流经历……此外，我要感谢我的朋友杨星煜和我的舍友们。感谢你们在我身边鼓励我，为我扫清心底的阴霾，让我在受挫、郁闷之时能够重拾勇气和信心，继续勇往直前。你们都是我硕士生涯画布上浓墨重彩的一笔，在此也祝愿大家学业有成、万事如意。

接下来，我要感谢将要审阅论文的专家和评委们，感谢你们百忙之中抽出宝贵的时间审阅本论文，感谢你们提出的宝贵意见。

最后，我要感谢我的家人，感谢父母对我无微不至的关怀，你们的鼓励和关爱给了我无尽的力量去战胜一个个困难；感谢我的姐姐许捷文，你是我的知己，不论是学业还是生活中都始终支持着我、陪伴着我，让我永不孤单。同时，我也感谢 WAR 同学，你在我找工作、完成毕业设计的期间给予了我鼓励。在此祝愿所有我爱的人和爱我的人都身体安康、心想事成。

附录 A：个人简历

1998 年 12 月 5 日出生于湖北省宜昌市当阳市。

2016 年 9 月考入武汉大学基础医学专业，2018 年 3 月转专业至计算机科学与技术专业，2021 年 7 月本科毕业并获得工学学士学位。

2021 年 9 月保研入武汉大学人工智能系攻读硕士学位至今。

附录 B：在学期间参与的科研项目

[1] 国家科学技术部-科技创新 2030-“新一代人工智能”重大项目课题“人机融合医疗会诊关键技术与应用-面向医疗会诊的受限自然语言理解与生成”（项目编号：2021ZD0113304，2021/12-2024/11），在研中，实质性参与.

附录 C：在学期间取得的学术成果

1. 发表的论文

[1] **Xu M**, Peng M, Liu F. Text style transfer between classical and modern chinese through prompt-based reinforcement learning[J]. World Wide Web, 2023, 26(2): 733-750.（CCF B 类期刊，学生一作）

[2] **Xu M**, Peng M, Liu F. A dual reinforcement network for classical and modern chinese text style transfer[C]//Web Information Systems Engineering–WISE 2021: 22nd International Conference on Web Information Systems Engineering, WISE 2021, Melbourne, VIC, Australia, October 26–29, 2021, Proceedings, Part II 22. Springer International Publishing, 2021: 306-320.（CCF C 类会议，学生一作）

2. 获得的学术性奖励

（1）滴滴专项奖学金，2022-2023 年

（2）优秀学业奖学金，2021-2023 年

（3）国泰君安专项奖学金，2021-2022 年

（4）优秀研究生，2022-2023 年