模拟实验声明（修订讨论稿）

本稿第 4.6.9 节及表 4.28 中的 ArgUNSC 数值为用于安排第三语料补充评价与展示预期分析方式的模拟结果，尚未进行对应的模型运行，不属于实测实验。表中统一假定评价对象含 1000 条金标关系，由预设的真阳性、假阳性和假阴性计数计算严格关系 F1；该分母不表示 ArgUNSC 真实划分的规模。该节设计是在 ArgUNSC 自身的训练、开发与测试划分上进行补充评价，模拟结果不纳入摘要、主要贡献或全文实测结论，也不构成跨任务泛化或跨语料迁移的证据。后续须以固定数据版本、真实划分和实际预测结果整体替换该节数值与分析，再用于正式送审。其余既有 AAEC、CDCP 正式实验结果沿用已完成的实测数据。

分类号：_____　　密　级：_____
U D C：_____　　编　号：10486

硕士学位论文

基于一致性学习与结构约束修正的端到端论辩挖掘研究

研究生姓名：（盲审版本隐去）
学　　号：（盲审版本隐去）
指导教师姓名、职称：（盲审版本隐去）
专业名称：（盲审版本隐去）
研究方向：（盲审版本隐去）

二〇二六年十月

End-to-End Argument Mining via Consistency Learning and Structure-Constrained Repair

By

***

Supervised By

***

Wuhan University

October, 2026

论文原创性声明

本人郑重声明：所呈交的学位论文，是本人在导师指导下，独立进行研究工作所取得的研究成果。除文中已经标明引用的内容外，本论文不包含任何其他个人或集体已发表或撰写的研究成果。对本文的研究做出贡献的个人和集体，均已在文中以明确方式标明。本声明的法律结果由本人承担。

学位论文作者（签名）：

日期:　　年　　月　　日

武汉大学学位论文使用授权协议书

本学位论文作者愿意遵守武汉大学关于保存、使用学位论文的管理办法及规定，即：学校有权保存学位论文的印刷本和电子版，并提供文献检索与阅览服务；学校可以采用影印、缩印、数字化或其它复制手段保存论文；在以教学与科研服务为目的前提下，学校可以在校园网内公布部分或全部内容。

一、在本论文提交当年，同意在校园网内以及中国高等教育文献保障系统（CALIS）、高校学位论文系统提供查询及前十六页浏览服务。

二、在本论文提交□当年/□一年/□两年/□三年以后，同意在校园网内允许读者在线浏览并下载全文，学校可以为存在馆际合作关系的兄弟高校用户提供文献传递服务和交换服务。（保密论文解密后遵守此规定）

论文作者（签名）：

学　　号:

学　　院:

日期:　　年　　月　　日

摘要

论辩挖掘旨在识别文本中的论点、前提及其支持与攻击关系，为写作评价、舆情分析等应用提供结构化依据。大语言模型能够从原始文本直接生成论辩结构，但组件与关系之间的相互依赖仍给模型学习和结果修正带来困难：局部改写可能改变组件的论辩角色或关联关系，使继承的标注成为错误监督；预测图中的组件错误会影响多条关系，独立修正局部对象又难以兼顾整体结构。

针对上述问题，论文分别研究增强监督的可靠利用与预测结构的协调修正：前者改善模型学习所依据的监督信号，后者在不更新抽取模型参数的条件下，联合决定组件及其关联关系的修改。具体研究内容如下：

（1）针对局部改写后原标注可能失效的问题，提出可靠监督与一致性学习方法。该方法先确定改写可能影响的组件与关系范围，并建立原文与改写文本之间的组件对应关系，再通过语义审核筛选仍然可靠的组件类型和关系状态。训练时，原文提供完整的论辩图监督，改写文本仅在通过审核的部分提供辅助监督与一致性约束，从而利用增强数据补充学习信号并减少错误监督的影响。在英文议论文与公共政策评论两个语料上的实验表明，与同骨干的基准模型相比，该方法使严格关系 F1 分别由 65.69%和 41.79%提高至 68.25%和 45.08%。

（2）针对组件错误及其关联关系难以协调修正的问题，提出结构约束联合修正方法。该方法将组件修改与全部受影响关系的重建组织为共同接受或拒绝的操作，在固定候选与对象评分的条件下，结合结构约束、分项效用和编辑预算选择修正结果，以控制修改范围并减少对原有正确结构的破坏。对照实验表明，联合修正直接作用于基准模型时能够改善抽取性能，在第一项研究得到的模型上仍可继续修正残余错误，使两个语料的严格关系 F1 进一步提高至 71.63%和 50.77%；与相同预算的重新生成相比，联合修正取得了更高的 F1，并保留了 98%以上的原有正确关系。

在同一开源大语言模型系列的三种骨干配置上，两项方法均取得性能提升。对照结果表明，可靠监督与一致性学习能够独立改善抽取效果，结构约束联合修正能够适用于不同训练配置的预测结果，并在可靠监督学习的基础上进一步提高完整论辩图的抽取准确性。

关键词：论辩挖掘；大语言模型；一致性学习；结构化预测；联合修正

Abstract

Argument mining identifies claims, premises, and their support or attack relations to provide structured evidence for applications such as writing assessment and public opinion analysis. Large language models can generate argument structures directly from text, but the interdependence of components and relations presents challenges for learning and repair. Local rewriting may change argumentative roles or relations, making inherited annotations unreliable. Component errors can affect multiple relations, while independent local corrections may fail to maintain structural consistency.

This thesis investigates the reliable use of augmented supervision and the coordinated repair of predicted structures. The first study improves the supervision used for learning, while the second makes joint decisions on component edits and associated relations without updating the extraction model. The main contributions are as follows.

(1) A reliable supervision and consistency learning method is proposed to address annotation invalidation after local rewriting. It identifies potentially affected components and relations, aligns components between the original and rewritten texts, and audits the validity of component types and relation states. The original text provides complete graph supervision, whereas the rewritten text contributes auxiliary supervision and consistency constraints only for accepted annotations. This uses augmented learning signals while reducing erroneous supervision. On persuasive essay and public policy comment corpora, strict relation F1 increases from 65.69% and 41.79% to 68.25% and 45.08%, respectively, compared with the baseline using the same backbone.

(2) A structure-constrained joint repair method is proposed to coordinate component corrections with their affected relations. Component edits and reconstruction of all affected relations are accepted or rejected together. With fixed candidates and object scores, structural constraints, separate utility requirements, and edit budgets guide repair decisions to limit changes and preserve correct structures. Controlled comparisons show that joint repair improves extraction when applied directly to the baseline and also corrects residual errors in the model obtained in the first study, further increasing strict relation F1 to 71.63% and 50.77% on the two corpora. Compared with regeneration under the same budget, joint repair achieves higher F1 while preserving more than 98% of previously correct relations.

Both methods improve performance across three backbone configurations from the same open-source large language model family. Controlled comparisons show that reliable supervision and consistency learning improve extraction independently, while structure-constrained joint repair can operate on predictions from different training configurations and further improve complete argument graph extraction when combined with reliable supervision learning.

Keywords: Argument Mining, Large Language Models, Consistency Learning, Structured Prediction, Joint Repair

目录

摘要.....I
Abstract.....II
主要符号对照表.....VII
第 1 章 绪论.....1
1.1 研究背景与意义.....1
1.2 国内外研究现状.....2
1.2.1 端到端论辩挖掘方法.....3
1.2.2 论辩挖掘中的数据增强.....4
1.2.3 结构化预测与预测结果修正.....5
1.3 主要研究内容.....6
1.4 论文组织结构.....8
第 2 章 相关理论与技术.....9
2.1 论辩挖掘任务与结构表示.....9
2.1.1 论辩组件与关系.....9
2.1.2 组件的字符级表示.....10
2.2 大语言模型与参数高效微调.....11
2.2.1 注意力机制与自回归生成.....11
2.2.2 参数高效微调与连续提示.....12
2.3 数据增强与一致性学习.....13
2.4 候选评分与结构化决策.....14
2.5 本章小结.....15
第 3 章 基于可靠监督与一致性学习的论辩挖掘方法.....16
3.1 引言.....16
3.2 总体框架与基础模型.....17
3.3 基于关系影响域的可靠增强数据构造.....19
3.3.1 改写范围与关系影响域.....19
3.3.2 改写生成与标注迁移.....21
3.3.3 语义审核与因素掩码.....22
3.3.4 标注迁移与改写案例.....24
3.4 一致性学习模型与训练.....26
3.4.1 辅助预测头与一致性约束.....28
3.4.2 损失归一化与参数更新.....30

3.4.3 算法流程与性质分析 31
3.5 实验与分析 32
3.5.1 数据集与评价指标 32
3.5.2 对照方法 34
3.5.3 实验环境与参数设置 35
3.5.4 主要结果与消融分析 38
3.5.5 增强数据的人工审核 40
3.5.6 训练成本与跨骨干表现 43
3.6 本章小结 45
第 4 章 基于结构约束的论辩图联合修正方法 46
4.1 引言 46
4.2 候选生成与初始图 49
4.2.1 多候选生成与初始图选择 49
4.2.2 候选空间构建 50
4.3 对象评分与接受准则 51
4.3.1 对象评分器与策略选择 52
4.3.2 效用函数与接受条件 53
4.4 依赖闭合事务的构造 54
4.4.1 组件冲突消解 54
4.4.2 受影响关系的重建 55
4.4.3 事务示例 56
4.5 求解算法及性质 57
4.5.1 集合局部搜索 57
4.5.2 全局整数规划求解 60
4.5.3 方法性质分析 62
4.5.4 求解方式的选择 63
4.6 实验与分析 64
4.6.1 实验设置 65
4.6.2 主要结果与消融分析 69
4.6.3 候选覆盖与评分质量分析 74
4.6.4 推理成本分析 81
4.6.5 与第 3 章方法的衔接分析 83
4.6.6 多前提关系分析 87
4.6.7 不同骨干模型上的结果 89

4.6.8 与外部系统及已发表结果的比较.....91
4.6.9 ArgUNSC 语料上的补充评价.....94
4.7 本章小结.....95
第 5 章 总结与展望.....97
5.1 全文工作总结.....97
5.2 未来工作展望.....98
参考文献.....100
致谢.....113
附录 A 个人简历.....114
附录 B 在学期间参与的科研项目.....115
附录 C 在学期间取得的学术成果.....116

主要符号对照表

符号	含义	定义位置
x、x'	原文及其改写文本	2.1.2
A	被改写组件的集合	3.3.1
D_A	关系影响域：可审核因素中至少一个端点位于 A 内的因素	3.3.1
J_A	实际审核的因素集合，包括受影响正关系和抽样的 NONE	3.3.3
φ	原文组件到改写组件的对应映射	3.3.2
m_C、m_R	组件与关系因素的可靠性掩码	3.3.3
Ω_{sem}	可审核的因素集合，排除语义未知的多前提子集	3.3.3
G_0；I0 / I1	初始图；MCR-BR 推理流程 / 追加联合修正的推理流程	2.4、4.2.1
U；V；P	跨度；带类型组件；完整关系候选池	4.2.2
q_C；q_R	完整组件与完整关系的固定评分	4.3.1
Φ_C；Φ_R；Φ	组件、关系与总效用	4.3.2
R_{DC}；BR-J	追加的联合修正；集合局部搜索子程序	4.1、4.5.1
δ；B_C；B_R	严格改进阈值；组件与关系编辑预算	4.3.2、4.5.2
T0／T1	MCR-BR 的训练配置／第 3 章可靠监督与一致性学习方法的训练配置	3.5.3
T0I0、T1I0、T0I1、T1I1	训练配置与推理配置的四种组合，如 T1I1 表示第 3 章训练配置加第 4 章联合修正	4.6.5

第 1 章 绪论

1.1 研究背景与意义

论辩广泛存在于议论文写作和公共议题讨论之中，人们通过提出观点、给出理由和回应异议来表达立场。理解这类文本，需要结合上下文识别各个片段的论证功能，并判断它们如何相互支持或反驳。由于论述内容分散、表达形式多样，人工梳理论证过程往往耗时较长，自动识别论辩结构因而成为自然语言理解领域的重要研究问题[1]。论辩挖掘（Argument Mining，AM）[1]旨在识别文本中的论辩组件及其关系，将非结构化的论述转化为论辩图。其中，组件是在论证中承担观点、理由等功能的文本片段，关系则描述这些片段之间的支持或攻击联系。通过定位组件、判断其类型并识别关系，论辩挖掘能够为写作反馈、公共讨论分析等应用提供结构化依据。

图 1.1 给出了论辩标注作文语料（Argument Annotated Essays Corpus，AAEC）[2]中文档 essay001 的局部结构，图中中文为辅助译文。T3 是被支持的观点，T4、T5 和 T6 是支撑该观点的理由。该观点主张合作有助于儿童学习人际交往技能，三条理由分别强调团队相处经验、沟通与妥协，以及这些技能对未来生活的价值。例如，若将 T5 改写为竞争对个人成长的益处，文字即使通顺，也未必继续支持合作的价值；若只更换措辞而保留原意，则原有支持关系仍可能成立。模型既要识别这些片段的边界和类型，又要恢复从理由指向观点的支持关系；若 T3 的边界或论证角色被误判，以其为端点的三条关系也可能受到影响。这说明，组件与关系相互依赖，孤立地预测局部对象难以保证完整论辩结构的准确性。

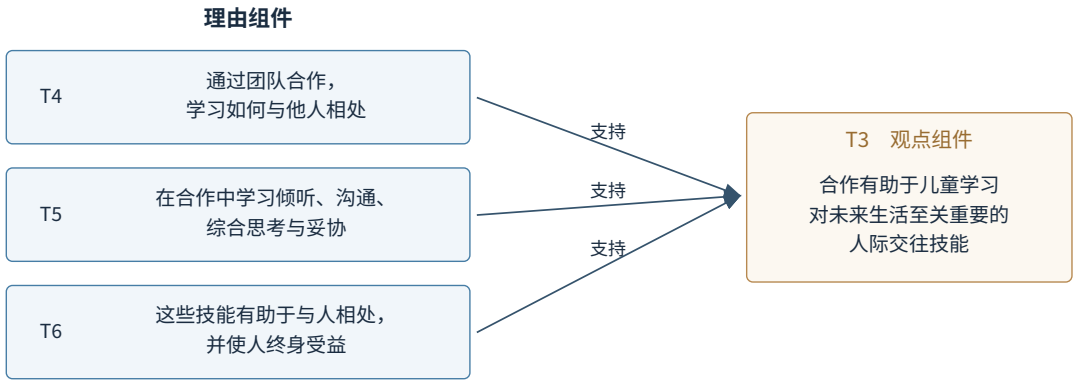


图 1.1 AAEC 语料中观点与理由的支持关系示例

早期研究分别处理组件识别与关系分类，随后逐步转向联合建模[2,3]；随着预训练语言模型和大语言模型的发展，生成式方法进一步将组件边界、类型和关系组织为统一的输出序列，直接从原文生成论辩结构[4]。然而，统一生成并不能消除结构判断中的错误，组件与关系的依赖仍给训练数据构造和预测结果修正带来困难。

训练数据构造的难点在于局部改写后的标注保持。论辩标注需要同时确定文本片段、组件类型和相互联系，构建成本较高[1,2]。借助语言模型改写文本可以扩充训练数据[5]，但表达流畅、主题相近并不意味着论证角色和支持关系保持不变。若像槽位化增强方法一样直接继承全部原标注[6]，就可能将失效标注作为新的监督。因此，需要判断改写后哪些组件与关系标注仍可用于学习。

预测结果修正的难点在于组件与关系的协调变化。组件边界或类型改变后，关联关系可能需要重新判断；若仅保留原有连接，修正后的图仍可能与文本不符，而反复生成或大范围修订又会增加开销，并可能破坏原本正确的部分。因此，需要在控制修改范围和计算成本的同时，联合决定组件及其关联关系的变化。围绕上述问题，本文分别研究训练阶段的可靠监督与一致性学习，以及推理阶段的结构约束联合修正，以组件与关系的相互依赖为主线，改进增强数据的利用方式和预测结构的决策过程。

1.2 国内外研究现状

本节从端到端论辩挖掘、论辩数据增强以及结构化预测与结果修正三个方面梳理国内外研究现状，重点比较已有方法的输入条件、监督使用方式及组件与关系的处理机制。

1.2.1 端到端论辩挖掘方法

端到端论辩挖掘以原始文本为输入，同时完成组件定位、类型判断及关系识别。现有方法主要包括流水线处理、联合结构建模和生成式结构预测，其中生成式预测也是联合建模的一种实现方式。早期方法通常分别处理组件与关系，Stab 和 Gurevych[9]研究说服性作文的论辩话语结构，Persing 和 Ng[10]构建学生作文端到端分析系统。这类流水线方法便于分解任务，但前序识别错误容易传递到关系判断。Potash 等人[11]通过联合指针架构关联组件分类与链接预测，推动了子任务间的联合学习。

联合结构建模进一步将组件、关系及结构约束纳入统一框架。LSTM-ER[3]采用神经网络联合识别组件与论证结构，Niculae 等人[12]以结构化支持向量机和循环神经网络联合预测组件与关系，Morio 等人[13]通过双仿射解析支持非树状结构。这些方法能够利用对象间的相互约束，但解析与推断机制通常需要适配语料的结构形式。

生成式方法利用统一序列直接表示论辩结构，但在输出表示和结构约束的施加位置上存在差别。Kawarada 等人[4]将任务转化为文本到文本生成，由模型学习从原文到结构序列的对应；GMAM[14]则利用约束指针及重构的位置编码，将组件定位与关系表示组织为紧凑序列，其重点是让生成结果能够指向原文中的结构对象。UniASA[15]把多种论辩结构分析任务统一为序列生成，并通过子任务分解进行多视图学习，侧重不同任务之间的监督共享；AASP[16]采用预定义动作逐步构建论辩结构，将结构信息融入自回归生成过程。Cabessa 等人[17]也通过生成方式处理组件与关系分类，但输入已经给定组件列表，省去了原文中的组件定位；ARGUS[18]整合组件切分、分类及关系预测，并引入符号求解器分析所得论辩框架。比较这些方法时，既要关注表示与推断机制，也需区分输入是否预先包含组件信息。Li 等人[19]的综述进一步梳理了大语言模型的应用及不同评价设定。

结构与语义信号也可辅助联合预测。DENIM[20]引入篇章结构感知前缀，Das 等人[21]通过关键短语关联组件语义，Sun 等人[22]利用一阶逻辑规则组织关系查询。其中后两者以预先切分的组件为输入，其分类结果不能直接等同于从原文定位组件的端到端效果。

语料条件同样影响方法比较。辅助语料多任务训练[23]、统一 19 个数据集的 AMELIA[24]扩展了数据利用范围，而 Feger 等人[25]发现模型对语料词汇线索的依赖限制了跨数据集泛化。本文以 AAEC 和消费者债务催收实践评论语料

（Consumer Debt Collection Practices，CDCP）[12,26]作为主要实验语料，分别保留其原生组件和关系定义。ORCHID[27]与 IAM[28]提供立场识别、论点及证据抽取等资源，但其任务范围与完整论辩图抽取存在差异。

国内研究从任务类型与应用场景补充了上述认识。李永泽和欧石燕[7]梳理了论辩模型、挖掘任务及应用，魏忠钰等人[8]区分单体式与对话式论辩，说明多参与者交互带来的建模差异。在跨主题和中文场景中，Stab 等人[29]研究异质来源的论辩识别，言佳润和鲜于波[30]比较中文网络对话中的微调与提示学习，张霄军和周静狮[31]构建中英双语政治论辩资源。这些研究表明，评价时需要区分文本来源、标注单位和关系定义。

总体而言，现有方法逐步实现了组件与关系的统一预测，但组件边界仍是误差来源。Caputo 等人[32]通过成对标签进行细粒度切分，并分析切分误差对后续分类的影响。如何减少训练监督中的结构噪声，以及如何协调修正预测对象，仍值得进一步研究。

1.2.2 论辩挖掘中的数据增强

数据增强通过改变文本表达扩充训练样本，其效果取决于内容与标签能否保持对应[5]。CoDa[33]利用训练实例中的约束控制生成，SegMix[34]在任务相关片段上进行结构感知混合，均强调增强操作与监督形式的匹配。通用增强方法包括 EDA[35]的词语替换、插入、交换与删除，利用翻译过程生成新表达的回译[36]，以及结合上下文选择替换词的语言模型增强[37]。相关综述[38,39]指出，增强方式应适配任务条件；对于同时包含跨度、类型和关系的标注，文本整体语义相近并不足以保证各项监督均有效。

论辩挖掘中的质量导向合成方法 QOS[6]采用槽位化输入，改写后恢复组件跨度并继承类型与关系标注；其生成过程不显式接收关系，而依靠语义保持延续原有关系。这为局部改写提供了实现途径，也留下了如何识别失效标注的问题。同一研究中的多样性导向合成方法 DOS[6]侧重丰富表达，Zhang 等人[40]则通过交替优化生成器和判别器合成文本—结构标注对。本文采用局部改写，但不直接沿用全部监督，而是保留原文的完整标注，并检查改写侧可继续使用的部分。局部改写通常只影响文档中的一部分监督：某条关系不再成立，并不意味着其他组件和关系都失效。若按整篇文本决定接受或丢弃，前者可能混入错误标签，后者又会损失尚可利用的监督。因而需要把审核粒度落实到组件类型和关系状态，既检查已标注的连接，也考虑原先无关系的端点是否产生了新的联系。这样的选择性保留才能将表达多样性与标注可靠性结合起来。

关系抽取增强也重视质量控制：ConsistRE[41]利用关系条件与上下文约束生成，CovEReD[42]通过反事实实体替换考察一致性，ODDA[43]平衡低资源增强中的质量与多样性，Wang 等人[44]结合生成样本、一致性正则化及反馈改进联合抽取。夏振涛等人[45]对监督方式和联合建模的梳理也说明，关系预测需要考虑其端点对象。与实体关系不同，论辩组件承载观点或理由，其局部改写可能改变论证角色及支持、攻击联系。因此，本文将单个组件类型或一组端点之间的关系状态作为监督判断单位，逐项确定哪些标注仍然可靠，而不以整篇文本是否相似替代标签检查。话语标记补全的效果因语料而异[46]，弱监督论辩挖掘也面临边界与关系噪声[47]。上述研究共同提示，增强评价需要同时考察新增样本、标签可靠性及训练收益，区分数据构造与学习目标各自的作用。

1.2.3 结构化预测与预测结果修正

结构化预测可在生成过程中施加约束，也可在生成后选择或修正候选。语法约束解码[48]限制下一步可生成的词元，AASP[16]约束结构构建动作，二者主要控制输出规则；组件边界及关系是否符合文本，仍需要语义判断。

生成后修订方面，Self-Refine[49]利用模型反馈迭代改写，自一致性方法[50]聚合多条推理路径，但缺乏外部反馈时自我纠错未必有效[51]。Tran 等人[52]从多种论点、证据与保证组合中选择切分结果，也说明候选质量和选择机制会影响收益。本文采用预先固定的对象评分，为组件与关系的选择提供一致的评价依据。

对象与关系的联合处理为结构修正提供了另一思路。Re-Cent[53]利用关系标签引导跨度对抽取，并通过二者相关性修正结果；大语言模型论辩重构流程[54]包含组件合并、重写与关系检查，其允许改写文本的设定不同于原文跨度抽取；Xiao 和 Li[55]将模型自我解释转为抽象论辩框架，并定义最小代价修复目标。

多候选重排序与有界修正方法（Multi-Candidate Reranking and Bounded Repair，MCR-BR）[56]支持候选跨度替换、类型调整与关系修订，但组件变化所涉及的关联范围和联合接受机制仍有进一步完善的空间。本文据此研究组件修改与受影响关系的整体决策，在有限候选和编辑预算内协调各项变化。这里需要处理的不只是被修改组件本身，还包括哪些既有关联关系需要删除或按新端点重建、替换后的端点如何连接，以及是否应新增或删除关系。组件得分上升而关联关系质量下降时，分别接受各项修改可能得到不协调的结构；反过来，若单项修改暂时破坏了端点或结构约束，连同关联关系一起调整则可能形成合

法且效用更高的结构。因此，关键在于确定受影响对象的范围，并在同一候选结构下评价和接受一组关联修改。

修正评价还需区分对象评分与整体指标：F1 最优决策一般不能由单个对象的边际概率直接确定[57]，校准概率与最优阈值的关系具有适用条件[58]，概率校准本身衡量的是置信度与正确率的一致程度[59]。因此，本文同时评价抽取效果、错误修改与计算成本。已有研究分别改进了生成、增强和修正过程。本文进一步围绕两个相互关联的问题展开：训练时如何保留局部改写后仍有效的监督，推理时如何将组件变化与相关关系的重建纳入共同决策。

1.3 主要研究内容

本文围绕组件与关系的相互依赖开展两项研究：训练阶段关注增强监督是否可靠，推理阶段关注预测结构如何协调修正。前者改善模型学习所依据的信号，后者处理训练后仍残留的结构错误，研究对象和决策条件各有侧重。两项工作的联系如图 1.2 所示。可靠监督与一致性学习以带标注文本为输入，构造经过审核的增强视图；结构约束联合修正面向无标注文本的预测结果，在固定候选与评分的条件下选择组件及关系。后者可与前者所得模型衔接，也可作用于其他训练配置得到的模型。

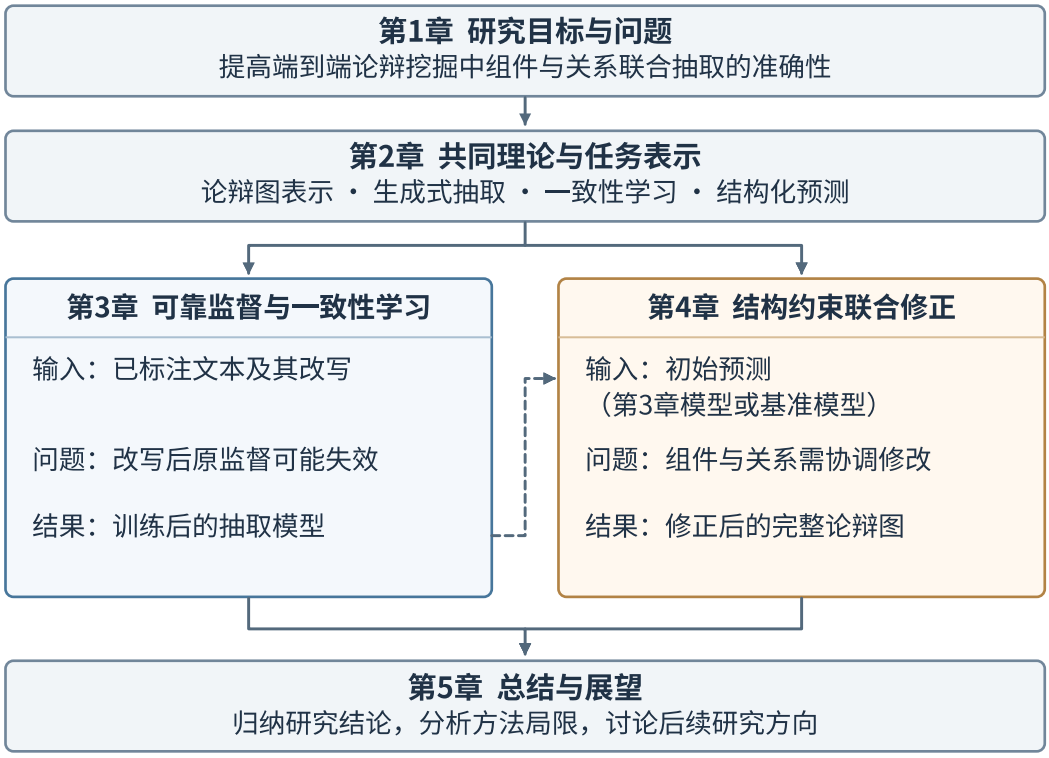


图 1.2 总体研究框架与章节逻辑关系

低秩适配（Low-Rank Adaptation，LoRA）[60]双分支、结论线索提示、句子辅助监督及初始候选处理沿用 MCR-BR[56]的配置，本文新增工作如下。

（1）提出可靠监督与一致性学习方法。针对局部改写可能使标注失效的问题，先界定受改写影响的组件与关系，将原标注迁移至改写文本，再逐项审核其语义可靠性。训练时保留原文的完整论辩图监督，仅在审核通过的组件与关系上施加辅助监督与一致性约束。与整篇筛选不同，该方法将监督和一致性约束限定在可靠的局部对象上，保留改写中仍有价值的部分，不要求增强文本完整继承原有论辩图。该方法分别处理多前提关系中的完整匹配与语义无关系状态，并通过控制增强样本和学习目标的对照实验检验各模块作用。

（2）提出结构约束联合修正方法。可靠监督能够改善训练信号，但不能保证所有预测组件与关系均正确。针对残余错误，该方法把组件修改及受影响关系的重建组织为须共同接受或拒绝的整体，在对象评分、结构约束和编辑预算下联合选择论辩结构，并给出集合局部搜索与全局整数规划两种求解方式。该研究进一步处理预测结构的选择，不重新训练抽取模型，而是根据组件与关系的共同变化作出决策，避免只依赖单个局部对象的得分。与仅修改关系或逐项修改对象相比，该方法进一步研究关联重建及共同决策的作用，并通过独立应用与组合应用验证其与第一项工作的衔接。

实验按完整组件和关系严格评价，并使用文档与种子联合重采样[61]及 Holm 校正[62]检验主要比较。在 AAEC 和 CDCP 上，训练方法使严格关系 F1 分别由 65.69%和 41.79%提高至 68.25%和 45.08%，追加联合修正后达到 71.63%和 50.77%。同一开源大语言模型系列的另外两种骨干配置也取得提升，具体实验设置及消融分析分别见第 3 章和第 4 章。

1.4 论文组织结构

本文共分为五章，各章围绕“监督可靠性—结构联合修正”的研究主线展开，逻辑关系见图 1.2。第 1 章从组件与关系的依赖出发提出训练与推理中的两个问题；第 2 章提供统一的任务表示和理论基础，第 3 章与第 4 章分别研究可靠学习和结构决策，二者通过模型预测衔接；第 5 章综合两项工作的结论与局限。各章内容安排如下。

第 2 章介绍论辩挖掘的任务定义、大语言模型与参数高效微调、连续提示[63]、一致性学习及结构化决策等相关理论与技术。

第 3 章介绍可靠监督与一致性学习方法，并通过对照实验分析抽取效果、监督审核质量及训练成本。

第 4 章介绍结构约束联合修正方法，分析联合决策、修正质量与计算开销，并考察其独立应用、与第 3 章方法组合以及不同骨干配置下的效果。

第 5 章总结全文研究工作，分析现有局限并展望后续方向。

第 2 章 相关理论与技术

论辩挖掘需要从没有结构标注的文本中同时识别论辩组件及其相互关系，组件与关系如何表示、模型如何学习、候选结构如何选择，共同决定了训练阶段能否保留可靠的监督、推理阶段能否修正残余的结构错误。本章围绕后续两章共同使用的任务表示与相关技术展开介绍，为第 3 章和第 4 章的方法设计奠定基础。首先，给出论辩组件与关系的统一表示，明确组件的字符级身份与合法结构的基本要求；在此基础上，介绍大语言模型的注意力机制、自回归生成与参数高效微调技术；进一步地，介绍数据增强与一致性学习，以及候选评分与结构化决策的基本概念。评价指标与实验设置与具体方法的实验分析联系更为紧密，分别在第 3 章和第 4 章的实验部分给出。

2.1 论辩挖掘任务与结构表示

2.1.1 论辩组件与关系

论辩挖掘以没有结构标注的文档为输入，旨在识别其中的论辩组件并判断组件之间的关系：组件识别确定论辩相关文字在原文中的位置，组件分类则判断其在论证中承担的类型。本文采用端到端设定，即直接从原文预测组件与关系，系统内部可以包含生成、候选选择和预测修正等多个步骤。

为统一描述上述任务，记文档为 x，其标识为 d，该标识同时记录语料、原始文档编号及文本版本，字符位置按原文的 Unicode 码点从 0 开始计数。在此基础上，组件表示为：

$$c=(d,b,e,t),\qquad 0\le b<e\le|x|, \tag{2-1}$$

其中，$[b,e)$ 为左闭右开的字符区间，$x[b:e]$ 为组件对应的原文片段，t 为语料定义的组件类型。由此，组件由字符区间和类型共同确定：相同文字出现在文档的不同位置时视为不同的组件，同一字符区间被赋予不同类型时也视为不同的预测对象，评价时二者都必须完全匹配。

二元关系表示两个组件之间的有向联系，记为 $r=(c_i,c_j,\ell)$，其中 c_i 为源组件，c_j 为目标组件，ℓ 为关系标签，关系方向由提供理由或发起攻击的一方指

向被支持或被攻击的一方。组件与关系共同构成文档的论辩结构，记为 $G=(C,R)$，其中 C 为组件集合，R 为关系集合。

部分语料允许多个组件共同支持同一个目标，此时关系表示为 $h=(S,c_j,\ell)$，其中 S 为非空的源组件集合，集合中的成员共同构成一条完整关系。若将其拆分为多条二元边，计数单位和匹配条件都会随之改变，因此本文保留原始的多前提结构，二元关系可视为源集合大小为 1 的特例[12,26]。两种语料的原生任务表示及中文标签如表 2.1 所示。

表 2.1 两种语料的原生任务表示与标签对照

语料	组件类型	关系类型	评价时保留的任务边界
AAEC	主论点、论点、前提	支持、攻击二元关系	论点对主论点的立场单列，不补造普通关系
CDCP	事实、证言、价值、政策、引用	理由、证据多前提关系	完整源集合参与匹配，不归并组件类型，不拆分超边

两种语料的任务定义沿用原始标注及相关研究[2,12,26]，实验也分别按各自的原始标注进行评价。以 CDCP 为例，若一条关系有两个源组件，预测时漏掉其中任意一个都不能与该关系匹配；第 3 章用到的“结论角色”仅用于选择增强中心，并不改变 CDCP 的原始组件类型。为便于阅读，后文正文与图表中的组件类型和关系标签统一使用表 2.1 给出的中文名称。

2.1.2 组件的字符级表示

严格匹配以原文字符边界识别组件，边界相差一个字符也视为不同对象。模型子词与评价分词均为原文的派生表示，需要通过字符偏移映射回原文。仅记录词元的起止索引和组件类型，不能区分覆盖相同词元、但字符边界不同的片段，尤其是边界位于单词内部的情形。因此，本文以字符区间确定组件身份，并在分词表示中额外保存边界偏移。

设评价分词所得各词元的字符区间为 $[a_i,z_i)$，组件的字符区间为 $[b,e)$。取与该组件相交的首、末词元索引 s、u（从 1 开始），并用左右字符残差保存精确边界：

$$\rho_L=b-a_s,\quad \rho_R=z_u-e;\qquad b=a_s+\rho_L,\quad e=z_u-\rho_R, \tag{2-2}$$

其中，ρL 和 ρR 分别表示组件边界相对首、末词元边界的偏移，由(s,u,ρ_L,ρ_R)即可恢复原始字符区间。模型子词也通过字符偏移与原文对应，聊天模板引入的位置偏移不计入原文坐标。

以 AAEC 文档 essay098 的论点组件 T6 为例，原始区间 [858,914) 在 responsible 的末尾字母之前结束，片段末尾为“responsibl”；将其扩展为完整单词，得到对照片段[858,915)。两者的评价词元闭区间均为[162,172]，对应词元字符区间均为[858,915)，但左右残差分别为(0,1)和(0,0)，由式（2-2）可恢复各自的字符边界。因此，两者虽然词元范围与类型相同，仍是严格匹配下的不同对象；字符残差只保存原始边界，不用于修正标注。

式（2-1）的文档标识、字符区间和类型共同构成组件的规范键；关系的规范键由全部端点的规范键和关系标签组成，多前提关系的源端保存排序后的完整组件集合。规范键用于候选去重、评分缓存、修改记录和严格匹配；T3、T4 等编号仅用于引用，重新编号不产生新对象，也不计为修改。

组件边界或类型改变时，其规范键及关联关系的端点身份随之改变，因此第 4 章需要按新端点重新判断相关关系，而不能直接沿用旧对象的评分。原文与增强文本属于不同文本版本，其组件对应与字符坐标迁移见 3.3.2 节。

记合法结构集合为 G_A，其中 A 为语料的标注规范。合法结构需满足以下基本要求：组件跨度位于原文范围内，组件类型和关系标签有效，且关系的全部端点均存在；各语料实际启用的结构约束在 4.2.2 节逐项给出。

2.2 大语言模型与参数高效微调

2.2.1 注意力机制与自回归生成

Transformer[64]通过注意力机制聚合序列中不同位置的信息，是本文所用大语言模型骨干的基础结构。注意力机制首先根据查询与键之间的相似度计算权重，再对值向量进行加权求和，其中缩放点积注意力的计算方式如下：

$$\mathrm{Attention}(Q,K,V)=\mathrm{softmax}\left(\frac{QK^{\mathrm{T}}}{\sqrt{d_k}}\right)V, \tag{2-3}$$

其中，Q、K、V 分别为查询、键和值矩阵，d_k 为键向量的维度，此处的 V 与第 4 章的组件候选集合含义不同。在此基础上，多头注意力在多个表示子空间中并行计算注意力；自回归解码时，每个位置只能关注输入和已经生成的输出。

基于 Transformer 的预训练模型具有不同的结构与训练目标。BERT[65]通过双向编码学习上下文表示，BART[66]采用去噪序列到序列预训练，T5[67]则将多种语言任务统一为文本到文本形式。三者为判别式表示学习和生成式结构预测提供了不同基础，本文所用骨干及对照系统的具体选择在实验设置中列出。

基于自回归生成范式，论辩挖掘可以将组件位置、类型和关系依次序列化为输出序列 $Y=(y_1,\ldots,y_L)$，给定原文 x，其生成概率和训练目标分别表示为：

$$P_\theta(Y\mid x)=\prod_{k=1}^{L} P_\theta(y_k\mid x, y_{<k}), \tag{2-4}$$

$$L_{\text{gen}}=-\sum_{k=1}^{L}\log P_\theta(y_k\mid x, y_{<k}), \tag{2-5}$$

其中，训练时以金标序列作为前缀计算下一个符号的损失，测试时则以模型已经生成的符号作为前缀。生成式论辩挖掘[4]借助这一范式将多个子任务统一到同一个输出序列中；然而，序列概率同时受输出长度和字段顺序的影响，难以直接衡量单个组件或关系是否正确，因此本文另外训练了对象评分器，用于直接估计每个组件和关系的正确概率。

2.2.2 参数高效微调与连续提示

大语言模型参数规模庞大，针对具体任务更新全部权重会带来较高的训练与存储成本，参数高效微调则通过冻结大部分预训练参数、仅优化少量新增参数，实现对下游任务的高效适配。以低秩适配（LoRA）[60]为例，该方法冻结基础权重，只学习一个低秩增量，表示为：

$$W=W_0+\frac{\alpha}{r}BA,\qquad A\in\mathbb{R}^{r\times d_{\text{in}}},\quad B\in\mathbb{R}^{d_{\text{out}}\times r}, \tag{2-6}$$

其中，r 为秩，α 为缩放系数，训练时只更新增量矩阵，基础权重 W_0 保持不变。与 LoRA 调整权重的方式不同，连续提示[63]通过学习一组提示向量来表达任务条件，从输入侧实现参数高效的适配，两类方法都只引入少量可训练参数。

参数高效适配还包括在预训练层中插入少量可训练模块的 Adapter 方法[68]、在注意力计算中引入可学习前缀的 Prefix-Tuning[69]，以及将低比特量化与低秩

适配结合的 QLoRA[70]。唐岸达和林宙辰[71]从适配机制、应用与效率等方面总结了相关方法。上述技术改变了任务适配时更新的参数及计算开销，但并不自动保证增强标注可靠或预测结构合法；这两类问题仍需由本文的监督筛选和结构决策机制分别处理。

2.3 数据增强与一致性学习

数据增强通过改变输入的表达方式来扩充训练样本，然而，利用语言模型改写文本时，即使结果通顺，也可能使部分原有标注失效[5,6]。论辩挖掘的监督包括组件位置、组件类型和关系，局部的语义变化往往只影响其中一部分，因此本文将通顺性与标注保持分开判断，并以单个组件或单条关系为单位决定保留哪些监督。

一致性学习已有明确的方法基础。Temporal Ensembling[72]积累不同训练时刻的预测以构造一致性目标，Mean Teacher[73]通过模型权重的滑动平均形成教师预测，虚拟对抗训练（Virtual Adversarial Training，VAT）[74]则约束模型在局部扰动下的预测变化。面向文本的无监督数据增强（Unsupervised Data Augmentation，UDA）[75]将增强文本与预测一致性结合，R-Drop[76]约束不同 Dropout 采样得到的输出分布，FixMatch[77]结合高置信度伪标签与强弱增强。这些方法的共同点是利用相关视图或预测目标约束输出，但视图来源、监督条件和损失形式并不相同；本文使用经过审核的原文—改写文本对应因素，并不直接照搬上述方法的完整训练流程。

为使模型在不同表达下保持稳定的预测，一致性学习约束同一对象在不同输入下的预测分布保持接近。设同一因素（即单个组件的类型或一组端点之间的关系状态）在两个视图下的类别分布为 p 和 q，令 $m=(p+q)/2$，Jensen–Shannon 散度[78]定义为：

$$\mathrm{JS}(p,q)=\frac{1}{2}\mathrm{KL}(p\|m)+\frac{1}{2}\mathrm{KL}(q\|m),\qquad m=\frac{p+q}{2},\tag{2-7}$$

其中，KL 表示 KL 散度，式（2-7）对两个分布是对称的。在训练目标中加入该散度项，可使模型对原文和改写文本中相互对应的可靠因素给出相近的预测；未经确认的关系标签既不参与监督，也不参与一致性约束，更不会被直接改标为无关系（NONE）。

然而，仅约束两个视图的预测分布相互接近，并不能保证预测与金标一致，当两个视图产生相同的错误时，JS 散度依然很小；金标监督则引导预测接近正确标签，二者互为补充。据此，本文组合三类训练信号，即原文的完整论辩图生成监督、因素级的辅助监督，以及原文与改写文本构成的成对视图之间的一致性约束，第 3 章给出具体的学习目标。

2.4 候选评分与结构化决策

单次生成可能遗漏组件或产生错误的关系，多候选方法通过生成若干备选结构来扩大选择范围。以 MCR-BR[56]为例，设候选图集合为 S，重排序函数为 $\mathrm{E}_{\mathrm{rank}}$，系统首先选出重排序得分最高的候选图，再依次执行合法化处理和 MCR-BR 中的原始有界修正模块（本文记为 BR-O），得到预测图，表示为:

$$\begin{aligned} G_{\mathrm{rank}} &= \operatorname{argmax}_{G \in S} \mathrm{E}_{\mathrm{rank}}(G), \\ G_{\mathrm{pre}} = L_A(G_{\mathrm{rank}}), &\qquad G_0 = \text{BR-O}(G_{\mathrm{pre}}), \end{aligned} \tag{2-8}$$

其中，L_A 为确定性的合法化过程，G_{rank} 为重排序得分最高的候选图，G_{pre} 为合法化后的图，G_0 为经 BR-O 修正后得到的初始图，后文提到的初始图均指 G_0。上述重排序、合法化与 BR-O 构成的完整流程沿用 MCR-BR，本文称之为推理配置 I0；第 4 章在 G_0 的基础上追加联合修正（记为 R_{DC}），I0 加上 R_{DC} 即为推理配置 I1，统计推理时延时同时计入 I0 和追加阶段的耗时。

在初始图 G_0 的基础上，第 4 章固定跨度候选集合 U、带类型的组件候选集合 V 和关系候选集合 P，修正只能从中选择对象。候选空间限定可选择范围，评分为选择提供依据，最终预测则须与金标匹配后计算 TP、FP、FN 及评价指标。因此，正确对象未进入候选时无法被恢复，进入候选后也可能因评分或搜索预算而未被选中；得分较高并不等同于预测正确。

对象评分的单位应当与最终评价一致。给定金标跨度的组件分类只判断类型，而对预测组件的完整评分还需判断字符边界；关系评分则须同时考虑全部端点、方向和标签。此外，全部候选上的评分质量与实际被接受修改的正确性属于不同评价对象，后者受选择过程影响，需要分别统计。第 4 章介绍完整对象评分器的训练、校准和修正质量评价。

概率校准[59]衡量模型置信度与实际正确率是否一致，例如，得分在 0.8 左右的一组对象若校准良好，应当有大约 80%是正确的。在此基础上，本文将校

准后的概率转化为保留或删除一个对象的期望得失，构造结构决策所用的效用函数，最终输出仍以严格 F1 评价[57,58]。

结构化决策从有限候选中选择满足约束的对象组合：结构约束限定可行的组合，目标函数比较不同组合的优劣。候选空间扩大后，评分与求解的开销也随之增加，因此还需结合计算与编辑预算控制搜索范围。第 4 章分别说明局部与全局求解的预算口径及其适用条件。

将多个局部预测纳入统一约束的思想在结构化自然语言处理中已有应用。Roth 和 Yih[79]采用线性规划组织全局推断，使局部分类结果服从共同约束。本文沿用结构化决策的基本思路，但研究对象是生成后的论辩图修正，额外要求组件修改所影响的关系在同一事务中重新判断，并通过分项效用和编辑预算限制修改。

本节给出了候选评分与结构化决策的基本概念，第 4 章将在此基础上定义组件修改后的依赖处理、接受条件和编辑预算。

2.5 本章小结

本章介绍了后续两章共同使用的任务表示与相关技术。首先，给出了论辩组件与关系的统一表示：组件由文档、字符区间和类型确定，关系由完整端点和标签确定，并支持多前提关系；在此基础上，借助字符残差与规范键明确了组件的字符级身份，说明了组件一旦修改，与之相连的关系为何必须重新判断。其次，介绍了注意力机制与自回归生成、参数高效微调与连续提示等大语言模型相关技术；进一步地，介绍了数据增强与一致性学习，以及候选评分、概率校准与结构化决策的基本概念。这些内容为第 3 章的可靠监督与一致性学习方法和第 4 章的结构约束联合修正方法提供了理论基础，两章的评价指标与实验设置分别在各自的实验部分给出。

第 3 章 基于可靠监督与一致性学习的论辩挖掘方法

利用大语言模型对已标注文本进行局部改写，可以增加训练文本的表达形式，但改写后的语言流畅并不意味着原有标注仍然成立。对于论辩挖掘任务，局部措辞变化可能改变组件的论辩角色、立场或与其他组件的关系，直接继承全部标注因而可能引入错误监督。针对这一问题，本章研究改写后可靠监督的选择及其学习方式，通过确定改写的影响范围、审核组件与关系的语义状态，并在可靠的对应因素上施加辅助监督和一致性约束，减少错误监督对增强学习的影响。本章依次介绍总体框架、可靠增强数据构造与一致性学习目标，并通过对照实验分析抽取效果、监督审核质量和训练成本。

3.1 引言

论辩挖掘需要从文本中识别论辩组件并确定组件之间的关系，而在论辩文本中，组件的文字既决定其自身的类型，也是判断它与其他组件之间关系的依据。由于此类结构化标注的构建成本较高，对已标注文本进行局部改写以扩充训练样本，是缓解监督不足的一种自然思路。然而，局部改写即使基本保持句意，也可能改变支持关系的方向、削弱跨越改写边界的理由，或使原本无关的两个组件产生联系；若将原有标签全部照搬到改写文本上，新增样本就可能带来错误的监督。

近年来，研究者开始借助语言模型的生成能力构造论辩挖掘的增强数据。例如，质量导向的合成方法 QOS[6]将上下文与组件组织为槽位化输入，在改写后恢复组件跨度，并直接继承原有的组件类型与关系标注，为局部改写提供了实现基础。然而，这类方法默认改写保持了语义、原标注在改写文本上依然成立，对于组件与关系相互依赖的论辩结构，这一假设仍面临两个问题。一方面，改写影响的并不只是被改写的组件本身，与之相连的关系、跨越改写边界的关系以及原本没有关系的组件对，其状态都可能随之改变，若不界定改写的影响范围并逐项判断监督是否可靠，错误标签就会混入训练；另一方面，即使筛选出了可靠的监督，若仅将改写文本作为独立样本参与训练，也无法约束模型对原文与改写文本中相互对应的组件和关系给出一致的判断，增强数据所提供的对应信息未能得到充分利用。

针对上述问题，本章提出可靠监督与一致性学习方法，旨在扩充训练数据的同时，只让改写后仍然可靠的组件与关系参与学习，并利用原文与改写文本之间的对应关系约束模型预测的一致性。具体而言，首先，确定一处改写可能影响的组件和关系，即关系影响域，并在字符坐标上将全部组件迁移到改写文本中；其次，分别审核组件与关系，凡是状态改变、无法判定或未经审核的，均不参与增强侧的监督；最后，在原文与改写文本之间，仅对可靠的组件与关系施加一致性约束，并结合原始标注进行辅助监督。

同一篇原文可以对应多个改写视图。训练时，分别将原文与每个被接受的改写组成视图对，在审核通过的对应因素上计算一致性损失，并按源文档在其改写样本间取平均；下文以一对原文与改写视图说明具体计算。本章将可以单独决定是否参与监督的一项判断称为一个“因素”，它可以是一个组件的类型，也可以是一组端点组件之间的关系状态。可靠因素决定增强侧哪些标签参与学习，一致性项则约束对应因素的预测分布，因此在增强样本与掩码固定的条件下，可以单独考察一致性目标的作用。主要符号见目录后的主要符号对照表。

3.2 总体框架与基础模型

本章方法的整体框架分为增强构造与参数学习两个阶段：构造阶段以训练文档及其标注为输入，输出改写后的全文、改写前后组件之间的对应关系 φ 以及可靠因素的掩码；学习阶段保留原文的完整生成监督，增强文本则只使用通过审核的因素，具体结构见 3.4 节图 3.2。本章围绕关系影响域约束、可靠因素监督与一致性目标组织训练过程。抽取生成器采用类型条件 LoRA 的全局与结论双分支，并结合结论线索提示与句子辅助监督，这些模型配置沿用 MCR-BR[56]的设置。增强生成器 A、自动审核器 V 与抽取生成器 G 分别负责构造改写文本、审核监督和抽取论辩结构（见 3.5.3 节），三者通过组件对应关系与因素掩码相互衔接。

因素掩码是随监督信号一同保存的 0/1 标记：取 1 表示该因素参与增强侧的监督与一致性约束，取 0 则表示不参与。掩码既不遮蔽输入文字，也不删除原始标注，组件掩码与关系掩码分别保存。

抽取生成器采用 Qwen3.5-9B[80]的文本部分，该模型共 32 层、隐藏维度为 4096[80]；全局分支与结论专项分支两组 LoRA 均挂载在 8 个全注意力块的 q/k/v/o 投影上，取 $r=16$、$\alpha=32$、dropout=0.05，其余 24 个线性注意力块、前馈层

和视觉编码器保持冻结[81]。对于投影矩阵 W_0，带门控的双分支 LoRA 输出定义为：

$$h'_t = W_0 h_t + \frac{\alpha}{r} B_g A_g h_t + g_t \frac{\alpha}{r} B_c A_c h_t, A_\cdot \in \mathbb{R}^{r \times d_{\text{in}}}, B_\cdot \in \mathbb{R}^{d_{\text{out}} \times r}, \quad (3\text{-}1)$$

其中，下标 g、c 分别表示全局分支与结论分支，h 和 h′分别为位置 t 的输入表示与输出表示。

全局分支作用于所有位置，结论分支则由门控 $g_t \in \{0,1\}$控制。具体而言，模型对每个组件依次输出 id（编号）、type（类型）和 span（原文片段）三个字段，当某一组件的类型字段已输出为结论类（AAEC 中为论点或主论点，CDCP 中为政策或价值）时，门控在该组件的后续字段上开启，并在组件结束时关闭；其余位置以及关系部分均有 g_t=0。由于门控仅依据已生成的前缀决定，训练时也不会读取后续答案。

当文本中出现 therefore、thus、in conclusion、consequently、hence、to conclude 这六类结论线索词时（不区分大小写，按词边界匹配），模型在输入嵌入前插入四个可训练的提示向量，否则不插入[63]，原文与增强文本分别判断是否触发。线索词仅用于触发提示，并不直接决定组件标签[46]。

生成目标对回答部分的全部 token（含结束符 EOS）取平均，聊天模板与提示向量均不计入损失，计算方式如下：

$$L_{\text{gen}}(x, G) = -\frac{1}{T_y} \sum_{t=1}^{T_y} \log p_\theta(y_t \mid x, y_{<t}). \quad (3\text{-}2)$$

句子辅助任务沿用 MCR-BR 的设置：按句末标点切分句子后，对每个句子的末层表示进行均值池化，再经线性层和 sigmoid 函数得到该句含有结论的概率$\hat{z}_i$；若句子与结论类组件存在重叠，则 z_i=1，否则为 0。句子损失与生成损失共同构成原文的基础监督目标，定义为：

$$L_{\text{sent}} = -\frac{1}{N_s} \sum_{i=1}^{N_s} \left[z_i \log \hat{z}_i + (1 - z_i) \log(1 - \hat{z}_i) \right], L_{\text{IC}} = L_{\text{gen}} + \lambda_{\text{sent}} L_{\text{sent}}, \quad (3\text{-}3)$$

其中，λ_{sent}=0.5，句子头仅用于辅助表示学习。在上述基础监督之上，3.3 节介绍增强文本的构造，3.4 节介绍新增的可靠因素监督与一致性目标。

3.3 基于关系影响域的可靠增强数据构造

3.3.1 改写范围与关系影响域

本章构造增强文本时不改变组件类型与关系标注，仅替换部分已标注组件的文字，被替换的组件构成改写集合，且可以分布在不同段落中。相应地，下文所说的“内部”与“跨边界”按关系的端点是否全部位于改写集合中区分，与句子或段落的划分无关。

为便于描述，本章将允许替换文字的组件片段称为“槽位”，将文字保持不变的其他组件称为“只读组件”；由于前面的改写可能改变文本长度，只读组件的字符位置也需随之更新。此外，下文的“正关系”指带有明确标签（如支持、攻击）的关系，与表示无关系的 NONE 相对。

以 AAEC 训练文档 essay001 为例，如表 3.1 所示，T4、T5 和 T6 均以支持关系指向 T3，而 T4 与 T7 之间没有关系。若取改写集合 A={T3,T4}，则 T4→T3 为内部正关系，T5→T3 与 T6→T3 为跨边界正关系，T4→T7 为跨边界 NONE。该集合仅用于说明上述概念，按默认规则以 T3 为中心时，所有指向 T3 的源组件 T4、T5、T6 都会进入改写集合。

表 3.1 AAEC essay001 的原生组件与关系因素

组件	原生类型	字符区间	原文
T3	论点	[591,714)	through cooperation, children can learn about interpersonal skills which are significant in the future life of all students
T4	前提	[716,851)	What we acquired from team work is not only how to achieve the same goal with others but more importantly, how to get along with others
T5	前提	[853,1086)	During the process of cooperation, children can learn about how to listen to opinions of others, how to communicate with others, how to think comprehensively, and even how to compromise with other team members when conflicts occurred
T6	前提	[1088,1191)	All of these skills help them to get on well with other people and will benefit them for the whole life
T7	论点	[1332,1376)	competition makes the society more effective

图 3.1 给出了因素掩码与完整筛选两种审核策略的处理路径，图中“内部／跨边界”描述关系端点相对于改写集合的位置，“正关系／NONE／语义未知”描述因素的状态。默认的因素掩码策略保留通过审核的组件，仅屏蔽不确定的关系监督；完整筛选策略则只要有一个因素未通过审核，就丢弃整个改写样本。

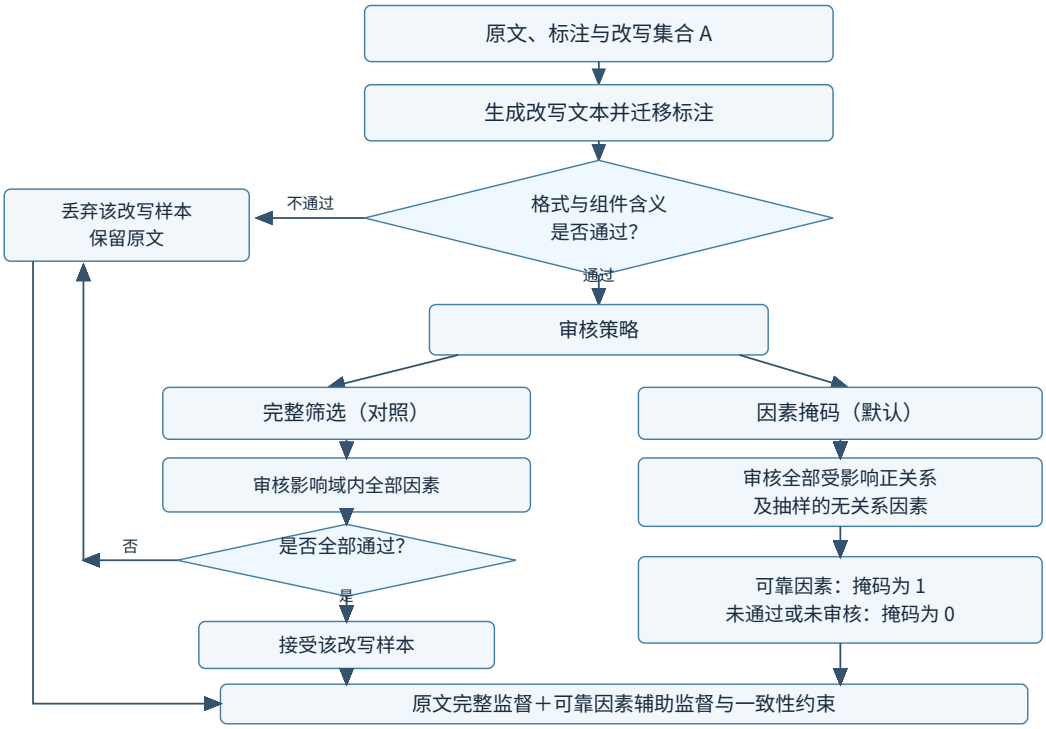


图 3.1 因素掩码与完整筛选两种审核策略

每篇训练文档选定一个改写中心，同一篇文档的所有改写样本均使用该中心。AAEC 优先从论点和主论点中选取，CDCP 优先从政策和价值中选取；为使选择结果确定且可复现，将固定种子 17、语料名、文档 ID、组件 ID 和 center 标记用竖线连接后计算 SHA-256，并按其前 16 位的数值升序选取，若不存在优先类型的组件，则在全部合法组件中按同样顺序选取。

改写集合 A 由中心组件以及所有指向中心的关系的源组件组成，不再继续向外扩展，其余组件均为只读组件；若中心没有入边，则只改写中心本身。

在生成预算上，每篇文档最多尝试生成四次、最多接受两个改写样本，原始样本始终保留；若槽位相互重叠或输入超过上下文长度上限，则跳过该文档的增强。

关系影响域建立在全部候选关系因素之上。记$\Omega(C)$为所有合法端点组合构成的集合，其中每个关系因素$\omega=(S,v)$由非空源组件集合 S 和目标组件 v 组成；

AAEC 中$|S|=1$，因此枚举所有合法的有向组件对即可。因素标签y_{ω}表示该端点组合的关系状态，没有标注关系的组合记为 NONE。

对于 CDCP，多前提关系$(\{c_{i_1},\ldots,c_{i_k}\},c_j,\ell)$保持原样，其中$\ell\in$\{Reason,Evidence\}，即关系标签为理由或证据；源组件按原文顺序排列，整条关系作为一个对象处理，不拆分为若干二元关系。

相应地，CDCP 的候选端点组合既包括全部金标关系的端点组合，也包括按源范围规则补充的、最多含三个源组件的组合，源组件超过三个的金标关系同样完整保留。

关系影响域用于刻画一处改写可能波及的关系范围：只要某个因素的端点中有组件被改写，该因素的状态就可能随之改变。设$V(\omega)=S\cup\{v\}$为因素ω的全部端点，则改写集合 A 的完整关系影响域定义为至少有一个端点落在改写集合中的全部因素，即：

$$D_A=\{\omega\in\Omega_{\text{sem}}(C):V(\omega)\cap A\neq\varnothing\},\tag{3-4}$$

其中，$\Omega_{\text{sem}}(C)=\Omega(C)\setminus U_{\text{sem}}$，语义未知集合$U_{\text{sem}}$见 3.3.3 节（AAEC 中为空）；在二元情形下，该定义即为$\{(u,v):u\in A\vee v\in A,(u,v)\in\Omega_{\text{sem}}(C)\}$。全部端点都在$A$中的因素称为内部因素，只有部分端点在$A$中的因素称为跨边界因素。此外，改写还可能通过指代等上下文影响只读组件之间的关系，这部分由 3.5.5 节的人工抽查评估。

3.3.2 改写生成与标注迁移

增强生成器 A 使用不加载任务 LoRA 的 Qwen3.5-9B，采样参数为 temperature=0.7、top-p=0.9[82]，关闭 thinking 模式，每次最多输出 2048 个 token，跨骨干实验也共用其生成的增强文本。生成器的输入包括训练文档全文、可改写的槽位及其类型、只读组件列表以及影响域标签，输出仅为从组件编号到替换文本的 JSON 映射，既不能新增组件，也不能修改类型或关系。

替换槽位文字通常会改变文本长度：改写后，未改写组件在全文中的字符位置也会整体平移，因此需要先建立改写前后的组件对应，再检查原标签是否仍然成立。坐标迁移解决的是组件在新文本中的定位问题，而 3.3.3 节的语义审核解决的是原有监督能否沿用的问题。具体而言，程序按原始字符区间替换槽位文字，然后对整篇文档重新分词，并建立改写前后组件之间的对应关系：

$$\varphi: C \to C', \quad (d, b_c, e_c, t_c) \mapsto (d', b_c', e_c', t_c), \tag{3-5}$$

其中，d′表示改写后的全文，它是同一文档的一个新的文本版本。回填文字后，程序先更新全部组件的字符区间，使只读组件随前文长度的变化而平移，再重新生成分词与子词表示；因此，φ 是组件之间的一一对应，而不是字符或 token 位置之间的对应，所有关系的端点都按 φ 迁移到新文本上。例如，被改写组件增加一个字符后，位于其后的只读组件在新文本中的起止位置都会后移一个字符，但其文字和标注保持不变。若出现槽位重叠、坐标无法对应或端点无法迁移，则丢弃该改写样本，只保留原始样本。

在此基础上，3.3.3 节介绍如何审核迁移后的标注，3.3.4 节再通过真实文档的案例展示坐标迁移与审核的具体过程。

3.3.3 语义审核与因素掩码

迁移后的改写样本需要依次经过格式检查与语义审核。所有改写样本首先须通过格式检查，包括 JSON 格式、槽位编号、坐标对应和关系端点引用；之后，审核器 V 分别读取原文与改写文本，在看不到原标签的条件下输出组件类型或关系状态，再由程序与原标注进行比较。组件审核同时检查含义、论辩角色、指代、否定和情态，只要有组件含义改变、无法判定或输出不合法，就丢弃该改写样本。

审核器 V 同样使用不加载抽取 LoRA 的 Qwen3.5-9B，关闭 thinking 模式并采用贪心解码，每次最多输出 1024 个 token，跨骨干实验共用 9B 模型生成的同一审核结果。

组件全部通过审核后，再对关系进行审核。关系审核集合 $J_A \subseteq D_A$ 包括全部受影响的正关系，以及从内部 NONE 和跨边界 NONE 中各随机抽取的至多 4 项，CDCP 中被定义为语义未知的真子集不作为 NONE 负例。若无法审核完全部正关系，该样本不参与关系学习，但通过审核的组件仍可用于组件监督；未经审核的 NONE 则不参与监督。

关系掩码的取值同时取决于关系自身及其端点组件的审核结果。只有当审核器认可原标注、改写后状态不变且端点对应有效时，关系掩码才取 $m_R(\omega)=1$，若原标签存在分歧、状态改变或无法判定，掩码取 0；组件掩码 $m_C(c)$ 则单独保存。由于文字不变并不能保证论辩角色不变，关系所连接的只读组件同样需

要在全文上下文中审核，关系掩码为 1 还要求其所有端点的组件掩码均为 1。满足上述条件的因素称为“可靠因素”，审核质量见 3.5.5 节。

对于掩码为 0 的因素，本章进一步区分两种情况：“待定”指审核过但无法确定原状态是否保持，“未审核”指没有对该因素进行审核，二者的增强侧掩码均为 0，原关系标签保持不变；“语义未知”则属于另一种情况，见下文。

在此基础上，默认策略保留通过审核的组件，既不会因为某一条关系未通过审核就丢弃全部组件，也不会把这条关系改标为 NONE，增强侧的损失只使用掩码为 1 的标签。作为对照，完整筛选策略检查影响域内的全部因素，只要有一个因素改变或待定就丢弃整个样本，3.5 节比较了两种策略的训练效果。

多前提关系需要额外处理。严格评价要求预测关系与金标关系完全一致，例如金标为$h=\langle\{c_1,c_2\},c_3,\text{Reason}\rangle$时，预测$\langle\{c_1\},c_3,\text{Reason}\rangle$因源集合不同而不能匹配；但这并不意味着 c_1 单独与 c3 没有关系，因为 c_1 与 c_2 共同构成理由，并不能由此推出 c_1 单独既不支持也不反对 c3。

因此，本章为训练阶段的关系头定义语义未知集合 U_{sem}：对于一条已标注的多前提关系，若其源集合的某个非空真子集没有单独的正关系标注，就将该真子集与目标构成的因素列为语义未知。相应地，可审核的因素集合为 $\Omega_{\text{sem}}=\Omega\setminus U_{\text{sem}}$，完整影响域与抽样均在该集合中定义。

无论原文还是改写文本，关系头都不把 U_{sem} 当作 NONE 负例，其监督掩码与一致性约束掩码均为 0，而原文的完整生成目标仍保留原始的多前提关系。与此不同，第 4 章的评分器判断的是对象是否与标注完全匹配，因此可以把这类真子集作为“不匹配”的负例，但这并不表示其在语义上没有关系。

记通过审核且端点组件也都通过审核的关系集合为 R_A，则上述各集合满足如下包含关系：

$$R_A \subseteq J_A \subseteq D_A \subseteq \Omega_{\text{sem}},\quad \Omega_{\text{sem}}=\Omega\setminus U_{\text{sem}}, \tag{3-6}$$

其中，完整影响域 D_A 是定义范围，J_A 是实际审核的范围，只有通过审核的 R_A 才进入增强侧的关系损失。默认策略下 J_A 通常小于 D_A，完整筛选策略则要求 $J_A=D_A$，语义未知集合 U_{sem} 始终不在两者之中，图 3.1 中的两条路径即对应这一层级关系。

3.3.4 标注迁移与改写案例

本节以 AAEC 训练文档 essay001 为例说明坐标迁移与审核范围。以 T3 为中心时，改写集合为 A={T3,T4,T5,T6}，原文片段见表 3.1。为单独检验坐标迁移是否正确，先进行一项确定性测试，即将四个槽位中的第一个空格改为两个空格、其余字符保持不变，再通过自然改写的例子说明语义审核。

测试结果表明，坐标迁移能够准确跟踪组件位置的变化：四个槽位各增加一个空格后，组件的左闭右开字符区间相应更新，例如 T3 由[591,714)变为[591,715)，位于槽位之后的只读组件则随之整体平移，T8 和 T2 均平移了 4 个字符。程序核对了全部 11 个组件的文字切片，并按 φ 迁移了全部原有关系，该样本的审核范围与损失掩码如表 3.2 所示。

表 3.2 essay001 的审核范围与损失掩码

监督对象	检查或覆盖结果	掩码	增强侧用途
11 个组件	规范化空白后逐字一致	m_C=1	组件头；A^+中 4 项参与一致性约束
T4/T5/T6→T3 支持	3 项内部正因素全部检查	m_R=1	正关系监督及一致性约束
抽取的内部 NONE 与边界 NONE	各 4 项，共 8 项	m_R=1	NONE 监督及一致性约束
影响域内其余 57 项	未纳入审核子集	m_R=0	不进入增强关系损失
影响域外 42 项	不在D_A	m_R=0	保留原文监督

在该例中，候选因素共 110 项，其中影响域 D_A 包含 68 项，实际审核 11 项，其余 57 项未审核；未审核因素的掩码为 0，不参与增强侧的关系损失，但原关系标签保持不变。

作为反例，在上述确定性测试中，若回填程序误把同一文档中 T7 的原文“competition makes the society more effective”填入 T3 的位置，则 T3 新坐标上的切片与预期的替换文本不一致，该样本会在逐字核对中被拒绝。逐字核对

只检验回填与坐标是否正确，自然改写后的语义是否保持仍由 3.3.3 节的审核判断。

在此基础上，表 3.3 给出两个自然改写的例子：例 A 改写了 T3、T4、T5 和 T6 四个槽位；例 B 与例 A 相同，只是将 T3 改为否定表达。

表 3.3 essay001 自然改写与语义判断

案例组件	自然改写	语义判断
A / T3	by cooperating, children can acquire interpersonal skills that will be important in their future lives	保留原含义
A / T4	Teamwork teaches us how to pursue a shared goal with others and, more importantly, how to get along with them	保留原含义
A / T5	Cooperating helps children learn to listen to others' opinions, communicate, think comprehensively, and even compromise with teammates when conflicts arise	保留原含义
A / T6	These skills help children get along with others and benefit them throughout their lives	保留原含义
B / T3	cooperation cannot help children acquire interpersonal skills that will be important in their future lives	否定原结论

例 A 保持了原有的论证功能：T3 仍主张合作有助于儿童学习人际交往技能，T4 说明团队协作需要共同目标与相处能力，T5 列举具体技能，T6 说明持续的收益。由于四个组件的含义以及 T4、T5、T6 到 T3 的三条支持关系均未改变，它们都可以参与增强侧监督，掩码取 1；但其余的 NONE 和跨边界因素仍需逐项审核，不能因这三条关系成立就默认通过。

例 B 中的 cannot 把 T3 从“可以学会”变为“不能帮助学会”，否定了原有结论，因此组件审核会丢弃整个样本，只保留原文和其他已接受的样本。与之相对，若组件全部通过审核、只有某条关系改变或无法判定，默认策略仅将该关系的掩码置为 0，其余可靠因素照常使用，也不会把该关系改标为 NONE。

回填自然改写文本后，程序同样核对了全部 11 个组件的切片和 6 条原有关系的端点迁移，在例 A 中，T3 由[591,714)迁移到[591,693)，T4 由[716,851)迁移到[695,804)。

3.4 一致性学习模型与训练

改写样本通过审核后，模型即可利用原文与改写文本中相互对应的可靠因素进行学习。以表 3.1 为例，T4 改写后若通过组件审核，其前提标签即可用于增强侧监督，而 T4→T3 的支持关系和 T4→T7 的 NONE 还需分别通过关系审核。一致性目标比较这些可靠因素在两个视图中的类别分布，允许两侧的词序、长度和位置不同，原始标签则同时为两个视图提供监督，整体学习架构如图 3.2 所示。

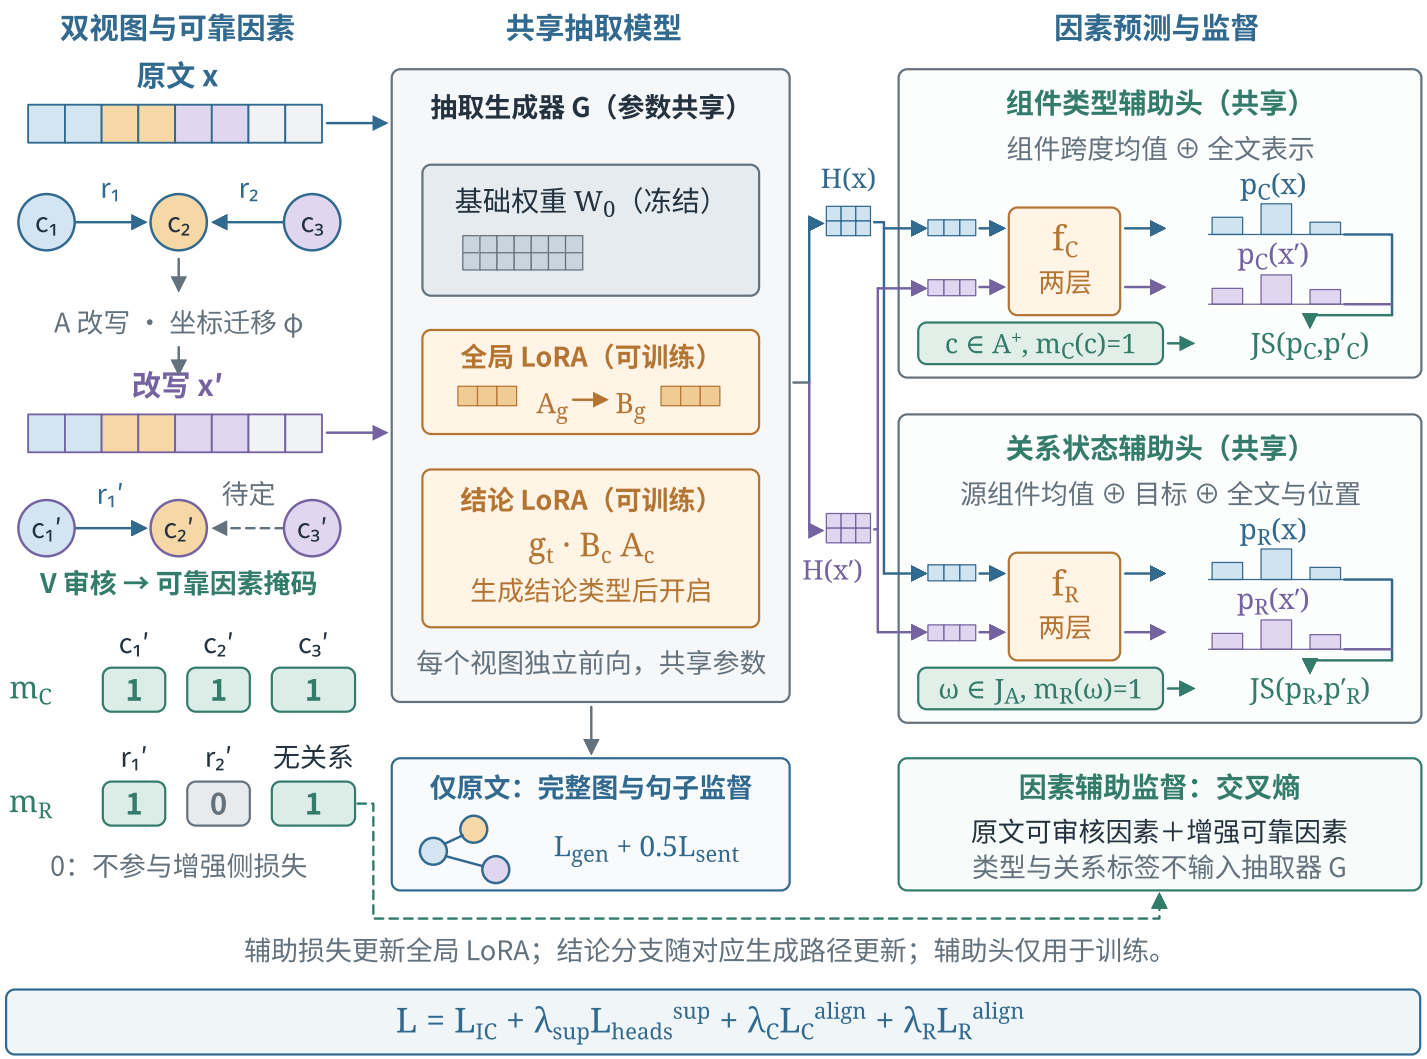


图 3.2 可靠监督与一致性学习模型结构

图 3.2 左侧结构与预测分布为机制示意，蓝色与紫色分别表示原文及改写视图，⊕表示向量拼接。两个视图经过同一个生成器，独立前向且均保留梯度，组件对应关系 φ 将两侧的组件类型分布与关系状态分布联系起来；掩码只筛选损失项，增强文本不计算完整论辩图的生成损失。生成目标、句子监督与新增的辅助目标共同更新可训练参数，基础模型权重保持冻结，辅助头仅在训练时使用。

3.4.1 辅助预测头与一致性约束

为在因素粒度上施加监督与一致性约束，本章在生成器之上设置组件类型头与关系状态头两个辅助分类器，二者读取生成器对输入文本的隐藏表示，并用金标跨度定位待预测的组件。抽取生成器的输入仅包含任务指令与文本本身，金标的槽位、类型和关系只用于构造训练样本与监督信号，并不作为生成器的输入。

令h_i^x为第 i 个输入子词的隐藏状态，$B_x(c)$为组件 c 的字符跨度所覆盖的子词集合，h_{end}^x为输入结束、回答开始之前位置的隐藏状态，则组件表示与类型分布定义为：

$$u_c^x = \text{MeanPool}_{i \in B_x(c)} h_i^x,\ p_C^x(c) = \text{softmax}\, f_C\left(\left[u_c^x; h_{\text{end}}^x\right]\right), \tag{3-7}$$

其中，MeanPool 表示对组件覆盖的子词表示取均值，方括号表示向量拼接。由于生成器为因果模型，靠前的 token 只能看到左侧的上下文，拼接h_{end}^x可以为组件表示补充全文信息；组件头的输入不包含金标类型。

与组件头输出类型分布不同，关系头输出一组端点之间的关系状态分布，并显式区分源组件与目标组件：

$$p_R^x(S, v) = \text{softmax}\, f_R\left(\left[\text{Pool}\left(\{u_c^x : c \in S\}\right); u_v^x; h_{\text{end}}^x; \eta(S, v)\right]\right), \tag{3-8}$$

其中，f_C、f_R为两层感知机，Pool 对各源组件的表示取均值；η 为位置特征，由源组件数与六个位置统计量组成，后者包括源组件起点的最小值与均值、终点的最大值与均值以及目标的起止位置。位置先由字符区间换算为评价 token 坐标，再除以文档的 token 数进行归一化，且不包含待预测的关系标签。二元关系只有一个源组件，多前提关系则以完整的源集合与目标为预测对象，状态中均包含 NONE；两个辅助头在验证和测试时均会移除。

组件一致性约束的范围包括被改写的组件，以及通过正关系与之相连的只读组件，定义为：

$$A^{+}=A\cup\bigcup_{\omega\in D_A,\ y_\omega\neq\mathrm{NONE}}V(\omega),\tag{3-9}$$

其中，并集只对影响域中的正关系因素取端点，NONE 因素仅参与关系一致性约束，因而不会把距离较远的组件也纳入组件一致性约束。对于通过组件审核的改写文本 x'，下式中的 A^{+}还需与$\{c:m_C(c)=1\}$取交集，组件一致性损失定义为：

$$L_C^{\mathrm{align}}(x,x')=\frac{1}{|A^{+}|}\sum_{c\in A^{+}}\mathrm{JS}\left(p_C^{x}(c),p_C^{x'}(\varphi(c))\right),\tag{3-10}$$

其中，JS 为式（2-7）定义的 Jensen–Shannon 散度，两个视图均保留梯度，共同参与参数更新。类似地，将通过审核的关系因素集合$\{\omega\in J_A:m_R(\omega)=1\}$划分为正关系组 D_{+}与 NONE 组 D_0，记非空的组为$B=\{b\in\{+,0\}:|D_b|>0\}$，关系一致性损失先在组内平均、再在组间平均：

$$L_R^{\mathrm{align}}(x,x')=\frac{1}{|B|}\sum_{b\in B}\frac{1}{|D_b|}\sum_{\omega\in D_b}\mathrm{JS}\left(p_R^{x}(\omega),p_R^{x'}(\varphi(\omega))\right),\tag{3-11}$$

其中，分组平均可以避免数量较多的 NONE 因素主导关系一致性损失。没有可靠关系时，关系一致性项为 0，但原文全部关系的生成监督不受影响；A^{+}为空时，组件一致性项同样为 0。

仅约束两个视图的预测分布相互接近，并不能保证预测与金标一致：当两个视图产生相同的错误时，JS 散度依然很小。因此，训练目标还需结合因素级监督，分别约束预测的一致性与正确性。对于视图 x，记 M_C和 M_R分别为受监督的组件集合与关系因素集合，M_R^{+}和M_R^{0}分别为其中的正关系与 NONE，$B_M=\{b\in\{+,0\}:|M_R^{b}|>0\}$，则辅助监督损失定义为：

$$S(x;M_C,M_R)=\frac{1}{|M_C|}\sum_{c\in M_C}\mathrm{CE}\left(p_C^{x}(c),t_c\right)+\frac{1}{|B_M|}\sum_{b\in B_M}\frac{1}{|M_R^{b}|}\sum_{\omega\in M_R^{b}}\mathrm{CE}\left(p_R^{x}(\omega),y_\omega\right),\tag{3-12}$$

其中，CE 为交叉熵，t_c为组件的原始类型；$M_C=\varnothing$时组件项为 0，$B_M=\varnothing$时关系项为 0，两项等权相加。原文取$S(x,G)=S\left(x;C,\Omega_{\mathrm{sem}}(C)\right)$，即使用全部组件与可审核的关系因素；改写文本取$S_m(x',\varphi(G))=S\left(x';\{\varphi(c):m_C(c)=1\},\{\varphi(\omega):\omega\in J_A,m_R(\omega)=1\}\right)$，即仅使用掩码为

1 的组件与关系。由此，一致性约束与原始标注的监督相互配合，使模型在两个视图上的预测既保持一致又接近正确标签。

3.4.2 损失归一化与参数更新

为避免改写样本数量不同的源文档在训练中获得不均衡的权重，本章按源文档对各项损失进行归一化。设源文档 d 有 m_d 个被接受的改写样本，原文承担完整的论辩图生成监督与句子监督；改写文本则只作为输入，由于其中可能含有未审核的关系，不将其完整论辩图作为生成目标。辅助监督损失定义为：

$$L_{\text{heads},d}^{\text{sup}}=\frac{S\left(x_d,G_d\right)+\sum_{j=1}^{m_d}S_{m_j}\left(x'_{dj},\varphi_j\left(G_d\right)\right)}{1+m_d}. \tag{3-13}$$

一致性项先在每个非空因素组内平均，再在同一源文档的各改写样本之间平均，总损失定义为：

$$L_d=L_{\text{IC}}\left(x_d,G_d\right)+\lambda_{\text{sup}}L_{\text{heads},d}^{\text{sup}}+\lambda_C\acute{L}_{C,d}^{\text{align}}+\lambda_R\acute{L}_{R,d}^{\text{align}}, \tag{3-14}$$

其中，默认取 λ_{sup}=1、λ_C=λ_R=0.5。没有改写样本时只保留原文的各项损失；有改写样本但没有可靠关系时，关系一致性项为 0，组件学习照常进行。由于被接受样本中的改写组件都已通过审核，m_C 均为 1，计入 m_d 的样本不会出现空的组件项。此外，每个批次内按源文档取平均，以避免改写样本较多的文档获得过高权重。

以 3.3.4 节的例子说明上述归一化过程：一个被接受的改写样本使 m_d=1，原文与改写文本的辅助监督各占 1/2；A^+={T3,T4,T5,T6}，组件一致性项对这 4 个组件取平均；关系一致性项中有 3 项正关系和 8 项 NONE，分组平均后，在 λ_R=0.5 时每项正关系与每项 NONE 的最终权重分别为 1/12 和 1/32。

按 $1+m_d$ 取平均使每篇源文档的辅助监督总权重固定，原文在其中的占比为 $1/\left(1+m_d\right)$，而原文的生成损失 L_{IC} 保持不变。若不加控制，完整筛选与因素掩码接受的样本数量通常不同，二者的比较会包含原文占比的差异；3.5 节将各增强配置的接受样本数匹配为相同规模，但二者保留的可靠因素数量仍可能不同；一致性学习的消融则固定了样本与掩码，不受此影响。

在参数更新上，生成损失与句子损失更新原有模块，组件头、关系头与一致性项通过共享的输入表示更新全局 LoRA，结论分支只随相应的生成路径更

新；基础权重保持冻结，辅助头在评价时移除。第 4 章的推理评分器另行训练，不使用这些辅助头的输出概率。

3.4.3 算法流程与性质分析

算法 3-1 概括了本章方法的主要步骤，包括增强构造与参数学习两个阶段：先在固定预算内生成并筛选改写样本，再按源文档归一化进行训练。两个阶段都只使用训练集，验证集仅用于参数选择和早停。

算法 3-1 可靠监督与一致性学习

输入：训练文档及其标注D_{train}，增强生成器 A、自动审核器 V；

尝试上限B_{try}、接受上限B_{accept}、更新上限 U，mode∈{FactorMask, FullFilter}。

输出：训练后的生成器θ、增强样本及组件对应关系。

01 检查数据划分、去重分组与标注坐标，依次处理源文档，保留原文及完整金标图。

02 按 3.3.1 节选取改写中心及全部源组件；无法处理则跳过该文档。

03 排除语义未知因素，构造Ω_{sem}、改写集合 A 及完整影响域D_A。

04 在B_{try}次尝试和B_{accept}个接受样本的上限内，重复步骤 05—08。

05 生成并回填替换文本，重新分词，建立全部组件的双射φ。

06 格式、槽位、坐标或端点检查失败，或组件含义、论辩角色改变或无法判定时，拒绝样本。

07 对非空D_A，FullFilter 审核全部因素，无法全部审核或任一项未通过则拒绝；FactorMask 审核全部受影响正关系及抽样的内部、跨边界 NONE，得到m_R。

08 保存改写文本、迁移标注、φ及因素掩码；无接受样本时仅使用原文。

09 构造完成后按源文档采样训练批次，重复步骤 10—12，直至达到 U 或满足早停条件。

10 计算原文生成损失、句子监督损失，以及原文可审核因素和增强文本可靠因素的辅助监督损失。

11 按φ计算可靠因素的一致性损失，无可靠因素时该项为 0；各项损失按改写样本和源文档两级归一化。

12 冻结基础模型权重，反向传播并更新 LoRA 与辅助头参数。

13 返回生成器及增强数据，评价和测试时移除辅助头。

性质一（标注迁移保持结构）。若改写槽位互不重叠、φ 是组件之间的双射，且组件类型与每条完整关系都按 φ 迁移，则 G 与$\varphi(G)$具有相同的组件数、

组件类型以及带方向和标签的关系结构。证明：双射保证每个原组件恰好对应一个新组件，而关系的全部端点逐一映射，因此关系既不会增加也不会丢失，利用逆映射即可恢复原图。该性质仅保证标注结构不变，改写后的文本是否仍然支持这些标签，需由 3.3.3 节的语义审核判断。

性质二（单因素预测稳定的充分条件）。对某一因素，设原视图中的正确类别为 y，预测分布 p 的间隔为 $\gamma=p_y-\max_{k\neq y}p_k>0$。若增强视图的分布 q 满足 $\|p-q\|_\infty<\gamma/2$，则 $\arg\max q=y$。证明：对任意 $k\neq y$，都有 $q_y-q_k>p_y-p_k-\gamma\geq 0$。该性质表明，只要两个视图的预测分布足够接近，增强视图就能保持原视图的正确预测，这正是一致性约束的出发点。进一步地，由 Pinsker 不等式可得 $\|p-q\|_\infty\leq\sqrt{(2\cdot JS(p,q))}$，因此当 $JS(p,q)<\gamma^2/8$ 时上述条件必然成立，这将式（2-7）定义的一致性目标与单因素预测稳定性直接联系起来；该性质只说明一致性约束的作用方向，并不保证原视图本身预测正确。

综上，性质一保证了标注迁移不破坏论辩结构，性质二说明了一致性约束为何有助于预测稳定，3.5 节将通过实验检验上述设计在完整论辩图抽取上的效果。

3.5 实验与分析

为验证本章所提方法的有效性，本节在两个公开的论辩挖掘语料上开展对照实验，主要回答以下三个问题：（1）本章的训练方法能否提升端到端论辩挖掘的抽取性能；（2）在增强数据相同的条件下，一致性目标本身能带来多少增益；（3）增强数据的审核质量与训练成本如何，训练增益在不同骨干模型上是否稳定。围绕上述问题，本节依次介绍数据集与评价指标、对照方法和实验设置，进而给出主要结果与消融分析、增强数据的人工审核结果以及训练成本与跨骨干表现。

3.5.1 数据集与评价指标

本章在两个广泛使用的论辩挖掘语料上开展实验，包括论辩标注作文语料（Argument Annotated Essays Corpus，AAEC）[2]与消费者债务催收实践评论语料（Consumer Debt Collection Practices，CDCP）[12,26]。AAEC 由英文议论文构成，CDCP 则来自公共政策规则制定中的用户评论，并包含多个前提共同指向同一目标的多前提关系。在数据划分方面，AAEC 采用官方发布的 train-test-

split.csv 划分，CDCP 采用原始数据包中的 train/test 目录，重复文档仅在训练集中去除，测试文档全部保留，两个语料的规模统计如表 3.4 所示。

表 3.4 数据规模与官方划分

语料	划分	原始文档	保留文档	组件	完整关系	多源关系	最大源数
AAEC	训练	322	319	4793	3006	0	1
AAEC	测试	80	80	1266	809	0	1
CDCP	训练	581	580	3901	969	85	8
CDCP	测试	150	150	1026	252	34	10

训练集按全文哈希去重：AAEC 中 essay171、210 与 400 内容相同，保留 essay171，essay209 与 377 内容相同，保留 essay209；CDCP 中保留 00410，去除与其正文重复且标注不完整的 00411。经去重后，训练集与测试集之间不存在重复文档。

对于评价指标，采用严格匹配下的组件 F1 与关系 F1 评估端到端抽取性能，并以严格关系 F1 为主要指标，边界 F1、给定金标组件时的关系分类等指标仅用于辅助分析误差来源。评价时，组件匹配要求字符区间与类型均与金标完全一致，关系匹配还要求完整的源集合、目标、方向和标签均一致，CDCP 中的多前提关系作为一个整体计数，不拆分为二元边。在此基础上，分别对组件和关系统计真正例 TP、假正例 FP 与假负例 FN，精确率、召回率与 F1 的计算方式如下：

$$\text{Precision}=\frac{\text{TP}}{\text{TP}+\text{FP}},\quad \text{Recall}=\frac{\text{TP}}{\text{TP}+\text{FN}},\quad F_1=\frac{2\,\text{TP}}{2\,\text{TP}+\text{FP}+\text{FN}},\qquad (3\text{-}15)$$

其中，TP、FP 与 FN 均先在全部测试文档上汇总，再代入式（3-15）计算，即本文报告的 F1 均为 micro-F1。匹配时每个预测对象与金标对象最多使用一次，重复预测计为 FP；解析失败或结构校验失败的文档仍保留在评价集中并按空预测处理，其金标对象全部计为 FN。F1 采用百分制报告；正文可用前后百分数表示变化，差值 ΔF1 以百分制分数表示，不表示相对增长率。差值按未舍入结果计算，可能与表中已舍入均值之差相差 0.01。第 4 章 AAEC 与 CDCP 主实验沿用相同的数据划分与评价口径。

3.5.2 对照方法

为全面评估本章方法的有效性，并区分数据构造方式与学习目标各自的作用，本节按表 3.5 设置九组训练对照，主要包括以下四类。

（1）基线配置。以 MCR-BR 训练配置（记为 T0）为基线，推理采用 MCR-BR 的推理流程（重排序、合法化与 BR-O，记为 I0），该组合记为 T0I0；在其基础上仅在原文上增加辅助预测头监督、不使用增强数据的配置记为 Heads，用于区分辅助头本身带来的影响。

（2）增强构造对照。普通改写增强（Plain）与槽位化增强（QOS）按各自的构造规则产生增强样本，二者仅与本章方法匹配接受样本的规模，用于考察可靠监督构造本身的作用。

（3）学习目标对照。去掉一致性项（NoPair）只使用可靠因素监督而不施加一致性约束，仅组件一致性（CompPair）只在组件上施加一致性约束，本章完整训练配置（记为 T1，在 I0 推理下记为 T1I0）则同时约束组件与关系；三者使用完全相同的改写样本、因素掩码与辅助头，仅在学习目标上不同，因而其差值能够直接反映一致性目标的作用。

（4）筛选策略与改写中心对照。完整影响域筛选（FullFilter）在任一因素未通过审核时丢弃整个改写样本，随机中心（RandomCenter）则随机选择改写中心，二者作为可独立选择的策略与默认设置进行比较。

为保证比较的公平性，九组对照使用相同的骨干、源文档访问次数和更新步数，推理均采用 I0，各增强组的接受样本规模相同（AAEC 500 个，CDCP 900 个），成本统计同时计入生成失败、被拒样本与审核的开销。在此基础上，比较学习目标时固定增强文本、因素掩码和辅助头，比较数据构造方式时则保持接受样本规模与训练预算相同；推理侧修正策略的对照属于第 4 章，见 4.6.1 节。

表 3.5 训练对照组的设置

配置	增强	可靠因素监督	组件一致性	关系一致性	与完整一致性学习配置输入相同
T0I0	无	无	无	无	—
Heads	无	原文	无	无	—

表 3.5 训练对照组的设置

配置	增强	可靠因素监督	组件一致性	关系一致性	与完整一致性学习配置输入相同
Plain／QOS	有	构造方法各自规则	无	无	仅匹配规模
NoPair	有	有	无	无	是
CompPair	有	有	有	无	是
T1I0	有	有	有	有	是
FullFilter／RandomCenter	有	有	有	有	独立可选策略

3.5.3 实验环境与参数设置

在模型选择方面，本章以 Qwen3.5-9B[80]为主骨干模型，MCR-BR 基线（T0）、本章训练配置（T1）以及外部对照方法均在该骨干上重新训练，完整的消融与错误分析也均基于 9B 模型；此外，使用 Qwen3.5-4B[83]考察较小骨干上的表现，并使用 Qwen2.5-7B-Instruct[84,85]与基础方法 MCR-BR 的原始设置衔接[56]。两种补充骨干复用 9B 模型生成并审核的增强数据，抽取器、评分器等模块则在各骨干上独立训练，各模型的具体版本如表 3.6 所示。

表 3.6 模型版本

模型	修订版本（revision）	用途
Qwen/Qwen3.5-9B	21eca8a083a2121a92fba681f4a7c72cf20ff1a7	主实验及共享的增强器 A 与审核器 V
Qwen/Qwen3.5-4B	1eef1f4e0bc57dec8f814d1e4c714c8e0065d261	共享增强下的四种配置补充实验
Qwen/Qwen2.5-7B-Instruct	a306ca65c69cb09b9ce8ae8396fd529d509d872e	共享增强下的四种配置补充实验

在训练与评价配置方面，主实验统一使用相同的训练预算、候选协议和评价器，训练种子取 17、29 和 43；多候选由 1 路贪心解码与 2 路采样解码组成，模型可自由决定预测对象的数量，不按测试集金标数量截断或补齐。实验仅使

用文本输入，关闭模型的 thinking 模式，不使用视觉模块与长上下文扩展，具体的硬件环境与训练配置如表 3.7 所示。

表 3.7 主要训练配置

项目	取值
骨干	Qwen/Qwen3.5-9B；后训练版本；文本路径；关闭 thinking
LoRA	8 个全注意力块 q/k/v/o；全局及结论各$r=16$，$\alpha=32$，dropout=0.05
优化器	AdamW[86]；LoRA 学习率 2×10^{-4}；权重衰减 0.01；β=(0.9,0.999)；$\varepsilon_{\text{Adam}}=10^{-8}$；预热比例 0.03
学习预算	5 轮；2 GPU×每卡 1 个源文档×梯度累积 16 步＝批大小 32；末批按有效源文档归一化
精度与分片	BF16；FSDP 全分片[87]；梯度检查点；梯度裁剪 1；基础与视觉权重冻结
上下文	模型配置上限 8192；单次输入≤4096、输出≤2048；不使用 YaRN[88]
生成	1 路贪心＋2 路采样；temperature=0.7、top-p=0.9；相同规范序列化
种子	17、29、43；相同官方测试文档
硬件	2×A100 80 GB；128 GiB RAM；4 CPU 线程；推理张量并行度 2
成本单位	GPU 小时=设备数×墙钟小时；显存为单卡最大峰值
辅助头	组件 8192→1024→3/5 类；关系 12295→1024→3 状态；GELU[89]、dropout 0.1
损失系数	原文生成 1；句子 0.5；辅助监督 1；组件与关系一致性项各 0.5；增强视图不作整图生成目标

在适配参数方面，9B 骨干的 Q 投影包含输出门控，维度为 4096→8192，K 与 V 投影为 4096→1024，O 投影为 4096→4096。全局与结论两条 LoRA 分支均取 *r=16*、*α=32* 和 dropout=0.05，每条分支含 3,932,160 个参数，合计 7,864,320 个，与单条秩为 32 的分支参数量相同；其余 24 个线性注意力块、前馈层和视觉编码器均保持冻结。

系统中的抽取生成器 G、增强生成器 A 与语义审核器 V 分别负责抽取、构造改写和确定监督掩码。G 在 Qwen3.5-9B 上加载双 LoRA 并训练 5 轮，输出原生组件与完整关系 JSON；A 使用同版本官方权重而不加载任务 LoRA，在训练时可见标注并输出槽位替换 JSON，仅用于构造训练视图；V 使用同一基础模型

的独立上下文，隐藏待审标签，以贪心解码输出组件或关系状态及待定判断。训练阶段的辅助头结构和损失系数统一列于表 3.7；对象评分器 S 与源组提案器 P 服务于第 4 章的联合修正，配置见 4.6.1 节。

软件环境为 Python 3.11、PyTorch 2.7.1[90]、Transformers 5.8.0[81]及 PEFT 0.17.1[91]；HiGHS[92]在固定 CPU 预算下执行参考求解。硬件、训练预算与成本统计口径见表 3.7。

在统计方法方面，所有结果均按语料、文档、训练种子和方法逐文档记录，同一配置在不同章节中出现时引用同一份记录，因此各章表格中相同方法的数值保持一致。对于每个训练种子，先汇总全部测试文档的计数并计算 micro-F1，再报告三个种子的均值与样本标准差；配对比较要求各方法使用相同的文档和种子，且金标对象总数 TP+FN 保持一致。

显著性检验采用文档与种子的联合 bootstrap 重采样[61]，共重采样 2000 次：每次有放回地抽取 3 个种子，并抽取与测试集规模相同的文档，所有方法共用同一组抽样结果；每次抽样后重新汇总计数并计算方法间的 F1 差值，由此得到差值的经验分布。

设观测差值为$\hat{\Delta}$，第 b 次重采样的差值为Δ_b^*，重采样次数为 B，95%置信区间取重采样分布的 2.5%与 97.5%分位数，双侧检验的 p 值计算方式如下：

$$p=\frac{1+\sum_{b=1}^{B}\mathrm{I}\left(|\Delta_b^*-\hat{\Delta}|\geq|\hat{\Delta}|\right)}{B+1}, \tag{3-16}$$

其中，$I(\cdot)$为指示函数，条件成立时取 1，否则取 0。

主要比较共 7 组，每组在两个语料上分别检验，共 14 项。这些比较依次考察训练配置（T1I0 与 T0I0）、一致性目标（T1I0 与 NoPair）、推理配置（T1I1 与 T1I0）、组件修改范围（T1I1 与 RelationOnly）、共同接受（Single 与 Sequential）、与重新生成的对比（T1I1 与 Regenerate）以及严格改进阈值的放宽（T1I1 与 NoRisk）；其中后五组属于第 4 章，I1 表示在 I0 上追加第 4 章联合修正的推理流程。14 项 p 值统一采用 Holm 方法[62]进行多重比较校正，各章的主要比较结果（表 3.9、表 4.8 和表 4.16）使用相同的逐文档记录与重采样索引，相应的复现材料说明如下。

为便于复现，配套材料包括逐文档的计数、预测图、固定的候选与评分、事务记录（含 4.4.3 节示例事务的复算脚本）、源组提案记录、审核记录以及分阶段的成本记录。统计检验使用 NumPy[93]的 PCG64 随机数生成器，AAEC 与

CDCP 的抽样种子分别为 72026 和 72027，所有方法共用 2000 次重采样索引；14 项主要比较统一进行 Holm 校正，跨骨干的 12 项补充比较单独校正，ThresholdFilter 与外部系统的比较则作为探索性结果报告。

3.5.4 主要结果与消融分析

表 3.8 给出了不同训练配置在 I0 推理下的抽取性能。在相同的 9B 骨干下，本章训练方法使 AAEC 的严格关系 F1 由 65.69%提高至 68.25%，使 CDCP 由 41.79%提高至 45.08%；Holm 校正后的 p 值分别为 0.0175 和 0.0150，且三个种子的提升均为正。与此同时，组件 F1 分别由 85.64%和 80.40%提高至 87.85%和 83.46%。这些结果表明，可靠监督与一致性学习在两个语料上均改善了完整组件与关系的抽取。

表 3.8 不同训练配置的抽取性能（推理均为 I0）

配置	AAEC 组件 F1	AAEC 关系 F1	CDCP 组件 F1	CDCP 关系 F1
T0I0：MCR-BR 基线	85.64 ± 0.07	65.69 ± 3.50	80.40 ± 1.24	41.79 ± 2.65
Heads：基线＋辅助头	85.75 ± 0.24	66.01 ± 3.37	80.76 ± 1.10	41.81 ± 3.01
Plain：普通增强	86.09 ± 0.28	65.95 ± 2.24	81.03 ± 1.14	41.57 ± 3.30
QOS：QOS 式适配	86.43 ± 0.21	66.65 ± 3.09	81.35 ± 1.49	42.54 ± 3.35
NoPair：可靠监督，无一致性项	86.67 ± 0.21	66.85 ± 2.73	81.85 ± 1.26	42.51 ± 2.89
CompPair：仅组件一致性	87.19 ± 0.20	67.70 ± 3.13	82.50 ± 1.15	43.21 ± 3.46
T1I0：完整一致性学习	87.85 ± 0.39	68.25 ± 2.08	83.46 ± 1.04	45.08 ± 2.73
FullFilter：完整筛选	87.61 ± 0.44	68.21 ± 2.71	83.16 ± 1.06	45.08 ± 3.02
RandomCenter：匹配随机中心	87.24 ± 0.12	67.74 ± 2.96	83.00 ± 0.83	44.49 ± 3.52

在改写样本、因素掩码与辅助头均相同的条件下，T1I0 与 NoPair 的差值反映了一致性目标本身的作用。如表 3.9 所示，一致性目标在 AAEC 上带来 1.39 分的提升（95%置信区间[0.28, 2.46]，Holm p=0.0175）；在 CDCP 上带来 2.57 分的提升（95%置信区间[1.05, 4.23]，Holm p=0.0175），且三个种子的差值均为正，CDCP 上的增益更大。由于这组对照固定了数据构造，上述增益可以归因于一致性目标，而非样本数量或掩码的变化。从逐项加入的探索性比较来

看，仅组件一致性相对 NoPair 分别提高 0.84 和 0.69 分，在此基础上加入关系一致性后又提高 0.55 和 1.88 分，其中 CDCP 上后一项的未校正 p 值为 0.0175，说明关系一致性项在 CDCP 上的作用更为突出。

表 3.9 训练配置之间的关系 F1 配对差值

语料	比较	差值（百分制分数）	单项 95%置信区间	种子 17 / 29 / 43	p	类型
AAEC	T1I0 − T0I0	2.56	[0.92, 4.39]	1.26 / 2.34 / 4.07	0.0175	主要／Holm
AAEC	T1I0 − NoPair	1.39	[0.28, 2.46]	1.02 / 0.99 / 2.17	0.0175	主要／Holm
AAEC	CompPair − NoPair	0.84	[0.04, 1.90]	0.79 / 1.43 / 0.31	0.0770	探索／原始 p
AAEC	T1I0 − CompPair	0.55	[-0.78, 1.90]	0.24 / -0.44 / 1.86	0.4018	探索／原始 p
AAEC	NoPair − QOS	0.20	[-0.40, 0.89]	-0.12 / 0.12 / 0.59	0.4993	探索／原始 p
AAEC	NoPair − Plain	0.90	[0.06, 1.75]	1.30 / 1.04 / 0.36	0.0415	探索／原始 p
AAEC	FullFilter − T1I0	-0.04	[-0.86, 0.60]	0.35 / 0.32 / -0.79	0.9015	探索／原始 p
AAEC	RandomCenter − T1I0	-0.51	[-1.71, 0.74]	-0.35 / 0.44 / -1.62	0.3838	探索／原始 p
CDCP	T1I0 − T0I0	3.30	[1.56, 5.17]	2.81 / 3.50 / 3.58	0.0150	主要／Holm
CDCP	T1I0 − NoPair	2.57	[1.05, 4.23]	3.25 / 2.34 / 2.12	0.0175	主要／Holm
CDCP	CompPair − NoPair	0.69	[0.00, 1.96]	0.74 / 1.34 / 0.00	0.1584	探索／原始 p
CDCP	T1I0 − CompPair	1.88	[0.54, 3.56]	2.51 / 1.00 / 2.12	0.0175	探索／原始 p

表 3.9 训练配置之间的关系 F1 配对差值

语料	比较	差值（百分制分数）	单项 95%置信区间	种子 17 / 29 / 43	p	类型
CDCP	NoPair − QOS	-0.03	[-1.47, 1.99]	-0.74 / -0.44 / 1.10	0.9645	探索／原始 p
CDCP	NoPair − Plain	0.94	[-0.49, 2.98]	0.00 / 0.64 / 2.19	0.2359	探索／原始 p
CDCP	FullFilter − T1I0	-0.00	[-0.85, 0.94]	-0.37 / 0.36 / 0.00	0.9885	探索／原始 p
CDCP	RandomCenter − T1I0	-0.59	[-1.86, 0.40]	-1.40 / 0.36 / -0.73	0.3118	探索／原始 p

其余对照的结果同样列于表 3.9。在数据构造方面，可靠监督构造（NoPair）相对普通增强（Plain）在 AAEC 上提高 0.90 分（未校正 p=0.0415），相对槽位化增强（QOS）的差值则仅为 0.20 和−0.03 分，且均不显著，即在不施加一致性约束时，可靠因素构造与 QOS 式继承原标注在关系 F1 上没有可区分的差异；审核的作用主要体现在降低增强监督中的错误（见 3.5.5 节），并为一致性约束提供可靠的对应因素。在样本筛选方面，完整筛选与默认因素掩码在两个语料上的差值分别为−0.04 和 0.00 分，说明丢弃整个改写样本并不优于仅屏蔽不可靠的关系监督；后者在设计上保留了更多可用监督，但本文未单独统计二者的监督覆盖与成本差异。在改写中心方面，随机选择中心在两个语料上均略低于固定中心，但差异并不显著。

3.5.5 增强数据的人工审核

为独立评估增强监督的质量，本节在自动审核器 V 之外另设人工分层审核，由两名审核员 A、B 与一名裁决人 C 完成；由于增强器与自动审核器使用同一基础模型，二者可能具有相关偏差，人工审核因而作为独立参照。A 与 B 分别将每个因素判为状态保持（stable）、状态改变（changed）、无法判定（undecided）或不认同原标注（original_disagreement），C 先独立判断，再给出最终结论；三人先以 60 项培训材料统一标准，培训阶段的一致性 κ 为 0.86。在抽样方面，组件审核同时覆盖被接受与被拒绝的样本，关系审核则从训练增

强池中分四层抽样，每层最多 300 项，不足 300 项时全部审核，抽样概率为 $\pi_h = n_h / N_h$。

在统计口径方面，比例的置信区间采用 Wilson 区间[94]，审核员之间的一致性采用 Cohen κ 系数[95]衡量。不安全率以被接受的因素为分母，漂移率以可以判定且原标注有效的因素为分母，无法判定与不认同原标注两类均不计为状态保持；计算时按 $1/\pi_h$ 加权，并以源文档为单位重采样 2000 次估计置信区间。组件审核与关系因素分层审核的结果分别如表 3.10 和表 3.11 所示。

表 3.10 组件审核结果

语料	抽样	接受	不安全接受	不安全接受率	Wilson 95%	一致率	κ
AAEC	320	300	4	1.33%	[0.52, 3.38]	94.69%	0.690
CDCP	320	300	3	1.00%	[0.34, 2.90]	95.94%	0.755

表 3.11 关系因素的分层人工审核

语料／层	抽样数 n／总体数 N	接受数	不安全接受数（率）	Wilson 95% 置信区间	一致率	κ
AAEC 内部正关系	300／683	280	3（1.07%）	[0.37, 3.10]	96.00%	0.771
AAEC 跨边界正关系	153／153	123	2（1.63%）	[0.45, 5.74]	92.16%	0.804
AAEC 内部 NONE	300／877	279	4（1.43%）	[0.56, 3.63]	90.67%	0.591
AAEC 跨边界 NONE	300／2000	266	1（0.38%）	[0.07, 2.10]	94.67%	0.785
CDCP 内部正关系	300／315	282	2（0.71%）	[0.19, 2.55]	93.00%	0.606
CDCP 跨边界正关系	290／290	249	4（1.61%）	[0.63, 4.06]	94.14%	0.811
CDCP 内部 NONE	300／470	277	5（1.81%）	[0.77, 4.16]	93.00%	0.697
CDCP 跨边界 NONE	300／3251	269	2（0.74%）	[0.20, 2.67]	94.33%	0.776

注：抽样概率 π＝n/N。各层抽样概率依表中顺序为：AAEC／内部正关系为 0.4392；AAEC／跨边界正关系为 1.0000；AAEC／内部 NONE 为 0.3421；AAEC／跨边界 NONE 为 0.1500；CDCP／内部正关系为 0.9524；CDCP／跨边界正关系为 1.0000；CDCP／内部 NONE 为 0.6383；CDCP／跨边界 NONE 为 0.0923。Wilson 置信区间以%为单位；κ 为 Cohen 一致性系数。

表 3.10 与表 3.11 的结果表明，审核后被接受的组件与关系中仅残留少量不安全监督：两个语料的组件不安全接受率分别为 1.33%和 1.00%，各关系层的不安全接受率介于 0.38%与 1.81%之间。由于同一篇源文档可以贡献多个样本和因素，记录之间并不独立，表 3.12 进一步给出了各层的源文档数以及按源文档聚类重采样得到的置信区间。

表 3.12 各审核层的源文档数与聚类置信区间

语料／层	审核因素	源组	π	不安全率	源聚类 95%	总体覆盖
AAEC／内部正关系	300	136	0.4392	1.07%	[0.00, 2.40]	抽样
AAEC／跨边界正关系	153	61	1.0000	1.63%	[0.00, 4.31]	全层
AAEC／内部 NONE	300	129	0.3421	1.43%	[0.34, 2.96]	抽样
AAEC／跨边界 NONE	300	201	0.1500	0.38%	[0.00, 1.18]	抽样
CDCP／内部正关系	300	163	0.9524	0.71%	[0.00, 1.85]	抽样
CDCP／跨边界正关系	290	160	1.0000	1.61%	[0.38, 3.31]	全层
CDCP／内部 NONE	300	133	0.6383	1.81%	[0.37, 3.57]	抽样
CDCP／跨边界 NONE	300	229	0.0923	0.74%	[0.00, 1.87]	抽样

跨边界关系需要单独检查，因为即使组件文字变化不大，也可能改变其与只读组件之间的联系。AAEC 的跨边界正关系层共 153 项，已全部审核，在被接受的 123 项中有 2 项不安全，说明审核后仍存在少量残留错误。

如表 3.13 所示，两个语料的加权漂移率分别为 5.83%和 5.98%，即约 6%的因素在改写后状态发生了变化，说明直接沿用全部原标签确实会引入错误监督；对审核后被接受的关系因素，加权不安全率估计分别为 0.81%和 0.91%。后一项估计以接受集为分母，与总体漂移率的统计对象不同。

表 3.13 增强数据的加权不安全率与漂移率

语料	审核因素／源组	未加权不安全率	加权不安全率	源聚类 95%	加权漂移率	漂移 95%	变化／可判定且原标注有效
AAEC	1053／257	1.05%	0.81%	[0.31, 1.45]	5.83%	[4.19, 7.60]	60／998
CDCP	1190／401	1.21%	0.91%	[0.26, 1.79]	5.98%	[4.06, 8.10]	68／1132

除影响域内的因素外，改写还可能通过指代等上下文影响只读组件之间的关系。为此，本节单独抽查了两端均为只读组件的关系，以检查改写是否影响到关系影响域之外的关系，这部分样本独立于表 3.11 的四层审核，也不影响默认的增强监督。如表 3.14 所示，两个语料各抽查 160 项，均发现 2 项变化，比例为 1.25%（Wilson 95%区间[0.34, 4.44]）。

表 3.14 两端均为只读组件的关系抽查

语料	域外候选总体	抽样	发现变化	比例	Wilson 95%
AAEC	3870	160	2	1.25%	[0.34, 4.44]
CDCP	915	160	2	1.25%	[0.34, 4.44]

3.5.6 训练成本与跨骨干表现

本章方法的训练增益伴随一定的额外计算成本。如表 3.15 所示，T0I0 在 AAEC 和 CDCP 上的平均训练时间分别为 2.45 和 4.15 GPU 小时，T1I0 分别为 5.12 和 8.67 GPU 小时，即分别增加 2.67 和 4.52 GPU 小时，换来 2.56 和 3.30 分的关系 F1 提升。表中 GPU 小时为两张 GPU 的耗时之和，显存为单卡峰值，各骨干的可训练参数量见表 4.22。

表 3.15 训练与增强成本（三个种子的 GPU 时间均值）

语料	配置	GPU 小时	峰值显存（GiB）
AAEC	T0I0	2.45	27.65

表 3.15 训练与增强成本（三个种子的 GPU 时间均值）

语料	配置	GPU 小时	峰值显存（GiB）
AAEC	Heads	2.80	29.76
AAEC	NoPair	4.50	35.19
AAEC	CompPair	4.72	36.77
AAEC	T1I0	5.12	36.42
CDCP	T0I0	4.15	27.79
CDCP	Heads	4.95	29.40
CDCP	NoPair	7.72	35.21
CDCP	CompPair	8.25	36.48
CDCP	T1I0	8.67	36.80

注（AAEC）：各配置的源文档访问数均为 1595，更新步数均为 50。T0I0 与 Heads 的接受改写样本数均为 0，尝试／接受生成词元数均为 0.00／0.00 百万，审核调用均为 0 次；NoPair、CompPair 与 T1I0 的接受改写样本数均为 500，尝试／接受生成词元数均为 1.14／0.82 百万，审核调用均为 1210 次。

注（CDCP）：各配置的源文档访问数均为 2900，更新步数均为 95。T0I0 与 Heads 的接受改写样本数均为 0，尝试／接受生成词元数均为 0.00／0.00 百万，审核调用均为 0 次；NoPair、CompPair 与 T1I0 的接受改写样本数均为 900，尝试／接受生成词元数均为 2.02／1.35 百万，审核调用均为 2190 次。

除表 3.15 中的逐配置训练成本外，一次性运行开销还包括最终训练、交叉拟合、评分头训练及跨度/源组提案。按每个语料 27 次最终训练、18 次交叉拟合、6 次评分头训练和 3 次提案运行统计，AAEC 各项累计成本依次为 120.49、44.69、2.38 和 0.96 GPU 小时，CDCP 依次为 206.83、77.81、3.85 和 1.62 GPU 小时；两个语料合计为 54 次最终训练、36 次交叉拟合、12 个评分头和 6 个提案头。上述一次性成本与单次推理成本分开统计，GPU 小时为设备数与实际耗时的乘积。4B 和 2.5-7B 的补充实验另有 24 次最终训练、72 次交叉拟合、24 个评分头和 12 个提案头，各骨干共用同一批增强数据；全局求解的规模耗时分析见 4.5.4 节。

为考察训练增益对骨干模型的依赖程度，本节在 Qwen3.5-4B 与 Qwen2.5-7B-Instruct 上复用 9B 模型生成并审核的增强数据，比较 T1I0 与同骨干 T0I0 的严格关系 F1。结果表明，本章训练方法在两种补充骨干上同样带来稳定提升：在 Qwen3.5-4B 上，T1I0 相对 T0I0 在 AAEC 和 CDCP 上分别提高 3.22 和 4.66 分；在 Qwen2.5-7B-Instruct 上分别提高 3.52 和 5.82 分。上述补充比较经单独的

Holm 校正后 p 值均低于 0.05。完整的跨骨干四组合结果见 4.6.7 节表 4.23 和表 4.24。

本章方法仍存在一定局限：一方面，改写文本可能表达流畅但监督状态已经改变，审核后仍会残留少量错误；另一方面，改写还可能通过上下文影响只读组件之间的关系，这部分影响已在 3.5.5 节通过抽查进行评估，但尚未在训练中显式处理。

3.6 本章小结

针对训练文本局部改写后部分标注可能失效、直接沿用原标签会引入错误监督的问题，本章提出了可靠监督与一致性学习方法。该方法首先通过关系影响域确定改写可能影响的组件与关系，并借助组件对应映射将原标注无损地迁移到改写文本上；在此基础上，通过语义审核与因素掩码确定增强侧监督的范围，使只有可靠的组件与关系参与学习；进而在可靠因素上施加一致性约束，并按源文档归一化控制改写样本数量带来的权重差异。在 AAEC 和 CDCP 上的实验结果表明，该方法使严格关系 F1 相对同骨干的 MCR-BR 基线分别提高 2.56 和 3.30 分；在固定增强样本与因素掩码的条件下，一致性目标本身带来 1.39 和 2.57 分的提升，且均通过多重比较校正；不施加一致性约束时，可靠因素构造与 QOS 式增强的差异不显著。此外，人工分层审核显示被接受因素的加权不安全率低于 1%，跨骨干实验也表明该训练方法在两种补充骨干上同样带来显著提升。

本章通过筛选可靠的增强监督并施加一致性约束，改善了模型在训练阶段学到的组件与关系预测，使因端点组件缺失或错误而无法命中的金标关系在 AAEC 上由 637 条减少到 546 条、在 CDCP 上由 294 条减少到 260 条（见 4.6.5 节表 4.18）；然而，这部分关系仍分别占金标关系的约 22.5%和 34.4%，而组件一旦出错，以其为端点的关系也随之失效，单靠改进训练信号难以消除这类错误。因此，下一章将以本章所得模型为起点转向推理阶段，研究在不改动原文的前提下如何修改预测组件并同步重建受影响的关系，以获得满足任务约束的论辩结构。

第 4 章 基于结构约束的论辩图联合修正方法

第 3 章通过筛选可靠增强监督并施加一致性约束，改善了模型的学习信号，但生成结果中仍然存在组件边界、类型及关系判断错误。这些错误具有相互依赖性：修正某个组件后，与其相连的关系需要重新判断；若分别决定组件和关系的修改，又可能使局部收益伴随其他正确预测的损失。因此，在已有预测结果上协调组件与关系的变化，并控制误改范围，仍是需要单独研究的问题。针对这一问题，本章提出结构约束联合修正方法，在固定候选与对象评分的条件下，将组件修改及受影响关系的重建纳入共同决策，通过结构约束和编辑预算选择修正结果。本章依次介绍候选生成、对象评分、联合修正机制及求解算法，并通过对照实验分析修正效果、计算开销及其与训练方法的衔接关系。

4.1 引言

推理阶段的结构错误中，有相当一部分源自组件。本章以第 3 章所得模型 T1I0 为起点，其中 T1 表示第 3 章的训练配置，I0 表示继承自 MCR-BR 的推理流程，包括重排序、合法化与原始有界修正。4.6.5 节的分析（表 4.18）表明，第 3 章的训练方法使因端点组件缺失或错误而无法命中的金标关系在 AAEC 上由 637 条减少到 546 条、在 CDCP 上由 294 条减少到 260 条，但这类关系在 T1I0 中仍分别占金标关系的约 22.5%（546/2427）和 34.4%（260/756）。造成这一现象的根源在于组件与关系之间的依赖：组件的边界或类型一旦改变，以其为端点的全部关系也随之成为不同的对象，例如将某个组件的类型由主论点改为论点后，原先关联该组件的关系需要按新的端点重新判断，而不能直接沿用其原有对象标识。因此，修正决策面临两方面的困难：一方面，若仅根据组件的置信度决定是否修改，就会忽略关系整体失效带来的损失；另一方面，若根据整图的平均得分决定是否修改，又可能把删除对象导致的分母变小误当作收益。

围绕组件与关系的协同决策，已有研究进行了多方面的探索：基于结构解析与整数规划的方法[12]在全局约束下联合推断组件与关系，关系抽取中的修正方法 Re-Cent[53]以及论辩重构研究[54]也提出了对预测结构进行修正的相关机制。然而，对于在已有预测图上进行修正的场景，简单的后处理并不足够：4.6.2 节的实验表明，仅按评分删除低分关系虽然能够提升 F1，却会误删一部分原本正

确的关系。由此可见，修正过程必须在同一目标下同时衡量恢复正确对象的收益与删除对象的代价。

针对上述问题，本章提出结构约束联合修正方法（简称联合修正）。结合MCR-BR[56]中的候选生成与初始修正流程，该方法在原文、候选和对象评分均固定的条件下，将组件冲突消解、受影响关系的重建、分项效用和编辑预算纳入统一的接受规则，使组件修正的收益与关系侧的代价在同一目标下得到权衡。具体而言，每次修改都以依赖闭合事务为单位进行：一个组件被修改后，以该组件为端点的全部关系连同新组件可能参与的关系都要一并重新决策，组件修改与这些关系的重建构成一个不可拆分的整体，要么整体接受，要么整体拒绝。在此基础上，完整推理配置 I1 在 I0 得到的初始图 G_0 上追加联合修正 R_{DC}，并根据候选规模选择全局整数规划求解或集合局部搜索子程序（本文记为 BR-J）。联合修正过程不更新抽取模型的参数，所依赖的对象评分器单独训练与校准（见 4.3.1 节），因此该方法既能作用于第 3 章所得模型，也能直接作用于其他训练配置得到的模型。

图 4.1 展示了候选对象、独立评分器与结构约束之间的关系，并以 AAEC 文档 essay077 的一次局部修改说明组件替换与关联关系重建。红色虚线表示删除的旧关系，绿色实线表示新增关系，案例的完整计算见 4.4.3 节。候选与评分在修正期间保持固定；局部搜索按累计编辑量检查预算，全局求解按相对初始图的净变化检查预算。后续各节分别介绍候选构造、对象评分、联合修正及求解算法，并通过实验分析其效果。

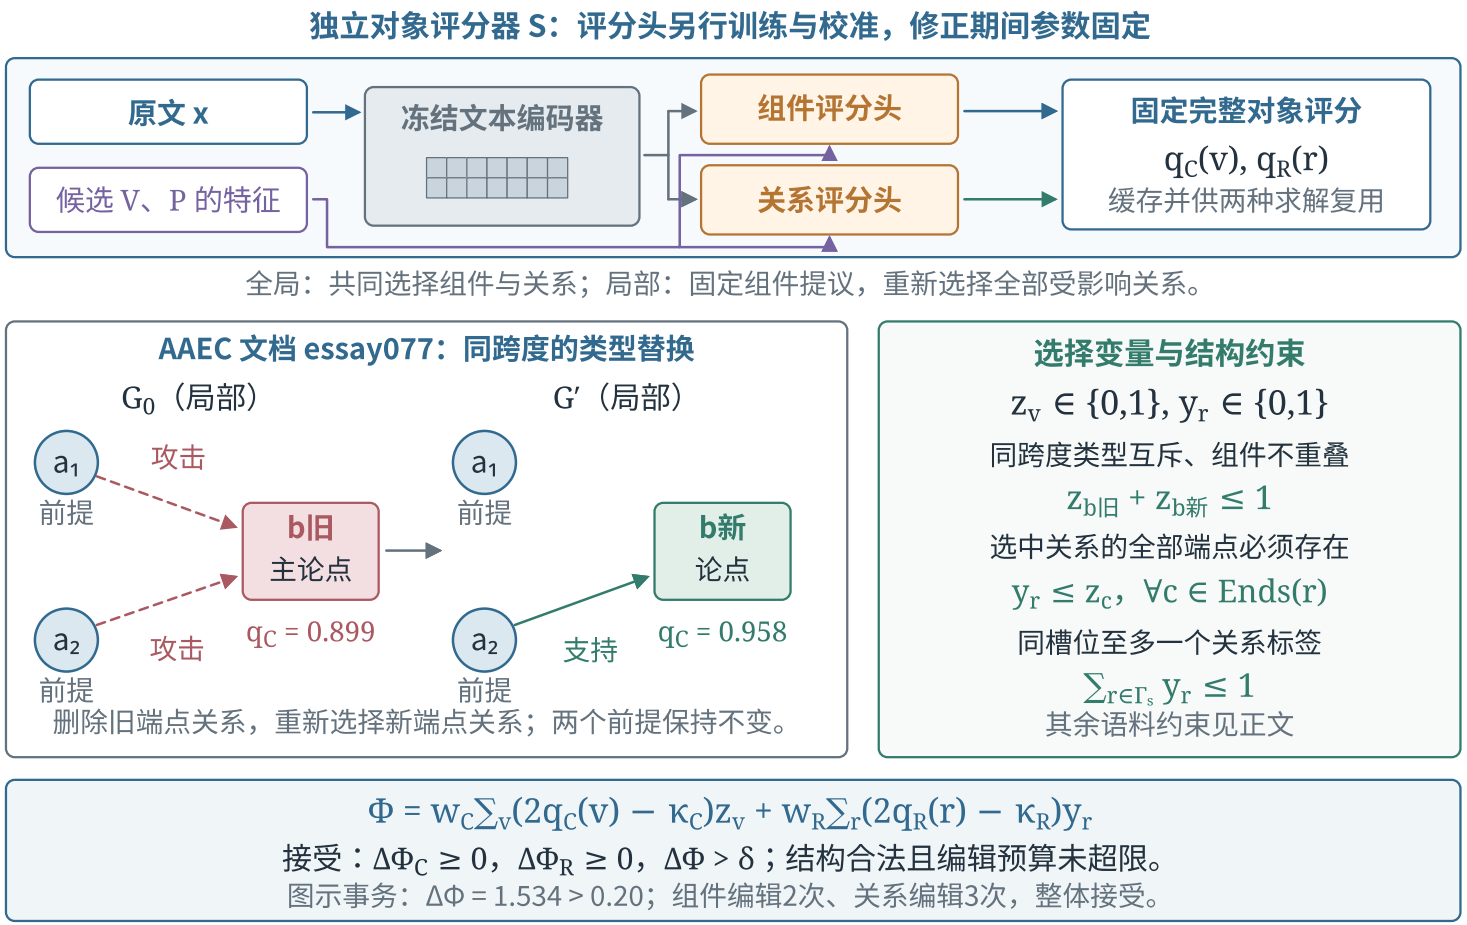


图 4.1 结构约束联合修正方法结构

4.2 候选生成与初始图

候选生成在本章方法中承担两项作用：一是为初始图的选择提供若干完整的备选结构，二是限定后续修正能够使用的对象范围。其中，初始图的选择沿用 MCR-BR 的做法；在修正开始前，再将多次生成与补充提议得到的对象汇总为固定的候选空间。

4.2.1 多候选生成与初始图选择

给定文档 x，生成器产生 K 组组件预测，默认取 $K=3$：其中一组采用贪心解码（temperature 为 0），另外两组采用核采样（temperature 为 0.7，top-p 为 0.9）。三组预测使用同一提示，差异仅来自解码方式，K 的取值固定为 3，本文未单独考察其影响。由此得到的组件预测集合表示为：

$$\mathcal{C}=\{C^{(1)},\dots,C^{(K)}\},\tag{4-1}$$

其中，每个组件由原文跨度和类型构成。关系生成器在给定的组件集合 $C^{(k)}$ 上预测关系，得到候选图 $G^{(k)}=\left(C^{(k)},R^{(k)}\right)$，这一过程不修改组件，预测对象的数量由模型自行决定。多个候选在边界、类型和连接上的差异，既用于选择初始图，也为后续的替换提供备选对象。

初始图 G_0 按 2.4 节所述流程得到，即沿用 MCR-BR 的重排序、合法化以及 MCR-BR 中的原始有界修正模块（本文记为 BR-O）；I1 在此基础上执行追加修正 R_{DC}，其预算单独计算。重排序的评分形式为：

$$\mathrm{E}_{\mathrm{rank}}(G)=0.4\,\mathrm{E}_{\mathrm{dens}}(G)+0.4\,\mathrm{E}_{\mathrm{coh}}(G)+0.2\,\mathrm{E}_{\mathrm{val}}(G),\tag{4-2}$$

其中，$\mathrm{E}_{\mathrm{val}}$ 为合法性分量，当输出可解析且跨度、类型和引用全部合法时取 1，否则取 0；覆盖分量与连贯分量均依赖关系的语义验证结果。设 $Q(G)$ 为预测图中参与覆盖评价的节点，$p_r\in\{0,1\}$ 为关系语义验证的结果，$d_{\mathrm{coh}}^{\mathrm{in}}(j)$ 为指向节点 j 且通过验证的关系数，则两个分量分别计算如下：

$$\mathrm{E}_{\mathrm{dens}}(G)=\frac{1}{|Q(G)|}\sum_{j\in Q(G)}\min\left\{\frac{d_{\mathrm{coh}}^{\mathrm{in}}(j)}{\tau_j},1\right\},\mathrm{E}_{\mathrm{coh}}(G)=\frac{1}{|R|}\sum_{r\in R}p_r,\tag{4-3}$$

其中，集合为空时对应分量取 0。AAEC 的覆盖节点为预测的论点，CDCP 的覆盖节点为预测的政策和价值，主论点不要求必须有入边；结构角色阈值按节点

是否有出边设置，没有出边时 τ_j=2，否则 τ_j=1；对于 CDCP 的多前提关系，只计一次入边。

初始图的合法化与 BR-O 修正同样沿用 MCR-BR 的处理方式。具体而言，重排序得分相同的候选按生成顺序选择；合法化只作用于 G_{rank}，通过坐标规范化、去重和重新编号得到 G_{pre}，遇到无法消解的冲突时返回失败；BR-O 在 G_{pre} 上执行，并经合法性检查后得到 G_0。

上述评分存在明显的局限：一方面，覆盖分量和连贯分量都依赖同一验证结果 p_r，二者并不独立；另一方面，覆盖节点数和当前边数又是平均分的分母，删除低分对象或改变组件类型可能提高平均分，却不一定提高真实的准确率。因此，本章仅将该评分用于初始候选的选择，并为允许修改组件的修正阶段另行定义接受目标。

4.2.2 候选空间构建

追加修正开始前，首先构建固定的跨度集合 U，该集合由两部分组成：一是保护部分，包括 G_0 以及各候选输出中全部合法的组件跨度，这些对象不会被裁剪；二是补充部分，由独立的跨度预测头和类型分类器提供。跨度预测头基于冻结的 Qwen3.5-9B 表示，通过两个线性层分别预测组件的起止边界，并在训练集上进行监督训练；补充跨度按边界得分排序，最多保留 64 个，其候选类型由类型分类器给出。

在类型层面，每个补充跨度保留类型头排名前 2 的类型，保护对象则保留其全部类型。记跨度 u 的候选类型集合为$T_*(u)$，则带类型的组件候选集合为 $V=\{(u,t):t\in T_*(u)\}$，每个跨度最多选择一个类型，NULL 表示不选。

候选对象的身份由字符坐标确定：跨度 u 即字符区间(d,b,e)，带类型候选(u,t)对应(d,b,e,t)，关系则由完整的源组件集合、目标组件和标签共同确定。候选去重、评分缓存、冲突检查和评价均使用这一身份。

关系候选按“源组件集合—目标”槽位构建。对于 AAEC，枚举同一文档中任意两个不同候选组件构成的有向对，不允许自环，也不按段落或组件类型预先过滤；对于 CDCP，则由一个学习得到的源组提案器 P 生成候选源组件集合，并用相邻源组件的规则进行补充。G_0 及各候选图中已有的槽位始终保留，不受数量上限限制。

源组提案器 P 在冻结的 Qwen3.5-9B 编码器上接一个隐藏维度为 1024 的两层 MLP，输入源组件表示、目标表示、全文表示和 7 维位置特征；训练时以训练集中真实的源组件集合为正例，为每个正例抽取 4 个负例，训练 5 个 epoch。P 最多输出 64 个候选槽位，再用相邻 2 或 3 个源组件的规则进行补充，补充后的总数不超过 256，而 G_0 以及各候选图中已有的槽位另行保留，不受该上限限制。

每个槽位包含该端点组合下的全部合法关系标签，NONE 由不选任何正关系表示；槽位按各标签对象得分的最大值排序，保留前 N_{slot} 个补充槽位。

为控制候选规模，若构建过程中合法槽位数超过 50000，则视为构造失败，直接返回 G_0。作为参考，若对 m 个跨度、每个跨度 q 个类型完全展开，AAEC 的槽位数为 $m(m-1)q^2$，CDCP 的槽位数为 $\sum_{k=1}^{3} C(m,k)(m-k)q^{k+1}$，其中 $C(m,k)$ 表示从 m 个跨度中选取 k 个的组合数，二者均远大于默认设置下的实际规模。

对于二元关系，只有当正反两个方向的槽位都在候选池中且端点合法时，才考虑反转关系方向；搜索期间不向候选池外补充关系。

在上述候选空间上，主实验施加的结构约束可逐项归纳如下，这些约束均针对论辩挖掘任务设定：①组件跨度互不重叠（嵌套也视为重叠），该约束在两个语料上均施加，与新增组件冲突的旧组件须在事务中补全删除（见 4.4.1 节）；②同一端点组合（槽位）至多选择一个关系标签，NONE 表示不选；③关系的全部端点都必须存在于当前组件集合中，不允许自环，二元关系反转方向时还需满足上述双向槽位条件；④ AAEC 的关系为任意两个不同组件之间的有向二元关系，CDCP 的源组件须按原文位置连续且目标不属于源集合，多前提关系作为一个整体，不在二元表示与多元表示之间任意拆合；⑤若语料要求无环，则引入顺序变量施加无环约束（见 4.5.1 节）。候选质量的统计见 4.6.3 节。

4.3 对象评分与接受准则

搜索过程需要比较不同状态的优劣，而各状态的组件数、关系数和图结构均在不断变化。为此，本章在搜索前固定每个对象的得分，以基于计数的效用

衡量对象的增加与删除，并设置分项接受门，既不允许以组件效用的下降换取关系效用的提高，也不允许以关系效用的下降换取组件效用的提高。

4.3.1 对象评分器与策略选择

对象评分器 S 分别估计组件和关系作为完整对象完全正确的概率，表示为：

$$q_C(c \mid x), q_R(r \mid x), \tag{4-4}$$

其中，组件得分由组件头给出，组件头根据跨度表示和全文表示预测类型（含 NULL）分布；关系得分由关系头给出，关系头以端点的跨度表示和类型、关系方向、关系标签以及全文表示为输入，判断整个关系对象是否正确。只有端点跨度、端点类型和关系标签都完全正确时，关系候选才被视为正例，因此在金标端点上训练得到的关系分类器，其准确率并不能代表完整对象的正确概率。

评分器 S 使用冻结的 Qwen3.5-9B 编码器，组件头和关系头均为两层 MLP，与抽取模型的 LoRA 和训练辅助头相互独立。具体而言，组件头以跨度均值表示与全文末端表示为输入，结构为 $8192 \to 1024 \to$ 类型数+1；关系头以源组件、目标、全文表示、类型和标签嵌入以及位置特征为输入，结构为 $12375 \to 1024 \to 1$。两个头均使用 GELU 激活和 0.1 的 dropout，采用 AdamW 优化器以 10^{-3} 的学习率训练 10 个 epoch；评分器 S 与提案器 P 共享冻结的文本表示缓存，但不共享可训练参数。

在跨骨干实验中，4B 和 2.5-7B 骨干分别重新训练和校准评分器，各模块的输入维度随骨干的隐藏维度 d 调整：评分器 S 的组件和关系输入维度分别为 $2d$ 和 $3d+87$，提案器 P 的输入维度为 $3d+7$。各骨干使用各自的分词器，结果通过字符坐标对齐，输入长度上限统一为 4096 个 token，不启用长上下文扩展。

在搜索开始前，同一文档的文本表示、校准参数和全部候选得分均被固定；由于对象得分 q 不依赖当前图的结构，同一对象在不同搜索状态中的得分保持不变。评分缺失等异常情况的处理见 4.5.4 节。

评分器的训练数据应当包含模型实际会犯的错误，而不能只使用人工构造的简单负例。因此，本文按源文档进行三折交叉拟合（out-of-fold，OOF）：对于每一折，使用未见过该折文档的生成器和跨度头为其生成候选，再与金标对

比得到正负标签；在比较两种训练方法时，OOF 候选同时来自两类生成器，以避免评分器只适应其中一种。

负例包括跨度错误和类型错误的组件，以及原本无关系的槽位上的关系候选，校准数据则保持候选的自然分布。按 4.6.1 节所述的交叉拟合划分，训练集源文档分为评分器拟合、校准和策略选择三部分，分别用于训练评分器、校准概率以及选择阈值和预算；评分质量的检查结果见 4.6.3 节。

策略在独立的策略集上选择。AAEC 固定 $\kappa_R=1$；CDCP 在 $\kappa_R\in\{0.5,1.0\}$和 $\delta\in\{0.01,0.05,0.10,0.20\}$的组合中进行选择：首先排除原有正确关系损失率超过 5%的组合，再从其余组合中选取关系 F1 最高者，若出现并列，则取较大的 κ_R 和 δ；若所有组合均不满足要求，则直接输出 I0 的结果。选定的参数在评价前固定，并由局部求解和全局求解共用。

4.3.2 效用函数与接受条件

对于对象类别 $X\in\{C,R\}$（C 为组件，R 为关系），设固定系数 $0<\kappa_X<2$，效用定义为：

$$\Phi_X(G)=2\sum_{o\in X(G)} q_X(o\ /\ x)-\kappa_X\left|X(G)\right|,\Phi(G)=w_C\Phi_C(G)+w_R\Phi_R(G),\quad(4\text{-}5)$$

其中，$w_C,w_R>0$，主配置取 $w_C=w_R=1$，κ_X 在开发集上确定后固定。该效用不按当前图的组件数或关系数进行归一化。

该效用具有清晰的概率含义。令 Y_X 为真实对象集合，并假设 $q_X(o\ /\ x)=P(o\in Y_X\ /\ x)$，即评分为对象正确的概率，则由$\mathrm{FP}_X=\left|X(G)\right|-\mathrm{TP}_X$和$\mathrm{FN}_X=\left|Y_X\right|-\mathrm{TP}_X$可得：

$$\Phi_X(G)=(2-\kappa_X)\mathrm{E}\left[\left|Y_X\right|\ /\ x\right]-E\left[\kappa_X\mathrm{FP}_X+(2-\kappa_X)\mathrm{FN}_X\ /\ x\right],\quad(4\text{-}6)$$

其中，第一项与预测图无关，因此最大化该效用等价于最小化误检和漏检的期望加权代价，κ 控制两类错误的相对权重；该推导只用到期望的线性性，无需假设各对象的正确性相互独立。

然而，F1 不能按对象分解，最大化 F1 的决策一般无法由边际概率直接确定[57,58]。因此，本文采用可分解的代价敏感效用作为代理目标，使其能够直接用于事务差分和整数规划，最终效果仍以严格关系 F1 评价。

在此基础上，一个候选事务只有同时满足以下条件才被接受：修改后的整图合法，剩余预算足够，且

$$\Delta\Phi_C \geq 0, \Delta\Phi_R \geq 0, \Delta\Phi > \delta > 0, \tag{4-7}$$

其中，前两个条件（分项门）要求组件和关系的效用均不下降，第三个条件要求总效用的提升超过阈值 δ，以排除收益很小的修改。

编辑成本用于限制修改规模。组件的编辑成本为 $d_C = |D| + |B|$，即删除和新增组件的数目；关系的编辑成本为 $d_R = |R \triangle R'|$，即修改前后关系集合的对称差；组件类型或边界改变导致的关系删除与新增分别计费。编辑成本只用于预算限制，以及在效用相同时优先选择改动较少的方案，不计入效用；此处只统计追加修正的编辑，并分别记录累计编辑量和相对 G_0 的净变化。

4.4 依赖闭合事务的构造

组件修改与关系重建构成一个不可拆分的事务，其构造过程分为三步：首先补全删除集合以消除跨度冲突，然后找出所有受端点变化影响的关系，最后对修改后的完整图进行一次接受判断。仅修改关系的操作也使用同一事务接口，此时组件保持不变。

4.4.1 组件冲突消解

设当前组件集合为 C，一次提议给出新增集合 B 和主动删除集合 D_0（D_0 和 D 均表示待删除的组件集合，输入文档仍记为 x）。冲突消解首先将 $B \cap C$ 中没有变化的对象从 B 和 D_0 中去掉，然后补上所有与新增组件冲突的旧组件，表示为：

$$D = D_0 \cup \{c \in C : \exists\, b \in B, \mathrm{Conflict}(c, b)\}, C' = (C \setminus D) \cup B, \tag{4-8}$$

其中，B 内部的组件必须互相兼容；所有与新增组件冲突的旧组件，即使不在提议范围内，也都必须加入 D，否则修改后的图仍可能存在非法重叠。若补全后超出预算，则拒绝该提议。

在此基础上，基本的修改操作包括 $0 \to 1$、$1 \to 0$、$1 \to 1$、$1 \to 2$ 和 $2 \to 1$，分别对应补回漏检、删除误检、替换类型或边界、拆分和合并；默认每个事务满足 $|D| + |B| \leq 3$，该限制在冲突补全之后检查。

4.4.2 受影响关系的重建

本章所说的“依赖闭合”是指，一个组件被删除或替换后，所有以旧组件为端点的关系以及新组件可能参与的关系都要一同进入决策，以免只计算组件的收益而遗漏关系的损失，其中“全部受影响关系”限于候选空间之内。另外，本章的 NONE 与第 3 章含义不同：第 3 章的 NONE 来自标注，需要在改写后保持；本章的 NONE 仅表示当前预测没有选择该关系，其中可能存在漏检，因此推理时可以将其改为一条关系。

令变化对象集合 $A=D\cup B$ 包括被删除的旧组件和新增的组件（与第 3 章的改写集合不同），P_A 为候选池 P 中至少有一个端点属于 A 的全部关系，包括入边、出边、已选的正关系和未选的 NONE 槽位。删除旧组件后，所有以其为端点的关系都必须删除，而新增组件的入边和出边则重新参与选择，不能按旧编号继承。

对于组件正确但关系有误的情况，事务保留纯关系提议 S_R，其关系范围定义为:

$$P_{\text{tx}}=P_A\cup S_R, \tag{4-9}$$

其中，纯关系事务（RelationOnly）取 $D=B=\varnothing$，通过 S_R 实现增边、删边、改标签或反转方向；一个槽位进入 S_R 时，其全部合法标签一同进入，反转方向则需满足 4.2.2 节的双向槽位条件。

对于每个新的组件集合 C'，算法先为受影响的关系求出最优（或可行）的补全，再比较完整的新图 $G'=(C',R')$，而不是先按组件得分决定 C'。事务以外的关系保持不变，但整图仍需满足全局约束：若组件的变化使某些事务外的已选关系变得不合法，就将这些关系的槽位加入 S_R，重新求解其全部标签并计入相应的编辑成本，若仍不可行或超出预算，则拒绝该事务。通过上述处理，端点变化导致的关系失效均被计入，组件收益与关系代价得以完整权衡。

CDCP 还存在一种特殊情况：由于源组件必须在原文中连续，删除某个中间组件可能使原本不合法的关系变得合法。例如，组件依次为 a,b,c,t，候选关系 $h=(\{a,c\},t,\text{Reason})$ 因 b 位于 a、c 之间而不合法；删除 b 之后 h 变得合法，但 a,c,t 均未变化，h 不在该事务的重建范围 P_A 之内，只能由后续的纯关系提议恢复。本文没有将这类槽位自动纳入事务，这是局部搜索在邻域上的限制，并不

影响已接受结果的合法性和算法的终止性；全局求解同时决定组件和关系，可以直接处理这种情况（见 4.5.2 节）。

综上，跨度或类型改变后，组件即成为一个新对象，以旧对象为端点的关系计为删除，以新对象为端点的关系计为新增。下面以一个真实事务说明这一过程。

4.4.3 事务示例

本节以 AAEC 测试文档 essay077 为例（种子 29，单对象共同接受中的第 1 次事务），组件文字取自原始语料，得分 q 来自 9B 模型固定后的评分，事务涉及的对象及其评分如表 4.1 所示。

表 4.1 essay077 示例事务涉及的对象及其评分

对象	原文／完整端点及标签	变化	评分 q
b 旧：[1483,1537) 主论点	complained about the drawbacks of zoos are often heard	删除	0.898635
b 新：[1483,1537) 论点	complained about the drawbacks of zoos are often heard	加入	0.958186
a1：[1555,1669) 前提	some zoos are lack of systematic management which attributes to numerous wild animals die because of food shortage	保持	0.898486
a2：[1677,1820) 前提	being caged in the zoos for long render wildlife lost the ability to survive in nature where is full of cruel competition among various animals	保持	0.897797
r1	a1 → b 旧 / 攻击	删除	0.669856
r2	a2 → b 新 / 支持	加入	0.890926
r3	a2 → b 旧 / 攻击	删除	0.013781

原预测将[1483,1537)标为主论点，而金标类型为论点。同一跨度上的新旧两个类型对象互相冲突，因此加入 b 新就必须删除 b 旧；随之，两条指向旧对

象的攻击关系被删除，并新增了 a2 指向新论点的支持关系，a1 和 a2 本身保持不变。

取 $\kappa_C=\kappa_R=1$、$\delta=0.20$ 时，该事务使组件效用增加 0.119102，关系效用增加 1.414578，总效用增加 1.533680。由于两个分项增量均非负且总增量超过阈值，组件和关系分别编辑 2 次和 3 次，也未超出追加阶段 24 和 96 的预算，该事务被接受。

按金标进行事后统计，组件的 TP/FP/FN 由 11/3/3 变为 12/2/2，关系由 4/5/5 变为 5/3/4。为检验拒绝条件，在同一事务上另行构造两种异常输入：若删除 1 个必需关系分数，检查结果为 reject_missing_score；若将剩余组件预算设为 1，检查结果为 reject_edit_budget。两种情况下事务均被拒绝，原图保持不变，语义编辑数为 0；而在正常输入下，全部必需分数齐备，事务以组件 2 次、关系 3 次编辑提交。

以上案例展示了单个事务的评估与接受过程，下一节将介绍如何在候选空间中搜索并提交这样的事务。

4.5 求解算法及性质

联合修正包括局部求解与全局求解两种方式：局部求解先固定通过冲突检查的组件提议，再补全受影响的关系；全局求解则一次性同时选择全部组件和关系。二者共用固定评分、分项门和整图约束，但编辑预算的计算方式不同，局部求解按累计修改计算，全局求解按相对初始图的净变化计算，因此二者的可行域也不同。下面依次介绍局部求解、全局求解、方法性质以及求解方式的选择。

4.5.1 集合局部搜索

局部求解采用“有界组件提议＋局部整数规划关系补全”的方式。对于一个已经通过冲突检查的组件集合 C'，令 $z_c=I[c\in C']$ 表示组件状态（已固定），$y_r\in\{0,1\}$ 表示是否选择关系候选 $r\in P$，则目标函数为：

$$\max_{y} w_C\Phi_C(C')+w_R\sum_{r\in P}\left(2q_R(r\mid x)-\kappa_R\right)y_r, \tag{4-10}$$

其中，组件提议固定后，组件项在关系求解中是常数，但在比较不同组件提议时仍需保留。约束条件如下：

$$\begin{aligned}
&\sum_{t\in T_*(u)} z_{(u,t)} \le 1,\\
&z_c + z_d \le 1 \text{ 若 } \mathrm{Conflict}(c,d);\\
&y_r \le z_c \ \forall\, c \in \mathrm{Ends}(r),\\
&\sum_{r\in\Gamma_s} y_r \le 1 \ \forall\, s;\\
&y_r = I[r\in R] \ \forall\, r \notin P_{\mathrm{tx}},\\
&G' \in G_A,
\end{aligned} \tag{4-11}$$

其中，Γ_s为同一槽位的互斥标签候选，全为 0 即为 NONE；G_A为整图合法集合；关系约束保证被选关系的端点全部存在。若语料要求无环，则引入顺序变量 $0\le o_c \le M-1$（$M=|V|$），并对全部候选二元边加入约束：

$$o_v \ge o_u + 1 - M\left(1 - y_{(u,v,\ell)}\right). \tag{4-12}$$

对于多前提关系，对每个源组件到目标的方向分别加入同样的约束；对于 CDCP 的源组件连续性规则，则在给定的 C'上判断每个候选关系是否合法，对不合法的关系强制 $y_h=0$，若这与事务外的固定关系冲突，则当前事务不可行。

此外，分项效用门和编辑预算也作为约束加入整数规划。设$y_r^0 = I[r\in R]$为修改前的关系状态，关系编辑成本可以线性地表示为：

$$d_R = \sum_{r:\,y_r^0=1}\left(1-y_r\right) + \sum_{r:\,y_r^0=0} y_r. \tag{4-13}$$

整数规划同时要求 d_C, d_R不超过剩余预算，并且 $\Delta\Phi_C, \Delta\Phi_R \ge 0$，提交前再检查 $\Delta\Phi > \delta$。这些条件必须在求解时加入，而不能先求最高分再检查是否违规；若存在多个最优解，则依次按效用最大、编辑最少、规范键最小的顺序选择；求解超时时，返回当前最好的可行解，并重新检查全部约束。

局部搜索的提议分为六类：纯关系、插入、删除、替换、拆分和合并。具体而言，纯关系提议枚举端点合法的全部槽位；插入从未选组件中选择，删除从已选组件中选择；替换以一个新组件代替一个旧组件，允许类型或边界变化；拆分将一个旧组件替换为两个相容、位于原跨度内且首尾包络与原跨度一致的新组件，合并则是其逆操作。每个提议都先补全冲突删除，再按实际的 S_R、$(|D|,|B|)$检查其是否属于上述类型以及是否超过三个组件的上限，例如，一个名义上的插入若实际变成了 $2\to1$，在单对象对照中就会被拒绝。

局部搜索按提议次数计算预算：评估一个提议计一次尝试，提议被提交计一次接受，每轮最多 32 次尝试、3 次接受，最多 4 轮，均从 G_0 开始计算。在每一批中，算法从六类提议中轮流选取，按得分和剩余预算择优检查，并从本批通过检查的候选中择优提交一个完整事务；同一状态下不重复评估相同的提议，无法安全提交时返回最近的合法图。执行流程如图 4.2 所示。

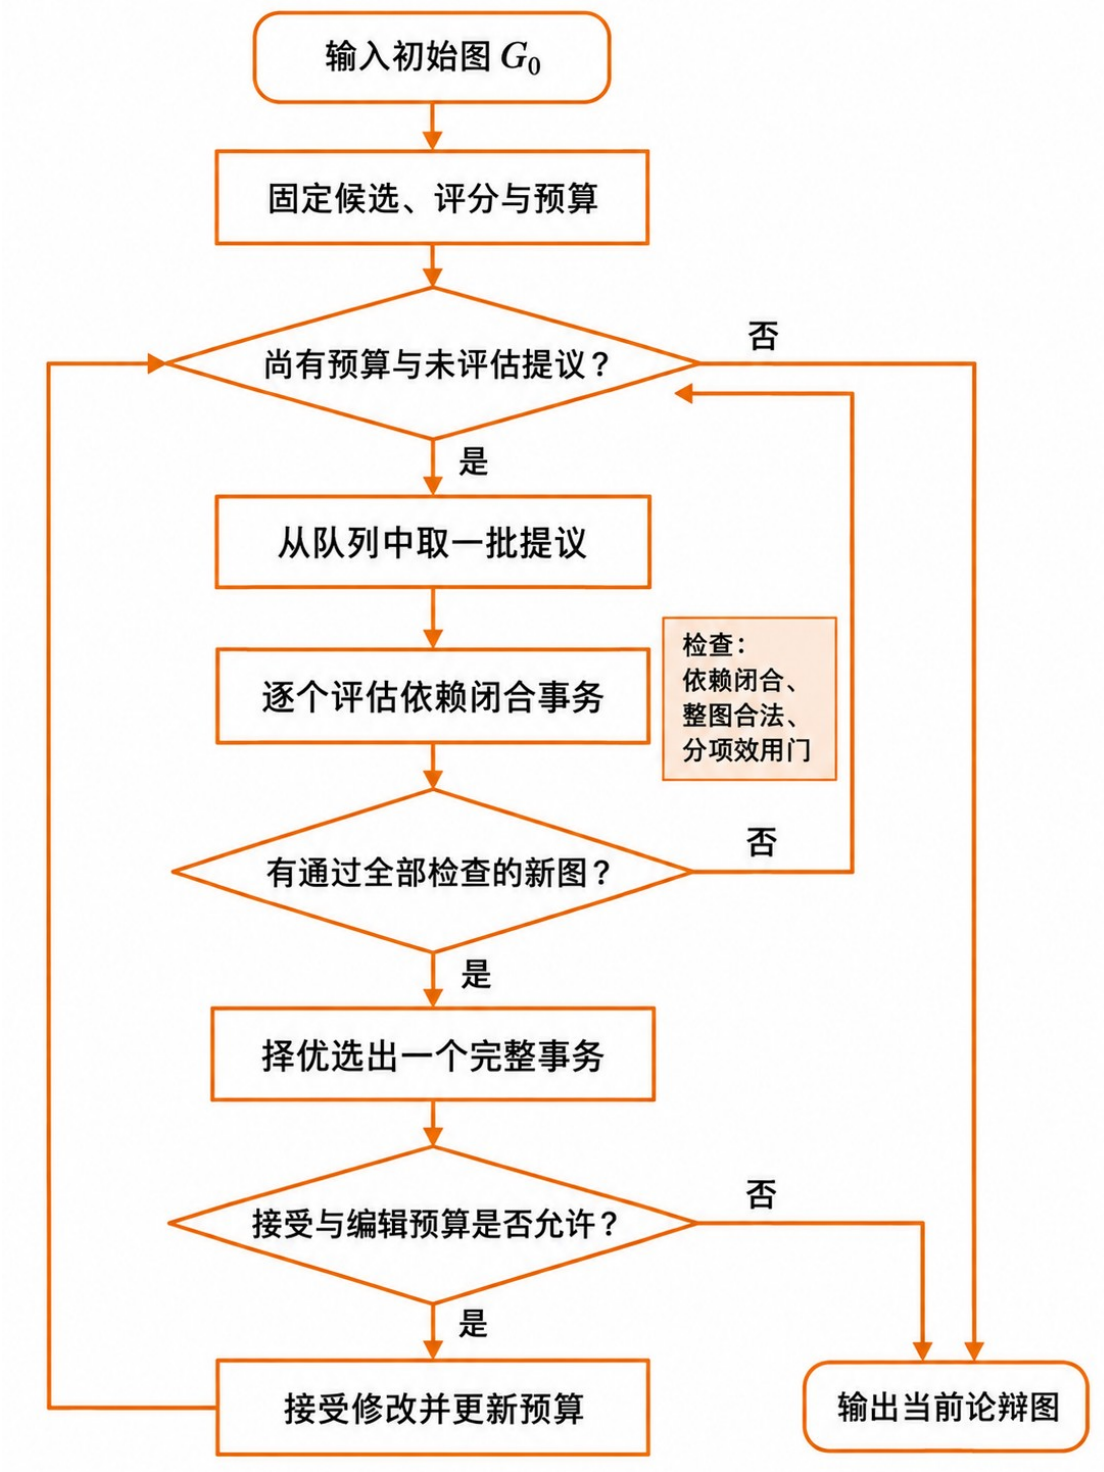


图 4.2 集合局部搜索 BR-J 的执行流程

图 4.2 概括了集合局部搜索子程序 BR-J 的执行流程。流程以 4.2 节得到的合法初始图 G_0 为起点；无法获得合法初始图时报告初始化失败，候选构造或评分固定失败时返回 G_0。每项提议先按 4.4 节补全冲突删除与受影响关系，再在预算和约束内求解；无可行解或评分失败的提议不予提交。接受前检查完整合法性、编辑预算、分项门和总效用增益，检查通过后整体提交；提交失败时，组件、关系和缓存全部恢复到提交前的状态，并返回最近的合法图。候选构造、评分、拒绝和超时的开销均计入成本。

4.5.2 全局整数规划求解

4.5.1 节固定组件提议 C'，只对关系进行求解；全局求解则同时选择全部组件和关系，此时不能简单地放开组件变量，还需相应调整约束：CDCP 的源组件连续性取决于中间组件是否被选中，编辑量和分项门也要改为相对初始图 G_0 计算。全局模型具体如下。

（1）变量与目标。对候选空间中的每个带类型组件 $v \in V$ 设变量 $z_v \in \{0,1\}$，对每个关系候选 $r \in P$ 设变量 $y_r \in \{0,1\}$，并以 z_v^0、y_r^0 表示 G_0 中的取值。记 $a_X(o) = 2q_X(o \mid x) - \kappa_X$，全局目标与局部求解使用同一效用，定义为：

$$\max_{z,y} \Phi(z,y) = w_C \sum_{v \in V} a_C(v) z_v + w_R \sum_{r \in P} a_R(r) y_r . \tag{4-14}$$

（2）结构约束。全局模型的结构约束表示为：

$$\begin{aligned} &\sum_{t \in T_*(u)} z_{(u,t)} \le 1 \ \forall u \in U, \\ &z_c + z_d \le 1 \text{ 若 } \mathrm{Conflict}(c,d); \\ &y_r \le z_c \ \forall r \in P, \forall c \in \mathrm{Ends}(r), \\ &\sum_{r \in \Gamma_s} y_r \le 1 \ \forall s; \\ &y_h + z_w \le 1 \ \forall h \in P_{\mathrm{CDCP}}, \forall w \in \mathrm{Btw}(h), \end{aligned} \tag{4-15}$$

其中，上述约束依次表示：同一跨度最多选择一个类型，所选组件两两兼容，被选关系的全部端点（包括多前提关系的全部源组件）都被选中，同一槽位的标签互斥。最后一个约束表达 CDCP 的源组件连续性：对于关系 $h = (S, v, \ell)$，令 $\mathrm{Btw}(h)$ 为起点位于 S 中最左和最右源组件之间、但不属于 S 的候选组件，由于被选组件互不重叠，S 在被选组件序列中连续，当且仅当 $\mathrm{Btw}(h)$ 中没有组件被选中，因此该约束是对连续性的精确线性化。若语料要求无环，则沿用 4.5.1 节的顺序变量约束。

仍以 4.4.2 节的 a,b,c,t 为例，全局模型中存在约束 $y_h+z_b\le 1$，因此删除 b 与选择 $h=(\{a,c\},t,\mathrm{Reason})$ 可以在一次求解中同时决定；而在局部求解中，h 与删除 b 的事务没有共同端点，只能留待后续的纯关系提议恢复。这是两种求解方式结果不同的一个具体原因。

（3）净编辑量与分项门。编辑量按最终图相对 G_0 的净变化计算，表示为：

$$d_C^{\mathrm{net}}=\sum_{v:z_v^0=1}(1-z_v)+\sum_{v:z_v^0=0}z_v\le B_C,\ d_R^{\mathrm{net}}=\sum_{r:y_r^0=1}(1-y_r)+\sum_{r:y_r^0=0}y_r\le B_R,\quad (4\text{-}16)$$

其中，类型或边界的改变对应不同的变量，计为一次删除和一次新增，与局部求解中的 $|D|+|B|$ 一致；因端点被删除而失效的关系计入 d_R^{net}。分项门相对 G_0 定义为 $\Phi_C(z)\ge\Phi_C(z^0)$ 和 $\Phi_R(y)\ge\Phi_R(y^0)$，追加阶段的预算为 B_C=24、B_R=96；求解后若 $\Phi^*-\Phi(z^0,y^0)>\delta$，则返回新图，否则返回 G_0。

由于 G_0 本身合法、其对象均在候选空间中、编辑量为 0 且分项门取等号，(z^0,y^0) 总是满足全部约束，因此全局模型总是可行的。

（4）多个最优解与超时的处理。当存在多个最优解时，全局求解依次进行三级优化：首先最大化 Φ；然后在 $\Phi\ge\Phi^*-\varepsilon_{\mathrm{tie}}$ 的条件下最小化 $d_C^{\mathrm{net}}+d_R^{\mathrm{net}}$；若仍有多个解，则按规范键顺序逐个固定对象取值，优先保持 G_0 中的状态，其中 $\varepsilon_{\mathrm{tie}}$ 为比较容差。

全局求解的时限与局部求解相同（AAEC 为 3 秒，CDCP 为 5 秒）。求得最优解时，按 δ 规则返回；超时但已有不同于 G_0 的可行解时，重新检查全部约束、分项门和 $\Phi-\Phi(G_0)>\delta$，通过则返回该解，否则返回 G_0；超时且没有更好的解时返回 G_0，求解出错时同样返回 G_0。

（5）与局部求解的区别。局部求解在每一步都相对当前状态检查分项门，编辑成本逐次累加，因此局部求解得到的任一结果都满足相对 G_0 的分项门，其净编辑量也不超过累计编辑量，即局部可达的结果都在全局可行域之内。反之则不一定成立：通向全局最优解的局部路径可能在某一步需要分项效用暂时下降，而这一步会被局部接受门拒绝。

除可行域外，两种求解方式在实现上还存在以下差异。在决策变量上，局部求解（Single 或 BR-J）将组件状态固定为提议后的组件集合，仅允许事务关系范围内的关系变量变化，全局求解则令全部组件变量与关系变量同时可变；

二者使用同一效用，只是局部单次求解中组件项为常数。在事务边界上，局部求解将事务外对象固定为当前状态，仅为保持合法性而最小限度地扩大关系范围，全局求解则不设事务边界；对于 CDCP 的源组件连续性，局部求解在固定的组件集合上预判并强制非法关系取 0，全局求解则以线性约束表达。在预算与评分上，二者追加阶段的预算均为组件 24、关系 96，但局部求解按各次提交的删增之和累计计数，全局求解按终态相对初始图的差异净计数；局部求解拒绝触及缺分对象的事务，全局求解则要求全池评分齐备，否则不进入该路径。在求解调用与返回上，局部求解对每个提议调用一次整数规划，外层至多进行 128 次尝试，返回最近的完整合法图及停止原因；全局求解每个文档执行一次主求解，另加破同分求解，返回经复核的终态，或返回初始图及状态码。

4.5.3 方法性质分析

命题 4-1：在候选空间和对象评分固定时，两个预测状态之间的效用差可以由新增和删除的对象精确计算。

证明：对 $X\in\{C,R\}$，记 $a_X(o)=2\,q_X(o\mid x)-\kappa_X$，则

$$\Delta\Phi_X=\sum_{o\in X(G')\setminus X(G)}a_X(o)-\sum_{o\in X(G)\setminus X(G')}a_X(o).\tag{4-17}$$

由于同一对象的得分固定，两个状态共有的对象在差分中相互抵消，而依赖闭合保证所有发生改变的关系都在差集之中，因此只要知道哪些对象被增删，就能精确计算效用的变化。

命题 4-2：存在这样的合法状态，其中任何单对象修改都无法通过严格改进条件，但一个集合替换可以通过。

构造如下：设两个兼容的旧组件 c_1=[0,4)、c_2=[4,8)，以及一个与二者都冲突的候选新组件 b=[0,8)，三者类型相同且没有关系，并取 κ_C=1、w_C=w_R=1。令 $q_C(c_1)$=$q_C(c_2)$=0.65、q_C(b)=0.95，则两个旧组件的效用为 0.30+0.30=0.60，新组件的效用为 0.90，替换后总效用增加 0.30，大于 δ=0.20；此时关系效用不变，编辑成本为 d_C=3、d_R=0。

在该状态下，单独删除任一旧组件会使效用下降 0.30，无法通过接受条件；直接插入 b 或用 b 替换其中一个旧组件时，冲突补全都会同时删除另一个旧组件，使操作实际成为 $2\to1$ 的合并，已不属于单对象修改。因此，只有允许 $2\to1$ 操作且组件预算不少于 3 时，这一替换才能被接受。

由此可见，集合动作能够越过单对象修改无法越过的障碍，4.6.2 节的 essay180 给出了这种情况的真实案例。

命题 4-3：在有限的候选状态空间中，若每次接受都严格提高同一个固定的效用 Φ，则接受序列不会重复访问任何状态，因而必定在有限步内终止。

由于每次接受都使效用严格增加，接受序列不可能回到已访问过的状态，而候选状态总数有限，因此接受序列也是有限的；在实际运行中，预算限制会使搜索更早停止。

最后说明代理效用与 F1 的关系。对于某个语料，设正确预测数为 T，预测总数为 P_0，金标总数为 Q，则 $F=2T/\left(P_0+Q\right)$；在修改前后分母均不为零时，展开可得：

$$F'-F=\frac{2\,\Delta T-F\,\Delta P_0}{P_0+Q+\Delta P_0}. \tag{4-18}$$

由式（4-18）可见，F1 的真实变化同时取决于正确数和预测数的变化，而推理时 ΔT 和 F 都是未知的，只能用估计的概率和固定的 κ 来近似。因此，上述理论性质保证的是代理效用的单调性和算法的终止性，严格 F1 上的效果仍需通过 4.6 节的实验检验。

4.5.4 求解方式的选择

依赖闭合规定了一次修改中哪些关系必须一起决策，而具体采用哪种求解方式则取决于候选规模：候选池较小时使用全局求解，较大时使用集合局部搜索以控制时延。默认的选择规则如下。

规模判断。令 n=|V|+|P|，当 n≤2500 时使用全局求解，否则使用集合局部搜索 BR-J。该阈值根据本文的硬件条件确定，表 4.2 给出了 500 至 4000 个变量规模下全局求解的耗时测试结果。

表 4.2 不同规模下全局求解的耗时

语料	变量数	问题数	均值/秒	P95/秒	时限/秒	超时数	择优完成数
AAEC	500	60	0.14	0.32	3	0	60
AAEC	1000	60	0.33	0.72	3	0	60
AAEC	1500	60	0.62	1.22	3	0	60
AAEC	2000	60	0.95	2.03	3	0	60

表 4.2 不同规模下全局求解的耗时

语料	变量数	问题数	均值/秒	P95/秒	时限/秒	超时数	择优完成数
AAEC	2500	60	1.35	2.71	3	0	60
AAEC	3000	60	1.90	3.00	3	7	53
AAEC	4000	60	2.60	3.00	3	20	40
CDCP	500	60	0.21	0.49	5	0	60
CDCP	1000	60	0.50	1.09	5	0	60
CDCP	1500	60	0.94	1.85	5	0	60
CDCP	2000	60	1.44	3.09	5	0	60
CDCP	2500	60	2.05	4.12	5	0	60
CDCP	3000	60	2.89	5.00	5	7	53
CDCP	4000	60	3.95	5.00	5	20	40

如表 4.2 所示，变量数为 2500 时，两个语料的 P95 耗时均低于时限，而达到 3000 和 4000 个变量时开始出现超时，因此本文以 2500 个变量作为选择全局求解或局部求解的阈值；更换硬件后，该阈值需要重新测定。

求解与返回。全局求解的时限与局部求解相同（AAEC 为 3 秒，CDCP 为 5 秒）；超时时，若已有通过全部检查的更优可行解，则返回该解，否则返回 G_0，详细规则见 4.5.2 节。

异常与边界处理。若某组候选的关系部分解析失败，已经通过检查的组件仍作为候选保留，失败调用的开销计入总成本；若资源连候选空间的保护部分都无法容纳，则直接返回 G_0。若全部对象评分都失败，同样返回 G_0；若只有部分对象缺少评分，则不使用全局求解而改用局部搜索，并拒绝涉及缺分对象的事务，缺失的评分不以默认值代替。主实验中未出现评分缺失。

以上给出了联合修正的完整求解流程，下一节将通过实验检验该方法的效果，并分析各项设计的作用。

4.6 实验与分析

为验证本章联合修正方法的有效性，本节围绕以下问题开展实验：（1）在第 3 章所得模型上追加联合修正，能否进一步提升组件与关系的抽取性能；（2）组件修改范围、组件与关系的共同接受、集合动作以及全局求解分别发挥

何种作用；（3）与相同预算下的重新生成以及简单的阈值过滤相比，联合修正的效果如何；（4）对象评分的质量与推理阶段的计算成本如何；（5）联合修正与第 3 章方法如何衔接，在基础方法的模型上是否同样有效。AAEC 与 CDCP 主实验所用的数据集、评价指标与显著性检验方法沿用 3.5.1 节和 3.5.3 节的设置，训练检查点统一采用第 3 章可靠监督与一致性学习方法得到的 T1；在此基础上，I0 表示继承自 MCR-BR 的推理流程（重排序、合法化与 BR-O），I1 表示在 I0 之上追加本章的联合修正，二者的差别仅在于推理阶段是否执行联合修正。4.6.5 节在此基础上分析联合修正与第 3 章方法的衔接关系，4.6.6 节至 4.6.8 节进一步给出多前提关系、不同骨干模型上的结果以及与外部系统的比较；4.6.9 节另行给出 ArgUNSC 语料上的补充评价设计。

4.6.1 实验设置

（1）数据划分与交叉拟合。对象评分器需要在抽取模型实际产生的预测候选上训练，为此，本章在训练集上采用以源文档为单位分组的三折交叉拟合，原文及其全部增强文本始终位于同一折中，从而保证每篇留出文档的候选都由没有见过该文档的生成器产生。评分器的拟合、校准和策略选择使用互不重叠的源文档，AAEC 分别为 255、32 和 32 篇，CDCP 分别为 464、58 和 58 篇；测试集只用于最终评价，不参与数据增强、模型训练、概率校准和策略选择。

（2）评分与提案模块。推理阶段在抽取生成器 G 之外引入对象评分器 S 和源组提案器 P。S 采用冻结的文本编码及独立的组件、关系多层感知机，在交叉拟合候选上训练，并通过 Platt 校准[96]得到完整对象的正确性概率；校准参数在搜索期间固定，对象评分缓存重复使用。P 采用同版本冻结编码和独立源组多层感知机，学习原生完整源集合及其目标，最多使用 64 个学习槽位，不将多前提关系拆成普通边。9B 主实验中二者可共享冻结的文本编码，但参数均与生成器 G 相互独立；跨骨干实验中，增强器 A 和审核器 V 固定使用 9B 模型，生成器、评分器和提案器则在各骨干上分别训练。具体配置统一列于表 4.3。

表 4.3 汇总了对象评分、源组提案、概率校准以及追加修正的效用、预算与求解路由等设置，其中，对象评分器 S 的组件头和关系头按语料、种子和对象类别分别进行 Platt 校准[96]。

表 4.3 推理阶段的评分与修正配置

项目	设置
对象评分 S	冻结 Qwen3.5-9B 文本编码；组件含 NULL；关系 12375→1024→1；10 epoch，AdamW 10^{-3}
源组提案 P	冻结同版本文本编码＋独立 12295→1024→1 MLP；5 epoch，AdamW 10^{-3}；最多 64 学习槽位
校准	训练内 OOF；拟合/校准/策略源文档隔离；按语料、种子、对象类别 Platt
效用与阈值	w_C=w_R=1；κ_C=1；AAEC κ_R=1、CDCP κ_R=0.5；δ=0.20
开发选择	先要求原 TP 损失≤5%，再最大化策略集关系 F1；无合格配置保持 I0
预算及路由	追加R_{DC}：组件 24、关系 96（全局净/局部累计）；局部每轮 32 尝试／3 接受、最多 4 轮；n≤2500 用全局求解，否则用集合局部搜索 BR-J；追加求解 AAEC 3 秒、CDCP 5 秒
候选与缺分	关系槽位上限 50000；保留初始图G_0全部对象；合计补充源组 256；评分缺失时拒绝相应事务

（3）对照方法。为考察联合修正中各项设计的作用，所有对照均使用同一个训练检查点 T1、同一张初始图 G_0 以及相同的候选和评分，仅改变修正方式。按修改范围由小到大，依次设置只修改关系（RelationOnly）、先改组件再改关系（Sequential）、组件与关系共同接受（Single）、允许拆分与合并（SetLocal）和全局求解（Global）五种配置。此外，另设四组参照，分别为相同预算下的重新生成（Regenerate）、仅删除低分关系（ThresholdFilter）、将严格改进阈值放宽至接近零（NoRisk）以及使用未校准评分（NoCalibration）。各配置的具体设置如表 4.4 所示，表中使用括号内的代号。主实验的 690 个文档—种子输入规模都小于 2500 个变量，因此完整方法 I1 全部使用全局求解，Single 和 SetLocal 作为消融单独报告。

表 4.4 推理对照组的设置

配置	候选与评分相同	变化项
RelationOnly	是	组件固定，只选择关系
ThresholdFilter	是	组件固定，仅删除低于门限的G_0关系；无事务与预算

表 4.4 推理对照组的设置

配置	候选与评分相同	变化项
Sequential／Single	是	组件优先接受／共同接受
SetLocal／Global	是	动作与可行域；累计／净编辑
NoRisk	是	放宽严格改进阈值δ
NoCalibration	候选相同	使用原始分数
MissingLow	正常缺分为 0	缺分解释
Regenerate	同检查点与追加资源	重生成完整图并重排序

（4）策略选择。效用中的关系代价系数与严格改进阈值按 4.3.1 节的规则在独立的策略集上选择，即先排除原有正确关系损失率超过 5%的组合，再从其余组合中选取汇总关系 F1 最高者。如表 4.5 所示，CDCP 在 κ_R=1 时，所有 δ 取值都不满足损失率要求，在 κ_R=0.5 时则全部满足，AAEC 在 κ_R=1 时同样全部满足；据此，在满足要求的配置中按 4.3.1 节的规则取 δ=0.20，且 δ 在 0.01 到 0.20 之间变化时开发集结果保持不变。表中 $\varepsilon_{\text{gain}}$ 一行对应 NoRisk 消融，$\varepsilon_{\text{gain}}$ 为该消融使用的最小正增益阈值，与 4.5.2 节全局求解中的比较容差 ε_{tie} 分别配置：δ 降到接近 0 后，收益极小的事务也被接受，AAEC 和 CDCP 在开发集上的误删分别增加到 6/598 和 3/130，关系 F1 降到 72.91 和 52.86，与测试集上 NoRisk 的下降趋势一致。此外，开发集 F1 由三个种子的计数汇总后计算，测试集 F1 则为逐种子 F1 的均值，二者的汇总方式有所不同。

表 4.5 开发集上的策略选择

语料	κ_R / δ	原 TP	误删 TP	损失率	汇总关系 F1	合格
AAEC	1.00 / 0.01	598	3	0.50%	73.25	是
AAEC	1.00 / 0.05	598	3	0.50%	73.25	是
AAEC	1.00 / 0.10	598	3	0.50%	73.25	是
AAEC	1.00 / 0.20	598	3	0.50%	73.25	是
AAEC	1.00 / $\varepsilon_{\text{gain}}$	598	6	1.00%	72.91	是
CDCP	1.00 / 0.01	130	41	31.54%	46.42	否
CDCP	1.00 / 0.05	130	35	26.92%	48.31	否

表 4.5 开发集上的策略选择

语料	κ_R / δ	原 TP	误删 TP	损失率	汇总关系 F1	合格
CDCP	1.00 / 0.10	130	29	22.31%	50.24	否
CDCP	1.00 / 0.20	130	25	19.23%	50.57	否
CDCP	1.00 / $\varepsilon_{\text{gain}}$	130	44	33.85%	45.73	否
CDCP	0.50 / 0.01	130	0	0.00%	53.47	是
CDCP	0.50 / 0.05	130	0	0.00%	53.47	是
CDCP	0.50 / 0.10	130	0	0.00%	53.47	是
CDCP	0.50 / 0.20	130	0	0.00%	53.47	是
CDCP	0.50 / $\varepsilon_{\text{gain}}$	130	3	2.31%	52.86	是

跨骨干实验中，各骨干按相同规则在开发集上独立选择策略，即先要求原有正确关系的损失不超过 5%，再选取关系 F1 最高的配置，并列时取较大的 κ 和 δ，选择结果如表 4.6 所示。由表可知，三种骨干在两个语料上选定的参数组合与 9B 主实验相同，原有正确关系的损失率均不超过 1.07%。

表 4.6 各骨干的独立开发选择

骨干	语料	κ_R / δ	原 TP	损失 TP	损失率	开发汇总 F1
Qwen3.5-9B	AAEC	1.00 / 0.20	598	3	0.50%	73.25
Qwen3.5-9B	CDCP	0.50 / 0.20	130	0	0.00%	53.47
Qwen3.5-4B	AAEC	1.00 / 0.20	583	4	0.69%	71.70
Qwen3.5-4B	CDCP	0.50 / 0.20	125	1	0.80%	51.69
Qwen2.5-7B-Instruct	AAEC	1.00 / 0.20	559	6	1.07%	68.63
Qwen2.5-7B-Instruct	CDCP	0.50 / 0.20	116	1	0.86%	48.30

（5）成本口径。计算成本分为一次性成本与逐文档成本两部分：前者包括增强、审核、交叉拟合和评分器训练，具体统计见 3.5.6 节；后者包括生成、提案、评分和求解，被拒绝、失败或超时的计算同样计入，4.6.4 节据此报告各推

理配置的逐文档时延。与重新生成对比时，两者的追加模型调用次数以及输入、输出 token 上限都相同，从而保证比较在同等资源条件下进行。

4.6.2 主要结果与消融分析

表 4.7 给出了训练配置固定为 T1 时不同推理配置的抽取性能，表 4.8 给出了各配置之间严格关系 F1 的配对差值及显著性检验结果。总体而言，追加联合修正能够在不改变训练检查点的情况下显著提升关系抽取性能：在固定 T1 的条件下，I1 使严格关系 F1 在 AAEC 和 CDCP 上分别比 I0 提高 3.38 和 5.68 分，Holm 校正 p 值均为 0.0070，组件 F1 也分别由 87.85 和 83.46 提高到 88.47 和 84.45。

表 4.7 不同推理配置的抽取性能（训练均为 T1）

配置	AAEC 组件 F1	AAEC 关系 F1	CDCP 组件 F1	CDCP 关系 F1
T1I0：完整一致性学习	87.85 ± 0.39	68.25 ± 2.08	83.46 ± 1.04	45.08 ± 2.73
仅关系阈值过滤（ThresholdFilter）	87.85 ± 0.39	69.76 ± 2.10	83.46 ± 1.04	47.84 ± 3.20
固定组件，仅修改关系（RelationOnly）	87.85 ± 0.39	70.45 ± 2.11	83.46 ± 1.04	49.19 ± 2.35
组件优先分步（Sequential）	88.12 ± 0.42	70.78 ± 2.08	83.97 ± 1.01	49.68 ± 2.35
单对象共同接受（Single）	88.26 ± 0.40	71.15 ± 2.11	84.15 ± 0.97	50.04 ± 2.38
集合局部搜索（SetLocal）	88.38 ± 0.43	71.40 ± 2.10	84.33 ± 0.95	50.44 ± 2.39
T1I1：完整配置	88.47 ± 0.46	71.63 ± 2.11	84.45 ± 0.94	50.77 ± 2.45
等预算重新生成（Regenerate）	87.71 ± 1.12	68.72 ± 2.67	83.62 ± 0.86	45.96 ± 4.28
放宽增益阈值（NoRisk）	88.39 ± 0.48	71.34 ± 2.11	84.37 ± 0.96	50.43 ± 2.38
取消概率校准（NoCalibration）	88.33 ± 0.57	71.02 ± 2.15	84.29 ± 0.91	50.11 ± 2.33

表 4.8 推理配置之间的关系 F1 配对差值（百分制分数）

语料	比较	差值	单项 95% CI	种子 17 / 29 / 43	p	类型
AAEC	T1I1 − T1I0	3.38	[2.56, 4.23]	3.30 / 3.54 / 3.31	0.0070	主要／Holm
AAEC	T1I1 − RelationOnly	1.18	[0.71, 1.68]	1.12 / 1.27 / 1.16	0.0070	主要／Holm
AAEC	Single − Sequential	0.37	[0.11, 0.65]	0.37 / 0.41 / 0.33	0.0175	主要／Holm
AAEC	T1I1 − Regenerate	2.91	[1.07, 4.83]	3.80 / 1.41 / 3.53	0.0120	主要／Holm
AAEC	T1I1 − NoRisk	0.29	[0.09, 0.51]	0.26 / 0.34 / 0.29	0.0140	主要／Holm
AAEC	SetLocal − Single	0.25	[0.04, 0.47]	0.23 / 0.27 / 0.25	0.0285	探索／原始 p
AAEC	Global − SetLocal	0.23	[0.02, 0.45]	0.21 / 0.26 / 0.21	0.0390	探索／原始 p
AAEC	Global − Single	0.48	[0.18, 0.80]	0.45 / 0.53 / 0.47	0.0030	探索／原始 p
AAEC	T1I1 − ThresholdFilter	1.88	[1.21, 2.58]	1.68 / 2.17 / 1.77	0.0005	探索／原始 p
AAEC	RelationOnly − ThresholdFilter	0.69	[0.24, 1.17]	0.56 / 0.90 / 0.62	0.0060	探索／原始 p
AAEC	T1I1 − MissingLow	0.00	[0.00, 0.00]	0.00 / 0.00 / 0.00	1.0000	探索／原始 p
AAEC	T1I1 − NoCalibration	0.61	[0.14, 1.10]	0.49 / 0.71 / 0.62	0.0175	探索／原始 p

表 4.8 推理配置之间的关系 F1 配对差值（百分制分数）（续表）

语料	比较	差值	单项 95% CI	种子 17 / 29 / 43	p	类型
CDCP	T1I1 − T1I0	5.68	[4.03, 7.47]	5.40 / 5.40 / 6.24	0.0070	主要／Holm
CDCP	T1I1 − RelationOnly	1.57	[0.74, 2.46]	1.49 / 1.68 / 1.54	0.0070	主要／Holm
CDCP	Single − Sequential	0.36	[0.10, 0.66]	0.33 / 0.40 / 0.35	0.0175	主要／Holm
CDCP	T1I1 − Regenerate	4.81	[2.12, 7.63]	6.57 / 2.76 / 5.10	0.0100	主要／Holm
CDCP	T1I1 − NoRisk	0.34	[0.07, 0.63]	0.30 / 0.41 / 0.30	0.0100	主要／Holm
CDCP	SetLocal − Single	0.40	[0.05, 0.78]	0.39 / 0.41 / 0.40	0.0260	探索／原始 p
CDCP	Global − SetLocal	0.32	[0.02, 0.66]	0.30 / 0.39 / 0.29	0.0450	探索／原始 p
CDCP	Global − Single	0.73	[0.24, 1.25]	0.68 / 0.80 / 0.69	0.0040	探索／原始 p
CDCP	T1I1 − ThresholdFilter	2.93	[1.62, 4.31]	2.81 / 2.12 / 3.86	0.0010	探索／原始 p
CDCP	RelationOnly − ThresholdFilter	1.36	[0.31, 2.52]	1.32 / 0.43 / 2.31	0.0140	探索／原始 p
CDCP	T1I1 − MissingLow	0.00	[0.00, 0.00]	0.00 / 0.00 / 0.00	1.0000	探索／原始 p
CDCP	T1I1 − NoCalibration	0.66	[0.06, 1.31]	0.60 / 0.80 / 0.59	0.0330	探索／原始 p

表 4.8 中的 95%置信区间为单项区间，未经多重校正；全文 14 项主要比较统一采用 Holm 校正并全部通过，本节报告其中的 5 组，ThresholdFilter 等对照则作为探索性比较，报告未校正的 p 值。

全局求解配置 Global 与完整配置 T1I1 对应同一组结果，表 4.7 不重复列示；主实验未出现缺失评分，因此 MissingLow 在本组数据中与完整配置相同，其异常处理规则见 4.5.4 节。

从消融结果看，推理阶段的增益大部分来自关系选择：仅修改关系已使 AAEC 和 CDCP 的关系 F1 相对 I0 提高 2.20 和 4.11 分，约占完整增益的 65%和 72%。在此基础上，允许修改组件并重建其关系，使关系 F1 再提高 1.18 和 1.57 分（表 4.8，校正 p 值均为 0.0070）；多出的收益一方面来自修正组件边界或类型后多恢复的 23 和 7 条完整关系，另一方面来自删除错误组件时连带清除的 44 和 26 条误边（表 4.12）。

组件与关系的接受方式同样影响修正效果。即使采用先改组件、再改关系的分步方式，关系 F1 也比只修改关系高 0.33 和 0.49 分；在此基础上，让组件与关系共同接受，又进一步提高了 0.37 和 0.36 分（Holm p 均为 0.0175），说明将组件修改及其受影响关系纳入同一事务进行决策是有效的。

集合动作与全局求解也分别带来了增益。允许拆分与合并后，关系 F1 比单对象共同接受提高 0.25 和 0.40 分，置信区间均不含零，并多恢复 3 和 1 条完整关系、多清除 11 和 6 条误边（表 4.12）；全局求解在此基础上再提高 0.23 和 0.32 分。这一结果与 4.5.2 节的分析相符：局部可达的结果都包含在全局可行域中，因此在固定评分下全局最优解的效用不低于局部结果；但效用只是严格 F1 的代理，全局求解在本实验中取得最高 F1 属于实验观察，而非理论保证。此外，主实验中全部 690 个输入的全局求解都得到了最优解，没有出现超时。

AAEC 测试文档 essay180（种子 17）给出了集合动作发挥作用的一个典型案例。该文档金标中的前提 T11 对应字符区间[1256,1368)“A solid group can be a suited environment, which provides people to improve themselves or broaden their horizons”，它支持论点 T10，同时受到 T12、T13、T14 三个前提的支持。G_0 在逗号处把 T11 错误地拆成了 c_1=[1256,1297)和 c_2=[1299,1368)两个片段，导致 $c_1 \to$ T10、T12 $\to c_2$、T13 $\to c_2$ 三条关系都因端点错误而成为 FP，T14 $\to$ T11 则被漏掉。

在固定评分下，q(c_1)=0.62、q(c_2)=0.66，合并后的组件 b=[1256,1368)得分 q(b)=0.93。此时，单独删除任一片段都会降低组件效用，而插入 b 会因冲突同时删除两个片段，实际构成 2 $\to$ 1 的合并，因此单对象修改无法完成这一修正。

允许拆分与合并的局部搜索和全局求解都接受了这一合并：组件效用增加 0.30；删除 3 条旧关系、重建 b $\to$ T10 以及 T12、T13、T14 $\to$ b 四条关系后，关系效用增加 2.38，组件和关系分别编辑 3 次和 7 次。修正后，组件 TP 增加 1、FP 减少 2，关系 TP 增加 4、FP 减少 3，这正是命题 4-2 所描述的情形，修正前后的结构如图 4.3 所示。

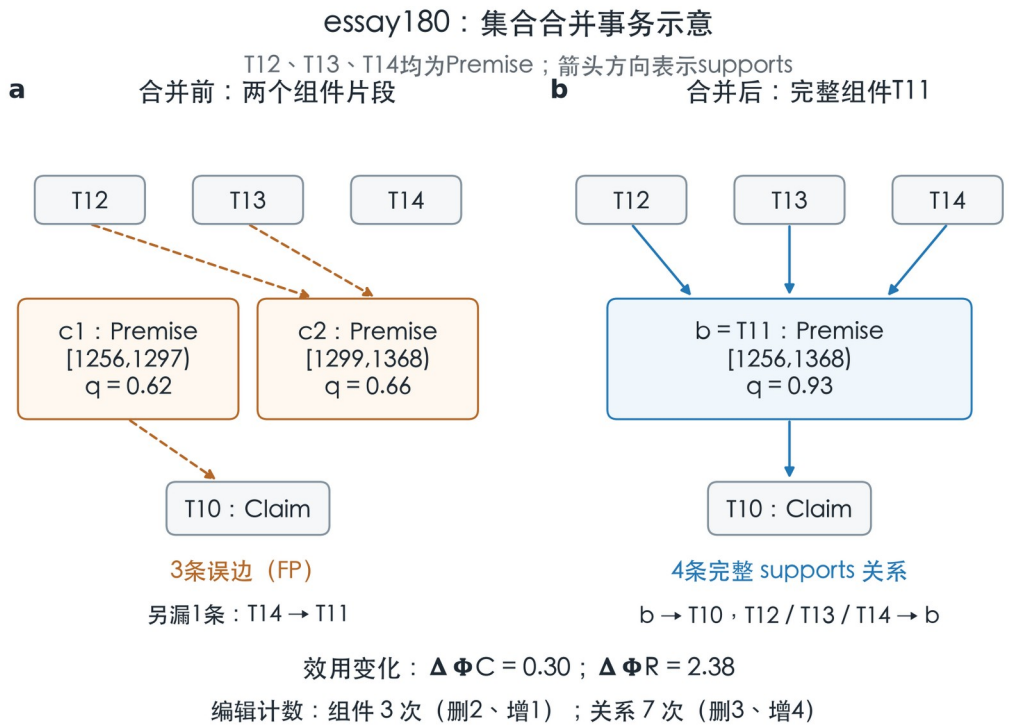


图 4.3 essay180 中组件合并与关系重建示意

注：（a）初始图把 T11 拆成了 c_1 和 c_2，橙色虚线表示三条端点错误的关系，T14→T11 未被输出；（b）合并后，蓝色实线表示 b→T10 以及 T12、T13、T14→b 四条支持关系。

与简单的阈值过滤相比，联合修正在相同候选和评分下仍有明显优势。仅删除低分关系的 ThresholdFilter 已有一定效果，比 I0 提高 1.51 和 2.76 分，但同时误删了 34 和 8 条原本正确的关系（表 4.12）。相比之下，只修改关系就比它高 0.69 和 1.36 分，完整方法 I1 则高 1.88 和 2.93 分。值得注意的是，仅删除低分关系即可获得完整增益的约 45%和 49%，说明固定评分下的关系筛选本身贡献了相当一部分收益，关系补全、组件修改与共同接受则在此基础上带来进一步提升。

与相同预算下的重新生成相比，联合修正的优势更加明显。重新生成的严格关系 F1 为 68.72 和 45.96，I1 分别比它高 2.91 和 4.81 分（Holm p 为 0.0120 和 0.0100）。重新生成虽然恢复了较多关系，但也误删了 471 和 174 条原本正确的关系，原有正确关系的保留率只有 72.71%和 52.97%，而联合修正的保留率都超过 98%。由此可见，在已有预测的基础上进行有约束的局部修改，比完整重新生成更为可靠。需要说明的是，这里的同等资源仅针对推理阶段；联合修正另需交叉拟合训练与评分器训练的一次性成本（3.5.6 节的一次性成本统计），重新生成则不需要这部分成本。

接受收益极小的修改会增加误改。将严格改进阈值放宽至接近零后，关系 F1 下降 0.29 和 0.34 分，误删的正确关系由 23 和 4 条增加到 31 和 7 条，F1 下降的文档—种子数由 14 和 3 增加到 17 和 6，开发集上也观察到同样的趋势（表 4.5）。需要指出的是，按表 4.5 的网格，5%的开发集风险筛选并未改变最终选中的配置，因此该对照反映的是阈值 δ 的作用，不能单独归因于风险筛选；即使保留阈值，也不能保证每篇文档都得到改善。此外，本文未单独消融分项效用门与编辑预算，二者对结果的独立作用仍有待检验。

评分校准同样直接影响接受决策。使用未校准的评分时，关系 F1 下降 0.61 和 0.66 分，AAEC 误删的正确关系由 23 条增加到 33 条；而将缺失评分视为低分（MissingLow）时，结果与 I1 完全相同，差值为 0.00，这与主实验中未出现评分缺失的情况一致。4.6.3 节将进一步分析候选覆盖与评分质量。

4.6.3 候选覆盖与评分质量分析

联合修正只能在候选池内选择对象，因此候选覆盖决定了修正所能达到的上限。表 4.9 按候选、评分和选择各环节统计了金标对象的保留情况：AAEC 和 CDCP 中分别有 98.3%和 89.4%的金标关系进入了候选池，其余关系无论如何搜索都无法恢复。在进入候选池的完整关系中，AAEC 和 CDCP 分别有 1793 条和 415 条评分过门，最终 TP 为 1736 和 386，可见进入候选池之后的主要损失发生在评分环节，CDCP 尤为明显。

表 4.9 金标对象在候选、评分和选择各环节的保留情况（三个种子合计）

语料	金标组件	组件入池	金标关系	全部端点入池	完整关系入池	评分过门	过门且端点被选	最终 TP
AAEC	3798	3778	2427	2411	2386	1793	1737	1736
CDCP	3078	3032	756	735	676	415	386	386

表 4.9 的计数单位为文档×种子×对象，AAEC 和 CDCP 的金标组件总数分别为 3798 和 3078，完整关系总数为 2427 和 756。其中，“评分过门”以关系已进入候选池为前提，“端点被选”进一步要求这些关系的全部端点出现在最终图中；最终 TP 按完整对象匹配计算，多前提关系只命中部分源组件不算命中。此外，G_0 中的合法对象全部保留在候选池中，CDCP 的补充槽位最多保留 64 个模型提案，总数不超过 256 个。

评分质量决定了接受决策的可靠性。表 4.10 和表 4.11 分别给出了开发集与测试集候选上的评分质量，其中，AUROC 为 ROC 曲线下面积，AP 为平均精确率，ECE 为期望校准误差，先验 Brier 表示按类别先验给出恒定概率时的 Brier 分数；AUROC、AP、Brier 和 ECE 为三个种子的均值，候选数和正例数为三个种子的合计。从结果看，各类对象的 Brier 分数均明显低于先验 Brier，关系评分的 AP 则明显低于组件评分，反映出完整关系正例稀少、判别难度更大；测试集上的评分质量与开发集接近，在这些评分指标上未见明显退化。

表 4.10 开发集候选上的评分质量

语料	用途	对象类别	候选	正例	AUROC	AP	Brier	先验 Brier	ECE10	门限以上候选数	门限以上精确率
AAEC	校准集	组件	3263	1402	0.9059	0.8580	0.0844	0.2450	0.0056	1418	0.887
AAEC	校准集	关系	14290	851	0.8637	0.5743	0.0271	0.0561	0.0040	901	0.719
AAEC	策略集	组件	3069	1323	0.9007	0.8436	0.0844	0.2452	0.0124	1366	0.880
AAEC	策略集	关系	12826	804	0.8788	0.5943	0.0277	0.0588	0.0043	855	0.725
CDCP	校准集	组件	3023	1042	0.8740	0.7753	0.1000	0.2259	0.0092	1031	0.839
CDCP	校准集	关系	6894	270	0.7731	0.4163	0.0258	0.0376	0.0016	297	0.542
CDCP	策略集	组件	3203	1094	0.8863	0.7924	0.0920	0.2249	0.0175	1076	0.856
CDCP	策略集	关系	6906	225	0.8082	0.3794	0.0222	0.0315	0.0059	280	0.500

表 4.11 测试集候选上的评分质量

语料／对象类别	候选 n／正例	AUROC	AP	Brier／先验 Brier	ECE10	门限	门限以上候选数／正确	门限以上精确率／平均评分
AAEC／组件	8800／3778	0.900	0.850	0.0877／0.2450	0.0073	0.5	3811／3368	0.884／0.885
AAEC／关系	42510／2386	0.862	0.557	0.0266／0.0530	0.0034	0.5	2551／1793	0.703／0.707
CDCP／组件	8835／3032	0.883	0.801	0.0904／0.2254	0.0165	0.5	3013／2577	0.855／0.835
CDCP／关系	19222／676	0.801	0.383	0.0240／0.0339	0.0044	0.25	822／415	0.505／0.542

在门限设置上，AAEC 和 CDCP 的关系门限分别为 0.5 和 0.25，组件门限均为 0.5。图 4.4 给出了测试候选的校准曲线：AAEC 关系在高分区仍存在局部过度自信，因此仅依靠评分门限并不足以保证修改正确，接受决策还需同时满足分项效用门和编辑预算。

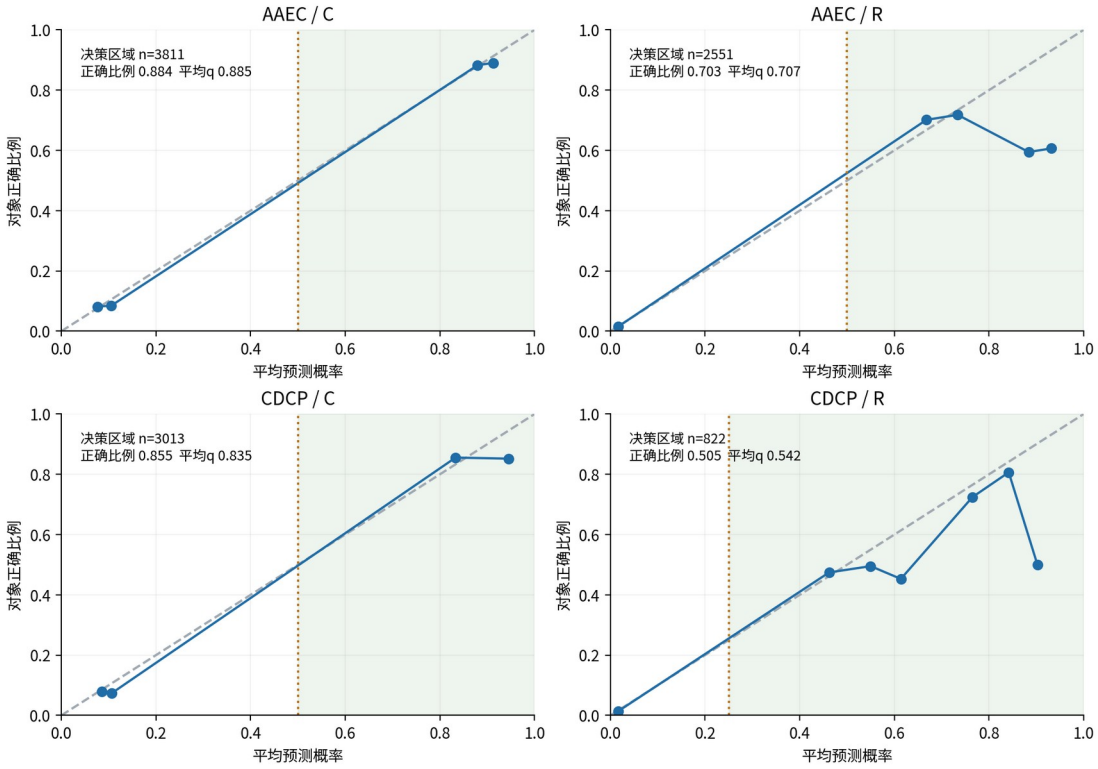


图 4.4 测试候选的校准与决策门限

注：C 和 R 分别表示组件与关系。灰色对角线表示理想校准，橙色线为门限，绿色区域为门限以上的候选；各点之间的连线仅辅助阅读，不代表中间概率区间的样本分布。CDCP 关系最高分箱的样本量为 100。

误改统计进一步表明，联合修正在提升关系 F1 的同时并未带来更多的逐文档退化。如表 4.12 所示，主配置中 F1 下降的文档—种子记录在 AAEC 上为 14/240，在 CDCP 上为 3/450，均不多于其他对照，放宽增益阈值后分别增加到 17/240 和 6/450；相比之下，重新生成在两个语料上分别有 107/240 和 106/450 条记录的 F1 下降。

表 4.12 各配置的误改统计与逐文档影响

语料	配置	原 TP	恢复 TP	误删 TP	删除 FP	新增 FP	原 TP 保留率	F1 下降的文档—种子数／总数
AAEC	T1I1	1726	33	23	230	9	98.67%	14／240
AAEC	RelationOnly	1726	10	18	186	13	98.96%	15／240
AAEC	ThresholdFilter	1726	0	34	173	0	98.03%	24／240
AAEC	Single	1726	27	22	208	11	98.73%	15／240
AAEC	SetLocal	1726	30	22	219	10	98.73%	14／240
AAEC	Sequential	1726	24	23	192	13	98.67%	16／240
AAEC	NoRisk	1726	35	31	228	16	98.20%	17／240
AAEC	NoCalibration	1726	30	33	217	14	98.09%	18／240
AAEC	Regenerate	1726	448	471	884	806	72.71%	107／240

表 4.12 各配置的误改统计与逐文档影响（续表）

语料	配置	原 TP	恢复 TP	误删 TP	删除 FP	新增 FP	原 TP 保留率	F1 下降的文档—种子数／总数
CDCP	T1I1	370	20	4	141	4	98.92%	3／450
CDCP	RelationOnly	370	13	4	115	5	98.92%	5／450
CDCP	ThresholdFilter	370	0	8	120	0	97.84%	8／450
CDCP	Single	370	18	5	128	4	98.65%	4／450
CDCP	SetLocal	370	19	4	134	4	98.92%	3／450
CDCP	Sequential	370	17	5	121	5	98.65%	5／450
CDCP	NoRisk	370	21	7	140	7	98.11%	6／450
CDCP	NoCalibration	370	17	4	131	5	98.92%	4／450
CDCP	Regenerate	370	180	174	440	430	52.97%	106／450

从被接受的修改看，修改范围越完整、接受条件越统一，修改本身越准确。如表 4.13 所示，主配置新增的关系中，AAEC 有 33/42 条正确，CDCP 有 20/24 条正确。从先改组件再改关系、单对象共同接受、允许拆分与合并到完整方法，AAEC 新增关系的精确率依次为 64.86%、71.05%、75.00%和 78.57%，CDCP 由 77.27%升至 83.33%，误删在全部删除中的比例也同步下降。

表 4.13 被接受修改的数量与正确率

语料	方法	提交数	组件增／删	关系增／删	新增关系正确	新增精确率	删除正确关系	误删占全部删除
AAEC	Sequential	156	23／15	37／215	24	64.86%	23	10.70%
AAEC	Single	151	18／24	38／230	27	71.05%	22	9.57%
AAEC	SetLocal	147	24／38	40／241	30	75.00%	22	9.13%
AAEC	T1I1	144	30／47	42／253	33	78.57%	23	9.09%
CDCP	Sequential	141	40／35	22／126	17	77.27%	5	3.97%

表 4.13 被接受修改的数量与正确率

语料	方法	提交数	组件增／删	关系增／删	新增关系正确	新增精确率	删除正确关系	误删占全部删除
CDCP	Single	146	26／41	22／133	18	81.82%	5	3.76%
CDCP	SetLocal	139	29／49	23／138	19	82.61%	4	2.90%
CDCP	T1I1	132	30／52	24／145	20	83.33%	4	2.76%

4.6.4 推理成本分析

联合修正新增的推理开销主要来自对象评分，求解本身的耗时较少。如表 4.14 所示，追加修正使 AAEC 和 CDCP 的平均推理时间分别从 20.11 秒和 28.12 秒增加到 36.08 秒和 50.48 秒，其中对象评分耗时 14.22 秒和 19.71 秒，追加求解只需 0.73 秒和 1.18 秒，在主实验的输入规模下低于集合局部搜索的 1.28 秒和 2.10 秒。相同预算下的重新生成平均耗时为 33.89 秒和 47.50 秒，与联合修正处于同一量级，但其关系 F1 明显较低（见 4.6.2 节）。因此，降低推理成本应优先从评分计算和缓存复用入手。

表 4.14 逐文档推理成本（秒）

语料／方法	生成／重排	合法化	BR-O	追加生成	提案	评分	追加求解	总均值	总 P95
AAEC/T0I0	19.46	0.018	0.63	0.00	0.00	0.00	0.00	20.11	23.60
AAEC/T1I0	19.46	0.018	0.63	0.00	0.00	0.00	0.00	20.11	23.62
AAEC/Single	19.46	0.018	0.63	0.00	1.02	14.22	0.47	35.82	42.09
AAEC/ SetLocal	19.46	0.018	0.63	0.00	1.02	14.22	1.28	36.63	42.72
AAEC/T1I1	19.46	0.018	0.63	0.00	1.02	14.22	0.73	36.08	42.38
AAEC/ Regenerate	19.46	0.018	0.63	13.74	0.00	0.00	0.05	33.89	39.87
CDCP/T0I0	27.05	0.024	1.03	0.00	0.00	0.00	0.00	28.10	33.07
CDCP/T1I0	27.05	0.024	1.04	0.00	0.00	0.00	0.00	28.12	33.08
CDCP/Single	27.05	0.024	1.04	0.00	1.48	19.71	0.75	50.05	58.91
CDCP/ SetLocal	27.05	0.024	1.04	0.00	1.48	19.71	2.10	51.41	60.29
CDCP/T1I1	27.05	0.024	1.04	0.00	1.48	19.71	1.18	50.48	59.39
CDCP/ Regenerate	27.05	0.024	1.04	19.30	0.00	0.00	0.08	47.50	56.02

在资源口径上，完整方法和重新生成都从 G_0 开始，追加的两次文本处理累计输入不超过 8192 个 token、输出不超过 2048 个 token，端到端时延为各阶段耗时之和。

4.6.5 与第 3 章方法的衔接分析

本章的联合修正以第 3 章所得模型为起点，主要比较为在 T1 训练检查点上追加联合修正（T1I1 相对 T1I0）；由于联合修正只依赖固定的候选与对象评分，它同样可以直接作用于基础方法训练的模型。为说明两项方法如何衔接，本节在同一骨干上比较训练与推理的四种组合，依次考察总体性能与交互、两阶段各自恢复的关系以及剩余漏检的来源。四种组合的含义如下：T0I0 为 MCR-BR 基线；T1I0 采用第 3 章的训练方法，推理沿用 I0；T0I1 采用基线训练，在 I0 给出的初始图 G_0 上追加本章的联合修正；T1I1 则在第 3 章所得模型上追加联合修正，即本文的完整方法。

不同比较的固定条件与检验目的各不相同：固定推理为 I0 时，T1I0 与 T0I0 在骨干、更新预算和推理流程均相同的条件下比较，反映训练方法对抽取的改善；固定训练为 T1 时，T1I1 与 T1I0 共用同一训练检查点与 I0 终态，仅追加候选、评分与修正规则，反映联合修正在第 3 章模型上带来的增益；固定训练为 T0 时，T0I1 与 T0I0 的比较检验联合修正在基础方法模型上的效果；四种组合在同一测试文档、随机种子和完整对象评价下并列比较，则可用于判断两项增益是相互重叠还是彼此互补。所有组合均采用相同的测试划分、评价规则和三个随机种子，而一致性目标、共同接受、集合动作等具体机制的作用，已分别在 3.5.4 节和 4.6.2 节的对照实验中分析，本节不再重复。

（1）总体性能与交互分析。两项方法组合后，完整配置在两个语料上均取得四种组合中最高的组件 F1 与严格关系 F1。表 4.15 给出四种组合的组件 F1 和关系 F1，“±”后为三个种子的样本标准差。

表 4.15 两阶段配置的组件与关系抽取性能

配置	AAEC 组件 F1	AAEC 关系 F1	CDCP 组件 F1	CDCP 关系 F1
T0I0	85.64 ± 0.07	65.69 ± 3.50	80.40 ± 1.24	41.79 ± 2.65
T1I0	87.85 ± 0.39	68.25 ± 2.08	83.46 ± 1.04	45.08 ± 2.73
T0I1	86.50 ± 0.15	69.43 ± 3.41	81.67 ± 1.12	47.69 ± 2.47
T1I1	88.47 ± 0.46	71.63 ± 2.11	84.45 ± 0.94	50.77 ± 2.45

如表 4.15 所示，在 Qwen3.5-9B 骨干下，T1I1 的关系 F1 分别为 71.63 和 50.77，比 T0I0 基线的 65.69 和 41.79 分别高 5.94 和 8.98 分；T1I0 与 T0I1 的组件 F1 和关系 F1 均介于二者之间，说明两项方法单独使用时都能改善抽取结果，组合后仍有进一步提升。

为进一步区分训练增益、推理增益及二者的交互，表 4.16 列出各项比较的平均配对差值、95%置信区间以及三个种子各自的差值。由于均值与差值均先由未舍入的逐种子结果计算、再保留两位小数，表 4.15 中均值直接相减的结果可能与表 4.16 相差 0.01 分，分析以表 4.16 为准。

表 4.16 四种配置的关系 F1 差值与交互

语料	比较	差值（百分制分数）	单项 95% CI	三个种子差值	类型
AAEC	T1I0 − T0I0	2.56	[0.92, 4.39]	1.26 / 2.34 / 4.07	主要
AAEC	T1I1 − T1I0	3.38	[2.56, 4.23]	3.30 / 3.54 / 3.31	主要
AAEC	T0I1 − T0I0	3.74	[2.82, 4.69]	3.58 / 3.84 / 3.78	探索
AAEC	T1I1 − T0I0	5.94	[4.01, 7.88]	4.56 / 5.88 / 7.38	探索
AAEC	交互项	-0.35	[-0.85, 0.03]	-0.27 / -0.30 / -0.48	探索
CDCP	T1I0 − T0I0	3.30	[1.56, 5.17]	2.81 / 3.50 / 3.58	主要
CDCP	T1I1 − T1I0	5.68	[4.03, 7.47]	5.40 / 5.40 / 6.24	主要
CDCP	T0I1 − T0I0	5.91	[4.21, 7.75]	5.59 / 5.80 / 6.33	探索
CDCP	T1I1 − T0I0	8.98	[6.56, 11.66]	8.21 / 8.91 / 9.82	探索
CDCP	交互项	-0.22	[-0.95, 0.35]	-0.18 / -0.40 / -0.08	探索

表 4.16 中标为“主要”的两项比较已分别在 3.5.4 节和 4.6.2 节通过 Holm 校正，即训练方法相对 T0I0、联合修正相对 T1I0 均带来显著增益；标为“探索”的比较报告单项置信区间，用于进一步检验联合修正在基础方法模型上的效果以及两项增益之间的交互。其中，T0I1 相对 T0I0 的差值为 3.74 和 5.91 分，95%置信区间分别为[2.82, 4.69]和[4.21, 7.75]，表明联合修正在基础方法的模型上同样有效。

两项方法的组合增益接近两项单独增益之和，交互项的置信区间在两个语料上均包含零，即未检出显著交互。交互项定义为(T1I1−T1I0)−(T0I1−T0I0)，AAEC 上的估计值为-0.35 分（95%置信区间[-0.85, 0.03]），CDCP 上为-0.22 分（[-0.95, 0.35]）。不过，AAEC 上三个种子的交互项均为负，联合修正在 T1 模型上带来的 3.38 和 5.68 分也略低于其在 T0 模型上的 3.74 和 5.91 分，说明两项方法的作用存在轻微重叠，两个语料均未检出显著交互，尚不能将这一结果解释为严格可加或统计等效。图 4.5 展示了四种组合的总体表现。

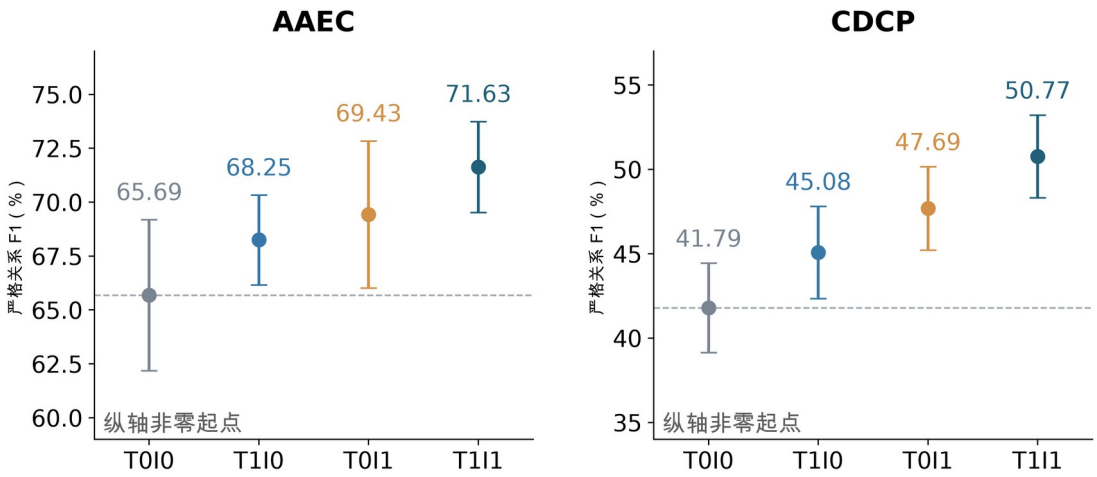


图 4.5 两种语料上四种配置的关系 F1（误差棒为三个种子的样本标准差；纵轴非零起点）

（2）两阶段恢复关系的对比。关系 F1 的变化同时来自恢复正确关系、减少误报以及丢失原有正确关系三个方面，为明确两项方法各自贡献了哪些关系，下面先比较两阶段分别恢复的关系，再从端点与关系选择两个层面分析漏检的原因。

表 4.17 以 T0I0 中预测正确的关系为基准，在每个种子内按关系的完整身份（文档、源集合、目标和标签）比对两种单独配置与完整配置中新增的 TP，从而区分两阶段共同恢复、各自独有恢复以及组合后才恢复的关系，表中计数为三个种子的合计。

表 4.17 两阶段恢复关系的分解（三个种子合计）

语料	初始 TP	共同恢复	训练独有	修正独有	组合独有	单阶段恢复后在组合中丢失	丢失初始 TP	完整 TP
AAEC	1658	6	82	31	1	1	41	1736
CDCP	343	2	28	20	0	0	7	386

表中，“共同恢复”为 T1I0 与 T0I1 相对 T0I0 新增 TP 的交集，“训练独有”和“修正独有”分别为二者的差集，“组合独有”为仅在 T1I1 中新增的 TP；由于完整配置也可能丢失单独配置恢复的关系或初始 TP，各项满足：初始 TP＋共同恢复＋训练独有＋修正独有＋组合独有−丢失单路恢复−丢失初始 TP ＝完整 TP。

两阶段恢复的关系几乎没有重叠，表明两项方法在恢复对象上具有互补性：AAEC 上，训练独有与修正独有的关系分别为 82 条和 31 条，而共同恢复的仅有 6 条，组合独有 1 条；CDCP 上相应为 28、20、2 和 0 条。

与此同时，完整配置也会丢失少量正确关系，AAEC 丢失单路恢复的关系 1 条、初始 TP 41 条，CDCP 分别为 0 条和 7 条，但与恢复的关系数量相比要少得多。

（3）漏检原因分析。一条完整关系得以恢复的前提是其正确端点全部出现在最终图中，据此，表 4.18 将未命中的金标关系分为两类：“端点缺失”指最终图中缺少该关系所需的组件，“端点齐全但未选”指正确端点均已存在，但该关系未被选中。

表 4.18 四种配置下未命中关系的分类

语料	配置	金标	TP	端点缺失	端点齐全但未选
AAEC	T0I0	2427	1658	637	132
AAEC	T1I0	2427	1726	546	155
AAEC	T0I1	2427	1673	601	153
AAEC	T1I1	2427	1736	517	174

表 4.18 四种配置下未命中关系的分类

语料	配置	金标	TP	端点缺失	端点齐全但未选
CDCP	T0I0	756	343	294	119
CDCP	T1I0	756	370	260	126
CDCP	T0I1	756	361	283	112
CDCP	T1I1	756	386	251	119

端点缺失类漏检随两个阶段逐级减少，但端点齐全后仍有部分关系未被选中。第 3 章的训练方法使 AAEC 和 CDCP 中端点缺失的关系分别从 T0I0 的 637 条和 294 条减少到 T1I0 的 546 条和 260 条，联合修正在此基础上进一步减少到 T1I1 的 517 条和 251 条；与此同时，AAEC 中端点齐全但未选的关系从 132 条增加到 174 条，CDCP 中则保持 119 条不变。由于整体 F1 还受误报变化的影响，4.6.6 节的表 4.21 将进一步按源组件数报告各组关系的 TP、FP 和 FN。

为定位完整配置中漏检发生的具体环节，表 4.19 进一步将 T1I1 中的每条未命中关系归入其遇到的第一个阻断环节（每条只归一次），各环节依次为：最终图中端点缺失、候选槽位未入池、未评分、评分未过门、受联合约束或接受门限制以及超时。

表 4.19 T1I1 未命中关系的首个阻断环节

语料	金标	TP	终态端点缺失	完整槽位未入池	未评分	评分未过门	联合约束／接受门	超时
AAEC	2427	1736	517	6	0	167	1	0
CDCP	756	386	251	5	0	114	0	0

由表 4.19 可见，未命中的关系主要集中在“端点缺失”和“评分未过门”两个环节，AAEC 上分别为 517 条和 167 条，CDCP 上分别为 251 条和 114 条；相比之下，槽位未入池的仅有 6 条和 5 条，受约束或接受门限制的仅有 AAEC 的 1 条，未评分与超时均为 0。由此可见，进一步提升的重点在于组件识别与关系评分，候选构建与求解环节造成的漏检很少。

4.6.6 多前提关系分析

CDCP 中的多前提关系要求完整的源集合、目标和标签同时匹配，其完整命中的难度明显高于单源关系。如表 4.20 所示，在 CDCP 训练文档 00662 中，两个价值组件分别表达偏好电子邮件与无法确认邮件是否送达，二者共同支持

一个政策组件，因而被标注为一条双源理由关系；评价时只有同时匹配完整的源集合、目标和标签才算命中，仅预测其中任一条单源关系均无法命中该关系。

表 4.20 CDCP 文档 00662 中的一条双源理由关系

对象	标注类型	字符跨度	数据集原文
源 1	价值	[0,53)	I generally prefer e-mail to telephone communication,
源 2	价值	[54,110)	but you can't be sure the e-mail has reached the person.
目标	政策	[111,222)	I would suggest a notice that says, "If you don't acknowledge receipt of this e-mail, we'll start phoning you."

由上例可见，源组件越多，完整命中所需同时恢复的端点就越多，因此本节按源组件数分组考察四种组合的结果。CDCP 测试集共有 252 条关系，其中单源 218 条、双源 20 条、三源 6 条、四源及以上 8 条，多源关系共 34 条；表 4.21 按源组件数分组汇总了四种组合的结果，其中 TP、FP 和 FN 为三个种子的合计，关系 F1 及其标准差由逐种子结果计算。

表 4.21 CDCP 按源组件数分组的结果

源数	配置	TP	FP	FN	关系 F1（均值 ± SD）
1	T0I0	309	494	345	42.41 ± 1.37
1	T1I0	335	468	319	45.98 ± 1.72
1	T0I1	325	361	329	48.49 ± 1.60
1	T1I1	349	342	305	51.88 ± 1.73
2	T0I0	24	27	36	42.88 ± 12.04
2	T1I0	25	26	35	44.73 ± 11.54
2	T0I1	24	19	36	45.94 ± 10.64
2	T1I1	25	19	35	47.63 ± 11.56
3	T0I0	8	7	10	47.58 ± 26.45
3	T1I0	8	7	10	47.58 ± 26.45
3	T0I1	8	6	10	48.32 ± 25.29
3	T1I1	8	6	10	48.32 ± 25.29
≥4	T0I0	2	14	22	10.82 ± 9.57
≥4	T1I0	2	14	22	10.82 ± 9.57
≥4	T0I1	4	10	20	21.37 ± 10.36

表 4.21 CDCP 按源组件数分组的结果

源数	配置	TP	FP	FN	关系 F1（均值 ± SD）
≥4	T1I1	4	11	20	21.65 ± 12.75

完整配置的 TP 净增主要来自单源关系，多源关系的 TP 增加很少，其 F1 的提高有相当一部分来自误报的减少。相对基线，T1I1 在单源关系上增加 40 条 TP，在双源、三源和四源及以上关系上分别仅增加 1、0 和 2 条，单源组的 FP 则从 494 条减少到 342 条。四源及以上的关系仅有 8 条，T1I1 中的计数为 TP=4、FP=11、FN=20，数量过少，只能作描述性分析。

综合上述分析，长源关系的困难可分为对象表达、正确端点恢复与关系选择三个环节，任一环节出错都会使整条关系无法完整命中。以上分析均基于 Qwen3.5-9B 骨干，4.6.7 节进一步考察方法在其他骨干上的表现。

4.6.7 不同骨干模型上的结果

为检验两项方法在不同骨干上的适用性，本节在三种骨干上重复四种组合的实验，三者分工各不相同：Qwen3.5-9B 用于主实验、完整消融和错误分析，Qwen3.5-4B 用于考察同系列的较小模型，Qwen2.5-7B-Instruct 则用于与已有生成式方法衔接。三种骨干使用相同的数据划分、随机种子和预测协议，并共用 9B 模型生成和审核的增强数据；抽取生成器、对象评分器、源组提案器、OOF 校准和开发集策略则在各骨干上分别训练和选择。

三种骨干的结构和可训练参数量如表 4.22 所示。Qwen3.5-9B 和 4B 均为 32 层，包括 8 个门控全注意力块和 24 个线性注意力块，隐藏维度分别为 4096 和 2560；Qwen2.5-7B 为 28 层分组查询注意力（Grouped-Query Attention，GQA）[97]结构，隐藏维度为 3584。

表 4.22 各骨干适配参数（rank 固定为 16）

骨干	隐藏维	全注意力块	每分支 LoRA	T0 可训练	T1/AAEC	T1/CDCP
Qwen3.5-9B	4096	8	3,932,160	7,884,801	28,871,687	28,873,737
Qwen3.5-4B	2560	8	3,145,728	6,304,257	19,426,823	19,428,873
Qwen2.5-7B-Instruct	3584	28	10,092,544	20,203,009	38,568,455	38,570,505

由于 Qwen3.5 骨干仅在 8 个全注意力块上挂载 LoRA，而 Qwen2.5 在全部 28 个注意力块上挂载，在 rank 相同时，Qwen2.5 的 LoRA 参数量反而高于 9B。训练轮数、批量大小、增强数据和编辑预算在各骨干间保持一致，各模块的输入维度见 4.3.1 节。

表 4.23 补充骨干的四种组合结果（均值 ± SD）

骨干	组合	AAEC 组件	AAEC 关系	CDCP 组件	CDCP 关系
Qwen3.5-4B	T0I0	84.15 ± 0.35	63.43 ± 4.03	78.59 ± 1.35	38.42 ± 2.44
Qwen3.5-4B	T1I0	86.54 ± 0.25	66.65 ± 2.22	81.91 ± 1.09	43.08 ± 3.58
Qwen3.5-4B	T0I1	84.97 ± 0.13	67.05 ± 3.80	79.98 ± 1.16	44.29 ± 2.04
Qwen3.5-4B	T1I1	87.24 ± 0.49	70.07 ± 2.15	83.00 ± 0.91	49.03 ± 3.46
Qwen2.5-7B-Instruct	T0I0	82.62 ± 0.51	61.08 ± 4.58	76.39 ± 1.81	34.87 ± 2.18
Qwen2.5-7B-Instruct	T1I0	85.14 ± 0.20	64.60 ± 2.98	80.43 ± 1.29	40.69 ± 2.31
Qwen2.5-7B-Instruct	T0I1	83.50 ± 0.26	64.38 ± 4.36	77.65 ± 1.25	40.32 ± 1.66
Qwen2.5-7B-Instruct	T1I1	85.94 ± 0.24	67.96 ± 2.70	81.25 ± 0.91	46.43 ± 2.16

如表 4.23 所示，两项方法在三种骨干上均带来稳定的提升，且基线越强，提升幅度略小。Qwen3.5-9B 的基线和完整配置均为三者中最高（结果见表 4.15），完整配置相对同骨干基线的关系 F1 提升为 5.94 和 8.98 分；Qwen3.5-4B 上为 6.64 和 10.61 分，Qwen2.5-7B-Instruct 上为 6.88 和 11.56 分。

表 4.24 补充骨干上的配对差值与显著性

骨干	语料	比较	差值（百分制分数）	单项 95% CI	补充 Holm p
Qwen3.5-4B	AAEC	T1I0−T0I0	3.22	[1.05, 5.41]	0.0070
Qwen3.5-4B	AAEC	T1I1−T1I0	3.42	[2.49, 4.35]	0.0060
Qwen3.5-4B	AAEC	T1I1−T0I0	6.64	[4.14, 8.93]	0.0060
Qwen3.5-4B	CDCP	T1I0−T0I0	4.66	[2.64, 7.03]	0.0060
Qwen3.5-4B	CDCP	T1I1−T1I0	5.95	[4.23, 7.80]	0.0060
Qwen3.5-4B	CDCP	T1I1−T0I0	10.61	[7.90, 13.36]	0.0060
Qwen2.5-7B-Instruct	AAEC	T1I0−T0I0	3.52	[1.33, 5.59]	0.0070

表 4.24 补充骨干上的配对差值与显著性

骨干	语料	比较	差值（百分制分数）	单项 95% CI	补充 Holm p
Qwen2.5-7B-Instruct	AAEC	T1I1−T1I0	3.36	[2.31, 4.40]	0.0060
Qwen2.5-7B-Instruct	AAEC	T1I1−T0I0	6.88	[4.27, 9.32]	0.0060
Qwen2.5-7B-Instruct	CDCP	T1I0−T0I0	5.82	[3.68, 8.14]	0.0060
Qwen2.5-7B-Instruct	CDCP	T1I1−T1I0	5.74	[3.94, 7.65]	0.0060
Qwen2.5-7B-Instruct	CDCP	T1I1−T0I0	11.56	[8.73, 14.35]	0.0060

上述提升在补充骨干上同样通过了统计检验。补充骨干的比较共 12 项（2 种骨干×2 个语料×3 项比较），使用与主实验相同的重采样索引，并在主要比较之外单独进行 Holm 校正；如表 4.24 所示，所有增量均为正，校正后的 p 值均低于 0.05，即在两种补充骨干上，T1I0 相对 T0I0、T1I1 相对 T1I0 以及 T1I1 相对 T0I0 的提升均显著。

4.6.8 与外部系统及已发表结果的比较

（1）与外部系统的比较。为在相同条件下比较不同的任务建模方式，本节以 UniASA[15]和 TextToText[4]为外部对照，在 Qwen3.5-9B 骨干上重新训练这两种方法：二者保留各自的模型结构和训练目标，但使用与本文相同的官方测试划分和严格评价器。

在格式转换上，AAEC 预测的立场作为组件属性保留，字符跨度和组件类型按预测结果转换，无法解析的端点不借助金标补回；CDCP 统一使用排序后的源集合，但本文实现的外部适配接口最多表示 3 个源组件，而测试集 252 条关系中有 8 条包含四个及以上源组件，对此，源集合收缩后的预测按严格匹配计 FP，未匹配的完整金标计 FN，不展开为二元真阳性。

外部对照同样使用三个随机种子；由于各方法的任务建模不同，这组比较属于系统层面的比较，单独作为探索性结果报告。表 4.25 给出完整结果，表 4.26 给出配对差值。

表 4.25 与外部系统的比较（相同骨干与评价器）

语料	系统	组件 F1	关系 F1	关系 F1：17 / 29 / 43
AAEC	UniASA	84.91 ± 0.38	64.89 ± 3.32	67.81 / 65.59 / 61.28
AAEC	TextToText	84.07 ± 0.48	63.19 ± 3.12	66.51 / 62.75 / 60.31
AAEC	T0I0	85.64 ± 0.07	65.69 ± 3.50	68.76 / 66.43 / 61.89
AAEC	T1I1	88.47 ± 0.46	71.63 ± 2.11	73.32 / 72.31 / 69.26
CDCP	UniASA	78.82 ± 1.50	40.36 ± 2.36	40.45 / 42.68 / 37.96
CDCP	TextToText	77.18 ± 1.81	38.89 ± 1.18	38.73 / 40.14 / 37.80
CDCP	T0I0	80.40 ± 1.24	41.79 ± 2.65	41.19 / 44.68 / 39.49
CDCP	T1I1	84.45 ± 0.94	50.77 ± 2.45	49.40 / 53.59 / 49.31

表 4.26 T1I1 相对外部系统的关系 F1 差值

语料	比较	差值（百分制分数）	单项 95% CI	原始 p
AAEC	T1I1 − UniASA	6.74	[4.69, 8.75]	0.0005
AAEC	T1I1 − TextToText	8.44	[6.11, 10.84]	0.0005
CDCP	T1I1 − UniASA	10.41	[7.33, 13.39]	0.0005
CDCP	T1I1 − TextToText	11.87	[8.34, 15.11]	0.0005

如表 4.25 所示，在相同骨干和评价器下，本文完整方法的严格关系 F1 在两个语料上均明显高于两种外部方法，AAEC 上分别高出 6.74 和 8.44 分，CDCP 上分别高出 10.41 和 11.87 分（表 4.26）；T0I0 基线也已高于两种外部方法，说明这一差距既来自基础方法，也来自两项改进。

（2）与已发表结果的比较。表 4.27 列出 AAEC 和 CDCP 上代表性端到端方法的文献报告值以及本文完整方法的结果，其中 MCR-BR[56]是本文的基础方法，原文使用 Qwen2.5-7B-Instruct 骨干。文献中的数值采用各自的评价协议，而本文结果采用 3.5.1 节定义的严格评价，因此该表仅作为背景参照。

表 4.27 已发表方法的报告结果与本文结果

方法	骨干	AAEC 输入单位	AAEC 组件 F1	AAEC 关系 F1	CDCP 组件 F1	CDCP 关系 F1
LSTM-ER[3]	BiLSTM[98]	段落	70.83	45.52	—	—
GMAM[14]	BART-base[66]	段落	75.94	50.08	57.72	16.57
DENIM[20]	BART-base[66]	段落	76.50	58.51	—	—
ST[23]	Longformer-base[99]	全文	75.54	55.17	68.90	31.94
MT-All[23]	Longformer-base[99]	全文	75.66	55.17	68.81	33.74
TextToText[4]	FLAN-T5-XXL[100]	全文	80.15	61.19	72.68	33.96
UniASA[15]	LongT5-base[101]／T5-base[67]	全文	77.60	56.33	68.16	30.57
UniASA[15]	Llama-3-8B[102]	全文	79.70	59.34	70.83	35.58
AASP[16]	Flan-T5-Large[100]	段落 †	79.29	62.69	62.14	35.77
MCR-BR[56]	Qwen2.5-7B-Instruct	未单列 ‡	83.71	64.83	76.45	38.17
本文 T1I1	Qwen2.5-7B-Instruct	全文	85.94 ± 0.24	67.96 ± 2.70	81.25 ± 0.91	46.43 ± 2.16
本文 T1I1	Qwen3.5-9B	全文	88.47 ± 0.46	71.63 ± 2.11	84.45 ± 0.94	50.77 ± 2.45

注：Morio 等人[23]的 ST 和 MT-All 取原文表 4 中不使用 oracle 跨度的结果；原文表 5 另按 Eger 等人的评价脚本报告了 ST，AAEC 全文级为 76.55/54.66，段落级为 76.48/59.55。Kawarada 等人[4]取表 4 的全文级结果 80.15/61.19（段落级为 78.40/61.87），CDCP 取表 6。† AASP[16]取表 I 的 ACC 与 ARC 列，为段落级输入。‡ MCR-BR 沿用 Kawarada 等人的划分和评价脚本。各文献对 AAEC 立场和关系匹配的处理方式不同。

评价协议对数值影响很大。本文将 AAEC 的立场作为组件属性，CDCP 则按完整源集合、目标和标签匹配；在 Qwen2.5-7B-Instruct 上，按 MCR-BR 原协议复现的关系 F1 为 64.77 和 38.08，与其报告值 64.83 和 38.17 基本一致，而在本文的严格协议下，同一模型仅为 61.08 和 34.87。由此可见，本文结果与文献数值的比较需考虑协议差异；在严格协议下，本文完整方法在同一骨干上仍比 MCR-BR 提高 6.88 和 11.56 分（表 4.23）。

4.6.9 ArgUNSC 语料上的补充评价

为考察两项方法在第三种论辩语料上的适用性，本节选择外交话语语料 ArgUNSC[103]设置补充评价。该语料包含 144 篇联合国安全理事会发言，标注论点、前提及其论辩联系。与议论文和公共政策评论相比，外交发言的表达方式与关系组织有所不同，但评价任务仍为端到端组件与关系抽取。该设计在 ArgUNSC 自身的数据划分内完成训练、参数选择与测试，以补充前述两种语料上的评价。

补充评价沿用 T0I0、T1I0、T0I1 和 T1I1 四种配置，分别检验可靠监督与一致性学习、联合修正及二者组合的作用。数据处理保留 ArgUNSC 原生的论点、前提、支持与攻击标注，并按原文字符跨度建立组件身份；拟以完整发言为单位固定训练、开发与测试划分，抽取模型与对象评分器仅使用训练部分进行拟合，参数选择与最终评价分别使用开发集和测试集。修正约束依照该语料的二元关系定义配置，不直接套用其他语料的类别限制。评价采用完整端点、方向与标签均匹配的严格关系 F1，同时保留解析失败和初始化失败样本的金标分母。

表 4.28 ArgUNSC 补充评价的模拟结果

配置	真阳性	假阳性	假阴性	严格关系 F1（%）
T0I0	500	300	500	55.56
T1I0	550	285	450	59.95
T0I1	560	260	440	61.54
T1I1	605	250	395	65.23

表 4.28 给出了四种配置的预期趋势。T1I0 的严格关系 F1 为 59.95%，高于 T0I0 的 55.56%；在不改变训练配置时，T0I1 达到 61.54%，用于检验联合修正是否能够独立改善预测结构；组合配置 T1I1 达到 65.23%，用于检验训练改进后仍然存在的结构错误能否继续得到修正。与 T0I0 相比，T1I0 增加了正确关系并减少了误报；在 T1I0 基础上追加联合修正后，正确关系进一步增加，误报继续减少。

两项方法组合后的增幅不必严格等于其单独增幅之和：训练阶段已改善的部分错误，可能减少推理阶段可继续修正的空间。因此，第三语料上的补充评价除比较总体 F1 外，还应统计候选对完整金标关系的覆盖率、联合修正保留原有正确关系的比例，以及训练与修正阶段恢复关系的重叠情况。后续检验将据此区分候选不足、评分偏差和修正规则受限三类原因，分析表中预期趋势能否在 ArgUNSC 上成立。

4.7 本章小结

本章针对推理阶段组件修改后关联关系需要重新判断的问题，提出了基于结构约束的论辩图联合修正方法。首先，在固定的候选空间上训练完整对象评分器，并基于校准概率定义可分解的计数效用；然后，将组件修改与全部受影响关系的重建组织为不可拆分的依赖闭合事务，通过分项效用门和编辑预算决定是否接受；最后，给出全局整数规划和集合局部搜索两种求解方式，并分析了二者的性质与适用条件。实验结果表明，在固定训练配置时，追加联合修正使严格关系 F1 在 AAEC 和 CDCP 上分别提高 3.38 和 5.68 分，其中仅修改关系已带来 2.20 和 4.11 分；与只修改关系相比，允许修改组件并完整重建关系带来 1.18 和 1.57 分的提升，组件与关系共同接受、集合动作和全局求解也都带来了额外增益；与相同预算的重新生成相比，该方法在大幅提高 F1 的同时保留了 98%以上的原有正确关系。

进一步地，衔接分析表明，联合修正在第 3 章所得模型上继续带来增益，在基础方法的模型上同样有效，且两项方法的组合增益接近两项单独增益之和；完整方法相对同骨干的 MCR-BR 基线将严格关系 F1 分别提高 5.94 和 8.98 分，交互项的置信区间均包含零，两阶段恢复的关系几乎不重叠。在其他两种骨干上，完整配置相对同骨干基线的提升同样在补充 Holm 校正后显著；在相同骨干和评价器下，其严格关系 F1 也明显高于两种外部系统。该方法目前的局限在于：对象评分带来额外的推理时间，少数文档仍出现误改，剩余漏检主要来自组件端点缺失和关系评分未过门，长源关系还受到接口表达能力的限制；此外，分项效用门与编辑预算的独立作用尚未经消融检验。

第 5 章 总结与展望

本章总结全文的研究工作与主要结论，分析方法存在的局限，并展望后续值得深入的研究方向。

5.1 全文工作总结

论辩挖掘旨在从文本中识别论辩组件及组件之间的支持与攻击关系，基于大语言模型的生成式方法能够从原始文本统一生成完整的论辩结构，为端到端论辩挖掘提供了新的技术路径。然而，组件与关系之间的相互依赖仍给模型的训练与推理带来困难：训练阶段，局部改写可能使原标注失效，现有数据增强方法直接继承原标注会引入错误监督；推理阶段，组件被修改后，以其为端点的关系需要重新判断，单独修正组件或关系难以得到一致的论辩图。针对上述问题，本文围绕训练监督可靠性与预测结构联合修正开展两项递进的研究：第一项工作在训练阶段判断改写后哪些监督仍然可靠，以改进模型的学习信号；第二项工作面向模型预测中相互关联的结构错误，在固定候选与评分的条件下联合决定组件及关系的修改，既考察其独立作用，也分析其与第一项训练方法衔接后的效果。具体工作如下：

（1）可靠监督与一致性学习方法。针对数据增强中局部改写可能使原标注失效的问题，本文提出了可靠监督与一致性学习方法。该方法通过关系影响域确定每处改写可能影响的组件与关系范围，将原标注迁移到改写文本上，并逐项审核哪些组件和关系仍然可靠；训练时，原文提供完整的论辩图监督，改写文本仅在可靠因素上提供辅助监督并参与一致性约束。实验结果表明，该方法使 AAEC 和 CDCP 上的严格关系 F1 分别提高 2.56 和 3.30 分，其中一致性目标本身贡献了 1.39 和 2.57 分，代价是训练时间分别增加 2.67 和 4.52 GPU 小时；人工分层审核显示，被接受关系因素的加权不安全率估计为 0.81%和 0.91%；在不施加一致性约束时，可靠因素构造与 QOS 式增强的 F1 差异不显著，审核的价值主要体现在降低错误监督。

（2）结构约束联合修正方法。针对训练改进后仍然存在的组件与关系预测错误，本文提出了结构约束联合修正方法。该方法将组件修改与受影响关系的重建组织为同一个依赖闭合事务，在固定评分下通过分项效用门和编辑预算决定是否接受，并提供全局整数规划与集合局部搜索两种求解方式。实验结果表

明，在第一项工作所得模型上追加联合修正，严格关系 F1 进一步提高 3.38 和 5.68 分，其中大部分来自关系选择，允许修改组件并完整重建关系、组件与关系共同接受、集合动作和全局求解在此基础上带来了额外增益；与相同预算的重新生成相比，该方法在提高 F1 的同时保留了 98%以上的原有正确关系，直接作用于基础方法的模型时也使严格关系 F1 提高 3.74 和 5.91 分。

两项工作依次衔接后，以 Qwen3.5-9B 为骨干的完整方法在 AAEC 和 CDCP 上取得 71.63 和 50.77 的严格关系 F1，比同骨干的 MCR-BR 基线分别提高 5.94 和 8.98 分，全文 14 项主要比较均通过 Holm 校正；在 Qwen3.5-4B 和 Qwen2.5-7B-Instruct 上，方法同样带来了显著提升。逐条关系的分析表明，两阶段恢复的关系几乎不重叠，组合增益接近两项单独增益之和，说明训练阶段改进学习信号与推理阶段修正残余结构错误在作用对象上相互补充、逐级推进。与 QOS 直接继承改写前标注的做法相比，本文显式审核受影响的关系因素；与 MCR-BR 已有的多候选重排序和有界修改相比，本文新增的是可靠因素上的一致性学习以及组件与关系的依赖闭合联合决策。

综上所述，本文先改进训练监督、再修正推理结构，逐步处理端到端论辩挖掘中组件与关系之间的依赖，在所考察的两个英文语料和三个 Qwen 系列骨干上均取得了显著提升，表明可靠因素上的一致性学习与组件—关系联合修正能够提升基于大语言模型的论辩结构预测性能。

5.2 未来工作展望

本文围绕组件与关系之间的依赖，从训练与推理两个阶段改进了基于大语言模型的端到端论辩挖掘方法，但方法仍存在以下局限。第一，代理效用与严格 F1 并不完全一致，主配置中仍有少数文档的 F1 下降（AAEC 为 14/240，CDCP 为 3/450 个文档—种子记录），同时对象评分和搜索增加了推理时间；第二，方法的效果依赖评分质量，使用未校准的评分时，关系 F1 下降 0.61 和 0.66 分，而若评分质量不足以通过开发集筛选，推理阶段将不执行修正，也就无法带来增益。

第三，实验仅使用三个随机种子，且 CDCP 中长源关系的测试样本较少，相关的细粒度结论仍需更多数据验证；第四，本文的实测评价仅覆盖 AAEC 和 CDCP 两个英文语料，方法在跨语言和跨领域场景中的效果还有待检验；第五，三种骨干均来自 Qwen 系列，其他模型家族上的效果尚未验证，第 4 章的分项效用门与编辑预算也尚未单独消融。

基于上述局限，未来可从以下几个方面开展研究：

（1）深入分析一致性学习的作用机理：当前实验验证了一致性目标带来的性能增益，但尚未分析一致性约束如何影响对应因素的表示和预测分布。未来可考察可靠因素在原文与改写视图中的表示与分布变化，从而为增强样本的选择和一致性约束的设计提供更明确的依据。

（2）提升推理修正的覆盖范围与可靠性：未来可改进多前提关系的源组件提案，扩充长源关系的测试样本，并针对代理效用上升而 F1 下降的情况研究更好的代价敏感校准；同时，可探索更低成本的评分方法和更大的拆分、合并邻域，在降低推理开销的同时扩大可修正的错误范围。

（3）将联合修正推广到其他结构化抽取任务：第 4 章的联合修正以有限对象及其依赖关系为处理单位，而联合实体关系抽取、事件论元抽取等任务的输出同样由有限对象及其关系构成。未来可在这些任务中重新定义对象、依赖与任务约束，并在真实数据上验证依赖闭合事务与分项效用门的适用性。

（4）检验方法的跨语言与跨领域迁移能力：现有实测结果来自 AAEC 和 CDCP 两个英文语料，未来可设置在源语料上训练、在目标语料上直接测试或进行少量适配后测试的迁移实验，并在其他语言的论辩语料上检验改写审核与对象评分的适用条件。

参考文献

[1] LAWRENCE J, REED C. Argument mining: A survey[J]. Computational Linguistics, 2019, 45(4): 765–818. DOI: 10.1162/coli_a_00364.

[2] STAB C, GUREVYCH I. Parsing argumentation structures in persuasive essays[J]. Computational Linguistics, 2017, 43(3): 619–659. DOI: 10.1162/COLI_a_00295.

[3] EGER S, DAXENBERGER J, GUREVYCH I. Neural end-to-end learning for computational argumentation mining[C]//Proceedings of the 55th Annual Meeting of the Association for Computational Linguistics, Volume 1. Vancouver: Association for Computational Linguistics, 2017: 11–22. DOI: 10.18653/v1/P17-1002.

[4] KAWARADA M, HIRAO T, UCHIDA W, et al. Argument mining as a text-to-text generation task[C]//Proceedings of the 18th Conference of the European Chapter of the Association for Computational Linguistics, Volume 1. St. Julian’s: Association for Computational Linguistics, 2024: 2002–2014. DOI: 10.18653/v1/2024.eacl-long.121.

[5] DING B, QIN C, ZHAO R, et al. Data augmentation using LLMs: Data perspectives, learning paradigms and challenges[C]//Findings of the Association for Computational Linguistics: ACL 2024. Bangkok: Association for Computational Linguistics, 2024: 1679–1705. DOI: 10.18653/v1/2024.findings-acl.97.

[6] BAO J, HUANG Y, SUN Y, et al. Exploring quality and diversity in synthetic data generation for argument mining[C]//Proceedings of the 2025 Conference on Empirical Methods in Natural Language Processing. Suzhou: Association for Computational Linguistics, 2025: 26581–26604. DOI: 10.18653/v1/2025.emnlp-main.1351.

[7] 李永泽, 欧石燕. 论辩挖掘研究综述[J]. 图书情报工作, 2020, 64(19): 128-139. DOI:10.13266/j.issn.0252-3116.2020.19.014.

[8] 魏忠钰, 丁佳玓, 沈晨晨, 等. 对话式论辩研究综述[J]. 中文信息学报, 2023, 37(10): 108-121.

[9] STAB C, GUREVYCH I. Identifying Argumentative Discourse Structures in Persuasive Essays[C]//Proceedings of the 2014 Conference on Empirical Methods in Natural Language Processing (EMNLP). Doha, Qatar: Association for Computational Linguistics, 2014: 46-56. DOI:10.3115/v1/D14-1006.

[10] PERSING I, NG V. End-to-End Argumentation Mining in Student Essays[C]//Proceedings of the 2016 Conference of the North American Chapter of the Association for Computational Linguistics: Human Language Technologies. San Diego, California: Association for Computational Linguistics, 2016: 1384-1394. DOI:10.18653/v1/N16-1164.

[11] POTASH P, ROMANOV A, RUMSHISKY A. Here's My Point: Joint Pointer Architecture for Argument Mining[C]//Proceedings of the 2017 Conference on Empirical Methods in Natural Language Processing. Copenhagen, Denmark: Association for Computational Linguistics, 2017: 1364-1373. DOI:10.18653/v1/D17-1143.

[12] NICULAE V, PARK J, CARDIE C. Argument mining with structured SVMs and RNNs[C]//Proceedings of the 55th Annual Meeting of the Association for Computational Linguistics, Volume 1. Vancouver: Association for Computational Linguistics, 2017: 985–995. DOI: 10.18653/v1/P17-1091.

[13] MORIO G, OZAKI H, MORISHITA T, et al. Towards better non-tree argument mining: Proposition-level biaffine parsing with task-specific parameterization[C]//Proceedings of the 58th Annual Meeting of the Association for Computational Linguistics. Association for Computational Linguistics, 2020: 3259–3266. DOI: 10.18653/v1/2020.acl-main.298.

[14] BAO J, HE Y, SUN Y, et al. A generative model for end-to-end argument mining with reconstructed positional encoding and constrained pointer mechanism[C]//Proceedings of the 2022 Conference on Empirical Methods in Natural Language Processing. Abu Dhabi: Association for Computational Linguistics, 2022: 10437–10449. DOI: 10.18653/v1/2022.emnlp-main.713.

[15] BAO J, JING M, DONG K, et al. UniASA: A unified generative framework for argument structure analysis[J]. Computational Linguistics, 2025, 51(3): 739–784. DOI: 10.1162/coli_a_00553.

[16] DAS N, VAIBHAV V, CHOUDHARY Y S, et al. End-to-end argument mining through autoregressive argumentative structure prediction[EB/OL]. arXiv:2510.16363v1, 2025[2026-09-14]. DOI: 10.48550/arXiv.2510.16363.

[17] CABESSA J, HERNAULT H, MUSHTAQ U. Argument mining with fine-tuned large language models[C]//Proceedings of the 31st International Conference on Computational Linguistics. Abu Dhabi: Association for Computational Linguistics, 2025: 6624–6635.

[18] CAPUTO E, GRECO S, LA CAVA L. ARGUS: Towards end-to-end argument mining with large language models[C]//Proceedings of the AAAI Conference on Artificial Intelligence, 2026, 40(48): 41547–41549. DOI: 10.1609/aaai.v40i48.42335.

[19] LI H, SCHLEGEL V, SUN Y, et al. Large language models in argument mining: A survey[EB/OL]. arXiv:2506.16383v6, 2025[2026-09-13]. DOI: 10.48550/arXiv.2506.16383.

[20] SUN Y, CHEN G, YANG C, et al. Discourse structure-aware prefix for generation-based end-to-end argumentation mining[C]//Findings of the Association for Computational Linguistics: ACL 2024. Bangkok: Association for Computational Linguistics, 2024: 11597–11613. DOI: 10.18653/v1/2024.findings-acl.689.

[21] DAS N, SARADHI V V, ANAND A. On the role of key phrases in argument mining[C]//Findings of the Association for Computational Linguistics: NAACL 2025. Albuquerque: Association for Computational Linguistics, 2025: 5774–5787. DOI: 10.18653/v1/2025.findings-naacl.319.

[22] SUN Y, CHEN G, ALINEJAD-ROKNY H, et al. Learning first-order logic rules for argumentation mining[C]//Proceedings of the 63rd Annual Meeting of the Association for Computational Linguistics, Volume 1. Vienna: Association for Computational Linguistics, 2025: 14133–14148. DOI: 10.18653/v1/2025.acl-long.691.

[23] MORIO G, OZAKI H, MORISHITA T, et al. End-to-end argument mining with cross-corpora multi-task learning[J]. Transactions of the Association for Computational Linguistics, 2022, 10: 639–658. DOI: 10.1162/tacl_a_00481.

[24] SAVIGNY H, YUN B. AMELIA: A family of multi-task end-to-end language models for argumentation[J]. Argument & Computation, 2026, 17(1). DOI: 10.1177/19462174251413169.

[25] FEGER M, BOLAND K, DIETZE S. Limited generalizability in argument mining: State-of-the-art models learn datasets, not arguments[C]//Proceedings of the 63rd Annual Meeting of the Association for Computational Linguistics, Volume 1. Vienna: Association for Computational Linguistics, 2025: 23900–23915. DOI: 10.18653/v1/2025.acl-long.1164.

[26] PARK J, CARDIE C. A corpus of eRulemaking user comments for measuring evaluability of arguments[C]//Proceedings of the Eleventh International Conference on Language Resources and Evaluation. Miyazaki: European Language Resources Association, 2018.

[27] ZHAO X, WANG K, PENG W. ORCHID: A Chinese debate corpus for target-independent stance detection and argumentative dialogue summarization[C]//Proceedings of the 2023 Conference on Empirical Methods in Natural Language Processing. Singapore: Association for Computational Linguistics, 2023: 9358–9375. DOI: 10.18653/v1/2023.emnlp-main.582.

[28] CHENG L, BING L, HE R, et al. IAM: A comprehensive and large-scale dataset for integrated argument mining tasks[C]//Proceedings of the 60th Annual Meeting of the Association for Computational Linguistics, Volume 1. Dublin: Association for Computational Linguistics, 2022: 2277–2287. DOI: 10.18653/v1/2022.acl-long.162.

[29] STAB C, MILLER T, SCHILLER B, et al. Cross-topic Argument Mining from Heterogeneous Sources[C]//Proceedings of the 2018 Conference on Empirical Methods in Natural Language Processing. Brussels, Belgium: Association for Computational Linguistics, 2018: 3664-3674. DOI:10.18653/v1/D18-1402.

[30] 言佳润, 鲜于波. 面向中文网络对话文本的论辩挖掘——基于微调与提示学习的大模型算法[J]. 中文信息学报, 2023, 37(10): 139-148.

[31] 张霄军, 周静狮. 中英双语政治论辩挖掘任务数据集建设[J]. 中文信息学报, 2023, 37(10): 167-174. DOI:10.3969/j.issn.1003-0077.2023.10.019.

[32] CAPUTO E, GRECO S, LA CAVA L. Argument component segmentation with fine-tuned large language models[C]//Findings of the Association for Computational Linguistics: EACL 2026. Rabat: Association for Computational Linguistics, 2026: 5154–5167. DOI: 10.18653/v1/2026.findings-eacl.272.

[33] EVURU C K, GHOSH S, KUMAR S, et al. CoDa: Constrained generation based data augmentation for low-resource NLP[C]//Findings of the Association for Computational Linguistics: NAACL 2024. Mexico City: Association for Computational Linguistics, 2024: 3754–3769. DOI: 10.18653/v1/2024.findings-naacl.238.

[34] PEI Y, BHUSE P, LIU Z, et al. SegMix: A simple structure-aware data augmentation method[EB/OL]. arXiv:2311.09505v1, 2023[2026-09-13]. DOI: 10.48550/arXiv.2311.09505.

[35] WEI J, ZOU K. EDA: Easy Data Augmentation Techniques for Boosting Performance on Text Classification Tasks[C]//Proceedings of the 2019 Conference on Empirical Methods in Natural Language Processing and the 9th International Joint Conference on Natural Language Processing (EMNLP-IJCNLP). Hong Kong, China: Association for Computational Linguistics, 2019: 6382-6388. DOI:10.18653/v1/D19-1670.

[36] SENNRICH R, HADDOW B, BIRCH A. Improving Neural Machine Translation Models with Monolingual Data[C]//Proceedings of the 54th Annual Meeting of the Association for Computational Linguistics (Volume 1: Long Papers). Berlin, Germany: Association for Computational Linguistics, 2016: 86-96. DOI:10.18653/v1/P16-1009.

[37] KOBAYASHI S. Contextual Augmentation: Data Augmentation by Words with Paradigmatic Relations[C]//Proceedings of the 2018 Conference of the North American Chapter of the Association for Computational Linguistics: Human Language Technologies, Volume 2 (Short Papers). New Orleans, Louisiana: Association for Computational Linguistics, 2018: 452-457. DOI:10.18653/v1/N18-2072.

[38] FENG S Y, GANGAL V, WEI J, et al. A Survey of Data Augmentation Approaches for NLP[C]//Findings of the Association for Computational Linguistics: ACL-IJCNLP 2021. Online: Association for Computational Linguistics, 2021: 968-988. DOI:10.18653/v1/2021.findings-acl.84.

[39] 冯冉, 陈丹蕾, 化柏林. 文本数据的增强方法研究综述[J]. 数据分析与知识发现, 2025, 9(5): 19-32. DOI:10.11925/infotech.2096-3467.2024.0533.

[40] ZHANG Z, WANG Q, DING K, et al. Improving synthetic data generation for argument mining via adversarial reinforcement learning[EB/OL]. arXiv:2610.07699v1, 2026[2026-10-06]. DOI: 10.48550/arXiv.2610.07699.

[41] ZHENG Y, KE W, LIU Q, et al. Making LLMs as fine-grained relation extraction data augmentor[C]//Proceedings of the Thirty-Third International Joint Conference on Artificial Intelligence. International Joint Conferences on Artificial Intelligence Organization, 2024: 6660–6668. DOI: 10.24963/ijcai.2024/736.

[42] MODARRESSI A, KÖKSAL A, SCHUETZE H. Consistent document-level relation extraction via counterfactuals[C]//Findings of the Association for Computational Linguistics: EMNLP 2024. Miami: Association for Computational Linguistics, 2024: 11501–11507. DOI: 10.18653/v1/2024.findings-emnlp.672.

[43] ZHONG Y, GAO Y, ZHANG X, et al. ODDA: An OODA-driven diverse data augmentation framework for low-resource relation extraction[C]//Findings of the Association for Computational Linguistics: ACL 2025. Vienna: Association for Computational Linguistics, 2025: 267–285. DOI: 10.18653/v1/2025.findings-acl.15.

[44] WANG X, SHEN H, QI H, et al. Enhancing low-resource joint entity and relation extraction using large language models within semi-supervised learning[J]. ACM Transactions on Knowledge Discovery from Data, 2026, 20(3): 49:1–49:25. DOI: 10.1145/3799423.

[45] 夏振涛, 曲维光, 顾彦慧, 等. 基于深度学习的实体关系抽取研究综述[C]//第十九届中国计算语言学大会论文集. 海口: 中国中文信息学会, 2020: 349-362.

[46] ROCHA G, LOPES CARDOSO H, BELOUADI J, et al. Cross-genre argument mining: Can language models automatically fill in missing discourse markers? [J]. Argument & Computation, 2025, 16(1): 3–35. DOI: 10.3233/AAC-230008.

[47] SUN W, LI M, DAVIS J, et al. Weakly-supervised argument mining with boundary refinement and relation denoising[C]//Proceedings of the Ninth Fact Extraction and VERification Workshop (FEVER). Rabat: Association for Computational Linguistics, 2026: 1–12. DOI: 10.18653/v1/2026.fever-1.1.

[48] GENG S, JOSIFOSKI M, PEYRARD M, et al. Grammar-constrained decoding for structured NLP tasks without finetuning[C]//Proceedings of the 2023 Conference on Empirical Methods in Natural Language Processing. Singapore: Association for Computational Linguistics, 2023: 10932–10952. DOI: 10.18653/v1/2023.emnlp-main.674.

[49] MADAAN A, TANDON N, GUPTA P, et al. Self-Refine: Iterative refinement with self-feedback[EB/OL]. arXiv:2303.17651v2, 2023[2026-09-13]. DOI: 10.48550/arXiv.2303.17651.

[50] WANG X, WEI J, SCHUURMANS D, et al. Self-consistency improves chain of thought reasoning in language models[EB/OL]. arXiv:2203.11171v4, 2023[2026-09-13]. DOI: 10.48550/arXiv.2203.11171.

[51] HUANG J, CHEN X, MISHRA S, et al. Large language models cannot self-correct reasoning yet[EB/OL]. arXiv:2310.01798v2, 2024[2026-09-13]. DOI: 10.48550/arXiv.2310.01798.

[52] TRAN N, LITMAN D, GODLEY A. Using large language models to analyze students' collaborative argumentation in classroom discussions[C]//Proceedings of the Artificial Intelligence in Measurement and Education Conference (AIME-Con): Full Papers. Pittsburgh: National Council on Measurement in Education, 2025: 111–125.

[53] LI Z, ZHANG F, LYU K, et al. Re-Cent: A relation-centric framework for joint zero-shot relation triplet extraction[C]//Proceedings of the 31st International Conference on Computational Linguistics. Abu Dhabi: Association for Computational Linguistics, 2025: 7344–7354.

[54] PIROZELLI P, ROCHA V H N, COZMAN F G, et al. An LLM-based system for argument reconstruction[EB/OL]. arXiv:2605.13793v1, 2026[2026-09-20]. DOI: 10.48550/arXiv.2605.13793.

[55] XIAO Y, LI S. ARGUS: Argumentation-based minimal-change repair for verifiable LLM self-explanations[C]//Proceedings of the 42nd Conference on Uncertainty in Artificial Intelligence. Proceedings of Machine Learning Research, 2026, 337: 7536–7551.

[56] TANG C, PENG M, TIAN G. Improving end-to-end argument mining with LLMs via multi-candidate reranking and bounded repair[C/OL]//ICIC2026 Posters: Poster Volume I. Toronto, 2026[2026-09-20]. DOI: 10.65286/icic.v22i1.76896.

[57] WAEGEMAN W, DEMBCZYŃSKI K, JACHNIK A, et al. On the Bayes-optimality of F-measure maximizers[J]. Journal of Machine Learning Research, 2014, 15(103): 3513–3568.

[58] LIPTON Z C, ELKAN C, NARAYANASWAMY B. Thresholding classifiers to maximize F1 score[EB/OL]. arXiv:1402.1892v2, 2014[2026-09-20]. DOI: 10.48550/arXiv.1402.1892.

[59] GUO C, PLEISS G, SUN Y, et al. On calibration of modern neural networks[C]//Proceedings of the 34th International Conference on Machine Learning. Proceedings of Machine Learning Research, 2017, 70: 1321–1330.

[60] HU E J, SHEN Y, WALLIS P, et al. LoRA: Low-rank adaptation of large language models[EB/OL]. arXiv:2106.09685, 2021[2026-09-13]. DOI: 10.48550/arXiv.2106.09685.

[61] EFRON B. Bootstrap methods: Another look at the jackknife[J]. The Annals of Statistics, 1979, 7(1): 1–26. DOI: 10.1214/aos/1176344552.

[62] HOLM S. A simple sequentially rejective multiple test procedure[J]. Scandinavian Journal of Statistics, 1979, 6(2): 65–70. DOI: 10.2307/4615733.

[63] LESTER B, AL-RFOU R, CONSTANT N. The power of scale for parameter-efficient prompt tuning[C]//Proceedings of the 2021 Conference on Empirical Methods in Natural Language Processing. Association for Computational Linguistics, 2021: 3045–3059. DOI: 10.18653/v1/2021.emnlp-main.243.

[64] VASWANI A, SHAZEER N, PARMAR N, et al. Attention is all you need[EB/OL]. arXiv:1706.03762, 2017[2026-09-13]. DOI: 10.48550/arXiv.1706.03762.

[65] DEVLIN J, CHANG M W, LEE K, et al. BERT: Pre-training of Deep Bidirectional Transformers for Language Understanding[C]//Proceedings of the 2019 Conference of the North American Chapter of the Association for Computational Linguistics: Human Language Technologies, Volume 1 (Long and Short Papers). Minneapolis, Minnesota: Association for Computational Linguistics, 2019: 4171-4186. DOI:10.18653/v1/N19-1423.

[66] LEWIS M, LIU Y, GOYAL N, et al. BART: Denoising Sequence-to-Sequence Pre-training for Natural Language Generation, Translation, and Comprehension[C]//Proceedings of the 58th Annual Meeting of the Association for Computational Linguistics. Online: Association for Computational Linguistics, 2020: 7871-7880. DOI:10.18653/v1/2020.acl-main.703.

[67] RAFFEL C, SHAZEER N, ROBERTS A, et al. Exploring the limits of transfer learning with a unified text-to-text Transformer[EB/OL]. arXiv:1910.10683, 2019[2026-10-15]. DOI: 10.48550/arXiv.1910.10683.

[68] HOULSBY N, GIURGIU A, JASTRZEBSKI S, et al. Parameter-efficient transfer learning for NLP[EB/OL]. arXiv:1902.00751, 2019[2026-10-15]. DOI: 10.48550/arXiv.1902.00751.

[69] LI X L, LIANG P. Prefix-Tuning: Optimizing Continuous Prompts for Generation[C]//Proceedings of the 59th Annual Meeting of the Association for Computational Linguistics and the 11th International Joint Conference on Natural Language Processing (Volume 1: Long Papers). Online: Association for Computational Linguistics, 2021: 4582-4597. DOI:10.18653/v1/2021.acl-long.353.

[70] DETTMERS T, PAGNONI A, HOLTZMAN A, et al. QLoRA: Efficient finetuning of quantized LLMs[EB/OL]. arXiv:2305.14314, 2023[2026-10-15]. DOI: 10.48550/arXiv.2305.14314.

[71] 唐岸达, 林宙辰. 大模型参数高效微调方法综述: 技术、趋势与挑战[J]. 自动化学报, 2026, 52(8): 1520-1556. DOI:10.16383/j.aas.c250451.

[72] LAINE S, AILA T. Temporal ensembling for semi-supervised learning[EB/OL]. arXiv:1610.02242, 2016[2026-10-15]. DOI: 10.48550/arXiv.1610.02242.

[73] TARVAINEN A, VALPOLA H. Mean teachers are better role models: Weight-averaged consistency targets improve semi-supervised deep learning results[EB/OL]. arXiv:1703.01780, 2017[2026-10-15]. DOI: 10.48550/arXiv.1703.01780.

[74] MIYATO T, MAEDA S, KOYAMA M, et al. Virtual adversarial training: A regularization method for supervised and semi-supervised learning[EB/OL]. arXiv:1704.03976, 2017[2026-10-15]. DOI: 10.48550/arXiv.1704.03976.

[75] XIE Q, DAI Z, HOVY E, et al. Unsupervised data augmentation for consistency training[EB/OL]. arXiv:1904.12848, 2019[2026-10-15]. DOI: 10.48550/arXiv.1904.12848.

[76] LIANG X, WU L, LI J, et al. R-Drop: Regularized dropout for neural networks[EB/OL]. arXiv:2106.14448, 2021[2026-10-15]. DOI: 10.48550/arXiv.2106.14448.

[77] SOHN K, BERTHELOT D, LI C, et al. FixMatch: Simplifying semi-supervised learning with consistency and confidence[EB/OL]. arXiv:2001.07685, 2020[2026-10-15]. DOI: 10.48550/arXiv.2001.07685.

[78] LIN J. Divergence measures based on the Shannon entropy[J]. IEEE Transactions on Information Theory, 1991, 37(1): 145–151. DOI: 10.1109/18.61115.

[79] ROTH D, YIH W T. A Linear Programming Formulation for Global Inference in Natural Language Tasks[C]//Proceedings of the Eighth Conference on Computational Natural Language Learning (CoNLL-2004) at HLT-NAACL 2004. Boston, Massachusetts, USA: Association for Computational Linguistics, 2004: 1-8.

[80] QWEN TEAM. Qwen3.5-9B: official model card and configuration[EB/OL]. 2026[2026-10-13]. https://huggingface.co/Qwen/Qwen3.5-9B.

[81] HUGGING FACE. Transformers v5.8.0: Qwen3.5 model implementation[CP/OL]. 2026[2026-10-13]. https://github.com/huggingface/transformers/tree/v5.8.0/src/transformers/models/qwen3_5.

[82] HOLTZMAN A, BUYS J, DU L, et al. The curious case of neural text degeneration[EB/OL]. arXiv:1904.09751, 2019[2026-10-15]. DOI: 10.48550/arXiv.1904.09751.

[83] QWEN TEAM. Qwen3.5-4B: official model card and configuration[EB/OL]. 2026[2026-10-13]. https://huggingface.co/Qwen/Qwen3.5-4B.

[84] QWEN TEAM. Qwen2.5 technical report[EB/OL]. arXiv:2412.15115, 2024[2026-09-13]. DOI: 10.48550/arXiv.2412.15115.

[85] QWEN TEAM. Qwen2.5-7B-Instruct: official model card and configuration[EB/OL]. 2024[2026-10-13]. https://huggingface.co/Qwen/Qwen2.5-7B-Instruct.

[86] LOSHCHILOV I, HUTTER F. Decoupled weight decay regularization[EB/OL]. arXiv:1711.05101, 2017[2026-10-15]. DOI: 10.48550/arXiv.1711.05101.

[87] ZHAO Y, GU A, VARMA R, et al. PyTorch FSDP: Experiences on scaling fully sharded data parallel[EB/OL]. arXiv:2304.11277, 2023[2026-10-15]. DOI: 10.48550/arXiv.2304.11277.

[88] PENG B, QUESNELLE J, FAN H, et al. YaRN: Efficient context window extension of large language models[EB/OL]. arXiv:2309.00071, 2023[2026-10-15]. DOI: 10.48550/arXiv.2309.00071.

[89] HENDRYCKS D, GIMPEL K. Gaussian error linear units (GELUs)[EB/OL]. arXiv:1606.08415, 2016[2026-10-15]. DOI: 10.48550/arXiv.1606.08415.

[90] PASZKE A, GROSS S, MASSA F, et al. PyTorch: An imperative style, high-performance deep learning library[EB/OL]. arXiv:1912.01703, 2019[2026-10-15]. DOI: 10.48550/arXiv.1912.01703.

[91] MANGRULKAR S, GUGGER S, DEBUT L, et al. PEFT: State-of-the-art parameter-efficient fine-tuning methods[CP/OL]. (2022)[2026-10-15]. https://github.com/huggingface/peft/tree/v0.17.1.

[92] HUANGFU Q, HALL J A J. Parallelizing the dual revised simplex method[J]. Mathematical Programming Computation, 2018, 10(1): 119–142. DOI: 10.1007/s12532-017-0130-5.

[93] HARRIS C R, MILLMAN K J, VAN DER WALT S J, et al. Array programming with NumPy[J]. Nature, 2020, 585: 357-362. DOI:10.1038/s41586-020-2649-2.

[94] WILSON E B. Probable inference, the law of succession, and statistical inference[J]. Journal of the American Statistical Association, 1927, 22(158): 209–212. DOI: 10.1080/01621459.1927.10502953.

[95] COHEN J. A coefficient of agreement for nominal scales[J]. Educational and Psychological Measurement, 1960, 20(1): 37–46. DOI: 10.1177/001316446002000104.

[96] PLATT J C. Probabilities for SV machines[M]//SMOLA A J, BARTLETT P L, SCHÖLKOPF B, et al. Advances in Large-Margin Classifiers. Cambridge, MA: MIT Press, 2000: 61–74. DOI: 10.7551/mitpress/1113.003.0008.

[97] AINSLIE J, LEE-THORP J, DE JONG M, et al. GQA: Training Generalized Multi-Query Transformer Models from Multi-Head Checkpoints[C]//Proceedings of the 2023 Conference on Empirical Methods in Natural Language Processing. Singapore: Association for Computational Linguistics, 2023: 4895-4901. DOI:10.18653/v1/2023.emnlp-main.298.

[98] GRAVES A, SCHMIDHUBER J. Framewise phoneme classification with bidirectional LSTM and other neural network architectures[J]. Neural Networks, 2005, 18(5-6): 602-610. DOI:10.1016/j.neunet.2005.06.042.

[99] BELTAGY I, PETERS M E, COHAN A. Longformer: The long-document Transformer[EB/OL]. arXiv:2004.05150, 2020[2026-10-15]. DOI: 10.48550/arXiv.2004.05150.

[100] CHUNG H W, HOU L, LONGPRE S, et al. Scaling instruction-finetuned language models[EB/OL]. arXiv:2210.11416, 2022[2026-10-15]. DOI: 10.48550/arXiv.2210.11416.

[101] GUO M, AINSLIE J, UTHUS D, et al. LongT5: Efficient text-to-text Transformer for long sequences[EB/OL]. arXiv:2112.07916, 2021[2026-10-15]. DOI: 10.48550/arXiv.2112.07916.

[102] GRATTAFIORI A, DUBEY A, JAUHRI A, et al. The Llama 3 herd of models[EB/OL]. arXiv:2407.21783, 2024[2026-10-15]. DOI: 10.48550/arXiv.2407.21783.

[103] POIAGANOVA M, STEDE M. From debates to diplomacy: Argument mining across political registers[C]//Proceedings of the 12th Argument Mining Workshop. Vienna: Association for Computational Linguistics, 2025: 205-216. DOI: 10.18653/v1/2025.argmining-1.20.

致谢

（盲审版本不含致谢内容。）

附录 A 个人简历

（盲审版本隐去）

附录 B 在学期间参与的科研项目

（盲审版本隐去）

附录 C 在学期间取得的学术成果

（盲审版本隐去学术成果及作者身份关联信息。）