分类号 _____ 密 级 _____

U D C _____ 编 号 10486

武漢大學

硕 士 学 位 论 文

基于对比式自监督学习的结构语义融合知识推理研究

研 究 生 姓 名 ： 彭淼

学 号 ： 2021202110008

指导教师姓名、职称 ： 彭 敏 教授

专 业 名 称 ： 计算机科学与技术

研 究 方 向 ： 人工智能（自然语言处理）

二〇二四年五月

Research on Structure-semantic Integrated Knowledge Reasoning Based on Contrastive Self-supervised Learning

By

Peng Miao

Supervised By

Prof. Peng Min

Wuhan University

May, 2024

论文原创性声明

本人郑重声明：所呈交的学位论文，是本人在导师指导下，独立进行研究工作所取得的研究成果。除文中已经标明引用的内容外，本论文不包含任何其他个人或集体已发表或撰写的研究成果。对本文的研究做出贡献的个人和集体，均已在文中以明确方式标明。本声明的法律结果由本人承担。

学位论文作者（签名）：_____

日期：　　年　　月　　日

武汉大学学位论文使用授权协议书

本学位论文作者愿意遵守武汉大学关于保存、使用学位论文的管理办法及规定，即：学校有权保存学位论文的印刷本和电子版，并提供文献检索与阅览服务；学校可以采用影印、缩印、数字化或其它复制手段保存论文；在以教学与科研服务为目的前提下，学校可以在校园网内公布部分或全部内容。

一、在本论文提交当年，同意在校园网内以及中国高等教育文献保障系统（CALIS）、高校学位论文系统提供查询及前十六页浏览服务。

二、在本论文提交□当年/□一年/□两年/□三年以后，同意在校园网内允许读者在线浏览并下载全文，学校可以为存在馆际合作关系的兄弟高校用户提供文献传递服务和交换服务。（保密论文解密后遵守此规定）

论文作者（签名）：_____

学　　号：_____

学　　院：_____

日期：　　年　　月　　日

摘要

近年来，随着互联网技术与智能信息服务的不断进步，知识图谱已成为互联网智能领域内一种关键的知识获取与表示工具。知识图谱通过结构化三元组的形式存储了现实世界中的丰富知识，一方面便于利用图算法进行高效的知识查询和检索；另一方面，知识图谱可以作为辅助信息来支撑其他知识密集型任务。然而，知识图谱中普遍存在信息稀疏和不完整的问题，这促使研究者们着力研究知识推理技术，以补充和完善知识图谱中的知识空缺。现有的研究针对知识推理任务，通常的做法是采用基于神经网络的表示方法，将知识图谱中的实体、关系和三元组转化为低维空间的特征编码，但现有方法通常只关注三元组的局部结构，未能全面挖掘知识图谱中的全局结构特征、上下文知识、文本语义与时序历史等异质信息，难以实现较优的知识推理性能。因此，如何捕捉和融合知识图谱中的各类异质信息是知识推理任务下非常重要的研究课题，主要存在以下挑战：（1）如何有效捕捉知识图谱中的上下文信息，以及融合平衡知识图谱中不同层级的上下文信息与全局结构知识；（2）针对知识图谱动态变化的特性，如何捕捉其中的时序历史信息并与文本语义进行融合，以完成复杂场景下的知识推理任务。为了解决上述挑战，论文工作主要包含以下两个部分：

（1）针对如何有效捕捉和融合知识图谱中的上下文语义知识与结构特征的问题，论文提出模式（schema）增强的多层级对比学习知识推理模型 SMiLE（**S**chema-augmented **M**ulti-level Contrastive **Le**arning Model for Knowledge Graph Reasoning）。模型基于实体类型自动构建知识图谱全局 schema 图，并利用 schema 来建模实体邻域的上下文信息。基于多关系图神经网络架构，模型通过结构视图和上下文视图的编码器对实体和关系分别进行建模。基于 schema 引导的正负样本采样策略，结合自监督对比学习目标，模型能够捕获和融合上下文层级和全局层级的语义结构信息。实验结果表明，在四个公开数据集上，模型在链接预测任务上的性能要普遍优于基线模型。

（2）针对如何有效融合知识图谱中的时序历史与文本语义知识的问题，论文提出语义增强的对比历史建模时序知识推理模型 ChapTER（Semantic-augmented **C**ontrastive **H**istoric**a**l Modeling Model with **P**refix-tuning for **Te**mporal Knowledge Graph **R**easoning）。模型采用基于预训练语言模型的双塔推理架构，将时序知识推理任务转化为查询项-候选项匹配问题。在输入层面，模型构造融合时序上下文的文本模板，通过自监督的对比学习优化目标进行训练，结合虚拟时间前缀微调，有效地整合了时序知识图谱中的时序历史与文本语义，并完成在复杂场景下的时序知识推理任务。实验结果表明，模型在仅对极小比例（0.17%）的参数进行微调的情况下，在直推式和少样本归纳式的时序知识推理任务上实现比基线模型更优的性能。此外，模型的训练时间消耗减少了 21.4%，证

明了模型在处理复杂场景下时序知识推理时的有效性和高效性。

综上所述，论文在知识图谱领域的知识推理研究中，针对异质信息捕捉与融合这一关键性问题，深入研究了通过 schema 增强的多层级对比学习实现知识图谱中结构特征与上下文语义的捕捉与融合，通过语义增强的对比历史建模实现知识图谱中时序历史与文本语义的捕捉与融合，提升了模型在复杂任务场景下对异质信息的捕捉与融合能力，实现了有效的知识推理。

关键词：知识推理；异质信息融合；对比学习；图神经网络；预训练语言模型

Abstract

In recent years, with the continuous advancement of Internet technology and intelligent information services, Knowledge Graphs (KGs) have become an essential tool for knowledge acquisition and representation in the field of Internet intelligence. Knowledge Graphs store rich knowledge from the real world in the form of structured triplets, facilitating efficient knowledge query and retrieval through graph algorithms on one hand; on the other hand, they can serve as auxiliary information to support other knowledge-intensive tasks. However, Knowledge Graphs are suffering the problem of information sparsity and incompleteness, prompting researchers to focus on knowledge reasoning technologies to complete the missing entities, relations and triplets within them. Current researches on knowledge reasoning tasks typically employ neural network-based knowledge representation methods, which map entities, relationships, and triplets of knowledge graphs into a low-dimensional vector space. However, these methods mainly focus on the local structure of triplets but fail to fully explore the global structural features, contextual knowledge, textual semantics, and temporal history in Knowledge Graphs, making it difficult to achieve optimal knowledge reasoning performance. Therefore, how to capture and integrate heterogeneous information in Knowledge Graphs becomes an essential challenge for knowledge reasoning tasks, and it contains the following two challenges: (1) How to effectively capture contextual information in knowledge graphs and balance contextual information with global structural knowledge in different levels; (2) Considering the dynamic characteristics of Knowledge Graphs, how to capture temporal historical information and integrate it with textual semantics to perform knowledge reasoning in various scenarios. To address the above challenges, this thesis mainly contains the following two part of works:

(1) To address the challenge of how to effectively capture and integrate contextual semantics and structural information in Knowledge Graphs, the thesis proposes the Schema-augmented Multi-level Contrastive Learning Model for Knowledge Graph Reasoning (SMiLE). SMiLE automatically constructs the global schema graph of the Knowledge Graph based on entity types, and utilizes schema to model the contextual information of the entity neighborhood. With the framework of multi-relation graph neural network, SMiLE encodes entities and relations separately through structural and contextual view encoders. With a schema-guided sample sampling strategy and self-supervised

contrastive learning objective, SMiLE is able to capture and integrate semantic structural information in both contextual and global levels. Experimental results demonstrate that SMiLE achieves state-of-the-art performance on link prediction task among other baselines on four public datasets.

(2) To address the challenge of how to effectively integrate temporal history and textual semantic knowledge in Knowledge Graphs, this thesis proposes the Semantic-augmented Contrastive Historical Modeling Model with Prefix-tuning for Temporal Knowledge Graph Reasoning (ChapTER). ChapTER uses a two-tower architecture based on pre-trained language models, and it converts the temporal knowledge reasoning task into a query-candidate matching task. As for the input, ChapTER constructs the input prompt with historical contexts, and it is trained in a self-supervised contrastive manner. By applying the prefix-tuning method with virtual time prefix, ChapTER can effectively integrate temporal history and textual semantics in Temporal Knowledge Graphs, and perform temporal knowledge reasoning in different scenarios. Experimental results demonstrate that ChapTER achieves superior performance compared to competitive baselines in both transductive and few-shot inductive temporal knowledge reasoning tasks with only 0.17% parameters tuned. In addition, the model's training time consumption was reduced by 21.4%, demonstrating the effectiveness and efficiency of ChapTER to perform temporal knowledge reasoning in various complex scenarios.

In summary, the thesis conducts in-depth research in the field of knowledge reasoning, focusing on the key issue of capturing and integrating heterogeneous information in Knowledge Graphs. It proposes a schema-augmented multi-level contrastive learning model to capture and integrate the structural features and contextual semantics in Knowledge Graphs. Besides, it designs a semantic-augmented contrastive historical modeling model to capture and integrate the temporal history and textual semantics in Knowledge Graphs, enhancing the model's ability to capture and integrate heterogeneous information in complex knowledge reasoning scenarios.

Keywords: Knowledge Reasoning, Heterogeneous Information Integration, Contrastive Learning, Graph Neural Network, Pre-trained Language Model

目录

摘要 ..... **I**
Abstract ..... **III**
第 1 章 绪　论 **1**
1.1 研究背景与意义 1
1.2 国内外研究现状 2
1.2.1 知识表示学习与推理 2
1.2.2 异质信息融合的知识推理方法 3
1.3 主要研究内容 5
1.4 论文的组织结构 7
第 2 章 相关理论与技术 **9**
2.1 知识推理任务定义 9
2.1.1 直推式知识推理 9
2.1.2 归纳式知识推理 10
2.2 知识图谱异质信息表示与融合 11
2.2.1 基于距离和相似度的方法 11
2.2.2 基于图神经网络的方法 13
2.2.3 基于预训练语言模型的方法 14
2.3 知识图谱自监督学习方法 16
2.3.1 生成式自监督学习 16
2.3.2 对比式自监督学习 17
2.4 本章小结 18
第 3 章 基于 schema 增强的多层级对比学习知识推理 **19**
3.1 引言 19
3.2 上下文 schema 构建 21
3.3 多视图实体编码 22
3.3.1 结构视图实体编码器 22
3.3.2 上下文视图实体编码器 23
3.4 多层级自监督对比预训练 23
3.4.1 上下文层级对比学习 23
3.4.2 全局层级对比学习 25
3.5 知识推理的预训练与微调范式 25
3.6 实验设计与结果分析 26

3.6.1 实验任务与数据.....26
3.6.2 实验设置.....28
3.6.3 对比实验结果.....30
3.6.4 消融实验.....31
3.6.5 模型性能分析.....32
3.6.6 案例分析.....35
3.7 本章小结.....36
第 4 章 语义增强的对比历史建模的时序知识推理.....37
4.1 引言.....37
4.2 基于预训练语言模型的双塔推理模型.....38
4.3 文本表示与输入模板构建.....39
4.3.1 实例描述文本组成.....39
4.3.2 融合时序上下文的输入模板.....40
4.4 时序文本编码与高效前缀微调.....40
4.5 负样本构造与对比学习训练目标.....41
4.6 实验设计与结果分析.....42
4.6.1 实验任务与数据.....42
4.6.2 实验设置.....44
4.6.3 对比实验结果.....46
4.6.4 消融实验.....49
4.6.5 模型性能分析.....51
4.7 本章小结.....55
第 5 章 总结与展望.....56
5.1 本文总结.....56
5.2 未来展望.....57
参考文献.....59
致谢.....71
附录 A：个人简历.....73
附录 B：在学期间参与的科研项目.....74
附录 C：在学期间取得的学术成果.....75

第 1 章 绪　论

1.1 研究背景与意义

知识图谱[1]（Knowledge Graph，KG）是一种高效的知识表示形式，将现实中的知识通过节点及节点间关系组成图来进行结构化的表示，经典的公开知识图谱包括了 Freebase[2]、DBpedia[3]和 YAGO[4]等。一方面，知识图谱以图的形式将抽象的知识形象化的表示，从而更直观地展示出知识的结构和内容，同时利用高效的图算法可以完成对知识的检索查询等任务[5]；另一方面，知识图谱作为知识的存储形式，可以作为辅助信息来辅助其他知识密集型任务，如在电商系统中，通过对用户偏好图谱的构建可以更好预测用户的购买意向进行相关商品推荐[6]，从而收获更好的经济效益。

随着神经网络模型的提出及其快速发展，它们凭借强大的自学习能力，在多个研究领域取得了显著的成就。然而，知识图谱的图结构不能作为神经网络模型的直接输入，如何将知识图谱中实体、关系和三元组中的丰富知识通过低维编码进行有效的表示，是知识表示学习[7]（Knowledge Representation Learning，KRL）领域的主要研究目标。在知识表示学习的研究基础上，基于知识图谱的知识推理[8]（Knowledge Reasoning，KR）旨在利用知识图谱中的信息图结构、文本等特性来填补知识图谱中的空缺的实体和关系，从而推导出新的知识或验证某些假设，进而实现知识图谱补全[9]（实体预测、关系预测、三元组分类），在相关下游应用如推荐系统[10]、知识问答[11]中有着广泛的应用。

知识图谱作为多关系异质图，具有丰富的异质信息，包括知识图谱自身的图结构、本体、实体类型以及描述文本等，如何利用这些潜在的辅助信息来增强实体和关系的表示，是实现高效知识推理的必需环节。为了将知识图谱中丰富且异质的信息有效利用起来，现有方法进行了各方面的探索与尝试。第一类是基于距离和相似度的传统三元组建模方法[12,13]，这类方法针对单个三元组，使用基于距离或基于语义匹配的假设对三元组进行打分，学习三元组中实体和关系的嵌入表示，从而实现对单个三元组关联信息的捕获。第二类方法旨在利用图神经网络对知识图谱自身的图结构属性进行挖掘[14]，通过消息传递机制融合实体邻域信息，从而使得模型能够更好地捕获知识图谱中的结构信息。此外，随着预训练语言模型相关技术的不断研究和突破，学者们开始尝试借助预训练语言模型在文本层面的高效建模能力[15,16]，利用名称、描述文档等文本来建模实体和关系的表示，从而完成知识推理相关任务。然而，现阶段的方法大部分仅集中于对知识图谱中单个三元组中的信息进行建模和学习，缺乏对知识图谱中结构特征、上下文知识和

文本语义等异质信息的建模，以及异质信息之间的融合。如何有效地捕捉和融合知识图谱中的各类异质信息，仍是一个亟待解决的问题。

此外，知识图谱中的数据分布通常是多样化和不均匀的。在实际应用场景中，知识图谱的规模经常处于不断更新的状态，其内部的实体和关系也在不断地被引入和更新[17]，此类具有时间敏感特性的知识图谱被称作时序知识图谱[18]（Temporal Knowledge Graph，TKG）。一方面，针对时序知识图谱上的推理任务，需要模型能够有效地捕捉并建模其时间序列特征[19]；另一方面，时序知识图谱中不断更新的实体，引入了更复杂场景下的少样本归纳式知识推理任务[20,21]。现有的时序知识推理方法通常需要针对不同类型的任务、以及不同的数据分布情况去设计具有特定架构的模型，这导致了同一模型难以在不同类型的任务和不同分布的数据上进行迁移和泛化。如何在不同的数据分布和任务背景设定下，进行高效且有效的推理，就成为了现实需要及未来发展的亟待完善和解决的难题。

综上，论文聚焦于基于知识图谱的知识推理任务，从知识图谱中的异质知识融合角度出发，研究如何有效建模和融合知识图谱中的上下文语义信息与结构知识，以及针对动态变化的时序知识图谱，如何捕捉其中的时序历史信息并与文本语义进行融合，以完成不同场景设定下的知识推理任务。

1.2 国内外研究现状

知识图谱这一概念由 Google 在 2012 年提出，它是一个多关系的图网络，基本组成单位是（头实体，关系，尾实体）三元组以及相关的属性键值对，实体间通过关系相互连接，构成网状的知识结构。不同于文档文本等非结构化数据，知识图谱中包含了丰富的语义知识和结构知识，如何有效地从中提取有用的知识，应用到下游任务当中，是知识图谱相关研究的主要目标。现阶段，知识图谱领域研究中最关键的部分是知识表示学习，如何对知识图谱中的实体和关系进行表示，以及如何将知识图谱中各类异质信息进行捕捉和融合，是知识表示学习的关键，也是完成有效知识推理的关键步骤。本小节将从知识表示学习与推理、知识推理中的异质信息融合两个方面对国内外研究现状进行介绍。

1.2.1 知识表示学习与推理

知识表示学习旨在将知识图谱中包含实体和关系的三元组嵌入到低维的连续向量空间中，将高维的图结构降维便于操作计算的同时，还能够保留图谱的隐含结构信息。通过这种方式，模型能够有效地编码实体和关系之间的潜在语义关系，进而完成知识推理任务。现有方法主要包含基于距离的翻译模型 TransE[12]、TransR[22]和 RotatE[23]，它们将关系建模为从头实体到尾实体的翻译操作，使用

基于距离的打分函数，从而建模每一个三元组在低维向量空间层面的距离差。另一种基于相似度的语义匹配模型，它们通过匹配实体和关系间的语义结构的相似性来衡量三元组事实的合理性，主要包括 RESCAL[24]、DistMult[13]、QuatE[25]等。为了更好地捕获知识图谱中丰富的结构信息，图神经网络（Graph Neural Network，GNN）的方法逐渐被运用到知识图谱的表示学习中，此类方法的核心思想是通过消息传递机制来聚合实体邻域结构的各种信息。其中，经典方法例如 R-GCN[14]和 CompGCN[26]均采用图卷积网络[27]（Graph Convolutional Network，GCN）来对多关系知识图谱建模。尽管这些方法在图结构信息的建模方面取得了进展，它们往往只专注于图结构本身，而忽略了知识图谱中的其他特征信息，如文本描述和本体类型等，这种偏颇的关注点限制了模型在表示学习任务中实现更优的效果。此外，这类方法在很大程度上依赖于知识图谱的结构完整性，面对较为稀疏的知识图谱，传统的基于图结构的方法难以捕捉到充分的局部邻域信息，从而影响模型的性能。

近期，一些学者开始探索使用 Transformer[28]模型架构来对知识图谱中的实体与关系进行建模，以完成知识推理任务。它们主要从模型结构、Attention 计算以及知识引导的掩码策略层面来改进模型：HittER[29]设计了多层级的 Transformer 从上下文和实体两个层面来平衡图结构与语义信息。Kformer[30]考虑到 Transformer 的前馈网络（Feed Forward Network，FFN）中的知识神经元负责表达事实知识这一特性，充分融合预训练语言模型中的蕴含知识以及在 Transformer 的 FFN 层中注入的外部知识。KgTransformer[31]提出了基于 Transformer 的 GNN 架构，将两类模块融合到一起，并通过两阶段的图预训练策略来训练模型。

上述方法通常只对知识图谱中的局部三元组与图结构信息进行建模，缺乏对其他类型的异质信息建模，不能够充分捕获和利用知识图谱中的潜藏知识，因此难以完成高效的知识推理。

1.2.2 异质信息融合的知识推理方法

知识图谱中蕴含了丰富的结构与文本语义信息，其中三元组以（头实体，关系，尾实体）的方式直接地建模了实体与关系之间的局部信息。除此之外，知识图谱中还有各类异质信息能够被进一步地挖掘。现阶段的研究工作，根据融合信息的类型，可以大致划分为建模本体类型信息、结构信息、文本信息与时序历史信息四个方面：

（1）融合本体类型信息的方法

大规模知识图谱如 DBpedia 和 Wikidata，包含了高阶层面的本体与 schema 信息[32]。知识图谱模式（Schema）是知识图谱中对实体和关系的高阶语义表示，

能够表达出概念层面的高阶元信息，能够提供全局层面的语义信息。为了能够将此类信息更高效地利用起来，TKRL[33]直接利用实体类型中的丰富信息来增强实体的特征表示。JOIE[34]将本体类型视作结点，元关系视作本体之间的关系，建立起了一个本体层面的视图，将知识图谱和本体分别嵌入到两个嵌入空间中，并通过跨视图关联使它们能够相互之间进行特征传递和增强。OntoEA[35]提出了本体引导的实体对齐方法，将知识图谱及其本体联合嵌入，并利用类别层次信息和类别的不相交性来避免错误映射。AutoETER[36]不依赖明确的预定义类型，而是自动学习类型表示来对所有关系模式进行推理。这些基于本体和实体类型信息的方法能进一步捕捉知识图谱本体层面的高阶元信息，却难以捕捉知识图谱中的上下文语义和模式信息。

（2）融合结构信息的方法

知识图谱中的知识以三元组的形式进行存储，可以被看作具有多类型结点的多关系网络，因而天然地具有图结构性质。随着图神经网络在自然语言处理等相关领域大放异彩，学者们开始尝试利用图神经网络来建模和捕获知识图谱中的局部结构信息[37]。KBGAT[38]利用图注意力网络，为邻居节点分配不同的权重，在每层图神经网络中传播节点注意力，以将不同关系的信息整合到中心实体嵌入中，并且通过关系组合在知识图谱中添加辅助边帮助特征信息传播，实现对多条关系的建模。R-GCN[14]将知识图谱建模为一个多关系图，对不同类型的关系分别学习一个权重矩阵，在进行消息传递的时候，分别对属于同一关系类型的邻居聚合，然后再对不同关系之间的特征进行聚合，从而实现多关系特征的融合。CompGCN[26]在消息传递的过程中同步地学习实体和关系的嵌入，利用参数分解方法使模型具备多关系的可扩展性，从而实现对知识图谱中多关系结构信息的捕获和建模。

（3）融合文本语义信息的方法

知识图谱中的实体和关系具有丰富的描述文本，此类信息并不能够直接被传统的知识图谱嵌入模型利用。为了提取实体和关系文本中丰富的语义特征信息，学者们尝试利用预训练语言模型来对知识图谱进行编码[39]。KG-BERT[15]将知识图谱三元组转化为文本句子作为 BERT[40]模型的输入，使用 BERT 输出的分类标签作为整个三元组的表示向量，再通过分类层实现对三元组的打分。KEPLER[41]将预训练语言模型的预训练损失和知识图谱表示学习的三元组损失整合到一起，联合训练知识表示和语言建模目标，从而实现文本语义与知识的融合。CoLAKE[42]则从大规模知识库中提取实体的知识上下文，考虑到知识上下文与语言上下文之间的异构性，将这两种上下文整合到一个统一的词-知识图表示中，随后采用改进的掩码预测训练策略，学习文本与知识的语境化表示。KG-S2S[43]

利用生成式语言模型，将具有不同类型与结构的知识图谱三元组转换为统一的文本格式，将知识图谱补全任务转化为“文本到文本”的生成式任务，直接使用语言模型生成待预测的目标实体文本。CSProm-KG[44]将实体、关系的嵌入与文本一同输入预训练模型，在冻结语言模型参数的情况下，仅对实体和关系嵌入进行学习，然后再利用图神经网络对输出的实体关系嵌入进行更新，以有效地平衡结构信息与文本信息。KoPA[45]基于生成式大语言模型架构，将知识图谱中的图结构知识通过前缀适配器注入语言模型，通过生成式的方法实现知识推理任务。

（4）融合时序历史信息的方法

在实际应用场景中，知识图谱是动态更新和变化的。为了在这类时序知识图谱上完成时序推理任务，关键在于捕获图中随时间变化的历史信息和演变模式。目前的研究工作集中在设计具备时间感知能力编码器，这类编码器能够结合已知的历史信息，并从待推理的三元组邻域中挖掘出时间演变的规律。CyGNet[46]分析发现知识图谱中的事实在时间轴上往往展现出重复出现的现象，因此提出基于时间感知的复制-生成机制，从而捕捉知识图谱随时间变化的动态特性。RE-GCN[47]提出了基于图卷积网络的递归进化模型，专注于通过当前知识图谱的序列化表示，学习实体和关系在各个时间戳上的演化，进而模拟出实体和关系随时间的演变过程。CE-NET[48]利用对比学习方法来学习历史和非历史依赖关系，以从给定查询中区分出最可能匹配的目标实体。此外，受预训练语言模型启发，现有的一些方法尝试利用预训练语言模型来建模和捕获时序知识图谱中潜在的时序关联。PPT[49]通过手工设计包含事实四元组文本的输入提示，利用预训练语言模型来捕获四元组之间的时序关联，并将时序知识推理任务转化为了掩码预测任务。SST-BERT[50]设计了时间引导的掩码策略以从头训练整个预训练语言模型，从而利用语言模型捕获时间序列信息；ECOLA[51]通过联合优化知识文本预测损失和时序知识表示损失，以将时序知识中的时间信息与预训练语言模型中的文本信息进行融合。

上述现有的融合异质信息的知识推理方法，集中于对单类信息进行建模和学习，没有考虑对多种类型信息的特征进行平衡。并且，现有模型需要针对特定的任务场景设计特定的模型结构以及特定的训练策略，因此难以完成高效的知识推理。

1.3 主要研究内容

论文针对知识推理这一任务，聚焦于对知识图谱中的结构特征、上下文知识、文本语义和时序历史等异质信息进行高效融合，分别在多关系图神经网络和预训练语言模型的基础上，提出特定的对比式自监督学习的模型框架，设计特定的对

比训练目标，让模型能够捕获知识图谱全局结构与上下文语义信息，完成在不同场景下的知识推理任务。如图 1.1 所示，论文的研究内容可以划分为两大部分：

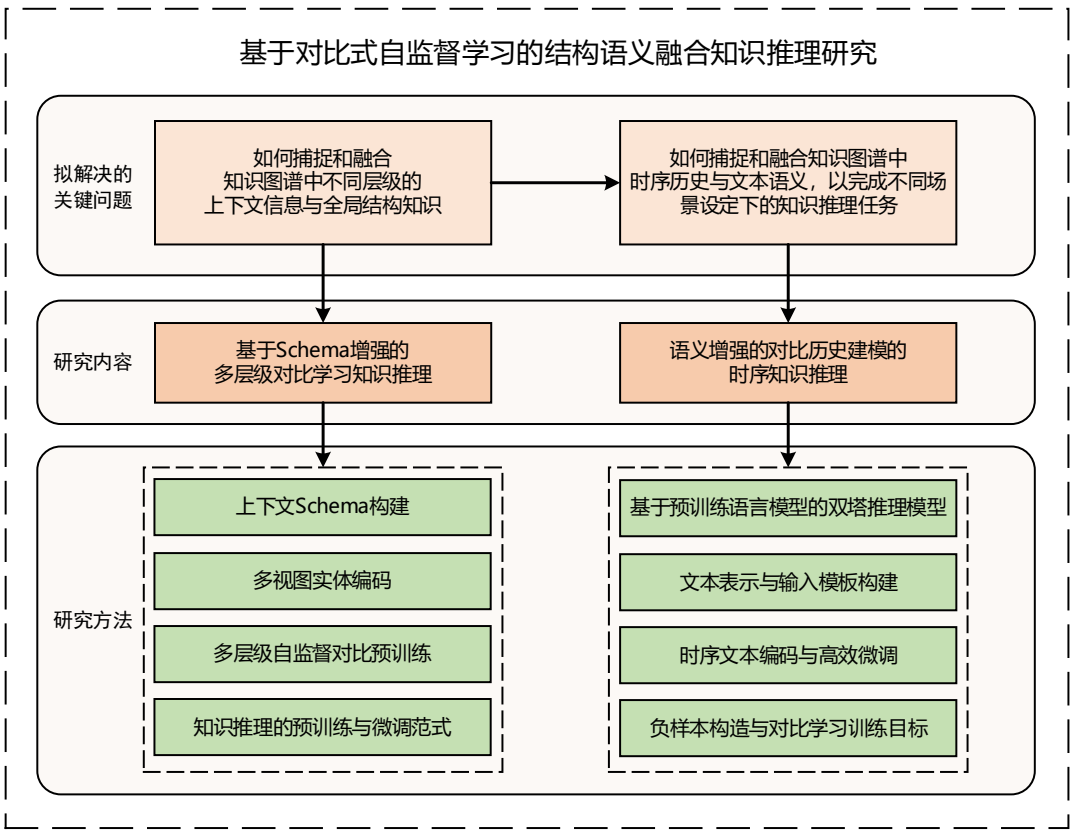


图 1.1 论文整体研究内容组织结构图

（1）基于 schema 增强的多层级对比学习知识推理

针对如何有效建模和融合知识图谱中的上下文语义信息与结构知识的问题，本章利用知识图谱 schema 来表征上下文语义，设计基于 schema 指导的多层级对比学习方法，在 schema 的约束下构建正负样本对，通过对比信息估计优化的方式对知识图谱中的全局结构与上下文语义知识进行融合，实现高效的实体和关系表征建模，从而增强模型的知识推理能力。此项研究工作的创新点可以概括如下：

1）提出了有效的上下文语义表示方法。使用知识图谱中的 schema 信息作为上下文语义的表征，能够更有效地捕获知识图谱中的高阶概念与元信息。

2）提出了知识图谱自监督对比学习策略。利用 schema 作为指导，从全局层级和上下文层级采样正负样本，并提出了多层级的对比优化目标，实现对局部上下文和全局结构信息的融合，学习更丰富的实体表征。

（2）语义增强的对比历史建模时序知识推理

针对如何有效融合知识图谱中的时序历史与文本语义知识，并实现各种复杂场景下的时序知识推理的问题，本章设计基于预训练语言模型的双塔推理模型，

将知识推理任务转化为查询-候选匹配任务。构造融合时序历史的文本模板作为输入，结合时序文本编码，通过对比学习的方法进行对比信息估计目标优化，更好地融合与平衡时序历史信息和文本语义信息。通过虚拟时间前缀微调的方式，将模型泛化到不同场景下（例如直推式和归纳式）的时序知识推理任务上。此项研究工作的创新点可以概括如下：

1）提出基于预训练语言模型的双塔推理模型：将知识推理任务转化为查询项-候选项匹配任务，利用双塔推理模型分别对四元组查询项和候选项进行编码，同时在输入模板中融入历史上下文，实现对时序历史信息的有效建模。

2）提出双塔模型负采样和自监督对比学习方法：对于一个四元组中的查询项，分别采样批次内、批次外和自负样本，构成整体的负样本集合。使用 InfoNCE 对比信息估计损失优化目标，实现更有效的对比学习，使得模型能够有效融合和平衡时序历史信息与文本语义信息。使用基于虚拟时间前缀的高效微调方法对模型进行微调，以此实现模型在复杂场景下的时序知识推理任务上的泛化。

1.4 论文的组织结构

论文共分为五章，每个章节的内容组织安排如下：

第一章为绪论。首先阐述本文课题的背景和意义，总结分析了当下国内外在知识图谱领域，关于知识表示学习和推理，以及知识图谱中异质信息融合这两个方面的研究现状，分析了当下研究的主要集中点以及挑战，然后引出并介绍了论文的具体研究内容，阐释了论文研究的必要性，最后概述了论文的内容组织安排。

第二章为相关理论和技术，主要介绍知识推理研究领域涉及到的相关基础理论与技术，具体包括知识推理任务定义、知识图谱异质信息表示与融合以及知识图谱自监督学习，是第三章和第四章的支撑基础。

第三章介绍论文提出的基于 schema 增强的多层级对比学习知识推理方法。本章以知识图谱中图结构信息与上下文语义信息融合这一难题为切入点，依次介绍了方法的主要框架与技术细节：提出了有效的上下文语义表示方法，将对比式自监督方法引入知识图谱，设计了多层级自监督对比预训练策略，提出了知识推理的预训练-微调范式，并在知识图谱相关数据集上开展了充分的实验，对结果进行了严谨的分析。

第四章介绍论文提出的语义增强的对比历史建模时序知识推理方法。本章聚焦于解决时序知识图谱中的时序历史信息与预训练语言模型中的文本语义信息融合的问题，首先介绍基于预训练语言模型的知识图谱双塔推理框架，使用预训练语言模型来建模知识图谱中的实体和关系表示。然后介绍输入模板构造方式，阐述如何将知识图谱中的四元组转化为输入文本，以及如何在输入文本中融入历

史时序信息；随后，介绍时序文本编码方式和高效前缀微调方法；然后介绍负样本的构造方法，以及具体的对比自监督训练目标。最后，在直推式和少样本归纳式的时序知识推理任务上展开了具体的实验，并对实验结果进行了具体的分析。

第五章为总结与展望。总结部分对论文的研究动机、模型方法与设计、实验效果等研究内容进行了回顾；展望部分对未来在知识推理任务上的可改进方向，以及值得探索的方向进行了展望。

第 2 章 相关理论与技术

知识图谱蕴含了大量的世界知识和领域知识，能够为众多的下游任务提供有效理论和技术支撑。对知识图谱中的知识进行有效的表示，能够实现高效可靠的知识推理。基于知识图谱的知识推理是本文研究的主要内容。因此，本章首先对知识推理任务进行了详细的阐释和定义，针对论文中涉及的相关理论与技术进行详细介绍，包括基于距离和相似度的知识表示技术、基于图神经网络的知识表示技术、基于预训练语言模型的知识表示技术和知识图谱自监督学习等。

2.1 知识推理任务定义

知识推理任务在知识图谱领域中扮演着核心角色，它指的是利用知识图谱中的信息图结构、文本等特性来填补知识图谱中的空缺的实体和关系，来推导出新的知识或验证某些假设的过程。知识推理使得知识图谱不仅能够存储和检索知识，还能够模拟人类的逻辑推理能力，从而扩展和丰富已有的知识体系。具体地，知识推理方法可以被细分为基于符号的推理和基于表示学习的推理。论文探讨的是基于表示学习的推理方法，通过为知识图谱中的每个实体和关系都学习一个向量表示，实现链接预测、三元组分类等知识补全任务。依据知识图谱中实体是否更新，测试集中是否存在训练集未见的实体，可以进一步划分为直推式知识推理和归纳式知识推理。

2.1.1 直推式知识推理

直推式知识推理主要关注于利用已有的知识图谱数据来推导出新的知识。根据直推式任务的定义，知识图谱测试集中的实体和关系均在训练集中出现过。这类方法通常假设知识图谱中存在某种模式或规律，通过学习这些模式，可以对未知的事实进行推理和预测。在直推式知识推理中，常见的任务包括链接预测、实体预测、关系预测和属性预测。这些任务的目标是通过分析知识图谱中已有的三元组（头实体，关系，尾实体）来推断出新的三元组或补全已有三元组中缺失的部分。

具体地，将一个完整的知识图谱定义为$\mathcal{G}=(\mathcal{E},\mathcal{R},\mathcal{F})$，其中$\mathcal{E}$表示知识图谱中的所有实体构成的集合，$\mathcal{R}$表示所有关系构成的集合，$\mathcal{F}$是知识图谱中所有三元组的集合，用$\mathcal{F}=\{(h,r,t)\big|h,t\in\mathcal{E},r\in\mathcal{R}\}$表示。直推式知识推理旨在学习一个固定大小的实体特征矩阵$E\in\mathbb{R}^{|\mathcal{E}|\times d}$以及固定大小的关系特征矩阵$R\in\mathbb{R}^{|\mathcal{E}|\times d}$，在实体特征矩阵$E$和关系特征矩阵$R$中查询实体和关系向量，然后使用一个知识图

谱嵌入模型对三元组进行打分，基于正确三元组$(h,r,t)\in\mathcal{F}$的得分通常高于错误三元组$(h',r,t')\notin\mathcal{F}$的得分这一假设，实现知识推理这一目标。

根据以上任务定义，现有的直推式学习的方法可以分为基于规则的推理、基于分布式表示的推理和基于神经网络的推理。基于规则的推理依赖于定义好的逻辑规则，在知识图谱上枚举关系路径作为候选逻辑规则，包括马尔可夫逻辑网络[52]等；而基于分布式表示的推理则通过分别学习实体和关系的低维向量表示来进行关系和实体的预测，包括基于距离的翻译模型 TransE[12]和基于张量分解的RESCAL[24]等。基于神经网络的推理利用神经网络的强大学习能力来处理复杂的推理任务，例如 CompGCN[26]设计了多关系图神经网络来同时学习知识图谱中的实体和关系特征，KG-BERT[15]利用预训练语言模型建模知识图谱文本语义信息。

然而，直推式方法专注于对实体信息建模，在固定的知识图谱上进行训练，以学习训练图中已存在的实体的向量表示。当在测试场景中引入未见实体时，此类方法无法生成未见实体的向量表示。因此，它们无法泛化到包含未见实体的新知识图谱，无法完成包含未见实体的知识推理任务。

2.1.2 归纳式知识推理

区别于直推式知识推理方法，归纳式知识推理指的是知识图谱测试集三元组中的实体均为训练集中未曾出现过的实体。归纳式的方法可以在包含未见实体的新知识图谱上实现知识推理，因为此类方法专注于利用于与不耦合于具体实例实体的信息来建模实体特征，更加注重从数据中提取普遍性的规律，从而能够推广到新的、未见过的实例上。具体地，给定一个源域知识图谱$\mathcal{G}_s=(\mathcal{E}_s,\mathcal{R}_s,\mathcal{F}_s)$和一个目标域知识图谱$\mathcal{G}_t$，其中目标域知识图谱$\mathcal{G}_t$中的实体均未在源域知识图谱$\mathcal{G}_s$中出现过，具体定义如公式(2-1)所示：

$$\begin{aligned}&\mathcal{G}_t=(\mathcal{E}_t,\mathcal{R}_t,\mathcal{F}_t)\\&\text{s.t. }\mathcal{E}_t\cap\mathcal{E}_s=\varnothing,\mathcal{R}_t\subseteq\mathcal{R}_s.\end{aligned}\tag{2-1}$$

对于目标域知识图谱中的一个测试三元组$(h_t,r_t,t_t)\in\mathcal{F}_t$，归纳式知识推理任务的目标是：在源域知识图谱$\mathcal{G}_s$上学习一个可以捕获和建模可迁移特征的知识嵌入模型$f$，然后能够泛化到目标域知识图谱上，编码得到未见实体的特征向量，从而实现对三元组正确与否的预测。

基于以上任务定义，现有的归纳式知识推理方法可以被划分为基于规则的方法和基于图神经网络的方法。基于规则的方法在原始知识图谱中提取通用的、与实体无关的逻辑规则，以泛化到新知识图谱，通常具有良好的可解释性。NeuralLP[53]学习逻辑规则和置信度，采用端到端的可微学习方式，此类方法通常受到计算效率低下和可扩展性差的限制。另一类基于图神经网络的方法，其对节

点自身的特征不敏感，因此具有良好的归纳推理能力。GraIL[54]提取封闭子图，使用双半径标记法来学习与实体实例无关的局部结构信息。SNRI[55]为了充分探索图神经网络的归纳能力，利用完全邻近关系和互信息最大化来克服部分关系被忽视和稀疏子图难以处理的问题。

2.2 知识图谱异质信息表示与融合

知识表示学习旨在学习将知识图谱中的符号（例如，实体和关系）与三元组映射到一个低维的向量空间。其优点在于学习得到的向量是连续的，且可以发掘隐藏的性质。此外，在向量空间中计算相似度是十分高效的。由于知识图谱中蕴含有大量的异质知识信息，根据所学习的知识类型，可以将现有的知识图谱表示学习方法划分为三类：基于距离和相似度的方法、基于图神经网络的方法和基于预训练语言模型的方法。

2.2.1 基于距离和相似度的方法

基于平移距离的模型如 TransE，其核心思想是将知识图谱中的三元组（头实体 h，关系 r，尾实体 t）建模为“从头实体经过关系在一个具体向量空间下平移后得到尾实体”这样的一个翻译过程。结合基于距离的打分函数，模型能够对于每一个三元组得到一个在向量空间层面的距离差。具体地，TransE 模型将基于距离的打分函数定义为 $f(h,r,t)=\|h+r-t\|_{l1/l2}$，其中距离的大小可以采用 L_1 范数或者 L_2 范数来进行度量，如公式(2-2)所示：

$$\begin{aligned} f_{l1}(h,r,t)&=\sum_{i=1}^{n}\left|h_i+r_i-t_i\right|, \\ f_{l2}(h,r,t)&=\sum_{i=1}^{n}(h_i+r_i-t_i)^2. \end{aligned} \tag{2-2}$$

其中 n 表示向量特征维度。

模型的学习目标是使得正确的三元组在向量空间上的距离尽量小，错误三元组的距离尽量大，因此模型的基于边际的损失函数具体如公式(2-3)所示：

$$\mathcal{L}=\sum_{(h,r,t)\in S}\sum_{(h',r,t')\in S'_{(h,r,t)}}\left[\gamma+f(h+r,t)-f\left(h'+r,t'\right)\right]_+, \tag{2-3}$$

其中，γ 是边际系数，S 表示知识图谱中真实存在的三元组集合，(h,r,t) 表示单个真实存在的三元组，S' 表示对照（损坏）三元组集合，它的每一项是由 S 中的某项通过替换头实体或尾实体构造出来的，并且三元组中的头尾实体不可同时被替换。具体地，S' 可以被表示为公式(2-4)的形式：

$$S'_{(h,r,t)}=\{(h',r,t)|h'\in\mathcal{E}\}\cup\{(h,r,t')|t'\in\mathcal{E}\},\tag{2-4}$$

其中，$\mathcal{E}$ 代表知识图谱中实体的集合。

在此基础上，TransE 的衍生模型 TransH[56]通过将知识图谱中的关系抽象成向量空间的超平面，在不同的超平面上编码不同的实体向量，从而消除 TransE 模型在处理一对多、多对一、多对多复杂关系时的局限性。具体地，关系超平面由平面法向量 ω_r 和平面上的平移向量 d_r 表示，给定一个三元组 (h,r,t)，将头实体 h 和尾实体 t 映射到关系特定的超平面上，从而得到映射向量 $h_\perp$ 和 $t_\perp$，具体如公式(2-5)所示：

$$\begin{aligned}h_\perp&=h-\omega_r^T h\omega_r,\\ t_\perp&=t-\omega_r^T t\omega_r,\end{aligned}\tag{2-5}$$

其中 $\omega_r^T h=|\omega||h|\cos\theta$ 表示头实体 h 在 ω_r 方向上投影的长度。结合实体映射向量、平面法向量和平移向量，可以利用打分函数得到三元组的距离分值，如公式(2-6)所示：

$$f(h,r,t)=\left\|\left(h-\omega_r^T h\omega_r\right)+d_r-\left(t-\omega_r^T t\omega_r\right)\right\|_2^2.\tag{2-6}$$

对于基于语义匹配的模型,如 RESCAL，将每个实体与一个向量相关联，每个关系都表示为一个矩阵，它模拟了潜在因素之间的成对相互作用，其核心理念在于采用多项式函数作为距离度量，借助张量分解技术，利用语义匹配来评估事实的可信程度，从而捕获实体间的语义联系。具体地，RESCAL 模型定义了一个张量 $\mathcal{X}$，每个关系对应于张量中的一个矩阵切片，代表图的邻接矩阵，其中元素为 1 的位置代表两个实体之间存在对应关系，反之为不存在。对张量 $\mathcal{X}$ 进行如公式(2-7)所示的分解：

$$\mathcal{X}_k\approx AR_kA^T,\ for\ k=1,...,m.\tag{2-7}$$

其中，A 是维度为 $n\times r$ 的矩阵，代表每个实体的隐层表示，R_k 是维度为 $r\times r$ 的非对称矩阵，用来表示第 k 个关系中实体之间的交互作用，可以建模非对称关系。矩阵 A 和 R_k 通过求解约束最小化问题来计算，如公式(2-8)所示：

$$\min_{A,R_k} f(A,R_k)+g(A,R_k).\tag{2-8}$$

在此基础上，DistMult 对 RESCAL 进行了简化，将 M_r 限制为对角矩阵。而 ComplEx[57]模型则将实体向量与关系矩阵所处的空间从实数域扩展至复数域,有效解决了 DistMult 无法对非对称关系进行建模的问题。QuatE[25]是 ComplEx 在超复数空间的拓展，通过在四元数空间为实体、关系建模，将关系建模为四元数空间上的旋转操作，以此提供更好空间解释。

基于距离的翻译模型和基于相似度的语义匹配模型同属浅层的基于嵌入的

模型范畴，但在对关系矩阵的建模方式上存在差异。这两类模型的参数量相对较少,可以保证较高的计算效率，并且在特定领域内展现出不错的表达能力。然而，面对多种多样的下游任务，它们均无法在所有任务中均优于其他同类型方法，导致其泛化能力不足。

2.2.2 基于图神经网络的方法

传统的表示学习方法针对单个三元组进行优化，无法表达丰富的语义信息和结构信息。随着图神经网络在表示学习领域的兴起，鉴于知识图谱自身特有的图结构属性，有学者提出了基于图神经网络的知识表示学习方法，此类方法的关键在于利用消息传递机制来综合利用和学习邻域的结构信息。对于每个图神经网络层，其都可以被写成一个非线性函数，如公式(2-9)所示：

$$H^{(l+1)} = f\left(H^{(l)}, A\right), \tag{2-9}$$

其中，$H^{(0)} = X$ 代表节点层级的输入（$N \times D$ 维特征矩阵，N 表示节点数量，D 表示输入特征数量），$H^{(L)} = Z$ 代表节点层级的输出（$N \times F$ 维特征矩阵，F 表示每个节点的输出特征数），L 表示模型层数。在图神经网络上，层级内的传播规则形式可以如公式(2-10)定义：

$$f\left(H^{(l)}, A\right) = \sigma\left(AH^{(l)}W^{(l)}\right), \tag{2-10}$$

其中 $W^{(l)}$ 是第 l 层图神经网络的权重矩阵，$\sigma(\bullet)$ 表示 ReLU 非线性激活函数。为了将捕获图结构中的自循环关系，将单位矩阵加入到 A 矩阵，再对其进行对称归一化，如公式(2-11)所示，图神经网络的传播规则可以被更新表示为：

$$f\left(H^{(l)}, A\right) = \sigma\left(\hat{D}^{-\frac{1}{2}}\hat{A}\hat{D}^{-\frac{1}{2}}H^{(l)}W^{(l)}\right), \tag{2-11}$$

其中 $\hat{A} = A + I$，I 代表单位矩阵，$\hat{D}$ 代表 $\hat{A}$ 的对角节点矩阵。进一步地，从 Weisfeiler-Lehman 算法广义版本的角度来对公式(2-11)所表示的图神经网络模型进行解释：对于所有节点 $v_i \in \mathcal{G}$，首先得到所有领域节点 v_j 的特征向量 h_{v_j}，然后更新中心节点 v_i 的特征 $h_{v_i} \leftarrow \text{hash}(\sum_j h_{v_j})$，其中 $hash(\bullet)$ 代表一个单射哈希函数。Weisfeiler-Lehman 算法的具体原理如公式(2-12)所示：

$$h_{v_i}^{(l+1)} = \sigma\left(\sum_j \frac{1}{c_{ij}} h_{v_j}^{(l)} W^{(l)}\right), \tag{2-12}$$

其中 j 是中心节点 v_i 的领域节点映射，c_{ij} 是边 (v_i, v_j) 的归一化常量，对应于 GCN 模型中的对称归一化邻接矩阵 $\hat{D}^{-\frac{1}{2}}\hat{A}\hat{D}^{-\frac{1}{2}}$。

得益于图神经网络的对图数据的优秀建模能力，R-GCN 将知识图谱建模为

多关系图，利用图卷积网络对关系数据进行建模，在知识图谱中加入关系特定的参数矩阵，并在消息传递的过程中增加了一个聚合关系的维度，使得节点的聚合操作变成一个双重聚合的过程。第$l+1$层中第i个节点的向量$h_i^{(l+1)}$更新过程如公式(2-13)所示：

$$h_i^{(l+1)}=\sigma\left(\sum_{r\in\mathcal{R}}\sum_{j\in\mathcal{N}_i^r}\frac{1}{c_{i,r}}W_r^{(l)}h_j^{(l)}+W_0^{(l)}h_i^{(l)}\right), \tag{2-13}$$

其中$\mathcal{N}_i^r$表示通过关系r与节点i相连的邻居节点集合，$c_{i,r}=\left|\mathcal{N}_i^r\right|$表示边类型为$r$的邻居节点数量。

不同于 R-GCN 独立地建模节点和关系特征，CompGCN 提出节点和关系表征的组合方式，利用知识图谱中的组合操作同时学习实体和关系的嵌入，并利用参数分解方法使模型具备多关系的可扩展性，实现对多关系知识图谱的有效建模。这些基于图的方法能够进一步捕捉知识图谱中的关系和结构信息，但是它们难以建模实体邻域上下文中的语义信息。

2.2.3 基于预训练语言模型的方法

随着预训练语言模型（Pre-trained Language Model，PLM）在自然语言处理领域的高速发展，学者们开始将视野投向使用预训练语言模型来实现知识推理的相关任务。知识图谱中包含了大量的领域专家知识，而预训练语言模型中包含了丰富的通用世界知识，两者可以相互促进与利用。基于预训练语言模型的文本知识表示，通常将知识图谱中的三元组转化为文本输入语言模型，通过优化语言模型的掩码预测损失，以及知识图谱的三元组损失，实现文本知识的注入与融合。

KG-BERT 最早将 BERT 模型应用于知识表示学习领域，它将实体、关系和三元组视为文本序列，并将知识图谱补全任务转化为一个序列分类任务，然后利用转化后的序列来微调 BERT 模型，以实现三元组和关系的预测。如图 2.1 所示是 KG-BERT 模型的结构图，展示了其在三元组分类任务上的输入输出形式。具体地，为了将知识图谱三元组应用于预训练语言模型，在输入层面，首先将三元组转化为自然语言文本，将实体和关系表示为它们的名称或描述，然后将名称或描述词序列通过分隔符令牌连接起来，并且每个输入序列的第一个令牌为特殊的分类标记$[CLS]$。针对三元组分类任务，仅需要对分类层的参数$W\in\mathbb{R}^{2\times H}$进行微调。对于三元组$s_\tau=(h,r,t)$，评分函数为$f(h,r,t)=sigmoid(CW^T)$。给定正三元组$\mathbb{D}^+$和负三元组$\mathbb{D}^-$，可以计算模型的交叉熵损失如公式(2-14)所示：

$$\mathcal{L}=-\sum_{\tau\in\mathbb{D}^+\cup\mathbb{D}^-}\left(y_\tau\log\left(s_{\tau 0}\right)+\left(1-y_\tau\right)\log\left(s_{\tau 1}\right)\right), \tag{2-14}$$

其中y_τ是三元组的标签，1 代表正三元组，0 代表负采样三元组。

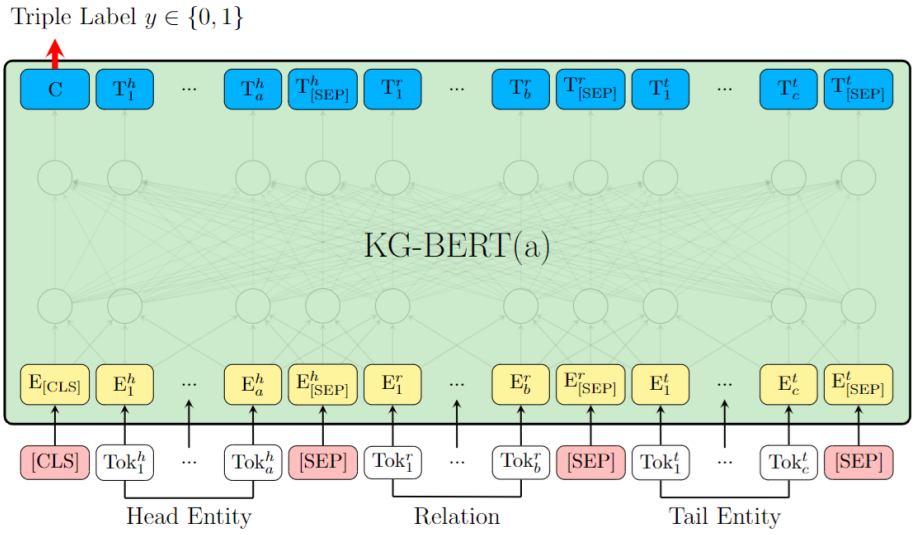


图 2.1　KG-BERT 模型结构图[15]

在此基础上，KEPLER[41]提出了知识图谱与预训练模型共同学习的框架，使用统一的 Transformer 编码器对实体描述等文本信息进行编码，并针对两个任务目标分别设计自监督预训练策略，使用联合预训练任务对编码器模型进行优化。具体地，模型多任务损失定义如公式(2-15)所示：

$$\mathcal{L} = \mathcal{L}_{KE} + \mathcal{L}_{LM}, \tag{2-15}$$

其中 $\mathcal{L}_{KE}$ 表示知识嵌入损失，$\mathcal{L}_{LM}$ 表示语言模型的掩码预测损失，由于语言模型同时参与了这两个任务，联合优化这两个目标可以隐式地将来自外部图的知识与文本编码器整合在一起。$\mathcal{L}_{KE}$ 遵循 RotatE 的知识嵌入损失，利用负采样进行高效优化，如公式(2-16)所示：

$$L = -\log\sigma\left(\gamma - d_r(h,t)\right) - \sum_{i=1}^{n}\frac{1}{n}\log\sigma\left(d_r\left(h_i',t_i'\right) - \gamma\right), \tag{2-16}$$

其中 (h,r,t) 为正确的三元组，(h_i',r,t_i') 为负采样三元组，γ 为边际参数，σ 为 sigmoid 函数，d_r 为距离评分函数 $d_r(h,t) = \| h + r - t \|_p$。

除此之外，近期许多方法尝试与其他类型的语言模型相结合，以及利用不同的结合方式来实现有效的知识表示。例如 KG-S2S[43]利用生成式语言模型，将知识图谱补全任务转化为“文本到文本”的生成式任务，直接使用语言模型生成待预测的目标实体文本。KoPA[45]基于大语言模型架构，将知识图谱中的结构知识通过前缀适配器在输入层面注入诸如 LLaMA[58]等大语言模型，以端到端生成式的方法实现知识图谱补全任务。基于文本的预训练语言模型方法，虽然能够很有效地建模文本语义信息，但是通常情况下知识的结构信息与文本语义信息缺乏有效对齐，并且依赖于高质量的文本信息，这导致此类方法难以适用于缺少实体描述文本的知识图谱上。

2.3 知识图谱自监督学习方法

传统的图神经网络应用遵循深度学习的经典范式，即面向特定任务使用大量标注数据训练模型，此类任务要求大量高质量的标注标签。为了让图神经网络具备知识迁移的能力，鉴于预训练模型在图像和语言领域取得的突破性成功，研究者将大量注意力转移到预训练图神经网络的研究上。区别于传统的自然语言文本，不同图之间的结构千差万别，利用自监督图模型对无标签的图数据进行预训练，能够有效减少对人工标签的依赖，然后预训练学习到的模型，可以被应用于只有少量标签数据的图相关下游任务。为了从大量无标注的数据中学习可迁移的知识，现阶段图预训练领域主要形成了两大研究范式：基于重构的生成式方法和最大化正例对与负例对差异的对比式方法。

2.3.1 生成式自监督学习

GPT[59]（Generative Pre-trained Transformer）是自然语言处理领域的生成式训练模型，预训练阶段通过大量语料进行无监督学习，预训练任务是自回归的生成任务。受生成式预训练语言模型启发，图神经网络上的生成式自监督模型，其通常做法是进行子图采样，然后基于预先设计好的生成式预训练任务进行自监督训练，从而捕获到图网络中属性与结构之间隐含的特征信息。

变分图自编码器[60]（Variational Graph Auto-Encoders，VGAE）提出了基于变分自编码器的图结构数据上的无监督学习框架，基于最基本的边重构思想，针对图结构数据，利用潜在变量学习无向图的可解释潜在表示。具体地，VGAE 包含了一个基于图卷积网络的编码器和一个基于内积的解码器，前者将映射输入图到一个更低的维度，后者用于从更低维度的嵌入来重构输入图。给定输入的节点特征 X 和图邻接矩阵 A，VGAE 使用两层的图卷积网络来计算得到均值 μ 和方差 $\log\sigma$，如公式(2-17)所示：

$$\begin{aligned} \mu &= GCN_{\mu}(X, A), \\ \log\sigma &= GCN_{\sigma}(X, A). \end{aligned} \tag{2-17}$$

根据均值 μ 和方差 $\log\sigma$，可以通过公式(2-18)计算得到图的隐层表示 z：

$$\begin{aligned} q\left(z_i \middle| X, A\right) &= \mathcal{N}\left(z_i \middle| \mu_i, \mathrm{diag}\left(\sigma_i^2\right)\right), \\ q(Z|X, A) &= \prod_{i=1}^{N} q\left(z_i \middle| X, A\right). \end{aligned} \tag{2-18}$$

然后，根据公式(2-19)计算隐层向量 z 之间的内积，得到重构后的图邻接矩阵：

$$
\begin{aligned}
p\left(A_{ij}=1\middle|z_i,z_j\right)&=\sigma\left(z_i^{\top}z_j\right),\\
p(A|Z)&=\prod_{i=1}^{N}\prod_{j=1}^{N}p\left(A_{ij}\middle|z_i,z_j\right).
\end{aligned}
\tag{2-19}
$$

在变分图自编码器的基础上，Hu 等人[61]首次提出预训练图神经网络模型，提出属性掩码和上下文预测两种预训练方法，在节点层面和全图层面同时学习，能够很好地得到图的局部和全局的表示。SS-GCNs[62]指出多任务学习优于“预训练-微调”和自训练范式，提出节点聚类、图分割、图补全三种自监督任务，并证明了自监督在不需要更大的模型或额外的数据的前提下，能够提高图网络在各种攻击下的鲁棒性。GPT-GNN[63]模型是自监督的生成式的预训练框架，设计了属性生成和边生成两个生成任务，掩码掉图结构中特定数量的节点或者边，通过剩余的已知节点和边结构来预测被掩盖掉的属性，从而捕获图谱内在固有的结构和语义等属性信息。

2.3.2 对比式自监督学习

对比学习是一种通过对比正样本和负样本之间的相似性来学习表示的有效技术，它已被广泛应用于许多不同的领域，包括无监督视觉表示、自然语言理解和句子嵌入等。最近，越来越多的学者将对比式自监督学习方法引入图表示领域。对比式图自监督学习方法的关键在于正例对和负例对的选择与构造，通常聚焦于节点、边、子图和全图层面。在确定好正负样例对之后，一般基于互信息来衡量正负样本之间的相似度，如公式(2-20)所示：

$$
\begin{aligned}
I\left[x;y\right] &= KL\left[p\left(x,y\right)|\,p\left(x\right)p\left(y\right)\right]\\
&=\mathop{\mathbb{E}}_{x,y}\left[log\frac{p\left(x,y\right)}{p\left(x\right)p\left(y\right)}\right]\\
&=\mathop{\mathbb{E}}_{x,y}\left[log\frac{p\left(x|\,y\right)}{p\left(x\right)}\right].
\end{aligned}
\tag{2-20}
$$

在实际实现过程中，一般选择使用 InfoNCE[64]损失函数作为模型对比优化目标，将其作为互信息的下界，通过最大化下界限来间接优化互信息，如公式(2-21)所示：

$$
\mathcal{L}_N=-\mathop{\mathbb{E}}_{x}\left[log\frac{f_\theta\left(x,y^{+}\right)}{f_\theta\left(x,y^{+}\right)+\sum_{i=1}^{K}f_\theta\left(x,y_i^{-}\right)}\right].
\tag{2-21}
$$

传统利用图结构数据进行无监督表示学习的算法主要依赖于基于随机游走

的目标，此类方法过分强调接近性信息，而牺牲了结构信息，并且方法的效果高度依赖于超参数的选择。DGI[65]提出了基于互信息估计的对比式自监督方法，通过“子图表示-全图表示”的对比学习，最大限度地扩大图增强表示和目前提取到的图信息之间的互信息，能够有效地适用于直推式学习和归纳式学习。为了不依赖于专门的编码器来学习图或节点级表示，Hassani 等人[66]将多视图增强方法应用于图数据，使用基于子图采样的多视图对比学习，最大化不同图结构视图表示之间的信息熵，在节点和图分类任务上均取得良好的效果。GraphCL[67]提出了图对比学习框架，利用四种针对图的数据增强方式，通过自监督方式，以最大化不同增强视图下的特征一致性作为对比学习目标，对图表示进行学习。

2.4 本章小结

本章对基于知识图谱的知识推理任务做出了详细定义，并详细介绍了知识推理相关理论和技术。首先，对直推式知识推理和归纳式知识推理任务做出了详细的定义；然后，对知识图谱异质信息表示与融合方法相关技术进行了阐述，介绍了基于距离和相似度的知识表示模型的结构与原理，基于图神经网络的知识表示模型的技术原理，以及基于预训练语言模型框架的知识推理模型技术细节与流程；最后，介绍了知识图谱自监督学习方法，阐述了生成式自监督与对比式自监督学习的技术细节，为论文第三章和第四章模型和实验设计提供了理论基础。

第 3 章 基于 schema 增强的多层级对比学习知识推理

论文前两章介绍了知识推理任务定义以及相关的技术理论，阐述了现有知识推理方法的研究现状。现有的知识表示方法难以针对各类信息进行有效建模并进行融合，导致知识推理的性能欠佳。在现有知识推理方法基础上，针对如何有效建模和融合知识图谱中的上下文语义信息与结构知识的问题，本章提出 schema 增强的多层级对比学习知识推理模型，构建和利用 schema 来表征知识图谱上下文语义信息，通过对比式自监督的优化目标，实现全局层级结构信息与上下文层级语义信息的融合，进而提高知识推理的能力。

3.1 引言

公开领域的知识图谱，例如 Freebase[2]和 DBpedia[3]等，除了包含大量的实体、关系三元组外，还包含了大量的图谱 schema、实体类别等本体层面的元信息。Schema 是知识图谱的模式和知识体系，是对知识图谱中的实体、属性及关系等知识数据的描述和定义，它构成了对知识图谱中高阶元信息和概念的抽象概括，能够对知识图谱中的实体和关系提供丰富的上下文语义信息。对于知识推理任务而言，上下文语义信息能够提供非常大的帮助，但其复杂且冗余的特性通常难以被直接加以利用。因此，如何有效地建模知识图谱中的上下文信息，提升实体和关系的表征能力，从而实现更有效地知识推理，是值得探索和解决的问题。

现阶段尝试融入高阶元知识来建模上下文语义的方法，通常是在本体视图对概念、类型等信息学习一个固定的特征嵌入，然后再通过特定的方式将本体视图的嵌入与实例视图的嵌入进行融合。TKRL[33]为了利用实体类型中丰富的信息，在构造实体的映射矩阵时考虑了类型限制，使用两个分层的类型编码器建模分层结构，并使用类型信息作为关系特定的类型约束。JOIE[34]对实例视图和本体视图分别单独进行表示，通过跨视图关联模型，使具有相同概念的实体在表示空间上距离更近，以此实现将本体视图和实例视图特征的相互融合。然而，现阶段此类型的方法缺少对实体邻域中的上下文信息的建模，忽略了不同上下文中实体表征的多样性，由此常常导致错误的推理结果。通常情况下，实体邻域上下文包含了子图特有的结构和语义信息，并且知识推理任务的效果极大程度上依赖于与特定实体和三元组相关的上下文语义。以知识图谱 Freebase[2]为例，数据集 FB15k 有 14579 个实体和 154916 个三元组，其中有 14417 个（98.89%）实体包含了一个及以上的类型信息，有两个以上类型信息的实体有 13853 个（95.02%），数据集中平均每个实体对应 10.02 个类型信息，实体众多的类型信息表明对知识图谱中上下文语义信息建模的必要性。

在实体和关系表征中捕获上下文知识的关键，在于如何精确表达和建模实体邻域子图的复杂上下文信息。简单地将实体子图中的所有信息作为上下文，可能会带来冗余的噪声信息。Schema 作为知识图谱的高阶元模式，包含实体和关系之间的类型约束，很好地表达了子图上下文中蕴含的结构信息和语义信息。此外，由于在不同的上下文中，同一个实体也会呈现出不同的特征信息，而 schema 精确定义了单个上下文子图中实体之间的类型关联与限制，因此它能够在特定的上下文中表达出实体的精确语义信息。在这种情况下，相同 schema 上下文中的实体在特征空间中通常具有更相近的特征表示，不同上下文中的实体则在特征空间中相距更远。

本章提出一种 schema 增强的多层次对比学习知识推理模型 SMiLE（**S**chema-augmented **M**ulti-level Contrastive **Le**arning Model for Knowledge Graph Reasoning），模型整体框架如图 3.1 所示，图中展示了模型的多层级对比学习任务目标、负样本构建方式以及预训练策略。在 3.2 节中，为了从知识图谱中抽取并表示出完整的 schema，本章从知识图谱中提取并建立一个<头实体类型，关系，尾实体类型>的张量来表示高阶的 schema 信息。在 3.3 节中，分别针对结构视图和上下文视图这两类不同视图下的实体编码器进行定义。在 3.4 节中，本章设计一种在 schema 指导下的多层次对比学习方法，分别在上下文层面和全局层面优化信息对比估计目标损失，以此捕获知识图谱的全局结构信息和局部上下文信息。在 3.5 节中，本章提出并定义模型的整套预训练-微调流程，在预训练阶段利用多视图对比策略获得具有结构和高阶语义信息的实体表征，然后在三元组的监督下对实体和关系的表征进行微调，以学习知识图谱中的更精细的三元组结构知识。

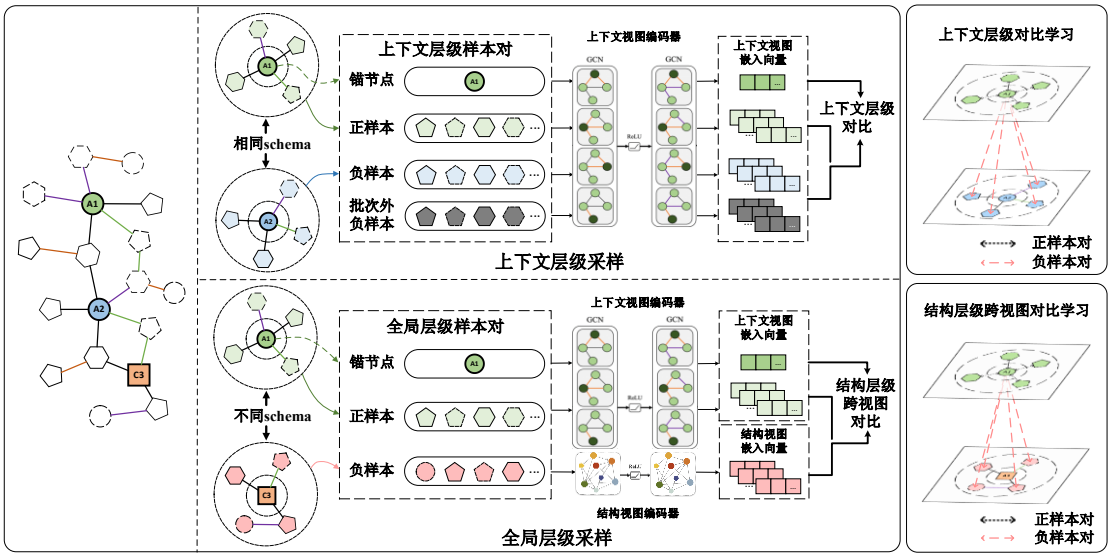


图 3.1 Schema 增强的多层级对比学习知识推理框架示意图

3.2 上下文 schema 构建

开放的知识图谱例如 Freebase、Wikipedia 等，均包含了源生的本体属性和关系，图 3.2 对一个知识图谱中的实例视图及其对应 schema 视图进行了展示。其中的“*Nicole Kidman*”实体有两种不同的类型：“*Actress*”和“*Citizen*”，该实体在两种不同的上下文中表达出不同的语义信息。图中左上部分描述的是有关“妮可基德曼作为演员获得的奖项和作品”的上下文信息。具体地，实体“*Nicole Kidman*”和实体“66th *Cannes*”之间存在关系相连，在这种情况下，模型很容易对（*Nicole Kidman*，*？*，*Lane Cove Public School*）这样的预测产生错误的推理结果，因为实体类型“*Actress*”和实体类型“*School*”之间没有直接的关系相连接。但是考虑到“*Nicole Kidman*”实际上也是“*Citizen of Austrilia*”，因此进行这样的预测实际上是合理且符合实际的。

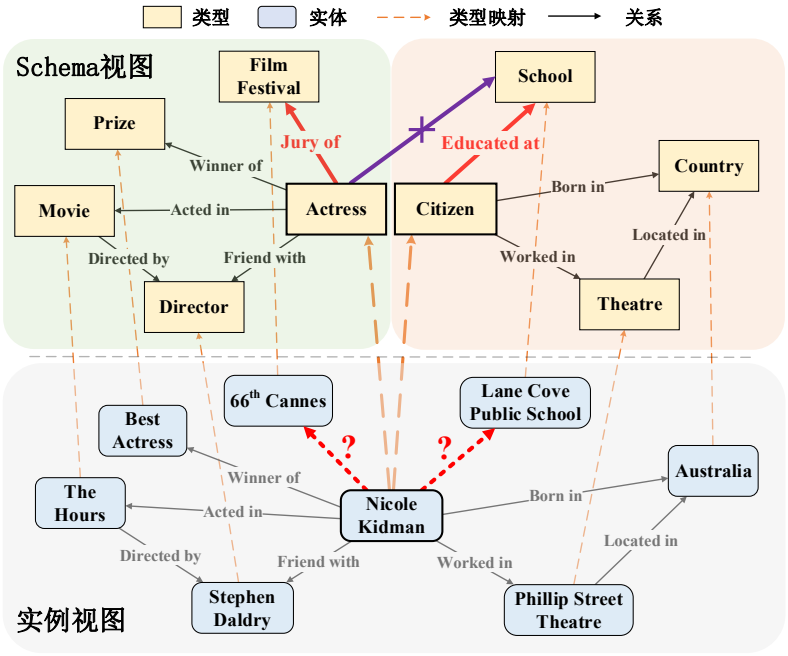


图 3.2 知识图谱实例视图及其对应的 schema 视图

由于知识图谱中的本体信息通常较为稀疏，且含有大量噪声，难以被直接建模为图结构加以利用。因此，本节旨在依赖现有的实体类型信息，构建出知识图谱的 schema 图，使得它能够合理地表达出知识图谱的高阶元特征和概念之间的关联。

对于一个知识图谱$\mathcal{G}$，它包含了若干实体组成的实体集合$\mathcal{E}$，若干关系组成的关系集合$\mathcal{R}$，所有三元组实例(s,r,o)组成的三元组集合$\mathcal{T}$，以及所有实体类型组成的实体类型集合$\mathcal{P}$。其中，对于一个头实体$s\in\mathcal{E}$或者尾实体$o\in\mathcal{E}$，它们均有一个或者多个对应的类型$t_{s1},t_{s2},...,t_{sn}\in\mathcal{P}$。首先，对于知识图谱中的所有三

元组(s,r,o)，将三元组中每个实体转换为其对应的类型，由此可以构建起一个实体类型三元组集合$\{(t_s,r,t_o)\,|\,(t_s,r,t_o)\in\mathcal{P}\times\mathcal{R}\times\mathcal{P}\}$。由于知识图谱中的每个实体可能有多种对应的类型，因此在构建实体类型三元组集合的时候，需要将其中所有可能得实体类型组合都考虑在内。为了保证模型运行效率，在计算时只保留对整体 schema 贡献较大的类型三元组组合。具体地，统计每个实体类型三元组出现的频次，并过滤掉频次低于阈值α的三元组，由此可以构建出全局的知识图谱 schema$\mathcal{T}\in\mathbb{B}^{|\mathcal{P}^s|\times|\mathcal{R}|\times|\mathcal{P}^o|}$，$\mathcal{T}$是布尔类型的张量，其中$\mathcal{P}^s$和$\mathcal{P}^o$分别是过滤后的头实体类型和尾实体类型的集合。用$S$表示知识图谱的全局 schema 中的类型三元组集合，给定实体s为中心的上下文子图，便可以得到它对应的上下文 schema。

具体地，以实体s为中心，通过随机游走的方式，可以得到包含s在内的 N 阶邻居实体，以及它们之间相连接的关系，由此形成s的上下文子图$g_c(s)$，如公式(3-1)所示：

$$g_c(s)=\{s\,|\,M^n(s,u)>0,u\in V\}, \tag{3-1}$$

其中M^n是转移概率矩阵的n次方，给出了从节点s通过n步随机游走到达节点u的概率。

得到了实体s的上下文子图$g_c(s)$之后，将$g_c(s)$中的所有实体映射为对应的实体类型，可以得到s的类型化子图$S_t(s)$。然后通过在$S_t(s)$和知识图谱 schema 集合S之间取交集，可以得到实体 s 的上下文 schema 如公式(3-2)所示：

$$S_c(s)=\left\{(t_s,r,t_o)\,|\,(t_s,r,t_o)\in S_t(s)\cap S\right\}. \tag{3-2}$$

3.3 多视图实体编码

通常情况下，实体在不同视图下会表现出不同特征信息，因此论文针对上下文视图和结构试图分别设计了不同的特征提取器，从而将实体编码为不同的表示形式，以分别捕获实体在上下文视图和结构视图中的不同特征。

3.3.1 结构视图实体编码器

知识图谱作为具有异质信息的多关系图网络，其中最基本和最重要的便是结构信息。给定知识图谱$\mathcal{G}$中的一个实体s和一个关系r，利用结构视图编码器得到它们的全局结构嵌入如公式(3-3)所示：

$$h_s=f_e(s;G);z_r=f_r(r). \tag{3-3}$$

为了保证模型在知识图谱中能够捕获到图结构层面的特征，论文采用图神经网络模型 CompGCN[26]作为$f_e(\cdot;G)$以学习实体嵌入，并同步得到关系嵌入$f_r(\cdot)$。

3.3.2 上下文视图实体编码器

为了捕捉上下文 schema 中的潜在知识，论文使用 K 层上下文翻译模块[68]来学习实体集合 $\mathcal{E}_c$ 的上下文嵌入。对于实体 s，以及上下文子图 $g_c(s)$ 中的实体嵌入 $H_c=(h_1,h_2,...,h_{|\mathcal{E}_c|})\in\mathbb{R}^{d\times|\mathcal{E}_c|}$，通过上下文翻译模块可以得到实体集合 $\mathcal{E}_c$ 在上下文视图的嵌入表示：

$$H_c^{i+1}=Enc(W_{sc}H_c^i\overline{A}^i+H_c^i),i=0,1,...,k-1, \tag{3-4}$$

其中 $Enc()$ 是一个线性层编码器，$W_{sc}\in\mathbb{R}^{d_k\times d_{k+1}}$ 是一个层特定的参数矩阵，此外每一层还使用了残差连接来保留前一层中的上下文嵌入信息。$\overline{A}^i\in\mathbb{R}^{|E_c|\times|E_c|}$ 表示上下文子图 $g_c(s)$ 的语义关联矩阵，由于上下文子图中两个节点之间的联系往往是不同的，因此语义关联矩阵 $\overline{A}^i$ 通常是不对称的。$\overline{A}^i$ 通过多头注意力机制计算得到，其中每一头的计算方式如公式(3-5)所示：

$$\overline{A}_{ij}^k=\frac{\exp\left(\left(W_1h_i^k\right)^T\left(W_2h_j^k\right)\right)}{\sum_{t=1}^{|V_c|}\exp\left(\left(W_1h_i^k\right)^T\left(W_2h_t^k\right)\right)}, \tag{3-5}$$

其中 W_1 和 W_2 是可学习的权重矩阵。聚合每一层上下文翻译模块的输出，就可以得到节点 s 的上下文视图嵌入，如公式(3-6)所示：

$$c_s=h_s^0\oplus h_s^1\oplus...\oplus h_s^{k-1}. \tag{3-6}$$

通过以上操作，上下文 $g_c(s)$ 中的节点经过翻译模块编码后，每个节点都能够学习到在特定局部上下文邻域中最具代表性的语义信息。

3.4 多层级自监督对比预训练

区别于传统方案对不同视图的特征分别建模再进行融合，本小节设计了多层级对比学习来捕捉和平衡全局结构与局部上下文。论文利用 schema 约束来指导模型正负样例的采样，通过采集具有更丰富信息的正负样例对，结合信息对比估计[64]实现高效的对比学习目标优化，从而隐式地建模全局结构与局部上下文语义。

3.4.1 上下文层级对比学习

上下文层级的对比学习，其目的旨在捕获上下文 schema 中实体的潜在语义。由于上下文 schema 限制了与实体相关的三元组的类型信息，模型能够依此采集到更复杂的负样本，从而更有效地实现信息对比估计目标优化。

正样例采样。对于一个上下文子图 $g_{c(s)}$ 及其对应的上下文 schema $S_{c(s)}$，假设 s 为 $g_{c(s)}$ 和 $S_{c(s)}$ 的中心锚实体，上下文子图 $g_{c(s)}$ 中的其他实体为上下文实体，如公式(3-7)所示，锚实体 s 在上下文层面和全局层面的正样本可以被定义为：

$$P_s = \left\{ u \mid (s,r,u) \in T_c(s), u \neq s \right\}, \tag{3-7}$$

其中 $T_c(s)$ 表示上下文子图 $g_{c(s)}$ 中的所有三元组集合。

上下文层级负样例采样。对于具有相同类型的两个实体 u 和 v，以它们为中心节点生成的上下文子图分别为 $g_{c(u)}$ 和 $g_{c(v)}$，如果这两个子图可以投射到相同的上下文 schema 中，则它们在 $g_{c(\mathrm{s})}$ 中的邻居实体可以被视为彼此的负样本。如公式(3-8)所示，给定一个批次的锚实体 E_B，锚实体 s 的负样本可以被表示为：

$$N_s^{cur} = \left\{ P_i \mid i \in E_B \backslash \{s\}, S_c(i) = S_c(s), t_i = t_s \right\}. \tag{3-8}$$

通常情况下，一个批次中的上下文层级负样本的数量与批次大小呈正相关，受批次大小的限制，上下文层级负样本数量通常较少。为了扩大负样本数量，论文采用动态队列来存储先前 n 个批次中的实体嵌入[64,69]，将这些样本也视作是当前批次锚实体的上下文层级负样本。具体地，如公式(3-9)所示，锚实体 s 的批次外动态队列负样本可以被表示为：

$$N_s^{pre} = \left\{ P_j \mid j \in E_B^{-1} \cup E_B^{-2} ... \cup E_B^{-n},\ S_c(j) = S_c(s), t_j = t_s \right\}, \tag{3-9}$$

其中，E_B^{-n} 表示最近前 n 个批次中的实体。由于先前批次的实体嵌入是使用先前模型的参数计算得到，因此需要将 n 限定为一个比较小的数字，以确保动态队列中的负样本 N_s^{pre} 能够尽可能地与 N_s^{cur} 负样本保持在同一特征空间中。综上，在上下文层面，锚实体 s 的负样本组成如公式(3-10)所示：

$$N_s^{ia} = N_s^{cur} \cup N_s^{pre}. \tag{3-10}$$

上下文层级优化目标。得到了实体的上下文层级正负样例之后，利用上下文视图编码器得到对应的嵌入向量，应用 InfoNCE[64]损失函数来进行对比损失估计，如公式(3-11)所示：

$$\mathcal{L}_s^c = -\log \frac{\sum_{t \in \mathbb{P}_s} \exp\left(\phi(c_s, c_t)/\tau\right)}{\sum_{k \in \{\mathbb{P}_s \cup \mathbb{N}_s^{ia}\}} \exp\left(\phi(c_s, c_k)/\tau\right)}, \tag{3-11}$$

其中，τ 是超参数温度系数，用于控制评分函数的灵敏度，评分函数 ϕ 使用余弦相似度来计算。与以往基于对比损失的自监督方法不同[70]，公式(3-11)在计算对比损失时考虑了多个正样本。

3.4.2 全局层级对比学习

除了局部上下文语义之外，学习各种上下文子图之间的结构关联也至关重要。一个实体在不同的上下文模式中会表达出不同的语义信息。采用跨视图对比学习策略，能够有效平衡知识图谱的全局 schema 特征和上下文语义信息。

全局层级负样例采样。对于两个具有相同类型的实体u和v，以它们为中心锚节点生成的上下文子图分别为$g_{c(u)}$和$g_{c(v)}$，如果这两个子图对应于不同的上下文 schema，则$g_{c(u)}$和$g_{c(v)}$的上下文实体可以被视为彼此的负样本，如公式(3-12)所示：

$$N_s^{ie} = \left\{ E_c^i \mid i \in E_B \backslash \{s\}, S_c(i) \neq S_c(s) \right\}, \tag{3-12}$$

其中E_B表示一个批次中的锚点实体集合。

全局层级优化目标。得到了实体s在上下文视图和结构视图的嵌入h_s和c_s后，使用一个具有单个隐层的 MLP（Multilayer Perceptron）编码器，将h_s和c_s统一映射到同一个计算对比损失的特征空间中，如公式(3-13)所示：

$$\begin{aligned} h_s^p &= W^2\sigma(W^1 h_s + b^1) + b^2, \\ c_s^p &= W^2\sigma(W^1 c_s + b^1) + b^2, \end{aligned} \tag{3-13}$$

其中，σ代表 ELU 激活函数。权重矩阵W^1, W^2和偏置参数b^1, b^2在两个不同视图的嵌入之间是共享的。基于以上操作，即可在实体的上下文视图表征和结构视图表征之间进行如公式(3-14)所示的跨视图对比学习：

$$\mathcal{L}_s^g = -\log \frac{\sum\limits_{t \in \mathbb{P}_s} e^{\left(\phi(c_s^p, c_t^p)/\tau\right)}}{\sum\limits_{k \in \mathbb{P}_s} e^{\left(\phi(c_s^p, c_k^p)/\tau\right)} + \sum\limits_{k \in \mathbb{N}_s^{ie}} e^{\left(\phi(c_s^p, h_k^p)/\tau\right)}}, \tag{3-14}$$

其中，τ是温度超参数，ϕ是基于余弦相似度的打分函数。

3.5 知识推理的预训练与微调范式

为了捕获到知识图谱中上下文 schema 和单个三元组中的语义和结构信息，从而进行准确的链接预测，基于 3.4 节中提出的对比学习策略，论文设计知识图谱上的预训练-微调流程来训练本章提出的 SMiLE 模型。

预训练的对比学习优化目标。在预训练阶段，采用 3.4 节中提出的多层次对比学习策略来优化 SMiLE 模型参数θ。为了在上下文层面和全局层面捕捉实体的语义和结构知识，模型联合地最小化上下文层面和全局层面的损失，如公式(3-15)所示：

$$\mathcal{L}=\frac{1}{|E|}\sum_{s\in E}\left[\lambda\cdot\mathcal{L}_s^g+(1-\lambda)\cdot\mathcal{L}_s^c\right], \tag{3-15}$$

其中，λ是平衡系数，用于控制上下文层级损失和全局层级损失之间的比重。

针对知识推理的微调。在预训练后的模型参数θ的基础上，进一步微调模型SMiLE，以便模型在单个三元组的监督下学习到实体和关系的更细微的局部结构表示。对于知识图谱中的一个正样本三元组(s,r,o)，通过随机替换头实体或尾实体来构造它的负样本（保证替换后的实体应与原实体具有相同的类型）。然后，计算三元组(s,r,o)中头实体s的关系感知嵌入$h_s^r=\phi(h_s,z_r)$，其中$\phi(\cdot)$表示非参数化的实体-关系组合操作[26]，包括减法、乘法、循环关联等。

然后，对于一个三元组(s,r,o)，将实体s与实体o之间的最短路径视为其对应的上下文子图$g_{c(s,o)}$。将上下文子图$g_{c(s,o)}$中的实体及其关系感知嵌入h_s^r输入到上下文视图编码器中，就可以得到三元组(s,r,o)中实体s和o的上下文视图嵌入，分别表示为c_s^r和c_o。基于以上的操作，如公式(3-16)所示，微调阶段的训练目标可以被定义为：

$$\mathcal{L}=\sum_{(s,r,o)\in T_p}\log\left(\phi_r(c_s^r,c_o)\right)+\sum_{(s',r,o')\in T_n}\log\left(1-\phi_r(c_{s'}^r,c_{o'})\right), \tag{3-16}$$

其中，T_p和T_n分别代表正样本三元组集合和负样本三元组集合。$\phi_r(c_s,c_o)$表示用于通过关系r来衡量实体对之间匹配程度的打分函数。论文采用点积相似性来实现$\phi_r(c_s,c_o)=\sigma(c_s\cdot c_o^T)$，其中$\sigma$是Sigmoid函数。

模型复杂度。理论上，本章所提出的SMiLE模型与之前的基线模型的主要区别在于：正负样例的采样和对比优化的损失，而这两者与负样本的数量直接相关。在预训练阶段，SMiLE模型的时间复杂度主要取决于正负样本的数量，复杂度数值为$O(|E|\times|P|\times(k_1+k_2))$，其中$|E|$代表实体节点的数量，$|P|$表示上下文层级和全局层级正样本的数量，$k_1$和$k_2$分别表示在上下文层级和全局层级每个正样本对应的负样本数量。在微调阶段，模型的时间复杂度主要取决于上下文子图节点数量，复杂度数值为$O(|R|\times N_c)$，其中$|R|$代表关系边的数量，N_c表示所有上下文子图中节点数量的最大值。

3.6 实验设计与结果分析

3.6.1 实验任务与数据

链接预测任务。链接预测任务是知识推理的最基本任务，其目的旨在根据知识图谱中的已知实体来推断它们之间是否存在直接相连的关系。该任务能够反映出模型对知识图谱中实体和关系的表示学习程度，并且反映出模型对知识图谱中

结构语义信息的建模能力，是评估知识推理性能的最重要任务。

评估指标。为了评估了本章所提出模型 SMiLE 在链接预测任务上的性能，采用以下两个指标作为链接预测效果的评估指标：1）AUC-ROC 分数：ROC 是以假阳性率为横轴，以真阳性率为纵轴所组成的坐标图中的概率曲线。AUC 值是 ROC 曲线下方的区域面积，是 ROC 曲线的数字摘要，取值范围一般为[0.5,1]，AUC-ROC 值越高表明模型的预测性能越好；2）Micro-F1 分数：F1 分数（F1-Score）是分类问题的衡量指标，用于权衡 Precision 和 Recall，被定义为精确率和召回率的调和平均数。对于 Micro-F1，先计算出所有类别的总的 Precision 和 Recall，然后利用 F1 计算公式计算得到的值即为 Micro-F1 分数，具体如公式(3-17)所示：

$$
\begin{aligned}
Precision_{\text{micro}} &= \frac{\sum_{i=1}^{n} \mathrm{TP}_i}{\sum_{i=1}^{n} \mathrm{TP}_i + \sum_{i=1}^{n} \mathrm{FP}_i}, \\
Recall_{\text{micro}} &= \frac{\sum_{i=1}^{n} \mathrm{TP}_i}{\sum_{i=1}^{n} \mathrm{TP}_i + \sum_{i=1}^{n} \mathrm{FN}_i}, \\
F1_{\text{micro}} &= 2 \cdot \frac{Precision_{\text{micro}} \cdot Recall_{\text{micro}}}{Precision_{\text{micro}} + Recall_{\text{micro}}}.
\end{aligned}
\tag{3-17}
$$

数据集。为了评估本章提出的 SMiLE 模型在链接预测任务上的性能，论文选取了四个在知识图谱领域内公开且通用的真实世界数据集：FB15k[12]、FB15k-237[71]、JF17k[72]和 HumanWiki[73]。四种数据集的统计信息如表 3.1 所示：

表 3.1 数据集参数统计

数据集	实体种类	实体类型数	关系种类	边数量	三元组数量
FB15k-237	14541	583	237	248661	310116
FB15k	14579	588	1208	117580	154916
JF17k	9233	511	326	18049	19342
HumanWiki	38949	388	221	105688	108199

具体地：1）Freebase 是一个由 Google 创建的庞大、多领域的知识图谱数据集，包含超过 2.5 亿个实体，实体之间的关系关系可以是人物的职业、电影的导演等。实体和关系都有一个或多个属性，用于描述它们的特征和属性，如人物的出生日期等。FB15k 和 JF17k 是从 Freebase 中构建出来的子集，FB15k-237 是从

FB15k 中去除正反关系后的子集；2）Wikidata[1]是一个免费开放、多语言的大规模链接知识库，它允许任何人进行编辑和修改。该数据库支持基于三元组的知识条目自由编辑，其中每个三元组都代表了一条关于特定条目的陈述。HumanWiki 是通过从 Wikidata 中提取所有包含头实体类型为 human 的三元组来构造的。

3.6.2 实验设置

基线模型。本章的实验选取了知识推理任务上九个代表性模型作为基线模型进行比较，这些模型可以进一步分为两类。第一类是基于知识图谱嵌入的模型，包括 TransE、TransR、ComplEx-N3、融合类型信息的 TypeComplex、结构感知负采样的 SANS 以及配对关系编码的 SOTA（State-of-the-art）模型 PairRE。第二类是采用图神经网络的模型，此类模型利用 GNN 来挖掘知识图谱中的结构信息，包括基于随机游走的同质图网络模型 Node2vec、多关系模型 CompGCN 以及基于元路径上下文建模的 SOTA 模型 SLiCE。参与比较的基线模型具体介绍如下：

TransE[12]是基于距离翻译的知识表示模型，主要将知识图谱中的（头实体，关系，尾实体）三元组建模为从头实体经过关系到尾实体的翻译操作，从而在低维向量空间中学习实体和关系的表示。

TransR[22]将实体和关系嵌入分别构建在独立的实体空间和关系空间中，针对实体的多方面语义，将实体从实体空间投影到相应的关系空间，然后在投影后的实体之间构建翻译操作，以此来学习嵌入表示。

ComplEx-N3[74]将知识库补全问题转化为三阶二元张量补全问题，通过引入基于张量核 p-范数的正则化器，消除数据集中谓词及其逆谓词选择的任意性，从而在低维向量空间中学习知识库的实体和关系表示。

TypeComplex[75]通过利用实体-关系对之间的类型相关项来增强模型基分解，并以一种新的方式组合信号，在没有显式类型监督的情况下预测实体间的相容性。

SANS[76]使用了结构感知的负采样策略，在对比学习过程中，显式考虑知识图谱的图结构，选择在语义上更有意义的负样本，实现结构感知的知识表示学习。

PairRE[77]为每个关系分配一对向量来适应性调整损失函数中的边界，编码了对称性、反对称性、逆关系和组合等复杂关系模式，能够同时处理知识图谱上的复杂关系和编码多种关系模式。

Node2vec[78]是学习网络节点连续特征表示的模型，通过设计一种灵活的随机游走过程来探索节点的多样化邻域，并学习将节点映射到低维特征空间的表示，从而最大化保持节点网络邻域的可能性。

[1] https://www.wikidata.org/

CompGCN[26]是多关系图卷积网络框架，通过结合知识图谱嵌入技术中的多种实体-关系组合操作，在关系图中联合学习节点和关系的嵌入。

SLiCE[68]基于子图来学习异质图中的节点表示，利用生成式自监督方法，自动学习不同元路径的组合，并对子图邻居的信息进行聚合，从而实现将子图中关系元路径的信息融入实体表示。

参数设置。模型训练阶段采用 Adam 作为优化器，预训练阶段的学习率设为 0.0001，微调阶段的学习率设为 0.001。模型使用随机游走方法来生成上下文子图，嵌入向量维度设为 128。温度系数 τ 初始化为 0.8，上下文翻译模块层数 K 设为 4。上下文层级和全局层级中的最大负样本数量为 512。GNN 模型 $f_e(\cdot;G)$ 采用 CompGCN 实现，实体-关系组合操作 $\phi(\cdot)$ 采用乘法实现。为了选择模型的最佳超参数，在验证集上对表 3.2 中列出的超参数进行网格搜索。具体地，将所有数据集的嵌入维度都设为 128。在预训练阶段，分别对 FB15k、FB15k-237、JF17k 和 HumanWiki 数据集使用 1024、2048、512 和 1024 的批次大小。微调阶段的批次大小统一设为 256。对于 schema 的频率阈值，考虑到不同数据集的大小不同，分别对 FB15k、FB15k-237、JF17k 和 HumanWiki 数据集使用 700、1000、70 和 50 作为阈值下限。批次外负样本动态队列的超参数 n 在所有数据集中都设为 2。为了控制上下文子图的大小，将 FB15k-237 数据集中上下文子图实体最大数量设为 12，在其他三个数据集上设为 6。

表 3.2 SMiLE 模型超参数搜索范围

超参数	搜索空间数值
温度系数 τ	{0.5, 0.6, 0.7, 0.8, 0.9}
学习率	{1e-4, 1e-3, 3e-2, 1e-1}
平衡系数 λ	{0.2, 0.4, 0.6, 0.8}
批次外负样本动态队列大小 n	{1, 2, 5, 8, 10}
上下文子图大小 $\lvert E_c \rvert$	{6, 12, 18}
嵌入向量维度	{64, 128, 256, 512}
批次大小（预训练阶段）	{128, 256, 512, 1024, 2048}
批次大小（微调阶段）	{64, 128, 256, 512}
运行周期数（预训练阶段）	{10, 15, 20}
运行周期数（微调阶段）	{10, 15, 20}

实验环境。模型采用 PyTorch 框架进行编码实现，在 NVIDIA TITAN V GPU 上进行训练。为了确保实验的公平性，所有基线模型的实现基于各自的源代码仓库，遵循其各自论文的实验设置。本章实验所使用的相关硬件配置如表 3.3 所示。在该实验环境下，预训练阶段的每个训练轮次所花费时间，在 FB15k 数据集上大约为 70 秒，FB15k-237 数据集上大约为 130 秒，JF17k 数据集上大约为 54 秒，HumanWiki 数据集上大约为 600 秒。

表 3.3 实验环境详细配置

配置项	具体设备
操作系统	Ubuntu 18.04.6 LTS
内存	504G
GPU	NVIDIA TITAN V (12G)
CPU	48 Intel(R) Xeon(R) Silver 4214 CPU @ 2.20GHz
CUDA	10.2

3.6.3 对比实验结果

本小节在四个知识图谱数据集上验证 SMiLE 模型的效果，并与各种具有代表性的 SOTA 模型进行比较，具体的实验结果如表 3.4 所示：

表 3.4 各模型在知识图谱数据集上的实验效果统计

模型	FB15k		FB15k-237		JF17k		HumanWiki	
	F1	AUC	F1	AUC	F1	AUC	F1	AUC
TransE[12]	50.36	50.13	47.78	48.18	44.68	46.18	49.06	49.31
TransR[22]	71.96	76.96	67.19	70.76	62.06	68.14	61.56	66.54
ComplEx-N3[74]	49.63	49.63	50.19	50.34	48.44	49.15	54.53	52.86
TypeComplex[75]	88.09	93.90	50.05	50.25	73.73	78.53	80.17	85.58
SANS[76]	88.97	94.59	50.03	50.26	68.62	79.41	78.18	83.69
PairRE[77]	88.27	92.67	49.62	49.30	71.89	79.65	80.07	87.68
Node2vec[78]	80.23	88.91	83.69	89.77	93.30	98.01	80.13	87.54
CompGCN[26]	60.35	63.59	65.39	72.01	66.27	52.13	56.88	40.09
SLiCE[68]	88.34	94.66	**90.26**	**96.41**	96.16	98.89	88.92	96.19
SMiLE	**90.76**	**96.53**	88.75	94.92	**96.98**	**99.22**	**93.40**	**97.92**

从表 3.4 中可以清晰地观察到，在四个数据集上，本章提出的 SMiLE 模型普遍优于现有基线模型。具体地，SMiLE 在四个数据集上的表现优于基于多关系图神经网络的 CompGCN 模型，原因在于 CompGCN 只建模了三元组内部的关系连接，以及三元组的局部结构信息，而没有考虑到子图内与子图间的上下文语义信息。该实验结果强调了：在链接预测中，从知识图谱上下文 schema 中学习到的上下文语义信息能够提供更丰富和有效的信息。

此外，从表 3.4 中可以观察到 SMiLE 在 FB15k、JF17k 和 HumanWiki 数据集上的表现远超最新的 SOTA 模型 SLiCE，但在 FB15k-237 上略有落后。原因在于：与其他数据集相比，FB15k-237 所包含的知识图谱图结构更为密集，每个实体的度数更大。在这种情况下，模型更依赖于知识推理中的一般化逻辑规则。由于 SLiCE 能够自动从上下文中学习元路径，这对链接预测提供了更多的逻辑规则信息。此外，FB15k-237 数据集中存在大量不可预测的关系链接[79]，因此，这能够一定程度上解释 SMiLE 在数据集 FB15k-237 上取得欠佳于 SLiCE 的结果。

3.6.4 消融实验

为了建模和融合知识图谱中的上下文信息和结构信息，论文提出了在预训练阶段的上下文层级对比学习和全局层级对比学习策略。为了探究模型中每个模块的作用效果，本小节对 SMiLE 模型在 FB15k 和 HumanWiki 数据集上的链接预测效果进行消融实验分析。具体地，本小节设置三组消融分析实验，对模型的三个部分消融：without Global Contrast 指模型舍弃全局层级的对比优化损失，即只在上下文层级进行对比学习；without Contextual Contrast 对模型上下文层级的对比学习策略进行消融，即只保留全局层级的对比损失；without Pre-batch 指模型删除掉上下文层级的动态队列负样本，仅保留批次内负样本。

表 3.5 SMiLE 模型在知识图谱数据集上的消融实验结果

模型	FB15k		HumanWiki	
	F1	AUC-ROC	F1	AUC-ROC
SMiLE	90.76	**96.53**	**93.40**	**97.92**
without Global Contrast	90.57	96.40	92.88	97.75
without Contextual Contrast	**91.04**	96.49	91.33	96.90
without Pre-batch	90.58	96.42	92.77	97.62

结合表 3.5 可以观察到：1）完整的 SMiLE 模型在 Micro-F1 和 AUC-ROC 分数上基本均超过了消融模型，各个模块的去除或者简化均会导致模型性能的下降，

证明了 SMiLE 模型中每个模块的重要性。进一步也证明了在上下文级别和全局级别中，语义信息和结构信息对 SMiLE 模型都有正向的贡献；2）分析第一种（without Global Contrast）和第二种（without Contextual Contrast）消融方式可以观察到：相较于 HumanWiki 数据集，全局层级的结构信息在 FB15k 数据集上对完整模型的性能贡献更大。原因在于 FB15k 数据集的图更为稠密，每个实体平均与更多的实体相连，实体具有更大的度，因此它们能够从其局部邻居中获得更多的上下文信息。在这种情况下，全局层级的结构信息能够更有助于丰富实体的表征，更有助于提高模型在知识推理任务上的表现；3）分析第二种（without Contextual Contrast）和第三种（without Pre-batch）消融方式可以观察到，动态队列负样本的存在与否对模型的影响在 FB15k 数据集上较小，而在 HumanWiki 数据集上较大。原因在于 FB15k 数据集具有图稠密的特性，上下文层级的批次内负样本数量会显著多于 HumanWiki 数据集，因此模型效果不会受到动态队列负样本数量的显著影响。

3.6.5 模型性能分析

采样方法对模型知识推理性能的影响。本小节实验探究不同的采样策略对模型性能的影响。在 SMiLE 模型中，预训练阶段采用了一种多层次的对比学习策略，该策略显著依赖于负样本的质量。为了验证 schema 引导下的采样策略是否能够采集得到更优质的负样本，本小节提出一个直观上更简单的关系层级采样策略，将其与基于 schema 的采样策略进行比较。该方法的思路是在正样本三元组 (s,r,o) 中随机扰乱替换头实体 s 或尾实体 t，并保证替换后的实体类型与替换前相同，具体如公式(3-18)所示：

$$N_s^{rel}=\{v \mid v\in E,(s,*,v)\notin T,t_v=t_o\}, \tag{3-18}$$

其中*表示实体 s 和实体 v 之间没有直接相连的关系。

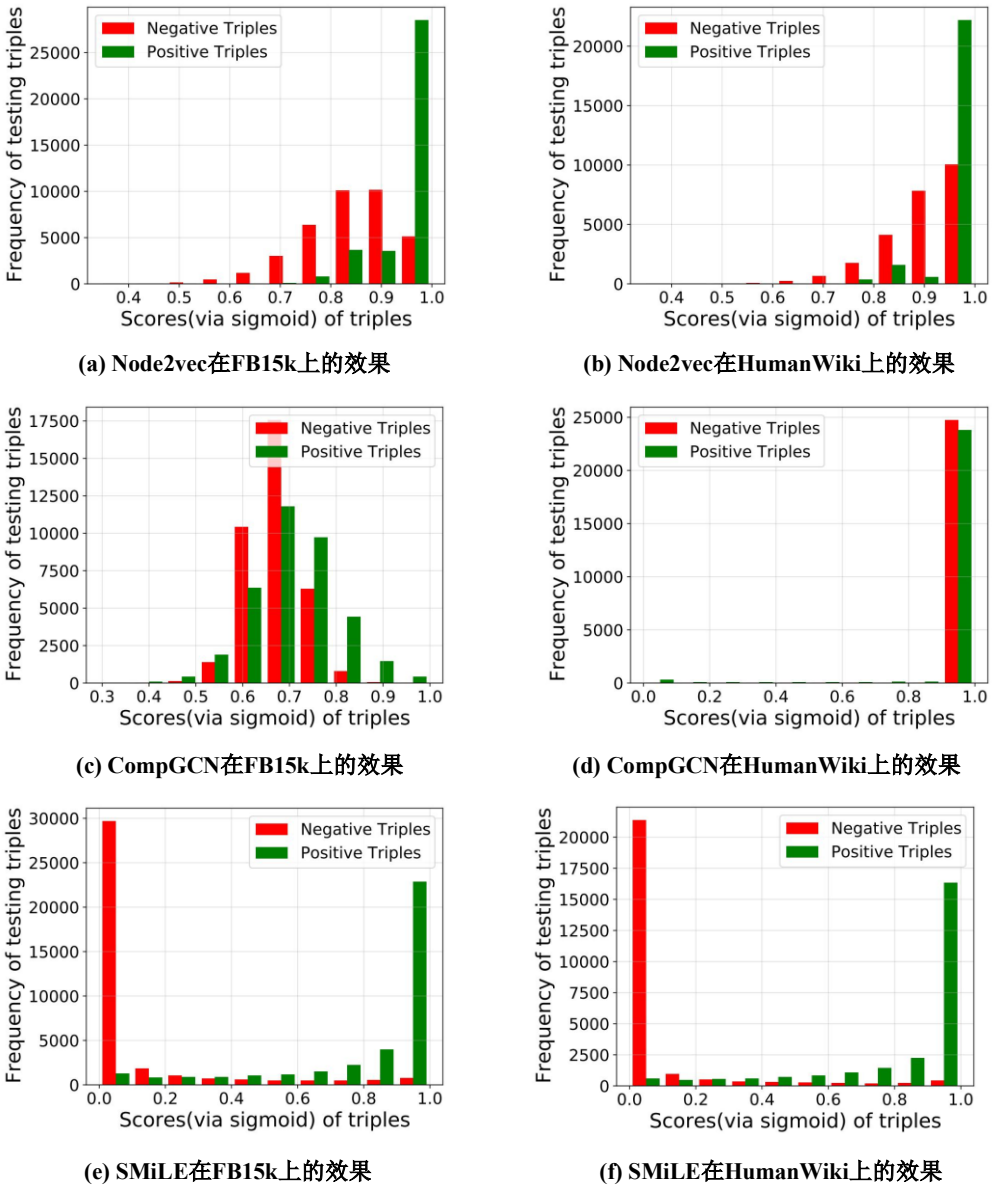
表 3.6 采样方法对模型知识推理性能的影响

采样策略	FB15k		HumanWiki	
	F1	AUC-ROC	F1	AUC-ROC
Schema-based	**90.76**	**96.53**	**93.40**	**97.92**
Relation-based	89.14	95.45	92.41	97.51

如表 3.6 所示，将基于 schema 的采样策略切换为基于关系的负采样策略，Micro-F1 分数平均上从 92.08%下降到了 90.77%，AUC-ROC 分数从 97.23%下降到了 96.48%。但是相比于其它知识图谱基线模型，SMiLE 模型仍然能够取得优

异的效果。结合实验结果可知，关系层级采样策略只关注于具有实体类型约束的独立三元组，而忽略了实体的上下文信息。综上，与传统的简单采样策略相比，本章所提出的 schema 引导采样策略能够采集到更有效的优质正负样本对。

模型对正负三元组的辨别能力。在本小节中，为了进一步展示 SMiLE 模型在链接预测任务上的区分能力，对 SMiLE 模型计算的正样本和负样本三元组的分数分布进行可视化，并将其与另一个基于 GNN 的模型 Node2vec 进行了比较，由此直观地评估模型在区分三元组真实存在与否方面的能力。理想情况下，正样本（即知识图谱中真实存在的三元组）应该获得较高的分数，而负样本（即人为破坏的、知识图谱中不存在的三元组）应该获得较低的分数。如果模型能够明显地区分这两类样本，那么它在链接预测任务上的性能更好。



(a) Node2vec在FB15k上的效果　(b) Node2vec在HumanWiki上的效果

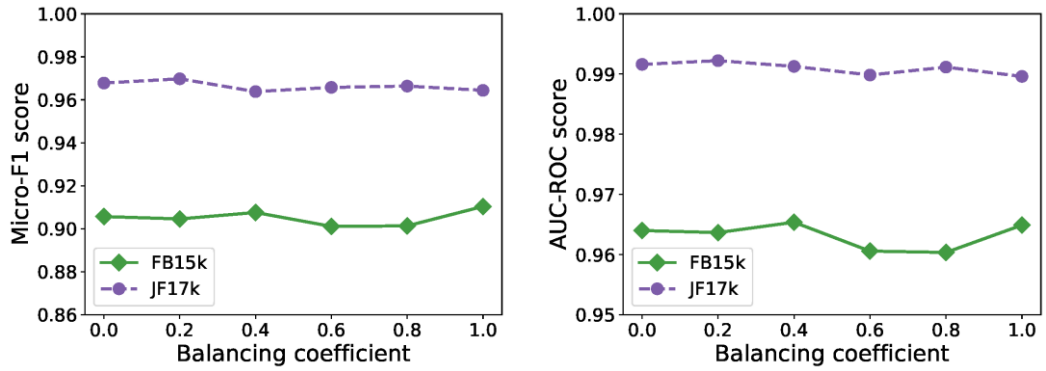
(c) CompGCN在FB15k上的效果　(d) CompGCN在HumanWiki上的效果

(e) SMiLE在FB15k上的效果　(f) SMiLE在HumanWiki上的效果

图 3.3 各类模型在知识图谱数据集上得到的正负三元组的分数分布

如图 3.3 所示，从图（a）和图（b）中可以看到，Node2vec 模型无法准确区分测试集中的正样本三元组和负样本三元组，导致大量负样本三元组仍然能够取得较高的分数。观察图（c）和图（d），可以看到 CompGCN 模型在 FB15k 数据集上正负三元组的分数均集中在 0.7 附近，在 HumanWiki 数据集上正负三元组的分数均集中在 0.9 附近，表明 CompGCN 模型对于正负样本的区分度不高。相反，从图（e）和图（f）SMiLE 模型得到的结果中可以看到，正样本三元组的得分集中靠近 1，负样本三元组的得分集中靠近 0，正样本三元组和负样本三元组之间的分数分布差距很大。实验结果表明，在语义空间上，SMiLE 模型能够将正样本三元组拉近，同时将负样本三元组推得更远，这证明了模型对比学习策略的有效性。

超参数对模型知识推理性能的影响。本小节探究对比损失中的平衡系数 λ 以及 schema 构建时的过滤频率阈值 α 对模型性能的影响。如图 3.4 所示，在 JF17k 数据集上，平衡系数 λ 为 0.2 的时候 Micro-F1 和 AUC-ROC 分值最高；在 FB15k 数据集上，平衡系数 λ 为 0.4 的时候 Micro-F1 和 AUC-ROC 分值最高。可以看出在不同数据集上平衡系数 λ 对模型性能的影响不同，但平衡系数 λ 的引入能够较好地平衡和融合两个层级之间的信息。



(a) Micro-F1 **(b) AUC-ROC**

图 3.4 平衡系数超参数 λ 对 SMiLE 模型的性能影响

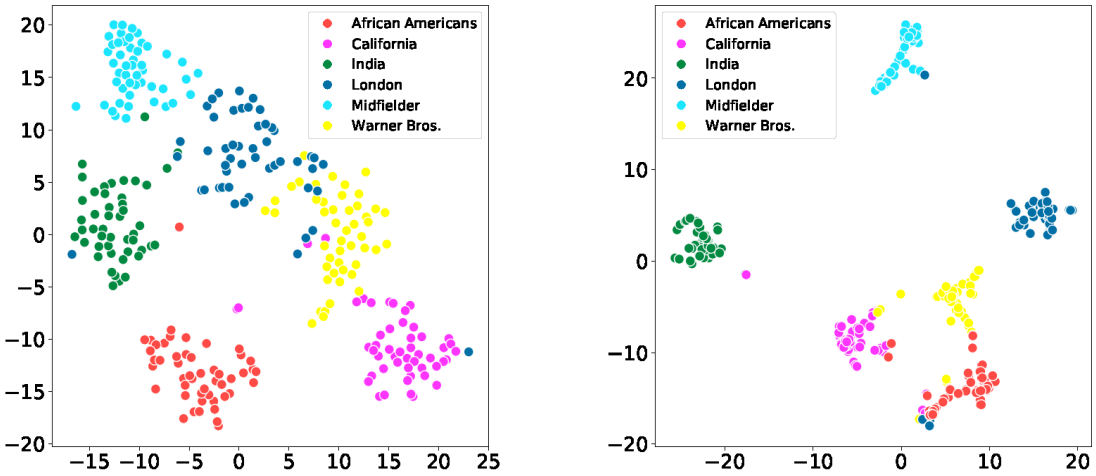
如第 3.2 节中所提到的，在构建知识图谱 schema 的时候采用频率阈值 α 来过滤掉出现次数较少的无意义的实体类型三元组。表 3.7 展示了在 FB15k 数据集上基于不同规模的 schema 训练的 SMiLE 模型的性能，其中“覆盖比率”表示过滤的实体类型三元组与所有实体类型三元组的比率。从表中可以观察到过低的频率阈值 α 会导致知识图谱整体 schema 的过大，这会进一步影响预训练阶段对比学习负采样的质量，从而导致模型表现下降；而过高的频率阈值 α 则会导致 schema 过小，采集的负样本数量变少，也会导致模型性能的下降。在 FB15k 数据集上，$\alpha = 700$ 时模型具有最优的性能效果。

表 3.7 Schema 构建时的频率阈值 α 对模型知识推理性能的影响

频率阈值 α	Schema 大小	覆盖比率	FB15k	
			F1	AUC-ROC
400	10469	0.044%	87.97	94.52
600	5532	0.023%	89.22	95.47
700	4239	0.018%	**90.76**	**96.54**
800	3528	0.015%	89.04	95.47

3.6.6 案例分析

为了验证本节提出的 SMiLE 模型的有效性和可解释性，本小节对 6 个不同上下文子图中的实体嵌入进行了可视化。具体地，从 FB15k 数据集中随机选择了 6 个中心实体，对于每个中心实体，随机采样 50 个与其直接相连的一阶邻居实体，由此构成中心实体的上下文子图实体集合。分别使用 Node2vec 模型和 SMiLE 模型计算这些上下文子图中所有实体的嵌入，并使用 T-SNE[80]对其进行降维可视化，可视化效果如图 3.5 所示。



(a) Node2vec **(b) SMiLE**

图 3.5 六种不同上下文中实体嵌入的可视化分布

从图 3.5（a）中可以观察到，Node2vec 模型难以清晰地区分不同上下文中的实体，尤其是上下文“*Warner Bros.*”中的实体和上下文“*London*”中的实体在语义空间层面存在一部分的重叠之处。相反，观察图 3.5（b），使用本章提出的 SMiLE 模型作为编码器，不同上下文中的实体能够得到很好的区分：在语义空间层面，同一上下文中实体之间的距离更近，而不同上下文之间的实体则分布

更为广泛。图 3.5（b）不同簇之间微小的空间上重叠表明了本章所提出的 SMiLE 模型在有效地建模实体上下文信息的同时，能够将不同类型实体更清晰地区分开来。为了更具体地解释图 3.5，表 3.8 中列出了与图 3.5 中实体相关的细节信息。从表中可以观察到，“*Warner Bros.*”、“*California*”、“*African Americans*”实体以及它们之间的关系构成了一个更大的上下文 schema。从直观上来看，它们之间存在一些在“*美洲*”层面上的语义联系，因此在语义空间上这些簇之间具有更近的距离。

表 3.8 FB15k 数据集中部分代表性实体名称与类型信息

	实体名称	实体类型	构成的上下文 schema
1	Warner Bros.	business.employer award.award_winner film.production_company	(award_winner, /place_lived/location, administrative_division)
2	California	government.political_district location.administrative_division	(award_winner, /person/ethnicity, book_subject)
3	African Americans	people.ethnicity book.book_subject	(administrative_division, /location/containedby, book_subject)

3.7 本章小结

本章针对知识图谱中“如何建模上下文语义信息以及如何与结构信息进行融合”的问题，提出了 schema 增强的多层级对比学习知识推理模型。首先，本章提出了一种自动从知识图谱中构建完整 schema 的方法，并分别设计了结构视图和上下文视图的实体编码器。然后，提出了在上下文层级和全局层级的正负样本采样策略，定义了多层级的对比自监督预训练目标，以充分捕获实体的上下文信息。最后在微调阶段，在三元组的监督下微调模型，以学习更细粒度的实体和关系表示。基于提出的模型，针对链接预测任务，在四个基准数据集上开展了详尽的实验，并对模型性能和具体案例进行了分析。实验结果表明，本章提出的模型能够有效建模和平衡知识图谱中的局部上下文信息和全局结构信息。

第 4 章 语义增强的对比历史建模的时序知识推理

在上一章中，论文聚焦对知识图谱中上下文语义信息进行建模，设计了多层级对比学习框架来融合和平衡知识图谱中的结构特征和上下文知识。但是，此类方法仅针对静态知识图谱进行建模，即要求知识图谱中的实体、关系和三元组是固定不变的。考虑到实际场景中的知识图谱存在着不断变动和更新的情况，在这一章将聚焦于对时序知识图谱中时序信息进行建模，如何有效地捕获其中蕴含的时序特征，以及如何将时序特征与丰富的文本语义信息进行结合，是本章进一步解决的问题。本章构建语义增强的对比历史建模的时序知识推理模型，将时序推理任务转化为查询项-候选项匹配问题，基于预训练语言模型对其进行编码，设计基于双塔架构的对比学习优化目标，通过虚拟时间前缀微调方法对模型进行训练，从而实现对知识图谱中文本和时序信息的融合与平衡，提高模型在复杂场景下的时序知识推理能力。

4.1 引言

带有时间序列信息的知识图谱被统称为时序知识图谱（Temporal Knowledge Graph，TKG），其中，知识通常以形如（头实体，关系，尾实体，时间戳）的四元组形式进行存储。由于时序知识图谱通常是不完整的，因此在时序知识图谱上的知识推理任务需要基于已知的历史事实，去推理预测四元组中的缺失实体和事实。时序知识图谱中的时间戳信息以文本的形式存在，如何有效捕捉四元组事实之间潜在的时序历史信息，是实现有效时序推理任务的关键问题。

现阶段的方法为了完成时序知识推理任务，尝试通过各种途径来捕获时序知识图谱中的时间演变信息。CyGNet[46]考虑到事实通常沿着时间轴呈现重复的模式，提出了基于时间感知复制-生成机制的时序知识图谱表示学习模型，通过识别重复发生的事实，参考过去已知的事实，从而预测未来事件。CE-NET[48]利用对比学习来建模时序知识图谱中历史和非历史依赖关系，从而避免模型在推理时对重复频繁发生事件的依赖。此外，现有的一些方法尝试利用预训练语言模型来建模和捕获时序知识图谱中潜在的时序关联。PPT[49]利用预训练语言模型来捕获四元组之间的时序关联，将时序知识推理任务转化为掩码预测任务。SST-BERT[50]设计了时间引导的掩码策略以从头训练整个预训练语言模型，从而利用语言模型捕获时间序列信息。然而，这类方法大多依赖于基于先验假设手工设计的提示模板，并且时间引导的掩码预训练策略在训练计算上通常需要很大的开销。此外，尽管语言模型在预训练阶段学习到了强大的内在语言特性，但它们总是过度倾向于关注文本语义，因此现有的基于语言模型的时序推理方法在平衡时序信息和文

本知识方面存在较大的困难。

考虑到时序知识图谱高度动态的特性，新实体的连续出现通常导致时序知识图谱需要在更复杂的场景（例如少样本归纳式场景）中预测实体。因此，本章重点研究的问题是：能否在一个统一的基于预训练语言模型的框架下有效地将时序信息整合到文本语义知识中，并适应于各种复杂场景下的时序知识推理任务。

为了解决如上问题，本章提出一种语义增强的对比历史建模时序知识推理模型 ChapTER（Semantic-augmented **C**ontrastive **H**istori**c**al Modeling Model with **P**refix-tuning for **T**emporal Knowledge Graph **R**easoning），模型整体框架如图 4.1 所示，图中展示了模型输入模板的构造方式，以及模型整体训练与推理流程。在本章 4.2 节中，定义并阐述模型框架和结构组成细节，将时序知识推理任务转化为查询-匹配问题，使用双塔架构的预训练语言模型分别对查询项和候选项进行编码，以学习得到其各自特定的语义表示。在 4.3 节中，使用实体和关系的名称和描述作为语义文本，构建融合时序上下文的模板作为模型的输入。在 4.4 节中，设计基于虚拟时间前缀的高效微调方式，在 Transformer 的每一层引入虚拟时间前缀嵌入，并冻结模型其余部分的参数。在 4.5 节中，定义正负样本的组成与采样方式，设计对比训练目标，使得模型能够融合和平衡时序历史信息与文本语义知识，赋予模型处理复杂场景下的时序知识推理任务的能力。

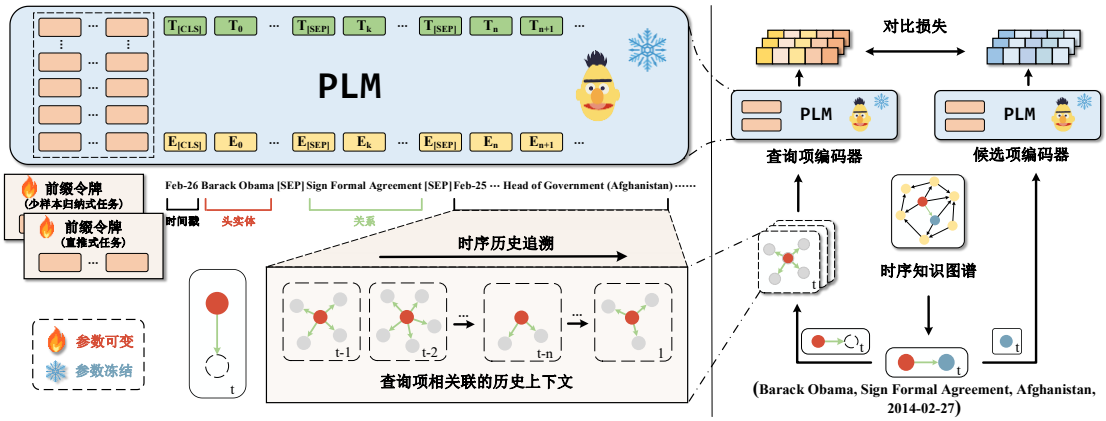


图 4.1 语义增强的对比历史建模的时序知识推理模型框架图

4.2 基于预训练语言模型的双塔推理模型

为了实现时序知识图谱中的推理任务，即给定（头实体，关系，？，时间戳）的四元组来预测尾实体，本节将四元组中带有时间戳的头实体关系对视作查询项，尾实体视作候选项，分别对查询项和编码项的特征进行编码，使用向量相似度进行匹配，从而将时序知识推理任务转化为查询项-候选项匹配任务。基于这一点，利用对比学习的方式，可以从时序知识图谱中挖掘和建模时序历史信息，并有效

地与文本语义进行融合和平衡。

如图 4.1 所示，本章提出的 ChapTER 模型是一个由两个编码器组成的双塔网络，包括了查询项编码器 $\mathcal{M}_q$ 和候选项编码器 $\mathcal{M}_k$。为了编码来自实体和关系的文本语义信息，采用基于 Transformer 的预训练语言模型来作为 ChapTER 模型的编码器，例如 BERT[40]。$\mathcal{M}_q$ 和 $\mathcal{M}_k$ 使用相同的权重进行初始化，但是分别独立进行微调。在进行尾实体预测的设定下，给定查询项 $q=\left(s,p,?,t_q\right)$，使用查询项编码器 $\mathcal{M}_q$ 对其进行编码，得到包含头实体-关系对 (s,p) 的文本信息以及时间 t 之前历史上下文的实体-关系嵌入 h_q。类似地，使用候选项编码器 $\mathcal{M}_k$ 对候选实体 o 进行编码得到文本嵌入 h_k。如公式(4-1)所示，分别取 $\mathcal{M}_q$ 和 $\mathcal{M}_k$ 最后一层隐状态的平均池化作为 h_q 和 h_k 的嵌入：

$$\begin{aligned} h_q &= \mathcal{M}_q(\mathcal{P}(q)), \\ h_k &= \mathcal{M}_k(\mathcal{P}(k)), \end{aligned} \tag{4-1}$$

其中，$\mathcal{P}(q)$ 和 $\mathcal{P}(k)$ 分别代表查询项和候选项的输入文本。

得到了查询项嵌入 h_q 和候选项嵌入 h_k 之后，四元组 (s,p,o,t) 的得分可以通过 h_q 和 h_k 之间的余弦相似度进行计算，如公式(4-2)所示，对两个嵌入之间进行点积运算：

$$f(s,p,o,t)=\cos(h_q,h_k)=\frac{h_q\cdot h_k}{\|h_q\|\|h_k\|}. \tag{4-2}$$

因此，对于查询项 q，计算查询项嵌入 h_q 与所有其他候选项实体嵌入 h_k 之间的余弦相似度，如公式(4-3)所示，将得分最高的候选项作为最终预测结果：

$$\arg\max_{k_i}\cos(h_q,h_{k_i}),\ k_i=o_i\in\mathcal{E}. \tag{4-3}$$

4.3 文本表示与输入模板构建

4.3.1 实例描述文本组成

将时序知识图谱中的四元组输入预训练语言模型，首先需要做的就是将其转化为适配语言模型的文本模板输入。基于预训练语言模型的编码器需要实体和关系的文字文本来得到对应的编码向量，为了表示四元组中的实体或关系，最具代表性的信息是名称文本，例如，ICEWS[81]（Integrated Crisis Early Warning System）数据集包括了例如“*Zalmai Rassoul*”的实体名称文本，以及例如“*Make statement*”的关系名称文本。但是通常情况下，数据集中实体和关系的名称文本很简洁，并且不同事实之间的文本存在较高的重叠情况，使得相同文本在语言模型的预训练语料库中可能指向多个不同实体，从而导致歧义问题。

为了减缓这个问题，模型引入额外的实体描述文本来丰富语义信息的表达，此类文本相比于名称文本具有更大的长度，例如，实体“*Virtue Party*”的描述文本是“*Turkey, Sunni International Religious*”。模型采集并整理了 ICEWS 源数据文档[2]中“*Country*”条目和“*Sector*”条目中的文本，以此作为实体的补充描述文本。将实体名称文本与描述文本拼接在一起，即可得到完整的实体描述 D_s。对于四元组中的关系而言，其名称文本 D_r 即可表达清晰且完整的语义。

4.3.2 融合时序上下文的输入模板

在尾实体预测任务的设定下，给定一个四元组事实，可以将其划分为两个部分：具有时间约束的实体-关系查询项 $q=(s,p,?,t_q)$ 以及候选实体项 $k=o$。对于查询项 q，与其相关历史信息保存在与“实体-关系”对相关的上下文邻居中，这些邻居四元组包含了与查询项 q 相同的头实体 s 和关系 p。如公式(4-4)所示，这些历史四元组可以被定义为：

$$\mathcal{H}(s,p,t)=\left\{(s,p,\tilde{o},t')\,|\,(s,p,\tilde{o},t')\in F,\ \tilde{o}\neq o, t'\leq t\right\}. \tag{4-4}$$

得到了四元组的历史上下文，分别对查询项 q 和候选项 k 使用两种不同的提示模板格式。对于格式为“YYYY-MM-DD”的时间戳文本 t，将其月份数字替换为相应的月份词汇文本 L_t。因此，如公式(4-5)所示，查询项 q 的输入文本模板 $P(q)$ 可以被表示为：

$$\langle cls\rangle\ L_t\,|\,D_s\,|\,D_r\ \langle sep\rangle\ \mathcal{H}(s,p,t)\ \langle sep\rangle, \tag{4-5}$$

其中，D_s 和 D_r 表示实体 s 和关系 r 对应的描述文本。类似地，如公式(4-6)所示，候选项 k 的输入文本模板 $P(k)$ 可以被表示为：

$$\langle cls\rangle\ D_s\ \langle sep\rangle. \tag{4-6}$$

4.4 时序文本编码与高效前缀微调

本章提出的 ChapTER 模型目标是在不同复杂场景中实现对时序知识图谱中历史信息和文本语义的充分融合和有效知识推理。为了实现这一目标，本节在预训练语言模型的每个 Transformer 层中引入虚拟时间前缀令牌，从而将历史和语义信息注入到基于 Transformer 的双塔模型的编码过程中。使用基于前缀的微调方法，使模型具备在直推和少样本归纳任务场景下的知识推理能力。先前的工作[82,83]探索和证明了前缀微调方法能够使得模型具备处理不同任务的能力，并且仅

[2] https://dataverse. harvard. edu/dataverse/icews

需要调整极少量的参数就能达到与全参数微调相当的性能。

具体地，使用 h 来统一表示通过 $\mathcal{M}_q$ 得到的查询项向量 h_q 和通过 $\mathcal{M}_k$ 得到的候选项向量 h_k。使用 $h^{(j)} \in \mathbb{R}^{n \times d}$ 表示第 j 层（$j \geq 1$）Transformer 层处理后的输入文本的嵌入表示，将具有 m 个令牌长度的虚拟时间前缀 p 的向量与模型每层 Tranformer 的文本令牌向量进行拼接，如公式(4-7)所示：

$$\overline{h}^{(j)} = p^{(j)} \| h^{(j)}, 0 \leq j \leq L, \tag{4-7}$$

其中 $p^{(j)}$ 表示第 j 层的虚拟前缀令牌向量，h 表示拼接后的输入令牌向量。如公式(4-8)所示，第 j 层 Transformer 的第 i 个输入令牌可以被表示为：

$$\overline{h}_i^{(j)} = \begin{cases} p_i^{(j)}, & 0 \leq i < m \\ e_i^{(j)}, & (i \geq m) \wedge (j = 0). \\ \mathrm{FFN}(\overline{h}^{(j-1)})_i, & (i \geq m) \wedge (j \geq 1) \end{cases} \tag{4-8}$$

在训练过程中，将预训练语言模型 $\mathcal{M}_q$ 和 $\mathcal{M}_k$ 的权重参数冻结，只对前缀令牌中的权重参数更新，在这一过程中，多头注意力机制的计算如公式(4-9)所示：

$$\begin{gathered} \mathrm{MHA}(h^{(j)}, \overline{h}^{(j)}) = \Big\|_{i=1}^{k} \mathrm{head}_i(h_i^{(j)}, \overline{h}_i^{(j)}) = \Big\|_{i=1}^{k} \mathrm{softmax}(Q^{(j)}, \overline{K}^{(j)\top}) \overline{V}^{(j)}, \\ Q^{(j)} = W_Q^{(j)} h^{(j)},\ \overline{K}^{(j)} = W_K^{(j)} \overline{h}^{(j)}, \overline{V}^{(j)} = W_V^{(j)} \overline{h}^{(j)}. \end{gathered} \tag{4-9}$$

其中，保持查询向量 Q 不变，使用前缀向量增强键向量 K 和值向量 V。通过在每一层 Transformer 中执行非对称的多头注意力机制，模型可以在只对前缀向量中极少量参数调整的同时，高效地泛化于不同场景下的知识推理任务。

4.5 负样本构造与对比学习训练目标

将四元组 (s, p, o, t) 拆分后分别输入查询项编码器 $\mathcal{M}_q$ 和候选项编码器 $\mathcal{M}_k$，得到对应的查询项向量 h_q 和候选项向量 h_k。在模型训练过程中，采用信息对比估计损失 InfoNCE[64]来作为模型的对比优化目标，如公式(4-10)所示：

$$\mathcal{L}_{cl} = -\log \frac{e^{(cos(h_q, h_k) - \gamma)/\tau}}{e^{(cos(h_q, h_k) - \gamma)/\tau} + \sum_{i \in \mathcal{N}_{neg}} e^{cos(h_q, h_i')/\tau}}, \tag{4-10}$$

其中 τ 是可学习的温度参数，用于控制评分函数的灵敏度。$\gamma(\gamma > 0)$ 是边际超参数，它鼓励模型对正确的四元组给出更高的分数。

使用 $\mathcal{N}_{neg}$ 代表训练过程中负样本的集合。不同于传统方法通过随机替换现有四元组中的头实体 s 或尾实体 o 来构造负样本，本小节设计了新的负样本构造方案，即通过三种类型的负样本来构造整体负样本集合 $\mathcal{N}_{neg}$，如公式(4-11)所示：

$$\mathcal{N}_{neg}=\left\{o' \mid o' \in \mathcal{N}_{in} \cup \mathcal{N}_{pre} \cup \mathcal{N}_{self},(s,p,o',t) \notin F\right\}. \tag{4-11}$$

其中，$\mathcal{N}_{in}$ 代表批次内负样本的集合，表示同一批次内的实体是彼此之间的负样本。对于批次外负样本 $\mathcal{N}_{pre}$，采用一个动态队列存储来自最近 k 个批次的实体。此外，对于尾实体预测任务的查询项 $\left(s,p,?,t_q\right)$，取其头部实体 s 本身作为自负样本 $\mathcal{N}_{self}$，这样做的目的是为了减少由于查询项与头实体之间文本语义高度重叠所导致的模型错误预测。

在模型推理的过程中，首先通过查询项编码器 $\mathcal{M}_q$ 和候选项编码器 $\mathcal{M}_k$ 分别编码得到查询项 $\left(s,p,?,t_q\right)$ 和所有候选实体的嵌入向量，然后通过查询项和候选项之间的点积得分计算即可得到实体排名。

4.6 实验设计与结果分析

4.6.1 实验任务与数据

（1）实验任务设计

为了对本章提出的 ChapTER 模型进行验证，评估其在时序知识推理任务上的有效性，本节选择在直推式时序推理任务和少样本归纳式时序推理任务上展开详细的实验。

直推式时序知识推理任务。时序知识图谱专注于处理和推理包含时间维度的知识图谱数据。时序知识推理任务旨在根据已知实体和关系，利用时序数据中的时间信息来丰富知识图谱的特征，来预测或补全知识图谱中缺失的实体或关系。该任务能够反映出模型对时序知识图谱中实体和关系随时间动态变化特性的建模能力。在直推式时序推理设置下，时序知识推理任务旨在回答形如 $\left(s,p,?,t_q\right)$ 和 $\left(?,p,o,t_q\right)$ 的查询问题。遵循传统的直推时序推理任务设定（例如 CyGNet[46]），训练集、验证集和测试集分别是时间戳范围在 T_0 到 T_1、T_1 到 T_2、T_2 到 T_3 的知识图谱（其中 $T_0<T_1<T_2<T_3$）。

少样本归纳式时序知识推理任务。在少样本归纳式时序知识推理设定下，给定一个已知的背景时序知识图谱 $\mathcal{G}_B \subseteq \mathcal{E}_B \times \mathcal{R} \times \mathcal{E}_B \times \mathcal{F}$，未见实体 e' 属于集合 $\mathcal{E}'$，其中 $\mathcal{E}_B \cap \mathcal{E}'=\varnothing$。假设对于每个未见实体 e'，有 K 个相关联的已知四元组事实，记为 (e',p,e^*,t) 或 (e^*,p,e',t)，其中 $e^* \in \mathcal{E}_B \cup \mathcal{E}'$。少样本归纳式时序推理的目标是从包含未见实体的未见四元组中回答形如 $\left(e',p,?,t_q\right)$ 或 $\left(?,p,e',t_q\right)$ 的查询问题。

（2）实验评估指标

为了评估本章所提出模型在时序知识推理任务上的性能，采用以下指标作为性能评估指标：

平均倒数排名（Mean Reciprocal Rank，MRR）。MRR 不仅能够衡量模型预测的准确性，还能够反映模型预测结果的排序质量。对于单个查询，根据模型的预测结果对所有可能的实体进行排序，可以得到正确实体在排序列表中的位置。如果正确实体出现在第 k 个位置，那么该查询的倒数排名（MR，reciprocal rank）定义为 $\frac{1}{k}$。MRR 是所有查询的倒数排名的平均值，具体计算如公式(4-12)所示：

$$MRR = \frac{1}{n}\times\left(\frac{1}{k_1} + \frac{1}{k_2} + ... + \frac{1}{k_n}\right), \tag{4-12}$$

其中，$k_1,k_2,...,k_n$ 是每个查询对应的正确实体在排序中的位置，n 代表查询的总数。MRR 的取值范围为[0,1]，值越接近 1 表示模型的性能越好。如果模型无法找到正确的实体，或者正确实体排名靠后，MRR 值会接近 0，表示模型性能较差。

正确实体命中率（Proportion of Correct Entity Rank，Hits@N）。Hits@N 衡量的是正确答案出现在模型预测结果的前 N 个位置的频率。不同于 MRR 指标，Hits@N 关注的是正确答案的具体排名位置，而不是倒数排名。对于每个查询，如果正确答案出现在模型预测的前 N 个结果中，则记为一次命中（hit）。对于所有的查询，统计正确答案出现在前 N 个位置的总次数，除以查询的总数即可得到 Hits@N 的值，如公式(4-13)所示：

$$Hits@N = \frac{\Sigma\left(hits@N(i)\right)}{m}, \tag{4-13}$$

其中，m 表示查询总次数，$hits@N(i)$ 当且仅当正确答案出现在前 N 个预测结果中时为 1，否则为 0。此外，传统的方法在计算 Hits@N 的时候使用的过滤设置存在缺陷，因为它在进行排名之前过滤掉所有具有相同实体和关系的三元组，而没有考虑到四元组事实的时间戳属性。但实际上，只有在查询时间点发生的四元组事实才应该被过滤掉。因此，本章实验的 Hits@N 指标均采用时间感知的过滤设置，该设置保证模型在计算最终排名的时候仅过滤掉在查询时间点发生的四元组。

（3）实验数据集

本章实验在直推式和少样本归纳式两种任务设置下评估模型在时序知识推理任务上的表现。对于直推式时序知识推理任务，使用六个公开的基于事件的时序知识图谱数据集：ICEWS14[84]、ICEWS18[84]、ICEWS05-15[84]、ICEWS14*[85]、WIKI[86]和 YAGO[87]。直推式任务数据集的详细统计信息如表 4.1 所示。对于少样本归纳式时序知识推理任务，使用了三个公开的评测基准数据集：ICEWS14-OOG[20]、ICEWS18-OOG[20]和 ICEWS0515-OOG[20]。少样本归纳式任务数据集的详细统计信息如表 4.2 所示。由于现有的 ICEWS 数据集没有提供具

体的实体描述文本，因此本章通过结合每个实体在 ICEWS 源数据中对应的“*Country*”条目和“*Sector*”条目来构建实体描述文本。

表 4.1 直推式时序知识推理任务数据集参数统计

数据集	训练集	验证集	测试集	实体数	关系数	时间戳	时间间隔
ICEWS14	63685	13823	13222	7128	230	365	1 day
ICEWS18	373018	45995	49545	23033	256	304	1 day
ICEWS05-15	322958	69224	69147	10488	251	4017	1 day
ICEWS14*	74845	8514	7371	7128	230	365	1 day
WIKI	539286	67538	63110	12554	24	232	1 year
YAGO	51205	10973	10973	10038	10	194	1 year

表 4.2 少样本归纳式时序知识推理任务数据集参数统计

数据集	源图四元组	训练集	验证集	测试集	实体数	关系数	时间戳	时间间隔
ICEWS14-OOG	83448	5772	718	705	7128	230	365	1 day
ICEWS18-OOG	444269	19291	2425	2373	23033	256	304	1 day
ICEWS0515-OOG	448695	10115	1271	1228	10448	251	4017	1 day

4.6.2 实验设置

基线模型。本章实验选取时序知识图谱上直推式任务和少样本归纳式任务的代表性模型作为基线模型。具体地，针对直推式时序知识推理任务，选取了 11 个代表性基线模型，包括 8 个基于图结构的方法和 3 个最新的基于预训练语言模型的方法。其中，基于图结构的方法可以细分为：1）传统知识嵌入方法：基于语义匹配的 DistMult[13]、基于张量分解的 ComplEx[57]、将三元组关系建模为旋转操作的 RotatE[23]；2）时序知识表示方法：TTransE[86]、TA-DistMult[88]、DE-SimplE[89]、TNTComplEx[90]和具有基于时间感知复制生成机制的 CyGNet[46]。3）基于预训练语言模型的方法包括：基于文本的对比编码模型 SimKGC[69]、生成式知识推理模型 KGT5[91]以及融合上下文的生成式知识推理模型 KGT5-context[92]。针对少样本归纳式时序知识推理任务，选取了 10 个代表性基线模型，可以细分为 5 类：1）传统的知识推理方法 ComplEx[57]和 BiQUE[93]；2）传统的时序知识推理方法 TNTComplEx[90]、TeLM[94]和 TeRo[95]；3）归纳式知识

推理方法 MEAN[96]和 LAN[97]；4）基于元学习的少样本归纳式知识推理方法 GEN[98]和 FILT[20]；5）基于预训练语言模型的知识推理方法 SimKGC[69]。

参数设置。训练阶段采用 AdamW 优化器，使用线性学习率衰减来训练模型。查询项编码器 $\mathcal{M}_q$ 和候选项编码器 $\mathcal{M}_k$ 使用 BERT-base-uncased[3]的参数进行初始化。为了平衡模型效果与训练效率，将模型的输入长度即实体描述文本长度设置为最大 50。可学习的温度系数 τ 初始化为 0.05，边际超参数 γ 设置为 0.02。批次外负样本 $\mathcal{N}_{pre}$ 的动态队列大小设置为 2。对于所有基线模型，均采用其论文中的默认配置。在直推式推理任务上部分基线模型的结果取自 xERTE[84]，在少样本归纳式推理任务上部分基线模型的结果取自 FILT[20]。具体地，在验证集上对模型的超参数例如学习率，提示模板长度，批次内负样本数量，批次外负样本动态队列大小、训练周期数以及输入令牌最大数量进行网格搜索，如表 4.3 所示。

表 4.3 模型超参数搜索范围

超参数	搜索空间数值
学习率	{1e-5, 3e-5, 5e-4, 5e-3}
提示模板长度	{2, 4, 6, 10, 15, 20, 50}
批次内负样本数量	{32, 64, 128, 256, 512, 764, 1024}
批次外负样本动态队列大小	{1, 2, 4}
训练周期数	{10, 15, 20}
输入令牌最大数量	{50, 60, 70}

实验环境。模型采用 PyTorch 框架进行编码实现，所有实验均在 24G 的 RTX 3090 显卡上开展进行，具体地，本章实验所使用的相关硬件配置如表 4.4 所示。

表 4.4 实验环境详细配置

配置项	具体设备
操作系统	Ubuntu 20.04.6 LTS
内存	504G
GPU	NVIDIA GeForce RTX 3090 (24G)
CPU	96 AMD EPYC 7413 24-Core Processor
CUDA	11.8

[3] https://huggingface.co/google-bert/bert-base-uncased

为了保证实验比较的公平性，对于以预训练语言模型为底座的基线模型SimKGC、KGT5 和 KGT5-context，根据其开源代码进行了复现，使其适配于时序知识图谱数据集，保证在模型编码的时候充分融合时间信息。具体实现上，将时间戳文本与其对应的输入文本进行拼接，将它们的输入格式从三元组修改为四元组。例如，KGT5 中的尾实体预测查询项的输入文本可以被构建为“*predict tail: 2014-01-01 | Benjamin Netanyahu | Sign formal agreement*”。

4.6.3 对比实验结果

本小节分别在直推式时序知识推理任务和少样本归纳式知识推理任务上验证了模型的效果，并与各种具有代表性的 SOTA 模型进行了比较。在后文表述中，使用 ChapTER 指代本章模型。通过这些对比，可以清楚地看到 ChapTER 在不同场景下处理时序知识推理任务时的性能表现。

直推式时序知识推理效果。在直推式时序知识推理实验中，比较了基于图的方法和基于 PLM 的方法与本章 ChapTER 模型之间的性能，具体结果如表 4.5 和表 4.6 所示。

表 4.5 各模型在 ICEWS 系列数据集上的直推式任务实验效果统计

模型	ICEWS14			ICEWS18			ICEWS05-15		
	MRR	H@3	H@10	MRR	H@3	H@10	MRR	H@3	H@10
DistMult[13]	16.2	17.9	25.3	10.2	10.3	21.3	28.7	32.2	47.5
ComplEx[57]	21.3	23.1	35.2	21.0	23.5	39.9	31.7	35.7	52.0
RotatE[23]	20.9	23.9	44.0	12.8	14.9	31.9	24.7	29.0	48.2
TTransE[86]	13.4	17.3	34.6	8.3	8.6	21.9	15.7	19.7	38.0
TA-DistMult[88]	26.5	30.2	45.4	16.8	18.4	33.6	26.5	30.2	45.4
DE-SimplE[89]	32.7	35.7	49.1	19.3	21.9	34.8	35.0	39.0	52.8
TNTComplEx[90]	32.1	36.0	49.1	21.2	24.0	36.9	27.5	30.8	42.9
CyGNet[46]	32.7	36.3	50.7	**24.9**	**28.3**	**42.6**	**35.0**	**39.1**	**52.9**
SimKGC[69]	26.7	28.9	41.3	21.0	23.5	34.9	30.9	33.7	47.2
KGT5[91]	26.1	29.7	45.3	22.1	25.0	39.6	26.4	29.5	41.1
KGT5-context[92]	28.0	33.3	47.8	22.8	26.7	41.1	30.4	36.2	48.9
ChapTER	**33.2**	**37.0**	**51.5**	24.4	27.6	41.2	33.1	36.9	52.5

表 4.5 中三个 ICEWS 系列数据集上的结果显示，ChapTER 在与基线模型的对比中取得了最先进的或具有竞争力的性能。具体来说，在 ICEWS14 数据集上，ChapTER 以显著的优势超越了所有基于 PLM 的方法，在 MRR 指标上提升了 18.5%（从 0.280 提升到 0.332）。值得注意的是，与全参数微调的基于 PLM 的基线模型相比， ChapTER 模型仅通过调整前缀令牌中的少量参数就实现了更好的性能，这证明了本章提出的虚拟时间前缀微调在时序知识推理任务中的有效性。

与基于图的方法相比，ChapTER 在 ICEWS14 数据集上超越了现有最新的基线模型。结果表明，ChapTER 在利用历史上下文建模未来时间戳的实体表示方面具有优势。在 ICEWS18 和 ICEWS05-15 数据集上，ChapTER 性能略低于 CyGNet 模型，但也能够实现具有竞争力的效果。原因在于：ICEWS18 和 ICEWS05-15 数据集中涉及的事件和实体更为密集与频繁，这表明在同一时间戳下发生的事件更多。由于 CyGNet 专注于捕获历史发生过的事实的重复性，它擅长预测具有重复历史背景的事件，但在建模时序知识图谱文本语义方面则表现不佳。由于受到预训练语言模型输入长度的限制，冗长的历史事件文本在模型输入部分被截断，ChapTER 在这两类数据集上的性能会略微落后于 CyGNet。

为了进一步证明模型在其他分布数据集上的有效性，在 WIKI 和 YAGO 数据集上开展了实验。表 4.6 中的结果表明 ChapTER 的性能要显著优于 SOTA 的基线模型，例如在 WIKI 上 ChapTER 的 MRR 指标为 53.4，高于 SimKGC 的 50.5；在 YAGO 数据集上 ChapTER 的 MRR 指标也要比 SimKGC 模型提升 11%。这些实验结果证明模型在不同类型的时序知识图谱数据集上也具有通用的优异性能。

表 4.6 各模型在 WIKI 和 YAGO 数据集上的直推式任务实验效果统计

模型	WIKI			YAGO		
	MRR	H@3	H@10	MRR	H@3	H@10
DistMult[13]	10.9	11.0	16.8	12.0	12.3	14.9
ComplEx[57]	24.5	27.3	34.8	12.1	12.4	14.8
TTransE[86]	29.3	34.4	42.4	5.7	9.0	11.2
TA-DistMult[88]	44.5	48.7	51.7	11.5	11.9	13.9
DE-SimplE[89]	45.4	47.7	49.6	11.7	12.1	13.5
TNTComplEx[90]	45.0	49.3	52.0	12.0	12.1	13.6
CyGNet[46]	33.9	36.1	41.9	12.5	12.7	14.8
SimKGC[69]	50.5	54.0	61.8	14.0	14.2	20.0
ChapTER	**53.4**	**57.0**	**65.3**	**14.8**	**14.4**	**20.2**

少样本归纳式时序知识推理效果。本小节在 ICEWS14-OOG、ICEWS18-OOG 和 ICEWS0515-OOG 数据集上验证 ChapTER 模型在更为复杂的少样本归纳式场景下的时序知识推理性能，同时考虑了样本数为 1（1-shot）和样本数为 3（3-shot）两种设置，实验结果分别如表 4.7 和表 4.8 所示。可以看出，ChapTER 模型显著优于现有的少样本归纳式时序知识推理基线模型。具体地，在 ICEWS14-OOG 数据集上，ChapTER 在 Hits@10 指标上取得了显著提升（在 1-shot 设定下从 41.0 提升到 75.0，在 3-shot 设定下从 47.5 提升到 76.1），在 3-shot 设定下的 Hits@3 指标略逊于 FILT 模型。此外，表 4.7 和表 4.8 中还展示了 ChapTER 在这三个数据集上的零样本（Zero-shot）推理性能，从表中可以观察到 ChapTER 在 Zero-shot 的设定下甚至也能取得比大多数基线模型在少样本设定下更好的性能。总的来说，ChapTER 在少样本归纳式推理任务上的卓越表现证明了：它能够有效地利用 PLM 中的丰富历史信息和先验知识，以适应新的、未见过的实体和场景。这种知识迁移的能力对于时序知识推理尤为重要，因为它使得模型能够在面对有限或不完整信息的情况下，仍然做出准确的预测和推理。

表 4.7 各模型在 ICEWS 系列数据集上的少样本归纳式任务（1-shot）实验效果统计

模型（1-shot）	ICEWS14-OOG			ICEWS18-OOG			ICEWS0515-OOG		
	MRR	H@3	H@10	MRR	H@3	H@10	MRR	H@3	H@10
ComplEx[57]	4.8	4.5	9.9	3.9	4.8	8.5	7.7	7.4	12.9
BiQUE[93]	3.9	4.1	7.3	2.9	3.3	6.4	7.5	7.2	13.0
TNTComplEx[90]	4.3	3.3	10.2	4.6	4.3	8.7	3.4	3.1	0.6
TeLM[94]	3.2	2.1	6.3	4.9	4.5	8.4	8.0	7.7	13.8
TeRo[95]	0.9	0.5	1.5	0.7	0.6	1.3	1.2	0.8	2.4
MEAN[96]	3.5	3.2	8.2	1.6	1.2	4.3	1.9	1.7	5.2
LAN[97]	16.8	19.9	42.1	7.7	6.7	19.9	17.1	18.0	36.7
GEN[98]	23.1	25.0	37.8	17.1	18.9	28.9	26.8	30.8	41.3
FILT[20]	27.8	30.5	41.0	19.1	20.9	31.6	27.3	30.3	40.5
SimKGC[69]	34.6	39.9	70.5	24.3	28.0	**54.9**	31.2	**37.5**	62.9
ChapTER	**36.4**	**42.8**	**75.0**	**25.7**	**28.4**	54.7	**31.9**	36.8	**64.4**
ChapTER -Zero shot	36.1	41.9	75.2	25.7	28.4	54.4	31.5	36.8	63.8

表 4.8 各模型在 ICEWS 系列数据集上的少样本归纳式任务（3-shot）实验效果统计

模型（3-shot）	ICEWS14-OOG			ICEWS18-OOG			ICEWS0515-OOG		
	MRR	H@3	H@10	MRR	H@3	H@10	MRR	H@3	H@10
ComplEx[57]	4.6	4.6	8.9	4.4	4.2	9.3	7.6	7.1	12.0
BiQUE[93]	3.5	3.0	6.6	3.2	3.7	7.3	8.3	7.7	14.4
TNTComplEx[90]	4.4	4.2	9.6	4.8	4.4	8.2	3.7	3.6	7.1
TeLM[94]	3.5	2.3	7.7	1.9	1.3	5.4	7.2	7.2	15.1
TeRo[95]	1.0	0.2	2.0	0.6	0.3	0.6	2.3	1.7	4.0
MEAN[96]	14.4	14.5	33.9	10.1	11.4	28.3	14.8	17.5	38.4
LAN[97]	19.9	25.5	50.0	12.7	16.5	34.4	18.2	19.1	46.7
GEN[98]	23.4	28.4	38.9	21.6	25.2	35.1	32.2	36.2	50.7
FILT[20]	32.1	35.7	47.5	26.6	**29.8**	41.7	**37.0**	**39.1**	51.6
SimKGC[69]	36.3	42.6	72.1	25.2	29.5	55.5	31.8	38.2	63.7
ChapTER	**37.9**	**44.6**	**76.1**	**26.6**	29.6	**55.8**	32.3	37.3	**64.8**
ChapTER -Zero shot	36.1	41.9	75.2	25.7	28.4	54.4	31.5	36.8	63.8

4.6.4 消融实验

为了进一步分析 ChapTER 模型各个组件对最终性能的贡献和影响，本小节在 ICEWS14 和 ICEWS14-OOG 数据集上进行了消融研究，完整的结果如表 4.9 所示。具体地，消融模块可以细分为：输入文本组成、负样本组合和模型训练策略。

输入文本组成。为了验证第 4.3 节中提出的文本表示方法的有效性，对模型输入文本的三个方面进行消融：移除时间戳文本（w/o timestamp）、移除描述文本（w/o description）和移除历史上下文文本（w/o historical contexts）。在表 4.9 中，第 2-4 行报告了 ChapTER 模型在不同输入组成下的表现性能。与 ChapTER 相比，每个消融模型的性能都表现出轻微的下降。直观上看，移除描述文本造成了最大程度的性能下降，在两个数据集上 MRR 分别下降了 3.9%和 14.7%，因为基于预训练语言模型（PLM）的方法很大程度上依赖于文本质量。如果能够引入更丰富的实体描述文本，ChapTER 的性能能够进一步得到提升。表 4.9 的第 3-4 行报告了时序历史信息对 ChapTER 的重要性。分析认为造成该现象主要有两个原因：1）尽管时间戳文本包含了必要的时间信息，但此类文本往往很简洁，容

易被冗长的文本淹没；2）相比之下，历史上下文文本对模型在时间建模方面的贡献更大，因为它们引入了时序的、最近邻的历史，为四元组查询项提供了丰富的背景知识。因此，ChapTER 模型可以从丰富的历史上下文中捕捉到更准确的时序历史信息。

表 4.9 模型在 ICEWS14 和 ICEWS14-OOG（Zero-shot）上消融实验效果统计

序号	模型	ICEWS14		ICEWS14-OOG	
		MRR	H@10	MRR	H@10
1	**ChapTER**	**33.2**	**51.5**	**36.1**	75.2
2	w/o timestamp	32.1	50.5	35.8	73.9
3	w/o description	31.9	49.7	30.8	65.1
4	w/o historical contexts	32.4	48.4	35.0	70.6
5	w/o pre-batch negatives	32.6	50.9	35.0	72.6
6	w/o self negative	32.9	51.0	35.8	**75.5**
7	w/o pre-batch & self negatives	32.6	50.7	34.3	73.4
8	w/ last layer tuned	32.3	50.4	34.7	74.8
9	w/ last 6 layers tuned	31.6	49.9	35.9	74.8
10	w/ first layer tuned	31.1	49.4	33.3	72.1
11	w/ fully tuned	31.6	49.3	35.7	74.8

负样本组成。表 4.9 的第 5-7 行展示了 ChapTER 在 ICEWS14 和 ICEWS14-OOG 数据集上使用不同类型的训练负样本（批次内负样本 $\mathcal{N}_{in}$、批次外负样本 $\mathcal{N}_{pre}$ 和自负样本 $\mathcal{N}_{self}$）的性能变化。具体地，对 ChapTER 模型的负样本组成从三个方面进行消融：移除 $\mathcal{N}_{pre}$ 负样本（w/o pre-batch negatives）、移除 $\mathcal{N}_{self}$ 负样本（w/o self negative）以及同时移除 $\mathcal{N}_{pre}$ 和 $\mathcal{N}_{self}$（w/o pre-batch & self negatives）。从表 4.9 的第 5-7 行可以观察到，同时移除 $\mathcal{N}_{pre}$ 和 $\mathcal{N}_{self}$ 比单独移除其中任一部分都会导致更差的性能结果。由于自负样本的存在能够减少 ChapTER 对简单文本匹配的依赖，它倾向于提高模型的 Hits@1 指标，但同时会降低 Hits@10（例如，在 ICEWS14-OOG 数据集上，Hits@10 从 75.5 降低到了 75.2）。此外，本小节进一步分析了模型训练过程中批次内负样本数量对模型整体性能的影响，如图 4.2 所示。随着负样本数量的增加，模型 MRR 指标从 19.2 稳步提升到了 32.2，但当负样本数量大于 768 时，模型性能的提升变得很微弱。总的来说，每种类型的负样本都对 ChapTER 的最终结果作出了贡献。批次内负

样本 $\mathcal{N}_{in}$ 有助于模型在训练批次内进行有效的对比学习，批次外负样本 $\mathcal{N}_{pre}$ 使模型能够从先前批次中学习并泛化到新的实例，而自负样本 $\mathcal{N}_{self}$ 通过提供与正样本相似但又不完全匹配的样本，促使模型更加关注细节和深层次的特征。

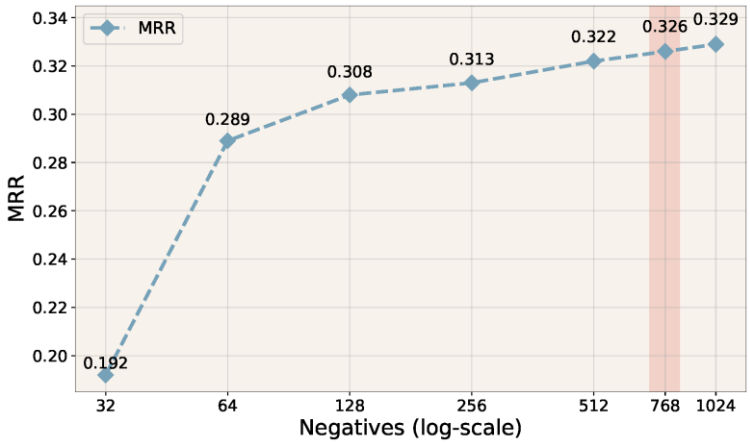


图 4.2 批次内负样本数量对模型性能在 MRR 指标上的影响

模型训练策略。表 4.9 的第 8-11 行总结了对模型不同部分层进行微调时 ChapTER 性能的变化。可以观察到，ChapTER 的性能优于全参数微调情况下的模型，分析原因认为：（1）通过虚拟时间前缀微调的 ChapTER 模型能够有效地捕获时序历史信息；（2）过多的微调参数可能导致模型对文本信息过拟合，从而忽视时间关联；（3）在 ICEWS14-OOG 数据集上，ChapTER 的性能受到微调参数的变化影响较小，因为在归纳式时序知识推理任务中，对未见实体的文本信息建模更为关键。此外，比较表 3.9 中第 8 行和第 10 行，可以发现调整 PLM 模型底层参数相较于调整顶层参数能够获得更好的性能，原因在于 PLM 模型中的较低的 Transformer 层通常能够捕获低层次的语义特征，这类语义特征对时序知识推理任务更为重要。

4.6.5 模型性能分析

在本小节中，为了进一步探究模型的性能，将针对模型效率、模型捕获时间信息的能力、不同前缀微调策略的影响、前缀模板长度的影响以及不同预训练语言模型的影响进行更深入的分析。

模型效率层面的变化。表 4.10 中详细阐述了 ChapTER 模型以及其他基于 PLM 的方法在模型训练参数量与训练时间上的具体数据。通过利用高效的调整策略，ChapTER 在对更少参数量进行微调，以及更少训练时间的情况下，实现了更优异的性能。与 SimKGC 相比，ChapTER 在训练时间上快了 1.4 倍，仅对 0.99M 的参数进行了微调，而 SimKGC 则需要微调近 670.3M 的参数，占比仅为 0.15%。与最近提出的序列到序列的生成式知识推理模型 KGT5 相比，ChapTER

在对比例仅为 0.6%的参数量进行微调的情况下，取得了更优异的性能，并且训练时间快了 12 倍。原因在于 KGT5 需要从头开始训练 T5[99]模型，并且依赖于任务特定的输入提示模板。此外，在推理过程中，由于巨大的解码搜索空间限制，KGT5 的时间开销非常大。这表明 ChapTER 在实现更优异性能的同时，在时间和计算效率上也更为高效。

表 4.10 各模型在 ICEWS14 数据集上的训练效率数据统计

模型	预训练模型基座	模型总参数量	训练参数量	训练时间/轮
SimKGC	BERT-base	218.9M	218.9M	3.2min
	BERT-large	670.3M	670.3M	20.0min
KGT5	T5-small	60.5M	60.5M	27.6min
	T5-base	223M	223M	42.6min
KGT5-context	T5-small	60.5M	60.5M	38.5min
	T5-base	223M	223M	55.5min
ChapTER	BERT-base	219.3M	0.37M	3.3min
	BERT-large	671.3M	0.99M	14.0min

模型对时序信息的建模能力。为了进一步研究 ChapTER 是如何实际利用历史上下文信息的，如表 4.11 所示，从三个方面分析了时序历史建模对模型的影响：“是否在模板中加入时间戳文本”、“历史事件的排列顺序”和“历史上下文的表达形式”。从表 4.11 中可以观察到：1）在对文本输入进行构造时，移除四元组的时间戳，或者使用随机的时间戳都会导致 ChapTER 模型性能下降；2）针对于历史序列的排列顺序，“按事件发生时间由近及远排列”情况下的模型效果比“按时间由远及近或随机顺序排列”情况下的模型效果更好，这表明了更近发生的历史事件对未来的时序预测具有更高的贡献；3）将历史上下文以两种方式进行构建：实体层面的拼接（将与查询项相关的所有历史实体按顺序进行拼接）和四元组层面的拼接（将与查询项相关的所有完整的历史四元组按顺序进行拼接）。结果表明，在相同的情况下，相比于以实体的为单位拼接的历史上下文文本，以四元组为单位串联历史上下文能够让 ChapTER 模型取得更好的性能，原因在于：四元组形式的上下文能够提供更细致和完整的事件演化历史。总的来说，该分析实验进一步证明了 ChapTER 模型能够有效地从历史上下文中挖掘和建模时序信息。

表 4.11 不同的时序上下文构建策略对模型性能的影响

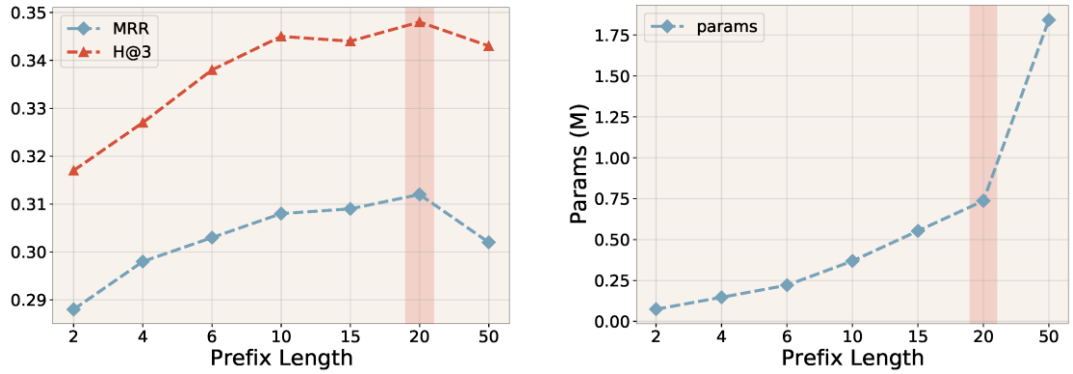
时序上下文构建策略	模型	ICEWS14		ICEWS14-OOG	
		MRR	H@10	MRR	H@10
Origin	**ChapTER**	**33.2**	**51.5**	**36.1**	**75.2**
Timestamp Text	w/o timestamp	32.1	50.5	35.8	73.9
	random timestamp	31.9	49.7	33.5	73.2
Historical Sequence	history descending order	33.2	51.5	36.1	75.2
	history ascending order	32.2	49.8	34.4	72.1
	history random order	32.8	50.4	34.9	74.3
Form of Context	pairs	33.2	51.5	36.1	75.2
	entities	32.4	50.2	35.9	73.4

不同前缀微调策略对模型性能的影响。由于 ChapTER 模型是基于虚拟时间前缀提示进行的微调，因此，模型在训练的时候仅对前缀向量进行梯度计算，同时冻结预训练语言模型的其余参数。为了进一步讨论不同前缀微调方法对 ChapTER 性能的影响，表 4.12 中总结和比较了在 ICEWS14 数据集上使用两种前缀微调策略（Prefix-tuning[82]和 P-tuning V2[83]）的 ChapTER 模型实验结果。从表 4.12 中可以观察到，使用具有重参数化编码器（MLP）的 P-tuning V2 方法比使用 Prefix-tuning 方法微调的 ChapTER 性能更好（前者 MRR 指标为 33.2，后者 MRR 指标为 32.1）。此外，表 4.10 中还展示了具有不同重参数化模块的 P-tuning V2 微调方法对 ChapTER 的性能影响。结果显示，MLP 重参数化模块为模型引入了更多可训练参数，在性能上带来了轻微的提升，但其具体效果在不同的数据集和任务设置中会有一定程度上的不同。

表 4.12 ICEWS14 数据集上不同的前缀微调策略对模型参数、效率及性能的影响

模型	重参数编码器	训练参数量	训练时间/轮	MRR	Hits@3	Hits@10
ChapTER - Prefix Tuning	MLP	47.3M	4.2min	32.1	35.8	50.3
ChapTER - P-tuning v2	MLP	19.7M	3.6min	**33.2**	**37.0**	**51.5**
ChapTER - P-tuning V2	Embedding	0.37M	3.3min	30.8	34.5	49.1

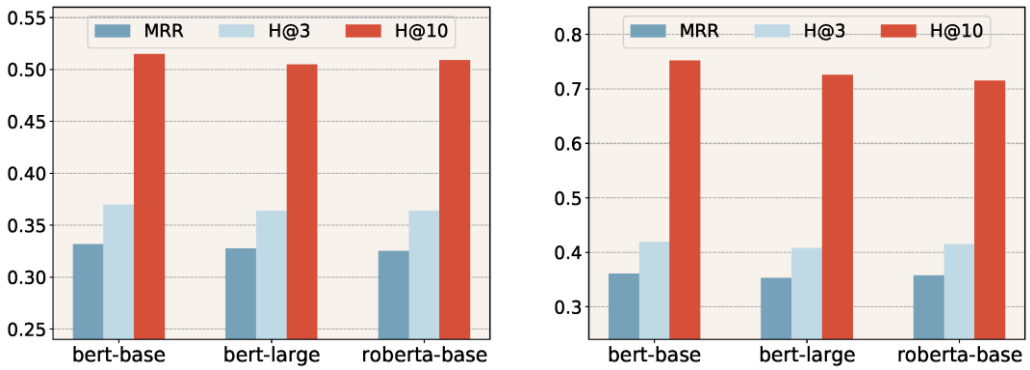
前缀模板长度对模型性能的影响。为了探究前缀模板对模型性能的影响，图 4.3 展示了 ChapTER 模型的性能和训练参数量随前缀模板长度的变化情况。实验结果表明，当前缀长度从 2 增加到 20 时，模型性能与前缀长度呈现出轻微的正相关（MRR 指标从 28.8 增涨到 31.2），同时训练的参数量也在增加（从 0.074M 增加到 0.737M）。但是，前缀长度的进一步增加会导致模型性能的下降（MRR 指标从 31.2 下降到 30.2）。这些实验结果证明：适度增加前缀长度可以提高模型对时序信息和文本信息的捕捉能力，从而提升推理性能；而过长的前缀可能会导致模型学习过程的复杂度过高，额外的参数量会给模型带来更复杂的训练挑战。



(a) MRR & Hits@3指标变化曲线 **(b) 训练参数量变化曲线**

图 4.3 前缀模板长度对模型性能以及训练参数量的影响

不同预训练语言模型基座对模型性能的影响。图 4.4 中比较了使用不同预训练语言模型时，ChapTER 模型的性能变化。从图 4.4 中可以观察到，使用三种不同的 PLM 基座时，ChapTER 在两个数据集上均取得了相近的良好性能效果，其中基于 BERT-base 的 ChapTER 模型性能略胜于其他两类模型。这一结果表明 ChapTER 模型对于具有不同参数和不同大小的 PLM 基座具有鲁棒性。除此之外，使用能够处理更长输入上下文的 PLM 模型作为基座能够进一步提高 ChapTER 模型的性能。



(a) ICEWS14数据集 **(b) ICEWS14-OOG数据集**

图 4.4 ICEWS14 和 ICEWS14-OOG 数据集上不同的 PLM 基座对模型性能的影响

4.7 本章小结

本章针对时序知识图谱中“如何有效地捕获和融合时序历史信息与文本语义知识，并能够适应于各种复杂场景下的时序知识推理任务”的问题，提出了基于语义增强的对比历史建模方法来实现时序知识推理。首先，本章将时序知识推理任务转化为了查询项-候选项匹配的任务形式，基于这一点提出了基于预训练语言模型的双塔推理架构，设计了双塔编码器来分别对查询项文本和候选项文本进行编码，使用余弦相似度来计算查询项和候选项之间的匹配程度。然后，提出了融合时序上下文的输入模板构造方法，定义了查询项和候选项的文本组成内容和格式，结合查询项的时间戳信息采集对应的时序上下文，从而将时序历史拼接融入到输入模板中。紧接着，提出了基于虚拟时间前缀的高效微调方法来对模型进行微调，在仅需对极少量参数进行调整的情况下，使模型具备在直推和少样本归纳任务场景下的知识推理能力。最后，定义了模型对比学习负样本的组成方式，以及模型训练的对比优化目标。基于提出的模型，在直推式和少样本归纳式时序知识推理任务上展开了详尽的实验，并对模型性能进行了分析。实验结果表明，本章提出的模型能够在复杂场景下有效建模和平衡时序知识图谱中的时序信息与文本语义知识。

第 5 章 总结与展望

5.1 本文总结

知识图谱作为一种高效的知识表示和组织方式，以三元组的形式存储着世界知识和领域知识，能够精确地为各类互联网应用提供可靠知识信息，因此基于知识图谱的知识推理任务对于当前的研究具有重要意义。现阶段主流的知识推理方法通过利用神经网络来对知识图谱中的实体和关系建模并学习可表示的向量，通过向量间的运算来完成知识推理任务。尽管现有方法在部分数据集上表现良好，但其通常只关注三元组的局部结构，未能全面挖掘知识图谱中的全局结构特征、上下文知识、文本语义与时序历史等异质信息。因此，论文聚焦基于知识图谱的知识推理任务，从知识图谱中的异质知识融合角度出发，探究了知识图谱中各类信息的特性，并根据其特殊的性质，设计了不同的对比式自监督模型从中挖掘出潜在的信息，并对异质信息进行有效的融合。本论文主要工作如下：

（1）对知识图谱的定义做出了解释，针对知识图谱的背景与发展进行了详细的阐述，对知识推理任务进行了定义，对知识表示和推理方法与知识图谱异质信息融合方法的国内外研究现状进行了详细介绍，针对现有的知识融合方法以及知识图谱自监督学习技术细节进行了介绍。

（2）针对“如何在知识图谱中有效地建模上下文语义信息，并且将其与结构信息进行有效融合”的问题，提出了 schema 增强的多层级对比学习知识推理模型。论文采用知识图谱的 schema 作为上下文语义的载体，基于这一假设，设计了从知识图谱中构建完整的 schema 的方法。为了精确捕获实体在不同层级的多维度信息，论文设计了结构视图和上下文视图的实体编码器。紧接着，设计了一种 schema 引导的在上下文层级和全局层级上的正负样本采样策略。在预训练阶段，通过定义多层级的对比自监督预训练目标，模型能够更加充分地捕获实体的上下文信息，从而提升知识推理的准确性。微调阶段，模型在三元组的监督下进行微调，以便学习到更为细粒度的实体和关系表示。最后进行实验分析，在链接预测的下游任务上，对比基于图结构的基线模型和基于关系建模的基线模型，本章提出的模型均具有优异的性能。此外，论文还对模型的进行了消融实验、性能分析与案例分析，进一步证明了模型各模块在建模局部上下文信息与全局结构信息的有效性。

（3）针对“如何有效融合知识图谱中的时序信息与文本语义知识，并实现在各种复杂场景下的时序知识推理任务”的问题，论文提出了语义增强的对比历史建模时序知识推理模型。首先，论文将时序知识推理任务了转化为查询项与候

选项匹配的问题，借助于预训练语言模型极强的文本语义建模能力，提出了一种基于预训练语言模型的双塔推理架构，分别对查询项文本和候选项文本进行编码。紧接着，提出了一种融合时序上下文的输入模板构造方法，通过定义查询项和候选项的文本组成内容与格式，并结合查询项的时间戳信息，从而有效地采集并整合对应的时序上下文。在模型训练阶段，定义了对比学习中负样本的采集方式与组成，定义了对比优化目标。并且，本章提出了一种基于虚拟时间前缀的高效微调方法，保证模型在仅需对极少量的参数进行调整的情况下，快速适应于直推式和少样本归纳式时序知识推理任务场景。最后，在直推式和少样本归纳式时序知识推理任务上对模型进行了实验分析，对比最新的基线模型，本章模型能够取得优异的性能，并且深入的性能分析证明了模型的有效性和灵活性。

5.2 未来展望

论文重点讨论了基于对比式自监督框架的知识图谱中异构信息融合表示方式，探讨了图神经网络架构下和预训练语言模型架构下的知识融合方式，并进行了大量的实验来验证所提出模型的效果。在现有工作的基础上，还有以下四方面值得改进和探索：

（1）利用图提示学习统一知识推理的各类任务：受启发于自然语言处理领域的提示学习，在图领域引入提示学习，能够提取预训练图模型中蕴含的下游任务的知识，应用到某个特定网络的具体任务上，借助提示学习激发预训练阶段的相关知识，能够有效完成这个下游任务。知识图谱本身具有图结构特征，其包含了节点层级的任务和边级别的任务，利用令牌层级的图提示和图层级的图提示，将不同级别的任务统一抽象为图级别的任务，可以缩小不同级别的任务存在的语义差距，从而实现更有效的知识推理性能。

（2）探索基于生成式语言模型架构的知识推理方法：现有的基于语言模型实现知识图谱建模和推理的方法，大多采用基于 Transformer 编码器的 BERT 等编码模型作为基座语言模型，从文本输入拼接，到掩码策略的设计，再到优化目标的设计等方面来实现知识的注入，而基于 GPT、T5 类似的生成式模型的知识推理方法则有待进一步探索。将知识推理任务从理解、编码、匹配这一范式转化为生成任务，一方面能提高模型的推理效率，另一方面能减少对语料文本信息的依赖。探究如何在生成模型上注入知识图谱的结构知识，在解码过程中实现知识引导的解码策略等，都是值得进一步探索和挖掘的方向。

（3）将知识图谱与大语言模型相结合：现阶段，随着大语言模型在自然语言处理领域掀起的热潮，领域研究者更多地关注将知识图谱与大语言模型结合起来。大语言模型以超大规模的预训练语料实现了极强的文本理解和生成能力，结

合上下文学习或者以四元组指令微调大模型的方式，能够利用大模型辅助完成知识推理任务。此外，另一种可行的方案是利用大语言模型对传统图模型的输出结果进行重排序，结合其文本语义层面的建模能力，实现语义与结构层面的信息融合。大模型的引入为知识推理任务引入了新的思路，是值得探索的研究方向。

（4）基于图神经网络的风险商品预测：真实场景中具有大规模、异构、存在噪声以及极不均衡的样本的商品数据，这类数据之间通过“购买”、“喜欢”等关系形成了超大规模的异质图神经网络。这类数据缺少人工分类标签，因此适用于采用自监督对比学习方法来学习异质图神经网络节点表示，从而实现节点分类和链接预测。将文本提出的方法应用于此类场景下，能够实现有效的风险商品检测。

参考文献

[1] Zou X. A Survey on Application of Knowledge Graph[J]. Journal of Physics: Conference Series, 2020, 1487(1): 012016.

[2] Bollacker K, Cook R, Tufts P. Freebase: a shared database of structured general human knowledge[C]//Proceedings of the 22nd national conference on Artificial intelligence - Volume 2. Vancouver, British Columbia, Canada: AAAI Press, 2007: 1962-1963.

[3] Auer S, Bizer C, Kobilarov G, et al. DBpedia: A Nucleus for a Web of Open Data[C]//The Semantic Web. Berlin, Heidelberg: Springer, 2007: 722-735.

[4] Suchanek F M, Kasneci G, Weikum G. Yago: a core of semantic knowledge[C]//Proceedings of the 16th international conference on World Wide Web. New York, NY, USA: Association for Computing Machinery, 2007: 697-706.

[5] Ercan G, Elbassuoni S, Hose K. Retrieving Textual Evidence for Knowledge Graph Facts[C]//The Semantic Web. Cham: Springer International Publishing, 2019: 52-67.

[6] Zou D, Wei W, Mao X L, et al. Multi-level Cross-view Contrastive Learning for Knowledge-aware Recommender System[C]//Proceedings of the 45th International ACM SIGIR Conference on Research and Development in Information Retrieval. New York, NY, USA: Association for Computing Machinery, 2022: 1358-1368.

[7] Ji S, Pan S, Cambria E, et al. A Survey on Knowledge Graphs: Representation, Acquisition, and Applications[J]. IEEE Transactions on Neural Networks and Learning Systems, 2022, 33(2): 494-514.

[8] 官赛萍, 靳小龙, 贾岩涛, 等. 面向知识图谱的知识推理研究进展[J]. 软件学报, 2018, 29(10): 2966-2994.

[9] 丁建辉, 贾维嘉. 知识图谱补全算法综述[J]. 信息通信技术, 2018, 12(1): 56-62.

[10] Yang Y, Huang C, Xia L, et al. Knowledge Graph Contrastive Learning for

Recommendation[C]//Proceedings of the 45th International ACM SIGIR Conference on Research and Development in Information Retrieval. New York, NY, USA: Association for Computing Machinery, 2022: 1434-1443.

[11] Yasunaga M, Ren H, Bosselut A, et al. QA-GNN: Reasoning with Language Models and Knowledge Graphs for Question Answering[C]//Proceedings of the 2021 Conference of the North American Chapter of the Association for Computational Linguistics: Human Language Technologies. Online: Association for Computational Linguistics, 2021: 535-546.

[12] Bordes A, Usunier N, Garcia-Duran A, et al. Translating Embeddings for Modeling Multi-relational Data[C]//Advances in Neural Information Processing Systems: Vol. 26. Curran Associates, Inc., 2013.

[13] Yang B, Yih W tau, He X, et al. Embedding Entities and Relations for Learning and Inference in Knowledge Bases[C]//3rd International Conference on Learning Representations, ICLR 2015, San Diego, CA, USA, May 7-9, 2015, Conference Track Proceedings. 2015.

[14] Schlichtkrull M, Kipf T N, Bloem P, et al. Modeling Relational Data with Graph Convolutional Networks[C]//The Semantic Web. Cham: Springer International Publishing, 2018: 593-607.

[15] Yao L, Mao C, Luo Y. KG-BERT: BERT for Knowledge Graph Completion[J]. arXiv:1909.03193 [cs], 2019.

[16] Wang B, Shen T, Long G, et al. Structure-Augmented Text Representation Learning for Efficient Knowledge Graph Completion[C]//Proceedings of the Web Conference 2021. Ljubljana Slovenia: ACM, 2021: 1737-1748.

[17] Gottschalk S, Demidova E. EventKG: A Multilingual Event-Centric Temporal Knowledge Graph[C]//The Semantic Web. Cham: Springer International Publishing, 2018: 272-287.

[18] 徐涌鑫, 赵俊峰, 王亚沙, 等. 时序知识图谱表示学习[J]. 计算机科学, 2022, 49(9): 162-171.

[19] Korkmaz G, Cadena J, Kuhlman C J, et al. Combining Heterogeneous Data Sources for Civil Unrest Forecasting[C]//Proceedings of the 2015 IEEE/ACM

International Conference on Advances in Social Networks Analysis and Mining 2015. New York, NY, USA: Association for Computing Machinery, 2015: 258-265.

[20] Ding Z, Wu J, He B, et al. Few-Shot Inductive Learning on Temporal Knowledge Graphs using Concept-Aware Information[C]//4th Conference on Automated Knowledge Base Construction. 2022.

[21] Ding Z, Wu J, Li Z, et al. Improving Few-Shot Inductive Learning on Temporal Knowledge Graphs Using Confidence-Augmented Reinforcement Learning[C]//Machine Learning and Knowledge Discovery in Databases: Research Track. Cham: Springer Nature Switzerland, 2023: 550-566.

[22] Lin Y, Liu Z, Sun M, et al. Learning Entity and Relation Embeddings for Knowledge Graph Completion[J]. Proceedings of the AAAI Conference on Artificial Intelligence, 2015, 29(1).

[23] Sun Z, Deng Z H, Nie J Y, et al. RotatE: Knowledge Graph Embedding by Relational Rotation in Complex Space[C]//International Conference on Learning Representations. 2018.

[24] Nickel M, Tresp V, Kriegel H P. A three-way model for collective learning on multi-relational data[C]//Proceedings of the 28th International Conference on International Conference on Machine Learning. Madison, WI, USA: Omnipress, 2011: 809-816.

[25] ZHANG S, Tay Y, Yao L, et al. Quaternion Knowledge Graph Embeddings[C]//Advances in Neural Information Processing Systems: Vol. 32. Curran Associates, Inc., 2019.

[26] Vashishth S, Sanyal S, Nitin V, et al. Composition-based Multi-Relational Graph Convolutional Networks[C]//International Conference on Learning Representations. 2019.

[27] Kipf T N, Welling M. Semi-Supervised Classification with Graph Convolutional Networks[C]//International Conference on Learning Representations. 2022.

[28] Vaswani A, Shazeer N, Parmar N, et al. Attention is All you Need[C]//Advances in Neural Information Processing Systems: Vol. 30. Curran Associates, Inc., 2017.

[29] Chen S, Liu X, Gao J, et al. HittER: Hierarchical Transformers for Knowledge Graph Embeddings[C]//Proceedings of the 2021 Conference on Empirical Methods in Natural Language Processing. Online and Punta Cana, Dominican Republic: Association for Computational Linguistics, 2021: 10395-10407.

[30] Yao Y, Huang S, Dong L, et al. Kformer: Knowledge Injection in Transformer Feed-Forward Layers[C]//Natural Language Processing and Chinese Computing. Cham: Springer International Publishing, 2022: 131-143.

[31] Liu X, Zhao S, Su K, et al. Mask and Reason: Pre-Training Knowledge Graph Transformers for Complex Logical Queries[C]//Proceedings of the 28th ACM SIGKDD Conference on Knowledge Discovery and Data Mining. Washington DC USA: ACM, 2022: 1120-1130.

[32] Oliveira D, Sahay R, D'Aquin M. Leveraging Ontologies for Knowledge Graph Schemas[C]//KGB@ESWC. 2019.

[33] Xie R, Liu Z, Sun M. Representation learning of knowledge graphs with hierarchical types[C]//Proceedings of the Twenty-Fifth International Joint Conference on Artificial Intelligence. New York, New York, USA: AAAI Press, 2016: 2965-2971.

[34] Hao J, Chen M, Yu W, et al. Universal Representation Learning of Knowledge Bases by Jointly Embedding Instances and Ontological Concepts[C]//Proceedings of the 25th ACM SIGKDD International Conference on Knowledge Discovery & Data Mining. New York, NY, USA: Association for Computing Machinery, 2019: 1709-1719.

[35] Xiang Y, Zhang Z, Chen J, et al. OntoEA: Ontology-guided Entity Alignment via Joint Knowledge Graph Embedding[C]//Findings of the Association for Computational Linguistics: ACL-IJCNLP 2021. Online: Association for Computational Linguistics, 2021: 1117-1128.

[36] Niu G, Li B, Zhang Y, et al. AutoETER: Automated Entity Type Representation for Knowledge Graph Embedding[C]//Findings of the Association for Computational Linguistics: EMNLP 2020. Online: Association for Computational Linguistics, 2020: 1172-1181.

[37] 孙水发, 李小龙, 李伟生, 等. 图神经网络应用于知识图谱推理的研究综述

[J]. 计算机科学与探索, 2023, 17(1): 27-52.

[38] Nathani D, Chauhan J, Sharma C, et al. Learning Attention-based Embeddings for Relation Prediction in Knowledge Graphs[C]//Proceedings of the 57th Annual Meeting of the Association for Computational Linguistics. Florence, Italy: Association for Computational Linguistics, 2019: 4710-4723.

[39] 孙毅, 裘杭萍, 郑雨, 等. 自然语言预训练模型知识增强方法综述[J]. 中文信息学报, 2021, 35(7): 10-29.

[40] Devlin J, Chang M W, Lee K, et al. BERT: Pre-training of Deep Bidirectional Transformers for Language Understanding[C]//Proceedings of the 2019 Conference of the North American Chapter of the Association for Computational Linguistics: Human Language Technologies, Volume 1 (Long and Short Papers). Minneapolis, Minnesota: Association for Computational Linguistics, 2019: 4171-4186.

[41] Wang X, Gao T, Zhu Z, et al. KEPLER: A Unified Model for Knowledge Embedding and Pre-trained Language Representation[J]. Transactions of the Association for Computational Linguistics, 2021, 9: 176-194.

[42] Sun T, Shao Y, Qiu X, et al. CoLAKE: Contextualized Language and Knowledge Embedding[C]//Proceedings of the 28th International Conference on Computational Linguistics. Barcelona, Spain (Online): International Committee on Computational Linguistics, 2020: 3660-3670.

[43] Chen C, Wang Y, Li B, et al. Knowledge Is Flat: A Seq2Seq Generative Framework for Various Knowledge Graph Completion[C]//Proceedings of the 29th International Conference on Computational Linguistics. Gyeongju, Republic of Korea: International Committee on Computational Linguistics, 2022: 4005-4017.

[44] Chen C, Wang Y, Sun A, et al. Dipping PLMs Sauce: Bridging Structure and Text for Effective Knowledge Graph Completion via Conditional Soft Prompting[C]//Findings of the Association for Computational Linguistics: ACL 2023. Toronto, Canada: Association for Computational Linguistics, 2023: 11489-11503.

[45] Zhang Y, Chen Z, Guo L, et al. Making Large Language Models Perform Better

in Knowledge Graph Completion[M]. arXiv, 2024.

[46] Zhu C, Chen M, Fan C, et al. Learning from History: Modeling Temporal Knowledge Graphs with Sequential Copy-Generation Networks[J]. Proceedings of the AAAI Conference on Artificial Intelligence, 2021, 35(5): 4732-4740.

[47] Li Z, Jin X, Li W, et al. Temporal Knowledge Graph Reasoning Based on Evolutional Representation Learning[C]//Proceedings of the 44th International ACM SIGIR Conference on Research and Development in Information Retrieval. Virtual Event Canada: ACM, 2021: 408-417.

[48] Xu Y, Ou J, Xu H, et al. Temporal Knowledge Graph Reasoning with Historical Contrastive Learning[J]. Proceedings of the AAAI Conference on Artificial Intelligence, 2023, 37(4): 4765-4773.

[49] Xu W, Liu B, Peng M, et al. Pre-trained Language Model with Prompts for Temporal Knowledge Graph Completion[C]//Findings of the Association for Computational Linguistics: ACL 2023. Toronto, Canada: Association for Computational Linguistics, 2023: 7790-7803.

[50] Chen Z, Xu C, Su F, et al. Incorporating Structured Sentences with Time-enhanced BERT for Fully-inductive Temporal Relation Prediction[C]//Proceedings of the 46th International ACM SIGIR Conference on Research and Development in Information Retrieval. New York, NY, USA: Association for Computing Machinery, 2023: 889-899.

[51] Han Z, Liao R, Gu J, et al. ECOLA: Enhancing Temporal Knowledge Embeddings with Contextualized Language Representations[C]//Findings of the Association for Computational Linguistics: ACL 2023. Toronto, Canada: Association for Computational Linguistics, 2023: 5433-5447.

[52] Richardson M, Domingos P. Markov logic networks[J]. Machine Learning, 2006, 62(1): 107-136.

[53] Yang F, Yang Z, Cohen W W. Differentiable Learning of Logical Rules for Knowledge Base Reasoning[C]//Advances in Neural Information Processing Systems: Vol. 30. Curran Associates, Inc., 2017.

[54] Teru K, Denis E, Hamilton W. Inductive Relation Prediction by Subgraph

Reasoning[C]//Proceedings of the 37th International Conference on Machine Learning. PMLR, 2020: 9448-9457.

[55] Xu X, Zhang P, He Y, et al. Subgraph Neighboring Relations Infomax for Inductive Link Prediction on Knowledge Graphs[C]//Proceedings of the Thirty-First International Joint Conference on Artificial Intelligence, IJCAI-22. International Joint Conferences on Artificial Intelligence Organization, 2022: 2341-2347.

[56] Wang Z, Zhang J, Feng J, et al. Knowledge Graph Embedding by Translating on Hyperplanes[J]. Proceedings of the AAAI Conference on Artificial Intelligence, 2014, 28(1).

[57] Trouillon T, Welbl J, Riedel S, et al. Complex Embeddings for Simple Link Prediction[C]//Proceedings of The 33rd International Conference on Machine Learning. PMLR, 2016: 2071-2080.

[58] Touvron H, Martin L, Stone K, et al. Llama 2: Open Foundation and Fine-Tuned Chat Models[M]. arXiv, 2023.

[59] Brown T, Mann B, Ryder N, et al. Language Models are Few-Shot Learners[C]//Advances in Neural Information Processing Systems: Vol. 33. Curran Associates, Inc., 2020: 1877-1901.

[60] Kipf T N, Welling M. Variational Graph Auto-Encoders[M]. arXiv, 2016.

[61] Hu* W, Liu* B, Gomes J, et al. Strategies for Pre-training Graph Neural Networks[C]//International Conference on Learning Representations. 2019.

[62] You Y, Chen T, Wang Z, et al. When Does Self-Supervision Help Graph Convolutional Networks?[C]//Proceedings of the 37th International Conference on Machine Learning. PMLR, 2020: 10871-10880.

[63] Hu Z, Dong Y, Wang K, et al. GPT-GNN: Generative Pre-Training of Graph Neural Networks[C]//Proceedings of the 26th ACM SIGKDD International Conference on Knowledge Discovery & Data Mining. New York, NY, USA: Association for Computing Machinery, 2020: 1857-1867.

[64] He K, Fan H, Wu Y, et al. Momentum Contrast for Unsupervised Visual Representation Learning[C]//Proceedings of the IEEE/CVF Conference on

Computer Vision and Pattern Recognition. 2020: 9729-9738.

[65] Veličković P, Fedus W, Hamilton W L, et al. Deep Graph Infomax[C]//International Conference on Learning Representations. 2018.

[66] Hassani K, Khasahmadi A H. Contrastive Multi-View Representation Learning on Graphs[C]//Proceedings of the 37th International Conference on Machine Learning. PMLR, 2020: 4116-4126.

[67] You Y, Chen T, Sui Y, et al. Graph Contrastive Learning with Augmentations[C]//Advances in Neural Information Processing Systems: Vol. 33. Curran Associates, Inc., 2020: 5812-5823.

[68] Wang P, Agarwal K, Ham C, et al. Self-Supervised Learning of Contextual Embeddings for Link Prediction in Heterogeneous Networks[C]//Proceedings of the Web Conference 2021. New York, NY, USA: Association for Computing Machinery, 2021: 2946-2957.

[69] Wang L, Zhao W, Wei Z, et al. SimKGC: Simple Contrastive Knowledge Graph Completion with Pre-trained Language Models[C]//Proceedings of the 60th Annual Meeting of the Association for Computational Linguistics (Volume 1: Long Papers). Dublin, Ireland: Association for Computational Linguistics, 2022: 4281-4294.

[70] Ouyang B, Huang W, Chen R, et al. Knowledge Representation Learning with Contrastive Completion Coding[C]//Findings of the Association for Computational Linguistics: EMNLP 2021. Punta Cana, Dominican Republic: Association for Computational Linguistics, 2021: 3061-3073.

[71] Toutanova K, Chen D. Observed versus latent features for knowledge base and text inference[C]//Proceedings of the 3rd workshop on continuous vector space models and their compositionality. 2015: 57-66.

[72] Wen J, Li J, Mao Y, et al. On the representation and embedding of knowledge bases beyond binary relations[C]//Proceedings of the Twenty-Fifth International Joint Conference on Artificial Intelligence. New York, New York, USA: AAAI Press, 2016: 1300-1307.

[73] Rosso P, Yang D, Ostapuk N, et al. RETA: A Schema-Aware, End-to-End

Solution for Instance Completion in Knowledge Graphs[C]//Proceedings of the Web Conference 2021. New York, NY, USA: Association for Computing Machinery, 2021: 845-856.

[74] Lacroix T, Usunier N, Obozinski G. Canonical Tensor Decomposition for Knowledge Base Completion[C]//Proceedings of the 35th International Conference on Machine Learning. PMLR, 2018: 2863-2872.

[75] Jain P, Kumar P, Chakrabarti S, et al. Type-sensitive knowledge base inference without explicit type supervision[C]//Proceedings of the 56th Annual Meeting of the Association for Computational Linguistics (Volume 2: Short Papers). 2018: 75-80.

[76] Ahrabian K, Feizi A, Salehi Y, et al. Structure Aware Negative Sampling in Knowledge Graphs[C]//Proceedings of the 2020 Conference on Empirical Methods in Natural Language Processing (EMNLP). Online: Association for Computational Linguistics, 2020: 6093-6101.

[77] Chao L, He J, Wang T, et al. PairRE: Knowledge Graph Embeddings via Paired Relation Vectors[C]//Proceedings of the 59th Annual Meeting of the Association for Computational Linguistics and the 11th International Joint Conference on Natural Language Processing (Volume 1: Long Papers). Online: Association for Computational Linguistics, 2021: 4360-4369.

[78] Grover A, Leskovec J. node2vec: Scalable Feature Learning for Networks[C]//Proceedings of the 22nd ACM SIGKDD International Conference on Knowledge Discovery and Data Mining. New York, NY, USA: Association for Computing Machinery, 2016: 855-864.

[79] Cao Y, Ji X, Lv X, et al. Are Missing Links Predictable? An Inferential Benchmark for Knowledge Graph Completion[C]//Proceedings of the 59th Annual Meeting of the Association for Computational Linguistics and the 11th International Joint Conference on Natural Language Processing (Volume 1: Long Papers). Online: Association for Computational Linguistics, 2021: 6855-6865.

[80] Van der Maaten L, Hinton G. Visualizing data using t-SNE.[J]. Journal of machine learning research, 2008, 9(11).

[81] Boschee E, Lautenschlager J, O'Brien S, et al. Integrated crisis early warning

system (icews) coded event data[J]. URL: https://dataverse. harvard. edu/dataverse/icews, 2015.

[82] Li X L, Liang P. Prefix-Tuning: Optimizing Continuous Prompts for Generation[C]//Proceedings of the 59th Annual Meeting of the Association for Computational Linguistics and the 11th International Joint Conference on Natural Language Processing (Volume 1: Long Papers). 2021: 4582-4597.

[83] Liu X, Zheng Y, Du Z, et al. GPT Understands, Too[M]. arXiv, 2023.

[84] Han Z, Chen P, Ma Y, et al. Explainable Subgraph Reasoning for Forecasting on Temporal Knowledge Graphs[C]//International Conference on Learning Representations. 2020.

[85] Li Z, Hou Z, Guan S, et al. HiSMatch: Historical Structure Matching based Temporal Knowledge Graph Reasoning[C]//Findings of the Association for Computational Linguistics: EMNLP 2022. Abu Dhabi, United Arab Emirates: Association for Computational Linguistics, 2022: 7328-7338.

[86] Leblay J, Chekol M W. Deriving Validity Time in Knowledge Graph[C]//Companion Proceedings of the The Web Conference 2018. Republic and Canton of Geneva, CHE: International World Wide Web Conferences Steering Committee, 2018: 1771-1776.

[87] Mahdisoltani F, Biega J, Suchanek F M. Yago3: A knowledge base from multilingual wikipedias[C]//CIDR. 2013.

[88] García-Durán A, Dumančić S, Niepert M. Learning Sequence Encoders for Temporal Knowledge Graph Completion[C]//Proceedings of the 2018 Conference on Empirical Methods in Natural Language Processing. Brussels, Belgium: Association for Computational Linguistics, 2018: 4816-4821.

[89] Goel R, Kazemi S M, Brubaker M, et al. Diachronic Embedding for Temporal Knowledge Graph Completion[J]. Proceedings of the AAAI Conference on Artificial Intelligence, 2020, 34(04): 3988-3995.

[90] Lacroix T, Obozinski G, Usunier N. Tensor Decompositions for Temporal Knowledge Base Completion[C]//International Conference on Learning Representations. 2019.

[91] Saxena A, Kochsiek A, Gemulla R. Sequence-to-Sequence Knowledge Graph Completion and Question Answering[C]//Proceedings of the 60th Annual Meeting of the Association for Computational Linguistics (Volume 1: Long Papers). Dublin, Ireland: Association for Computational Linguistics, 2022: 2814-2828.

[92] Kochsiek A, Saxena A, Nair I, et al. Friendly Neighbors: Contextualized Sequence-to-Sequence Link Prediction[C]//Proceedings of the 8th Workshop on Representation Learning for NLP (RepL4NLP 2023). Toronto, Canada: Association for Computational Linguistics, 2023: 131-138.

[93] Guo J, Kok S. BiQUE: Biquaternionic Embeddings of Knowledge Graphs[C]//Proceedings of the 2021 Conference on Empirical Methods in Natural Language Processing. Online and Punta Cana, Dominican Republic: Association for Computational Linguistics, 2021: 8338-8351.

[94] Xu C, Chen Y Y, Nayyeri M, et al. Temporal Knowledge Graph Completion using a Linear Temporal Regularizer and Multivector Embeddings[C]//Proceedings of the 2021 Conference of the North American Chapter of the Association for Computational Linguistics: Human Language Technologies. Online: Association for Computational Linguistics, 2021: 2569-2578.

[95] Xu C, Nayyeri M, Alkhoury F, et al. TeRo: A Time-aware Knowledge Graph Embedding via Temporal Rotation[C]//Proceedings of the 28th International Conference on Computational Linguistics. Barcelona, Spain (Online): International Committee on Computational Linguistics, 2020: 1583-1593.

[96] Hamaguchi T, Oiwa H, Shimbo M, et al. Knowledge Transfer for Out-of-Knowledge-Base Entities : A Graph Neural Network Approach[J]. 2017: 1802-1808.

[97] Wang P, Han J, Li C, et al. Logic Attention Based Neighborhood Aggregation for Inductive Knowledge Graph Embedding[J]. Proceedings of the AAAI Conference on Artificial Intelligence, 2019, 33(01): 7152-7159.

[98] Baek J, Lee D B, Hwang S J. Learning to Extrapolate Knowledge: Transductive Few-shot Out-of-Graph Link Prediction[C]//Advances in Neural Information Processing Systems: Vol. 33. Curran Associates, Inc., 2020: 546-560.

[99] Raffel C, Shazeer N, Roberts A, et al. Exploring the Limits of Transfer Learning with a Unified Text-to-Text Transformer[J]. Journal of Machine Learning Research, 2020, 21(140): 1-67.

致谢

不同于在沈阳 1400 亩荒地里校园中度过的略带青涩的四年，在武大的三年生活总是会显得更加强烈与鲜活。“选择未来，选择生活，我选择不做选择，我选择其他”，伊万·麦克格雷格在《猜火车》中的台词，亦是对我三年研究生学业的印证。回忆往昔，与珞珈相识于初秋，三年后的我已走上了当初未曾设想过的道路，既知不易而倍感珍惜，一路上的惊喜和遗憾都造就了现在更好的我。

桃李不言，下自成蹊。求学路上最感谢的是我的研究生导师彭敏教授，回首过往三年，得到了太多来自于老师的鼓励和帮助，给予了我继续向学术道路前进的勇气和信心。导师三年前的一通电话带领我步入了学术的大门，她深厚的学术造诣和前沿的学术视野，都是我在学术生涯中探索的明灯。除此之外，实验室自由舒适的学习环境以及充分的实验设备资源，都支撑我充分探索自己的实验与想法。更重要的是，导师还以自己的实际行动教导我做人做事应有的认真态度，对任何事情都严谨对待，一丝不苟。

过往如云烟，恩情最难忘。感谢我的父母和家人，他们把自己最炽热和无私的爱全部给予了我，用自己的行动默默做我求学路上坚实的后盾，消化掉我所有的悲伤与泪水，支持我的每一个选择，让我能站在你们的肩上看到整个世界。爱不挂口，长记于心，希望他们永远身体健康。

山河不足重，重在遇知己。感谢实验室每一位帮助过我的师兄师姐和同门们。感谢刘磊博士在我初来乍到武汉时对我的悉心关照。感谢刘奔博士，带领我在科研的道路上摸爬滚打，也是我在学术道路上最可靠的伙伴，合作的每一篇论文，参与的每一项比赛，参加的每一场学术会议，都是三年科研历程凝成的结晶。感谢徐文杰博士，不仅在学术上给予我帮助，在生活和娱乐中更是不可多得的益友。感谢贾旭博士，在生活科研各方面对我的帮助，他每天早晨的点赞都是我开启学习的标志与动力。感谢我的研究生同门许敏章、陈嘉辉、杨世杰、武涵，以及师弟蒋梓浩，陪我一起度过了精彩的研究生生涯。还要感谢已经毕业的张鼎、谢烁圻、彭美政、罗娟、袁尤良等师兄师姐，在我入学初期，在我的求学过程中给予了我太多的帮助。很长一段时间，光是待在实验室就是一件幸福的事，白天科研讨论，晚上约饭健身，这是我将来以及永远也不会忘记的时光。

愿岁并谢，与友长兮。庆幸一路走来有那么多的朋友陪伴在我身边，与我分享喜悦与难过，即便身在各地。感谢周静同学，从高中同桌，到研究生上下楼，兜兜转转八年时光属实不易。感谢张萌和骆淳洁，以及在武大三年的约饭瞎逛时光。感谢李博文、马天姿、曹子鋆、唐弘彧、刘前沛与我一同分享生活，分享学术路上和工作中的趣闻。感谢“喵星球”的三位伙伴刘昀涵、邱泽元、韩耀兴，

即便在大洋彼岸也互相关心着彼此，希望能为了热爱的生活一直勇敢下去。

感谢这个世界还有文学、电影与音乐。电影银幕是我感知纷繁多彩世界的器官，它总能将我抽离出繁重的课业生活，沉浸于那一方充满想象力的世界。感谢 Nicole Kidman，感谢 Olivia Rodrigo，电影带我游历，音乐抚慰我心，有它们负载着我身，去穿过暗夜里的惊涛骇浪，去对抗漫漫长夜的孤寂。

夕阳打在屏幕上，键盘敲下的每个字符都是在武大的日日夜夜。三年的研究生生涯诚然不会一帆风顺，我学会了去坦然面对理想与现实的差距，学会去接受不在计划和意料之中的事实，学会去接受自己的平庸，但也学会了发现自己独一无二的闪光点，去拥抱生活，去看到生活中美的那一面。

结束亦是开始，借用《死亡诗社》的一句台词：“及时采拮你的花蕾，旧时光一去不回”。纵有千古，横有八荒，前途似海，来日方长。

2024 年 6 月 1 日

附录 A：个人简历

2000 年 8 月 26 日出生于四川省成都市。

2017 年 9 月考入东北大学软件工程专业，2021 年 6 月本科毕业并获得工学学士学位。

2021 年 9 月保送至武汉大学计算机科学系攻读硕士学位至今。

附录 B：在学期间参与的科研项目

[1] 优质多抗草莓新品种培育及绿色智能化生产，湖北省科技厅重点研发计划，核心成员.

[2] 人机融合医疗会诊关键技术与应用，科技创新 2030-“新一代人工智能”重大项目，核心成员.

附录 C：在学期间取得的学术成果

1. 已发表论文

[1] **Peng, M.**, Liu, B., Xie, Q., Xu, W., Wang, H., & Peng, M. (2022, December). SMiLE: Schema-augmented Multi-level Contrastive Learning for Knowledge Graph Link Prediction. In Findings of the Association for Computational Linguistics: EMNLP 2022 (pp. 4165-4177). （EI 检索，CCF B 类会议，对应论文第三章内容）

[2] **Peng, M.**, Liu, B., Xu, W., Jiang, Z., Zhu, J., & Peng, M. (2024, June). Deja vu: Contrastive Historical Modeling with Prefix-tuning for Temporal Knowledge Graph Reasoning. In Findings of the Association for Computational Linguistics: NAACL 2024. （EI 检索，CCF B 类会议，对应论文第四章内容）

[3] Liu, B., **Peng, M.**, Xu, W., & Peng, M. (2023). Neighboring relation enhanced inductive knowledge graph link prediction via meta-learning. World Wide Web, 26(5), 2909-2930. （SCI 检索，三区，CCF B 类期刊）

[4] Liu, B., **Peng, M.**, Xu, W., Jia, X., & Peng, M. (2024, May). UniLP: Unified Topology-aware Generative Framework for Link Prediction in Knowledge Graph. In Proceedings of the web conference 2024. （EI 检索，CCF A 类会议）

[5] Xu, W., Liu, B., **Peng, M.**, Jia, X., & Peng, M. (2023, July). Pre-trained Language Model with Prompts for Temporal Knowledge Graph Completion. In Findings of the Association for Computational Linguistics: ACL 2023 (pp. 7790-7803). （EI 检索，CCF A 类会议）

[6] Xiao, M., Liu, B., **Peng, M.**, Xu, W., & Peng, M. (2024, June) Clarified Aggregation and Predictive Modeling (CAPM): High-Interpretability Framework for Inductive Link Prediction. In 2024 International Joint Conference on Neural Networks (IJCNN). IEEE. （EI 检索，CCF C 类会议）

2. 投稿中论文

[1] Liu, B.*, **Peng, M.***, Jia, X., Xu, W., & Peng, M. Filter-then-Generate: Large Language Models with Structure-Text Adapter for Knowledge Graph Completion. （投稿 EMNLP 2024，共同一作）

[2] Liu, B., Xu, W., **Peng, M.**, & Peng, M. Hierarchical Knowledge Propagation for Few-Shot Inductive Relation Prediction. （投稿 EMNLP 2024）

3. 获得的学术性奖励

（1）腾讯特等奖学金，2023 年

（2）武汉大学二等奖学金，2022-2023 年

（3）武汉大学优秀研究生，2022-2023 年

（4）武汉大学优秀毕业生，2024 年