分 类 号_____ 密　　级_____

U　D　C_____ 编　　号 10486

武漢大學

硕 士 专 业 学 位 论 文

面向可解释性与鲁棒推理的大语言模型分子性质预测方法研究

研　究　生　姓　名：夏星雨

学　　号：2024282110085

指导教师姓名、职称：彭敏 教授

专 业 类 别（领 域）：计算机技术（自然语言处理）

二〇二六年五月

English title

By

Xingyu Xia

SupervisedBy

Prof. Min Peng

WuhanUniversity

May, 2025

论文原创性声明

本人郑重声明：所呈交的学位论文，是本人在导师指导下，独立进行研究工作所取得的研究成果。除文中已经标明引用的内容外，本论文不包含任何其他个人或集体已经发表或撰写过的研究成果。对本文的研究做出贡献的个人和集体，均已在文中以明确方式标明。本声明的法律结果由本人承担。

学位论文作者（签名）：

日期：　　年　　月　　日

武汉大学学位论文使用授权协议书

本学位论文作者愿意遵守武汉大学关于保存、使用学位论文的管理办法及规定，即：学校有权保存学位论文的印刷本和电子版，并提供文献检索与阅览服务；学校可以采用影印、缩印、数字化或其它复制手段保存论文；在以教学与科研服务为目的前提下，学校可以在校园网内公布部分或全部内容。

一、在本论文提交当年，同意在校园网内以及中国高等教育文献保障系统（CALIS）、高校学位论文系统提供查询及前十六页浏览服务。

二、在本论文提交 □当年/ □一年/□两年/ □三年以后，同意在校园网内允许读者在线浏览并下载全文，学校可以为存在馆际合作关系的兄弟高校用户提供文献传递服务和交换服务。（保密论文解密后遵守此规定）

论文作者（签名）：_____

学　　号：_____

学　　院：_____

日期：　　年　　月　　日

摘 要

分子性质预测是药物发现、材料设计与化学工程中的关键基础任务，其目标是在实验验证之前，快速、准确地评估分子的理化性质、生物活性及安全性等关键指标。传统分子性质预测方法虽然在一定程度上提升了预测效率，但在多源异质分子信息融合、领域知识驱动推理以及结果可解释性方面仍存在明显不足。近年来，大语言模型凭借其强大的知识建模与自然语言生成能力，为分子性质预测提供了新的研究范式。

然而，现有方法在分子多模态信息统一建模、端到端推理生成以及推理过程的鲁棒性与可信性保障方面仍面临重要挑战。针对上述问题，本文围绕分子性质预测任务，研究面向可解释性与鲁棒推理的大语言模型方法，旨在同步提升模型的端到端推理能力、解释生成能力以及复杂场景下的推理稳定性。本文主要开展了两方面研究：

第一，针对多源异质分子表示难以有效统一建模、端到端推理能力不足的问题，提出了一种面向多源异质分子表示融合的端到端可解释推理方法。该方法首先构建面向分子性质预测的高质量思维链数据，并通过质量评估机制提升推理监督信号的可靠性；随后设计融合分子图、SMILES 与文本指令的统一建模框架，实现多源分子信息的协同表示与对齐；在此基础上，采用两阶段训练策略，使模型能够联合生成分子性质预测结果及其对应的自然语言推理过程。

第二，针对模型推理过程中存在的幻觉干扰与逻辑不一致等问题，进一步提出了一种基于反思与探索的鲁棒推理优化方法。该方法通过显式建模“推理—反思—探索”的动态思维链形式，结合多 Agent 协同的数据生成机制与外部知识增强手段，构建更具鲁棒性的推理数据；同时引入分层奖励驱动的强化学习策略，从答案正确性、推理一致性和化学合理性等多个层面优化模型决策过程，从而提升模型在复杂分子场景下的可信度与泛化能力。

本文的研究从端到端链式推理建模与鲁棒推理优化两个层面，系统探索了大语言模型在分子性质预测任务中的应用路径，为构建兼具多源信息融合能力、可解释推理能力与事实一致性保障能力的分子性质预测模型提供了新的方法支撑。

关键词：分子性质预测；大语言模型；可解释推理；强化学习

Abstract

Molecular property prediction is a fundamental task in drug discovery, materials design, and chemical engineering. Its goal is to rapidly and accurately evaluate key indicators of molecules, such as physicochemical properties, biological activity, and safety, before experimental validation. Although traditional molecular property prediction methods have improved prediction efficiency to some extent, they still exhibit notable limitations in the integration of multi-source heterogeneous molecular information, domain knowledge-driven reasoning, and result interpretability. In recent years, large language models, with their powerful capabilities in knowledge modeling and natural language generation, have provided a new research paradigm for molecular property prediction.

However, existing methods still face important challenges in the unified modeling of multimodal molecular information, end-to-end reasoning generation, and the robustness and trustworthiness of the reasoning process. To address these issues, this paper focuses on molecular property prediction and investigates large language model methods oriented toward interpretability and robust reasoning, aiming to simultaneously improve end-to-end reasoning, explanation generation, and reasoning stability in complex scenarios. This paper mainly conducts research in two aspects:

First, to address the difficulty of effectively unifying multi-source heterogeneous molecular representations and the insufficient capability of end-to-end reasoning, this paper proposes an end-to-end interpretable reasoning method for the fusion of multi-source heterogeneous molecular representations. The method first constructs high-quality chain-of-thought data for molecular property prediction and improves the reliability of reasoning supervision signals through a quality evaluation mechanism. It then designs a unified modeling framework integrating molecular graphs, SMILES, and textual instructions, enabling collaborative representation and alignment of multi-source molecular information. On this basis, a two-stage training strategy is adopted so that the model can jointly generate molecular property prediction results and their corresponding natural language reasoning processes.

Second, to address issues such as hallucination interference and logical inconsistency in the model reasoning process, this paper further proposes a robust reasoning optimization method based on reflection and exploration. This method explicitly models a dynamic chain-of-thought paradigm of “reasoning–reflection–exploration,” and combines a multi-

agent collaborative data generation mechanism with external knowledge enhancement to construct more robust reasoning data. At the same time, a hierarchical reward-driven reinforcement learning strategy is introduced to optimize the model's decision-making process from multiple perspectives, including answer correctness, reasoning consistency, and chemical plausibility, thereby improving the model's trustworthiness and generalization ability in complex molecular scenarios.

From the two perspectives of end-to-end chain-of-thought reasoning modeling and robust reasoning optimization, this study systematically explores the application of large language models to molecular property prediction tasks, and provides new methodological support for building molecular property prediction models that possess multi-source information fusion capability, interpretable reasoning ability, and factual consistency guarantees.

Key words: Molecular property prediction; Large Language Model; Explainable Reasoning; Reinforcement Learning

目　　录

摘　要 ····· I

Abstract ····· II

第 1 章　绪　论 ····· 1

1.1　研究背景与意义 ····· 1

1.2　国内外研究现状 ····· 3

1.2.1　基于机器学习的分子性质预测方法 ····· 4

1.2.2　基于传统深度学习的分子性质预测方法 ····· 4

1.2.3　基于大语言模型的分子性质预测方法 ····· 7

1.2.4　研究路径 ····· 8

1.3　主要研究内容 ····· 9

1.4　论文的组织结构 ····· 10

第 2 章　相关理论基础与关键技术 ····· 14

2.1　分子性质预测 ····· 14

2.2　图神经网络 ····· 15

2.3　大语言模型 ····· 16

2.3.1　大语言模型概述 ····· 16

2.3.2　大语言模型解码器架构 ····· 16

2.3.3　大语言模型的推理能力与可解释性 ····· 17

2.4　Q-Former ····· 18

2.5　检索增强生成 ····· 18

2.6　监督指令微调方法 ····· 19

2.7　强化学习方法 ····· 20

2.8　本章小结 ····· 21

第 3 章　面向多源异质分子表示融合的端到端可解释推理方法 ····· 22

3.1　引言 ····· 22

3.2　CoT 数据构建与质量评估 ····· 22

3.3　面向分子性质预测的多源分子表示融合模型 ····· 27

3.3.1　分子图编码器：基于消息传递的结构表示学习 ····· 27

3.3.2 多层级图投影器：将图表示转换为图 token ····· 28
3.3.3 输入表示与多模态 token 组织方式 ····· 29
3.3.4 大语言模型：融合与自回归生成 ····· 30
3.4 面向语义对齐与推理生成的两阶段训练策略 ····· 31
3.4.1 第一阶段：分子图—语言表示对齐 ····· 31
3.4.2 第二阶段：基于指令的端到端微调 ····· 32
3.5 实验对比与分析 ····· 33
3.5.1 数据集 ····· 33
3.5.2 基准模型概述 ····· 34
3.5.3 评价指标 ····· 35
3.5.4 实验结果与分析 ····· 37

第 4 章 基于反思与探索的分子性质鲁棒推理优化方法 ····· 38
4.1 引言 ····· 38
4.2 基于反思与探索的思维链形式建模 ····· 39
4.3 多 Agent 协同的思维链数据生成框架 ····· 40
4.3.1 总体框架 ····· 40
4.3.2 数据生成流程 ····· 41
4.4 分层奖励驱动的鲁棒推理强化学习方法 ····· 43
4.4.1 推理轨迹与强化学习目标 ····· 44
4.4.2 分层奖励函数设计 ····· 44
4.4.3 重启与探索：面向鲁棒推理的状态扩展策略 ····· 45
4.4.4 反思奖励设计 ····· 48
4.5 实验对比与分析 ····· 48

第 5 章 总结与展望 ····· 50
5.1 全文工作总结 ····· 50
5.2 未来工作展望 ····· 50

参考文献 ····· 51

致谢 ····· 67

附录 A 个人简历 ····· 68

附录 B 在学期间参与的科研项目 ····· 69

附录 C　在学期间取得的学术成果 …… 70

附录 D　prompt …… 71

第 1 章　绪　论

1.1　研究背景与意义

分子是由原子通过化学键连接而成的基本化学实体，其结构特征在很大程度上决定了分子的物理化学性质及功能表现 [99]。对分子结构—性质关系的深入理解，不仅有助于揭示化学体系的内在规律，也为药物、功能材料以及化工产品的理性设计提供了理论基础，因此在化学 [100]、药理学 [101] 和材料科学 [102] 等领域具有重要意义。

分子性质预测（Molecular Property Prediction, MPP）是现代药物发现与材料设计中的关键基础问题。借助计算方法，研究人员能够在开展昂贵且耗时的实验验证之前，对候选分子的生物利用度、毒性和治疗效果等关键性质进行快速评估 [103–106]。相比之下，传统实验测定通常周期长、成本高，往往需要数周甚至数月完成，每种化合物的测试费用可达数千美元 [107–109]。以 ADMET（吸收、分布、代谢、排泄和毒性）筛选为例，单个分子的测试成本可能超过 10,000 美元，这使得对化学空间中海量化合物进行全面实验评估几乎不可行 [110, 111]。因此，发展高效、准确的分子性质预测方法，不仅具有重要的理论价值，也具有显著的经济意义和现实需求 [112]。

早期的分子性质预测研究主要依赖传统深度学习方法。尽管相关方法在该任务上取得了一定进展，但在真实复杂场景中仍面临若干关键挑战。首先，化学分子的表示形式具有明显的多样性，包括 SMILES（Simplified Molecular Input Line Entry System，简化分子线性输入规范）、分子图、三维结构以及理化描述符等，不同表示从不同角度刻画了分子的结构与性质信息。然而，传统深度学习模型通常围绕单一表示进行设计，难以有效融合多源异质信息，从而限制了模型的表征能力与泛化性能。其次，分子性质预测是一项高度依赖领域知识的任务，往往需要综合考虑官能团效应、电子分布、空间位阻等化学先验。传统深度学习模型缺乏将此类知识有效融入预测过程的机制，因而其决策结果可能偏离化学常识。再次，这类模型通常只能输出最终预测结果，难以给出清晰、可信的推理依据，呈现出明显的“黑箱”特征，从而制约了其在科研与工业场景中的实际应用。

近年来，大语言模型（Large Language Model, LLM）为分子性质预测提供了新的研究范式。得益于其较强的上下文建模、知识迁移和自然语言生成能力，LLM 为多源分子信息的统一建模与可解释推理提供了新的技术路径。与传统方法相比，LLM 不仅有望实现“预测—解释”一体化建模，还能够通过自然语言形式呈现模

型判断所依据的化学逻辑，从而为提升分子性质预测的可解释性与可信度带来了新的可能。

然而，将 LLM 真正应用于分子性质预测任务，仍面临两方面的核心挑战：

（1）缺乏对多源异质分子表示的有效端到端推理能力。理想的模型预期能够识别并对齐输入中的多源分子信息，提取关键化学特征，推理其对目标性质的影响，并同时生成准确的预测结果与合理的解释文本。然而，现有基础模型在未经专门设计与训练的情况下，往往难以胜任这一任务。一方面，若将 SMILES、图结构、描述符等异质表示直接拼接为输入，容易引起语义混淆，导致模型难以建立跨模态关联；另一方面，在缺乏高质量推理监督的情况下，模型难以形成稳定的端到端推理能力，生成的解释文本质量有限，进而影响最终预测性能。

针对多源异质分子信息，现有研究通常采用占位 token 或适配器模块将异质表示嵌入文本序列，再通过监督微调（Supervised Fine Tuning, SFT）进行任务适配。然而，SFT 通常以最终预测结果为主要监督信号，容易使模型更关注“答案拟合”而非“推理学习”，从而难以充分理解不同分子表示之间的关联关系，并削弱其对新分子与复杂分子的泛化能力。

为增强模型泛化能力，向模型提供分步推理文本是一种常见思路。这类方法一方面有助于提升模型的逐步推理能力，另一方面也能增强输出结果的可解释性。例如，相关研究在化学任务中采用两阶段提示策略：首先引导大模型生成逐步推理文本，再将其作为后续预测模型的输入；也有工作尝试利用能力更强的模型合成推理数据，以训练具备端到端推理能力的模型。然而，在分子性质预测场景下，兼具多源信息融合能力与端到端推理能力的训练框架仍然相对缺乏。

因此，如何构建能够有效融合多源分子表示、并支持高质量推理生成的端到端训练框架，是当前亟待解决的问题。

（2）模型推理过程的鲁棒性与可信性不足。即使模型已经具备初步的推理生成能力，其输出的推理链在化学事实准确性和逻辑一致性方面仍然存在鲁棒性不足的风险。这一问题主要体现在两个层面。

首先，推理训练数据本身的鲁棒性不足。当前不少方法依赖大模型自动生成推理文本作为训练数据，但这类合成数据常常受到模型幻觉（hallucination）的影响，可能包含与化学事实不符的内容，例如错误归因官能团效应、混淆电子效应与空间位阻等。由于缺乏细粒度的化学逻辑校验机制，这些“形式合理但事实错误”的样本一旦进入训练过程，便可能固化模型的错误推理模式，进而削弱其在化学任务中的可靠性和实用性。

其次，标准的 next-token 预测训练范式本质上属于序列模仿学习，难以对推理过程的整体一致性进行有效约束。化学推理通常是一个多步、强依赖的决策过程：

一旦前序步骤出现偏差，例如错误识别关键活性位点，后续推理便可能沿错误路径持续累积，最终产生逻辑断裂或自相矛盾的解释。因此，仅依赖传统生成式训练目标，难以充分保障推理链的因果连贯性和逻辑一致性。

基于上述分析，亟需从数据与训练机制两个层面提升 LLM 分子性质预测的鲁棒性：一方面，构建更加鲁棒、可校验的推理数据生成机制；另一方面，设计面向推理路径完整性的优化目标，例如引入强化学习进行推理一致性约束，以提升模型在复杂场景中的化学事实准确性和逻辑一致性。

综上所述，本文围绕分子性质预测任务，面向可解释性与可信性需求，研究基于大语言模型的分子性质预测方法，旨在同步提升模型的端到端推理能力与推理过程的鲁棒性。围绕这一目标，本文开展以下两方面的研究：

（1）面向多源异质分子表示融合的端到端可解释推理方法。针对多源异质分子表示难以有效统一建模、端到端推理能力不足的问题，本文提出一种面向多源异质分子表示融合的端到端可解释推理方法。该方法构建统一的端到端训练框架，通过协同优化分子表示对齐与推理生成过程，实现对 SMILES、分子图、理化描述符等多模态信息的有效整合，并生成具有明确化学意义的自然语言推理链与预测结果。

（2）基于反思与探索的分子性质鲁棒推理优化方法。针对模型推理过程易受幻觉干扰、逻辑一致性不足以及事实准确性受限等问题，本文进一步提出了一种基于基于反思与探索的分子性质鲁棒推理优化方法。该方法首先在推理过程中引入反思与探索步骤，对基于反思—探索机制的思维链进行显式建模；进一步设计多 Agent 协同的多思维链数据生成框架，并结合外部知识检索，构建更鲁棒的推理思维链数据。在此基础上，引入分层奖励驱动的鲁棒推理强化学习方法，以提升模型在多步推理过程中的决策稳定性，从而增强其在复杂分子场景下的可信度与泛化能力。

1.2 国内外研究现状

分子性质预测具有分子表征异质、结构信息复杂以及性质推断过程高度依赖领域知识等特点，因此其准确建模与鲁棒推理始终是该领域的重要挑战。针对这一问题，国内外研究人员开展了大量探索，相关研究按照技术发展脉络主要可分为三类：基于传统机器学习的预测方法、基于传统深度学习的预测方法以及基于大语言模型的预测方法。本小节将从以上三个方面对国内外研究现状进行归纳与总结。

1.2.1 基于机器学习的分子性质预测方法

早期的分子性质预测研究主要依赖基于分子描述符和分子指纹的传统机器学习方法。Mucs 等人 [125] 采用 LightGBM 方法，在 Tox21 和致突变性数据集上对多种毒性终点进行预测，并将其性能与 XGBoost、深度神经网络（DNN）、随机森林（RF）和支持向量机（SVM）进行了系统比较。Zhang 等人 [126] 基于 1003 种结构各异的化合物提取了 12 类分子指纹，并构建了分别基于 RF、SVM 和 XGBoost 的三种集成模型，用于药物致癌性预测。多项研究 [126, 127] 表明，在不同数据划分条件下，系统评估多种分子描述符、机器学习算法及其超参数配置，对于构建稳定且高性能的预测模型具有重要意义。

为进一步评估传统机器学习方法在分子性质预测任务中的适用性，Sheridan [128] 在 30 个涵盖靶点相关和非靶点相关性质的数据集上，对多类机器学习模型进行了全面比较。Yang [129] 提出了 SPOC，一种结合传统分子指纹与常用分子描述符的混合分子表示方法。在 12 个基准数据集上的实验结果表明，SPOC 具有显著的预测潜力，其中 Avalon 指纹与原子对指纹结合 RDKit 描述符的方案在所有任务上均取得了最佳性能。

总体来看，这些研究表明，专家设计的分子描述符和分子指纹在分子性质预测中具有重要价值。然而，随着 SMILES 字符串、分子图和分子图像等新型分子表示方式的广泛应用，传统特征工程的优势逐渐减弱，人工构建特征与机器自动学习特征之间的边界日益模糊。因而，尽管经典描述符和分子指纹在 MPP 发展历程中发挥了关键作用，研究范式正逐步由基于人工特征的机器学习转向端到端的表征学习方法。

1.2.2 基于传统深度学习的分子性质预测方法

随着深度学习的发展，分子性质预测研究逐渐由依赖人工设计特征转向基于原始分子表示的端到端建模。根据输入形式的不同，相关方法主要可分为基于 SMILES、分子图（Molecular Graph）、分子图像（Molecular Image）以及多模态融合的方法。

1.2.2.1 基于 SMILES 的深度学习分子性质预测方法

自然语言处理（Natural Language Processing, NLP）领域的发展为将 SMILES 序列有效应用于 MPP 任务提供了有力支撑 [130]。通过特定的预处理策略与表示学习机制，研究者能够从 SMILES 字符串中提取具有语义信息的特征，从而提升性

质预测性能。此外，基于 SMILES 的方法还常结合数据增强技术扩充训练样本，以增强模型的表征学习能力 [131]。例如，Kimber 等人 [132] 在理化性质数据集上应用了五种 SMILES 增强策略，显著提高了模型的预测准确率；Chen 与 Tseng [133] 则基于 convS2S 架构验证了卷积神经网络（Convolutional Neural Network，CNN）在该任务中的有效性，并通过引入位置嵌入来捕获序列顺序信息。

尽管 CNN 在 SMILES 建模中表现出较好的性能，但其对输入长度的要求在一定程度上限制了模型处理序列的灵活性。因此，循环神经网络（Recurrent Neural Network，RNN），尤其是 LSTM 和 GRU，被广泛用于 SMILES 序列建模。Li 等人 [134] 提出了一种堆叠 CNN 与 RNN 层的混合架构用于分子表征学习；Segler 等人 [135] 则证明了基于 SMILES 训练的 RNN 能够有效捕获化学空间分布。然而，RNN 在刻画原子间相互作用及化学键类型方面仍存在不足。

为缓解上述问题，研究者进一步探索了融合官能团等局部化学信息的方法。例如，Mol2Context-vec [136] 利用 BiLSTM 框架动态生成分子子结构表征。与此同时，基于 Transformer 的方法已成为推动分子性质预测发展的关键技术之一，如 SMILES-Transformer（ST）[139]、ChemFormer [140] 和 Transformer-CNN [141]。这些模型分别以 BERT [137]、BART [142] 和 RoBERTa [143] 为基础架构，不仅提升了预测性能，还增强了模型对 SMILES 非唯一性的理解能力。此外，Transformer 也被拓展用于分子几何信息建模，为高效编码和理解分子内原子的空间排布提供了新的技术路径 [145, 146]。

1.2.2.2 基于 Molecular Graph 的深度学习分子性质预测方法

基于图的方法将分子表示为图结构，其中原子作为节点、化学键作为边，从而能够显式利用分子的拓扑结构信息。图卷积网络（Graph Convolutional Network，GCN）通过图上的卷积操作在节点与边之间传播信息，以提取对性质预测至关重要的局部和全局特征。现有 GCN 方法主要包括谱域卷积和空域卷积两类：前者建立在图论与谱分析基础之上，后者则更侧重于对邻域节点信息的聚合。

Shang 等人 [147] 提出一种边感知的谱域 GCN 模型，通过多视角图分割和一致的边映射机制学习边注意力权重。然而，由于固定图尺寸等限制，谱域方法在灵活性上通常不如空域方法，因此如 GraphSAGE 和 GIN [148] 等空域模型在实际应用中更为常见。TrimNet [149] 通过三元消息机制直接建模“原子—键—原子”相互作用，避免了复杂的矩阵映射，在降低计算复杂度的同时增强了边信息表达能力。Gilmer 等人 [150] 提出的消息传递神经网络（MPNN）则通过整合节点特征与加权边信息，生成具有上下文语义的图级表示。

尽管 GNN 在分子性质预测中取得了显著进展，但其仍面临“过平滑”等问题，

即随着网络层数加深，节点表征趋于同质化。针对这一问题，研究者提出了多种改进策略。例如，Edge Memory Neural Network [151] 更加关注边级消息传递，而 IFGN 则面向特定性质识别关键属性，以提高模型的判别能力。

此外，分子图通常具有层次化组织结构，因此对多尺度结构与关系的建模同样十分重要。Su 等人 [152] 和 Wang 等人 [167] 通过将图转换为树结构来捕捉其层次特征，但该类方法的性能可能受到遍历策略差异的影响。近年来，自监督学习（SSL）进一步增强了 GNN 利用未标注数据的能力，降低了对标注样本的依赖。典型的预训练方法如 GROVER [154]、MoCL [155] 和 MGSSL [156] 均展现出较强的迁移性能，使预训练 GNN 能够更有效地服务于下游性质预测任务。

值得注意的是，分子内原子的三维空间排布对其性质具有决定性影响。Lu 等人 [157] 提出多层级 GCN 以整合分子构象特征。针对构象柔性建模困难的问题，研究者还引入曲率信息以增强图模型的结构感知能力。例如，Chen 与 Tseng [158] 开发了一种基于离散 Ricci 曲率的 Transformer 模型，提升了模型对分子结构与功能信息的理解能力。这些研究表明，GNN 正从二维拓扑建模逐步扩展到更加细粒度和高保真的结构表征阶段。

1.2.2.3 基于 Molecular Image 的深度学习分子性质预测方法

深度学习在图像处理领域的成功推动了基于图像的方法在分子性质预测中的应用。这类方法将分子结构转换为图像，再利用图像分析模型捕捉其中蕴含的结构细节。尽管 RDKit 等工具能够方便地生成分子图像，但其输出结果通常缺少部分关键视觉元素，例如明确的键类型标注、原子标签以及清晰的立体化学信息。为弥补这一不足，Yoshimori 提出了分子地形矩阵（Molecular Topographic Matrices, MTMs） [159]，通过构建拓扑映射将分子编码为二维矩阵，并在多项任务中展现出优于传统分子指纹的性能。

此外，频域方法也被引入分子性质预测领域以提取与分子结构和性质相关的信息。Tchagang [160] 利用频域技术将分子转换为图像，并引入类时频变换，以更有效地编码分子的多种特征。

然而，基于图像的方法也存在明显局限。首先，将分子映射到欧几里得空间后，往往会损失部分关键的原子与化学键信息。其次，尽管三维网格方法能够通过体素化分子周围空间，并结合三维卷积来捕捉局部空间模式，Libmolgrid [162] 等开源工具也为相关研究提供了支持，但目前 3D 网格在分子性质预测中的应用仍相对有限 [163]。总体而言，图像模型虽然能够表征分子的视觉结构与空间构型，但在显式编码关键化学属性方面仍显不足；同时，高分辨率图像带来的计算开销也较大。相比之下，SMILES 序列和分子图等表示形式通常更加紧凑，且具有更高的

化学语义密度。因此，图像方法在 MPP 中的适用范围往往受到一定限制。

1.2.2.4 基于多模态的深度学习分子性质预测方法

为了综合利用不同分子表示所包含的互补信息，多模态方法逐渐成为分子性质预测的重要研究方向。这类方法通过融合专家特征、SMILES、分子图和分子图像等多种模态，试图从不同视角刻画分子的多维特性，从而提升预测性能。代表性工作包括 GraSeq [164]，其联合使用 LSTM 和 GNN 对 SMILES 序列与图拓扑进行建模；MTBG [**?**] 则通过 BiGRU 与 GraphSAGE [166] 融合序列嵌入和图嵌入，用于毒性预测任务。

将专家特征与图结构结合也是常见策略。Wang 等人 [167] 将 GCN 与分子指纹进行融合；FP-GNN [168] 整合了分子指纹和 GAT 的空间信息；Dnn-PP [169] 则结合了 GAT 学习到的图嵌入与 DNN 处理的传统描述符。

近年来，融合三种及以上模态的方法逐渐增多。Karim 等人 [170, 171] 通过元集成学习融合图像、二维特征和 SMILES 信息；He 等人 [172] 则利用自监督学习与模态专用编码器缓解表示冲突，并通过后期融合或跨模态注意力实现多源特征对齐。其他相关工作还包括 Busk 等人 [**?**] 基于 MPNN 集成不确定性量化信息，以及 Ding 等人 [174] 证明了多维指纹在 hERG 毒性预测中的有效性。

针对分子的层次化结构特征，HRGCN+ [175] 在双曲空间中联合 GCN 与分子描述符，并利用黎曼流形上的可微映射增强模型表征能力，尤其在小样本场景下表现突出。总体而言，多模态融合通过整合异构表示，有效弥补了单一模态方法的不足，为构建更准确、更鲁棒的 MPP 模型提供了新的思路。

1.2.3 基于大语言模型的分子性质预测方法

随着大语言模型在通用领域取得显著成功，研究者开始探索其在分子性质预测中的应用。一类工作通过构建分子—文本联合语料，对语言模型进行微调，以增强其对分子结构与性质之间关系的建模能力。例如，Liu 等人 [176] 将训练语料中的分子标识符替换为 SMILES 序列，构建包含分子表示的文本数据，并在此基础上微调 MolT5 [177]，从而实现分子性质预测以及分子与自然语言之间的双向翻译。类似地，Liu 等人 [178] 基于 SMILES 构建了混合指令集，用于微调 LLaMA，并在少样本（few-shot）和零样本（zero-shot）MPP 任务中取得了较优性能。Luo 等人 [179] 提出的 MolFM 进一步融合知识图谱、分子结构与自然语言，训练了一个多模态分子基础模型；Pei 等人 [180] 开发的 BioT5 则在 SELFIES 分子表示、蛋白质序列与自然语言上进行联合训练，同样支持 MPP 及相关任务。

另一类研究尝试直接利用通用大语言模型中蕴含的人类经验知识，而非完全依赖大规模领域微调。事实上，现有通用大语言模型，如 ChatGPT [181] 和 DeepSeek [182]，已在海量人类知识语料上进行了预训练，因而可能内化了丰富的分子相关经验知识。例如，LLM4Mol [183] 利用 ChatGPT 对分子序列进行自然语言注释，并将得到的注释文本嵌入用于下游任务；LLM4SD [184] 则借助 LLM 提取任务相关规则，并基于这些规则对分子进行向量化表示，随后训练随机森林模型完成分子性质预测。

尽管上述方法在一定程度上展示了 LLM 在分子性质预测中的潜力，但仍存在明显局限。一方面，基于微调的模型通常依赖大规模数据和较高的训练成本，本质上仍是通过学习分子表示与自然语言之间的映射关系来完成任务，而未充分挖掘预训练语言模型中已蕴含的化学知识。另一方面，直接利用通用 LLM 知识的相关方法虽然能够借助人类经验辅助建模，却往往忽略了分子本身固有的结构信息。

从本质上看，LLM 从人类语料中习得的分子知识具有明显的长尾分布特征：对于研究较为充分的分子或性质，模型可能积累了较丰富的经验知识；而对于文献支持不足或较为罕见的分子性质关系，LLM 则难以提供稳定且可靠的参考。因此，在分子相关任务中，如何将 LLM 的知识推理能力与分子固有的结构信息有机结合，成为进一步提升分子性质预测性能与可信度的关键问题。

总体来看，分子性质预测研究已呈现出从“专家特征驱动的传统机器学习”，到“基于单一分子表示的深度表征学习”，再到“面向异构信息融合的多模态建模”，并进一步迈向“基于大语言模型的知识增强与可解释推理”的演进趋势。然而，现有研究在多源分子信息的统一建模、端到端推理能力以及化学事实一致性保障等方面仍存在不足，这也为后续研究提供了重要的切入点。

1.2.4 研究路径

综上所述，分子性质预测研究经历了由专家特征驱动的传统机器学习，到基于单一分子表示的深度学习，再到面向异构信息融合的多模态建模，并进一步发展到利用大语言模型进行知识增强与可解释推理的阶段。整体上，研究范式已由早期以预测精度为核心，逐步转向兼顾表征能力、解释能力与决策可信性的综合建模。然而，现有方法在多源分子信息统一建模、端到端推理能力以及化学事实一致性保障等方面仍存在明显不足，这也构成了本文进一步开展研究的现实背景与理论动因。

1.3 主要研究内容

本文围绕分子性质预测任务中大语言模型的可解释推理与鲁棒推理问题展开研究。针对现有方法在多源分子信息统一建模、端到端链式推理能力以及复杂场景下推理稳定性方面的不足，本文按照“端到端链式推理构建—鲁棒链式推理优化”的总体思路，开展了以下两方面研究。

（1）面向多源异质分子表示融合的端到端可解释推理方法。

针对传统分子性质预测方法中多源异质分子表示难以有效统一建模、端到端推理能力不足的问题，本文提出了一种面向多源异质分子表示融合的端到端可解释推理方法。

首先，在数据层面，设计基于提示工程的思维链数据构建与质量评估方法，利用高性能模型自动生成分子性质预测过程中的思维链与答案，并通过 LLM 评估从逻辑性、连贯性和专业性等维度对生成结果进行筛选，构建高质量 CoT 训练数据集。

其次，在模型层面，提出面向分子性质预测的多源分子表示融合模型。该模型通过分子图编码器提取图结构表示，利用多层级图投影器将多尺度图结构信息映射到语言模型输入空间，并与 SMILES 及自然语言指令共同组成统一输入序列，从而实现分子图、SMILES 与文本指令的统一建模。基于该框架，模型能够同时输出分子性质预测结果及其对应的自然语言推理过程。

最后，在训练层面，采用面向语义对齐与推理生成的两阶段训练策略：首先实现分子图表示与语言空间的有效对齐，然后在此基础上进行任务级端到端微调，使模型具备面向分子性质预测的可解释推理生成能力。该部分工作的目标是构建一个兼具多源异质分子表示融合能力与端到端可解释推理生成能力的分子性质预测模型。

（2）基于反思与探索的分子性质鲁棒推理优化方法。

尽管端到端推理模型能够生成结构化推理过程，但其推理链仍容易受到早期误判、知识缺失及幻觉的影响，进而导致逻辑不一致与错误结论。为此，本文进一步研究基于反思与探索的分子性质鲁棒推理优化方法。

首先，在推理形式上，提出基于反思与探索的思维链形式，将传统单路径 CoT 扩展为包含连续推理、反思和探索的动态思维链形式，使模型在推理过程中具备自我检查、错误修正和探索能力。

其次，在数据构建上，提出多 Agent 协同的思维链数据生成框架。该框架通过生成、评估、筛选与知识检索等模块协同工作，构建包含“尝试—检查—修正—再推理”过程的高质量轨迹，从而提升训练数据对鲁棒推理行为的刻画能力。

最后，在训练优化上，提出分层奖励驱动的鲁棒推理强化学习方法，结合反思与探索策略，对模型进行进一步精炼。该方法从答案正确性、推理一致性和化学合理性三个层面构建奖励函数，使模型能够进一步学会何时继续推理以及何时进行反思，从而提升其在复杂场景下的推理稳定性与可信度。

综上，如图1.1所示，本文区别与传统机器学习的分子性质预测方法，形成了一条从端到端链式推理建模到鲁棒链式推理优化的完整技术路线，为构建可解释、可信且具有良好泛化能力的分子性质预测模型提供了系统的方法支撑。

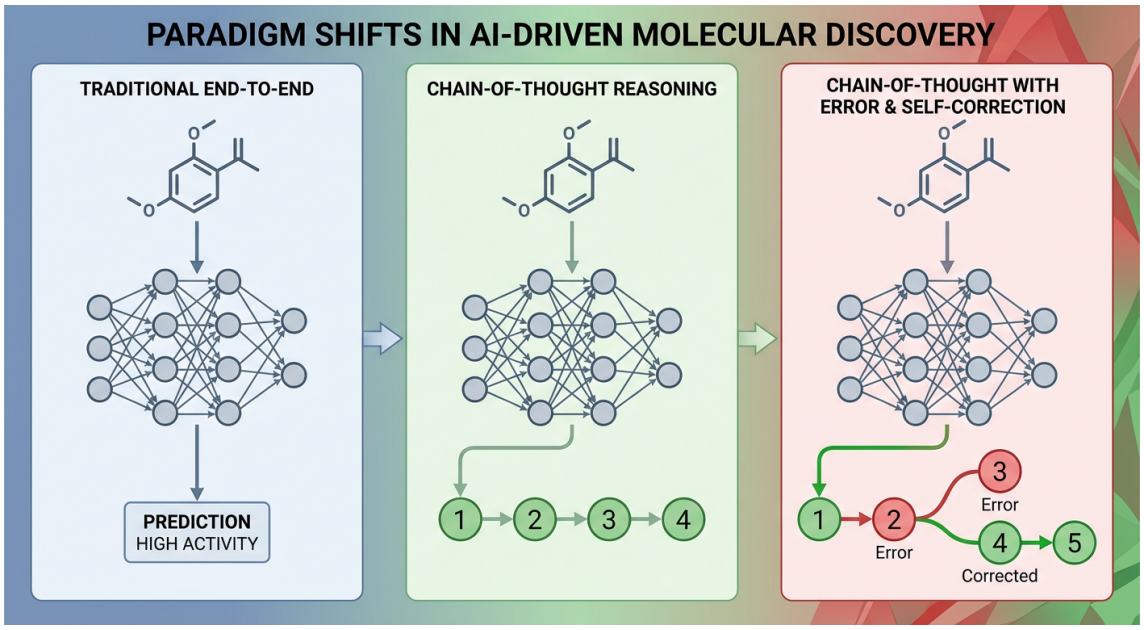


图 1.1　主要研究内容

1.4　论文的组织结构

本论文共分为五个章节，组织结构如图1.3所示。各章节的内容安排如下：

第一章，绪论：介绍本论文的研究背景、研究意义和国内外研究现状并总结本论文的主要研究内容与贡献。

第二章，相关理论和技术：介绍与本论文研究内容相关的理论背景和技术，具体包括分子性质预测任务的形式化定义、图神经网络、大语言模型、Q-Former、检索增强生成、监督指令微调方法、强化学习方法，是第三、四章的理论技术基础。

第三章，面向多源异质分子表示融合的端到端可解释推理方法：针对分子图、SMILES 表示与文本知识等多源异质信息难以统一建模，以及传统方法缺乏端到端推理与解释生成能力的问题，提出一种面向多源异质分子表示融合的端到端可解释推理方法。本章首先构建用于分子性质预测的高质量思维链数据，并设计相

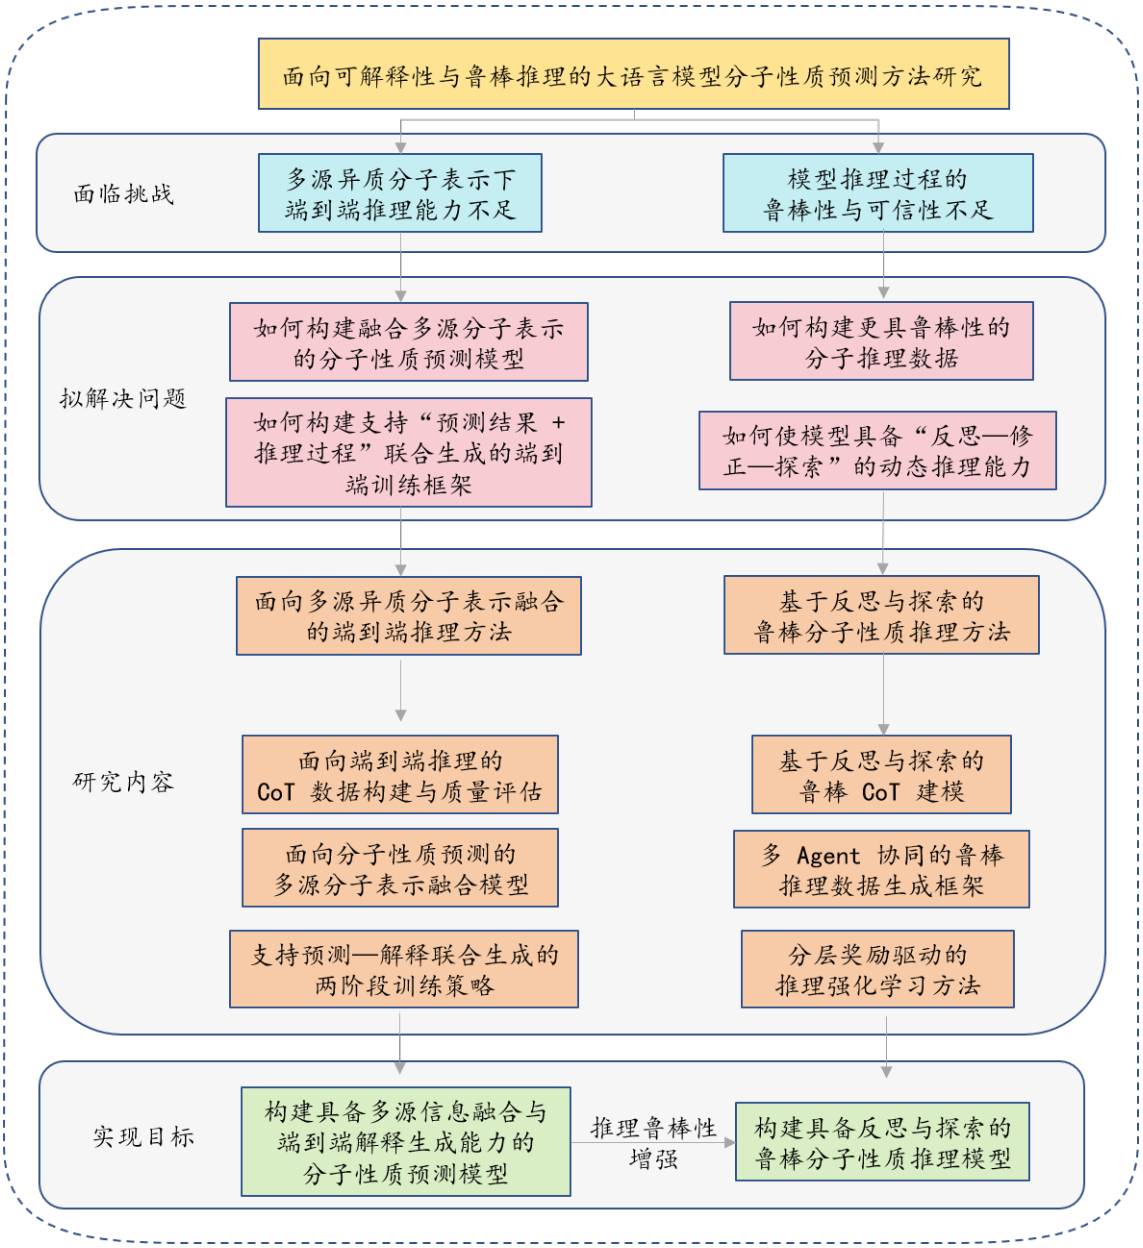


图 1.2　论文主要研究内容

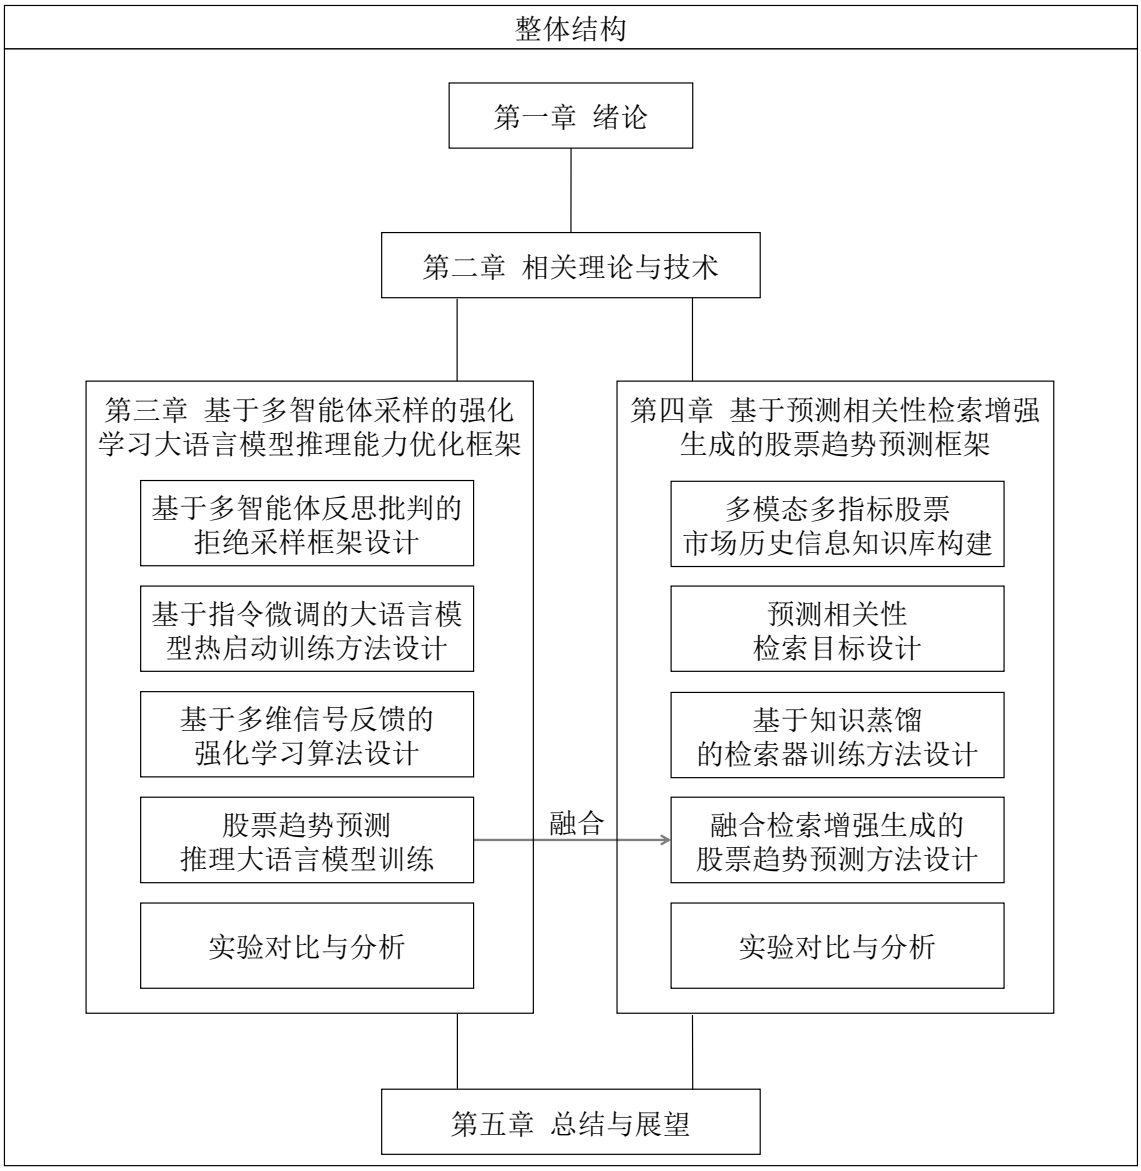


图 1.3 论文组织结构图

应的数据质量评估机制；随后，构建融合分子图、SMILES 与文本指令的统一建模框架，通过 Q-Former 等模块实现不同模态分子信息的有效对齐与协同表示；在此基础上，采用两阶段训练策略，使模型能够联合完成分子性质预测与自然语言推理过程生成。最后，通过在多个分子性质预测数据集上的实验，验证所提方法在预测性能、推理质量与可解释性方面的有效性。

第四章，基于反思与探索的分子性质鲁棒推理优化：针对大语言模型在分子性质推理过程中存在的幻觉干扰、逻辑不一致以及复杂场景下推理稳定性不足等问题，提出一种基于反思与探索的分子性质鲁棒推理优化方法。本章首先构建“推理—反思—探索”的动态思维链推理框架，并结合多 Agent 协同机制与外部知识

增强手段生成更加鲁棒的训练数据；随后，引入分层奖励驱动的强化学习优化策略，从答案正确性、推理一致性和化学合理性等多个维度对模型进行优化；最后，通过对比实验与消融实验，系统分析所提方法在复杂分子任务中的鲁棒性、可信性与泛化能力提升效果。

第五章，总结与展望：总结本论文的研究结果并对未来研究方向和可能的改进方法进行展望。

第 2 章　相关理论基础与关键技术

本章介绍本文研究所依赖的相关理论与关键技术。由于本文面向分子性质预测任务，且核心目标是构建具备端到端链式推理能力与鲁棒推理能力的大语言模型，因此本章首先对分子性质预测任务进行形式化定义，在此基础上，围绕本文技术路线，分别介绍分子结构建模所依赖的图神经网络、大语言模型及其链式推理能力、模态对齐模块 Q-Former、检索增强生成、监督指令微调以及强化学习等关键方法。上述理论与技术共同构成了后续模型设计、数据构建与训练优化的理论基础。

2.1　分子性质预测

分子性质预测（Molecular Property Prediction, MPP）旨在根据分子的结构信息，对其理化性质、生物活性、毒性或药代动力学性质等进行预测。传统方法通常将该问题建模为分类或回归任务，即给定分子的某种表示形式，输出相应的性质标签或数值。然而，本文关注的不仅是最终预测结果本身，还关注模型在生成预测结论时所依据的推理过程。因此，本文将分子性质预测统一建模为一个“预测结果与解释性推理联合生成”的任务。

具体而言，给定一个分子，其一维 SMILES 表示记为 S，二维分子图表示记为 $G = (V, E)$；对于特定的分子性质预测任务，构造相应的自然语言指令 T，用于描述任务目标与输出要求。模型在接收分子的多模态表示及任务指令后，生成响应文本序列

$$Y = \{y_i\}_{i=1}^{K},$$

其中 Y 是包含链式推理过程（Chain-of-Thought, CoT）与最终答案的结构化响应。进一步地，可将输出写为

$$Y = (Y_{\text{cot}}, y),$$

其中 Y_{cot} 表示推理过程文本，y 表示最终性质预测结果。

在此基础上，本文将分子性质预测任务形式化为条件文本生成问题，即：

$$p(Y \mid S, G, T) = \prod_{i=1}^{K} p(y_i \mid S, G, T, y_{<i}), \tag{2.1}$$

其中 $y_{<i}$ 表示第 i 个 token 之前已生成的历史序列。该条件概率由融合分子图表示、SMILES 表示和任务指令的大语言模型进行建模。若记分子图编码器与图投影器

对分子图 G 的表示变换为 $\mathbf{H}_{\text{graph}} = \text{Proj}(g(G))$，则模型可进一步写为：

$$Y \sim LLM_\theta(S, \mathbf{H}_{\text{graph}}, T). \tag{2.2}$$

本文研究的分子性质预测不再是单纯的标签预测问题，而是一个融合 SMILES、分子图和自然语言指令的多模态条件生成问题。在这一统一框架下，模型不仅需要输出性质判断结果，还需要生成与预测结论相对应的可解释推理过程。

2.2 图神经网络

分子本质上由原子及其之间的化学键构成，因此天然可以表示为图结构。与仅依赖线性序列表示的方法相比，图表示能够更直接地刻画分子的拓扑关系和局部化学环境。图神经网络（Graph Neural Network, GNN）为分子图表示学习提供了有效手段，因此成为分子机器学习中的核心技术之一。

对于每个分子，本文将其表示为一个无向图 $G = (V, E)$，其中 V 表示节点集合，对应分子中的原子；E 表示边集合，对应原子之间的化学键，且 $|V| = n_V$。对于任一节点 $v \in V$，其初始特征表示为 $\mathbf{x}_v$，可包含原子类型、价态、电荷、杂化方式、芳香性等信息；边 $(u, v) \in E$ 则可包含键类型、键阶等化学键信息。节点 v 的邻居集合记为：

$$\mathcal{N}(v) = \{u \mid (u, v) \in E\}.$$

GNN 的核心思想是通过消息传递机制迭代聚合邻域信息，从而学习节点及图的结构表示。设第 l 层中节点 v 的表示为 $\mathbf{z}_v^{(l)} \in \mathbb{R}^{d^{(l)}}$，则一般形式的消息传递过程可写为：

$$\mathbf{z}_v^{(l)} = \text{UPDATE}^{(l)}\left(\mathbf{z}_v^{(l-1)}, \text{AGGREGATE}^{(l)}\left(\left\{\mathbf{z}_u^{(l-1)} : u \in \mathcal{N}_v\right\}\right)\right), \quad l = 1, \ldots, L, \tag{2.3}$$

其中 $\mathbf{z}_v^{(0)} = \mathbf{x}_v$。聚合函数 AGGREGATE(·) 用于汇总邻居节点信息，更新函数 UPDATE(·) 用于结合自身表示与邻域聚合结果生成新的节点表示。

经过 L 层消息传递后，节点表示 $\mathbf{z}_v^{(L)}$ 能够编码其在 L 跳邻域范围内的结构上下文信息。由于分子性质往往与局部官能团和全局拓扑结构共同相关，因此 GNN 对分子图建模具有天然优势。

本文采用图同构网络（Graph Isomorphism Network, GIN）[114] 作为分子图编码器。GIN 具有较强的判别能力，已被广泛应用于分子图理解任务 [124]。其更新公式为：

$$\mathbf{z}_v^{(l)} = \text{MLP}^{(l)}\left((1 + \epsilon^{(l)}) \cdot \mathbf{z}_v^{(l-1)} + \sum_{u \in \mathcal{N}_v} \mathbf{z}_u^{(l-1)}\right), \tag{2.4}$$

其中 $\epsilon^{(l)}$ 为可学习参数或固定标量，$\mathrm{MLP}^{(l)}$ 表示第 l 层的多层感知机。GIN 通过求和聚合邻域信息，并使用 MLP 对聚合后的表示进行非线性映射，从而有效提升对图结构差异的辨别能力。

在本文中，GNN 的主要作用是为分子提供结构化表示，使大语言模型在处理 SMILES 等序列信息之外，还能够利用分子的二维拓扑结构与局部化学语义，为后续的性质预测与链式推理生成提供结构基础。

2.3 大语言模型

2.3.1 大语言模型概述

大语言模型（Large Language Model, LLM）是基于大规模语料预训练的深度神经网络模型，具有较强的语言理解、文本生成和上下文推理能力。其核心优势在于能够通过参数化知识表示学习通用语义模式，并在下游任务中展现较强的迁移能力和指令遵循能力。近年来，大语言模型已从单纯的自然语言处理工具逐步发展为支持复杂任务求解与多步推理的重要基础模型。

从架构上看，当前主流大语言模型主要包括编码器型、解码器型和编码器—解码器型三类。编码器型模型更擅长文本表示学习与理解任务，解码器型模型更适合自回归文本生成，而编码器—解码器型模型则常用于序列到序列任务。由于本文的目标是联合生成分子性质预测结果与自然语言推理过程，因此更关注基于解码器架构的大语言模型。

2.3.2 大语言模型解码器架构

解码器型大语言模型通常基于自回归语言建模范式，其目标是在给定前文上下文的条件下，逐步预测序列中的下一个词元。设输入序列为 $X = (x_1, x_2, \ldots, x_T)$，则其联合概率可表示为：

$$P(x_1, x_2, \ldots, x_T) = \prod_{t=1}^{T} P(x_t \mid x_1, x_2, \ldots, x_{t-1}). \tag{2.5}$$

在具体实现上，输入序列首先经过词嵌入与位置编码，得到初始表示：

$$H^{(0)} = E(X) + P, \tag{2.6}$$

其中 $E(X)$ 表示词嵌入，P 表示位置编码。

解码器通常由多层 Transformer 模块堆叠构成，每一层主要包括掩码多头自注意力、前馈网络，以及残差连接与层归一化。对于第 l 层，其自注意力机制可表示

为：

$$Q = H^{(l-1)}W_Q, \quad K = H^{(l-1)}W_K, \quad V = H^{(l-1)}W_V, \tag{2.7}$$

$$\text{Attention}(Q, K, V) = \text{Softmax}\left(\frac{QK^\top}{\sqrt{d_k}} + M\right)V, \tag{2.8}$$

其中 M 为因果掩码，用于限制当前位置只能关注自身及之前的位置。

多头注意力输出后，经过残差连接与层归一化，再输入前馈网络，可写为：

$$\tilde{H}^{(l)} = \text{LayerNorm}\left(H^{(l-1)} + \text{MHA}(H^{(l-1)})\right), \tag{2.9}$$

$$H^{(l)} = \text{LayerNorm}\left(\tilde{H}^{(l)} + \text{FFN}(\tilde{H}^{(l)})\right). \tag{2.10}$$

经过多层解码器堆叠后，最终隐藏状态通过线性层和 softmax 映射为词表上的概率分布：

$$P(x_{t+1} \mid x_{\le t}) = \text{Softmax}(W_o h_t^{(L)} + b). \tag{2.11}$$

总体而言，解码器型大语言模型通过掩码自注意力机制建模序列中的条件依赖关系，并以自回归方式逐步生成输出词元。

由于解码器型大语言模型能够自然建模“输入条件—逐步生成输出”的过程，因此非常适合本文所研究的“给定分子表示和任务指令，生成预测结果及推理过程”的统一建模任务。

2.3.3 大语言模型的推理能力与可解释性

在复杂任务中，大语言模型不仅能够生成最终答案，还能够生成由中间步骤构成的自然语言推理过程。思维链（Chain of Thought，CoT）提示通过引导模型在输出答案前显式生成中间推理步骤，将原本隐式的推断过程外化为可观察的文本序列，从而有效增强模型的多步推理能力 [187]。

CoT 提升推理性能的原因主要体现在以下几个方面。首先，它能够将复杂问题分解为多个更易处理的子问题，降低整体推理难度；其次，逐步生成过程更符合预训练语料中常见的“解释—结论”模式，有助于模型更自然地调用已有知识；再次，CoT 将一次性的全局决策转化为一系列局部决策，降低了搜索空间复杂度。

对于本文而言，CoT 的意义不仅在于提升分子性质预测性能，更在于为模型提供可解释性。通过分析模型生成的推理链，可以更清楚地观察模型在判断分子性质时所依据的结构特征、化学概念和推理逻辑。然而需要指出的是，生成的推理文本并不必然等同于模型真实的内部计算过程，因此 CoT 提供的是一种“可分析的解释窗口”，而非完全忠实的内部机制刻画。

综上，大语言模型及其 CoT 能力为本文构建“预测—推理联合生成”的分子性质预测模型提供了关键理论基础。

2.4 Q-Former

在多模态模型中，不同模态的特征往往分布在不同表示空间，如何将它们有效对齐并映射到统一语义空间，是实现多模态融合的关键问题。本文关注的分子多模态信息包括分子图、SMILES 以及自然语言指令，其中分子图通常首先通过 GNN 编码为一组连续节点表示，而大语言模型则以离散 token 序列作为输入，因此需要一种适配模块实现图模态与语言模态之间的高效对齐。Q-Former[185] 正是一类具有代表性的跨模态适配器。

Q-Former 的核心思想是引入一组可学习查询向量（learnable queries），通过跨注意力机制主动从输入特征中提取对下游任务最有用的信息。设输入特征为 $X \in \mathbb{R}^{N\times d_x}$，其中 N 为 token 数量，d_x 为特征维度。Q-Former 引入 M 个查询向量 $Q = \{\mathbf{q}_1, \dots, \mathbf{q}_M\}$，其中通常有 $M \ll N$。通过跨注意力操作，生成压缩后的表示：

$$Z = \{\mathbf{z}_1, \dots, \mathbf{z}_M\} \in \mathbb{R}^{M\times d_q}.$$

这一机制具有三方面优势。首先，它能够将原始长度不固定的多模态输入压缩为固定长度表示，便于与大语言模型对接；其次，可学习查询向量能够根据任务需求主动筛选关键信息，而非被动地平均聚合输入特征；再次，Q-Former 输出维度固定，适合作为不同模态到统一表示空间的桥梁。

在本文中，Q-Former 的思想主要体现在图结构特征向语言模型输入空间的映射过程中。虽然本文采用了更贴合分子图特点的多层级图投影机制，但其本质与 Q-Former 一样，都是通过可学习查询来主动提取和压缩跨模态信息，其为本文多模态融合框架提供了重要的理论参考。

2.5 检索增强生成

检索增强生成（Retrieval-Augmented Generation, RAG）是一种将信息检索系统与生成式语言模型相结合的技术框架，其核心思想是在生成过程中动态引入外部知识，以弥补模型参数化知识的不足，从而提升生成结果的准确性、完整性与事实一致性。该方法已被广泛应用于开放域问答、知识生成和复杂推理等任务中 [68]。

在 RAG 框架中，首先由检索器根据输入查询从外部知识库中检索出若干相关文档或知识片段，然后将这些检索结果作为补充上下文与原始输入一同送入生成模型，从而指导其生成更加可靠的输出。根据表示方式的不同，检索器通常分为

稀疏检索器与密集检索器两类。稀疏检索器主要依赖关键词匹配与统计特征，具有实现简单、效率高和可解释性强等优点；密集检索器则通过神经网络将文本映射到连续语义空间中，通过向量相似度进行匹配，能够更好地捕捉语义层面的相关性，因此成为当前主流 RAG 系统中的常用方案。

密集检索器通常采用双塔式编码器（Bi-Encoder）架构。对于查询 q 和候选文档 d，通过共享编码器 Enc_ϕ 分别得到其向量表示：

$$\boldsymbol{e}_q = \mathrm{Enc}_\phi(q), \quad \boldsymbol{e}_d = \mathrm{Enc}_\phi(d), \tag{2.12}$$

并进一步计算二者的相似度：

$$\mathrm{sim}(q, d) = \frac{\boldsymbol{e}_q^\top \boldsymbol{e}_d}{\|\boldsymbol{e}_q\| \, \|\boldsymbol{e}_d\|}. \tag{2.13}$$

在本文中，RAG 的作用并非一般意义上的开放域知识补充，而是面向分子任务的检索增强，即根据分子结构、任务需求以及推理中的不确定点，从外部知识库中检索与官能团特征、理化性质、经验规则和相似分子有关的知识片段，为模型提供更加细粒度的领域知识支撑。因此，RAG 是本文提升鲁棒推理能力、降低化学幻觉的重要技术之一。

2.6 监督指令微调方法

监督指令微调（Supervised Instruction Tuning, SFT）是使预训练语言模型适应特定任务和指令跟随场景的基础方法。其核心思想是在高质量“指令—响应”数据对上对模型进行有监督训练，使模型学会根据输入指令生成符合预期的输出。

从形式上看，给定输入指令 x 和目标回答 y，监督指令微调的目标函数可表示为最大化条件概率 $\log p(y|x)$，通常采用标准的自回归交叉熵损失进行优化。对于本文而言，SFT 的输入不仅包括任务指令，还包括分子的多模态表示；输出则可以是分子性质预测结果，也可以是“推理过程 + 最终答案”的结构化文本。因此，SFT 是本文构建端到端 CoT 分子性质预测模型的关键训练手段。

在大语言模型参数规模较大的情况下，直接进行全参数微调往往需要较高的计算资源和存储开销。为此，参数高效微调（Parameter-Efficient Fine-Tuning, PEFT）方法被广泛采用，其中 LoRA（Low-Rank Adaptation）是最具代表性的技术之一[85]。LoRA 通过将权重更新矩阵表示为两个低秩矩阵的乘积，从而显著减少可训练参数数量。具体而言，对于原始权重矩阵 $\boldsymbol{W}_0 \in \mathbb{R}^{d\times k}$，其更新形式为：

$$\boldsymbol{W} = \boldsymbol{W}_0 + \Delta\boldsymbol{W}, \tag{2.14}$$

其中 LoRA 将更新矩阵表示为：

$$\Delta \boldsymbol{W} = \boldsymbol{B}\boldsymbol{A}, \tag{2.15}$$

这里 $\boldsymbol{B} \in \mathbb{R}^{d\times r}$、$\boldsymbol{A} \in \mathbb{R}^{r\times k}$，且 $r \ll \min(d,k)$。通过这种方式，LoRA 在保持原有模型结构不变的前提下，大幅降低了微调成本。

本文采用基于 LoRA 的监督指令微调方法，在高质量合成推理数据上训练大语言模型，从而增强模型的指令遵循能力、分子分析能力与端到端链式推理能力。

2.7 强化学习方法

监督学习能够使模型模仿高质量数据中的推理模式，但难以直接优化推理路径本身的质量，尤其难以显式鼓励模型学习“何时反思”“何时修正”以及“何时切换推理路径”等高级行为。为此，本文进一步引入强化学习方法，对模型的推理策略进行后训练优化。

强化学习通过“策略与环境交互—获取奖励—更新策略”的方式，使模型能够在试错过程中逐步学习更优决策。近年来，在大语言模型后训练领域，基于奖励信号优化生成行为已成为提升复杂推理能力的重要手段。其中，近端策略优化（Proximal Policy Optimization, PPO）[186] 是最具代表性的策略梯度方法之一。

设当前策略为 $\pi_{\theta_{\text{old}}}$，其与环境交互后得到一批轨迹数据：

$$\mathcal{D} = \{(s_t, a_t, r_t, s_{t+1})\}_{t=1}^{T},$$

其中 s_t 表示状态，a_t 表示动作，r_t 表示即时奖励。基于这些轨迹数据，可以进一步估计优势函数：

$$\hat{A}_t = \hat{Q}(s_t, a_t) - \hat{V}(s_t),$$

用以衡量当前动作相对于平均策略的优劣程度。

PPO 的核心是利用如下剪切代理目标函数对策略进行更新：

$$L^{\text{CLIP}}(\theta) = \mathbb{E}_t\left[\min\left(r_t(\theta)\hat{A}_t,\ \text{clip}(r_t(\theta), 1-\epsilon, 1+\epsilon)\hat{A}_t\right)\right],$$

其中

$$r_t(\theta) = \frac{\pi_\theta(a_t|s_t)}{\pi_{\theta_{\text{old}}}(a_t|s_t)}.$$

该目标函数通过限制新旧策略之间的偏移幅度，避免模型在利用自生成样本更新时出现不稳定甚至性能崩溃。

在本文中，强化学习的作用是进一步优化模型生成的推理轨迹，使其不仅输出正确答案，还能够在推理过程中保持逻辑一致性、化学合理性以及较强的自我

修正能力。因此，强化学习是本文从“端到端可解释推理”进一步走向“鲁棒推理”的关键技术。

2.8 本章小结

本章系统介绍了本文研究所依赖的相关理论与关键技术。首先，对本文所研究的分子性质预测任务进行了形式化定义，明确了其“多模态输入—预测结果与推理联合生成”的任务形式。随后，介绍了分子结构建模所需的图神经网络、大语言模型及其链式推理能力、多模态对齐模块 Q-Former、检索增强生成、监督指令微调以及强化学习等方法。上述理论与技术为后续章节研究内容提供了理论基础和方法支撑。

第 3 章　面向多源异质分子表示融合的端到端可解释推理方法

3.1　引言

本章围绕面向多源异质分子表示融合的端到端可解释推理方法展开，重点介绍本文在数据构建、模型设计与训练策略三个层面的技术实现。尽管大语言模型在自然语言理解与生成任务中展现出较强的推理能力，但将其直接应用于分子性质预测仍面临两方面关键挑战：一方面，分子性质预测不仅要求模型输出准确的预测结果，还要求其能够结合分子结构信息给出具有化学意义的推理过程；另一方面，分子本身具有多源异质的表示形式，尤其是 SMILES 与分子图在语义空间和结构表达上存在显著差异，如何将其有效对齐并统一融入大语言模型仍是一个亟待解决的问题。

针对上述挑战，本章从“高质量推理监督信号构建”与“多模态结构—语言统一建模”两个维度展开研究。首先，为了使模型具备端到端的链式推理能力，本文设计了一种基于提示工程的大规模 CoT 数据构建方法，并引入独立的质量评估与筛选机制，以获得兼具答案正确性与推理可信度的训练数据。其次，为充分利用分子的结构信息，本文提出一种融合分子图与大语言模型的统一建模框架，通过分子图编码器和多层级图投影器，将分子图中的多尺度结构语义映射到语言模型可处理的向量空间，并与 SMILES 及自然语言指令共同参与建模。最后，为缓解跨模态对齐困难和直接端到端训练不稳定的问题，本文进一步采用两阶段训练策略，逐步完成图结构表示与语言空间的对齐，并在此基础上实现面向指令的端到端微调。

通过上述设计，本章构建了一个从高质量 CoT 数据生成，到分子图—语言统一建模，再到分阶段训练优化的完整技术框架，实现了多源异质分子表示场景下的端到端可解释推理方法。

3.2　CoT 数据构建与质量评估

为构建高质量的思维链训练数据，本文采用基于提示工程（prompt engineering）的自动化生成与筛选策略。具体而言，选用具备较强推理能力的大语言模型 Qwen3-235B-A22B-Thinking-2507 作为教师模型，面向分子性质预测任务生成包含详细推理过程的思维链及其对应答案。在此基础上，进一步引入独立的思维链质量评估

环节，从逻辑性、连贯性和领域专业性等维度对生成结果进行量化评分，并结合最终答案的正确性进行双重筛选，保留结论正确且推理质量较高的样本，最终构建得到高可信度的 CoT 数据集。

CoT 数据构建的关键在于提示词模板的设计。为提高生成结果的稳定性、专业性和可迁移性，本文构建了由四个核心模块组成的通用提示模板：

- **Role**（角色定义）：明确要求模型扮演分子性质预测领域的资深计算化学或药物化学专家，以保证推理过程尽可能符合领域知识和专业表达规范；
- **Task**（任务描述）：清晰给出当前待解决的具体任务，例如判断给定分子是否具有某种生物活性，从而引导模型围绕目标性质开展分析；
- **Output Formatting**（输出格式）：对推理文本与最终答案的输出结构进行严格约束，要求模型按照预设的步骤化形式生成内容，以提升结果的可解析性与一致性；
- **Few-Shot Examples**（少样本示例）：提供若干高质量的输入—输出示例，帮助模型更好地理解任务语义，并模仿合理的化学推理路径。

基于上述设计，本文采用如表3.1所示的通用提示词模板进行 CoT 数据构建。

表 3.1　思维链数据构建提示词模板

思维链数据构建提示词模板
Role: < 模型角色描述 > **Task:** < 模型任务描述 > **Output Formatting:** < 输出格式描述 > **Few-Shot Examples:** < 少样本样例 > **Molecular:** < 分子的 SMILES 表示 >

针对不同分子性质预测任务，模板中的具体内容将根据任务目标与数据集特点进行适配。以 BACE（Beta-secretase 1）抑制剂预测任务为例，其 CoT 生成提示词示例如表3.2所示。

仅依赖生成模型直接产出 CoT 数据，容易引入事实性错误、推理跳步或表达含混等问题。为进一步保证构建数据的可靠性与泛化能力，本文设计了一套与生

表 3.2　BACE 数据集思维链数据构建提示词

BACE 数据集思维链数据构建提示词

Role:

You are an expert medicinal chemist specializing in central nervous system (CNS) drug discovery....

Task:

Given a SMILES string representing a small molecule...

Output Formatting:

Provide your reasoning and prediction in the following exact format:

<cot>

Step 1: [Parse the SMILES and describe key structural features...

</cot>

<answer>[True or False]</answer>

Few-Shot Examples:

smiles: s1cc(cc1)-c1cc2c(nc(N)cc2)cc1

answer: True

Molecular:

<smiles>

成过程相互独立的思维链质量评估机制，对生成样本进行二次筛选。

该评估流程同样基于结构化提示词设计，主要包含以下四个组成部分：

- **Role**（角色定义）：设定模型扮演专业的推理质量评审专家，强调其从推理过程本身而非最终结论出发进行评价；
- **Task**（任务描述）：明确要求模型严格依据评分规则，对给定思维链的内在质量进行客观打分；
- **Scoring Dimension**（评价维度）：规定评估重点，包括推理过程的递进性、步骤之间的逻辑依赖关系以及语言表达的清晰程度；
- **Scoring Scale**（评分标准）：提供 0–10 的细粒度评分准则，覆盖从逻辑混乱到推理严谨的不同水平。

其通用评估模板如下表3.3所示：

表 3.3　思维链数据评估提示词模板

思维链数据评估提示词模板

Role:
< 模型角色描述 >
Task:
< 模型任务描述 >
Scoring Dimension:
< 评估维度 >
Scoring Scale (0-10):
< 评分标准 >
Smiles:
<SMILES>
Model Response:
< 思维链数据 >
Output:
<integer score>

仍以 BACE 任务为例，其具体评估提示词如下表3.4所示：

综合而言，本文采用“**教师模型生成 + 独立评估模型打分 + 答案正确性筛选**”的 CoT 数据构建流程，在保证样本规模的同时兼顾推理质量与结果可信度，为后续端到端 CoT 学习提供了高质量监督信号。

表 3.4　BACE 思维链数据评估提示词模板

BACE 思维链数据评估提示词模板

Role:

You are a professional reasoning-evaluation expert...

Task:

Adhering strictly to the rubric above, you must...

Scoring Dimension:

- Do reasoning steps build progressively and ...

confusing wording?

Scoring Scale (0-10):

- 10: Perfect logical structure; steps are crystal-clear and...

Smiles:

<SMILES>

Model Response:

<cot 数据 >

Output Format:

<integer score>

3.3 面向分子性质预测的多源分子表示融合模型

近年来，大语言模型在自然语言理解与生成任务中展现出较强的泛化能力和指令遵循能力，但将其直接应用于分子性质预测任务仍面临显著挑战。其根本原因在于，分子本质上是一类具有复杂拓扑关系的图结构数据，而纯文本模型难以充分刻画其中的局部化学环境与多尺度结构语义。现有分子语言模型大多依赖 SMILES 等一维序列表示，虽然能够保留基本的化学语法信息，但对分子拓扑结构、多跳依赖关系以及关键子结构的表达仍然有限；另一方面，图神经网络擅长建模分子结构，却难以直接与自回归大语言模型的语义空间对齐，且深层 GNN 容易出现过平滑（over-smoothing）问题，从而削弱对细粒度结构差异的辨识能力。

针对上述问题，本文提出一种面向分子性质预测的多源分子表示融合模型，用于实现面向指令的分子理解与性质预测。该框架在保留分子多源异质信息的基础上，通过多层级图投影机制将分子图表征有效对齐到语言模型的输入空间，实现分子图、SMILES 与自然语言指令的统一建模。整体模型由三个核心模块构成：**分子图编码器（Molecular Graph Encoder）**、**多层级图投影器（Multi-level Graph Projector）**和**大语言模型**。其中，分子图编码器用于提取分子结构表征；多层级图投影器负责将连续图表示转换为可被 LLM 处理的图 token；LLM 则负责跨模态信息融合与自回归生成，从而输出符合任务要求的响应。

3.3.1 分子图编码器：基于消息传递的结构表示学习

分子图编码器采用图神经网络对二维分子结构进行建模，以充分捕获原子之间的相互作用关系及分子整体拓扑结构。GNN 的基本思想是通过多轮消息传递（message passing）对邻域信息进行聚合，从而使节点表示逐层获得更大感受野下的结构语义。

设第 l 层中节点 v 的表示为 $\mathbf{z}_v^{(l)} \in \mathbb{R}^{d_l}$，其中第 0 层表示即为节点的输入特征：

$$\mathbf{z}_v^{(0)} = \mathbf{x}_v \tag{3.1}$$

在第 l 层，节点表示通过聚合邻居节点的信息并进行更新，得到：

$$\mathbf{z}_v^{(l)} = \mathrm{UPDATE}^{(l)}\Big(\mathbf{z}_v^{(l-1)}, \mathrm{AGGREGATE}^{(l)}\big(\{\mathbf{z}_u^{(l-1)} \mid u \in \mathcal{N}(v)\}\big)\Big), \quad l = 1, \ldots, L, \tag{3.2}$$

其中 $\mathcal{N}(v)$ 表示节点 v 的邻居集合。

本文选用图同构网络（Graph Isomorphism Network, GIN）[114] 作为分子图编码器。GIN 具有较强的判别能力，已被广泛应用于分子图理解任务。其第 l 层节点

更新形式为：

$$\mathbf{z}_v^{(l)} = \mathrm{MLP}^{(l)}\left((1+\epsilon^{(l)})\cdot \mathbf{z}_v^{(l-1)} + \sum_{u\in\mathcal{N}(v)} \mathbf{z}_u^{(l-1)}\right), \tag{3.3}$$

其中 $\epsilon^{(l)}$ 为可学习参数或固定标量。该模型以求和操作作为聚合函数，并以多层感知机（MLP）作为更新函数。

经过 L 层消息传递后，可得到最终的节点表示矩阵：

$$\mathbf{Z}^{(L)} = [\mathbf{z}_1^{(L)}, \mathbf{z}_2^{(L)}, \ldots, \mathbf{z}_{n_V}^{(L)}]^\top \in \mathbb{R}^{n_V\times d}. \tag{3.4}$$

若仅使用最后一层节点表示，则图 token 的嵌入可写为：

$$\mathbf{H}_{\text{graph}} = \mathrm{Proj}(\mathbf{Z}^{(L)}), \quad \text{where } \mathbf{Z}^{(L)} = g(G), \tag{3.5}$$

其中 Proj(·) 表示投影器，通常由 MLP 实现，$g(\cdot)$ 表示图编码器。

3.3.2 多层级图投影器：将图表示转换为图 token

在深层 GNN 中，节点表示容易出现过平滑现象，即随着层数增加，不同节点的表示逐渐趋同，进而导致局部结构差异被弱化。若仅使用最终层输出作为图表示，可能会丢失浅层所保留的细粒度结构信息，从而影响官能团识别、局部反应位点分析以及细粒度性质判断等任务。

为缓解这一问题，本文引入多层级图投影器，对不同层级的图表示进行联合建模。直观上，浅层表示更偏向于捕获局部原子环境信息，而深层表示则更侧重于编码更大范围的拓扑上下文。因此，本文提出多层级图投影器 $\mathrm{Proj}_{\mathrm{ML}}(\cdot)$，综合利用 $\{\mathbf{Z}^{(l)}\}_{l=0}^{L}$ 中的多尺度结构特征，以在 token 层面保留更丰富的分子结构信息。其形式化定义如下：

$$\mathbf{H}_{\text{graph}} = \mathrm{Proj}_{\mathrm{ML}}\left(\left\{\mathbf{Z}^{(l)}\right\}_{l=0}^{L}\right), \quad \text{where} \quad \left\{\mathbf{Z}^{(l)}\right\}_{l=0}^{L} = g(G). \tag{3.6}$$

由于分子图的节点数 n_V 随分子而变化，而 LLM 更适合处理固定长度或可控长度的 token 序列，因此投影器需要将可变长度的节点集合压缩为固定数量 b 的图 token。为此，本文引入 b 个可学习查询向量：

$$\mathbf{P}^{(l)} = \left[\mathbf{p}_1^{(l)}, \ldots, \mathbf{p}_b^{(l)}\right] \in \mathbb{R}^{b\times d}, \quad l = 0, \ldots, L. \tag{3.7}$$

对于第 l 层节点表示 $\mathbf{Z}^{(l)} \in \mathbb{R}^{n_V\times d}$，采用交叉注意力（cross-attention）进行聚合：

$$\hat{\mathbf{P}}^{(l)} = \mathrm{Attn}\left(\mathbf{P}^{(l)}, \mathbf{Z}^{(l)}, \mathbf{Z}^{(l)}\right) \in \mathbb{R}^{b\times d}. \tag{3.8}$$

其中 $\mathrm{Attn}(Q, K, V)$ 表示标准注意力操作，即以 Q 为 query、K 为 key、V 为 value。该机制使得固定数量的查询向量能够从不同层的节点表示中自适应读取关键信息，从而形成长度可控的结构摘要 token。

除节点级多尺度结构外，关键子结构（motif），尤其是官能团，往往直接影响分子的化学性质与反应活性。为增强模型对这类关键信息的显式感知，本文进一步引入 motif 级表示。设通过规则库或化学工具识别得到分子中的若干官能团子结构，其表示为：

$$\mathbf{Z}_{\mathrm{FG}} = [\mathbf{z}_{\mathrm{FG},1}, \ldots, \mathbf{z}_{\mathrm{FG},M}]^{\top} \in \mathbb{R}^{M \times d}, \tag{3.9}$$

其中 M 为官能团数量，$\mathbf{z}_{\mathrm{FG},i}$ 表示第 i 个官能团的向量表示。类似地，引入可学习查询向量 $\mathbf{P}^{(\mathrm{motif})} \in \mathbb{R}^{b \times d}$，并利用交叉注意力进行聚合：

$$\hat{\mathbf{P}}^{(\mathrm{motif})} = \mathrm{Attn}\big(\mathbf{P}^{(\mathrm{motif})}, \mathbf{Z}_{\mathrm{FG}}, \mathbf{Z}_{\mathrm{FG}}\big) \in \mathbb{R}^{b \times d}. \tag{3.10}$$

通过该模块，模型能够在 token 层面对关键子结构形成显式摘要表示，从而在后续推理与生成过程中更准确地聚焦与性质相关的化学基团。

最终，将不同层级的图 token 与 motif 级 token 进行拼接，并通过 MLP 映射得到图模态的最终输入表示：

$$\mathbf{H}_{\mathrm{graph}} = \mathrm{MLP}\Big([\hat{\mathbf{P}}^{(0)}, \ldots, \hat{\mathbf{P}}^{(L)}, \hat{\mathbf{P}}^{(\mathrm{motif})}]\Big) \in \mathbb{R}^{b \cdot (L+2) \times d}. \tag{3.11}$$

其中，$\mathbf{H}_{\mathrm{graph}}$ 的 token 数量为 $b \cdot (L+2)$。通过合理设置 b 与 L，可在结构信息表达能力与模型计算开销之间取得平衡。

3.3.3 输入表示与多模态 token 组织方式

LLM 的核心计算建立在 token 序列之上。为了使模型能够同时利用 SMILES、分子图结构以及自然语言指令，本文将三种模态统一组织为一个连续输入序列，并通过特殊标识符区分不同片段的语义角色。这样的设计使得 LLM 的自注意力机制能够跨越模态边界建立依赖关系，例如在生成性质判断时同时关注指令要求、SMILES 语法线索和图 token 中的结构信息。

设 SMILES token 的嵌入序列为 $\mathbf{E}^{(S)} \in \mathbb{R}^{n_S \times d}$，指令 token 的嵌入序列为 $\mathbf{E}^{(T)} \in \mathbb{R}^{n_T \times d}$，图 token 序列为 $\mathbf{H}_{\mathrm{graph}} \in \mathbb{R}^{n_G \times d}$（其中 $n_G = b \cdot (L+2)$）。则最终输入可组织为：

$$\mathbf{E}^{(\mathrm{in})} = [\mathbf{e}_{\langle \mathrm{BOS} \rangle}, \mathbf{E}^{(S)}, \mathbf{e}_{\langle \mathrm{GRAPH} \rangle}, \mathbf{H}_{\mathrm{graph}}, \mathbf{e}_{\langle \mathrm{INST} \rangle}, \mathbf{E}^{(T)}, \mathbf{e}_{\langle \mathrm{EOS} \rangle}], \tag{3.12}$$

其中 $\mathbf{e}_{\langle \cdot \rangle}$ 表示对应特殊标识符的可学习嵌入向量，$\langle \mathrm{BOS} \rangle$ 与 $\langle \mathrm{EOS} \rangle$ 分别表示序列起始符与终止符。上述模板可根据具体实现进行适当调整，例如交换指令与 SMILES

的位置，或为图 token 添加额外起止标记，但其核心原则是不变的，即**通过清晰分隔不同模态片段，使模型在训练中学习到稳定的输入结构与跨模态对齐方式**。

在位置编码方面，本文将图 token 视作序列的一部分，与文本 token 共享同一套位置编码机制。由于图 token 的长度可能显著影响整体输入长度，因此在设置 b 与 L 时需要综合考虑表达能力与计算效率。实践中可选取较小的 b（如 8 或 16）以及适中的层数 L，在保证结构信息充分表达的同时，控制 LLM 的输入规模。

3.3.4 大语言模型：融合与自回归生成

在构造统一输入序列 $\mathbf{E}^{(\text{in})}$ 后，模型将其输入大语言模型，以完成多模态信息融合与推理序列生成。本文所采用的大语言模型由多层 Transformer 解码器组成，各层均包含带因果掩码（causal mask）的自注意力模块。该掩码机制保证模型在生成第 i 个 token 时仅能利用其之前的上下文信息，从而满足自回归生成的约束条件。

由于图 token、SMILES token 以及指令 token 被统一组织于同一序列中，模型能够借助自注意力机制在不同模态之间建立全局交互关系，并依据当前生成目标自适应地选择关键信息来源。具体而言，局部化学子结构相关内容的生成通常更多依赖 motif token，而涉及分子整体拓扑特征或高层语义属性的生成则更多依赖深层图 token；与此同时，任务指令 token 在约束输出形式、控制响应内容以及引导生成目标方面发挥重要作用。

上述融合机制以统一序列建模为基础，无需对大语言模型的主体结构进行额外设计，因而能够在较低结构改动成本下实现多模态输入的协同建模。同时，该方式保留了大语言模型原有的上下文建模与自然语言生成能力，使模型能够在统一表示空间中综合利用分子结构信息与任务语义信息，从而支持分子性质预测结果及其解释性推理过程的联合生成。

设生成阶段第 i 个位置的隐藏状态为 $\mathbf{h}_i$，则对应词表上的条件概率分布定义为：

$$p(y_i \mid S, G, T, y_{<i}) = \text{Softmax}(\mathbf{W}_o \mathbf{h}_i + \mathbf{b}_o), \tag{3.13}$$

其中 $\mathbf{W}_o$ 与 $\mathbf{b}_o$ 分别为输出层的权重矩阵和偏置项。由此，目标序列 Y 的生成概率可进一步表示为：

$$p(Y \mid S, G, T) = \prod_{i=1}^{K} p(y_i \mid S, G, T, y_{<i}). \tag{3.14}$$

3.4 面向语义对齐与推理生成的两阶段训练策略

为充分结合分子图编码器对分子结构信息的建模能力与大语言模型在自然语言理解和生成方面的优势，同时缓解直接端到端联合训练可能带来的优化不稳定性问题，本文采用两阶段训练策略。该策略将模型训练过程划分为语义对齐与任务适应两个阶段：第一阶段侧重于分子图表示与语言空间的对齐，使模型能够将分子结构信息映射为大语言模型可有效利用的图 token；第二阶段在此基础上进一步引入自然语言指令，对模型进行面向下游任务的微调，使其具备分子性质预测及解释性响应生成能力。

具体而言，第一阶段主要训练分子图编码器与多层级图投影器，并保持大语言模型参数冻结；第二阶段则冻结分子图编码器，在继续优化图投影器的同时，对大语言模型进行参数高效微调。通过这种分阶段训练方式，模型能够在保证训练稳定性的前提下逐步完成结构表示对齐与任务能力适配，从而实现分子结构信息与语言语义信息的统一建模。

3.4.1 第一阶段：分子图—语言表示对齐

第一阶段的核心目标是实现分子图结构表示与大语言模型输入空间之间的有效对齐。由于分子图编码器输出的是连续向量表示，而大语言模型通常接收由离散 token 对应的嵌入序列作为输入，若直接将未经适配的图表示输入语言模型，往往难以被模型充分利用，甚至可能扰动其原有的语义分布。因此，在该阶段中冻结大语言模型参数，仅训练分子图编码器与多层级图投影器，使模型逐步学习将分子结构信息压缩并映射为分布稳定、语义可用的图 token，从而为后续指令驱动的任务学习奠定基础。

第一阶段所使用的训练数据主要由分子及其对应的自然语言描述构成。对于每个训练样本，输入包括分子的 SMILES 表示 S、对应的二维分子图 G 以及与该分子相关的自然语言描述 T_{desc}。其中，T_{desc} 主要用于描述分子的结构特征、类别信息或基础化学属性，而不包含显式的复杂任务指令，其作用在于帮助模型建立从分子结构到文本语义的基础映射关系。在输入组织上，SMILES token、图 token 与目标描述文本按照预定义模板拼接后输入大语言模型，并通过自回归方式生成相应的描述内容。

在参数更新策略上，第一阶段仅对分子图编码器与多层级图投影器进行训练，而保持大语言模型参数不变。这样做的目的在于避免在训练初期破坏大语言模型已有的语言建模能力，同时提升整体优化过程的稳定性。其中，分子图编码器负

责学习更适用于语言建模场景的结构表示，多层级图投影器则承担从图表示到图 token 的映射任务。

第一阶段采用标准的自回归语言建模损失进行优化。设模型在第 i 个位置生成目标 token 的条件概率为 $p(y_i \mid S, G, y_{<i})$，真实 token 为 y_i，则损失函数定义为：

$$\mathcal{L}_{\text{stage1}} = -\sum_{i=1}^{K} \log p(y_i \mid S, G, y_{<i}), \tag{3.15}$$

其中 K 表示目标描述文本的长度。该目标函数促使模型在保持大语言模型参数冻结的条件下，学习如何通过图 token 向语言模型注入有效的分子结构信息，从而完成图表示与语言表示空间之间的初步对齐。

3.4.2 第二阶段：基于指令的端到端微调

在完成第一阶段的图—语言表示对齐后，模型已经初步具备利用分子结构信息生成基础文本描述的能力。然而，此时模型学习到的主要仍是较为固定的结构—文本映射关系，尚不足以分子性质预测任务场景下的推理与结果生成。因此，第二阶段进一步引入自然语言指令，对模型进行指令驱动的端到端微调，以提升其对分子性质预测任务的适应能力。

第二阶段的目标在于使模型能够根据指令语义动态调整生成行为，从而在统一框架下支持分子性质预测及其解释生成等任务。对于分子性质预测场景，模型输出既可以是最终预测标签，也可以是包含“CoT 推理过程 + 最终答案”的结构化响应。相较于第一阶段主要学习结构信息到文本表达的映射，第二阶段更强调任务语义约束下的条件生成能力。

在训练数据构造上，第二阶段的样本以“指令—（CoT + 预测结果）”形式组织。具体而言，每个训练样本包括分子的 SMILES 表示 S、对应的二维分子图 G、自然语言形式的任务指令 T_{inst} 以及目标响应文本 $Y = (Y_{cot}, y)$。其中，指令 T_{inst} 明确规定模型需要完成的任务类型及输出要求，例如判断某一分子是否具有特定性质，并给出分步推理过程并输出最终结论。通过引入自然语言形式的任务描述，模型能够进一步学习任务语义与生成行为之间的映射关系，从而增强其在不同任务设置下的泛化能力与控制能力。

在参数更新策略上，第二阶段冻结分子图编码器，以保留第一阶段已经学习到的结构表示能力；与此同时，继续优化多层级图投影器，使其进一步适配指令驱动场景下的表示需求；对于大语言模型部分，则采用参数高效微调方式进行更新，以在控制训练成本的前提下提升模型的任务适应能力。该策略能够在尽量保留原有语言能力的同时，提高模型对分子性质预测任务的适配效果，并避免对大规模

语言模型进行全参数微调所带来的高额资源消耗。

第二阶段同样采用自回归语言建模损失进行优化，其目标函数定义为：

$$\mathcal{L}_{\text{stage2}} = -\sum_{i=1}^{K} \log p(y_i \mid S, G, T_{\text{inst}}, y_{<i}), \tag{3.16}$$

其中，模型在生成每个 token 时同时条件化于分子结构信息与任务指令语义。通过该优化目标，模型能够逐步学习在不同任务约束下生成符合要求的响应文本，从而在统一建模框架下实现分子性质预测结果与解释性推理过程的联合生成。

3.5 实验对比与分析

3.5.1 数据集

我们在 8 个多样化的分子性质预测数据集上评估 Mol-CoT 模型，以全面考察其在分布内（In-Distribution, ID）和分布外（Out-of-Distribution, OOD）场景下的性能表现。

分布内（ID）数据集：我们采用来自 MoleculeNet[188] 的四个经典基准数据集。MoleculeNet 是分子机器学习领域广泛使用的基准平台，用于预测给定分子是否具有特定生物或化学性质。具体包括：

① **BACE**（1,513 个分子）：该数据集用于预测分子对 β-分泌酶（Beta-site APP Cleaving Enzyme）的抑制活性，是阿尔茨海默病药物研发中的关键靶点。

② **BBBP**（2,039 个分子）：血脑屏障通透性（Blood-Brain Barrier Penetration）数据集，用于判断化合物是否能够穿透血脑屏障，这对中枢神经系统药物的设计至关重要。

③ **SIDER**（1,427 个分子）：Side Effect Resource 数据集，记录了药物与其在临床中观察到的副作用之间的关联，常用于多标签分类任务，评估模型对药物安全性的预测能力。

④**HIV**（41,127 个分子）：人类免疫缺陷病毒（Human Immunodeficiency Virus）抑制活性数据集，用于识别具有抗 HIV 活性的化合物，是抗病毒药物发现的重要资源。

分布外（OOD）数据集：我们使用来自 Therapeutic Data Commons[189, 190] 的四个数据集，以评估模型在跨任务、跨领域场景下的泛化能力。这些数据集更具挑战性，通常样本量较小且任务目标与 ID 数据集不同。具体包括：

①**Bioavailability**（128 个分子）：口服生物利用度（Oral Bioavailability）数据集，衡量药物在口服后被吸收进入系统循环的比例。该指标直接影响药物疗效，但

因数据规模极小，对模型的小样本学习能力提出高要求。

②**CYP2C9_V**（2,418 个分子）：细胞色素 P450 2C9 亚型（Cytochrome P450 2C9）抑制活性数据集。CYP2C9 是肝脏中药物代谢的关键酶，其抑制作用可能引发药物相互作用，因此该任务对药物安全性评估意义重大。

③**CYP2D6_V**（2,626 个分子）：细胞色素 P450 2D6 亚型抑制活性数据集。CYP2D6 参与约 25% 的临床药物代谢，其遗传多态性显著影响个体药物反应，是精准医疗中的重要考量因素。

④**AMES**（1,456 个分子）：Ames 致突变性测试数据集，用于预测化合物是否具有致突变性（即可能引起 DNA 突变），是早期药物筛选中评估遗传毒性的关键指标。

通过在上述 ID 与 OOD 数据集上的综合评估，我们能够全面衡量 MPPReasoner 在常规预测任务和更具挑战性的分布外泛化任务中的表现。

3.5.2 基准模型概述

为了证明本章方法的有效性，本论文将其与拥有公开源码的基于大语言模型的方法和基于传统深度学习的方法进行比较。

(1) 基于通用领域大语言模型的方法：

①o3-mini

②DeepSeek-V3.1

③GPT-4o

④Qwen2.5-VL-72B-Instruct

⑤Gemma-3-12b-it

⑥Qwen3-8B

(2) 基于特定任务专家模型的方法：

①Graphormer-p

②Uni-Mol

③GIMLET

④MolecularGPT

⑤Mol-LLM

⑥InstructMol-GS

⑦BioT5-Plus

⑧MolXPT

⑨3D-MoLM

⑩MolLLaMA

⑪TxGemma

表 3.5　基于指令微调的大语言模型热启动训练超参数

超参数	取值
Batch 大小	128
学习率	3e-4
epoch	2
混合精度	fp16
LORA_R	8
LORA_ALPHA	16
LORA_DROPOUT	0.05

表 3.6　基于多维信号反馈的强化学习训练超参数

超参数	取值
clip_ratio	0.2
entropy_coeff	0.001
grad_clip	1.0
kl_loss_coef	0.001
学习率	1e - 06
折扣因子 γ	1.0
Batch 大小	128
epoch	2

大语言模型训练与实验在 NVIDIA A800 80GB PCIe 上开展。本章实验所使用的相关硬件配置如表 3.7 所示。

3.5.3　评价指标

分子性质预测任务本质上可建模为二元分类问题。为全面评估模型的分类性能，本文采用 F1 分数和 AUC-ROC 作为评价指标。其中，F1 分数用于衡量模型在精确率与召回率之间的综合表现，AUC-ROC 则用于刻画模型在不同分类阈值下区分正负样本的整体能力。

表 3.7　实验环境详细配置

配置项	具体设备
操作系统	Ubuntu 20.04.1 LTS
内存	251G
GPU	NVIDIA A800 80GB PCIe
CPU	Intel(R) Xeon(R) Silver 4314 CPU @ 2.40GHz
CUDA	CUDA 12.8

F1 分数是精确率（Precision）与召回率（Recall）的调和平均数，尤其适用于类别分布不均衡的二元分类场景。其定义如下：

$$\text{Precision} = \frac{TP}{TP + FP}, \tag{3.17}$$

$$\text{Recall} = \frac{TP}{TP + FN}, \tag{3.18}$$

$$\text{F1-Score} = 2 \cdot \frac{\text{Precision} \cdot \text{Recall}}{\text{Precision} + \text{Recall}} = \frac{2 \cdot TP}{2 \cdot TP + FP + FN}, \tag{3.19}$$

其中，TP、FP 和 FN 分别表示真正例（True Positives）、假正例（False Positives）和假负例（False Negatives）。F1 分数的取值范围为 $[0, 1]$，其数值越大，表明模型在保证较高精确率的同时也具有较强的召回能力，因此能够更好地反映模型对正类样本的综合识别效果。

除 F1 分数外，本文还采用 ROC 曲线下面积（Area Under the Receiver Operating Characteristic Curve, AUC-ROC）作为评价指标。ROC 曲线通过统计不同分类阈值下的真阳性率（True Positive Rate, TPR）与假阳性率（False Positive Rate, FPR），刻画模型对正负样本的区分能力。其中，

$$\text{TPR} = \frac{TP}{TP + FN}, \tag{3.20}$$

$$\text{FPR} = \frac{FP}{FP + TN}, \tag{3.21}$$

其中，TN 表示真负例（True Negatives）。ROC 曲线以 FPR 为横轴、TPR 为纵轴，反映模型在不同判别阈值下的性能变化。

AUC-ROC 定义为 ROC 曲线下的面积，其取值范围为 $[0, 1]$。AUC-ROC 越大，说明模型对正负样本的排序与区分能力越强。当 AUC-ROC 等于 1 时，表示模型能够完全区分正负类；当 AUC-ROC 等于 0.5 时，表示模型的判别能力接近随机猜测。

综合而言，F1 分数强调模型在精确率与召回率之间的平衡，更适用于评价类别不均衡场景下的正类识别效果；AUC-ROC 则从阈值无关的角度刻画模型整体判别能力。本文同时报告这两项指标，以从不同侧面全面评估模型在分子性质预测任务上的性能。

3.5.4 实验结果与分析

Model	ID Performance				OOD Performance				Average	
	BACE	BBBP	SIDER	HIV	Bioavail.	C2C9_V	C2D6_V	AMES	ID	OOD
# Task-specific specialist models										
Graphormer-p	0.8575	0.7163	–	0.7788	–	–	–	–	0.7842	–
Uni-Mol	0.8570	0.7290	0.6590	**0.8080**	–	–	–	–	0.7633	–
GIMLET	0.6957	0.5939	–	0.6624	–	–	–	–	0.6507	–
MolecularGPT	0.7331	0.6822	–	0.6382	–	–	–	–	0.6845	–
Mol-LLM	0.8080	**0.8430**	0.7610	0.7650	–	–	–	–	0.7943	–
InstructMol-GS	0.8210	0.7240	–	0.6890	–	–	–	–	0.7447	–
BioT5-Plus	0.8620	0.7650	0.5201	0.7630	0.5243	0.4971	0.5321	0.4466	0.7275	0.5000
MolXPT	0.8840	0.8000	0.7170	0.7810	0.4749	0.5904	0.5291	0.6073	0.7955	0.5504
3D-MoLM	0.7287	0.5141	0.5073	0.6603	0.6066	0.7081	0.7029	0.7190	0.6026	0.6842
Mol-LlaMA	0.8349	0.6263	0.5576	0.7249	0.6020	0.7556	0.7789	0.7928	0.6859	0.7323
TxGemma	0.6380	0.7102	0.5619	0.5235	0.5813	0.8075	0.7595	0.7907	0.6084	0.7348
# LLM-based generalist models										
o3-mini	0.7891	0.5972	0.5626	0.6039	0.6246	0.7729	0.7643	0.8361	0.6382	0.7495
DeepSeek-V3.1-Think	0.7017	0.6048	0.5637	0.5938	0.6572	0.7633	0.7484	0.8218	0.6160	0.7477
GPT-4o	0.6070	0.6731	0.6347	0.5698	0.5826	0.5508	0.5902	0.6141	0.6212	0.5844
Qwen3-12b-it	**0.8526**	**0.6802**	**0.5652**	**0.6886**	0.6194	0.7886	0.7780	0.8130	**0.6967**	0.7498
Qwen3-8B	0.7924	0.6961	0.6442	0.5706	0.6181	0.7496	0.7165	0.7392	0.6758	0.7309
Qwen3-VL-8B-Instruct	0.8757	0.7096	0.5905	0.7143	0.5919	0.8012	0.7784	0.8514	0.7225	0.7557
Qwen3-VL-8B-Thinking	0.8597	0.7055	0.5973	0.5890	0.6073	0.7883	0.7572	0.8718	0.6879	0.7562
Qwen2.5-VL-72B-Instruct	0.7764	0.5791	0.5880	0.7325	0.6388	0.7624	0.7222	0.8156	0.6690	0.7348
Qwen2.5-VL-7B-Instruct	0.6910	0.6175	0.5823	0.5125	0.5232	0.7333	0.6999	0.7667	0.6008	0.6808
MPPReasoner (Ours)	**0.9090**	0.7436	**0.8280**	0.7932	**0.6728**	**0.8480**	**0.7950**	**0.8750**	**0.8190**	**0.7977**

第 4 章　基于反思与探索的分子性质鲁棒推理优化方法

4.1　引言

在前一章中，本文构建面向多源异质分子表示融合的端到端可解释推理方法，其基于 CoT 数据实现了分子性质预测结果与推理过程的联合生成。该方法使模型初步具备了端到端推理能力，能够围绕分子结构特征、官能团组成和化学性质生成较为完整的解释性文本。然而，现有思维链生成方式在推理鲁棒性方面仍存在明显不足，主要体现在以下两个方面：

一方面，模型生成的推理训练数据本身的鲁棒性不足。分子性质预测本质上是一类高度依赖领域知识的任务。其有效推理不仅需要识别分子结构、官能团和局部环境特征，还需要综合电子效应、分子间相互作用等多层次化学知识。在此情形下，模型容易产生事实性偏差或化学幻觉，即生成形式上合理但与真实化学规律不一致的解释。仅依赖模型参数中隐含的经验性知识，往往难以覆盖长尾分子、罕见结构和复杂机制分析所需的细粒度化学知识。这说明，仅靠监督微调得到的端到端推理能力，尚不足以支撑复杂场景下的可信推理。

另一方面，推理链通常表现为单一路径的连续展开过程，一旦在早期步骤中对关键结构特征、化学概念或作用机制作出错误判断，后续推理往往沿错误方向持续展开，缺乏有效的自我检查与纠错机制。这种“单路径、弱修正”的推理方式在复杂分子、边界样本或分布偏移场景下尤为脆弱。**在训练数据层面**，现有 CoT 数据大多强调最终答案正确与文本表面连贯，却较少显式包含“反思—修正—再推理”的过程性信息，导致模型更倾向于模仿静态答案式推理，而非学习动态的、可修正的推理策略。**在训练方法层面**，传统基于 next-token 预测的训练方式主要关注局部生成概率的优化，缺乏对多步推理链全局一致性、因果连贯性和关键中间结论正确性的直接约束，因此即便最终预测结果正确，其推理过程也可能存在逻辑跳跃甚至自相矛盾等问题。

针对上述问题，本章在前一章工作的基础上，进一步提出一种基于反思与探索的分子性质鲁棒推理优化方法。整体而言，本章从**数据构建和强化学习**两个层面提升模型的推理鲁棒性：（1）在数据层面，本文提出一种基于反思（reflection）与探索（exploration）的思维链形式，并设计多 Agent 协同的思维链数据生成框架，以显式构建包含“推理—反思/探索—修正—再推理”过程的高质量轨迹，在此过程中引入面向分子任务的检索增强机制（Molecular Retrieval-Augmented Generation,

Mol-RAG），通过外部化学知识补充关键结构、性质和机理信息，降低模型在推理过程中的幻觉风险；（2）在训练层面，设计分层奖励驱动的强化学习方法，对模型进行进一步优化，使其不仅能够生成正确答案，还能够学会何时继续推理以及何时进行反思，从而系统提升推理的一致性、稳定性和化学合理性。

与前一章侧重于“让模型学会端到端推理”不同，本章更加关注“让模型在复杂分子场景下进行更鲁棒的推理”。本章提出的方法为分子性质预测从“推理”进一步迈向“鲁棒推理”提供了技术支撑。

4.2 基于反思与探索的思维链形式建模

为增强分子性质预测中推理过程的鲁棒性，本文不再将思维链视为一次性生成的静态文本，而是将其建模为一个动态展开的序列决策过程。在这一框架下，思维链由多个连续的推理片段构成，每个片段不仅包含具体的分析内容，还隐式对应当前推理过程所采取的行为类型。通过显式区分不同类型的推理行为，模型能够在推理过程中进行自检、修正与路径切换，从而提升面对复杂场景时的稳定性。

结合分子性质预测任务的特点，本文将推理行为划分为以下三类：

（1）连续推理（Continue）：在当前已有分析基础上继续展开性质判断或化学机理推导，旨在兼容原有的思维链顺序推理过程；

（2）反思修正（Reflect）：对已有推理过程进行回顾与检查，识别其中可能存在的逻辑跳跃、概念误用、结构误判或结论过于武断等问题，并在必要时对推理方向进行修正；

（3）探索路径（Explore）：当当前推理路径存在较大不确定性或信息不足时，从新的结构视角或化学因素重新分析问题，例如由局部官能团分析切换至整体拓扑、构象约束、电子效应或类比分子视角。

在该推理范式下，思维链被允许包含试探性假设、中间错误甚至路径切换，只要模型能够通过反思或探索逐步纠正偏差，并最终给出合理结论。这种包含“尝试—验证—修正”过程的思维链，更符合真实分子分析中研究者的认知方式，也为后续建模推理鲁棒性提供了结构基础。

为形式化上述过程，本文将分子性质预测中的推理建模为一个序列决策问题。给定输入上下文 x（包括分子表示、任务描述及可选的检索知识），策略 π_θ 从初始状态 $z_0 = x$ 出发，逐步生成推理步骤 y_l，并通过字符串拼接更新状态：

$$z_{l+1} = z_l \oplus y_l, \tag{4.1}$$

其中 $\oplus$ 表示将新生成的推理片段附加到当前上下文中。该过程持续进行，直至策

略输出结束标记（EOS）或最终答案。为使行为类型显式可见，本文在每个关键推理片段前引入元动作标记，如 ⟨continue⟩、⟨reflect⟩ 和 ⟨explore⟩，使模型能够显式学习不同推理行为的触发条件及作用方式。

由此，本文将传统的“单路径 CoT”扩展为一种可反思、可探索的动态推理形式，为后续数据生成与强化学习优化提供统一表示基础。

4.3 多 Agent 协同的思维链数据生成框架

尽管高性能大语言模型能够生成表面连贯的思维链文本，但若直接依赖单一模型一次性生成训练数据，往往难以稳定获得符合本章目标的高质量轨迹。其根本原因在于：本文所关注的不再只是“最终答案是否正确”，而是“推理过程是否体现出反思、探索与修正等鲁棒行为”。这类行为具有明显的过程性、层次性与结构性，仅依赖单一模型的单轮输出，通常难以同时兼顾多样性、正确性和教学价值。

基于此，本文提出一种多 Agent 协同的思维链数据生成框架，通过将“生成—评估—修正—筛选”功能解耦到不同智能体中，将推理质量控制显式嵌入数据构建流程。与传统仅保留正确答案样本的数据生成方式不同，本文更加关注推理过程本身的结构质量，特别是模型如何从错误中恢复、如何在不确定情形下切换分析路径，以及如何借助外部知识纠正潜在幻觉。

4.3.1 总体框架

本文提出的多 Agent 协同数据生成框架由四类功能互补的模块组成：**生成 Agent**、**评估 Agent**、**筛选 Agent** 和**知识检索器**。各模块围绕“构造高质量鲁棒推理轨迹”这一目标协同工作，其功能如下。

（1）生成 Agent：给定分子输入（包括 SMILES 字符串、分子图及任务描述），生成 Agent 负责产出多条候选推理轨迹。与传统 CoT 数据构造不同，本文在生成阶段鼓励推理路径的多样性，允许模型从不同化学视角展开分析，并有意保留部分初始错误、不完整分析或不确定判断，以便后续显式触发反思与探索行为。

（2）评估 Agent：评估 Agent 对生成 Agent 输出的候选轨迹进行细粒度分析，重点考察推理逻辑的合理性、化学概念使用的准确性以及最终预测结果的正确性。其核心任务包括：识别推理中的首个关键错误步骤、判断该错误属于结构误读、化学知识缺失还是逻辑跳跃，并决定后续应优先触发“反思修正”还是“探索替代路径”。

（3）筛选 Agent：筛选 Agent 综合评估结果与候选轨迹质量，对多条轨迹进行筛选与重组。本文优先保留那些虽然包含中间偏差，但能够通过显式反思或探索最终修正错误、得到合理结论的轨迹，因为此类“从错误中恢复”的样本对于训练模型学习鲁棒推理策略具有更高价值。

（4）知识检索器：知识检索器根据当前分子特征、任务类型以及推理过程中暴露出的不确定点，从外部知识库中检索与当前问题相关的领域知识，为生成 Agent 和评估 Agent 提供补充信息支持。该模块的引入有助于减少模型依赖参数记忆进行“猜测式推理”的倾向，从而降低化学幻觉风险。

通过上述多模块协同，本框架将数据生成范式由传统的“结果导向”转变为“过程质量导向”，从而构建出兼具多样性、解释性和纠错价值的高质量思维链数据集。

4.3.2 数据生成流程

在上述多 Agent 框架与 Mol-RAG 支撑下，本文将鲁棒 CoT 数据生成过程划分为三个阶段。

（1）初始轨迹采样。对于输入问题 $\boldsymbol{x} \in \boldsymbol{D}$，首先由知识检索器获得相关知识 $\mathcal{K}(\boldsymbol{x})$，并构造增强上下文 $\boldsymbol{x}' = [\boldsymbol{x}; \mathcal{K}(\boldsymbol{x})]$。随后，从生成策略 π_g 中采样 K 条初始推理轨迹：

$$\tilde{\boldsymbol{y}} \sim \pi_g(\cdot \mid \boldsymbol{x}'). \tag{4.2}$$

对于每条轨迹，根据其最终答案是否与真实标签 $\boldsymbol{y}^*$ 一致，将样本划分为“正确轨迹”和“错误轨迹”两个子集。

（2）评论与精炼（Critique and Refinement）。对于错误轨迹，评估 Agent（评论者）π_c 在真实答案与检索知识的辅助下，识别首个关键错误步骤 $\tilde{\boldsymbol{y}}_l$，并生成一段反馈总结 $\tilde{\boldsymbol{y}}_{l+1}$，指出错误原因、解释潜在知识缺口，并给出继续反思或探索的新方向：

$$\tilde{\boldsymbol{y}}_{l+1} \sim \pi_c(\cdot \mid \boldsymbol{x}', \tilde{\boldsymbol{y}}_1, \ldots, \tilde{\boldsymbol{y}}_l; \boldsymbol{y}^*). \tag{4.3}$$

随后，生成 Agent 在该反馈条件下继续生成修正后的后续推理步骤：

$$[\tilde{\boldsymbol{y}}_{l+2}, \ldots, \tilde{\boldsymbol{y}}_L] \sim \pi_g(\cdot \mid \boldsymbol{x}', \tilde{\boldsymbol{y}}_1, \ldots, \tilde{\boldsymbol{y}}_l, \tilde{\boldsymbol{y}}_{l+1}). \tag{4.4}$$

对于原本正确的轨迹，评论者则随机选取一个中间步骤，生成一段正向验证性反馈，总结当前分析为何成立，并鼓励模型显式呈现验证过程。这一设计有助于避免训练数据只强调“纠错”，而忽略了“确认有效推理”的能力。

上述精炼过程最多迭代 m 次，直至得到最终正确答案或达到最大迭代次数。所有中间反馈、修正步骤及原始轨迹共同组成一条完整演示轨迹。为突出行为类型，每个关键步骤前均插入元动作标记，以显式标识其属于 `continue`、`reflect` 还是 `explore`。

（3）轨迹筛选。对于同一输入问题，框架可能生成多条候选演示轨迹。为进一步保证最终数据质量，本文引入奖励模型 π_r 对每条轨迹进行打分：

$$r = \pi_r(\tilde{\boldsymbol{y}}, \boldsymbol{x}'), \tag{4.5}$$

并选取得分最高的前 k 条轨迹（$k < K$）纳入最终合成数据集 $\mathcal{D}_{\text{syn}}$。该策略使数据集既包含简洁高效的直接求解型路径，也包含经由多轮反思与探索最终得到正确结论的复杂路径，从而更全面地支持模型对鲁棒推理过程的学习。

整体流程如1所示。

算法 1 基于多 Agent 协同与 Mol-RAG 的鲁棒 CoT 数据生成流程

输入： 训练集 $\mathcal{D} = \{(\boldsymbol{x}^{(i)}, \boldsymbol{y}^{*(i)})\}_{i=1}^{N}$；生成 Agent π_g；评估 Agent π_c；奖励模型 π_r；知识检索器 $\mathcal{R}$；初始采样数 K；最大精炼轮数 m；保留轨迹数 k

输出： 合成鲁棒 CoT 数据集 $\mathcal{D}_{\text{syn}}$

初始化： $\mathcal{D}_{\text{syn}} \leftarrow \varnothing$
for $i = 1, 2, \ldots, N$ **do**
  取样本 $(\boldsymbol{x}^{(i)}, \boldsymbol{y}^{*(i)})$；
  检索相关知识 $\mathcal{K}^{(i)} \leftarrow \mathcal{R}(\boldsymbol{x}^{(i)})$；
  构造增强上下文 $\boldsymbol{x}'^{(i)} \leftarrow [\boldsymbol{x}^{(i)}; \mathcal{K}^{(i)}]$；

  从生成 Agent π_g 采样 K 条候选推理轨迹，得到轨迹集合 $\mathcal{T}^{(i)}$；
  初始化精炼后轨迹集合 $\hat{\mathcal{T}}^{(i)} \leftarrow \varnothing$；

  for *每条轨迹* $\tilde{\boldsymbol{y}} \in \mathcal{T}^{(i)}$ **do**
    令当前轨迹 $\hat{\boldsymbol{y}} \leftarrow \tilde{\boldsymbol{y}}$，$t \leftarrow 0$；

    while $t < m$ ***且*** *当前轨迹最终答案错误* **do**
      由评估 Agent 生成评论与修正建议；
      由生成 Agent 继续生成修正后的后续推理；
      插入元动作标记并更新当前轨迹 $\hat{\boldsymbol{y}}$；
      $t \leftarrow t + 1$；
    end
    更新：

$$\hat{\mathcal{T}}^{(i)} \leftarrow \hat{\mathcal{T}}^{(i)} \cup \{\hat{\boldsymbol{y}}\}$$

  end
  for *每条轨迹* $\hat{\boldsymbol{y}} \in \hat{\mathcal{T}}^{(i)}$ **do**
    计算质量分数 $r(\hat{\boldsymbol{y}}) \leftarrow \pi_r(\hat{\boldsymbol{y}}, \boldsymbol{x}'^{(i)})$；
  end
  选取得分最高的前 k 条轨迹并加入 $\mathcal{D}_{\text{syn}}$；
end
return $\mathcal{D}_{\text{syn}}$

4.4 分层奖励驱动的鲁棒推理强化学习方法

经过监督微调以及鲁棒 CoT 数据构建后，模型已经能够生成包含反思与探索行为的结构化推理过程，并在一定程度上具备了自我修正能力。然而，此时模型的推理行为仍主要来源于对训练数据分布的模仿，其“何时继续”“何时反思”“何

时切换路径”的决策，更多依赖统计共现，而非对当前推理状态的显式优化。

为了进一步提升模型在复杂分子性质预测任务中的高级推理能力，本文在监督训练的基础上引入强化学习，通过显式奖励信号对模型进行进一步精炼。与单一答案级奖励不同，本文关注的不仅是最终预测是否正确，还包括推理过程本身是否一致、是否符合化学规律、是否有效利用了反思与探索机制。因此，本文提出一种分层奖励驱动的强化学习方法（RLPGR, Reinforcement Learning with Progressive Granular Rewards），从基础任务达成、一般推理质量和领域特定化学合理性三个层面共同约束模型行为。

4.4.1 推理轨迹与强化学习目标

在强化学习框架下，模型生成的一条完整思维链被视为一条推理轨迹。设输入状态为分子描述 z，其中包含分子表示、任务指令及可选检索知识；模型生成的推理轨迹为 y，对应最终预测结果为 $\hat{a}$，真实标签为 a。则强化学习的优化目标是最大化策略在数据分布上的期望奖励：

$$\mathcal{J}_{\mathrm{RL}}(\theta) = \mathbb{E}_{z\sim\mathcal{D},\, y\sim\pi_\theta(\cdot|z)}\left[R_{\mathrm{total}}(z, y, a)\right]. \tag{4.6}$$

实际训练中，本文采用基于策略梯度的优化方式更新模型参数。为兼顾训练稳定性与策略探索能力，可进一步加入与参考策略 π_{ref} 的 KL 正则项，以限制策略偏移过大：

$$\mathcal{L}_{\mathrm{RL}} = -\mathbb{E}_{z\sim\mathcal{D},\, y\sim\pi_\theta(\cdot|z)}\left[R_{\mathrm{total}}(z, y, a)\right] + \beta_{\mathrm{KL}}\,\mathrm{KL}\big(\pi_\theta(\cdot|z)\,\|\,\pi_{\mathrm{ref}}(\cdot|z)\big), \tag{4.7}$$

其中 β_{KL} 为正则化系数。参考策略通常取监督微调后的模型，以避免强化学习阶段出现语言质量退化或过度偏离已有能力。

4.4.2 分层奖励函数设计

为更细粒度地评估模型的推理质量，本文将复杂的分子推理过程分解为三个层次上的可测量奖励组件。给定分子输入 x、推理轨迹 z 和预测结果 y，总奖励定义为：

$$R_{\mathrm{total}}(x, z, y) = \lambda_1 \underbrace{(r_{\mathrm{ans}} + r_{\mathrm{fmt}})}_{R_{\mathrm{foundation}}} + \lambda_2 \underbrace{(r_{\mathrm{cons}} + r_{\mathrm{comp}})}_{R_{\mathrm{reasoning}}} + \lambda_3 \underbrace{(r_{\mathrm{prin}} + r_{\mathrm{struct}})}_{R_{\mathrm{chemistry}}} + r_{\mathrm{bonus}}, \tag{4.8}$$

其中 $\lambda_1, \lambda_2, \lambda_3$ 为控制各层奖励相对重要性的超参数，r_{bonus} 为与反思重启相关的额外奖励项。

（1）基础层（Foundation Layer）该层奖励用于保证模型满足最基本的任务要求：

- **答案奖励** r_{ans}：根据最终预测是否正确给予二元反馈；
- **格式奖励** r_{fmt}：检查模型输出是否满足预定义格式，例如推理内容是否位于 `<think>` 标签中、最终答案是否位于 `<answer>` 标签中。

（2）推理层（Reasoning Layer）该层用于评价一般层面的推理质量，而不仅仅是答案正确与否：

- **逻辑一致性奖励** r_{cons}：衡量推理链内部结论与最终预测之间是否保持一致。本文通过检测推理中是否存在明确结论句、以及该结论与最终预测在语义极性上是否一致来进行判定；
- **对比分析奖励** r_{comp}：鼓励模型在推理中引用已知示例、相似分子或对照结构进行类比，以增强分析的可解释性与可迁移性。若推理中显式引用了少样本示例或检索到的相似结构信息，则给予奖励。

（3）化学层（Chemistry Layer）该层面向分子性质预测的领域特性，重点评估推理是否符合化学知识和结构事实。本文利用 RDKit 等化学工具对分子进行程序化分析，以提供更客观的奖励信号：

- **化学原理应用奖励** r_{prin}：评估模型在推理中提及的化学概念是否与可计算得到的分子性质一致。例如，当推理提及疏水性、极性或氢键作用时，可与 LogP、TPSA、氢键供受体数等指标交叉验证；
- **结构分析奖励** r_{struct}：衡量推理中识别出的结构特征与真实分子结构特征之间的覆盖程度：

$$r_{\text{struct}} = \frac{|S_{\text{actual}} \cap S_{\text{pred}}|}{|S_{\text{actual}}| + \epsilon}, \tag{4.9}$$

其中 S_{actual} 表示由 RDKit 自动识别出的结构特征集合，S_{pred} 表示推理中提及的结构特征集合，$\epsilon = 10^{-5}$ 用于数值稳定。

通过上述设计，分层奖励函数能够同时约束模型的答案正确性、推理连贯性和化学合理性，使强化学习不再局限于优化“答对”，而是优化“答对且推得合理”。

4.4.3 重启与探索：面向鲁棒推理的状态扩展策略

仅从原始问题出发进行 rollout，容易使模型反复探索相似的推理路径，尤其在长链推理任务中效率较低。事实上，许多推理错误并非源于整体思路完全错误，而是由于某一中间步骤中的局部误判所致。因此，与其从头重新生成整条轨迹，不如允许模型从部分轨迹中间状态重新启动，并在此基础上进行修正与扩展。

受 Go-Explore 思想启发，本文采用“重启与探索”（Restart and Explore, RAE）

策略。具体而言，对于每个输入样本，首先由当前策略生成多条正确与错误的推理轨迹；随后，从这些轨迹的中间步骤中随机回溯，构造若干新的初始状态，并在状态末尾附加 ⟨reflect⟩ 标记，提示模型从当前局部上下文出发进行修正性推理。设从正确轨迹与错误轨迹中采样得到的中间状态分别记为 z^{+}_{L-t} 和 z^{-}_{L-t}，则扩展后的状态集合记为：

$$\mathcal{D}_{\text{restart}} = \{x^{(i)}\}_{i=1}^{n} \cup \mathcal{D}^{+}_{\text{restart}} \cup \mathcal{D}^{-}_{\text{restart}}. \tag{4.10}$$

RAE 使模型不仅从原始问题陈述出发学习推理，还能够从历史正确路径和错误路径的中间状态出发学习“如何继续正确推理”以及“如何纠正已有偏差”。这种状态扩展策略有效增加了训练中的状态覆盖范围，提升了模型在局部错误修复和复杂推理分叉场景下的鲁棒性。

如算法 2 所示，RAE 的核心思想是：不再仅从原始问题陈述出发生成完整推理轨迹，而是进一步从已有正确轨迹与错误轨迹的中间状态出发，构造新的“可反思初始状态”。具体而言，给定输入样本，模型首先生成多条候选推理轨迹，并根据最终答案是否正确将其划分为正轨迹集合与负轨迹集合。随后，分别从正确轨迹和错误轨迹中随机选取样本，并从轨迹末尾随机回溯若干步，截取对应的中间状态作为新的起点。在该中间状态后附加 ⟨reflect⟩ 标记，以提示模型在后续 rollout 中执行修正性推理。

通过同时保留来自正确路径与错误路径的中间状态，RAE 能够使模型学习两类互补能力：一是从正确的部分轨迹继续保持稳定推理，避免无必要的路径偏移；二是从错误的中间状态出发进行纠错和重构，从而提升模型的自我修正能力。最终，原始问题状态与上述两类重启状态共同构成增强初始状态集合 $\mathcal{D}_{\text{restart}}$，并用于后续强化学习训练。

算法 2 重启与探索（Restart and Explore, RAE）

输入：数据集 $\mathcal{D} = \{(\boldsymbol{x}^{(i)}, \boldsymbol{y}^{*(i)})\}_{i=1}^{n}$；当前策略 π_θ；每个样本采样轨迹数 K；最大回溯步数 T

输出：增强初始状态集合 $\mathcal{D}_{\text{restart}}$

初始化： $\mathcal{D}^{+}_{\text{restart}} \leftarrow \varnothing, \quad \mathcal{D}^{-}_{\text{restart}} \leftarrow \varnothing$

for $i = 1, 2, \ldots, n$ **do**

给定输入 $\boldsymbol{x}^{(i)}$，从策略 π_θ 采样 K 条推理轨迹：

$$\{\tilde{\boldsymbol{y}}^{(i,1)}, \ldots, \tilde{\boldsymbol{y}}^{(i,K)}\} \sim \pi_\theta(\cdot \mid \boldsymbol{x}^{(i)})$$

将最终答案正确的轨迹划入正轨迹集合 $\mathcal{T}^{+}$，错误的轨迹划入负轨迹集合 $\mathcal{T}^{-}$；

if $\mathcal{T}^{+} \neq \varnothing$ **then**

从 $\mathcal{T}^{+}$ 中随机选取一条正确轨迹 $\tilde{\boldsymbol{y}}^{+}$；

end

if $\mathcal{T}^{-} \neq \varnothing$ **then**

从 $\mathcal{T}^{-}$ 中随机选取一条错误轨迹 $\tilde{\boldsymbol{y}}^{-}$；

end

if *存在* $\tilde{\boldsymbol{y}}^{+}$ **then**

随机采样回溯步数 $t^{+} \sim \text{Uniform}\{1, \ldots, \min(T, L^{+} - 1)\}$；

构造正确轨迹的中间状态：

$$z^{+}_{L^{+}-t^{+}} = [\boldsymbol{x}^{(i)}, \tilde{\boldsymbol{y}}^{+}_{1}, \ldots, \tilde{\boldsymbol{y}}^{+}_{L^{+}-t^{+}}, \langle \texttt{reflect} \rangle]$$

更新：

$$\mathcal{D}^{+}_{\text{restart}} \leftarrow \mathcal{D}^{+}_{\text{restart}} \cup \{z^{+}_{L^{+}-t^{+}}\}$$

end

if *存在* $\tilde{\boldsymbol{y}}^{-}$ **then**

随机采样回溯步数 $t^{-} \sim \text{Uniform}\{1, \ldots, \min(T, L^{-} - 1)\}$；

构造错误轨迹的中间状态：

$$z^{-}_{L^{-}-t^{-}} = [\boldsymbol{x}^{(i)}, \tilde{\boldsymbol{y}}^{-}_{1}, \ldots, \tilde{\boldsymbol{y}}^{-}_{L^{-}-t^{-}}, \langle \texttt{reflect} \rangle]$$

更新：

$$\mathcal{D}^{-}_{\text{restart}} \leftarrow \mathcal{D}^{-}_{\text{restart}} \cup \{z^{-}_{L^{-}-t^{-}}\}$$

end

end

构造最终增强初始状态集合：

$$\mathcal{D}_{\text{restart}} = \{\boldsymbol{x}^{(i)}\}_{i=1}^{n} \cup \mathcal{D}^{+}_{\text{restart}} \cup \mathcal{D}^{-}_{\text{restart}}$$

return $\mathcal{D}_{\text{restart}}$

4.4.4 反思奖励设计

为了进一步强化模型的自我修正能力，本文在分层奖励之外引入额外的反思奖励 r_{bonus}。该奖励直接针对模型在重启状态上的表现进行调节：

$$r_{\text{bonus}}(z, \tilde{\mathbf{y}}) = \begin{cases} \beta, & \text{if } z \in \mathcal{D}^{-}_{\text{restart}} \text{ and } \tilde{\mathbf{y}}_L = \mathbf{y}^*, \\ -\beta, & \text{if } z \in \mathcal{D}^{+}_{\text{restart}} \text{ and } \tilde{\mathbf{y}}_L \neq \mathbf{y}^*, \\ 0, & \text{otherwise}, \end{cases} \tag{4.11}$$

其中 β 为奖励缩放超参数。

该设计具有明确的行为导向：若模型能够从错误轨迹的中间状态出发成功纠正错误并得到正确答案，则说明其具备有效的反思修正能力，应给予额外奖励；反之，若模型从原本正确的轨迹中间状态出发反而偏离了正确结论，则说明其进行了不必要甚至有害的修改，应给予惩罚。由此，模型被显式引导学习“何时应改、何时不应改”的反思策略。

4.5 实验对比与分析

表 4.1　超参数设置

超参数	值
# 监督微调（SFT）	
GPU 数量（A100）	8
每设备训练批次大小	2
梯度累积步数	4
学习率	1.0e-5
训练轮数	3
学习率调度器类型	线性
预热比例	0.03
# 强化学习（RL）	
GPU 数量（A100）	8
学习率	1.0e-6
权重衰减	1.0e-2
KL 系数	1.0e-2
rollout 轮数	5
rollout 温度	1.0
全局批次大小	128
rollout 批次大小	512
每设备更新微批次大小	8
# 推理	
温度	1.0
Top K	5
最大 token 数	8,192

第 5 章　总结与展望

5.1　全文工作总结

5.2　未来工作展望

参考文献

[1] Jiang W. Applications of deep learning in stock market prediction: recent progress[J]. Expert Systems with Applications, 2021: 115537.

[2] Zou J, Zhao Q, Jiao Y, et al. Stock Market Prediction via Deep Learning Techniques: A Survey[J]. arXiv preprint arXiv:2212.12717,2022.

[3] Xiang S, Cheng D, Shang C, et al. Temporal and Heterogeneous Graph Neural Network for Financial Time Series Prediction[J]. Proceedings of the 31st ACM International Conference on Information & Knowledge Management, 2022: 3584-3593.

[4] Xu Y, Cohen S B. Stock Movement Prediction from Tweets and Historical Prices[C]//In Proceedings of the 56th Annual Meeting of the Association for Computational Linguistics. 2018: 1970-1979.

[5] Feng F, He X, Wang X, et al. Temporal relational ranking for stock prediction[J]. ACM Transactions on Information Systems (TOIS), 2019, 37(2): 1-30.

[6] Koa K J L, Ma Y, Ng R, et al. Diffusion Variational Autoencoder for Tackling Stochasticity in Multi-Step Regression Stock Price Prediction[C]//Proceedings of the 32nd ACM International Conference on Information and Knowledge Management. 2023: 1087-1096.

[7] Li W, Bao R, Harimoto K, et al. Modeling the Stock Relation with Graph Network for Overnight Stock Movement Prediction[C]//Proceedings of the Twenty-Ninth International Joint Conference on Artificial Intelligence, 2020: 4541-4547.

[8] Song G, Zhao T, Wang S, et al. Stock ranking prediction using a graph aggregation network based on stock price and stock relationship information[J]. Information Sciences, 2023.

[9] Yu X, Chen Z, Ling Y, et al. Temporal Data Meets LLM – Explainable Financial Time Series Forecasting[J]. arXiv preprint arXiv:2306.11025,2023.

[10] Carta S M, Consoli s, Piras L, et al. Explainable Machine Learning Exploiting News and Domain-Specific Lexicon for Stock Market Forecasting[J]. IEEE Access, 2021: 30193-30205.

[11] Li S, Liao W, Chen Y, et al. PEN: Prediction-Explanation Network to Forecast Stock Price Movement with Better Explainability[J]. Proceedings of the AAAI Conference on Artificial Intelligence, 2023: 5187-5194.

[12] Deng S, Zhang N, Zhang W, et al. Knowledge-Driven Stock Trend Prediction and Explanation via Temporal Convolutional Network[C]//Companion Proceedings of The 2019 World Wide Web Conference(WWW). 2019: 678-685.

[13] Sawhney R, Agarwal S, Wadhwa A, et al. Deep Attentive Learning for Stock Movement Prediction From Social Media Text and Company Correlations[C]//Proceedings of the 2020 Conference on Empirical Methods in Natural Language Processing (EMNLP). 2020: 8415–8426.

[14] Biran O, Mckeown K. Human-Centric Justification of Machine Learning Predictions[C]//Proceedings of the Twenty-Sixth International Joint Conference on Artificial Intelligence. 2017: 1461-1467.

[15] Pu X, Gao M, Wan X. Summarization is (Almost) Dead[J]. arXiv preprint arXiv:2309.09558,2023.

[16] Yang J, Jin H, Tang R, et al. Harnessing the Power of LLMs in Practice: A Survey on ChatGPT and Beyond[J]. arXiv preprint arXiv:2304.13712,2023.

[17] Zhao X, Zhou K, Li J, et al. A survey of large language models[J]. arXiv preprint arXiv:2303.18223,2023.

[18] Chen Z, Zheng N, Lu C, et al. ChatGPT Informed Graph Neural Network for Stock Movement Prediction[J]. arXiv preprint arXiv:2306.03763,2023.

[19] Wang S,Ji T,Wang L, et al. StockTime: A Time Series Specialized Large Language Model Architecture for Stock Price Prediction[J]. arXiv preprint arXiv:2409.08281, 2024.

[20] Liang P, Bommasani R, Lee T, et al. Holistic Evaluation of Language Models[J]. arXiv preprint arXiv:2211.09110, 2022.

[21] Liu H, Sferrazza C, Abbeel P. Chain of Hindsight Aligns Language Models with Feedback[J]. arXiv preprint arXiv:2302.02676, 2023.

[22] Wei J, Wang X, Schuurmans D, et al. Chain of Thought Prompting Elicits Reasoning in Large Language Models[C]//Advances in Neural Information Processing Systems 35. 2022:24824-24837.

[23] Hu Z, Liu W, Bian J, et al. Listening to Chaotic Whispers: A Deep Learning Framework for News-oriented Stock Trend Prediction[C]//In Proceedings of the Eleventh ACM International Conference on Web Search and Data Mining (WSDM). 2018: 261-269.

[24] Sprenger T O, Welpe I M. News or Noise? The Stock Market Reaction to Different Types of Company-Specific News Events[J]. SSRN Electronic Journal, 2011.

[25] Fama E F, French K R. A five-factor asset pricing model[J]. Journal of Financial Economics, 2015: 1-22.

[26] Kelly B T, Xiu D. Factor Models, Machine Learning, and Asset Pricing[J]. SSRN Electronic Journal, 2022: 337-368.

[27] Xie Q, Han W, Lai Y, et al. The Wall Street Neophyte: A Zero-Shot Analysis of ChatGPT Over MultiModal Stock Movement Prediction Challenges[J]. arXiv preprint arXiv:2304.05351, 2023.

[28] Xie Q, Han W, Zhang X, et al. PIXIU: A Large Language Model, Instruction Data and Evaluation Benchmark for Finance[C]//Advances in Neural Information Processing Systems 36. 2023: 33469-33484.

[29] Wu S, İrsoy O, Lu S, et al. BloombergGPT: A Large Language Model for Finance[J]. arXiv preprint arXiv:2303.17564, 2023.

[30] Huang J, Xiao M, Li D, et al. Open-finllms: Open multimodal large language models for financial applications[J]. arXiv preprint arXiv:2408.11878, 2024

[31] Xie Q, Han W, Chen Z, et al. The FinBen: An Holistic Financial Benchmark for Large Language Models[C]//Advances in Neural Information Processing Systems 37. 2024: 95716-95743.

[32] Tong H, Li J, Wu N, et al. Ploutos: Towards interpretable stock movement prediction with financial large language model[J]. arXiv preprint arXiv:2403.00782, 2024.

[33] Koa L, Ma Y, Ng R, et al. Learning to Generate Explainable Stock Predictions using Self-Reflective Large Language Models[C]//In Proceedings of the ACM Web Conference. 2024:4304-4315.

[34] Feng F, Li M, Luo C, et al. Hybrid Learning to Rank for Financial Event Ranking[C]//Proceedings of the 44th International ACM SIGIR Conference on Research and Development in Information Retrieval, 2021: 233-243.

[35] Wang M, Kiyoshi I, Hiroki S. LLMFactor: Extracting profitable factors through prompts for explainable stock movement prediction[J]. arXiv preprint arXiv:2406.10811, 2024.

[36] Liang Y, Liu Y, Zhang, et al. FinGPT: Enhancing Sentiment-Based Stock Movement Prediction with Dissemination-Aware and Context-Enriched LLMs[J]. arXiv preprint arXiv:2412.10823, 2024.

[37] Li X, Li Z, Shi C, et al. Alphafin: Benchmarking financial analysis with retrieval-augmented stock-chain framework[J]. arXiv preprint arXiv:2403.12582, 2024

[38] Li X, Li J. Angle-optimized text embeddings[J]. arXiv preprint arXiv:2309.12871, 2023.

[39] Su H, Shi W, Kasai J, et al. One embedder, any task: Instruction-finetuned text embeddings[J]. arXiv preprint arXiv:2212.09741, 2023.

[40] Wang L, Yang N, Huang X, et al. Improving Text Embeddings with Large Language Models[J]. arXiv preprint arXiv:2401.00368, 2023.

[41] Xiao S, Liu Z, Zhang P, et al. C-pack: Packed resources for general chinese embeddings[C]//In Proceedings of the 47th international ACM SIGIR conference on research and development in information retrieval. 2024: 641-649.

[42] Box G.E.P., Jenkins G.M. Time Series Analysis: Forecasting and Control [M]. Holden-Day, 1970.

[43] Ariyo A, Adewumi O, Ayo K. Stock Price Prediction Using the ARIMA Model[C]//2014 UKSim-AMSS 16th International Conference on Computer Modelling and Simulation, Cambridge, United Kingdom. 2014: 106-112.

[44] Bollerslev, T. Generalized autoregressive conditional heteroskedasticity. Journal of econometrics[J], 1986, 31(3): 307-327.

[45] Dash R K, Nguyen T N, Cengiz K, et al. Fine-tuned support vector regression model for stock predictions[J]. Neural Computing and Applications, 2023, 35(32): 23295-23309.

[46] Vijh M, Chandola D, Tikkiwal V A, et al. Stock closing price prediction using machine learning techniques[J]. Procedia computer science, 2020, 167: 599-606.

[47] Kim K J. Financial time series forecasting using support vector machines[J]. Neurocomputing, 2003, 55(1/2): 307-319.

[48] Huang W, Nakamori Y and Wang S Y. Forecasting stock market movement direction with support vector machine[J]. Computers & operations research, 2005, 32(10): 2513- 2522.

[49] Tan Z, Yan Z, Zhu G. Stock selection with random forest: An exploitation of excess return in the Chinese stock market[J]. Heliyon, 2019, 5(8): e02310.

[50] Xu C, Liu Z,Li Z. FinArena: A Human-Agent Collaboration Framework for Financial Market Analysis and Forecasting[J]. arXiv preprint arXiv:2503.02692, 2025.

[51] 黄卿, 谢合亮. 机器学习方法在股指期货预测中的应用研究——基于 BP 神经网络、SVM 和 XGBoost 的比较分析 [J]. 数学的实践与认识, 2018, 48(8): 297-307.

[52] 王燕, 郭元凯. 改进的 XGBoost 模型在股票预测中的应用 [J]. 计算机工程与

应用, 2019, 55(20): 202-207.

[53] Lecun Y, Bottou L, Bengio Y, et al. Gradient-based learning applied to document recognition[J]. Proceedings of the IEEE, 1998, 86(11): 2278-2324.

[54] Rather A M, Agarwal A, Sastry V N. Recurrent neural network and a hybrid model for prediction of stock returns[J]. Expert Systems with Applications, 2015, 42(6): 3234-3241.

[55] Roy Choudhury A, Abrishami S, Turek M, et al. Enhancing profit from stock transactions using neural networks[J]. Ai Communications, 2020, 33(2): 75-92.

[56] Yoo S;Jeon S;Jeong S. Prediction of the Change Points in Stock Markets Using DAE-LSTM[J]. Sustainability, 2021, 13(21): 11822.

[57] Nelson D M Q, Pereira A C M, de Oliveira R A. Stock market’s price movement prediction with LSTM neural networks[C]//2017 International Joint Conference on Neural Networks (IJCNN). 2017: 1419-1426.

[58] 曹超凡, 罗泽南, 谢佳鑫, 等. MDT-CNN-LSTM 模型的股价预测研究 [J]. 计算机工程与应用, 2022, 58(5): 280-286.

[59] 孙存浩, 胡兵, 邹雨轩. 指数趋势预测的 BP-LSTM 模型 [J]. 四川大学学报 (自然科学版), 2020, 57(1): 27-31.

[60] 邓飞燕, 岑少琪, 钟凤琪, 潘家辉. 基于 LSTM 神经网络的短期价格趋势预测 [J]. 计算机系统应用, 2021, 30(4): 187-192.

[61] 杨青，王晨蔚．基于深度学习 LSTM 神经网络的全球股票指数预测研究 [J]. 统计研究，2019，(3) : 65 － 77.

[62] Gao Y, Wang R, Zhou E. Stock Prediction Based on Optimized LSTM and GRU Models[J]. Scientific Programming, 2021, 2021: 1-8.

[63] Jiang J, Kelly B T, Xiu D. (Re-)Imag(in)ing Price Trends[J]. The Journal of Finance, 2023, 78(06): 3193-3249.

[64] Selvin S, Vinayakumar R, Gopalakrishnan E A, et al. Stock price prediction using LSTM, RNN and CNN-sliding window model[C]//2017 International Conference on Advances in Computing, Communications and Informatics (ICACCI), 2017: 1643-1647.

[65] Wang H, Wang J, Cao L, et al. A Stock Closing Price Prediction Model Based on CNN-BiSLSTM[J]. Complex, 2021.

[66] Qian H, Zhou H, Zhao Q, et al. MDGNN: Multi-Relational Dynamic Graph Neural Network for Comprehensive and Dynamic Stock Investment Prediction[C]//In Proceedings of the AAAI Conference on Artificial Intelligence, 2024, 38(13): 14642-

14650.

[67] You Z, Shi Z, Boh , et al. DGDNN: Decoupled Graph Diffusion Neural Network for Stock Movement Prediction[J]. arXiv preprint arXiv:2401.01846, 2024.

[68] Cui L, Li H,Chen K. Shou, et al. Tabular data augmentation for machine learning: Progress and prospects of embracing generative ai[J]. arXiv preprint arXiv:2407.21523, 2024.

[69] Ye J, Zhao J, Ye K, et al. Multi-graph convolutional network for relationship-driven stock movement prediction[C]//2020 25th International Conference on Pattern Recognition (ICPR). 2021: 6702-6709.

[70] Ma B, Xue Y, Lu Y, et al. Stockformer: A price-volume factor stock selection model based on wavelet transform and multi-task self-attention networks[J]. Expert Systems with Applications, 126803，2024.

[71] Zhang Z, Chen B, Zhu S, et al. Quantformer: from attention to profit with a quantitative transformer trading strategy[J]. arXiv preprint arXiv:2404.00424, 2024

[72] Ding Q, Wu S, Sun H, et al. Hierarchical Multi-Scale Gaussian Transformer for Stock Movement Prediction[C]//In Proceedings of the Twenty-Ninth International Joint Conference on Artificial Intelligence (IJCAI). 2020: 4640-4646.

[73] Yoo J, Soun Y, Park Y, et al. Accurate multivariate stock movement prediction via data-Axis transformer with multi-level contexts[C]//Proceedings of the 27th ACM SIGKDD Conference on Knowledge Discovery & Data Mining. 2021: 2037-2045.

[74] Qin Y, Song D, Chen H, et al. A Dual-Stage Attention-Based Recurrent Neural Network for Time Series Prediction[C]//In Proceedings of the 26th International Joint Conference on Artificial Intelligence(IJCAI). 2017: 2627-2633.

[75] Yang L, Zhang Z, Xiong S, et al. Explainable Text-Driven Neural Network for Stock Prediction[C]//2018 5th IEEE International Conference on Cloud Computing and Intelligence Systems (CCIS). 2018: 441-445.

[76] Ding X, Zhang Y, Liu T, et al. Deep learning for event-driven stock prediction[C]//In Proceedings of the 24th International Conference on Artificial Intelligence (IJCAI). 2015: 2327-2333.

[77] Lopez-Lira A, Tang Y. Can ChatGPT Forecast Stock Price Movements? Return Predictability and Large Language Models[J]. SSRN Electronic Journal, 2023.

[78] Deng Y, He X, Hu J, et al. Enhancing few-shot stock trend prediction with large language models[J]. arXiv preprint arXiv:2407.09003, 2024.

[79] Fatemi S,Hu Y. FinVision: A Multi-Agent Framework for Stock Market Predic-

tion[C]//In Proceedings of the 5th ACM International Conference on AI in Finance. 2024: 582-590.

[80] Wang S, Yuan H, Zhou L, et al. Alpha-GPT: Human-AI Interactive Alpha Mining for Quantitative Investment[J]. arXiv preprint arXiv:2308.00016, 2023.

[81] Yang Y, Tang Y, Tam K. InvestLM: A Large Language Model for Investment using Financial Domain Instruction Tuning[J]. arXiv preprint arXiv:2309.13064, 2023.

[82] Benhenda, M. FinRL-DeepSeek: LLM-Infused Risk-Sensitive Reinforcement Learning for Trading Agents[J]. arXiv preprint arXiv:2502.07393, 2025.

[83] Araci D. FinBERT: Financial Sentiment Analysis with Pre-trained Language Models[J]. arXiv preprint arXiv:1908.10063, 2019.

[84] Yang Y, Uy M, Huang. Finbert: A pretrained language model for financial communications[J]. arXiv preprint arXiv:2006.08097, 2019.

[85] Hu E, Shen Y, Wallis P, et al. Lora: Low-rank adaptation of large language models[C]//International Conference on Learning Representations(ICLR). 2022, 1(2): 3.

[86] Soun Y, Yoo J, Cho M, et al. Accurate stock movement prediction with self-supervised learning from sparse noisy tweets[C]//2022 IEEE International Conference on Big Data (Big Data). 2022:1691-1700.

[87] Wu H, Zhang W, Shen W, et al. Hybrid Deep Sequential Modeling for Social Text-Driven Stock Prediction[C]//Proceedings of the 27th ACM International Conference on Information and Knowledge Management. 2018: 1627-1630.

[88] Yang A, Xiao B, Wang B, et al. Baichuan 2: Open large-scale language models[J]. arXiv preprint arXiv:2309.10305, 2023.

[89] Cai Z, Cao M, Chen H, et al. Internlm2 technical report[J]. arXiv preprint arXiv:2403.17297, 2024.

[90] Grattafiori A, Dubey A, Jauhri A, et al. The llama 3 herd of models[J]. arXiv preprint arXiv:2407.21783, 2024.

[91] Guo D, Yang D, Zhang H, et al. Deepseek-r1: Incentivizing reasoning capability in llms via reinforcement learning[J]. arXiv preprint arXiv:2501.12948, 2025.

[92] Yang A, Yang B, Zhang B, et al. Qwen2. 5 technical report[J]. arXiv preprint arXiv:2412.15115, 2024.

[93] Chen W, Wang Q, Long Z, et al. Disc-finllm: A chinese financial large language model based on multiple experts fine-tuning[J]. arXiv preprint arXiv:2310.15205, 2023.

[94] Qian L, Zhou W, Wang Y, et al. Fino1: On the transferability of reasoning enhanced llms to finance[J]. arXiv preprint arXiv:2502.08127, 2025.

[95] Fang X, Xu W, Tan F, et al. Large Language Models on Tabular Data – A Survey[J]. arXiv e-prints: arXiv-2402,2024.

[96] Muennighoff N, Tazi N, Magne L, et al. MTEB: Massive text embedding benchmark[J]. arXiv preprint arXiv:2210.07316, 2022.

[97] Chen J, Xiao S, Zhang P, et al. BGE M3-Embedding: Multi-Lingual, Multi-Functionality, Multi-Granularity Text Embeddings Through Self-Knowledge Distillation[J]. arXiv preprint arXiv:2402.03216, 2024.

[98] Zhang P, Xiao S, Liu Z, et al. Retrieve Anything To Augment Large Language Models[J]. arXiv preprint arXiv:2310.07554, 2023.

[99] J. Xu, Y. Li, J. Yang, S. Zhou, and W. Situ, “Plasma etching effect on the molecular structure of chitosan-based hydrogels and its biological properties,” Int. J. Biol. Macromolecules, 2023, Art. no. 123257.

[100] Y. Weng, B. Ding, Y. Liu, C. Song, L.-Y. Chan, and C.-W. Chiang, “Latestage photoredox C−H amidation of N-unprotected indole derivatives: Access to n-(indol-2-yl) amides,” Org. Lett., vol. 23, no. 7, pp. 2710−2714, 2021.

[101] B. Ding et al., “Selective photoredox trifluoromethylation of tryptophancontaining peptides,” Eur. J. Org. Chem., vol. 2019, no. 46, pp. 7596−7605, 2019.

[102] A. Higuchi et al., “Material design for next-generation mRNA vaccines using lipid nanoparticles,” Polym. Rev., vol. 63, no. 2, pp. 394−436, 2023.

[103] Jessica Vamathevan, Dominic Clark, Paul Czodrowski, Ian Dunham, Edgardo Ferran, George Lee, Bin Li, Anant Madabhushi, Parantu Shah, Michaela Spitzer, et al. Applications of machine learning in drug discovery and development. Nature reviews Drug discovery, 18(6):463−477, 2019.

[104] Michael Schlander, Karla Hernandez-Villafuerte, Chih-Yuan Cheng, Jorge Mestre-Ferrandiz, and Michael Baumann. How much does it cost to research and develop a new drug? a systematic review and assessment. Pharmacoeconomics, 39(11):1243−1269, 2021.

[105] Suresh Dara, Swetha Dhamercherla, Surender Singh Jadav, CH Madhu Babu, and Mohamed Jawed Ahsan. Machine learning in drug discovery: a review. Artificial intelligence review, 55(3):1947−1999, 2022.

[106] Anastasiia V Sadybekov and Vsevolod Katritch. Computational approaches streamlining drug discovery. Nature, 616(7958):673−685, 2023.

[107] Steven M Paul, Daniel S Mytelka, Christopher T Dunwiddie, Charles C Persinger, Bernard H Munos, Stacy R Lindborg, and Aaron L Schacht. How to improve r&d productivity: the pharmaceutical industry’s grand challenge. Nature reviews Drug discovery, 9(3):203–214, 2010.

[108] J.A. DiMasi, H.G. Grabowski, and R.W. Hansen. Innovation in the pharmaceutical industry: New estimates of r&d costs. Journal of Health Economics, 47:20–33, 2016.

[109] Oliver Wieder, Stefan Kohlbacher, Mélaine Kuenemann, Arthur Garon, Pierre Ducrot, Thomas Seidel, and Thierry Langer. A compact review of molecular property prediction with graph neural networks. Drug Discovery Today: Technologies, 37:1–12, 2020.

[110] Jie Dong, Ning-Ning Wang, Zhi-Jiang Yao, Lin Zhang, Yan Cheng, Defang Ouyang, Ai-Ping Lu, and Dong-Sheng Cao. Admetlab: a platform for systematic admet evaluation based on a comprehensively collected admet database. Journal of cheminformatics, 10(1):29, 2018.

[111] Leonardo LG Ferreira and Adriano D Andricopulo. Admet modeling approaches in drug discovery. Drug discovery today, 24(5):1157–1165, 2019.

[112] Jie Shen and Christos A Nicolaou. Molecular property prediction: recent trends in the era of artificial intelligence. Drug Discovery Today: Technologies, 32:29–36, 2019.

[113] Shang C, Liu Q, Tong Q, Sun J, Song M, Bi J (2021) Multiview spectral graph convolution with consistent edge attention for molecular modeling. Neurocomputing 445:12–25

[114] Keyulu Xu, Weihua Hu, Jure Leskovec, and Stefanie Jegelka. How powerful are graph neural networks?In ICLR, 2019.

[115] Li P, Li Y, Hsieh C-Y, Zhang S, Liu X, Liu H, Song S, Yao X(2021) Trimnet: learning molecular representation from triplet messages for biomedicine. Brief Bioinform 22(4):266

[116] Su Y, Wang Z, Jin S, Shen W, Ren J, Eden MR (2019) An architecture of deep learning in qspr modeling for the prediction of critical properties using molecular signatures. AIChE J65(9):16678

[117] Gilmer J, Schoenholz SS, Riley PF, Vinyals O, Dahl GE (2017) Neural message passing for quantum chemistry. In: International Conference on Machine Learning, pp. 1263–1272. PMLR

[118] Tian Y, Wang X, Yao X, Liu H, Yang Y (2023) Predicting molecular properties based on the interpretable graph neural network with multistep focus mechanism. Brief Bioinform 24(1):534

[119] Wang Z, Su Y, Shen W, Jin S, Clark JH, Ren J, Zhang X (2019) Predictive deep learning models for environmental properties: the direct calculation of octanol-water partition coefficients from molecular graphs. Green Chem 21(16):4555–4565

[120] Wang S, Li Z, Zhang S, Jiang M, Wang X, Wei Z (2020) Molecular property prediction based on a multichannel substructure graph. IEEE Access 8:18601–18614

[121] Rong Y, Bian Y, Xu T, Xie W, Wei Y, Huang W, Huang J (2020) Grover: Self-supervised message passing transformer on largescale molecular data. arXiv preprint arXiv: 2007. 02835 2(3), 17

[122] Sun M, Xing J, Wang H, Chen B, Zhou J (2021) Mocl: datadriven molecular fingerprint via knowledge-aware contrastive learning from molecular graph. In: Proceedings of the 27th ACM SIGKDD Conference on Knowledge Discovery & Data Mining, pp. 3585–3594

[123] Zhang Z, Liu Q, Wang H, Lu C, Lee C-K (2021) Motif-based graph self-supervised learning for molecular property prediction. Adv Neural Inf Process Syst 34:15870–15882

[124] Bing Su, Dazhao Du, Zhao Yang, Yujie Zhou, Jiangmeng Li, Anyi Rao, Hao Sun, Zhiwu Lu, and Ji-Rong Wen. A molecular multimodal foundation model associating molecule graphs with natural language.arXiv:2209.05481, 2022.

[125] Zhang J, Mucs D, Norinder U, Svensson F (2019) Lightgbm: An effective and scalable algorithm for prediction of chemical toxicity-application to the tox21 and mutagenicity data sets. J Chem Inf Model 59(10):4150–4158

[126] Zhang L, Ai H, Chen W, Yin Z, Hu H, Zhu J, Zhao J, Zhao Q, Liu H (2017) Carcinopred-el: Novel models for predicting the carcinogenicity of chemicals using molecular fingerprints and ensemble learning methods. Sci Rep 7(1):2118

[127] Fu L, Liu L, Yang ZJ, Li P, Ding JJ, Yun YH, Lu AP, Hou TJ, Cao DS (2019) Systematic modeling of log d 7.4 based on ensemble machine learning, group contribution, and matched molecular pair analysis. Journal of Chemical Information and Modeling 60(1), 63–76

[128] Sheridan RP, Wang WM, Liaw A, Ma J, Gifford EM (2016) Extreme gradient boosting as a method for quantitative structureactivity relationships. J Chem Inf Model 56(12):2353–2360

[129] Yang Q, Liu Y, Cheng J, Li Y, Liu S, Duan Y, Zhang L, Luo S (2022) An ensemble structure and physicochemical (spoc) descriptor for machine-learning prediction of chemical reaction and molecular properties. ChemPhysChem 23(14):202200255

[130] Weininger D (1988) Smiles, a chemical language and information system. 1. introduction to methodology and encoding rules. Journal of chemical information and computer sciences 28(1), 31–36

[131] Shorten C, Khoshgoftaar TM (2019) A survey on image data augmentation for deep learning. J Big Data 6(1):1–48

[132] Kimber TB, Gagnebin M, Volkamer A (2021) Maxsmi: maximizing molecular property prediction performance with confidence estimation using smiles augmentation and deep learning. Artificial Intelligence in the Life Sciences 1:100014

[133] Chen J-H, Tseng YJ (2021) Different molecular enumeration influences in deep learning: an example using aqueous solubility. Brief Bioinform 22(3):092

[134] Li C, Feng J, Liu S, Yao J (2022) A novel molecular representation learning for molecular property prediction with a multiple smiles-based augmentation. Computational Intelligence and Neuroscience 2022

[135] Segler MH, Kogej T, Tyrchan C, Waller MP (2018) Generating focused molecule libraries for drug discovery with recurrent neural networks. ACS Cent Sci 4(1):120–131

[136] Lv Q, Chen G, Zhao L, Zhong W, Yu-Chian Chen C (2021) Mol2context-vec: learning molecular representation from context awareness for drug discovery. Brief Bioinform 22(6):317

[137] Devlin J, Chang MW, Lee K, Toutanova K (2018) Bert: Pretraining of deep bidirectional transformers for language understanding. arXiv preprint arXiv: 1810. 04805

[138] Wang S, Guo Y, Wang Y, Sun H, Huang J (2019) Smiles-bert: large scale unsupervised pre-training for molecular property prediction. In: Proceedings of the 10th ACM International Conference on Bioinformatics, Computational Biology and Health Informatics, pp. 429–436

[139] Honda S, Shi S, Ueda HR (2019) Smiles transformer: Pre-trained molecular fingerprint for low data drug discovery. arXiv preprint arXiv: 1911.04738

[140] Irwin R, Dimitriadis S, He J, Bjerrum EJ (2022) Chemformer: a pre-trained transformer for computational chemistry. Machine Learning Science and Technology 3(1):015022

[141] Karpov P, Godin G, Tetko IV (2020) Transformer-cnn: Swiss knife for qsar mod-

eling and interpretation. Journal of Cheminformatics 12(1):1–12

[142] Lewis M, Liu Y, Goyal N, Ghazvininejad M, Mohamed A, Levy O, Stoyanov V, Zettlemoyer L (2019) Bart: Denoising sequence-to-sequence pre-training for natural language generation, translation, and comprehension. arXiv preprint arXiv: 1910.13461

[143] Liu Y, Ott M, Goyal N, Du J, Joshi M, Chen D, Levy O, Lewis M, Zettlemoyer L, Stoyanov V (2019) Roberta: A robustly optimized bert pretraining approach. arXiv preprint arXiv: 1907.11692

[144] Li J, Jiang X (2021) Mol-bert: An effective molecular representation with bert for molecular property prediction. Wirel Commun Mob Comput 2021:1–7

[145] Choukroun Y, Wolf L (2021) Geometric transformer for end-toend molecule properties prediction. arXiv preprint arXiv: 2110.13721

[146] Kwak B, Jo J, Lee B, Yoon S 2021) Geometry-aware transformer for molecular property prediction. arXiv preprint arXiv: 2106.15516

[147] Shang C, Liu Q, Tong Q, Sun J, Song M, Bi J (2021) Multiview spectral graph convolution with consistent edge attention for molecular modeling. Neurocomputing 445:12–25

[148] Wu L, Cui P, Pei J, Zhao L, Guo X (2022) Graph neural networks: foundation, frontiers and applications. In: Proceedings of the 28th ACM SIGKDD Conference on Knowledge Discovery and Data Mining, pp. 4840–4841

[149] Li P, Li Y, Hsieh C-Y, Zhang S, Liu X, Liu H, Song S, Yao X (2021) Trimnet: learning molecular representation from triplet messages for biomedicine. Brief Bioinform 22(4):266

[150] Gilmer J, Schoenholz SS, Riley PF, Vinyals O, Dahl GE (2017) Neural message passing for quantum chemistry. In: International Conference on Machine Learning, pp. 1263–1272. PMLR

[151] Tian Y, Wang X, Yao X, Liu H, Yang Y (2023) Predicting molecular properties based on the interpretable graph neural network with multistep focus mechanism. Brief Bioinform 24(1):534

[152] Kwak B, Jo J, Lee B, Yoon S 2021) Geometry-aware transformer for molecular property prediction. arXiv preprint arXiv: 2106.15516

[153] Wang Z, Su Y, Shen W, Jin S, Clark JH, Ren J, Zhang X (2019) Predictive deep learning models for environmental properties: the direct calculation of octanol-water partition coefficients from molecular graphs. Green Chem 21(16):4555–4565

[154] Rong Y, Bian Y, Xu T, Xie W, Wei Y, Huang W, Huang J (2020) Grover: Self-supervised message passing transformer on largescale molecular data. arXiv preprint arXiv: 2007. 02835 2(3), 17

[155] Sun M, Xing J, Wang H, Chen B, Zhou J (2021) Mocl: datadriven molecular fingerprint via knowledge-aware contrastive learning from molecular graph. In: Proceedings of the 27th ACM SIGKDD Conference on Knowledge Discovery & Data Mining, pp. 3585–3594

[156] Zhang Z, Liu Q, Wang H, Lu C, Lee C-K (2021) Motif-based graph self-supervised learning for molecular property prediction. Adv Neural Inf Process Syst 34:15870–15882

[157] Lu C, Liu Q, Wang C, Huang Z, Lin P, He L (2019) Molecular property prediction: A multilevel quantum interactions modeling perspective. Proceedings of the AAAI Conference on Artificial Intelligence 33:1052–1060

[158] Chen Y, Li Z, Wan Z, Yu H, Wei X (2023) Curvature-based transformer for molecular property prediction. arXiv preprint arXiv: 2307.13275

[159] Yoshimori A (2021) Prediction of molecular properties usingmolecular topographic map. Molecules 26(15):4475

[160] Tchagang AB, Valdés J.J (2021) Time frequency representations and deep convolutional neural networks: A recipe for molecular properties prediction. In: 2021 IEEE Canadian Conference on Electrical and Computer Engineering (CCECE), pp. 1–5. IEEE

[161] Tong Q, Shen J, Liu X (2023) Vismole: a molecular representation based on voxel for molecular property prediction. In: Fifth International Conference on Computer Information Science and Artificial Intelligence (CISAI 2022), vol. 12566, pp. 566–575. SPIE

[162] Sunseri J, Koes DR (2020) Libmolgrid: graphics processing unit accelerated molecular gridding for deep learning applications. J Chem Inf Model 60(3):1079–1084

[163] Li C, Wang J, Niu Z, Yao J, Zeng X (2021) A spatial-temporal gated attention module for molecular property prediction based on molecular geometry. Brief Bioinform 22(5):078

[164] Guo Z, Yu W, Zhang C, Jiang M, Chawla NV (2020) Graseq: graph and sequence fusion learning for molecular property prediction. In: Proceedings of the 29th ACM International Conference on Information & Knowledge Management, pp. 435–443

[165] Liu J, Lei X, Zhang Y, Pan Y (2023) The prediction of molecular toxicity based on bigru and graphsage. Computers in Biology and Medicine, 106524

[166] Hamilton W, Ying Z, Leskovec J (2017) Inductive representation learning on large graphs. Advances in neural information processing systems 30

[167] Wang X, Li Z, Jiang M, Wang S, Zhang S, Wei Z (2019) Molecule property prediction based on spatial graph embedding. J Chem Inf Model 59(9):3817−3828

[168] Cai H, Zhang H, Zhao D, Wu J, Wang L (2022) Fp-gnn: a versatile deep learning architecture for enhanced molecular property prediction. Brief Bioinform 23(6):408

[169] Wiercioch M, Kirchmair J (2023) Dnn-pp A novel deep neural network approach and its applicability in drug-related property prediction. Expert Syst Appl 213:119055

[170] Karim A, Singh J, Mishra A, Dehzangi A, Newton MH, Sattar A (2019) Toxicity prediction by multimodal deep learning. In: Knowledge Management and Acquisition for Intelligent Systems: 16th Pacific Rim Knowledge Acquisition Workshop, PKAW 2019, Cuvu, Fiji, August 26 – 27, 2019, Proceedings 16, pp. 142 – 152. Springer

[171] Karim A, Riahi V, Mishra A, Newton MH, Dehzangi A, Balle T, Sattar A (2021) Quantitative toxicity prediction via meta ensembling of multitask deep learning models. ACS Omega 6(18):12306−12317

[172] He Z, Chen L, Lv H, Zhou Rn, Xu J, Chen Y, Hu J, Gao Y (2023) A novel descriptor and molecular graph-based bimodal contrastive learning framework for drug molecular property prediction. In: International Conference on Intelligent Computing, pp. 700−715 . Springer

[173] Busk J, Jørgensen PB, Bhowmik A, Schmidt MN, Winther O, Vegge T (2021) Calibrated uncertainty for molecular property prediction using ensembles of message passing neural networks. Machine Learning Science and Technology 3(1):015012

[174] Ding W, Nan Y, Wu J, Han C, Xin X, Li S, Liu H, Zhang L (2022) Combining multi-dimensional molecular fingerprints to predict the herg cardiotoxicity of compounds. Comput Biol Med 144:105390

[175] Wu Z, Jiang D, Hsieh C-Y, Chen G, Liao B, Cao D, Hou T (2021) Hyperbolic relational graph convolution networks plus: a simple but highly efficient qsar-modeling method. Brief Bioinform 22(5):112

[176] Liu, Z.; Zhang, W.; Xia, Y.; Wu, L.; Xie, S.; Qin, T.; Zhang, M.; and Liu, T.-Y. 2023. MolXPT: Wrapping Molecules with Text for Generative Pre-training. In

Rogers, A.; BoydGraber, J.; and Okazaki, N., eds., Proceedings of the 61st Annual Meeting of the Association for Computational Linguistics (Volume 2: Short Papers), 1606–1616. Toronto, Canada: Association for Computational Linguistics.

[177] Edwards, C.; Lai, T.; Ros, K.; Honke, G.; Cho, K.; and Ji, H. 2022. Translation between Molecules and Natural Language. In Goldberg, Y.; Kozareva, Z.; and Zhang, Y., eds., Proceedings of the 2022 Conference on Empirical Methods in Natural Language Processing, 375–413. Abu Dhabi, United Arab Emirates: Association for Computational Linguistics.

[178] Liu, Y.; Ding, S.; Zhou, S.; Fan, W.; and Tan, Q. 2024. Moleculargpt: Open large language model (llm) for few-shot molecular property prediction. arXiv preprint arXiv:2406.12950.

[179] Luo, Y.; Yang, K.; Hong, M.; Liu, X. Y.; and Nie, Z. 2023. Molfm: A multimodal molecular foundation model. arXiv preprint arXiv:2307.09484.

[180] Pei, Q.; Zhang, W.; Zhu, J.; Wu, K.; Gao, K.; Wu, L.; Xia, Y.; and Yan, R. 2023. BioT5: Enriching Cross-modal Integration in Biology with Chemical Knowledge and Natural Language Associations. In Bouamor, H.; Pino, J.; and Bali, K., eds., Proceedings of the 2023 Conference on Empirical Methods in Natural Language Processing, 1102–1123. Singapore: Association for Computational Linguistics.

[181] OpenAI. 2022. Introducing ChatGPT.

[182] Guo, D.; Yang, D.; Zhang, H.; Song, J.; Zhang, R.; Xu, R.; Zhu, Q.; Ma, S.; Wang, P.; Bi, X.; et al. 2025. Deepseek-r1: Incentivizing reasoning capability in llms via reinforcement learning. arXiv preprint arXiv:2501.12948.

[183] Qian, C.; Tang, H.; Yang, Z.; Liang, H.; and Liu, Y. 2023. Can large language models empower molecular property prediction? arXiv preprint arXiv:2307.07443.

[184] Zheng, Y.; Koh, H. Y.; Ju, J.; Nguyen, A. T.; May, L. T.; Webb, G. I.; and Pan, S. 2025. Large language models for scientific discovery in molecular property prediction. Nature Machine Intelligence, 1–11.

[185] Junnan Li, Dongxu Li, Silvio Savarese, and Steven C. H.Hoi. 2023. BLIP-2: bootstrapping language-image pre-training with frozen image encoders and large language models. CoRR, abs/2301.12597.

[186] J. Schulman, F. Wolski, P. Dhariwal, A. Radford, and O. Klimov, “Proximal policy optimization algorithms,” arXiv preprint arXiv:1707.06347, 2017. 4

[187]

[188] Zhenqin Wu, Bharath Ramsundar, Evan N Feinberg, Joseph Gomes, Caleb Ge-

niesse, Aneesh S Pappu, Karl Leswing, and Vijay Pande. Moleculenet: a benchmark for molecular machine learning. Chemical science, 9(2):513–530, 2018.

[189] Kexin Huang, Tianfan Fu, Wenhao Gao, Yue Zhao, Yusuf Roohani, Jure Leskovec, Connor W Coley, Cao Xiao, Jimeng Sun, and Marinka Zitnik. Therapeutics data commons: Machine learning datasets and tasks for drug discovery and development. Proceedings of Neural Information Processing Systems, NeurIPS Datasets and Benchmarks, 2021.

[190] Kexin Huang, Tianfan Fu, Wenhao Gao, Yue Zhao, Yusuf Roohani, Jure Leskovec, Connor W Coley, Cao Xiao, Jimeng Sun, and Marinka Zitnik. Artificial intelligence foundation for therapeutic science. Nature Chemical Biology, 2022.

致谢

致谢

附录 A　个人简历

简历

附录 B　在学期间参与的科研项目

[1] 产业项目，实质性参与。

附录 C　在学期间取得的学术成果

1. 已发表论文

[1] Xie Q, Han W, **Chen Z**, et al. The FinBen: An Holistic Financial Benchmark for Large Language Models[C]//Advances in Neural Information Processing Systems 37（NeurIPS）. 2024: 95716-95743.

[2] Wang Y, Feng D, Dai Y, **Chen Z**, et al. HARMONIC: Harnessing LLMs for Tabular Data Synthesis and Privacy Protection[C]//Advances in Neural Information Processing Systems 37（NeurIPS）. 2024: 100196–100212.

[3] Xie Q, Huang J, Li D, **Chen Z**,et al. FinNLP-AgentScen-2024 Shared Task: Financial Challenges in Large Language Models - FinLLMs[C]//In Proceedings of the Eighth Financial Technology and Natural Language Processing (FinNLP) and the 1st Agent AI for Scenario Planning (AgentScen). 2024: 119–126.

附录 D　prompt

表 D.1　BACE 数据集思维链数据构建提示词

BACE 数据集思维链数据构建提示词

Role:

You are an expert medicinal chemist specializing in central nervous system (CNS) drug discovery, with extensive experience in designing and evaluating inhibitors of proteolytic enzymes—particularly BACE-1 (beta-site amyloid precursor protein cleaving enzyme 1), a validated therapeutic target for Alzheimer’s disease.

Task:

Given a SMILES string representing a small molecule, determine whether it is likely to act as a BACE-1 inhibitor. Provide a binary prediction: True if it is an inhibitor, False otherwise.

Output Formatting：

Provide your reasoning and prediction in the following exact format:

<cot>

Step 1: [Parse the SMILES and describe key structural features—e.g., presence of aromatic rings, heteroatoms, hydrogen bond donors/acceptors, functional groups like amides or amines, and overall molecular complexity.]

Step 2: [Assess whether these features align with known BACE-1 inhibitor pharmacophores. Reference common motifs (e.g., hydroxyethylene core, basic amines, heterocycles) and evaluate suitability for binding the catalytic site.]

Step 3: [Identify potential red flags that suggest inactivity—e.g., excessive simplicity, high lipophilicity without polarity, lack of H-bonding groups, or structural features incompatible with BACE-1 binding.]

Step 4: [Synthesize the above analysis into a clear, concise conclusion about inhibitory potential.]

</cot>

<answer>[True or False]</answer>

Few-Shot Examples：

smiles: s1cc(cc1)-c1cc2c(nc(N)cc2)cc1 answer: True **Molecular：**

<smiles>

表 D.2　BACE 思维链数据评估提示词模板

BACE 思维链数据评估提示词模板

[Role] You are a strict domain expert evaluating chain-of-thought reasoning for DATA CLEANING in chemical molecular property prediction tasks. Your goal is NOT to judge whether the final answer is correct, but whether the reasoning is safe, explicit, and suitable as training data.
You must output ONLY a single integer score from 0 to 10. Do not provide explanations.
[Evaluation Focus] Critically audit the reasoning as if it will be directly imitated by a model. Assume the model has NO hidden chemical intuition beyond what is explicitly stated.
Evaluate whether: - Every structure–property relationship is explicitly justified - All assumptions about molecular features (e.g., polarity, conjugation, steric effects, electron donation/withdrawal) are clearly derived from structure, not implied - The reasoning avoids using the target property itself (or proxies of it) as justification - No step relies on expert intuition, heuristics, or “typical” behavior without explanation - The reasoning can be followed and reproduced step by step without external chemical knowledge
[Critical Defects —ANY ONE forces score ≤6] - Reasoning appears to infer causes from the target property itself (label leakage) - Use of domain intuition without mechanistic explanation - Skipped or merged steps in structure → feature → property reasoning - Reliance on vague statistical associations instead of causal chemical reasoning - Statements that would require a chemistry expert’s background knowledge to justify - Conclusions that are correct but whose reasoning path is not explicitly reconstructable
[Scoring Rubric] 10: Exceptionally clean and explicit. Every molecular feature is derived from structure, every inference is mechanistic, and the reasoning is fully reproducible without hidden knowledge. Suitable for direct training. 9: Very high quality. One minor implicit assumption exists but does not affect reproducibility. 7–8: Plausible chemical reasoning, but contains multiple implicit assumptions, compressed steps, or heuristic statements. Not ideal for training without revision. 5–6: Partially valid but unsafe. Key structure–property links are asserted rather than derived. 3–4: Weak or intuition-driven reasoning. Heavy reliance on unstated chemical knowledge. 1–2: Largely invalid reasoning. Steps are disconnected, circular, or rely on outcome-based justification. 0: No meaningful or trustworthy reasoning present.
[Conversation] User: <question>
Model Response: <model_response>
[Output Format] <score>an integer score</score>