面向关系感知学习与依赖闭合修正的端到端论辩挖掘方法研究

English Title: End-to-End Argument Mining via Relation-Aware Learning and Dependency-Closed Repair

2026 年 10 月

摘要

论辩挖掘旨在识别文本中的论点、理由等论辩组件及组件之间的支持与攻击关系，是自然语言理解的重要研究方向，可服务于写作评价、舆情分析等应用。近年来，基于大语言模型的生成式方法能够直接从原始文本生成完整的论辩结构，但组件与关系之间的相互依赖仍给模型的训练和推理带来困难。具体而言，现有方法面临两方面挑战：（1）论辩标注成本高，数据增强是扩充训练样本的常用手段，但对文本做局部改写可能改变组件的论辩角色或组件之间的关系，直接沿用原标注会引入错误监督；（2）生成结果中常含有边界或类型错误的组件，而修改一个组件会使以它为端点的关系随之失效，单独修正组件或单独修正关系都难以得到一致的论辩图。

针对上述挑战，本文以多候选重排序与有界修正方法（MCR-BR）为基础，开展了以下两方面研究：（1）针对数据增强中的监督保持问题，提出关系影响域约束的增强与成对学习方法。该方法先确定每处改写可能影响的组件与关系范围，将原标注无损地迁移到改写文本上，再逐项审核哪些组件和关系仍然可靠；训练时，原文提供完整的论辩图监督，改写文本只在可靠的组件与关系上提供辅助监督，并与原文进行成对的分布对齐。实验表明，该方法使 AAEC 和 CDCP 上的严格关系 F1 分别提高 2.56 和 3.30 个百分点，人工审核显示被接受关系因素的加权不安全率估计为 0.81%和 0.91%。

（2）针对推理阶段的结构修正问题，提出依赖闭合的论辩图修正方法。该方法把组件修改与全部受影响关系的重建组织为一个事务，在预先固定的对象评分下，通过分项效用门和编辑预算决定是否接受，并提供全局整数规划与集合局部搜索两种求解方式。实验表明，在训练配置固定时，该方法使严格关系 F1 分别提高 3.38 和 5.68 个百分点；与相同预算下的重新生成相比，它在取得更高 F1 的同时保留了 98%以上的原有正确关系。

两项方法结合后，以 Qwen3.5-9B 为骨干的完整模型在 AAEC 和 CDCP 官方测试集上取得 71.63 和 50.77 的严格关系 F1，比同骨干的 MCR-BR 基线分别提高 5.94 和 8.98 个百分点，在 Qwen3.5-4B 和 Qwen2.5-7B-Instruct 上同样取得了显著提升。进一步分析表明，两阶段方法恢复的关系重叠较少，增益基本可以叠加。本文的研究表明，在训练中保持改写前后监督的可靠对应、在推理中同时处理组件与关系，能够有效提升端到端论辩结构预测的性能。

关键词：端到端论辩挖掘；可靠对应；成对学习；依赖闭合；图修正；结构化预测

Abstract

Argument mining aims to identify argumentative components, such as claims and premises, together with the support and attack relations between them. It is an important task in natural language understanding and benefits applications such as writing assessment and public opinion analysis. Recent generative approaches based on large language models can produce complete argument structures directly from raw text, yet the interdependence between components and relations still makes both training and inference difficult. Specifically, existing methods face two challenges: (1) Annotating argument structures is costly, and data augmentation is a common way to enlarge the training set. However, local rewriting may change the argumentative role of a component or its relations with other components, so directly reusing the original annotations introduces noisy supervision. (2) Generated structures often contain components with incorrect boundaries or types, and modifying a component invalidates every relation that uses it as an endpoint. As a result, correcting components alone or relations alone can hardly yield a consistent argument graph.

To address these challenges, this thesis builds on multi-candidate reranking and bounded repair (MCR-BR) and carries out the following two studies. (1) For supervision preservation in data augmentation, this thesis proposes relation-influence-domain constrained augmentation with paired learning. For each local rewrite, the method determines the components and relations that may be affected, transfers the original annotations losslessly to the rewritten text, and audits each component and relation to decide whether its label still holds. During training, the original text provides full argument-graph supervision, while the rewritten text contributes auxiliary supervision and paired distribution alignment only on reliable components and relations. Experiments show that this method improves strict relation F1 by 2.56 and 3.30 points on AAEC and CDCP, and human auditing shows that the weighted unsafe-rate estimates for accepted relation factors are 0.81% and 0.91%.

(2) For structural repair at inference time, this thesis proposes dependency-closed argument graph repair. The method treats a component modification and the reconstruction of all affected relations as a single transaction, and decides whether to accept it according to frozen object scores, per-type utility gates, and edit budgets. Both a global integer programming solver and a set-based local search are provided. With the training configuration

fixed, the method improves strict relation F1 by 3.38 and 5.68 points. Compared with regeneration under the same budget, it achieves higher F1 while retaining more than 98% of the originally correct relations.

Combining the two methods, the full model with a Qwen3.5-9B backbone achieves strict relation F1 scores of 71.63 and 50.77 on the official AAEC and CDCP test sets, outperforming the MCR-BR baseline with the same backbone by 5.94 and 8.98 points. Consistent and significant gains are also observed on Qwen3.5-4B and Qwen2.5-7B-Instruct. Further analysis shows that the relations recovered by the two stages have little overlap and that their gains are largely additive. These results indicate that preserving reliable supervision under rewriting during training and jointly handling components and relations during inference can effectively improve end-to-end argument structure prediction.

Keywords: End-to-End Argument Mining; Reliable Correspondence; Paired Learning; Dependency Closure; Graph Repair; Structured Prediction

目录

摘要.....I
Abstract.....II
第一章 绪论.....1
1.1 研究背景与意义.....1
1.2 国内外研究现状.....2
1.2.1 端到端论辩挖掘与生成建模.....2
1.2.2 关系保持数据增强.....3
1.2.3 结构化预测与论辩图修正.....4
1.3 研究问题与主要研究工作.....5
1.4 主要贡献与创新.....7
1.5 论文组织结构.....8
第二章 理论基础与公共实验设置.....9
2.1 论辩挖掘任务与结构表示.....9
2.1.1 论辩组件与关系.....9
2.1.2 组件的字符级表示.....10
2.2 预训练语言模型与学习方法.....12
2.2.1 注意力机制与自回归生成.....12
2.2.2 参数高效微调与连续提示.....12
2.2.3 数据增强与一致性学习.....13
2.3 候选评分与结构化决策.....13
2.4 评价指标.....15
2.5 训练与推理流程概述.....15
2.6 公共实验设置与统计方法.....17
2.6.1 数据与划分.....17
2.6.2 模型与训练配置.....17
2.6.3 对照设计与显著性检验.....19
2.7 本章小结.....20
第三章 关系影响域约束的增强与成对学习.....21
3.1 引言.....21
3.2 总体框架与基础模型.....22

3.3 关系影响域与可靠增强样本构造.....23
3.3.1 改写范围与关系影响域.....23
3.3.2 改写生成与标注迁移.....26
3.3.3 语义审核与因素掩码.....26
3.3.4 标注迁移与改写案例.....28
3.4 成对组件与关系学习.....29
3.4.1 辅助预测头与成对对齐.....32
3.4.2 损失归一化与参数更新.....33
3.5 算法及性质.....34
3.6 实验结果与分析.....36
3.6.1 实验设置与对照组.....36
3.6.2 主要结果与消融分析.....37
3.6.3 增强数据的人工审核.....38
3.6.4 训练成本与局限性.....40
3.7 本章小结.....41
第四章 多候选驱动的依赖闭合论辩图修正.....42
4.1 引言.....42
4.2 候选生成与初始图.....44
4.2.1 多候选生成与初始图选择.....44
4.2.2 候选空间构建.....45
4.3 对象评分与接受准则.....46
4.3.1 对象评分器与策略选择.....46
4.3.2 效用函数与接受条件.....47
4.4 依赖闭合事务的构造.....48
4.4.1 组件冲突消解.....48
4.4.2 受影响关系的重建.....48
4.4.3 事务示例.....49
4.5 求解算法及性质.....51
4.5.1 集合局部搜索.....51
4.5.2 全局整数规划求解.....55
4.5.3 方法性质分析.....56
4.5.4 求解方式的选择.....57
4.6 实验结果与分析.....58
4.6.1 主要结果与消融分析.....58

4.6.2 候选覆盖分析.....63
4.6.3 评分质量与误改分析.....63
4.6.4 多前提关系的评价示例.....67
4.7 本章小结.....67
第五章 两阶段框架的综合分析.....69
5.1 实验设置.....69
5.2 两阶段组合的效果.....69
5.2.1 总体性能.....69
5.2.2 增益分解与交互分析.....70
5.3 关系恢复与漏检分析.....71
5.3.1 两阶段恢复关系的对比.....71
5.3.2 漏检原因分析.....72
5.4 多前提关系分析.....73
5.5 不同骨干模型上的结果.....74
5.6 与外部系统的比较.....75
5.7 与已发表结果的比较.....76
5.8 本章小结.....78
第六章 总结与展望.....79
6.1 研究总结.....79
6.2 局限性.....79
6.3 后续研究.....80
参考文献.....81
附录 A 实现细节与复现信息.....86
A.1 确定性选择规则.....86
A.2 模型版本与参数量.....86
A.3 复现材料.....86
A.4 推理与增强模块的实现细节.....87
附录 B 补充实验结果.....89
B.1 开发选择.....89
B.2 审核的补充统计.....90
B.3 运行成本与求解规模测试.....91

第一章 绪论

1.1 研究背景与意义

论辩广泛存在于议论文写作和公共议题讨论中，人们通过提出观点、给出理由和回应异议来表达立场。要理解这类文本，就需要把作者的主张与理由联系起来，并辨别不同论述之间是支持还是反驳。由于文本内容分散、表达形式多样，人工梳理论证过程往往需要逐句分析上下文。因此，自动识别文本中的论辩结构既有实际价值，也是自然语言理解的重要研究问题[1]。

论辩挖掘（Argument Mining，AM）旨在识别文本中的论辩组件及其关系，将非结构化的论述转化为可分析的结构[1]。论辩组件是承担观点、理由等功能的文本片段，组件之间的关系描述这些片段如何共同构成论证。定位组件、判断其类型并识别关系后，就得到了文本对应的论辩图。论辩图既可以用来检查议论文中的理由是否围绕观点展开，也可以用来整理公共讨论中的各方立场及依据，为写作反馈和舆情研判提供支持。

以论辩标注作文语料 AAEC 中的 essay001 为例。~~作者认为~~合作有助于儿童学习人际交往技能，并以团队合作中的相处经验、沟通与妥协、生活技能等作为理由。图 1-1 展示了其中一组支持关系：T3 是被支持的观点，T4、T5 和 T6 是支撑该观点的理由。论辩挖掘需要从原文中找出这些片段，判断它们的类型，并恢复从理由指向观点的连接。可以看到，组件识别和关系判断紧密相关，都离不开上下文。

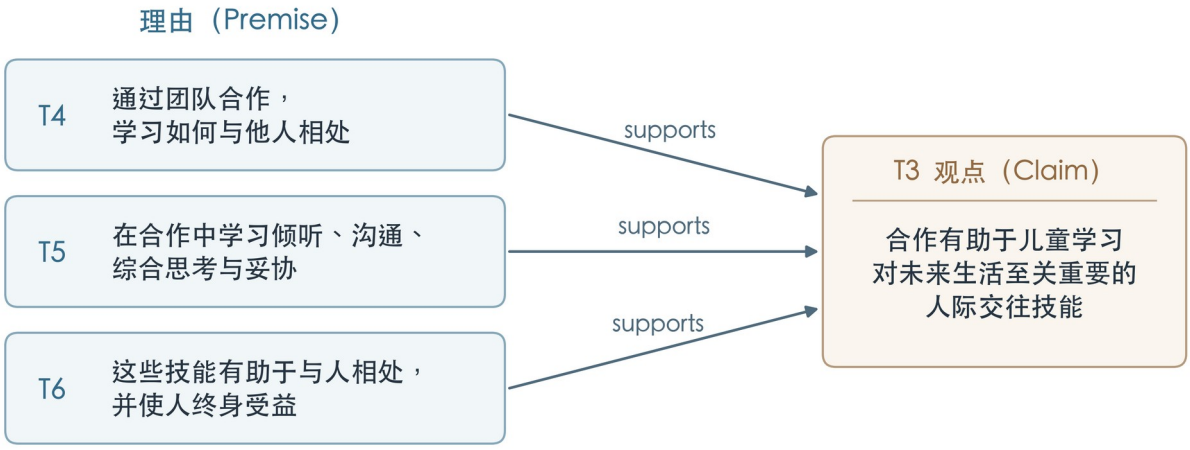


图 1-1 AAEC 作文中的观点与理由及其支持关系（essay001 局部结构，中文为阅读提示）

早期研究分别处理组件识别和关系分类，随后逐步转向组件与关系的联合建模[2][4]。随着预训练语言模型的发展，生成式方法把组件边界、类型和关系组织成统一的

输出序列，使模型能够直接从原始文本生成论辩结构[7]。这种方式便于利用上下文、联合处理多个子任务，但并不能消除结构判断中的错误。本文关注其中两个问题：扩充训练数据时如何保留有效监督，以及如何修正预测图中的局部错误。

第一个问题是数据增强中的标注保持。论辩标注需要同时确定文本片段、组件类型和组件间的连接，构建成本很高[1][2]。用语言模型改写已有文本可以丰富表达、扩充训练样本[15]，但改写后的文本能否沿用原标注并不确定。两段主题相同的文字，可能在立场、论述范围或理由强度上有所不同，从而改变组件类型以及它与其他组件的支持关系。已有的槽位化增强方法默认改写保持了语义，因而直接沿用全部标注[35]。对于组件与关系相互依赖的论辩结构，需要进一步判断改写后哪些监督仍然可靠。

第二个问题是预测图的修正。组件边界或类型改变后，与它相连的多条关系都可能需要重新判断。例如，图 1-1 中的 T3 与三个理由相连，如果只修改 T3 而保留原有关系，修正后的图仍然可能与文本含义不符。另一方面，反复重新生成或大范围修订既增加计算开销，也可能破坏原本正确的部分。因此，修正时需要让组件与其关联关系协调变化，同时控制修改范围和计算成本。

这两个问题分别对应结构化学习中的监督保持和结构修正。明确改写后哪些标注仍然可用，可以为数据增强划定清晰的使用条件；刻画组件变化对关联关系的影响，则可以把局部修改与整体结构联系起来。本文据此分别设计训练方法和推理方法，二者的共同主线是处理组件与关系之间的依赖。

1.2 国内外研究现状

与本文直接相关的研究包括端到端论辩建模、训练数据构造和预测结果修正三个方向。本节依次梳理各方向的代表方法，并说明本文的研究定位。

1.2.1 端到端论辩挖掘与生成建模

端到端论辩挖掘的核心是联合预测组件与关系。Stab 和 Gurevych 针对说服性作文建立了组件与关系的分析方法[2]，Eger 等将组件识别和论证结构预测纳入神经网络端到端学习框架[4]。Morio 等通过双仿射解析和任务特定参数化支持非树状结构的预测[5]。这些研究将组件识别、关系判断与结构约束统一到一个任务中，也表明不同语料的论辩结构并不都能用树来表示。

生成式方法用统一的输出表示连接多个子任务。Kawarada 等将论辩挖掘建模为文本到文本的生成任务[7]，本文将其作为生成式对照方法。Cabessa 等将组件分类、关系识别和关系分类组织为生成任务，但其输入已经给定组件列表，与从原始文本定位组

件的端到端设定不同[8]。AASP 使用受约束的预定义动作逐步构建论辩结构，把结构信息融入自回归生成过程[9]。

GMAM 利用约束指针和重构的位置编码，将组件与关系组织为紧凑的生成序列[47]。UniASA 将多种论辩结构分析任务统一为序列生成，并通过子任务分解进行多视图学习[48]。二者分别为结构生成和辅助任务设计提供了参考。

另一些研究借助结构或语义信号辅助预测。DENIM 使用篇章结构感知的前缀进行端到端预测[12]；Das 等用关键短语表示关联组件之间的概念联系[13]；FOL-AM 利用一阶逻辑规则组织关系查询和多跳推理[14]。后两项工作以预先切分好的组件为输入，主要评价给定组件条件下的分类能力，对本文的关系语义建模有借鉴意义。

即使采用生成式建模，组件边界仍然是主要的误差来源之一。Caputo 等使用成对标签进行细粒度的组件切分，并分析了自动切分对后续分类的影响[6]。ARGUS 系统整合了组件切分、组件分类、关系识别与分类，并接入符号求解器分析论辩框架[10]。Li 等的综述系统讨论了大语言模型在论辩挖掘各子任务上的应用及评价差异[11]。在此基础上，本文聚焦监督保持与结构修正两类机制。

除方法本身外，比较结果还受语料表示和训练数据来源的影响。MT-AM 利用辅助论辩语料进行多任务训练[25]，AMELIA 统一了 19 个数据集的格式，并比较了单任务、多任务和模型合并策略[26]。Feger 等发现模型会依赖与数据集相关的词汇线索，跨数据集泛化能力有限[27]。本文在 AAEC 和 CDCP 两种原生任务上分别进行域内比较。 ORCHID 提供中文辩论中的立场识别与摘要任务[28]，IAM 联合组织论点抽取、立场分类和证据抽取[29]；这些资源扩展了语言与任务范围，但不等同于本文的完整论辩图抽取。

1.2.2 关系保持数据增强

数据增强通过改变文本表达来扩充训练样本，其效果取决于生成内容能否与标签保持一致[15]。CoDa 从训练实例中提取约束来控制生成[16]，SegMix 在任务相关片段上进行结构感知的混合[17]。这些方法都说明，增强的价值不在于新增样本的数量，而在于生成内容与标签的对应。

在论辩挖掘中，与本文最相关的是质量导向的合成方法 QOS[35]。QOS 将上下文和组件组织为槽位化输入，改写后恢复组件跨度，并直接继承原有的组件类型和关系标注。生成模型并不显式接收论辩关系，而是依靠改写保持语义来使原关系继续成立。这为局部改写提供了实现基础，但也留下了一个问题：改写后哪些标签仍然成立，哪些标签已经无法确定。

同一研究还提出了多样性导向的合成方法 DOS，分别从质量和多样性两方面构造增强数据[35]。本文借鉴 QOS 的槽位化改写思路，具体做法见第三章。Zhang 等通过交替优化生成器和判别器来合成新的文本—结构标注对[49]。与之不同，本文采用保留原图监督的局部改写，并在训练规模和下游抽取器相同的条件下，分别比较数据构造和学习目标的作用。

关系抽取领域也有控制增强质量的研究。ConsistRE 以关系条件和上下文约束组织细粒度生成[38]，CovEReD 通过反事实实体替换研究文档级关系预测的一致性[37]，ODDA 关注低资源条件下增强样本的质量与多样性[39]。Wang 等将大语言模型生成的样本用于联合实体关系抽取，并结合一致性正则化、伪标签和迭代反馈[36]。这些工作面向实体关系，而本文面向组件与关系相互依赖的论辩结构，并在单个组件和单条关系（本文称为“因素”）的粒度上判断哪些监督可以保留。

增强还可能改变模型对表面线索的依赖。已有研究发现，话语标记补全的效果因语料而异[40]，弱监督论辩挖掘也面临组件边界和关系噪声问题[18]。因此，本文从标签漂移、表达多样性、可用覆盖率和训练成本几个方面评价增强数据，并在同一批增强样本上比较不同的学习目标。

1.2.3 结构化预测与论辩图修正

结构化预测可以在生成过程中施加约束，也可以在生成之后选择或修正候选。语法约束解码通过限制后继 token 来控制输出格式[19]，AASP 把结构动作约束纳入生成过程[9]。这些方法能保证输出满足格式规则，但无法判断跨度和关系本身是否正确，后者正是本文生成后修正要解决的问题。

生成后修订和多候选聚合是改进预测的另一条路径。Self-Refine 根据反馈迭代修订输出[20]，自一致性方法通过采样多条推理路径来聚合答案[22]。但在缺乏外部反馈时，模型的自我纠错可能无效，甚至会降低性能[21]。在论辩分析中，LLM-refine 生成不同的 Claim、Evidence 和 Warrant 组合，再从中选择切分结果[23]。可见，修订的收益取决于候选质量和选择机制。本文用预先固定的组件与关系评分来驱动选择，为每次修改提供统一的效用度量。

还有研究关注对象与关系的联合处理。Re-Cent 用关系标签引导跨度对的抽取，并利用关系与跨度对之间的相关性进行修正[43]。Pirozelli 等的论辩重构流程包括组件合并、重写和关系检查，允许改写组件的表述，这与保留原文跨度的抽取任务不同[44]。Xiao 和 Li 提出的 ARGUS 将大语言模型的自我解释转化为抽象论辩框架，并以形式语义定义最小代价的修复目标[24]，它与前述同名的论辩挖掘系统无关。

本文在多候选重排序与有界修正方法 MCR-BR[34]的基础上开展研究。MCR-BR 已经支持候选跨度替换、组件类型调整和关系修改，但修改组件时没有系统处理与之相连的关系。本文要解决的正是这一依赖问题：组件修改后，哪些关系需要重新评价，组件与关系的变化在什么条件下一起接受。本文用依赖闭合事务统一这些决策，并通过集合动作和全局求解来实现。

评价修正方法时，还需要区分单个对象的评分和最终的抽取指标。以 F1 为目标的最优决策一般不能由单个对象的边际概率直接确定[41]，校准概率与 F1 最优阈值之间的关系也只在特定条件下成立[42]。概率校准衡量的是模型置信度与实际正确率是否一致[45]。因此，本文将校准概率与代价敏感的效用函数相结合，并同时报告错误修改的数量和计算成本。

表 1-1 从输入条件和方法机制两个方面，对比了与本文最接近的研究。

表 1-1 相关方法与本文研究定位

研究	任务或输入条件	相关机制	本文比较重点
QOS[35]	论辩标注文本的槽位化增强	改写后恢复跨度并继承类型及关系	内部与跨边界关系、NONE 检查及资源匹配
ConsistRE 与 CovEReD[38][37]	关系抽取及文档级关系预测	关系条件生成或反事实一致性	论辩角色依赖与组件关系成对学习
AASP[9]	自回归论辩结构生成	受约束动作构建结构	生成过程约束与生成后事务决策的区别
Re-Cent[43]	联合实体关系抽取	关系引导跨度对抽取与修正	组件集合修改的依赖域与整体接受条件
MCR-BR[34]	从原文生成多个完整论辩图	整图重排序及有界组件关系修改	集合替换、完整关系重建及风险与成本分析

综上，现有工作为结构化生成、槽位改写和生成后修正奠定了基础，但仍有两个问题没有解决：局部改写后哪些监督可以继续使用，以及组件变化后如何一并处理与之相关的关系。本文分别从训练阶段的可靠因素学习和推理阶段的依赖闭合修正两方面展开研究。

1.3 研究问题与主要研究工作

本文围绕组件与关系之间的依赖，从训练和推理两个阶段开展研究：训练阶段识别文本改写后仍可用于学习的可靠标注，推理阶段在修改组件的同时重建与之相关的关系。两项工作的关系如图 1-2 所示。

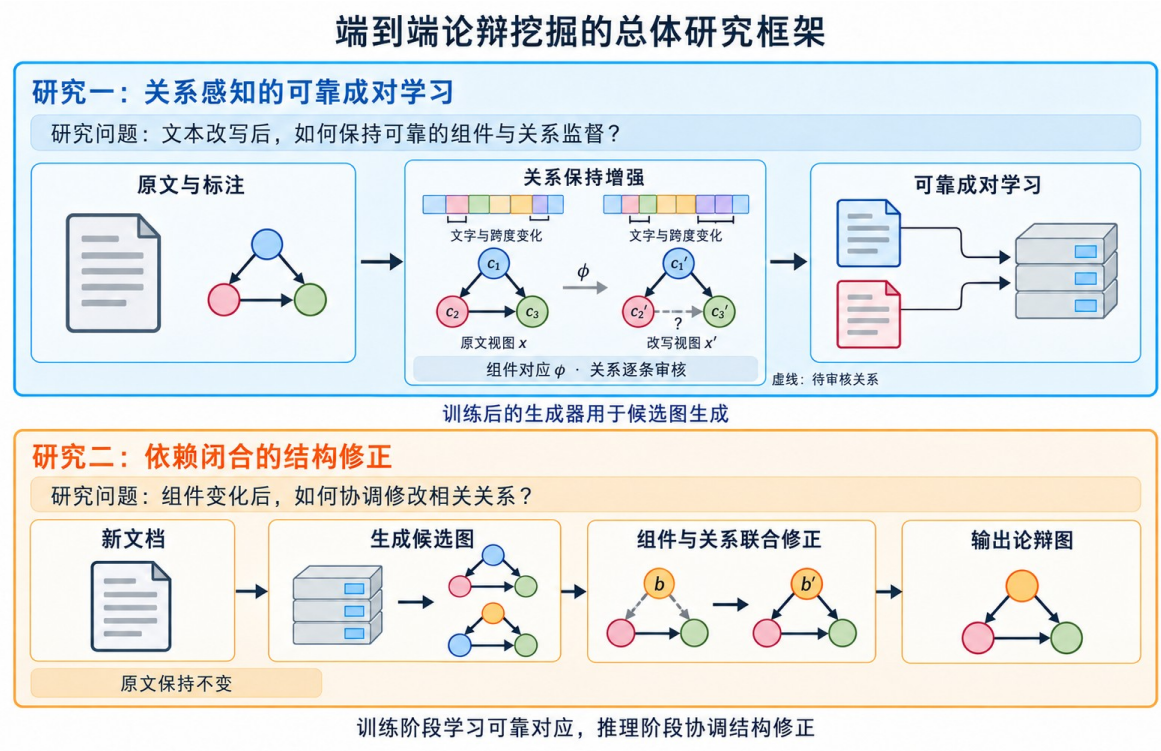


图 1-2 端到端论辩挖掘的总体研究框架

围绕上述两个阶段，本文提出以下研究问题。

~~RQ1：~~对文本进行局部改写后，如何识别仍可用于学习的组件与关系标注？在源文档、增强规模和训练预算相同的条件下，可靠标注的构造、辅助监督和成对学习分别能带来多少性能提升，又需要多少生成、审核和训练成本？

RQ2：在候选集合和评分固定的条件下，如何在修改组件时完整地处理与之相关的关系，同时控制误改风险和计算成本？修改粒度、组件与关系的共同接受以及求解方式分别如何影响修正质量和计算开销？

~~此外，本文通过训练与推理两阶段的四种组合，分析两项工作之间的关系，考察三者的增益是重叠还是互补。~~

针对上述研究问题，本文开展以下两项研究工作。

（1）基于可靠因素的关系感知成对学习。针对局部改写后部分标注可能失效的问题，本文先确定每处改写可能影响的组件与关系范围（关系影响域），将原标注映射到改写文本上，再通过逐项审核确定哪些组件和关系仍然可靠。训练时，原文提供完整的论辩图监督，改写文本只在可靠的组件与关系上提供辅助监督，并与原文进行分布对齐。 这里的“关系感知”是指根据组件改写对内部及跨边界关系的影响确定可用监督。

（2）基于依赖闭合的论辩图修正。针对组件变化可能使关联关系失效的问题，本文把组件修改与全部受影响关系的重建组织为一个事务，事务中的修改必须一起接受或一起拒绝。是否接受由组件和关系各自的效用变化以及编辑预算共同决定。在此基础上，本文比较仅修改关系、分步决策、单对象共同决策和集合动作等不同方案，并分析全局求解与局部求解各自的适用条件。

实验既评价完整方法的总体效果，也通过受控对照分析各个机制的作用。训练侧分别控制数据构造和学习目标；推理侧固定候选与评分，考察修改范围、共同接受和求解方式的影响，并与相同预算下的重新生成进行比较。最后，通过两阶段四种组合的比较和逐条关系的成员分析，说明两项工作的组合效果。

本文以前期工作 MCR-BR[34]为基础，表 1-2 列出子继承的机制和本文新增的研究内容。

表 1-2 MCR-BR 已有机制与本文研究内容

研究层次	MCR-BR 已有机制	本文研究内容
训练与表示	结论专项适配、线索提示、句子辅助监督	可靠对应构造、因素掩码与成对学习
候选生成与选择	多候选组件、关系构建与整图重排序	保留初始图接口，明确固定候选及完整对象身份
组件与关系修正	类型调整、候选跨度替换、删边与局部重预测	依赖完整重建与事务接受，比较单对象及集合动作
评分与评价	覆盖、语义、合法性混合评分及非下降接受	完整对象正确性评分、计数效用与风险分析

其中，LoRA 微调、线索提示和句子辅助监督沿用 MCR-BR，本文的新增工作集中在可靠因素上的学习，以及组件变化后关系依赖的完整处理与共同决策。

1.4 主要贡献与创新

本文围绕端到端论辩挖掘中组件与关系的相互依赖，分别从训练和推理两个阶段提出改进方法，主要贡献与创新如下：

（1）提出关系影响域约束的增强与成对学习方法。与 QOS 等直接继承全部原标注的槽位化增强方法不同，本文以单个组件和单条关系为粒度判断改写后的监督是否仍然可靠：通过关系影响域界定每处改写需要检查的内部、跨边界和无关系因素，通过无损的标注迁移和逐项语义审核确定可靠因素，并且只在可靠因素上施加辅助监督与成对一致性约束。针对多前提关系，本文进一步区分“与完整关系不匹配”和“语义上

无关系”，避免把联合理由的子集错误地当作负例。人工分层审核表明，改写会使约6%的因素状态发生变化，而经过审核后，被接受关系因素的加权不安全率估计为0.81%和0.91%。

（2）提出依赖闭合的论辩图修正方法。针对已有修正方法在修改组件时没有系统处理关联关系的问题，本文把组件修改与全部受影响关系的重建定义为一个不可拆分的事务，基于校准后的完整对象评分构造可分解的计数效用，并通过分项效用门和编辑预算决定是否接受；在此基础上给出集合局部搜索和全局整数规划两种求解方式，并分析了方法的理论性质：效用变化可以由增删对象精确计算，集合动作能够越过单对象修改无法越过的局部障碍，搜索过程在有限步内终止。与相同预算下的重新生成相比，该方法在取得更高 F1 的同时保留了 98%以上的原有正确关系。

（3）建立了严格、可复现的评价与分析方法，并对两项工作进行了系统验证。本文以字符区间和完整端点定义论辩对象，按完整的多前提关系严格计数，采用文档与种子联合重采样和 Holm 多重比较校正进行显著性检验。在 AAEC 和 CDCP 上，完整方法比同骨干的 MCR-BR 基线分别提高 5.94 和 8.98 个百分点，14 项主要比较全部通过校正；逐条关系的成员分析表明，两阶段方法恢复的关系几乎不重叠，增益基本可以叠加；在三种骨干模型和两种外部系统上的实验进一步验证了结论的一致性。

1.5 论文组织结构

全文共六章。第一章介绍研究背景，梳理相关工作，提出研究问题并概括本文的主要贡献与创新。第二章介绍任务定义、相关技术、评价指标和公共实验设置。

第三章提出关系影响域约束的增强与成对学习方法，并分析其性能增益与审核成本。第四章提出依赖闭合的论辩图修正方法，并分析其修正质量、误改风险和计算开销。

第五章分析两阶段方法的组合效果、关系恢复来源和剩余错误，并给出跨骨干模型和外部系统的比较结果。第六章总结全文并展望后续研究。附录 A 补充复现信息，附录 B 给出开发集选择、分层审核和资源消耗的详细结果。

第二章 理论基础与公共实验设置

第一章介绍了论辩挖掘的研究背景和现状，并提出了本文的研究问题。本章介绍后续各章共同使用的理论基础和实验设置。训练阶段的监督保持和推理阶段的结构修正，都依赖于三个基本问题：组件和关系如何表示，模型如何学习，预测结果如何评价。本章首先给出论辩组件与关系的统一表示，然后介绍生成建模、参数高效微调、数据增强与一致性学习、候选评分与结构化决策等相关技术，最后说明评价指标和公共实验设置。

2.1 论辩挖掘任务与结构表示

2.1.1 论辩组件与关系

论辩挖掘以没有结构标注的文档为输入，输出其中的论辩组件及组件间的关系。组件识别确定相关文字在原文中的位置，组件分类判断它在论证中的类型。本文采用端到端设定，即直接从原文预测组件与关系，测试集标注只用于评价。系统内部可以包含生成、候选选择和预测修正等多个步骤。

记文档为 x，其标识为 d，文档标识同时记录语料、原始文档编号及文本版本。字符位置按原文的 Unicode 码点从 0 开始计数。组件表示为

$$c=(d,b,e,t),\qquad 0\le b<e\le|x|. \tag{2-1}$$

其中，$[b,e)$ 为左闭右开的字符区间，$x[b{:}e]$ 是组件对应的原文片段，t 为语料定义的组件类型。相同文字出现在文档的不同位置时，视为不同的组件；同一字符区间被赋予不同类型时，也视为不同的预测对象。也就是说，组件由字符区间和类型共同确定，评价时二者都必须完全匹配。

模型使用的子词切分和评价使用的分词都只是原文的派生表示，二者都通过字符偏移映射回原文。分词方式可以不同，但组件的字符边界始终以原文为准。

二元关系表示两个组件之间的有向联系，记为 $r=(c_i,c_j,\ell)$，其中 c_i 为源组件，c_j 为目标组件，ℓ 为关系标签。关系方向由提供理由或发起攻击的一方指向被支持或被攻击的一方。文档的论辩结构记为 $G=(C,R)$，其中 C 为组件集合，R 为关系集合。

有些语料允许多个组件共同支持同一个目标。此时关系表示为 $h=(S,c_j,\ell)$，其中 S 为非空的源组件集合，集合中的成员共同构成一条完整关系。如果把它拆成多条二

元边，计数单位和匹配条件都会改变，因此本文保留原始的多前提结构；二元关系可以看作源集合大小为 1 的特例[3][46]。

表 2-1 两种语料的原生任务表示

语料	组件类型	关系对象	评价时保留的边界
AAEC	MajorClaim、Claim、Premise	Support、Attack 二元关系	Claim 对 MajorClaim 的 stance 单列，不补造普通关系
CDCP	Fact、Testimony、Value、Policy、Reference	Reason、Evidence 多前提关系	完整源集合参与匹配，不归并组件类型、不拆分超边

两种语料的任务定义沿用原始标注及相关研究[2][3][46]。以 CDCP 为例，若一条关系有两个源组件，预测时漏掉任意一个都不能匹配这条关系。第三章用到的“结论角色”只用于选择增强中心，不改变 CDCP 的原始组件类型。两个语料的实验分别按各自的原始标注进行评价。

2.1.2 组件的字符级表示

使用字符坐标而不是 token 位置来确定组件，是为了准确区分边界不同的片段。如果只用 token 的起止位置和类型来标识组件，那么覆盖相同 token、但字符边界不同的两个片段就会被当成同一个组件。组件边界落在单词内部时，这一问题尤其明显。

设评价 token 的字符区间依次为 $[a_i, z_i)$。对于字符区间为 $[b, e)$ 的组件，取与其相交的首、末 token 索引 s, u（从 1 开始），并记录左右两端的字符残差：

$$\rho_L = b - a_s, \quad \rho_R = z_u - e; \qquad b = a_s + \rho_L, \quad e = z_u - \rho_R. \tag{2-2}$$

这样，由 (s, u, ρ_L, ρ_R) 就可以精确恢复原字符区间，而仅凭 (s, u) 通常做不到。模型子词同样通过字符偏移与原文对应，聊天模板等引入的位置偏移不计入原文坐标。

表 2-2 以 AAEC 文档 essay098 中的组件 T6 为例。原标注在单词 responsible 的最后一个字母之前结束，本文保留这一边界。作为对照，表中另列了一个扩展到完整单词的片段，二者是不同的对象。

表 2-2 token 范围相同但字符边界不同的两个组件

对象	字符区间	评价 token 闭区间	左右残差	片段末尾
原生 T6，Claim	[858,914)	[162,172]	(0,1)	responsibl
扩展边界的构造对照，Claim	[858,915)	[162,172]	(0,0)	responsible

两行覆盖的 token 字符区间都是[858,915)，借助字符残差，第一行恢复为[858,914)（$858+0$，$915-1$），第二行恢复为[858,915)。两行的文档、token 范围和类型都相同，但结束位置不同，因此不会被合并。字符残差只用于保存原始边界，不用于修正标注。

组件由式（2-1）中的四个字段唯一确定，本文称之为组件的规范键。关系的规范键由全部端点的规范键和关系标签组成，多前提关系的源端保存排序后的完整组件集合。候选去重、评分缓存、修改记录和评价匹配都通过规范键识别对象。T3、T4 等编号只用于文中引用，重新编号不会产生新对象，也不算作一次修改。

组件的边界或类型一旦改变，规范键也随之改变，与它相连的关系必须按新的端点重新判断。因此，即使关系在图中的编号没有变，也不能直接沿用旧关系的身份和评分。这正是第四章依赖闭合修正的出发点。

原文与增强文本是两个不同的文本版本。第三章的映射 φ 描述改写前后组件之间的对应关系，并不要求两侧字符位置相同。改写改变文本长度时，所有受影响组件的字符位置都要相应更新；更新后哪些组件和关系可以参与学习，再由审核结果决定。

结构化预测涉及对象定义、候选范围、实际输出、对象评分和结果评价五个层次，如表 2-3 所示。需要注意区分三件事：一个对象“可以被选择”、“得分较高”和“预测正确”。

表 2-3 论辩结构预测的五个层次

层次	主要内容	需要回答的问题
对象	按字符区间、类型和完整端点定义的组件或关系	所比较的是否为同一对象
候选	有限组件集合及完整关系候选集合	正确对象是否进入可选择范围
预测	模型或决策过程实际输出的合法结构	系统最终选择了哪些对象
评分	对候选对象正确性的估计及其决策用途	分数能否支持可靠选择
指标	与金标匹配后的 TP、FP、FN 及其汇总	预测在统一任务下的准确性如何

记合法结构集合为 G_A，其中 A 为语料的标注规范。合法结构的基本要求是：组件跨度位于原文范围内，组件类型和关系标签有效，关系的端点都存在；跨度能否重叠或嵌套、结构是否必须为树或无环图，则按各语料的标注规范确定。

2.2 预训练语言模型与学习方法

2.2.1 注意力机制与自回归生成

Transformer 通过注意力机制聚合不同位置的信息，是本文所用骨干模型的基础[30][31]。注意力先根据查询与键的相似度计算权重，再对值向量加权求和。缩放点积注意力表示为

$$\mathrm{Attention}(Q,K,V)=\mathrm{softmax}(\frac{QK^{\mathrm{T}}}{\sqrt{d_k}})V. \tag{2-3}$$

其中，Q、K、V 分别为查询、键和值矩阵，d_k 为键向量的维度。注意此处的 V 与第四章的组件候选集合含义不同。多头注意力在多个表示子空间中并行计算注意力。自回归解码时，每个位置只能看到输入和已经生成的输出。

在论辩挖掘中，可以把组件位置、类型和关系依次序列化为输出序列 $Y=(y_1,\ldots,y_L)$。给定原文 x，其生成概率和训练目标分别为

$$P_\theta(Y|x)=\prod_{k=1}^{L}P_\theta(y_k|x,y_{<k}), \tag{2-4}$$

$$L_{\mathrm{gen}}=-\sum_{k=1}^{L}\log P_\theta(y_k|x,y_{<k}). \tag{2-5}$$

训练时以金标序列作为前缀计算下一个符号的损失，测试时则以模型已经生成的符号作为前缀。生成式论辩挖掘将多个子任务统一到一个输出序列中[7]。由于序列概率同时受输出长度和字段顺序的影响，不适合直接衡量单个组件或关系是否正确，本文为此另外训练了对象评分器，直接估计每个组件和关系的正确概率。

2.2.2 参数高效微调与连续提示

预训练模型参数量很大，针对具体任务更新全部权重会带来很高的训练和存储成本。低秩适配（LoRA）冻结基础权重，只学习一个低秩增量[32]：

$$W=W_0+\frac{\alpha}{r}BA,\qquad A\in\mathbb{R}^{r\times d_{\mathrm{in}}},\quad B\in\mathbb{R}^{d_{\mathrm{out}}\times r}. \tag{2-6}$$

其中，r 为秩，α 为缩放系数。训练时只更新增量矩阵，基础权重 W_0 保持不变。连续提示通过学习一组提示向量来表达任务条件，也是一种参数高效的适配方式[33]。前者调整权重，后者调整输入，二者都只引入少量可训练参数。

本文以 Qwen3.5-9B 为主骨干模型[50]，MCR-BR 基线（记为 T0）、本文方法（记为 T1）以及外部对照方法都在该骨干上重新训练。完整的消融和错误分析都基于 9B 模型；另外使用 Qwen3.5-4B 考察较小骨干的表现，使用 Qwen2.5-7B-Instruct 与已有方法衔接[52][53]。两种补充骨干复用 9B 模型生成和审核的增强数据，抽取器、评分器等模块则各自独立训练。

2.2.3 数据增强与一致性学习

数据增强通过改变输入的表达方式来扩充训练样本。用语言模型改写文本，即使结果通顺，也可能使部分原有标注失效[15][35]。论辩挖掘的监督包括组件位置、组件类型和关系，局部的语义变化往往只影响其中一部分。因此，本文把通顺性和标注保持分开判断，并以单个组件或单条关系为单位决定保留哪些监督。

一致性学习约束同一对象在不同输入下的预测分布保持接近。设同一因素在两个视图下的类别分布为 p 和 q，令 $m=(p+q)/2$，Jensen–Shannon 散度[54]定义为

$$\mathrm{JS}(p,q)=\frac{1}{2}\mathrm{KL}(p\|m)+\frac{1}{2}\mathrm{KL}(q\|m),\qquad m=\frac{p+q}{2}. \tag{2-7}$$

其中 KL 表示 KL 散度。式（2-7）对两个分布是对称的。在训练目标中加入该散度项，可以让模型对原文和改写文本中相互对应的可靠因素给出相近的预测。未经确认的关系标签既不参与监督，也不参与一致性约束，更不会被直接改标为“无关系”。

分布对齐使模型在两种表达下保持一致，金标监督则引导预测接近正确标签，二者互为补充。本文据此组合三类训练信号：原文的完整论辩图生成监督、因素级的辅助监督，以及原文与改写之间的成对一致性约束。第三章给出具体的学习目标。

2.3 候选评分与结构化决策

单次生成可能遗漏组件或产生错误的关系，多候选方法通过生成若干备选结构来扩大选择范围。设候选图集合为 S，重排序函数为 $\mathrm{E}_{\mathrm{rank}}$。系统先选出得分最高的候选图，再依次执行合法化处理和 MCR-BR 中的有界修正（BR-O），得到最终的预测图：

$$\begin{aligned} G_{\mathrm{rank}}&=\operatorname{argmax}_{G\in S}\mathrm{E}_{\mathrm{rank}}(G),\\ G_{\mathrm{pre}}&=L_A(G_{\mathrm{rank}}),\qquad G_0=\mathrm{BR\text{-}O}(G_{\mathrm{pre}}). \end{aligned} \tag{2-8}$$

其中，L_A 为确定性的合法化过程。记重排序得分最高的候选图为G_{rank}，合法化后的图为G_{pre}，再经 BR-O 修正后得到G_0。以上整个流程沿用 MCR-BR，本文称之为推理

配置 I0。第四章在G_0的基础上追加依赖闭合修正（记为R_{DC}），I0 加上R_{DC}称为推理配置 I1。合法化和 BR-O 都不使用测试集标注。

得到G_0之后，第四章预先构建并固定三个有限集合：跨度候选集合 U、带类型的组件候选集合 V 和关系候选集合 P，合称候选空间。修正只能在候选空间内进行。因此，最终结果同时受候选覆盖、评分质量和搜索预算三方面影响：正确对象如果不在候选中，就不可能被恢复；即使在候选中，也可能因为评分不够高或搜索受限而没有被选中。

对象评分的单位应当与最终评价的单位一致。在给定金标跨度时，组件分类只需判断片段的类别；而对于模型预测的组件，还需要判断其字符边界是否准确。关系评分则要同时考虑全部端点、方向和标签。因此，本文为推理阶段单独训练了完整对象评分器，它与训练阶段的辅助分类头相互独立。

概率校准衡量模型置信度与实际正确率是否一致[45]。例如，得分在 0.8 左右的一组对象，若校准良好，应当有大约 80%是正确的。本文将校准后的概率转化为保留或删除一个对象的期望得失，构造结构决策所用的效用函数，最终输出仍以严格 F1 评价[41][42]。

推理评分器在交叉拟合产生的预测候选上训练，拟合、校准和策略选择使用互不重叠的数据。由于修正过程优先采纳高分对象，本文既评价评分器在全部候选上的质量，也统计实际被接受的修改中有多少是错误的。

结构化决策是从有限候选中选出满足约束的对象组合。候选空间越大，可选对象越多，评分和求解的开销也越大。本文的局部求解按累计修改次数计算编辑预算，全局求解按相对初始图的净变化计算编辑预算，因此二者的搜索范围并不相同。

对于 AAEC，关系候选为同一文档中任意两个不同组件构成的有向对，不允许自环，也不按段落或组件类型预先过滤。对于 CDCP，候选源集合取按原文位置排序后的连续组件，目标不能属于源集合。本文用 NONE 表示一个组件对之间没有关系，它不是输出的论辩关系。

~~对同一组端点，主配置只允许一种关系状态；跨度的重叠、嵌套以及是否无环，按各语料的标注规范处理。~~

本节给出了候选与结构化决策的基本概念。第四章将在此基础上定义组件修改后的依赖处理、接受条件和编辑预算。

2.4 评价指标

评价分别对组件和关系统计真正例 TP、假正例 FP 和假负例 FN，精确率、召回率和 F1 定义为

$$\text{Precision}=\frac{\text{TP}}{\text{TP}+\text{FP}},\quad \text{Recall}=\frac{\text{TP}}{\text{TP}+\text{FN}},\quad F_1=\frac{2\,\text{TP}}{2\,\text{TP}+\text{FP}+\text{FN}}. \tag{2-9}$$

组件匹配要求字符区间和类型都与金标完全一致；关系匹配还要求完整的源集合、目标、方向和标签都一致。CDCP 的多前提关系作为一个整体计数，不拆成二元边。本文以严格关系 F1 为主要指标，边界 F1、给定金标组件时的关系分类等指标用于辅助分析误差来源。

本文的 F1 均为 micro-F1，即先汇总全部对象的计数，再代入式（2-9）计算。分数以百分制报告，方法之间的差值以百分点报告。

匹配时每个预测对象和金标对象最多使用一次，重复预测计为 FP。解析失败或结构校验失败的文档仍保留在评价集中，按空预测处理，其金标对象全部计为 FN。

所有结果都按语料、文档、训练种子和方法逐文档记录。同一配置在不同章节中出现时引用同一份记录，因此各章表格中相同方法的数值是一致的。

需要说明的是，I0 指完整的 MCR-BR 推理流程（多候选生成与重排序、合法化和 BR-O 修正），其输出为G_0；I1 则在 I0 之后追加R_{DC}。第五章中的 T0I1 和 T1I1，分别以相同训练配置下的G_0为起点。统计推理时延时，同时计入 I0 和追加阶段的耗时。

2.5 训练与推理流程概述

训练和推理的输入与监督条件不同。训练阶段读取带标注的原文，构造局部改写，并判断哪些监督可以保留；推理阶段读取没有标注的新文档，不改动原文，只对预测的组件和关系进行选择与修正。图 2-1 展示了两个阶段的数据流。

训练时，原文提供完整的论辩图监督，增强文本只在通过审核的因素上参与辅助监督和一致性学习。辅助分类头只在训练时使用，测试时移除。推理评分器在交叉拟合的预测候选上学习判断完整对象是否正确，其输出只用于结构决策，不反过来更新生成器。

结论专项建模、多候选生成和初始重排序沿用 MCR-BR。第三章研究关系影响域与可靠因素学习，第四章研究组件修改后的依赖处理和接受决策，第五章分析两阶段组合的作用。各阶段保留各自的拒绝或失败处理分支，评价统一采用本章定义的完整对象身份与计数规则。

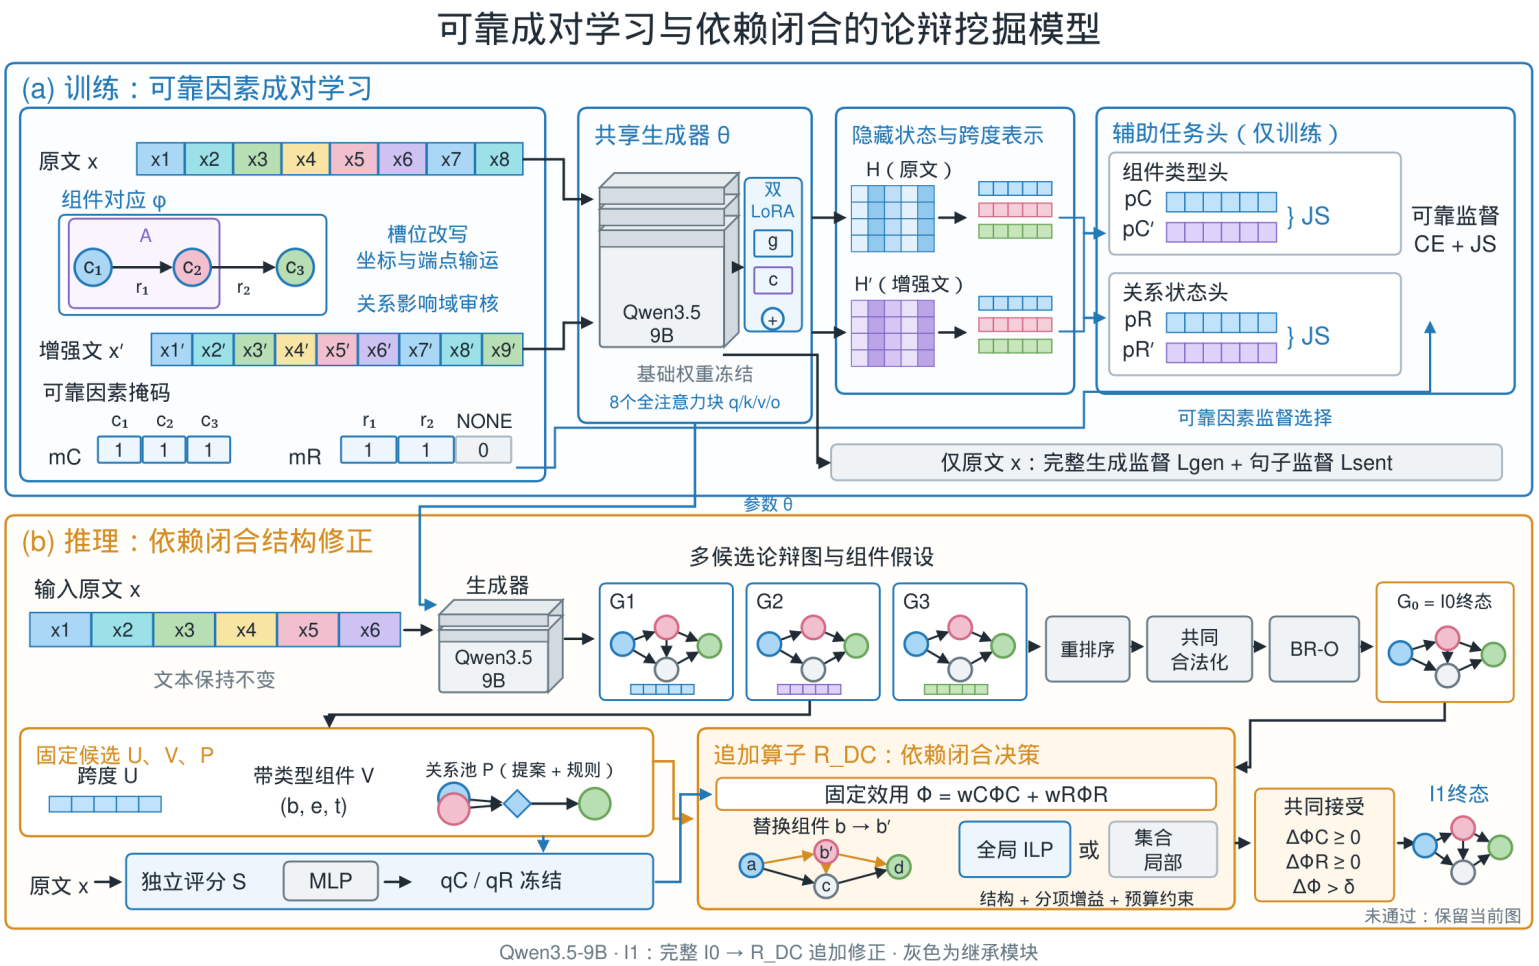


图 2-1 端到端论辩挖掘的总体模型架构

2.6 公共实验设置与统计方法

2.6.1 数据与划分

AAEC 采用官方发布的 train-test-split.csv 划分，CDCP 采用原始数据包中的 train/test 目录。重复文档只在训练集中去除，测试文档全部保留。表 2-4 列出两个语料的规模。

表 2-4 数据规模与官方划分

语料	划分	原始文档	保留文档	组件	完整关系	多源关系	最大源数
AAEC	train	322	319	4793	3006	0	1
AAEC	test	80	80	1266	809	0	1
CDCP	train	581	580	3901	969	85	8
CDCP	test	150	150	1026	252	34	10

训练集按全文哈希去重：AAEC 中 essay171、210、400 内容相同，保留 essay171，essay209 与 377 相同，保留 essay209；CDCP 保留 00410，去除与其正文重复且标注不完整的 00411。训练集与测试集之间没有重复文档。

交叉拟合采用三折划分，以源文档为单位分组，原文及其全部增强文本始终位于同一折中。每篇留出文档的候选，都由没有见过该文档的生成器产生。评分器的拟合、校准和策略选择使用互不重叠的源文档，AAEC 分别为 255、32 和 32 篇，CDCP 分别为 464、58 和 58 篇。测试集不参与增强、校准或策略选择。

2.6.2 模型与训练配置

主实验统一使用 Qwen3.5-9B、相同的训练预算、候选协议和评价器，训练种子为 17、29 和 43。多候选由 1 路贪心解码和 2 路采样解码组成。模型可以自由决定预测对象的数量，不按测试集金标数量截断或补齐。MCR-BR 基线 T0 也在同一骨干上重新训练。

表 2-5 列出公共训练与评价配置，表 2-6 列出抽取、增强、审核、评分与提案五类模块，表 2-7 汇总辅助头与推理参数。实验只使用文本输入，关闭模型的 thinking 模式，不使用视觉模块和长上下文扩展。

表 2-5 公共训练与评价配置

项目	固定值
骨干	Qwen/Qwen3.5-9B；后训练版本；文本路径；关闭 thinking

项目	固定值
LoRA	8 个全注意力块 q/k/v/o；全局及结论各$r=16$，$\alpha=32$，dropout=0.05
优化器	AdamW；LoRA 学习率 2×10^{-4}；weight decay=0.01；β=(0.9,0.999)；$\varepsilon_{\text{Adam}}=10^{-8}$；warmup=0.03
学习预算	5 epoch；2 GPU×每卡 1 源×累计 16 步 = 批 32；末批按有效源归一化
精度与分片	BF16；FSDP full shard；梯度检查点；梯度裁剪 1；基础与视觉权重冻结
上下文	模型配置上限 8192；每次输入≤4096、输出≤2048；无 YaRN
生成	1 路贪心 + 2 路采样；temperature=0.7、top-p=0.9；相同规范序列化
种子	17、29、43；相同官方测试文档
硬件	2×A100 80 GB；128 GiB RAM；4 CPU 线程；推理 TP=2
成本单位	GPU 小时=设备数×墙钟小时；显存为单卡最大峰值

表 2-6 系统中的五类模块

模块	实现方式	输出与用途
G 抽取生成器	Qwen3.5-9B + 双 LoRA；基础权重冻结；5 epoch	原生组件及完整关系 JSON；I0/T0/T1
A 增强生成器	Qwen3.5-9B 官方权重，不加载任务 LoRA；训练时可见标注	槽位替换 JSON；仅构造训练视图
V 语义审核器	同基础模型、独立上下文；待审标签隐藏；贪心输出	组件/关系状态或待定；决定监督掩码
S 对象评分器	冻结 Qwen3.5-9B 文本编码 + 独立 C/R MLP；OOF 训练；Platt 校准参数冻结	完整对象正确性概率估计；单次搜索期间复用缓存
P 源组提案器	冻结同版本文本编码 + 独立源组 MLP；训练原生完整组	最多 64 学习槽位；完整源集合及目标，不拆超边

9B 主实验中，评分器 S 和提案器 P 可以共享冻结的文本编码，但各自的参数与生成器 G 分开。跨骨干实验中，增强器 A 和审核器 V 固定使用 9B 模型，生成器、评分器和提案器在各骨干上分别训练。

表 2-7 列出辅助头、评分、提案和追加修正的设置。对象评分器 S 的组件头和关系头，按语料、种子和对象类别分别进行 Platt 校准[55]。

表 2-7 辅助头、评分与推理配置

项目	设置
辅助头	组件 8192→1024→3/5 类；关系 12295→1024→3 状态；GELU、dropout 0.1
对象评分 S	冻结 Qwen3.5-9B 文本编码；组件含 NULL；关系 12375→1024→1；10 epoch，AdamW 10^{-3}

项目	设置
源组提案 P	冻结同版本文本编码 + 独立 12295→1024→1 MLP；5 epoch，AdamW 10^{-3}；最多 64 学习槽位
损失系数	原文生成 1；句子 0.5；辅助监督 1；组件与关系对齐各 0.5；变体不作整图生成目标
校准	训练内 OOF；拟合/校准/策略源文档隔离；按语料、种子、对象类别 Platt
效用与阈值	w_C=w_R=1；κ_C=1；AAEC κ_R=1、CDCP κ_R=0.5；δ=0.20
开发选择	先要求原 TP 损失≤5%，再最大化策略集关系 F1；无合格配置保持 I0
预算及路由	追加R_{DC}：组件 24、关系 96（全局净/局部累计）；局部每轮 32 尝试 / 3 接受、最多 4 轮；n≤2500 用 Global，否则集合局部 BR-J；追加求解 AAEC 3 秒、CDCP 5 秒
候选与缺分	关系槽位上限 50000；保留初始图G_0全部对象；合计补充源组 256；评分缺失时拒绝相应事务
软件	Python 3.11；PyTorch 2.7.1；Transformers 5.8.0；PEFT 0.17.1；HiGHS[60]参考求解固定 CPU 预算

2.6.3 对照设计与显著性检验

训练侧的对照分两类。比较学习目标时（NoPair、CompPair 与完整成对配置），三者使用相同的增强文本、因素掩码和辅助头；比较数据构造方式时，则保持接受的样本规模和训练预算相同。推理侧比较不同修正策略时，固定训练检查点、候选和评分，只改变决策方式。

计算成本分为两部分：一次性成本，包括增强、审核、交叉拟合和评分器训练；逐文档成本，包括生成、提案、评分和求解。被拒绝、失败或超时的计算同样计入成本。与重新生成的对比中，两者的追加模型调用次数和输入、输出 token 上限都相同。一次性成本见附录 B.3。

对于每个训练种子，先汇总全部测试文档的计数并计算 micro-F1，再报告三个种子的均值和样本标准差。配对比较要求各方法使用相同的文档和种子，且金标对象总数 $\mathrm{TP}+\mathrm{FN}$ 保持一致。

显著性检验采用文档与种子的联合 bootstrap 重采样[56]，共 2000 次。每次有放回地抽取 3 个种子，并抽取与测试集大小相同的文档，所有方法共用同一组抽样结果；每次抽样后重新汇总计数，计算方法间的 F1 差值，由此得到差值的经验分布。

设观测差值为 $\hat{\Delta}$，第 b 次重采样的差值为 Δ_b^*，重采样次数为 B。95%置信区间取重采样分布的 2.5%和 97.5%分位数，双侧检验的 p 值按下式计算： 其中$I(\cdot)$为指示函数，条件成立时取 1，否则取 0。

$$p=\frac{1+\sum_{b=1}^{B}\mathrm{I}\left(|\Delta_b^*-\hat{\Delta}|\geq|\hat{\Delta}|\right)}{B+1}. \tag{2-10}$$

主要比较共 7 组，每组在两个语料上分别检验，共 14 项，依次考察：训练配置（T1I0 与 T0I0）、成对目标（T1I0 与 NoPair）、推理配置（T1I1 与 T1I0）、组件修改范围（T1I1 与 RelationOnly）、共同接受（Single 与 Sequential）、与重新生成的对比（T1I1 与 Regenerate）以及开发集风险限制（T1I1 与 NoRisk）。14 项 p 值统一用 Holm 方法[57]做多重比较校正。

各章的主要比较结果（表 3-7、表 4-6 和表 5-3）使用相同的逐文档记录和重采样索引，复现材料见附录 A.3。

2.7 本章小结

本章介绍了全文共用的理论基础与实验设置。首先，给出了论辩组件和关系的统一表示：组件由文档、字符区间和类型确定，关系由完整端点和标签确定，并支持多前提关系；然后，介绍了生成建模、参数高效微调、数据增强与一致性学习、候选评分与结构化决策等相关技术；最后，说明了严格匹配的评价方法、公共实验设置和统计检验方法。这些内容为第三章和第四章的方法设计与实验分析提供了基础。

第三章 关系影响域约束的增强与成对学习

论文前两章介绍了论辩挖掘的研究现状、相关技术和公共实验设置。在此基础上，针对训练文本局部改写后部分标注可能失效的问题，本章提出关系影响域约束的增强与成对学习方法：通过关系影响域确定改写可能影响的范围，通过语义审核筛选仍然可靠的组件与关系，并在可靠因素上进行成对学习，从而在扩充训练数据的同时避免引入错误监督。本章首先介绍增强文本的构造方法和学习目标，然后通过对照实验分析方法的整体效果、成对目标的作用以及审核质量与成本。

3.1 引言

在论辩文本中，组件的文字既决定它自身的类型，也是判断它与其他组件关系的依据。对文本做局部改写，即使句意基本不变，也可能改变支持的方向，削弱跨越改写边界的理由，或者让原本无关的两个组件产生联系。如果把原有标签全部照搬到改写文本上，新增样本就可能带来错误的监督。

针对这一问题，本章提出关系影响域约束的增强与成对学习方法，分三步进行：首先确定一处改写可能影响的组件和关系（即关系影响域），并在字符坐标上把全部组件迁移到改写文本中；然后分别审核组件和关系，凡是状态改变、无法判定或未经审核的，都不参与增强侧的监督；最后在原文和改写文本之间，对可靠的组件和关系施加成对的一致性约束。

为便于叙述，本章把同一篇文档的原文和改写版本称为不同的“视图”，把可以单独决定是否参与监督的一项判断称为一个“因素”，它可以是一个组件的类型，也可以是一组端点之间的关系状态。成对学习要求模型对原文和改写文本中相互对应的可靠因素给出一致的预测。

由于可靠因素决定了哪些标签参与学习，而成对项只在这些因素上施加一致性约束，在增强数据和掩码固定的情况下，就可以单独衡量成对项带来的增益。

本章主要符号及其含义如下。

符号	含义	定义位置
x、x'	原文及其改写文本	2.1.2
A	被改写组件的集合	3.3.1
D_A	关系影响域：可审核因素中至少一个端点位于 A 内的因素	3.3.1
J_A	实际审核的因素集合，包括受影响正关系和抽样的 NONE	3.3.3
φ	原文组件到改写组件的对应映射	3.3.2
m_C、m_R	组件与关系因素的可靠性掩码	3.3.3
Ω_{sem}	可审核的因素集合，排除语义未知的多前提子集	3.3.3

3.2 总体框架与基础模型

整体框架分为增强构造和参数学习两个阶段。构造阶段以训练文档及其标注为输入，输出改写后的全文、改写前后组件的对应关系φ以及可靠因素的掩码。学习阶段保留原文的完整生成监督，增强文本只使用通过审核的因素，具体结构见 3.4 节图 3-2。类型条件 LoRA、线索提示和句子监督沿用 MCR-BR 的配置，本章新增的是关系影响域约束、可靠因素监督和成对学习目标。

增强生成器 A、自动审核器 V 和抽取生成器 G 分别负责构造改写文本、审核监督和抽取论辩结构（见表 2-6），三者通过组件对应关系和因素掩码衔接。

因素掩码是随监督一起保存的 0/1 标记：1 表示该因素参与增强侧的监督和对齐，0 表示不参与。掩码不遮蔽输入文字，也不删除原始标注，组件和关系的掩码分别保存。

抽取生成器采用 Qwen3.5-9B 的文本部分，共 32 层，隐藏维度为 4096[50]。全局分支和结论专项分支两条 LoRA 挂载在 8 个全注意力块的 q/k/v/o 投影上，均取$r=16$、$\alpha=32$、dropout=0.05；其余 24 个线性注意力块、前馈层和视觉编码器保持冻结[51]。对投影矩阵W_0，定义

$$h'_t = W_0 h_t + \frac{\alpha}{r} B_g A_g h_t + g_t \frac{\alpha}{r} B_c A_c h_t,\ A_\cdot \in \mathbb{R}^{r \times d_{\text{in}}},\ B_\cdot \in \mathbb{R}^{d_{\text{out}} \times r}. \tag{3-1}$$

其中下标 g、c 分别表示全局分支和结论分支，h 和 h′ 为位置 t 的输入和输出表示。

全局分支作用于所有位置，结论分支由门控 $g_t \in \{0,1\}$ 控制。模型对每个组件依次输出 id（编号）、type（类型）和 span（原文片段）三个字段。当某个组件的类型字段已输出为结论类（AAEC 中为 Claim 或 MajorClaim，CDCP 中为 Policy 或 Value）时，门控在该组件的后续字段上开启，在组件结束时关闭；其余位置以及关系部分均有 $g_t = 0$。门控只依据已生成的前缀，训练时也不读取后续答案。

当文本中出现 therefore、thus、in conclusion、consequently、hence、to conclude 这六类结论线索词时（不区分大小写，按词边界匹配），在输入嵌入前插入四个可训练的提示向量，否则不插入[33]。原文和增强文本分别判断是否触发。线索词只用于触发提示，不直接决定组件标签[40]。

生成目标对回答部分的全部 token（含结束符 EOS）取平均，聊天模板和提示向量不计入损失：

$$L_{\text{gen}}(x, G) = -\frac{1}{T_y}\sum_{t=1}^{T_y} \log p_\theta(y_t \mid x, y_{<t}). \tag{3-2}$$

句子辅助任务沿用 MCR-BR 的设置：按句末标点切分句子，对每个句子的末层表示做均值池化，经线性层和 sigmoid 得到该句含有结论的概率 $\hat{z}_i$；若句子与结论类组件有重叠，则 $z_i = 1$，否则为 0。句子损失与生成损失共同构成原文的基础监督目标：

$$L_{\text{sent}} = -\frac{1}{N_s}\sum_{i=1}^{N_s}\left[z_i \log \hat{z}_i + (1 - z_i)\log(1 - \hat{z}_i)\right], L_{\text{IC}} = L_{\text{gen}} + \lambda_{\text{sent}} L_{\text{sent}}. \tag{3-3}$$

其中 $\lambda_{\text{sent}} = 0.5$。句子头只用于辅助表示学习。下面 3.3 节介绍增强文本的构造，3.4 节介绍在基础监督之上加入的可靠因素监督和成对目标。

3.3 关系影响域与可靠增强样本构造

3.3.1 改写范围与关系影响域

本章不改变组件类型和关系标注，只替换部分已标注组件的文字来构造增强文本。被替换的组件构成改写集合，它们可以分布在不同的段落中。下文所说的“内部”和“跨边界”，是按关系的端点是否都在改写集合中来区分的，与句子或段落无关。

本章把允许替换文字的组件片段称为“槽位”，把文字保持不变的其他组件称为“只读组件”。由于前面的改写可能改变文本长度，只读组件的字符位置也要随之更新。下文的“正关系”指带有明确标签（如 supports、attacks）的关系，与表示无关系的 NONE 相对。

表 3-1 AAEC essay001 的原生组件与关系因素

组件	原生类型	字符区间	原文
T3	Claim	[591,714)	through cooperation, children can learn about interpersonal skills which are significant in the future life of all students
T4	Premise	[716,851)	What we acquired from team work is not only how to achieve the same goal with others but more importantly, how to get along with others
T5	Premise	[853,1086)	During the process of cooperation, children can learn about how to listen to opinions of others, how to communicate with others, how to think comprehensively, and even how to compromise with other team members when conflicts occurred
T6	Premise	[1088,1191)	All of these skills help them to get on well with other people and will benefit them for the whole life
T7	Claim	[1332,1376)	competition makes the society more effective

如表 3-1 所示，T4、T5、T6 都以 supports 关系指向 T3，而 T4 与 T7 之间没有关系。假设改写集合为 A={T3,T4}，那么 T4→T3 是内部正关系，T5→T3 和 T6→T3 是跨边界正关系，T4→T7 是跨边界 NONE。这个集合只用于说明概念；按默认规则以 T3 为中心时，所有指向 T3 的源组件 T4、T5、T6 都会进入改写集合。

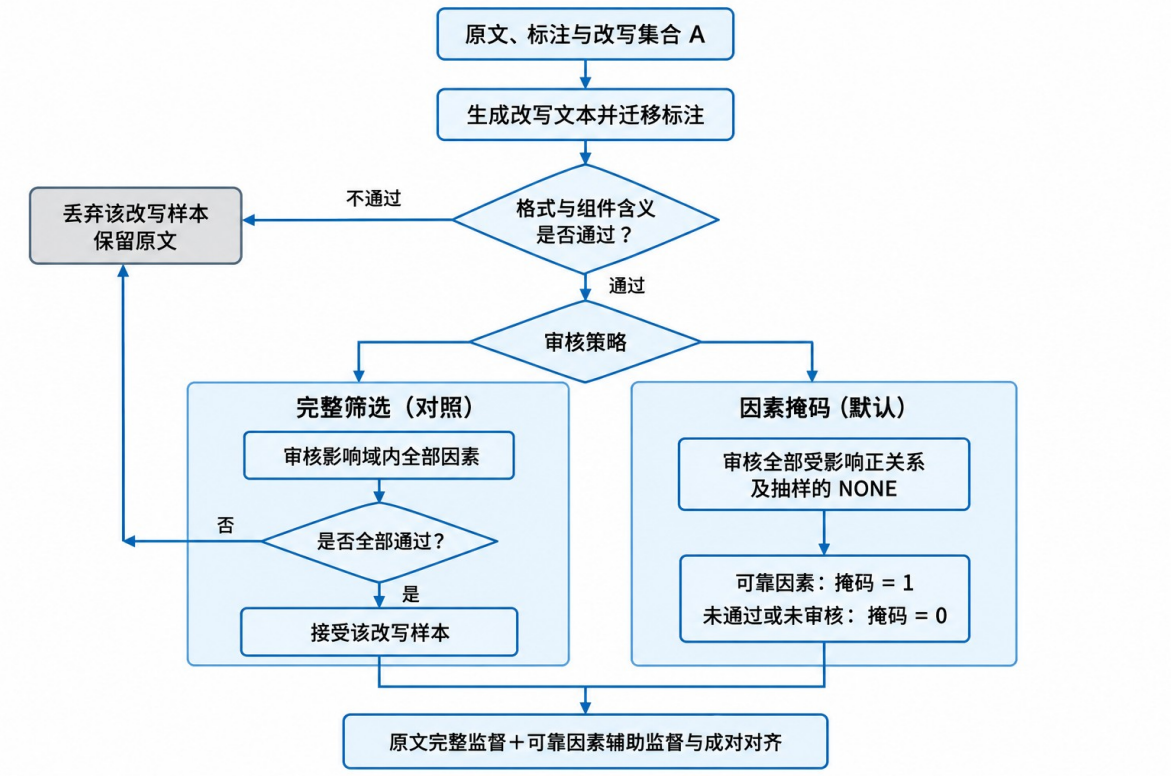


图 3-1 因素掩码与完整筛选两种策略

图 3-1 中，“内部 / 跨边界”描述关系端点相对于改写集合的位置，“正关系 / NONE / 语义未知”描述因素的状态。默认策略保留通过审核的组件，只屏蔽不确定的关系监督；完整筛选策略则只要有一个因素未通过审核，就丢弃整个改写样本。

每篇训练文档选定一个改写中心。AAEC 优先从 Claim 和 MajorClaim 中选，CDCP 优先从 Policy 和 Value 中选，选择方法见附录 A.1。同一篇文档的所有改写样本使用同一个中心。

改写集合A由中心组件和所有指向中心的关系的源组件组成，不再继续向外扩展，其余组件均为只读组件。中心没有入边时，只改写中心本身。

每篇文档最多尝试生成四次，最多接受两个改写样本，原始样本始终保留。若槽位相互重叠或输入超过上下文长度上限，则跳过该文档的增强。

记 $\Omega(C)$ 为所有合法端点组合构成的集合，每个关系因素 $\omega=(S,v)$ 由非空源组件集合 S 和目标组件 v 组成。AAEC 中 $|S|=1$，因此枚举所有合法的有向组件对即可。因素标签 y_ω 表示该端点组合的关系状态，没有标注关系的组合记为 NONE。

CDCP 中的多前提关系 $(\{c_{i_1},\dots,c_{i_k}\},c_j,\ell)$ 保持原样，其中 $\ell\in\{\text{Reason},\text{Evidence}\}$。源组件按原文顺序排列，整条关系作为一个对象，不拆成二元关系。

对于 CDCP，候选端点组合包括全部金标关系的端点组合，以及按源范围规则补充的、最多含三个源组件的组合；源组件超过三个的金标关系同样完整保留。

设 $V(\omega)=S\cup\{v\}$ 为因素 ω 的全部端点，改写集合 A 的完整关系影响域定义为

$$D_A=\{\omega\in\Omega_{\text{sem}}(C):V(\omega)\cap A\neq\varnothing\}. \tag{3-4}$$

即至少有一个端点落在改写集合中的全部因素。其中 $\Omega_{\text{sem}}(C)=\Omega(C)\setminus U_{\text{sem}}$，语义未知集合 U_{sem}见 3.3.3 节（AAEC 中为空）。二元情形下即 $\{(u,v):u\in A\vee v\in A,(u,v)\in\Omega_{\text{sem}}(C)\}$。全部端点都在 A 中的称为内部因素，只有部分端点在 A 中的称为跨边界因素。改写还可能通过指代等上下文影响只读组件之间的关系，这部分由附录 B.2 的人工抽查评估。

3.3.2 改写生成与标注迁移

增强生成器 A 使用不加载任务 LoRA 的 Qwen3.5-9B（解码设置见附录 A.4），跨骨干实验也共用它生成的增强文本。其输入包括训练文档全文、可改写的槽位及其类型、只读组件列表和影响域标签。模型只返回从组件编号到替换文本的 JSON 映射，不能新增组件，也不能修改类型或关系。

程序按原始字符区间替换槽位文字，然后对整篇文档重新分词，并建立改写前后的组件对应关系

$$\varphi:C\to C',\quad (d,b_c,e_c,t_c)\mapsto(d',b_c',e_c',t_c). \tag{3-5}$$

改写后的全文是一个新的文本版本，记为 d′。回填文字后，程序先更新全部组件的字符区间（只读组件随前文长度变化而平移），再重新生成分词和子词表示。因此，φ是组件之间的一一对应，而不是字符或 token 位置之间的对应。所有关系的端点都按φ迁移到新文本上。若出现槽位重叠、坐标无法对应或端点无法迁移，则丢弃该改写样本，只保留原始样本。

下面 3.3.3 节介绍如何审核迁移后的标注，3.3.4 节再通过真实文档的案例展示坐标迁移和审核的具体过程。

3.3.3 语义审核与因素掩码

所有改写样本首先要通过格式检查，包括 JSON 格式、槽位编号、坐标对应和关系端点引用。之后，审核器 V 分别读取原文和改写文本，在看不到原标签的情况下输出组件类型或关系状态，再由程序与原标注比较。组件审核同时检查含义、论辩角色、指代、否定和情态；只要有组件含义改变、无法判定或输出不合法，就丢弃该改写样本。

审核器 V 同样使用不加载抽取 LoRA 的 Qwen3.5-9B，采用贪心解码（设置见附录 A.4），跨骨干实验共用同一审核结果。

组件全部通过审核后，再审核关系。关系审核集合 $J_A \subseteq D_A$ 包括全部受影响的正关系，以及从内部 NONE 和跨边界 NONE 中各随机抽取的至多 4 项。CDCP 中被定义为语义未知的真子集不作为 NONE 负例。若无法审核完全部正关系，该样本不参与关系学习，但通过审核的组件仍可用于组件监督。未经审核的 NONE 不参与监督。

只有当审核器认可原标注、改写后状态不变且端点对应有效时，关系掩码才取 $m_R(\omega)=1$；若原标签有分歧、状态改变或无法判定，掩码为 0。组件掩码 $m_C(c)$ 单独保存。关系所连接的只读组件同样需要在全文上下文中审核，因为文字不变并不能保证其论辩角色不变。关系掩码为 1 还要求其所有端点的组件掩码均为 1。满足这些条件的因素称为“可靠因素”，审核质量见 3.6.3 节。

“待定”指审核过但无法确定原状态是否保持，“未审核”指没有对该因素做审核，二者的增强侧掩码都为 0，原关系标签不变。“语义未知”是另一种情况，见下文。

默认策略保留通过审核的组件，不会因为某一条关系未通过审核就丢弃全部组件，也不会把这条关系改标为 NONE；增强侧的损失只使用掩码为 1 的标签。作为对照，完整筛选策略检查影响域内的全部因素，只要有一个改变或待定就丢弃整个样本。3.6 节比较两种策略的监督覆盖、训练效果和成本。

严格评价要求预测关系与金标关系完全一致。例如，金标为 $h=(\{c_1,c_2\},c_3,\text{Reason})$ 时，预测 $(\{c_1\},c_3,\text{Reason})$ 因源集合不同而不能匹配。但这并不意味着c_1单独与 c3 没有关系：c_1和c_2共同构成理由，不能推出c_1单独既不支持也不反对 c3。

因此，本文为训练阶段的关系头定义语义未知集合 U_{sem}：对于一条已标注的多前提关系，若其源集合的某个非空真子集没有单独的正关系标注，就将该真子集与目标构成的因素列为语义未知。可审核的因素集合为 $\Omega_{\text{sem}}=\Omega \setminus U_{\text{sem}}$，完整影响域和抽样都在其中定义。

无论原文还是改写文本，关系头都不把 U_{sem} 当作 NONE 负例，其监督和对齐掩码均为 0；原文的完整生成目标仍保留原始的多前提关系。与此不同，第四章的评分器判断的是对象是否与标注完全匹配，因此可以把这类真子集作为“不匹配”的负例，但这并不表示其语义上没有关系。

记通过审核、且端点组件也都通过审核的关系集合为R_A，则各集合满足

$$R_A \subseteq J_A \subseteq D_A \subseteq \Omega_{\text{sem}},\quad \Omega_{\text{sem}}=\Omega \setminus U_{\text{sem}}. \tag{3-6}$$

即完整影响域D_A是定义范围，J_A是实际审核的范围，只有通过审核的R_A才进入增强侧的关系损失。默认策略下J_A通常小于D_A；完整筛选策略要求$J_A=D_A$。语义未知集合U_{sem}始终不在两者之中。图 3-1 的两条路径对应这一层级关系。

3.3.4 标注迁移与改写案例

本节以 AAEC 训练文档 essay001 为例说明坐标迁移和审核范围。以 T3 为中心，改写集合为 A={T3,T4,T5,T6}。为了单独检验坐标迁移是否正确，先做一个确定性的测试：把四个槽位中的第一个空格改成两个空格，其余字符不变。然后再用自然改写的例子说明语义审核。原文片段见表 3-1。

表 3-2 essay001 代表组件的实际坐标迁移

ID 及类型	原字符区间	新字符区间	文字变化
T3 / Claim	[591,714)	[591,715)	首次空格加倍
T4 / Premise	[716,851)	[717,853)	首次空格加倍
T5 / Premise	[853,1086)	[855,1089)	首次空格加倍
T6 / Premise	[1088,1191)	[1091,1195)	首次空格加倍
T8 / Premise	[1212,1301)	[1216,1305)	逐字保留
T2 / MajorClaim	[2154,2231)	[2158,2235)	逐字保留

表中坐标为左闭右开的字符区间。四个槽位各增加了一个空格，后面的只读组件随之平移，例如 T8 和 T2 都平移了 4 个字符。程序核对了全部 11 个组件的文字切片，并按φ迁移了全部原有关系。

表 3-3 essay001 的审核范围与损失掩码

监督对象	检查或覆盖结果	掩码	增强侧用途
11 个组件	规范化空白后逐字一致	m_C=1	组件头；A^+中 4 项参与对齐
T4/T5/T6→T3 supports	3 项内部正因素全部检查	m_R=1	正关系监督及对齐
抽取的内部 NONE 与边界 NONE	各 4 项，共 8 项	m_R=1	NONE 监督及对齐
影响域内其余 57 项	未纳入审核子集	m_R=0	不进入增强关系损失
影响域外 42 项	不在D_A	m_R=0	保留原文监督

在这个例子中，候选因素共 110 项，影响域D_A包含 68 项，实际审核 11 项，其余 57 项未审核。未审核因素的掩码为 0，不参与增强侧的关系损失，但原关系标签保持不变。

作为反例，把同一文档中 T7 的原文“competition makes the society more effective”填入 T3 的位置，由于内容与 T3 不同，该样本在一致性检查中被拒绝。

表 3-4 给出两个自然改写的例子。例 A 改写了 T3、T4、T5 和 T6 四个槽位；例 B 与例 A 相同，只是把 T3 改成了否定表达。

表 3-4 essay001 自然改写与语义判断

案例组件	自然改写	语义判断
A / T3	by cooperating, children can acquire interpersonal skills that will be important in their future lives	保留原含义
A / T4	Teamwork teaches us how to pursue a shared goal with others and, more importantly, how to get along with them	保留原含义
A / T5	Cooperating helps children learn to listen to others' opinions, communicate, think comprehensively, and even compromise with teammates when conflicts arise	保留原含义
A / T6	These skills help children get along with others and benefit them throughout their lives	保留原含义
B / T3	cooperation cannot help children acquire interpersonal skills that will be important in their future lives	否定原结论

例 A 保持了原有的论证功能：T3 仍然主张合作有助于儿童学习人际交往技能，T4 说明团队协作需要共同目标和相处能力，T5 列举具体技能，T6 说明持续的收益。四个组件的含义和 T4、T5、T6 到 T3 的三条 supports 关系都没有改变，因此它们都可以参与增强侧监督，掩码为 1。其余的 NONE 和跨边界因素仍需逐项审核，不能因为这三条关系成立就默认通过。

例 B 中的 cannot 把 T3 从“可以学会”变成了“不能帮助学会”，否定了原来的结论，因此组件审核会丢弃整个样本，只保留原文和其他已接受的样本。如果组件都通过审核，只有某条关系改变或无法判定，默认策略只把这条关系的掩码置为 0，其他可靠因素照常使用，也不会把它改标为 NONE。

回填改写文本后，程序核对了全部 11 个组件的切片和 6 条原有关系的端点迁移。在例 A 中，T3 从[591,714)迁移到[591,693)，T4 从[716,851)迁移到[695,804)。

3.4 成对组件与关系学习

改写样本通过审核后，模型就可以利用原文与改写文本中可靠的对应关系进行学习。以表 3-1 为例，T4 改写后若通过组件审核，其 Premise 标签就可以用于增强侧监

督；而 T4→T3 的 supports 和 T4→T7 的 NONE 还需分别通过关系审核。成对目标比较这些可靠因素在两个视图中的类别分布，允许两边的词序、长度和位置不同；原始标签则同时为两个视图提供监督。学习架构如图 3-2 所示。

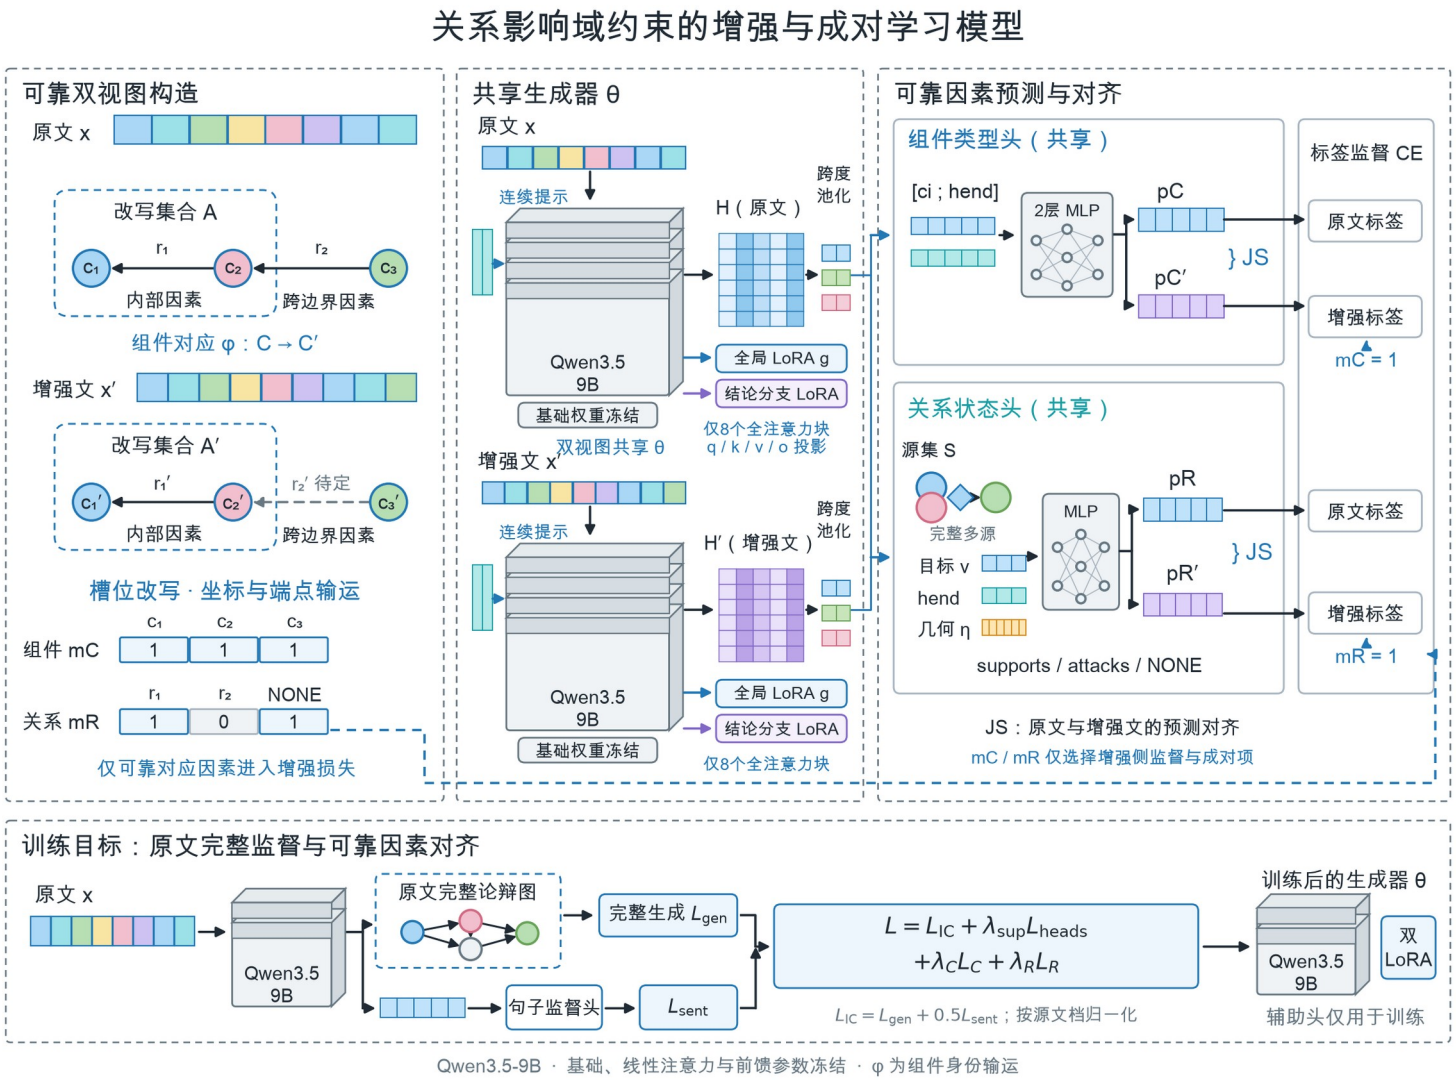


图 3-2 关系影响域约束的成对学习模型

如图 3-2 所示，原文和增强文本经过同一个生成器，组件对应关系 φ 把两个视图中的组件类型分布和关系状态分布联系起来。生成目标、句子监督和新增的辅助目标共同更新可训练的参数，基础模型权重保持冻结，辅助头只在训练时使用。

3.4.1 辅助预测头与成对对齐

组件类型头和关系状态头都是辅助分类器，它们读取生成器对输入文本的隐藏表示，并用金标跨度定位要预测的组件。抽取生成器的输入只有任务指令和文本本身，金标的槽位、类型和关系只用于构造训练样本和监督信号，不作为生成器的输入。

令 h_i^x 为第 i 个输入子词的隐藏状态，$B_x(c)$ 为组件 c 的字符跨度所覆盖的子词集合，h_{end}^x 为输入结束、回答开始之前位置的隐藏状态。组件表示和类型分布定义为

$$u_c^x = \text{MeanPool}_{i \in B_x(c)} h_i^x,\ p_C^x(c) = \text{softmax}\, f_C\left(\left[u_c^x ; h_{\text{end}}^x\right]\right). \tag{3-7}$$

由于是因果模型，靠前的 token 只能看到左侧的上下文；拼接 h_{end}^x 可以为组件表示补充全文的信息。组件头的输入不包含金标类型。

其中 MeanPool 表示对组件覆盖的子词表示取均值，方括号表示向量拼接。组件头输出类型分布，关系头输出一组端点之间的关系状态分布。

关系头显式区分源组件和目标组件：

$$p_R^x(S, v) = \text{softmax}\, f_R\left(\left[\text{Pool}\left(\{u_c^x : c \in S\}\right); u_v^x ; h_{\text{end}}^x ; \eta(S, v)\right]\right), \tag{3-8}$$

其中，f_C、f_R为两层感知机，Pool 对各源组件的表示取均值。η为位置特征，由源组件数与六个位置统计量组成，后者包括源组件起点的最小值与均值、终点的最大值与均值以及目标的起止位置；位置先由字符区间换算为评价 token 坐标，再除以文档的 token 数进行归一化，且不包含待预测的关系标签。二元关系只有一个源组件，多前提关系以完整的源集合和目标为预测对象，状态中包含 NONE。两个辅助头在验证和测试时都会移除。

组件对齐的范围包括被改写的组件，以及通过正关系与它们相连的只读组件：

$$A^+ = A \cup \bigcup_{\omega \in D_A,\ y_\omega \neq \text{NONE}} V(\omega). \tag{3-9}$$

NONE 因素只参与关系对齐，不会把距离较远的组件也纳入组件对齐。对于通过组件审核的改写文本 x'，下式中的 A^+ 还要与 $\{c : m_C(c) = 1\}$ 取交集。组件对齐损失为

$$L_C^{\text{align}}(x, x') = \frac{1}{\left|A^+\right|} \sum_{c \in A^+} \text{JS}\left(p_C^x(c), p_C^{x'}(\varphi(c))\right), \tag{3-10}$$

两个视图都保留梯度，共同参与参数更新。

把通过审核的关系因素集合 $\{\omega\in J_A:m_R(\omega)=1\}$ 分为正关系组 D_+ 和 NONE 组 D_0，记非空的组为 $B=\{b\in\{+,0\}:|D_b|>0\}$。关系对齐先在组内平均，再在组间平均：

$$L_R^{\text{align}}(x,x')=\frac{1}{|B|}\sum_{b\in B}\frac{1}{|D_b|}\sum_{\omega\in D_b}\text{JS}\left(p_R^{x}(\omega),p_R^{x'}(\varphi(\omega))\right). \tag{3-11}$$

这样可以避免数量较多的 NONE 因素主导关系对齐损失。没有可靠关系时，关系对齐项为 0，但原文全部关系的生成监督不受影响；A^+ 为空时，组件对齐项也为 0。

仅靠对齐是不够的，因为两个视图可能犯同样的错误，此时 JS 散度同样很小，所以还需要用标签进行约束。对于视图 x，记 M_C 和 M_R 分别为受监督的组件集合和关系因素集合，M_R^+ 和 M_R^0 分别为其中的正关系和 NONE，$B_M=\{b\in\{+,0\}:|M_R^b|>0\}$。辅助监督损失定义为

$$S(x;M_C,M_R)=\frac{1}{|M_C|}\sum_{c\in M_C}\text{CE}\left(p_C^{x}(c),t_c\right)+\frac{1}{|B_M|}\sum_{b\in B_M}\frac{1}{|M_R^b|}\sum_{\omega\in M_R^b}\text{CE}\left(p_R^{x}(\omega),y_\omega\right), \tag{3-12}$$

其中 CE 为交叉熵，t_c 为组件的原始类型。$M_C=\varnothing$ 时组件项为 0，$B_M=\varnothing$ 时关系项为 0，两项等权相加。原文取 $S(x,G)=S\left(x;C,\Omega_{\text{sem}}(C)\right)$，即全部组件和可审核的关系因素；改写文本取 $S_m(x',\varphi(G))=S\left(x';\{\varphi(c):m_C(c)=1\},\{\varphi(\omega):\omega\in J_A,m_R(\omega)=1\}\right)$，即只使用掩码为 1 的组件和关系。这样，分布对齐的同时也受到原始标注的约束。

3.4.2 损失归一化与参数更新

设源文档 d 有 m_d 个被接受的改写样本。原文承担完整的论辩图生成监督和句子监督；改写文本只作为输入，由于其中可能含有未审核的关系，不把它的完整论辩图作为生成目标。辅助监督损失为

$$L_{\text{heads},d}^{\text{sup}}=\frac{S(x_d,G_d)+\sum_{j=1}^{m_d}S_{m_j}\left(x'_{dj},\varphi_j(G_d)\right)}{1+m_d}. \tag{3-13}$$

成对项先在每个非空因素组内平均，再在同一源文档的各改写样本之间平均。总损失为：

$$L_d=L_{\text{IC}}(x_d,G_d)+\lambda_{\text{sup}}L_{\text{heads},d}^{\text{sup}}+\lambda_C\acute{L}_{C,d}^{\text{align}}+\lambda_R\acute{L}_{R,d}^{\text{align}}. \tag{3-14}$$

默认取 $\lambda_{\text{sup}}=1$，$\lambda_C=\lambda_R=0.5$。没有改写样本时只保留原文的各项损失；有改写样本但没有可靠关系时，关系对齐项为 0，组件学习照常进行。被接受样本中的改写组件都

已通过审核，m_C 均为 1，因此计入 m_d 的样本不会出现空的组件项。每个批次内按源文档取平均，避免改写样本较多的文档获得过高权重。

以 3.3.4 节的例子说明：一个被接受的改写样本使m_d=1，原文和改写文本的辅助监督各占 1/2。A^+={T3,T4,T5,T6}，组件对齐对这 4 个组件取平均；关系对齐中有 3 项正关系和 8 项 NONE，分组平均后，在λ_R=0.5 时每项正关系和每项 NONE 的最终权重分别为 1/12 和 1/32。

按 $1+m_d$ 取平均使每篇源文档的辅助监督总权重固定，原文在其中的占比为 $1/(1+m_d)$，而原文的生成损失 L_{IC} 不变。完整筛选和因素掩码接受的样本数量通常不同，因此二者的比较也包含原文占比的差异；成对学习的消融则固定了样本和掩码，不受此影响。

生成损失和句子损失更新原有模块，组件头、关系头和成对项通过共享的输入表示更新全局 LoRA；结论分支只随相应的生成路径更新。基础权重保持冻结，辅助头在评价时移除。第四章的推理评分器另外训练，不使用这些辅助头的输出概率。

3.5 算法及性质

算法 3-1 包括增强构造和参数学习两个阶段：先在固定预算内生成并筛选改写样本，再按源文档归一化进行训练。两个阶段都只使用训练集，验证集用于参数选择和早停，测试集标签不参与训练过程。

算法 3-1 关系影响域增强与成对学习

输入：训练文档及其标注 D_{train}，增强生成器 A 与自动审核器 V，

每文档尝试上限 B_{try}、接受上限 B_{accept}，训练更新上限 U，

审核模式 mode ∈ {FactorMask, FullFilter}。

输出：训练后的生成器 θ，以及增强样本和组件对应关系。

01 检查训练数据划分、去重分组与标注坐标

02 for 每篇源文档 d ∈ D_{train} do

03 保留原文 x_d 和完整金标图 G_d；令 $\text{Views}_d = \varnothing$

04 按 3.3.1 节选择改写中心及其全部源组件；无法处理则跳过该文档

05 构造候选因素集合 Ω(C_d)，排除语义未知因素得到 Ω_{sem}，并确定改写集合 A

06 构造完整影响域 D_A；令 attempts = 0

07 while attempts < B_{try} 且 $|\text{Views}_d| < B_{\text{accept}}$ do

08 attempts ← attempts + 1；生成组件槽位的替换文本

算法 3-1 关系影响域增强与成对学习

回填全文、重新分词，建立全部组件的双射 φ
if 格式、槽位、坐标或端点检查失败 then
  拒绝该改写样本并记录原因
  continue
end if
检查组件的含义与论辩角色是否改变
if $D_A \neq \varnothing$ then
  if mode = FullFilter then $J_A \leftarrow D_A$（无法全部审核则拒绝该样本）
  else $J_A \leftarrow$ 全部受影响正关系 $\cup$ 抽样的内部及跨边界 NONE
  逐项审核 J_A 中因素在原文和改写文本中的状态，得到关系掩码 m_R
end if
if 组件含义改变或无法判定，或完整筛选下有因素未通过 then
  拒绝该改写样本并记录原因
  continue
end if
将改写文本、迁移后的标注 $\varphi(G_d)$、对应关系 φ 和因素掩码加入 Views_d
end while
保存 Views_d（为空时仅使用原文）
end for
for step = 1, …, U do
按源文档采样训练批次，读取原文及其被接受的改写样本
计算原文的生成损失和句子监督损失
计算原文可审核因素及改写文本中掩码为 1 的因素的辅助监督损失
按 φ 计算可靠因素上的成对对齐损失（无可靠因素时为 0）
按改写样本和源文档两级归一化各项损失
反向传播，更新 LoRA 与辅助头参数（基础模型权重冻结）
if 满足早停条件 then
  break
end if
end for
返回生成器（评价和测试时移除辅助头）

性质一（标注迁移保持结构）。若改写槽位互不重叠、φ 是组件之间的双射，且组件类型和每条完整关系都按 φ 迁移，则 G 与 $\varphi(G)$ 具有相同的组件数、组件类型以及带方向和标签的关系结构。证明：双射保证每个原组件恰好对应一个新组件；关系

的全部端点逐一映射，所以关系既不会增加也不会丢失，用逆映射即可恢复原图。需要注意，该性质只保证标注结构不变，改写后的文本是否仍然支持这些标签，要由 3.3.3 节的语义审核来判断。

性质二（单因素预测稳定的充分条件）。对某一因素，设原视图中的正确类别为 y，预测分布 p 的间隔为 $\gamma = p_y - \max_{k \neq y} p_k > 0$。若增强视图的分布 q 满足 $\| p - q \|_\infty < \gamma / 2$，则 $\operatorname{argmax} q = y$。这是因为对任意 $k \neq y$，都有 $q_y - q_k > p_y - p_k - \gamma \geq 0$。也就是说，只要两个视图的预测分布足够接近，增强视图就能保持原视图的正确预测，这正是成对一致性约束的出发点。

性质一保证了标注迁移不破坏论辩结构，性质二说明了一致性约束为何有助于预测稳定。下一节通过实验检验这些设计在完整论辩图抽取上的效果。

3.6 实验结果与分析

3.6.1 实验设置与对照组

为了验证本章方法的有效性，本节在 AAEC 和 CDCP 上开展实验，主要回答以下三个问题：（1）本文的训练方法能否提升端到端抽取性能；（2）在增强数据相同时，成对目标本身能带来多少增益；（3）增强与审核的质量和成本如何。实验结果见表 3-6 至表 3-11。对照组设置如下：T0I0 为 MCR-BR 基线；Heads 在 T0I0 基础上只增加辅助头；Plain 和 QOS 分别使用普通改写增强和槽位化增强；NoPair 使用可靠因素监督但不做成对对齐；CompPair 只对齐组件；T1I0（本文方法）同时对齐组件和关系；FullFilter 使用完整影响域筛选；RandomCenter 随机选择改写中心。九组使用相同的骨干、源文档访问次数和更新步数，推理均采用 I0。各增强组的接受样本规模相同（AAEC 500 个，CDCP 900 个），成本包括生成失败、被拒样本和审核的开销。

其中，NoPair、CompPair 与 T1I0 使用完全相同的改写样本和关系掩码，三者的差异只在学习目标上。

表 3-5 训练对照组的设置

配置	增强	可靠因素监督	组件对齐	关系对齐	与完整成对配置使用相同输入
T0I0	无	无	无	无	—
Heads	无	原文	无	无	—
Plain／QOS	有	构造方法各自规则	无	无	仅匹配规模
NoPair	有	有	无	无	是
CompPair	有	有	有	无	是
T1I0	有	有	有	有	是
FullFilter／RandomCenter	有	有	有	有	独立可选策略

3.6.2 主要结果与消融分析

表 3-6 不同训练配置的抽取性能（推理均为 I0）

配置	AAEC 组件 F1	AAEC 关系 F1	CDCP 组件 F1	CDCP 关系 F1
T0I0：MCR-BR 基线	85.64 ± 0.07	65.69 ± 3.50	80.40 ± 1.24	41.79 ± 2.65
基线 + 辅助头	85.75 ± 0.24	66.01 ± 3.37	80.76 ± 1.10	41.81 ± 3.01
普通增强	86.09 ± 0.28	65.95 ± 2.24	81.03 ± 1.14	41.57 ± 3.30
QOS 式适配	86.43 ± 0.21	66.65 ± 3.09	81.35 ± 1.49	42.54 ± 3.35
可靠对应，无成对	86.67 ± 0.21	66.85 ± 2.73	81.85 ± 1.26	42.51 ± 2.89
仅组件成对	87.19 ± 0.20	67.70 ± 3.13	82.50 ± 1.15	43.21 ± 3.46
T1I0：完整成对	87.85 ± 0.39	68.25 ± 2.08	83.46 ± 1.04	45.08 ± 2.73
完整筛选	87.61 ± 0.44	68.21 ± 2.71	83.16 ± 1.06	45.08 ± 3.02
匹配随机中心	87.24 ± 0.12	67.74 ± 2.96	83.00 ± 0.83	44.49 ± 3.52

在相同的 9B 骨干下，T0I0 在 AAEC 和 CDCP 上的严格关系 F1 分别为 65.69 和 41.79，T1I0 分别为 68.25 和 45.08，分别提高 2.56 和 3.30 个百分点，Holm 校正后的 p 值为 0.0175 和 0.0150，差异显著。三个种子上的提升均为正。

表 3-7 训练配置之间的关系 F1 配对差值

语料	比较	差值（百分点）	单项 95% CI	种子 17 / 29 / 43	p	类型
AAEC	T1I0 − T0I0	2.56	[0.92, 4.39]	1.26 / 2.34 / 4.07	0.0175	主要 / Holm

语料	比较	差值（百分点）	单项 95% CI	种子 17 / 29 / 43	p	类型
AAEC	T1I0 − NoPair	1.39	[0.28, 2.46]	1.02 / 0.99 / 2.17	0.0175	主要 / Holm
AAEC	CompPair − NoPair	0.84	[0.04, 1.90]	0.79 / 1.43 / 0.31	0.0770	探索／原始 p
AAEC	T1I0 − CompPair	0.55	[-0.78, 1.90]	0.24 / -0.44 / 1.86	0.4018	探索／原始 p
AAEC	NoPair − QOS	0.20	[-0.40, 0.89]	-0.12 / 0.12 / 0.59	0.4993	探索／原始 p
AAEC	NoPair − Plain	0.90	[0.06, 1.75]	1.30 / 1.04 / 0.36	0.0415	探索／原始 p
AAEC	FullFilter − T1I0	-0.04	[-0.86, 0.60]	0.35 / 0.32 / -0.79	0.9015	探索／原始 p
AAEC	RandomCenter − T1I0	-0.51	[-1.71, 0.74]	-0.35 / 0.44 / -1.62	0.3838	探索／原始 p
CDCP	T1I0 − T0I0	3.30	[1.56, 5.17]	2.81 / 3.50 / 3.58	0.0150	主要 / Holm
CDCP	T1I0 − NoPair	2.57	[1.05, 4.23]	3.25 / 2.34 / 2.12	0.0175	主要 / Holm
CDCP	CompPair − NoPair	0.69	[0.00, 1.96]	0.74 / 1.34 / 0.00	0.1584	探索／原始 p
CDCP	T1I0 − CompPair	1.88	[0.54, 3.56]	2.51 / 1.00 / 2.12	0.0175	探索／原始 p
CDCP	NoPair − QOS	-0.03	[-1.47, 1.99]	-0.74 / -0.44 / 1.10	0.9645	探索／原始 p
CDCP	NoPair − Plain	0.94	[-0.49, 2.98]	0.00 / 0.64 / 2.19	0.2359	探索／原始 p
CDCP	FullFilter − T1I0	-0.00	[-0.85, 0.94]	-0.37 / 0.36 / 0.00	0.9885	探索／原始 p
CDCP	RandomCenter − T1I0	-0.59	[-1.86, 0.40]	-1.40 / 0.36 / -0.73	0.3118	探索／原始 p

在改写样本、掩码和辅助头都相同的条件下，T1I0 与 NoPair 的差值反映了成对目标的作用。AAEC 上提高 1.39 个百分点（95% 置信区间 [0.28, 2.46]，Holm p=0.0175），CDCP 上提高 2.57 个百分点（95% 置信区间 [1.05, 4.23]，Holm p=0.0175），三个种子的差值均为正，且 CDCP 上的增益更大。由于这组对照固定了数据构造，增益可以归因于成对目标本身，而不是样本数量或掩码的变化。

其余对照的结果见表 3-7。可靠对应构造比普通增强在 AAEC 上提高 0.90 个百分点（未校正 p=0.0415）。完整筛选与默认因素掩码的差值分别为−0.04 和 0.00 个百分点，说明丢弃整个样本并不比只屏蔽不可靠的关系更好，而后者保留了更多可用监督。随机选择中心在两个语料上都略低于固定中心，但差异不显著。

3.6.3 增强数据的人工审核

人工分层审核由两名审核员 A、B 和一名裁决人 C 完成（与自动审核器 V 无关）。A 和 B 分别把每个因素判为 stable（状态保持）、changed（状态改变）、

undecided（无法判定）或 original_disagreement（不认同原标注），C 先独立判断，再给出最终结论。三人先用 60 项培训材料统一标准，培训阶段的一致性κ为 0.86。组件审核覆盖被接受和被拒绝的样本；关系审核从训练增强池中分四层抽样，每层最多 300 项，不足 300 项时全部审核，抽样概率为$\pi_h=n_h/N_h$。增强器与自动审核器使用同一基础模型，可能具有相关偏差，因此另设上述人工分层审核作为独立参照。

表 3-8 和表 3-9 用 Wilson 区间[58]表示比例的置信区间，用 Cohen κ系数[59]表示审核员之间的一致性。

不安全率的分母是被接受的因素，漂移率的分母是可以判定且原标注有效的因素；undecided 和 original_disagreement 都不算作稳定。计算时按$1/\pi_h$加权，并以源文档为单位重采样 2000 次估计置信区间。

表 3-8 组件审核结果

语料	抽样	接受	不安全接受	不安全接受率	Wilson 95%	一致率	κ
AAEC	320	300	4	1.33%	[0.52, 3.38]	94.69%	0.690
CDCP	320	300	3	1.00%	[0.34, 2.90]	95.94%	0.755

表 3-9 关系因素的分层人工审核

语料／层	N_h	抽样 n	π	接受数	不安全接受数	不安全接受率	Wilson 95%	一致率	κ
AAEC／内部正关系	683	300	0.4392	280	3	1.07%	[0.37, 3.10]	96.00%	0.771
AAEC／跨边界正关系	153	153	1.0000	123	2	1.63%	[0.45, 5.74]	92.16%	0.804
AAEC／内部 NONE	877	300	0.3421	279	4	1.43%	[0.56, 3.63]	90.67%	0.591
AAEC／跨边界 NONE	2000	300	0.1500	266	1	0.38%	[0.07, 2.10]	94.67%	0.785
CDCP／内部正关系	315	300	0.9524	282	2	0.71%	[0.19, 2.55]	93.00%	0.606
CDCP／跨边界正关系	290	290	1.0000	249	4	1.61%	[0.63, 4.06]	94.14%	0.811
CDCP／内部 NONE	470	300	0.6383	277	5	1.81%	[0.77, 4.16]	93.00%	0.697
CDCP／跨边界 NONE	3251	300	0.0923	269	2	0.74%	[0.20, 2.67]	94.33%	0.776

由于同一篇源文档可以贡献多个样本和因素，记录之间并不独立。附录 B 表 B-3 给出了各层的源文档数和按源文档聚类重采样得到的置信区间。

跨边界关系需要单独检查，因为组件文字变化不大，也可能改变它与只读组件之间的联系。AAEC 的这一层共 153 项，全部进行了审核；在被接受的 123 项中有 2 项不安全，说明审核后仍存在少量残留错误。

表 3-10 增强数据的加权不安全率与漂移率

语料	审核因素／源组	未加权不安全率	加权不安全率	源聚类 95%	加权漂移率	漂移 95%	变化／可判定且原标注有效
AAEC	1053／257	1.05%	0.81%	[0.31, 1.45]	5.83%	[4.19, 7.60]	60／998
CDCP	1190／401	1.21%	0.91%	[0.26, 1.79]	5.98%	[4.06, 8.10]	68／1132

两个语料的加权漂移率分别为 5.83%和 5.98%，即约 6%的因素在改写后状态发生了变化，这说明直接沿用全部原标签确实会引入错误监督。对审核后被接受的关系因素，加权不安全率估计分别为 0.81%和 0.91%。这两项估计使用接受集作为分母，与总体漂移率的统计对象不同。

只读组件的上下文检查见附录 B.2。因素掩码可以保留已经判定可靠的部分，而完整筛选会丢弃更多样本，两者的训练效果见表 3-6。

3.6.4 训练成本与局限性

表 3-11 训练与增强成本（三个种子的 GPU 时间均值）

语料	配置	源文档访问数	更新步	接受改写样本数	尝试／接受生成 token 数（百万）	审核调用	GPU 小时	峰值 GiB
AAEC	T0I0	1595	50	0	0.00／0.00	0	2.45	27.65
AAEC	Heads	1595	50	0	0.00／0.00	0	2.80	29.76
AAEC	NoPair	1595	50	500	1.14／0.82	1210	4.50	35.19
AAEC	CompPair	1595	50	500	1.14／0.82	1210	4.72	36.77
AAEC	T1I0	1595	50	500	1.14／0.82	1210	5.12	36.42
CDCP	T0I0	2900	95	0	0.00／0.00	0	4.15	27.79
CDCP	Heads	2900	95	0	0.00／0.00	0	4.95	29.40
CDCP	NoPair	2900	95	900	2.02／1.35	2190	7.72	35.21
CDCP	CompPair	2900	95	900	2.02／1.35	2190	8.25	36.48
CDCP	T1I0	2900	95	900	2.02／1.35	2190	8.67	36.80

GPU 小时为两张 GPU 的耗时之和，显存为单卡峰值。各骨干的可训练参数量见表 5-7。

训练增益伴随着额外的计算成本。T0I0 在 AAEC 和 CDCP 上的平均训练时间分别为 2.45 和 4.15 GPU 小时，T1I0 为 5.12 和 8.67 GPU 小时，分别增加 2.67 和 4.52 GPU 小时，换来 2.56 和 3.30 个百分点的关系 F1 提升。增强与审核的一次性成本另见附录 B.3。

本方法的主要局限在于：改写文本可能表达流畅但监督状态已经改变，而审核后仍会残留少量错误；此外，改写还可能通过上下文影响只读组件，这部分由附录 B.2 的抽查评估。

3.7 本章小结

本章针对训练文本改写中的监督保持问题，提出了关系影响域约束的增强与成对学习方法。首先，通过关系影响域确定改写可能影响的组件与关系，并借助组件双射把原标注无损地迁移到改写文本上；然后，通过语义审核和因素掩码确定增强监督的范围，只让可靠的组件与关系参与学习；最后，在可靠因素上施加成对一致性约束，并按源文档归一化控制改写样本数量带来的权重差异。实验表明，该方法使严格关系 F1 在 AAEC 和 CDCP 上分别提高 2.56 和 3.30 个百分点；在固定增强样本和掩码时，成对目标本身带来 1.39 和 2.57 个百分点的提升，均通过多重比较校正。人工分层审核显示，被接受因素的加权不安全率低于 1%。

本章在训练阶段约束了跨视图的组件与关系预测。下一章转向推理阶段，研究在原文不变的情况下，如何修改预测组件并同步处理受影响的关系。

第四章 多候选驱动的依赖闭合论辩图修正

第三章从训练阶段出发，研究了文本改写后的监督保持问题。然而，即使模型训练得更好，生成的论辩图中仍会存在组件边界或类型错误，而这些错误又会牵连与之相连的关系。针对这一问题，本章研究推理阶段的预测图修正，提出多候选驱动的依赖闭合修正方法：修改一个组件时，所有受其影响的关系与该组件的修改共同构成一个事务，在固定的对象评分下统一评估、统一决定是否接受。本章首先介绍候选与初始图、对象评分与接受准则，然后说明依赖闭合事务的构造及其局部与全局求解方法，最后通过对照实验分析各项设计的作用。

4.1 引言

组件的边界或类型一旦改变，所有以它为端点的关系也随之变成了不同的对象。如果只根据组件的置信度决定是否修改，就会忽略关系整体失效带来的损失；如果根据整图的平均得分决定是否修改，又可能把删除对象导致的分母变小误当作收益。

已有研究通过结构解析和整数规划联合处理组件与关系[46]，关系抽取修正和论辩重构研究也提出了相关机制[43][44]。本章在原文、候选和评分都固定的条件下，把组件变化和关系重建放进同一个接受条件中，使组件修正的收益与关系侧的代价在同一个目标下权衡。

本章以 MCR-BR 中已有的类型与跨度修改为基础[34]，在固定的候选空间和对象评分下，把冲突消解、关系重建、分项效用和编辑预算纳入统一的接受规则。完整配置 I1 从 I0 的输出G_0出发，追加依赖闭合修正R_{DC}；其中的集合局部搜索子程序记为 BR-J，它与全局求解的选择方式见 4.5 节。

例如，4.6.1 节的实验显示，仅按评分删除低分关系虽然能提升 F1，但同时会误删一部分正确的关系。可见，修正时必须同时衡量恢复的收益和删除的代价。

图 4-1 给出了候选、评分与修正之间的数据流。4.2 节确定可修改的对象，4.3 节给出对象评分和接受条件，4.4 节说明一次事务如何构造，4.5 节介绍求解算法。 第五章表 5-5a 显示，T0I0 中 AAEC 有 637/2427、CDCP 有 294/756 条金标关系因端点缺失而无法命中，约占 26%和 39%；图 4-3 给出组件合并与关系重建的具体案例。

I0 包含多候选生成与重排序、共同合法化和 BR-O 有界修正；G_0为其最终合法图。I1 在G_0上追加R_{DC}，BR-J 为追加阶段的集合局部求解程序。

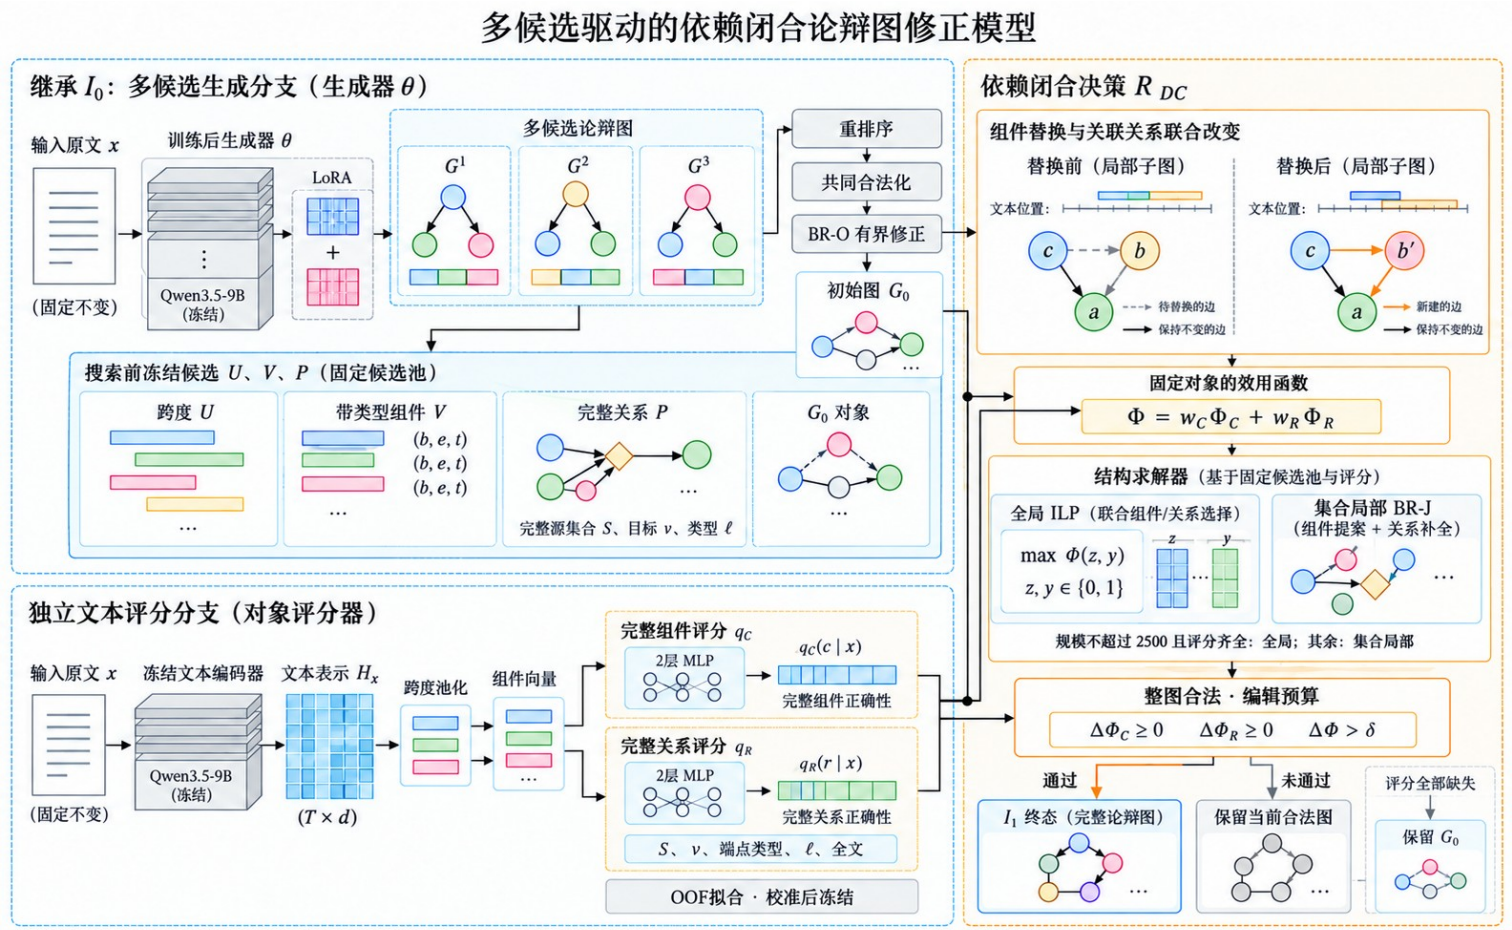


图 4-1 多候选驱动的依赖闭合修正模型

主要符号速查

符号	含义	定义位置
G_0；I0 / I1	继承流程终态；继承 / 完整推理配置	4.1、4.2.1
U；V；P	跨度；带类型组件；完整关系候选池	4.2.2
q_C；q_R	完整组件与完整关系的固定评分	4.3.1
Φ_C；Φ_R；Φ	组件、关系与总效用	4.3.2
R_{DC}；BR-J	追加依赖闭合修正；集合局部子程序	4.1、4.5.1
δ；B_C；B_R	严格改进阈值；组件与关系编辑预算	4.3.2、4.4.2

4.2 候选生成与初始图

候选生成有两个作用：一是为初始图的选择提供若干完整的备选结构，二是限定后续修正能够使用的对象范围。初始选择沿用 MCR-BR 的做法；修正开始前，再把多次生成和补充提议得到的对象汇总成固定的候选空间。

4.2.1 多候选生成与初始图选择

给定文档 x，生成器产生 K 组组件预测。默认 $K=3$：一组为贪心解码（temperature 为 0），另外两组为核采样（temperature 为 0.7，top-p 为 0.9）。三组使用同一提示，差异只来自解码方式。K 的影响作为可选消融。

$$\mathscr{C}=\{C^{(1)},\dots,C^{(K)}\}. \tag{4-1}$$

每个组件包括原文跨度和类型。关系生成器在给定的组件集合 $C^{(k)}$ 上预测关系，得到 $G^{(k)}=(C^{(k)},R^{(k)})$，这一过程不能修改组件。若关系部分解析失败，已经通过检查的组件仍作为候选保留，失败调用的开销计入总成本。

多个候选在边界、类型和连接上的差异，既用于选择初始图，也用于后续的替换。模型自行决定预测对象的数量，测试集标注只用于事后评价。

初始重排序沿用 MCR-BR 的加权评分，得到G_{rank}，经合法化后得到G_{pre}，再经 BR-O 修正得到 I0 的输出G_0。I1 从G_0出发执行追加修正R_{DC}，其预算单独计算。重排序的评分形式为：

$$\mathrm{E}_{\text{rank}}(G)=0.4\,\mathrm{E}_{\text{dens}}(G)+0.4\,\mathrm{E}_{\text{coh}}(G)+0.2\,\mathrm{E}_{\text{val}}(G). \tag{4-2}$$

设 $Q(G)$ 为预测图中参与覆盖评价的节点，$p_r \in \{0,1\}$ 为关系语义验证的结果，$d_{\text{coh}}^{\text{in}}(j)$ 为指向节点 j 且通过验证的关系数，则

$$\mathrm{E}_{\text{dens}}(G)=\frac{1}{|Q(G)|}\sum_{j\in Q(G)}\min\left\{\frac{d_{\text{coh}}^{\text{in}}(j)}{\tau_j},1\right\},\mathrm{E}_{\text{coh}}(G)=\frac{1}{|R|}\sum_{r\in R}p_r. \tag{4-3}$$

集合为空时对应分量取 0。AAEC 的覆盖节点为预测的 Claim，CDCP 为预测的 Policy 和 Value；MajorClaim 不要求必须有入边。结构角色阈值按节点是否有出边设置：没有出边时 $\tau_j=2$，否则 $\tau_j=1$。CDCP 的多前提关系只计一次入边。

式中，当输出可解析且跨度、类型和引用全部合法时，E_{val}取 1，否则取 0。合法化与 BR-O 的处理细节见附录 A.4。

这一评分有明显的局限：覆盖分量和连贯分量都依赖同一个验证结果 p_r，并不独立；覆盖节点数和当前边数又是平均分的分母，因此删除低分对象或改变组件类型可能提高平均分，但不一定提高真实的准确率。所以，本章只把它用于初始候选的选择，另外为允许修改组件的修正阶段定义新的接受目标。

4.2.2 候选空间构建

追加修正开始前，先构建固定的跨度集合U。它由两部分组成：一是保护部分，包括G_0以及各候选输出中所有合法的组件跨度，这些对象不会被裁剪；二是补充部分，由独立的跨度预测头和类型分类器提供（结构见附录 A.4）。若资源连保护部分都无法容纳，则直接返回G_0，以免改变基线结果。

每个补充跨度保留类型头排名前 2 的类型，保护对象则保留其全部类型。记跨度 u 的候选类型集合为$T_*(u)$，带类型的组件候选集合为$V=\{(u,t):t\in T_*(u)\}$。每个跨度最多选择一个类型，NULL 表示不选。

这里的跨度 u 即字符区间(d,b,e)，带类型候选(u,t)对应(d,b,e,t)。关系由完整的源组件集合、目标组件和标签确定。候选去重、评分缓存、冲突检查和评价都使用这一身份。

关系候选按“源组件集合—目标”槽位构建。AAEC 直接枚举候选组件之间的合法有向对；CDCP 则由一个学习得到的源组提案器 P 生成候选源组件集合，并用相邻源组件的规则进行补充。G_0及各候选图中已有的槽位始终保留，不受数量上限限制。提案器的结构和规模上限见附录 A.4。

一个槽位包含该端点组合下的全部合法关系标签，NONE 由不选任何正关系表示。槽位按各标签对象得分的最大值排序，保留前N_{slot}个补充槽位。

对于二元关系，只有当正反两个方向的槽位都在候选池中且端点合法时，才考虑反转关系方向。搜索期间不向池外补充关系。候选池和对象评分在搜索开始前固定。

各语料的结构约束分别设定。CDCP 保留完整源集合及其连续性要求，多前提关系作为一个整体，不在二元表示与多元表示之间任意拆合。

候选质量的统计见 4.6.2 节。局部求解与全局求解使用同一候选池和同一组评分。

4.3 对象评分与接受准则

在搜索过程中，需要比较不同状态的优劣，而组件数、关系数和图结构都在不断变化。为此，本章在搜索前固定每个对象的得分，用基于计数的效用衡量对象的增加与删除；并设置分项接受门，不允许用组件效用的下降换取关系效用的提高，反之亦然。

4.3.1 对象评分器与策略选择

评分器分别估计组件和关系作为完整对象完全正确的概率：

$$q_C(c \mid x), q_R(r \mid x). \tag{4-4}$$

组件头根据跨度表示和全文表示预测类型（含 NULL）分布。关系头输入端点的跨度表示和类型、关系方向、关系标签和全文表示，判断整个关系对象是否正确。只有端点跨度、端点类型和关系标签都完全正确时，才算正例。因此，在金标端点上训练出的关系分类器，其准确率并不能代表完整对象的正确概率。

评分器 S 使用冻结的 Qwen3.5-9B 编码器，组件头和关系头均为两层 MLP，与抽取模型的 LoRA 和训练辅助头相互独立；4B 和 2.5-7B 骨干分别重新训练和校准评分器。具体结构和训练设置见附录 A.4。

搜索开始前，同一文档的文本表示、校准参数和全部候选得分都被固定。对象得分 q 不依赖当前图的结构，因此同一对象在不同搜索状态中得分相同。得分缺失或无效的对象单独标记，涉及这些对象的修改一律拒绝，而不是用默认值代替。

评分器的训练数据应当包含模型实际会犯的错误，而不能只用人工构造的简单负例。因此，本文按源文档进行三折交叉拟合（out-of-fold，OOF）：对每一折，用没有见过该折文档的生成器和跨度头为其生成候选，再与金标对比得到正负标签。比较两种训练方法时，OOF 候选同时来自两类生成器，以免评分器只适应其中一种。

负例包括跨度错误和类型错误的组件，以及原本无关系的槽位上的关系候选。校准数据保持候选的自然分布。按 2.6 节的划分，训练集源文档分为评分器拟合、校准和策略选择三部分，分别用于训练评分器、校准概率以及选择阈值和预算。

概率校准只在 OOF 校准数据上拟合，冻结后在独立数据上检查评分质量，结果见 4.6.3 节。

策略在独立的策略集上选择。AAEC 固定κ_R=1；CDCP 在$\kappa_R \in \{0.5,1.0\}$和$\delta \in \{0.01,0.05,0.10,0.20\}$的组合中选择：先排除原有正确关系损失率超过 5%的组合，再从其余组合中选关系 F1 最高的；若并列，取较大的κ_R和δ。若所有组合都不满足要求，则直接输出 I0 的结果。测试集标签不参与选择。

选定的δ和κ在评价前固定，局部和全局求解共用。

4.3.2 效用函数与接受条件

对对象类别 $X \in \{C, R\}$（C 为组件，R 为关系），设固定系数 $0 < \kappa_X < 2$，定义效用

$$\Phi_X(G) = 2 \sum_{o \in X(G)} q_X(o \mid x) - \kappa_X \left| X(G) \right|, \Phi(G) = w_C \Phi_C(G) + w_R \Phi_R(G), \tag{4-5}$$

其中 $w_C, w_R > 0$。主配置取 $w_C = w_R = 1$，κ_X 在开发集上确定后固定。效用不按当前图的组件数或关系数归一化。

这一效用有清晰的含义。令 Y_X 为真实对象集合，并假设 $q_X(o \mid x) = P\left(o \in Y_X \mid x\right)$，即评分是对象正确的概率。由 $\mathrm{FP}_X = \left| X(G) \right| - \mathrm{TP}_X$ 和 $\mathrm{FN}_X = \left| Y_X \right| - \mathrm{TP}_X$ 可得

$$\Phi_X(G) = \left(2 - \kappa_X\right) \mathrm{E}\left[\left| Y_X \right| \mid x \right] - E\left[\kappa_X \mathrm{FP}_X + \left(2 - \kappa_X\right) \mathrm{FN}_X \mid x \right]. \tag{4-6}$$

第一项与预测图无关，因此最大化该效用等价于最小化误检和漏检的期望加权代价，κ控制两类错误的相对权重。该推导只用到期望的线性性，不需要假设各对象的正确性相互独立。

需要指出，F1 不能按对象分解，最大化 F1 的决策一般无法由边际概率直接确定[41][42]。本文采用可分解的代价敏感效用作为代理目标，它可以直接用于事务差分和整数规划；最终效果仍以严格关系 F1 评价。

一个候选事务只有满足以下条件才被接受：修改后的整图合法，剩余预算足够，且

$$\Delta\Phi_C \geq 0, \Delta\Phi_R \geq 0, \Delta\Phi > \delta > 0. \tag{4-7}$$

前两个条件（分项门）要求组件和关系的效用都不下降，第三个条件要求总效用的提升超过阈值δ，以排除收益很小的修改。

组件的编辑成本为 $d_C=|D|+|B|$，即删除和新增组件的数目；关系的编辑成本为 $d_R=|R \triangle R'|$，即前后关系集合的对称差。组件类型或边界改变导致的关系删除与新增分别计费。编辑成本只用于预算限制以及在效用相同时优先选择改动少的方案，不计入效用。这里只统计追加修正的编辑，同时分别记录累计编辑量和相对 G_0 的净变化。

4.4 依赖闭合事务的构造

组件修改与关系重建构成一个不可拆分的事务。算法先补全删除集合以消除跨度冲突，再找出所有受端点变化影响的关系，最后对修改后的完整图做一次接受判断。仅修改关系的操作也使用同样的事务接口，此时组件保持不变。

4.4.1 组件冲突消解

设当前组件集合为 C，一次提议给出新增集合 B 和主动删除集合 D_0（D_0 和 D 都表示待删除的组件集合，输入文档仍记为 x）。首先把 $B \cap C$ 中没有变化的对象从 B 和 D_0 中去掉，然后补上所有与新增组件冲突的旧组件：

$$D = D_0 \cup \{c \in C : \exists b \in B, \mathrm{Conflict}(c, b)\}, C' = (C \setminus D) \cup B. \tag{4-8}$$

B 内部的组件必须互相兼容，所有与新增组件冲突的旧组件都必须加入 D，即使它们不在提议的范围内，否则修改后的图仍可能存在非法重叠。若补全后超出预算，则拒绝该提议。

基本的修改操作包括 $0 \to 1$、$1 \to 0$、$1 \to 1$、$1 \to 2$ 和 $2 \to 1$，分别对应补回漏检、删除误检、替换类型或边界、拆分和合并。默认每个事务满足 $|D|+|B| \le 3$，该限制在冲突补全之后检查。

4.4.2 受影响关系的重建

本章所说的“依赖闭合”是指：一个组件被删除或替换后，所有以旧组件为端点的关系，以及新组件可能参与的关系，都要一起进入决策，以免只计算组件的收益而漏掉关系的损失。这里的“全部受影响关系”限于候选空间之内。还要注意，本章的 NONE 与第三章不同：第三章的 NONE 来自标注，需要在改写后保持；本章的 NONE 只表示当前预测没有选择该关系，其中可能存在漏检，因此推理时可以把它改为一条关系。

令变化对象集合 $A=D\cup B$ 包括被删除的旧组件和新增的组件（与第三章的改写集合不同）。P_A 为候选池 P 中至少有一个端点属于 A 的全部关系，包括入边、出边、已选的正关系和未选的 NONE 槽位。删除旧组件后，所有以它为端点的关系都必须删除；新增组件的入边和出边则重新参与选择，不能按旧编号继承。

对于组件正确但关系有误的情况，保留纯关系提议 S_R，事务的关系范围定义为

$$P_{\text{tx}}=P_A\cup S_R. \tag{4-9}$$

纯关系事务（RelationOnly）取 $D=B=\varnothing$，通过 S_R 实现增边、删边、改标签或反转方向。一个槽位进入 S_R 时，其全部合法标签一同进入；反转方向需满足 4.2.2 节的双向槽位条件。

对于每个新的组件集合 C'，算法先为受影响的关系求出最优（或可行）的补全，然后比较完整的新图 $G'=(C',R')$，而不是先按组件得分决定 C'。事务以外的关系保持不变，但整图仍需满足全局约束。如果组件的变化使某些事务外的已选关系变得不合法，就把这些关系的槽位加入S_R，重新求解其全部标签，并计入相应的编辑成本；若仍不可行或超出预算，则拒绝该事务。这样，端点变化导致的关系失效都能被计入，组件收益与关系代价得到完整的权衡。

CDCP 的源组件连续性还取决于哪些中间组件被选中，这带来一个特殊情况。例如，当前组件按位置依次为a,b,c,t，候选池中有关系$h=(\{a,c\},t,\text{Reason})$。由于$b$位于两个源组件之间，$h$当前不合法。如果某个事务删除了$b$，$h$就变得合法了；但$a,c,t$都没有变化，所以$h$不属于该事务的$P_A$，若$S_R$中也不包含它，$h$在这次事务后仍然不会被选中。

此时，要恢复h，需要后续的纯关系提议把h的槽位纳入S_R，并通过合法性、效用门和预算检查；而要恢复h，前提是删除b的事务已被接受、h在候选池中且预算尚未耗尽。本文没有把这类“因其他组件变化而变得合法”的槽位自动纳入事务，这是局部搜索在邻域和预算上的限制，并不影响已接受结果的合法性和终止性。4.5.2 节的全局求解可以同时处理这种情况。

总之，跨度或类型改变后，组件就成为一个新对象：以旧对象为端点的关系计为删除，以新对象为端点的关系计为新增。下面用一个真实的事务说明这一过程。

4.4.3 事务示例

本节以 AAEC 测试文档 essay077（种子 29，Single 路径的第 1 次事务）为例。组件文字取自原始语料，得分 q 来自 9B 模型固定后的评分。

表 4-1 essay077 示例事务涉及的对象及其评分

对象	原文／完整端点及标签	变化	评分 q
b 旧：[1483,1537) MajorClaim	complained about the drawbacks of zoos are often heard	删除	0.898635
b 新：[1483,1537) Claim	complained about the drawbacks of zoos are often heard	加入	0.958186
a1：[1555,1669) Premise	some zoos are lack of systematic management which attributes to numerous wild animals die because of food shortage	保持	0.898486
a2：[1677,1820) Premise	being caged in the zoos for long render wildlife lost the ability to survive in nature where is full of cruel competition among various animals	保持	0.897797
r1	a1 → b 旧 / attacks	删除	0.669856
r2	a2 → b 新 / supports	加入	0.890926
r3	a2 → b 旧 / attacks	删除	0.013781

原预测将[1483,1537)标为 MajorClaim，而金标类型为 Claim。同一跨度上的新旧两个类型对象互相冲突，因此加入 b 新就必须删除 b 旧。随之，两条指向旧对象的 attacks 关系被删除，并新增了 a2 指向新 Claim 的 supports 关系；a1 和 a2 本身保持不变。

取$\kappa_C=\kappa_R=1$、$\delta=0.20$ 时，该事务使组件效用增加 0.119102，关系效用增加 1.414578，总效用增加 1.533680。两个分项增量均非负，总增量超过阈值；组件和关系分别编辑 2 次和 3 次，未超出追加阶段 24 和 96 的预算。因此该事务被接受。

表 4-2 示例事务在不同条件下的处理结果

条件	输入处理	实际检查结果	处理结果
正常输入	全部必需分数齐备	accept	提交；组件 2／关系 3 编辑
缺分注入	删除 1 个必需关系分数	reject_missing_score	原图保留；语义编辑 0
预算不足	剩余组件预算为 1	reject_edit_budget	原图保留；语义编辑 0

按金标进行事后统计，组件的 TP/FP/FN 由 11/3/3 变为 12/2/2，关系由 4/5/5 变为 5/3/4。金标只用于这一事后统计。表 4-2 还给出了评分缺失和预算不足两种拒绝情形，此时保留原图，但已发生的计算仍计入开销。

以上案例展示了单个事务的评估和接受过程。下一节介绍如何在候选空间中搜索并提交这样的事务。

4.5 求解算法及性质

局部求解先固定通过冲突检查的组件提议，再补全受影响的关系；全局求解则一次性同时选择全部组件和关系。二者共用固定评分、分项门和整图约束，但编辑预算的计算方式不同：局部按累计修改计算，全局按相对初始图的净变化计算，因此可行域也不同。下面依次介绍局部求解、全局求解、方法性质和路径选择。

4.5.1 集合局部搜索

局部求解采用“有界组件提议 + 局部整数规划关系补全”的方式。对于一个已经通过冲突检查的组件集合 C'，令 $z_c=I[c\in C']$ 表示组件状态（已固定），$y_r\in\{0,1\}$ 表示是否选择关系候选 $r\in P$。目标为

$$\max_{y} w_C\Phi_C(C')+w_R\sum_{r\in P}\left(2q_R(r\mid x)-\kappa_R\right)y_r. \tag{4-10}$$

组件提议固定后，组件项在关系求解中是常数，但比较不同组件提议时仍需保留。约束如下：

$$\begin{gathered}\sum_{t\in T_*(u)} z_{(u,t)}\le 1,\\ z_c+z_d\le 1\ \text{若}\ \operatorname{Conflict}(c,d);\\ y_r\le z_c\ \forall\, c\in\operatorname{Ends}(r),\\ \sum_{r\in\Gamma_s} y_r\le 1\ \forall\, s;\\ y_r=I[r\in R]\ \forall\, r\notin P_{\text{tx}},\\ G'\in G_A.\end{gathered} \tag{4-11}$$

其中 Γ_s 为同一槽位的互斥标签候选，全为 0 即为 NONE；G_A 为整图合法集合。关系约束保证被选关系的端点全部存在。若语料要求无环，则引入顺序变量 $0\le o_c\le M-1$（$M=|V|$），并对全部候选二元边加入约束

$$o_v\ge o_u+1-M\left(1-y_{(u,v,\ell)}\right). \tag{4-12}$$

多前提关系对每个源组件到目标的方向分别加入同样的约束。对于 CDCP 的源组件连续性规则，在给定的 C' 上判断每个候选关系是否合法，不合法的强制 $y_h=0$；若这与事务外的固定关系冲突，则当前事务不可行。

分项效用门和编辑预算也作为约束加入整数规划。设 $y_r^0=I[r\in R]$ 为修改前的关系状态，关系编辑成本可以线性地写为

$$d_R=\sum_{r:y_r^0=1}(1-y_r)+\sum_{r:y_r^0=0}y_r. \tag{4-13}$$

整数规划同时要求 d_C,d_R 不超过剩余预算，并且 $\Delta\Phi_C,\Delta\Phi_R\geq 0$；提交前再检查 $\Delta\Phi>\delta$。这些条件必须在求解时就加入，而不能先求最高分再检查是否违规。若有多个最优解，依次按效用最大、编辑最少、规范键最小的顺序选择。求解超时时返回当前最好的可行解，并重新检查全部约束。

提议分为六类：纯关系、插入、删除、替换、拆分和合并。纯关系提议枚举端点合法的全部槽位；插入从未选组件中选择，删除从已选组件中选择；替换用一个新组件代替一个旧组件，允许类型或边界变化；拆分把一个旧组件替换为两个相容且位于原跨度内、首尾包络与原跨度一致的新组件，合并是其逆操作。每个提议都先补全冲突删除，再按实际的S_R、$(|D|,|B|)$检查是否属于上述类型，以及是否超过三个组件的上限。例如，一个名义上的插入若实际变成了$2\to 1$，在单对象对照中就会被拒绝。

局部搜索的预算按提议的尝试次数和接受次数计算，上限见表 2-7，执行细节见附录 A.4。

算法 4-1 多候选驱动的依赖闭合修正

输入：原文、生成候选、固定的评分与配置、资源预算。

输出：修正后的合法论辩图（或初始化失败状态）及修改记录。

01 按 MCR-BR 流程得到初始图：$G_{\text{rank}}\leftarrow$ 重排序；$G_{\text{pre}}\leftarrow L_A(G_{\text{rank}})$；$G_0\leftarrow$ BR-O(G_{pre})

02 if 无法得到合法的G_0 then

03 return 初始化失败

04 end if

05 固定候选、评分及效用系数（构建失败返回G_0）；初始化预算；G $\leftarrow G_0$

06 for 每一轮（不超过轮数上限和总预算） do

07 重置本轮计数；为当前状态建立（或继续使用）提议队列

08 while 队列非空且各项预算均未耗尽 do

09 从队列中取一批提议 Q；$G_{\text{noop}}\leftarrow$ G；H $\leftarrow\varnothing$

算法 4-1 多候选驱动的依赖闭合修正

for Q 中每个未评估且预算允许的提议 do
  尝试次数加 1；调用算法 4-2 进行评估，记录开销
  若评估通过，将得到的新图加入 H
 end for
 if H 非空 then
  按总效用最大、编辑最少的顺序选出最优新图
  检查接受额度和编辑预算
  若不满足，保留G_{noop}并停止
  整体提交；若提交失败，恢复为G_{noop}并停止
  更新编辑量；接受次数加 1
 else
  保留G_{noop}；若队列已遍历完则停止，否则继续下一批
 end if
 end while
end for
return 当前合法图 G 及停止原因

算法 4-2 单个提议的闭合评估

输入：当前合法图 G、一个提议、固定的对象评分和剩余预算。

输出：通过检查的新图，或拒绝。

复制 G；去掉提议中未变化的对象；补全与新增组件冲突的删除
if 新增组件互相冲突、操作类型不符或组件编辑超出预算 then
 return 拒绝，原图不变
end if
找出受端点变化影响的全部关系；若事务外已选关系失效，将其槽位一并纳入
固定其余关系，将整图约束、分项效用门和编辑预算加入整数规划
求解；若超时，使用当前最好的可行解
if 无可行解或评分失败 then
 return 拒绝（记录原因）
end if
检查整图合法性、编辑成本、两个分项门和总效用增益
return 通过检查的新图；否则返回拒绝

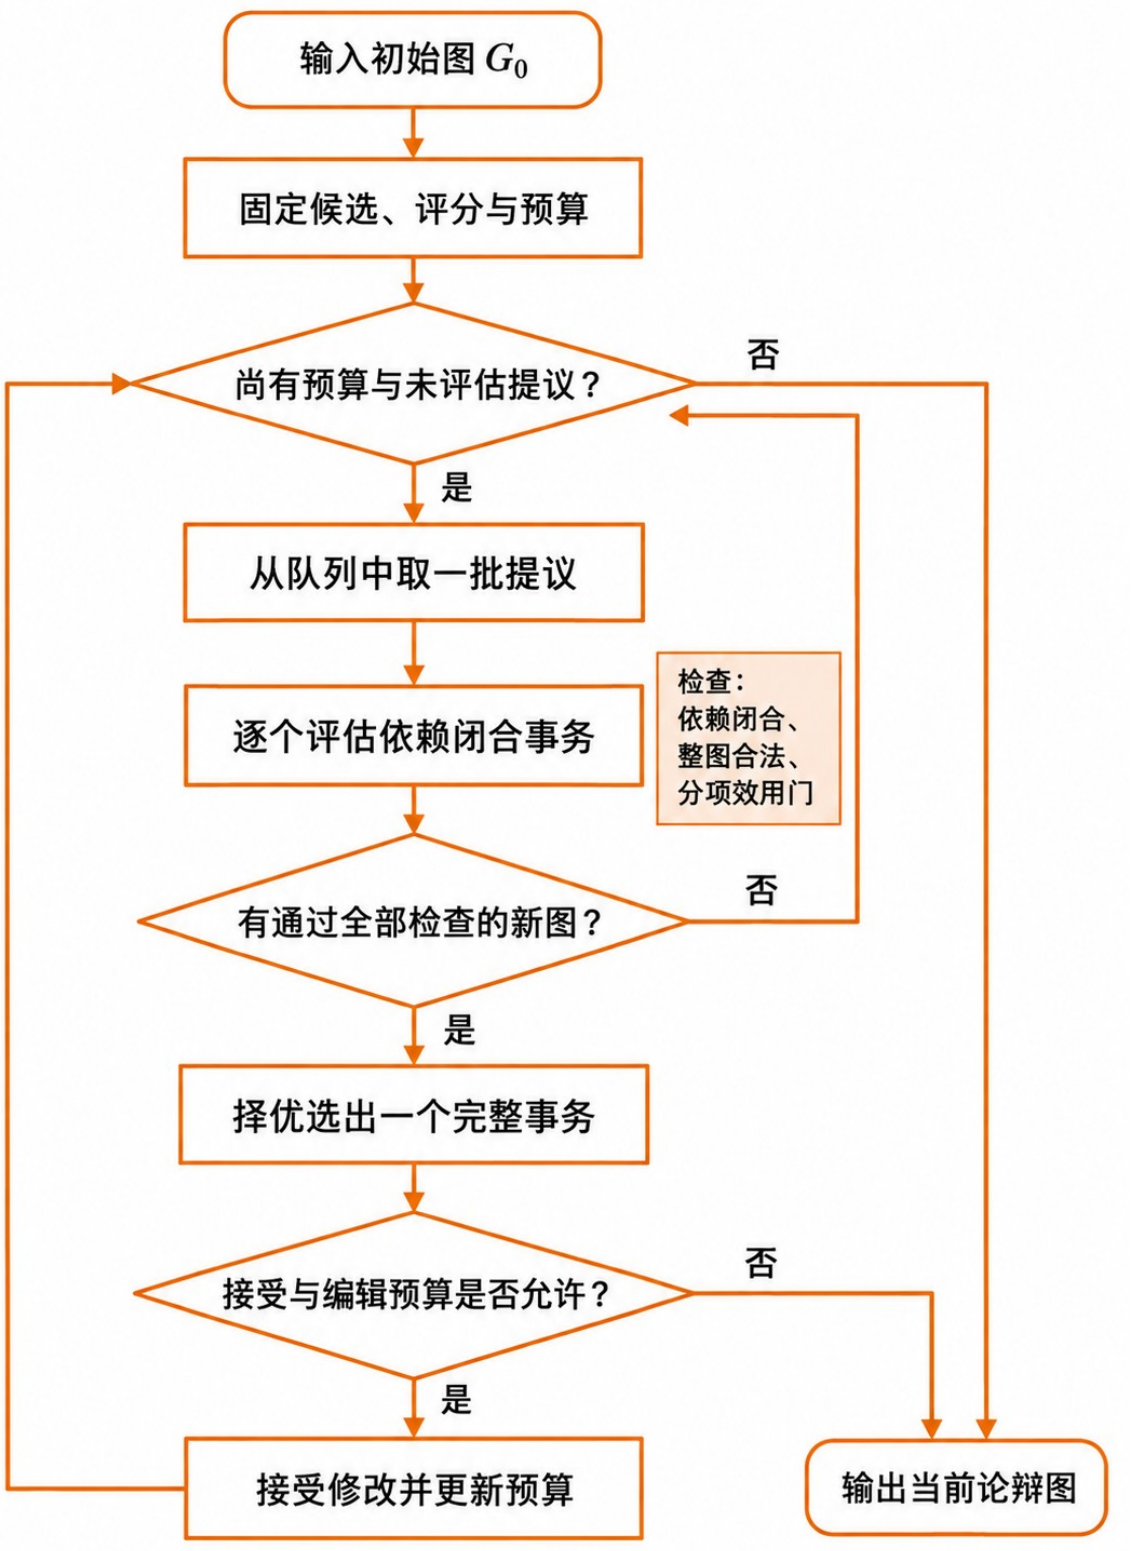


图 4-2 集合局部搜索 BR-J 的执行流程

图 4-2 给出了集合局部子程序 BR-J 的流程（对应算法 4-1 和 4-2），输入为G_0或最近的合法图。提交失败时，组件、关系和缓存全部恢复到提交前的状态。候选构造、评分、拒绝和超时的开销都计入成本。

4.5.2 全局整数规划求解

4.5.1 节固定组件提议C'，只求解关系。全局求解则同时选择全部组件和关系，这时不能简单地把组件变量放开，还需要相应地调整约束：CDCP 的源组件连续性取决于中间组件是否被选中，编辑量和分项门也要改为相对初始图G_0计算。全局模型如下。

（1）变量与目标。对候选空间中的每个带类型组件$v \in V$设变量$z_v \in \{0,1\}$，对每个关系候选$r \in P$设变量$y_r \in \{0,1\}$；z_v^0、y_r^0表示G_0中的取值。记$a_X(o)=2q_X(o \mid x)-\kappa_X$，全局目标与局部求解使用同一效用：

$$\max_{z,y} \Phi(z,y)=w_C \sum_{v \in V} a_C(v) z_v + w_R \sum_{r \in P} a_R(r) y_r . \tag{4-14}$$

（2）结构约束。

$$\begin{gathered} \sum_{t \in T_*(u)} z_{(u,t)} \le 1 \; \forall u \in U , \\ z_c + z_d \le 1 \text{ 若 } \operatorname{Conflict}(c,d); \\ y_r \le z_c \; \forall r \in P, \forall c \in \operatorname{Ends}(r), \\ \sum_{r \in \Gamma_s} y_r \le 1 \; \forall s; \\ y_h + z_w \le 1 \; \forall h \in P_{\mathrm{CDCP}}, \forall w \in \operatorname{Btw}(h). \end{gathered} \tag{4-15}$$

上述约束依次为：同一跨度最多选一个类型，所选组件两两兼容，被选关系的全部端点（包括多前提关系的全部源组件）都被选中，同一槽位的标签互斥。最后一个约束表达 CDCP 的源组件连续性：对关系$h=(S,v,\ell)$，令$\operatorname{Btw}(h)$为起点位于S中最左和最右源组件之间、但不属于S的候选组件。由于被选组件互不重叠，S在被选组件序列中连续，当且仅当$\operatorname{Btw}(h)$中没有组件被选中，因此该约束是对连续性的精确线性化。若语料要求无环，沿用 4.5.1 节的顺序变量约束。

仍以 4.4.2 节的a,b,c,t为例，全局模型中有约束$y_h + z_b \le 1$，因此删除b和选择$h=(\{a,c\},t,\text{Reason})$可以在一次求解中同时决定。而在局部求解中，$h$与删除$b$的事务没有共同端点，只能留待后续的纯关系提议来恢复。这是两种求解方式结果不同的一个具体原因。

（3）净编辑量与分项门。编辑量按最终图相对G_0的净变化计算：

$$d_C^{\mathrm{net}} = \sum_{v:z_v^0=1} (1-z_v) + \sum_{v:z_v^0=0} z_v \le B_C , d_R^{\mathrm{net}} = \sum_{r:y_r^0=1} (1-y_r) + \sum_{r:y_r^0=0} y_r \le B_R . \tag{4-16}$$

类型或边界的改变对应不同的变量，计为一次删除和一次新增，与局部求解的$|D|+|B|$一致；因端点被删除而失效的关系计入d_R^{net}。分项门相对G_0定义为$\Phi_C(z) \ge \Phi_C(z^0)$

和$\Phi_R(y)\geq\Phi_R(y^0)$，追加阶段的预算为$B_C=24$、$B_R=96$。求解后若$\Phi^*-\Phi(z^0,y^0)>\delta$，则返回新图，否则返回$G_0$。

(z^0,y^0)总是满足全部约束：G_0本身合法，其对象都在候选空间中，编辑量为 0，分项门取等号。因此全局模型总是可行的。

（4）与局部求解的区别。局部求解在每一步都相对当前状态检查分项门，编辑成本逐次累加。因此，局部求解得到的任一结果都满足相对G_0的分项门，其净编辑量也不超过累计编辑量，即局部可达的结果都在全局可行域内。反之则不一定成立：通向全局最优解的局部路径可能在某一步需要分项效用暂时下降，而这一步会被局部接受门拒绝。二者的区别总结于表 4-3。全局求解存在多个最优解时的处理规则见附录 A.4。

表 4-3 局部求解与全局求解的对比

项目	局部求解（Single 或 BR-J）	全局求解
决策变量	组件状态固定为提议后的C'；仅y_r，$r\in P_{\text{tx}}$可变	全部z_v与y_r同时可变
目标	同一Φ；单次求解中组件项为常数	同一Φ
事务外对象	固定为当前状态，仅最小合法化扩域	无事务边界
CDCP 连续性	在固定C'上预判，非法超边强制$y_h=0$	$y_h+z_w\leq 1$，$w\in\text{Btw}(h)$
分项门参照	每次事务相对当前状态	终态相对G_0
编辑计数	累计：各次提交的删增之和	净：终态相对G_0的差异
追加阶段预算	组件 24、关系 96（累计）	组件 24、关系 96（净）
缺失评分	触及缺分对象的事务拒绝	要求全池评分齐备，否则不进入本路径
求解调用	每个提议一次 ILP；外层至多 128 次尝试	每文档一次主求解，另加破同分求解
返回	最近完整合法图及停止原因	经复核的终态，或G_0及状态码

4.5.3 方法性质分析

命题 4-1：在候选空间和对象评分固定时，两个预测状态之间的效用差可以由新增和删除的对象精确计算。

证明：对 $X\in\{C,R\}$，记 $a_X(o)=2q_X(o\mid x)-\kappa_X$，则

$$\Delta\Phi_X=\sum_{o\in X(G')\setminus X(G)}a_X(o)-\sum_{o\in X(G)\setminus X(G')}a_X(o).\tag{4-17}$$

由于同一对象的得分固定，两个状态共有的对象在差分中相互抵消；依赖闭合则保证所有改变的关系都在差集中。因此，只要知道哪些对象被增删，就能精确计算效用变化。

命题 4-2：存在这样的合法状态，其中任何单对象修改都无法通过严格改进条件，但一个集合替换可以通过。

构造如下：两个兼容的旧组件c_1=[0,4)、c_2=[4,8)，一个候选新组件 b=[0,8)与二者都冲突。三者类型相同，没有关系，κ_C=1，w_C=w_R=1。令$q_C(c_1)$=$q_C(c_2)$=0.65，q_C(b)=0.95，则两个旧组件的效用为 0.30+0.30=0.60，新组件的效用为 0.90，替换后总效用增加 0.30，大于δ=0.20；关系效用不变，编辑成本为d_C=3、d_R=0。

单独删除任一旧组件，效用下降 0.30，无法通过；直接插入 b 或用 b 替换其中一个旧组件，冲突补全都会同时删除另一个，实际上成为 2→1 的合并，已不属于单对象修改。只有允许 2→1 操作且组件预算不少于 3 时，这一替换才能被接受。

这说明集合动作可以越过单对象修改无法越过的障碍。4.6.1 节的 essay180 给出了这种情况的真实案例。

命题 4-3：在有限的候选状态空间中，若每次接受都严格提高同一个固定的效用 Φ，则接受序列不会重复访问任何状态，因而必定在有限步内终止。

由于每次接受都使效用严格增加，不可能回到已访问过的状态；而候选状态总数有限，所以接受序列也是有限的。实际中预算限制会使搜索更早停止。

最后说明代理效用与 F1 的关系。对某个语料，设正确预测数为 T，预测总数为 P_0，金标总数为 Q，则 $F=2T/(P_0+Q)$。修改前后分母均不为零时，展开可得

$$F'-F=\frac{2\Delta T-F\Delta P_0}{P_0+Q+\Delta P_0}.\tag{4-18}$$

可见，F1 的真实变化同时取决于正确数和预测数的变化。推理时 ΔT 和 F 都是未知的，只能用估计的概率和固定的 κ 来近似。因此，上述理论性质保证的是代理效用的单调性和算法的终止性，严格 F1 的效果需要通过 4.6 节的实验来检验。

4.5.4 求解方式的选择

依赖闭合规定了一次修改中哪些关系必须一起决策，而具体采用哪种求解方式则取决于候选规模：候选池较小时用全局求解，较大时用集合局部搜索以控制时延。默认按以下规则选择：

评分检查。若$V \cup P$中的全部对象评分都失败，直接返回G_0；若部分对象缺少评分，则不使用全局求解，改用局部求解，并拒绝涉及缺分对象的事务。

规模判断。令 n=|V|+|P|，n≤2500 时使用全局求解，否则使用集合局部搜索 BR-J。这一阈值是根据本文的硬件条件确定的，500 至 4000 个变量的耗时测试见附录 B.3。

求解与返回。全局求解的时限与局部求解相同（AAEC 为 3 秒，CDCP 为 5 秒）；超时时，若已有通过全部检查的更优可行解，则返回该解，否则返回G_0，详细规则见附录 A.4。

以上给出了依赖闭合修正的完整求解流程。下一节通过实验检验该方法的效果，并分析各项设计的作用。

4.6 实验结果与分析

4.6.1 主要结果与消融分析

为了验证依赖闭合修正的有效性，本节围绕以下问题开展实验：（1）在训练配置固定时，追加修正能否提升抽取性能；（2）组件修改范围、共同接受、集合动作和全局求解分别起什么作用；（3）与相同预算的重新生成以及简单的阈值过滤相比效果如何；（4）评分质量和计算成本如何。各结构修正对照固定训练检查点 T1、初始图G_0、候选池、对象评分和合法化规则，只改变修正方式：I0 直接输出G_0；RelationOnly 只修改关系，不修改组件；Sequential 先修改组件、再修改关系，两步分别接受；Single 以单个组件为单位，组件与关系共同接受；SetLocal 在 Single 基础上允许集合动作（拆分、合并）；Global 同时选择全部对象。主实验的 690 个文档—种子输入规模都小于 2500 个变量，因此 I1 全部使用全局求解，Single 和 SetLocal 作为消融单独报告。

另设四组对照。Regenerate 在相同的追加模型调用次数和 token 上限下重新采样完整图并重排序。ThresholdFilter 是一个简单基线：保留G_0的组件，删除评分低于门限（AAEC 为 0.5，CDCP 为 0.25）的关系，不新增关系。NoRisk 取消开发集上的风险限制，把δ降到接近 0，但仍保留合法性约束和分项门。NoCalibration 使用未校准的评分。

表 4-4 推理对照组的设置

配置	候选与评分相同	变化项
RelationOnly	是	组件固定，只选择关系
ThresholdFilter	是	组件固定，仅删除低于门限的G_0关系；无事务与预算
Sequential／Single	是	组件优先接受／共同接受
SetLocal／Global	是	动作与可行域；累计／净编辑
NoRisk	是	开发风险选择与δ
NoCalibration	候选相同	使用原始分数
MissingLow	正常缺分为 0	缺分解释
Regenerate	同检查点与追加资源	重生成完整图并重排序

表 4-5 不同推理配置的抽取性能（训练均为 T1）

配置	AAEC 组件 F1	AAEC 关系 F1	CDCP 组件 F1	CDCP 关系 F1
T1I0：完整成对	87.85 ± 0.39	68.25 ± 2.08	83.46 ± 1.04	45.08 ± 2.73
仅关系阈值过滤	87.85 ± 0.39	69.76 ± 2.10	83.46 ± 1.04	47.84 ± 3.20
固定组件，RelationOnly	87.85 ± 0.39	70.45 ± 2.11	83.46 ± 1.04	49.19 ± 2.35
组件优先分步	88.12 ± 0.42	70.78 ± 2.08	83.97 ± 1.01	49.68 ± 2.35
单对象闭合	88.26 ± 0.40	71.15 ± 2.11	84.15 ± 0.97	50.04 ± 2.38
集合局部	88.38 ± 0.43	71.40 ± 2.10	84.33 ± 0.95	50.44 ± 2.39
全局选择	88.47 ± 0.46	71.63 ± 2.11	84.45 ± 0.94	50.77 ± 2.45
T1I1：完整配置	88.47 ± 0.46	71.63 ± 2.11	84.45 ± 0.94	50.77 ± 2.45
等预算重生成	87.71 ± 1.12	68.72 ± 2.67	83.62 ± 0.86	45.96 ± 4.28
取消开发风险限制	88.39 ± 0.48	71.34 ± 2.11	84.37 ± 0.96	50.43 ± 2.38
取消概率校准	88.33 ± 0.57	71.02 ± 2.15	84.29 ± 0.91	50.11 ± 2.33
缺分当低分	88.47 ± 0.46	71.63 ± 2.11	84.45 ± 0.94	50.77 ± 2.45

表 4-6 推理配置之间的关系 F1 配对差值（百分点）

语料	比较	差值	单项 95% CI	种子 17 / 29 / 43	p	类型
AAEC	T1I1 − T1I0	3.38	[2.56, 4.23]	3.30 / 3.54 / 3.31	0.0070	主要 / Holm
AAEC	T1I1 − RelationOnly	1.18	[0.71, 1.68]	1.12 / 1.27 / 1.16	0.0070	主要 / Holm
AAEC	Single − Sequential	0.37	[0.11, 0.65]	0.37 / 0.41 / 0.33	0.0175	主要 / Holm
AAEC	T1I1 − Regenerate	2.91	[1.07, 4.83]	3.80 / 1.41 / 3.53	0.0120	主要 / Holm
AAEC	T1I1 − NoRisk	0.29	[0.09, 0.51]	0.26 / 0.34 / 0.29	0.0140	主要 / Holm
AAEC	SetLocal − Single	0.25	[0.04, 0.47]	0.23 / 0.27 / 0.25	0.0285	探索 / 原始 p
AAEC	Global − SetLocal	0.23	[0.02, 0.45]	0.21 / 0.26 / 0.21	0.0390	探索 / 原始 p
AAEC	Global − Single	0.48	[0.18, 0.80]	0.45 / 0.53 / 0.47	0.0030	探索 / 原始 p
AAEC	T1I1 − ThresholdFilter	1.88	[1.21, 2.58]	1.68 / 2.17 / 1.77	0.0005	探索 / 原始 p
AAEC	RelationOnly − ThresholdFilter	0.69	[0.24, 1.17]	0.56 / 0.90 / 0.62	0.0060	探索 / 原始 p
AAEC	T1I1 − MissingLow	0.00	[0.00, 0.00]	0.00 / 0.00 / 0.00	1.0000	探索 / 原始 p
AAEC	T1I1 − NoCalibration	0.61	[0.14, 1.10]	0.49 / 0.71 / 0.62	0.0175	探索 / 原始 p
CDCP	T1I1 − T1I0	5.68	[4.03, 7.47]	5.40 / 5.40 / 6.24	0.0070	主要 / Holm
CDCP	T1I1 − RelationOnly	1.57	[0.74, 2.46]	1.49 / 1.68 / 1.54	0.0070	主要 / Holm
CDCP	Single − Sequential	0.36	[0.10, 0.66]	0.33 / 0.40 / 0.35	0.0175	主要 / Holm
CDCP	T1I1 − Regenerate	4.81	[2.12, 7.63]	6.57 / 2.76 / 5.10	0.0100	主要 / Holm
CDCP	T1I1 − NoRisk	0.34	[0.07, 0.63]	0.30 / 0.41 / 0.30	0.0100	主要 / Holm
CDCP	SetLocal − Single	0.40	[0.05, 0.78]	0.39 / 0.41 / 0.40	0.0260	探索 / 原始 p
CDCP	Global − SetLocal	0.32	[0.02, 0.66]	0.30 / 0.39 / 0.29	0.0450	探索 / 原始 p
CDCP	Global − Single	0.73	[0.24, 1.25]	0.68 / 0.80 / 0.69	0.0040	探索 / 原始 p
CDCP	T1I1 − ThresholdFilter	2.93	[1.62, 4.31]	2.81 / 2.12 / 3.86	0.0010	探索 / 原始 p
CDCP	RelationOnly − ThresholdFilter	1.36	[0.31, 2.52]	1.32 / 0.43 / 2.31	0.0140	探索 / 原始 p
CDCP	T1I1 − MissingLow	0.00	[0.00, 0.00]	0.00 / 0.00 / 0.00	1.0000	探索 / 原始 p
CDCP	T1I1 − NoCalibration	0.66	[0.06, 1.31]	0.60 / 0.80 / 0.59	0.0330	探索 / 原始 p

在固定 T1 的条件下，追加修正 I1 使严格关系 F1 在 AAEC 和 CDCP 上分别比 I0 提高 3.38 和 5.68 个百分点，Holm 校正 p 值均为 0.0070。

允许修改组件并完整重建关系的配置，比只修改关系的 RelationOnly 高 1.18 和 1.57 个百分点，三个种子的差值均为正，校正 p 值均为 0.0070。表 4-8 显示，I1 多恢复了 23 和 7 条完整关系，多清除了 44 和 26 条误边，这些变化来自组件边界或类型的修正，以及错误组件所连关系的删除。这说明修改组件、并让其关系随之重建，是推理阶段增益的重要来源。

共同接受的方式同样重要。Single 比 Sequential 高 0.37 和 0.36 个百分点（Holm p 均为 0.0175），而 Sequential 本身又比 RelationOnly 高 0.33 和 0.49 个百分点。也就是说，修改组件本身就有帮助，而让组件和关系一起接受又能带来进一步的提升。

ThresholdFilter 使用同样的评分和门限删除低分关系，比 I0 提高 1.51 和 2.76 个百分点，但误删了 34 和 8 条原本正确的关系（表 4-8）。在相同的候选和评分下，RelationOnly 比它高 0.69 和 1.36 个百分点，完整的 I1 高 1.88 和 2.93 个百分点，三个种子的差值均为正。可见，简单的低分删边已有一定效果，而加入关系选择、组件修改和接受条件后，还能进一步显著提升。

表 4-6 中的 95%置信区间未经多重校正。全文 14 项主要比较均采用 Holm 校正并全部通过，本节报告其中的 5 组；ThresholdFilter 等对照为探索性比较，报告未校正的 p 值。

集合动作和全局求解也各有增益：SetLocal 比 Single 高 0.25 和 0.40 个百分点，置信区间均不含零，多恢复 3 和 1 条完整关系，多清除 11 和 6 条误边（表 4-8）；Global 在 SetLocal 的基础上再提高 0.23 和 0.32 个百分点。

局部求解逐个接受事务，全局求解同时选择全部端点和关系，正如 4.5.2 节所分析的，局部可达的结果都包含在全局可行域中，这与 Global 取得最好结果是一致的。主实验中全部 690 个输入的全局求解都得到了最优解，没有出现超时。

AAEC 测试文档 essay180（种子 17）是集合动作的一个典型案例。金标中的 Premise T11 为 [1256,1368)“A solid group can be a suited environment, which provides people to improve themselves or broaden their horizons”，它支持 Claim T10，并受到 T12、T13、T14 三个 Premise 的支持。G_0在逗号处把它错误地拆成了两个片段c_1=[1256,1297)和c_2=[1299,1368)，于是c_1→T10、T12→c_2、T13→c_2三条关系都因端点不对而成为 FP，T14→T11 则被漏掉。

固定评分为 q(c_1)=0.62、q(c_2)=0.66，合并后的 b=[1256,1368)得分 q(b)=0.93。单独删除任一片段都会降低组件效用；插入 b 则会因冲突同时删除两个片段，成为 2→1 的合并，所以 Single 无法完成这一修正。

SetLocal 和 Global 都接受了这一合并：组件效用增加 0.30；删除 3 条旧关系、重建 b→T10 以及 T12、T13、T14→b 四条关系后，关系效用增加 2.38；组件和关系分别编辑 3 次和 7 次。最终组件 TP 增加 1、FP 减少 2，关系 TP 增加 4、FP 减少 3。这正是命题 4-2 所描述的情形，修正前后的结构见图 4-3。

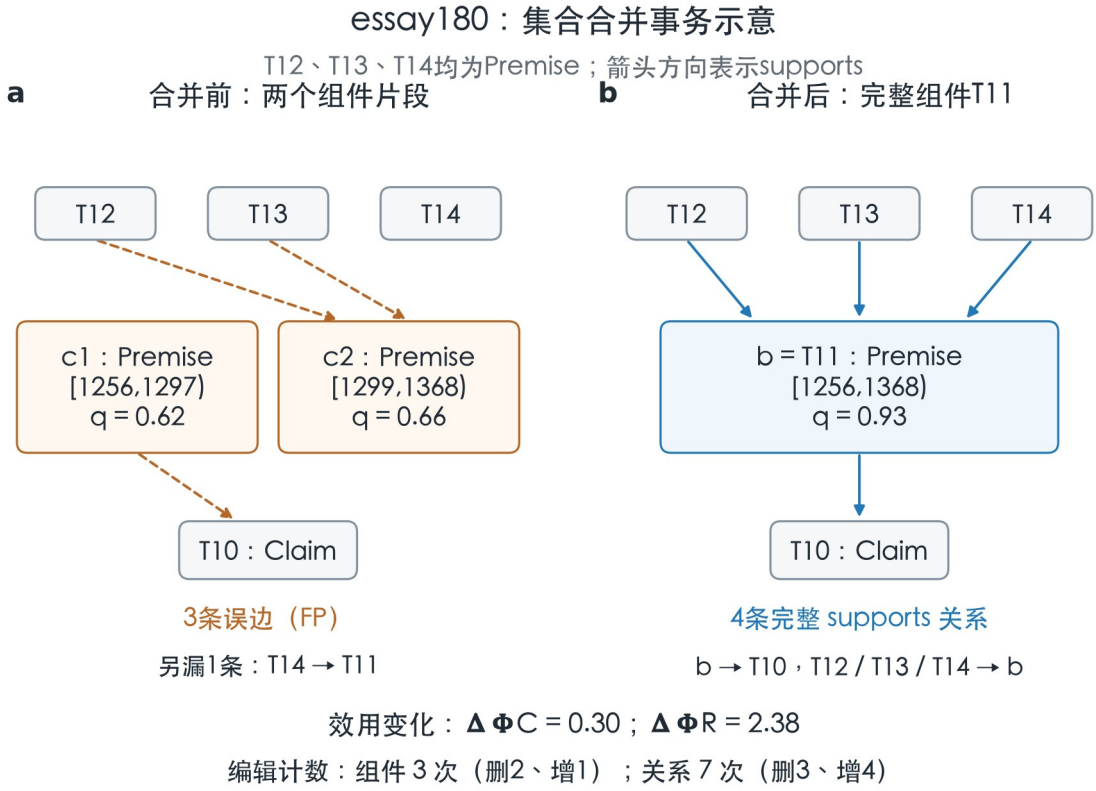


图 4-3 essay180 中组件合并与关系重建示意

注：（a）初始图把 T11 拆成了c_1和c_2，橙色虚线为三条端点错误的关系，T14→T11 未被输出。（b）合并后，蓝色实线为 b→T10 以及 T12、T13、T14→b 四条 supports 关系。

在相同的追加调用次数和 token 上限下，重新生成（Regenerate）的严格关系 F1 为 68.72 和 45.96，I1 分别比它高 2.91 和 4.81 个百分点（Holm p 为 0.0120 和 0.0100），三个种子的差值均为正。重新生成虽然恢复了较多关系，但也误删了 471 和 174 条原本正确的关系，原有正确关系的保留率只有 72.71%和 52.97%，而依赖闭合修正的保留率都超过 98%。这说明，在已有预测基础上做有约束的局部修改，比推倒重来更可靠。

表 4-7 显示，AAEC 和 CDCP 中分别有 98.3%和 89.4%的金标关系进入了候选池，其余关系无论如何搜索都无法恢复。

取消开发集风险限制（NoRisk）后，关系 F1 下降 0.29 和 0.34 个百分点，误删的正确关系由 23 和 4 条增加到 31 和 7 条，F1 下降的文档—种子数由 14 和 3 增加到 17 和 6。开发集上也观察到同样的趋势（表 B-1）。可见，风险限制有效减少了误改，但并不能保证每篇文档都得到改善。

使用未校准的评分时，关系 F1 下降 0.61 和 0.66 个百分点，AAEC 误删的正确关系由 23 条增加到 33 条，说明评分校准对接受决策有直接影响。下一节进一步分析评分质量。

4.6.2 候选覆盖分析

表 4-7 金标对象在候选、评分和选择各环节的保留情况（三个种子合计）

语料	金标组件	组件入池	金标关系	全部端点入池	完整关系入池	评分过门	过门且端点被选	最终 TP
AAEC	3798	3778	2427	2411	2386	1793	1737	1736
CDCP	3078	3032	756	735	676	415	386	386

计数单位为文档×种子×对象。AAEC 和 CDCP 的金标组件总数分别为 3798 和 3078，完整关系总数为 2427 和 756。“评分过门”以关系已进入候选池为前提，“端点被选”进一步要求这些关系的全部端点出现在最终图中。最终 TP 按完整对象匹配计算，多前提关系只命中部分源组件不算命中。

G_0中的合法对象全部保留在候选池中。CDCP 的补充槽位最多保留 64 个模型提案，总数不超过 256 个。

4.6.3 评分质量与误改分析

表 4-8 各配置的误改统计与逐文档影响

语料	配置	原 TP	恢复 TP	误删 TP	删除 FP	新增 FP	原 TP 保留率	F1 下降的文档—种子数／总数
AAEC	T1I1	1726	33	23	230	9	98.67%	14 / 240
AAEC	RelationOnly	1726	10	18	186	13	98.96%	15 / 240
AAEC	ThresholdFilter	1726	0	34	173	0	98.03%	24 / 240
AAEC	Single	1726	27	22	208	11	98.73%	15 / 240
AAEC	SetLocal	1726	30	22	219	10	98.73%	14 / 240
AAEC	Sequential	1726	24	23	192	13	98.67%	16 / 240

语料	配置	原 TP	恢复 TP	误删 TP	删除 FP	新增 FP	原 TP 保留率	F1 下降的文档—种子数／总数
AAEC	NoRisk	1726	35	31	228	16	98.20%	17 / 240
AAEC	NoCalibration	1726	30	33	217	14	98.09%	18 / 240
AAEC	Regenerate	1726	448	471	884	806	72.71%	107 / 240
CDCP	T1I1	370	20	4	141	4	98.92%	3 / 450
CDCP	RelationOnly	370	13	4	115	5	98.92%	5 / 450
CDCP	ThresholdFilter	370	0	8	120	0	97.84%	8 / 450
CDCP	Single	370	18	5	128	4	98.65%	4 / 450
CDCP	SetLocal	370	19	4	134	4	98.92%	3 / 450
CDCP	Sequential	370	17	5	121	5	98.65%	5 / 450
CDCP	NoRisk	370	21	7	140	7	98.11%	6 / 450
CDCP	NoCalibration	370	17	4	131	5	98.92%	4 / 450
CDCP	Regenerate	370	180	174	440	430	52.97%	106 / 450

主配置中，AAEC 有 14/240 个文档—种子记录的 F1 下降，CDCP 有 3/450 个，均不多于其他对照；取消风险限制后分别增加到 17/240 和 6/450。

表 4-9 开发集候选上的评分质量

语料	用途	对象类别	候选	正例	AUROC	AP	Brier	先验 Brier	ECE10	门限以上候选数	门限以上精确率
AAEC	calibration	C	3263	1402	0.9059	0.8580	0.0844	0.2450	0.0056	1418	0.887
AAEC	calibration	R	14290	851	0.8637	0.5743	0.0271	0.0561	0.0040	901	0.719
AAEC	strategy	C	3069	1323	0.9007	0.8436	0.0844	0.2452	0.0124	1366	0.880
AAEC	strategy	R	12826	804	0.8788	0.5943	0.0277	0.0588	0.0043	855	0.725
CDCP	calibration	C	3023	1042	0.8740	0.7753	0.1000	0.2259	0.0092	1031	0.839
CDCP	calibration	R	6894	270	0.7731	0.4163	0.0258	0.0376	0.0016	297	0.542
CDCP	strategy	C	3203	1094	0.8863	0.7924	0.0920	0.2249	0.0175	1076	0.856
CDCP	strategy	R	6906	225	0.8082	0.3794	0.0222	0.0315	0.0059	280	0.500

表 4-9 中，AUROC、AP、Brier 和 ECE 为三个种子的均值，候选数和正例数为三个种子的合计。表 4-10 显示，测试集上的评分质量与开发集接近，在这些评分指标上未见明显退化。 其中 AUROC 为 ROC 曲线下面积，AP 为平均精确率，ECE 为期望校准误差；先验 Brier 表示按类别先验给出恒定概率时的 Brier 分数。

表 4-10 测试集候选上的评分质量

语料／族	候选 n／正例	AUROC	AP	Brier／先验 Brier	ECE10	门限	门限以上候选数／正确	门限以上精确率／平均评分
AAEC/C	8800／3778	0.900	0.850	0.0877／0.2450	0.0073	0.5	3811／3368	0.884／0.885
AAEC/R	42510／2386	0.862	0.557	0.0266／0.0530	0.0034	0.5	2551／1793	0.703／0.707
CDCP/C	8835／3032	0.883	0.801	0.0904／0.2254	0.0165	0.5	3013／2577	0.855／0.835
CDCP/R	19222／676	0.801	0.383	0.0240／0.0339	0.0044	0.25	822／415	0.505／0.542

表 4-11 被接受修改的数量与正确率

语料	方法	提交数	组件增／删	关系增／删	新增关系正确	新增精确率	删除正确关系	误删占全部删除
AAEC	Sequential	156	23 / 15	37 / 215	24	64.86%	23	10.70%
AAEC	Single	151	18 / 24	38 / 230	27	71.05%	22	9.57%
AAEC	SetLocal	147	24 / 38	40 / 241	30	75.00%	22	9.13%
AAEC	T1I1	144	30 / 47	42 / 253	33	78.57%	23	9.09%
CDCP	Sequential	141	40 / 35	22 / 126	17	77.27%	5	3.97%
CDCP	Single	146	26 / 41	22 / 133	18	81.82%	5	3.76%
CDCP	SetLocal	139	29 / 49	23 / 138	19	82.61%	4	2.90%
CDCP	T1I1	132	30 / 52	24 / 145	20	83.33%	4	2.76%

AAEC 和 CDCP 的关系门限分别为 0.5 和 0.25，组件门限均为 0.5。图 4-4 中，灰色对角线表示理想校准，橙色线为门限，绿色区域为门限以上的候选。主配置新增的关系中，AAEC 有 33/42 条正确，CDCP 有 20/24 条正确。从 Sequential、Single、SetLocal 到 T1I1，AAEC 新增关系的精确率依次为 64.86%、71.05%、75.00%和 78.57%，CDCP 由 77.27%升至 83.33%，误删在全部删除中的比例也同步下降。这表明，修改范围越完整、接受条件越统一，修改本身越准确。 图 4-4 中的 C 和 R 分别表示组件与关系；各点之间的连线仅辅助阅读，不代表中间概率区间的样本分布。AAEC 关系在高分区仍有局部过度自信，因此接受决策还需同时满足分项效用门和编辑预算。 CDCP 关系最高分箱的实际样本量为 100。

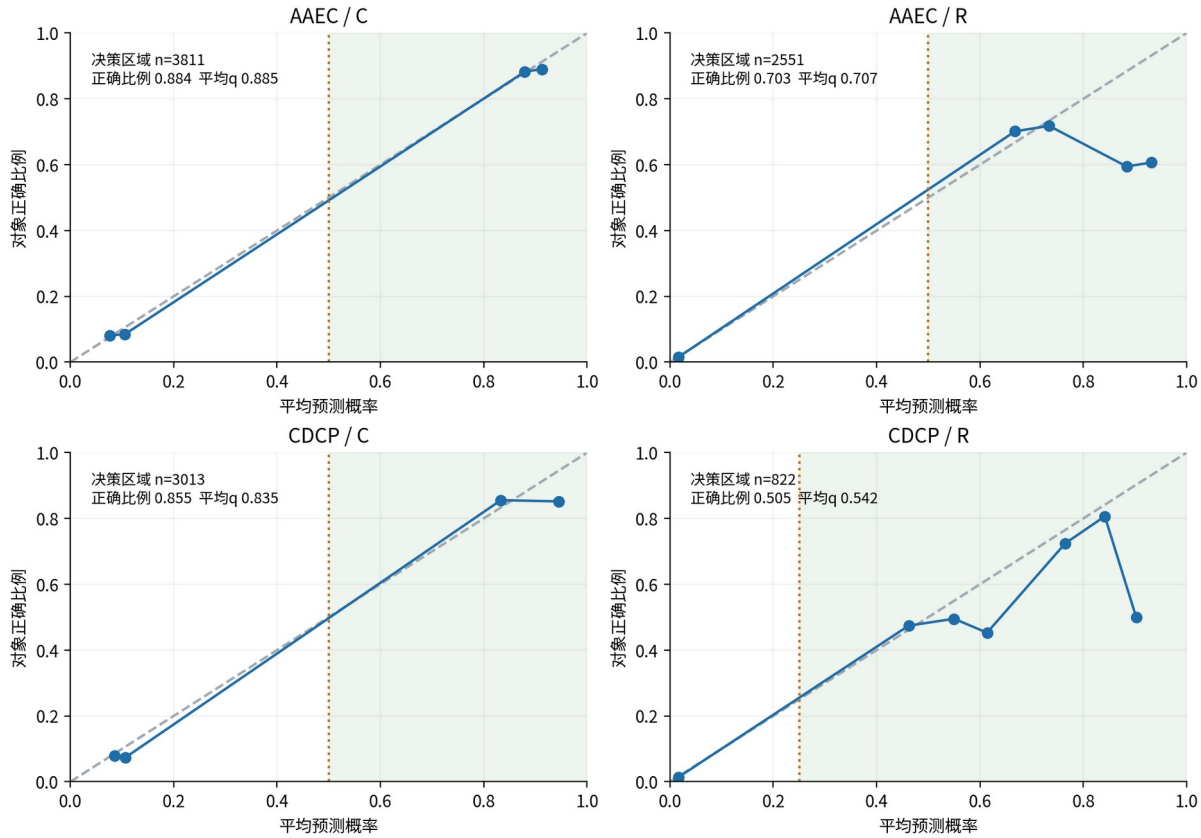


图 4-4 测试候选的校准与决策门限（CDCP 关系最高分箱 n=100）

主实验中没有出现评分缺失的情况。

表 4-12 逐文档推理成本（秒）

语料／方法	生成／重排	合法化	BR-O	追加生成	提案	评分	追加求解	总均值	总 P95
AAEC/T0I0	19.46	0.018	0.63	0.00	0.00	0.00	0.00	20.11	23.60
AAEC/T1I0	19.46	0.018	0.63	0.00	0.00	0.00	0.00	20.11	23.62
AAEC/Single	19.46	0.018	0.63	0.00	1.02	14.22	0.47	35.82	42.09
AAEC/SetLocal	19.46	0.018	0.63	0.00	1.02	14.22	1.28	36.63	42.72
AAEC/T1I1	19.46	0.018	0.63	0.00	1.02	14.22	0.73	36.08	42.38
AAEC/Regenerate	19.46	0.018	0.63	13.74	0.00	0.00	0.05	33.89	39.87
CDCP/T0I0	27.05	0.024	1.03	0.00	0.00	0.00	0.00	28.10	33.07
CDCP/T1I0	27.05	0.024	1.04	0.00	0.00	0.00	0.00	28.12	33.08

语料／方法	生成／重排	合法化	BR-O	追加生成	提案	评分	追加求解	总均值	总 P95
CDCP/ Single	27.05	0.024	1.04	0.00	1.48	19.71	0.75	50.05	58.91
CDCP/ SetLocal	27.05	0.024	1.04	0.00	1.48	19.71	2.10	51.41	60.29
CDCP/T1I1	27.05	0.024	1.04	0.00	1.48	19.71	1.18	50.48	59.39
CDCP/ Regenerate	27.05	0.024	1.04	19.30	0.00	0.00	0.08	47.50	56.02

追加修正使 AAEC 和 CDCP 的平均推理时间分别从 20.11 秒和 28.12 秒增加到 36.08 秒和 50.48 秒。从表 4-12 可以看出，新增开销主要来自对象评分（14.22 秒和 19.71 秒），求解本身只需 0.73 秒和 1.18 秒。因此，降低推理成本应优先从评分计算和缓存复用入手。

I1 和 Regenerate 都从G_0开始，追加的两次文本处理累计输入不超过 8192 个 token，输出不超过 2048 个 token。端到端时延为各阶段耗时之和。

4.6.4 多前提关系的评价示例

表 4-13 CDCP 文档 00662 中的一条双源 reason 关系

对象	原生类型	字符跨度	数据集原文
源 1	value	[0,53)	I generally prefer e-mail to telephone communication,
源 2	value	[54,110)	but you can't be sure the e-mail has reached the person.
目标	policy	[111,222)	I would suggest a notice that says, "If you don't acknowledge receipt of this e-mail, we'll start phoning you."

表 4-13 给出 CDCP 训练文档 00662 中的一条多前提关系。两个 value 分别表达偏好电子邮件和无法确认邮件是否送达，共同支持 policy，因此被标注为一条双源 reason 关系。评价时需要同时匹配完整的源集合、目标和标签，只预测其中一条单源关系无法命中该关系。这也是 5.4 节按源组件数分组分析的原因。

4.7 本章小结

本章针对推理阶段的结构修正问题，提出了依赖闭合的论辩图修正方法。首先，在固定的候选空间上训练完整对象评分器，并基于校准概率定义可分解的计数效用；然后，把组件修改与受影响关系的重建组织为一个事务，通过分项效用门和编辑预算决定是否接受；最后，给出全局整数规划和集合局部搜索两种求解方式，并分析了它

们的性质和适用条件。实验表明，在固定训练配置时，追加修正使严格关系 F1 在 AAEC 和 CDCP 上分别提高 3.38 和 5.68 个百分点；与只修改关系相比，允许修改组件并完整重建关系带来 1.18 和 1.57 个百分点的提升；组件与关系共同接受、集合动作和全局求解也都带来了额外增益。与相同预算的重新生成相比，本方法在大幅提高 F1 的同时保留了 98% 以上的原有正确关系。方法的主要代价是对象评分带来的额外推理时间，且仍有少数文档出现误改。

第五章将结合训练方法与推理方法，分析二者组合的效果、关系恢复的来源以及剩余的错误。

第五章 两阶段框架的综合分析

第三章研究了训练阶段的监督保持，第四章研究了推理阶段的关系依赖处理。本章把两者结合起来，分析它们如何共同影响抽取结果，依次考察总体性能、两阶段各自恢复了哪些关系以及剩余错误的来源，并给出跨骨干模型、外部系统和已发表结果的比较。

5.1 实验设置

本章比较训练与推理的四种组合：T0I0 为 MCR-BR 基线；T1I0 使用第三章的训练方法，推理沿用 I0；T0I1 使用基线训练，在G_0上追加第四章的依赖闭合修正；T1I1 同时使用两项方法。四种组合分别用于考察训练增量、推理增量以及二者的交互。所有实验使用相同的测试划分、评价规则和三个随机种子。

表 5-1 说明了不同比较的含义：固定推理为 I0 时，比较反映训练方法的作用；固定训练为 T1 时，比较反映追加修正的作用；四种组合放在一起，则可以分析两者的增益是重叠还是互补。至于成对目标、共同接受、集合动作等具体机制的作用，已在第三、四章的对照实验中分别分析。

表 5-1 本章各类比较的设置与目的

层次	固定条件	回答问题
训练增量	骨干、更新预算、I0	整套训练是否改善抽取
推理增量	T1 检查点及 I0 终态；追加候选、评分与规则	在同一 I0 终态上追加R_{DC}是否改善结果
两阶段组合	同一测试文档、种子与完整对象	增量的重叠与交互
外部系统	官方测试划分、完整对象评价器	系统层面的共同任务比较

此外，5.6 节在相同骨干和评价器下比较外部系统 UniASA 和 TextToText，5.7 节列出已发表方法的报告结果并说明评价协议的差异。

5.2 两阶段组合的效果

5.2.1 总体性能

表 5-2 给出四种配置的组件 F1 和关系 F1，“±”后为三个种子的样本标准差。

表 5-2 两阶段配置的组件与关系抽取性能

配置	AAEC 组件 F1	AAEC 关系 F1	CDCP 组件 F1	CDCP 关系 F1
T0I0	85.64 ± 0.07	65.69 ± 3.50	80.40 ± 1.24	41.79 ± 2.65
T1I0	87.85 ± 0.39	68.25 ± 2.08	83.46 ± 1.04	45.08 ± 2.73
T0I1	86.50 ± 0.15	69.43 ± 3.41	81.67 ± 1.12	47.69 ± 2.47
T1I1	88.47 ± 0.46	71.63 ± 2.11	84.45 ± 0.94	50.77 ± 2.45

在 Qwen3.5-9B 骨干下，T1I1 的组件 F1 和严格关系 F1 在两个语料上都是四种配置中最高的，关系 F1 分别为 71.63 和 50.77，比 T0I0 基线的 65.69 和 41.79 分别高 5.94 和 8.98 个百分点。

5.2.2 增益分解与交互分析

表 5-3 列出各项比较的平均配对差值、95%置信区间以及三个种子各自的差值。由于均值和差值都由未舍入的逐种子结果计算后再保留两位小数，表 5-2 中均值直接相减的结果可能与表 5-3 相差 0.01 个百分点，分析以表 5-3 为准。

表 5-3 四种配置的关系 F1 差值与交互

语料	比较	差值（百分点）	单项 95% CI	三个种子差值	类型
AAEC	T1I0 − T0I0	2.56	[0.92, 4.39]	1.26 / 2.34 / 4.07	主要
AAEC	T1I1 − T1I0	3.38	[2.56, 4.23]	3.30 / 3.54 / 3.31	主要
AAEC	T0I1 − T0I0	3.74	[2.82, 4.69]	3.58 / 3.84 / 3.78	探索
AAEC	T1I1 − T0I0	5.94	[4.01, 7.88]	4.56 / 5.88 / 7.38	探索
AAEC	Interaction − 0	-0.35	[-0.85, 0.03]	-0.27 / -0.30 / -0.48	探索
CDCP	T1I0 − T0I0	3.30	[1.56, 5.17]	2.81 / 3.50 / 3.58	主要
CDCP	T1I1 − T1I0	5.68	[4.03, 7.47]	5.40 / 5.40 / 6.24	主要
CDCP	T0I1 − T0I0	5.91	[4.21, 7.75]	5.59 / 5.80 / 6.33	探索
CDCP	T1I1 − T0I0	8.98	[6.56, 11.66]	8.21 / 8.91 / 9.82	探索
CDCP	Interaction − 0	-0.22	[-0.95, 0.35]	-0.18 / -0.40 / -0.08	探索

训练和推理两项方法的增益都是显著的（见第三、四章的主要比较），完整配置相对基线的提升为 5.94 和 8.98 个百分点。下面进一步检验二者之间是否存在交互。

交互项定义为(T1I1−T1I0)−(T0I1−T0I0)。AAEC 上的估计值为-0.35 个百分点（95%置信区间[-0.85, 0.03]），CDCP 上为-0.22 个百分点（[-0.95, 0.35]），两个区间都包含零，尚不能确定交互项的方向。从点估计看，组合增益接近两项单独增益之

和，可描述为基本叠加；训练改进之后，推理修正仍带来额外提升。图 5-1 展示了四种配置的总体表现，5.3 节进一步分析两者分别恢复了哪些关系。

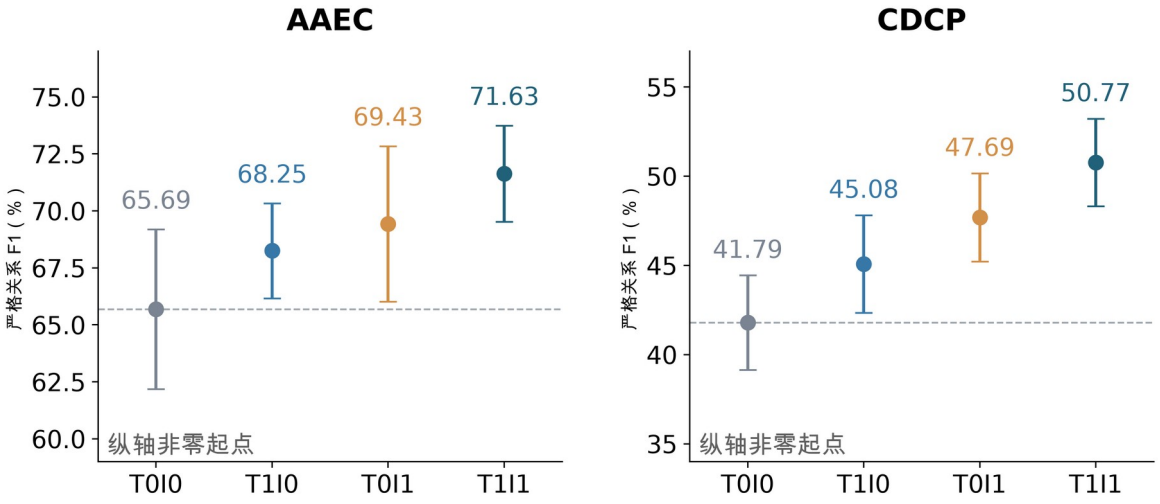


图 5-1 两种语料上四种配置的关系 F1（误差棒为三个种子的样本标准差；纵轴非零起点）

5.3 关系恢复与漏检分析

关系 F1 的变化同时来自三个方面：恢复正确关系、减少误报以及丢失原有正确关系。本节先比较两阶段各自恢复的关系，再从端点和关系选择两个层面分析漏检的原因。

5.3.1 两阶段恢复关系的对比

表 5-4 以 T0I0 中预测正确的关系为基准，在每个种子内按关系的完整身份（文档、源集合、目标和标签），比对两种单独配置和完整配置中新增的 TP，区分两阶段共同恢复、各自独有恢复和组合后才恢复的关系。表中计数为三个种子的合计。

表 5-4 两阶段恢复关系的分解（三个种子合计）

语料	初始 TP	共同恢复	训练独有	修正独有	组合独有	单阶段恢复后在组合中丢失	丢失初始 TP	完整 TP
AAEC	1658	6	82	31	1	1	41	1736
CDCP	343	2	28	20	0	0	7	386

“共同恢复”是 T1I0 和 T0I1 相对 T0I0 新增 TP 的交集，“训练独有”和“修正独有”分别是各自的差集，“组合独有”是只在 T1I1 中新增的 TP。完整配置也可能丢失单独配置恢复的关系或初始的 TP。各项满足：初始 TP + 共同恢复 + 训练独有 + 修正独有 + 组合独有−丢失单路恢复−丢失初始 TP = 完整 TP。

两阶段恢复的关系几乎没有重叠。AAEC 上，训练独有和修正独有的关系分别为 82 条和 31 条，共同恢复的只有 6 条，组合独有 1 条；CDCP 上分别为 28、20、2 和 0 条。这表明两项方法在恢复对象上具有互补性。

当然，完整配置也会丢失一些正确关系：AAEC 丢失单路恢复的关系 1 条、初始 TP 41 条，CDCP 分别为 0 条和 7 条，但与恢复的数量相比要少得多。

5.3.2 漏检原因分析

要恢复一条完整关系，其正确的端点必须都出现在最终图中。表 5-5a 把未命中的金标关系分为两类：“端点缺失”指缺少关系所需的组件；“端点齐全但未选”指正确端点都已存在，但没有选中这条关系。

表 5-5a 四种配置下未命中关系的分类

语料	配置	金标	TP	端点缺失	端点齐全但未选
AAEC	T0I0	2427	1658	637	132
AAEC	T1I0	2427	1726	546	155
AAEC	T0I1	2427	1673	601	153
AAEC	T1I1	2427	1736	517	174
CDCP	T0I0	756	343	294	119
CDCP	T1I0	756	370	260	126
CDCP	T0I1	756	361	283	112
CDCP	T1I1	756	386	251	119

从 T0I0 到 T1I1，AAEC 中端点缺失的关系从 637 条减少到 517 条，端点齐全但未选的关系从 132 条增加到 174 条；CDCP 中前者从 294 条减少到 251 条，后者保持 119 条不变。可见，端点缺失类漏检有所减少，但端点齐全后仍有关系未被选中。整体 F1 还受误报变化影响，表 5-6 进一步报告了各类关系的 TP、FP 和 FN。

表 5-5b 进一步把完整配置中的每条未命中关系归入它遇到的第一个阻断环节（每条只归一次），依次为：最终图中端点缺失、候选槽位未入池、未评分、评分未过门、受联合约束或接受门限制、超时。

表 5-5b T1I1 未命中关系的首个阻断环节

语料	金标	TP	终态端点缺失	完整槽位未入池	未评分	评分未过门	联合约束／接受门	超时
AAEC	2427	1736	517	6	0	167	1	0
CDCP	756	386	251	5	0	114	0	0

结果显示，未命中的关系主要集中在“端点缺失”和“评分未过门”两个环节：AAEC 分别为 517 条和 167 条，CDCP 分别为 251 条和 114 条。槽位未入池的只有 6 条和 5 条，受约束或接受门限制的只有 AAEC 的 1 条，未评分和超时均为 0。因此，进一步提升的重点在于组件识别和关系评分。

5.4 多前提关系分析

CDCP 的一条关系需要完整的源集合、目标和标签同时匹配，源组件越多，完整命中需要同时恢复的端点就越多。因此，本节按源组件数分组观察结果。测试集共有 252 条关系，其中单源 218 条、双源 20 条、三源 6 条、四源及以上 8 条，多源关系共 34 条。

表 5-6 按源组件数分组汇总四种配置的结果，TP、FP 和 FN 为三个种子的合计，关系 F1 及标准差由逐种子结果计算。

表 5-6 CDCP 按源组件数分组的结果

源数	配置	TP	FP	FN	关系 F1（均值 ± SD）
1	T0I0	309	494	345	42.41 ± 1.37
1	T1I0	335	468	319	45.98 ± 1.72
1	T0I1	325	361	329	48.49 ± 1.60
1	T1I1	349	342	305	51.88 ± 1.73
2	T0I0	24	27	36	42.88 ± 12.04
2	T1I0	25	26	35	44.73 ± 11.54
2	T0I1	24	19	36	45.94 ± 10.64
2	T1I1	25	19	35	47.63 ± 11.56
3	T0I0	8	7	10	47.58 ± 26.45
3	T1I0	8	7	10	47.58 ± 26.45
3	T0I1	8	6	10	48.32 ± 25.29
3	T1I1	8	6	10	48.32 ± 25.29
≥4	T0I0	2	14	22	10.82 ± 9.57
≥4	T1I0	2	14	22	10.82 ± 9.57
≥4	T0I1	4	10	20	21.37 ± 10.36
≥4	T1I1	4	11	20	21.65 ± 12.75

相对基线，完整配置的 TP 净增主要来自单源关系（增加 40 条），双源、三源和四源及以上分别增加 1、0 和 2 条；单源组的 FP 则从 494 减少到 342。多源组 F1 的提

高也有相当一部分来自误报的减少。四源及以上的关系只有 8 条，在 T1I1 中的计数为 TP=4、FP=11、FN=20，数量太少，只能做描述性分析。

长源关系的困难可以分为三个环节：对象表达、正确端点恢复和关系选择。以上分析均基于 9B 骨干，下一节考察方法在其他骨干上的表现。

5.5 不同骨干模型上的结果

三种骨干承担不同的作用：Qwen3.5-9B 用于主实验、完整消融和错误分析，Qwen3.5-4B 用于考察同系列的较小模型，Qwen2.5-7B-Instruct 用于与已有生成式方法衔接。三者使用相同的数据划分、随机种子和预测协议，并共用 9B 模型生成和审核的增强数据；抽取生成器、对象评分器、源组提案器、OOF 校准和开发集策略则在各骨干上分别训练和选择。

三种骨干的结构和可训练参数量见表 5-7。Qwen3.5-9B 和 4B 均为 32 层，包括 8 个门控全注意力块和 24 个线性注意力块，隐藏维度分别为 4096 和 2560；Qwen2.5-7B 为 28 层 GQA 结构，隐藏维度为 3584。

表 5-7 各骨干适配参数（rank 固定为 16）

骨干	隐藏维	全注意力块	每分支 LoRA	T0 可训练	T1/AAEC	T1/CDCP
Qwen3.5-9B	4096	8	3,932,160	7,884,801	28,871,687	28,873,737
Qwen3.5-4B	2560	8	3,145,728	6,304,257	19,426,823	19,428,873
Qwen2.5-7B-Instruct	3584	28	10,092,544	20,203,009	38,568,455	38,570,505

Qwen3.5 骨干在 8 个全注意力块上挂载 LoRA，Qwen2.5 则在全部 28 个注意力块上挂载，因此在 rank 相同时，Qwen2.5 的 LoRA 参数量反而高于 9B。训练轮数、批量大小、增强数据和编辑预算在各骨干间保持一致，各模块的输入维度见附录 A.4。

表 5-8 三种骨干的四种配置结果（均值 ± SD）

骨干	组合	AAEC 组件	AAEC 关系	CDCP 组件	CDCP 关系
Qwen3.5-9B	T0I0	85.64 ± 0.07	65.69 ± 3.50	80.40 ± 1.24	41.79 ± 2.65
Qwen3.5-9B	T1I0	87.85 ± 0.39	68.25 ± 2.08	83.46 ± 1.04	45.08 ± 2.73
Qwen3.5-9B	T0I1	86.50 ± 0.15	69.43 ± 3.41	81.67 ± 1.12	47.69 ± 2.47
Qwen3.5-9B	T1I1	88.47 ± 0.46	71.63 ± 2.11	84.45 ± 0.94	50.77 ± 2.45
Qwen3.5-4B	T0I0	84.15 ± 0.35	63.43 ± 4.03	78.59 ± 1.35	38.42 ± 2.44
Qwen3.5-4B	T1I0	86.54 ± 0.25	66.65 ± 2.22	81.91 ± 1.09	43.08 ± 3.58
Qwen3.5-4B	T0I1	84.97 ± 0.13	67.05 ± 3.80	79.98 ± 1.16	44.29 ± 2.04
Qwen3.5-4B	T1I1	87.24 ± 0.49	70.07 ± 2.15	83.00 ± 0.91	49.03 ± 3.46
Qwen2.5-7B-Instruct	T0I0	82.62 ± 0.51	61.08 ± 4.58	76.39 ± 1.81	34.87 ± 2.18

骨干	组合	AAEC 组件	AAEC 关系	CDCP 组件	CDCP 关系
Qwen2.5-7B-Instruct	T1I0	85.14 ± 0.20	64.60 ± 2.98	80.43 ± 1.29	40.69 ± 2.31
Qwen2.5-7B-Instruct	T0I1	83.50 ± 0.26	64.38 ± 4.36	77.65 ± 1.25	40.32 ± 1.66
Qwen2.5-7B-Instruct	T1I1	85.94 ± 0.24	67.96 ± 2.70	81.25 ± 0.91	46.43 ± 2.16

如表 5-8 所示，Qwen3.5-9B 的基线和完整配置都是三者中最高的，相对同骨干基线的关系 F1 提升为 5.94 和 8.98 个百分点；4B 上为 6.64 和 10.61 个百分点，Qwen2.5-7B-Instruct 上为 6.88 和 11.56 个百分点。可以看到，基线越强，提升幅度略小，但本文方法在三种骨干上都带来了稳定的提升。

表 5-9 补充骨干上的配对差值与显著性

骨干	语料	比较	差值（百分点）	单项 95% CI	补充 Holm p
Qwen3.5-4B	AAEC	T1I0−T0I0	3.22	[1.05, 5.41]	0.0070
Qwen3.5-4B	AAEC	T1I1−T1I0	3.42	[2.49, 4.35]	0.0060
Qwen3.5-4B	AAEC	T1I1−T0I0	6.64	[4.14, 8.93]	0.0060
Qwen3.5-4B	CDCP	T1I0−T0I0	4.66	[2.64, 7.03]	0.0060
Qwen3.5-4B	CDCP	T1I1−T1I0	5.95	[4.23, 7.80]	0.0060
Qwen3.5-4B	CDCP	T1I1−T0I0	10.61	[7.90, 13.36]	0.0060
Qwen2.5-7B-Instruct	AAEC	T1I0−T0I0	3.52	[1.33, 5.59]	0.0070
Qwen2.5-7B-Instruct	AAEC	T1I1−T1I0	3.36	[2.31, 4.40]	0.0060
Qwen2.5-7B-Instruct	AAEC	T1I1−T0I0	6.88	[4.27, 9.32]	0.0060
Qwen2.5-7B-Instruct	CDCP	T1I0−T0I0	5.82	[3.68, 8.14]	0.0060
Qwen2.5-7B-Instruct	CDCP	T1I1−T1I0	5.74	[3.94, 7.65]	0.0060
Qwen2.5-7B-Instruct	CDCP	T1I1−T0I0	11.56	[8.73, 14.35]	0.0060

补充骨干的比较共 12 项（2 种骨干×2 个语料×3 项比较），使用与主实验相同的重采样索引，并单独进行 Holm 校正。所有增量均为正，校正后的 p 值均低于 0.05（表 5-9）。

5.6 与外部系统的比较

本节以 UniASA[48]和 Kawarada 等的 TextToText[7]为外部对照，在 Qwen3.5-9B 骨干上重新训练这两种方法。它们保留各自的模型结构和训练目标，但使用与本文相同的测试划分和严格评价器。表 5-10 给出完整结果，表 5-11 给出配对差值。

在格式转换上，AAEC 预测的 stance 作为组件属性保留；字符跨度和组件类型按预测结果转换，无法解析的端点不借助金标补回。CDCP 统一使用排序后的源集合，但本文实现的外部适配接口最多表示 3 个源组件，而测试集 252 条关系中有 8 条包含四个及以上源组件，源集合收缩后的预测按严格匹配计 FP，未匹配的完整金标计 FN，不展开为二元真阳性。

外部对照同样使用三个随机种子。由于各方法的任务建模不同，这组比较属于系统层面的比较，单独作为探索性结果报告。

表 5-10 与外部系统的比较（相同骨干与评价器）

语料	系统	组件 F1	关系 F1	关系 F1：17 / 29 / 43
AAEC	UniASA	84.91 ± 0.38	64.89 ± 3.32	67.81 / 65.59 / 61.28
AAEC	TextToText	84.07 ± 0.48	63.19 ± 3.12	66.51 / 62.75 / 60.31
AAEC	T0I0	85.64 ± 0.07	65.69 ± 3.50	68.76 / 66.43 / 61.89
AAEC	T1I1	88.47 ± 0.46	71.63 ± 2.11	73.32 / 72.31 / 69.26
CDCP	UniASA	78.82 ± 1.50	40.36 ± 2.36	40.45 / 42.68 / 37.96
CDCP	TextToText	77.18 ± 1.81	38.89 ± 1.18	38.73 / 40.14 / 37.80
CDCP	T0I0	80.40 ± 1.24	41.79 ± 2.65	41.19 / 44.68 / 39.49
CDCP	T1I1	84.45 ± 0.94	50.77 ± 2.45	49.40 / 53.59 / 49.31

表 5-11 T1I1 相对外部系统的关系 F1 差值

语料	比较	差值（百分点）	单项 95% CI	原始 p
AAEC	T1I1 − UniASA	6.74	[4.69, 8.75]	0.0005
AAEC	T1I1 − TextToText	8.44	[6.11, 10.84]	0.0005
CDCP	T1I1 − UniASA	10.41	[7.33, 13.39]	0.0005
CDCP	T1I1 − TextToText	11.87	[8.34, 15.11]	0.0005

如表 5-10 所示，在相同骨干和评价器下，本文完整方法的严格关系 F1 在两个语料上都明显高于两种外部方法，AAEC 上分别高 6.74 和 8.44 个百分点，CDCP 上分别高 10.41 和 11.87 个百分点（表 5-11）。

5.7 与已发表结果的比较

表 5-12 列出 AAEC 和 CDCP 上代表性端到端方法的文献报告值，以及本文完整方法的结果。其中，MCR-BR[34]是本文的直接基础，原文使用 Qwen2.5-7B-Instruct 骨干。需要注意，文献中的数值采用各自的评价协议，本文结果采用第二章定义的严格评价。

表 5-12 已发表方法的报告结果与本文结果

方法	骨干	AAEC 输入单位	AAEC 组件 F1	AAEC 关系 F1	CDCP 组件 F1	CDCP 关系 F1
LSTM-ER，Eger 等[4]	BiLSTM	段落	70.83	45.52	—	—
GMAM[47]	BART-base	段落	75.94	50.08	57.72	16.57
DENIM[12]	BART-base	段落	76.50	58.51	—	—
ST，Morio 等[25]	Longformer-base	全文	75.54	55.17	68.90	31.94
MT-All，Morio 等[25]	Longformer-base	全文	75.66	55.17	68.81	33.74
TextToText，Kawarada 等[7]	FLAN-T5-XXL	全文	80.15	61.19	72.68	33.96
UniASA[48]	LongT5-base / T5-base	全文	77.60	56.33	68.16	30.57
UniASA[48]	Llama-3-8B	全文	79.70	59.34	70.83	35.58
AASP[9]	Flan-T5-Large	段落†	79.29	62.69	62.14	35.77
MCR-BR[34]	Qwen2.5-7B-Instruct	未单列‡	83.71	64.83	76.45	38.17
本文 T1I1	Qwen2.5-7B-Instruct	全文	85.94 ± 0.24	67.96 ± 2.70	81.25 ± 0.91	46.43 ± 2.16
本文 T1I1	Qwen3.5-9B	全文	88.47 ± 0.46	71.63 ± 2.11	84.45 ± 0.94	50.77 ± 2.45

注：Morio 等[25]的 ST 和 MT-All 取原文表 4 中不使用 oracle 跨度的结果；原文表 5 另按 Eger 等的评价脚本报告了 ST，AAEC 全文级为 76.55/54.66，段落级为 76.48/59.55。Kawarada 等[7]取表 4 的全文级结果 80.15/61.19（段落级为 78.40/61.87），CDCP 取表 6。†AASP[9]取表 I 的 ACC 与 ARC 列，为段落级输入。‡MCR-BR 沿用 Kawarada 等的划分和评价脚本。各文献对 AAEC 立场和关系匹配的处理方式不同。

评价协议对数值影响很大。本文把 AAEC 的 stance 作为组件属性，CDCP 按完整源集合、目标和标签匹配。在 Qwen2.5-7B-Instruct 上，按 MCR-BR 原协议复现的关系 F1 为 64.77 和 38.08，与其报告值 64.83 和 38.17 基本一致；而在本文的严格协议下，同一模型只有 61.08 和 34.87。因此，本文结果与文献数值的比较需要考虑协议差异；在严格协议下，本文完整方法在同一骨干上仍比 MCR-BR 提高 6.88 和 11.56 个百分点（表 5-8）。

5.8 本章小结

本章分析了训练方法与推理方法的组合效果。两者组合时增益基本可以叠加，完整配置在两个语料上取得最高的组件 F1 和关系 F1；两阶段恢复的关系几乎不重叠，体现了恢复对象的互补性。剩余漏检主要来自组件端点缺失和关系评分未过门，长源关系还受到接口表达能力的限制。跨骨干实验和外部系统比较进一步验证了方法的有效性。

第六章 总结与展望

本章总结全文的研究工作，讨论方法的局限，并展望后续研究方向。

6.1 研究总结

针对 RQ1，本文提出了关系影响域约束的增强与成对学习方法。该方法通过关系影响域确定改写可能影响的范围，把原标注迁移到改写文本上，并逐项审核哪些组件和关系仍然可靠；训练时原文提供完整论辩图监督，改写文本只在可靠因素上提供辅助监督和成对约束。实验表明，该方法使 AAEC 和 CDCP 上的严格关系 F1 分别提高 2.56 和 3.30 个百分点，其中成对目标本身贡献了 1.39 和 2.57 个百分点；代价是训练时间分别增加 2.67 和 4.52 GPU 小时。人工分层审核显示，被接受关系因素的加权不安全率估计为 0.81%和 0.91%。

针对 RQ2，本文提出了依赖闭合的论辩图修正方法。该方法把组件修改与受影响关系的重建放进同一个事务，在固定评分下通过分项效用门和编辑预算决定是否接受，并提供全局与局部两种求解方式。实验表明，在固定训练配置时，追加修正使严格关系 F1 分别提高 3.38 和 5.68 个百分点；完整重建关系、组件与关系共同接受、集合动作和全局求解都带来了额外增益；与相同预算的重新生成相比，本方法在提高 F1 的同时保留了 98%以上的原有正确关系。

两项方法结合后，Qwen3.5-9B 上的完整配置在 AAEC 和 CDCP 上取得 71.63 和 50.77 的严格关系 F1，比同骨干的 MCR-BR 基线分别提高 5.94 和 8.98 个百分点，全文 14 项主要比较均通过 Holm 校正。两阶段恢复的关系几乎不重叠，增益基本可以叠加。在 Qwen3.5-4B 和 Qwen2.5-7B-Instruct 上，方法同样带来了显著提升。 与 QOS 直接继承改写前标注的做法相比，本文显式审核受影响的关系因素；与 MCR-BR 已有的多候选重排序和有界修改相比，本文新增的是可靠因素成对学习及组件—关系依赖闭合决策。

6.2 局限性

本文方法仍存在以下局限。第一，代理效用与严格 F1 并不完全一致，主配置中仍有少数文档的 F1 下降（AAEC 为 14/240，CDCP 为 3/450 个文档—种子记录）；同时，对象评分和搜索增加了推理时间。第二，方法的效果依赖评分质量：使用未校准的评分时，关系 F1 下降 0.61 和 0.66 个百分点；若评分质量不足以通过开发集筛选，推理阶段将不执行修正，也就无法带来增益。

第三，实验只使用了三个随机种子，CDCP 中长源关系的测试样本较少，相关的细粒度结论仍需更多数据验证。第四，本文只在 AAEC 和 CDCP 两个英文语料上进行了评价，跨语言和跨领域的效果还有待检验。

6.3 后续研究

后续研究可以从以下几个方面展开。在训练方面，可以分析成对约束如何影响对应因素的表示和预测分布。在推理方面，可以改进多前提关系的源组件提案，扩充长源关系的测试样本，并针对代理效用上升而 F1 下降的情况研究更好的代价敏感校准；还可以探索更低成本的评分方法和更大的拆分、合并邻域。此外，还可以在新领域和其他语言的语料上检验方法的迁移能力。

参考文献

[1] LAWRENCE J, REED C. Argument mining: A survey[J]. Computational Linguistics, 2019, 45(4): 765–818. DOI: 10.1162/coli_a_00364.

[2] STAB C, GUREVYCH I. Parsing argumentation structures in persuasive essays[J]. Computational Linguistics, 2017, 43(3): 619–659. DOI: 10.1162/COLI_a_00295.

[3] PARK J, CARDIE C. A corpus of eRulemaking user comments for measuring evaluability of arguments[C]//Proceedings of the Eleventh International Conference on Language Resources and Evaluation. Miyazaki: European Language Resources Association, 2018.

[4] EGER S, DAXENBERGER J, GUREVYCH I. Neural end-to-end learning for computational argumentation mining[C]//Proceedings of the 55th Annual Meeting of the Association for Computational Linguistics, Volume 1. Vancouver: Association for Computational Linguistics, 2017: 11–22. DOI: 10.18653/v1/P17-1002.

[5] MORIO G, OZAKI H, MORISHITA T, et al. Towards better non-tree argument mining: Proposition-level biaffine parsing with task-specific parameterization[C]//Proceedings of the 58th Annual Meeting of the Association for Computational Linguistics. Association for Computational Linguistics, 2020: 3259–3266. DOI: 10.18653/v1/2020.acl-main.298.

[6] CAPUTO E, GRECO S, LA CAVA L. Argument component segmentation with fine-tuned large language models[C]//Findings of the Association for Computational Linguistics: EACL 2026. Rabat: Association for Computational Linguistics, 2026: 5154–5167. DOI: 10.18653/v1/2026.findings-eacl.272.

[7] KAWARADA M, HIRAO T, UCHIDA W, et al. Argument mining as a text-to-text generation task[C]//Proceedings of the 18th Conference of the European Chapter of the Association for Computational Linguistics, Volume 1. St. Julian's: Association for Computational Linguistics, 2024: 2002–2014. DOI: 10.18653/v1/2024.eacl-long.121.

[8] CABESSA J, HERNAULT H, MUSHTAQ U. Argument mining with fine-tuned large language models[C]//Proceedings of the 31st International Conference on Computational Linguistics. Abu Dhabi: Association for Computational Linguistics, 2025: 6624–6635.

[9] DAS N, VAIBHAV V, CHOUDHARY Y S, et al. End-to-end argument mining through autoregressive argumentative structure prediction[EB/OL]. arXiv:2510.16363v1, 2025[2026-09-14]. DOI: 10.48550/arXiv.2510.16363.

[10] CAPUTO E, GRECO S, LA CAVA L. ARGUS: Towards end-to-end argument mining with large language models[C]//Proceedings of the AAAI Conference on Artificial Intelligence, 2026, 40(48): 41547–41549. DOI: 10.1609/aaai.v40i48.42335.

[11] LI H, SCHLEGEL V, SUN Y, et al. Large language models in argument mining: A survey[EB/OL]. arXiv:2506.16383v6, 2025[2026-09-13]. DOI: 10.48550/arXiv.2506.16383.

[12] SUN Y, CHEN G, YANG C, et al. Discourse structure-aware prefix for generation-based end-to-end argumentation mining[C]//Findings of the Association for Computational Linguistics: ACL 2024. Bangkok: Association for Computational Linguistics, 2024: 11597–11613. DOI: 10.18653/v1/2024.findings-acl.689.

[13] DAS N, SARADHI V V, ANAND A. On the role of key phrases in argument mining[C]//Findings of the Association for Computational Linguistics: NAACL 2025. Albuquerque: Association for Computational Linguistics, 2025: 5774–5787. DOI: 10.18653/v1/2025.findings-naacl.319.

[14] SUN Y, CHEN G, ALINEJAD-ROKNY H, et al. Learning first-order logic rules for argumentation mining[C]//Proceedings of the 63rd Annual Meeting of the Association for Computational Linguistics, Volume 1. Vienna: Association for Computational Linguistics, 2025: 14133–14148. DOI: 10.18653/v1/2025.acl-long.691.

[15] DING B, QIN C, ZHAO R, et al. Data augmentation using LLMs: Data perspectives, learning paradigms and challenges[C]//Findings of the Association for Computational Linguistics: ACL 2024. Bangkok: Association for Computational Linguistics, 2024: 1679–1705. DOI: 10.18653/v1/2024.findings-acl.97.

[16] EVURU C K, GHOSH S, KUMAR S, et al. CoDa: Constrained generation based data augmentation for low-resource NLP[C]//Findings of the Association for Computational Linguistics: NAACL 2024. Mexico City: Association for Computational Linguistics, 2024: 3754–3769. DOI: 10.18653/v1/2024.findings-naacl.238.

[17] PEI Y, BHUSE P, LIU Z, et al. SegMix: A simple structure-aware data augmentation method[EB/OL]. arXiv:2311.09505v1, 2023[2026-09-13]. DOI: 10.48550/arXiv.2311.09505.

[18] SUN W, LI M, DAVIS J, et al. Weakly-supervised argument mining with boundary refinement and relation denoising[C]//Proceedings of the Ninth Fact Extraction and VERification Workshop (FEVER). Rabat: Association for Computational Linguistics, 2026: 1–12. DOI: 10.18653/v1/2026.fever-1.1.

[19] GENG S, JOSIFOSKI M, PEYRARD M, et al. Grammar-constrained decoding for structured NLP tasks without finetuning[C]//Proceedings of the 2023 Conference on Empirical Methods in Natural Language Processing. Singapore: Association for Computational Linguistics, 2023: 10932–10952. DOI: 10.18653/v1/2023.emnlp-main.674.

[20] MADAAN A, TANDON N, GUPTA P, et al. Self-Refine: Iterative refinement with self-feedback[EB/OL]. arXiv:2303.17651v2, 2023[2026-09-13]. DOI: 10.48550/arXiv.2303.17651.

[21] HUANG J, CHEN X, MISHRA S, et al. Large language models cannot self-correct reasoning yet[EB/OL]. arXiv:2310.01798v2, 2024[2026-09-13]. DOI: 10.48550/arXiv.2310.01798.

[22] WANG X, WEI J, SCHUURMANS D, et al. Self-consistency improves chain of thought reasoning in language models[EB/OL]. arXiv:2203.11171v4, 2023[2026-09-13]. DOI: 10.48550/arXiv.2203.11171.

[23] TRAN N, LITMAN D, GODLEY A. Using large language models to analyze students' collaborative argumentation in classroom discussions[C]//Proceedings of the Artificial Intelligence in Measurement and Education Conference (AIME-Con): Full Papers. Pittsburgh: National Council on Measurement in Education, 2025: 111–125.

[24] XIAO Y, LI S. ARGUS: Argumentation-based minimal-change repair for verifiable LLM self-explanations[C]//Proceedings of the 42nd Conference on Uncertainty in Artificial Intelligence. Proceedings of Machine Learning Research, 2026, 337: 7536–7551.

[25] MORIO G, OZAKI H, MORISHITA T, et al. End-to-end argument mining with cross-corpora multi-task learning[J]. Transactions of the Association for Computational Linguistics, 2022, 10: 639–658. DOI: 10.1162/tacl_a_00481.

[26] SAVIGNY H, YUN B. AMELIA: A family of multi-task end-to-end language models for argumentation[J]. Argument & Computation, 2026, 17(1). DOI: 10.1177/19462174251413169.

[27] FEGER M, BOLAND K, DIETZE S. Limited generalizability in argument mining: State-of-the-art models learn datasets, not arguments[C]//Proceedings of the 63rd Annual Meeting of the Association for Computational Linguistics, Volume 1. Vienna: Association for Computational Linguistics, 2025: 23900–23915. DOI: 10.18653/v1/2025.acl-long.1164.

[28] ZHAO X, WANG K, PENG W. ORCHID: A Chinese debate corpus for target-independent stance detection and argumentative dialogue summarization[C]//Proceedings of the 2023 Conference on Empirical Methods in Natural Language Processing. Singapore: Association for Computational Linguistics, 2023: 9358–9375. DOI: 10.18653/v1/2023.emnlp-main.582.

[29] CHENG L, BING L, HE R, et al. IAM: A comprehensive and large-scale dataset for integrated argument mining tasks[C]//Proceedings of the 60th Annual Meeting of the Association for Computational Linguistics, Volume 1. Dublin: Association for Computational Linguistics, 2022: 2277–2287. DOI: 10.18653/v1/2022.acl-long.162.

[30] VASWANI A, SHAZEER N, PARMAR N, et al. Attention is all you need[EB/OL]. arXiv:1706.03762, 2017[2026-09-13]. DOI: 10.48550/arXiv.1706.03762.

[31] QWEN TEAM. Qwen2.5 technical report[EB/OL]. arXiv:2412.15115, 2024[2026-09-13]. DOI: 10.48550/arXiv.2412.15115.

[32] HU E J, SHEN Y, WALLIS P, et al. LoRA: Low-rank adaptation of large language models[EB/OL]. arXiv:2106.09685, 2021[2026-09-13]. DOI: 10.48550/arXiv.2106.09685.

[33] LESTER B, AL-RFOU R, CONSTANT N. The power of scale for parameter-efficient prompt tuning[C]//Proceedings of the 2021 Conference on Empirical Methods in Natural Language Processing. Association for Computational Linguistics, 2021: 3045–3059. DOI: 10.18653/v1/2021.emnlp-main.243.

[34] TANG C, PENG M, TIAN G. Improving end-to-end argument mining with LLMs via multi-candidate reranking and bounded repair[C/OL]//ICIC2026 Posters: Poster Volume I. Toronto, 2026[2026-09-20]. DOI: 10.65286/icic.v22i1.76896.

[35] BAO J, HUANG Y, SUN Y, et al. Exploring quality and diversity in synthetic data generation for argument mining[C]//Proceedings of the 2025 Conference on Empirical Methods in Natural Language Processing. Suzhou: Association for Computational Linguistics, 2025: 26581–26604. DOI: 10.18653/v1/2025.emnlp-main.1351.

[36] WANG X, SHEN H, QI H, et al. Enhancing low-resource joint entity and relation extraction using large language models within semi-supervised learning[J]. ACM Transactions on Knowledge Discovery from Data, 2026, 20(3): 49:1–49:25. DOI: 10.1145/3799423.

[37] MODARRESSI A, KÖKSAL A, SCHUETZE H. Consistent document-level relation extraction via counterfactuals[C]//Findings of the Association for Computational Linguistics: EMNLP 2024. Miami: Association for Computational Linguistics, 2024: 11501–11507. DOI: 10.18653/v1/2024.findings-emnlp.672.

[38] ZHENG Y, KE W, LIU Q, et al. Making LLMs as fine-grained relation extraction data augmentor[C]//Proceedings of the Thirty-Third International Joint Conference on Artificial Intelligence. International Joint Conferences on Artificial Intelligence Organization, 2024: 6660–6668. DOI: 10.24963/ijcai.2024/736.

[39] ZHONG Y, GAO Y, ZHANG X, et al. ODDA: An OODA-driven diverse data augmentation framework for low-resource relation extraction[C]//Findings of the Association for Computational Linguistics: ACL 2025. Vienna: Association for Computational Linguistics, 2025: 267–285. DOI: 10.18653/v1/2025.findings-acl.15.

[40] ROCHA G, LOPES CARDOSO H, BELOUADI J, et al. Cross-genre argument mining: Can language models automatically fill in missing discourse markers?[J]. Argument & Computation, 2025, 16(1): 3–35. DOI: 10.3233/AAC-230008.

[41] WAEGEMAN W, DEMBCZYŃSKI K, JACHNIK A, et al. On the Bayes-optimality of F-measure maximizers[J]. Journal of Machine Learning Research, 2014, 15(103): 3513–3568.

[42] LIPTON Z C, ELKAN C, NARAYANASWAMY B. Thresholding classifiers to maximize F1 score[EB/OL]. arXiv:1402.1892v2, 2014[2026-09-20]. DOI: 10.48550/arXiv.1402.1892.

[43] LI Z, ZHANG F, LYU K, et al. Re-Cent: A relation-centric framework for joint zero-shot relation triplet extraction[C]//Proceedings of the 31st International Conference on Computational Linguistics. Abu Dhabi: Association for Computational Linguistics, 2025: 7344–7354.

[44] PIROZELLI P, ROCHA V H N, COZMAN F G, et al. An LLM-based system for argument reconstruction[EB/OL]. arXiv:2605.13793v1, 2026[2026-09-20]. DOI: 10.48550/arXiv.2605.13793.

[45] GUO C, PLEISS G, SUN Y, et al. On calibration of modern neural networks[C]//Proceedings of the 34th International Conference on Machine Learning. Proceedings of Machine Learning Research, 2017, 70: 1321–1330.

[46] NICULAE V, PARK J, CARDIE C. Argument mining with structured SVMs and RNNs[C]//Proceedings of the 55th Annual Meeting of the Association for Computational Linguistics, Volume 1. Vancouver: Association for Computational Linguistics, 2017: 985–995. DOI: 10.18653/v1/P17-1091.

[47] BAO J, HE Y, SUN Y, et al. A generative model for end-to-end argument mining with reconstructed positional encoding and constrained pointer mechanism[C]//Proceedings of the 2022 Conference on Empirical Methods in Natural Language Processing. Abu Dhabi: Association for Computational Linguistics, 2022: 10437–10449. DOI: 10.18653/v1/2022.emnlp-main.713.

[48] BAO J, JING M, DONG K, et al. UniASA: A unified generative framework for argument structure analysis[J]. Computational Linguistics, 2025, 51(3): 739–784. DOI: 10.1162/coli_a_00553.

[49] ZHANG Z, WANG Q, DING K, et al. Improving synthetic data generation for argument mining via adversarial reinforcement learning[EB/OL]. arXiv:2610.07699v1, 2026[2026-10-10]. DOI: 10.48550/arXiv.2610.07699.

[50] QWEN TEAM. Qwen3.5-9B: official model card and configuration[EB/OL]. 2026[2026-10-13].

[51] HUGGING FACE. Transformers v5.8.0: Qwen3.5 model implementation[CP/OL]. 2026[2026-10-13].

[52] QWEN TEAM. Qwen3.5-4B: official model card and configuration[EB/OL]. 2026[2026-10-13].

[53] QWEN TEAM. Qwen2.5-7B-Instruct: official model card and configuration[EB/OL]. 2024[2026-10-13].

[54] LIN J. Divergence measures based on the Shannon entropy[J]. IEEE Transactions on Information Theory, 1991, 37(1): 145–151. DOI: 10.1109/18.61115.

[55] PLATT J C. Probabilities for SV machines[M]//SMOLA A J, BARTLETT P L, SCHÖLKOPF B, et al. Advances in Large-Margin Classifiers. Cambridge, MA: MIT Press, 2000: 61–74. DOI: 10.7551/mitpress/1113.003.0008.

[56] EFRON B. Bootstrap methods: Another look at the jackknife[J]. The Annals of Statistics, 1979, 7(1): 1–26. DOI: 10.1214/aos/1176344552.

[57] HOLM S. A simple sequentially rejective multiple test procedure[J]. Scandinavian Journal of Statistics, 1979, 6(2): 65–70. DOI: 10.2307/4615733.

[58] WILSON E B. Probable inference, the law of succession, and statistical inference[J]. Journal of the American Statistical Association, 1927, 22(158): 209–212. DOI: 10.1080/01621459.1927.10502953.

[59] COHEN J. A coefficient of agreement for nominal scales[J]. Educational and Psychological Measurement, 1960, 20(1): 37–46. DOI: 10.1177/001316446002000104.

[60] HUANGFU Q, HALL J A J. Parallelizing the dual revised simplex method[J]. Mathematical Programming Computation, 2018, 10(1): 119–142. DOI: 10.1007/s12532-017-0130-5.

附录 A 实现细节与复现信息

A.1 确定性选择规则

改写中心的选择方法为：将固定种子 17、语料名、文档 ID、组件 ID 和 center 标记用竖线连接后计算 SHA-256，按前 16 位的数值升序选取。若优先类型的组件不存在，则在全部合法组件中按同样顺序选取。同一文档的所有改写样本使用同一个中心。

A.2 模型版本与参数量

9B 骨干的 Q 投影包含输出门控，维度为 4096→8192，K 和 V 为 4096→1024，O 为 4096→4096。两条 LoRA 分支均取$r=16$、$\alpha=32$、dropout=0.05，每条分支 3,932,160 个参数，共 7,864,320 个，与单条 rank 为 32 的分支参数量相同。24 个线性注意力块、前馈层和视觉编码器均冻结。

表 A-1 模型版本

模型	revision	角色
Qwen/Qwen3.5-9B	21eca8a083a2121a92fba681f4a7c72cf20ff1a7	主实验与共享 A/V
Qwen/Qwen3.5-4B	1eef1f4e0bc57dec8f814d1e4c714c8e0065d261	共享增强下的四种配置补充实验
Qwen/Qwen2.5-7B-Instruct	a306ca65c69cb09b9ce8ae8396fd529d509d872e	共享增强下的四种配置补充实验

A.3 复现材料

配套材料保存了逐文档的计数、预测图、固定的候选与评分、事务记录、审核记录和成本记录。统计检验使用 NumPy 的 PCG64 随机数生成器，AAEC 和 CDCP 的抽样种子分别为 72026 和 72027，所有方法共用 2000 次重采样索引。14 项主要比较统一做 Holm 校正，跨骨干的 12 项补充比较单独校正，ThresholdFilter 和外部系统比较作为探索性结果报告。

CDCP 的源组提案文件记录了每个提案的源组件、目标和返回状态。

4.4.3 节参考事务的记录包括对象身份、原文切片、对象评分、提交前后的效用、对象差集、严格计数以及两种拒绝情形的结果，并附有复算脚本。

各阶段的推理成本按文档分别记录 I0 阶段和追加阶段的耗时，BR-O 的成本单独计量。

A.4 推理与增强模块的实现细节

本节给出第三、四章中各模块的结构参数、资源上限和执行细节，正文只保留方法思路。

（1）增强生成器与审核器。增强生成器 A 使用不加载任务 LoRA 的 Qwen3.5-9B，采样参数为 temperature=0.7、top-p=0.9，关闭 thinking，最多输出 2048 个 token。审核器 V 同样使用不加载抽取 LoRA 的 Qwen3.5-9B，关闭 thinking，采用贪心解码，每次最多输出 1024 个 token。跨骨干实验共用 9B 模型生成的增强数据和审核结果。

（2）初始图的合法化。MCR-BR 重排序得分相同的候选按生成顺序选择。合法化只作用于G_{rank}，进行坐标规范化、去重和重新编号，得到G_{pre}；遇到无法消解的冲突时返回失败。BR-O 在G_{pre}上执行，并经合法性检查后得到G_0。

（3）跨度预测头。跨度预测头基于冻结的 Qwen3.5-9B 表示，用两个线性层分别预测组件的起止边界，在训练集上监督训练；候选类型由类型分类器给出。补充跨度按边界得分排序，最多保留 64 个，每个跨度保留排名前 2 的类型。

（4）源组提案器 P。提案器 P 在冻结的 Qwen3.5-9B 编码器上接一个隐藏维度为 1024 的两层 MLP，输入源组件表示、目标表示、全文表示和 7 维位置特征。训练时以训练集中真实的源组件集合为正例，为每个正例抽取 4 个负例，训练 5 个 epoch。P 最多输出 64 个候选槽位，再用相邻 2 或 3 个源组件的规则进行补充，总数不超过 256；G_0以及各候选图中已有的槽位另行保留，不受上限限制。

（5）候选规模上限。若构建过程中合法槽位数超过 50000，则视为构造失败，直接返回G_0。作为参考，若对m个跨度、每个跨度q个类型完全展开，AAEC 的槽位数为$m(m-1)q^2$，CDCP 为$\sum_{k=1}^{3} C(m,k)(m-k)q^{k+1}$，远大于默认设置下的实际规模。$C(m,k)$表示从$m$个跨度中选取$k$个的组合数。

（6）对象评分器 S。组件头的输入为跨度均值表示与全文末端表示，结构为 8192→1024→类型数+1；关系头的输入为源组件、目标、全文表示、类型和标签嵌入以及位置特征，结构为 12375→1024→1。两个头均使用 GELU 激活和 0.1 的 dropout，用 AdamW 优化器以10^{-3}的学习率训练 10 个 epoch。评分器 S 与提案器 P 共享冻结的文本表示缓存，但不共享可训练参数。

（7）局部搜索的预算计数与提交。局部搜索按提议次数计算预算：评估一个提议计一次尝试，提议被提交计一次接受。每轮最多 32 次尝试、3 次接受，最多 4 轮，均从G_0开始计算。每一批从六类提议中轮流选取，按得分和剩余预算择优检查，并从本

批通过检查的候选中择优提交一个完整事务；同一状态下不重复评估相同的提议，无法安全提交时返回最近的合法图。

（8）全局求解中多个最优解的处理。全局求解依次进行三级优化：先最大化Φ；再在$\Phi \geq \Phi^{*} - \varepsilon_{\text{tie}}$的条件下最小化$d_C^{\text{net}} + d_R^{\text{net}}$；若仍有多个解，则按规范键顺序逐个固定对象取值，优先保持G_0中的状态。其中ε_{tie}为比较容差。

（9）全局求解的超时与返回。全局求解的时限与局部求解相同（AAEC 为 3 秒，CDCP 为 5 秒）。求得最优解时按δ规则返回；超时但已有不同于G_0的可行解时，重新检查全部约束、分项门和$\Phi - \Phi(G_0) > \delta$，通过则返回该解，否则返回$G_0$；超时且没有更好的解时返回$G_0$；求解出错时同样返回$G_0$。

（10）跨骨干实验的模块输入。评分器 S 的组件和关系输入维度分别为$2d$和$3d+87$，提案器 P 的输入维度为$3d+7$，其中d为骨干的隐藏维度。各骨干使用各自的分词器，结果通过字符坐标对齐；输入长度上限统一为 4096 个 token，不启用长上下文扩展。

附录 B 补充实验结果

B.1 开发选择

表 B-1 开发集上的策略选择

语料	κ_R / δ	原 TP	误删 TP	损失率	汇总关系 F1	合格
AAEC	1.00 / 0.01	598	3	0.50%	73.25	是
AAEC	1.00 / 0.05	598	3	0.50%	73.25	是
AAEC	1.00 / 0.10	598	3	0.50%	73.25	是
AAEC	1.00 / 0.20	598	3	0.50%	73.25	是
AAEC	1.00 / $\varepsilon_{\text{gain}}$	598	6	1.00%	72.91	是
CDCP	1.00 / 0.01	130	41	31.54%	46.42	否
CDCP	1.00 / 0.05	130	35	26.92%	48.31	否
CDCP	1.00 / 0.10	130	29	22.31%	50.24	否
CDCP	1.00 / 0.20	130	25	19.23%	50.57	否
CDCP	1.00 / $\varepsilon_{\text{gain}}$	130	44	33.85%	45.73	否
CDCP	0.50 / 0.01	130	0	0.00%	53.47	是
CDCP	0.50 / 0.05	130	0	0.00%	53.47	是
CDCP	0.50 / 0.10	130	0	0.00%	53.47	是
CDCP	0.50 / 0.20	130	0	0.00%	53.47	是
CDCP	0.50 / $\varepsilon_{\text{gain}}$	130	3	2.31%	52.86	是

如表 B-1 所示，CDCP 在κ_R=1 时，所有δ取值都不满足原有正确关系损失不超过 5%的要求，κ_R=0.5 时则全部满足；AAEC 在κ_R=1 时全部满足。在满足要求的配置中选择汇总关系 F1 最高的，并按 4.3.1 节的规则取δ=0.20；δ在 0.01 到 0.20 之间时开发集结果不变。$\varepsilon_{\text{gain}}$一行对应 NoRisk 消融：$\delta$降到接近 0 后，收益极小的事务也被接受，AAEC 和 CDCP 在开发集上的误删分别增加到 6/598 和 3/130，关系 F1 降到 72.91 和 52.86，与测试集上 NoRisk 的下降趋势一致。注意开发集 F1 由三个种子的计数汇总后计算，而测试集 F1 为逐种子 F1 的均值。 其中$\varepsilon_{\text{gain}}$为 NoRisk 的最小正增益阈值，与附录 A.4 的破同分容差ε_{tie}分别配置。

表 B-2 各骨干的独立开发选择

骨干	语料	κ_R / δ	原 TP	损失 TP	损失率	开发汇总 F1
Qwen3.5-9B	AAEC	1.00 / 0.20	598	3	0.50%	73.25
Qwen3.5-9B	CDCP	0.50 / 0.20	130	0	0.00%	53.47
Qwen3.5-4B	AAEC	1.00 / 0.20	583	4	0.69%	71.70
Qwen3.5-4B	CDCP	0.50 / 0.20	125	1	0.80%	51.69
Qwen2.5-7B-Instruct	AAEC	1.00 / 0.20	559	6	1.07%	68.63
Qwen2.5-7B-Instruct	CDCP	0.50 / 0.20	116	1	0.86%	48.30

如表 B-2 所示，各骨干分别在开发集上选择策略，规则相同：先要求原有正确关系的损失不超过 5%，再选关系 F1 最高的配置，并列时取较大的κ和δ。

B.2 审核的补充统计

表 B-3 各审核层的源文档数与聚类置信区间

语料／层	审核因素	源组	π	不安全率	源聚类 95%	总体覆盖
AAEC／内部正关系	300	136	0.4392	1.07%	[0.00, 2.40]	抽样
AAEC／跨边界正关系	153	61	1.0000	1.63%	[0.00, 4.31]	全层
AAEC／内部 NONE	300	129	0.3421	1.43%	[0.34, 2.96]	抽样
AAEC／跨边界 NONE	300	201	0.1500	0.38%	[0.00, 1.18]	抽样
CDCP／内部正关系	300	163	0.9524	0.71%	[0.00, 1.85]	抽样
CDCP／跨边界正关系	290	160	1.0000	1.61%	[0.38, 3.31]	全层
CDCP／内部 NONE	300	133	0.6383	1.81%	[0.37, 3.57]	抽样
CDCP／跨边界 NONE	300	229	0.0923	0.74%	[0.00, 1.87]	抽样

表 B-4 两端均为只读组件的关系抽查

语料	域外候选总体	抽样	发现变化	比例	Wilson 95%
AAEC	3870	160	2	1.25%	[0.34, 4.44]
CDCP	915	160	2	1.25%	[0.34, 4.44]

表 B-4 单独给出两端都是只读组件的关系的抽查结果，用于检查改写是否通过上下文影响到影响域之外的关系。这部分样本独立于表 3-9 的四层审核，不影响默认的增强监督。

B.3 运行成本与求解规模测试

表 B-5 汇总了 9B 主配置的一次性运行成本，包括 54 次最终训练、36 次 OOF 训练、12 个评分头和 6 个提案头；GPU 小时按设备数乘以实际耗时计算。4B 和 2.5-7B 的补充实验另有 24 次最终训练、72 次 OOF 训练、24 个评分头和 12 个提案头，各骨干共用同一批增强数据。表 B-6 给出不同规模下全局求解的耗时，作为 4.5.4 节路径选择的依据。

表 B-5 一次性运行成本（GPU 小时）

语料	最终训练（27 运行）	OOF（18 运行）	评分头（6 运行）	跨度/源组提案（3 运行）
AAEC	120.49	44.69	2.38	0.96
CDCP	206.83	77.81	3.85	1.62

表 B-6 不同规模下全局求解的耗时

语料	变量数	问题数	均值/秒	P95/秒	时限/秒	超时数	择优完成数
AAEC	500	60	0.14	0.32	3	0	60
AAEC	1000	60	0.33	0.72	3	0	60
AAEC	1500	60	0.62	1.22	3	0	60
AAEC	2000	60	0.95	2.03	3	0	60
AAEC	2500	60	1.35	2.71	3	0	60
AAEC	3000	60	1.90	3.00	3	7	53
AAEC	4000	60	2.60	3.00	3	20	40
CDCP	500	60	0.21	0.49	5	0	60
CDCP	1000	60	0.50	1.09	5	0	60
CDCP	1500	60	0.94	1.85	5	0	60
CDCP	2000	60	1.44	3.09	5	0	60
CDCP	2500	60	2.05	4.12	5	0	60
CDCP	3000	60	2.89	5.00	5	7	53
CDCP	4000	60	3.95	5.00	5	20	40

从表 B-6 可以看到，变量数为 2500 时，两个语料的 P95 耗时都低于时限；达到 3000 和 4000 个变量时开始出现超时。因此，本文以 2500 个变量作为选择全局或局部求解的阈值。更换硬件后，该阈值需要重新测定。