分类号：_____　　密　级：_____
U D C：_____　　编　号：10486

硕士学位论文

基于一致性学习与结构约束修正的端到端论辩挖掘研究

研究生姓名：（盲审版本隐去）
学　　号：（盲审版本隐去）
指导教师姓名、职称：（盲审版本隐去）
专业名称：（盲审版本隐去）
研究方向：（盲审版本隐去）

二〇二六年十月

End-to-End Argument Mining via Consistency Learning and Structure-Constrained Repair

By

***

Supervised By

***

Wuhan University

October, 2026

论文原创性声明

本人郑重声明：所呈交的学位论文，是本人在导师指导下，独立进行研究工作所取得的研究成果。除文中已经标明引用的内容外，本论文不包含任何其他个人或集体已发表或撰写的研究成果。对本文的研究做出贡献的个人和集体，均已在文中以明确方式标明。本声明的法律结果由本人承担。

学位论文作者（签名）：

日期：　　年　　月　　日

武汉大学学位论文使用授权协议书

本学位论文作者愿意遵守武汉大学关于保存、使用学位论文的管理办法及规定，即：学校有权保存学位论文的印刷本和电子版，并提供文献检索与阅览服务；学校可以采用影印、缩印、数字化或其它复制手段保存论文；在以教学与科研服务为目的前提下，学校可以在校园网内公布部分或全部内容。

一、在本论文提交当年，同意在校园网内以及中国高等教育文献保障系统（CALIS）、高校学位论文系统提供查询及前十六页浏览服务。

二、在本论文提交□当年/□一年/□两年/□三年以后，同意在校园网内允许读者在线浏览并下载全文，学校可以为存在馆际合作关系的兄弟高校用户提供文献传递服务和交换服务。（保密论文解密后遵守此规定）

论文作者（签名）：

学　　号：

学　　院：

日期：　　年　　月　　日

摘要

论辩挖掘旨在识别文本中的论点、前提等论辩组件及组件之间的支持与攻击关系，将非结构化的论述转化为可分析的论辩结构，从而为写作评价、舆情分析等应用提供支持。近年来，大语言模型凭借较强的上下文语义理解能力，能够以统一的生成方式从原始文本直接输出组件边界、类型及组件之间的关系，从而联合处理多个子任务；然而，组件与关系之间相互依赖，模型在训练与推理阶段仍面临以下两方面挑战。首先，现有数据增强方法难以保证改写后监督的可靠性：这类方法通常默认改写保持原文语义并直接继承全部原标注，而局部改写可能改变组件的论辩角色或组件之间的关系，使沿用的标注成为错误监督。其次，生成结果中的结构错误难以通过单独修正组件或关系得到一致纠正：生成的论辩图中常含有边界或类型错误的组件，而组件一旦被修改，以其为端点的关系随之失效，单独修正组件或单独修正关系都难以得到结构一致的论辩图。

针对上述问题，论文围绕端到端论辩挖掘中组件与关系之间的相互依赖，按照从训练到推理的顺序开展两项递进的研究：首先在训练阶段判断局部改写后哪些监督仍然可靠，以改进模型的学习信号；进而以所得模型为起点，在推理阶段对其预测结果中残余的组件错误及其关联关系进行联合决策，以提升训练信号的可靠性和组件与关系联合抽取的准确性。具体工作如下：

（1）针对数据增强中局部改写可能使原标注失效的问题，提出可靠监督与一致性学习方法。该方法以单个组件类型或一组端点之间的关系状态（称为因素）为粒度判断监督是否可靠：首先，确定每处改写可能影响的组件与关系范围，即关系影响域，并将原标注无损地迁移到改写文本上；其次，对影响域内的因素逐项进行语义审核，仅保留仍然成立的可靠因素；在训练阶段，原文提供完整的论辩图监督，改写文本则与原文构成成对视图，仅在可靠因素上提供辅助监督并施加一致性约束。在英文议论文与公共政策评论两个广泛使用的论辩挖掘语料上的实验结果表明，与作为基础方法的多候选重排序与有界修正方法相比，该方法使严格关系 F1 分别提高 2.56 和 3.30 个百分点，其中在增强样本与因素掩码固定时，一致性目标本身带来 1.39 和 2.57 个百分点；人工分层审核显示，被接受关系因素的加权不安全率估计为 0.81%和 0.91%。

（2）在上述模型的基础上，针对其预测结果中残余的组件错误会使关联关系随之失效的问题，进一步提出结构约束联合修正方法，在不更新抽取模型参数的前提下对初始预测图中的组件与关系进行联合修正。一方面，将组件修改与全部受影响关系的重建组织为不可拆分的依赖闭合事务，使组件及其关联关系一同被接受或拒绝；另一方面，在预先固定的对象评分下构造组件与关系的分项效用门，并结合编辑预算决定

是否接受修改，用于控制误改风险与修改范围；在此基础上，提供全局整数规划与集合局部搜索两种求解方式。实验结果表明，在第一项工作所得模型上追加该方法，严格关系 F1 进一步显著提高 3.38 和 5.68 个百分点，其中仅修正关系已带来 2.20 和 4.11 个百分点，允许修改组件并重建关联关系再带来 1.18 和 1.57 个百分点；与相同预算的重新生成相比，该方法在取得更高 F1 的同时保留了 98%以上的原有正确关系，直接作用于基础方法的模型时同样带来稳定提升。

综上所述，论文先改进训练监督、再修正推理结构，逐步处理组件与关系之间的依赖。以 9B 规模骨干为例，两项方法依次叠加后，模型在两个语料上取得 71.63 和 50.77 的严格关系 F1，相对同骨干的基础方法分别提高 5.94 和 8.98 个百分点；在所考察的三个同系列开源大语言模型骨干上，完整方法均取得显著提升，两阶段恢复的关系重叠很少，组合增益接近两项单独增益之和，表明推理阶段的联合修正能够在训练改进的基础上继续发挥作用。研究结果表明，在训练中对改写后仍然可靠的因素施加监督与一致性约束、在推理中对组件与关系进行联合决策，能够提升基于大语言模型的端到端论辩挖掘性能，为结构化输出的可靠学习与联合修正提供了一种可行的技术路径。

关键词：论辩挖掘；大语言模型；一致性学习；结构化预测；联合修正

Abstract

Argument mining aims to identify argumentative components, such as claims and premises, together with the support and attack relations between them, thereby turning unstructured discourse into analyzable argument structures for applications such as writing assessment and public opinion analysis. With their strong contextual semantic understanding, large language models can generate component boundaries, types, and relations directly from raw text in a unified manner and thus handle multiple subtasks jointly. However, because components and relations depend on each other, two challenges remain in training and inference. First, existing data augmentation methods cannot guarantee that supervision remains reliable after rewriting: they generally assume that rewriting preserves meaning and inherit all original annotations, whereas a local rewrite may change the argumentative role of a component or its relations with other components, turning the inherited labels into erroneous supervision. Second, structural errors in generated outputs can hardly be corrected consistently by repairing components or relations separately: generated argument graphs often contain components with incorrect boundaries or types, and once a component is modified, every relation that uses it as an endpoint becomes invalid, so correcting components alone or relations alone can hardly yield a consistent argument graph.

To address these challenges, this thesis studies the interdependence between components and relations in end-to-end argument mining through two progressive studies that follow the order of training and inference. The first study improves the learning signal by determining which supervision remains reliable after local rewriting; building on the resulting model, the second study makes joint decisions on the residual component errors in its predictions and on their associated relations. Together, the two studies improve the reliability of training signals and the accuracy of joint component-relation extraction. The main work is as follows.

(1) To address the problem that local rewriting may invalidate original annotations, this thesis proposes a method of reliable supervision with consistency learning. The method judges reliability at the level of factors, i.e., the type of a single component or the relation status between a set of endpoints. It first determines the relation influence domain of each rewrite, namely the components and relations that may be affected, and transfers the original annotations losslessly to the rewritten text; it then audits the factors within this domain one by one and retains only the reliable factors whose labels still hold. During training, the original text provides full argument-graph supervision, while the rewritten text, which forms

a paired view with the original, contributes auxiliary supervision and consistency constraints only on reliable factors. Experiments on two widely used English argument mining corpora of persuasive essays and public policy comments show that, compared with the base method of multi-candidate reranking and bounded repair, the proposed method improves strict relation F1 by 2.56 and 3.30 points, respectively, of which 1.39 and 2.57 points are attributable to the consistency objective when the augmented samples and factor masks are fixed. Stratified human auditing estimates the weighted unsafe rates of accepted relation factors at 0.81% and 0.91%.

(2) Building on this model, and to address the problem that residual component errors in its predictions invalidate their associated relations, this thesis further proposes a structure-constrained joint repair method, which jointly revises the components and relations of the initial predicted graph without updating the parameters of the extraction model. On the one hand, a component modification and the reconstruction of all affected relations are organized into an indivisible dependency-closed transaction, so that the component and its associated relations are accepted or rejected together. On the other hand, per-type utility gates for components and relations are built on frozen object scores and combined with edit budgets to decide whether a modification is accepted, which are intended to control the risk and scope of edits. Both a global integer programming solver and a set-based local search are provided. Applied to the model obtained in the first study, the method further improves strict relation F1 by 3.38 and 5.68 points, of which relation selection alone accounts for 2.20 and 4.11 points and component modification with relation reconstruction adds 1.18 and 1.57 points. Compared with regeneration under the same budget, it achieves higher F1 while retaining more than 98% of the originally correct relations, and it also yields consistent gains when applied directly to the model of the base method.

In summary, this thesis first improves training supervision and then repairs inference-time structures, addressing the dependency between components and relations step by step. Taking a 9B-scale backbone as an example, the full method with both stages achieves strict relation F1 scores of 71.63 and 50.77 on the two corpora, outperforming the base method with the same backbone by 5.94 and 8.98 points. Significant gains are observed on all three open-source backbones examined, which come from the same model family; the relations recovered by the two stages overlap little, no significant interaction between the two stages is detected, and joint repair continues to contribute on top of the improved training. These results indicate that applying supervision and consistency constraints only to factors that remain reliable after rewriting during training and making joint decisions on components and relations during inference can improve end-to-end argument mining based on large language models, offering a practical path toward reliable learning and joint repair of structured outputs.

Keywords: Argument Mining, Large Language Models, Consistency Learning, Structured Prediction, Joint Repair

目录

摘要 ..... **I**
Abstract ..... **III**
主要符号对照表 ..... **IX**
第 1 章 绪论 **1**
1.1 研究背景与意义 1
1.2 国内外研究现状 3
1.2.1 端到端论辩挖掘方法 3
1.2.2 论辩挖掘中的数据增强 5
1.2.3 结构化预测与预测结果修正 6
1.3 主要研究内容 8
1.4 论文组织结构 10 .....
第 2 章 相关理论与技术 13 .....
2.1 论辩挖掘任务与结构表示 13 .....
2.1.1 论辩组件与关系 13 .....
2.1.2 组件的字符级表示 14 .....
2.2 大语言模型与参数高效微调 16 .....
2.2.1 注意力机制与自回归生成 16 .....
2.2.2 参数高效微调与连续提示 17 .....
2.3 数据增强与一致性学习 17
2.4 候选评分与结构化决策 18
2.5 本章小结 20 .....
第 3 章 基于可靠监督与一致性学习的论辩挖掘方法 21 .....
3.1 引言 21 .....
3.2 总体框架与基础模型 22 .....
3.3 基于关系影响域的可靠增强数据构造 24 .....
3.3.1 改写范围与关系影响域 24 .....
3.3.2 改写生成与标注迁移 26
3.3.3 语义审核与因素掩码 27 .....
3.3.4 标注迁移与改写案例 28
3.4 一致性学习模型与训练 30
3.4.1 辅助预测头与一致性约束 32 .....
3.4.2 损失归一化与参数更新 33 .....

3.4.3 算法流程与性质分析 34
3.5 实验与分析 36
3.5.1 数据集与评价指标 36
3.5.2 对照方法 37
3.5.3 实验环境与参数设置 38
3.5.4 主要结果与消融分析 41
3.5.5 增强数据的人工审核 44
3.5.6 训练成本与跨骨干表现 47
3.6 本章小结 49
第 4 章 基于结构约束的论辩图联合修正方法 51
4.1 引言 51
4.2 候选生成与初始图 54
4.2.1 多候选生成与初始图选择 54
4.2.2 候选空间构建 55
4.3 对象评分与接受准则 56
4.3.1 对象评分器与策略选择 56
4.3.2 效用函数与接受条件 58
4.4 依赖闭合事务的构造 59
4.4.1 组件冲突消解 59
4.4.2 受影响关系的重建 59
4.4.3 事务示例 60
4.5 求解算法及性质 62
4.5.1 集合局部搜索 62
4.5.2 全局整数规划求解 65
4.5.3 方法性质分析 67
4.5.4 求解方式的选择 68
4.6 实验与分析 69
4.6.1 实验设置 69
4.6.2 主要结果与消融分析 73
4.6.3 候选覆盖与评分质量分析 79
4.6.4 推理成本分析 86
4.6.5 与第 3 章方法的衔接分析 88
4.6.6 多前提关系分析 92
4.6.7 不同骨干模型上的结果 93

4.6.8 与外部系统及已发表结果的比较 95.....
4.7 本章小结 98.....
第 5 章 总结与展望 99.....
5.1 全文工作总结 99.....
5.2 未来工作展望 100.....
参考文献 102.....
致谢 115.....
附录 A 个人简历 116.....
附录 B 在学期间参与的科研项目 117.....
附录 C 在学期间取得的学术成果 118.....

主要符号对照表

符号	含义	定义位置
x、x'	原文及其改写文本	2.1.2
A	被改写组件的集合	3.3.1
D_A	关系影响域：可审核因素中至少一个端点位于 A 内的因素	3.3.1
J_A	实际审核的因素集合，包括受影响正关系和抽样的 NONE	3.3.3
φ	原文组件到改写组件的对应映射	3.3.2
m_C、m_R	组件与关系因素的可靠性掩码	3.3.3
Ω_{sem}	可审核的因素集合，排除语义未知的多前提子集	3.3.3
G_0；I0 / I1	初始图；MCR-BR 推理流程 / 追加联合修正的推理流程	2.4、4.2.1
U；V；P	跨度；带类型组件；完整关系候选池	4.2.2
q_C；q_R	完整组件与完整关系的固定评分	4.3.1
Φ_C；Φ_R；Φ	组件、关系与总效用	4.3.2
R_{DC}；BR-J	追加的联合修正；集合局部搜索子程序	4.1、4.5.1
δ；B_C；B_R	严格改进阈值；组件与关系编辑预算	4.3.2、4.5.2
T0／T1	MCR-BR 的训练配置／第 3 章可靠监督与一致性学习方法的训练配置	3.5.3
T0I0、T1I0、T0I1、T1I1	训练配置与推理配置的四种组合，如 T1I1 表示第 3 章训练配置加第 4 章联合修正	4.6.5

第 1 章 绪论

1.1 研究背景与意义

论辩广泛存在于议论文写作和公共议题讨论之中，人们通过提出观点、给出理由和回应异议来表达立场并说服他人。理解这类文本，不仅需要把作者的主张与理由联系起来，还需要辨别不同论述之间是相互支持还是相互反驳；然而，由于论述内容分散、表达形式多样，人工梳理论证过程往往需要逐句结合上下文进行分析。因此，自动识别文本中的论辩结构既具有实际应用价值，也是自然语言理解领域的重要研究问题[1]。

在此背景下，论辩挖掘（Argument Mining，AM）[1]旨在识别文本中的论辩组件及其相互关系，从而将非结构化的论述转化为可供分析的结构化表示。其中，论辩组件是在论证中承担观点、理由等功能的文本片段，组件之间的关系则刻画这些片段如何共同构成论证；在定位组件、判断其类型并识别组件间的关系之后，即可得到文本对应的论辩图。论辩图既可用于检查议论文中的理由是否围绕观点展开，也可用于整理公共讨论中各方的立场及其依据，从而为写作反馈和舆情研判等应用提供支持。

如图 1.1 所示，论辩标注作文语料（Argument Annotated Essays Corpus，AAEC）[2]中的 essay001 主张合作有助于儿童学习人际交往技能，并以团队合作中的相处经验、沟通与妥协以及生活技能等作为理由；其中，T3 是被支持的观点（标注类型为论点），T4、T5 和 T6 是支撑该观点的理由（标注类型为前提）。论辩挖掘需要从原文中定位这些片段并判断其类型，进而恢复从理由指向观点的支持关系。该例表明，一个片段承担观点还是理由，需要依据其在上下文中的论证功能加以识别，而这一角色判断又直接决定了片段之间是否存在支持关系以及关系的方向：若 T3 的角色被误判，指向它的三条支持关系也将随之失去依据。因此，孤立地预测每个片段的类型或每对片段之间的关系，难以保证组件与关系相互一致，也就难以得到完整、连贯的论辩结构。

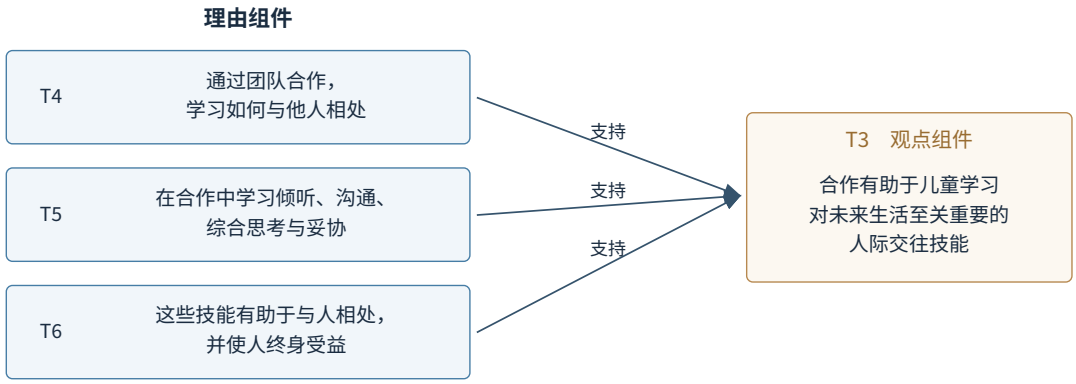


图 1.1 AAEC 作文中的观点与理由及其支持关系（essay001 局部结构，中文为阅读提示）

从方法演进来看，早期研究分别处理组件识别和关系分类，随后逐步转向组件与关系的联合建模[2,3]；随着预训练语言模型和大语言模型的发展，生成式方法把组件边界、类型和关系组织为统一的输出序列，使模型能够直接从原始文本生成论辩结构[4]。这种方式便于利用上下文并联合处理多个子任务，但并不能消除结构判断中的错误，组件与关系之间的相互依赖仍然给模型的训练和推理带来困难。本文关注其中两个问题：一是扩充训练数据时如何保留有效监督，二是如何修正预测图中的局部错误。

第一个问题是数据增强中的标注保持。论辩标注需要同时确定文本片段、组件类型和组件之间的连接，构建成本很高[1,2]；借助语言模型改写已有文本虽然能够丰富表达、扩充训练样本[5]，但改写后的文本能否沿用原标注并不确定，这是因为两段主题相同的文字可能在立场、论述范围或理由强度上有所不同，从而改变组件类型以及该组件与其他组件之间的支持关系。已有的槽位化增强方法默认改写保持了语义，因而直接沿用全部标注[6]；对于组件与关系相互依赖的论辩结构，则需要进一步判断改写后哪些监督仍然可靠，否则新增样本可能带来错误的监督。

第二个问题是预测图的修正。组件的边界或类型一旦改变，以其为端点的多条关系都可能需要重新判断，例如图 1.1 中的 T3 与三个理由相连，若只修改 T3 而保留原有关系，修正后的图仍然可能与文本含义不符；另一方面，反复重新生成或大范围修订不仅增加计算开销，还可能破坏原本正确的部分。因此，修正过程既需要让组件与其关联关系协调变化，又需要控制修改范围和计算成本。

上述两个问题分别对应结构化学习中的监督保持和结构修正，围绕二者开展研究，有助于更好地利用大语言模型抽取论辩结构。一方面，明确改写后哪些标注仍然可用，能够为论辩数据增强划定清晰的使用条件；另一方面，刻画

组件变化对关联关系的影响，能够把局部修改与整体结构联系起来。据此，本文分别设计训练方法和推理方法，二者的共同主线是处理组件与关系之间的相互依赖。

1.2 国内外研究现状

论辩挖掘经历了从分步处理到联合建模、再到生成式结构预测的发展过程，而训练数据的构造方式和预测结果的修正机制同样直接影响端到端抽取的效果。基于此，本节从端到端论辩挖掘方法、论辩挖掘中的数据增强以及结构化预测与预测结果修正三个方面，对与本文直接相关的国内外研究现状进行梳理，并说明本文的研究定位。

1.2.1 端到端论辩挖掘方法

端到端论辩挖掘以原始文本为输入，要求模型同时完成组件定位、组件类型判断以及关系识别与分类，其核心在于联合预测组件与关系。根据建模方式的不同，现有方法大致可分为基于流水线的方法、联合结构建模方法和生成式结构预测方法三类，其中生成式方法以统一的输出序列同时表示组件与关系，同样可以视为一种联合建模；此外，部分研究在上述框架中引入结构或语义信号辅助预测，另有研究关注语料表示与训练数据来源对比较结果的影响。

早期工作主要围绕论辩组件及其联系分别建模。Stab 和 Gurevych[9]研究说服性作文中的论辩话语结构识别，Persing 和 Ng[10]在学生作文上构建端到端论辩挖掘系统；随着联合建模的发展，Potash 等人[11]通过联合指针架构关联组件分类与论辩链接预测。这一演进说明，端到端描述的是从原始文本到最终论辩结构的任务范围，其内部既可以采用分阶段处理，也可以采用联合预测。

基于流水线的方法将论辩挖掘拆分为组件识别和关系分类等子任务分别处理，早期研究多采用这一思路，例如 Stab 和 Gurevych[2]针对说服性作文建立了组件与关系的分析方法。这类方法子任务边界清晰、便于分别建模，但前一阶段的错误会传递到后续阶段，各子任务之间的相互约束也难以充分利用。为此，联合结构建模方法将组件识别、关系判断与结构约束统一到一个任务中。LSTM-ER[3]将组件识别和论证结构预测纳入神经网络端到端学习框架，Niculae 等人[12]以结构化支持向量机和循环神经网络联合预测组件与关系；Morio 等人[13]则通过双仿射解析和任务特定参数化支持非树状结构的预测。这类方法能够在统一框架中利用组件与关系之间的约束，相关研究也表明不同语料的论辩结

构并不都能用树来表示，但其解析与推断过程通常需要针对特定的结构形式专门设计。

生成式结构预测方法借助预训练语言模型和大语言模型的生成能力，用统一的输出表示连接多个子任务，从而直接从原始文本生成论辩结构。Kawarada 等人[4]将论辩挖掘建模为文本到文本的生成任务，本文将其作为生成式对照方法；GMAM[14]利用约束指针和重构的位置编码，将组件与关系组织为紧凑的生成序列；UniASA[15]将多种论辩结构分析任务统一为序列生成，并通过子任务分解进行多视图学习；AASP[16]则使用受约束的预定义动作逐步构建论辩结构，把结构信息融入自回归生成过程。Cabessa 等人[17]同样将组件分类、关系识别和关系分类组织为生成任务，但其输入已经给定组件列表，与从原始文本定位组件的端到端设定不同；ARGUS 系统[18]整合了组件切分、组件分类、关系识别与分类，并接入符号求解器分析论辩框架；Li 等人[19]的综述则系统讨论了大语言模型在论辩挖掘各子任务上的应用及评价差异。

在上述框架的基础上，另一些研究借助结构或语义信号辅助预测：DENIM[20]使用篇章结构感知的前缀进行端到端预测，Das 等人[21]用关键短语表示关联组件之间的概念联系，Sun 等人[22]利用一阶逻辑规则组织关系查询和多跳推理。其中，后两项工作以预先切分好的组件为输入，主要评价给定组件条件下的分类能力，虽与端到端设定不同，但对本文的关系语义建模具有借鉴意义。

除方法本身外，比较结果还受语料表示和训练数据来源的影响。Morio 等人[23]利用辅助论辩语料进行多任务训练，AMELIA[24]统一了 19 个数据集的格式，并比较了单任务、多任务和模型合并策略；Feger 等人[25]则发现模型会依赖与数据集相关的词汇线索，跨数据集泛化能力有限。因此，本文在 AAEC 和消费者债务催收实践评论语料（Consumer Debt Collection Practices，CDCP）[12,26]两种原生任务上分别进行域内比较，后者来自公共政策规则制定中的用户评论。ORCHID[27]提供中文辩论中的立场识别与摘要任务，IAM[28]联合组织论点抽取、立场分类和证据抽取，这些资源扩展了论辩挖掘的语言与任务范围，但与本文的完整论辩图抽取并不等同。

国内研究同样围绕论辩结构的识别与应用展开。李永泽和欧石燕[7]从论辩模型、挖掘任务与应用场景梳理了该领域的研究脉络；魏忠钰等人[8]进一步区分单体式论辩与对话式论辩，说明多参与者交互会带来不同于单篇议论文的建模问题。上述研究提示，论辩挖掘方法的比较需要同时说明文本来源、标注单位和关系定义，不能仅依据任务名称相同就认为实验设置相同。

跨主题与中文研究进一步展示了语料条件的重要性。Stab 等人[29]研究异质来源中的跨主题论辩挖掘，强调在新主题上识别论辩信息的能力；言佳润和鲜于波[30]面向中文网络对话比较预训练模型微调与提示学习，张霄军和周静狮[31]则为中英双语政治论辩提供数据资源。这些研究有助于界定本文的实验范围：本文在两种英文语料上分析组件与关系的联合抽取，尚不能据此直接推断中文对话或跨主题场景中的效果。

总体而言，从流水线方法到联合结构建模，再到生成式结构预测，现有研究逐步将组件与关系纳入统一框架，生成式方法更是能够直接从原文生成完整的论辩结构，为结构生成和辅助任务设计提供了重要参考。然而，统一生成并不能消除结构判断中的错误，即使采用生成式建模，组件边界仍然是主要的误差来源之一：Caputo 等人[32]使用成对标签进行细粒度的组件切分，并分析了自动切分对后续分类的影响。由于组件一旦出错，以其为端点的关系也随之受到影响，本文在上述研究的基础上聚焦监督保持与结构修正两类机制。

1.2.2 论辩挖掘中的数据增强

数据增强通过改变文本表达来扩充训练样本，其效果取决于生成内容能否与标签保持一致[5]。围绕这一问题，现有研究大致沿通用文本增强、论辩挖掘专用合成和关系抽取增强三条路线展开。在通用文本增强方面，CoDa[33]从训练实例中提取约束来控制生成，SegMix[34]在任务相关片段上进行结构感知的混合，这些方法均表明，增强的价值不在于新增样本的数量，而在于生成内容与标签之间的对应。

从增强方式看，EDA[35]通过同义词替换、插入、交换和删除等操作构造文本变体，回译方法[36]借助翻译过程生成新的表达，上下文增强[37]则利用语言模型选择与上下文相容的替换词。Feng 等人[38]以及冯冉等人[39]的综述表明，增强方式需要与任务及监督形式相匹配。对于包含跨度、类型和关系的结构化标注，句子层面的语义相近并不足以保证全部标注仍然成立，因此增强质量还应落实到具体监督对象的检查。

在论辩挖掘中，与本文最相关的是质量导向的合成方法 QOS[6]。该方法将上下文和组件组织为槽位化输入，改写后恢复组件跨度，并直接继承原有的组件类型和关系标注，其生成模型并不显式接收论辩关系，而是依靠改写保持语义来使原关系继续成立。这一思路为局部改写提供了实现基础，但也留下了改写后哪些标签仍然成立、哪些标签已经无法确定的问题。

同一研究还提出了多样性导向的合成方法 DOS，分别从质量和多样性两方面构造增强数据[6]；Zhang 等人[40]则通过交替优化生成器和判别器来合成新的文本—结构标注对。本文借鉴 QOS 的槽位化改写思路（具体做法见第 3 章），但与上述方法不同，采用保留原图监督的局部改写，并在训练规模和下游抽取器相同的条件下，分别比较数据构造和学习目标的作用。

关系抽取领域同样关注增强质量的控制：ConsistRE[41]以关系条件和上下文约束组织细粒度生成，CovEReD[42]通过反事实实体替换研究文档级关系预测的一致性；ODDA[43]关注低资源条件下增强样本的质量与多样性，Wang 等人[44]则将大语言模型生成的样本用于联合实体关系抽取，并结合一致性正则化、伪标签和迭代反馈。这些工作面向实体关系，而本文面向组件与关系相互依赖的论辩结构，并在单个组件和单条关系的粒度上判断哪些监督可以保留，这种可单独决定是否参与监督的判断单元在本文中称为“因素”。

夏振涛等人[45]对实体关系抽取中的监督方式和联合建模进行了梳理。与实体关系联合抽取类似，论辩挖掘中的关系也依赖端点对象；但论辩组件通常是承载理由或观点的文本片段，其改写不仅会改变表面表达，还可能影响论证角色及支持、攻击关系。因此，其他关系抽取任务中的增强机制可以提供设计参考，具体的标签保持条件仍需根据论辩语料重新界定。

此外，增强还可能改变模型对表面线索的依赖：已有研究发现，话语标记补全的效果因语料而异[46]，弱监督论辩挖掘也面临组件边界和关系噪声问题[47]。由此可见，以 QOS 为代表的槽位化增强方法虽然提供了局部改写的实现途径，但默认改写保持语义并沿用全部原标注，尚未在组件与关系层面逐项检查监督是否仍然可靠。因此，本文从标签漂移、审核后的残余错误和训练成本几个方面评价增强数据，并在同一批增强样本上比较不同的学习目标。

1.2.3 结构化预测与预测结果修正

结构化预测的输出需要满足组件与关系之间的结构要求，现有方法主要从两个环节改进输出：一是在生成过程中施加约束，二是在生成之后对候选进行选择或修正。在前一类方法中，语法约束解码[48]通过限制后继 token 来控制输出格式，AASP[16]把结构动作约束纳入生成过程，这些方法能够保证输出满足格式规则，却无法判断跨度和关系本身是否正确，而后者正是本文生成后修正所要解决的问题。

生成后修订和多候选聚合是改进预测的另一条路径。Self-Refine[49]通过模型对自身输出的反馈迭代修订结果，自一致性方法[50]通过采样多条推理路径来聚

合答案；然而，在缺乏外部反馈时，模型的自我纠错可能无效，甚至会降低性能[51]。在论辩分析中，Tran 等人[52]生成论点（Claim）、证据（Evidence）与保证（Warrant）的不同组合，再从中选择切分结果。由此可见，修订的收益取决于候选质量和选择机制。与 Self-Refine 依靠模型自身反馈改写输出不同，本文的反馈来源是预先固定的组件与关系评分，输出对象则是从固定候选中选出的组件与关系集合，从而为每次修改提供统一的效用度量。

还有一些研究关注对象与关系的联合处理。Re-Cent[53]面向联合零样本关系三元组抽取，以关系为中心，利用关系标签引导跨度对的抽取，并借助关系与跨度对之间的相关性对结果进行修正；与之相比，本文在候选集合和对象评分均预先固定的条件下进行修正，以编辑预算约束修改范围，并要求组件修改与受影响关系的重建作为一个整体接受或拒绝。基于大语言模型的论辩重构流程[54]包括组件合并、重写和关系检查，允许改写组件的表述，这与保留原文跨度的抽取任务不同。面向大语言模型自我解释修复的 ARGUS[55]将自我解释转化为抽象论辩框架，并以形式语义定义最小代价的修复目标，该方法与前述同名的论辩挖掘系统 ARGUS[18]无关。

本文以多候选重排序与有界修正方法（Multi-Candidate Reranking and Bounded Repair，MCR-BR）[56]为基础方法开展研究。MCR-BR 已经支持候选跨度替换、组件类型调整和关系修改，但修改组件时没有系统处理与之相连的关系，因而组件修改后哪些关系需要重新评价、组件与关系的变化在什么条件下一起接受，仍有待解决。针对这一依赖问题，本文将组件修改与全部受影响关系的重建组织为不可拆分、须整体接受或拒绝的依赖闭合事务，并通过集合动作和全局求解实现组件与关系的联合修正。

评价修正方法时，还需要区分单个对象的评分和最终的抽取指标：以 F1 为目标的最优决策一般不能由单个对象的边际概率直接确定[57]，校准概率与 F1 最优阈值之间的关系也只在特定条件下成立[58]，而概率校准衡量的是模型置信度与实际正确率是否一致[59]。因此，本文将校准概率与代价敏感的效用函数相结合，并同时报告错误修改的数量和计算成本。

综上，现有工作为结构化生成、槽位改写和生成后修正奠定了基础，但与本文最接近的研究在输入条件和机制上仍存在差异。在训练数据构造方面，QOS[6]在槽位化改写后直接继承组件类型及关系，ConsistRE[41]与 CovEReD[42]则分别以关系条件生成和反事实一致性控制关系抽取中的增强质量，均未逐项检查改写对内部关系、跨边界关系及无关系状态的影响。在结构决策方面，AASP[16]将约束施加于生成过程，Re-Cent[53]以关系引导跨度对抽取并进行修

正，MCR-BR[56]在多个完整论辩图上进行整图重排序及有界的组件与关系修改，但均未将组件集合修改所波及的关系完整重建并纳入同一接受条件。由此可见，局部改写后哪些监督可以继续使用、组件变化后如何一并处理与之相关的关系，仍是有待解决的两个问题，本文据此分别从训练阶段的可靠监督与一致性学习和推理阶段的联合修正两方面展开研究。

1.3 主要研究内容

尽管基于大语言模型的生成式方法能够从原文统一生成论辩组件与关系，但组件与关系之间的相互依赖仍使其在训练和推理两个阶段面临挑战。一方面，论辩标注成本高，数据增强是扩充训练样本的常用手段，而局部改写可能改变组件的论辩角色或组件之间的关系，直接沿用原标注会引入错误监督。因此，训练阶段需要研究局部改写后如何识别仍可用于学习的组件与关系标注，并在源文档、增强规模和训练预算相同的条件下，考察可靠标注的构造、辅助监督和一致性学习分别带来多少性能提升，又需要多少生成、审核和训练成本。另一方面，生成结果中常含有边界或类型错误的组件，而组件一旦修改，以其为端点的关系随之失效。因此，推理阶段需要研究在候选集合和评分固定的条件下，如何在修改组件时完整处理与之相关的关系，同时控制误改风险和计算成本，并考察修改粒度、组件与关系的共同接受以及求解方式分别如何影响修正质量和计算开销。

为应对上述挑战，本文以 MCR-BR[56]为基础方法，按照从训练到推理的顺序开展两项递进的研究，旨在使大语言模型更可靠地完成端到端论辩挖掘：第一项工作在训练阶段控制增强监督的可靠性，以改进模型的学习信号；第二项工作以第一项工作所得模型为起点，在推理阶段对其预测中残余的组件错误及受影响的关系进行联合修正。两个阶段在输入和监督条件上存在明显差异：训练阶段以带标注的原文为输入，通过构造局部改写并判断哪些监督仍可保留来扩充训练信号；推理阶段则面向无标注的新文档，在不改动原文的前提下，仅对模型预测的组件与关系进行选择和修正。如图 1.2 所示，两项工作沿同一条数据流依次衔接，第二项工作处理的正是第一项工作所得模型的预测结果；由于联合修正只依赖固定的候选与对象评分，该方法同样可以作用于其他训练配置得到的模型。本文的研究内容据此划分为以下两部分。

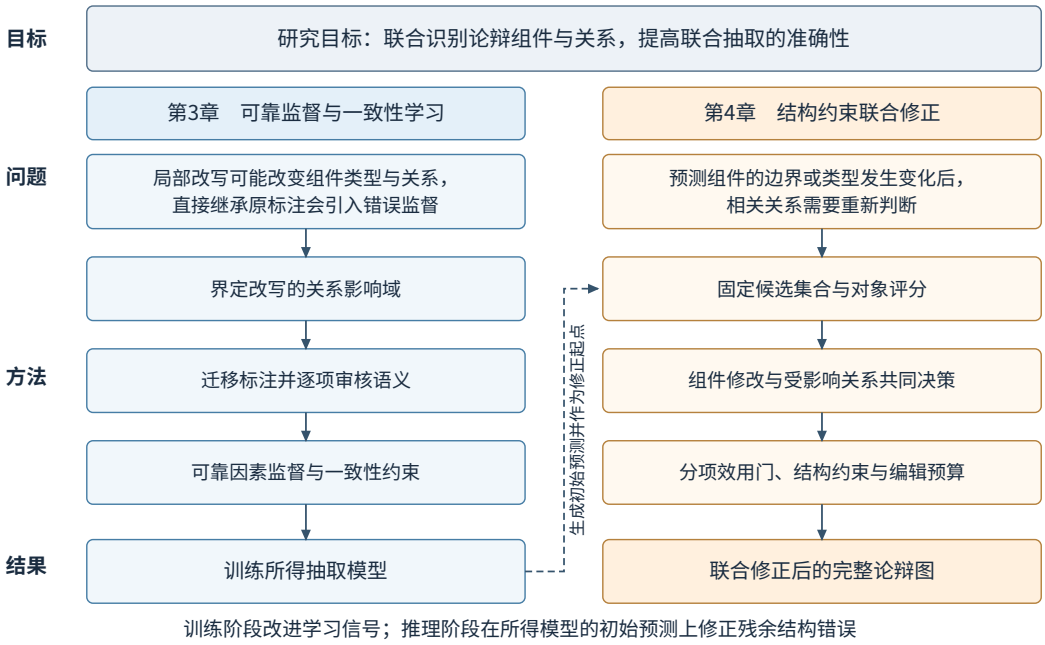


图 1.2 端到端论辩挖掘的总体研究框架

其中，低秩适配（Low-Rank Adaptation，LoRA）[60]双分支微调、结论线索提示、句子辅助监督、多候选生成与初始重排序以及合法化与原始有界修正模块均沿用 MCR-BR[56]，本文新增的工作集中在训练阶段的可靠增强数据构造与一致性学习，以及推理阶段组件修改后受影响关系的完整重建与联合决策，具体如下。

（1）针对局部改写后部分标注可能失效的问题，提出可靠监督与一致性学习方法。与 QOS 直接继承全部原标注的槽位化增强方法不同，该方法以单个组件和单条关系为粒度判断改写后的监督是否仍然可靠。具体而言，首先通过关系影响域界定每处改写可能影响、因而需要检查的内部、跨边界和无关系因素，并通过无损的标注迁移将原标注映射到改写文本上；随后逐项进行语义审核，确定仍然可靠的组件与关系，并以因素掩码记录哪些因素参与增强侧的学习；在此基础上，训练时由原文提供完整的论辩图监督，改写文本只在可靠因素上提供辅助监督并与原文施加一致性约束，辅助分类头仅在训练时使用，测试时移除。针对多前提关系，该方法进一步区分“与完整关系不匹配”和“语义上无关系”，避免把联合理由的子集错误地当作负例。人工分层审核表明，改写会使约 6%的因素状态发生变化，而经过审核后，被接受关系因素的加权不安全率估计为 0.81%和 0.91%。

（2）在第一项工作的基础上，针对模型预测中残余的组件错误会使关联关系随之失效的问题，进一步提出结构约束联合修正方法。第一项工作改善了模型的学习信号，但其预测结果中仍残留组件边界或类型错误，而组件一旦修

改，以其为端点的关系也随之失效，单靠改进训练信号难以消除这类错误。为此，该方法在原文、候选集合和对象评分均固定的条件下，把组件修改与全部受影响关系的重建定义为一个不可拆分的依赖闭合事务，事务中的修改必须一起接受或一起拒绝。具体而言，对象评分器在交叉拟合的预测候选上学习判断完整对象是否正确，其校准后的输出用于构造可分解的计数效用，且只服务于结构决策，修正过程不更新抽取模型参数；是否接受一个事务，则由组件和关系各自的效用变化（分项效用门）以及编辑预算共同决定。在此基础上，本文给出集合局部搜索和全局整数规划两种求解方式，并分析了方法的性质：效用变化可以由增删对象精确计算，集合动作能够越过单对象修改无法越过的局部障碍，搜索过程在有限步内终止。实验结果表明，在第一项工作所得模型上追加该方法，严格关系 F1 进一步提高 3.38 和 5.68 个百分点，其中仅修正关系已带来 2.20 和 4.11 个百分点，允许修改组件并重建关联关系再带来 1.18 和 1.57 个百分点，分步决策、单对象共同决策和集合动作等方案的对比进一步说明了共同接受与集合动作的作用；与相同预算下的重新生成相比，该方法在取得更高 F1 的同时保留了 98%以上的原有正确关系。

为系统验证上述两项工作，本文采用严格、可复现的评价与分析方法：以字符区间和完整端点定义论辩对象，按完整的多前提关系严格计数，并采用文档与种子联合重采样[61]和 Holm 多重比较校正[62]进行显著性检验；训练侧分别控制数据构造和学习目标，推理侧固定候选与评分，考察修改范围、共同接受和求解方式的影响，并与相同预算下的重新生成进行比较。在 AAEC 和 CDCP 上，依次采用两项方法的完整配置比同骨干的 MCR-BR 基线分别提高 5.94 和 8.98 个百分点，14 项主要比较全部通过校正。第 4 章还通过训练与推理的四种组合以及逐条关系的成员分析考察两项工作的衔接关系，结果表明联合修正在第一项工作的基础上继续带来增益，在基础方法的模型上同样有效，两阶段恢复的关系几乎不重叠，未检出显著交互；在另外两种 Qwen 系列骨干上，两项方法同样带来显著提升。

1.4 论文组织结构

本文共分为五章，整体组织结构如图 1.3 所示，各章内容安排如下。第 1 章为绪论。首先阐述论辩挖掘的研究背景与意义，分析大语言模型生成式论辩挖掘中组件与关系相互依赖给训练和推理带来的困难；其次从端到端论辩挖掘方法、论辩挖掘中的数据增强以及结构化预测与预测结果修正三个方面梳理国内

外研究现状，明确本文的研究定位；最后介绍本文的主要研究内容，并对论文的整体结构进行说明。

第 2 章介绍相关理论与技术。首先给出论辩组件与关系的任务定义以及组件的字符级表示；随后介绍大语言模型的注意力机制、自回归生成以及参数高效微调与连续提示技术[63]；进一步地，介绍数据增强与一致性学习、候选评分与结构化决策的相关基础，为后续方法设计提供理论支撑。

第 3 章介绍提出的基于可靠监督与一致性学习的论辩挖掘方法。该方法通过关系影响域确定改写可能影响的组件与关系，借助标注迁移与语义审核筛选可靠因素，并在可靠因素上施加辅助监督与一致性约束，从而在扩充训练数据的同时减少错误监督；最后在 AAEC 和 CDCP 上通过对照实验，从整体效果、一致性目标的作用、增强数据的审核质量与训练成本等方面验证方法的有效性。

第 4 章介绍提出的基于结构约束的论辩图联合修正方法。本章以第 3 章所得模型为起点，针对其预测结果中残余的组件与关系错误，将组件修改与受影响关系的重建组织为依赖闭合事务，在固定的对象评分下通过分项效用门和编辑预算决定是否接受，并给出集合局部搜索与全局整数规划两种求解方式；实验部分在分析修正质量、误改风险和计算开销的基础上，进一步分析联合修正与第 3 章方法之间的衔接与互补关系，并给出不同骨干模型上的结果以及与外部系统和已发表结果的比较。

第 5 章为总结与展望。本章回顾全文的研究工作与主要结论，分析方法存在的局限，并对后续研究方向进行展望。

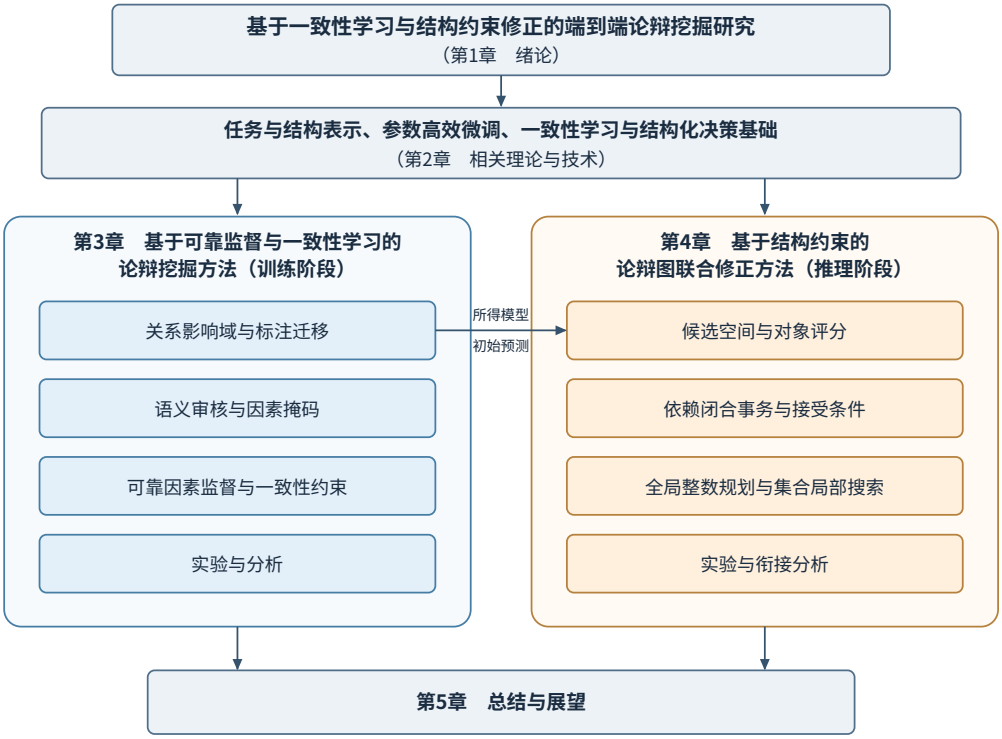

基于一致性学习与结构约束修正的端到端论辩挖掘研究
（第1章　绪论）
任务与结构表示、参数高效微调、一致性学习与结构化决策基础
（第2章　相关理论与技术）
第3章　基于可靠监督与一致性学习的
论辩挖掘方法（训练阶段）
关系影响域与标注迁移
语义审核与因素掩码
可靠因素监督与一致性约束
实验与分析
所得模型
初始预测
第4章　基于结构约束的
论辩图联合修正方法（推理阶段）
候选空间与对象评分
依赖闭合事务与接受条件
全局整数规划与集合局部搜索
实验与衔接分析
第5章　总结与展望

图 1.3 论文组织结构

第 2 章 相关理论与技术

论辩挖掘需要从没有结构标注的文本中同时识别论辩组件及其相互关系，组件与关系如何表示、模型如何学习、候选结构如何选择，共同决定了训练阶段能否保留可靠的监督、推理阶段能否修正残余的结构错误。本章围绕后续两章共同使用的任务表示与相关技术展开介绍，为第 3 章和第 4 章的方法设计奠定基础。首先，给出论辩组件与关系的统一表示，明确组件的字符级身份与合法结构的基本要求；在此基础上，介绍大语言模型的注意力机制、自回归生成与参数高效微调技术；进一步地，介绍数据增强与一致性学习，以及候选评分与结构化决策的基本概念。评价指标与实验设置与具体方法的实验分析联系更为紧密，分别在第 3 章和第 4 章的实验部分给出。

2.1 论辩挖掘任务与结构表示

2.1.1 论辩组件与关系

论辩挖掘以没有结构标注的文档为输入，旨在识别其中的论辩组件并判断组件之间的关系：组件识别确定论辩相关文字在原文中的位置，组件分类则判断其在论证中承担的类型。本文采用端到端设定，即直接从原文预测组件与关系，系统内部可以包含生成、候选选择和预测修正等多个步骤。

为统一描述上述任务，记文档为 x，其标识为 d，该标识同时记录语料、原始文档编号及文本版本，字符位置按原文的 Unicode 码点从 0 开始计数。在此基础上，组件表示为：

$$c=(d,b,e,t),\qquad 0\le b<e\le|x|, \tag{2-1}$$

其中，$[b,e)$ 为左闭右开的字符区间，$x[b{:}e]$ 为组件对应的原文片段，t 为语料定义的组件类型。由此，组件由字符区间和类型共同确定：相同文字出现在文档的不同位置时视为不同的组件，同一字符区间被赋予不同类型时也视为不同的预测对象，评价时二者都必须完全匹配。

二元关系表示两个组件之间的有向联系，记为 $r=(c_i,c_j,\ell)$，其中 c_i 为源组件，c_j 为目标组件，ℓ 为关系标签，关系方向由提供理由或发起攻击的一方指向被支持或被攻击的一方。组件与关系共同构成文档的论辩结构，记为 $G=(C,R)$，其中 C 为组件集合，R 为关系集合。

部分语料允许多个组件共同支持同一个目标，此时关系表示为 $h=(S,c_j,\ell)$，其中 S 为非空的源组件集合，集合中的成员共同构成一条完整关系。若将其拆分为多条二元边，计数单位和匹配条件都会随之改变，因此本文保留原始的多前提结构，二元关系可视为源集合大小为 1 的特例[12,26]。两种语料的原生任务表示及标签的中英文对照如表 2.1 所示。

表 2.1 两种语料的原生任务表示与标签对照

语料	组件类型	关系类型	评价时保留的任务边界
AAEC	主论点（MajorClaim）、论点（Claim）、前提（Premise）	支持（Support）、攻击（Attack）二元关系	论点对主论点的立场（stance）单列，不补造普通关系
CDCP	事实（Fact）、证言（Testimony）、价值（Value）、政策（Policy）、引用（Reference）	理由（Reason）、证据（Evidence）多前提关系	完整源集合参与匹配，不归并组件类型，不拆分超边

两种语料的任务定义沿用原始标注及相关研究[2,12,26]，实验也分别按各自的原始标注进行评价。以 CDCP 为例，若一条关系有两个源组件，预测时漏掉其中任意一个都不能与该关系匹配；第 3 章用到的“结论角色”仅用于选择增强中心，并不改变 CDCP 的原始组件类型。为便于阅读，后文正文与图表中的组件类型和关系标签统一使用表 2.1 给出的中文名称。

2.1.2 组件的字符级表示

严格匹配要求预测组件与金标组件的字符边界完全一致，即使只相差一个字符，预测组件也会被判为错误，因此组件的身份需要以原文字符坐标而非 token 位置来确定。模型使用的子词切分和评价使用的分词都只是原文的派生表示，二者均通过字符偏移映射回原文，分词方式可以不同，但组件的字符边界始终以原文为准。若仅用 token 的起止位置和类型标识组件，覆盖相同 token 而字符边界不同的两个片段就会被当成同一个组件，当组件边界落在单词内部时，这一问题尤为明显。

为在 token 表示下精确保存字符边界，设评价 token 的字符区间依次为 $[a_i,z_i)$，对于字符区间为 $[b,e)$ 的组件，取与其相交的首、末 token 索引 s,u（从 1 开始），并记录左右两端的字符残差：

$$\rho_L=b-a_s,\quad \rho_R=z_u-e;\qquad b=a_s+\rho_L,\quad e=z_u-\rho_R, \tag{2-2}$$

其中，左右残差记录了组件边界相对于首、末 token 边界的字符偏移，由 (s,u,ρ_L,ρ_R) 即可精确恢复原字符区间，而仅凭 (s,u) 通常无法做到；模型子词同样通过字符偏移与原文对应，聊天模板等引入的位置偏移不计入原文坐标。

以 AAEC 文档 essay098 中的论点组件 T6 为例，其原标注的字符区间为 [858,914)，在单词 responsible 的最后一个字母之前结束，片段末尾为“responsibl”，本文保留这一原始边界。作为对照，将边界扩展到完整单词可构造另一个论点片段，其字符区间为[858,915)，片段末尾为“responsible”。两个片段对应的评价 token 闭区间均为 [162,172]，覆盖的 token 字符区间均为 [858,915)：借助字符残差，前者的左右残差为(0,1)，恢复为[858,914)（858+0，915-1），后者的左右残差为(0,0)，恢复为[858,915)。由此可见，两者的文档、token 范围和类型都相同，仅结束位置相差一个字符，在严格匹配下属于不同的对象而不会被合并；字符残差仅用于保存原始边界，并不用于修正标注。

在此基础上，组件由式（2-1）中的四个字段唯一确定，本文称之为组件的规范键；关系的规范键由全部端点的规范键和关系标签组成，多前提关系的源端保存排序后的完整组件集合。候选去重、评分缓存、修改记录和评价匹配均通过规范键识别对象，而 T3、T4 等组件编号只用于文中引用，重新编号既不会产生新对象，也不计为一次修改。

规范键的定义直接决定了组件修改对关系的影响：组件的边界或类型一旦改变，其规范键随之改变，与之相连的关系必须按新的端点重新判断，即使关系在图中的编号不变，也不能直接沿用旧关系的身份和评分。这一性质正是第 4 章联合修正的出发点。

原文与增强文本属于两个不同的文本版本，第 3 章的映射 φ 用于描述改写前后组件之间的对应关系，并不要求两侧字符位置相同。局部改写改变文本长度后，位于改写处之后的组件即使文字未变，其字符位置也会随之偏移，因此所有受影响组件的字符位置都需相应更新；位置更新只解决对象的定位问题，更新后哪些组件和关系能够参与学习，仍由审核结果决定。

基于上述表示，论辩结构预测可以划分为对象、候选、预测、评分和指标五个层次，各层次分别回答不同的问题：对象层按字符区间、类型和完整端点定义组件或关系，回答所比较的是否为同一对象；候选层给出有限的组件集合及完整关系候选集合，回答正确对象是否进入可选择范围；预测层是模型或决策过程实际输出的合法结构，回答系统最终选择了哪些对象；评分层是对候选对象正确性的估计及其决策用途，回答分数能否支持可靠选择；指标层基于与

金标匹配后的 TP、FP、FN 及其汇总，回答预测在统一任务下的准确性如何。区分这五个层次，也就区分了一个对象“可以被选择”“得分较高”与“预测正确”三种不同的情形。

记合法结构集合为 G_A，其中 A 为语料的标注规范。合法结构需满足以下基本要求：组件跨度位于原文范围内，组件类型和关系标签有效，且关系的全部端点均存在；各语料实际启用的结构约束在 4.2.2 节逐项给出。

2.2 大语言模型与参数高效微调

2.2.1 注意力机制与自回归生成

Transformer[64]通过注意力机制聚合序列中不同位置的信息，是本文所用大语言模型骨干的基础结构。注意力机制首先根据查询与键之间的相似度计算权重，再对值向量进行加权求和，其中缩放点积注意力的计算方式如下：

$$\mathrm{Attention}(Q,K,V)=\mathrm{softmax}\left(\frac{QK^{\mathrm{T}}}{\sqrt{d_k}}\right)V, \tag{2-3}$$

其中，Q、K、V 分别为查询、键和值矩阵，d_k 为键向量的维度，此处的 V 与第 4 章的组件候选集合含义不同。在此基础上，多头注意力在多个表示子空间中并行计算注意力；自回归解码时，每个位置只能关注输入和已经生成的输出。

基于 Transformer 的预训练模型具有不同的结构与训练目标。BERT[65]通过双向编码学习上下文表示，BART[66]采用去噪序列到序列预训练，T5[67]则将多种语言任务统一为文本到文本形式。三者为判别式表示学习和生成式结构预测提供了不同基础，本文所用骨干及对照系统的具体选择在实验设置中列出。

基于自回归生成范式，论辩挖掘可以将组件位置、类型和关系依次序列化为输出序列 $Y=(y_1,\ldots,y_L)$，给定原文 x，其生成概率和训练目标分别表示为：

$$P_\theta(Y\mid x)=\prod_{k=1}^{L}P_\theta(y_k\mid x,y_{<k}), \tag{2-4}$$

$$L_{\mathrm{gen}}=-\sum_{k=1}^{L}\log P_\theta(y_k\mid x,y_{<k}), \tag{2-5}$$

其中，训练时以金标序列作为前缀计算下一个符号的损失，测试时则以模型已经生成的符号作为前缀。生成式论辩挖掘[4]借助这一范式将多个子任务统一到同一个输出序列中；然而，序列概率同时受输出长度和字段顺序的影响，难以

直接衡量单个组件或关系是否正确，因此本文另外训练了对象评分器，用于直接估计每个组件和关系的正确概率。

2.2.2 参数高效微调与连续提示

大语言模型参数规模庞大，针对具体任务更新全部权重会带来较高的训练与存储成本，参数高效微调则通过冻结大部分预训练参数、仅优化少量新增参数，实现对下游任务的高效适配。以低秩适配（LoRA）[60]为例，该方法冻结基础权重，只学习一个低秩增量，表示为：

$$W = W_0 + \frac{\alpha}{r} BA, \qquad A \in \mathbb{R}^{r \times d_{\text{in}}}, \quad B \in \mathbb{R}^{d_{\text{out}} \times r}, \tag{2-6}$$

其中，r 为秩，α 为缩放系数，训练时只更新增量矩阵，基础权重 W_0 保持不变。与 LoRA 调整权重的方式不同，连续提示[63]通过学习一组提示向量来表达任务条件，从输入侧实现参数高效的适配，两类方法都只引入少量可训练参数。

参数高效适配还包括在预训练层中插入少量可训练模块的 Adapter 方法[68]、在注意力计算中引入可学习前缀的 Prefix-Tuning[69]，以及将低比特量化与低秩适配结合的 QLoRA[70]。唐岸达和林宙辰[71]从适配机制、应用与效率等方面总结了相关方法。上述技术改变了任务适配时更新的参数及计算开销，但并不自动保证增强标注可靠或预测结构合法；这两类问题仍需由本文的监督筛选和结构决策机制分别处理。

2.3 数据增强与一致性学习

数据增强通过改变输入的表达方式来扩充训练样本，然而，利用语言模型改写文本时，即使结果通顺，也可能使部分原有标注失效[5,6]。论辩挖掘的监督包括组件位置、组件类型和关系，局部的语义变化往往只影响其中一部分，因此本文将通顺性与标注保持分开判断，并以单个组件或单条关系为单位决定保留哪些监督。

一致性学习已有明确的方法基础。Temporal Ensembling[72]积累不同训练时刻的预测以构造一致性目标，Mean Teacher[73]通过模型权重的滑动平均形成教师预测，虚拟对抗训练（Virtual Adversarial Training，VAT）[74]则约束模型在局部扰动下的预测变化。面向文本的无监督数据增强（Unsupervised Data Augmentation，UDA）[75]将增强文本与预测一致性结合，R-Drop[76]约束不同

Dropout 采样得到的输出分布，FixMatch[77]结合高置信度伪标签与强弱增强。这些方法的共同点是利用相关视图或预测目标约束输出，但视图来源、监督条件和损失形式并不相同；本文使用经过审核的原文—改写文本对应因素，并不直接照搬上述方法的完整训练流程。

为使模型在不同表达下保持稳定的预测，一致性学习约束同一对象在不同输入下的预测分布保持接近。设同一因素（即单个组件的类型或一组端点之间的关系状态）在两个视图下的类别分布为 p 和 q，令 $m=(p+q)/2$，Jensen–Shannon 散度[78]定义为：

$$\mathrm{JS}(p,q)=\frac{1}{2}\mathrm{KL}(p\|m)+\frac{1}{2}\mathrm{KL}(q\|m),\qquad m=\frac{p+q}{2},\tag{2-7}$$

其中，KL 表示 KL 散度，式（2-7）对两个分布是对称的。在训练目标中加入该散度项，可使模型对原文和改写文本中相互对应的可靠因素给出相近的预测；未经确认的关系标签既不参与监督，也不参与一致性约束，更不会被直接改标为无关系（NONE）。

然而，仅约束两个视图的预测分布相互接近，并不能保证预测与金标一致，当两个视图产生相同的错误时，JS 散度依然很小；金标监督则引导预测接近正确标签，二者互为补充。据此，本文组合三类训练信号，即原文的完整论辩图生成监督、因素级的辅助监督，以及原文与改写文本构成的成对视图之间的一致性约束，第 3 章给出具体的学习目标。

2.4 候选评分与结构化决策

单次生成可能遗漏组件或产生错误的关系，多候选方法通过生成若干备选结构来扩大选择范围。以 MCR-BR[56]为例，设候选图集合为 S，重排序函数为 $\mathrm{E}_{\mathrm{rank}}$，系统首先选出重排序得分最高的候选图，再依次执行合法化处理和 MCR-BR 中的原始有界修正模块（本文记为 BR-O），得到预测图，表示为：

$$\begin{aligned} G_{\mathrm{rank}}&=\mathrm{argmax}_{G\in S}\,\mathrm{E}_{\mathrm{rank}}(G),\\ G_{\mathrm{pre}}&=L_A(G_{\mathrm{rank}}),\qquad G_0=\text{BR-O}(G_{\mathrm{pre}}),\end{aligned}\tag{2-8}$$

其中，L_A 为确定性的合法化过程，G_{rank} 为重排序得分最高的候选图，G_{pre} 为合法化后的图，G_0 为经 BR-O 修正后得到的初始图，后文提到的初始图均指 G_0。上述重排序、合法化与 BR-O 构成的完整流程沿用 MCR-BR，本文称之为推理配置 I0；第 4 章在 G_0 的基础上追加联合修正（记为 R_{DC}），I0 加上 R_{DC} 即为推理配置 I1，统计推理时延时同时计入 I0 和追加阶段的耗时。

得到 G_0 之后，第 4 章预先构建并固定三个有限集合，即跨度候选集合 U、带类型的组件候选集合 V 和关系候选集合 P，合称候选空间，修正只能在候选空间内进行。因此，最终结果同时受候选覆盖、评分质量和搜索预算三方面影响：正确对象若不在候选中，就不可能被恢复；即使进入候选，也可能因评分不够高或搜索受限而未被选中。

对象评分的单位应当与最终评价的单位保持一致：在给定金标跨度时，组件分类只需判断片段的类别，而对于模型预测的组件，还需判断其字符边界是否准确；关系评分则要同时考虑全部端点、方向和标签。为此，本文为推理阶段单独训练了完整对象评分器，该评分器与训练阶段的辅助分类头相互独立，在交叉拟合产生的预测候选上训练，拟合、校准和策略选择使用互不重叠的数据。由于修正过程优先采纳高分对象，本文既评价评分器在全部候选上的质量，也统计实际被接受的修改中有多少是错误的。

概率校准[59]衡量模型置信度与实际正确率是否一致，例如，得分在 0.8 左右的一组对象若校准良好，应当有大约 80%是正确的。在此基础上，本文将校准后的概率转化为保留或删除一个对象的期望得失，构造结构决策所用的效用函数，最终输出仍以严格 F1 评价[57,58]。

结构化决策旨在从有限候选中选出满足约束的对象组合，候选空间越大，可选对象越多，评分和求解的开销也随之增大。本文的局部求解按累计修改次数计算编辑预算，全局求解则按相对初始图的净变化计算编辑预算，因此二者的搜索范围并不相同。

将多个局部预测纳入统一约束的思想在结构化自然语言处理中已有应用。Roth 和 Yih[79]采用线性规划组织全局推断，使局部分类结果服从共同约束。本文沿用结构化决策的基本思路，但研究对象是生成后的论辩图修正，额外要求组件修改所影响的关系在同一事务中重新判断，并通过分项效用和编辑预算限制修改。

关系候选的构造方式因语料而异：对于 AAEC，关系候选为同一文档中任意两个不同组件构成的有向对，不允许自环，也不按段落或组件类型预先过滤；对于 CDCP，候选源集合取按原文位置排序后的连续组件，且目标不能属于源集合。本文以无关系（NONE）表示一个组件对之间不存在关系，NONE 不作为论辩关系输出。

本节给出了候选评分与结构化决策的基本概念，第 4 章将在此基础上定义组件修改后的依赖处理、接受条件和编辑预算。

2.5 本章小结

本章介绍了后续两章共同使用的任务表示与相关技术。首先，给出了论辩组件与关系的统一表示：组件由文档、字符区间和类型确定，关系由完整端点和标签确定，并支持多前提关系；在此基础上，借助字符残差与规范键明确了组件的字符级身份，说明了组件一旦修改，与之相连的关系为何必须重新判断。其次，介绍了注意力机制与自回归生成、参数高效微调与连续提示等大语言模型相关技术；进一步地，介绍了数据增强与一致性学习，以及候选评分、概率校准与结构化决策的基本概念。这些内容为第 3 章的可靠监督与一致性学习方法和第 4 章的结构约束联合修正方法提供了理论基础，两章的评价指标与实验设置分别在各自的实验部分给出。

第 3 章 基于可靠监督与一致性学习的论辩挖掘方法

利用语言模型对已标注文本进行局部改写，是扩充论辩挖掘训练数据的一种常用方式。然而，论辩组件与关系相互依赖，改写后部分原有标注可能已经失效，直接沿用全部原标注会把错误监督引入训练。针对上述问题，本章聚焦训练阶段增强监督的可靠性，提出可靠监督与一致性学习方法。具体地，通过关系影响域确定一处改写可能波及的组件与关系，通过语义审核筛选其中仍然可靠的部分，并仅在这些可靠的组件与关系上施加辅助监督和一致性约束，从而在扩充训练数据的同时避免引入错误监督。本章首先介绍总体框架与基础模型，然后依次说明可靠增强数据的构造方法与一致性学习的训练目标，最后通过对照实验分析方法的整体效果、一致性项的作用以及增强数据的审核质量与成本。

3.1 引言

论辩挖掘需要从文本中识别论辩组件并确定组件之间的关系，而在论辩文本中，组件的文字既决定其自身的类型，也是判断它与其他组件之间关系的依据。由于此类结构化标注的构建成本较高，对已标注文本进行局部改写以扩充训练样本，是缓解监督不足的一种自然思路。然而，局部改写即使基本保持句意，也可能改变支持关系的方向、削弱跨越改写边界的理由，或使原本无关的两个组件产生联系；若将原有标签全部照搬到改写文本上，新增样本就可能带来错误的监督。

近年来，研究者开始借助语言模型的生成能力构造论辩挖掘的增强数据。例如，质量导向的合成方法 QOS[6]将上下文与组件组织为槽位化输入，在改写后恢复组件跨度，并直接继承原有的组件类型与关系标注，为局部改写提供了实现基础。然而，这类方法默认改写保持了语义、原标注在改写文本上依然成立，对于组件与关系相互依赖的论辩结构，这一假设仍面临两个问题。一方面，改写影响的并不只是被改写的组件本身，与之相连的关系、跨越改写边界的关系以及原本没有关系的组件对，其状态都可能随之改变，若不界定改写的影响范围并逐项判断监督是否可靠，错误标签就会混入训练；另一方面，即使筛选出了可靠的监督，若仅将改写文本作为独立样本参与训练，也无法约束模型对原文与改写文本中相互对应的组件和关系给出一致的判断，增强数据所提供的对应信息未能得到充分利用。

针对上述问题，本章提出可靠监督与一致性学习方法，旨在扩充训练数据的同时，只让改写后仍然可靠的组件与关系参与学习，并利用原文与改写文本之间的对应关系约束模型预测的一致性。具体而言，首先，确定一处改写可能影响的组件和关系，即关系影响域，并在字符坐标上将全部组件迁移到改写文本中；其次，分别审核组件与关系，凡是状态改变、无法判定或未经审核的，均不参与增强侧的监督；最后，在原文与改写文本之间，仅对可靠的组件与关系施加一致性约束，并结合原始标注进行辅助监督。

为便于叙述，本章将同一篇文档的原文与其改写版本看作对同一内容的两种表述，称为两个“视图”，二者构成一组成对视图；同时，将可以单独决定是否参与监督的一项判断称为一个“因素”，它既可以是一个组件的类型，也可以是一组端点组件之间的关系状态。在此基础上，一致性学习要求模型对两个视图中相互对应的可靠因素给出一致的预测。由于可靠因素决定了哪些标签参与学习，而一致性项仅在这些因素上施加约束，在增强数据与掩码固定的条件下，即可单独衡量一致性项带来的增益。本章的主要符号见目录后的主要符号对照表。

3.2 总体框架与基础模型

本章方法的整体框架分为增强构造与参数学习两个阶段：构造阶段以训练文档及其标注为输入，输出改写后的全文、改写前后组件之间的对应关系φ以及可靠因素的掩码；学习阶段保留原文的完整生成监督，增强文本则只使用通过审核的因素，具体结构见 3.4 节图 3.2。本章围绕关系影响域约束、可靠因素监督与一致性目标组织训练过程。抽取生成器采用类型条件 LoRA 的全局与结论双分支，并结合结论线索提示与句子辅助监督，这些模型配置沿用 MCR-BR[56] 的设置。增强生成器 A、自动审核器 V 与抽取生成器 G 分别负责构造改写文本、审核监督和抽取论辩结构（见表 3.8），三者通过组件对应关系与因素掩码相互衔接。

因素掩码是随监督信号一同保存的 0/1 标记：取 1 表示该因素参与增强侧的监督与一致性约束，取 0 则表示不参与。掩码既不遮蔽输入文字，也不删除原始标注，组件掩码与关系掩码分别保存。

抽取生成器采用 Qwen3.5-9B[80]的文本部分，该模型共 32 层、隐藏维度为 4096[80]；全局分支与结论专项分支两组 LoRA 均挂载在 8 个全注意力块的 q/k/v/o 投影上，取$r=16$、$\alpha=32$、dropout=0.05，其余 24 个线性注意力块、前馈层

和视觉编码器保持冻结[81]。对于投影矩阵W_0，带门控的双分支 LoRA 输出定义为：

$$h'_t = W_0 h_t + \frac{\alpha}{r} B_g A_g h_t + g_t \frac{\alpha}{r} B_c A_c h_t, A_\cdot \in \mathbb{R}^{r \times d_{\text{in}}}, B_\cdot \in \mathbb{R}^{d_{\text{out}} \times r}, \quad (3\text{-}1)$$

其中，下标 g、c 分别表示全局分支与结论分支，h 和 h′分别为位置 t 的输入表示与输出表示。

全局分支作用于所有位置，结论分支则由门控$g_t \in \{0,1\}$控制。具体而言，模型对每个组件依次输出 id（编号）、type（类型）和 span（原文片段）三个字段，当某一组件的类型字段已输出为结论类（AAEC 中为论点或主论点，CDCP 中为政策或价值）时，门控在该组件的后续字段上开启，并在组件结束时关闭；其余位置以及关系部分均有$g_t = 0$。由于门控仅依据已生成的前缀决定，训练时也不会读取后续答案。

当文本中出现 therefore、thus、in conclusion、consequently、hence、to conclude 这六类结论线索词时（不区分大小写，按词边界匹配），模型在输入嵌入前插入四个可训练的提示向量，否则不插入[63]，原文与增强文本分别判断是否触发。线索词仅用于触发提示，并不直接决定组件标签[46]。

生成目标对回答部分的全部 token（含结束符 EOS）取平均，聊天模板与提示向量均不计入损失，计算方式如下：

$$L_{\text{gen}}(x, G) = -\frac{1}{T_y} \sum_{t=1}^{T_y} \log p_\theta(y_t \mid x, y_{<t}). \quad (3\text{-}2)$$

句子辅助任务沿用 MCR-BR 的设置：按句末标点切分句子后，对每个句子的末层表示进行均值池化，再经线性层和 sigmoid 函数得到该句含有结论的概率$\hat{z}_i$；若句子与结论类组件存在重叠，则$z_i = 1$，否则为 0。句子损失与生成损失共同构成原文的基础监督目标，定义为：

$$L_{\text{sent}} = -\frac{1}{N_s} \sum_{i=1}^{N_s} \left[z_i \log \hat{z}_i + (1 - z_i) \log(1 - \hat{z}_i) \right], L_{\text{IC}} = L_{\text{gen}} + \lambda_{\text{sent}} L_{\text{sent}}, \quad (3\text{-}3)$$

其中，$\lambda_{\text{sent}} = 0.5$，句子头仅用于辅助表示学习。在上述基础监督之上，3.3 节介绍增强文本的构造，3.4 节介绍新增的可靠因素监督与一致性目标。

3.3 基于关系影响域的可靠增强数据构造

3.3.1 改写范围与关系影响域

本章构造增强文本时不改变组件类型与关系标注，仅替换部分已标注组件的文字，被替换的组件构成改写集合，且可以分布在不同段落中。相应地，下文所说的“内部”与“跨边界”按关系的端点是否全部位于改写集合中区分，与句子或段落的划分无关。

为便于描述，本章将允许替换文字的组件片段称为“槽位”，将文字保持不变的其他组件称为“只读组件”；由于前面的改写可能改变文本长度，只读组件的字符位置也需随之更新。此外，下文的“正关系”指带有明确标签（如支持、攻击）的关系，与表示无关系的 NONE 相对。

以 AAEC 训练文档 essay001 为例，如表 3.1 所示，T4、T5 和 T6 均以支持关系指向 T3，而 T4 与 T7 之间没有关系。若取改写集合 A={T3,T4}，则 T4→T3 为内部正关系，T5→T3 与 T6→T3 为跨边界正关系，T4→T7 为跨边界 NONE。该集合仅用于说明上述概念，按默认规则以 T3 为中心时，所有指向 T3 的源组件 T4、T5、T6 都会进入改写集合。

表 3.1 AAEC essay001 的原生组件与关系因素

组件	原生类型	字符区间	原文
T3	论点	[591,714)	through cooperation, children can learn about interpersonal skills which are significant in the future life of all students
T4	前提	[716,851)	What we acquired from team work is not only how to achieve the same goal with others but more importantly, how to get along with others
T5	前提	[853,1086)	During the process of cooperation, children can learn about how to listen to opinions of others, how to communicate with others, how to think comprehensively, and even how to compromise with other team members when conflicts occurred
T6	前提	[1088,1191)	All of these skills help them to get on well with other people and will benefit them for the whole life
T7	论点	[1332,1376)	competition makes the society more effective

图 3.1 给出了因素掩码与完整筛选两种审核策略的处理路径，图中“内部／跨边界”描述关系端点相对于改写集合的位置，“正关系／NONE／语义未知”描

述因素的状态。默认的因素掩码策略保留通过审核的组件，仅屏蔽不确定的关系监督；完整筛选策略则只要有一个因素未通过审核，就丢弃整个改写样本。

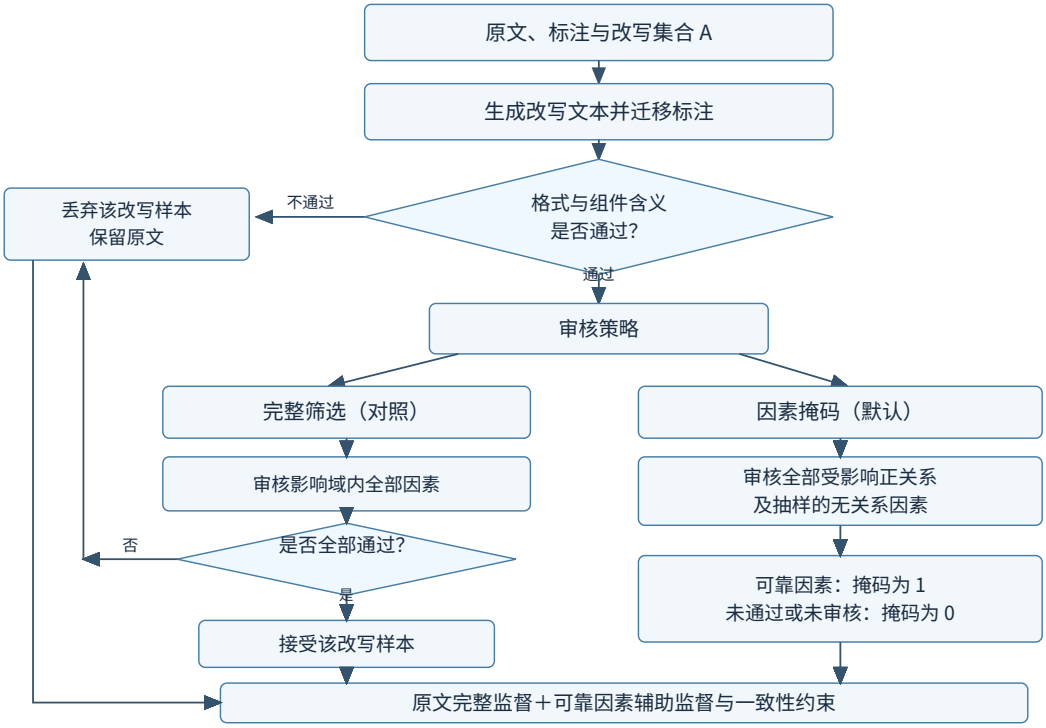


图 3.1 因素掩码与完整筛选两种审核策略

每篇训练文档选定一个改写中心，同一篇文档的所有改写样本均使用该中心。AAEC 优先从论点和主论点中选取，CDCP 优先从政策和价值中选取；为使选择结果确定且可复现，将固定种子 17、语料名、文档 ID、组件 ID 和 center 标记用竖线连接后计算 SHA-256，并按其前 16 位的数值升序选取，若不存在优先类型的组件，则在全部合法组件中按同样顺序选取。

改写集合A由中心组件以及所有指向中心的关系的源组件组成，不再继续向外扩展，其余组件均为只读组件；若中心没有入边，则只改写中心本身。

在生成预算上，每篇文档最多尝试生成四次、最多接受两个改写样本，原始样本始终保留；若槽位相互重叠或输入超过上下文长度上限，则跳过该文档的增强。

关系影响域建立在全部候选关系因素之上。记$\Omega(C)$为所有合法端点组合构成的集合，其中每个关系因素$\omega=(S,v)$由非空源组件集合S和目标组件v组成；AAEC 中$|S|=1$，因此枚举所有合法的有向组件对即可。因素标签y_{ω}表示该端点组合的关系状态，没有标注关系的组合记为 NONE。

对于 CDCP，多前提关系$(\{c_{i_1},\dots,c_{i_k}\},c_j,\ell)$保持原样，其中$\ell\in\{\text{Reason},\text{Evidence}\}$，即关系标签为理由或证据；源组件按原文顺序排列，整条关系作为一个对象处理，不拆分为若干二元关系。

相应地，CDCP 的候选端点组合既包括全部金标关系的端点组合，也包括按源范围规则补充的、最多含三个源组件的组合，源组件超过三个的金标关系同样完整保留。

关系影响域用于刻画一处改写可能波及的关系范围：只要某个因素的端点中有组件被改写，该因素的状态就可能随之改变。设$V(\omega)=S\cup\{v\}$为因素ω的全部端点，则改写集合 A 的完整关系影响域定义为至少有一个端点落在改写集合中的全部因素，即：

$$D_A=\{\omega\in\Omega_{\text{sem}}(C):V(\omega)\cap A\neq\varnothing\},\tag{3-4}$$

其中，$\Omega_{\text{sem}}(C)=\Omega(C)\setminus U_{\text{sem}}$，语义未知集合$U_{\text{sem}}$见 3.3.3 节（AAEC 中为空）；在二元情形下，该定义即为$\{(u,v):u\in A\vee v\in A,(u,v)\in\Omega_{\text{sem}}(C)\}$。全部端点都在$A$中的因素称为内部因素，只有部分端点在$A$中的因素称为跨边界因素。此外，改写还可能通过指代等上下文影响只读组件之间的关系，这部分由 3.5.5 节的人工抽查评估。

3.3.2 改写生成与标注迁移

增强生成器 A 使用不加载任务 LoRA 的 Qwen3.5-9B，采样参数为 temperature=0.7、top-p=0.9[82]，关闭 thinking 模式，每次最多输出 2048 个 token，跨骨干实验也共用其生成的增强文本。生成器的输入包括训练文档全文、可改写的槽位及其类型、只读组件列表以及影响域标签，输出仅为从组件编号到替换文本的 JSON 映射，既不能新增组件，也不能修改类型或关系。

替换槽位文字通常会改变文本长度：改写后，未改写组件在全文中的字符位置也会整体平移，因此需要先建立改写前后的组件对应，再检查原标签是否仍然成立。坐标迁移解决的是组件在新文本中的定位问题，而 3.3.3 节的语义审核解决的是原有监督能否沿用的问题。具体而言，程序按原始字符区间替换槽位文字，然后对整篇文档重新分词，并建立改写前后组件之间的对应关系：

$$\varphi:C\to C',\quad (d,b_c,e_c,t_c)\mapsto(d',b_c',e_c',t_c),\tag{3-5}$$

其中，d′表示改写后的全文，它是同一文档的一个新的文本版本。回填文字后，程序先更新全部组件的字符区间，使只读组件随前文长度的变化而平移，

再重新生成分词与子词表示；因此，φ是组件之间的一一对应，而不是字符或 token 位置之间的对应，所有关系的端点都按φ迁移到新文本上。例如，被改写组件增加一个字符后，位于其后的只读组件在新文本中的起止位置都会后移一个字符，但其文字和标注保持不变。若出现槽位重叠、坐标无法对应或端点无法迁移，则丢弃该改写样本，只保留原始样本。

在此基础上，3.3.3 节介绍如何审核迁移后的标注，3.3.4 节再通过真实文档的案例展示坐标迁移与审核的具体过程。

3.3.3 语义审核与因素掩码

迁移后的改写样本需要依次经过格式检查与语义审核。所有改写样本首先须通过格式检查，包括 JSON 格式、槽位编号、坐标对应和关系端点引用；之后，审核器 V 分别读取原文与改写文本，在看不到原标签的条件下输出组件类型或关系状态，再由程序与原标注进行比较。组件审核同时检查含义、论辩角色、指代、否定和情态，只要有组件含义改变、无法判定或输出不合法，就丢弃该改写样本。

审核器 V 同样使用不加载抽取 LoRA 的 Qwen3.5-9B，关闭 thinking 模式并采用贪心解码，每次最多输出 1024 个 token，跨骨干实验共用 9B 模型生成的同一审核结果。

组件全部通过审核后，再对关系进行审核。关系审核集合$J_A \subseteq D_A$包括全部受影响的正关系，以及从内部 NONE 和跨边界 NONE 中各随机抽取的至多 4 项，CDCP 中被定义为语义未知的真子集不作为 NONE 负例。若无法审核完全部正关系，该样本不参与关系学习，但通过审核的组件仍可用于组件监督；未经审核的 NONE 则不参与监督。

关系掩码的取值同时取决于关系自身及其端点组件的审核结果。只有当审核器认可原标注、改写后状态不变且端点对应有效时，关系掩码才取$m_R(\omega)=1$，若原标签存在分歧、状态改变或无法判定，掩码取 0；组件掩码$m_C(c)$则单独保存。由于文字不变并不能保证论辩角色不变，关系所连接的只读组件同样需要在全文上下文中审核，关系掩码为 1 还要求其所有端点的组件掩码均为 1。满足上述条件的因素称为“可靠因素”，审核质量见 3.5.5 节。

对于掩码为 0 的因素，本章进一步区分两种情况：“待定”指审核过但无法确定原状态是否保持，“未审核”指没有对该因素进行审核，二者的增强侧掩码均为 0，原关系标签保持不变；“语义未知”则属于另一种情况，见下文。

在此基础上，默认策略保留通过审核的组件，既不会因为某一条关系未通过审核就丢弃全部组件，也不会把这条关系改标为 NONE，增强侧的损失只使用掩码为 1 的标签。作为对照，完整筛选策略检查影响域内的全部因素，只要有一个因素改变或待定就丢弃整个样本，3.5 节比较了两种策略的训练效果。

多前提关系需要额外处理。严格评价要求预测关系与金标关系完全一致，例如金标为$h=\langle\{c_1,c_2\},c_3,\text{Reason}\rangle$时，预测$\langle\{c_1\},c_3,\text{Reason}\rangle$因源集合不同而不能匹配；但这并不意味着$c_1$单独与 c3 没有关系，因为$c_1$与$c_2$共同构成理由，并不能由此推出$c_1$单独既不支持也不反对 c3。

因此，本章为训练阶段的关系头定义语义未知集合U_{sem}：对于一条已标注的多前提关系，若其源集合的某个非空真子集没有单独的正关系标注，就将该真子集与目标构成的因素列为语义未知。相应地，可审核的因素集合为$\Omega_{\text{sem}}=\Omega\setminus U_{\text{sem}}$，完整影响域与抽样均在该集合中定义。

无论原文还是改写文本，关系头都不把U_{sem}当作 NONE 负例，其监督掩码与一致性约束掩码均为 0，而原文的完整生成目标仍保留原始的多前提关系。与此不同，第 4 章的评分器判断的是对象是否与标注完全匹配，因此可以把这类真子集作为“不匹配”的负例，但这并不表示其在语义上没有关系。

记通过审核且端点组件也都通过审核的关系集合为R_A，则上述各集合满足如下包含关系：

$$R_A\subseteq J_A\subseteq D_A\subseteq\Omega_{\text{sem}},\quad \Omega_{\text{sem}}=\Omega\setminus U_{\text{sem}}, \tag{3-6}$$

其中，完整影响域D_A是定义范围，J_A是实际审核的范围，只有通过审核的R_A才进入增强侧的关系损失。默认策略下J_A通常小于D_A，完整筛选策略则要求$J_A=D_A$，语义未知集合U_{sem}始终不在两者之中，图 3.1 中的两条路径即对应这一层级关系。

3.3.4 标注迁移与改写案例

本节以 AAEC 训练文档 essay001 为例说明坐标迁移与审核范围。以 T3 为中心时，改写集合为 A={T3,T4,T5,T6}，原文片段见表 3.1。为单独检验坐标迁移是否正确，先进行一项确定性测试，即将四个槽位中的第一个空格改为两个空格、其余字符保持不变，再通过自然改写的例子说明语义审核。

测试结果表明，坐标迁移能够准确跟踪组件位置的变化：四个槽位各增加一个空格后，组件的左闭右开字符区间相应更新，例如 T3 由[591,714)变为

[591,715)，位于槽位之后的只读组件则随之整体平移，T8 和 T2 均平移了 4 个字符。程序核对了全部 11 个组件的文字切片，并按φ迁移了全部原有关系，该样本的审核范围与损失掩码如表 3.2 所示。

表 3.2 essay001 的审核范围与损失掩码

监督对象	检查或覆盖结果	掩码	增强侧用途
11 个组件	规范化空白后逐字一致	m_C=1	组件头；A^+中 4 项参与一致性约束
T4/T5/T6→T3 支持	3 项内部正因素全部检查	m_R=1	正关系监督及一致性约束
抽取的内部 NONE 与边界 NONE	各 4 项，共 8 项	m_R=1	NONE 监督及一致性约束
影响域内其余 57 项	未纳入审核子集	m_R=0	不进入增强关系损失
影响域外 42 项	不在D_A	m_R=0	保留原文监督

在该例中，候选因素共 110 项，其中影响域D_A包含 68 项，实际审核 11 项，其余 57 项未审核；未审核因素的掩码为 0，不参与增强侧的关系损失，但原关系标签保持不变。

作为反例，在上述确定性测试中，若回填程序误把同一文档中 T7 的原文“competition makes the society more effective”填入 T3 的位置，则 T3 新坐标上的切片与预期的替换文本不一致，该样本会在逐字核对中被拒绝。逐字核对只检验回填与坐标是否正确，自然改写后的语义是否保持仍由 3.3.3 节的审核判断。

在此基础上，表 3.3 给出两个自然改写的例子：例 A 改写了 T3、T4、T5 和 T6 四个槽位；例 B 与例 A 相同，只是将 T3 改为否定表达。

表 3.3 essay001 自然改写与语义判断

案例组件	自然改写	语义判断
A / T3	by cooperating, children can acquire interpersonal skills that will be important in their future lives	保留原含义
A / T4	Teamwork teaches us how to pursue a shared goal with others and, more importantly, how to get along with them	保留原含义
A / T5	Cooperating helps children learn to listen to others' opinions, communicate, think comprehensively, and even compromise with teammates when conflicts arise	保留原含义
A / T6	These skills help children get along with others and benefit them throughout their lives	保留原含义
B / T3	cooperation cannot help children acquire interpersonal skills that will be important in their future lives	否定原结论

例 A 保持了原有的论证功能：T3 仍主张合作有助于儿童学习人际交往技能，T4 说明团队协作需要共同目标与相处能力，T5 列举具体技能，T6 说明持续的收益。由于四个组件的含义以及 T4、T5、T6 到 T3 的三条支持关系均未改变，它们都可以参与增强侧监督，掩码取 1；但其余的 NONE 和跨边界因素仍需逐项审核，不能因这三条关系成立就默认通过。

例 B 中的 cannot 把 T3 从“可以学会”变为“不能帮助学会”，否定了原有结论，因此组件审核会丢弃整个样本，只保留原文和其他已接受的样本。与之相对，若组件全部通过审核、只有某条关系改变或无法判定，默认策略仅将该关系的掩码置为 0，其余可靠因素照常使用，也不会把该关系改标为 NONE。

回填自然改写文本后，程序同样核对了全部 11 个组件的切片和 6 条原有关系的端点迁移，在例 A 中，T3 由[591,714)迁移到[591,693)，T4 由[716,851)迁移到[695,804)。

3.4 一致性学习模型与训练

改写样本通过审核后，模型即可利用原文与改写文本中相互对应的可靠因素进行学习。以表 3.1 为例，T4 改写后若通过组件审核，其前提标签即可用于增强侧监督，而 T4→T3 的支持关系和 T4→T7 的 NONE 还需分别通过关系审核。一致性目标比较这些可靠因素在两个视图中的类别分布，允许两侧的词序、长度和位置不同，原始标签则同时为两个视图提供监督，整体学习架构如图 3.2 所示。

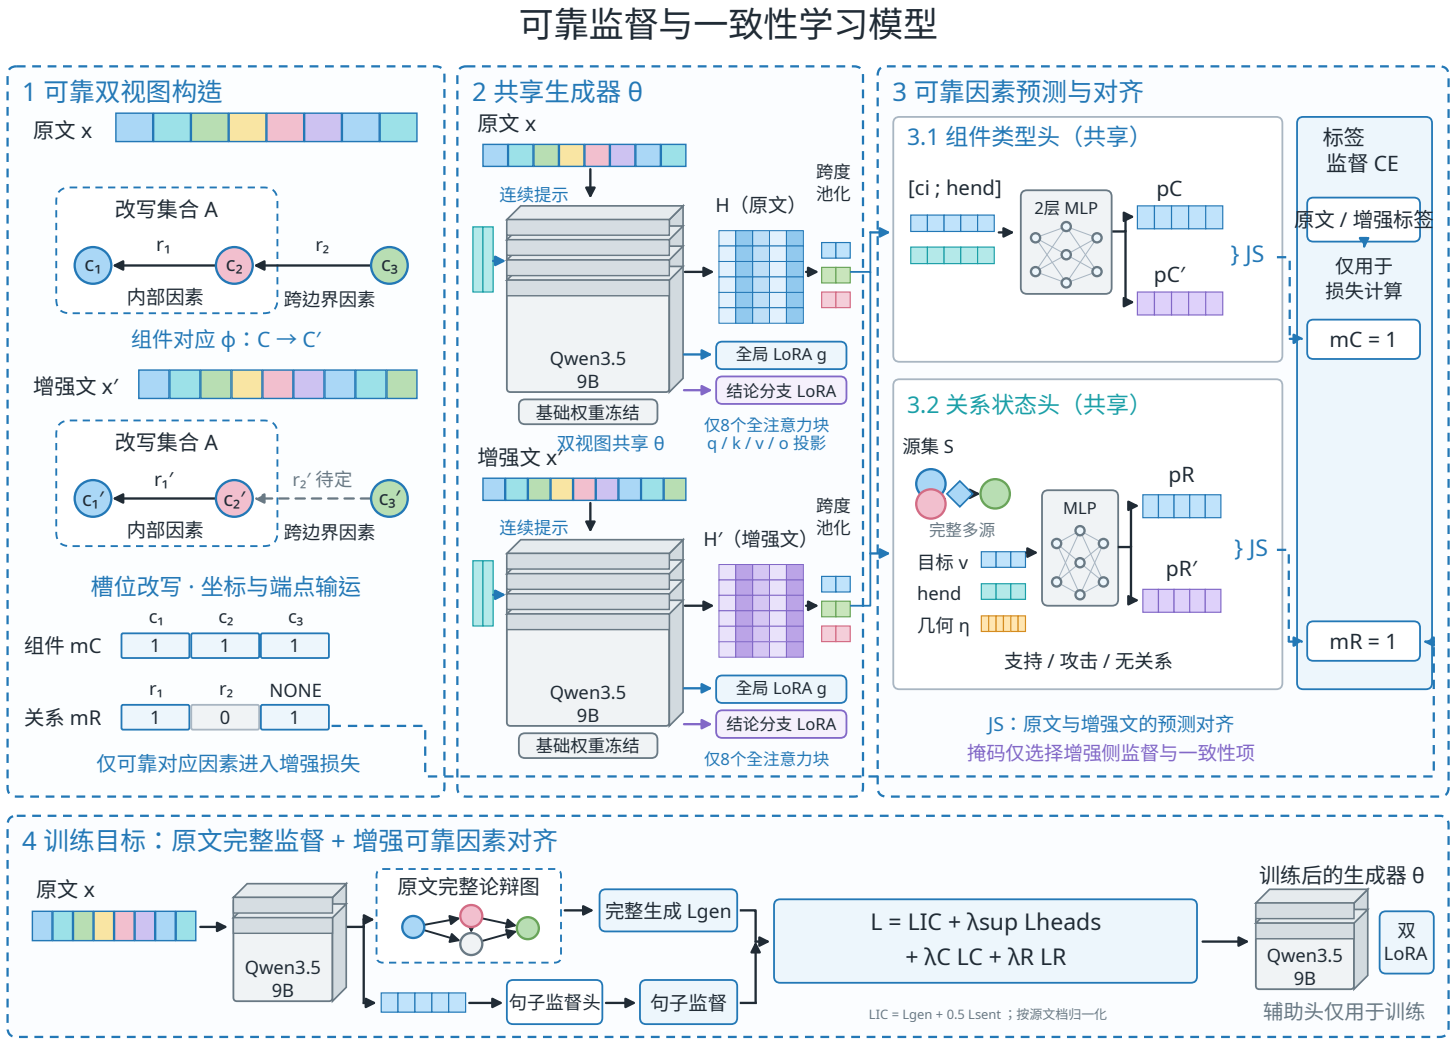


图 3.2 可靠监督与一致性学习模型

图 3.2 中，原文与增强文本经过同一个生成器，组件对应关系φ将两个视图中的组件类型分布与关系状态分布联系起来；生成目标、句子监督与新增的辅助目标共同更新可训练参数，基础模型权重保持冻结，辅助头仅在训练时使用。

3.4.1 辅助预测头与一致性约束

为在因素粒度上施加监督与一致性约束，本章在生成器之上设置组件类型头与关系状态头两个辅助分类器，二者读取生成器对输入文本的隐藏表示，并用金标跨度定位待预测的组件。抽取生成器的输入仅包含任务指令与文本本身，金标的槽位、类型和关系只用于构造训练样本与监督信号，并不作为生成器的输入。

令h_i^x为第 i 个输入子词的隐藏状态，$B_x(c)$为组件 c 的字符跨度所覆盖的子词集合，h_{end}^x为输入结束、回答开始之前位置的隐藏状态，则组件表示与类型分布定义为：

$$u_c^x = \text{MeanPool}_{i \in B_x(c)} h_i^x,\ p_C^x(c) = \text{softmax}\, f_C\left(\left[u_c^x; h_{\text{end}}^x\right]\right), \tag{3-7}$$

其中，MeanPool 表示对组件覆盖的子词表示取均值，方括号表示向量拼接。由于生成器为因果模型，靠前的 token 只能看到左侧的上下文，拼接h_{end}^x可以为组件表示补充全文信息；组件头的输入不包含金标类型。

与组件头输出类型分布不同，关系头输出一组端点之间的关系状态分布，并显式区分源组件与目标组件：

$$p_R^x(S, v) = \text{softmax}\, f_R\left(\left[\text{Pool}\left(\{u_c^x : c \in S\}\right); u_v^x; h_{\text{end}}^x; \eta(S, v)\right]\right), \tag{3-8}$$

其中，f_C、f_R为两层感知机，Pool 对各源组件的表示取均值；η为位置特征，由源组件数与六个位置统计量组成，后者包括源组件起点的最小值与均值、终点的最大值与均值以及目标的起止位置。位置先由字符区间换算为评价 token 坐标，再除以文档的 token 数进行归一化，且不包含待预测的关系标签。二元关系只有一个源组件，多前提关系则以完整的源集合与目标为预测对象，状态中均包含 NONE；两个辅助头在验证和测试时均会移除。

组件一致性约束的范围包括被改写的组件，以及通过正关系与之相连的只读组件，定义为：

$$A^+ = A \cup \bigcup_{\omega \in D_A,\ y_\omega \neq \text{NONE}} V(\omega), \tag{3-9}$$

其中，并集只对影响域中的正关系因素取端点，NONE 因素仅参与关系一致性约束，因而不会把距离较远的组件也纳入组件一致性约束。对于通过组件审核的改写文本x'，下式中的A^{+}还需与$\{c:m_C(c)=1\}$取交集，组件一致性损失定义为：

$$L_C^{\text{align}}(x,x')=\frac{1}{\left|A^{+}\right|}\sum_{c\in A^{+}}\mathrm{JS}\left(p_C^{x}(c),p_C^{x'}(\varphi(c))\right),\tag{3-10}$$

其中，JS 为式（2-7）定义的 Jensen–Shannon 散度，两个视图均保留梯度，共同参与参数更新。类似地，将通过审核的关系因素集合$\{\omega\in J_A:m_R(\omega)=1\}$划分为正关系组$D_{+}$与 NONE 组$D_0$，记非空的组为$B=\{b\in\{+,0\}:\left|D_b\right|>0\}$，关系一致性损失先在组内平均、再在组间平均：

$$L_R^{\text{align}}(x,x')=\frac{1}{|B|}\sum_{b\in B}\frac{1}{\left|D_b\right|}\sum_{\omega\in D_b}\mathrm{JS}\left(p_R^{x}(\omega),p_R^{x'}(\varphi(\omega))\right),\tag{3-11}$$

其中，分组平均可以避免数量较多的 NONE 因素主导关系一致性损失。没有可靠关系时，关系一致性项为 0，但原文全部关系的生成监督不受影响；A^{+}为空时，组件一致性项同样为 0。

仅约束两个视图的预测分布相互接近，并不能保证预测与金标一致：当两个视图产生相同的错误时，JS 散度依然很小。因此，训练目标还需结合因素级监督，分别约束预测的一致性与正确性。对于视图x，记M_C和M_R分别为受监督的组件集合与关系因素集合，M_R^{+}和M_R^{0}分别为其中的正关系与 NONE，$B_M=\{b\in\{+,0\}:\left|M_R^{b}\right|>0\}$，则辅助监督损失定义为：

$$S(x;M_C,M_R)=\frac{1}{\left|M_C\right|}\sum_{c\in M_C}\mathrm{CE}\left(p_C^{x}(c),t_c\right)+\frac{1}{\left|B_M\right|}\sum_{b\in B_M}\frac{1}{\left|M_R^{b}\right|}\sum_{\omega\in M_R^{b}}\mathrm{CE}\left(p_R^{x}(\omega),y_\omega\right),\tag{3-12}$$

其中，CE为交叉熵，t_c为组件的原始类型；$M_C=\varnothing$时组件项为 0，$B_M=\varnothing$时关系项为 0，两项等权相加。原文取$S(x,G)=S\left(x;C,\Omega_{\text{sem}}(C)\right)$，即使用全部组件与可审核的关系因素；改写文本取$S_m\left(x',\varphi(G)\right)=S\left(x';\{\varphi(c):m_C(c)=1\},\{\varphi(\omega):\omega\in J_A,m_R(\omega)=1\}\right)$，即仅使用掩码为 1 的组件与关系。由此，一致性约束与原始标注的监督相互配合，使模型在两个视图上的预测既保持一致又接近正确标签。

3.4.2 损失归一化与参数更新

为避免改写样本数量不同的源文档在训练中获得不均衡的权重，本章按源文档对各项损失进行归一化。设源文档d有m_d个被接受的改写样本，原文承担

完整的论辩图生成监督与句子监督；改写文本则只作为输入，由于其中可能含有未审核的关系，不将其完整论辩图作为生成目标。辅助监督损失定义为：

$$L_{\text{heads},d}^{\text{sup}}=\frac{S\left(x_d,G_d\right)+\sum_{j=1}^{m_d}S_{m_j}\left(x'_{dj},\varphi_j\left(G_d\right)\right)}{1+m_d}. \tag{3-13}$$

一致性项先在每个非空因素组内平均，再在同一源文档的各改写样本之间平均，总损失定义为：

$$L_d=L_{\text{IC}}\left(x_d,G_d\right)+\lambda_{\text{sup}}L_{\text{heads},d}^{\text{sup}}+\lambda_C\acute{L}_{C,d}^{\text{align}}+\lambda_R\acute{L}_{R,d}^{\text{align}}, \tag{3-14}$$

其中，默认取$\lambda_{\text{sup}}=1$、$\lambda_C=\lambda_R=0.5$。没有改写样本时只保留原文的各项损失；有改写样本但没有可靠关系时，关系一致性项为 0，组件学习照常进行。由于被接受样本中的改写组件都已通过审核，m_C均为 1，计入m_d的样本不会出现空的组件项。此外，每个批次内按源文档取平均，以避免改写样本较多的文档获得过高权重。

以 3.3.4 节的例子说明上述归一化过程：一个被接受的改写样本使$m_d=1$，原文与改写文本的辅助监督各占 1/2；A^+={T3,T4,T5,T6}，组件一致性项对这 4 个组件取平均；关系一致性项中有 3 项正关系和 8 项 NONE，分组平均后，在λ_R=0.5 时每项正关系与每项 NONE 的最终权重分别为 1/12 和 1/32。

按$1+m_d$取平均使每篇源文档的辅助监督总权重固定，原文在其中的占比为$1/\left(1+m_d\right)$，而原文的生成损失L_{IC}保持不变。若不加控制，完整筛选与因素掩码接受的样本数量通常不同，二者的比较会包含原文占比的差异；3.5 节将各增强配置的接受样本数匹配为相同规模，但二者保留的可靠因素数量仍可能不同；一致性学习的消融则固定了样本与掩码，不受此影响。

在参数更新上，生成损失与句子损失更新原有模块，组件头、关系头与一致性项通过共享的输入表示更新全局 LoRA，结论分支只随相应的生成路径更新；基础权重保持冻结，辅助头在评价时移除。第 4 章的推理评分器另行训练，不使用这些辅助头的输出概率。

3.4.3 算法流程与性质分析

算法 3-1 概括了本章方法的主要步骤，包括增强构造与参数学习两个阶段：先在固定预算内生成并筛选改写样本，再按源文档归一化进行训练。两个阶段都只使用训练集，验证集仅用于参数选择和早停。

算法 3-1 可靠监督与一致性学习

输入：训练文档及其标注D_{train}，增强生成器 A、自动审核器 V；

尝试上限B_{try}、接受上限B_{accept}、更新上限 U，mode∈{FactorMask, FullFilter}。

输出：训练后的生成器θ、增强样本及组件对应关系。

01 、。

02 按 3.3.1。

03 排除语义未知因素，构造Ω_{sem}、改写集合 A 及完整影响域D_A。

04 在B_{try}次尝试和B_{accept}个接受样本的上限内，重复步骤 05—08。

05 生成并回填替换文本，重新分词，建立全部组件的双射φ。

06 格式、槽位、坐标或端点检查失败，或组件含义、论辩角色改变或无法判定时，拒绝样本。

07 对非空D_A，FullFilter 审核全部因素，无法全部审核或任一项未通过则拒绝；FactorMask 审核全部受影响正关系及抽样的内部、跨边界 NONE，得到m_R。

08 保存改写文本、迁移标注、φ及因素掩码；无接受样本时仅使用原文。

09 构造完成后按源文档采样训练批次，重复步骤 10—12，直至达到 U。

10 、。

11 按φ计算可靠因素的一致性损失，无可靠因素时该项为 0；各项损失按改写样本和源文档两级归一化。

12 冻结基础模型权重，反向传播并更新 LoRA 与辅助头参数。

13。

性质一（标注迁移保持结构）。若改写槽位互不重叠、φ是组件之间的双射，且组件类型与每条完整关系都按φ迁移，则G与$\varphi(G)$具有相同的组件数、组件类型以及带方向和标签的关系结构。证明：双射保证每个原组件恰好对应一个新组件，而关系的全部端点逐一映射，因此关系既不会增加也不会丢失，利用逆映射即可恢复原图。该性质仅保证标注结构不变，改写后的文本是否仍然支持这些标签，需由 3.3.3 节的语义审核判断。

性质二（单因素预测稳定的充分条件）。对某一因素，设原视图中的正确类别为y，预测分布p的间隔为$\gamma = p_y - \max_{k \neq y} p_k > 0$。若增强视图的分布$q$满足$\| p - q \|_\infty < \gamma / 2$，则$\arg\max q = y$。证明：对任意$k \neq y$，都有$q_y - q_k > p_y - p_k - \gamma \geq 0$。该性质表明，只要两个视图的预测分布足够接近，增强视图就能保持原视图的正确预测，这正是一致性约束的出发点。进一步地，由 Pinsker 不等式可得$\|p-q\|_\infty \leq \sqrt{(2 \cdot \mathrm{JS}(p,q))}$，因此当$\mathrm{JS}(p,q) < \gamma^2/8$时上述条件必然成立，这将式（2-7）定义的一致性目标与单因素预测稳定性直接联系起来；该性质只说明一致性约束的作用方向，并不保证原视图本身预测正确。

综上，性质一保证了标注迁移不破坏论辩结构，性质二说明了一致性约束为何有助于预测稳定，3.5 节将通过实验检验上述设计在完整论辩图抽取上的效果。

3.5 实验与分析

为验证本章所提方法的有效性，本节在两个公开的论辩挖掘语料上开展对照实验，主要回答以下三个问题：（1）本章的训练方法能否提升端到端论辩挖掘的抽取性能；（2）在增强数据相同的条件下，一致性目标本身能带来多少增益；（3）增强数据的审核质量与训练成本如何，训练增益在不同骨干模型上是否稳定。围绕上述问题，本节依次介绍数据集与评价指标、对照方法和实验设置，进而给出主要结果与消融分析、增强数据的人工审核结果以及训练成本与跨骨干表现。

3.5.1 数据集与评价指标

本章在两个广泛使用的论辩挖掘语料上开展实验，包括论辩标注作文语料（Argument Annotated Essays Corpus，AAEC）[2]与消费者债务催收实践评论语料（Consumer Debt Collection Practices，CDCP）[12,26]。AAEC 由英文议论文构成，CDCP 则来自公共政策规则制定中的用户评论，并包含多个前提共同指向同一目标的多前提关系。在数据划分方面，AAEC 采用官方发布的 train-test-split.csv 划分，CDCP 采用原始数据包中的 train/test 目录，重复文档仅在训练集中去除，测试文档全部保留，两个语料的规模统计如表 3.4 所示。

表 3.4 数据规模与官方划分

语料	划分	原始文档	保留文档	组件	完整关系	多源关系	最大源数
AAEC	训练	322	319	4793	3006	0	1
AAEC	测试	80	80	1266	809	0	1
CDCP	训练	581	580	3901	969	85	8
CDCP	测试	150	150	1026	252	34	10

训练集按全文哈希去重：AAEC 中 essay171、210 与 400 内容相同，保留 essay171，essay209 与 377 内容相同，保留 essay209；CDCP 中保留 00410，去除与其正文重复且标注不完整的 00411。经去重后，训练集与测试集之间不存在重复文档。

对于评价指标，采用严格匹配下的组件 F1 与关系 F1 评估端到端抽取性能，并以严格关系 F1 为主要指标，边界 F1、给定金标组件时的关系分类等指标仅用于辅助分析误差来源。评价时，组件匹配要求字符区间与类型均与金标完全一致，关系匹配还要求完整的源集合、目标、方向和标签均一致，CDCP 中的多前提关系作为一个整体计数，不拆分为二元边。在此基础上，分别对组件和关系统计真正例 TP、假正例 FP 与假负例 FN，精确率、召回率与 F1 的计算方式如下：

$$\text{Precision}=\frac{\text{TP}}{\text{TP}+\text{FP}},\quad \text{Recall}=\frac{\text{TP}}{\text{TP}+\text{FN}},\quad F_1=\frac{2\,\text{TP}}{2\,\text{TP}+\text{FP}+\text{FN}},\quad (3\text{-}15)$$

其中，TP、FP 与 FN 均先在全部测试文档上汇总，再代入式（3-15）计算，即本文报告的 F1 均为 micro-F1。匹配时每个预测对象与金标对象最多使用一次，重复预测计为 FP；解析失败或结构校验失败的文档仍保留在评价集中并按空预测处理，其金标对象全部计为 FN。所有分数均以百分制报告，方法之间的提升幅度均为 F1 的绝对差值，以百分点表示，第 4 章沿用本节相同的数据划分与评价口径。

3.5.2 对照方法

为全面评估本章方法的有效性，并区分数据构造方式与学习目标各自的作用，本节按表 3.5 设置九组训练对照，主要包括以下四类。

（1）基线配置。以 MCR-BR 训练配置（记为 T0）为基线，推理采用 MCR-BR 的推理流程（重排序、合法化与 BR-O，记为 I0），该组合记为 T0I0；在其基础上仅在原文上增加辅助预测头监督、不使用增强数据的配置记为 Heads，用于区分辅助头本身带来的影响。

（2）增强构造对照。普通改写增强（Plain）与槽位化增强（QOS）按各自的构造规则产生增强样本，二者仅与本章方法匹配接受样本的规模，用于考察可靠监督构造本身的作用。

（3）学习目标对照。去掉一致性项（NoPair）只使用可靠因素监督而不施加一致性约束，仅组件一致性（CompPair）只在组件上施加一致性约束，本章完整训练配置（记为 T1，在 I0 推理下记为 T1I0）则同时约束组件与关系；三者使用完全相同的改写样本、因素掩码与辅助头，仅在学习目标上不同，因而其差值能够直接反映一致性目标的作用。

（4）筛选策略与改写中心对照。完整影响域筛选（FullFilter）在任一因素未通过审核时丢弃整个改写样本，随机中心（RandomCenter）则随机选择改写中心，二者作为可独立选择的策略与默认设置进行比较。

为保证比较的公平性，九组对照使用相同的骨干、源文档访问次数和更新步数，推理均采用 I0，各增强组的接受样本规模相同（AAEC 500 个，CDCP 900 个），成本统计同时计入生成失败、被拒样本与审核的开销。在此基础上，比较学习目标时固定增强文本、因素掩码和辅助头，比较数据构造方式时则保持接受样本规模与训练预算相同；推理侧修正策略的对照属于第 4 章，见 4.6.1 节。

表 3.5 训练对照组的设置

配置	增强	可靠因素监督	组件一致性	关系一致性	与完整一致性学习配置输入相同
T0I0	无	无	无	无	—
Heads	无	原文	无	无	—
Plain／QOS	有	构造方法各自规则	无	无	仅匹配规模
NoPair	有	有	无	无	是
CompPair	有	有	有	无	是
T1I0	有	有	有	有	是
FullFilter／RandomCenter	有	有	有	有	独立可选策略

3.5.3 实验环境与参数设置

在模型选择方面，本章以 Qwen3.5-9B[80]为主骨干模型，MCR-BR 基线（T0）、本章训练配置（T1）以及外部对照方法均在该骨干上重新训练，完整的消融与错误分析也均基于 9B 模型；此外，使用 Qwen3.5-4B[83]考察较小骨干上的表现，并使用 Qwen2.5-7B-Instruct[84,85]与基础方法 MCR-BR 的原始设置衔接[56]。两种补充骨干复用 9B 模型生成并审核的增强数据，抽取器、评分器等模块则在各骨干上独立训练，各模型的具体版本如表 3.6 所示。

表 3.6 模型版本

模型	修订版本（revision）	用途
Qwen/Qwen3.5-9B	21eca8a083a2121a92fba681f4a7c72cf20ff1a7	主实验及共享的增强器 A 与审核器 V
Qwen/Qwen3.5-4B	1eef1f4e0bc57dec8f814d1e4c714c8e0065d261	共享增强下的四种配置补充实验
Qwen/Qwen2.5-7B-Instruct	a306ca65c69cb09b9ce8ae8396fd529d509d872e	共享增强下的四种配置补充实验

在训练与评价配置方面，主实验统一使用相同的训练预算、候选协议和评价器，训练种子取 17、29 和 43；多候选由 1 路贪心解码与 2 路采样解码组成，模型可自由决定预测对象的数量，不按测试集金标数量截断或补齐。实验仅使用文本输入，关闭模型的 thinking 模式，不使用视觉模块与长上下文扩展，具体的硬件环境与训练配置如表 3.7 所示。

表 3.7 实验环境与训练配置

项目	取值
骨干	Qwen/Qwen3.5-9B；后训练版本；文本路径；关闭 thinking
LoRA	8 个全注意力块 q/k/v/o；全局及结论各$r=16$，$\alpha=32$，dropout=0.05
优化器	AdamW[86]；LoRA 学习率 2×10^{-4}；权重衰减 0.01；β=(0.9,0.999)；$\varepsilon_{\text{Adam}}=10^{-8}$；预热比例 0.03
学习预算	5 轮；2 GPU×每卡 1 个源文档×梯度累积 16 步＝批大小 32；末批按有效源文档归一化
精度与分片	BF16；FSDP 全分片[87]；梯度检查点；梯度裁剪 1；基础与视觉权重冻结
上下文	模型配置上限 8192；单次输入≤4096，输出≤2048；不使用 YaRN[88]
生成	1 路贪心＋2 路采样；temperature=0.7，top-p=0.9；相同规范序列化
种子	17，29，43；相同官方测试文档
硬件	2×A100 80 GB；128 GiB RAM；4 CPU 线程；推理张量并行度 2
成本单位	GPU 小时=设备数×墙钟小时；显存为单卡最大峰值

在适配参数方面，9B 骨干的 Q 投影包含输出门控，维度为 4096→8192，K 与 V 投影为 4096→1024，O 投影为 4096→4096。全局与结论两条 LoRA 分支均取$r=16$、$\alpha=32$和 dropout=0.05，每条分支含 3,932,160 个参数，合计 7,864,320 个，与单条秩为 32 的分支参数量相同；其余 24 个线性注意力块、前馈层和视觉编码器均保持冻结。

系统中的模块按职责可分为抽取、增强、审核、评分与提案五类，其中与本章训练相关的抽取生成器 G、增强生成器 A 和语义审核器 V 如表 3.8 所示，对象评分器 S 与源组提案器 P 服务于第 4 章的联合修正，其配置见 4.6.1 节；训练阶段辅助预测头的结构与各项损失系数如表 3.9 所示。

表 3.8 抽取、增强与审核模块

模块	实现方式	输出与用途
G 抽取生成器	Qwen3.5-9B＋双 LoRA；基础权重冻结；5 轮	原生组件及完整关系 JSON；I0/T0/T1
A 增强生成器	Qwen3.5-9B 官方权重，不加载任务 LoRA；训练时可见标注	槽位替换 JSON；仅构造训练视图
V 语义审核器	同基础模型、独立上下文；待审标签隐藏；贪心输出	组件/关系状态或待定；决定监督掩码

表 3.9 训练阶段的辅助头与损失配置

项目	设置
辅助头	组件 8192→1024→3/5 类；关系 12295→1024→3 状态；GELU[89]，dropout 0.1
损失系数	原文生成 1；句子 0.5；辅助监督 1；组件与关系一致性项各 0.5；增强视图不作整图生成目标
软件	Python 3.11；PyTorch 2.7.1[90]；Transformers 5.8.0[81]；PEFT 0.17.1[91]；HiGHS[92]参考求解固定 CPU 预算

在统计方法方面，所有结果均按语料、文档、训练种子和方法逐文档记录，同一配置在不同章节中出现时引用同一份记录，因此各章表格中相同方法的数值保持一致。对于每个训练种子，先汇总全部测试文档的计数并计算 micro-F1，再报告三个种子的均值与样本标准差；配对比较要求各方法使用相同的文档和种子，且金标对象总数TP + FN保持一致。

显著性检验采用文档与种子的联合 bootstrap 重采样[61]，共重采样 2000 次：每次有放回地抽取 3 个种子，并抽取与测试集规模相同的文档，所有方法共用同一组抽样结果；每次抽样后重新汇总计数并计算方法间的 F1 差值，由此得到差值的经验分布。

设观测差值为$\hat{\Delta}$，第b次重采样的差值为Δ_b^*，重采样次数为B，95%置信区间取重采样分布的 2.5%与 97.5%分位数，双侧检验的 p 值计算方式如下：

$$p=\frac{1+\sum_{b=1}^{B}\mathrm{I}\left(|\Delta_b^{*}-\hat{\Delta}|\geq|\hat{\Delta}|\right)}{B+1}, \tag{3-16}$$

其中，$I(\cdot)$为指示函数，条件成立时取 1，否则取 0。

主要比较共 7 组，每组在两个语料上分别检验，共 14 项。这些比较依次考察训练配置（T1I0 与 T0I0）、一致性目标（T1I0 与 NoPair）、推理配置（T1I1 与 T1I0）、组件修改范围（T1I1 与 RelationOnly）、共同接受（Single 与 Sequential）、与重新生成的对比（T1I1 与 Regenerate）以及严格改进阈值的放宽（T1I1 与 NoRisk）；其中后五组属于第 4 章，I1 表示在 I0 上追加第 4 章联合修正的推理流程。14 项 p 值统一采用 Holm 方法[62]进行多重比较校正，各章的主要比较结果（表 3.11、表 4.9 和表 4.17）使用相同的逐文档记录与重采样索引，相应的复现材料说明如下。

为便于复现，配套材料包括逐文档的计数、预测图、固定的候选与评分、事务记录（含 4.4.3 节示例事务的复算脚本）、源组提案记录、审核记录以及分阶段的成本记录。统计检验使用 NumPy[93]的 PCG64 随机数生成器，AAEC 与 CDCP 的抽样种子分别为 72026 和 72027，所有方法共用 2000 次重采样索引；14 项主要比较统一进行 Holm 校正，跨骨干的 12 项补充比较单独校正，ThresholdFilter 与外部系统的比较则作为探索性结果报告。

3.5.4 主要结果与消融分析

表 3.10 给出了不同训练配置在 I0 推理下的抽取性能。结果表明，本章训练方法在两个语料上均显著提升了严格关系 F1。在相同的 9B 骨干下，T0I0 在 AAEC 和 CDCP 上的严格关系 F1 分别为 65.69 和 41.79，T1I0 分别达到 68.25 和 45.08，即相对同骨干的 MCR-BR 基线分别提高 2.56 和 3.30 个百分点；Holm 校正后的 p 值分别为 0.0175 和 0.0150，且三个种子上的提升均为正。与此同时，组件 F1 也由 85.64 和 80.40 提高到 87.85 和 83.46。

表 3.10 不同训练配置的抽取性能（推理均为 I0）

配置	AAEC 组件 F1	AAEC 关系 F1	CDCP 组件 F1	CDCP 关系 F1
T0I0：MCR-BR 基线	85.64 ± 0.07	65.69 ± 3.50	80.40 ± 1.24	41.79 ± 2.65
Heads：基线＋辅助头	85.75 ± 0.24	66.01 ± 3.37	80.76 ± 1.10	41.81 ± 3.01
Plain：普通增强	86.09 ± 0.28	65.95 ± 2.24	81.03 ± 1.14	41.57 ± 3.30
QOS：QOS 式适配	86.43 ± 0.21	66.65 ± 3.09	81.35 ± 1.49	42.54 ± 3.35
NoPair：可靠监督，无一致性项	86.67 ± 0.21	66.85 ± 2.73	81.85 ± 1.26	42.51 ± 2.89
CompPair：仅组件一致性	87.19 ± 0.20	67.70 ± 3.13	82.50 ± 1.15	43.21 ± 3.46
T1I0：完整一致性学习	87.85 ± 0.39	68.25 ± 2.08	83.46 ± 1.04	45.08 ± 2.73
FullFilter：完整筛选	87.61 ± 0.44	68.21 ± 2.71	83.16 ± 1.06	45.08 ± 3.02
RandomCenter：匹配随机中心	87.24 ± 0.12	67.74 ± 2.96	83.00 ± 0.83	44.49 ± 3.52

在改写样本、因素掩码与辅助头均相同的条件下，T1I0 与 NoPair 的差值反映了一致性目标本身的作用。如表 3.11 所示，一致性目标在 AAEC 上带来 1.39 个百分点的提升（95%置信区间[0.28, 2.46]，Holm p=0.0175）；在 CDCP 上带来 2.57 个百分点的提升（95%置信区间[1.05, 4.23]，Holm p=0.0175），且三个种子的差值均为正，CDCP 上的增益更大。由于这组对照固定了数据构造，上述增益可以归因于一致性目标，而非样本数量或掩码的变化。从逐项加入的探索性比较来看，仅组件一致性相对 NoPair 分别提高 0.84 和 0.69 个百分点，在此基础上加入关系一致性后又提高 0.55 和 1.88 个百分点，其中 CDCP 上后一项的未校正 p 值为 0.0175，说明关系一致性项在 CDCP 上的作用更为突出。

表 3.11 训练配置之间的关系 F1 配对差值

语料	比较	差值（百分点）	单项 95%置信区间	种子 17 / 29 / 43	p	类型
AAEC	T1I0 − T0I0	2.56	[0.92, 4.39]	1.26 / 2.34 / 4.07	0.0175	主要／Holm
AAEC	T1I0 − NoPair	1.39	[0.28, 2.46]	1.02 / 0.99 / 2.17	0.0175	主要／Holm
AAEC	CompPair − NoPair	0.84	[0.04, 1.90]	0.79 / 1.43 / 0.31	0.0770	探索／原始 p
AAEC	T1I0 − CompPair	0.55	[-0.78, 1.90]	0.24 / -0.44 / 1.86	0.4018	探索／原始 p
AAEC	NoPair − QOS	0.20	[-0.40, 0.89]	-0.12 / 0.12 / 0.59	0.4993	探索／原始 p
AAEC	NoPair − Plain	0.90	[0.06, 1.75]	1.30 / 1.04 / 0.36	0.0415	探索／原始 p
AAEC	FullFilter − T1I0	-0.04	[-0.86, 0.60]	0.35 / 0.32 / -0.79	0.9015	探索／原始 p
AAEC	RandomCenter − T1I0	-0.51	[-1.71, 0.74]	-0.35 / 0.44 / -1.62	0.3838	探索／原始 p
CDCP	T1I0 − T0I0	3.30	[1.56, 5.17]	2.81 / 3.50 / 3.58	0.0150	主要／Holm
CDCP	T1I0 − NoPair	2.57	[1.05, 4.23]	3.25 / 2.34 / 2.12	0.0175	主要／Holm
CDCP	CompPair − NoPair	0.69	[0.00, 1.96]	0.74 / 1.34 / 0.00	0.1584	探索／原始 p
CDCP	T1I0 − CompPair	1.88	[0.54, 3.56]	2.51 / 1.00 / 2.12	0.0175	探索／原始 p
CDCP	NoPair − QOS	-0.03	[-1.47, 1.99]	-0.74 / -0.44 / 1.10	0.9645	探索／原始 p
CDCP	NoPair − Plain	0.94	[-0.49, 2.98]	0.00 / 0.64 / 2.19	0.2359	探索／原始 p
CDCP	FullFilter − T1I0	-0.00	[-0.85, 0.94]	-0.37 / 0.36 / 0.00	0.9885	探索／原始 p
CDCP	RandomCenter − T1I0	-0.59	[-1.86, 0.40]	-1.40 / 0.36 / -0.73	0.3118	探索／原始 p

其余对照的结果同样列于表 3.11。在数据构造方面，可靠监督构造（NoPair）相对普通增强（Plain）在 AAEC 上提高 0.90 个百分点（未校正 p=0.0415），相对槽位化增强（QOS）的差值则仅为 0.20 和−0.03 个百分点，且

均不显著，即在不施加一致性约束时，可靠因素构造与 QOS 式继承原标注在关系 F1 上没有可区分的差异；审核的作用主要体现在降低增强监督中的错误（见 3.5.5 节），并为一致性约束提供可靠的对应因素。在样本筛选方面，完整筛选与默认因素掩码在两个语料上的差值分别为−0.04 和 0.00 个百分点，说明丢弃整个改写样本并不优于仅屏蔽不可靠的关系监督；后者在设计上保留了更多可用监督，但本文未单独统计二者的监督覆盖与成本差异。在改写中心方面，随机选择中心在两个语料上均略低于固定中心，但差异并不显著。

3.5.5 增强数据的人工审核

为独立评估增强监督的质量，本节在自动审核器 V 之外另设人工分层审核，由两名审核员 A、B 与一名裁决人 C 完成；由于增强器与自动审核器使用同一基础模型，二者可能具有相关偏差，人工审核因而作为独立参照。A 与 B 分别将每个因素判为状态保持（stable）、状态改变（changed）、无法判定（undecided）或不认同原标注（original_disagreement），C 先独立判断，再给出最终结论；三人先以 60 项培训材料统一标准，培训阶段的一致性κ为 0.86。在抽样方面，组件审核同时覆盖被接受与被拒绝的样本，关系审核则从训练增强池中分四层抽样，每层最多 300 项，不足 300 项时全部审核，抽样概率为$\pi_h = n_h/N_h$。

在统计口径方面，比例的置信区间采用 Wilson 区间[94]，审核员之间的一致性采用 Cohen κ系数[95]衡量。不安全率以被接受的因素为分母，漂移率以可以判定且原标注有效的因素为分母，无法判定与不认同原标注两类均不计为状态保持；计算时按 $1/\pi_h$加权，并以源文档为单位重采样 2000 次估计置信区间。组件审核与关系因素分层审核的结果分别如表 3.12 和表 3.13 所示。

表 3.12 组件审核结果

语料	抽样	接受	不安全接受	不安全接受率	Wilson 95%	一致率	κ
AAEC	320	300	4	1.33%	[0.52, 3.38]	94.69%	0.690
CDCP	320	300	3	1.00%	[0.34, 2.90]	95.94%	0.755

表 3.13 关系因素的分层人工审核

语料／层	N_h	抽样 n	π	接受数	不安全接受数	不安全接受率	Wilson 95%	一致率	κ
AAEC／内部正关系	683	300	0.4392	280	3	1.07%	[0.37, 3.10]	96.00%	0.771
AAEC／跨边界正关系	153	153	1.0000	123	2	1.63%	[0.45, 5.74]	92.16%	0.804
AAEC／内部 NONE	877	300	0.3421	279	4	1.43%	[0.56, 3.63]	90.67%	0.591
AAEC／跨边界 NONE	2000	300	0.1500	266	1	0.38%	[0.07, 2.10]	94.67%	0.785
CDCP／内部正关系	315	300	0.9524	282	2	0.71%	[0.19, 2.55]	93.00%	0.606
CDCP／跨边界正关系	290	290	1.0000	249	4	1.61%	[0.63, 4.06]	94.14%	0.811
CDCP／内部 NONE	470	300	0.6383	277	5	1.81%	[0.77, 4.16]	93.00%	0.697
CDCP／跨边界 NONE	3251	300	0.0923	269	2	0.74%	[0.20, 2.67]	94.33%	0.776

表 3.12 与表 3.13 的结果表明，审核后被接受的组件与关系中仅残留少量不安全监督：两个语料的组件不安全接受率分别为 1.33%和 1.00%，各关系层的不安全接受率介于 0.38%与 1.81%之间。由于同一篇源文档可以贡献多个样本和因素，记录之间并不独立，表 3.14 进一步给出了各层的源文档数以及按源文档聚类重采样得到的置信区间。

表 3.14 各审核层的源文档数与聚类置信区间

语料／层	审核因素	源组	π	不安全率	源聚类 95%	总体覆盖
AAEC／内部正关系	300	136	0.4392	1.07%	[0.00, 2.40]	抽样
AAEC／跨边界正关系	153	61	1.0000	1.63%	[0.00, 4.31]	全层
AAEC／内部 NONE	300	129	0.3421	1.43%	[0.34, 2.96]	抽样
AAEC／跨边界 NONE	300	201	0.1500	0.38%	[0.00, 1.18]	抽样
CDCP／内部正关系	300	163	0.9524	0.71%	[0.00, 1.85]	抽样
CDCP／跨边界正关系	290	160	1.0000	1.61%	[0.38, 3.31]	全层
CDCP／内部 NONE	300	133	0.6383	1.81%	[0.37, 3.57]	抽样
CDCP／跨边界 NONE	300	229	0.0923	0.74%	[0.00, 1.87]	抽样

跨边界关系需要单独检查，因为即使组件文字变化不大，也可能改变其与只读组件之间的联系。AAEC 的跨边界正关系层共 153 项，已全部审核，在被接受的 123 项中有 2 项不安全，说明审核后仍存在少量残留错误。

如表 3.15 所示，两个语料的加权漂移率分别为 5.83%和 5.98%，即约 6%的因素在改写后状态发生了变化，说明直接沿用全部原标签确实会引入错误监督；对审核后被接受的关系因素，加权不安全率估计分别为 0.81%和 0.91%。后一项估计以接受集为分母，与总体漂移率的统计对象不同。

表 3.15 增强数据的加权不安全率与漂移率

语料	审核因素／源组	未加权不安全率	加权不安全率	源聚类 95%	加权漂移率	漂移 95%	变化／可判定且原标注有效
AAEC	1053／257	1.05%	0.81%	[0.31, 1.45]	5.83%	[4.19, 7.60]	60／998
CDCP	1190／401	1.21%	0.91%	[0.26, 1.79]	5.98%	[4.06, 8.10]	68／1132

除影响域内的因素外，改写还可能通过指代等上下文影响只读组件之间的关系。为此，本节单独抽查了两端均为只读组件的关系，以检查改写是否影响到关系影响域之外的关系，这部分样本独立于表 3.13 的四层审核，也不影响默认的增强监督。如表 3.16 所示，两个语料各抽查 160 项，均发现 2 项变化，比例为 1.25%（Wilson 95%区间[0.34, 4.44]）。

表 3.16 两端均为只读组件的关系抽查

语料	域外候选总体	抽样	发现变化	比例	Wilson 95%
AAEC	3870	160	2	1.25%	[0.34, 4.44]
CDCP	915	160	2	1.25%	[0.34, 4.44]

3.5.6 训练成本与跨骨干表现

本章方法的训练增益伴随一定的额外计算成本。如表 3.17 所示，T0I0 在 AAEC 和 CDCP 上的平均训练时间分别为 2.45 和 4.15 GPU 小时，T1I0 分别为 5.12 和 8.67 GPU 小时，即分别增加 2.67 和 4.52 GPU 小时，换来 2.56 和 3.30 个百分点的关系 F1 提升。表中 GPU 小时为两张 GPU 的耗时之和，显存为单卡峰值，各骨干的可训练参数量见表 4.23。

表 3.17 训练与增强成本（三个种子的 GPU 时间均值）

语料	配置	源文档访问数	更新步	接受改写样本数	尝试／接受生成 token 数（百万）	审核调用	GPU 小时	峰值 GiB
AAEC	T0I0	1595	50	0	0.00／0.00	0	2.45	27.65
AAEC	Heads	1595	50	0	0.00／0.00	0	2.80	29.76
AAEC	NoPair	1595	50	500	1.14／0.82	1210	4.50	35.19
AAEC	CompPair	1595	50	500	1.14／0.82	1210	4.72	36.77
AAEC	T1I0	1595	50	500	1.14／0.82	1210	5.12	36.42
CDCP	T0I0	2900	95	0	0.00／0.00	0	4.15	27.79
CDCP	Heads	2900	95	0	0.00／0.00	0	4.95	29.40
CDCP	NoPair	2900	95	900	2.02／1.35	2190	7.72	35.21
CDCP	CompPair	2900	95	900	2.02／1.35	2190	8.25	36.48
CDCP	T1I0	2900	95	900	2.02／1.35	2190	8.67	36.80

除表 3.17 中的逐配置训练成本外，表 3.18 进一步汇总了 9B 主配置的一次性运行成本，包括 54 次最终训练、36 次 OOF 训练、12 个评分头和 6 个提案头，GPU 小时按设备数乘以实际耗时计算，其中 OOF 训练、评分头与提案头的成本对应第 4 章的联合修正。4B 和 2.5-7B 的补充实验另有 24 次最终训练、72 次 OOF 训练、24 个评分头和 12 个提案头，各骨干共用同一批增强数据；全局求解在不同规模下的耗时测试见 4.5.4 节。

表 3.18 一次性运行成本（GPU 小时）

语料	最终训练（27 运行）	OOF（18 运行）	评分头（6 运行）	跨度/源组提案（3 运行）
AAEC	120.49	44.69	2.38	0.96
CDCP	206.83	77.81	3.85	1.62

为考察训练增益对骨干模型的依赖程度，本节在 Qwen3.5-4B 与 Qwen2.5-7B-Instruct 上复用 9B 模型生成并审核的增强数据，比较 T1I0 与同骨干 T0I0 的严格关系 F1。结果表明，本章训练方法在两种补充骨干上同样带来稳定提升：在 Qwen3.5-4B 上，T1I0 相对 T0I0 在 AAEC 和 CDCP 上分别提高 3.22 和 4.66 个百分点；在 Qwen2.5-7B-Instruct 上分别提高 3.52 和 5.82 个百分点。上述补充比较经单独的 Holm 校正后 p 值均低于 0.05。完整的跨骨干四组合结果见 4.6.7 节表 4.24 和表 4.25。

本章方法仍存在一定局限：一方面，改写文本可能表达流畅但监督状态已经改变，审核后仍会残留少量错误；另一方面，改写还可能通过上下文影响只读组件之间的关系，这部分影响已在 3.5.5 节通过抽查进行评估，但尚未在训练中显式处理。

3.6 本章小结

针对训练文本局部改写后部分标注可能失效、直接沿用原标签会引入错误监督的问题，本章提出了可靠监督与一致性学习方法。该方法首先通过关系影响域确定改写可能影响的组件与关系，并借助组件对应映射将原标注无损地迁移到改写文本上；在此基础上，通过语义审核与因素掩码确定增强侧监督的范围，使只有可靠的组件与关系参与学习；进而在可靠因素上施加一致性约束，并按源文档归一化控制改写样本数量带来的权重差异。在 AAEC 和 CDCP 上的实验结果表明，该方法使严格关系 F1 相对同骨干的 MCR-BR 基线分别提高 2.56 和 3.30 个百分点；在固定增强样本与因素掩码的条件下，一致性目标本身

带来 1.39 和 2.57 个百分点的提升，且均通过多重比较校正；不施加一致性约束时，可靠因素构造与 QOS 式增强的差异不显著。此外，人工分层审核显示被接受因素的加权不安全率低于 1%，跨骨干实验也表明该训练方法在两种补充骨干上同样带来显著提升。

本章通过筛选可靠的增强监督并施加一致性约束，改善了模型在训练阶段学到的组件与关系预测，使因端点组件缺失或错误而无法命中的金标关系在 AAEC 上由 637 条减少到 546 条、在 CDCP 上由 294 条减少到 260 条（见 4.6.5 节表 4.19）；然而，这部分关系仍分别占金标关系的约 22.5%和 34.4%，而组件一旦出错，以其为端点的关系也随之失效，单靠改进训练信号难以消除这类错误。因此，下一章将以本章所得模型为起点转向推理阶段，研究在不改动原文的前提下如何修改预测组件并同步重建受影响的关系，以获得满足任务约束的论辩结构。

第 4 章 基于结构约束的论辩图联合修正方法

第 3 章在训练阶段改善了监督的可靠性，本章以其所得模型为起点，进一步围绕推理阶段预测论辩图中残余的结构错误展开研究。可靠监督与一致性学习改进了模型的学习信号，但模型生成的论辩图中仍存在组件边界或类型错误，而组件与关系相互依赖，组件一旦出错，以其为端点的关系也会随之失效，仅对组件或关系分别进行局部修正难以得到一致的论辩结构。针对上述问题，本章提出一种结构约束联合修正方法，在原文、候选与对象评分均固定的条件下，将一次组件修改与全部受影响关系的重建作为一个不可拆分的事务，统一评估并统一决定是否接受。具体而言，首先介绍候选生成与初始图的构造，以及对象评分与接受准则；然后说明依赖闭合事务的构造方式及其局部与全局求解算法，并分析方法的性质；最后通过对照实验检验各项设计的作用，并分析本章方法与第 3 章方法之间的衔接关系。

4.1 引言

推理阶段的结构错误中，有相当一部分源自组件。本章以第 3 章所得模型 T1I0 为起点，其中 T1 表示第 3 章的训练配置，I0 表示继承自 MCR-BR 的推理流程，包括重排序、合法化与原始有界修正。4.6.5 节的分析（表 4.19）表明，第 3 章的训练方法使因端点组件缺失或错误而无法命中的金标关系在 AAEC 上由 637 条减少到 546 条、在 CDCP 上由 294 条减少到 260 条，但这类关系在 T1I0 中仍分别占金标关系的约 22.5%（546/2427）和 34.4%（260/756）。造成这一现象的根源在于组件与关系之间的依赖：组件的边界或类型一旦改变，以其为端点的全部关系也随之成为不同的对象，例如将某个组件的类型由主论点改为论点后，原先指向该组件的攻击关系需要随之删除，而指向新组件的支持关系则需要重新判断。因此，修正决策面临两方面的困难：一方面，若仅根据组件的置信度决定是否修改，就会忽略关系整体失效带来的损失；另一方面，若根据整图的平均得分决定是否修改，又可能把删除对象导致的分母变小误当作收益。

围绕组件与关系的协同决策，已有研究进行了多方面的探索：基于结构解析与整数规划的方法[12]在全局约束下联合推断组件与关系，关系抽取中的修正方法 Re-Cent[53]以及论辩重构研究[54]也提出了对预测结构进行修正的相关机制。然而，对于在已有预测图上进行修正的场景，简单的后处理并不足够：4.6.2 节的实验表明，仅按评分删除低分关系虽然能够提升 F1，却会误删一部分原本正

确的关系。由此可见，修正过程必须在同一目标下同时衡量恢复正确对象的收益与删除对象的代价。

针对上述问题，本章以第 3 章所得模型为起点、以 MCR-BR[56]为基础方法，提出一种结构约束联合修正方法（简称联合修正）。该方法以 MCR-BR 中已有的类型与跨度修改为基础，在原文、候选和对象评分均固定的条件下，将组件冲突消解、受影响关系的重建、分项效用和编辑预算纳入统一的接受规则，使组件修正的收益与关系侧的代价在同一目标下得到权衡。具体而言，每次修改都以依赖闭合事务为单位进行：一个组件被修改后，以该组件为端点的全部关系连同新组件可能参与的关系都要一并重新决策，组件修改与这些关系的重建构成一个不可拆分的整体，要么整体接受，要么整体拒绝。在此基础上，完整推理配置 I1 在 I0 得到的初始图G_0上追加联合修正R_{DC}，并根据候选规模选择全局整数规划求解或集合局部搜索子程序（本文记为 BR-J）。联合修正过程不更新抽取模型的参数，所依赖的对象评分器单独训练与校准（见 4.3.1 节），因此该方法既能作用于第 3 章所得模型，也能直接作用于其他训练配置得到的模型。

如图 4.1 所示，本章方法由候选生成、对象评分与联合修正三部分构成，图中给出了三者之间的数据流。本章其余部分安排如下：4.2 节确定可修改的对象及候选空间，4.3 节给出对象评分与接受条件，4.4 节说明依赖闭合事务的构造方式，4.5 节介绍局部与全局求解算法并分析其性质，4.6 节报告实验结果。

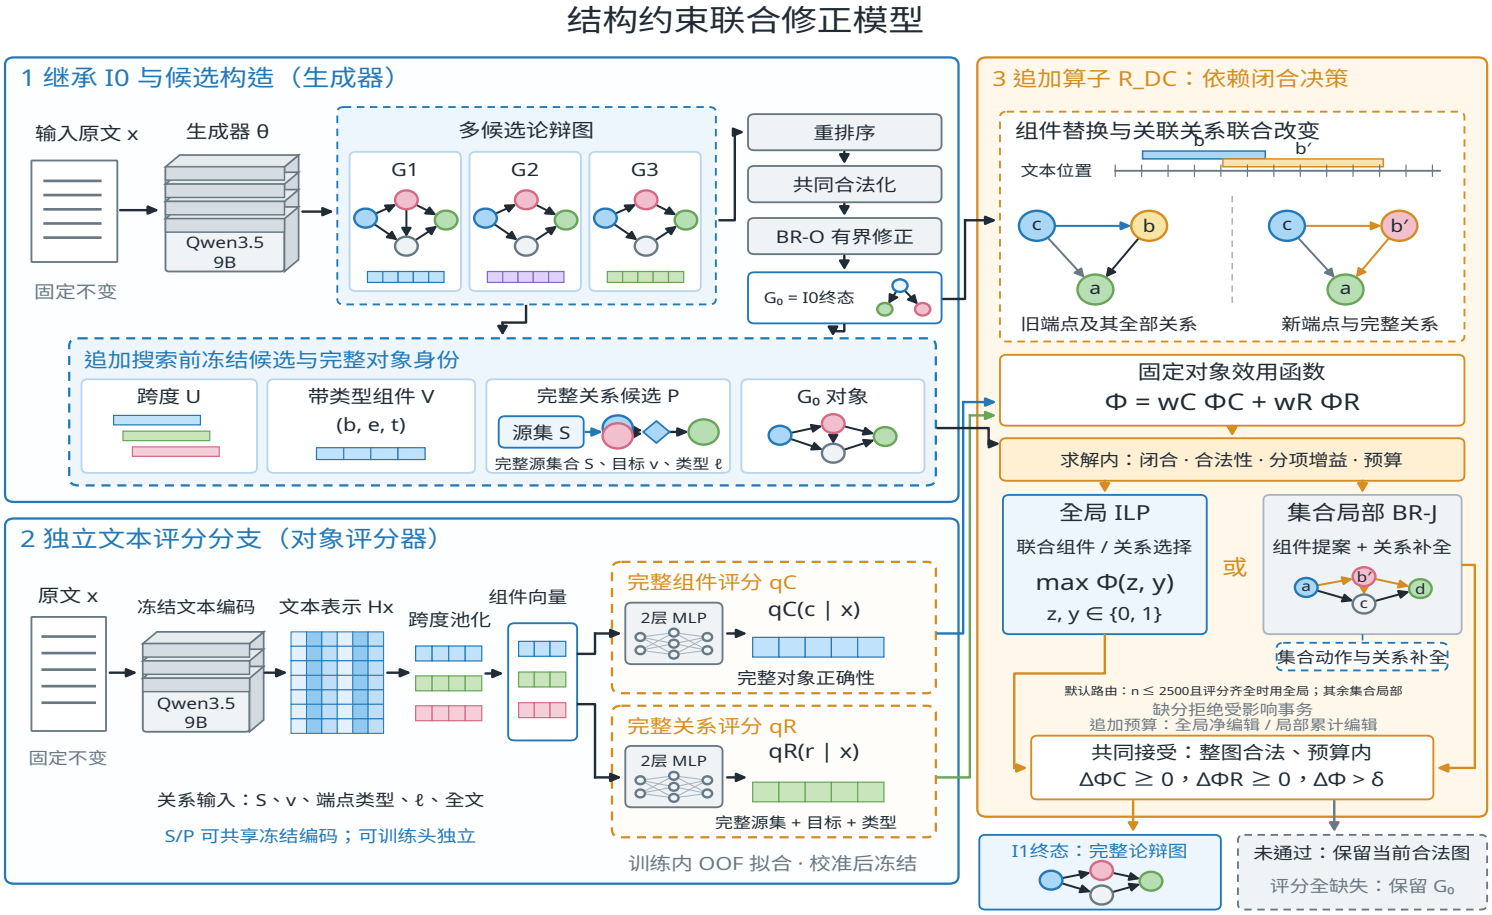


图 4.1 结构约束联合修正模型

4.2 候选生成与初始图

候选生成在本章方法中承担两项作用：一是为初始图的选择提供若干完整的备选结构，二是限定后续修正能够使用的对象范围。其中，初始图的选择沿用 MCR-BR 的做法；在修正开始前，再将多次生成与补充提议得到的对象汇总为固定的候选空间。

4.2.1 多候选生成与初始图选择

给定文档x，生成器产生K组组件预测，默认取$K=3$：其中一组采用贪心解码（temperature 为 0），另外两组采用核采样（temperature 为 0.7，top-p 为 0.9）。三组预测使用同一提示，差异仅来自解码方式，K的取值固定为 3，本文未单独考察其影响。由此得到的组件预测集合表示为：

$$\mathcal{C}=\{C^{(1)},\dots,C^{(K)}\},\tag{4-1}$$

其中，每个组件由原文跨度和类型构成。关系生成器在给定的组件集合$C^{(k)}$上预测关系，得到候选图$G^{(k)}=\left(C^{(k)},R^{(k)}\right)$，这一过程不修改组件，预测对象的数量由模型自行决定。多个候选在边界、类型和连接上的差异，既用于选择初始图，也为后续的替换提供备选对象。

初始图G_0按 2.4 节所述流程得到，即沿用 MCR-BR 的重排序、合法化以及 MCR-BR 中的原始有界修正模块（本文记为 BR-O）；I1 在此基础上执行追加修正R_{DC}，其预算单独计算。重排序的评分形式为：

$$\mathrm{E}_{\mathrm{rank}}(G)=0.4\,\mathrm{E}_{\mathrm{dens}}(G)+0.4\,\mathrm{E}_{\mathrm{coh}}(G)+0.2\,\mathrm{E}_{\mathrm{val}}(G),\tag{4-2}$$

其中，$\mathrm{E}_{\mathrm{val}}$为合法性分量，当输出可解析且跨度、类型和引用全部合法时取 1，否则取 0；覆盖分量与连贯分量均依赖关系的语义验证结果。设$Q(G)$为预测图中参与覆盖评价的节点，$p_r\in\{0,1\}$为关系语义验证的结果，$d_{\mathrm{coh}}^{\mathrm{in}}(j)$为指向节点$j$且通过验证的关系数，则两个分量分别计算如下：

$$\mathrm{E}_{\mathrm{dens}}(G)=\frac{1}{\left|Q(G)\right|}\sum_{j\in Q(G)}\min\left\{\frac{d_{\mathrm{coh}}^{\mathrm{in}}(j)}{\tau_j},1\right\},\mathrm{E}_{\mathrm{coh}}(G)=\frac{1}{|R|}\sum_{r\in R}p_r,\tag{4-3}$$

其中，集合为空时对应分量取 0。AAEC 的覆盖节点为预测的论点，CDCP 的覆盖节点为预测的政策和价值，主论点不要求必须有入边；结构角色阈值按节点是否有出边设置，没有出边时$\tau_j=2$，否则$\tau_j=1$；对于 CDCP 的多前提关系，只计一次入边。

初始图的合法化与 BR-O 修正同样沿用 MCR-BR 的处理方式。具体而言，重排序得分相同的候选按生成顺序选择；合法化只作用于G_{rank}，通过坐标规范化、去重和重新编号得到G_{pre}，遇到无法消解的冲突时返回失败；BR-O 在G_{pre}上执行，并经合法性检查后得到G_0。

上述评分存在明显的局限：一方面，覆盖分量和连贯分量都依赖同一验证结果p_r，二者并不独立；另一方面，覆盖节点数和当前边数又是平均分的分母，删除低分对象或改变组件类型可能提高平均分，却不一定提高真实的准确率。因此，本章仅将该评分用于初始候选的选择，并为允许修改组件的修正阶段另行定义接受目标。

4.2.2 候选空间构建

追加修正开始前，首先构建固定的跨度集合U，该集合由两部分组成：一是保护部分，包括G_0以及各候选输出中全部合法的组件跨度，这些对象不会被裁剪；二是补充部分，由独立的跨度预测头和类型分类器提供。跨度预测头基于冻结的 Qwen3.5-9B 表示，通过两个线性层分别预测组件的起止边界，并在训练集上进行监督训练；补充跨度按边界得分排序，最多保留 64 个，其候选类型由类型分类器给出。

在类型层面，每个补充跨度保留类型头排名前 2 的类型，保护对象则保留其全部类型。记跨度 u 的候选类型集合为$T_*(u)$，则带类型的组件候选集合为$V=\{(u,t):t\in T_*(u)\}$，每个跨度最多选择一个类型，NULL 表示不选。

候选对象的身份由字符坐标确定：跨度 u 即字符区间(d,b,e)，带类型候选(u,t)对应(d,b,e,t)，关系则由完整的源组件集合、目标组件和标签共同确定。候选去重、评分缓存、冲突检查和评价均使用这一身份。

关系候选按“源组件集合—目标”槽位构建。对于 AAEC，直接枚举候选组件之间的合法有向对；对于 CDCP，则由一个学习得到的源组提案器 P 生成候选源组件集合，并用相邻源组件的规则进行补充。G_0及各候选图中已有的槽位始终保留，不受数量上限限制。

源组提案器 P 在冻结的 Qwen3.5-9B 编码器上接一个隐藏维度为 1024 的两层 MLP，输入源组件表示、目标表示、全文表示和 7 维位置特征；训练时以训练集中真实的源组件集合为正例，为每个正例抽取 4 个负例，训练 5 个 epoch。P 最多输出 64 个候选槽位，再用相邻 2 或 3 个源组件的规则进行补充，补充后

的总数不超过 256，而G_0以及各候选图中已有的槽位另行保留，不受该上限限制。

每个槽位包含该端点组合下的全部合法关系标签，NONE 由不选任何正关系表示；槽位按各标签对象得分的最大值排序，保留前N_{slot}个补充槽位。

为控制候选规模，若构建过程中合法槽位数超过 50000，则视为构造失败，直接返回G_0。作为参考，若对m个跨度、每个跨度q个类型完全展开，AAEC 的槽位数为$m(m-1)q^2$，CDCP 的槽位数为$\sum_{k=1}^{3} C(m,k)(m-k)q^{k+1}$，其中$C(m,k)$表示从$m$个跨度中选取$k$个的组合数，二者均远大于默认设置下的实际规模。

对于二元关系，只有当正反两个方向的槽位都在候选池中且端点合法时，才考虑反转关系方向；搜索期间不向候选池外补充关系。

在上述候选空间上，主实验施加的结构约束可逐项归纳如下，这些约束均针对论辩挖掘任务设定：①组件跨度互不重叠（嵌套也视为重叠），该约束在两个语料上均施加，与新增组件冲突的旧组件须在事务中补全删除（见 4.4.1 节）；②同一端点组合（槽位）至多选择一个关系标签，NONE 表示不选；③关系的全部端点都必须存在于当前组件集合中，不允许自环，二元关系反转方向时还需满足上述双向槽位条件；④ AAEC 的关系为任意两个不同组件之间的有向二元关系，CDCP 的源组件须按原文位置连续且目标不属于源集合，多前提关系作为一个整体，不在二元表示与多元表示之间任意拆合；⑤若语料要求无环，则引入顺序变量施加无环约束（见 4.5.1 节）。候选质量的统计见 4.6.3 节。

4.3 对象评分与接受准则

搜索过程需要比较不同状态的优劣，而各状态的组件数、关系数和图结构均在不断变化。为此，本章在搜索前固定每个对象的得分，以基于计数的效用衡量对象的增加与删除，并设置分项接受门，既不允许以组件效用的下降换取关系效用的提高，也不允许以关系效用的下降换取组件效用的提高。

4.3.1 对象评分器与策略选择

对象评分器 S 分别估计组件和关系作为完整对象完全正确的概率，表示为：

$$q_C(c \mid x), q_R(r \mid x), \tag{4-4}$$

其中，组件得分由组件头给出，组件头根据跨度表示和全文表示预测类型（含NULL）分布；关系得分由关系头给出，关系头以端点的跨度表示和类型、关系方向、关系标签以及全文表示为输入，判断整个关系对象是否正确。只有端点跨度、端点类型和关系标签都完全正确时，关系候选才被视为正例，因此在金标端点上训练得到的关系分类器，其准确率并不能代表完整对象的正确概率。

评分器 S 使用冻结的 Qwen3.5-9B 编码器，组件头和关系头均为两层 MLP，与抽取模型的 LoRA 和训练辅助头相互独立。具体而言，组件头以跨度均值表示与全文末端表示为输入，结构为 $8192 \to 1024 \to$ 类型数+1；关系头以源组件、目标、全文表示、类型和标签嵌入以及位置特征为输入，结构为 $12375 \to 1024 \to 1$。两个头均使用 GELU 激活和 0.1 的 dropout，采用 AdamW 优化器以10^{-3}的学习率训练 10 个 epoch；评分器 S 与提案器 P 共享冻结的文本表示缓存，但不共享可训练参数。

在跨骨干实验中，4B 和 2.5-7B 骨干分别重新训练和校准评分器，各模块的输入维度随骨干的隐藏维度d调整：评分器 S 的组件和关系输入维度分别为$2d$和$3d+87$，提案器 P 的输入维度为$3d+7$。各骨干使用各自的分词器，结果通过字符坐标对齐，输入长度上限统一为 4096 个 token，不启用长上下文扩展。

在搜索开始前，同一文档的文本表示、校准参数和全部候选得分均被固定；由于对象得分q不依赖当前图的结构，同一对象在不同搜索状态中的得分保持不变。评分缺失等异常情况的处理见 4.5.4 节。

评分器的训练数据应当包含模型实际会犯的错误，而不能只使用人工构造的简单负例。因此，本文按源文档进行三折交叉拟合（out-of-fold，OOF）：对于每一折，使用未见过该折文档的生成器和跨度头为其生成候选，再与金标对比得到正负标签；在比较两种训练方法时，OOF 候选同时来自两类生成器，以避免评分器只适应其中一种。

负例包括跨度错误和类型错误的组件，以及原本无关系的槽位上的关系候选，校准数据则保持候选的自然分布。按 4.6.1 节所述的交叉拟合划分，训练集源文档分为评分器拟合、校准和策略选择三部分，分别用于训练评分器、校准概率以及选择阈值和预算；评分质量的检查结果见 4.6.3 节。

策略在独立的策略集上选择。AAEC 固定κ_R=1；CDCP 在$\kappa_R \in \{0.5,1.0\}$和$\delta \in \{0.01,0.05,0.10,0.20\}$的组合中进行选择：首先排除原有正确关系损失率超过

5%的组合，再从其余组合中选取关系 F1 最高者，若出现并列，则取较大的κ_R和δ；若所有组合均不满足要求，则直接输出 I0 的结果。选定的参数在评价前固定，并由局部求解和全局求解共用。

4.3.2 效用函数与接受条件

对于对象类别$X \in \{C, R\}$（C 为组件，R 为关系），设固定系数$0 < \kappa_X < 2$，效用定义为：

$$\Phi_X(G) = 2 \sum_{o \in X(G)} q_X(o \mid x) - \kappa_X \left| X(G) \right|, \Phi(G) = w_C \Phi_C(G) + w_R \Phi_R(G), \quad (4\text{-}5)$$

其中，$w_C, w_R > 0$，主配置取$w_C = w_R = 1$，κ_X在开发集上确定后固定。该效用不按当前图的组件数或关系数进行归一化。

该效用具有清晰的概率含义。令Y_X为真实对象集合，并假设$q_X(o \mid x) = P(o \in Y_X \mid x)$，即评分为对象正确的概率，则由$\mathrm{FP}_X = \left| X(G) \right| - \mathrm{TP}_X$和$\mathrm{FN}_X = \left| Y_X \right| - \mathrm{TP}_X$可得：

$$\Phi_X(G) = (2 - \kappa_X) \mathrm{E}\left[\left| Y_X \right| \mid x \right] - E\left[\kappa_X \mathrm{FP}_X + (2 - \kappa_X) \mathrm{FN}_X \mid x \right], \quad (4\text{-}6)$$

其中，第一项与预测图无关，因此最大化该效用等价于最小化误检和漏检的期望加权代价，κ控制两类错误的相对权重；该推导只用到期望的线性性，无需假设各对象的正确性相互独立。

然而，F1 不能按对象分解，最大化 F1 的决策一般无法由边际概率直接确定[57,58]。因此，本文采用可分解的代价敏感效用作为代理目标，使其能够直接用于事务差分和整数规划，最终效果仍以严格关系 F1 评价。

在此基础上，一个候选事务只有同时满足以下条件才被接受：修改后的整图合法，剩余预算足够，且

$$\Delta\Phi_C \geq 0, \Delta\Phi_R \geq 0, \Delta\Phi > \delta > 0, \quad (4\text{-}7)$$

其中，前两个条件（分项门）要求组件和关系的效用均不下降，第三个条件要求总效用的提升超过阈值δ，以排除收益很小的修改。

编辑成本用于限制修改规模。组件的编辑成本为$d_C = |D| + |B|$，即删除和新增组件的数目；关系的编辑成本为$d_R = |R \triangle R'|$，即修改前后关系集合的对称差；组件类型或边界改变导致的关系删除与新增分别计费。编辑成本只用于预算限制，以及在效用相同时优先选择改动较少的方案，不计入效用；此处只统计追加修正的编辑，并分别记录累计编辑量和相对G_0的净变化。

4.4 依赖闭合事务的构造

组件修改与关系重建构成一个不可拆分的事务，其构造过程分为三步：首先补全删除集合以消除跨度冲突，然后找出所有受端点变化影响的关系，最后对修改后的完整图进行一次接受判断。仅修改关系的操作也使用同一事务接口，此时组件保持不变。

4.4.1 组件冲突消解

设当前组件集合为C，一次提议给出新增集合B和主动删除集合D_0（D_0和D均表示待删除的组件集合，输入文档仍记为x）。冲突消解首先将$B \cap C$中没有变化的对象从B和D_0中去掉，然后补上所有与新增组件冲突的旧组件，表示为：

$$D = D_0 \cup \{c \in C : \exists b \in B, \mathrm{Conflict}(c, b)\}, C' = (C \setminus D) \cup B, \tag{4-8}$$

其中，B内部的组件必须互相兼容；所有与新增组件冲突的旧组件，即使不在提议范围内，也都必须加入D，否则修改后的图仍可能存在非法重叠。若补全后超出预算，则拒绝该提议。

在此基础上，基本的修改操作包括$0 \to 1$、$1 \to 0$、$1 \to 1$、$1 \to 2$和$2 \to 1$，分别对应补回漏检、删除误检、替换类型或边界、拆分和合并；默认每个事务满足$|D| + |B| \le 3$，该限制在冲突补全之后检查。

4.4.2 受影响关系的重建

本章所说的“依赖闭合”是指，一个组件被删除或替换后，所有以旧组件为端点的关系以及新组件可能参与的关系都要一同进入决策，以免只计算组件的收益而遗漏关系的损失，其中“全部受影响关系”限于候选空间之内。另外，本章的 NONE 与第 3 章含义不同：第 3 章的 NONE 来自标注，需要在改写后保持；本章的 NONE 仅表示当前预测没有选择该关系，其中可能存在漏检，因此推理时可以将其改为一条关系。

令变化对象集合$A = D \cup B$包括被删除的旧组件和新增的组件（与第 3 章的改写集合不同），P_A为候选池P中至少有一个端点属于A的全部关系，包括入边、出边、已选的正关系和未选的 NONE 槽位。删除旧组件后，所有以其为端点的关系都必须删除，而新增组件的入边和出边则重新参与选择，不能按旧编号继承。

对于组件正确但关系有误的情况，事务保留纯关系提议S_R，其关系范围定义为：

$$P_{\text{tx}} = P_A \cup S_R, \tag{4-9}$$

其中，纯关系事务（RelationOnly）取$D = B = \varnothing$，通过S_R实现增边、删边、改标签或反转方向；一个槽位进入S_R时，其全部合法标签一同进入，反转方向则需满足 4.2.2 节的双向槽位条件。

对于每个新的组件集合C'，算法先为受影响的关系求出最优（或可行）的补全，再比较完整的新图$G' = (C', R')$，而不是先按组件得分决定C'。事务以外的关系保持不变，但整图仍需满足全局约束：若组件的变化使某些事务外的已选关系变得不合法，就将这些关系的槽位加入S_R，重新求解其全部标签并计入相应的编辑成本，若仍不可行或超出预算，则拒绝该事务。通过上述处理，端点变化导致的关系失效均被计入，组件收益与关系代价得以完整权衡。

CDCP 还存在一种特殊情况：由于源组件必须在原文中连续，删除某个中间组件可能使原本不合法的关系变得合法。例如，组件依次为a, b, c, t，候选关系$h = (\{a, c\}, t, \text{Reason})$因$b$位于 a、c 之间而不合法；删除$b$之后$h$变得合法，但$a, c, t$均未变化，$h$不在该事务的重建范围$P_A$之内，只能由后续的纯关系提议恢复。本文没有将这类槽位自动纳入事务，这是局部搜索在邻域上的限制，并不影响已接受结果的合法性和算法的终止性；全局求解同时决定组件和关系，可以直接处理这种情况（见 4.5.2 节）。

综上，跨度或类型改变后，组件即成为一个新对象，以旧对象为端点的关系计为删除，以新对象为端点的关系计为新增。下面以一个真实事务说明这一过程。

4.4.3 事务示例

本节以 AAEC 测试文档 essay077 为例（种子 29，单对象共同接受中的第 1 次事务），组件文字取自原始语料，得分 q 来自 9B 模型固定后的评分，事务涉及的对象及其评分如表 4.1 所示。

表 4.1 essay077 示例事务涉及的对象及其评分

对象	原文／完整端点及标签	变化	评分 q
b 旧：[1483,1537) 主论点	complained about the drawbacks of zoos are often heard	删除	0.898635
b 新：[1483,1537) 论点	complained about the drawbacks of zoos are often heard	加入	0.958186
a1：[1555,1669) 前提	some zoos are lack of systematic management which attributes to numerous wild animals die because of food shortage	保持	0.898486
a2：[1677,1820) 前提	being caged in the zoos for long render wildlife lost the ability to survive in nature where is full of cruel competition among various animals	保持	0.897797
r1	a1 → b 旧 / 攻击	删除	0.669856
r2	a2 → b 新 / 支持	加入	0.890926
r3	a2 → b 旧 / 攻击	删除	0.013781

原预测将[1483,1537)标为主论点，而金标类型为论点。同一跨度上的新旧两个类型对象互相冲突，因此加入 b 新就必须删除 b 旧；随之，两条指向旧对象的攻击关系被删除，并新增了 a2 指向新论点的支持关系，a1 和 a2 本身保持不变。

取$\kappa_C=\kappa_R=1$、$\delta=0.20$ 时，该事务使组件效用增加 0.119102，关系效用增加 1.414578，总效用增加 1.533680。由于两个分项增量均非负且总增量超过阈值，组件和关系分别编辑 2 次和 3 次，也未超出追加阶段 24 和 96 的预算，该事务被接受。

按金标进行事后统计，组件的 TP/FP/FN 由 11/3/3 变为 12/2/2，关系由 4/5/5 变为 5/3/4。为检验拒绝条件，在同一事务上另行构造两种异常输入：若删除 1 个必需关系分数，检查结果为 reject_missing_score；若将剩余组件预算设为 1，检查结果为 reject_edit_budget。两种情况下事务均被拒绝，原图保持不变，语义编辑数为 0；而在正常输入下，全部必需分数齐备，事务以组件 2 次、关系 3 次编辑提交。

以上案例展示了单个事务的评估与接受过程，下一节将介绍如何在候选空间中搜索并提交这样的事务。

4.5 求解算法及性质

联合修正包括局部求解与全局求解两种方式：局部求解先固定通过冲突检查的组件提议，再补全受影响的关系；全局求解则一次性同时选择全部组件和关系。二者共用固定评分、分项门和整图约束，但编辑预算的计算方式不同，局部求解按累计修改计算，全局求解按相对初始图的净变化计算，因此二者的可行域也不同。下面依次介绍局部求解、全局求解、方法性质以及求解方式的选择。

4.5.1 集合局部搜索

局部求解采用“有界组件提议＋局部整数规划关系补全”的方式。对于一个已经通过冲突检查的组件集合C'，令$z_c = I[c \in C']$表示组件状态（已固定），$y_r \in \{0,1\}$表示是否选择关系候选$r \in P$，则目标函数为：

$$\max_{y} w_C \Phi_C(C') + w_R \sum_{r \in P} \left(2 q_R(r \mid x) - \kappa_R\right) y_r, \tag{4-10}$$

其中，组件提议固定后，组件项在关系求解中是常数，但在比较不同组件提议时仍需保留。约束条件如下：

$$\begin{aligned}
&\sum_{t \in T_*(u)} z_{(u,t)} \le 1, \\
&z_c + z_d \le 1 \text{若 } \mathrm{Conflict}(c,d); \\
&y_r \le z_c \forall c \in \mathrm{Ends}(r), \\
&\sum_{r \in \Gamma_s} y_r \le 1 \forall s; \\
&y_r = I[r \in R] \forall r \notin P_{\mathrm{tx}}, \\
&G' \in G_A,
\end{aligned} \tag{4-11}$$

其中，Γ_s为同一槽位的互斥标签候选，全为 0 即为 NONE；G_A为整图合法集合；关系约束保证被选关系的端点全部存在。若语料要求无环，则引入顺序变量$0 \le o_c \le M-1$（$M = |V|$），并对全部候选二元边加入约束：

$$o_v \ge o_u + 1 - M\left(1 - y_{(u,v,\ell)}\right). \tag{4-12}$$

对于多前提关系，对每个源组件到目标的方向分别加入同样的约束；对于 CDCP 的源组件连续性规则，则在给定的C'上判断每个候选关系是否合法，对不合法的关系强制$y_h = 0$，若这与事务外的固定关系冲突，则当前事务不可行。

此外，分项效用门和编辑预算也作为约束加入整数规划。设$y_r^0 = I[r \in R]$为修改前的关系状态，关系编辑成本可以线性地表示为：

$$d_R=\sum_{r:y_r^0=1}\left(1-y_r\right)+\sum_{r:y_r^0=0}y_r. \tag{4-13}$$

整数规划同时要求d_C,d_R不超过剩余预算，并且$\Delta\Phi_C,\Delta\Phi_R\geq 0$，提交前再检查$\Delta\Phi>\delta$。这些条件必须在求解时加入，而不能先求最高分再检查是否违规；若存在多个最优解，则依次按效用最大、编辑最少、规范键最小的顺序选择；求解超时时，返回当前最好的可行解，并重新检查全部约束。

局部搜索的提议分为六类：纯关系、插入、删除、替换、拆分和合并。具体而言，纯关系提议枚举端点合法的全部槽位；插入从未选组件中选择，删除从已选组件中选择；替换以一个新组件代替一个旧组件，允许类型或边界变化；拆分将一个旧组件替换为两个相容、位于原跨度内且首尾包络与原跨度一致的新组件，合并则是其逆操作。每个提议都先补全冲突删除，再按实际的S_R、$\left(\left|D\right|,\left|B\right|\right)$检查其是否属于上述类型以及是否超过三个组件的上限，例如，一个名义上的插入若实际变成了$2\rightarrow 1$，在单对象对照中就会被拒绝。

局部搜索按提议次数计算预算：评估一个提议计一次尝试，提议被提交计一次接受，每轮最多 32 次尝试、3 次接受，最多 4 轮，均从G_0开始计算。在每一批中，算法从六类提议中轮流选取，按得分和剩余预算择优检查，并从本批通过检查的候选中择优提交一个完整事务；同一状态下不重复评估相同的提议，无法安全提交时返回最近的合法图。执行流程如图 4.2 所示。

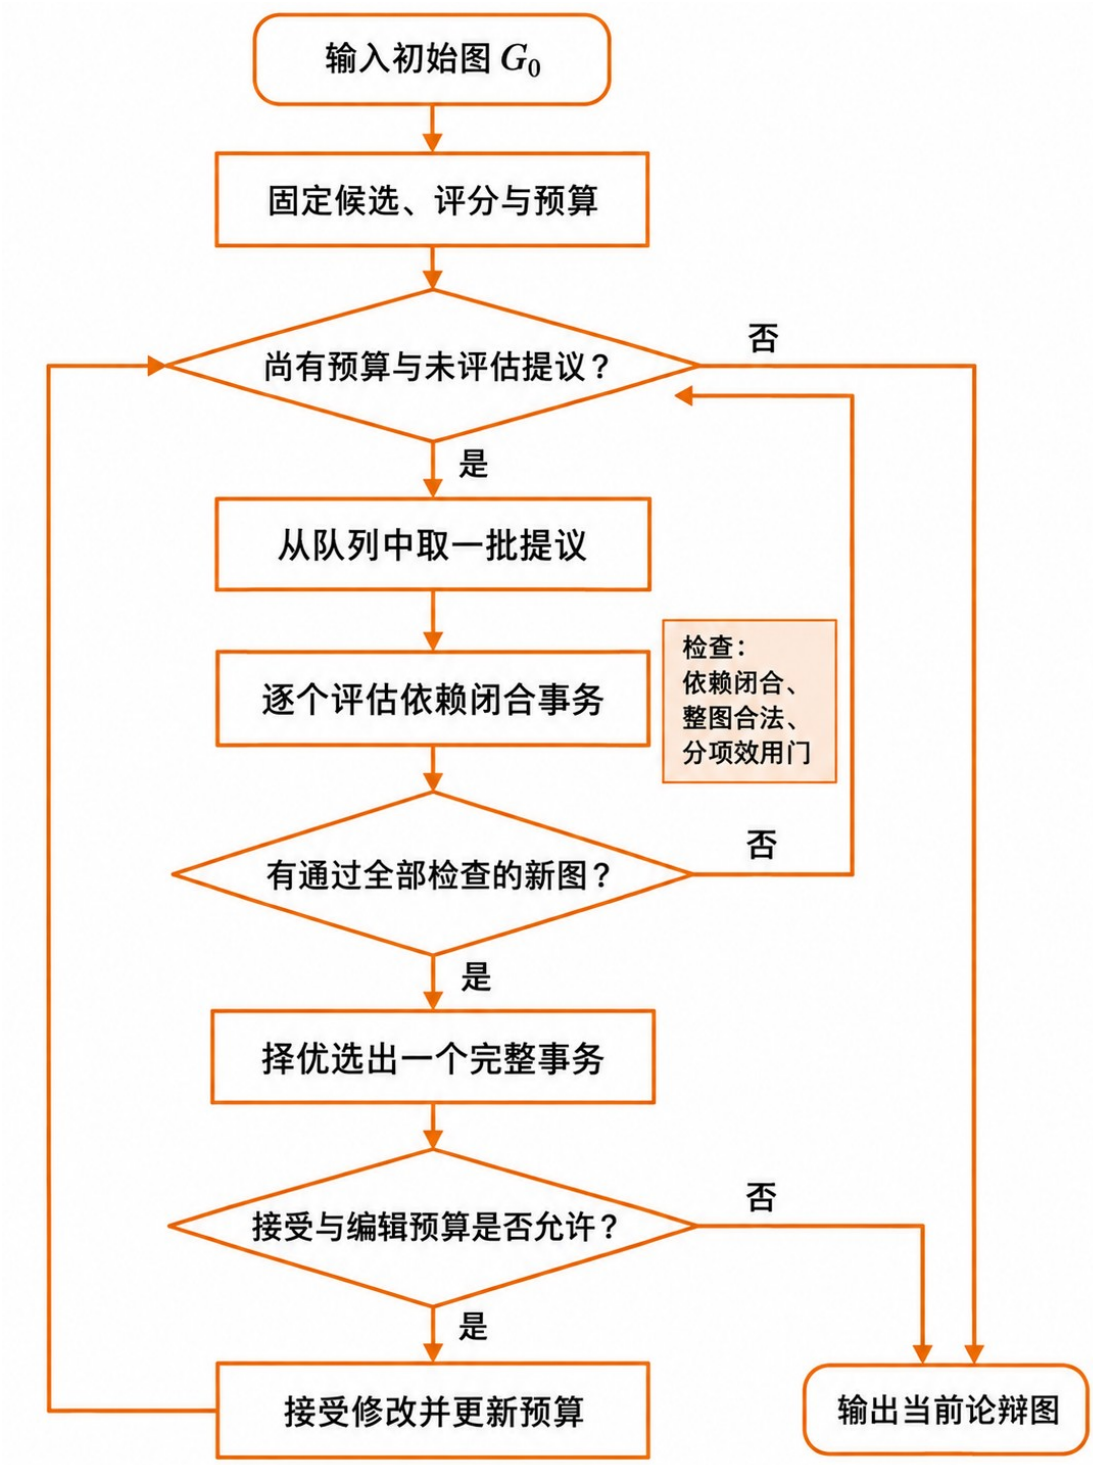


图 4.2 集合局部搜索 BR-J 的执行流程

图 4.2 概括了集合局部搜索子程序 BR-J 的执行流程。流程以 4.2 节得到的合法初始图G_0为起点；无法获得合法初始图时报告初始化失败，候选构造或评分固定失败时返回G_0。每项提议先按 4.4 节补全冲突删除与受影响关系，再在预算和约束内求解；无可行解或评分失败的提议不予提交。接受前检查完整合法性、编辑预算、分项门和总效用增益，检查通过后整体提交；提交失败时，

组件、关系和缓存全部恢复到提交前的状态，并返回最近的合法图。候选构造、评分、拒绝和超时的开销均计入成本。

4.5.2 全局整数规划求解

4.5.1 节固定组件提议C'，只对关系进行求解；全局求解则同时选择全部组件和关系，此时不能简单地放开组件变量，还需相应调整约束：CDCP 的源组件连续性取决于中间组件是否被选中，编辑量和分项门也要改为相对初始图G_0计算。全局模型具体如下。

（1）变量与目标。对候选空间中的每个带类型组件$v \in V$设变量$z_v \in \{0,1\}$，对每个关系候选$r \in P$设变量$y_r \in \{0,1\}$，并以z_v^0、y_r^0表示G_0中的取值。记$a_X(o)=2q_X(o \mid x)-\kappa_X$，全局目标与局部求解使用同一效用，定义为：

$$\max_{z,y} \Phi(z,y)=w_C \sum_{v \in V} a_C(v) z_v + w_R \sum_{r \in P} a_R(r) y_r . \tag{4-14}$$

（2）结构约束。全局模型的结构约束表示为：

$$\begin{gathered} \sum_{t \in T_*(u)} z_{(u,t)} \le 1 \;\forall u \in U, \\ z_c + z_d \le 1 \;若\; \mathrm{Conflict}(c,d); \\ y_r \le z_c \;\forall r \in P, \forall c \in \mathrm{Ends}(r), \\ \sum_{r \in \Gamma_s} y_r \le 1 \;\forall s; \\ y_h + z_w \le 1 \;\forall h \in P_{\mathrm{CDCP}}, \forall w \in \mathrm{Btw}(h), \end{gathered} \tag{4-15}$$

其中，上述约束依次表示：同一跨度最多选择一个类型，所选组件两两兼容，被选关系的全部端点（包括多前提关系的全部源组件）都被选中，同一槽位的标签互斥。最后一个约束表达 CDCP 的源组件连续性：对于关系$h=(S,v,\ell)$，令$\mathrm{Btw}(h)$为起点位于S中最左和最右源组件之间、但不属于S的候选组件，由于被选组件互不重叠，S在被选组件序列中连续，当且仅当$\mathrm{Btw}(h)$中没有组件被选中，因此该约束是对连续性的精确线性化。若语料要求无环，则沿用 4.5.1 节的顺序变量约束。

仍以 4.4.2 节的a,b,c,t为例，全局模型中存在约束$y_h+z_b \le 1$，因此删除b与选择$h=(\{a,c\},t,\mathrm{Reason})$可以在一次求解中同时决定；而在局部求解中，$h$与删除$b$的事务没有共同端点，只能留待后续的纯关系提议恢复。这是两种求解方式结果不同的一个具体原因。

（3）净编辑量与分项门。编辑量按最终图相对G_0的净变化计算，表示为：

$$d_C^{\text{net}}=\sum_{v:z_v^0=1}\left(1-z_v\right)+\sum_{v:z_v^0=0}z_v\le B_C,\ d_R^{\text{net}}=\sum_{r:y_r^0=1}\left(1-y_r\right)+\sum_{r:y_r^0=0}y_r\le B_R,\quad (4\text{-}16)$$

其中，类型或边界的改变对应不同的变量，计为一次删除和一次新增，与局部求解中的$|D|+|B|$一致；因端点被删除而失效的关系计入d_R^{net}。分项门相对G_0定义为$\Phi_C(z)\ge\Phi_C(z^0)$和$\Phi_R(y)\ge\Phi_R(y^0)$，追加阶段的预算为$B_C=24$、$B_R=96$；求解后若$\Phi^*-\Phi(z^0,y^0)>\delta$，则返回新图，否则返回$G_0$。

由于G_0本身合法、其对象均在候选空间中、编辑量为 0 且分项门取等号，(z^0,y^0)总是满足全部约束，因此全局模型总是可行的。

（4）多个最优解与超时的处理。当存在多个最优解时，全局求解依次进行三级优化：首先最大化Φ；然后在$\Phi\ge\Phi^*-\varepsilon_{\text{tie}}$的条件下最小化$d_C^{\text{net}}+d_R^{\text{net}}$；若仍有多个解，则按规范键顺序逐个固定对象取值，优先保持G_0中的状态，其中ε_{tie}为比较容差。

全局求解的时限与局部求解相同（AAEC 为 3 秒，CDCP 为 5 秒）。求得最优解时，按δ规则返回；超时但已有不同于G_0的可行解时，重新检查全部约束、分项门和$\Phi-\Phi(G_0)>\delta$，通过则返回该解，否则返回G_0；超时且没有更好的解时返回G_0，求解出错时同样返回G_0。

（5）与局部求解的区别。局部求解在每一步都相对当前状态检查分项门，编辑成本逐次累加，因此局部求解得到的任一结果都满足相对G_0的分项门，其净编辑量也不超过累计编辑量，即局部可达的结果都在全局可行域之内。反之则不一定成立：通向全局最优解的局部路径可能在某一步需要分项效用暂时下降，而这一步会被局部接受门拒绝。

除可行域外，两种求解方式在实现上还存在以下差异。在决策变量上，局部求解（Single 或 BR-J）将组件状态固定为提议后的组件集合，仅允许事务关系范围内的关系变量变化，全局求解则令全部组件变量与关系变量同时可变；二者使用同一效用，只是局部单次求解中组件项为常数。在事务边界上，局部求解将事务外对象固定为当前状态，仅为保持合法性而最小限度地扩大关系范围，全局求解则不设事务边界；对于 CDCP 的源组件连续性，局部求解在固定的组件集合上预判并强制非法关系取 0，全局求解则以线性约束表达。在预算与评分上，二者追加阶段的预算均为组件 24、关系 96，但局部求解按各次提交的删增之和累计计数，全局求解按终态相对初始图的差异净计数；局部求解拒绝触及缺分对象的事务，全局求解则要求全池评分齐备，否则不进入该路径。在求解调用与返回上，局部求解对每个提议调用一次整数规划，外层至多进行

128 次尝试，返回最近的完整合法图及停止原因；全局求解每个文档执行一次主求解，另加破同分求解，返回经复核的终态，或返回初始图及状态码。

4.5.3 方法性质分析

命题 4-1：在候选空间和对象评分固定时，两个预测状态之间的效用差可以由新增和删除的对象精确计算。

证明：对 $X \in \{C, R\}$，记 $a_X(o) = 2q_X(o \mid x) - \kappa_X$，则

$$\Delta \Phi_X = \sum_{o \in X(G') \setminus X(G)} a_X(o) - \sum_{o \in X(G) \setminus X(G')} a_X(o). \tag{4-17}$$

由于同一对象的得分固定，两个状态共有的对象在差分中相互抵消，而依赖闭合保证所有发生改变的关系都在差集之中，因此只要知道哪些对象被增删，就能精确计算效用的变化。

命题 4-2：存在这样的合法状态，其中任何单对象修改都无法通过严格改进条件，但一个集合替换可以通过。

构造如下：设两个兼容的旧组件c_1=[0,4)、c_2=[4,8)，以及一个与二者都冲突的候选新组件 b=[0,8)，三者类型相同且没有关系，并取κ_C=1、w_C=w_R=1。令q_C(c_1)=q_C(c_2)=0.65、q_C(b)=0.95，则两个旧组件的效用为 0.30+0.30=0.60，新组件的效用为 0.90，替换后总效用增加 0.30，大于δ=0.20；此时关系效用不变，编辑成本为d_C=3、d_R=0。

在该状态下，单独删除任一旧组件会使效用下降 0.30，无法通过接受条件；直接插入 b 或用 b 替换其中一个旧组件时，冲突补全都会同时删除另一个旧组件，使操作实际成为 $2 \to 1$ 的合并，已不属于单对象修改。因此，只有允许 $2 \to 1$ 操作且组件预算不少于 3 时，这一替换才能被接受。

由此可见，集合动作能够越过单对象修改无法越过的障碍，4.6.2 节的 essay180 给出了这种情况的真实案例。

命题 4-3：在有限的候选状态空间中，若每次接受都严格提高同一个固定的效用 Φ，则接受序列不会重复访问任何状态，因而必定在有限步内终止。

由于每次接受都使效用严格增加，接受序列不可能回到已访问过的状态，而候选状态总数有限，因此接受序列也是有限的；在实际运行中，预算限制会使搜索更早停止。

最后说明代理效用与 F1 的关系。对于某个语料，设正确预测数为T，预测总数为P_0，金标总数为Q，则$F=2T/\left(P_0+Q\right)$；在修改前后分母均不为零时，展开可得：

$$F'-F=\frac{2\Delta T-F\Delta P_0}{P_0+Q+\Delta P_0}. \tag{4-18}$$

由式（4-18）可见，F1 的真实变化同时取决于正确数和预测数的变化，而推理时ΔT和F都是未知的，只能用估计的概率和固定的κ来近似。因此，上述理论性质保证的是代理效用的单调性和算法的终止性，严格 F1 上的效果仍需通过 4.6 节的实验检验。

4.5.4 求解方式的选择

依赖闭合规定了一次修改中哪些关系必须一起决策，而具体采用哪种求解方式则取决于候选规模：候选池较小时使用全局求解，较大时使用集合局部搜索以控制时延。默认的选择规则如下。

规模判断。令 n=|V|+|P|，当 n≤2500 时使用全局求解，否则使用集合局部搜索 BR-J。该阈值根据本文的硬件条件确定，表 4.2 给出了 500 至 4000 个变量规模下全局求解的耗时测试结果。

表 4.2 不同规模下全局求解的耗时

语料	变量数	问题数	均值/秒	P95/秒	时限/秒	超时数	择优完成数
AAEC	500	60	0.14	0.32	3	0	60
AAEC	1000	60	0.33	0.72	3	0	60
AAEC	1500	60	0.62	1.22	3	0	60
AAEC	2000	60	0.95	2.03	3	0	60
AAEC	2500	60	1.35	2.71	3	0	60
AAEC	3000	60	1.90	3.00	3	7	53
AAEC	4000	60	2.60	3.00	3	20	40
CDCP	500	60	0.21	0.49	5	0	60
CDCP	1000	60	0.50	1.09	5	0	60
CDCP	1500	60	0.94	1.85	5	0	60
CDCP	2000	60	1.44	3.09	5	0	60
CDCP	2500	60	2.05	4.12	5	0	60
CDCP	3000	60	2.89	5.00	5	7	53
CDCP	4000	60	3.95	5.00	5	20	40

如表 4.2 所示，变量数为 2500 时，两个语料的 P95 耗时均低于时限，而达到 3000 和 4000 个变量时开始出现超时，因此本文以 2500 个变量作为选择全局求解或局部求解的阈值；更换硬件后，该阈值需要重新测定。

求解与返回。全局求解的时限与局部求解相同（AAEC 为 3 秒，CDCP 为 5 秒）；超时时，若已有通过全部检查的更优可行解，则返回该解，否则返回G_0，详细规则见 4.5.2 节。

异常与边界处理。若某组候选的关系部分解析失败，已经通过检查的组件仍作为候选保留，失败调用的开销计入总成本；若资源连候选空间的保护部分都无法容纳，则直接返回G_0。若全部对象评分都失败，同样返回G_0；若只有部分对象缺少评分，则不使用全局求解而改用局部搜索，并拒绝涉及缺分对象的事务，缺失的评分不以默认值代替。主实验中未出现评分缺失。

以上给出了联合修正的完整求解流程，下一节将通过实验检验该方法的效果，并分析各项设计的作用。

4.6 实验与分析

为验证本章联合修正方法的有效性，本节围绕以下问题开展实验：（1）在第 3 章所得模型上追加联合修正，能否进一步提升组件与关系的抽取性能；（2）组件修改范围、组件与关系的共同接受、集合动作以及全局求解分别发挥何种作用；（3）与相同预算下的重新生成以及简单的阈值过滤相比，联合修正的效果如何；（4）对象评分的质量与推理阶段的计算成本如何；（5）联合修正与第 3 章方法如何衔接，在基础方法的模型上是否同样有效。实验所用的数据集、评价指标与显著性检验方法均沿用 3.5.1 节和 3.5.3 节的设置，训练检查点统一采用第 3 章可靠监督与一致性学习方法得到的 T1；在此基础上，I0 表示继承自 MCR-BR 的推理流程（重排序、合法化与 BR-O），I1 表示在 I0 之上追加本章的联合修正，二者的差别仅在于推理阶段是否执行联合修正。4.6.5 节在此基础上分析联合修正与第 3 章方法的衔接关系，4.6.6 节至 4.6.8 节进一步给出多前提关系、不同骨干模型上的结果以及与外部系统的比较。

4.6.1 实验设置

（1）数据划分与交叉拟合。对象评分器需要在抽取模型实际产生的预测候选上训练，为此，本章在训练集上采用以源文档为单位分组的三折交叉拟合，原文及其全部增强文本始终位于同一折中，从而保证每篇留出文档的候选都由

没有见过该文档的生成器产生。评分器的拟合、校准和策略选择使用互不重叠的源文档，AAEC 分别为 255、32 和 32 篇，CDCP 分别为 464、58 和 58 篇；测试集只用于最终评价，不参与数据增强、模型训练、概率校准和策略选择。

（2）评分与提案模块。推理阶段在抽取生成器 G 之外引入对象评分器 S 和源组提案器 P 两个模块，其实现方式与用途如表 4.3 所示。9B 主实验中，评分器 S 和提案器 P 可以共享冻结的文本编码，但二者的参数均与生成器 G 相互独立；跨骨干实验中，增强器 A 和审核器 V 固定使用 9B 模型，生成器、评分器和提案器则在各骨干上分别训练。

表 4.3 推理阶段的评分与提案模块

模块	实现方式	输出与用途
S 对象评分器	冻结 Qwen3.5-9B 文本编码＋独立 C/R MLP；OOF 训练；Platt 校准[96]参数冻结	完整对象正确性概率估计；单次搜索期间复用缓存
P 源组提案器	冻结同版本文本编码＋独立源组 MLP；训练原生完整组	最多 64 学习槽位；完整源集合及目标，不拆超边

表 4.4 汇总了对象评分、源组提案、概率校准以及追加修正的效用、预算与求解路由等设置，其中，对象评分器 S 的组件头和关系头按语料、种子和对象类别分别进行 Platt 校准[96]。

表 4.4 推理阶段的评分与修正配置

项目	设置
对象评分 S	冻结 Qwen3.5-9B 文本编码；组件含 NULL；关系 12375→1024→1；10 epoch，AdamW 10^{-3}
源组提案 P	冻结同版本文本编码＋独立 12295→1024→1 MLP；5 epoch，AdamW 10^{-3}；最多 64 学习槽位
校准	训练内 OOF；拟合/校准/策略源文档隔离；按语料、种子、对象类别 Platt
效用与阈值	w_C=w_R=1；κ_C=1；AAEC κ_R=1，CDCP κ_R=0.5；δ=0.20
开发选择	先要求原 TP 损失≤5%，再最大化策略集关系 F1；无合格配置保持 I0
预算及路由	追加R_{DC}：组件 24，关系 96（全局净/局部累计）；局部每轮 32 尝试／3 接受、最多 4 轮；n≤2500 用全局求解，否则用集合局部搜索 BR-J；追加求解 AAEC 3 ，CDCP 5 秒
候选与缺分	关系槽位上限 50000；保留初始图G_0全部对象；合计补充源组 256；评分缺失时拒绝相应事务

（3）对照方法。为考察联合修正中各项设计的作用，所有对照均使用同一个训练检查点 T1、同一张初始图G_0以及相同的候选和评分，仅改变修正方式。按修改范围由小到大，依次设置只修改关系（RelationOnly）、先改组件再改关系（Sequential）、组件与关系共同接受（Single）、允许拆分与合并（SetLocal）和全局求解（Global）五种配置。此外，另设四组参照，分别为相同预算下的重新生成（Regenerate）、仅删除低分关系（ThresholdFilter）、将严格改进阈值放宽至接近零（NoRisk）以及使用未校准评分（NoCalibration）。各配置的具体设置如表 4.5 所示，表中使用括号内的代号。主实验的 690 个文档—种子输入规模都小于 2500 个变量，因此完整方法 I1 全部使用全局求解，Single 和 SetLocal 作为消融单独报告。

表 4.5 推理对照组的设置

配置	候选与评分相同	变化项
RelationOnly	是	组件固定，只选择关系
ThresholdFilter	是	组件固定，仅删除低于门限的G_0关系；无事务与预算
Sequential／Single	是	组件优先接受／共同接受
SetLocal／Global	是	动作与可行域；累计／净编辑
NoRisk	是	放宽严格改进阈值δ
NoCalibration	候选相同	使用原始分数
MissingLow	正常缺分为 0	缺分解释
Regenerate	同检查点与追加资源	重生成完整图并重排序

（4）策略选择。效用中的关系代价系数与严格改进阈值按 4.3.1 节的规则在独立的策略集上选择，即先排除原有正确关系损失率超过 5%的组合，再从其余组合中选取汇总关系 F1 最高者。如表 4.6 所示，CDCP 在κ_R=1 时，所有δ取值都不满足损失率要求，在κ_R=0.5 时则全部满足，AAEC 在κ_R=1 时同样全部满足；据此，在满足要求的配置中按 4.3.1 节的规则取δ=0.20，且δ在 0.01 到 0.20 之间变化时开发集结果保持不变。表中$\varepsilon_{\text{gain}}$一行对应 NoRisk 消融，$\varepsilon_{\text{gain}}$为该消融使用的最小正增益阈值，与 4.5.2 节全局求解中的比较容差ε_{tie}分别配置：δ降到接近 0 后，收益极小的事务也被接受，AAEC 和 CDCP 在开发集上的误删分别增加到 6/598 和 3/130，关系 F1 降到 72.91 和 52.86，与测试集上 NoRisk 的下降趋势一致。此外，开发集 F1 由三个种子的计数汇总后计算，测试集 F1 则为逐种子 F1 的均值，二者的汇总方式有所不同。

表 4.6 开发集上的策略选择

语料	κ_R / δ	原 TP	误删 TP	损失率	汇总关系 F1	合格
AAEC	1.00 / 0.01	598	3	0.50%	73.25	是
AAEC	1.00 / 0.05	598	3	0.50%	73.25	是
AAEC	1.00 / 0.10	598	3	0.50%	73.25	是
AAEC	1.00 / 0.20	598	3	0.50%	73.25	是
AAEC	1.00 / $\varepsilon_{\text{gain}}$	598	6	1.00%	72.91	是
CDCP	1.00 / 0.01	130	41	31.54%	46.42	否
CDCP	1.00 / 0.05	130	35	26.92%	48.31	否
CDCP	1.00 / 0.10	130	29	22.31%	50.24	否
CDCP	1.00 / 0.20	130	25	19.23%	50.57	否
CDCP	1.00 / $\varepsilon_{\text{gain}}$	130	44	33.85%	45.73	否
CDCP	0.50 / 0.01	130	0	0.00%	53.47	是
CDCP	0.50 / 0.05	130	0	0.00%	53.47	是
CDCP	0.50 / 0.10	130	0	0.00%	53.47	是
CDCP	0.50 / 0.20	130	0	0.00%	53.47	是
CDCP	0.50 / $\varepsilon_{\text{gain}}$	130	3	2.31%	52.86	是

跨骨干实验中，各骨干按相同规则在开发集上独立选择策略，即先要求原有正确关系的损失不超过 5%，再选取关系 F1 最高的配置，并列时取较大的κ和δ，选择结果如表 4.7 所示。由表可知，三种骨干在两个语料上选定的参数组合与 9B 主实验相同，原有正确关系的损失率均不超过 1.07%。

表 4.7 各骨干的独立开发选择

骨干	语料	κ_R / δ	原 TP	损失 TP	损失率	开发汇总 F1
Qwen3.5-9B	AAEC	1.00 / 0.20	598	3	0.50%	73.25
Qwen3.5-9B	CDCP	0.50 / 0.20	130	0	0.00%	53.47
Qwen3.5-4B	AAEC	1.00 / 0.20	583	4	0.69%	71.70
Qwen3.5-4B	CDCP	0.50 / 0.20	125	1	0.80%	51.69
Qwen2.5-7B-Instruct	AAEC	1.00 / 0.20	559	6	1.07%	68.63
Qwen2.5-7B-Instruct	CDCP	0.50 / 0.20	116	1	0.86%	48.30

（5）成本口径。计算成本分为一次性成本与逐文档成本两部分：前者包括增强、审核、交叉拟合和评分器训练，具体统计见 3.5.6 节；后者包括生成、提案、评分和求解，被拒绝、失败或超时的计算同样计入，4.6.4 节据此报告各推理配置的逐文档时延。与重新生成对比时，两者的追加模型调用次数以及输入、输出 token 上限都相同，从而保证比较在同等资源条件下进行。

4.6.2 主要结果与消融分析

表 4.8 给出了训练配置固定为 T1 时不同推理配置的抽取性能，表 4.9 给出了各配置之间严格关系 F1 的配对差值及显著性检验结果。总体而言，追加联合修正能够在不改变训练检查点的情况下显著提升关系抽取性能：在固定 T1 的条件下，I1 使严格关系 F1 在 AAEC 和 CDCP 上分别比 I0 提高 3.38 和 5.68 个百分点，Holm 校正 p 值均为 0.0070，组件 F1 也分别由 87.85 和 83.46 提高到 88.47 和 84.45。

表 4.8 不同推理配置的抽取性能（训练均为 T1）

配置	AAEC 组件 F1	AAEC 关系 F1	CDCP 组件 F1	CDCP 关系 F1
T1I0：完整一致性学习	87.85 ± 0.39	68.25 ± 2.08	83.46 ± 1.04	45.08 ± 2.73
仅关系阈值过滤（ThresholdFilter）	87.85 ± 0.39	69.76 ± 2.10	83.46 ± 1.04	47.84 ± 3.20
固定组件，仅修改关系（RelationOnly）	87.85 ± 0.39	70.45 ± 2.11	83.46 ± 1.04	49.19 ± 2.35
组件优先分步（Sequential）	88.12 ± 0.42	70.78 ± 2.08	83.97 ± 1.01	49.68 ± 2.35
单对象共同接受（Single）	88.26 ± 0.40	71.15 ± 2.11	84.15 ± 0.97	50.04 ± 2.38
集合局部搜索（SetLocal）	88.38 ± 0.43	71.40 ± 2.10	84.33 ± 0.95	50.44 ± 2.39
全局求解（Global）	88.47 ± 0.46	71.63 ± 2.11	84.45 ± 0.94	50.77 ± 2.45
T1I1：完整配置	88.47 ± 0.46	71.63 ± 2.11	84.45 ± 0.94	50.77 ± 2.45
等预算重新生成（Regenerate）	87.71 ± 1.12	68.72 ± 2.67	83.62 ± 0.86	45.96 ± 4.28
放宽增益阈值（NoRisk）	88.39 ± 0.48	71.34 ± 2.11	84.37 ± 0.96	50.43 ± 2.38
取消概率校准（NoCalibration）	88.33 ± 0.57	71.02 ± 2.15	84.29 ± 0.91	50.11 ± 2.33
缺分当低分（MissingLow）	88.47 ± 0.46	71.63 ± 2.11	84.45 ± 0.94	50.77 ± 2.45

表 4.9 推理配置之间的关系 F1 配对差值（百分点）

语料	比较	差值	单项 95% CI	种子 17 / 29 / 43	p	类型
AAEC	T1I1 − T1I0	3.38	[2.56, 4.23]	3.30 / 3.54 / 3.31	0.0070	主要／Holm
AAEC	T1I1 − RelationOnly	1.18	[0.71, 1.68]	1.12 / 1.27 / 1.16	0.0070	主要／Holm
AAEC	Single − Sequential	0.37	[0.11, 0.65]	0.37 / 0.41 / 0.33	0.0175	主要／Holm
AAEC	T1I1 − Regenerate	2.91	[1.07, 4.83]	3.80 / 1.41 / 3.53	0.0120	主要／Holm
AAEC	T1I1 − NoRisk	0.29	[0.09, 0.51]	0.26 / 0.34 / 0.29	0.0140	主要／Holm
AAEC	SetLocal − Single	0.25	[0.04, 0.47]	0.23 / 0.27 / 0.25	0.0285	探索／原始 p
AAEC	Global − SetLocal	0.23	[0.02, 0.45]	0.21 / 0.26 / 0.21	0.0390	探索／原始 p
AAEC	Global − Single	0.48	[0.18, 0.80]	0.45 / 0.53 / 0.47	0.0030	探索／原始 p
AAEC	T1I1 − ThresholdFilter	1.88	[1.21, 2.58]	1.68 / 2.17 / 1.77	0.0005	探索／原始 p
AAEC	RelationOnly − ThresholdFilter	0.69	[0.24, 1.17]	0.56 / 0.90 / 0.62	0.0060	探索／原始 p
AAEC	T1I1 − MissingLow	0.00	[0.00, 0.00]	0.00 / 0.00 / 0.00	1.0000	探索／原始 p
AAEC	T1I1 − NoCalibration	0.61	[0.14, 1.10]	0.49 / 0.71 / 0.62	0.0175	探索／原始 p

表 4.9 推理配置之间的关系 F1 配对差值（百分点）（续表）

语料	比较	差值	单项 95% CI	种子 17 / 29 / 43	p	类型
CDCP	T1I1 − T1I0	5.68	[4.03, 7.47]	5.40 / 5.40 / 6.24	0.0070	主要／Holm
CDCP	T1I1 − RelationOnly	1.57	[0.74, 2.46]	1.49 / 1.68 / 1.54	0.0070	主要／Holm
CDCP	Single − Sequential	0.36	[0.10, 0.66]	0.33 / 0.40 / 0.35	0.0175	主要／Holm
CDCP	T1I1 − Regenerate	4.81	[2.12, 7.63]	6.57 / 2.76 / 5.10	0.0100	主要／Holm
CDCP	T1I1 − NoRisk	0.34	[0.07, 0.63]	0.30 / 0.41 / 0.30	0.0100	主要／Holm
CDCP	SetLocal − Single	0.40	[0.05, 0.78]	0.39 / 0.41 / 0.40	0.0260	探索／原始 p
CDCP	Global − SetLocal	0.32	[0.02, 0.66]	0.30 / 0.39 / 0.29	0.0450	探索／原始 p
CDCP	Global − Single	0.73	[0.24, 1.25]	0.68 / 0.80 / 0.69	0.0040	探索／原始 p
CDCP	T1I1 − ThresholdFilter	2.93	[1.62, 4.31]	2.81 / 2.12 / 3.86	0.0010	探索／原始 p
CDCP	RelationOnly − ThresholdFilter	1.36	[0.31, 2.52]	1.32 / 0.43 / 2.31	0.0140	探索／原始 p
CDCP	T1I1 − MissingLow	0.00	[0.00, 0.00]	0.00 / 0.00 / 0.00	1.0000	探索／原始 p
CDCP	T1I1 − NoCalibration	0.66	[0.06, 1.31]	0.60 / 0.80 / 0.59	0.0330	探索／原始 p

表 4.9 中的 95%置信区间为单项区间，未经多重校正；全文 14 项主要比较统一采用 Holm 校正并全部通过，本节报告其中的 5 组，ThresholdFilter 等对照则作为探索性比较，报告未校正的 p 值。

从消融结果看，推理阶段的增益大部分来自关系选择：仅修改关系已使 AAEC 和 CDCP 的关系 F1 相对 I0 提高 2.20 和 4.11 个百分点，约占完整增益的 65%和 72%。在此基础上，允许修改组件并重建其关系，使关系 F1 再提高 1.18 和 1.57 个百分点（表 4.9，校正 p 值均为 0.0070）；多出的收益一方面来自修正组件边界或类型后多恢复的 23 和 7 条完整关系，另一方面来自删除错误组件时连带清除的 44 和 26 条误边（表 4.13）。

组件与关系的接受方式同样影响修正效果。即使采用先改组件、再改关系的分步方式，关系 F1 也比只修改关系高 0.33 和 0.49 个百分点；在此基础上，

让组件与关系共同接受，又进一步提高了 0.37 和 0.36 个百分点（Holm p 均为 0.0175），说明将组件修改及其受影响关系纳入同一事务进行决策是有效的。

集合动作与全局求解也分别带来了增益。允许拆分与合并后，关系 F1 比单对象共同接受提高 0.25 和 0.40 个百分点，置信区间均不含零，并多恢复 3 和 1 条完整关系、多清除 11 和 6 条误边（表 4.13）；全局求解在此基础上再提高 0.23 和 0.32 个百分点。这一结果与 4.5.2 节的分析相符：局部可达的结果都包含在全局可行域中，因此在固定评分下全局最优解的效用不低于局部结果；但效用只是严格 F1 的代理，全局求解在本实验中取得最高 F1 属于实验观察，而非理论保证。此外，主实验中全部 690 个输入的全局求解都得到了最优解，没有出现超时。

AAEC 测试文档 essay180（种子 17）给出了集合动作发挥作用的一个典型案例。该文档金标中的前提 T11 对应字符区间[1256,1368)“A solid group can be a suited environment, which provides people to improve themselves or broaden their horizons”，它支持论点 T10，同时受到 T12、T13、T14 三个前提的支持。G_0在逗号处把 T11 错误地拆成了c_1=[1256,1297)和c_2=[1299,1368)两个片段，导致c_1→T10、T12→c_2、T13→c_2三条关系都因端点错误而成为 FP，T14→T11 则被漏掉。

在固定评分下，q(c_1)=0.62、q(c_2)=0.66，合并后的组件 b=[1256,1368)得分 q(b)=0.93。此时，单独删除任一片段都会降低组件效用，而插入 b 会因冲突同时删除两个片段，实际构成 2→1 的合并，因此单对象修改无法完成这一修正。

允许拆分与合并的局部搜索和全局求解都接受了这一合并：组件效用增加 0.30；删除 3 条旧关系、重建 b→T10 以及 T12、T13、T14→b 四条关系后，关系效用增加 2.38，组件和关系分别编辑 3 次和 7 次。修正后，组件 TP 增加 1、FP 减少 2，关系 TP 增加 4、FP 减少 3，这正是命题 4-2 所描述的情形，修正前后的结构如图 4.3 所示。

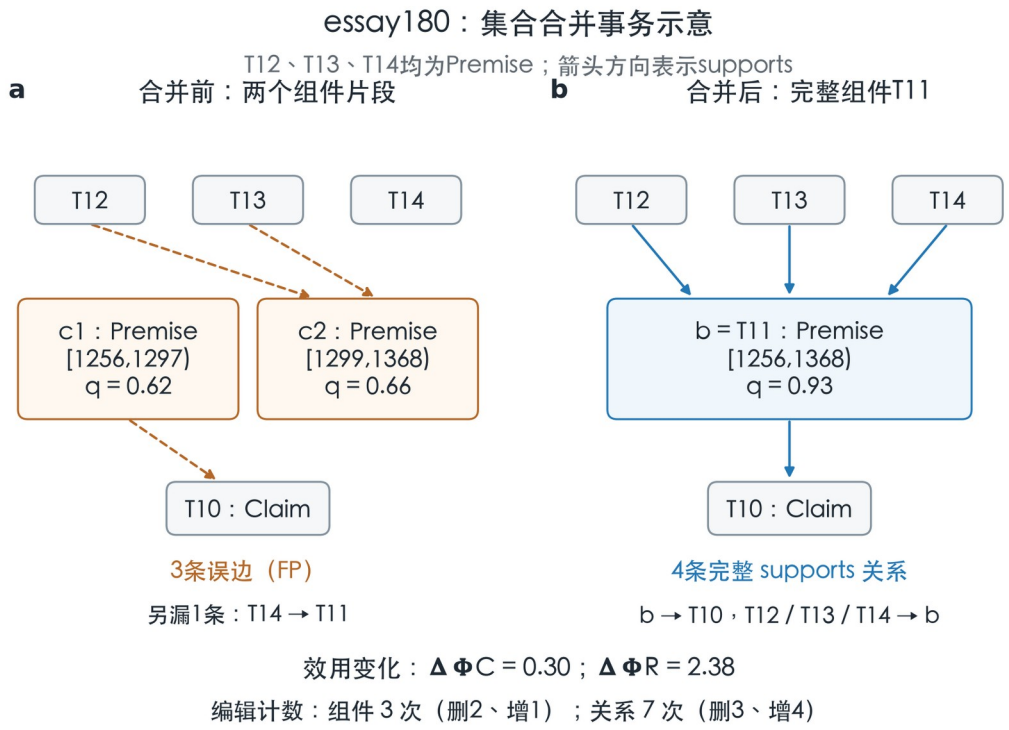


图 4.3 essay180 中组件合并与关系重建示意

注：（a）初始图把 T11 拆成了c_1和c_2，橙色虚线表示三条端点错误的关系，T14→T11 未被输出；（b）合并后，蓝色实线表示 b→T10 以及 T12、T13、T14→b 四条支持关系。

与简单的阈值过滤相比，联合修正在相同候选和评分下仍有明显优势。仅删除低分关系的 ThresholdFilter 已有一定效果，比 I0 提高 1.51 和 2.76 个百分点，但同时误删了 34 和 8 条原本正确的关系（表 4.13）。相比之下，只修改关系就比它高 0.69 和 1.36 个百分点，完整方法 I1 则高 1.88 和 2.93 个百分点。值得注意的是，仅删除低分关系即可获得完整增益的约 45%和 49%，说明固定评分下的关系筛选本身贡献了相当一部分收益，关系补全、组件修改与共同接受则在此基础上带来进一步提升。

与相同预算下的重新生成相比，联合修正的优势更加明显。重新生成的严格关系 F1 为 68.72 和 45.96，I1 分别比它高 2.91 和 4.81 个百分点（Holm p 为 0.0120 和 0.0100）。重新生成虽然恢复了较多关系，但也误删了 471 和 174 条原本正确的关系，原有正确关系的保留率只有 72.71%和 52.97%，而联合修正的保留率都超过 98%。由此可见，在已有预测的基础上进行有约束的局部修改，比完整重新生成更为可靠。需要说明的是，这里的同等资源仅针对推理阶段；联合修正另需交叉拟合训练与评分器训练的一次性成本（表 3.18），重新生成则不需要这部分成本。

接受收益极小的修改会增加误改。将严格改进阈值放宽至接近零后，关系 F1 下降 0.29 和 0.34 个百分点，误删的正确关系由 23 和 4 条增加到 31 和 7 条，F1 下降的文档—种子数由 14 和 3 增加到 17 和 6，开发集上也观察到同样的趋势（表 4.6）。需要指出的是，按表 4.6 的网格，5%的开发集风险筛选并未改变最终选中的配置，因此该对照反映的是阈值 δ 的作用，不能单独归因于风险筛选；即使保留阈值，也不能保证每篇文档都得到改善。此外，本文未单独消融分项效用门与编辑预算，二者对结果的独立作用仍有待检验。

评分校准同样直接影响接受决策。使用未校准的评分时，关系 F1 下降 0.61 和 0.66 个百分点，AAEC 误删的正确关系由 23 条增加到 33 条；而将缺失评分视为低分（MissingLow）时，结果与 I1 完全相同，差值为 0.00，这与主实验中未出现评分缺失的情况一致。4.6.3 节将进一步分析候选覆盖与评分质量。

4.6.3 候选覆盖与评分质量分析

联合修正只能在候选池内选择对象，因此候选覆盖决定了修正所能达到的上限。表 4.10 按候选、评分和选择各环节统计了金标对象的保留情况：AAEC 和 CDCP 中分别有 98.3%和 89.4%的金标关系进入了候选池，其余关系无论如何搜索都无法恢复。在进入候选池的完整关系中，AAEC 和 CDCP 分别有 1793 条和 415 条评分过门，最终 TP 为 1736 和 386，可见进入候选池之后的主要损失发生在评分环节，CDCP 尤为明显。

表 4.10 金标对象在候选、评分和选择各环节的保留情况（三个种子合计）

语料	金标组件	组件入池	金标关系	全部端点入池	完整关系入池	评分过门	过门且端点被选	最终 TP
AAEC	3798	3778	2427	2411	2386	1793	1737	1736
CDCP	3078	3032	756	735	676	415	386	386

表 4.10 的计数单位为文档×种子×对象，AAEC 和 CDCP 的金标组件总数分别为 3798 和 3078，完整关系总数为 2427 和 756。其中，“评分过门”以关系已进入候选池为前提，“端点被选”进一步要求这些关系的全部端点出现在最终图中；最终 TP 按完整对象匹配计算，多前提关系只命中部分源组件不算命中。此外，G_0中的合法对象全部保留在候选池中，CDCP 的补充槽位最多保留 64 个模型提案，总数不超过 256 个。

评分质量决定了接受决策的可靠性。表 4.11 和表 4.12 分别给出了开发集与测试集候选上的评分质量，其中，AUROC 为 ROC 曲线下面积，AP 为平均精确率，ECE 为期望校准误差，先验 Brier 表示按类别先验给出恒定概率时的

Brier 分数；AUROC、AP、Brier 和 ECE 为三个种子的均值，候选数和正例数为三个种子的合计。从结果看，各类对象的 Brier 分数均明显低于先验 Brier，关系评分的 AP 则明显低于组件评分，反映出完整关系正例稀少、判别难度更大；测试集上的评分质量与开发集接近，在这些评分指标上未见明显退化。

表 4.11 开发集候选上的评分质量

语料	用途	对象类别	候选	正例	AUROC	AP	Brier	先验 Brier	ECE10	门限以上候选数	门限以上精确率
AAEC	校准集	组件	3263	1402	0.9059	0.8580	0.0844	0.2450	0.0056	1418	0.887
AAEC	校准集	关系	14290	851	0.8637	0.5743	0.0271	0.0561	0.0040	901	0.719
AAEC	策略集	组件	3069	1323	0.9007	0.8436	0.0844	0.2452	0.0124	1366	0.880
AAEC	策略集	关系	12826	804	0.8788	0.5943	0.0277	0.0588	0.0043	855	0.725
CDCP	校准集	组件	3023	1042	0.8740	0.7753	0.1000	0.2259	0.0092	1031	0.839
CDCP	校准集	关系	6894	270	0.7731	0.4163	0.0258	0.0376	0.0016	297	0.542
CDCP	策略集	组件	3203	1094	0.8863	0.7924	0.0920	0.2249	0.0175	1076	0.856
CDCP	策略集	关系	6906	225	0.8082	0.3794	0.0222	0.0315	0.0059	280	0.500

表 4.12 测试集候选上的评分质量

语料／对象类别	候选 n／正例	AUROC	AP	Brier／先验 Brier	ECE10	门限	门限以上候选数／正确	门限以上精确率／平均评分
AAEC／组件	8800／3778	0.900	0.850	0.0877／0.2450	0.0073	0.5	3811／3368	0.884／0.885
AAEC／关系	42510／2386	0.862	0.557	0.0266／0.0530	0.0034	0.5	2551／1793	0.703／0.707
CDCP／组件	8835／3032	0.883	0.801	0.0904／0.2254	0.0165	0.5	3013／2577	0.855／0.835
CDCP／关系	19222／676	0.801	0.383	0.0240／0.0339	0.0044	0.25	822／415	0.505／0.542

在门限设置上，AAEC 和 CDCP 的关系门限分别为 0.5 和 0.25，组件门限均为 0.5。图 4.4 给出了测试候选的校准曲线：AAEC 关系在高分区仍存在局部过度自信，因此仅依靠评分门限并不足以保证修改正确，接受决策还需同时满足分项效用门和编辑预算。

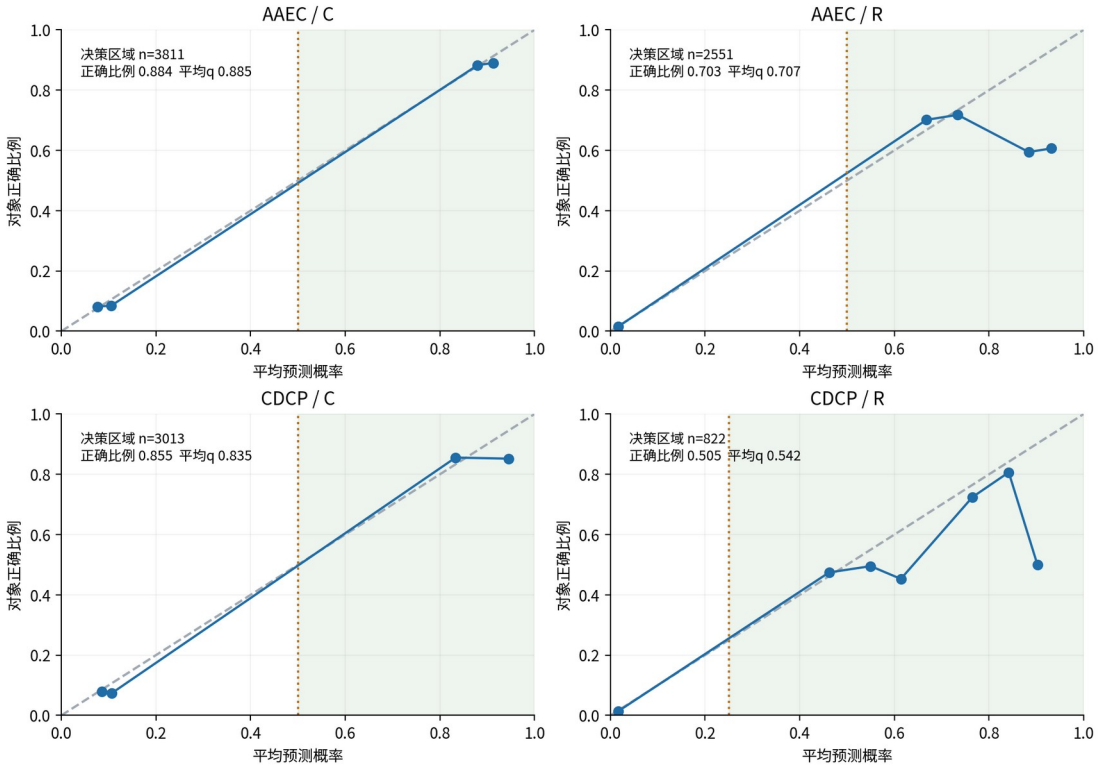


图 4.4 测试候选的校准与决策门限

注：C 和 R 分别表示组件与关系。灰色对角线表示理想校准，橙色线为门限，绿色区域为门限以上的候选；各点之间的连线仅辅助阅读，不代表中间概率区间的样本分布。CDCP 关系最高分箱的样本量为 100。

误改统计进一步表明，联合修正在提升关系 F1 的同时并未带来更多的逐文档退化。如表 4.13 所示，主配置中 F1 下降的文档—种子记录在 AAEC 上为 14/240，在 CDCP 上为 3/450，均不多于其他对照，放宽增益阈值后分别增加到 17/240 和 6/450；相比之下，重新生成在两个语料上分别有 107/240 和 106/450 条记录的 F1 下降。

表 4.13 各配置的误改统计与逐文档影响

语料	配置	原 TP	恢复 TP	误删 TP	删除 FP	新增 FP	原 TP 保留率	F1 下降的文档—种子数／总数
AAEC	T1I1	1726	33	23	230	9	98.67%	14／240
AAEC	RelationOnly	1726	10	18	186	13	98.96%	15／240
AAEC	ThresholdFilter	1726	0	34	173	0	98.03%	24／240
AAEC	Single	1726	27	22	208	11	98.73%	15／240
AAEC	SetLocal	1726	30	22	219	10	98.73%	14／240
AAEC	Sequential	1726	24	23	192	13	98.67%	16／240
AAEC	NoRisk	1726	35	31	228	16	98.20%	17／240
AAEC	NoCalibration	1726	30	33	217	14	98.09%	18／240
AAEC	Regenerate	1726	448	471	884	806	72.71%	107／240

表 4.13 各配置的误改统计与逐文档影响（续表）

语料	配置	原 TP	恢复 TP	误删 TP	删除 FP	新增 FP	原 TP 保留率	F1 下降的文档—种子数／总数
CDCP	T1I1	370	20	4	141	4	98.92%	3／450
CDCP	RelationOnly	370	13	4	115	5	98.92%	5／450
CDCP	ThresholdFilter	370	0	8	120	0	97.84%	8／450
CDCP	Single	370	18	5	128	4	98.65%	4／450
CDCP	SetLocal	370	19	4	134	4	98.92%	3／450
CDCP	Sequential	370	17	5	121	5	98.65%	5／450
CDCP	NoRisk	370	21	7	140	7	98.11%	6／450
CDCP	NoCalibration	370	17	4	131	5	98.92%	4／450
CDCP	Regenerate	370	180	174	440	430	52.97%	106／450

从被接受的修改看，修改范围越完整、接受条件越统一，修改本身越准确。如表 4.14 所示，主配置新增的关系中，AAEC 有 33/42 条正确，CDCP 有 20/24 条正确。从先改组件再改关系、单对象共同接受、允许拆分与合并到完整方法，AAEC 新增关系的精确率依次为 64.86%、71.05%、75.00%和 78.57%，CDCP 由 77.27%升至 83.33%，误删在全部删除中的比例也同步下降。

表 4.14 被接受修改的数量与正确率

语料	方法	提交数	组件增／删	关系增／删	新增关系正确	新增精确率	删除正确关系	误删占全部删除
AAEC	Sequential	156	23／15	37／215	24	64.86%	23	10.70%
AAEC	Single	151	18／24	38／230	27	71.05%	22	9.57%
AAEC	SetLocal	147	24／38	40／241	30	75.00%	22	9.13%
AAEC	T1I1	144	30／47	42／253	33	78.57%	23	9.09%
CDCP	Sequential	141	40／35	22／126	17	77.27%	5	3.97%
CDCP	Single	146	26／41	22／133	18	81.82%	5	3.76%
CDCP	SetLocal	139	29／49	23／138	19	82.61%	4	2.90%
CDCP	T1I1	132	30／52	24／145	20	83.33%	4	2.76%

4.6.4 推理成本分析

联合修正新增的推理开销主要来自对象评分，求解本身的耗时较少。如表 4.15 所示，追加修正使 AAEC 和 CDCP 的平均推理时间分别从 20.11 秒和 28.12 秒增加到 36.08 秒和 50.48 秒，其中对象评分耗时 14.22 秒和 19.71 秒，追加求解只需 0.73 秒和 1.18 秒，在主实验的输入规模下低于集合局部搜索的 1.28 秒和 2.10 秒。相同预算下的重新生成平均耗时为 33.89 秒和 47.50 秒，与联合修正处于同一量级，但其关系 F1 明显较低（见 4.6.2 节）。因此，降低推理成本应优先从评分计算和缓存复用入手。

表 4.15 逐文档推理成本（秒）

语料／方法	生成／重排	合法化	BR-O	追加生成	提案	评分	追加求解	总均值	总 P95
AAEC/T0I0	19.46	0.018	0.63	0.00	0.00	0.00	0.00	20.11	23.60
AAEC/T1I0	19.46	0.018	0.63	0.00	0.00	0.00	0.00	20.11	23.62
AAEC/Single	19.46	0.018	0.63	0.00	1.02	14.22	0.47	35.82	42.09
AAEC/ SetLocal	19.46	0.018	0.63	0.00	1.02	14.22	1.28	36.63	42.72
AAEC/T1I1	19.46	0.018	0.63	0.00	1.02	14.22	0.73	36.08	42.38
AAEC/ Regenerate	19.46	0.018	0.63	13.74	0.00	0.00	0.05	33.89	39.87
CDCP/T0I0	27.05	0.024	1.03	0.00	0.00	0.00	0.00	28.10	33.07
CDCP/T1I0	27.05	0.024	1.04	0.00	0.00	0.00	0.00	28.12	33.08
CDCP/Single	27.05	0.024	1.04	0.00	1.48	19.71	0.75	50.05	58.91
CDCP/ SetLocal	27.05	0.024	1.04	0.00	1.48	19.71	2.10	51.41	60.29
CDCP/T1I1	27.05	0.024	1.04	0.00	1.48	19.71	1.18	50.48	59.39
CDCP/ Regenerate	27.05	0.024	1.04	19.30	0.00	0.00	0.08	47.50	56.02

在资源口径上，完整方法和重新生成都从G_0开始，追加的两次文本处理累计输入不超过 8192 个 token、输出不超过 2048 个 token，端到端时延为各阶段耗时之和。

4.6.5 与第 3 章方法的衔接分析

本章的联合修正以第 3 章所得模型为起点，主要比较为在 T1 训练检查点上追加联合修正（T1I1 相对 T1I0）；由于联合修正只依赖固定的候选与对象评分，它同样可以直接作用于基础方法训练的模型。为说明两项方法如何衔接，本节在同一骨干上比较训练与推理的四种组合，依次考察总体性能与交互、两阶段各自恢复的关系以及剩余漏检的来源。四种组合的含义如下：T0I0 为 MCR-BR 基线；T1I0 采用第 3 章的训练方法，推理沿用 I0；T0I1 采用基线训练，在 I0 给出的初始图G_0上追加本章的联合修正；T1I1 则在第 3 章所得模型上追加联合修正，即本文的完整方法。

不同比较的固定条件与检验目的各不相同：固定推理为 I0 时，T1I0 与 T0I0 在骨干、更新预算和推理流程均相同的条件下比较，反映训练方法对抽取的改善；固定训练为 T1 时，T1I1 与 T1I0 共用同一训练检查点与 I0 终态，仅追加候选、评分与修正规则，反映联合修正在第 3 章模型上带来的增益；固定训练为 T0 时，T0I1 与 T0I0 的比较检验联合修正在基础方法模型上的效果；四种组合在同一测试文档、随机种子和完整对象评价下并列比较，则可用于判断两项增益是相互重叠还是彼此互补。所有组合均采用相同的测试划分、评价规则和三个随机种子，而一致性目标、共同接受、集合动作等具体机制的作用，已分别在 3.5.4 节和 4.6.2 节的对照实验中分析，本节不再重复。

（1）总体性能与交互分析。两项方法组合后，完整配置在两个语料上均取得四种组合中最高的组件 F1 与严格关系 F1。表 4.16 给出四种组合的组件 F1 和关系 F1，“±”后为三个种子的样本标准差。

表 4.16 两阶段配置的组件与关系抽取性能

配置	AAEC 组件 F1	AAEC 关系 F1	CDCP 组件 F1	CDCP 关系 F1
T0I0	85.64 ± 0.07	65.69 ± 3.50	80.40 ± 1.24	41.79 ± 2.65
T1I0	87.85 ± 0.39	68.25 ± 2.08	83.46 ± 1.04	45.08 ± 2.73
T0I1	86.50 ± 0.15	69.43 ± 3.41	81.67 ± 1.12	47.69 ± 2.47
T1I1	88.47 ± 0.46	71.63 ± 2.11	84.45 ± 0.94	50.77 ± 2.45

如表 4.16 所示，在 Qwen3.5-9B 骨干下，T1I1 的关系 F1 分别为 71.63 和 50.77，比 T0I0 基线的 65.69 和 41.79 分别高 5.94 和 8.98 个百分点；T1I0 与 T0I1 的组件 F1 和关系 F1 均介于二者之间，说明两项方法单独使用时都能改善抽取结果，组合后仍有进一步提升。

为进一步区分训练增益、推理增益及二者的交互，表 4.17 列出各项比较的平均配对差值、95%置信区间以及三个种子各自的差值。由于均值与差值均先由未舍入的逐种子结果计算、再保留两位小数，表 4.16 中均值直接相减的结果可能与表 4.17 相差 0.01 个百分点，分析以表 4.17 为准。

表 4.17 四种配置的关系 F1 差值与交互

语料	比较	差值（百分点）	单项 95% CI	三个种子差值	类型
AAEC	T1I0 − T0I0	2.56	[0.92, 4.39]	1.26 / 2.34 / 4.07	主要
AAEC	T1I1 − T1I0	3.38	[2.56, 4.23]	3.30 / 3.54 / 3.31	主要
AAEC	T0I1 − T0I0	3.74	[2.82, 4.69]	3.58 / 3.84 / 3.78	探索
AAEC	T1I1 − T0I0	5.94	[4.01, 7.88]	4.56 / 5.88 / 7.38	探索
AAEC	交互项	-0.35	[-0.85, 0.03]	-0.27 / -0.30 / -0.48	探索
CDCP	T1I0 − T0I0	3.30	[1.56, 5.17]	2.81 / 3.50 / 3.58	主要
CDCP	T1I1 − T1I0	5.68	[4.03, 7.47]	5.40 / 5.40 / 6.24	主要
CDCP	T0I1 − T0I0	5.91	[4.21, 7.75]	5.59 / 5.80 / 6.33	探索
CDCP	T1I1 − T0I0	8.98	[6.56, 11.66]	8.21 / 8.91 / 9.82	探索
CDCP	交互项	-0.22	[-0.95, 0.35]	-0.18 / -0.40 / -0.08	探索

表 4.17 中标为“主要”的两项比较已分别在 3.5.4 节和 4.6.2 节通过 Holm 校正，即训练方法相对 T0I0、联合修正相对 T1I0 均带来显著增益；标为“探索”的比较报告单项置信区间，用于进一步检验联合修正在基础方法模型上的效果以及两项增益之间的交互。其中，T0I1 相对 T0I0 的差值为 3.74 和 5.91 个百分点，95%置信区间分别为[2.82, 4.69]和[4.21, 7.75]，表明联合修正在基础方法的模型上同样有效。

两项方法的组合增益接近两项单独增益之和，交互项的置信区间在两个语料上均包含零，即未检出显著交互。交互项定义为(T1I1−T1I0)−(T0I1−T0I0)，AAEC 上的估计值为-0.35 个百分点（95%置信区间[-0.85, 0.03]），CDCP 上为-0.22 个百分点（[-0.95, 0.35]），组合增益接近两项单独增益之和。不过，

AAEC 上三个种子的交互项均为负，联合修正在 T1 模型上带来的 3.38 和 5.68 个百分点也略低于其在 T0 模型上的 3.74 和 5.91 个百分点，说明两项方法的作用存在轻微重叠，但第 3 章的训练改进并未明显削弱联合修正的增益。图 4.5 展示了四种组合的总体表现。

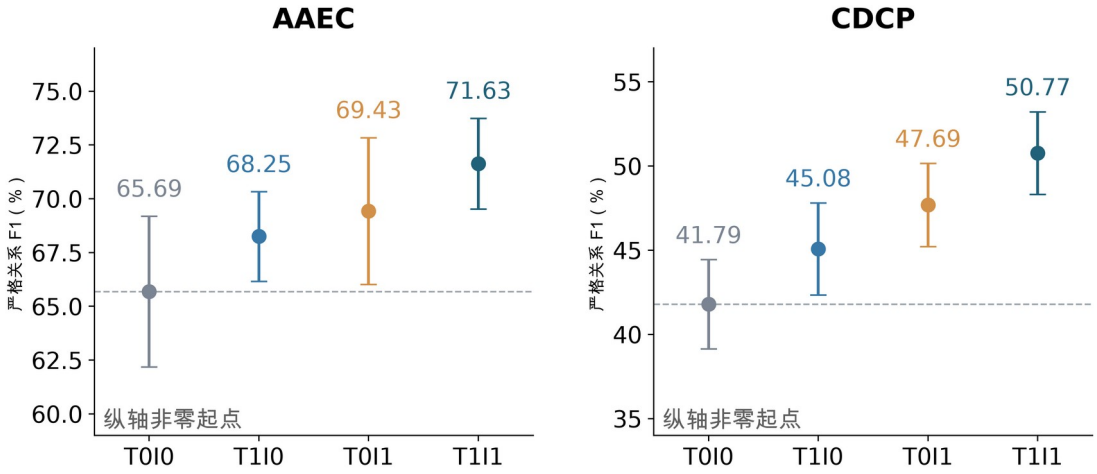


图 4.5 两种语料上四种配置的关系 F1（误差棒为三个种子的样本标准差；纵轴非零起点）

（2）两阶段恢复关系的对比。关系 F1 的变化同时来自恢复正确关系、减少误报以及丢失原有正确关系三个方面，为明确两项方法各自贡献了哪些关系，下面先比较两阶段分别恢复的关系，再从端点与关系选择两个层面分析漏检的原因。

表 4.18 以 T0I0 中预测正确的关系为基准，在每个种子内按关系的完整身份（文档、源集合、目标和标签）比对两种单独配置与完整配置中新增的 TP，从而区分两阶段共同恢复、各自独有恢复以及组合后才恢复的关系，表中计数为三个种子的合计。

表 4.18 两阶段恢复关系的分解（三个种子合计）

语料	初始 TP	共同恢复	训练独有	修正独有	组合独有	单阶段恢复后在组合中丢失	丢失初始 TP	完整 TP
AAEC	1658	6	82	31	1	1	41	1736
CDCP	343	2	28	20	0	0	7	386

表中，“共同恢复”为 T1I0 与 T0I1 相对 T0I0 新增 TP 的交集，“训练独有”和“修正独有”分别为二者的差集，“组合独有”为仅在 T1I1 中新增的 TP；由于完整配置也可能丢失单独配置恢复的关系或初始 TP，各项满足：初始 TP＋共同恢复＋训练独有＋修正独有＋组合独有−丢失单路恢复−丢失初始 TP＝完整 TP。

两阶段恢复的关系几乎没有重叠，表明两项方法在恢复对象上具有互补性：AAEC 上，训练独有与修正独有的关系分别为 82 条和 31 条，而共同恢复的仅有 6 条，组合独有 1 条；CDCP 上相应为 28、20、2 和 0 条。

与此同时，完整配置也会丢失少量正确关系，AAEC 丢失单路恢复的关系 1 条、初始 TP 41 条，CDCP 分别为 0 条和 7 条，但与恢复的关系数量相比要少得多。

（3）漏检原因分析。一条完整关系得以恢复的前提是其正确端点全部出现在最终图中，据此，表 4.19 将未命中的金标关系分为两类：“端点缺失”指最终图中缺少该关系所需的组件，“端点齐全但未选”指正确端点均已存在，但该关系未被选中。

表 4.19 四种配置下未命中关系的分类

语料	配置	金标	TP	端点缺失	端点齐全但未选
AAEC	T0I0	2427	1658	637	132
AAEC	T1I0	2427	1726	546	155
AAEC	T0I1	2427	1673	601	153
AAEC	T1I1	2427	1736	517	174
CDCP	T0I0	756	343	294	119
CDCP	T1I0	756	370	260	126
CDCP	T0I1	756	361	283	112
CDCP	T1I1	756	386	251	119

端点缺失类漏检随两个阶段逐级减少，但端点齐全后仍有部分关系未被选中。第 3 章的训练方法使 AAEC 和 CDCP 中端点缺失的关系分别从 T0I0 的 637 条和 294 条减少到 T1I0 的 546 条和 260 条，联合修正在此基础上进一步减少到 T1I1 的 517 条和 251 条；与此同时，AAEC 中端点齐全但未选的关系从 132 条增加到 174 条，CDCP 中则保持 119 条不变。由于整体 F1 还受误报变化的影响，4.6.6 节的表 4.22 将进一步按源组件数报告各组关系的 TP、FP 和 FN。

为定位完整配置中漏检发生的具体环节，表 4.20 进一步将 T1I1 中的每条未命中关系归入其遇到的第一个阻断环节（每条只归一次），各环节依次为：最

终图中端点缺失、候选槽位未入池、未评分、评分未过门、受联合约束或接受门限制以及超时。

表 4.20 T1I1 未命中关系的首个阻断环节

语料	金标	TP	终态端点缺失	完整槽位未入池	未评分	评分未过门	联合约束／接受门	超时
AAEC	2427	1736	517	6	0	167	1	0
CDCP	756	386	251	5	0	114	0	0

由表 4.20 可见，未命中的关系主要集中在“端点缺失”和“评分未过门”两个环节，AAEC 上分别为 517 条和 167 条，CDCP 上分别为 251 条和 114 条；相比之下，槽位未入池的仅有 6 条和 5 条，受约束或接受门限制的仅有 AAEC 的 1 条，未评分与超时均为 0。由此可见，进一步提升的重点在于组件识别与关系评分，候选构建与求解环节造成的漏检很少。

4.6.6 多前提关系分析

CDCP 中的多前提关系要求完整的源集合、目标和标签同时匹配，其完整命中的难度明显高于单源关系。如表 4.21 所示，在 CDCP 训练文档 00662 中，两个价值组件分别表达偏好电子邮件与无法确认邮件是否送达，二者共同支持一个政策组件，因而被标注为一条双源理由关系；评价时只有同时匹配完整的源集合、目标和标签才算命中，仅预测其中任一条单源关系均无法命中该关系。

表 4.21 CDCP 文档 00662 中的一条双源理由关系

对象	标注类型	字符跨度	数据集原文
源 1	价值	[0,53)	I generally prefer e-mail to telephone communication,
源 2	价值	[54,110)	but you can't be sure the e-mail has reached the person.
目标	政策	[111,222)	I would suggest a notice that says, "If you don't acknowledge receipt of this e-mail, we'll start phoning you."

由上例可见，源组件越多，完整命中所需同时恢复的端点就越多，因此本节按源组件数分组考察四种组合的结果。CDCP 测试集共有 252 条关系，其中单源 218 条、双源 20 条、三源 6 条、四源及以上 8 条，多源关系共 34 条；表

4.22 按源组件数分组汇总了四种组合的结果，其中 TP、FP 和 FN 为三个种子的合计，关系 F1 及其标准差由逐种子结果计算。

表 4.22 CDCP 按源组件数分组的结果

源数	配置	TP	FP	FN	关系 F1（均值 ± SD）
1	T0I0	309	494	345	42.41 ± 1.37
1	T1I0	335	468	319	45.98 ± 1.72
1	T0I1	325	361	329	48.49 ± 1.60
1	T1I1	349	342	305	51.88 ± 1.73
2	T0I0	24	27	36	42.88 ± 12.04
2	T1I0	25	26	35	44.73 ± 11.54
2	T0I1	24	19	36	45.94 ± 10.64
2	T1I1	25	19	35	47.63 ± 11.56
3	T0I0	8	7	10	47.58 ± 26.45
3	T1I0	8	7	10	47.58 ± 26.45
3	T0I1	8	6	10	48.32 ± 25.29
3	T1I1	8	6	10	48.32 ± 25.29
≥4	T0I0	2	14	22	10.82 ± 9.57
≥4	T1I0	2	14	22	10.82 ± 9.57
≥4	T0I1	4	10	20	21.37 ± 10.36
≥4	T1I1	4	11	20	21.65 ± 12.75

完整配置的 TP 净增主要来自单源关系，多源关系的 TP 增加很少，其 F1 的提高有相当一部分来自误报的减少。相对基线，T1I1 在单源关系上增加 40 条 TP，在双源、三源和四源及以上关系上分别仅增加 1、0 和 2 条，单源组的 FP 则从 494 条减少到 342 条。四源及以上的关系仅有 8 条，T1I1 中的计数为 TP=4、FP=11、FN=20，数量过少，只能作描述性分析。

综合上述分析，长源关系的困难可分为对象表达、正确端点恢复与关系选择三个环节，任一环节出错都会使整条关系无法完整命中。以上分析均基于 Qwen3.5-9B 骨干，4.6.7 节进一步考察方法在其他骨干上的表现。

4.6.7 不同骨干模型上的结果

为检验两项方法在不同骨干上的适用性，本节在三种骨干上重复四种组合的实验，三者分工各不相同：Qwen3.5-9B 用于主实验、完整消融和错误分析，Qwen3.5-4B 用于考察同系列的较小模型，Qwen2.5-7B-Instruct 则用于与已有生

成式方法衔接。三种骨干使用相同的数据划分、随机种子和预测协议，并共用9B模型生成和审核的增强数据；抽取生成器、对象评分器、源组提案器、OOF校准和开发集策略则在各骨干上分别训练和选择。

三种骨干的结构和可训练参数量如表4.23所示。Qwen3.5-9B和4B均为32层，包括8个门控全注意力块和24个线性注意力块，隐藏维度分别为4096和2560；Qwen2.5-7B为28层分组查询注意力（Grouped-Query Attention，GQA）[97]结构，隐藏维度为3584。

表4.23 各骨干适配参数（rank固定为16）

骨干	隐藏维	全注意力块	每分支LoRA	T0可训练	T1/AAEC	T1/CDCP
Qwen3.5-9B	4096	8	3,932,160	7,884,801	28,871,687	28,873,737
Qwen3.5-4B	2560	8	3,145,728	6,304,257	19,426,823	19,428,873
Qwen2.5-7B-Instruct	3584	28	10,092,544	20,203,009	38,568,455	38,570,505

由于Qwen3.5骨干仅在8个全注意力块上挂载LoRA，而Qwen2.5在全部28个注意力块上挂载，在rank相同时，Qwen2.5的LoRA参数量反而高于9B。训练轮数、批量大小、增强数据和编辑预算在各骨干间保持一致，各模块的输入维度见4.3.1节。

表4.24 补充骨干的四种组合结果（均值 ± SD）

骨干	组合	AAEC组件	AAEC关系	CDCP组件	CDCP关系
Qwen3.5-4B	T0I0	84.15 ± 0.35	63.43 ± 4.03	78.59 ± 1.35	38.42 ± 2.44
Qwen3.5-4B	T1I0	86.54 ± 0.25	66.65 ± 2.22	81.91 ± 1.09	43.08 ± 3.58
Qwen3.5-4B	T0I1	84.97 ± 0.13	67.05 ± 3.80	79.98 ± 1.16	44.29 ± 2.04
Qwen3.5-4B	T1I1	87.24 ± 0.49	70.07 ± 2.15	83.00 ± 0.91	49.03 ± 3.46
Qwen2.5-7B-Instruct	T0I0	82.62 ± 0.51	61.08 ± 4.58	76.39 ± 1.81	34.87 ± 2.18
Qwen2.5-7B-Instruct	T1I0	85.14 ± 0.20	64.60 ± 2.98	80.43 ± 1.29	40.69 ± 2.31
Qwen2.5-7B-Instruct	T0I1	83.50 ± 0.26	64.38 ± 4.36	77.65 ± 1.25	40.32 ± 1.66
Qwen2.5-7B-Instruct	T1I1	85.94 ± 0.24	67.96 ± 2.70	81.25 ± 0.91	46.43 ± 2.16

如表 4.24 所示，两项方法在三种骨干上均带来稳定的提升，且基线越强，提升幅度略小。Qwen3.5-9B 的基线和完整配置均为三者中最高（结果见表 4.16），完整配置相对同骨干基线的关系 F1 提升为 5.94 和 8.98 个百分点；Qwen3.5-4B 上为 6.64 和 10.61 个百分点，Qwen2.5-7B-Instruct 上为 6.88 和 11.56 个百分点。

表 4.25 补充骨干上的配对差值与显著性

骨干	语料	比较	差值（百分点）	单项 95% CI	补充 Holm p
Qwen3.5-4B	AAEC	T1I0−T0I0	3.22	[1.05, 5.41]	0.0070
Qwen3.5-4B	AAEC	T1I1−T1I0	3.42	[2.49, 4.35]	0.0060
Qwen3.5-4B	AAEC	T1I1−T0I0	6.64	[4.14, 8.93]	0.0060
Qwen3.5-4B	CDCP	T1I0−T0I0	4.66	[2.64, 7.03]	0.0060
Qwen3.5-4B	CDCP	T1I1−T1I0	5.95	[4.23, 7.80]	0.0060
Qwen3.5-4B	CDCP	T1I1−T0I0	10.61	[7.90, 13.36]	0.0060
Qwen2.5-7B-Instruct	AAEC	T1I0−T0I0	3.52	[1.33, 5.59]	0.0070
Qwen2.5-7B-Instruct	AAEC	T1I1−T1I0	3.36	[2.31, 4.40]	0.0060
Qwen2.5-7B-Instruct	AAEC	T1I1−T0I0	6.88	[4.27, 9.32]	0.0060
Qwen2.5-7B-Instruct	CDCP	T1I0−T0I0	5.82	[3.68, 8.14]	0.0060
Qwen2.5-7B-Instruct	CDCP	T1I1−T1I0	5.74	[3.94, 7.65]	0.0060
Qwen2.5-7B-Instruct	CDCP	T1I1−T0I0	11.56	[8.73, 14.35]	0.0060

上述提升在补充骨干上同样通过了统计检验。补充骨干的比较共 12 项（2 种骨干×2 个语料×3 项比较），使用与主实验相同的重采样索引，并在主要比较之外单独进行 Holm 校正；如表 4.25 所示，所有增量均为正，校正后的 p 值均低于 0.05，即在两种补充骨干上，T1I0 相对 T0I0、T1I1 相对 T1I0 以及 T1I1 相对 T0I0 的提升均显著。

4.6.8 与外部系统及已发表结果的比较

（1）与外部系统的比较。为在相同条件下比较不同的任务建模方式，本节以 UniASA[15]和 TextToText[4]为外部对照，在 Qwen3.5-9B 骨干上重新训练这两

种方法：二者保留各自的模型结构和训练目标，但使用与本文相同的官方测试划分和严格评价器。

在格式转换上，AAEC 预测的立场作为组件属性保留，字符跨度和组件类型按预测结果转换，无法解析的端点不借助金标补回；CDCP 统一使用排序后的源集合，但本文实现的外部适配接口最多表示 3 个源组件，而测试集 252 条关系中有 8 条包含四个及以上源组件，对此，源集合收缩后的预测按严格匹配计 FP，未匹配的完整金标计 FN，不展开为二元真阳性。

外部对照同样使用三个随机种子；由于各方法的任务建模不同，这组比较属于系统层面的比较，单独作为探索性结果报告。表 4.26 给出完整结果，表 4.27 给出配对差值。

表 4.26 与外部系统的比较（相同骨干与评价器）

语料	系统	组件 F1	关系 F1	关系 F1：17 / 29 / 43
AAEC	UniASA	84.91 ± 0.38	64.89 ± 3.32	67.81 / 65.59 / 61.28
AAEC	TextToText	84.07 ± 0.48	63.19 ± 3.12	66.51 / 62.75 / 60.31
AAEC	T0I0	85.64 ± 0.07	65.69 ± 3.50	68.76 / 66.43 / 61.89
AAEC	T1I1	88.47 ± 0.46	71.63 ± 2.11	73.32 / 72.31 / 69.26
CDCP	UniASA	78.82 ± 1.50	40.36 ± 2.36	40.45 / 42.68 / 37.96
CDCP	TextToText	77.18 ± 1.81	38.89 ± 1.18	38.73 / 40.14 / 37.80
CDCP	T0I0	80.40 ± 1.24	41.79 ± 2.65	41.19 / 44.68 / 39.49
CDCP	T1I1	84.45 ± 0.94	50.77 ± 2.45	49.40 / 53.59 / 49.31

表 4.27 T1I1 相对外部系统的关系 F1 差值

语料	比较	差值（百分点）	单项 95% CI	原始 p
AAEC	T1I1 − UniASA	6.74	[4.69, 8.75]	0.0005
AAEC	T1I1 − TextToText	8.44	[6.11, 10.84]	0.0005
CDCP	T1I1 − UniASA	10.41	[7.33, 13.39]	0.0005
CDCP	T1I1 − TextToText	11.87	[8.34, 15.11]	0.0005

如表 4.26 所示，在相同骨干和评价器下，本文完整方法的严格关系 F1 在两个语料上均明显高于两种外部方法，AAEC 上分别高出 6.74 和 8.44 个百分点，CDCP 上分别高出 10.41 和 11.87 个百分点（表 4.27）；T0I0 基线也已高于两种外部方法，说明这一差距既来自基础方法，也来自两项改进。

（2）与已发表结果的比较。表 4.28 列出 AAEC 和 CDCP 上代表性端到端方法的文献报告值以及本文完整方法的结果，其中 MCR-BR[56]是本文的基础方

法，原文使用 Qwen2.5-7B-Instruct 骨干。文献中的数值采用各自的评价协议，而本文结果采用 3.5.1 节定义的严格评价，因此该表仅作为背景参照。

表 4.28 已发表方法的报告结果与本文结果

方法	骨干	AAEC 输入单位	AAEC 组件 F1	AAEC 关系 F1	CDCP 组件 F1	CDCP 关系 F1
LSTM-ER[3]	BiLSTM[98]	段落	70.83	45.52	—	—
GMAM[14]	BART-base[66]	段落	75.94	50.08	57.72	16.57
DENIM[20]	BART-base[66]	段落	76.50	58.51	—	—
ST[23]	Longformer-base[99]	全文	75.54	55.17	68.90	31.94
MT-All[23]	Longformer-base[99]	全文	75.66	55.17	68.81	33.74
TextToText[4]	FLAN-T5-XXL[100]	全文	80.15	61.19	72.68	33.96
UniASA[15]	LongT5-base[101]／T5-base[67]	全文	77.60	56.33	68.16	30.57
UniASA[15]	Llama-3-8B[102]	全文	79.70	59.34	70.83	35.58
AASP[16]	Flan-T5-Large[100]	段落†	79.29	62.69	62.14	35.77
MCR-BR[56]	Qwen2.5-7B-Instruct	未单列‡	83.71	64.83	76.45	38.17
本文 T1I1	Qwen2.5-7B-Instruct	全文	85.94 ± 0.24	67.96 ± 2.70	81.25 ± 0.91	46.43 ± 2.16
本文 T1I1	Qwen3.5-9B	全文	88.47 ± 0.46	71.63 ± 2.11	84.45 ± 0.94	50.77 ± 2.45

注：Morio 等人[23]的 ST 和 MT-All 取原文表 4 中不使用 oracle 跨度的结果；原文表 5 另按 Eger 等人的评价脚本报告了 ST，AAEC 全文级为 76.55/54.66，段落级为 76.48/59.55。Kawarada 等人[4]取表 4 的全文级结果 80.15/61.19（段落级为 78.40/61.87），CDCP 取表 6。†AASP[16]取表 I 的 ACC 与 ARC 列，为段落级输入。‡MCR-BR 沿用 Kawarada 等人的划分和评价脚本。各文献对 AAEC 立场和关系匹配的处理方式不同。

评价协议对数值影响很大。本文将 AAEC 的立场作为组件属性，CDCP 则按完整源集合、目标和标签匹配；在 Qwen2.5-7B-Instruct 上，按 MCR-BR 原协议复现的关系 F1 为 64.77 和 38.08，与其报告值 64.83 和 38.17 基本一致，而在本文的严格协议下，同一模型仅为 61.08 和 34.87。由此可见，本文结果与文献数值的比较需考虑协议差异；在严格协议下，本文完整方法在同一骨干上仍比 MCR-BR 提高 6.88 和 11.56 个百分点（表 4.24）。

4.7 本章小结

本章针对推理阶段组件一旦修改、以其为端点的关系随之失效的问题，提出了基于结构约束的论辩图联合修正方法。首先，在固定的候选空间上训练完整对象评分器，并基于校准概率定义可分解的计数效用；然后，将组件修改与全部受影响关系的重建组织为不可拆分的依赖闭合事务，通过分项效用门和编辑预算决定是否接受；最后，给出全局整数规划和集合局部搜索两种求解方式，并分析了二者的性质与适用条件。实验结果表明，在固定训练配置时，追加联合修正使严格关系 F1 在 AAEC 和 CDCP 上分别提高 3.38 和 5.68 个百分点，其中仅修改关系已带来 2.20 和 4.11 个百分点；与只修改关系相比，允许修改组件并完整重建关系带来 1.18 和 1.57 个百分点的提升，组件与关系共同接受、集合动作和全局求解也都带来了额外增益；与相同预算的重新生成相比，该方法在大幅提高 F1 的同时保留了 98%以上的原有正确关系。

进一步地，衔接分析表明，联合修正在第 3 章所得模型上继续带来增益，在基础方法的模型上同样有效，且两项方法的组合增益接近两项单独增益之和；完整方法相对同骨干的 MCR-BR 基线将严格关系 F1 分别提高 5.94 和 8.98 个百分点，交互项的置信区间均包含零，两阶段恢复的关系几乎不重叠。在其他两种骨干上，完整配置相对同骨干基线的提升同样在补充 Holm 校正后显著；在相同骨干和评价器下，其严格关系 F1 也明显高于两种外部系统。该方法目前的局限在于：对象评分带来额外的推理时间，少数文档仍出现误改，剩余漏检主要来自组件端点缺失和关系评分未过门，长源关系还受到接口表达能力的限制；此外，分项效用门与编辑预算的独立作用尚未经消融检验。

第 5 章将对全文工作进行总结，并结合上述局限讨论后续研究方向。

第 5 章 总结与展望

本章总结全文的研究工作与主要结论，分析方法存在的局限，并展望后续值得深入的研究方向。

5.1 全文工作总结

论辩挖掘旨在从文本中识别论辩组件及组件之间的支持与攻击关系，基于大语言模型的生成式方法能够从原始文本统一生成完整的论辩结构，为端到端论辩挖掘提供了新的技术路径。然而，组件与关系之间的相互依赖仍给模型的训练与推理带来困难：训练阶段，局部改写可能使原标注失效，现有数据增强方法直接继承原标注会引入错误监督；推理阶段，组件一旦被修改，以其为端点的关系随之失效，单独修正组件或关系难以得到一致的论辩图。针对上述问题，本文以 MCR-BR 为基础方法，按照从训练到推理的顺序开展两项递进的研究：第一项工作在训练阶段判断改写后哪些监督仍然可靠，以改进模型的学习信号；第二项工作以第一项工作所得模型为起点，对其预测中残余的结构错误进行组件与关系的联合决策。具体工作如下：

（1）可靠监督与一致性学习方法。针对数据增强中局部改写可能使原标注失效的问题，本文提出了可靠监督与一致性学习方法。该方法通过关系影响域确定每处改写可能影响的组件与关系范围，将原标注迁移到改写文本上，并逐项审核哪些组件和关系仍然可靠；训练时，原文提供完整的论辩图监督，改写文本仅在可靠因素上提供辅助监督并参与一致性约束。实验结果表明，该方法使 AAEC 和 CDCP 上的严格关系 F1 分别提高 2.56 和 3.30 个百分点，其中一致性目标本身贡献了 1.39 和 2.57 个百分点，代价是训练时间分别增加 2.67 和 4.52 GPU 小时；人工分层审核显示，被接受关系因素的加权不安全率估计为 0.81% 和 0.91%；在不施加一致性约束时，可靠因素构造与 QOS 式增强的 F1 差异不显著，审核的价值主要体现在降低错误监督。

（2）结构约束联合修正方法。在第一项工作的基础上，针对模型预测中残余的组件错误会使关联关系失效的问题，本文进一步提出了结构约束联合修正方法。该方法将组件修改与受影响关系的重建组织为同一个依赖闭合事务，在固定评分下通过分项效用门和编辑预算决定是否接受，并提供全局整数规划与集合局部搜索两种求解方式。实验结果表明，在第一项工作所得模型上追加联合修正，严格关系 F1 进一步提高 3.38 和 5.68 个百分点，其中大部分来自关系选择，允许修改组件并完整重建关系、组件与关系共同接受、集合动作和全局

求解在此基础上带来了额外增益；与相同预算的重新生成相比，该方法在提高 F1 的同时保留了 98%以上的原有正确关系，直接作用于基础方法的模型时也使严格关系 F1 提高 3.74 和 5.91 个百分点。

两项工作依次衔接后，以 Qwen3.5-9B 为骨干的完整方法在 AAEC 和 CDCP 上取得 71.63 和 50.77 的严格关系 F1，比同骨干的 MCR-BR 基线分别提高 5.94 和 8.98 个百分点，全文 14 项主要比较均通过 Holm 校正；在 Qwen3.5-4B 和 Qwen2.5-7B-Instruct 上，方法同样带来了显著提升。逐条关系的分析表明，两阶段恢复的关系几乎不重叠，组合增益接近两项单独增益之和，说明训练阶段改进学习信号与推理阶段修正残余结构错误在作用对象上相互补充、逐级推进。与 QOS 直接继承改写前标注的做法相比，本文显式审核受影响的关系因素；与 MCR-BR 已有的多候选重排序和有界修改相比，本文新增的是可靠因素上的一致性学习以及组件与关系的依赖闭合联合决策。

综上所述，本文先改进训练监督、再修正推理结构，逐步处理端到端论辩挖掘中组件与关系之间的依赖，在所考察的两个英文语料和三个 Qwen 系列骨干上均取得了显著提升，表明可靠因素上的一致性学习与组件—关系联合修正能够提升基于大语言模型的论辩结构预测性能。

5.2 未来工作展望

本文围绕组件与关系之间的依赖，从训练与推理两个阶段改进了基于大语言模型的端到端论辩挖掘方法，但方法仍存在以下局限。第一，代理效用与严格 F1 并不完全一致，主配置中仍有少数文档的 F1 下降（AAEC 为 14/240，CDCP 为 3/450 个文档—种子记录），同时对象评分和搜索增加了推理时间；第二，方法的效果依赖评分质量，使用未校准的评分时，关系 F1 下降 0.61 和 0.66 个百分点，而若评分质量不足以通过开发集筛选，推理阶段将不执行修正，也就无法带来增益。

第三，实验仅使用三个随机种子，且 CDCP 中长源关系的测试样本较少，相关的细粒度结论仍需更多数据验证；第四，本文仅在 AAEC 和 CDCP 两个英文语料上进行评价，方法在跨语言和跨领域场景中的效果还有待检验；第五，三种骨干均来自 Qwen 系列，其他模型家族上的效果尚未验证，第 4 章的分项效用门与编辑预算也尚未单独消融。

基于上述局限，未来可从以下几个方面开展研究：

（1）深入分析一致性学习的作用机理：当前实验验证了一致性目标带来的性能增益，但尚未分析一致性约束如何影响对应因素的表示和预测分布。未来可考察可靠因素在原文与改写视图中的表示与分布变化，从而为增强样本的选择和一致性约束的设计提供更明确的依据。

（2）提升推理修正的覆盖范围与可靠性：未来可改进多前提关系的源组件提案，扩充长源关系的测试样本，并针对代理效用上升而 F1 下降的情况研究更好的代价敏感校准；同时，可探索更低成本的评分方法和更大的拆分、合并邻域，在降低推理开销的同时扩大可修正的错误范围。

（3）将联合修正推广到其他结构化抽取任务：第 4 章的联合修正以有限对象及其依赖关系为处理单位，而联合实体关系抽取、事件论元抽取等任务的输出同样由有限对象及其关系构成。未来可在这些任务中重新定义对象、依赖与任务约束，并在真实数据上验证依赖闭合事务与分项效用门的适用性。

（4）检验方法的跨语言与跨领域迁移能力：本文实验局限于两个英文语料，未来可在新领域和其他语言的论辩语料上检验方法的迁移能力，并分析改写审核与对象评分在不同语言和文体中的适用条件。

参考文献

[1] LAWRENCE J, REED C. Argument mining: A survey[J]. Computational Linguistics, 2019, 45(4): 765–818. DOI: 10.1162/coli_a_00364.

[2] STAB C, GUREVYCH I. Parsing argumentation structures in persuasive essays[J]. Computational Linguistics, 2017, 43(3): 619–659. DOI: 10.1162/COLI_a_00295.

[3] EGER S, DAXENBERGER J, GUREVYCH I. Neural end-to-end learning for computational argumentation mining[C]//Proceedings of the 55th Annual Meeting of the Association for Computational Linguistics, Volume 1. Vancouver: Association for Computational Linguistics, 2017: 11–22. DOI: 10.18653/v1/P17-1002.

[4] KAWARADA M, HIRAO T, UCHIDA W, et al. Argument mining as a text-to-text generation task[C]//Proceedings of the 18th Conference of the European Chapter of the Association for Computational Linguistics, Volume 1. St. Julian's: Association for Computational Linguistics, 2024: 2002–2014. DOI: 10.18653/v1/2024.eacl-long.121.

[5] DING B, QIN C, ZHAO R, et al. Data augmentation using LLMs: Data perspectives, learning paradigms and challenges[C]//Findings of the Association for Computational Linguistics: ACL 2024. Bangkok: Association for Computational Linguistics, 2024: 1679–1705. DOI: 10.18653/v1/2024.findings-acl.97.

[6] BAO J, HUANG Y, SUN Y, et al. Exploring quality and diversity in synthetic data generation for argument mining[C]//Proceedings of the 2025 Conference on Empirical Methods in Natural Language Processing. Suzhou: Association for Computational Linguistics, 2025: 26581–26604. DOI: 10.18653/v1/2025.emnlp-main.1351.

[7] 李永泽, 欧石燕. 论辩挖掘研究综述[J]. 图书情报工作, 2020, 64(19): 128-139. DOI:10.13266/j.issn.0252-3116.2020.19.014.

[8] 魏忠钰, 丁佳玓, 沈晨晨, 等. 对话式论辩研究综述[J]. 中文信息学报, 2023, 37(10): 108-121.

[9] STAB C, GUREVYCH I. Identifying Argumentative Discourse Structures in Persuasive Essays[C]//Proceedings of the 2014 Conference on Empirical Methods in Natural Language Processing (EMNLP). Doha, Qatar: Association for Computational Linguistics, 2014: 46-56. DOI:10.3115/v1/D14-1006.

[10] PERSING I, NG V. End-to-End Argumentation Mining in Student Essays[C]//Proceedings of the 2016 Conference of the North American Chapter of the Association for Computational Linguistics: Human Language Technologies. San Diego, California: Association for Computational Linguistics, 2016: 1384-1394. DOI:10.18653/v1/N16-1164.

[11] POTASH P, ROMANOV A, RUMSHISKY A. Here's My Point: Joint Pointer Architecture for Argument Mining[C]//Proceedings of the 2017 Conference on Empirical Methods in Natural Language Processing. Copenhagen, Denmark: Association for Computational Linguistics, 2017: 1364-1373. DOI:10.18653/v1/D17-1143.

[12] NICULAE V, PARK J, CARDIE C. Argument mining with structured SVMs and RNNs[C]//Proceedings of the 55th Annual Meeting of the Association for Computational Linguistics, Volume 1. Vancouver: Association for Computational Linguistics, 2017: 985–995. DOI: 10.18653/v1/P17-1091.

[13] MORIO G, OZAKI H, MORISHITA T, et al. Towards better non-tree argument mining: Proposition-level biaffine parsing with task-specific parameterization[C]//Proceedings of the 58th Annual Meeting of the Association for Computational Linguistics. Association for Computational Linguistics, 2020: 3259–3266. DOI: 10.18653/v1/2020.acl-main.298.

[14] BAO J, HE Y, SUN Y, et al. A generative model for end-to-end argument mining with reconstructed positional encoding and constrained pointer mechanism[C]//Proceedings of the 2022 Conference on Empirical Methods in Natural Language Processing. Abu Dhabi: Association for Computational Linguistics, 2022: 10437–10449. DOI: 10.18653/v1/2022.emnlp-main.713.

[15] BAO J, JING M, DONG K, et al. UniASA: A unified generative framework for argument structure analysis[J]. Computational Linguistics, 2025, 51(3): 739–784. DOI: 10.1162/coli_a_00553.

[16] DAS N, VAIBHAV V, CHOUDHARY Y S, et al. End-to-end argument mining through autoregressive argumentative structure prediction[EB/OL]. arXiv:2510.16363v1, 2025[2026-09-14]. DOI: 10.48550/arXiv.2510.16363.

[17] CABESSA J, HERNAULT H, MUSHTAQ U. Argument mining with fine-tuned large language models[C]//Proceedings of the 31st International Conference on Computational Linguistics. Abu Dhabi: Association for Computational Linguistics, 2025: 6624–6635.

[18] CAPUTO E, GRECO S, LA CAVA L. ARGUS: Towards end-to-end argument mining with large language models[C]//Proceedings of the AAAI Conference on Artificial Intelligence, 2026, 40(48): 41547–41549. DOI: 10.1609/aaai.v40i48.42335.

[19] LI H, SCHLEGEL V, SUN Y, et al. Large language models in argument mining: A survey[EB/OL]. arXiv:2506.16383v6, 2025[2026-09-13]. DOI: 10.48550/arXiv.2506.16383.

[20] SUN Y, CHEN G, YANG C, et al. Discourse structure-aware prefix for generation-based end-to-end argumentation mining[C]//Findings of the Association for Computational Linguistics: ACL 2024. Bangkok: Association for Computational Linguistics, 2024: 11597–11613. DOI: 10.18653/v1/2024.findings-acl.689.

[21] DAS N, SARADHI V V, ANAND A. On the role of key phrases in argument mining[C]//Findings of the Association for Computational Linguistics: NAACL 2025. Albuquerque: Association for Computational Linguistics, 2025: 5774–5787. DOI: 10.18653/v1/2025.findings-naacl.319.

[22] SUN Y, CHEN G, ALINEJAD-ROKNY H, et al. Learning first-order logic rules for argumentation mining[C]//Proceedings of the 63rd Annual Meeting of the Association for Computational Linguistics, Volume 1. Vienna: Association for Computational Linguistics, 2025: 14133–14148. DOI: 10.18653/v1/2025.acl-long.691.

[23] MORIO G, OZAKI H, MORISHITA T, et al. End-to-end argument mining with cross-corpora multi-task learning[J]. Transactions of the Association for Computational Linguistics, 2022, 10: 639–658. DOI: 10.1162/tacl_a_00481.

[24] SAVIGNY H, YUN B. AMELIA: A family of multi-task end-to-end language models for argumentation[J]. Argument & Computation, 2026, 17(1). DOI: 10.1177/19462174251413169.

[25] FEGER M, BOLAND K, DIETZE S. Limited generalizability in argument mining: State-of-the-art models learn datasets, not arguments[C]//Proceedings of the 63rd Annual Meeting of the Association for Computational Linguistics, Volume 1. Vienna: Association for Computational Linguistics, 2025: 23900–23915. DOI: 10.18653/v1/2025.acl-long.1164.

[26] PARK J, CARDIE C. A corpus of eRulemaking user comments for measuring evaluability of arguments[C]//Proceedings of the Eleventh International Conference on Language Resources and Evaluation. Miyazaki: European Language Resources Association, 2018.

[27] ZHAO X, WANG K, PENG W. ORCHID: A Chinese debate corpus for target-independent stance detection and argumentative dialogue summarization[C]//Proceedings of the 2023 Conference on Empirical Methods in Natural Language Processing. Singapore: Association for Computational Linguistics, 2023: 9358–9375. DOI: 10.18653/v1/2023.emnlp-main.582.

[28] CHENG L, BING L, HE R, et al. IAM: A comprehensive and large-scale dataset for integrated argument mining tasks[C]//Proceedings of the 60th Annual Meeting of the Association for Computational Linguistics, Volume 1. Dublin: Association for Computational Linguistics, 2022: 2277–2287. DOI: 10.18653/v1/2022.acl-long.162.

[29] STAB C, MILLER T, SCHILLER B, et al. Cross-topic Argument Mining from Heterogeneous Sources[C]//Proceedings of the 2018 Conference on Empirical Methods in Natural Language Processing. Brussels, Belgium: Association for Computational Linguistics, 2018: 3664-3674. DOI:10.18653/v1/D18-1402.

[30] 言佳润, 鲜于波. 面向中文网络对话文本的论辩挖掘——基于微调与提示学习的大模型算法[J]. 中文信息学报, 2023, 37(10): 139-148.

[31] 张霄军, 周静狮. 中英双语政治论辩挖掘任务数据集建设[J]. 中文信息学报, 2023, 37(10): 167-174. DOI:10.3969/j.issn.1003-0077.2023.10.019.

[32] CAPUTO E, GRECO S, LA CAVA L. Argument component segmentation with fine-tuned large language models[C]//Findings of the Association for Computational Linguistics: EACL 2026. Rabat: Association for Computational Linguistics, 2026: 5154–5167. DOI: 10.18653/v1/2026.findings-eacl.272.

[33] EVURU C K, GHOSH S, KUMAR S, et al. CoDa: Constrained generation based data augmentation for low-resource NLP[C]//Findings of the Association for Computational Linguistics: NAACL 2024. Mexico City: Association for Computational Linguistics, 2024: 3754–3769. DOI: 10.18653/v1/2024.findings-naacl.238.

[34] PEI Y, BHUSE P, LIU Z, et al. SegMix: A simple structure-aware data augmentation method[EB/OL]. arXiv:2311.09505v1, 2023[2026-09-13]. DOI: 10.48550/arXiv.2311.09505.

[35] WEI J, ZOU K. EDA: Easy Data Augmentation Techniques for Boosting Performance on Text Classification Tasks[C]//Proceedings of the 2019 Conference on Empirical Methods in Natural Language Processing and the 9th International Joint Conference on Natural Language Processing (EMNLP-IJCNLP). Hong Kong, China: Association for Computational Linguistics, 2019: 6382-6388. DOI:10.18653/v1/D19-1670.

[36] SENNRICH R, HADDOW B, BIRCH A. Improving Neural Machine Translation Models with Monolingual Data[C]//Proceedings of the 54th Annual Meeting of the Association for Computational Linguistics (Volume 1: Long Papers). Berlin, Germany: Association for Computational Linguistics, 2016: 86-96. DOI:10.18653/v1/P16-1009.

[37] KOBAYASHI S. Contextual Augmentation: Data Augmentation by Words with Paradigmatic Relations[C]//Proceedings of the 2018 Conference of the North American Chapter of the Association for Computational Linguistics: Human Language Technologies, Volume 2 (Short Papers). New Orleans, Louisiana: Association for Computational Linguistics, 2018: 452-457. DOI:10.18653/v1/N18-2072.

[38] FENG S Y, GANGAL V, WEI J, et al. A Survey of Data Augmentation Approaches for NLP[C]//Findings of the Association for Computational Linguistics: ACL-IJCNLP 2021. Online: Association for Computational Linguistics, 2021: 968-988. DOI:10.18653/v1/2021.findings-acl.84.

[39] 冯冉, 陈丹蕾, 化柏林. 文本数据的增强方法研究综述[J]. 数据分析与知识发现, 2025, 9(5): 19-32. DOI:10.11925/infotech.2096-3467.2024.0533.

[40] ZHANG Z, WANG Q, DING K, et al. Improving synthetic data generation for argument mining via adversarial reinforcement learning[EB/OL]. arXiv:2610.07699v1, 2026[2026-10-06]. DOI: 10.48550/arXiv.2610.07699.

[41] ZHENG Y, KE W, LIU Q, et al. Making LLMs as fine-grained relation extraction data augmentor[C]//Proceedings of the Thirty-Third International Joint Conference on Artificial Intelligence. International Joint Conferences on Artificial Intelligence Organization, 2024: 6660–6668. DOI: 10.24963/ijcai.2024/736.

[42] MODARRESSI A, KÖKSAL A, SCHUETZE H. Consistent document-level relation extraction via counterfactuals[C]//Findings of the Association for Computational Linguistics: EMNLP 2024. Miami: Association for Computational Linguistics, 2024: 11501–11507. DOI: 10.18653/v1/2024.findings-emnlp.672.

[43] ZHONG Y, GAO Y, ZHANG X, et al. ODDA: An OODA-driven diverse data augmentation framework for low-resource relation extraction[C]//Findings of the Association for Computational Linguistics: ACL 2025. Vienna: Association for Computational Linguistics, 2025: 267–285. DOI: 10.18653/v1/2025.findings-acl.15.

[44] WANG X, SHEN H, QI H, et al. Enhancing low-resource joint entity and relation extraction using large language models within semi-supervised learning[J]. ACM Transactions on Knowledge Discovery from Data, 2026, 20(3): 49:1–49:25. DOI: 10.1145/3799423.

[45] 夏振涛, 曲维光, 顾彦慧, 等. 基于深度学习的实体关系抽取研究综述[C]//第十九届中国计算语言学大会论文集. 海口: 中国中文信息学会, 2020: 349-362.

[46] ROCHA G, LOPES CARDOSO H, BELOUADI J, et al. Cross-genre argument mining: Can language models automatically fill in missing discourse markers? [J]. Argument & Computation, 2025, 16(1): 3–35. DOI: 10.3233/AAC-230008.

[47] SUN W, LI M, DAVIS J, et al. Weakly-supervised argument mining with boundary refinement and relation denoising[C]//Proceedings of the Ninth Fact Extraction and VERification Workshop (FEVER). Rabat: Association for Computational Linguistics, 2026: 1–12. DOI: 10.18653/v1/2026.fever-1.1.

[48] GENG S, JOSIFOSKI M, PEYRARD M, et al. Grammar-constrained decoding for structured NLP tasks without finetuning[C]//Proceedings of the 2023 Conference on Empirical Methods in Natural Language Processing. Singapore: Association for Computational Linguistics, 2023: 10932–10952. DOI: 10.18653/v1/2023.emnlp-main.674.

[49] MADAAN A, TANDON N, GUPTA P, et al. Self-Refine: Iterative refinement with self-feedback[EB/OL]. arXiv:2303.17651v2, 2023[2026-09-13]. DOI: 10.48550/arXiv.2303.17651.

[50] WANG X, WEI J, SCHUURMANS D, et al. Self-consistency improves chain of thought reasoning in language models[EB/OL]. arXiv:2203.11171v4, 2023[2026-09-13]. DOI: 10.48550/arXiv.2203.11171.

[51] HUANG J, CHEN X, MISHRA S, et al. Large language models cannot self-correct reasoning yet[EB/OL]. arXiv:2310.01798v2, 2024[2026-09-13]. DOI: 10.48550/arXiv.2310.01798.

[52] TRAN N, LITMAN D, GODLEY A. Using large language models to analyze students' collaborative argumentation in classroom discussions[C]//Proceedings of the Artificial Intelligence in Measurement and Education Conference (AIME-Con): Full Papers. Pittsburgh: National Council on Measurement in Education, 2025: 111–125.

[53] LI Z, ZHANG F, LYU K, et al. Re-Cent: A relation-centric framework for joint zero-shot relation triplet extraction[C]//Proceedings of the 31st International Conference on Computational Linguistics. Abu Dhabi: Association for Computational Linguistics, 2025: 7344–7354.

[54] PIROZELLI P, ROCHA V H N, COZMAN F G, et al. An LLM-based system for argument reconstruction[EB/OL]. arXiv:2605.13793v1, 2026[2026-09-20]. DOI: 10.48550/arXiv.2605.13793.

[55] XIAO Y, LI S. ARGUS: Argumentation-based minimal-change repair for verifiable LLM self-explanations[C]//Proceedings of the 42nd Conference on Uncertainty in Artificial Intelligence. Proceedings of Machine Learning Research, 2026, 337: 7536–7551.

[56] TANG C, PENG M, TIAN G. Improving end-to-end argument mining with LLMs via multi-candidate reranking and bounded repair[C/OL]//ICIC2026 Posters: Poster Volume I. Toronto, 2026[2026-09-20]. DOI: 10.65286/icic.v22i1.76896.

[57] WAEGEMAN W, DEMBCZYŃSKI K, JACHNIK A, et al. On the Bayes-optimality of F-measure maximizers[J]. Journal of Machine Learning Research, 2014, 15(103): 3513–3568.

[58] LIPTON Z C, ELKAN C, NARAYANASWAMY B. Thresholding classifiers to maximize F1 score[EB/OL]. arXiv:1402.1892v2, 2014[2026-09-20]. DOI: 10.48550/arXiv.1402.1892.

[59] GUO C, PLEISS G, SUN Y, et al. On calibration of modern neural networks[C]//Proceedings of the 34th International Conference on Machine Learning. Proceedings of Machine Learning Research, 2017, 70: 1321–1330.

[60] HU E J, SHEN Y, WALLIS P, et al. LoRA: Low-rank adaptation of large language models[EB/OL]. arXiv:2106.09685, 2021[2026-09-13]. DOI: 10.48550/arXiv.2106.09685.

[61] EFRON B. Bootstrap methods: Another look at the jackknife[J]. The Annals of Statistics, 1979, 7(1): 1–26. DOI: 10.1214/aos/1176344552.

[62] HOLM S. A simple sequentially rejective multiple test procedure[J]. Scandinavian Journal of Statistics, 1979, 6(2): 65–70. DOI: 10.2307/4615733.

[63] LESTER B, AL-RFOU R, CONSTANT N. The power of scale for parameter-efficient prompt tuning[C]//Proceedings of the 2021 Conference on Empirical Methods in Natural Language Processing. Association for Computational Linguistics, 2021: 3045–3059. DOI: 10.18653/v1/2021.emnlp-main.243.

[64] VASWANI A, SHAZEER N, PARMAR N, et al. Attention is all you need[EB/OL]. arXiv:1706.03762, 2017[2026-09-13]. DOI: 10.48550/arXiv.1706.03762.

[65] DEVLIN J, CHANG M W, LEE K, et al. BERT: Pre-training of Deep Bidirectional Transformers for Language Understanding[C]//Proceedings of the 2019 Conference of the North American Chapter of the Association for Computational Linguistics: Human Language Technologies, Volume 1 (Long and Short Papers). Minneapolis, Minnesota: Association for Computational Linguistics, 2019: 4171-4186. DOI:10.18653/v1/N19-1423.

[66] LEWIS M, LIU Y, GOYAL N, et al. BART: Denoising Sequence-to-Sequence Pre-training for Natural Language Generation, Translation, and Comprehension[C]//Proceedings of the 58th Annual Meeting of the Association for Computational Linguistics. Online: Association for Computational Linguistics, 2020: 7871-7880. DOI:10.18653/v1/2020.acl-main.703.

[67] RAFFEL C, SHAZEER N, ROBERTS A, et al. Exploring the limits of transfer learning with a unified text-to-text Transformer[EB/OL]. arXiv:1910.10683, 2019[2026-10-15]. DOI: 10.48550/arXiv.1910.10683.

[68] HOULSBY N, GIURGIU A, JASTRZEBSKI S, et al. Parameter-efficient transfer learning for NLP[EB/OL]. arXiv:1902.00751, 2019[2026-10-15]. DOI: 10.48550/arXiv.1902.00751.

[69] LI X L, LIANG P. Prefix-Tuning: Optimizing Continuous Prompts for Generation[C]//Proceedings of the 59th Annual Meeting of the Association for Computational Linguistics and the 11th International Joint Conference on Natural Language Processing (Volume 1: Long Papers). Online: Association for Computational Linguistics, 2021: 4582-4597. DOI:10.18653/v1/2021.acl-long.353.

[70] DETTMERS T, PAGNONI A, HOLTZMAN A, et al. QLoRA: Efficient finetuning of quantized LLMs[EB/OL]. arXiv:2305.14314, 2023[2026-10-15]. DOI: 10.48550/arXiv.2305.14314.

[71] 唐岸达, 林宙辰. 大模型参数高效微调方法综述: 技术、趋势与挑战[J]. 自动化学报, 2026, 52(8): 1520-1556. DOI:10.16383/j.aas.c250451.

[72] LAINE S, AILA T. Temporal ensembling for semi-supervised learning[EB/OL]. arXiv:1610.02242, 2016[2026-10-15]. DOI: 10.48550/arXiv.1610.02242.

[73] TARVAINEN A, VALPOLA H. Mean teachers are better role models: Weight-averaged consistency targets improve semi-supervised deep learning results[EB/OL]. arXiv:1703.01780, 2017[2026-10-15]. DOI: 10.48550/arXiv.1703.01780.

[74] MIYATO T, MAEDA S, KOYAMA M, et al. Virtual adversarial training: A regularization method for supervised and semi-supervised learning[EB/OL]. arXiv:1704.03976, 2017[2026-10-15]. DOI: 10.48550/arXiv.1704.03976.

[75] XIE Q, DAI Z, HOVY E, et al. Unsupervised data augmentation for consistency training[EB/OL]. arXiv:1904.12848, 2019[2026-10-15]. DOI: 10.48550/arXiv.1904.12848.

[76] LIANG X, WU L, LI J, et al. R-Drop: Regularized dropout for neural networks[EB/OL]. arXiv:2106.14448, 2021[2026-10-15]. DOI: 10.48550/arXiv.2106.14448.

[77] SOHN K, BERTHELOT D, LI C, et al. FixMatch: Simplifying semi-supervised learning with consistency and confidence[EB/OL]. arXiv:2001.07685, 2020[2026-10-15]. DOI: 10.48550/arXiv.2001.07685.

[78] LIN J. Divergence measures based on the Shannon entropy[J]. IEEE Transactions on Information Theory, 1991, 37(1): 145–151. DOI: 10.1109/18.61115.

[79] ROTH D, YIH W T. A Linear Programming Formulation for Global Inference in Natural Language Tasks[C]//Proceedings of the Eighth Conference on Computational Natural Language Learning (CoNLL-2004) at HLT-NAACL 2004. Boston, Massachusetts, USA: Association for Computational Linguistics, 2004: 1-8.

[80] QWEN TEAM. Qwen3.5-9B: official model card and configuration[EB/OL]. 2026[2026-10-13]. https://huggingface.co/Qwen/Qwen3.5-9B.

[81] HUGGING FACE. Transformers v5.8.0: Qwen3.5 model implementation[CP/OL]. 2026[2026-10-13]. https://github.com/huggingface/transformers/tree/v5.8.0/src/transformers/models/qwen3_5.

[82] HOLTZMAN A, BUYS J, DU L, et al. The curious case of neural text degeneration[EB/OL]. arXiv:1904.09751, 2019[2026-10-15]. DOI: 10.48550/arXiv.1904.09751.

[83] QWEN TEAM. Qwen3.5-4B: official model card and configuration[EB/OL]. 2026[2026-10-13]. https://huggingface.co/Qwen/Qwen3.5-4B.

[84] QWEN TEAM. Qwen2.5 technical report[EB/OL]. arXiv:2412.15115, 2024[2026-09-13]. DOI: 10.48550/arXiv.2412.15115.

[85] QWEN TEAM. Qwen2.5-7B-Instruct: official model card and configuration[EB/OL]. 2024[2026-10-13]. https://huggingface.co/Qwen/Qwen2.5-7B-Instruct.

[86] LOSHCHILOV I, HUTTER F. Decoupled weight decay regularization[EB/OL]. arXiv:1711.05101, 2017[2026-10-15]. DOI: 10.48550/arXiv.1711.05101.

[87] ZHAO Y, GU A, VARMA R, et al. PyTorch FSDP: Experiences on scaling fully sharded data parallel[EB/OL]. arXiv:2304.11277, 2023[2026-10-15]. DOI: 10.48550/arXiv.2304.11277.

[88] PENG B, QUESNELLE J, FAN H, et al. YaRN: Efficient context window extension of large language models[EB/OL]. arXiv:2309.00071, 2023[2026-10-15]. DOI: 10.48550/arXiv.2309.00071.

[89] HENDRYCKS D, GIMPEL K. Gaussian error linear units (GELUs)[EB/OL]. arXiv:1606.08415, 2016[2026-10-15]. DOI: 10.48550/arXiv.1606.08415.

[90] PASZKE A, GROSS S, MASSA F, et al. PyTorch: An imperative style, high-performance deep learning library[EB/OL]. arXiv:1912.01703, 2019[2026-10-15]. DOI: 10.48550/arXiv.1912.01703.

[91] MANGRULKAR S, GUGGER S, DEBUT L, et al. PEFT: State-of-the-art parameter-efficient fine-tuning methods[CP/OL]. (2022)[2026-10-15]. https://github.com/huggingface/peft/tree/v0.17.1.

[92] HUANGFU Q, HALL J A J. Parallelizing the dual revised simplex method[J]. Mathematical Programming Computation, 2018, 10(1): 119–142. DOI: 10.1007/s12532-017-0130-5.

[93] HARRIS C R, MILLMAN K J, VAN DER WALT S J, et al. Array programming with NumPy[J]. Nature, 2020, 585: 357-362. DOI:10.1038/s41586-020-2649-2.

[94] WILSON E B. Probable inference, the law of succession, and statistical inference[J]. Journal of the American Statistical Association, 1927, 22(158): 209–212. DOI: 10.1080/01621459.1927.10502953.

[95] COHEN J. A coefficient of agreement for nominal scales[J]. Educational and Psychological Measurement, 1960, 20(1): 37–46. DOI: 10.1177/001316446002000104.

[96] PLATT J C. Probabilities for SV machines[M]//SMOLA A J, BARTLETT P L, SCHÖLKOPF B, et al. Advances in Large-Margin Classifiers. Cambridge, MA: MIT Press, 2000: 61–74. DOI: 10.7551/mitpress/1113.003.0008.

[97] AINSLIE J, LEE-THORP J, DE JONG M, et al. GQA: Training Generalized Multi-Query Transformer Models from Multi-Head Checkpoints[C]//Proceedings of the 2023 Conference on Empirical Methods in Natural Language Processing. Singapore: Association for Computational Linguistics, 2023: 4895-4901. DOI:10.18653/v1/2023.emnlp-main.298.

[98] GRAVES A, SCHMIDHUBER J. Framewise phoneme classification with bidirectional LSTM and other neural network architectures[J]. Neural Networks, 2005, 18(5-6): 602-610. DOI:10.1016/j.neunet.2005.06.042.

[99] BELTAGY I, PETERS M E, COHAN A. Longformer: The long-document Transformer[EB/OL]. arXiv:2004.05150, 2020[2026-10-15]. DOI: 10.48550/arXiv.2004.05150.

[100] CHUNG H W, HOU L, LONGPRE S, et al. Scaling instruction-finetuned language models[EB/OL]. arXiv:2210.11416, 2022[2026-10-15]. DOI: 10.48550/arXiv.2210.11416.

[101] GUO M, AINSLIE J, UTHUS D, et al. LongT5: Efficient text-to-text Transformer for long sequences[EB/OL]. arXiv:2112.07916, 2021[2026-10-15]. DOI: 10.48550/arXiv.2112.07916.

[102] GRATTAFIORI A, DUBEY A, JAUHRI A, et al. The Llama 3 herd of models[EB/OL]. arXiv:2407.21783, 2024[2026-10-15]. DOI: 10.48550/arXiv.2407.21783.

致谢

（盲审版本不含致谢内容。）

附录 A 个人简历

（盲审版本隐去）

附录 B 在学期间参与的科研项目

（盲审版本隐去）

附录 C 在学期间取得的学术成果

（盲审版本隐去学术成果及作者身份关联信息。）